Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase 0 · Preliminares matemáticos

Módulo 0.9

Estadística

Apuntes del curso

Edición de octubre de 2026

Presentación del módulo

La probabilidad parte de un modelo conocido y calcula qué datos cabe esperar; la estadística recorre el camino inverso: parte de unos datos observados y extrae conclusiones sobre el modelo que los ha generado. Entrenar un modelo de lenguaje es un problema de estimación (se buscan los parámetros que hacen más verosímil el corpus), y evaluarlo es un problema de inferencia (se mide la exactitud en un conjunto finito de preguntas y se quiere saber cuánto se parece esa cifra a la exactitud real y si la diferencia con otro modelo es auténtica o fruto del azar). Este módulo, el último de la fase de preliminares, presenta las herramientas básicas de la estadística con el nivel y la organización de un primer curso universitario, y ofrece una colección amplia de ejercicios numéricos y de demostración.

Objetivos

Al finalizar el módulo, el estudiante debe ser capaz de:

1. resumir un conjunto de datos con medidas de centralización, posición y dispersión, construir histogramas y diagramas de caja, y calcular e interpretar la covarianza y el coeficiente de correlación;
2. definir estimador, sesgo, varianza, error estándar, error cuadrático medio y consistencia, y demostrar que la media muestral y la varianza muestral con denominador $n-1$ son estimadores insesgados;
3. enunciar el teorema central del límite y aplicarlo a medias, sumas y proporciones, incluida la aproximación normal a la binomial;
4. obtener estimadores por el método de los momentos y por máxima verosimilitud para los modelos de Bernoulli, Poisson, normal y exponencial, y construir intervalos de confianza para medias y proporciones, así como calcular el tamaño muestral necesario;
5. plantear y resolver contrastes de hipótesis (z, t y χ^2 de bondad de ajuste), interpretar el p-valor, los errores de tipo I y II y la potencia, y corregir por comparaciones múltiples;
6. deducir la recta de mínimos cuadrados, interpretar R^2 y los residuos, y distinguir correlación de causalidad.

Requisitos previos

Matemáticas de bachillerato y los módulos anteriores de esta fase, en especial el módulo 0.8 (combinatoria y probabilidad), cuya notación se mantiene: $\mathbb{P}$ para la probabilidad, $\mathbb{E}$ para la esperanza y Var para la varianza. Se usan además derivadas e integrales de una variable (módulos 0.5 y 0.6) y derivadas parciales (módulo 0.7). Al comienzo del tema 2 se recuerdan las propiedades de la esperanza y la varianza que se emplean.

Organización

Tema	Contenido	Fuentes principales
1	Estadística descriptiva	[2], [4], [3]
2	Muestreo y estimadores	[6], [1], [5]
3	Distribuciones muestrales y teorema central del límite	[1], [3], [2]
4	Estimación puntual e intervalos de confianza	[3], [6], [5]
5	Contrastes de hipótesis	[3], [6], [5]
6	Regresión lineal simple y correlación	[2], [4], [6]

Cada tema termina con una lista de lecturas y con una colección extensa de ejercicios graduados en tres niveles: $\star$ comprensión, $\star\star$ cálculo o práctica mecánica y $\star\star\star$ demostración. Los ejercicios marcados con *Fuente* están adaptados de cursos y libros de texto universitarios; el enunciado se ha redactado de nuevo y, en algunos casos, se han cambiado los datos. Las soluciones completas, paso a paso, están en el apéndice A, y las tablas de la distribución normal, de la t de Student y de la χ^2 que se necesitan para resolver los ejercicios a mano están en el apéndice B.

Dónde se usa en el curso

Concepto	Módulos del curso que lo emplean
Media, varianza y tipificación	M05 (momentos), M11 (normalización por capas y RMSNorm), M07 (medias exponenciales de Adam).
Estimador, sesgo, varianza, ECM	M05 (estimación de parámetros), M08 (descomposición sesgo–varianza), M22 y M23 (estimador insesgado de pass@k).
Máxima verosimilitud	M01 (EMV de los bigramas), M05 (EMV de la normal), M08 (mínimos cuadrados y regresión logística como EMV).
Teorema central del límite, error estándar	M05 (Monte Carlo), M07 (ruido del gradiente con minilotes), M22 y M23 (error estándar de una exactitud).
Intervalos de confianza	M05 (comparación de modelos), M16 (ajuste de leyes de escala), M22 y M23 (intervalos para benchmarks, regla del 3).
Contrastes y comparaciones múltiples	M22 y M23 (comparar modelos en muchos benchmarks), M21 (evaluaciones por preferencias).
Regresión lineal y R^2	M08 (ecuaciones normales), M16 (ajuste log-log de leyes de potencia), M23 (sondas lineales).
Correlación frente a causalidad	M23 (intervenciones causales frente a correlaciones en la interpretabilidad).

Sobre las fuentes

El texto es de redacción propia. La estadística descriptiva sigue el capítulo 2 de *Introductory Statistics* de OpenStax [2] y el capítulo 10 de Rice [4]. La teoría de estimadores, máxima verosimilitud, contrastes y regresión sigue los capítulos 6, 9, 10 y 13 de Wasserman [6], las lecturas del curso 18.05 del MIT de Orloff y Bloom [3] y las clases del curso Stats 200 de Stanford [5]. Los resultados de probabilidad (momentos muestrales, teorema central del límite, distribuciones χ^2 y t) siguen los capítulos 6, 7 y 10 de Blitzstein y Hwang [1], texto del curso Stat 110 de Harvard.

Notación

Símbolo	Significado
$x_1, \ldots, x_n$; $x_{(1)} \leq \cdots \leq x_{(n)}$	datos observados y datos ordenados
$\bar{x}$, s^2, s	media, varianza y desviación típica muestrales (observadas)
$X_1, \ldots, X_n$ i.i.d.	muestra aleatoria simple (variables independientes e idénticamente distribuidas)
$\overline{X}$, S^2	media y varianza muestrales como variables aleatorias
μ, σ^2, p, λ, θ	parámetros de la población
$\widehat{\theta}$	estimador (o estimación) de θ
$\mathbb{P}$, $\mathbb{E}$, Var, Cov	probabilidad, esperanza, varianza y covarianza
$\mathcal{N}(\mu, \sigma^2)$, Φ	distribución normal y función de distribución de la normal estándar
Ber(p), Bin(n, p), Pois(λ), Exp(λ)	Bernoulli, binomial, Poisson y exponencial de tasa λ
z_q, $t_{k;q}$, $\chi^2_{k;q}$	cuantiles de orden q de $\mathcal{N}(0,1)$, de t_k y de χ^2_k
H_0, H_1, α, β	hipótesis nula y alternativa, nivel de significación y probabilidad de error de tipo II
ee($\widehat{\theta}$), ECM($\widehat{\theta}$)	error estándar y error cuadrático medio
$\xrightarrow{\mathbb{P}}$	convergencia en probabilidad

Los cuantiles se escriben siempre por su probabilidad acumulada: $z_{0{,}975} = 1{,}96$ es el valor que deja a su izquierda una probabilidad 0,975.

Índice

Presentación del módulo **ii**

1 Estadística descriptiva **1**

1.1 Datos, población y muestra . . . 1
1.2 Medidas de centralización . . . 1
1.3 Medidas de posición: cuantiles y diagrama de caja . . . 2
1.4 Medidas de dispersión . . . 3
1.5 Datos bivariantes: covarianza y correlación . . . 4
Ejercicios del tema 1 . . . 6

2 Muestreo y estimadores **8**

2.1 Recordatorio: esperanza y varianza . . . 8
2.2 Muestra aleatoria, parámetro y estadístico . . . 9
2.3 Estimadores y sus propiedades . . . 9
2.4 La media muestral . . . 10
2.5 La varianza muestral . . . 10
2.6 Consistencia y ley de los grandes números . . . 11
Ejercicios del tema 2 . . . 12

3 Distribuciones muestrales y teorema central del límite **15**

3.1 La distribución normal . . . 15
3.2 El teorema central del límite . . . 16
3.3 Aproximación normal a la binomial . . . 16
3.4 Distribuciones χ^2 y t de Student . . . 17
Ejercicios del tema 3 . . . 18

4 Estimación puntual e intervalos de confianza **21**

4.1 El método de los momentos . . . 21
4.2 Máxima verosimilitud . . . 22
4.3 Intervalos de confianza . . . 23
4.4 Intervalo para la media con σ desconocida . . . 24
4.5 Intervalos para proporciones . . . 24
Ejercicios del tema 4 . . . 26

5 Contrastes de hipótesis **28**
5.1 Planteamiento de un contraste . . . 28
5.2 El p-valor . . . 29
5.3 Contrastes z y t . . . 29
5.4 Potencia y tamaño muestral . . . 30
5.5 Contraste χ^2 de bondad de ajuste . . . 30
5.6 Comparaciones múltiples . . . 31
Ejercicios del tema 5 . . . 32

6 Regresión lineal simple y correlación **35**
6.1 La recta de mínimos cuadrados . . . 35
6.2 Residuos y coeficiente de determinación . . . 36
6.3 Diagnóstico con residuos . . . 37
6.4 Transformaciones: ajuste de leyes de potencia . . . 37
6.5 Correlación y causalidad . . . 38
Ejercicios del tema 6 . . . 39

A Soluciones de los ejercicios **41**
A.1 Tema 1 . . . 41
A.2 Tema 2 . . . 47
A.3 Tema 3 . . . 53
A.4 Tema 4 . . . 58
A.5 Tema 5 . . . 63
A.6 Tema 6 . . . 69

B Tablas estadísticas **76**
B.1 Distribución normal estándar . . . 76
B.2 Distribución t de Student . . . 77
B.3 Distribución χ^2 . . . 77

Bibliografía **80**

Tema 1

Estadística descriptiva

Antes de construir modelos conviene mirar los datos: resumirlos con unos pocos números y dibujarlos. Este tema presenta las medidas de centralización (media, mediana), de posición (cuantiles y cuartiles), de dispersión (rango, recorrido intercuartílico, varianza y desviación típica), las representaciones gráficas básicas (histograma y diagrama de caja) y las medidas de relación entre dos variables (covarianza y correlación). Se sigue el capítulo 2 de *Introductory Statistics* de OpenStax [2] (§2.2 a §2.7), el capítulo 10 de Rice [4], «Summarizing Data», y, para la covarianza y la correlación, la lectura 7b del curso 18.05 del MIT [3] y la §7.3 de Blitzstein y Hwang [1].

1.1 Datos, población y muestra

Definición 1.1 (Población, muestra y variable). La *población* es el conjunto de todos los individuos u objetos sobre los que se quiere obtener información; una *muestra* es un subconjunto de la población que efectivamente se observa. Una *variable* es una característica que se mide en cada individuo. La variable es *cuantitativa* si toma valores numéricos con los que tiene sentido operar (discreta si toma valores aislados, como un número de errores; continua si puede tomar cualquier valor de un intervalo, como un tiempo) y *cualitativa* o *categórica* si toma valores en un conjunto de categorías.

Un conjunto de datos cuantitativos es una lista $x_1, \dots, x_n$ de números reales, donde n es el *tamaño* de la muestra. Los mismos datos ordenados de menor a mayor se escriben $x_{(1)} \le x_{(2)} \le \cdots \le x_{(n)}$; $x_{(1)}$ es el mínimo y $x_{(n)}$, el máximo. En este tema los datos son números fijos y las definiciones son puramente descriptivas; a partir del tema 2 se interpretarán como valores observados de variables aleatorias.

Ejemplo 1.2 (Datos de referencia). Se miden las longitudes, en tokens, de ocho respuestas de un modelo de lenguaje:

$$12, \quad 15, \quad 11, \quad 18, \quad 14, \quad 40, \quad 13, \quad 16.$$

Ordenados: $11, 12, 13, 14, 15, 16, 18, 40$. Este conjunto se usará como ejemplo a lo largo del tema; el valor 40 es claramente mayor que los demás.

1.2 Medidas de centralización

Definición 1.3 (Media, mediana y moda). Sean $x_1, \dots, x_n$ datos reales.

(i) La *media* (aritmética) es $\bar{x} = \dfrac{1}{n} \displaystyle\sum_{i=1}^{n} x_i$.

(ii) La *mediana* es el valor central de los datos ordenados: $x_{((n+1)/2)}$ si n es impar, y $\frac{1}{2}\big(x_{(n/2)}+x_{(n/2+1)}\big)$ si n es par.

(iii) La *moda* es el valor que aparece con mayor frecuencia (puede no ser única).

Ejemplo 1.4. En el ejemplo 1.2, $\sum x_i = 139$ y $\bar{x} = 139/8 = 17{,}375$. Como $n = 8$ es par, la mediana es la media de los valores cuarto y quinto ordenados: $(14+15)/2 = 14{,}5$. Si se elimina el valor 40, la media pasa a $99/7 \approx 14{,}14$ y la mediana a 14: la media se ha desplazado más de tres unidades y la mediana, media unidad.

El ejemplo ilustra que la media es *sensible a los valores atípicos* y la mediana es *robusta*. Cuando la distribución de los datos es asimétrica con cola larga a la derecha (como las longitudes de respuesta, los tiempos o los ingresos), la media suele ser mayor que la mediana [2, §2.6]. Las dos medidas tienen una caracterización variacional que explica ese comportamiento.

Proposición 1.5 (Propiedades extremales de la media y la mediana). *Sean $x_1, \dots, x_n$ datos reales.*

(i) $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$.

(ii) *Para todo $a \in \mathbb{R}$,* $\displaystyle\sum_{i=1}^{n}(x_i - a)^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2 + n(\bar{x} - a)^2$. *En consecuencia, la función $a \mapsto \sum_i (x_i - a)^2$ alcanza su mínimo únicamente en $a = \bar{x}$.*

(iii) *La función $a \mapsto \sum_i |x_i - a|$ alcanza su mínimo en la mediana.*

Demostración. (i) $\sum_i (x_i - \bar{x}) = \sum_i x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0$.

(ii) Se escribe $x_i - a = (x_i - \bar{x}) + (\bar{x} - a)$ y se desarrolla el cuadrado:

$$\sum_i (x_i - a)^2 = \sum_i (x_i - \bar{x})^2 + 2(\bar{x} - a)\sum_i (x_i - \bar{x}) + n(\bar{x} - a)^2.$$

El término central es nulo por (i). El último sumando es no negativo y solo se anula si $a = \bar{x}$.

(iii) Se demuestra en el ejercicio 1.11. ∎

1.3 Medidas de posición: cuantiles y diagrama de caja

La mediana divide los datos ordenados en dos mitades. Los cuartiles los dividen en cuatro partes. Hay varias convenciones para calcularlos que dan resultados ligeramente distintos con pocos datos (los programas estadísticos suelen interpolar); en este módulo se usa la siguiente, que es la de [2, §2.3] y la habitual en el cálculo a mano.

Definición 1.6 (Cuartiles y recorrido intercuartílico). Sean $x_{(1)} \le \cdots \le x_{(n)}$ los datos ordenados. La *mitad inferior* está formada por los $\lfloor n/2 \rfloor$ primeros datos y la *mitad superior*, por los $\lfloor n/2 \rfloor$ últimos (si n es impar, la mediana no pertenece a ninguna de las dos). El *primer cuartil* Q_1 es la mediana de la mitad inferior; el *segundo cuartil* Q_2 es la mediana; el *tercer cuartil* Q_3 es la mediana de la mitad superior. El *recorrido intercuartílico* es $\mathrm{RIC} = Q_3 - Q_1$ y el *rango* es $x_{(n)} - x_{(1)}$.

Más en general, el *cuantil* de orden $q \in (0, 1)$ (o *percentil* $100q$) es un valor que deja a su izquierda aproximadamente una fracción q de los datos; Q_1, Q_2 y Q_3 son los cuantiles de órdenes 0,25, 0,5 y 0,75.

Definición 1.7 (Resumen de cinco números y diagrama de caja). El *resumen de cinco números* es $(x_{(1)}, Q_1, Q_2, Q_3, x_{(n)})$. Un dato se considera *atípico* (criterio de Tukey) si está fuera del intervalo

$$\big[\, Q_1 - 1{,}5 \text{ RIC},\ Q_3 + 1{,}5 \text{ RIC} \,\big],$$

cuyos extremos se llaman *vallas*. El *diagrama de caja* dibuja una caja de Q_1 a Q_3 con una línea en la mediana y dos «bigotes» que llegan hasta el dato más extremo no atípico de cada lado; los atípicos se marcan por separado [2, §2.4].

Ejemplo 1.8. En el ejemplo 1.2, $n = 8$, la mitad inferior es $11, 12, 13, 14$ y la superior $15, 16, 18, 40$. Entonces $Q_1 = (12 + 13)/2 = 12{,}5$, $Q_2 = 14{,}5$, $Q_3 = (16 + 18)/2 = 17$ y $\text{RIC} = 4{,}5$. Las vallas son $12{,}5 - 6{,}75 = 5{,}75$ y $17 + 6{,}75 = 23{,}75$, de modo que 40 es atípico. El bigote superior llega hasta 18.

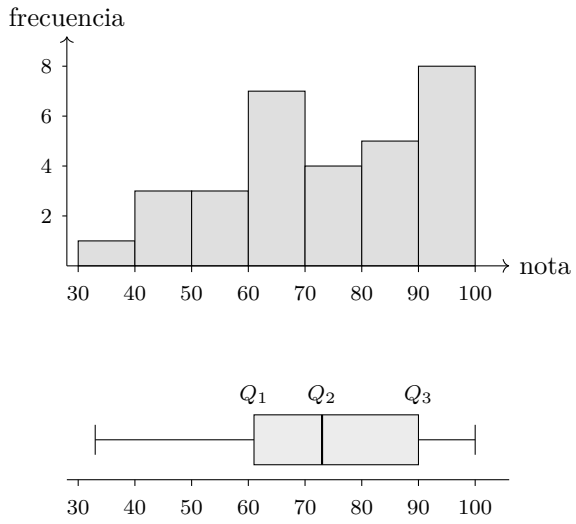


Figura 1.1: Histograma (clases de amplitud 10) y diagrama de caja de las 31 notas de examen del ejemplo 2.33 de [2]: mínimo 33, $Q_1 = 61$, mediana 73, $Q_3 = 90$, máximo 100. La cola izquierda más larga se aprecia en ambos gráficos.

Definición 1.9 (Histograma). Se divide un intervalo que contiene los datos en *clases* contiguas $[a_0, a_1), [a_1, a_2), \ldots, [a_{k-1}, a_k]$ y se cuenta la *frecuencia absoluta* f_j de datos en cada clase. El *histograma* dibuja sobre cada clase un rectángulo de altura proporcional a f_j (si las clases tienen igual amplitud) o a $f_j/(a_j - a_{j-1})$ (si no la tienen, de modo que el *área* sea proporcional a la frecuencia). La *frecuencia relativa* es f_j/n.

El histograma muestra la forma de la distribución (simetría, asimetría, número de modas), mientras que el diagrama de caja resume la posición y la dispersión y señala los atípicos; la figura 1.1 muestra ambos para un mismo conjunto de datos.

1.4 Medidas de dispersión

Definición 1.10 (Varianza y desviación típica muestrales). La *varianza muestral* de $x_1, \ldots, x_n$ $(n \geq 2)$ es

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2,$$

y la *desviación típica muestral* es $s = \sqrt{s^2}$. La cantidad $\sum_i (x_i - \bar{x})^2$ se llama *suma de cuadrados* de los datos.

Observación 1.11 (¿Por qué $n-1$?). El denominador $n-1$ en lugar de n tiene dos justificaciones. La primera es algebraica: las n desviaciones $x_i - \bar{x}$ suman cero (proposición 1.5), de modo que solo $n-1$ de ellas pueden elegirse libremente; se dice que la suma de cuadrados tiene $n-1$ *grados de libertad*. La segunda es estadística: si los datos son una muestra aleatoria de una población con varianza σ^2, la versión con $n-1$ acierta «en promedio», es decir, es un estimador insesgado de σ^2, mientras que la versión con n la subestima sistemáticamente. Esto se demuestra en el tema 2 (teorema 2.8). Con denominador n se obtiene la *varianza poblacional* de los propios datos, $\frac{1}{n}\sum_i (x_i - \bar{x})^2$, que es la que se usa cuando los datos *son* toda la población o cuando se normaliza un vector, como en la normalización por capas de una red (módulo 11).

Proposición 1.12 (Fórmula de cálculo). $\displaystyle\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2$, *y por tanto* $s^2 = \dfrac{\sum_i x_i^2 - n\bar{x}^2}{n-1}$.

Demostración. Es el caso $a = 0$ de la proposición 1.5(ii): $\sum_i x_i^2 = \sum_i (x_i - \bar{x})^2 + n\bar{x}^2$. ∎

Ejemplo 1.13. En el ejemplo 1.2, $\sum x_i^2 = 3035$ y $n\bar{x}^2 = 8 \cdot 17{,}375^2 = 2415{,}125$. La suma de cuadrados es $3035 - 2415{,}125 = 619{,}875$, de donde $s^2 = 619{,}875/7 \approx 88{,}55$ y $s \approx 9{,}41$. Sin el dato 40 se obtiene $s \approx 2{,}41$: la desviación típica, como la media, es muy sensible a los atípicos, mientras que el RIC apenas cambia (de 4,5 a 4).

Proposición 1.14 (Cambios de escala y de origen). *Si* $y_i = ax_i + b$ *con* $a, b \in \mathbb{R}$, *entonces* $\bar{y} = a\bar{x} + b$, $s_y^2 = a^2 s_x^2$ *y* $s_y = |a|\, s_x$. *Si* $a > 0$, *la mediana y los cuartiles se transforman igual que la media y* $\mathrm{RIC}_y = a\,\mathrm{RIC}_x$.

Demostración. $\bar{y} = \frac{1}{n}\sum_i (ax_i + b) = a\bar{x} + b$. Entonces $y_i - \bar{y} = a(x_i - \bar{x})$, y elevando al cuadrado y sumando, $\sum_i (y_i - \bar{y})^2 = a^2 \sum_i (x_i - \bar{x})^2$. Si $a > 0$, la transformación conserva el orden, luego transforma los datos ordenados en datos ordenados y las medianas de cualquier subconjunto se transforman por $t \mapsto at + b$. ∎

Definición 1.15 (Tipificación). Si $s > 0$, la *puntuación tipificada* (o puntuación z) del dato x_i es $z_i = (x_i - \bar{x})/s$. Por la proposición 1.14, los datos tipificados tienen media 0 y desviación típica 1; z_i mide a cuántas desviaciones típicas está x_i de la media.

1.5 Datos bivariantes: covarianza y correlación

Cuando en cada individuo se miden dos variables se obtienen pares $(x_1, y_1), \ldots, (x_n, y_n)$, que se representan en un *diagrama de dispersión*.

Definición 1.16 (Covarianza y correlación muestrales). La *covarianza muestral* y el *coeficiente de correlación* (de Pearson) son

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}), \qquad r = \frac{s_{xy}}{s_x\, s_y} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2}\,\sqrt{\sum_i (y_i - \bar{y})^2}},$$

donde se supone $s_x, s_y > 0$.

El signo de cada producto $(x_i-\bar{x})(y_i-\bar{y})$ es positivo cuando el punto está en el cuadrante superior derecho o inferior izquierdo respecto de $(\bar{x},\bar{y})$ y negativo en los otros dos; $s_{xy}>0$ indica que predominan los primeros, es decir, una tendencia creciente. La covarianza depende de las unidades; la correlación no (ejercicio 1.12).

Teorema 1.17 (Acotación de la correlación). *Se cumple $-1\le r\le 1$. Además, $|r|=1$ si y solo si existen $a\neq 0$ y b tales que $y_i=ax_i+b$ para todo i, y entonces el signo de r es el de a.*

Demostración. Sean $u_i=x_i-\bar{x}$ y $v_i=y_i-\bar{y}$, y $\mathbf{u},\mathbf{v}\in\mathbb{R}^n$ los vectores correspondientes, ambos no nulos porque $s_x,s_y>0$. Entonces $r=\langle\mathbf{u},\mathbf{v}\rangle/(\|\mathbf{u}\|\|\mathbf{v}\|)$, y la desigualdad de Cauchy–Schwarz, $|\langle\mathbf{u},\mathbf{v}\rangle|\le\|\mathbf{u}\|\|\mathbf{v}\|$, da $|r|\le 1$. La igualdad en Cauchy–Schwarz se da exactamente cuando $\mathbf{v}=a\mathbf{u}$ para algún $a\neq 0$, es decir, $y_i-\bar{y}=a(x_i-\bar{x})$ para todo i, que equivale a $y_i=ax_i+b$ con $b=\bar{y}-a\bar{x}$. En ese caso $\langle\mathbf{u},\mathbf{v}\rangle=a\|\mathbf{u}\|^2$ tiene el signo de a. Recíprocamente, si $y_i=ax_i+b$ entonces $v_i=au_i$ y $r=a\|\mathbf{u}\|^2/(\|\mathbf{u}\|\,|a|\|\mathbf{u}\|)=a/|a|=\pm 1$. ∎

Ejemplo 1.18. Para los pares $(1,2),(2,4),(3,5),(4,4),(5,5)$: $\bar{x}=3$, $\bar{y}=4$, $\sum(x_i-\bar{x})^2=10$, $\sum(y_i-\bar{y})^2=6$ y $\sum(x_i-\bar{x})(y_i-\bar{y})=(-2)(-2)+(-1)(0)+0\cdot 1+1\cdot 0+2\cdot 1=6$. Entonces $s_{xy}=6/4=1{,}5$ y $r=6/\sqrt{60}\approx 0{,}775$: asociación lineal positiva moderadamente fuerte.

Los mismos conceptos existen para variables aleatorias. Si (X,Y) es un vector aleatorio con varianzas finitas y positivas, su *covarianza* y su *correlación* son

$$\operatorname{Cov}(X,Y)=\mathbb{E}\big[(X-\mathbb{E}X)(Y-\mathbb{E}Y)\big]=\mathbb{E}[XY]-\mathbb{E}[X]\mathbb{E}[Y],\qquad \operatorname{Cor}(X,Y)=\frac{\operatorname{Cov}(X,Y)}{\sqrt{\operatorname{Var}X\,\operatorname{Var}Y}},$$

y también $|\operatorname{Cor}(X,Y)|\le 1$ [1, §7.3]. Las fórmulas muestrales de la definición 1.16 son las análogas con los datos (salvo el factor $n/(n-1)$, que se cancela en r).

Observación 1.19 (Errores frecuentes). (a) Una correlación cercana a cero no significa que no haya relación, sino que no hay relación *lineal*: para los puntos $(-2,4),(-1,1),(0,0),(1,1),(2,4)$, en los que $y=x^2$, se tiene $r=0$ (ejercicio 6.10). (b) Una correlación alta no implica causalidad (tema 6). (c) Calcular s^2 con denominador n cuando se pide la varianza muestral, o confundir s^2 con s. (d) Olvidar ordenar los datos antes de calcular la mediana o los cuartiles. (e) Comparar medias de grupos muy asimétricos o con atípicos sin mirar también la mediana.

Observación 1.20 (Conexión con el curso). La normalización por capas (*LayerNorm*) del módulo 11 y de los Transformers del módulo 14 tipifica el vector de activaciones de cada token: le resta su media y lo divide por su desviación típica (con denominador n, como en la observación 1.11). Las tablas de resultados de los benchmarks de los módulos 22 y 23 son, en esencia, medias de variables 0/1 (acierto o fallo), y los diagramas de caja son la forma habitual de mostrar la variabilidad entre semillas o entre ejecuciones de un mismo entrenamiento.

Lecturas recomendadas para este tema

- OpenStax [2], cap. 2: §2.2 «Histograms, Frequency Polygons, and Time Series Graphs», §2.3 «Measures of the Location of the Data», §2.4 «Box Plots», §2.5 «Measures of the Center of the Data», §2.6 «Skewness and the Mean, Median, and Mode» y §2.7 «Measures of the Spread of the Data».
- Rice [4], cap. 10 «Summarizing Data».
- Orloff y Bloom [3], lectura 7b «Covariance and Correlation».
- Blitzstein y Hwang [1], §7.3 «Covariance and correlation».

Ejercicios del tema 1

Ejercicio 1.1 ⋆ Indique si cada afirmación es verdadera o falsa y justifíquelo brevemente. (a) Si se multiplica por 10 el mayor dato de un conjunto, la mediana no cambia. (b) La desviación típica de un conjunto de datos puede ser negativa. (c) Si todos los datos son iguales, $s = 0$ y RIC $= 0$. (d) Si $r = 0{,}9$, los puntos están exactamente sobre una recta. (e) Sumar 5 a todos los datos no cambia ni la varianza ni el RIC.

Ejercicio 1.2 ⋆⋆ Para los datos 4, 7, 2, 9, 5, 6, 3, 25, 6 (número de llamadas a herramientas de un agente en nueve tareas), calcule la media, la mediana, la moda, los cuartiles, el RIC, las vallas de Tukey, la varianza y la desviación típica muestrales. ¿Hay atípicos? Repita el cálculo de la media, la mediana y s sin el atípico y comente el resultado.

Ejercicio 1.3 ⋆⋆ Las edades (en años) de veinte alumnos de una clase son 9; 9,5; 9,5; 10; 10; 10; 10; 10,5; 10,5; 10,5; 10,5; 11; 11; 11; 11; 11; 11; 11,5; 11,5; 11,5. Calcule la media, la mediana, los cuartiles y la desviación típica muestral. ¿Qué fracción de los datos está a menos de una desviación típica de la media?

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §2.7, ejemplo 2.32.

Ejercicio 1.4 ⋆⋆ Los resúmenes de cinco números de las notas de un examen en un grupo de mañana y otro de tarde son (32; 56; 74,5; 82,5; 99) y (25,5; 78; 81; 89; 98). (a) Calcule el rango y el RIC de cada grupo. (b) ¿Qué grupo tiene la mitad central de los datos más dispersa? (c) Calcule las vallas de Tukey y determine si el mínimo de cada grupo es atípico. (d) Esboce los dos diagramas de caja sobre un mismo eje.

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §2.4, ejemplo 2.24.

Ejercicio 1.5 ⋆⋆ Una tabla de frecuencias agrupa 26 datos en clases con marcas de clase (puntos medios) $1, 4, 7, 10, 13, 16$ y frecuencias $1, 6, 10, 7, 0, 2$, respectivamente. Aproxime la media y la desviación típica muestral sustituyendo cada dato por la marca de su clase.

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §2.7, ejemplo 2.34.

Ejercicio 1.6 ⋆⋆ De un conjunto de $n = 10$ datos se conocen $\sum x_i = 50$ y $\sum x_i^2 = 290$. (a) Calcule $\bar{x}$ y s^2. (b) Se añade un undécimo dato igual a 5. Calcule la nueva media y la nueva varianza muestral sin recalcular desde cero.

Ejercicio 1.7 ⋆⋆ Las temperaturas máximas de una semana, en grados Celsius, son $18, 21, 25, 19, 22, 30, 24$. (a) Calcule $\bar{x}$, la mediana, s y el RIC. (b) Sin repetir los cálculos, obtenga esas mismas medidas en grados Fahrenheit ($F = 1{,}8\,C + 32$). (c) ¿Cambian las puntuaciones z?

Ejercicio 1.8 ⋆⋆ Juan obtiene un 2,85 en una escala en la que la media de su centro es 3,0 y la desviación típica 0,7. Alí obtiene un 77 en otra escala cuya media es 80 y cuya desviación típica es 10. ¿Quién tiene una nota mejor en relación con su centro?

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §2.7, ejemplo 2.35.

Ejercicio 1.9 ⋆⋆ Las variables X e Y toman los valores 1 y -1, cada una con probabilidad $1/2$, y $c = \mathbb{P}(X = 1, Y = 1)$. (a) Escriba la distribución conjunta en función de c y calcule

$\mathrm{Cov}(X,Y)$ y $\mathrm{Cor}(X,Y)$. (b) ¿Para qué valores de c son independientes? ¿Para cuáles es $\mathrm{Cor}(X,Y)=1$? ¿Y -1?

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 5, problema 3.

Ejercicio 1.10 ⋆⋆ Un grupo de 10 alumnos tiene media 70 y desviación típica muestral 8 en un examen; otro de 15 alumnos tiene media 80 y desviación típica 6. Calcule la media y la desviación típica muestral de los 25 alumnos juntos.

Ejercicio 1.11 ⋆⋆⋆ Demuestre que la función $g(a)=\sum_{i=1}^{n}|x_i-a|$ alcanza su mínimo en la mediana. (*Indicación:* estudie cómo cambia g al mover a en un intervalo entre dos datos ordenados consecutivos.)

Ejercicio 1.12 ⋆⋆⋆ Sean $x'_i=ax_i+b$ e $y'_i=cy_i+d$ con $a,c\neq 0$. Demuestre que $s_{x'y'}=ac\,s_{xy}$ y que $r_{x'y'}=\mathrm{signo}(ac)\,r_{xy}$. Deduzca que la correlación no depende de las unidades de medida.

Ejercicio 1.13 ⋆⋆⋆ Sean $x_1,\dots,x_n$ datos con desviación típica muestral $s>0$ y sea $k>0$. Demuestre que la fracción de datos con $|x_i-\bar{x}|\geq ks$ es a lo sumo $\dfrac{n-1}{nk^2}<\dfrac{1}{k^2}$. ¿Qué garantiza esta cota para $k=2$?

Ejercicio 1.14 ⋆⋆⋆ Sean $\bar{x}_m$ y $M_m=\sum_{i=1}^{m}(x_i-\bar{x}_m)^2$ la media y la suma de cuadrados de los m primeros datos. Demuestre las fórmulas de actualización

$$\bar{x}_m=\bar{x}_{m-1}+\frac{x_m-\bar{x}_{m-1}}{m},\qquad M_m=M_{m-1}+(x_m-\bar{x}_{m-1})(x_m-\bar{x}_m),$$

que permiten calcular la media y la varianza en una sola pasada sobre los datos. Compruébelas con los datos $2,4,9$.

Ejercicio 1.15 ⋆⋆⋆ Demuestre la identidad

$$s^2=\frac{1}{n(n-1)}\sum_{1\leq i<j\leq n}(x_i-x_j)^2,$$

que expresa la varianza muestral sin usar la media: es la mitad del promedio de los cuadrados de las diferencias entre todos los pares de datos distintos.

Tema 2

Muestreo y estimadores

La estadística inferencial trata los datos como valores observados de variables aleatorias cuya distribución depende de parámetros desconocidos. Este tema introduce el modelo de muestra aleatoria simple, la noción de estimador y los criterios para juzgar su calidad: sesgo, varianza, error estándar, error cuadrático medio y consistencia. Se demuestran los dos resultados centrales del muestreo: la media muestral es un estimador insesgado de la media y la varianza muestral con denominador $n-1$ lo es de la varianza. Se sigue el capítulo 6 de Wasserman [6], «Models, Statistical Inference and Learning», la §6.3 de Blitzstein y Hwang [1], «Sample moments», la clase 12 del curso Stats 200 de Stanford [5] y la lectura 10a del curso 18.05 del MIT [3].

2.1 Recordatorio: esperanza y varianza

Se recogen las propiedades de la esperanza y la varianza de variables aleatorias (discretas o continuas) que se usarán continuamente [1, cap. 4 y §7.3]. Todas las variables que aparecen se suponen con varianza finita.

Proposición 2.1 (Propiedades de la esperanza y la varianza). *Sean $X, Y, X_1, \dots, X_n$ variables aleatorias y $a, b \in \mathbb{R}$.*

(i) Linealidad: $\mathbb{E}[aX+bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$ *y, en general,* $\mathbb{E}\big[\sum_i X_i\big] = \sum_i \mathbb{E}[X_i]$.

(ii) $\operatorname{Var}(X) = \mathbb{E}[(X-\mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2$, *y* $\operatorname{Var}(aX+b) = a^2 \operatorname{Var}(X)$.

(iii) $\operatorname{Var}\big(\sum_i X_i\big) = \sum_i \operatorname{Var}(X_i) + 2\sum_{i<j} \operatorname{Cov}(X_i, X_j)$.

(iv) Si X e Y son independientes, $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$ *y, por tanto,* $\operatorname{Cov}(X,Y) = 0$. *En consecuencia, si $X_1, \dots, X_n$ son independientes,* $\operatorname{Var}\big(\sum_i X_i\big) = \sum_i \operatorname{Var}(X_i)$.

(v) La covarianza es bilineal,

$$\operatorname{Cov}\Big(\sum_i a_i X_i, \sum_j b_j Y_j\Big) = \sum_{i,j} a_i b_j \operatorname{Cov}(X_i, Y_j),$$

y $\operatorname{Cov}(X,X) = \operatorname{Var}(X)$.

Demostración. (i) y la independencia en (iv) son propiedades de la esperanza que se suponen conocidas [1, §4.2 y §7.3]. (ii) Desarrollando el cuadrado y usando (i): $\mathbb{E}[(X-\mu)^2] = \mathbb{E}[X^2] - 2\mu\mathbb{E}[X] + \mu^2 = \mathbb{E}[X^2] - \mu^2$ con $\mu = \mathbb{E}X$; además $aX + b - \mathbb{E}[aX+b] = a(X-\mu)$. (v) Se sigue de la linealidad de la esperanza aplicada a $\big(\sum_i a_i(X_i - \mathbb{E}X_i)\big)\big(\sum_j b_j(Y_j - \mathbb{E}Y_j)\big)$. (iii) Es (v) con $Y_j = X_j$ y todos los coeficientes iguales a 1, separando los términos $i=j$ de los $i \neq j$. La última afirmación de (iv) se sigue de (iii). ∎

2.2 Muestra aleatoria, parámetro y estadístico

Definición 2.2 (Muestra aleatoria simple). Una *muestra aleatoria simple* de tamaño n de una distribución F es una colección de variables aleatorias $X_1, \ldots, X_n$ independientes y todas con distribución F; se dice que son *independientes e idénticamente distribuidas* (i.i.d.) y se escribe $X_1, \ldots, X_n \sim F$ i.i.d. Los datos $x_1, \ldots, x_n$ son una realización (valores observados) de la muestra.

El modelo describe el muestreo con reemplazamiento de una población, o el muestreo sin reemplazamiento cuando la población es mucho mayor que la muestra, y también la repetición independiente de un experimento: lanzar una moneda, generar una respuesta de un modelo de lenguaje con una semilla distinta o elegir al azar una pregunta de un banco muy grande.

Definición 2.3 (Modelo paramétrico, parámetro y estadístico). Un *modelo paramétrico* es una familia de distribuciones $\{F_\theta : \theta \in \Theta\}$ indexada por un *parámetro* θ (un número o un vector) que toma valores en el *espacio paramétrico* Θ. Un *estadístico* es cualquier función $T = g(X_1, \ldots, X_n)$ de la muestra que no depende de parámetros desconocidos; es, por tanto, una variable aleatoria, y su distribución se llama *distribución muestral* de T.

Por ejemplo, $\{\mathrm{Ber}(p) : p \in [0,1]\}$, $\{\mathrm{Pois}(\lambda) : \lambda > 0\}$ y $\{\mathcal{N}(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma > 0\}$ son modelos paramétricos. Los estadísticos más importantes son la *media muestral* y la *varianza muestral*

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2,$$

que son las cantidades del tema 1 vistas como variables aleatorias. Se reserva la mayúscula para la variable aleatoria y la minúscula ($\bar{x}$, s^2) para su valor observado.

2.3 Estimadores y sus propiedades

Definición 2.4 (Estimador, sesgo, error estándar y error cuadrático medio). Un *estimador* de un parámetro θ es un estadístico $\widehat{\theta} = \widehat{\theta}(X_1, \ldots, X_n)$ que se usa para aproximar θ; su valor con unos datos concretos es una *estimación*. Se definen:

(i) el *sesgo*: $\mathrm{sesgo}(\widehat{\theta}) = \mathbb{E}_\theta[\widehat{\theta}] - \theta$; el estimador es *insesgado* si su sesgo es nulo para todo $\theta \in \Theta$;

(ii) el *error estándar*: $\mathrm{ee}(\widehat{\theta}) = \sqrt{\mathrm{Var}_\theta(\widehat{\theta})}$;

(iii) el *error cuadrático medio*: $\mathrm{ECM}(\widehat{\theta}) = \mathbb{E}_\theta\big[(\widehat{\theta} - \theta)^2\big]$.

El subíndice θ indica que las esperanzas se calculan con la distribución F_θ.

El sesgo mide el error sistemático y el error estándar, la dispersión del estimador alrededor de su propia media. El error estándar suele depender de θ, que es desconocido; al sustituir θ por su estimación se obtiene el *error estándar estimado*, que se escribe $\widehat{\mathrm{ee}}$.

Proposición 2.5 (Descomposición sesgo–varianza). $\mathrm{ECM}(\widehat{\theta}) = \mathrm{sesgo}(\widehat{\theta})^2 + \mathrm{Var}(\widehat{\theta})$.

Demostración. Sea $m = \mathbb{E}[\widehat{\theta}]$. Se escribe $\widehat{\theta} - \theta = (\widehat{\theta} - m) + (m - \theta)$, donde el segundo sumando

es una constante. Entonces

$$\mathbb{E}[(\widehat{\theta}-\theta)^2] = \mathbb{E}[(\widehat{\theta}-m)^2] + 2(m-\theta)\mathbb{E}[\widehat{\theta}-m] + (m-\theta)^2 = \operatorname{Var}(\widehat{\theta}) + 0 + \operatorname{sesgo}(\widehat{\theta})^2,$$

porque $\mathbb{E}[\widehat{\theta}-m]=0$. ∎

Un estimador ligeramente sesgado puede tener menor ECM que uno insesgado si su varianza es bastante menor (ejercicio 2.10); este compromiso entre sesgo y varianza reaparece en el aprendizaje automático (módulo 8).

2.4 La media muestral

Teorema 2.6 (Media y varianza de la media muestral). *Sean $X_1,\dots,X_n$ i.i.d. con media μ y varianza σ^2. Entonces*

$$\mathbb{E}[\overline{X}] = \mu, \qquad \operatorname{Var}(\overline{X}) = \frac{\sigma^2}{n}, \qquad \operatorname{ee}(\overline{X}) = \frac{\sigma}{\sqrt{n}}.$$

En particular, $\overline{X}$ es un estimador insesgado de μ.

Demostración. Por la linealidad de la esperanza, $\mathbb{E}[\overline{X}] = \frac{1}{n}\sum_i \mathbb{E}[X_i] = \frac{1}{n}\cdot n\mu = \mu$. Por la proposición 2.1(ii) y (iv), usando la independencia,

$$\operatorname{Var}(\overline{X}) = \frac{1}{n^2}\operatorname{Var}\Big(\sum_{i=1}^n X_i\Big) = \frac{1}{n^2}\sum_{i=1}^n \operatorname{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$ ∎

El error estándar de la media decrece como $1/\sqrt{n}$: para dividirlo por dos hay que multiplicar el tamaño de la muestra por cuatro. Esta ley de la raíz cuadrada gobierna el coste de casi toda estimación por muestreo, desde las encuestas hasta la evaluación de modelos.

Ejemplo 2.7 (Proporción muestral). Si $X_1,\dots,X_n \sim \operatorname{Ber}(p)$ i.i.d. (por ejemplo, $X_i=1$ si un modelo responde bien a la pregunta i), entonces $\mu=p$ y $\sigma^2=p(1-p)$. La *proporción muestral* $\widehat{p}=\overline{X}$ es la fracción de aciertos; es insesgada y $\operatorname{ee}(\widehat{p})=\sqrt{p(1-p)/n}$, que se estima por $\widehat{\operatorname{ee}}=\sqrt{\widehat{p}(1-\widehat{p})/n}$. Con $n=1000$ preguntas y $\widehat{p}=0{,}8$, $\widehat{\operatorname{ee}}=\sqrt{0{,}16/1000}\approx 0{,}0126$, es decir, algo más de un punto porcentual.

2.5 La varianza muestral

Teorema 2.8 (Insesgadez de la varianza muestral). *Sean $X_1,\dots,X_n$ i.i.d. con media μ y varianza σ^2, con $n\geq 2$. Entonces $\mathbb{E}[S^2]=\sigma^2$.*

Demostración. Paso 1. Por la proposición 1.5(ii) con $a=\mu$, aplicada a los valores $X_1,\dots,X_n$,

$$\sum_{i=1}^n (X_i-\overline{X})^2 = \sum_{i=1}^n (X_i-\mu)^2 - n(\overline{X}-\mu)^2.$$

Paso 2. Se toman esperanzas. Como $\mathbb{E}[(X_i-\mu)^2]=\operatorname{Var}(X_i)=\sigma^2$ y, por el teorema 2.6, $\mathbb{E}[(\overline{X}-\mu)^2]=\operatorname{Var}(\overline{X})=\sigma^2/n$,

$$\mathbb{E}\Big[\sum_{i=1}^n (X_i-\overline{X})^2\Big] = n\sigma^2 - n\cdot\frac{\sigma^2}{n} = (n-1)\sigma^2.$$

Paso 3. Dividiendo por $n-1$ se obtiene $\mathbb{E}[S^2]=\sigma^2$. ∎

La demostración explica el $n-1$: las desviaciones se miden respecto de $\overline{X}$, que está más cerca de los datos que la verdadera media μ (es la que minimiza la suma de cuadrados), de modo que $\sum_i (X_i - \overline{X})^2$ es en promedio menor que $\sum_i (X_i - \mu)^2$, exactamente en una cantidad σ^2.

Corolario 2.9 (Sesgo de la varianza con denominador n). *El estimador $\widehat{\sigma}^2 = \frac{1}{n}\sum_i (X_i - \overline{X})^2 = \frac{n-1}{n} S^2$ cumple $\mathbb{E}[\widehat{\sigma}^2] = \frac{n-1}{n}\sigma^2$, luego tiene sesgo $-\sigma^2/n$: subestima la varianza, aunque el sesgo tiende a cero cuando $n \to \infty$.*

Observación 2.10. Que S^2 sea insesgado para σ^2 no implica que S lo sea para σ: en general $\mathbb{E}[S] < \sigma$ (ejercicio 2.14). La insesgadez no se conserva por transformaciones no lineales.

2.6 Consistencia y ley de los grandes números

Un estimador razonable debe acercarse al parámetro cuando crece el tamaño de la muestra. Se escribe $\widehat{\theta}_n$ para subrayar la dependencia de n.

Definición 2.11 (Consistencia). Una sucesión de variables aleatorias Y_n *converge en probabilidad* a una constante c, y se escribe $Y_n \xrightarrow{\mathbb{P}} c$, si para todo $\varepsilon > 0$

$$\lim_{n\to\infty} \mathbb{P}\big(|Y_n - c| > \varepsilon\big) = 0.$$

Un estimador $\widehat{\theta}_n$ es *consistente* si $\widehat{\theta}_n \xrightarrow{\mathbb{P}} \theta$ para todo $\theta \in \Theta$.

Lema 2.12 (Desigualdades de Markov y de Chebyshev). *Si $Y \geq 0$ y $a > 0$, entonces $\mathbb{P}(Y \geq a) \leq \mathbb{E}[Y]/a$. En consecuencia, si W tiene media μ_W y varianza finita, para todo $\varepsilon > 0$*

$$\mathbb{P}(|W - \mu_W| \geq \varepsilon) \leq \frac{\operatorname{Var}(W)}{\varepsilon^2}.$$

Demostración. Sea $\mathbf{1}_A$ la variable que vale 1 si $Y \geq a$ y 0 en otro caso. Como $Y \geq 0$, se tiene $Y \geq a\mathbf{1}_A$ en todos los casos, y tomando esperanzas $\mathbb{E}[Y] \geq a\mathbb{P}(Y \geq a)$. Para la segunda desigualdad se aplica la primera a $Y = (W - \mu_W)^2$ y $a = \varepsilon^2$, observando que $|W - \mu_W| \geq \varepsilon$ equivale a $(W - \mu_W)^2 \geq \varepsilon^2$. ∎

Proposición 2.13 (Un ECM que tiende a cero implica consistencia). *Si $\operatorname{ECM}(\widehat{\theta}_n) \to 0$ para todo θ, entonces $\widehat{\theta}_n$ es consistente. En particular, basta que el sesgo y la varianza tiendan a cero.*

Demostración. Por la desigualdad de Markov aplicada a $Y = (\widehat{\theta}_n - \theta)^2$ con $a = \varepsilon^2$, $\mathbb{P}(|\widehat{\theta}_n - \theta| > \varepsilon) \leq \mathbb{P}\big((\widehat{\theta}_n - \theta)^2 \geq \varepsilon^2\big) \leq \operatorname{ECM}(\widehat{\theta}_n)/\varepsilon^2 \to 0$. La segunda afirmación se sigue de la proposición 2.5. ∎

Teorema 2.14 (Ley débil de los grandes números). *Si $X_1, X_2, \ldots$ son i.i.d. con media μ y varianza finita σ^2, entonces $\overline{X}_n \xrightarrow{\mathbb{P}} \mu$; es decir, la media muestral es un estimador consistente de la media.*

Demostración. $\overline{X}_n$ es insesgado y $\operatorname{ECM}(\overline{X}_n) = \operatorname{Var}(\overline{X}_n) = \sigma^2/n \to 0$; se aplica la proposición 2.13. Explícitamente, $\mathbb{P}(|\overline{X}_n - \mu| > \varepsilon) \leq \sigma^2/(n\varepsilon^2)$. ∎

La cota de Chebyshev es válida para cualquier distribución, pero es muy conservadora; en el tema 3 el teorema central del límite dará aproximaciones mucho más precisas.

Observación 2.15 (Errores frecuentes). (a) Confundir el parámetro μ (un número fijo y desconocido) con el estadístico $\overline{X}$ (una variable aleatoria) o con su valor observado $\bar{x}$ (un número conocido). (b) Confundir la desviación típica de la población, σ, con el error estándar de la media, $\sigma/\sqrt{n}$. (c) Pensar que «insesgado» significa «cercano al parámetro»: un estimador insesgado con mucha varianza puede ser casi siempre malo. (d) Usar $\operatorname{Var}(X+Y) = \operatorname{Var} X + \operatorname{Var} Y$ sin comprobar la independencia (o, al menos, la incorrelación).

Observación 2.16 (Conexión con el curso). El módulo 5 retoma estos conceptos (estimadores, sesgo y error cuadrático medio, ley de los grandes números y método de Monte Carlo) y el módulo 8 desarrolla la descomposición sesgo–varianza del error de predicción. En los módulos 22 y 23, la exactitud de un modelo en un benchmark es una proporción muestral (ejemplo 2.7) y la métrica pass@k se estima con un estimador insesgado que se construye con un argumento de muestreo (ejercicio 2.15).

Lecturas recomendadas para este tema

- Wasserman [6], cap. 6 «Models, Statistical Inference and Learning» (estimación puntual, sesgo, error estándar, consistencia) y cap. 5 «Convergence of Random Variables».
- Blitzstein y Hwang [1], §6.3 «Sample moments» y §10.2 «Law of large numbers».
- Stats 200 [5], clase 12 «Parametric models, method of moments estimation» (sesgo, varianza y error cuadrático medio).
- Orloff y Bloom [3], lectura 10a «Introduction to Statistics».

Ejercicios del tema 2

Ejercicio 2.1 ⋆ Se quiere conocer la exactitud real p de un modelo de lenguaje en un banco de un millón de preguntas. Se eligen al azar 500 preguntas, el modelo acierta 410 y se informa de que «la exactitud es del 82 %». Identifique la población, la muestra, el parámetro, el estimador y la estimación. ¿Es aleatorio el número 0,82? ¿Y $\widehat{p}$?

Ejercicio 2.2 ⋆⋆ Una población está formada por los valores $1, 3, 5$, cada uno con probabilidad $1/3$. Se extraen muestras de tamaño $n = 2$ con reemplazamiento. (a) Calcule μ y σ^2. (b) Enumere las nueve muestras posibles y obtenga la distribución muestral de $\overline{X}$; compruebe que $\mathbb{E}[\overline{X}] = \mu$ y $\operatorname{Var}(\overline{X}) = \sigma^2/2$. (c) Obtenga la distribución de S^2 y compruebe que $\mathbb{E}[S^2] = \sigma^2$. ¿Cuánto vale $\mathbb{E}[\widehat{\sigma}^2]$ con denominador n?

Ejercicio 2.3 ⋆⋆ Sean X_1, X_2, X_3 i.i.d. con media μ y varianza σ^2. Se consideran $T_1 = \overline{X}$, $T_2 = (X_1 + 2X_2 + X_3)/4$, $T_3 = X_1 + X_2 - X_3$ y $T_4 = (X_1 + X_2 + X_3)/4$. (a) Calcule el sesgo, la varianza y el ECM de cada uno. (b) ¿Cuál es el mejor de los insesgados? (c) ¿Para qué valores de μ tiene T_4 menor ECM que T_1?

Ejercicio 2.4 ⋆⋆ Sean $X_1, \dots, X_n \sim \text{Pois}(\lambda)$ i.i.d., y $\widehat{\lambda} = \overline{X}$. (a) Demuestre que $\widehat{\lambda}$ es insesgado y calcule su varianza, su error estándar y su ECM. (b) En $n = 50$ bloques de texto se cuentan los errores ortográficos y se obtiene $\bar{x} = 3{,}2$. Dé la estimación de λ y su error estándar estimado.

Fuente: adaptado de Stats 200, Stanford [5], clase 12, ejemplo 12.5.

Ejercicio 2.5 ⋆⋆ Sean $X_1, \dots, X_n \sim \mathrm{Exp}(\lambda)$ i.i.d. ($n \geq 2$), con media $1/\lambda$. Se admite que $\mathbb{E}[1/\overline{X}] = \dfrac{n\lambda}{n-1}$. (a) Calcule el sesgo de $\widehat{\lambda} = 1/\overline{X}$. (b) Proponga un estimador insesgado de λ de la forma $c/\overline{X}$. (c) Con $n = 5$ y $\sum x_i = 10$, calcule ambas estimaciones.

Fuente: adaptado de Stats 200, Stanford [5], clase 12, ejemplo 12.6.

Ejercicio 2.6 ⋆⋆ Sean $X_1, X_2, \dots$ i.i.d. con distribución exponencial de tasa 2 (varianza $1/4$) y sea $n \geq 8$. Se definen $X = X_1 + \cdots + X_n$ e $Y = X_{n-7} + X_{n-6} + \cdots + X_{2n-8}$. Calcule $\mathrm{Cov}(X, Y)$ y $\mathrm{Cor}(X, Y)$.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 5, problema 5.

Ejercicio 2.7 ⋆⋆ Un modelo acierta 300 de 400 preguntas elegidas al azar de un banco grande. (a) Estime la exactitud y su error estándar. (b) ¿Cuántas preguntas harían falta para reducir el error estándar a la mitad, si la exactitud estimada no cambia?

Ejercicio 2.8 ⋆⋆ Se dispone de dos estimadores independientes e insesgados A y B de un mismo parámetro, con $\mathrm{Var}(A) = 4$ y $\mathrm{Var}(B) = 1$. (a) Demuestre que $T_w = wA + (1-w)B$ es insesgado para todo $w \in \mathbb{R}$. (b) Halle el w que minimiza $\mathrm{Var}(T_w)$ y el valor mínimo. (c) Generalice a varianzas σ_A^2 y σ_B^2.

Ejercicio 2.9 ⋆⋆ Se quiere estimar la exactitud p de un modelo con una muestra de n preguntas de modo que $\mathbb{P}(|\widehat{p} - p| \geq 0{,}05) \leq 0{,}05$ sea cual sea p. Usando la desigualdad de Chebyshev y la cota $p(1-p) \leq 1/4$, halle un n suficiente.

Ejercicio 2.10 ⋆⋆⋆ Para una muestra i.i.d. de una normal se sabe que $\mathrm{Var}(S^2) = 2\sigma^4/(n-1)$. Calcule el ECM de S^2 y el de $\widehat{\sigma}^2 = \frac{n-1}{n} S^2$, y demuestre que el estimador sesgado $\widehat{\sigma}^2$ tiene menor ECM para todo $n \geq 2$.

Ejercicio 2.11 ⋆⋆⋆ Sean $X_1, \dots, X_n \sim \mathrm{U}(0, \theta)$ i.i.d. y $M = \max_i X_i$. (a) Demuestre que $T_1 = 2\overline{X}$ es insesgado y que $\mathrm{Var}(T_1) = \theta^2/(3n)$. (b) Demuestre que $\mathbb{P}(M \leq x) = (x/\theta)^n$ para $0 \leq x \leq \theta$, calcule $\mathbb{E}[M]$ y $\mathbb{E}[M^2]$ y deduzca que $T_2 = \frac{n+1}{n} M$ es insesgado con $\mathrm{Var}(T_2) = \dfrac{\theta^2}{n(n+2)}$. (c) Demuestre que $\mathrm{Var}(T_2) \leq \mathrm{Var}(T_1)$, con igualdad solo si $n = 1$.

Fuente: adaptado de Stats 200, Stanford [5], *homework* 5, problema 3, y de Orloff y Bloom, MIT 18.05 [3], *problem set* 6, problema 3.

Ejercicio 2.12 ⋆⋆⋆ Con la notación del ejercicio 2.11, demuestre que M es un estimador consistente de θ de dos maneras: (a) calculando directamente $\mathbb{P}(|M - \theta| > \varepsilon)$; (b) mediante la proposición 2.13.

Ejercicio 2.13 ⋆⋆⋆ Sean $X_1, \dots, X_n$ i.i.d. con varianza σ^2. Demuestre que $\mathrm{Cov}(\overline{X}, X_i - \overline{X}) = 0$ para cada i. (Para datos normales, este hecho es la clave de la independencia entre $\overline{X}$ y S^2.)

Ejercicio 2.14 ⋆⋆⋆ Demuestre que $\mathbb{E}[S] \leq \sigma$, con igualdad solo si S es constante con probabilidad 1. (*Indicación:* $\mathrm{Var}(S) \geq 0$.)

Ejercicio 2.15 ⋆⋆⋆ Un modelo genera n soluciones independientes a un problema, cada una correcta con probabilidad p, y sea $C \sim \mathrm{Bin}(n, p)$ el número de correctas. Para $1 \leq k \leq n$,

la métrica pass@k es la probabilidad de que al menos una de k soluciones independientes sea correcta, $1-(1-p)^k$. Demuestre que

$$\widehat{\pi}_k = 1 - \binom{n-C}{k} \Big/ \binom{n}{k}$$

es un estimador insesgado de pass@k. (*Indicación:* interprete $\binom{n-C}{k}/\binom{n}{k}$ como la probabilidad de que un subconjunto de k soluciones elegido al azar no contenga ninguna correcta.)

Tema 3

Distribuciones muestrales y teorema central del límite

Un estadístico es una variable aleatoria y, para hacer inferencia, hace falta conocer (al menos aproximadamente) su distribución. Este tema estudia la distribución de la media muestral: exacta cuando los datos son normales y aproximada, gracias al teorema central del límite, en cualquier otro caso. Se incluyen la aproximación normal a la binomial y las distribuciones χ^2 y t de Student, que se usarán en los intervalos de confianza y en los contrastes. Se sigue el capítulo 10 de Blitzstein y Hwang [1] (§10.3 «Central limit theorem» y §10.4 «Chi-Square and Student-t»), la lectura 6b del curso 18.05 del MIT [3], «Central Limit Theorem and the Law of Large Numbers», y el capítulo 7 de OpenStax [2] (§7.1 y §7.2).

3.1 La distribución normal

Definición 3.1 (Distribución normal). Una variable X tiene distribución *normal* de media $\mu \in \mathbb{R}$ y varianza $\sigma^2 > 0$, y se escribe $X \sim \mathcal{N}(\mu, \sigma^2)$, si su densidad es

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\Big(-\frac{(x-\mu)^2}{2\sigma^2}\Big), \qquad x \in \mathbb{R}.$$

La *normal estándar* es $Z \sim \mathcal{N}(0,1)$; su función de distribución se denota $\Phi(z) = \mathbb{P}(Z \leq z)$ y su cuantil de orden q, $z_q = \Phi^{-1}(q)$.

La función Φ no tiene expresión mediante funciones elementales y se tabula (cuadro B.1). Por la simetría de la densidad respecto de 0, $\Phi(-z) = 1 - \Phi(z)$ y $z_{1-q} = -z_q$.

Proposición 3.2 (Tipificación). *Si $X \sim \mathcal{N}(\mu, \sigma^2)$ y $a \neq 0$, entonces $aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$. En particular, $Z = (X - \mu)/\sigma \sim \mathcal{N}(0,1)$ y*

$$\mathbb{P}(X \leq x) = \Phi\Big(\frac{x-\mu}{\sigma}\Big).$$

La demostración es el ejercicio 3.12. Con la tabla se obtiene la conocida regla empírica: una normal toma valores a menos de 1, 2 y 3 desviaciones típicas de su media con probabilidades $2\Phi(1) - 1 \approx 0{,}683$, $2\Phi(2) - 1 \approx 0{,}954$ y $2\Phi(3) - 1 \approx 0{,}997$.

Teorema 3.3 (Combinaciones lineales de normales independientes). *Si $X_1, \ldots, X_n$ son independientes con $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, entonces $\sum_i a_i X_i \sim \mathcal{N}\big(\sum_i a_i\mu_i, \sum_i a_i^2\sigma_i^2\big)$ para cualesquiera a_i no todos nulos. En particular, si $X_1, \ldots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ son i.i.d.,*

$$\overline{X} \sim \mathcal{N}\Big(\mu, \frac{\sigma^2}{n}\Big).$$

La media y la varianza se siguen de la proposición 2.1; que la distribución siga siendo normal se demuestra con funciones generadoras de momentos [1, §6.6] y se admite aquí sin demostración.

3.2 El teorema central del límite

Cuando los datos no son normales, la distribución exacta de $\overline{X}$ suele ser complicada. El teorema central del límite afirma que, sin embargo, para n grande es aproximadamente normal, sea cual sea la distribución de partida, con tal de que tenga varianza finita.

Teorema 3.4 (Teorema central del límite). *Sean $X_1, X_2, \dots$ i.i.d. con media μ y varianza $0 < \sigma^2 < \infty$, y sea $S_n = X_1 + \cdots + X_n$. Entonces, para todo $z \in \mathbb{R}$,*

$$\lim_{n\to\infty} \mathbb{P}\Big(\frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \le z\Big) = \lim_{n\to\infty} \mathbb{P}\Big(\frac{S_n - n\mu}{\sigma\sqrt{n}} \le z\Big) = \Phi(z).$$

Las dos variables tipificadas son la misma (basta multiplicar numerador y denominador por n). La demostración, con funciones generadoras de momentos, está en [1, §10.3]; aquí interesa su uso.

Observación 3.5 (Uso práctico). Para n «grande» se aproxima

$$\overline{X} \approx \mathcal{N}\Big(\mu, \frac{\sigma^2}{n}\Big), \qquad S_n \approx \mathcal{N}(n\mu, n\sigma^2).$$

Una regla habitual es $n \ge 30$ [2, §7.1], pero la calidad de la aproximación depende de la forma de la distribución: con datos simétricos basta un n pequeño y con datos muy asimétricos hace falta bastante más. El teorema exige varianza finita: para distribuciones de cola muy pesada, como la de Cauchy (o la t con un grado de libertad), la media muestral no se estabiliza [1, §10.3].

Ejemplo 3.6. La longitud de las respuestas de un modelo tiene media $\mu = 200$ tokens y desviación típica $\sigma = 80$, con distribución asimétrica. Para una muestra de $n = 64$ respuestas, el error estándar de la media es $80/\sqrt{64} = 10$, y por el teorema central del límite

$$\mathbb{P}(\overline{X} > 215) \approx 1 - \Phi\Big(\frac{215 - 200}{10}\Big) = 1 - \Phi(1{,}5) = 1 - 0{,}9332 = 0{,}0668.$$

Una respuesta individual supera los 215 tokens con mucha mayor probabilidad: la media de 64 respuestas fluctúa ocho veces menos que cada respuesta.

3.3 Aproximación normal a la binomial

Si $X \sim \mathrm{Bin}(n, p)$, entonces X tiene la misma distribución que la suma de n variables $\mathrm{Ber}(p)$ i.i.d., con $\mu = p$ y $\sigma^2 = p(1-p)$. El teorema central del límite da el resultado clásico de De Moivre y Laplace.

Corolario 3.7 (Aproximación normal a la binomial). *Si $X \sim \mathrm{Bin}(n, p)$ con $0 < p < 1$, para n grande*

$$X \approx \mathcal{N}\big(np,\, np(1-p)\big), \qquad \widehat{p} = \frac{X}{n} \approx \mathcal{N}\Big(p,\, \frac{p(1-p)}{n}\Big).$$

Una regla habitual para usarla es $np \ge 10$ y $n(1-p) \ge 10$.

Definición 3.8 (Corrección por continuidad). Al aproximar una variable con valores enteros por una continua, cada valor entero k se identifica con el intervalo $[k-\frac{1}{2}, k+\frac{1}{2}]$. Así, para enteros $a \le b$,

$$\mathbb{P}(a \le X \le b) \approx \Phi\Big(\frac{b+\frac{1}{2}-np}{\sqrt{np(1-p)}}\Big) - \Phi\Big(\frac{a-\frac{1}{2}-np}{\sqrt{np(1-p)}}\Big).$$

Ejemplo 3.9. Sea $X \sim \text{Bin}(100;\, 0{,}5)$: $np = 50$ y $\sqrt{np(1-p)} = 5$. Sin corrección, $\mathbb{P}(X \ge 60) \approx 1 - \Phi(2) = 0{,}0228$; con corrección, $\mathbb{P}(X \ge 60) = \mathbb{P}(X \ge 59{,}5) \approx 1 - \Phi(1{,}9) = 0{,}0287$. El valor exacto es 0,0284: la corrección mejora mucho la aproximación.

3.4 Distribuciones χ^2 y t de Student

Cuando σ es desconocida y se sustituye por S, la variable $(\overline{X}-\mu)/(S/\sqrt{n})$ ya no es normal. Su distribución exacta, para datos normales, se describe con dos familias derivadas de la normal [1, §10.4].

Definición 3.10 (Distribuciones χ^2 y t). Sean $Z_1, \dots, Z_k \sim \mathcal{N}(0,1)$ i.i.d. La distribución de $V = Z_1^2 + \cdots + Z_k^2$ se llama χ^2 *con k grados de libertad* y se escribe $V \sim \chi^2_k$. Si $Z \sim \mathcal{N}(0,1)$ y $V \sim \chi^2_k$ son independientes, la distribución de

$$T = \frac{Z}{\sqrt{V/k}}$$

se llama t *de Student con k grados de libertad* y se escribe $T \sim t_k$. Sus cuantiles se denotan $\chi^2_{k;q}$ y $t_{k;q}$ (cuadros B.3 y B.4).

La χ^2_k toma valores positivos, tiene media k y varianza $2k$ (ejercicio 3.14). La t_k es simétrica respecto de 0 (ejercicio 3.15), tiene colas más pesadas que la normal y converge a ella cuando $k \to \infty$: por ejemplo, $t_{5;0{,}975} = 2{,}571$, $t_{30;0{,}975} = 2{,}042$ y $z_{0{,}975} = 1{,}960$.

Teorema 3.11 (Teorema de Fisher). *Sean $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ i.i.d. con $n \ge 2$. Entonces $\overline{X}$ y S^2 son independientes, $\overline{X} \sim \mathcal{N}(\mu, \sigma^2/n)$ y*

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}.$$

Se admite sin demostración [1, §10.4]. Los $n-1$ grados de libertad son los de la observación 1.11: la suma de cuadrados respecto de $\overline{X}$ equivale a una suma de $n-1$ cuadrados de normales estándar independientes. Como $\mathbb{E}[\chi^2_{n-1}] = n-1$, el teorema reproduce, para datos normales, el resultado $\mathbb{E}[S^2] = \sigma^2$ del teorema 2.8, y como $\text{Var}(\chi^2_{n-1}) = 2(n-1)$, da $\text{Var}(S^2) = 2\sigma^4/(n-1)$, que se usó en el ejercicio 2.10.

Corolario 3.12 (Estadístico t). *En las condiciones del teorema 3.11,*

$$T = \frac{\overline{X}-\mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Demostración. Sean $Z = (\overline{X}-\mu)/(\sigma/\sqrt{n}) \sim \mathcal{N}(0,1)$ y $V = (n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$, independientes por el teorema 3.11. Entonces

$$\frac{Z}{\sqrt{V/(n-1)}} = \frac{(\overline{X}-\mu)\sqrt{n}/\sigma}{S/\sigma} = \frac{\overline{X}-\mu}{S/\sqrt{n}},$$

que tiene distribución t_{n-1} por la definición 3.10. ∎

Observación 3.13 (Errores frecuentes). (a) El teorema central del límite no dice que los *datos* se vuelvan normales al aumentar n, sino que lo hace la distribución de su *media* (o de su suma). (b) Usar la desviación típica de la población, σ, en lugar del error estándar, $\sigma/\sqrt{n}$, al tipificar una media. (c) Olvidar la corrección por continuidad con n moderado o confundir su sentido: $\mathbb{P}(X > 59) = \mathbb{P}(X \geq 60) \approx \mathbb{P}(Y \geq 59{,}5)$, no $\mathbb{P}(Y \geq 60{,}5)$. (d) Usar la t para datos claramente no normales y n pequeño: el corolario 3.12 exige normalidad; para n grande, la t y la normal prácticamente coinciden.

Observación 3.14 (Conexión con el curso). El módulo 5 enuncia el teorema central del límite y lo aplica al método de Monte Carlo. En el módulo 7, el gradiente calculado con un minilote de B ejemplos es una media muestral: su ruido decrece como $1/\sqrt{B}$. En los módulos 22 y 23, el error estándar de una exactitud medida sobre n preguntas es $\sqrt{p(1-p)/n}$, que con $n = 1000$ y $p = 0{,}8$ vale unos 1,3 puntos porcentuales; las diferencias de un punto entre modelos en un benchmark de ese tamaño están, por tanto, dentro del ruido de muestreo.

Lecturas recomendadas para este tema

- Blitzstein y Hwang [1], §5.4 «Normal», §10.3 «Central limit theorem» y §10.4 «Chi-Square and Student-t».
- Orloff y Bloom [3], lecturas 6b «Central Limit Theorem and the Law of Large Numbers» y 5c «Gallery of Continuous Random Variables».
- OpenStax [2], cap. 7: §7.1 «The Central Limit Theorem for Sample Means (Averages)» y §7.2 «The Central Limit Theorem for Sums».
- Wasserman [6], cap. 5 «Convergence of Random Variables».

Ejercicios del tema 3

Ejercicio 3.1 ⋆ Indique si cada afirmación es verdadera o falsa. (a) Por el teorema central del límite, si $n = 1000$ los datos de una muestra de una exponencial son aproximadamente normales. (b) Si los datos son normales, $\overline{X}$ es exactamente normal para todo n. (c) El error estándar de la media de 100 observaciones es la décima parte de la desviación típica de cada observación. (d) La t_{10} tiene más probabilidad en las colas que la $\mathcal{N}(0,1)$. (e) Si $X \sim \text{Bin}(20;\, 0{,}02)$, la aproximación normal es adecuada.

Ejercicio 3.2 ⋆ Con la cuadros B.1 y B.2, calcule: (a) $\Phi(1{,}23)$; (b) $\mathbb{P}(Z > -0{,}5)$; (c) $\mathbb{P}(-1 < Z < 2)$; (d) $z_{0{,}95}$ y $z_{0{,}99}$; (e) el valor $c > 0$ tal que $\mathbb{P}(|Z| \leq c) = 0{,}90$.

Ejercicio 3.3 ⋆⋆ Una puntuación X sigue una distribución $\mathcal{N}(100, 15^2)$. Calcule $\mathbb{P}(X > 130)$, $\mathbb{P}(85 < X < 115)$ y el percentil 90 de X.

Ejercicio 3.4 ⋆⋆ Una población tiene media 90 y desviación típica 15. Se toma una muestra de tamaño $n = 25$. (a) Calcule aproximadamente $\mathbb{P}(85 < \overline{X} < 92)$. (b) ¿Qué valor de $\overline{X}$ está dos errores estándar por encima de la media?

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §7.1, ejemplo 7.1.

Ejercicio 3.5 ⋆⋆ Con la población del ejercicio 3.4 y una muestra de tamaño $n = 80$: (a) calcule aproximadamente la probabilidad de que la suma de los 80 valores supere 7500; (b) halle el valor de la suma que está 1,5 desviaciones típicas por encima de su media.

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §7.2, ejemplo 7.5.

Ejercicio 3.6 ⋆⋆ El 50 % de una población apoya al candidato A y el 30 % a otros candidatos menores. Se encuesta a 400 personas elegidas al azar. Con el teorema central del límite, estime: (a) la probabilidad de que al menos el 52,5 % de los encuestados apoye a A; (b) la probabilidad de que menos del 31 % apoye a los candidatos menores.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 4, problema 2.

Ejercicio 3.7 ⋆⋆ Un comercio redondea el importe de cada pedido a los 5 céntimos más próximos. Se supone que el error de redondeo de cada pedido toma los valores $-2, -1, 0, 1, 2$ céntimos con igual probabilidad, de forma independiente. Con 1000 pedidos diarios, estime la probabilidad de que el error total del día supere los 100 céntimos en valor absoluto.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 4, problema 3.

Ejercicio 3.8 ⋆⋆ Sea $X \sim \mathrm{Bin}(100;\, 0{,}5)$ el número de caras en 100 lanzamientos. (a) Aproxime $\mathbb{P}(X = 50)$ con la corrección por continuidad. (b) Aproxime $\mathbb{P}(40 \le X \le 60)$ con y sin corrección. (c) Compare con los valores exactos $\mathbb{P}(X = 50) = 0{,}0796$ y $\mathbb{P}(40 \le X \le 60) = 0{,}9648$.

Ejercicio 3.9 ⋆⋆ Un modelo tiene exactitud real $p = 0{,}8$ en un banco de preguntas muy grande. Se evalúa con $n = 1000$ preguntas elegidas al azar. (a) Calcule el error estándar de $\widehat{p}$. (b) Estime $\mathbb{P}(\widehat{p} \ge 0{,}82)$. (c) Halle un intervalo centrado en 0,8 que contenga a $\widehat{p}$ con probabilidad aproximada 0,95.

Ejercicio 3.10 ⋆⋆ (a) ¿Qué tamaño muestral garantiza, según el teorema central del límite, que $\mathbb{P}(|\overline{X} - \mu| < 0{,}1\,\sigma) \ge 0{,}95$? (b) Aplíquelo para estimar una exactitud con error menor que 0,05 con probabilidad 0,95, sea cual sea p. Compare con el ejercicio 2.9.

Ejercicio 3.11 ⋆⋆ Con la cuadro B.3: (a) obtenga $t_{9;0{,}975}$, $t_{29;0{,}975}$ y $t_{120;0{,}975}$ y compárelos con $z_{0{,}975}$; (b) si $T \sim t_{15}$, calcule $\mathbb{P}(T > 2{,}131)$ y $\mathbb{P}(|T| \le 1{,}753)$; (c) si $V \sim \chi^2_{10}$, halle c con $\mathbb{P}(V > c) = 0{,}05$.

Ejercicio 3.12 ⋆⋆⋆ Demuestre la proposición 3.2: si $X \sim \mathcal{N}(\mu, \sigma^2)$ y $a \neq 0$, entonces $Y = aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$. (*Indicación:* calcule $\mathbb{P}(Y \le y)$ distinguiendo $a > 0$ y $a < 0$, y derive.)

Ejercicio 3.13 ⋆⋆⋆ Sea $Z \sim \mathcal{N}(0, 1)$ y $V = Z^2$. Demuestre que $\mathbb{P}(V \le v) = 2\Phi(\sqrt{v}) - 1$ para $v > 0$ y deduzca que la densidad de la χ^2_1 es

$$f_V(v) = \frac{1}{\sqrt{2\pi v}}\, e^{-v/2}, \qquad v > 0.$$

Ejercicio 3.14 ⋆⋆⋆ (a) Demuestre, integrando por partes, que si $Z \sim \mathcal{N}(0, 1)$ entonces $\mathbb{E}[Z^4] = 3\mathbb{E}[Z^2] = 3$. (b) Deduzca que si $V \sim \chi^2_k$, entonces $\mathbb{E}[V] = k$ y $\mathrm{Var}(V) = 2k$.

Ejercicio 3.15 ⋆⋆⋆ Sea $T \sim t_k$. Demuestre que T y $-T$ tienen la misma distribución y deduzca que $t_{k;1-q} = -t_{k;q}$ y que $\mathbb{P}(|T| \leq t_{k;1-\alpha/2}) = 1 - \alpha$. (Se admite que la distribución de T es continua.)

Tema 4

Estimación puntual e intervalos de confianza

El tema 2 enseñó a juzgar un estimador; este tema enseña a construirlo. Se presentan los dos métodos generales de estimación puntual, el método de los momentos y el de máxima verosimilitud, y se aplican a los modelos de Bernoulli, Poisson, normal y exponencial. Después se pasa de la estimación puntual a la estimación por intervalos: intervalos de confianza para la media con varianza conocida y desconocida, para proporciones y cálculo del tamaño muestral. Se sigue el capítulo 9 de Wasserman [6], «Parametric Inference» (método de los momentos y máxima verosimilitud), las clases 12, 13 y 18 de Stats 200 [5], las lecturas 10b, 22 y 23a del curso 18.05 del MIT [3] y el capítulo 8 de OpenStax [2].

4.1 El método de los momentos

Sea $X_1, \dots, X_n$ una muestra i.i.d. de un modelo F_θ con $\theta = (\theta_1, \dots, \theta_k)$. El *momento poblacional* de orden j es $m_j(\theta) = \mathbb{E}_\theta[X^j]$ y el *momento muestral* de orden j es $\widehat{m}_j = \frac{1}{n}\sum_i X_i^j$. Por la ley de los grandes números, $\widehat{m}_j \xrightarrow{\mathbb{P}} m_j(\theta)$.

Definición 4.1 (Estimador por el método de los momentos). El *estimador por el método de los momentos* $\widehat{\theta}$ es la solución del sistema de k ecuaciones

$$m_j(\widehat{\theta}) = \widehat{m}_j, \qquad j = 1, \dots, k,$$

es decir, el valor del parámetro con el que los primeros k momentos del modelo coinciden con los de la muestra [6, cap. 9].

Ejemplo 4.2 (Momentos en los modelos básicos).

(i) Bernoulli: $\mathbb{E}X = p$, luego $\widehat{p} = \overline{X}$.

(ii) Poisson: $\mathbb{E}X = \lambda$, luego $\widehat{\lambda} = \overline{X}$.

(iii) Exponencial de tasa λ: $\mathbb{E}X = 1/\lambda$, luego $\widehat{\lambda} = 1/\overline{X}$.

(iv) Normal: $\mathbb{E}X = \mu$ y $\mathbb{E}X^2 = \sigma^2 + \mu^2$. De $\widehat{\mu} = \overline{X}$ y $\widehat{\sigma}^2 + \widehat{\mu}^2 = \frac{1}{n}\sum_i X_i^2$ se obtiene $\widehat{\sigma}^2 = \frac{1}{n}\sum_i X_i^2 - \overline{X}^2 = \frac{1}{n}\sum_i (X_i - \overline{X})^2$, la varianza con denominador n.

(v) Uniforme en $[0, \theta]$: $\mathbb{E}X = \theta/2$, luego $\widehat{\theta} = 2\overline{X}$ (ejercicio 2.11).

El método es sencillo y produce estimadores consistentes en condiciones generales, pero no siempre los mejores y, a veces, incompatibles con los datos (ejercicio 4.5).

4.2 Máxima verosimilitud

Definición 4.3 (Verosimilitud y estimador de máxima verosimilitud). Sean $x_1, \dots, x_n$ los datos observados y $f(x \mid \theta)$ la función de probabilidad (caso discreto) o la densidad (caso continuo) del modelo. La *función de verosimilitud* y la *log-verosimilitud* son

$$\mathcal{L}(\theta) = \prod_{i=1}^{n} f(x_i \mid \theta), \qquad \ell(\theta) = \ln \mathcal{L}(\theta) = \sum_{i=1}^{n} \ln f(x_i \mid \theta).$$

El *estimador de máxima verosimilitud* (EMV) es el valor $\widehat{\theta} = \arg\max_{\theta \in \Theta} \mathcal{L}(\theta)$ [6, cap. 9].

La verosimilitud es la probabilidad (o densidad) de los datos observados vista como función del parámetro, con los datos fijos. Como el logaritmo es estrictamente creciente, maximizar $\mathcal{L}$ equivale a maximizar ℓ, que es una suma y se deriva con más facilidad. El procedimiento habitual es resolver la *ecuación de verosimilitud* $\ell'(\theta) = 0$ y comprobar que la solución es un máximo global.

Teorema 4.4 (EMV de Bernoulli). *Si $x_1, \dots, x_n \in \{0, 1\}$ son observaciones i.i.d. de* $\mathrm{Ber}(p)$ *y $k = \sum_i x_i$ es el número de unos, con $0 < k < n$, el EMV es $\widehat{p} = k/n = \bar{x}$.*

Demostración. La función de probabilidad es $f(x \mid p) = p^x (1-p)^{1-x}$ para $x \in \{0, 1\}$. Entonces $\mathcal{L}(p) = p^k (1-p)^{n-k}$ y, para $0 < p < 1$,

$$\ell(p) = k \ln p + (n-k) \ln(1-p), \qquad \ell'(p) = \frac{k}{p} - \frac{n-k}{1-p}.$$

La ecuación $\ell'(p) = 0$ equivale a $k(1-p) = (n-k)p$, es decir, $p = k/n$. Como $\ell''(p) = -k/p^2 - (n-k)/(1-p)^2 < 0$, ℓ es estrictamente cóncava en $(0, 1)$ y el punto crítico es el máximo global. (En los extremos, $\mathcal{L}(0) = \mathcal{L}(1) = 0$ cuando $0 < k < n$.) ∎

Si $k = 0$ o $k = n$, el máximo está en $\widehat{p} = 0$ o $\widehat{p} = 1$, respectivamente, y la fórmula $\widehat{p} = k/n$ sigue siendo válida.

Teorema 4.5 (EMV de la normal). *Si $x_1, \dots, x_n$ son observaciones i.i.d. de $\mathcal{N}(\mu, \sigma^2)$, no todas iguales, el EMV de (μ, σ^2) es*

$$\widehat{\mu} = \bar{x}, \qquad \widehat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2.$$

Demostración. Con $v = \sigma^2 > 0$, la log-verosimilitud es

$$\ell(\mu, v) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln v - \frac{1}{2v} \sum_{i=1}^{n} (x_i - \mu)^2.$$

Paso 1 (μ). Para cada v fijo, maximizar ℓ en μ equivale a minimizar $\sum_i (x_i - \mu)^2$, cuyo mínimo está en $\mu = \bar{x}$ (proposición 1.5). Por tanto $\ell(\mu, v) \le \ell(\bar{x}, v)$ para todo (μ, v).

Paso 2 (v). Sea $Q = \sum_i (x_i - \bar{x})^2 > 0$ y $h(v) = \ell(\bar{x}, v) = c - \frac{n}{2} \ln v - \frac{Q}{2v}$. Entonces $h'(v) = -\frac{n}{2v} + \frac{Q}{2v^2} = \frac{Q - nv}{2v^2}$, positiva para $v < Q/n$ y negativa para $v > Q/n$. Luego h alcanza su máximo en $v = Q/n$.

Paso 3. Combinando: $\ell(\mu, v) \le \ell(\bar{x}, v) \le \ell(\bar{x}, Q/n)$ para todo (μ, v). ∎

El EMV de σ^2 coincide con el estimador por momentos y es sesgado (corolario 2.9); por eso, para datos, se usa casi siempre S^2.

Ejemplo 4.6 (Un caso sin derivadas). Si $x_1, \dots, x_n$ son observaciones de $\mathrm{U}(0, \theta)$, entonces $f(x \mid \theta) = 1/\theta$ si $0 \le x \le \theta$ y 0 en otro caso, luego

$$\mathcal{L}(\theta) = \begin{cases} \theta^{-n} & \text{si } \theta \ge \max_i x_i, \\ 0 & \text{si } \theta < \max_i x_i. \end{cases}$$

$\mathcal{L}$ es decreciente en $[\max_i x_i, \infty)$, de modo que $\widehat{\theta} = \max_i x_i$. La ecuación $\ell'(\theta) = 0$ no tiene solución: el máximo está en un extremo del dominio.

Observación 4.7 (Propiedades del EMV). Se enuncian sin demostración, como ampliación [6, cap. 9]: (a) *invariancia*: si $\widehat{\theta}$ es el EMV de θ, el EMV de $g(\theta)$ es $g(\widehat{\theta})$; por ejemplo, el EMV de σ es $\sqrt{\widehat{\sigma^2}}$; (b) en condiciones de regularidad (que no se cumplen en el ejemplo 4.6), el EMV es consistente y aproximadamente normal para n grande, con un error estándar que se puede estimar a partir de la curvatura de ℓ en el máximo.

4.3 Intervalos de confianza

Una estimación puntual no informa de su precisión. Un intervalo de confianza acompaña la estimación de un margen de error con una garantía probabilística.

Definición 4.8 (Intervalo de confianza). Sea $0 < \alpha < 1$. Un *intervalo de confianza* de nivel $1 - \alpha$ para θ es un intervalo $[L, U]$ cuyos extremos $L = L(X_1, \dots, X_n)$ y $U = U(X_1, \dots, X_n)$ son estadísticos y tal que

$$\mathbb{P}_\theta(L \le \theta \le U) \ge 1 - \alpha \qquad \text{para todo } \theta \in \Theta.$$

La probabilidad $\mathbb{P}_\theta(L \le \theta \le U)$ se llama *cobertura* [6, cap. 6].

Observación 4.9 (Interpretación). Lo aleatorio es el intervalo, no el parámetro. Si se repitiera muchas veces el experimento y se calculara cada vez el intervalo de nivel 95 %, aproximadamente el 95 % de esos intervalos contendría el verdadero θ. Una vez observados los datos, el intervalo concreto (por ejemplo, [0,79; 0,84]) contiene o no contiene a θ; no es correcto decir que θ está en él «con probabilidad 0,95» en el sentido frecuentista [3, lectura 23a].

El método general para construir intervalos usa un *pivote*: una función $Q(X_1, \dots, X_n; \theta)$ cuya distribución no depende de θ.

Teorema 4.10 (Intervalo para la media con σ conocida). *Sean $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ i.i.d. con σ conocida. El intervalo*

$$\left[\overline{X} - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}},\ \overline{X} + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right]$$

tiene cobertura exactamente $1-\alpha$. Si los datos no son normales pero n es grande, la cobertura es aproximadamente $1-\alpha$.

Demostración. El pivote $Z = (\overline{X} - \mu)/(\sigma/\sqrt{n})$ tiene distribución $\mathcal{N}(0,1)$ para todo μ (teorema 3.3 y proposición 3.2). Con $c = z_{1-\alpha/2}$, $\mathbb{P}(-c \le Z \le c) = \Phi(c) - \Phi(-c) = 2\Phi(c) - 1 = 1 - \alpha$. Despejando μ en las desigualdades,

$$-c \le \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \le c \iff \overline{X} - c\frac{\sigma}{\sqrt{n}} \le \mu \le \overline{X} + c\frac{\sigma}{\sqrt{n}}.$$

Los dos sucesos son el mismo y tienen la misma probabilidad. Para datos no normales se aplica el mismo argumento con la aproximación del teorema 3.4. ■

La cantidad $E = z_{1-\alpha/2}\,\sigma/\sqrt{n}$ es el *margen de error* (la semiamplitud del intervalo). Los valores más usados son $z_{0,95} = 1{,}645$ (nivel 90 %), $z_{0,975} = 1{,}960$ (95 %) y $z_{0,995} = 2{,}576$ (99 %).

Corolario 4.11 (Tamaño muestral). *Para que el margen de error del teorema 4.10 sea a lo sumo E basta tomar*

$$n \geq \left(\frac{z_{1-\alpha/2}\,\sigma}{E}\right)^2,$$

redondeando al entero superior.

Demostración. $z_{1-\alpha/2}\sigma/\sqrt{n} \leq E \iff \sqrt{n} \geq z_{1-\alpha/2}\sigma/E$, y se elevan al cuadrado ambos miembros, que son positivos. ■

4.4 Intervalo para la media con σ desconocida

En la práctica σ casi nunca se conoce. Al sustituirla por S hay que reemplazar la normal por la t de Student.

Teorema 4.12 (Intervalo t). *Sean $X_1, \ldots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ i.i.d. con σ desconocida y $n \geq 2$. El intervalo*

$$\left[\overline{X} - t_{n-1;1-\alpha/2}\frac{S}{\sqrt{n}},\ \overline{X} + t_{n-1;1-\alpha/2}\frac{S}{\sqrt{n}}\right]$$

tiene cobertura exactamente $1-\alpha$.

Demostración. Por el corolario 3.12, el pivote $T = (\overline{X} - \mu)/(S/\sqrt{n})$ tiene distribución t_{n-1}, que no depende de μ ni de σ. Con $c = t_{n-1;1-\alpha/2}$, la simetría de la t (ejercicio 3.15) da $\mathbb{P}(-c \leq T \leq c) = 1-\alpha$, y se despeja μ como en el teorema 4.10. ■

Como $t_{n-1;1-\alpha/2} > z_{1-\alpha/2}$, el intervalo t es más ancho: refleja la incertidumbre adicional por estimar σ. Para n grande (digamos $n \geq 30$ o más) ambos cuantiles casi coinciden y, por el teorema central del límite, el intervalo es aproximadamente válido aunque los datos no sean normales.

Ejemplo 4.13. Se miden los tiempos de respuesta (en segundos) de un sistema en $n = 10$ consultas y se obtiene $\bar{x} = 2{,}40$ y $s = 0{,}50$. Con $t_{9;0,975} = 2{,}262$, el intervalo de nivel 95 % es $2{,}40 \pm 2{,}262 \cdot 0{,}50/\sqrt{10} = 2{,}40 \pm 0{,}358$, es decir, $[2{,}04;\ 2{,}76]$. Si se hubiera usado 1,96, el margen habría sido 0,310, un 13 % menor.

4.5 Intervalos para proporciones

Si $X_1, \ldots, X_n \sim \mathrm{Ber}(p)$, el corolario 3.7 da $\widehat{p} \approx \mathcal{N}\big(p, p(1-p)/n\big)$. El error estándar depende de p, desconocido, y se estima por $\sqrt{\widehat{p}(1-\widehat{p})/n}$.

Definición 4.14 (Intervalo de Wald para una proporción). El intervalo de confianza aproximado de nivel $1-\alpha$ para p es

$$\widehat{p} \pm z_{1-\alpha/2}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}}.$$

Como $p(1-p) \le 1/4$, el intervalo *conservador* $\widehat{p} \pm z_{1-\alpha/2}/(2\sqrt{n})$ es siempre al menos tan ancho [2, §8.3].

La aproximación es buena si $n\widehat{p}$ y $n(1-\widehat{p})$ son ambos al menos del orden de 10; con muestras pequeñas o con $\widehat{p}$ cercano a 0 o a 1 la cobertura real es inferior a la nominal. Existen correcciones sencillas, como el método de «más cuatro» de [2, §8.3] (sumar dos éxitos y dos fracasos antes de calcular) o el intervalo de Wilson, que quedan fuera de este módulo.

Corolario 4.15 (Tamaño muestral para una proporción). *Para que el margen de error sea a lo sumo E sea cual sea p, basta $n \ge z_{1-\alpha/2}^2/(4E^2)$. Si se dispone de una estimación previa p^*, basta $n \ge z_{1-\alpha/2}^2\, p^*(1-p^*)/E^2$.*

Demostración. Es el corolario 4.11 con $\sigma = \sqrt{p(1-p)}$, acotado por $1/2$ o sustituido por $\sqrt{p^*(1-p^*)}$. ∎

Ejemplo 4.16 (Exactitud en un benchmark). Un modelo acierta 820 de 1000 preguntas. Entonces $\widehat{p} = 0{,}82$, $\widehat{\mathrm{ee}} = \sqrt{0{,}82 \cdot 0{,}18/1000} \approx 0{,}01215$ y el intervalo de nivel 95 % es $0{,}82 \pm 1{,}96 \cdot 0{,}01215 = 0{,}82 \pm 0{,}0238$, es decir, $[0{,}796;\ 0{,}844]$. Para reducir el margen a un punto porcentual ($E = 0{,}01$) harían falta $1{,}96^2 \cdot 0{,}82 \cdot 0{,}18/0{,}01^2 \approx 5671$ preguntas.

Observación 4.17 (Errores frecuentes). (a) Interpretar un intervalo de confianza del 95 % como «hay un 95 % de probabilidad de que θ esté en este intervalo concreto» o como «el 95 % de los datos está en el intervalo» (observación 4.9). (b) Usar z en lugar de t con n pequeño y σ estimada. (c) Olvidar que el margen de error solo recoge el error de muestreo: no protege contra sesgos (por ejemplo, preguntas del benchmark que estaban en los datos de entrenamiento). (d) Para comparar dos modelos, mirar solo si sus intervalos se solapan; dos intervalos que se solapan ligeramente pueden corresponder a una diferencia significativa (tema 5). (e) En el EMV, derivar sin comprobar que el punto crítico es un máximo, o derivar cuando el soporte depende del parámetro (ejemplo 4.6).

Observación 4.18 (Conexión con el curso). El módulo 1 obtiene el EMV de un modelo de bigramas, que generaliza el teorema 4.4 a distribuciones categóricas: la frecuencia relativa. Entrenar un modelo de lenguaje minimizando la entropía cruzada es exactamente maximizar la log-verosimilitud del corpus (módulos 1, 5 y 8). En los módulos 22 y 23 se construyen intervalos de confianza para la exactitud en un benchmark (ejemplo 4.16) y la regla del 3 (ejercicio 4.15) para acotar la tasa de fallos graves cuando no se ha observado ninguno; en el módulo 16, los exponentes de las leyes de escala se estiman con su incertidumbre.

Lecturas recomendadas para este tema

- Wasserman [6], cap. 9 «Parametric Inference» (método de los momentos y máxima verosimilitud) y cap. 6 (intervalos de confianza).
- Stats 200 [5], clases 12 «Parametric models, method of moments estimation», 13 «Maximum likelihood estimation» y 18 «Confidence intervals».
- Orloff y Bloom [3], lecturas 10b «Maximum Likelihood Estimates», 22 «Confidence intervals based on normal data», 23a «Confidence Intervals: Three Views» y 23b «Confidence Intervals for the Mean of Non-normal Data».
- OpenStax [2], cap. 8: §8.1 «A Single Population Mean using the Normal Distribution», §8.2 «A Single Population Mean using the Student t Distribution» y §8.3 «A Population Proportion».
- Rice [4], cap. 8 «Estimation of Parameters and Fitting of Probability Distributions».

Ejercicios del tema 4

Ejercicio 4.1 ⋆ Un estudio concluye que un nuevo método de ajuste fino mejora la exactitud media en 15 puntos, con un intervalo de confianza del 95 % de $[10, 20]$ puntos. Indique cuáles de estas afirmaciones se deducen del intervalo: (i) hay una probabilidad del 95 % de que la mejora real esté entre 10 y 20; (ii) la probabilidad de que el método mejore la exactitud es al menos del 95 %; (iii) el intervalo da una estimación de la mejora real; (iv) la hipótesis de que no hay mejora es probablemente falsa; (v) si se repitiera el estudio muchas veces, alrededor del 95 % de los intervalos contendría la mejora real; (vi) un contraste bilateral al 5 % rechazaría la hipótesis de mejora nula.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 10, problema 5(c).

Ejercicio 4.2 ⋆⋆ (a) Los tiempos entre peticiones a un servidor, en segundos, son 0,5; 1,2; 0,3; 2,0. Suponiendo un modelo exponencial, estime λ por el método de los momentos. (b) Para los datos $2, 4, 4, 5, 7$ y un modelo normal, obtenga las estimaciones de μ y σ^2 por el método de los momentos y compárelas con s^2.

Ejercicio 4.3 ⋆⋆ Sean $X_1, \dots, X_n$ i.i.d. con distribución geométrica en $\{1, 2, 3, \dots\}$, $\mathbb{P}(X = x) = p(1-p)^{x-1}$, cuya media es $1/p$. (a) Obtenga el estimador de p por el método de los momentos. (b) Obtenga el EMV. (c) Calcule ambos con los datos $2, 1, 4, 3, 1, 1$ (número de intentos hasta que un agente resuelve una tarea).

Fuente: adaptado de Stats 200, Stanford [5], *homework* 5, problema 1.

Ejercicio 4.4 ⋆⋆ Una variable positiva tiene densidad $f(x \mid a) = \dfrac{a^5}{4!}\, x^4 e^{-ax}$ para $x > 0$, con $a > 0$. (a) Obtenga el EMV de a a partir de n observaciones i.i.d.. (b) Calcúlelo para los datos 2,0; 3,0; 2,5; 4,5.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 6, problema 1.

Ejercicio 4.5 ⋆⋆ Los datos 1,2; 2,1; 1,3; 10,5; 5 proceden de una distribución $\mathrm{U}(a, b)$. (a) Obtenga el EMV de a y b razonando directamente sobre la verosimilitud, sin derivar. (b) Obtenga los estimadores por el método de los momentos, sabiendo que la media es $(a+b)/2$ y la varianza $(b-a)^2/12$. (c) ¿Son compatibles con los datos los estimadores de (b)?

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 6, problema 3.

Ejercicio 4.6 ⋆⋆ El número de alucinaciones detectadas en ocho documentos generados es $2, 0, 3, 1, 4, 2, 1, 3$. Suponiendo un modelo de Poisson, (a) estime λ; (b) construya un intervalo aproximado del 95 % usando que $\mathrm{Var}(\overline{X}) = \lambda/n$.

Ejercicio 4.7 ⋆⋆ Una máquina llena latas con volúmenes $\mathcal{N}(\mu, \sigma^2)$. Se miden nueve latas (en mL): $352, 351, 361, 353, 352, 358, 360, 358, 359$. (a) Con $\sigma = 3$ conocida, construya los intervalos de confianza del 95 % y del 98 % para μ. (b) Repita el apartado suponiendo σ desconocida y compare.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 10, problema 2.

Ejercicio 4.8 ⋆⋆ Se mide la estatura de 20 personas, que se suponen normales, y se obtiene $\bar{x} = 69{,}55$ y $s^2 = 14{,}26$ (en pulgadas y pulgadas cuadradas). (a) Construya un intervalo t del

90 % para μ. (b) Suponiendo conocida $\sigma = 3{,}77$, construya el intervalo z del 90 %. (c) En la situación de (b), ¿cuántas personas hay que medir para que el intervalo del 90 % tenga una amplitud total de una pulgada?

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 11, problema 1.

Ejercicio 4.9 ⋆⋆ (a) Una población tiene $\sigma = 3$; una muestra de $n = 36$ da $\bar{x} = 68$. Construya el intervalo del 90 % para μ. (b) Si $\sigma = 15$, ¿qué tamaño muestral hace falta para que el margen de error del 95 % sea 2?

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §8.1, ejemplos 8.2 y 8.7.

Ejercicio 4.10 ⋆⋆ (a) En una encuesta a 500 personas, 421 declaran usar un asistente de IA a diario. Construya el intervalo del 95 % para la proporción. (b) ¿Qué tamaño muestral garantiza un margen de error del 3 % con confianza del 90 %, sin información previa sobre p?

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §8.3, ejemplos 8.10 y 8.14.

Ejercicio 4.11 ⋆⋆ Se usa el intervalo conservador $\widehat{p} \pm z_{1-\alpha/2}/(2\sqrt{n})$. (a) ¿Cuántas preguntas debe tener un benchmark para que el margen sea 0,01 al 95 %? Hágalo con $z = 1{,}96$ y con la aproximación $z \approx 2$. (b) ¿Y al 80 %? (c) Una encuesta anuncia un margen de error de ± 4 puntos al 95 %; estime cuántas personas se encuestaron.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], problemas de la clase 23, pregunta conceptual 1 y problema 1.

Ejercicio 4.12 ⋆⋆⋆ Sean $x_1, \dots, x_n$ observaciones i.i.d. de Pois(λ) con $\sum_i x_i > 0$. Demuestre que el EMV de λ es $\bar{x}$, comprobando que es un máximo global, y que coincide con el estimador por momentos.

Ejercicio 4.13 ⋆⋆⋆ Sean $x_1, \dots, x_n > 0$ observaciones i.i.d. de Exp(λ), con densidad $\lambda e^{-\lambda x}$. (a) Demuestre que el EMV de λ es $1/\bar{x}$. (b) Reparametrice el modelo por la media $\beta = 1/\lambda$ y demuestre directamente que el EMV de β es $\bar{x}$, de acuerdo con la propiedad de invariancia.

Ejercicio 4.14 ⋆⋆⋆ La distribución de Laplace con parámetro de posición μ tiene densidad $f(x \mid \mu) = \frac{1}{2} e^{-|x-\mu|}$. Demuestre que el EMV de μ es la mediana muestral. (*Indicación:* ejercicio 1.11.) Compare con el modelo normal, cuyo EMV de la media es $\bar{x}$.

Ejercicio 4.15 ⋆⋆⋆ Se prueban n entradas adversarias independientes contra un modelo y ninguna provoca un fallo grave. Sea p la probabilidad de fallo en cada entrada. (a) Demuestre que el conjunto de valores de p para los que observar cero fallos tiene probabilidad al menos α es $[0, p_{\max}]$ con $p_{\max} = 1 - \alpha^{1/n}$. (b) Demuestre que, para $\alpha = 0{,}05$, $p_{\max} \le -\ln(0{,}05)/n \approx 3/n$ («regla del 3»). (c) Calcule $p_{\max}$ y $3/n$ para $n = 300$.

Ejercicio 4.16 ⋆⋆⋆ Sea $\widehat{p}$ la proporción muestral de n ensayos de Bernoulli. Usando la aproximación normal $\widehat{p} \approx \mathcal{N}(p, p(1-p)/n)$, demuestre que el intervalo conservador $\widehat{p} \pm z_{1-\alpha/2}/(2\sqrt{n})$ tiene cobertura aproximada al menos $1 - \alpha$ para todo $p \in (0, 1)$, con igualdad solo si $p = 1/2$. ¿Qué ocurre con la cobertura aproximada cuando $p = 0{,}1$, $n = 100$ y $\alpha = 0{,}05$?

Tema 5

Contrastes de hipótesis

Un contraste de hipótesis decide, a partir de los datos, si hay evidencia suficiente contra una afirmación sobre la población: que una moneda es equilibrada, que un nuevo modelo no mejora al anterior o que unos recuentos siguen una distribución dada. Este tema presenta el marco de Neyman y Pearson (hipótesis nula y alternativa, región de rechazo, errores de tipo I y II, potencia), el p-valor, los contrastes z y t para medias y proporciones, el contraste χ^2 de bondad de ajuste y el problema de las comparaciones múltiples, con su aplicación a la evaluación de modelos de lenguaje en muchos benchmarks. Se sigue el capítulo 10 de Wasserman [6], «Hypothesis Testing and p-values», las lecturas 17b, 18 y 19 del curso 18.05 del MIT [3], las clases 5, 7 y 11 de Stats 200 [5] y los capítulos 9 y 11 de OpenStax [2].

5.1 Planteamiento de un contraste

Definición 5.1 (Hipótesis, estadístico y región de rechazo). Sea $\{F_\theta : \theta \in \Theta\}$ un modelo y $\Theta_0 \subset \Theta$. Se contrastan la *hipótesis nula* $H_0 : \theta \in \Theta_0$ frente a la *hipótesis alternativa* $H_1 : \theta \in \Theta \setminus \Theta_0$. Una hipótesis es *simple* si especifica un único valor de θ y *compuesta* en otro caso. Un *contraste* consiste en un *estadístico de contraste* $T = T(X_1, \dots, X_n)$ y una *región de rechazo* R: si $T \in R$ se rechaza H_0; si no, no se rechaza.

La hipótesis nula representa la situación por defecto («no hay efecto», «la moneda es equilibrada», «los dos modelos son igual de buenos») y el contraste busca evidencia contra ella. Las alternativas más comunes para un parámetro real son la *bilateral* $H_1 : \theta \neq \theta_0$ y las *unilaterales* $H_1 : \theta > \theta_0$ o $H_1 : \theta < \theta_0$.

Definición 5.2 (Errores, nivel y potencia). Se comete un *error de tipo I* si se rechaza H_0 siendo cierta, y un *error de tipo II* si no se rechaza siendo falsa:

	H_0 cierta	H_0 falsa
No se rechaza H_0	decisión correcta	error de tipo II
Se rechaza H_0	error de tipo I	decisión correcta

El contraste tiene *nivel de significación* α si $\mathbb{P}_\theta(T \in R) \leq \alpha$ para todo $\theta \in \Theta_0$. La *función de potencia* es $\pi(\theta) = \mathbb{P}_\theta(T \in R)$; para $\theta \in \Theta \setminus \Theta_0$, $\pi(\theta)$ es la *potencia* contra esa alternativa y $\beta(\theta) = 1 - \pi(\theta)$ es la probabilidad de error de tipo II [6, cap. 10].

Los dos errores no se pueden reducir a la vez con un tamaño muestral fijo: agrandar la región de rechazo reduce los errores de tipo II y aumenta los de tipo I. El convenio es fijar α (habitualmente 0,05 o 0,01) y, entre los contrastes de nivel α, preferir los más potentes. Las dos hipótesis no son simétricas: no rechazar H_0 no prueba que sea cierta, solo que los datos no aportan evidencia suficiente contra ella.

5.2 El p-valor

Definición 5.3 (p-valor). Supóngase que se rechaza H_0 para valores grandes de un estadístico T y que H_0 es simple. Si el valor observado es t_{obs}, el *p-valor* es

$$p = \mathbb{P}_{H_0}(T \geq t_{\text{obs}}),$$

la probabilidad, calculada suponiendo H_0 cierta, de obtener un resultado al menos tan extremo como el observado. (Si se rechaza para valores pequeños, $p = \mathbb{P}_{H_0}(T \leq t_{\text{obs}})$; en un contraste bilateral con estadístico de distribución simétrica, $p = \mathbb{P}_{H_0}(|T| \geq |t_{\text{obs}}|)$.)

Proposición 5.4 (Decisión con el p-valor). *Sea un contraste que rechaza H_0 si $T \geq c_\alpha$, donde c_α cumple $\mathbb{P}_{H_0}(T \geq c_\alpha) = \alpha$ y T tiene distribución continua bajo H_0. Entonces se rechaza H_0 al nivel α si y solo si $p \leq \alpha$.*

Demostración. Sea $G(t) = \mathbb{P}_{H_0}(T \geq t)$, que es continua y no creciente, de modo que $p = G(t_{\text{obs}})$ y $G(c_\alpha) = \alpha$. Si $t_{\text{obs}} \geq c_\alpha$, entonces $p = G(t_{\text{obs}}) \leq G(c_\alpha) = \alpha$. Recíprocamente, si $t_{\text{obs}} < c_\alpha$, entonces $p = \mathbb{P}_{H_0}(T \geq t_{\text{obs}}) = \mathbb{P}_{H_0}(t_{\text{obs}} \leq T < c_\alpha) + \alpha$, y el primer sumando es positivo si la densidad de T no se anula entre t_{obs} y c_α, de modo que $p > \alpha$. (Si la densidad se anulara en ese tramo, se toma como c_α el menor valor con $G(c_\alpha) = \alpha$ y el argumento es el mismo.) ■

El p-valor es, por tanto, el menor nivel al que los datos permiten rechazar H_0, y resume en un número la fuerza de la evidencia contra H_0: cuanto menor, más incompatibles son los datos con H_0.

Observación 5.5 (Lo que el p-valor no es). El p-valor *no* es la probabilidad de que H_0 sea cierta, ni la probabilidad de que los resultados se deban al azar, ni mide el tamaño del efecto. Un p-valor muy pequeño puede acompañar a un efecto irrelevante si n es enorme, y un efecto grande puede dar un p-valor alto si n es pequeño. Por eso conviene informar siempre del efecto estimado con su intervalo de confianza, además del p-valor [3, lecturas 17b y 20].

5.3 Contrastes z y t

Los contrastes de esta sección usan como estadístico una estimación tipificada con su error estándar calculado bajo H_0. En todos ellos, las regiones de rechazo de nivel α son $T > q_{1-\alpha}$ (alternativa $>$), $T < -q_{1-\alpha}$ (alternativa $<$) y $|T| > q_{1-\alpha/2}$ (bilateral), donde q es el cuantil de la distribución de referencia.

Contraste	H_0	Estadístico	Distribución bajo H_0
z para la media (σ conocida)	$\mu = \mu_0$	$Z = \dfrac{\overline{X} - \mu_0}{\sigma/\sqrt{n}}$	$\mathcal{N}(0,1)$ (datos normales)
t para la media	$\mu = \mu_0$	$T = \dfrac{\overline{X} - \mu_0}{S/\sqrt{n}}$	t_{n-1} (datos normales)
z para una proporción	$p = p_0$	$Z = \dfrac{\widehat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$	$\approx \mathcal{N}(0,1)$ (n grande)

La distribución bajo H_0 se sigue del teorema 3.3, del corolario 3.12 y del corolario 3.7, respectivamente. En el contraste de una proporción, el error estándar se calcula con p_0, no con $\widehat{p}$, porque se razona bajo H_0.

Ejemplo 5.6 (Contraste z unilateral). Se afirma que un modelo genera respuestas de $\mu_0 = 200$ tokens de media, con $\sigma = 80$. En $n = 64$ respuestas se observa $\bar{x} = 221$. Se contrasta $H_0 : \mu = 200$ frente a $H_1 : \mu > 200$ al nivel 0,05. El estadístico vale $z = (221 - 200)/(80/8) = 2{,}1 > z_{0{,}95} = 1{,}645$, y $p = 1 - \Phi(2{,}1) = 0{,}0179 < 0{,}05$: se rechaza H_0.

5.4 Potencia y tamaño muestral

Proposición 5.7 (Potencia del contraste z unilateral). *Para el contraste z de $H_0 : \mu = \mu_0$ frente a $H_1 : \mu > \mu_0$ al nivel α con datos $\mathcal{N}(\mu, \sigma^2)$, la función de potencia es*

$$\pi(\mu) = 1 - \Phi\Big(z_{1-\alpha} - \frac{(\mu - \mu_0)\sqrt{n}}{\sigma}\Big).$$

Demostración. Se rechaza si $\overline{X} > \mu_0 + z_{1-\alpha}\sigma/\sqrt{n}$. Si la media verdadera es μ, entonces $(\overline{X} - \mu)/(\sigma/\sqrt{n}) \sim \mathcal{N}(0,1)$, y

$$\pi(\mu) = \mathbb{P}_\mu\Big(\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} > \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} + z_{1-\alpha}\Big) = 1 - \Phi\Big(z_{1-\alpha} - \frac{(\mu - \mu_0)\sqrt{n}}{\sigma}\Big). \qquad \blacksquare$$

En el ejemplo 5.6, si la media real fuera 220, la potencia sería $1 - \Phi(1{,}645 - 2) = \Phi(0{,}355) \approx 0{,}64$: con 64 respuestas, el contraste detectaría esa diferencia solo en dos de cada tres ocasiones. El ejercicio 5.16 deduce el tamaño muestral necesario para alcanzar una potencia dada.

5.5 Contraste χ^2 de bondad de ajuste

Sea una variable categórica con k categorías y probabilidades $p_1, \dots, p_k$. En n observaciones independientes se obtienen los recuentos $O_1, \dots, O_k$, con $\sum_j O_j = n$. Se quiere contrastar $H_0 : p_j = p_{0j}$ para todo j, con p_{0j} dados.

Definición 5.8 (Estadístico χ^2 de Pearson). Sean $E_j = n p_{0j}$ los recuentos *esperados* bajo H_0. El estadístico es

$$X^2 = \sum_{j=1}^{k} \frac{(O_j - E_j)^2}{E_j}.$$

Bajo H_0, y si todos los E_j son al menos 5, X^2 sigue aproximadamente una distribución χ^2_{k-1}. Se rechaza H_0 al nivel α si $X^2 > \chi^2_{k-1;1-\alpha}$ [2, §11.2].

Los $k-1$ grados de libertad se deben a la restricción $\sum_j O_j = n$: conocidos $k-1$ recuentos, el último queda determinado. Si se estiman m parámetros del modelo a partir de los mismos datos, se restan también: $k-1-m$ grados de libertad. Si algún E_j es menor que 5, se agrupan categorías contiguas.

Ejemplo 5.9 (¿Es equilibrado un dado?). En 120 lanzamientos de un dado se obtienen los recuentos $25, 17, 15, 23, 24, 16$ para las caras 1 a 6. Bajo H_0 (dado equilibrado), $E_j = 20$ y

$$X^2 = \frac{25 + 9 + 25 + 9 + 16 + 16}{20} = \frac{100}{20} = 5.$$

Con 5 grados de libertad, $\chi^2_{5;0{,}95} = 11{,}07$; como $5 < 11{,}07$, no se rechaza H_0 al 5 % (el p-valor es aproximadamente 0,42).

5.6 Comparaciones múltiples

Si se realizan muchos contrastes, cada uno al nivel α, la probabilidad de cometer *algún* error de tipo I crece rápidamente.

Proposición 5.10. *Si se realizan m contrastes independientes al nivel α y todas las hipótesis nulas son ciertas, la probabilidad de rechazar al menos una es $1-(1-\alpha)^m$, y el número esperado de rechazos (todos falsos) es $m\alpha$.*

Demostración. Cada contraste no rechaza con probabilidad $1-\alpha$; por independencia, ninguno rechaza con probabilidad $(1-\alpha)^m$. El número de rechazos es una suma de m indicadores con esperanza α cada uno. ∎

Con $m = 20$ y $\alpha = 0{,}05$, la probabilidad de al menos un «descubrimiento» falso es $1 - 0{,}95^{20} \approx 0{,}64$.

Definición 5.11 (Tasa de error por familia). La *tasa de error por familia* (FWER, *family-wise error rate*) de un procedimiento que realiza m contrastes es la probabilidad de cometer al menos un error de tipo I [5, clase 11].

Teorema 5.12 (Corrección de Bonferroni). *Si cada uno de los m contrastes se realiza al nivel α/m (es decir, se rechaza la hipótesis i si $p_i \le \alpha/m$), la tasa de error por familia es a lo sumo α, cualquiera que sea la dependencia entre los contrastes y cualquiera que sea el conjunto de hipótesis nulas ciertas.*

Demostración. Sea I_0 el conjunto de índices de las hipótesis nulas ciertas, con $m_0 = |I_0| \le m$, y sea A_i el suceso «se rechaza $H_{0,i}$». Para $i \in I_0$, $\mathbb{P}(A_i) \le \alpha/m$ porque el contraste i tiene nivel α/m. Por la desigualdad de la unión (subaditividad de la probabilidad),

$$\mathrm{FWER} = \mathbb{P}\Big(\bigcup_{i\in I_0} A_i\Big) \le \sum_{i\in I_0} \mathbb{P}(A_i) \le m_0 \frac{\alpha}{m} \le \alpha. \qquad ∎$$

La corrección de Bonferroni es sencilla y muy general, pero conservadora: con m grande reduce mucho la potencia. Existen procedimientos más potentes, como el de Holm o el de Benjamini y Hochberg, que controla una cantidad distinta, la tasa de falsos descubrimientos [5, clase 11]; quedan fuera de este módulo.

Observación 5.13 (Comparar modelos en muchos benchmarks). La evaluación de modelos de lenguaje es un terreno abonado para las comparaciones múltiples: se comparan dos modelos en decenas de benchmarks, se prueban muchas variantes de *prompt* y se informa de la mejor, o se ordena una tabla con cientos de modelos. Si en 20 benchmarks independientes no hay ninguna diferencia real, se esperan $20 \cdot 0{,}05 = 1$ diferencias «significativas» al 5 %. Para comparar la exactitud de dos modelos se puede usar un contraste z de diferencia de proporciones (ejercicio 5.11); cuando ambos modelos responden a las *mismas* preguntas, es preferible un contraste pareado que use las diferencias pregunta a pregunta, porque elimina la variabilidad debida a la dificultad de cada pregunta (ampliación).

Observación 5.14 (Errores frecuentes). (a) Formular la hipótesis nula a partir de los datos ya vistos, o elegir el contraste unilateral después de ver en qué sentido va el efecto. (b) Concluir «H_0 es cierta» porque no se rechaza. (c) Interpretar el p-valor como $\mathbb{P}(H_0 \mid \text{datos})$ (observación 5.5). (d) En el contraste χ^2, usar proporciones o porcentajes en lugar de recuentos, o no

restar los parámetros estimados de los grados de libertad. (e) Realizar muchos contrastes y destacar solo los significativos sin corregir por multiplicidad.

Observación 5.15 (Conexión con el curso). Los módulos 22 y 23 comparan modelos con exactitudes medidas sobre conjuntos finitos de preguntas y discuten la significación de las diferencias, la contaminación de los benchmarks y su saturación; las ideas de este tema (error estándar, potencia, comparaciones múltiples) son las que permiten decidir si una mejora de un punto en una tabla de resultados es real. En el módulo 21, las preferencias humanas entre pares de respuestas se agregan con modelos probabilísticos cuyas diferencias también deben valorarse frente al ruido de muestreo.

Lecturas recomendadas para este tema

- Wasserman [6], cap. 10 «Hypothesis Testing and p-values» (incluye el contraste de Wald, el χ^2 de Pearson y los contrastes múltiples).
- Orloff y Bloom [3], lecturas 17b «Null Hypothesis Significance Testing I», 18 «NHST II», 19 «NHST III» y 20 «Comparison of frequentist and Bayesian inference».
- Stats 200 [5], clases 5 «Testing a simple null hypothesis», 7 «Composite hypotheses and the t-test» y 11 «Testing multiple hypotheses».
- OpenStax [2], cap. 9: §9.1 «Null and Alternative Hypotheses», §9.2 «Outcomes and the Type I and Type II Errors» y §9.5 «Additional Information and Full Hypothesis Test Examples»; §11.2 «Goodness-of-Fit Test».
- Rice [4], cap. 9 «Testing Hypotheses and Assessing Goodness of Fit».

Ejercicios del tema 5

Ejercicio 5.1 ⋆ Un contraste da $p = 0{,}03$. Indique si cada afirmación es verdadera o falsa. (a) La probabilidad de que H_0 sea cierta es 0,03. (b) Al nivel 0,05 se rechaza H_0. (c) Al nivel 0,01 se rechaza H_0. (d) Si H_0 fuera cierta, un resultado al menos tan extremo como el observado ocurriría con probabilidad 0,03. (e) El efecto observado es grande. (f) Si no se hubiera rechazado H_0, quedaría demostrado que es cierta.

Ejercicio 5.2 ⋆⋆ Una moneda se hace girar sobre su canto 250 veces y sale cara 140 veces. Sea θ la probabilidad de cara y $H_0 : \theta = 0{,}5$ frente a $H_1 : \theta \neq 0{,}5$. (a) Calcule el p-valor con la aproximación normal y corrección por continuidad. (b) ¿Se rechaza H_0 al nivel 0,10? ¿Y al 0,05? (c) ¿Cuántas caras harían falta para rechazar al nivel 0,01? (d) Con la región de rechazo de nivel 0,05, estime la potencia contra $\theta = 0{,}6$.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 8, problema 1.

Ejercicio 5.3 ⋆⋆ En un estudio sobre detectores de mentiras, 140 personas dicen la verdad y 140 mienten. De las sinceras, 131 son clasificadas como sinceras y 9 como mentirosas; de las que mienten, 15 son clasificadas como sinceras y 125 como mentirosas. Con H_0: «la persona dice la verdad», describa los errores de tipo I y II y estime sus probabilidades, el nivel y la potencia del detector.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 8, problema 2.

Ejercicio 5.4 ⋆⋆ Tres radares miden la velocidad de cada coche con errores independientes $\mathcal{N}(0, 5^2)$ (en km/h) y se usa la media $\overline{X}$ de las tres lecturas. El límite es 40 y se quiere multar a lo sumo al 4 % de los conductores que circulan exactamente a 40. (a) Plantee el contraste y halle el umbral de multa. (b) Si nadie superase el límite, ¿qué fracción de las multas sería errónea? (c) Calcule la potencia contra $\mu = 45$. (d) ¿Cuántos radares harían falta para que esa potencia fuera 0,9?

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 8, problema 3.

Ejercicio 5.5 ⋆⋆ Se observa un único valor x de una distribución $\mathrm{U}(0, \theta)$ para contrastar $H_0 : \theta = 2$ frente a $H_1 : \theta \neq 2$, y se rechaza H_0 si $x \leq 0{,}1$ o $x \geq 1{,}9$. (a) Calcule la probabilidad de error de tipo I. (b) Calcule la probabilidad de error de tipo II si $\theta = 2{,}5$.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 8, problema 4.

Ejercicio 5.6 ⋆⋆ Una muestra normal de tamaño $n = 16$ tiene $\bar{x} = 11$ y $s^2 = 4$. Contraste $H_0 : \mu = 10$ al nivel 0,05 (a) frente a $H_1 : \mu \neq 10$ y (b) frente a $H_1 : \mu > 10$. Dé en cada caso el valor crítico y acote el p-valor con la cuadro B.3.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 9, problema 1.

Ejercicio 5.7 ⋆⋆ Un fabricante afirma que sus envases contienen de media 16,43 onzas, con $\sigma = 0{,}8$. Una muestra de 15 envases da $\bar{x} = 16$. Contraste al nivel 0,05 si la media es menor que la anunciada, calculando el estadístico y el p-valor.

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §9.5, ejemplo 9.14.

Ejercicio 5.8 ⋆⋆ Un tratamiento es eficaz, según su fabricante, en el 25 % de los casos o menos. En una muestra de 42 casos es eficaz en 17. Al nivel 0,01, ¿hay evidencia de que la proporción de éxitos es mayor que 0,25?

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §9.5, ejemplo 9.19.

Ejercicio 5.9 ⋆⋆ Las ausencias de 60 empleados se reparten entre los días laborables así: lunes 15, martes 12, miércoles 9, jueves 9, viernes 15. Contraste al nivel 0,05 si las ausencias se reparten uniformemente entre los cinco días.

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §11.2, ejemplo 11.2.

Ejercicio 5.10 ⋆⋆ Según la ley de Benford, el primer dígito k de muchas cantidades contables tiene probabilidades 0,301; 0,176; 0,125; 0,097; 0,079; 0,067; 0,058; 0,051; 0,046 para $k = 1, \ldots, 9$. En 100 partidas de una nota de gastos, los primeros dígitos aparecen $7, 13, 12, 9, 9, 13, 11, 10, 16$ veces. Contraste al nivel 0,001 si los datos siguen la ley de Benford.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 9, problema 4.

Ejercicio 5.11 ⋆⋆ Dos modelos se evalúan sobre muestras independientes de 1000 preguntas cada una: A acierta 780 y B, 750. (a) Plantee el contraste $H_0 : p_A = p_B$ frente a $H_1 : p_A \neq p_B$. (b) Bajo H_0, estime la varianza de $\widehat{p}_A - \widehat{p}_B$ con la proporción combinada y calcule el estadístico z y el p-valor. (c) ¿Es significativa la diferencia al 5 %?

Fuente: adaptado de Stats 200, Stanford [5], *homework* 3, problema 3.

Ejercicio 5.12 ⋆⋆ Se compara un modelo con otro en 20 benchmarks independientes y, en realidad, ambos son igual de buenos en todos. (a) Si cada comparación se contrasta al 5 %, ¿cuál es la probabilidad de encontrar al menos una diferencia significativa? ¿Cuántas se esperan? (b) ¿A qué nivel debe hacerse cada contraste con la corrección de Bonferroni? ¿Cuál es entonces exactamente la probabilidad de al menos un falso positivo?

Ejercicio 5.13 ⋆⋆⋆ Se realizan n contrastes independientes con p-valores $P_1, \dots, P_n$. (a) Si todas las nulas son ciertas y los P_i son i.i.d. $\mathrm{U}(0,1)$, demuestre que $\mathbb{P}(\min_i P_i \le t) = 1-(1-t)^n$ para $t \in (0,1)$. (b) Deduzca que realizar cada contraste al nivel $1-(1-\alpha)^{1/n}$ da una probabilidad de algún falso positivo exactamente igual a α. (c) Demuestre que $\alpha/n \le 1-(1-\alpha)^{1/n}$, de modo que este procedimiento es al menos tan potente como el de Bonferroni. (*Indicación:* desigualdad de Bernoulli, $(1+x)^n \ge 1+nx$ para $x \ge -1$.)

Fuente: adaptado de Stats 200, Stanford [5], *homework* 4, problema 4.

Ejercicio 5.14 ⋆⋆⋆ Sea T un estadístico con función de distribución continua y estrictamente creciente F_0 bajo H_0, y sea $p = 1 - F_0(T)$ el p-valor del contraste que rechaza para valores grandes de T. Demuestre que, bajo H_0, $p \sim \mathrm{U}(0,1)$, y deduzca que $\mathbb{P}_{H_0}(p \le \alpha) = \alpha$.

Ejercicio 5.15 ⋆⋆⋆ Sean datos $\mathcal{N}(\mu, \sigma^2)$ con σ conocida. Demuestre que, para cada μ_0, el contraste z bilateral de nivel α *no* rechaza $H_0 : \mu = \mu_0$ si y solo si μ_0 pertenece al intervalo de confianza de nivel $1-\alpha$ del teorema 4.10. Interprete el resultado.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], problemas de la clase 23, problema 2.

Ejercicio 5.16 ⋆⋆⋆ Con la función de potencia de la proposición 5.7: (a) demuestre que π es creciente en μ y que $\pi(\mu_0) = \alpha$; (b) demuestre que, para $\mu > \mu_0$ fijo, $\pi(\mu) \to 1$ cuando $n \to \infty$; (c) demuestre que la potencia contra $\mu_1 = \mu_0 + \delta$ ($\delta > 0$) es al menos $1-\beta$ si y solo si

$$n \ge \left(\frac{(z_{1-\alpha} + z_{1-\beta})\,\sigma}{\delta} \right)^2 ;$$

(d) aplíquelo al ejemplo 5.6 con $\delta = 20$, $\alpha = 0{,}05$ y potencia $0{,}9$.

Tema 6

Regresión lineal simple y correlación

La regresión estudia cómo cambia en promedio una variable respuesta y cuando cambia una variable explicativa x. Este tema deduce la recta de mínimos cuadrados, estudia los residuos y la descomposición de la variabilidad que da lugar al coeficiente de determinación R^2, muestra cómo las transformaciones logarítmicas permiten ajustar leyes de potencia y termina con la distinción entre correlación y causalidad. Se sigue el capítulo 12 de OpenStax [2] (§12.3 «The Regression Equation»), el capítulo 14 de Rice [4], «Linear Least Squares», el capítulo 13 de Wasserman [6], «Linear and Logistic Regression», y la lectura 26 del curso 18.05 del MIT [3]; para la causalidad, el capítulo 16 de Wasserman, «Causal Inference».

6.1 La recta de mínimos cuadrados

Se dispone de $n \geq 2$ pares $(x_1, y_1), \dots, (x_n, y_n)$ con los x_i no todos iguales. Se usan las sumas centradas

$$S_{xx} = \sum_{i=1}^{n} (x_i - \bar{x})^2, \qquad S_{yy} = \sum_{i=1}^{n} (y_i - \bar{y})^2, \qquad S_{xy} = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}),$$

de modo que $s_x^2 = S_{xx}/(n-1)$, $s_{xy} = S_{xy}/(n-1)$ y $r = S_{xy}/\sqrt{S_{xx}S_{yy}}$ (definición 1.16). Por la proposición 1.12, $S_{xx} = \sum x_i^2 - n\bar{x}^2$ y, análogamente, $S_{xy} = \sum x_i y_i - n\bar{x}\bar{y}$.

Definición 6.1 (Recta de mínimos cuadrados). Para cada recta $y = b_0 + b_1 x$, el *valor ajustado* del dato i es $\widehat{y}_i = b_0 + b_1 x_i$ y el *residuo* es $e_i = y_i - \widehat{y}_i$. La *recta de mínimos cuadrados* (o de regresión de y sobre x) es la que minimiza la suma de cuadrados de los residuos

$$\mathrm{SC}(b_0, b_1) = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2.$$

Teorema 6.2 (Coeficientes de mínimos cuadrados). *Si $S_{xx} > 0$, la función* SC *tiene un único mínimo, en*

$$\widehat{b}_1 = \frac{S_{xy}}{S_{xx}} = r\,\frac{s_y}{s_x}, \qquad \widehat{b}_0 = \bar{y} - \widehat{b}_1 \bar{x},$$

y el valor mínimo es $S_{yy} - S_{xy}^2/S_{xx} = S_{yy}(1 - r^2)$.

Demostración. Paso 1 (separar la ordenada). Sea $c = \bar{y} - b_0 - b_1\bar{x}$. Entonces $y_i - b_0 - b_1 x_i = \big[(y_i - \bar{y}) - b_1(x_i - \bar{x})\big] + c$. Al desarrollar el cuadrado y sumar, el término cruzado es $2c\sum_i \big[(y_i - \bar{y}) - b_1(x_i - \bar{x})\big] = 0$, porque las desviaciones respecto de la media suman cero (proposición 1.5). Por tanto,

$$\mathrm{SC}(b_0, b_1) = \sum_{i} \big[(y_i - \bar{y}) - b_1(x_i - \bar{x})\big]^2 + n\,c^2.$$

Paso 2 (completar el cuadrado en b_1). Desarrollando el primer sumando,

$$\sum_i \big[(y_i-\bar y)-b_1(x_i-\bar x)\big]^2 = S_{yy}-2b_1S_{xy}+b_1^2S_{xx} = S_{xx}\Big(b_1-\frac{S_{xy}}{S_{xx}}\Big)^2 + S_{yy}-\frac{S_{xy}^2}{S_{xx}}.$$

Paso 3 (minimizar). Como $S_{xx}>0$, $\mathrm{SC}(b_0,b_1)\geq S_{yy}-S_{xy}^2/S_{xx}$, con igualdad si y solo si $b_1=S_{xy}/S_{xx}$ y $c=0$, es decir, $b_0=\bar y-b_1\bar x$. Finalmente, $S_{xy}/S_{xx}=r\sqrt{S_{yy}/S_{xx}}=r\,s_y/s_x$ y $S_{xy}^2/S_{xx}=r^2S_{yy}$. ∎

La condición $\widehat{b}_0=\bar y-\widehat{b}_1\bar x$ dice que la recta pasa por el punto de medias $(\bar x,\bar y)$. La pendiente tiene el signo de r: es positiva cuando la asociación es creciente.

Ejemplo 6.3. Para los datos del ejemplo 1.18, $(1,2),(2,4),(3,5),(4,4),(5,5)$: $S_{xx}=10$, $S_{yy}=6$ y $S_{xy}=6$. Entonces $\widehat{b}_1=0{,}6$, $\widehat{b}_0=4-0{,}6\cdot 3=2{,}2$ y la recta es $\widehat{y}=2{,}2+0{,}6x$ (figura 6.1). Los residuos son $-0{,}8;\ 0{,}6;\ 1{,}0;\ -0{,}6;\ -0{,}2$, que suman cero, y su suma de cuadrados es $2{,}4=6\,(1-0{,}6)$.

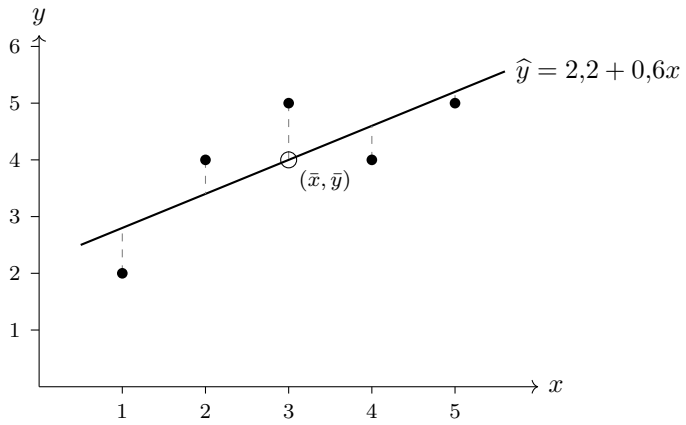


Figura 6.1: Recta de mínimos cuadrados del ejemplo 6.3. Los segmentos discontinuos son los residuos; la recta pasa por el punto de medias $(3,4)$.

6.2 Residuos y coeficiente de determinación

Proposición 6.4 (Propiedades de los residuos). *Para la recta de mínimos cuadrados, $\sum_i e_i=0$, $\sum_i x_ie_i=0$ y $\sum_i \widehat{y}_ie_i=0$.*

La demostración es el ejercicio 6.12. Las dos primeras igualdades son las *ecuaciones normales* (ejercicio 6.11): los residuos son ortogonales, como vectores de $\mathbb{R}^n$, al vector de unos y al vector de las x_i. Este es el punto de vista geométrico que el módulo 8 generaliza a varias variables explicativas.

Teorema 6.5 (Descomposición de la variabilidad). *Sean $\mathrm{SC}_T=\sum_i(y_i-\bar y)^2=S_{yy}$ (suma de cuadrados total), $\mathrm{SC}_R=\sum_i(\widehat{y}_i-\bar y)^2$ (explicada por la regresión) y $\mathrm{SC}_E=\sum_i e_i^2$ (residual o de error). Entonces*

$$\mathrm{SC}_T=\mathrm{SC}_R+\mathrm{SC}_E\,.$$

Demostración. Se escribe $y_i - \bar{y} = (\widehat{y}_i - \bar{y}) + e_i$ y se eleva al cuadrado: $\sum_i (y_i - \bar{y})^2 = \sum_i (\widehat{y}_i - \bar{y})^2 + \sum_i e_i^2 + 2\sum_i (\widehat{y}_i - \bar{y}) e_i$. El último término es $2\sum_i \widehat{y}_i e_i - 2\bar{y}\sum_i e_i = 0 - 0$ por la proposición 6.4. ∎

Definición 6.6 (Coeficiente de determinación). El *coeficiente de determinación* es $R^2 = \mathrm{SC}_R \,/\, \mathrm{SC}_T = 1 - \mathrm{SC}_E \,/\, \mathrm{SC}_T$, la fracción de la variabilidad de y explicada por la recta. Por el teorema 6.5, $0 \le R^2 \le 1$.

Corolario 6.7. *En la regresión lineal simple,* $R^2 = r^2$.

Demostración. Por el teorema 6.2, $\mathrm{SC}_E = S_{yy}(1 - r^2)$, luego $R^2 = 1 - \mathrm{SC}_E \,/ S_{yy} = r^2$. ∎

En el ejemplo 6.3, $R^2 = 0{,}6$: la recta explica el 60 % de la variabilidad de y. La dispersión de los puntos alrededor de la recta se resume en el *error típico residual* $s_e = \sqrt{\mathrm{SC}_E \,/ (n-2)}$; se divide por $n - 2$ porque se han estimado dos parámetros (compárese con la observación 1.11).

6.3 Diagnóstico con residuos

Un R^2 alto no garantiza que el modelo lineal sea adecuado. La herramienta básica de diagnóstico es el *gráfico de residuos*, que representa e_i frente a x_i (o frente a $\widehat{y}_i$). Si el modelo es adecuado, los residuos se distribuyen sin estructura alrededor de cero. Algunas señales de alarma [2, §12.3]:

(i) una curvatura sistemática (residuos positivos en los extremos y negativos en el centro, o al revés) indica que la relación no es lineal;

(ii) una dispersión que crece con x (forma de embudo) indica varianza no constante;

(iii) un punto con un residuo muy grande es un posible atípico, y un punto con x_i muy alejado de $\bar{x}$ puede ser muy *influyente*: puede cambiar mucho la recta por sí solo.

Además, la recta solo describe la relación en el rango de los x_i observados: *extrapolar* fuera de ese rango (ejercicio 6.5) es arriesgado.

Observación 6.8 (El modelo estadístico). Si se supone que $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ con errores $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ i.i.d., la log-verosimilitud de (β_0, β_1) es una constante menos $\frac{1}{2\sigma^2}\,\mathrm{SC}(\beta_0, \beta_1)$; por tanto, los estimadores de mínimos cuadrados son los estimadores de máxima verosimilitud [6, cap. 13], [3, *problem set* 6]. Con este modelo pueden construirse intervalos de confianza y contrastes para la pendiente (ampliación), que se estudian en [4, cap. 14].

6.4 Transformaciones: ajuste de leyes de potencia

Muchas relaciones no lineales se vuelven lineales tras una transformación. Una *ley de potencia* $y = a\,x^b$ con $a, x, y > 0$ cumple

$$\log y = \log a + b \log x,$$

de modo que en escala log-log es una recta de pendiente b y ordenada $\log a$. Para ajustarla se aplica mínimos cuadrados a los pares $(\log x_i, \log y_i)$ y se deshace la transformación: $\widehat{a} = 10^{\widehat{b}_0}$ (o $e^{\widehat{b}_0}$ si se usan logaritmos naturales) y $\widehat{b} = \widehat{b}_1$. Análogamente, una relación exponencial $y = a\,e^{bx}$ se linealiza con $\ln y = \ln a + bx$. Obsérvese que así se minimizan los errores *relativos* (en escala logarítmica), no los absolutos.

Ejemplo 6.9. Si la pérdida de un modelo cumpliera exactamente $L = 20\,N^{-0{,}1}$, al multiplicar el número de parámetros N por 10 la pérdida se multiplicaría por $10^{-0{,}1} \approx 0{,}794$, y en escala log-log los puntos estarían sobre una recta de pendiente $-0{,}1$. El ejercicio 6.8 ajusta una ley así a partir de cuatro mediciones.

6.5 Correlación y causalidad

Una correlación entre x e y puede deberse a que x influye en y, a que y influye en x (causalidad inversa), a que una tercera variable z influye en ambas (*variable de confusión*) o simplemente al azar. Los datos observacionales, por sí solos, no permiten distinguir estos casos [6, cap. 16].

Ejemplo 6.10 (Variable de confusión). En un conjunto de modelos de lenguaje, la longitud media de las respuestas y la puntuación en un benchmark de razonamiento pueden estar fuertemente correlacionadas. De ahí no se sigue que alargar artificialmente las respuestas mejore la puntuación: ambos rasgos pueden deberse a una tercera variable, como el tamaño del modelo o el entrenamiento con cadenas de razonamiento.

Un caso extremo de confusión es la *paradoja de Simpson*: una asociación que se da en cada uno de los grupos de una población puede invertirse al agregar los grupos, cuando los tamaños de los grupos difieren entre las condiciones comparadas (ejercicio 6.9).

La forma más fiable de establecer una relación causal es el *experimento aleatorizado*: si el tratamiento (por ejemplo, el *prompt* A o el B) se asigna al azar a las unidades (las preguntas), las variables de confusión se reparten en promedio por igual entre los grupos, y una diferencia sistemática en la respuesta solo puede atribuirse al tratamiento o al azar, cuya magnitud se cuantifica con los contrastes del tema 5.

Observación 6.11 (Errores frecuentes). (a) Interpretar la pendiente como efecto causal con datos observacionales. (b) Extrapolar la recta fuera del rango de los datos. (c) Concluir que no hay relación porque $r \approx 0$ (la relación puede ser no lineal; ejercicio 6.10). (d) Creer que la recta de regresión de x sobre y es la inversa de la de y sobre x: solo lo es si $|r| = 1$ (ejercicio 6.7). (e) Juzgar un ajuste solo por R^2, sin mirar el gráfico de residuos.

Observación 6.12 (Conexión con el curso). El módulo 8 generaliza la recta de mínimos cuadrados a varias variables mediante las ecuaciones normales $X^\top X\widehat{\boldsymbol{\beta}} = X^\top \mathbf{y}$ y su interpretación como proyección, de la que la proposición 6.4 es el caso más sencillo, y demuestra que mínimos cuadrados es máxima verosimilitud con errores normales (observación 6.8). El módulo 16 ajusta en escala log-log las leyes de escala que relacionan la pérdida con el número de parámetros, de datos y de operaciones (ejemplo 6.9). En el módulo 23, las sondas lineales detectan *correlaciones* entre activaciones y conceptos, mientras que las intervenciones causales (modificar una activación y observar el efecto) son el análogo del experimento aleatorizado.

Lecturas recomendadas para este tema

- OpenStax [2], §12.3 «The Regression Equation» y §12.4 «Testing the Significance of the Correlation Coefficient».
- Rice [4], cap. 14 «Linear Least Squares».
- Wasserman [6], cap. 13 «Linear and Logistic Regression» y cap. 16 «Causal Inference».
- Orloff y Bloom [3], lectura 26 «Linear regression».

– Stats 200 [5], clase 25 «The linear model».

Ejercicios del tema 6

Ejercicio 6.1 ⋆ Indique si cada afirmación es verdadera o falsa. (a) La recta de mínimos cuadrados pasa siempre por $(\bar{x}, \bar{y})$. (b) Si $r = -0{,}9$, entonces $R^2 = -0{,}81$. (c) Un R^2 cercano a 1 prueba que x causa y. (d) La suma de los residuos de mínimos cuadrados es cero. (e) Si se intercambian los papeles de x e y, la pendiente pasa a ser $1/\widehat{b}_1$.

Ejercicio 6.2 ⋆⋆ Para los datos $(0,1), (1,3), (2,2), (3,5), (4,4)$: (a) calcule S_{xx}, S_{yy}, S_{xy} y r; (b) obtenga la recta de mínimos cuadrados; (c) calcule los residuos, SC_E, R^2 y s_e; (d) prediga y para $x = 2{,}5$.

Ejercicio 6.3 ⋆⋆ Se ajusta el modelo $y_i = ax_i + b + \varepsilon_i$ con errores $\mathcal{N}(0, \sigma^2)$ i.i.d. a los datos $(1,8), (3,2), (5,1)$. (a) Escriba la log-verosimilitud de un dato (x_1, y_1). (b) Obtenga los EMV de a y b y compruebe que no dependen de σ.

Fuente: adaptado de Orloff y Bloom, MIT 18.05 [3], *problem set* 6, problema 2.

Ejercicio 6.4 ⋆⋆ Las notas de once estudiantes en un tercer examen (x, sobre 80) y en el final (y, sobre 200) cumplen $n = 11$, $\sum x_i = 761$, $\sum y_i = 1765$, $\sum x_i^2 = 52\,729$, $\sum y_i^2 = 287\,529$ y $\sum x_i y_i = 122\,500$. (a) Calcule la recta de regresión y r. (b) Prediga la nota final de un estudiante con 73 en el tercer examen. (c) Un estudiante tiene $(65, 175)$; calcule su residuo.

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §12.3, ejemplo 12.6.

Ejercicio 6.5 ⋆⋆ La profundidad de una inmersión (x, en pies) y el tiempo máximo de inmersión (y, en minutos) son $(50,80), (60,55), (70,45), (80,35), (90,25), (100,22)$. (a) Calcule la recta de regresión y r. (b) Prediga y para $x = 85$ y para $x = 110$. ¿Cuál de las dos predicciones es fiable? (c) Observe el signo de los residuos en los extremos y en el centro: ¿qué sugiere?

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §12.3, *Try It* 12.6.

Ejercicio 6.6 ⋆⋆ La temperatura máxima (x, en grados Fahrenheit) y el número de helados vendidos (y) en nueve días son $(70,105)$, $(85,240)$, $(65,49)$, $(72,147)$, $(80,231)$, $(61,38)$, $(75,193)$, $(78,196)$, $(68,89)$. Se dan $\sum x_i = 654$, $\sum y_i = 1288$, $\sum x_i^2 = 47\,988$, $\sum y_i^2 = 231\,026$ y $\sum x_i y_i = 98\,132$. Calcule la recta de regresión, r y R^2, y prediga las ventas de un día a 74 grados.

Fuente: adaptado de OpenStax, *Introductory Statistics* 2e [2], §12.3, ejemplo «Ice Cream Cones».

Ejercicio 6.7 ⋆⋆ De un conjunto de pares se conocen $\bar{x} = 10$, $\bar{y} = 50$, $s_x = 2$, $s_y = 8$ y $r = 0{,}75$. (a) Obtenga la recta de regresión de y sobre x y prediga y para $x = 12$. (b) Obtenga la recta de regresión de x sobre y. (c) Compruebe que el producto de las dos pendientes es r^2 y que las dos rectas no coinciden.

Ejercicio 6.8 ⋆⋆ Se mide la pérdida L de cuatro modelos con $N = 10^6, 10^7, 10^8, 10^9$ parámetros y se obtiene $L = 5{,}0;\ 4{,}1;\ 3{,}3;\ 2{,}7$, cuyos logaritmos decimales son $0{,}6990;\ 0{,}6128;\ 0{,}5185;$

0,4314. (a) Ajuste una ley de potencia $L = aN^{-\alpha}$ por mínimos cuadrados en escala log-log. (b) Prediga la pérdida para $N = 10^{10}$. (c) ¿Por qué esta predicción es una extrapolación?

Ejercicio 6.9 ⋆⋆ Dos modelos se evalúan en un banco con preguntas fáciles y difíciles. El modelo A acierta 45 de 50 fáciles y 75 de 250 difíciles; el modelo B acierta 200 de 250 fáciles y 10 de 50 difíciles. (a) Calcule las exactitudes de cada modelo en cada tipo de pregunta y en total. (b) ¿Qué modelo es mejor? Explique la aparente contradicción.

Ejercicio 6.10 ⋆⋆ Para los puntos $(-2, 4), (-1, 1), (0, 0), (1, 1), (2, 4)$, en los que $y = x^2$: (a) calcule r y la recta de mínimos cuadrados; (b) calcule los residuos y describa el patrón del gráfico de residuos; (c) ¿qué se concluye?

Ejercicio 6.11 ⋆⋆⋆ Demuestre el teorema 6.2 por otra vía: (a) obtenga las ecuaciones normales igualando a cero las derivadas parciales de $\mathrm{SC}(b_0, b_1)$; (b) resuélvalas; (c) compruebe que la matriz hessiana es definida positiva, de modo que el punto crítico es un mínimo (y, por ser SC un polinomio de grado 2, global).

Ejercicio 6.12 ⋆⋆⋆ Demuestre la proposición 6.4: $\sum_i e_i = 0$, $\sum_i x_i e_i = 0$ y $\sum_i \widehat{y}_i e_i = 0$. Deduzca que la media de los valores ajustados es $\bar{y}$.

Ejercicio 6.13 ⋆⋆⋆ (a) Demuestre que la recta que pasa por el origen y minimiza $\sum_i (y_i - b x_i)^2$ tiene pendiente $\widehat{b} = \sum_i x_i y_i / \sum_i x_i^2$ (suponga que algún $x_i \neq 0$). (b) Demuestre que sus residuos cumplen $\sum_i x_i e_i = 0$ y dé un ejemplo en el que $\sum_i e_i \neq 0$.

Ejercicio 6.14 ⋆⋆⋆ Sean $x'_i = \alpha x_i + \beta$ e $y'_i = \gamma y_i + \delta$ con $\alpha, \gamma \neq 0$. Demuestre que la pendiente de mínimos cuadrados de y' sobre x' es $\widehat{b}'_1 = (\gamma/\alpha)\,\widehat{b}_1$, que R^2 no cambia y que los residuos se multiplican por γ. ¿Cómo cambia la pendiente al pasar x de metros a centímetros?

Ejercicio 6.15 ⋆⋆⋆ Sean $z_{x,i} = (x_i - \bar{x})/s_x$ y $z_{y,i} = (y_i - \bar{y})/s_y$. (a) Demuestre que la recta de mínimos cuadrados, escrita en unidades tipificadas, es $\widehat{z}_y = r\, z_x$. (b) Deduzca que, si $|r| < 1$, la predicción de y está a menos desviaciones típicas de su media que x de la suya («regresión a la media»). (c) Un modelo obtiene en una primera evaluación una puntuación 2 desviaciones típicas por encima de la media de los modelos; si la correlación entre dos evaluaciones es 0,5, ¿qué puntuación tipificada se predice para la segunda?

Apéndice A

Soluciones de los ejercicios

Cada solución se presenta en cinco partes: datos, planteamiento, desarrollo, resultado y comprobación. En los pasos intermedios se redondea a cuatro cifras significativas salvo que se indique otra cosa; los valores de Φ y los cuantiles se toman de las tablas del apéndice B o se dan con cuatro decimales. En los ejercicios de demostración, el apartado «Desarrollo» contiene la demostración redactada tal como debería entregarse.

A.1 Tema 1

Solución del ejercicio 1.1

Planteamiento. contrastar cada afirmación con las definiciones del tema 1.

Desarrollo.

(a) **Verdadera** (si $n \geq 3$). El mayor dato sigue siendo el mayor después de multiplicarlo por 10, de modo que el orden de los demás no cambia y la mediana, que depende solo de los valores centrales, tampoco. (Con $n = 2$ la mediana es la media de los dos datos y sí cambia.)

(b) **Falsa.** s es la raíz cuadrada no negativa de una suma de cuadrados dividida por $n-1 > 0$.

(c) **Verdadera.** Si $x_i = c$ para todo i, entonces $\bar{x} = c$, todas las desviaciones son nulas y $s = 0$; además $Q_1 = Q_3 = c$.

(d) **Falsa.** Por el teorema 1.17, los puntos están sobre una recta si y solo si $|r| = 1$.

(e) **Verdadera.** Por la proposición 1.14 con $a = 1$, $b = 5$: $s_y^2 = s_x^2$ y $\mathrm{RIC}_y = \mathrm{RIC}_x$.

Resultado. **(a) V (para $n \geq 3$); (b) F; (c) V; (d) F; (e) V.**

Solución del ejercicio 1.2

Datos. $4, 7, 2, 9, 5, 6, 3, 25, 6$; $n = 9$.

Planteamiento. ordenar, aplicar las definiciones 1.3, 1.6 y 1.7 y la fórmula de cálculo (proposición 1.12).

Desarrollo.

1. Ordenados: $2, 3, 4, 5, 6, 6, 7, 9, 25$. Suma 67; $\bar{x} = 67/9 \approx 7{,}444$.
2. Mediana: el dato quinto, 6. Moda: 6 (aparece dos veces).
3. Mitad inferior $2, 3, 4, 5$: $Q_1 = (3+4)/2 = 3{,}5$. Mitad superior $6, 7, 9, 25$: $Q_3 = (7+9)/2 = 8$. RIC $= 4{,}5$.
4. Vallas: $3{,}5 - 1{,}5 \cdot 4{,}5 = -3{,}25$ y $8 + 6{,}75 = 14{,}75$. El dato 25 es atípico.

5. $\sum x_i^2 = 16+49+4+81+25+36+9+625+36 = 881$; $n\bar{x}^2 = 67^2/9 = 4489/9 \approx 498{,}78$; suma de cuadrados $881 - 498{,}78 = 382{,}22$; $s^2 = 382{,}22/8 \approx 47{,}78$; $s \approx 6{,}912$.
6. Sin el 25 ($n = 8$): suma 42, $\bar{x} = 5{,}25$; mediana $(5+6)/2 = 5{,}5$; $\sum x_i^2 = 256$, suma de cuadrados $256 - 8 \cdot 5{,}25^2 = 256 - 220{,}5 = 35{,}5$, $s^2 = 35{,}5/7 \approx 5{,}071$, $s \approx 2{,}252$.

Resultado. $\bar{x} \approx 7{,}44$**; mediana** 6**; moda** 6**;** $Q_1 = 3{,}5$**;** $Q_3 = 8$**;** RIC $= 4{,}5$**; vallas** $-3{,}25$ **y** $14{,}75$**;** $s^2 \approx 47{,}78$**;** $s \approx 6{,}91$**; el** 25 **es atípico.** Sin él, $\bar{x} = 5{,}25$, mediana 5,5, $s \approx 2{,}25$: la media baja unas dos unidades y s se reduce a menos de la tercera parte, mientras que la mediana apenas cambia.

Comprobación. la suma de desviaciones con todos los datos es $67 - 9 \cdot \frac{67}{9} = 0$, como exige la proposición 1.5.

Solución del ejercicio 1.3

Datos. $n = 20$ edades; $\sum x_i = 210{,}5$; $\sum x_i^2 = 2225{,}25$.

Planteamiento. aplicar las definiciones; los datos ya están ordenados.

Desarrollo.

1. $\bar{x} = 210{,}5/20 = 10{,}525$.
2. Mediana: media de los datos décimo y undécimo, ambos 10,5; mediana 10,5.
3. Mitad inferior (diez primeros): sus valores quinto y sexto son 10 y 10, luego $Q_1 = 10$. Mitad superior (diez últimos): sus valores quinto y sexto son 11 y 11, luego $Q_3 = 11$.
4. Suma de cuadrados: $2225{,}25 - 20 \cdot 10{,}525^2 = 2225{,}25 - 2215{,}5125 = 9{,}7375$; $s^2 = 9{,}7375/19 \approx 0{,}5125$; $s \approx 0{,}7159$.
5. Intervalo $\bar{x} \pm s = (9{,}809;\ 11{,}241)$. Contiene los valores 10 (cuatro veces), 10,5 (cuatro) y 11 (seis): 14 datos.

Resultado. $\bar{x} = 10{,}525$**; mediana** 10,5**;** $Q_1 = 10$**;** $Q_3 = 11$**;** $s \approx 0{,}716$**; el** 70 % **de los datos está a menos de una desviación típica de la media.**

Comprobación. la fuente da $s \approx 0{,}72$. El 70 % es parecido al 68 % que se esperaría con datos de forma aproximadamente normal (tema 3).

Solución del ejercicio 1.4

Datos. mañana $(32; 56; 74{,}5; 82{,}5; 99)$; tarde $(25{,}5; 78; 81; 89; 98)$.

Planteamiento. rango = máximo − mínimo; RIC $= Q_3 - Q_1$; vallas de la definición 1.7.

Desarrollo.

1. Mañana: rango $99 - 32 = 67$; RIC $= 82{,}5 - 56 = 26{,}5$.
2. Tarde: rango $98 - 25{,}5 = 72{,}5$; RIC $= 89 - 78 = 11$.
3. La mitad central más dispersa es la de la mañana ($26{,}5 > 11$), aunque el rango de la tarde sea mayor.
4. Vallas de la mañana: $56 - 1{,}5 \cdot 26{,}5 = 16{,}25$ y $82{,}5 + 39{,}75 = 122{,}25$; el mínimo 32 no es atípico.

5. Vallas de la tarde: $78-16{,}5=61{,}5$ y $89+16{,}5=105{,}5$; el mínimo $25{,}5<61{,}5$ es atípico, y el bigote inferior acaba en el menor dato no atípico, que no se conoce con el resumen (está entre 61,5 y 78).
6. Esbozo: la caja de la tarde es estrecha y está desplazada a la derecha (de 78 a 89, mediana 81), con el 25,5 marcado aparte; la de la mañana es ancha (de 56 a 82,5, mediana 74,5) con bigotes hasta 32 y 99.

Resultado. **Rangos 67 y 72,5; RIC 26,5 y 11; la mañana tiene la mitad central más dispersa; solo el mínimo de la tarde es atípico.**

Comprobación. el rango de la tarde es mayor solo por un dato: el RIC, robusto, revela que el grupo de la tarde es más homogéneo.

Solución del ejercicio 1.5

Datos. marcas $m_j=1,4,7,10,13,16$; frecuencias $f_j=1,6,10,7,0,2$; $n=26$.

Planteamiento. $\bar{x}\approx\frac{1}{n}\sum_j f_j m_j$ y $s^2\approx\frac{1}{n-1}\big(\sum_j f_j m_j^2-n\bar{x}^2\big)$.

Desarrollo.

1. $\sum f_j m_j=1+24+70+70+0+32=197$; $\bar{x}=197/26\approx 7{,}577$.
2. $\sum f_j m_j^2=1+96+490+700+0+512=1799$.
3. $n\bar{x}^2=197^2/26=38\,809/26\approx 1492{,}65$; suma de cuadrados $1799-1492{,}65=306{,}35$.
4. $s^2\approx 306{,}35/25\approx 12{,}25$; $s\approx 3{,}50$.

Resultado. $\bar{x}\approx 7{,}58$ **y** $s\approx 3{,}50$**.**

Comprobación. la fuente obtiene los mismos valores. Son aproximaciones: se ha supuesto que todos los datos de cada clase valen la marca de clase.

Solución del ejercicio 1.6

Datos. $n=10$, $\sum x_i=50$, $\sum x_i^2=290$; nuevo dato $x_{11}=5$.

Planteamiento. fórmula de cálculo (proposición 1.12); las sumas se actualizan sumando el nuevo dato.

Desarrollo.

1. $\bar{x}=50/10=5$; suma de cuadrados $290-10\cdot 25=40$; $s^2=40/9\approx 4{,}444$.
2. Con el nuevo dato: $\sum x_i=55$, $\sum x_i^2=290+25=315$, $n=11$, $\bar{x}=5$.
3. Suma de cuadrados $315-11\cdot 25=40$; $s^2=40/10=4$.

Resultado. **(a)** $\bar{x}=5$**,** $s^2=40/9\approx 4{,}44$**. (b)** $\bar{x}=5$**,** $s^2=4$**.**

Comprobación. el dato añadido coincide con la media, de modo que no altera la suma de cuadrados (40); solo aumenta el denominador, y la varianza disminuye.

Solución del ejercicio 1.7

Datos. $18,21,25,19,22,30,24$ $(n=7)$; $F=1{,}8C+32$.

Planteamiento. calcular en Celsius y transformar con la proposición 1.14 ($a=1{,}8>0$).

Desarrollo.

1. Ordenados: $18, 19, 21, 22, 24, 25, 30$; suma 159; $\bar{x} = 159/7 \approx 22{,}71$; mediana 22.
2. Mitad inferior $18, 19, 21$: $Q_1 = 19$; superior $24, 25, 30$: $Q_3 = 25$; RIC $= 6$.
3. $\sum x_i^2 = 3711$; suma de cuadrados $3711 - 159^2/7 = 3711 - 3611{,}57 = 99{,}43$; $s^2 = 99{,}43/6 \approx 16{,}57$; $s \approx 4{,}071$.
4. Fahrenheit: $\bar{x}_F = 1{,}8 \cdot 22{,}714 + 32 \approx 72{,}89$; mediana $1{,}8 \cdot 22 + 32 = 71{,}6$; $s_F = 1{,}8 \cdot 4{,}071 \approx 7{,}327$; $\mathrm{RIC}_F = 1{,}8 \cdot 6 = 10{,}8$.
5. Las puntuaciones z no cambian: $z_i^F = \dfrac{1{,}8x_i + 32 - (1{,}8\bar{x} + 32)}{1{,}8\, s} = \dfrac{x_i - \bar{x}}{s}$.

Resultado. **Celsius:** $\bar{x} \approx 22{,}71$**, mediana** 22**,** $s \approx 4{,}07$**,** RIC $= 6$**. Fahrenheit:** $\bar{x} \approx 72{,}89$**, mediana** $71{,}6$**,** $s \approx 7{,}33$**,** RIC $= 10{,}8$**. Las puntuaciones** z **son las mismas.**

Comprobación. el desplazamiento $+32$ afecta a la media y a la mediana, pero no a s ni al RIC.

Solución del ejercicio 1.8

Datos. Juan: $x = 2{,}85$, media $3{,}0$, $s = 0{,}7$. Alí: $x = 77$, media 80, $s = 10$.

Planteamiento. comparar puntuaciones tipificadas (definición 1.15).

Desarrollo.

1. $z_{\text{Juan}} = (2{,}85 - 3{,}0)/0{,}7 = -0{,}15/0{,}7 \approx -0{,}214$.
2. $z_{\text{Alí}} = (77 - 80)/10 = -0{,}3$.

Resultado. **Juan**, porque su nota está a 0,21 desviaciones típicas por debajo de la media de su centro, frente a 0,30 en el caso de Alí.

Comprobación. la comparación directa de 2,85 con 77 carece de sentido porque las escalas son distintas; la tipificación las hace comparables.

Solución del ejercicio 1.9

Datos. $X, Y \in \{-1, 1\}$ con $\mathbb{P}(X = 1) = \mathbb{P}(Y = 1) = 1/2$; $c = \mathbb{P}(X = 1, Y = 1)$.

Planteamiento. completar la tabla con las marginales y usar $\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.

Desarrollo.

1. Como $\mathbb{P}(X = 1) = 1/2$, $\mathbb{P}(X = 1, Y = -1) = 1/2 - c$; análogamente $\mathbb{P}(X = -1, Y = 1) = 1/2 - c$ y $\mathbb{P}(X = -1, Y = -1) = 1 - c - 2(1/2 - c) = c$. Debe ser $0 \le c \le 1/2$.
2. $\mathbb{E}[X] = \mathbb{E}[Y] = 0$ y $\operatorname{Var} X = \operatorname{Var} Y = \mathbb{E}[X^2] = 1$.
3. $XY = 1$ con probabilidad $2c$ y $XY = -1$ con probabilidad $1 - 2c$, luego $\mathbb{E}[XY] = 2c - (1 - 2c) = 4c - 1$.
4. $\mathrm{Cov}(X, Y) = 4c - 1$ y $\mathrm{Cor}(X, Y) = (4c - 1)/\sqrt{1 \cdot 1} = 4c - 1$.
5. Independencia: debe cumplirse $\mathbb{P}(X = 1, Y = 1) = \frac{1}{2} \cdot \frac{1}{2}$, es decir, $c = 1/4$; entonces las cuatro casillas valen $1/4$ y la tabla es producto de las marginales.
6. $\mathrm{Cor} = 1 \iff c = 1/2$ (entonces $Y = X$); $\mathrm{Cor} = -1 \iff c = 0$ (entonces $Y = -X$).

Resultado. $\mathrm{Cov}(X, Y) = \mathrm{Cor}(X, Y) = 4c - 1$**; independientes si y solo si** $c = 1/4$**; correlación** 1 **si** $c = 1/2$ **y** -1 **si** $c = 0$**.**

Comprobación. $c \in [0, 1/2]$ da $\mathrm{Cor} \in [-1, 1]$, de acuerdo con la acotación de la correlación.

Solución del ejercicio 1.10

Datos. $n_1 = 10$, $\bar{x}_1 = 70$, $s_1 = 8$; $n_2 = 15$, $\bar{x}_2 = 80$, $s_2 = 6$.

Planteamiento. la suma de cuadrados respecto de la media global $\bar{x}$ se descompone por la proposición 1.5(ii): $\sum_{\text{grupo } g}(x_i - \bar{x})^2 = (n_g - 1)s_g^2 + n_g(\bar{x}_g - \bar{x})^2$.

Desarrollo.

1. $\bar{x} = (10 \cdot 70 + 15 \cdot 80)/25 = (700 + 1200)/25 = 76$.
2. Grupo 1: $9 \cdot 64 + 10 \cdot (70 - 76)^2 = 576 + 360 = 936$.
3. Grupo 2: $14 \cdot 36 + 15 \cdot (80 - 76)^2 = 504 + 240 = 744$.
4. Total: $936 + 744 = 1680$; $s^2 = 1680/24 = 70$; $s = \sqrt{70} \approx 8{,}367$.

Resultado. $\bar{x} = 76$ **y** $s \approx 8{,}37$**.**

Comprobación. s es mayor que las dos desviaciones de grupo porque se añade la variabilidad entre las medias de los grupos.

Solución del ejercicio 1.11

Planteamiento. estudiar la pendiente de g en cada intervalo entre datos ordenados consecutivos.

Desarrollo.

1. g es continua y lineal a trozos. Sea a un punto que no coincide con ningún dato y sean $L(a) = \#\{i : x_i < a\}$ y $U(a) = \#\{i : x_i > a\}$, de modo que $L(a) + U(a) = n$. Cerca de a, cada término con $x_i < a$ vale $a - x_i$ (pendiente $+1$) y cada término con $x_i > a$ vale $x_i - a$ (pendiente -1). Por tanto, $g'(a) = L(a) - U(a)$.
2. Si $L(a) < n/2$, entonces $U(a) > n/2$ y $g'(a) < 0$: g decrece. Si $L(a) > n/2$, g crece.
3. Caso $n = 2m + 1$ impar. Para $a < x_{(m+1)}$ (y fuera de los datos) hay a lo sumo $m < n/2$ datos menores que a, y g decrece; para $a > x_{(m+1)}$ hay al menos $m + 1 > n/2$, y g crece. Por continuidad, el mínimo está en $a = x_{(m+1)}$, la mediana.
4. Caso $n = 2m$ par. Para $a < x_{(m)}$, $L(a) \le m - 1 < m$ y g decrece; para $a > x_{(m+1)}$, $L(a) \ge m + 1$ y g crece; para $x_{(m)} < a < x_{(m+1)}$, $L(a) = U(a) = m$ y g es constante. Luego g es mínima en todo el intervalo $[x_{(m)}, x_{(m+1)}]$, que contiene la mediana $\frac{1}{2}(x_{(m)} + x_{(m+1)})$.

Resultado. g **alcanza su mínimo en la mediana** (si n es par, en todo el intervalo entre los dos datos centrales). ■

Comprobación. con los datos $1, 2, 10$: $g(2) = 1 + 0 + 8 = 9$, $g(3) = 2 + 1 + 7 = 10$ y $g(\bar{x}) = g(13/3) \approx 3{,}33 + 2{,}33 + 5{,}67 = 11{,}33$; la media no minimiza la suma de valores absolutos.

Solución del ejercicio 1.12

Planteamiento. por la proposición 1.14, $x'_i - \bar{x}' = a(x_i - \bar{x})$ e $y'_i - \bar{y}' = c(y_i - \bar{y})$.

Desarrollo.

1. $s_{x'y'} = \frac{1}{n-1}\sum_i a(x_i - \bar{x})\, c(y_i - \bar{y}) = ac\, s_{xy}$.
2. $s_{x'} = |a|\, s_x$ y $s_{y'} = |c|\, s_y$.
3. $r_{x'y'} = \dfrac{ac\, s_{xy}}{|a||c|\, s_x s_y} = \dfrac{ac}{|ac|}\, r_{xy} = \text{signo}(ac)\, r_{xy}$.

4. Un cambio de unidades es una transformación con $a > 0$ (o $c > 0$), luego no altera r.

Resultado. $s_{x'y'} = ac\, s_{xy}$ **y** $r_{x'y'} = \text{signo}(ac)\, r_{xy}$; la correlación es adimensional. ■

Comprobación. con los datos del ejemplo 1.18 y $x' = 10x$: la covarianza pasa de 1,5 a 15 y r sigue valiendo 0,775.

Solución del ejercicio 1.13

Planteamiento. acotar inferiormente la suma de cuadrados por la contribución de los datos alejados.

Desarrollo.

1. Sea $A = \{i : |x_i - \bar{x}| \geq ks\}$ y $N_A = |A|$.
2. Como todos los sumandos son no negativos,

$$(n-1)s^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2 \geq \sum_{i \in A}(x_i - \bar{x})^2 \geq N_A\, k^2 s^2.$$

3. Dividiendo por $nk^2s^2 > 0$: $N_A/n \leq (n-1)/(nk^2) < 1/k^2$.
4. Con $k = 2$: menos del 25 % de los datos dista $2s$ o más de la media; al menos el 75 % está en $(\bar{x} - 2s, \bar{x} + 2s)$.

Resultado. **La fracción es a lo sumo** $(n-1)/(nk^2) < 1/k^2$; para $k = 2$, al menos el 75 % de los datos está a menos de dos desviaciones típicas de la media, sea cual sea la forma de los datos. ■

Comprobación. en el ejemplo 1.2, $\bar{x} \pm 2s = (-1{,}45;\ 36{,}2)$ deja fuera solo el 40: $1/8 = 12{,}5\,\% \leq 7/32 \approx 21{,}9\,\%$.

Solución del ejercicio 1.14

Planteamiento. escribir $m\bar{x}_m = (m-1)\bar{x}_{m-1} + x_m$ y aplicar la proposición 1.5(ii) a los $m-1$ primeros datos con $a = \bar{x}_m$.

Desarrollo.

1. Media: $\bar{x}_m = \dfrac{(m-1)\bar{x}_{m-1} + x_m}{m} = \bar{x}_{m-1} + \dfrac{x_m - \bar{x}_{m-1}}{m}$.
2. Por la proposición 1.5(ii), $\sum_{i=1}^{m-1}(x_i - \bar{x}_m)^2 = M_{m-1} + (m-1)(\bar{x}_{m-1} - \bar{x}_m)^2$. Sumando el término $i = m$: $M_m = M_{m-1} + (m-1)(\bar{x}_{m-1} - \bar{x}_m)^2 + (x_m - \bar{x}_m)^2$.
3. Sea $d = x_m - \bar{x}_{m-1}$. Por el paso 1, $\bar{x}_m - \bar{x}_{m-1} = d/m$ y $x_m - \bar{x}_m = d - d/m = d(m-1)/m$.
4. Sustituyendo: $(m-1)\dfrac{d^2}{m^2} + \dfrac{(m-1)^2 d^2}{m^2} = \dfrac{(m-1)d^2(1+m-1)}{m^2} = \dfrac{(m-1)d^2}{m} = d \cdot \dfrac{(m-1)d}{m} = (x_m - \bar{x}_{m-1})(x_m - \bar{x}_m)$.
5. Datos $2, 4, 9$: $\bar{x}_1 = 2$, $M_1 = 0$; $\bar{x}_2 = 2 + 2/2 = 3$, $M_2 = 0 + (4-2)(4-3) = 2$; $\bar{x}_3 = 3 + 6/3 = 5$, $M_3 = 2 + (9-3)(9-5) = 26$.

Resultado. **Las dos fórmulas son ciertas**; con $2, 4, 9$ se obtiene $\bar{x}_3 = 5$, $M_3 = 26$ y $s^2 = 26/2 = 13$. ■

Comprobación. directamente: $(2-5)^2 + (4-5)^2 + (9-5)^2 = 9 + 1 + 16 = 26$.

Solución del ejercicio 1.15

Planteamiento. desarrollar la suma sobre todos los pares ordenados y usar $\sum_i (x_i - \bar{x}) = 0$.

Desarrollo.

1. Sean $u_i = x_i - \bar{x}$; como $x_i - x_j = u_i - u_j$, se trabaja con los u_i, que suman cero.
2. Sumando sobre todos los pares ordenados (i, j), incluidos $i = j$ (que aportan 0):

$$\sum_{i=1}^{n}\sum_{j=1}^{n}(u_i - u_j)^2 = \sum_{i,j} u_i^2 + \sum_{i,j} u_j^2 - 2\Big(\sum_i u_i\Big)\Big(\sum_j u_j\Big) = 2n\sum_i u_i^2 - 0.$$

3. Cada par no ordenado $\{i, j\}$ con $i \neq j$ aparece dos veces, luego $\sum_{i<j}(x_i - x_j)^2 = n\sum_i u_i^2 = n(n-1)s^2$.
4. Dividiendo por $n(n-1)$ se obtiene la identidad.

Resultado. $s^2 = \frac{1}{n(n-1)}\sum_{i<j}(x_i - x_j)^2$**.** ■

Comprobación. con $2, 4, 9$: $(2-4)^2 + (2-9)^2 + (4-9)^2 = 4 + 49 + 25 = 78$ y $78/(3 \cdot 2) = 13$, que coincide con el ejercicio 1.14.

A.2 Tema 2

Solución del ejercicio 2.1

Planteamiento. aplicar las definiciones 2.2 a 2.4.

Desarrollo.

1. Población: el banco de un millón de preguntas (o, mejor, la variable «acierto» en cada una de ellas).
2. Muestra: las 500 preguntas elegidas al azar, con variables $X_1, \ldots, X_{500}$, donde $X_i = 1$ si el modelo acierta la pregunta i.
3. Parámetro: la exactitud real p, fracción de aciertos en todo el banco; es un número fijo y desconocido.
4. Estimador: $\widehat{p} = \overline{X} = \frac{1}{500}\sum_i X_i$, una variable aleatoria. Estimación: su valor observado $410/500 = 0{,}82$.

Resultado. **El número** 0,82 **no es aleatorio (es un valor observado);** $\widehat{p}$ **sí lo es**, porque con otra muestra de 500 preguntas tomaría otro valor.

Comprobación. la muestra (500) es mucho menor que la población (10^6), de modo que el muestreo sin reemplazamiento se puede tratar como i.i.d. (definición 2.2).

Solución del ejercicio 2.2

Datos. población $\{1, 3, 5\}$ equiprobable; $n = 2$ con reemplazamiento.

Planteamiento. enumerar las $3^2 = 9$ muestras equiprobables y calcular $\bar{x}$ y $s^2 = (x_1 - x_2)^2/2$ en cada una.

Desarrollo.

1. $\mu = (1+3+5)/3 = 3$; $\sigma^2 = \big((1-3)^2 + 0 + (5-3)^2\big)/3 = 8/3$.
2. Muestras y medias: $(1,1) \to 1$; $(1,3),(3,1) \to 2$; $(1,5),(3,3),(5,1) \to 3$; $(3,5),(5,3) \to 4$; $(5,5) \to 5$. Distribución de $\overline{X}$: valores $1,2,3,4,5$ con probabilidades $\frac{1}{9}, \frac{2}{9}, \frac{3}{9}, \frac{2}{9}, \frac{1}{9}$.
3. $\mathbb{E}[\overline{X}] = (1+4+9+8+5)/9 = 27/9 = 3 = \mu$.
4. $\mathrm{Var}(\overline{X}) = \big(4\cdot 1 + 1\cdot 2 + 0\cdot 3 + 1\cdot 2 + 4\cdot 1\big)/9 = 12/9 = 4/3 = \sigma^2/2$.
5. Para $n=2$, $s^2 = \big((x_1-\bar{x})^2 + (x_2-\bar{x})^2\big)/1 = (x_1-x_2)^2/2$. Vale 0 en las tres muestras con $x_1 = x_2$, 2 en las cuatro con $|x_1 - x_2| = 2$ y 8 en las dos con $|x_1 - x_2| = 4$.
6. $\mathbb{E}[S^2] = (0\cdot 3 + 2\cdot 4 + 8\cdot 2)/9 = 24/9 = 8/3 = \sigma^2$.
7. $\widehat{\sigma}^2 = S^2/2$, luego $\mathbb{E}[\widehat{\sigma}^2] = 4/3$.

Resultado. $\mu = 3$, $\sigma^2 = 8/3$; $\mathbb{E}[\overline{X}] = 3$, $\mathrm{Var}(\overline{X}) = 4/3$; $\mathbb{E}[S^2] = 8/3$; $\mathbb{E}[\widehat{\sigma}^2] = 4/3$, la mitad de σ^2.

Comprobación. el corolario 2.9 predice $\mathbb{E}[\widehat{\sigma}^2] = \frac{n-1}{n}\sigma^2 = \frac{1}{2}\cdot\frac{8}{3} = \frac{4}{3}$.

Solución del ejercicio 2.3

Datos. X_1, X_2, X_3 i.i.d., media μ, varianza σ^2.

Planteamiento. para $T = \sum_i a_i X_i$: $\mathbb{E}[T] = \mu \sum_i a_i$ y $\mathrm{Var}(T) = \sigma^2 \sum_i a_i^2$ (proposición 2.1); después, proposición 2.5.

Desarrollo.

1. T_1: $a = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$; $\sum a_i = 1$, sesgo 0; $\sum a_i^2 = \frac{1}{3}$; ECM = Var $= \sigma^2/3$.
2. T_2: $a = (\frac{1}{4}, \frac{1}{2}, \frac{1}{4})$; $\sum a_i = 1$, sesgo 0; $\sum a_i^2 = \frac{1}{16} + \frac{1}{4} + \frac{1}{16} = \frac{3}{8}$; ECM $= 3\sigma^2/8$.
3. T_3: $a = (1, 1, -1)$; $\sum a_i = 1$, sesgo 0; $\sum a_i^2 = 3$; ECM $= 3\sigma^2$.
4. T_4: $a = (\frac{1}{4}, \frac{1}{4}, \frac{1}{4})$; $\mathbb{E}[T_4] = \frac{3}{4}\mu$, sesgo $-\mu/4$; Var $= \frac{3}{16}\sigma^2$; ECM $= \frac{3\sigma^2}{16} + \frac{\mu^2}{16}$.
5. Entre los insesgados, $\frac{1}{3} < \frac{3}{8} < 3$: el mejor es T_1.
6. $\mathrm{ECM}(T_4) < \mathrm{ECM}(T_1) \iff \frac{3\sigma^2+\mu^2}{16} < \frac{\sigma^2}{3} \iff \mu^2 < \frac{16\sigma^2}{3} - 3\sigma^2 = \frac{7\sigma^2}{3}$.

Resultado. **Sesgos** $0, 0, 0, -\mu/4$**; varianzas** $\sigma^2/3$**,** $3\sigma^2/8$**,** $3\sigma^2$**,** $3\sigma^2/16$**; el mejor insesgado es** $\overline{X}$**;** T_4 **es mejor que** $\overline{X}$ **si y solo si** $|\mu| < \sigma\sqrt{7/3} \approx 1{,}528\,\sigma$**.**

Comprobación. para $\mu = 0$, T_4 es insesgado y tiene varianza $3\sigma^2/16 < \sigma^2/3$: encoger hacia el cero ayuda cuando el parámetro está cerca de cero.

Solución del ejercicio 2.4

Datos. $X_i \sim \mathrm{Pois}(\lambda)$, $\mathbb{E}X_i = \mathrm{Var}\, X_i = \lambda$; $n = 50$, $\bar{x} = 3{,}2$.

Planteamiento. teorema 2.6 con $\mu = \sigma^2 = \lambda$.

Desarrollo.

1. $\mathbb{E}[\widehat{\lambda}] = \lambda$: insesgado.
2. $\mathrm{Var}(\widehat{\lambda}) = \lambda/n$; $\mathrm{ee}(\widehat{\lambda}) = \sqrt{\lambda/n}$; ECM = Var $= \lambda/n$.
3. Estimación: $\widehat{\lambda} = 3{,}2$. Error estándar estimado: $\sqrt{3{,}2/50} = \sqrt{0{,}064} \approx 0{,}2530$.

Resultado. $\widehat{\lambda}$ **es insesgado, con** $\mathrm{Var} = \mathrm{ECM} = \lambda/n$ **y** $\mathrm{ee} = \sqrt{\lambda/n}$**; con los datos,** $\widehat{\lambda} = 3{,}2$ **y** $\widehat{\mathrm{ee}} \approx 0{,}253$**.**

Comprobación. el error estándar es pequeño frente a 3,2 (un 8 %), coherente con $n = 50$ bloques.

Solución del ejercicio 2.5

Datos. $\mathbb{E}[1/\overline{X}] = n\lambda/(n-1)$; $n = 5$; $\sum x_i = 10$.

Planteamiento. sesgo $= \mathbb{E}[\widehat{\lambda}] - \lambda$; elegir c para que $\mathbb{E}[c/\overline{X}] = \lambda$.

Desarrollo.

1. $\mathrm{sesgo}(1/\overline{X}) = \dfrac{n\lambda}{n-1} - \lambda = \dfrac{\lambda}{n-1} > 0$: sobrestima λ.
2. $\mathbb{E}[c/\overline{X}] = c\,n\lambda/(n-1) = \lambda \iff c = (n-1)/n$. El estimador insesgado es $\dfrac{n-1}{n\overline{X}} = \dfrac{n-1}{\sum_i X_i}$.
3. Datos: $\bar{x} = 2$; $1/\bar{x} = 0{,}5$; insesgado: $4/10 = 0{,}4$.

Resultado. **Sesgo** $\lambda/(n-1)$**; estimador insesgado** $(n-1)/\sum_i X_i$**; estimaciones** 0,5 **y** 0,4**.**

Comprobación. el sesgo tiende a cero cuando $n \to \infty$ y la corrección $(n-1)/n \to 1$; con $n = 5$ la diferencia es del 20 %.

Solución del ejercicio 2.6

Datos. $\mathrm{Var}(X_i) = 1/4$; $X = \sum_{i=1}^{n} X_i$; $Y = \sum_{i=n-7}^{2n-8} X_i$.

Planteamiento. bilinealidad de la covarianza (proposición 2.1(v)): $\mathrm{Cov}(X_i, X_j) = 0$ si $i \neq j$ y $\mathrm{Var}(X_i)$ si $i = j$; solo cuentan los índices comunes.

Desarrollo.

1. Y tiene $(2n-8) - (n-7) + 1 = n$ sumandos, luego $\mathrm{Var}(Y) = n/4 = \mathrm{Var}(X)$.
2. Índices comunes: de $n-7$ a n, que son 8 (como $n \geq 8$, $n - 7 \geq 1$).
3. $\mathrm{Cov}(X, Y) = \sum_{i=n-7}^{n} \mathrm{Var}(X_i) = 8 \cdot \frac{1}{4} = 2$.
4. $\mathrm{Cor}(X, Y) = \dfrac{2}{\sqrt{(n/4)(n/4)}} = \dfrac{2}{n/4} = \dfrac{8}{n}$.

Resultado. $\mathrm{Cov}(X, Y) = 2$ **y** $\mathrm{Cor}(X, Y) = 8/n$**.**

Comprobación. para $n = 8$ se obtiene Cor $= 1$: entonces $Y = X_1 + \cdots + X_8 = X$.

Solución del ejercicio 2.7

Datos. $n = 400$; 300 aciertos.

Planteamiento. ejemplo 2.7: $\widehat{\mathrm{ee}} = \sqrt{\widehat{p}(1-\widehat{p})/n}$.

Desarrollo.

1. $\widehat{p} = 300/400 = 0{,}75$.
2. $\widehat{\mathrm{ee}} = \sqrt{0{,}75 \cdot 0{,}25/400} = \sqrt{0{,}000\,468\,75} \approx 0{,}02165$.

3. El error estándar es proporcional a $1/\sqrt{n}$; para dividirlo por 2 se necesita $4n = 1600$ preguntas.

Resultado. $\widehat{p} = 0{,}75$**,** $\widehat{\text{ee}} \approx 0{,}0217$ **(unos** 2,2 **puntos porcentuales);** 1600 **preguntas.**
Comprobación. $\sqrt{0{,}1875/1600} \approx 0{,}01083$, la mitad de 0,02165.

Solución del ejercicio 2.8

Datos. $\mathbb{E}A = \mathbb{E}B = \theta$; A, B independientes; $\operatorname{Var} A = 4$, $\operatorname{Var} B = 1$.

Planteamiento. linealidad para el sesgo; varianza de una combinación de independientes; minimizar un polinomio de grado 2.

Desarrollo.

1. $\mathbb{E}[T_w] = w\theta + (1-w)\theta = \theta$ para todo w.
2. $V(w) = \operatorname{Var}(T_w) = 4w^2 + (1-w)^2$. $V'(w) = 8w - 2(1-w) = 10w - 2 = 0 \iff w = 0{,}2$; $V'' = 10 > 0$, mínimo.
3. $V(0{,}2) = 4 \cdot 0{,}04 + 0{,}64 = 0{,}8$.
4. En general, $V(w) = w^2\sigma_A^2 + (1-w)^2\sigma_B^2$ y $V'(w) = 0$ da $w^* = \dfrac{\sigma_B^2}{\sigma_A^2 + \sigma_B^2}$, con $V(w^*) = \dfrac{\sigma_A^2\sigma_B^2}{\sigma_A^2 + \sigma_B^2}$.

Resultado. $w^* = 0{,}2$ **y** $\operatorname{Var}_{\min} = 0{,}8$; en general, cada estimador se pondera de forma inversamente proporcional a su varianza y $1/\operatorname{Var}_{\min} = 1/\sigma_A^2 + 1/\sigma_B^2$.

Comprobación. $1/4 + 1/1 = 1{,}25 = 1/0{,}8$. La combinación es mejor que el mejor de los dos ($0{,}8 < 1$).

Solución del ejercicio 2.9

Datos. $\varepsilon = 0{,}05$; probabilidad máxima 0,05; $\operatorname{Var}(\widehat{p}) = p(1-p)/n \le 1/(4n)$.

Planteamiento. lema 2.12 con $W = \widehat{p}$.

Desarrollo.

1. $\mathbb{P}(|\widehat{p} - p| \ge 0{,}05) \le \dfrac{p(1-p)}{n \cdot 0{,}0025} \le \dfrac{1}{4n \cdot 0{,}0025} = \dfrac{100}{n}$.
2. $100/n \le 0{,}05 \iff n \ge 2000$.

Resultado. $n = 2000$ **preguntas bastan**, sea cual sea p.

Comprobación. la aproximación normal del tema 3 dará $n = 385$ (ejercicio 3.10); Chebyshev es válida para cualquier distribución, pero es muy conservadora.

Solución del ejercicio 2.10

Datos. $\mathbb{E}[S^2] = \sigma^2$; $\operatorname{Var}(S^2) = 2\sigma^4/(n-1)$; $\widehat{\sigma}^2 = \frac{n-1}{n}S^2$.

Planteamiento. proposición 2.5 para cada estimador y comparación de las dos expresiones.

Desarrollo.

1. S^2 es insesgado, luego $\operatorname{ECM}(S^2) = \dfrac{2\sigma^4}{n-1}$.

2. $\text{sesgo}(\widehat{\sigma}^2) = -\sigma^2/n$ (corolario 2.9) y $\text{Var}(\widehat{\sigma}^2) = \dfrac{(n-1)^2}{n^2} \cdot \dfrac{2\sigma^4}{n-1} = \dfrac{2(n-1)\sigma^4}{n^2}$.
3. $\text{ECM}(\widehat{\sigma}^2) = \dfrac{2(n-1)\sigma^4}{n^2} + \dfrac{\sigma^4}{n^2} = \dfrac{(2n-1)\sigma^4}{n^2}$.
4. Comparación: $\dfrac{2n-1}{n^2} < \dfrac{2}{n-1} \iff (2n-1)(n-1) < 2n^2 \iff 2n^2 - 3n + 1 < 2n^2 \iff 1 < 3n$, que se cumple para todo $n \geq 1$.

Resultado. $\text{ECM}(S^2) = 2\sigma^4/(n-1)$ **y** $\text{ECM}(\widehat{\sigma}^2) = (2n-1)\sigma^4/n^2$**, que es menor para todo** $n \geq 2$**.** ■

Comprobación. con $n = 2$: $\text{ECM}(S^2) = 2\sigma^4$ y $\text{ECM}(\widehat{\sigma}^2) = \frac{3}{4}\sigma^4$. La insesgadez no garantiza el menor error cuadrático medio.

Solución del ejercicio 2.11

Datos. $X_i \sim \text{U}(0, \theta)$: densidad $1/\theta$ en $[0, \theta]$, media $\theta/2$, varianza $\theta^2/12$.

Planteamiento. (a) teorema 2.6; (b) la función de distribución del máximo por independencia; (c) comparar.

Desarrollo.

1. $\mathbb{E}[2\overline{X}] = 2 \cdot \theta/2 = \theta$; $\text{Var}(2\overline{X}) = 4 \cdot \dfrac{\theta^2}{12n} = \dfrac{\theta^2}{3n}$.
2. $M \leq x$ si y solo si todos los $X_i \leq x$; por independencia, $\mathbb{P}(M \leq x) = \prod_i \mathbb{P}(X_i \leq x) = (x/\theta)^n$ para $0 \leq x \leq \theta$. Derivando, la densidad de M es $f_M(x) = nx^{n-1}/\theta^n$ en $[0, \theta]$.
3. $\mathbb{E}[M] = \displaystyle\int_0^\theta x \, \frac{nx^{n-1}}{\theta^n} \, dx = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n\theta}{n+1}$; análogamente $\mathbb{E}[M^2] = \dfrac{n}{\theta^n} \cdot \dfrac{\theta^{n+2}}{n+2} = \dfrac{n\theta^2}{n+2}$.
4. $\mathbb{E}[T_2] = \frac{n+1}{n} \cdot \frac{n\theta}{n+1} = \theta$: insesgado.
5. $\text{Var}(M) = \dfrac{n\theta^2}{n+2} - \dfrac{n^2\theta^2}{(n+1)^2} = \dfrac{n\theta^2\big[(n+1)^2 - n(n+2)\big]}{(n+2)(n+1)^2} = \dfrac{n\theta^2}{(n+2)(n+1)^2}$.
6. $\text{Var}(T_2) = \dfrac{(n+1)^2}{n^2} \cdot \dfrac{n\theta^2}{(n+2)(n+1)^2} = \dfrac{\theta^2}{n(n+2)}$.
7. $\dfrac{\theta^2}{n(n+2)} \leq \dfrac{\theta^2}{3n} \iff 3 \leq n+2 \iff n \geq 1$, con igualdad solo si $n = 1$.

Resultado. **Ambos son insesgados;** $\text{Var}(T_1) = \theta^2/(3n)$ **y** $\text{Var}(T_2) = \theta^2/(n(n+2))$**.** T_2 es mejor para $n \geq 2$ y su varianza decrece como $1/n^2$, no como $1/n$. ■

Comprobación. con $n = 1$, $M = X_1$ y $T_2 = 2X_1 = T_1$: deben coincidir, y en efecto $\theta^2/3 = \theta^2/(1 \cdot 3)$.

Solución del ejercicio 2.12

Datos. $\mathbb{P}(M \leq x) = (x/\theta)^n$; $\text{ECM}(M)$ a partir del ejercicio 2.11.

Planteamiento. (a) como $M \leq \theta$, el suceso $|M - \theta| > \varepsilon$ es $M < \theta - \varepsilon$; (b) calcular el ECM.

Desarrollo.

1. Si $\varepsilon \geq \theta$, la probabilidad es 0. Si $0 < \varepsilon < \theta$: $\mathbb{P}(|M - \theta| > \varepsilon) = \mathbb{P}(M < \theta - \varepsilon) = \big(1 - \varepsilon/\theta\big)^n \to 0$, porque $0 < 1 - \varepsilon/\theta < 1$.
2. Sesgo: $\mathbb{E}[M] - \theta = -\theta/(n+1) \to 0$. Varianza: $\dfrac{n\theta^2}{(n+2)(n+1)^2} \leq \dfrac{\theta^2}{(n+1)^2} \to 0$. Luego $\mathrm{ECM}(M) \to 0$ y la proposición 2.13 da la consistencia.

Resultado. $M \xrightarrow{\mathbb{P}} \theta$: el máximo es un estimador consistente (aunque sesgado). ■

Comprobación. con $\theta = 1$, $\varepsilon = 0{,}05$ y $n = 100$: $0{,}95^{100} \approx 0{,}0059$.

Solución del ejercicio 2.13

Planteamiento. bilinealidad de la covarianza y $\mathrm{Cov}(X_j, X_i) = \sigma^2$ si $j = i$ y 0 si $j \neq i$.

Desarrollo.

1. $\mathrm{Cov}(\overline{X}, X_i) = \frac{1}{n}\sum_{j=1}^{n} \mathrm{Cov}(X_j, X_i) = \frac{1}{n}\sigma^2$.
2. $\mathrm{Cov}(\overline{X}, \overline{X}) = \mathrm{Var}(\overline{X}) = \sigma^2/n$.
3. $\mathrm{Cov}(\overline{X}, X_i - \overline{X}) = \mathrm{Cov}(\overline{X}, X_i) - \mathrm{Cov}(\overline{X}, \overline{X}) = \sigma^2/n - \sigma^2/n = 0$.

Resultado. $\mathrm{Cov}(\overline{X}, X_i - \overline{X}) = 0$ **para todo** i**.** ■

Comprobación. la incorrelación no implica en general independencia; para datos normales, el vector $(\overline{X}, X_1 - \overline{X}, \ldots, X_n - \overline{X})$ es normal multivariante y en ese caso sí la implica, lo que lleva a la independencia de $\overline{X}$ y S^2 (teorema 3.11).

Solución del ejercicio 2.14

Planteamiento. $\mathrm{Var}(S) = \mathbb{E}[S^2] - (\mathbb{E}S)^2 \geq 0$ y $\mathbb{E}[S^2] = \sigma^2$ (teorema 2.8).

Desarrollo.

1. $0 \leq \mathrm{Var}(S) = \sigma^2 - (\mathbb{E}S)^2$, luego $(\mathbb{E}S)^2 \leq \sigma^2$.
2. Como $S \geq 0$, $\mathbb{E}S \geq 0$, y tomando raíces: $\mathbb{E}S \leq \sigma$.
3. Igualdad $\iff$ $\mathrm{Var}(S) = 0$ $\iff$ S es constante con probabilidad 1.

Resultado. $\mathbb{E}[S] \leq \sigma$, con igualdad solo en el caso degenerado; S subestima σ en promedio. ■

Comprobación. con la población del ejercicio 2.2: $S = \sqrt{S^2}$ vale 0, $\sqrt{2}$ y $\sqrt{8}$ con probabilidades 3/9, 4/9 y 2/9, luego $\mathbb{E}S = (4\sqrt{2} + 2\sqrt{8})/9 = 8\sqrt{2}/9 \approx 1{,}257 < \sigma = \sqrt{8/3} \approx 1{,}633$.

Solución del ejercicio 2.15

Datos. n soluciones independientes, cada una correcta con probabilidad p; C correctas.

Planteamiento. introducir un subconjunto aleatorio K de k índices, elegido uniformemente entre los $\binom{n}{k}$ posibles e independiente de las soluciones, y aplicar la ley de la probabilidad total de dos formas.

Desarrollo.

1. Sea A el suceso «todas las soluciones de índice en K son incorrectas».
2. Condicionando a los resultados de las n soluciones (y, por tanto, a C), K es un subconjunto uniforme, y el número de subconjuntos de k índices formados solo por incorrectas es $\binom{n-C}{k}$ (es 0 si $n - C < k$). Luego $\mathbb{P}(A \mid \text{resultados}) = \binom{n-C}{k}/\binom{n}{k}$.

3. Tomando esperanzas (probabilidad total): $\mathbb{P}(A) = \mathbb{E}\left[\binom{n-C}{k}/\binom{n}{k}\right]$.
4. Condicionando ahora a $K = J$ para un subconjunto fijo J: las k soluciones de J son independientes y cada una es incorrecta con probabilidad $1-p$, luego $\mathbb{P}(A \mid K = J) = (1-p)^k$ para todo J, y $\mathbb{P}(A) = (1-p)^k$.
5. Igualando 3 y 4: $\mathbb{E}\left[\binom{n-C}{k}/\binom{n}{k}\right] = (1-p)^k$, y por linealidad $\mathbb{E}[\widehat{\pi}_k] = 1-(1-p)^k$.

Resultado. **$\widehat{\pi}_k$ es un estimador insesgado de pass@k.** ■

Comprobación. para $k = 1$, $\widehat{\pi}_1 = 1-(n-C)/n = C/n$, la proporción muestral, que es insesgada para p. Numéricamente, con $n = 10$, $k = 3$ y $p = 0{,}3$, la esperanza calculada sumando sobre $C = 0, \ldots, 10$ vale $0{,}657 = 1 - 0{,}7^3$.

A.3 Tema 3

Solución del ejercicio 3.1

Planteamiento. contrastar con el teorema 3.4, el teorema 3.3, el corolario 3.7 y la definición 3.10.

Desarrollo.

(a) **Falsa.** Los datos siguen siendo exponenciales (asimétricos); lo que es aproximadamente normal es la distribución de $\overline{X}$.

(b) **Verdadera**, por el teorema 3.3.

(c) **Verdadera**: $\mathrm{ee}(\overline{X}) = \sigma/\sqrt{100} = \sigma/10$.

(d) **Verdadera**: por ejemplo, $t_{10;0{,}975} = 2{,}228 > 1{,}960 = z_{0{,}975}$, de modo que $\mathbb{P}(T_{10} > 1{,}96) > 0{,}025$.

(e) **Falsa**: $np = 0{,}4$, muy lejos de $np \geq 10$; la distribución es muy asimétrica (de hecho, $\mathbb{P}(X = 0) = 0{,}98^{20} \approx 0{,}668$).

Resultado. **(a) F; (b) V; (c) V; (d) V; (e) F.**

Solución del ejercicio 3.2

Planteamiento. leer la cuadro B.1 y usar $\Phi(-z) = 1 - \Phi(z)$.

Desarrollo.

(a) Fila 1,2, columna 0,03: $\Phi(1{,}23) = 0{,}8907$.

(b) $\mathbb{P}(Z > -0{,}5) = 1 - \Phi(-0{,}5) = \Phi(0{,}5) = 0{,}6915$.

(c) $\Phi(2) - \Phi(-1) = 0{,}9772 - (1 - 0{,}8413) = 0{,}8185$.

(d) $z_{0{,}95} = 1{,}6449$ y $z_{0{,}99} = 2{,}3263$ (cuadro B.2).

(e) $\mathbb{P}(|Z| \leq c) = 2\Phi(c) - 1 = 0{,}90 \iff \Phi(c) = 0{,}95 \iff c = z_{0{,}95} = 1{,}6449$.

Resultado. **(a)** $0{,}8907$**; (b)** $0{,}6915$**; (c)** $0{,}8185$**; (d)** $1{,}6449$ **y** $2{,}3263$**; (e)** $c \approx 1{,}645$**.**

Comprobación. en (e), cada cola tiene probabilidad 0,05, y por eso aparece el cuantil 0,95 y no el 0,90.

Solución del ejercicio 3.3

Datos. $X \sim \mathcal{N}(100, 15^2)$.

Planteamiento. tipificar (proposición 3.2).

Desarrollo.

1. $\mathbb{P}(X > 130) = 1 - \Phi\big(\frac{130-100}{15}\big) = 1 - \Phi(2) = 1 - 0{,}9772 = 0{,}0228$.
2. $\mathbb{P}(85 < X < 115) = \Phi(1) - \Phi(-1) = 2\Phi(1) - 1 = 2 \cdot 0{,}8413 - 1 = 0{,}6826$.
3. Percentil 90: $x = 100 + 15\, z_{0{,}90} = 100 + 15 \cdot 1{,}2816 = 119{,}22$.

Resultado. 0,0228**;** 0,683**;** 119,2**.**

Comprobación. los dos primeros resultados reproducen la regla empírica (68 % a una desviación típica; 2,3 % por encima de dos).

Solución del ejercicio 3.4

Datos. $\mu = 90$, $\sigma = 15$, $n = 25$.

Planteamiento. por el teorema central del límite, $\overline{X} \approx \mathcal{N}(90,\, 3^2)$, pues ee $= 15/\sqrt{25} = 3$.

Desarrollo.

1. $z_1 = (85 - 90)/3 \approx -1{,}67$; $z_2 = (92 - 90)/3 \approx 0{,}67$.
2. $\mathbb{P}(85 < \overline{X} < 92) \approx \Phi(0{,}67) - \Phi(-1{,}67) = 0{,}7486 - 0{,}0475 = 0{,}7011$.
3. Dos errores estándar por encima: $90 + 2 \cdot 3 = 96$.

Resultado. **(a)** $\approx 0{,}70$**;** **(b)** 96**.**

Comprobación. sin redondear z a dos decimales se obtiene 0,6997, que es el valor de la fuente.

Solución del ejercicio 3.5

Datos. $\mu = 90$, $\sigma = 15$, $n = 80$.

Planteamiento. $S_n \approx \mathcal{N}(n\mu, n\sigma^2)$ (observación 3.5).

Desarrollo.

1. $\mathbb{E}S_n = 80 \cdot 90 = 7200$; $\sqrt{\operatorname{Var} S_n} = \sqrt{80} \cdot 15 \approx 134{,}16$.
2. $z = (7500 - 7200)/134{,}16 \approx 2{,}24$; $\mathbb{P}(S_n > 7500) \approx 1 - \Phi(2{,}24) = 1 - 0{,}9875 = 0{,}0125$.
3. $7200 + 1{,}5 \cdot 134{,}16 \approx 7401{,}2$.

Resultado. **(a)** $\approx 0{,}0125$**;** **(b)** ≈ 7401**.**

Comprobación. con $z = 2{,}236$ sin redondear se obtiene 0,0127, el valor de la fuente.

Solución del ejercicio 3.6

Datos. $n = 400$; $p_A = 0{,}5$; $p_{\text{menores}} = 0{,}3$.

Planteamiento. $\widehat{p} \approx \mathcal{N}\big(p, p(1-p)/n\big)$ (corolario 3.7).

Desarrollo.

1. (a) ee $= \sqrt{0{,}25/400} = 0{,}025$; $z = (0{,}525 - 0{,}5)/0{,}025 = 1$; $\mathbb{P}(\widehat{p} \geq 0{,}525) \approx 1 - \Phi(1) = 0{,}1587$.

2. (b) ee $= \sqrt{0{,}21/400} \approx 0{,}02291$; $z = (0{,}31 - 0{,}3)/0{,}02291 \approx 0{,}44$; $\mathbb{P}(\widehat{p} < 0{,}31) \approx \Phi(0{,}44) = 0{,}6700$.

Resultado. **(a)** $\approx 0{,}16$**; (b)** $\approx 0{,}67$**.**

Comprobación. en (a), con corrección por continuidad, $\mathbb{P}(X \geq 210) \approx 1 - \Phi\big((209{,}5 - 200)/10\big) = 1 - \Phi(0{,}95) = 0{,}1711$, que coincide con el valor binomial exacto (0,1711).

Solución del ejercicio 3.7

Datos. errores E_i uniformes en $\{-2, -1, 0, 1, 2\}$, independientes; $n = 1000$.

Planteamiento. calcular media y varianza de cada error y aplicar el teorema central del límite a la suma S.

Desarrollo.

1. $\mathbb{E}E_i = 0$; $\operatorname{Var} E_i = \mathbb{E}E_i^2 = (4 + 1 + 0 + 1 + 4)/5 = 2$.
2. $\mathbb{E}S = 0$; $\operatorname{Var} S = 1000 \cdot 2 = 2000$; desviación típica $\sqrt{2000} \approx 44{,}72$.
3. $\mathbb{P}(|S| > 100) \approx 2\big(1 - \Phi(100/44{,}72)\big) = 2\big(1 - \Phi(2{,}24)\big) = 2 \cdot 0{,}0125 = 0{,}025$.

Resultado. $p \approx 0{,}025$**.**

Comprobación. como S es entera, $|S| > 100$ equivale a $|S| \geq 101$, y con corrección por continuidad se obtiene $2\big(1 - \Phi(100{,}5/44{,}72)\big) \approx 0{,}0246$; la diferencia es pequeña.

Solución del ejercicio 3.8

Datos. $np = 50$, $\sqrt{np(1-p)} = 5$.

Planteamiento. corolario 3.7 y definición 3.8.

Desarrollo.

1. $\mathbb{P}(X = 50) = \mathbb{P}(49{,}5 \leq Y \leq 50{,}5) \approx \Phi(0{,}1) - \Phi(-0{,}1) = 2 \cdot 0{,}5398 - 1 = 0{,}0796$.
2. Con corrección: $\mathbb{P}(39{,}5 \leq Y \leq 60{,}5) \approx \Phi(2{,}1) - \Phi(-2{,}1) = 2 \cdot 0{,}9821 - 1 = 0{,}9642$.
3. Sin corrección: $\mathbb{P}(40 \leq Y \leq 60) \approx 2\Phi(2) - 1 = 2 \cdot 0{,}9772 - 1 = 0{,}9544$.

Resultado. **(a)** 0,0796**; (b)** 0,9642 **con corrección y** 0,9544 **sin ella.**

Comprobación. los valores exactos son 0,0796 y 0,9648: con corrección el error es de 0,0006 y sin ella de 0,0104. Sin corrección, $\mathbb{P}(X = 50)$ se aproximaría por 0.

Solución del ejercicio 3.9

Datos. $p = 0{,}8$; $n = 1000$.

Planteamiento. $\widehat{p} \approx \mathcal{N}\big(0{,}8,\ 0{,}16/1000\big)$.

Desarrollo.

1. ee $= \sqrt{0{,}8 \cdot 0{,}2/1000} = \sqrt{0{,}000\,16} \approx 0{,}01265$.
2. $z = (0{,}82 - 0{,}8)/0{,}01265 \approx 1{,}58$; $\mathbb{P}(\widehat{p} \geq 0{,}82) \approx 1 - \Phi(1{,}58) = 1 - 0{,}9429 = 0{,}0571$.
3. Intervalo: $0{,}8 \pm z_{0{,}975}$ ee $= 0{,}8 \pm 1{,}96 \cdot 0{,}01265 = 0{,}8 \pm 0{,}0248$, es decir, $[0{,}775;\ 0{,}825]$.

Resultado. **(a)** 0,0126**; (b)** $\approx 0{,}057$**; (c)** $[0{,}775;\ 0{,}825]$**.**

Comprobación. un modelo con exactitud real del 80 % obtiene un 82 % o más en casi un 6 % de las evaluaciones: una ventaja de dos puntos en un benchmark de 1000 preguntas no es concluyente por sí sola.

Solución del ejercicio 3.10

Datos. probabilidad 0,95; tolerancia $0{,}1\sigma$; en (b), tolerancia 0,05 y $\sigma = \sqrt{p(1-p)} \le 1/2$.

Planteamiento. $\mathbb{P}(|\overline{X} - \mu| < c) \approx 2\Phi\big(c\sqrt{n}/\sigma\big) - 1 \ge 0{,}95 \iff c\sqrt{n}/\sigma \ge z_{0{,}975} = 1{,}96$.

Desarrollo.

1. (a) $c = 0{,}1\sigma$: $0{,}1\sqrt{n} \ge 1{,}96 \iff n \ge (19{,}6)^2 = 384{,}16$, luego $n = 385$.
2. (b) $c = 0{,}05$ y $\sigma \le 0{,}5$: basta $0{,}05\sqrt{n}/0{,}5 \ge 1{,}96$, que es la misma condición que en (a): $n = 385$.

Resultado. $n = 385$ **en ambos casos**, frente a $n = 2000$ con Chebyshev (ejercicio 2.9).

Comprobación. con $n = 385$ y $p = 1/2$: $\mathrm{ee} = 0{,}5/\sqrt{385} \approx 0{,}02548$ y $1{,}96 \cdot 0{,}02548 \approx 0{,}0499 < 0{,}05$.

Solución del ejercicio 3.11

Planteamiento. leer las cuadros B.3 y B.4 y usar la simetría de la t.

Desarrollo.

1. $t_{9;0{,}975} = 2{,}262$, $t_{29;0{,}975} = 2{,}045$, $t_{120;0{,}975} = 1{,}980$, frente a $z_{0{,}975} = 1{,}960$.
2. $t_{15;0{,}975} = 2{,}131$, luego $\mathbb{P}(T > 2{,}131) = 0{,}025$.
3. $t_{15;0{,}95} = 1{,}753$, luego $\mathbb{P}(|T| \le 1{,}753) = 1 - 2 \cdot 0{,}05 = 0{,}90$.
4. $\mathbb{P}(V > c) = 0{,}05 \iff c = \chi^2_{10;0{,}95} = 18{,}307$.

Resultado. **(a)** 2,262**;** 2,045**;** 1,980 **(decrecen hacia** 1,960**); (b)** 0,025 **y** 0,90**; (c)** $c = 18{,}307$**.**

Comprobación. la χ^2_{10} tiene media 10 y desviación típica $\sqrt{20} \approx 4{,}47$; 18,3 está unas 1,9 desviaciones por encima, razonable para un cuantil 0,95 de una distribución asimétrica a la derecha.

Solución del ejercicio 3.12

Planteamiento. calcular la función de distribución de Y, derivarla y reconocer la densidad normal.

Desarrollo.

1. Caso $a > 0$: $F_Y(y) = \mathbb{P}(aX + b \le y) = \mathbb{P}\big(X \le \tfrac{y-b}{a}\big) = F_X\big(\tfrac{y-b}{a}\big)$. Derivando (regla de la cadena), $f_Y(y) = \tfrac{1}{a} f_X\big(\tfrac{y-b}{a}\big)$.
2. Caso $a < 0$: $F_Y(y) = \mathbb{P}\big(X \ge \tfrac{y-b}{a}\big) = 1 - F_X\big(\tfrac{y-b}{a}\big)$, y $f_Y(y) = -\tfrac{1}{a} f_X\big(\tfrac{y-b}{a}\big)$. En ambos casos, $f_Y(y) = \tfrac{1}{|a|} f_X\big(\tfrac{y-b}{a}\big)$.
3. Sustituyendo la densidad normal y usando $\tfrac{y-b}{a} - \mu = \tfrac{y-(a\mu+b)}{a}$:

$$f_Y(y) = \frac{1}{|a|\sigma\sqrt{2\pi}} \exp\!\Big(-\frac{(y - (a\mu + b))^2}{2a^2\sigma^2}\Big),$$

que es la densidad $\mathcal{N}(a\mu+b, a^2\sigma^2)$, con desviación típica $|a|\sigma$.

4. Con $a = 1/\sigma$ y $b = -\mu/\sigma$ se obtiene $Z = (X-\mu)/\sigma \sim \mathcal{N}(0,1)$ y $\mathbb{P}(X \le x) = \mathbb{P}\big(Z \le \frac{x-\mu}{\sigma}\big) = \Phi\big(\frac{x-\mu}{\sigma}\big)$.

Resultado. $aX+b \sim \mathcal{N}(a\mu+b, a^2\sigma^2)$, y la tipificación lleva cualquier normal a la estándar. ■

Comprobación. con $a=-1$, $b=0$, $\mu=0$, $\sigma=1$: $-Z \sim \mathcal{N}(0,1)$, que expresa la simetría de la normal estándar.

Solución del ejercicio 3.13

Planteamiento. para $v>0$, $Z^2 \le v \iff -\sqrt{v} \le Z \le \sqrt{v}$.

Desarrollo.

1. $\mathbb{P}(V \le v) = \Phi(\sqrt{v}) - \Phi(-\sqrt{v}) = \Phi(\sqrt{v}) - \big(1-\Phi(\sqrt{v})\big) = 2\Phi(\sqrt{v}) - 1$.
2. Sea $\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} = \Phi'(z)$. Por la regla de la cadena,

$$f_V(v) = 2\varphi(\sqrt{v}) \cdot \frac{1}{2\sqrt{v}} = \frac{\varphi(\sqrt{v})}{\sqrt{v}} = \frac{1}{\sqrt{2\pi v}} e^{-v/2}, \qquad v>0.$$

3. Para $v \le 0$, $\mathbb{P}(V \le v) = \mathbb{P}(Z^2 \le v) \le \mathbb{P}(Z=0) = 0$, y la densidad es nula.

Resultado. $f_V(v) = (2\pi v)^{-1/2} e^{-v/2}$ **para** $v>0$**.** ■

Comprobación. $\mathbb{P}(V \le 3{,}841) = 2\Phi(\sqrt{3{,}841}) - 1 = 2\Phi(1{,}96) - 1 = 0{,}95$, de acuerdo con $\chi^2_{1;0,95} = 3{,}841$ en la cuadro B.4.

Solución del ejercicio 3.14

Planteamiento. $\varphi'(z) = -z\varphi(z)$; integrar por partes $\int z^m \cdot z\varphi(z)\,dz$; después, linealidad e independencia.

Desarrollo.

1. Para $m \ge 0$ entero, con $u = z^{m+1}$ y $dv = z\varphi(z)\,dz$, $v = -\varphi(z)$:

$$\begin{aligned}\mathbb{E}[Z^{m+2}] &= \int_{-\infty}^{\infty} z^{m+1}\, z\varphi(z)\,dz = \Big[-z^{m+1}\varphi(z)\Big]_{-\infty}^{\infty} + (m+1)\int_{-\infty}^{\infty} z^m \varphi(z)\,dz \\ &= (m+1)\mathbb{E}[Z^m],\end{aligned}$$

   porque $z^{m+1}e^{-z^2/2} \to 0$ cuando $|z| \to \infty$.
2. $m=0$: $\mathbb{E}[Z^2] = 1 \cdot \mathbb{E}[1] = 1$. $m=2$: $\mathbb{E}[Z^4] = 3\mathbb{E}[Z^2] = 3$.
3. $\operatorname{Var}(Z^2) = \mathbb{E}[Z^4] - (\mathbb{E}Z^2)^2 = 3-1 = 2$.
4. $V = \sum_{i=1}^k Z_i^2$ con Z_i i.i.d.: $\mathbb{E}V = k \cdot 1 = k$ y, por independencia, $\operatorname{Var} V = k \cdot 2 = 2k$.

Resultado. $\mathbb{E}[Z^4] = 3$**;** $\mathbb{E}[\chi^2_k] = k$ **y** $\operatorname{Var}(\chi^2_k) = 2k$**.** ■

Comprobación. para $k=10$, media 10 y varianza 20, coherente con el ejercicio 3.11.

Solución del ejercicio 3.15

Planteamiento. escribir $T = Z/\sqrt{V/k}$ con $Z \sim \mathcal{N}(0,1)$ y $V \sim \chi^2_k$ independientes, y observar que $-T$ es la misma función aplicada a $(-Z, V)$.

Desarrollo.

1. $-Z \sim \mathcal{N}(0,1)$ (ejercicio 3.12 con $a=-1$) y $-Z$ es independiente de V. Luego el par $(-Z, V)$ tiene la misma distribución conjunta que (Z, V).
2. Como $-T = (-Z)/\sqrt{V/k}$ es la misma función del par $(-Z, V)$ que T del par (Z, V), $-T$ y T tienen la misma distribución.
3. Sea F la función de distribución de T, continua. Para todo t: $F(-t) = \mathbb{P}(T \le -t) = \mathbb{P}(-T \ge t) = \mathbb{P}(T \ge t) = 1 - F(t)$.
4. Con $t = t_{k;q}$: $F(-t_{k;q}) = 1 - q$, es decir, $-t_{k;q} = t_{k;1-q}$.
5. Con $c = t_{k;1-\alpha/2}$: $\mathbb{P}(|T| \le c) = F(c) - F(-c) = 2F(c) - 1 = 2(1-\alpha/2) - 1 = 1 - \alpha$.

Resultado. $T \overset{d}{=} -T$, $t_{k;1-q} = -t_{k;q}$ **y** $\mathbb{P}(|T| \le t_{k;1-\alpha/2}) = 1 - \alpha$**.** ■

Comprobación. el mismo argumento con $V = k$ constante da la simetría de la normal estándar, cuyo caso límite es la t_k cuando $k \to \infty$.

A.4 Tema 4

Solución del ejercicio 4.1

Planteamiento. aplicar la observación 4.9: la confianza se refiere al procedimiento, no a la probabilidad de un valor concreto del parámetro.

Desarrollo.

(i) **No se deduce.** En el enfoque frecuentista la mejora real es fija; el 95 % es la cobertura del procedimiento.

(ii) **No se deduce**, por la misma razón: el intervalo no asigna probabilidades a hipótesis.

(iii) **Se deduce**: el centro, 15, es la estimación puntual y el intervalo indica su precisión.

(iv) **No se deduce**: «probablemente falsa» es una afirmación de probabilidad sobre una hipótesis.

(v) **Se deduce**: es la definición de cobertura (definición 4.8).

(vi) **Se deduce**: el valor 0 queda fuera del intervalo, y un intervalo de nivel 95 % contiene exactamente los valores no rechazados por el contraste bilateral al 5 % (ejercicio 5.15).

Resultado. **Se deducen (iii), (v) y (vi); no se deducen (i), (ii) y (iv).**

Solución del ejercicio 4.2

Planteamiento. ejemplo 4.2: igualar media (y segundo momento) muestrales y poblacionales.

Desarrollo.

1. (a) $\bar{x} = (0{,}5 + 1{,}2 + 0{,}3 + 2{,}0)/4 = 4{,}0/4 = 1{,}0$; $\widehat{\lambda} = 1/\bar{x} = 1{,}0$ peticiones por segundo.
2. (b) $\widehat{\mu} = \bar{x} = 22/5 = 4{,}4$. Desviaciones: $-2{,}4$; $-0{,}4$; $-0{,}4$; $0{,}6$; $2{,}6$; cuadrados: 5,76; 0,16; 0,16; 0,36; 6,76; suma 13,2.
3. $\widehat{\sigma}^2 = 13{,}2/5 = 2{,}64$, mientras que $s^2 = 13{,}2/4 = 3{,}3$.

Resultado. **(a)** $\widehat{\lambda} = 1$**; (b)** $\widehat{\mu} = 4{,}4$ **y** $\widehat{\sigma}^2 = 2{,}64$**, menor que** $s^2 = 3{,}3$**.**
Comprobación. $\frac{1}{n}\sum x_i^2 - \bar{x}^2 = (4+16+16+25+49)/5 - 19{,}36 = 22 - 19{,}36 = 2{,}64$.

Solución del ejercicio 4.3

Datos. $f(x \mid p) = p(1-p)^{x-1}$, $\mathbb{E}X = 1/p$; datos $2, 1, 4, 3, 1, 1$.
Planteamiento. (a) $1/p = \bar{x}$; (b) derivar la log-verosimilitud.
Desarrollo.

1. Momentos: $1/\widehat{p} = \bar{x}$, luego $\widehat{p} = 1/\bar{x}$.
2. Verosimilitud: $\mathcal{L}(p) = \prod_i p(1-p)^{x_i-1} = p^n(1-p)^{\sum x_i - n}$; $\ell(p) = n\ln p + \big(\sum x_i - n\big)\ln(1-p)$.
3. $\ell'(p) = \dfrac{n}{p} - \dfrac{\sum x_i - n}{1-p} = 0 \iff n(1-p) = \big(\sum x_i - n\big)p \iff n = p\sum x_i \iff p = \dfrac{n}{\sum x_i} = \dfrac{1}{\bar{x}}$.
4. $\ell''(p) = -n/p^2 - \big(\sum x_i - n\big)/(1-p)^2 < 0$: máximo global.
5. Datos: $\sum x_i = 12$, $n = 6$, $\bar{x} = 2$, $\widehat{p} = 0{,}5$.

Resultado. **Ambos métodos dan** $\widehat{p} = 1/\bar{x}$**; con los datos,** $\widehat{p} = 0{,}5$**.**
Comprobación. un agente que resuelve cada intento con probabilidad 0,5 necesita en media 2 intentos, que es la media observada.

Solución del ejercicio 4.4

Datos. $f(x \mid a) = a^5 x^4 e^{-ax}/24$; datos 2,0; 3,0; 2,5; 4,5.
Planteamiento. escribir $\ell(a)$ con $S = \sum x_i$ y $P = \prod x_i$ y resolver $\ell'(a) = 0$.
Desarrollo.

1. $\mathcal{L}(a) = \dfrac{a^{5n}P^4 e^{-aS}}{24^n}$; $\ell(a) = 5n\ln a + 4\ln P - aS - n\ln 24$.
2. $\ell'(a) = 5n/a - S = 0 \iff a = 5n/S$.
3. $\ell''(a) = -5n/a^2 < 0$: máximo global en $(0, \infty)$.
4. Datos: $n = 4$, $S = 12$; $\widehat{a} = 20/12 = 5/3 \approx 1{,}667$.

Resultado. $\widehat{a} = 5n/\sum x_i = 5/\bar{x}$**; con los datos,** $\widehat{a} = 5/3$**.**
Comprobación. la media de esta distribución es $5/a$ (es una gamma de forma 5), luego el EMV coincide con el estimador por momentos: $5/\widehat{a} = \bar{x} = 3$.

Solución del ejercicio 4.5

Datos. 1,2; 2,1; 1,3; 10,5; 5; $n = 5$.
Planteamiento. (a) $\mathcal{L}(a,b) = (b-a)^{-n}$ si $a \le \min x_i$ y $b \ge \max x_i$, y 0 en otro caso; (b) igualar media y varianza (con denominador n).
Desarrollo.

1. (a) $\mathcal{L}$ es positiva solo si el intervalo $[a, b]$ contiene todos los datos y, en ese caso, es mayor cuanto menor es $b - a$. El intervalo más corto que contiene los datos es $[\min x_i, \max x_i]$: $\widehat{a} = 1{,}2$ y $\widehat{b} = 10{,}5$.
2. (b) $\bar{x} = 20{,}1/5 = 4{,}02$; $\frac{1}{n}\sum x_i^2 = (1{,}44+4{,}41+1{,}69+110{,}25+25)/5 = 142{,}79/5 = 28{,}558$; $\widehat{\sigma}^2 = 28{,}558 - 4{,}02^2 = 12{,}3976$; $\widehat{\sigma} \approx 3{,}521$.
3. De $(b-a)/2 = \sqrt{3}\,\widehat{\sigma} \approx 6{,}099$ y $(a+b)/2 = 4{,}02$: $\widehat{a} \approx -2{,}08$ y $\widehat{b} \approx 10{,}12$.
4. (c) $\widehat{b} \approx 10{,}12 < 10{,}5$: según el modelo estimado, el dato 10,5 sería imposible.

Resultado. **EMV:** $\widehat{a} = 1{,}2$**,** $\widehat{b} = 10{,}5$**. Momentos:** $\widehat{a} \approx -2{,}08$**,** $\widehat{b} \approx 10{,}12$**, incompatibles con los datos.**

Comprobación. la media del modelo con los estimadores de momentos es $(-2{,}08 + 10{,}12)/2 = 4{,}02 = \bar{x}$, como debe ser.

Solución del ejercicio 4.6

Datos. $2, 0, 3, 1, 4, 2, 1, 3$; $n = 8$.

Planteamiento. $\widehat{\lambda} = \bar{x}$ (ejercicio 4.12); intervalo $\widehat{\lambda} \pm 1{,}96\sqrt{\widehat{\lambda}/n}$.

Desarrollo.

1. $\sum x_i = 16$; $\widehat{\lambda} = 2$.
2. $\widehat{\text{ee}} = \sqrt{2/8} = 0{,}5$; margen $1{,}96 \cdot 0{,}5 = 0{,}98$.

Resultado. $\widehat{\lambda} = 2$**; intervalo aproximado** $[1{,}02;\ 2{,}98]$**.**

Comprobación. con $n = 8$ la aproximación normal es tosca; el intervalo es solo orientativo, pero su amplitud ya muestra que λ está poco determinado.

Solución del ejercicio 4.7

Datos. $n = 9$; $\sum x_i = 3204$; $\bar{x} = 356$.

Planteamiento. (a) teorema 4.10; (b) teorema 4.12 con 8 grados de libertad.

Desarrollo.

1. $\sigma/\sqrt{n} = 3/3 = 1$. Al 95 %: $356 \pm 1{,}96$, es decir, $[354{,}04;\ 357{,}96]$. Al 98 % ($z_{0{,}99} = 2{,}326$): $[353{,}67;\ 358{,}33]$.
2. Desviaciones respecto de 356: $-4, -5, 5, -3, -4, 2, 4, 2, 3$; suma de cuadrados $16 + 25 + 25 + 9 + 16 + 4 + 16 + 4 + 9 = 124$; $s^2 = 124/8 = 15{,}5$; $s \approx 3{,}937$; $s/\sqrt{n} \approx 1{,}312$.
3. Al 95 %: $t_{8;0{,}975} = 2{,}306$, margen 3,026, intervalo $[352{,}97;\ 359{,}03]$.
4. Al 98 %: $t_{8;0{,}99} = 2{,}896$, margen 3,801, intervalo $[352{,}20;\ 359{,}80]$.

Resultado. σ **conocida:** [354,04; 357,96] **y** [353,67; 358,33]**.** σ **desconocida:** [352,97; 359,03] **y** [352,20; 359,80]**.**

Comprobación. los intervalos t son más anchos por dos motivos: $t_8 > z$ y, en esta muestra, $s \approx 3{,}94 > \sigma = 3$. Al aumentar el nivel, todos los intervalos se ensanchan.

Solución del ejercicio 4.8

Datos. $n = 20$; $\bar{x} = 69{,}55$; $s^2 = 14{,}26$; en (b), $\sigma = 3{,}77$.

Planteamiento. teoremas 4.10 y 4.12 y corolario 4.11 con $E = 0{,}5$ (la mitad de la amplitud).

Desarrollo.

1. (a) $s/\sqrt{n} = \sqrt{14{,}26/20} = \sqrt{0{,}713} \approx 0{,}8444$; $t_{19;0{,}95} = 1{,}729$; margen 1,460; intervalo $[68{,}09;\ 71{,}01]$.
2. (b) $\sigma/\sqrt{n} = 3{,}77/\sqrt{20} \approx 0{,}8430$; $z_{0{,}95} = 1{,}645$; margen 1,387; intervalo $[68{,}16;\ 70{,}94]$.
3. (c) $n \geq (1{,}645 \cdot 3{,}77/0{,}5)^2 = (12{,}40)^2 \approx 153{,}8$, luego $n = 154$.

Resultado. **(a)** [68,09; 71,01]**; (b)** [68,16; 70,94]**; (c)** 154 **personas.**

Comprobación. con $n = 154$ la amplitud es $2 \cdot 1{,}645 \cdot 3{,}77/\sqrt{154} \approx 0{,}9995 < 1$.

Solución del ejercicio 4.9

Datos. (a) $\sigma = 3$, $n = 36$, $\bar{x} = 68$, nivel 90 %; (b) $\sigma = 15$, $E = 2$, nivel 95 %.

Planteamiento. teorema 4.10 y corolario 4.11.

Desarrollo.

1. (a) Margen $1{,}645 \cdot 3/6 = 0{,}8225$; intervalo $[67{,}18;\ 68{,}82]$.
2. (b) $n \geq (1{,}96 \cdot 15/2)^2 = 14{,}7^2 = 216{,}09$, luego $n = 217$.

Resultado. **(a)** [67,18; 68,82]**; (b)** $n = 217$**.**

Comprobación. se redondea hacia arriba: con $n = 216$ el margen sería $1{,}96 \cdot 15/\sqrt{216} \approx 2{,}0004 > 2$.

Solución del ejercicio 4.10

Datos. (a) $n = 500$, $x = 421$; (b) $E = 0{,}03$, nivel 90 %.

Planteamiento. definición 4.14 y corolario 4.15.

Desarrollo.

1. (a) $\widehat{p} = 421/500 = 0{,}842$; $\widehat{\text{ee}} = \sqrt{0{,}842 \cdot 0{,}158/500} \approx 0{,}01631$; margen $1{,}96 \cdot 0{,}01631 \approx 0{,}0320$; intervalo $[0{,}810;\ 0{,}874]$.
2. (b) $n \geq z_{0{,}95}^2/(4E^2) = 1{,}645^2/(4 \cdot 0{,}0009) = 2{,}706/0{,}0036 \approx 751{,}7$, luego $n = 752$.

Resultado. **(a)** [0,810; 0,874]**; (b)** 752 **personas.**

Comprobación. en (a), $n\widehat{p} = 421$ y $n(1 - \widehat{p}) = 79$ son grandes, y la aproximación normal es adecuada.

Solución del ejercicio 4.11

Planteamiento. margen conservador $z/(2\sqrt{n}) = E \iff n = \big(z/(2E)\big)^2$.

Desarrollo.

1. (a) $z = 1{,}96$: $n = (1{,}96/0{,}02)^2 = 98^2 = 9604$. Con $z \approx 2$: $n = 100^2 = 10\,000$.
2. (b) $z_{0{,}90} = 1{,}2816$: $n = (1{,}2816/0{,}02)^2 = 64{,}08^2 \approx 4106$.
3. (c) Con $z \approx 2$: $2/(2\sqrt{n}) = 0{,}04 \iff \sqrt{n} = 25 \iff n = 625$ (con 1,96 saldría unas 600).

Resultado. **(a)** 9604 **(o** 10 000 **con** $z \approx 2$**); (b) unas** 4106**; (c) unas** 600 **personas.**

Comprobación. la regla práctica «margen $\approx 1/\sqrt{n}$ al 95 %» da $1/\sqrt{625} = 0{,}04$: un benchmark de 10 000 preguntas tiene un margen de un punto porcentual.

Solución del ejercicio 4.12

Planteamiento. escribir $\ell(\lambda)$, resolver $\ell'(\lambda) = 0$ y estudiar la concavidad.

Desarrollo.

1. $f(x \mid \lambda) = e^{-\lambda}\lambda^x/x!$, luego $\ell(\lambda) = \left(\sum_i x_i\right)\ln\lambda - n\lambda - \sum_i \ln(x_i!)$ para $\lambda > 0$.
2. $\ell'(\lambda) = \dfrac{\sum_i x_i}{\lambda} - n = 0 \iff \lambda = \dfrac{\sum_i x_i}{n} = \bar{x}$.
3. $\ell''(\lambda) = -\sum_i x_i/\lambda^2 < 0$ para todo $\lambda > 0$ (pues $\sum x_i > 0$): ℓ es estrictamente cóncava en $(0, \infty)$ y su único punto crítico es el máximo global.
4. Por el ejemplo 4.2, el estimador por momentos también es $\overline{X}$.

Resultado. **El EMV es $\widehat{\lambda} = \bar{x}$ y coincide con el de momentos.** ■

Comprobación. con los datos del ejercicio 4.6, $\ell'(2) = 16/2 - 8 = 0$.

Solución del ejercicio 4.13

Planteamiento. derivar la log-verosimilitud en cada parametrización.

Desarrollo.

1. (a) $\ell(\lambda) = n\ln\lambda - \lambda\sum_i x_i$; $\ell'(\lambda) = n/\lambda - \sum_i x_i = 0 \iff \lambda = n/\sum_i x_i = 1/\bar{x}$; $\ell''(\lambda) = -n/\lambda^2 < 0$: máximo global.
2. (b) Con $\beta = 1/\lambda$, $f(x \mid \beta) = \beta^{-1}e^{-x/\beta}$ y $\ell(\beta) = -n\ln\beta - \sum_i x_i/\beta$.
3. $\ell'(\beta) = -\dfrac{n}{\beta} + \dfrac{\sum_i x_i}{\beta^2} = \dfrac{\sum_i x_i - n\beta}{\beta^2}$, positiva para $\beta < \bar{x}$ y negativa para $\beta > \bar{x}$: máximo global en $\widehat{\beta} = \bar{x}$.
4. $\widehat{\beta} = \bar{x} = 1/\widehat{\lambda}$, como predice la invariancia con $g(\lambda) = 1/\lambda$.

Resultado. $\widehat{\lambda} = 1/\bar{x}$ **y** $\widehat{\beta} = \bar{x}$**.** ■

Comprobación. con los datos del ejercicio 4.2(a), $\widehat{\lambda} = 1$ y $\widehat{\beta} = 1$ segundo.

Solución del ejercicio 4.14

Planteamiento. la log-verosimilitud es, salvo una constante, $-\sum_i |x_i - \mu|$.

Desarrollo.

1. $\ell(\mu) = \sum_i \ln\left(\frac{1}{2}e^{-|x_i-\mu|}\right) = -n\ln 2 - \sum_i |x_i - \mu|$.
2. Maximizar ℓ equivale a minimizar $g(\mu) = \sum_i |x_i - \mu|$, que alcanza su mínimo en la mediana (ejercicio 1.11).
3. En el modelo normal con σ fija, $\ell(\mu) = c - \frac{1}{2\sigma^2}\sum_i (x_i - \mu)^2$, que se maximiza en $\bar{x}$ (proposición 1.5).

Resultado. **El EMV de la posición de Laplace es la mediana muestral** (cualquier punto entre los dos datos centrales si n es par). ■

Comprobación. la densidad de Laplace tiene colas más pesadas que la normal, y su EMV es el estimador robusto frente a atípicos: el modelo elegido determina el estimador.

Solución del ejercicio 4.15

Planteamiento. $\mathbb{P}_p(\text{cero fallos}) = (1-p)^n$, decreciente en p; usar $e^x \geq 1 + x$.

Desarrollo.

1. (a) $(1-p)^n \geq \alpha \iff 1-p \geq \alpha^{1/n} \iff p \leq 1-\alpha^{1/n}$, pues $t \mapsto t^n$ es creciente en $[0,1]$. El conjunto es $[0, p_{\max}]$ con $p_{\max} = 1-\alpha^{1/n}$.
2. (b) $\alpha^{1/n} = e^{(\ln\alpha)/n} \geq 1 + \dfrac{\ln\alpha}{n}$, luego $p_{\max} = 1-\alpha^{1/n} \leq -\dfrac{\ln\alpha}{n}$. Para $\alpha = 0{,}05$, $-\ln 0{,}05 \approx 2{,}996 \approx 3$.
3. (c) $n = 300$: $p_{\max} = 1 - 0{,}05^{1/300} \approx 0{,}009\,936$; $3/n = 0{,}01$.

Resultado. $p_{\max} = 1-\alpha^{1/n} \leq -\ln(\alpha)/n \approx 3/n$**; con** $n = 300$**,** $p_{\max} \approx 0{,}0099$: con 95 % de confianza, la tasa de fallos graves es menor que un 1 %. ■

Comprobación. $(1 - 0{,}009\,936)^{300} = e^{300\ln(0{,}990\,064)} \approx e^{-2{,}996} \approx 0{,}05$.

Solución del ejercicio 4.16

Planteamiento. calcular la cobertura aproximada con la normal y usar $\sqrt{p(1-p)} \leq \frac{1}{2}$.

Desarrollo.

1. Sea $c = z_{1-\alpha/2}$ y $\tau = \sqrt{p(1-p)/n}$. El intervalo cubre p si y solo si $|\widehat{p} - p| \leq c/(2\sqrt{n})$.
2. Con $\widehat{p} \approx \mathcal{N}(p, \tau^2)$: $\mathbb{P}\big(|\widehat{p}-p| \leq \frac{c}{2\sqrt{n}}\big) \approx 2\Phi\Big(\dfrac{c}{2\sqrt{n}\,\tau}\Big) - 1 = 2\Phi\Big(\dfrac{c}{2\sqrt{p(1-p)}}\Big) - 1$.
3. Como $p(1-p) \leq 1/4$ con igualdad solo si $p = 1/2$, el argumento es $\geq c$, y como Φ es creciente, la cobertura aproximada es $\geq 2\Phi(c) - 1 = 1-\alpha$, con igualdad solo si $p = 1/2$.
4. $p = 0{,}1$: $\sqrt{p(1-p)} = 0{,}3$ y el argumento vale $1{,}96/0{,}6 \approx 3{,}27$; cobertura aproximada $2\Phi(3{,}27) - 1 \approx 0{,}9989$, independiente de n.

Resultado. **La cobertura aproximada es al menos** $1-\alpha$, y el intervalo es tanto más conservador cuanto más lejos está p de $1/2$; con $p = 0{,}1$ cubre el 99,9 % de las veces en lugar del 95 %. ■

Comprobación. el precio es la amplitud: con $p = 0{,}1$ el intervalo de Wald tendría un margen de $1{,}96 \cdot 0{,}3/\sqrt{n}$, un 40 % menor que el conservador $1{,}96 \cdot 0{,}5/\sqrt{n}$.

A.5 Tema 5

Solución del ejercicio 5.1

Planteamiento. definición 5.3, proposición 5.4 y observación 5.5.

Desarrollo.

(a) **Falsa.** El p-valor se calcula suponiendo H_0 cierta; no es $\mathbb{P}(H_0 \mid \text{datos})$.

(b) **Verdadera**: $0{,}03 \le 0{,}05$.

(c) **Falsa**: $0{,}03 > 0{,}01$.

(d) **Verdadera**: es la definición.

(e) **Falsa**: el p-valor no mide el tamaño del efecto; depende también de n.

(f) **Falsa**: no rechazar no demuestra H_0.

Resultado. **(a) F; (b) V; (c) F; (d) V; (e) F; (f) F.**

Solución del ejercicio 5.2

Datos. $n = 250$, $x = 140$; bajo H_0, $X \sim \mathrm{Bin}(250;\, 0{,}5)$, con media 125 y desviación típica $\sqrt{62{,}5} \approx 7{,}906$.

Planteamiento. aproximación normal con corrección por continuidad (definición 3.8); contraste bilateral.

Desarrollo.

1. (a) $p = 2\mathbb{P}(X \ge 140) \approx 2\Big(1 - \Phi\big(\frac{139{,}5-125}{7{,}906}\big)\Big) = 2\big(1 - \Phi(1{,}83)\big) = 2 \cdot 0{,}0336 = 0{,}0672$.
2. (b) $0{,}0672 \le 0{,}10$: se rechaza al 10 %; $0{,}0672 > 0{,}05$: no se rechaza al 5 %.
3. (c) Al 1 % se rechaza si $|x - 125| - 0{,}5 \ge z_{0{,}995} \cdot 7{,}906 = 2{,}576 \cdot 7{,}906 \approx 20{,}37$, es decir, $|x - 125| \ge 20{,}87$: hacen falta al menos 146 caras (o a lo sumo 104).
4. (d) Al 5 % se rechaza si $|x-125|-0{,}5 \ge 1{,}96 \cdot 7{,}906 \approx 15{,}50$, es decir, $x \ge 141$ o $x \le 109$. Si $\theta = 0{,}6$: media 150, desviación típica $\sqrt{60} \approx 7{,}746$, y $\mathbb{P}(X \ge 141) \approx 1 - \Phi\big(\frac{140{,}5-150}{7{,}746}\big) = \Phi(1{,}23) = 0{,}8907$; $\mathbb{P}(X \le 109)$ es despreciable.

Resultado. **(a)** $p \approx 0{,}067$**; (b) se rechaza al** 10 %**, no al** 5 %**; (c)** 146 **caras; (d) potencia** $\approx 0{,}89$**.**

Comprobación. los valores binomiales exactos son $p = 0{,}0664$ (el «7 %» de la fuente), $2\mathbb{P}(X \ge 146) = 0{,}0094 \le 0{,}01$ y potencia 0,8896.

Solución del ejercicio 5.3

Datos. sinceras: 131 bien, 9 mal; mentirosas: 15 mal, 125 bien.

Planteamiento. con H_0: «dice la verdad», rechazar H_0 es clasificar como mentirosa.

Desarrollo.

1. Error de tipo I: clasificar como mentirosa a una persona sincera. Estimación: $9/140 \approx 0{,}064$, que es el nivel estimado del detector.
2. Error de tipo II: clasificar como sincera a una persona que miente. Estimación: $15/140 \approx 0{,}107$.
3. Potencia: $1 - 0{,}107 = 125/140 \approx 0{,}893$.

Resultado. $\mathbb{P}$**(tipo I)** $\approx 0{,}064$**;** $\mathbb{P}$**(tipo II)** $\approx 0{,}107$**; nivel** $\approx 0{,}064$**; potencia** $\approx 0{,}893$**.**

Comprobación. nivel $= \mathbb{P}$(tipo I) y potencia $= 1 - \mathbb{P}$(tipo II), como en la definición 5.2.

Solución del ejercicio 5.4

Datos. $n = 3$; $\sigma = 5$; $\alpha = 0{,}04$; $\mu_0 = 40$.

Planteamiento. contraste z unilateral (proposición 5.7); $\sigma/\sqrt{3} \approx 2{,}887$; $z_{0{,}96} = 1{,}7507$.

Desarrollo.

1. (a) $H_0 : \mu = 40$ (el coche no supera el límite; también puede tomarse la compuesta $\mu \leq 40$) frente a $H_1 : \mu > 40$. Se multa si $\bar{x} > 40 + 1{,}7507 \cdot 2{,}887 \approx 45{,}05$.
2. (b) Si nadie supera el límite, toda multa es un error de tipo I: el 100 % de las multas serían erróneas (aunque solo se multaría a un 4 % o menos de los conductores).
3. (c) $\pi(45) = 1 - \Phi\big(1{,}7507 - 5\sqrt{3}/5\big) = 1 - \Phi(1{,}7507 - 1{,}7321) = 1 - \Phi(0{,}019) \approx 0{,}49$.
4. (d) $n \geq \big((z_{0{,}96} + z_{0{,}90})\sigma/\delta\big)^2 = \big((1{,}7507 + 1{,}2816) \cdot 5/5\big)^2 \approx 9{,}19$, luego 10 radares.

Resultado. **(a) umbral** $\approx 45{,}05$ **km/h; (b) todas; (c) potencia** $\approx 0{,}49$**; (d)** 10 **radares.**

Comprobación. la potencia contra 45 es casi 1/2 porque el umbral (45,05) es casi igual a 45: un coche a 45 supera el umbral la mitad de las veces.

Solución del ejercicio 5.5

Datos. $X \sim \mathrm{U}(0, \theta)$; región de rechazo $\{x \leq 0{,}1\} \cup \{x \geq 1{,}9\}$.

Planteamiento. calcular probabilidades de intervalos con la densidad uniforme.

Desarrollo.

1. (a) Con $\theta = 2$: $\mathbb{P}(X \leq 0{,}1) + \mathbb{P}(X \geq 1{,}9) = 0{,}1/2 + 0{,}1/2 = 0{,}1$.
2. (b) Con $\theta = 2{,}5$, no se rechaza si $0{,}1 < X < 1{,}9$: probabilidad $1{,}8/2{,}5 = 0{,}72$.

Resultado. **(a)** 0,10**; (b)** 0,72**.**

Comprobación. la potencia contra $\theta = 2{,}5$ es 0,28, mayor que el nivel 0,10, pero pequeña: con una sola observación es difícil distinguir $\theta = 2$ de $\theta = 2{,}5$.

Solución del ejercicio 5.6

Datos. $n = 16$; $\bar{x} = 11$; $s = 2$; $\mu_0 = 10$; $\alpha = 0{,}05$; 15 grados de libertad.

Planteamiento. contraste t; $t_{15;0{,}975} = 2{,}131$ y $t_{15;0{,}95} = 1{,}753$.

Desarrollo.

1. $t = \dfrac{11 - 10}{2/\sqrt{16}} = \dfrac{1}{0{,}5} = 2$.
2. (a) Bilateral: $|t| = 2 < 2{,}131$, no se rechaza. Como $1{,}753 < 2 < 2{,}131$, el p-valor unilateral está entre 0,025 y 0,05 y el bilateral entre 0,05 y 0,10.
3. (b) Unilateral: $t = 2 > 1{,}753$, se rechaza; $0{,}025 < p < 0{,}05$.

Resultado. **(a) No se rechaza** $(0{,}05 < p < 0{,}10)$**; (b) se rechaza** $(0{,}025 < p < 0{,}05)$**.**

Comprobación. los p-valores exactos son 0,0639 y 0,0320. El ejemplo muestra por qué la alternativa debe fijarse antes de ver los datos (observación 5.14(a)).

Solución del ejercicio 5.7

Datos. $\mu_0 = 16{,}43$; $\sigma = 0{,}8$; $n = 15$; $\bar{x} = 16$; $\alpha = 0{,}05$.

Planteamiento. contraste z unilateral: $H_0 : \mu = 16{,}43$ frente a $H_1 : \mu < 16{,}43$.

Desarrollo.

1. $\sigma/\sqrt{n} = 0{,}8/\sqrt{15} \approx 0{,}2066$.
2. $z = (16 - 16{,}43)/0{,}2066 \approx -2{,}08$.
3. $p = \Phi(-2{,}08) = 1 - 0{,}9812 = 0{,}0188 < 0{,}05$.

Resultado. $z \approx -2{,}08$**,** $p \approx 0{,}019$**: se rechaza** H_0; hay evidencia de que la media es menor que la anunciada.

Comprobación. equivalentemente, $z = -2{,}08 < -z_{0{,}95} = -1{,}645$.

Solución del ejercicio 5.8

Datos. $p_0 = 0{,}25$; $n = 42$; $x = 17$; $\alpha = 0{,}01$.

Planteamiento. contraste z unilateral para una proporción, con el error estándar calculado con p_0.

Desarrollo.

1. $\widehat{p} = 17/42 \approx 0{,}4048$.
2. $\sqrt{p_0(1-p_0)/n} = \sqrt{0{,}1875/42} \approx 0{,}06682$.
3. $z = (0{,}4048 - 0{,}25)/0{,}06682 \approx 2{,}32$; $p = 1 - \Phi(2{,}32) = 1 - 0{,}9898 = 0{,}0102$.
4. $0{,}0102 > 0{,}01$: no se rechaza.

Resultado. $z \approx 2{,}32$**,** $p \approx 0{,}010$**: no se rechaza** H_0 **al** $1\,\%$ (sí se rechazaría al $5\,\%$).

Comprobación. $np_0 = 10{,}5$ y $n(1-p_0) = 31{,}5$, de modo que la aproximación normal es aceptable; el resultado está justo en el límite, y conviene informar del p-valor en lugar de solo «no significativo».

Solución del ejercicio 5.9

Datos. $O = (15, 12, 9, 9, 15)$; $n = 60$; $k = 5$.

Planteamiento. definición 5.8 con $p_{0j} = 1/5$.

Desarrollo.

1. $E_j = 60/5 = 12$ para todo j.
2. $X^2 = \dfrac{3^2 + 0^2 + 3^2 + 3^2 + 3^2}{12} = \dfrac{36}{12} = 3$.
3. Grados de libertad: $k - 1 = 4$; $\chi^2_{4;0{,}95} = 9{,}488$.
4. $3 < 9{,}488$: no se rechaza.

Resultado. $X^2 = 3$ **con** 4 **grados de libertad; no se rechaza la uniformidad** ($p \approx 0{,}56$)**.**

Comprobación. $\mathbb{E}[\chi^2_4] = 4$: un valor de 3 es completamente típico bajo H_0.

Solución del ejercicio 5.10

Datos. $n = 100$; $E_j = 100p_j$; $O = (7, 13, 12, 9, 9, 13, 11, 10, 16)$.

Planteamiento. definición 5.8 con $k - 1 = 8$ grados de libertad.

Desarrollo.

1. $E = (30{,}1;\ 17{,}6;\ 12{,}5;\ 9{,}7;\ 7{,}9;\ 6{,}7;\ 5{,}8;\ 5{,}1;\ 4{,}6)$.

2. Contribuciones $(O_j - E_j)^2/E_j$: 17,73; 1,20; 0,02; 0,05; 0,15; 5,92; 4,66; 4,71; 28,25.
3. $X^2 \approx 62{,}70$; $\chi^2_{8;0{,}999} = 26{,}12$.
4. $62{,}70 > 26{,}12$: se rechaza H_0 al nivel 0,001.

Resultado. $X^2 \approx 62{,}7$ **con** 8 **grados de libertad: se rechaza con mucha claridad** (hay demasiados nueves y muy pocos unos); se recomienda revisar la nota de gastos.

Comprobación. $E_9 = 4{,}6 < 5$. Agrupando los dígitos 8 y 9 ($E = 9{,}7$, $O = 26$) se obtiene $X^2 \approx 57{,}1$ con 7 grados de libertad, frente a $\chi^2_{7;0{,}999} = 24{,}32$: la conclusión no cambia.

Solución del ejercicio 5.11

Datos. $n_A = n_B = 1000$; $\widehat{p}_A = 0{,}78$; $\widehat{p}_B = 0{,}75$.

Planteamiento. bajo H_0, $p_A = p_B = p$, $\operatorname{Var}(\widehat{p}_A - \widehat{p}_B) = p(1-p)(1/n_A + 1/n_B)$, y p se estima con la proporción combinada.

Desarrollo.

1. (a) $H_0 : p_A = p_B$ (compuesta: no fija el valor común) frente a $H_1 : p_A \neq p_B$.
2. (b) $\widehat{p} = (780 + 750)/2000 = 0{,}765$; $\widehat{\operatorname{Var}} = 0{,}765 \cdot 0{,}235 \cdot (2/1000) \approx 0{,}000\,359\,6$; $\widehat{\text{ee}} \approx 0{,}01896$.
3. $z = (0{,}78 - 0{,}75)/0{,}01896 \approx 1{,}58$; $p = 2\big(1 - \Phi(1{,}58)\big) = 2 \cdot 0{,}0571 = 0{,}1142$.
4. (c) $0{,}114 > 0{,}05$: no es significativa.

Resultado. $z \approx 1{,}58$**,** $p \approx 0{,}11$**: la diferencia de tres puntos no es significativa al** 5 %**.**

Comprobación. para que una diferencia de tres puntos fuera significativa con estas exactitudes haría falta que $0{,}03/\sqrt{0{,}18 \cdot 2/n} \geq 1{,}96$, es decir, $n \geq 1{,}96^2 \cdot 0{,}36/0{,}0009 \approx 1537$ preguntas por modelo.

Solución del ejercicio 5.12

Datos. $m = 20$; $\alpha = 0{,}05$; todas las nulas ciertas; contrastes independientes.

Planteamiento. proposición 5.10 y teorema 5.12.

Desarrollo.

1. (a) $\mathbb{P}(\text{al menos uno}) = 1 - 0{,}95^{20} \approx 1 - 0{,}3585 = 0{,}6415$. Número esperado: $20 \cdot 0{,}05 = 1$.
2. (b) Bonferroni: nivel $0{,}05/20 = 0{,}0025$ por contraste.
3. Probabilidad exacta de algún falso positivo con contrastes independientes: $1 - (1 - 0{,}0025)^{20} = 1 - 0{,}9975^{20} \approx 0{,}0488$.

Resultado. **(a)** $\approx 0{,}64$ **y** 1 **falso positivo esperado; (b)** 0,0025 **por contraste y FWER** $\approx 0{,}049 \leq 0{,}05$**.**

Comprobación. el valor 0,0488 es algo menor que 0,05, como garantiza el teorema 5.12; la diferencia es la holgura de la desigualdad de la unión.

Solución del ejercicio 5.13

Planteamiento. (a) complemento e independencia; (b) igualar a α; (c) desigualdad de Bernoulli.

Desarrollo.

1. (a) $\mathbb{P}(\min_i P_i > t) = \mathbb{P}(P_1 > t, \dots, P_n > t) = \prod_i \mathbb{P}(P_i > t) = (1-t)^n$, luego $\mathbb{P}(\min_i P_i \le t) = 1-(1-t)^n$.
2. (b) Se produce algún falso positivo si y solo si $\min_i P_i \le t$. Con $t = 1-(1-\alpha)^{1/n}$: $1-(1-t)^n = 1-\big((1-\alpha)^{1/n}\big)^n = 1-(1-\alpha) = \alpha$.
3. (c) Con $x = -\alpha/n \ge -1$, Bernoulli da $(1-\alpha/n)^n \ge 1-\alpha$. Tomando raíces n-ésimas (función creciente): $1-\alpha/n \ge (1-\alpha)^{1/n}$, es decir, $\alpha/n \le 1-(1-\alpha)^{1/n}$.
4. Un umbral mayor rechaza más hipótesis, luego el procedimiento es al menos tan potente como el de Bonferroni.

Resultado. $\mathbb{P}(\min P_i \le t) = 1-(1-t)^n$**; el umbral** $1-(1-\alpha)^{1/n}$ **da FWER exactamente** α **y es mayor o igual que** α/n**.** ■

Comprobación. con $n = 20$ y $\alpha = 0{,}05$: $1-0{,}95^{1/20} \approx 0{,}002\,561 > 0{,}0025$. La ganancia es pequeña, y a cambio exige independencia; Bonferroni no la exige.

Solución del ejercicio 5.14

Planteamiento. calcular la función de distribución de p usando que F_0 es continua y estrictamente creciente, y por tanto invertible en su recorrido.

Desarrollo.

1. Sea $u \in (0,1)$. $p \le u \iff 1-F_0(T) \le u \iff F_0(T) \ge 1-u \iff T \ge F_0^{-1}(1-u)$.
2. Bajo H_0, $\mathbb{P}\big(T \ge F_0^{-1}(1-u)\big) = 1-F_0\big(F_0^{-1}(1-u)\big) = 1-(1-u) = u$ (por continuidad, $\mathbb{P}(T=c)=0$).
3. Luego $\mathbb{P}_{H_0}(p \le u) = u$ para todo $u \in (0,1)$: $p \sim \mathrm{U}(0,1)$. Con $u=\alpha$, $\mathbb{P}_{H_0}(p \le \alpha) = \alpha$.

Resultado. **Bajo** H_0**, el** p**-valor es uniforme en** $(0,1)$ **y la regla «rechazar si** $p \le \alpha$**» tiene nivel exactamente** α**.** ■

Comprobación. este resultado justifica el apartado (a) del ejercicio 5.13. Si el estadístico es discreto (por ejemplo, binomial), p no es exactamente uniforme y el nivel real es $\le \alpha$.

Solución del ejercicio 5.15

Planteamiento. escribir la condición de no rechazo y despejar μ_0.

Desarrollo.

1. Sea $c = z_{1-\alpha/2}$. El contraste no rechaza $H_0 : \mu = \mu_0$ si y solo si $|\bar{x}-\mu_0| \le c\,\sigma/\sqrt{n}$.
2. $|\bar{x}-\mu_0| \le c\sigma/\sqrt{n} \iff -c\sigma/\sqrt{n} \le \mu_0 - \bar{x} \le c\sigma/\sqrt{n} \iff \bar{x}-c\sigma/\sqrt{n} \le \mu_0 \le \bar{x}+c\sigma/\sqrt{n}$.
3. La última condición es la pertenencia de μ_0 al intervalo del teorema 4.10.

Resultado. **No se rechaza** μ_0 **al nivel** α **si y solo si** μ_0 **está en el intervalo de nivel** $1-\alpha$**.** El intervalo de confianza es el conjunto de valores del parámetro compatibles con los datos al nivel α. ■

Comprobación. en el ejercicio 4.1, el 0 no está en $[10, 20]$, luego un contraste bilateral al 5 % rechaza la mejora nula.

Solución del ejercicio 5.16

Datos. $\pi(\mu) = 1-\Phi\big(z_{1-\alpha} - (\mu-\mu_0)\sqrt{n}/\sigma\big)$.

Planteamiento. monotonía de Φ; resolver la desigualdad $\pi(\mu_1) \geq 1-\beta$.

Desarrollo.

1. (a) El argumento $g(\mu) = z_{1-\alpha} - (\mu-\mu_0)\sqrt{n}/\sigma$ es estrictamente decreciente en μ y Φ es estrictamente creciente, luego $\pi = 1 - \Phi \circ g$ es estrictamente creciente. Además $\pi(\mu_0) = 1 - \Phi(z_{1-\alpha}) = 1-(1-\alpha) = \alpha$.
2. (b) Si $\mu > \mu_0$, $g(\mu) \to -\infty$ cuando $n \to \infty$, y $\Phi(g) \to 0$, luego $\pi(\mu) \to 1$.
3. (c) $\pi(\mu_1) \geq 1-\beta \iff \Phi\big(z_{1-\alpha} - \delta\sqrt{n}/\sigma\big) \leq \beta \iff z_{1-\alpha} - \delta\sqrt{n}/\sigma \leq z_\beta = -z_{1-\beta} \iff \sqrt{n} \geq (z_{1-\alpha}+z_{1-\beta})\sigma/\delta$, y se elevan al cuadrado ambos miembros, positivos.
4. (d) $n \geq \big((1{,}645+1{,}2816)\cdot 80/20\big)^2 = (11{,}706)^2 \approx 137{,}0$, luego $n = 138$.

Resultado. π **es creciente, vale** α **en** μ_0 **y tiende a** 1**; el tamaño muestral es el indicado; en el ejemplo,** $n = 138$ **respuestas.** ■

Comprobación. con $n = 138$: $\pi(220) = 1 - \Phi\big(1{,}645 - 20\sqrt{138}/80\big) = 1 - \Phi(1{,}645 - 2{,}937) = \Phi(1{,}292) \approx 0{,}90$.

A.6 Tema 6

Solución del ejercicio 6.1

Planteamiento. teorema 6.2, proposición 6.4, corolario 6.7 y observación 6.11.

Desarrollo.

(a) **Verdadera**: $\widehat{b}_0 = \bar{y} - \widehat{b}_1\bar{x}$ equivale a $\bar{y} = \widehat{b}_0 + \widehat{b}_1\bar{x}$.

(b) **Falsa**: $R^2 = r^2 = 0{,}81 \geq 0$.

(c) **Falsa**: R^2 mide la calidad del ajuste lineal, no la causalidad.

(d) **Verdadera**, por la proposición 6.4.

(e) **Falsa**: la pendiente de x sobre y es $r\,s_x/s_y$, que coincide con $1/\widehat{b}_1 = s_x/(r\,s_y)$ solo si $r^2 = 1$.

Resultado. **(a) V; (b) F; (c) F; (d) V; (e) F.**

Solución del ejercicio 6.2

Datos. $n = 5$; $\sum x_i = 10$; $\sum y_i = 15$; $\sum x_i^2 = 30$; $\sum y_i^2 = 55$; $\sum x_i y_i = 38$.

Planteamiento. sumas centradas con la fórmula de cálculo y teorema 6.2.

Desarrollo.

1. $\bar{x} = 2$, $\bar{y} = 3$; $S_{xx} = 30 - 5\cdot 4 = 10$; $S_{yy} = 55 - 5\cdot 9 = 10$; $S_{xy} = 38 - 5\cdot 2\cdot 3 = 8$; $r = 8/\sqrt{100} = 0{,}8$.
2. $\widehat{b}_1 = 8/10 = 0{,}8$; $\widehat{b}_0 = 3 - 0{,}8\cdot 2 = 1{,}4$; $\widehat{y} = 1{,}4 + 0{,}8x$.
3. Ajustados: 1,4; 2,2; 3,0; 3,8; 4,6. Residuos: $-0{,}4$; $0{,}8$; $-1{,}0$; $1{,}2$; $-0{,}6$.
4. $\mathrm{SC}_E = 0{,}16 + 0{,}64 + 1 + 1{,}44 + 0{,}36 = 3{,}6$; $R^2 = 1 - 3{,}6/10 = 0{,}64$; $s_e = \sqrt{3{,}6/3} = \sqrt{1{,}2} \approx 1{,}095$.

5. $\widehat{y}(2{,}5) = 1{,}4 + 2 = 3{,}4$.

Resultado. $\widehat{y} = 1{,}4 + 0{,}8x$**;** $r = 0{,}8$**;** $R^2 = 0{,}64$**;** $s_e \approx 1{,}10$**; predicción** $3{,}4$**.**

Comprobación. los residuos suman 0 y $\mathrm{SC}_E = S_{yy}(1 - r^2) = 10 \cdot 0{,}36 = 3{,}6$.

Solución del ejercicio 6.3

Datos. $(1, 8), (3, 2), (5, 1)$.

Planteamiento. la log-verosimilitud total es una constante menos $\mathrm{SC}(b, a)/(2\sigma^2)$; se maximiza minimizando SC (observación 6.8).

Desarrollo.

1. (a) $y_1 \sim \mathcal{N}(ax_1 + b, \sigma^2)$: $\ln f(y_1) = -\ln\big(\sigma\sqrt{2\pi}\big) - \dfrac{(y_1 - ax_1 - b)^2}{2\sigma^2}$.
2. (b) Sumando para los tres datos, $\ell(a, b) = -3\ln(\sigma\sqrt{2\pi}) - \frac{1}{2\sigma^2}\sum_i (y_i - ax_i - b)^2$; para cualquier σ, el máximo en (a, b) es el mínimo de la suma de cuadrados.
3. $\bar{x} = 3$; $\bar{y} = 11/3$; $S_{xx} = 35 - 27 = 8$; $S_{xy} = 19 - 3 \cdot 3 \cdot \frac{11}{3} = 19 - 33 = -14$.
4. $\widehat{a} = -14/8 = -1{,}75$; $\widehat{b} = \frac{11}{3} + 1{,}75 \cdot 3 = \frac{107}{12} \approx 8{,}917$.

Resultado. $\widehat{a} = -1{,}75$ **y** $\widehat{b} = 107/12 \approx 8{,}92$, independientes de σ.

Comprobación. residuos: $8 - 7{,}167 = 0{,}833$; $2 - 3{,}667 = -1{,}667$; $1 - 0{,}167 = 0{,}833$; suman 0 y $\sum x_i e_i = 0{,}833 - 5 + 4{,}167 = 0$.

Solución del ejercicio 6.4

Datos. $n = 11$ y las sumas del enunciado.

Planteamiento. fórmula de cálculo para las sumas centradas y teorema 6.2.

Desarrollo.

1. $\bar{x} = 761/11 \approx 69{,}18$; $\bar{y} = 1765/11 \approx 160{,}45$.
2. $S_{xx} = 52\,729 - 761^2/11 \approx 52\,729 - 52\,647{,}36 = 81{,}64$.
3. $S_{xy} = 122\,500 - 761 \cdot 1765/11 \approx 122\,500 - 122\,105{,}91 = 394{,}09$.
4. $S_{yy} = 287\,529 - 1765^2/11 \approx 287\,529 - 283\,202{,}27 = 4326{,}73$.
5. $\widehat{b}_1 = 394{,}09/81{,}64 \approx 4{,}827$; $\widehat{b}_0 = 160{,}45 - 4{,}827 \cdot 69{,}18 \approx -173{,}51$.
6. $r = 394{,}09/\sqrt{81{,}64 \cdot 4326{,}73} \approx 394{,}09/594{,}31 \approx 0{,}663$.
7. (b) $\widehat{y}(73) = -173{,}51 + 4{,}827 \cdot 73 \approx 178{,}9$.
8. (c) $\widehat{y}(65) \approx -173{,}51 + 313{,}78 = 140{,}27$; residuo $175 - 140{,}27 \approx 34{,}7$.

Resultado. $\widehat{y} = -173{,}51 + 4{,}83x$**;** $r \approx 0{,}663$**; predicción** $\approx 178{,}9$**; residuo** $\approx 34{,}7$**.**

Comprobación. coincide con la recta y la correlación de la fuente; $R^2 \approx 0{,}44$: el tercer examen explica menos de la mitad de la variabilidad del final.

Solución del ejercicio 6.5

Datos. $n = 6$; $\sum x_i = 450$; $\sum y_i = 262$; $\sum x_i^2 = 35\,500$; $\sum y_i^2 = 13\,784$; $\sum x_i y_i = 17\,700$.

Planteamiento. teorema 6.2; después, examinar los residuos.

Desarrollo.

1. $\bar{x} = 75$; $\bar{y} \approx 43{,}67$; $S_{xx} = 35\,500 - 33\,750 = 1750$; $S_{xy} = 17\,700 - 450 \cdot 262/6 = 17\,700 - 19\,650 = -1950$; $S_{yy} = 13\,784 - 11\,440{,}67 = 2343{,}33$.
2. $\widehat{b}_1 = -1950/1750 \approx -1{,}114$; $\widehat{b}_0 = 43{,}67 + 1{,}114 \cdot 75 \approx 127{,}24$.
3. $r = -1950/\sqrt{1750 \cdot 2343{,}33} \approx -1950/2025{,}0 \approx -0{,}963$.
4. (b) $\widehat{y}(85) \approx 127{,}24 - 94{,}71 = 32{,}5$ minutos; $\widehat{y}(110) \approx 127{,}24 - 122{,}57 = 4{,}7$ minutos.
5. La primera es una interpolación (dentro de $[50, 100]$) y es razonable; la segunda es una extrapolación y no es fiable.
6. (c) Residuos: 8,5; $-5{,}4$; $-4{,}2$; $-3{,}1$; $-2{,}0$; 6,2. Son positivos en los extremos y negativos en el centro: la relación es curva (convexa), y la recta subestima en los extremos.

Resultado. $\widehat{y} = 127{,}24 - 1{,}114x$**;** $r \approx -0{,}963$**; predicciones** 32,5 **(fiable) y** 4,7 **(extrapolación); los residuos sugieren curvatura.**

Comprobación. los residuos suman $8{,}48 - 5{,}38 - 4{,}24 - 3{,}10 - 1{,}95 + 6{,}19 \approx 0$. A pesar de $R^2 \approx 0{,}93$, el patrón de residuos indica que un modelo curvo sería mejor (observación 6.11(e)).

Solución del ejercicio 6.6

Datos. $n = 9$ y las sumas del enunciado.

Planteamiento. teorema 6.2 y corolario 6.7.

Desarrollo.

1. $\bar{x} = 654/9 \approx 72{,}67$; $\bar{y} = 1288/9 \approx 143{,}11$.
2. $S_{xx} = 47\,988 - 654^2/9 = 47\,988 - 47\,524 = 464$.
3. $S_{xy} = 98\,132 - 654 \cdot 1288/9 \approx 98\,132 - 93\,594{,}67 = 4537{,}33$.
4. $S_{yy} = 231\,026 - 1288^2/9 \approx 231\,026 - 184\,327{,}11 = 46\,698{,}89$.
5. $\widehat{b}_1 = 4537{,}33/464 \approx 9{,}779$; $\widehat{b}_0 = 143{,}11 - 9{,}779 \cdot 72{,}67 \approx -567{,}48$.
6. $r = 4537{,}33/\sqrt{464 \cdot 46\,698{,}89} \approx 4537{,}33/4654{,}9 \approx 0{,}975$; $R^2 \approx 0{,}950$.
7. $\widehat{y}(74) \approx -567{,}48 + 9{,}779 \cdot 74 \approx 156{,}1$.

Resultado. $\widehat{y} = -567{,}48 + 9{,}78x$**;** $r \approx 0{,}975$**;** $R^2 \approx 0{,}95$**; unos** 156 **helados.**

Comprobación. la ordenada en el origen, -567, no tiene interpretación (no se venden helados negativos a 0 grados): $x = 0$ está muy fuera del rango de los datos.

Solución del ejercicio 6.7

Datos. $\bar{x} = 10$; $\bar{y} = 50$; $s_x = 2$; $s_y = 8$; $r = 0{,}75$.

Planteamiento. teorema 6.2 con $\widehat{b}_1 = r\, s_y/s_x$; para x sobre y, intercambiar los papeles.

Desarrollo.

1. (a) $\widehat{b}_1 = 0{,}75 \cdot 8/2 = 3$; $\widehat{b}_0 = 50 - 3 \cdot 10 = 20$; $\widehat{y} = 20 + 3x$; $\widehat{y}(12) = 56$.
2. (b) Pendiente $r\, s_x/s_y = 0{,}75 \cdot 2/8 = 0{,}1875$; ordenada $10 - 0{,}1875 \cdot 50 = 0{,}625$; $\widehat{x} = 0{,}625 + 0{,}1875\, y$.
3. (c) $3 \cdot 0{,}1875 = 0{,}5625 = 0{,}75^2$. Despejando x en la recta de (a) se obtendría $x = (y-20)/3$, de pendiente $1/3 \neq 0{,}1875$.

Resultado. $\widehat{y} = 20 + 3x$ **(predicción** 56**) y** $\widehat{x} = 0{,}625 + 0{,}1875y$**; el producto de pendientes es** $r^2 = 0{,}5625$**.**

Comprobación. ambas rectas pasan por $(10, 50)$: $20 + 30 = 50$ y $0{,}625 + 9{,}375 = 10$.

Solución del ejercicio 6.8

Datos. $u_i = \log_{10} N_i = 6, 7, 8, 9$; $v_i = \log_{10} L_i = 0{,}6990;\ 0{,}6128;\ 0{,}5185;\ 0{,}4314$.

Planteamiento. recta de mínimos cuadrados de v sobre u; $\widehat{\alpha} = -\widehat{b}_1$ y $\widehat{a} = 10^{\widehat{b}_0}$.

Desarrollo.

1. $\bar{u} = 7{,}5$; $\bar{v} = 2{,}2617/4 = 0{,}565\,43$; $S_{uu} = 2{,}25 + 0{,}25 + 0{,}25 + 2{,}25 = 5$.
2. $S_{uv} = \sum (u_i - \bar{u}) v_i = -1{,}5 \cdot 0{,}6990 - 0{,}5 \cdot 0{,}6128 + 0{,}5 \cdot 0{,}5185 + 1{,}5 \cdot 0{,}4314 = -0{,}448\,55$.
3. $\widehat{b}_1 = -0{,}448\,55/5 \approx -0{,}0897$; $\widehat{b}_0 = 0{,}565\,43 + 0{,}0897 \cdot 7{,}5 \approx 1{,}2382$.
4. $\widehat{\alpha} \approx 0{,}0897$; $\widehat{a} = 10^{1{,}2382} \approx 17{,}3$; $L \approx 17{,}3\, N^{-0{,}0897}$.
5. (b) $\log_{10} \widehat{L} = 1{,}2382 - 0{,}0897 \cdot 10 \approx 0{,}3411$; $\widehat{L} \approx 10^{0{,}3411} \approx 2{,}19$.
6. (c) $N = 10^{10}$ está fuera del rango observado (10^6 a 10^9); la predicción supone que la ley de potencia sigue valiendo un orden de magnitud más allá.

Resultado. $L \approx 17{,}3\, N^{-0{,}090}$**; predicción para** $N = 10^{10}$**:** $L \approx 2{,}19$ **(extrapolación).**

Comprobación. con la ley ajustada, $L(10^6) = 17{,}3 \cdot 10^{-0{,}538} \approx 17{,}3 \cdot 0{,}290 \approx 5{,}02$, muy próximo al dato 5,0; $r \approx -0{,}9999$.

Solución del ejercicio 6.9

Datos. A: 45/50 fáciles, 75/250 difíciles. B: 200/250 fáciles, 10/50 difíciles.

Planteamiento. calcular proporciones por grupo y en total, y observar la composición de cada evaluación.

Desarrollo.

1. A: fáciles 0,90; difíciles 0,30; total $120/300 = 0{,}40$.
2. B: fáciles 0,80; difíciles 0,20; total $210/300 = 0{,}70$.
3. A es mejor en cada tipo de pregunta, pero peor en el total: A se ha evaluado sobre todo con preguntas difíciles (250 de 300) y B sobre todo con fáciles. La dificultad es una variable de confusión.
4. Una comparación justa usa la misma mezcla para ambos. Con una mezcla al 50 %: A obtiene $(0{,}90 + 0{,}30)/2 = 0{,}60$ y B, $(0{,}80 + 0{,}20)/2 = 0{,}50$.

Resultado. **A es mejor** (lo es en ambos estratos); la exactitud total favorece a B solo porque los dos modelos se evaluaron con mezclas distintas de dificultad (paradoja de Simpson).

Comprobación. con cualquier mezcla común con proporción w de fáciles, A obtiene $0{,}30 + 0{,}60w$ y B, $0{,}20 + 0{,}60w$: A gana por 0,10 siempre.

Solución del ejercicio 6.10

Datos. $x = -2, \ldots, 2$; $y = x^2$.

Planteamiento. calcular S_{xy} y los residuos.

Desarrollo.

1. $\bar{x} = 0$; $\bar{y} = 10/5 = 2$; $S_{xy} = \sum x_i y_i - 0 = \sum x_i^3 = -8 - 1 + 0 + 1 + 8 = 0$. Luego $r = 0$.
2. $\widehat{b}_1 = 0$; $\widehat{b}_0 = 2$; la recta es $\widehat{y} = 2$.
3. Residuos: $2, -1, -2, -1, 2$. Forman una «U»: positivos en los extremos, negativos en el centro.

Resultado. $r = 0$ **y la recta es horizontal, pero** y **está determinada exactamente por** x; el patrón de los residuos revela la relación cuadrática.

Comprobación. $\mathrm{SC}_E = 4 + 1 + 4 + 1 + 4 = 14 = S_{yy}$, coherente con $R^2 = 0$.

Solución del ejercicio 6.11

Planteamiento. derivadas parciales de $\mathrm{SC}(b_0, b_1) = \sum_i (y_i - b_0 - b_1 x_i)^2$.

Desarrollo.

1. $\dfrac{\partial \mathrm{SC}}{\partial b_0} = -2\sum_i (y_i - b_0 - b_1 x_i)$ y $\dfrac{\partial \mathrm{SC}}{\partial b_1} = -2\sum_i x_i (y_i - b_0 - b_1 x_i)$.
2. Igualando a cero se obtienen las ecuaciones normales: $n b_0 + b_1 \sum x_i = \sum y_i$ y $b_0 \sum x_i + b_1 \sum x_i^2 = \sum x_i y_i$.
3. De la primera, $b_0 = \bar{y} - b_1 \bar{x}$. Sustituyendo en la segunda: $(\bar{y} - b_1\bar{x}) n\bar{x} + b_1 \sum x_i^2 = \sum x_i y_i$, es decir, $b_1\big(\sum x_i^2 - n\bar{x}^2\big) = \sum x_i y_i - n\bar{x}\bar{y}$, y $b_1 = S_{xy}/S_{xx}$.
4. Hessiana: $H = \begin{pmatrix} 2n & 2\sum x_i \\ 2\sum x_i & 2\sum x_i^2 \end{pmatrix}$, constante. Su elemento $(1,1)$ es $2n > 0$ y su determinante es $4\big(n\sum x_i^2 - (\sum x_i)^2\big) = 4nS_{xx} > 0$. Por el criterio de Sylvester, H es definida positiva.
5. Una función cuadrática con hessiana constante definida positiva es estrictamente convexa, y su único punto crítico es el mínimo global.

Resultado. **Se recupera** $\widehat{b}_1 = S_{xy}/S_{xx}$ **y** $\widehat{b}_0 = \bar{y} - \widehat{b}_1\bar{x}$**, y el punto crítico es el mínimo global.** ■

Comprobación. con los datos del ejemplo 6.3: $5b_0 + 15b_1 = 20$ y $15b_0 + 55b_1 = 66$ tienen solución $b_1 = 0{,}6$, $b_0 = 2{,}2$.

Solución del ejercicio 6.12

Planteamiento. las ecuaciones normales del ejercicio 6.11 se escriben en términos de los residuos $e_i = y_i - \widehat{b}_0 - \widehat{b}_1 x_i$.

Desarrollo.

1. La primera ecuación normal es $\sum_i (y_i - \widehat{b}_0 - \widehat{b}_1 x_i) = 0$, es decir, $\sum_i e_i = 0$. (Directamente: $e_i = (y_i - \bar{y}) - \widehat{b}_1(x_i - \bar{x})$ y ambas desviaciones suman cero.)
2. La segunda es $\sum_i x_i (y_i - \widehat{b}_0 - \widehat{b}_1 x_i) = 0$, es decir, $\sum_i x_i e_i = 0$. (Directamente: $\sum_i x_i e_i = \sum_i (x_i - \bar{x}) e_i = S_{xy} - \widehat{b}_1 S_{xx} = 0$.)
3. $\sum_i \widehat{y}_i e_i = \widehat{b}_0 \sum_i e_i + \widehat{b}_1 \sum_i x_i e_i = 0$.
4. Como $y_i = \widehat{y}_i + e_i$ y $\sum e_i = 0$, $\frac{1}{n}\sum \widehat{y}_i = \bar{y}$.

Resultado. **Las tres identidades son ciertas, y la media de los ajustados es $\bar{y}$.** ■

Comprobación. en el ejemplo 6.3: $\sum x_i e_i = -0{,}8 + 1{,}2 + 3{,}0 - 2{,}4 - 1{,}0 = 0$.

Solución del ejercicio 6.13

Planteamiento. derivar $g(b) = \sum_i (y_i - b x_i)^2$.

Desarrollo.

1. $g'(b) = -2\sum_i x_i(y_i - b x_i) = 0 \iff \sum x_i y_i = b \sum x_i^2 \iff b = \sum x_i y_i / \sum x_i^2$.
2. $g''(b) = 2\sum x_i^2 > 0$: g es una parábola convexa y el punto crítico es su mínimo global.
3. La ecuación $g'(\widehat{b}) = 0$ es precisamente $\sum_i x_i e_i = 0$.
4. Ejemplo: $(1,2), (2,2)$. $\widehat{b} = (2+4)/(1+4) = 1{,}2$; residuos $2 - 1{,}2 = 0{,}8$ y $2 - 2{,}4 = -0{,}4$; $\sum e_i = 0{,}4 \neq 0$, mientras que $\sum x_i e_i = 0{,}8 - 0{,}8 = 0$.

Resultado. $\widehat{b} = \sum x_i y_i / \sum x_i^2$**;** $\sum x_i e_i = 0$**, pero en general** $\sum e_i \neq 0$, porque sin ordenada en el origen no hay ecuación normal asociada a b_0. ■

Comprobación. con ordenada libre, esos dos puntos dan la recta horizontal $y = 2$ con residuos nulos.

Solución del ejercicio 6.14

Planteamiento. por la proposición 1.14, $x'_i - \bar{x}' = \alpha(x_i - \bar{x})$ e $y'_i - \bar{y}' = \gamma(y_i - \bar{y})$.

Desarrollo.

1. $S_{x'y'} = \alpha\gamma S_{xy}$ y $S_{x'x'} = \alpha^2 S_{xx}$, luego $\widehat{b}'_1 = \alpha\gamma S_{xy}/(\alpha^2 S_{xx}) = (\gamma/\alpha)\widehat{b}_1$.
2. Por el ejercicio 1.12, $r' = \text{signo}(\alpha\gamma)\, r$, luego $R^2 = r'^2 = r^2$.
3. Recta ajustada: $\widehat{y}'_i - \bar{y}' = \widehat{b}'_1(x'_i - \bar{x}') = (\gamma/\alpha)\widehat{b}_1\,\alpha(x_i - \bar{x}) = \gamma(\widehat{y}_i - \bar{y})$, de modo que $\widehat{y}'_i = \gamma\widehat{y}_i + \delta$.
4. Residuos: $e'_i = y'_i - \widehat{y}'_i = \gamma y_i + \delta - \gamma\widehat{y}_i - \delta = \gamma e_i$.
5. De metros a centímetros: $\alpha = 100$, $\gamma = 1$; la pendiente se divide por 100.

Resultado. $\widehat{b}'_1 = (\gamma/\alpha)\widehat{b}_1$**,** R^2 **invariante y** $e'_i = \gamma e_i$; al pasar x a centímetros, la pendiente se divide por 100 (es el cambio de y por centímetro, no por metro). ■

Comprobación. la predicción es equivariante: transformar los datos y ajustar da lo mismo que ajustar y transformar la predicción.

Solución del ejercicio 6.15

Planteamiento. escribir la recta como $\widehat{y} - \bar{y} = \widehat{b}_1(x - \bar{x})$ con $\widehat{b}_1 = r\, s_y/s_x$.

Desarrollo.

1. (a) $\widehat{y} - \bar{y} = r\dfrac{s_y}{s_x}(x - \bar{x})$; dividiendo por s_y: $\dfrac{\widehat{y} - \bar{y}}{s_y} = r\,\dfrac{x - \bar{x}}{s_x}$, es decir, $\widehat{z}_y = r\, z_x$.
2. (b) $|\widehat{z}_y| = |r|\,|z_x| < |z_x|$ si $|r| < 1$ y $z_x \neq 0$: la predicción está más cerca de la media, en unidades de desviación típica.
3. (c) $\widehat{z}_y = 0{,}5 \cdot 2 = 1$.

Resultado. $\widehat{z}_y = r\, z_x$**; con** $r = 0{,}5$**, un modelo a** $+2$ **desviaciones en la primera evaluación se predice a** $+1$ **en la segunda.** ■

Comprobación. si $|r| = 1$ no hay regresión a la media ($\widehat{z}_y = \pm z_x$); si $r = 0$, la mejor predicción es la media. Es una razón para desconfiar del modelo que encabeza una única evaluación ruidosa.

Apéndice B

Tablas estadísticas

Las tablas se han calculado numéricamente con cuatro decimales (tres en la tabla de la χ^2). Para $z < 0$ se usa la simetría $\Phi(-z) = 1 - \Phi(z)$; para la t de Student, $t_{k;1-q} = -t_{k;q}$.

B.1 Distribución normal estándar

Cuadro B.1: Función de distribución $\Phi(z) = \mathbb{P}(Z \leq z)$ de $Z \sim \mathcal{N}(0,1)$. La fila da las unidades y la primera cifra decimal de z; la columna, la segunda cifra decimal.

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998

Cuadro B.2: Cuantiles de la normal estándar más usados: $\Phi(z_q) = q$.

q	0,80	0,90	0,95	0,96	0,975	0,98	0,99	0,995
z_q	0,8416	1,2816	1,6449	1,7507	1,9600	2,0537	2,3263	2,5758

B.2 Distribución t de Student

B.3 Distribución χ^2

Cuadro B.3: Cuantiles $t_{k;q}$ de la distribución t con k grados de libertad: $\mathbb{P}(T_k \le t_{k;q}) = q$. La última fila ($k = \infty$) son los cuantiles de la normal estándar.

k	$q = 0{,}90$	0,95	0,975	0,99	0,995
1	3,078	6,314	12,706	31,821	63,657
2	1,886	2,920	4,303	6,965	9,925
3	1,638	2,353	3,182	4,541	5,841
4	1,533	2,132	2,776	3,747	4,604
5	1,476	2,015	2,571	3,365	4,032
6	1,440	1,943	2,447	3,143	3,707
7	1,415	1,895	2,365	2,998	3,499
8	1,397	1,860	2,306	2,896	3,355
9	1,383	1,833	2,262	2,821	3,250
10	1,372	1,812	2,228	2,764	3,169
11	1,363	1,796	2,201	2,718	3,106
12	1,356	1,782	2,179	2,681	3,055
13	1,350	1,771	2,160	2,650	3,012
14	1,345	1,761	2,145	2,624	2,977
15	1,341	1,753	2,131	2,602	2,947
16	1,337	1,746	2,120	2,583	2,921
17	1,333	1,740	2,110	2,567	2,898
18	1,330	1,734	2,101	2,552	2,878
19	1,328	1,729	2,093	2,539	2,861
20	1,325	1,725	2,086	2,528	2,845
21	1,323	1,721	2,080	2,518	2,831
22	1,321	1,717	2,074	2,508	2,819
23	1,319	1,714	2,069	2,500	2,807
24	1,318	1,711	2,064	2,492	2,797
25	1,316	1,708	2,060	2,485	2,787
26	1,315	1,706	2,056	2,479	2,779
27	1,314	1,703	2,052	2,473	2,771
28	1,313	1,701	2,048	2,467	2,763
29	1,311	1,699	2,045	2,462	2,756
30	1,310	1,697	2,042	2,457	2,750
40	1,303	1,684	2,021	2,423	2,704
60	1,296	1,671	2,000	2,390	2,660
120	1,289	1,658	1,980	2,358	2,617
∞	1,282	1,645	1,960	2,326	2,576

Cuadro B.4: Cuantiles $\chi^2_{k;q}$ de la distribución χ^2 con k grados de libertad: $\mathbb{P}(\chi^2_k \leq \chi^2_{k;q}) = q$.

k	$q = 0{,}005$	0,025	0,05	0,90	0,95	0,975	0,99	0,999
1	0,000	0,001	0,004	2,706	3,841	5,024	6,635	10,828
2	0,010	0,051	0,103	4,605	5,991	7,378	9,210	13,816
3	0,072	0,216	0,352	6,251	7,815	9,348	11,345	16,266
4	0,207	0,484	0,711	7,779	9,488	11,143	13,277	18,467
5	0,412	0,831	1,145	9,236	11,070	12,833	15,086	20,515
6	0,676	1,237	1,635	10,645	12,592	14,449	16,812	22,458
7	0,989	1,690	2,167	12,017	14,067	16,013	18,475	24,322
8	1,344	2,180	2,733	13,362	15,507	17,535	20,090	26,124
9	1,735	2,700	3,325	14,684	16,919	19,023	21,666	27,877
10	2,156	3,247	3,940	15,987	18,307	20,483	23,209	29,588
11	2,603	3,816	4,575	17,275	19,675	21,920	24,725	31,264
12	3,074	4,404	5,226	18,549	21,026	23,337	26,217	32,909
13	3,565	5,009	5,892	19,812	22,362	24,736	27,688	34,528
14	4,075	5,629	6,571	21,064	23,685	26,119	29,141	36,123
15	4,601	6,262	7,261	22,307	24,996	27,488	30,578	37,697
16	5,142	6,908	7,962	23,542	26,296	28,845	32,000	39,252
17	5,697	7,564	8,672	24,769	27,587	30,191	33,409	40,790
18	6,265	8,231	9,390	25,989	28,869	31,526	34,805	42,312
19	6,844	8,907	10,117	27,204	30,144	32,852	36,191	43,820
20	7,434	9,591	10,851	28,412	31,410	34,170	37,566	45,315
25	10,520	13,120	14,611	34,382	37,652	40,646	44,314	52,620
30	13,787	16,791	18,493	40,256	43,773	46,979	50,892	59,703

Bibliografía

[1] J. K. Blitzstein y J. Hwang. *Introduction to Probability*, 2.ª ed. CRC Press, 2019. Texto del curso Stat 110 de Harvard. Capítulos 4 «Expectation», 5 «Continuous Random Variables», 6 «Moments», 7 «Joint Distributions» y 10 «Inequalities and Limit Theorems».

[2] B. Illowsky y S. Dean. *Introductory Statistics*, 2.ª ed. OpenStax, Rice University, 2023. Libro de texto de acceso libre. Secciones 2.2–2.7, 7.1–7.2, 8.1–8.3, 9.1–9.5, 11.2 y 12.3–12.4. https://openstax.org/details/books/introductory-statistics-2e

[3] J. Orloff y J. Bloom. 18.05: Introduction to Probability and Statistics. Massachusetts Institute of Technology, MIT OpenCourseWare, primavera de 2022. Lecturas (*readings*) 5c, 6b, 7b, 10a, 10b, 17b, 18, 19, 20, 22, 23a, 23b y 26; *problem sets* 4, 5, 6, 8, 9, 10 y 11; problemas de la clase 23. https://ocw.mit.edu/courses/18-05-introduction-to-probability-and-statistics-spring-2022/

[4] J. A. Rice. *Mathematical Statistics and Data Analysis*, 3.ª ed. Duxbury (Thomson Brooks/Cole), 2007. Capítulos 8 «Estimation of Parameters and Fitting of Probability Distributions», 9 «Testing Hypotheses and Assessing Goodness of Fit», 10 «Summarizing Data» y 14 «Linear Least Squares».

[5] Z. Fan. Stats 200: Introduction to Statistical Inference. Stanford University, otoño de 2016 (edición archivada `stats200.1172`). Clases 5, 7, 11, 12, 13, 18 y 25; *homework* 3, 4 y 5. https://web.stanford.edu/class/archive/stats/stats200/stats200.1172/

[6] L. Wasserman. *All of Statistics: A Concise Course in Statistical Inference*. Springer, 2004. Capítulos 5 «Convergence of Random Variables», 6 «Models, Statistical Inference and Learning», 9 «Parametric Inference», 10 «Hypothesis Testing and p-values», 13 «Linear and Logistic Regression» y 16 «Causal Inference».