Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase I · Fundamentos matemáticos

Módulo 2

Álgebra lineal I

Vectores, matrices y embeddings

Apuntes del curso

Edición de octubre de 2026

Presentación del módulo

Un gran modelo de lenguaje no manipula palabras, sino vectores: cada token se representa por un elemento de $\mathbb{R}^d$, y casi todo el cálculo posterior consiste en productos escalares y productos de matrices. Este módulo desarrolla la parte del álgebra lineal que se necesita para entender esa representación: la geometría del producto escalar, las matrices como aplicaciones lineales y la composición de aplicaciones mediante el producto matricial. Todo ello se aplica después a la capa de embeddings, a las analogías entre palabras y, como adelanto, a la puntuación de la atención.

Objetivos

Al finalizar el módulo, el estudiante debe ser capaz de:

1. operar con vectores de $\mathbb{R}^d$ y enunciar las propiedades del producto escalar y de las normas;
2. demostrar la desigualdad de Cauchy–Schwarz y la desigualdad triangular, y usarlas para definir el ángulo entre vectores en cualquier dimensión;
3. calcular proyecciones sobre una recta y similitudes coseno, y relacionar la similitud coseno con la distancia euclídea;
4. interpretar una matriz como una aplicación lineal y demostrar que toda aplicación lineal entre espacios $\mathbb{R}^n$ es de esa forma;
5. calcular productos de matrices de varias maneras, justificar sus propiedades y estimar su coste;
6. describir la capa de embeddings como una matriz $K \times d$, resolver analogías con aritmética de vectores y explicar el escalado por $\sqrt{d}$ de la atención.

Requisitos previos

Trigonometría elemental (seno, coseno y teorema del coseno), resolución de sistemas 2×2 y manejo de sumatorios. Del módulo 1 se usan el vocabulario $\mathcal{V}$ y los índices de los tokens (tema 1), la matriz de transición de un modelo de bigramas (tema 2) y la función softmax (tema 4). En el tema 2 y en el ejercicio 5.7 se emplean la esperanza y la varianza de variables aleatorias y su comportamiento con la independencia, que se estudian con detalle en el módulo 5.

Organización

Tema	Contenido	Fuentes principales
1	Vectores, producto escalar y norma	[14], [5], [3]
2	Ángulos, ortogonalidad y similitud coseno	[14], [5], [1]
3	Matrices y aplicaciones lineales	[14], [16], [5]
4	El producto de matrices	[14], [16], [3]
5	Embeddings, analogías y atención	[8], [9], [17]

Cada tema termina con una lista de lecturas y con ejercicios graduados en tres niveles: $\star$ comprensión, $\star\star$ cálculo y $\star\star\star$ demostración. Los ejercicios marcados con *Fuente* están adaptados de cursos y libros de texto universitarios; el enunciado se ha redactado de nuevo y, en algunos casos, se han cambiado los datos para que puedan resolverse a mano. Las soluciones completas, paso a paso, están en el apéndice A.

Sobre las fuentes

El texto es de redacción propia. La secuencia de los temas 1 a 4 sigue los capítulos 1 y 2 del libro de Strang [14], texto de los cursos 18.06 y 18.06SC del MIT [15, 16], y los capítulos 2 y 3 de Deisenroth, Faisal y Ong [5], de donde se toman las definiciones abstractas de norma, producto interior y aplicación lineal. El libro de Boyd y Vandenberghe [3], texto del curso EE103 de Stanford, aporta el punto de vista computacional (coste de las operaciones, vectores de recuento de palabras). La geometría en alta dimensión sigue el capítulo 2 de Blum, Hopcroft y Kannan [1]. El tema 5 se basa en el capítulo 5 de Jurafsky y Martin [8], en la clase 2 del curso CS224N [18] y en los artículos originales citados en él. Sobre los modelos comerciales (Claude, Gemini, Grok) solo se usa información pública.

Notación

Símbolo	Significado
$u = (u_1, \ldots, u_d) \in \mathbb{R}^d$	vector columna de d componentes
$e_1, \ldots, e_d$	vectores de la base canónica (o vectores *one-hot*)
$u \cdot v = u^\top v$	producto escalar
$\|u\|$, $\|u\|_1$, $\|u\|_\infty$	normas euclídea, ℓ_1 y del máximo
$\hat{u} = u/\|u\|$	vector normalizado ($u \neq 0$)
$\cos(u, v)$	similitud coseno
$A \in \mathbb{R}^{m \times n}$, A_{ij}	matriz de m filas y n columnas y su entrada (i, j)
$A^\top$, I_n	traspuesta e identidad de orden n
$\mathcal{V}$, $K = \|\mathcal{V}\|$, $E \in \mathbb{R}^{K \times d}$	vocabulario, su tamaño y matriz de embeddings
q, k, d_k	consulta, clave y su dimensión (atención)

Los vectores se escriben con letras minúsculas y se consideran columnas; cuando se escriben en línea, $(u_1, \ldots, u_d)$ denota la columna correspondiente. Los índices de los tokens empiezan en 0, como en el módulo 1; los de las componentes de un vector, en 1.

Índice

Presentación del módulo **ii**

1 Vectores, producto escalar y norma **1**

1.1 El espacio $\mathbb{R}^d$ . . . 1

1.2 El producto escalar . . . 2

1.3 Normas . . . 3

Ejercicios del tema 1 . . . 4

2 Ángulos, ortogonalidad y similitud coseno **5**

2.1 El ángulo entre dos vectores . . . 5

2.2 Proyección sobre una recta . . . 6

2.3 Similitud coseno . . . 7

2.4 Geometría en alta dimensión . . . 7

Ejercicios del tema 2 . . . 8

3 Matrices y aplicaciones lineales **10**

3.1 Matrices . . . 10

3.2 El producto de una matriz por un vector . . . 10

3.3 Aplicaciones lineales . . . 11

Ejercicios del tema 3 . . . 13

4 El producto de matrices **14**

4.1 Definición y composición . . . 14

4.2 Cuatro formas de calcular un producto . . . 15

4.3 Propiedades algebraicas . . . 15

4.4 Coste y matriz de Gram . . . 16

Ejercicios del tema 4 . . . 17

5 Embeddings, analogías y atención **18**

5.1 La matriz de embeddings . . . 18

5.2 De dónde salen los embeddings . . . 19

5.3 La capa de salida y el atado de pesos . . . 19

5.4 Analogías y aritmética de vectores . . . 19

5.5 Adelanto: el producto escalar en la atención . . . 20

Ejercicios del tema 5 . . . 21

A Soluciones de los ejercicios **22**

A.1 Tema 1 22

A.2 Tema 2 24

A.3 Tema 3 27

A.4 Tema 4 29

A.5 Tema 5 32

Bibliografía **36**

Tema 1

Vectores, producto escalar y norma

Este tema introduce el espacio $\mathbb{R}^d$, sus dos operaciones básicas y las dos herramientas métricas sobre las que descansa todo el módulo: el producto escalar y la norma. La presentación sigue las secciones 1.1 y 1.2 de Strang [14] y la clase 1 del curso 18.06SC [16]; las definiciones abstractas de espacio vectorial, norma y producto interior proceden de [5, §2.4, §3.1 y §3.2], y el punto de vista computacional, de [3, cap. 1 y §3.1].

1.1 El espacio $\mathbb{R}^d$

Definición 1.1 (Vector). Sea $d \geq 1$ un entero. Un *vector* de $\mathbb{R}^d$ es una lista ordenada $u = (u_1, \ldots, u_d)$ de d números reales, llamados *componentes* de u. Dos vectores son iguales si lo son todas sus componentes. El *vector nulo* es $0 = (0, \ldots, 0)$.

Un vector de $\mathbb{R}^2$ o de $\mathbb{R}^3$ admite dos lecturas geométricas equivalentes: un punto del plano o del espacio, o una flecha que parte del origen y termina en ese punto. Para $d > 3$ no hay dibujo posible, pero todas las definiciones de este módulo se formulan componente a componente y valen igual en cualquier dimensión.

Definición 1.2 (Suma y producto por un escalar). Para $u, v \in \mathbb{R}^d$ y $c \in \mathbb{R}$ se definen

$$u + v = (u_1 + v_1, \ldots, u_d + v_d), \qquad c\,u = (c\,u_1, \ldots, c\,u_d).$$

Geométricamente, $u+v$ se obtiene colocando la flecha v a continuación de la flecha u (regla del paralelogramo), y $c\,u$ estira la flecha si $c > 1$, la encoge si $0 < c < 1$ y la invierte si $c < 0$. La diferencia $u - v = u + (-1)v$ es la flecha que va del extremo de v al extremo de u.

Proposición 1.3. *Con la suma y el producto por un escalar, $\mathbb{R}^d$ satisface, para todos $u, v, w \in \mathbb{R}^d$ y $a, b \in \mathbb{R}$:*

(i) $u + v = v + u$ *y* $(u + v) + w = u + (v + w)$;

(ii) $u + 0 = u$ *y* $u + (-u) = 0$;

(iii) $a(u + v) = au + av$, $(a + b)u = au + bu$ *y* $(ab)u = a(bu)$;

(iv) $1\,u = u$.

Demostración. Cada igualdad se reduce, componente a componente, a la propiedad correspondiente de los números reales. Por ejemplo, la componente i de $a(u+v)$ es $a(u_i+v_i) = au_i+av_i$, que es la componente i de $au + av$. ∎

Un conjunto dotado de una suma y de un producto por escalares reales que cumplen las propiedades de la proposición 1.3 se llama *espacio vectorial real* [5, §2.4]. Además de $\mathbb{R}^d$, son

espacios vectoriales el conjunto $\mathbb{R}^{m\times n}$ de matrices (tema 3) y el de polinomios de grado a lo sumo n. Este módulo trabaja casi siempre en $\mathbb{R}^d$.

Definición 1.4 (Combinación lineal). Sean $v_1,\dots,v_k \in \mathbb{R}^d$ y $c_1,\dots,c_k \in \mathbb{R}$. El vector $c_1v_1+\cdots+c_kv_k$ es una *combinación lineal* de $v_1,\dots,v_k$ con coeficientes $c_1,\dots,c_k$.

Ejemplo 1.5. Sean $u=(1,2)$ y $v=(3,-1)$. Entonces $u+v=(4,1)$, $2u=(2,4)$ y $u-v=(-2,3)$. La combinación lineal $2u+v$ vale $(5,3)$.

Las combinaciones lineales son la operación central del álgebra lineal [14, §1.1]: el producto de una matriz por un vector (tema 3) es una combinación lineal de las columnas de la matriz, y la cuestión de qué vectores se obtienen como combinación de otros dados conduce a los conceptos de independencia, base y rango del módulo 3.

Observación 1.6 (Vectores en los modelos de lenguaje). Un modelo de lenguaje asigna a cada token un vector de $\mathbb{R}^d$, su *embedding* (tema 5). En el modelo más pequeño de GPT-2 es $d=768$ [13], y en GPT-3, con 175 000 millones de parámetros, $d=12\,288$ [4, tabla 2.1]. Anthropic, Google y xAI no publican este valor para los modelos actuales de Claude, Gemini y Grok. Otro ejemplo clásico es el *vector de recuentos* de un documento: fijado un diccionario de n palabras, la componente i es el número de veces que aparece la palabra i [3, §1.1].

1.2 El producto escalar

Definición 1.7 (Producto escalar). El *producto escalar* (o producto interior euclídeo) de $u,v\in\mathbb{R}^d$ es el número real

$$u\cdot v=\sum_{i=1}^{d}u_iv_i.$$

Con la notación matricial del tema 3, $u\cdot v=u^{\top}v$.

Ejemplo 1.8. $(1,2,3)\cdot(4,5,6)=4+10+18=32$. Obsérvese que el resultado es un número, no un vector: el producto componente a componente $(4,10,18)$ es otra operación.

Proposición 1.9 (Propiedades del producto escalar). *Para todos $u,v,w\in\mathbb{R}^d$ y $a,b\in\mathbb{R}$:*

(i) (simetría) $u\cdot v=v\cdot u$;

(ii) (linealidad en cada argumento) $(au+bv)\cdot w=a\,(u\cdot w)+b\,(v\cdot w)$;

(iii) (positividad) $u\cdot u\geq 0$, con igualdad si y solo si $u=0$.

Demostración. (i) Se sigue de $u_iv_i=v_iu_i$. (ii) $\sum_i(au_i+bv_i)w_i=a\sum_i u_iw_i+b\sum_i v_iw_i$. Por la simetría, la linealidad vale también en el segundo argumento. (iii) $u\cdot u=\sum_i u_i^2$ es una suma de cuadrados, luego es ≥ 0, y se anula si y solo si cada $u_i=0$. ∎

Una aplicación $\langle\cdot,\cdot\rangle\colon V\times V\to\mathbb{R}$ sobre un espacio vectorial que cumple (i)–(iii) se llama *producto interior* [5, §3.2]. El producto escalar es el producto interior estándar de $\mathbb{R}^d$; todos los resultados de este tema, salvo los que usan componentes, valen para un producto interior cualquiera.

Observación 1.10 (Coste). Calcular $u\cdot v$ en $\mathbb{R}^d$ requiere d multiplicaciones y $d-1$ sumas, unas $2d$ operaciones en coma flotante [3, §1.5]. Un LLM calcula miles de millones de productos

escalares por cada token generado, y su organización en productos de matrices (tema 4) es lo que permite ejecutarlos eficientemente en una GPU.

1.3 Normas

Definición 1.11 (Norma euclídea). La *norma* (o longitud) euclídea de $u \in \mathbb{R}^d$ es

$$\|u\| = \sqrt{u \cdot u} = \sqrt{u_1^2 + \cdots + u_d^2}.$$

Un vector u es *unitario* si $\|u\| = 1$. Si $u \neq 0$, el vector $\hat{u} = u/\|u\|$ es unitario y tiene la misma dirección y sentido que u; se dice que $\hat{u}$ es el *normalizado* de u. La *distancia* entre u y v es $\|u - v\|$.

En $\mathbb{R}^2$ y $\mathbb{R}^3$ la norma es la longitud de la flecha, por el teorema de Pitágoras. Por ejemplo, $\|(3,4)\| = 5$, $\|(1,2,2)\| = 3$ y el normalizado de $(3,4)$ es $(0{,}6;\ 0{,}8)$.

Definición 1.12 (Norma). Una *norma* sobre un espacio vectorial V es una aplicación $\|\cdot\| \colon V \to \mathbb{R}$ que cumple, para todos $u, v \in V$ y $c \in \mathbb{R}$ [5, §3.1]:

(i) (definida positiva) $\|u\| \geq 0$, con igualdad si y solo si $u = 0$;

(ii) (homogeneidad) $\|c\,u\| = |c|\,\|u\|$;

(iii) (desigualdad triangular) $\|u + v\| \leq \|u\| + \|v\|$.

Ejemplo 1.13 (Otras normas de $\mathbb{R}^d$). Además de la euclídea, también llamada norma ℓ_2, se usan la norma ℓ_1, $\|u\|_1 = \sum_i |u_i|$, y la norma del máximo, $\|u\|_\infty = \max_i |u_i|$. Para $u = (3, -4)$: $\|u\|_1 = 7$, $\|u\| = 5$ y $\|u\|_\infty = 4$. El cuadrado de la norma euclídea de los parámetros es la penalización de la regularización L_2 del módulo 8.

Las propiedades (i) y (ii) de la definición 1.12 son inmediatas para la norma euclídea. La desigualdad triangular, en cambio, requiere un resultado previo que es probablemente la desigualdad más importante del álgebra lineal.

Teorema 1.14 (Desigualdad de Cauchy–Schwarz). *Para todos $u, v \in \mathbb{R}^d$,*

$$|u \cdot v| \leq \|u\|\,\|v\|,$$

y la igualdad se da si y solo si uno de los dos vectores es múltiplo del otro.

Demostración. Si $v = 0$, ambos miembros valen 0 y $v = 0 \cdot u$. Sea $v \neq 0$ y sea $t^* = (u \cdot v)/\|v\|^2$. Por la positividad y la linealidad del producto escalar (proposición 1.9),

$$0 \leq \|u - t^* v\|^2 = \|u\|^2 - 2t^*(u \cdot v) + (t^*)^2\|v\|^2 = \|u\|^2 - \frac{(u \cdot v)^2}{\|v\|^2}.$$

Multiplicando por $\|v\|^2 > 0$ se obtiene $(u \cdot v)^2 \leq \|u\|^2\|v\|^2$, y tomando raíces cuadradas, el enunciado. La igualdad se da si y solo si $\|u - t^* v\| = 0$, es decir, si $u = t^* v$. Recíprocamente, si $u = cv$, entonces $|u \cdot v| = |c|\|v\|^2 = \|u\|\|v\|$. ∎

La elección de t^* no es arbitraria: $t^* v$ es la proyección de u sobre la recta de v (proposición 2.5), y la demostración dice que el cuadrado de la distancia de u a esa recta es no negativo. El ejercicio 1.4 propone una demostración alternativa.

Corolario 1.15 (Desigualdad triangular). *Para todos $u, v \in \mathbb{R}^d$, $\|u+v\| \le \|u\| + \|v\|$. En consecuencia, la norma euclídea es una norma en el sentido de la definición 1.12.*

Demostración. Por la linealidad del producto escalar y el teorema 1.14,

$$\|u+v\|^2 = \|u\|^2 + 2\,u\cdot v + \|v\|^2 \le \|u\|^2 + 2\|u\|\|v\| + \|v\|^2 = \big(\|u\| + \|v\|\big)^2.$$

Ambos miembros son no negativos, luego se puede tomar la raíz cuadrada. Las propiedades (i) y (ii) son inmediatas: $\|cu\|^2 = \sum_i c^2 u_i^2 = c^2\|u\|^2$. ∎

Observación 1.16. La desigualdad triangular expresa que el camino directo es el más corto: la longitud del lado $u+v$ de un triángulo no supera la suma de las de los otros dos. Aplicada a $u - w = (u - v) + (v - w)$, da $\|u - w\| \le \|u - v\| + \|v - w\|$, que es la desigualdad triangular para distancias.

Lecturas recomendadas para este tema

- Strang [14], §1.1 (vectores y combinaciones lineales) y §1.2 (longitudes y productos escalares).
- MIT 18.06SC [16], unidad I, sesión «The Geometry of Linear Equations».
- Deisenroth, Faisal y Ong [5], §2.4 «Vector Spaces», §3.1 «Norms» y §3.2 «Inner Products».
- Boyd y Vandenberghe [3], cap. 1 «Vectors» y §3.1 «Norm».

Ejercicios del tema 1

Ejercicio 1.1 ⋆ Sean $u = (1, 2)$ y $v = (3, -1)$. Halle los coeficientes $a, b \in \mathbb{R}$ tales que $au + bv = (5, 3)$ e interprete geométricamente el resultado.

Ejercicio 1.2 ⋆ Sea $w \in \mathbb{R}^n$ el vector de recuentos de un documento respecto de un diccionario de n palabras que contiene todas las del documento, y sea $\mathbf{1} = (1, \dots, 1) \in \mathbb{R}^n$. (a) ¿Qué representa $\mathbf{1} \cdot w$? (b) ¿Qué significa que $w_{282} = 0$? (c) Se define el *vector histograma* h, cuya componente i es la fracción de las palabras del documento que son la palabra i. Exprese h en función de w. (d) Con el diccionario (el, gato, come, pez), en este orden, calcule w, $\mathbf{1} \cdot w$ y h para el documento «el gato come el pez».

Fuente: adaptado de Boyd y Vandenberghe [3], cap. 1, ejercicio 1.11; se añade el apartado (d).

Ejercicio 1.3 ⋆⋆ Sea $x = (3, -4, 12)$. Calcule $\|x\|_1$, $\|x\|$ y $\|x\|_\infty$, compruebe que $\|x\|_\infty \le \|x\| \le \|x\|_1$ y calcule el normalizado $\hat{x}$ respecto de la norma euclídea.

Ejercicio 1.4 ⋆⋆⋆ Demuestre la desigualdad de Cauchy–Schwarz con el siguiente argumento, distinto del de la demostración del teorema 1.14: para $v \neq 0$, la función $f(t) = \|u - tv\|^2$ es un polinomio de segundo grado en t que no toma valores negativos. Deduzca que $-1 \le u \cdot v/(\|u\|\|v\|) \le 1$ para $u, v \neq 0$.

Ejercicio 1.5 ⋆⋆⋆ (a) Demuestre la *ley del paralelogramo*: $\|u+v\|^2 + \|u-v\|^2 = 2\|u\|^2 + 2\|v\|^2$ para todos $u, v \in \mathbb{R}^d$. (b) Demuestre la *identidad de polarización*: $u \cdot v = \frac{1}{4}\big(\|u+v\|^2 - \|u-v\|^2\big)$. (c) Compruebe con $u = (1, 0)$ y $v = (0, 1)$ que la norma ℓ_1 no cumple la ley del paralelogramo, y deduzca que no procede de ningún producto interior.

Tema 2

Ángulos, ortogonalidad y similitud coseno

La desigualdad de Cauchy–Schwarz permite definir el ángulo entre dos vectores en cualquier dimensión. Este tema desarrolla esa geometría: ortogonalidad, proyección sobre una recta y similitud coseno, que es la medida con la que se comparan los embeddings. Se sigue la sección 1.2 de Strang [14] y las secciones 3.3, 3.4 y 3.8 de [5]; el comportamiento en alta dimensión procede del capítulo 2 de Blum, Hopcroft y Kannan [1].

2.1 El ángulo entre dos vectores

Definición 2.1 (Ángulo). Sean $u, v \in \mathbb{R}^d$ no nulos. El *ángulo* entre u y v es el único $\theta \in [0, \pi]$ tal que

$$\cos\theta = \frac{u \cdot v}{\|u\|\,\|v\|}.$$

La definición es correcta porque, por el teorema 1.14, el cociente está en $[-1, 1]$, y la función coseno es una biyección de $[0, \pi]$ en $[-1, 1]$. La proposición siguiente muestra que, en el plano, coincide con el ángulo de la geometría elemental.

Proposición 2.2. *Sean $u, v \in \mathbb{R}^2$ no nulos y sea φ el ángulo geométrico que forman las flechas u y v. Entonces $u \cdot v = \|u\|\|v\|\cos\varphi$.*

Demostración. Los vectores u, v y $u - v$ forman un triángulo cuyos lados miden $\|u\|$, $\|v\|$ y $\|u - v\|$, y el ángulo opuesto al lado $u - v$ es φ. El teorema del coseno da $\|u - v\|^2 = \|u\|^2 + \|v\|^2 - 2\|u\|\|v\|\cos\varphi$. Por otra parte, la linealidad del producto escalar da $\|u - v\|^2 = \|u\|^2 + \|v\|^2 - 2\,u \cdot v$. Igualando ambas expresiones se obtiene el enunciado. (Si u y v son paralelos, el triángulo degenera y la igualdad se comprueba directamente con $u = cv$.) ∎

El signo del producto escalar indica, por tanto, si dos vectores apuntan en direcciones parecidas u opuestas (cuadro 2.1). El ejercicio 2.6 explora hasta dónde pueden «llevarse mal» varios vectores del plano.

Cuadro 2.1: Signo del producto escalar y ángulo entre dos vectores no nulos.

Producto escalar	Ángulo	Interpretación
$u \cdot v > 0$	$0 \le \theta < \pi/2$	direcciones parecidas
$u \cdot v = 0$	$\theta = \pi/2$	direcciones perpendiculares
$u \cdot v < 0$	$\pi/2 < \theta \le \pi$	direcciones opuestas

Definición 2.3 (Ortogonalidad). Dos vectores $u, v \in \mathbb{R}^d$ son *ortogonales*, y se escribe $u \perp v$, si $u \cdot v = 0$.

El vector nulo es ortogonal a todos, y es el único vector ortogonal a sí mismo, por la positividad del producto escalar. Los vectores de la base canónica son ortogonales dos a dos: $e_i \cdot e_j = 0$ si $i \neq j$.

Teorema 2.4 (Pitágoras). *Si $u \perp v$, entonces $\|u+v\|^2 = \|u\|^2 + \|v\|^2$.*

Demostración. $\|u+v\|^2 = \|u\|^2 + 2\,u \cdot v + \|v\|^2$, y el término central es nulo. ∎

2.2 Proyección sobre una recta

Proposición 2.5 (Proyección ortogonal sobre una recta). *Sean $u, a \in \mathbb{R}^d$ con $a \neq 0$. Entre todos los vectores de la recta $\{ta : t \in \mathbb{R}\}$, el más próximo a u es*

$$p = \frac{u \cdot a}{a \cdot a}\, a,$$

y es el único punto de la recta tal que $u - p \perp a$. El número $(u \cdot a)/\|a\|$ se llama proyección escalar *de u sobre a; si $\|a\| = 1$, coincide con $u \cdot a$.*

Demostración. Sea $t^* = (u \cdot a)/(a \cdot a)$ y $p = t^* a$. Entonces $(u - p) \cdot a = u \cdot a - t^*\, a \cdot a = 0$. Recíprocamente, $(u - ta) \cdot a = 0$ obliga a $t = t^*$. Para cualquier t, el vector $u - ta = (u - p) + (t^* - t)a$ es suma de dos vectores ortogonales, y por el teorema 2.4

$$\|u - ta\|^2 = \|u - p\|^2 + (t^* - t)^2 \|a\|^2 \geq \|u - p\|^2,$$

con igualdad solo si $t = t^*$. ∎

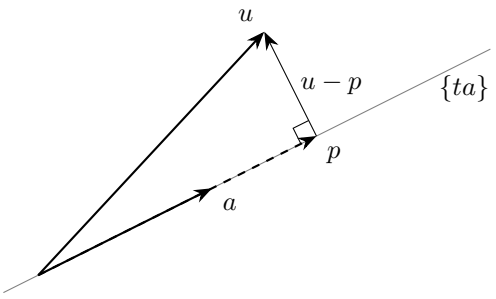


Figura 2.1: Proyección ortogonal de u sobre la recta generada por a (proposición 2.5). El error $u - p$ es perpendicular a a.

Ejemplo 2.6. Sean $u = (4, -1, 2)$ y $a = (1, 1, 1)$. Como $u \cdot a = 5$ y $a \cdot a = 3$, la proyección es $p = \frac{5}{3}(1, 1, 1)$, y el error $u - p = \frac{1}{3}(7, -8, 1)$ cumple $(u - p) \cdot a = \frac{1}{3}(7 - 8 + 1) = 0$.

La proyección sobre una recta es el caso más sencillo de la proyección sobre un subespacio, que conduce a los mínimos cuadrados [14, §4.2]; en el tema 4 se escribe como producto de matrices (ejercicio 4.6).

2.3 Similitud coseno

Definición 2.7 (Similitud coseno). La *similitud coseno* de dos vectores no nulos $u, v \in \mathbb{R}^d$ es

$$\cos(u, v) = \frac{u \cdot v}{\|u\| \, \|v\|} = \hat{u} \cdot \hat{v} \in [-1, 1].$$

Proposición 2.8. *Sean $u, v \in \mathbb{R}^d$ no nulos.*

(i) $\cos(au, bv) = \cos(u, v)$ *para todos* $a, b > 0$, *y* $\cos(u, -v) = -\cos(u, v)$.

(ii) $\cos(u, v) = 1$ *si y solo si* $u = cv$ *con* $c > 0$; $\cos(u, v) = -1$ *si y solo si* $u = cv$ *con* $c < 0$.

Demostración. (i) Numerador y denominador se multiplican por $ab = |ab|$; con $b = -1$, el numerador cambia de signo y el denominador no. (ii) Si $|\cos(u, v)| = 1$, se da la igualdad en el teorema 1.14, luego $u = cv$ con $c \neq 0$, y entonces $\cos(u, v) = c\|v\|^2/(|c|\|v\|^2)$ es el signo de c. El recíproco es inmediato. ∎

La similitud coseno mide, por tanto, solo la dirección: $\cos((1, 2), (2, 4)) = 1$ aunque los vectores tengan longitudes distintas.

Ejemplo 2.9 (Embeddings de juguete). Considérense vectores de $\mathbb{R}^4$ cuyas componentes se interpretan como (realeza, masculino, persona, comida):

Palabra	Vector	Norma	Palabra	Vector	Norma
rey	$(2, 1, 2, 0)$	3	hombre	$(0, 1, 2, 0)$	$\sqrt{5}$
reina	$(2, -1, 2, 0)$	3	mujer	$(0, -1, 2, 0)$	$\sqrt{5}$
manzana	$(0, 0, 0, 2)$	2			

Se obtiene $\cos(\text{rey}, \text{reina}) = 7/9 \approx 0{,}7778$ (ángulo de 38,94°), $\cos(\text{rey}, \text{hombre}) = 5/(3\sqrt{5}) \approx 0{,}7454$, $\cos(\text{rey}, \text{mujer}) = 3/(3\sqrt{5}) \approx 0{,}4472$ y $\cos(\text{rey}, \text{manzana}) = 0$. El vecino más próximo de «rey» es «reina»: comparten realeza y humanidad y solo discrepan en una componente. En un modelo real las componentes no tienen un significado asignado de antemano, pero la comparación se hace de la misma forma.

Proposición 2.10 (Coseno y distancia). *Si* $\|u\| = \|v\| = 1$, *entonces* $\|u - v\|^2 = 2 - 2\cos(u, v)$. *En consecuencia, entre vectores normalizados, ordenar los candidatos por distancia creciente a una consulta equivale a ordenarlos por similitud coseno decreciente.*

La demostración se propone en el ejercicio 2.7. Sin normalizar, ambas medidas pueden discrepar: un vector muy largo en la misma dirección que la consulta tiene coseno 1 pero puede estar lejos (ejercicio 2.4). Los buscadores vectoriales de los sistemas RAG (módulo 22) usan el coseno o el producto escalar sobre vectores normalizados.

2.4 Geometría en alta dimensión

En $\mathbb{R}^2$, dos direcciones elegidas al azar forman ángulos de cualquier tamaño. En dimensión alta el comportamiento es muy distinto: dos direcciones aleatorias son casi ortogonales [1, §2.4.2]. El resultado siguiente lo cuantifica.

Proposición 2.11. *Sea U un vector aleatorio de $\mathbb{R}^d$ con $\|U\| = 1$ cuya distribución no cambia al permutar sus componentes ni al cambiar el signo de cualquiera de ellas (por ejemplo, $U = G/\|G\|$ con $G_1, \dots, G_d$ normales estándar independientes). Para todo vector unitario fijo v,*

$$\mathbb{E}[U \cdot v] = 0, \qquad \mathbb{E}\big[(U \cdot v)^2\big] = \frac{1}{d}.$$

En particular, la similitud coseno entre U y v tiene media 0 y desviación típica $1/\sqrt{d}$.

Demostración. Cambiar el signo de la componente i no altera la distribución, luego $\mathbb{E}[U_i] = \mathbb{E}[-U_i]$ y $\mathbb{E}[U_i] = 0$. Del mismo modo, para $i \neq j$, $\mathbb{E}[U_i U_j] = \mathbb{E}[-U_i U_j] = 0$. Por la invariancia bajo permutaciones, $\mathbb{E}[U_i^2]$ es el mismo número c para todo i, y como $\sum_i U_i^2 = 1$, se tiene $dc = 1$. Entonces $\mathbb{E}[U \cdot v] = \sum_i v_i \mathbb{E}[U_i] = 0$ y

$$\mathbb{E}\big[(U \cdot v)^2\big] = \sum_{i=1}^{d} \sum_{j=1}^{d} v_i v_j \, \mathbb{E}[U_i U_j] = \sum_{i=1}^{d} v_i^2 \, \frac{1}{d} = \frac{1}{d}. \qquad \blacksquare$$

Si v también es aleatorio e independiente de U, el resultado se aplica condicionando al valor de v. Para $d = 768$, la desviación típica del coseno entre dos direcciones aleatorias es $1/\sqrt{768} \approx 0{,}0361$; para $d = 12\,288$, $\approx 0{,}0090$. Una simulación con 2000 pares de vectores gaussianos da 0,0363 y 0,0091, respectivamente. Por eso un coseno de 0,3 entre dos embeddings de dimensión 768, que equivale a más de ocho desviaciones típicas, es una señal fuerte de parecido.

Observación 2.12. Este fenómeno permite que un espacio de dimensión d contenga muchas más de d direcciones casi ortogonales entre sí. La hipótesis de *superposición* de la interpretabilidad (módulo 23) se apoya en esta propiedad: un modelo puede representar más conceptos que dimensiones tiene su espacio, asignando a cada uno una dirección casi ortogonal a las demás.

Lecturas recomendadas para este tema

- Strang [14], §1.2, problemas sobre productos escalares y ángulos.
- Deisenroth, Faisal y Ong [5], §3.3 «Lengths and Distances», §3.4 «Angles and Orthogonality» y §3.8 «Orthogonal Projections».
- Boyd y Vandenberghe [3], §3.2 «Distance» y §3.4 «Angle».
- Blum, Hopcroft y Kannan [1], §2.3 «The Geometry of High Dimensions» y §2.4.2 «Volume Near the Equator».

Ejercicios del tema 2

Ejercicio 2.1 ⋆ Calcule el producto escalar y la similitud coseno entre $(1, 2)$ y $(2, 4)$, y entre $(1, 2)$ y $(10, 20)$. ¿Qué indica la comparación sobre lo que mide cada cantidad?

Ejercicio 2.2 ⋆ Justifique si son verdaderas o falsas: (a) si $u \cdot v = 0$, uno de los dos vectores es nulo; (b) $\cos(u, u) = 1$ para todo $u \neq 0$; (c) si $\cos(u, v) = 1$, entonces $u = v$.

Ejercicio 2.3 ⋆⋆ Sean $u = (2, -1, 2)$ y $v = (1, 2, 2)$. Calcule $u \cdot v$, $\|u\|$, $\|v\|$, $\cos(u, v)$ y el ángulo entre ambos en grados.

Ejercicio 2.4 ⋆⋆ Sean $a = (1, 1)$, $b = (3, 3)$ y $c = (1, -1)$. Calcule $\|a - b\|$, $\|a - c\|$, $\cos(a, b)$ y $\cos(a, c)$. ¿Qué vecino de a elige cada medida? ¿Qué ocurre si antes se normalizan los tres vectores?

Ejercicio 2.5 ⋆⋆ Normalice $x = (3, 4)$. Con $p = \hat{x}$ y $r = (1, 0)$, compruebe numéricamente que $\|p - r\|^2 = 2 - 2\cos(p, r)$.

Ejercicio 2.6 ⋆⋆ (a) ¿Pueden tres vectores $u, v, w \in \mathbb{R}^2$ cumplir a la vez $u \cdot v < 0$, $v \cdot w < 0$ y $u \cdot w < 0$? Si es posible, dé un ejemplo con vectores unitarios y calcule el ángulo entre cada par. (b) ¿Pueden hacerlo cuatro vectores de $\mathbb{R}^2$, con los seis productos escalares negativos?

Fuente: adaptado de Strang [14], §1.2, problema 28, propuesto en el curso 18.06 del MIT [15], primavera de 2010, hoja de problemas 1.

Ejercicio 2.7 ⋆⋆⋆ Demuestre la proposición 2.10: si $\|u\| = \|v\| = 1$, entonces $\|u - v\|^2 = 2 - 2\cos(u, v)$. Deduzca que, si q, a, b son unitarios y $\cos(q, a) > \cos(q, b)$, entonces $\|q - a\| < \|q - b\|$. ¿Qué distancia corresponde a $\cos(u, v) = -1$?

Tema 3

Matrices y aplicaciones lineales

Una matriz es una tabla de números, pero su papel en el álgebra lineal es el de una función: transforma vectores en vectores respetando las combinaciones lineales. Este tema establece esa correspondencia entre matrices y aplicaciones lineales. Se sigue la sección 2.1 de Strang [14] y la sesión «The Geometry of Linear Equations» de 18.06SC [16]; las definiciones proceden de [5, §2.2 y §2.7] y de [3, cap. 6 y §8.1].

3.1 Matrices

Definición 3.1 (Matriz). Sean $m, n \geq 1$. Una *matriz* real de tamaño $m \times n$ es una tabla $A = (A_{ij})$ de mn números reales dispuestos en m filas y n columnas; A_{ij} es la entrada de la fila i y la columna j. El conjunto de estas matrices se denota $\mathbb{R}^{m\times n}$. Se escribe $a_j \in \mathbb{R}^m$ para la columna j y $A = [\, a_1 \ \cdots \ a_n \,]$.

Un vector de $\mathbb{R}^d$ se identifica con una matriz $d\times 1$ (vector columna). Las matrices del mismo tamaño se suman y se multiplican por escalares entrada a entrada, y con esas operaciones $\mathbb{R}^{m\times n}$ es un espacio vectorial.

Definición 3.2 (Traspuesta e identidad). La *traspuesta* de $A \in \mathbb{R}^{m\times n}$ es la matriz $A^\top \in \mathbb{R}^{n\times m}$ con $(A^\top)_{ij} = A_{ji}$: las filas de A son las columnas de $A^\top$. Una matriz cuadrada es *simétrica* si $A^\top = A$. La *identidad* $I_n \in \mathbb{R}^{n\times n}$ tiene unos en la diagonal y ceros fuera de ella; sus columnas son los vectores $e_1, \ldots, e_n$ de la base canónica.

Si $u \in \mathbb{R}^d$ es una columna, $u^\top$ es una matriz $1 \times d$ (vector fila). Esta notación permite escribir el producto escalar como $u \cdot v = u^\top v$.

3.2 El producto de una matriz por un vector

Definición 3.3 (Producto matriz-vector). Sean $A \in \mathbb{R}^{m\times n}$ y $x \in \mathbb{R}^n$. El producto $Ax \in \mathbb{R}^m$ es el vector de componentes

$$(Ax)_i = \sum_{j=1}^{n} A_{ij} x_j, \qquad i = 1, \ldots, m.$$

El producto solo está definido si el número de columnas de A coincide con el número de componentes de x.

Proposición 3.4 (Dos lecturas del producto). *Sea $A \in \mathbb{R}^{m\times n}$ con filas $r_1^\top, \ldots, r_m^\top$ y columnas $a_1, \ldots, a_n$. Para todo $x \in \mathbb{R}^n$:*

(i) (por filas) la componente i de Ax es el producto escalar $r_i \cdot x$;

(ii) (por columnas) $Ax = x_1a_1 + x_2a_2 + \cdots + x_na_n$ *es una combinación lineal de las columnas de* A*.*

Demostración. (i) La fila i de A es $(A_{i1}, \ldots, A_{in})$, y su producto escalar con x es $\sum_j A_{ij}x_j$. (ii) La componente i de $\sum_j x_j a_j$ es $\sum_j x_j A_{ij}$, que es la misma suma. ∎

Ejemplo 3.5. Sean $W = \begin{pmatrix} 1 & 0 & 2 \\ 0 & -1 & 1 \end{pmatrix}$ y $x = (3, 1, 2)$. Por filas, $(Wx)_1 = 3 + 0 + 4 = 7$ y $(Wx)_2 = 0 - 1 + 2 = 1$. Por columnas, $3(1, 0) + 1(0, -1) + 2(2, 1) = (7, 1)$. La matriz transforma un vector de $\mathbb{R}^3$ en uno de $\mathbb{R}^2$.

Las dos lecturas corresponden a las dos imágenes de un sistema de ecuaciones lineales $Ax = b$ que Strang llama imagen por filas e imagen por columnas [14, §2.1]: por filas, cada ecuación es un hiperplano y la solución es su intersección; por columnas, se buscan los coeficientes con los que las columnas de A se combinan para dar b.

3.3 Aplicaciones lineales

Definición 3.6 (Aplicación lineal). Una aplicación $T\colon \mathbb{R}^n \to \mathbb{R}^m$ es *lineal* si

$$T(au + bv) = a\,T(u) + b\,T(v) \qquad \text{para todos } u, v \in \mathbb{R}^n,\ a, b \in \mathbb{R}.$$

Tomando $a = b = 0$ se obtiene $T(0) = 0$: una aplicación lineal fija el origen. Por inducción, T transforma cualquier combinación lineal en la combinación lineal de las imágenes con los mismos coeficientes.

Proposición 3.7. *Para toda* $A \in \mathbb{R}^{m\times n}$*, la aplicación* $x \mapsto Ax$ *es lineal.*

Demostración. La componente i de $A(au+bv)$ es $\sum_j A_{ij}(au_j + bv_j) = a\sum_j A_{ij}u_j + b\sum_j A_{ij}v_j$, que es la componente i de $aAu + bAv$. ∎

El resultado recíproco es el que justifica la frase «una matriz es una aplicación lineal».

Teorema 3.8 (Matriz de una aplicación lineal). *Sea* $T\colon \mathbb{R}^n \to \mathbb{R}^m$ *lineal y sea* $A \in \mathbb{R}^{m\times n}$ *la matriz cuyas columnas son* $T(e_1), \ldots, T(e_n)$*. Entonces* $T(x) = Ax$ *para todo* $x \in \mathbb{R}^n$*, y* A *es la única matriz con esta propiedad.*

Demostración. Todo $x \in \mathbb{R}^n$ se escribe $x = x_1e_1 + \cdots + x_ne_n$. Por la linealidad de T y la proposición 3.4(ii),

$$T(x) = x_1T(e_1) + \cdots + x_nT(e_n) = x_1a_1 + \cdots + x_na_n = Ax.$$

Si B también cumple $T(x) = Bx$ para todo x, entonces la columna j de B es $Be_j = T(e_j) = a_j$, luego $B = A$. ∎

El teorema 3.8 da una receta práctica: para conocer una aplicación lineal basta saber adónde envía los vectores de la base canónica, y esas imágenes son las columnas de su matriz. El cuadro 3.1 recoge las transformaciones del plano más habituales, y la figura 3.1 muestra el efecto de una cizalla sobre el cuadrado unidad.

Cuadro 3.1: Transformaciones lineales del plano. Las columnas de cada matriz son las imágenes de e_1 y e_2.

Transformación	Matriz	$e_1 \mapsto$	$e_2 \mapsto$
Rotación de ángulo θ	$R_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$	$(\cos\theta, \sin\theta)$	$(-\sin\theta, \cos\theta)$
Rotación de 90°	$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$	$(0, 1)$	$(-1, 0)$
Escalado	$\begin{pmatrix} 2 & 0 \\ 0 & 0{,}5 \end{pmatrix}$	$(2, 0)$	$(0;\ 0{,}5)$
Cizalla	$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$	$(1, 0)$	$(1, 1)$
Simetría respecto de $y = x$	$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$	$(0, 1)$	$(1, 0)$
Proyección sobre el eje x	$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$	$(1, 0)$	$(0, 0)$

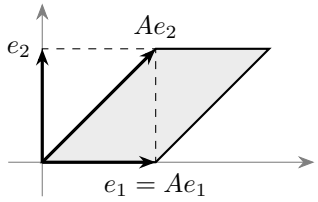


Figura 3.1: La cizalla $A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$ transforma el cuadrado unidad (discontinuo) en un paralelogramo. La imagen de e_1 no cambia y la de e_2 es la segunda columna de A.

Proposición 3.9 (Las rotaciones conservan la norma). *Para todo $\theta \in \mathbb{R}$ y todo $x \in \mathbb{R}^2$, $\|R_\theta x\| = \|x\|$.*

Demostración. Con $x = (x_1, x_2)$, $R_\theta x = (x_1\cos\theta - x_2\sin\theta,\ x_1\sin\theta + x_2\cos\theta)$. Desarrollando los cuadrados, los términos cruzados $\mp 2x_1x_2\sin\theta\cos\theta$ se cancelan y queda $\|R_\theta x\|^2 = (x_1^2 + x_2^2)(\cos^2\theta + \sin^2\theta) = \|x\|^2$. ∎

Las rotaciones conservan también los productos escalares y, por tanto, los ángulos (ejercicio 4.7). Los escalados no: con la matriz de escalado del cuadro 3.1, $e_1 + e_2$, de norma $\sqrt{2}$, pasa a $(2;\ 0{,}5)$, de norma $\sqrt{4{,}25}$.

Observación 3.10 (Matrices en los modelos de lenguaje). Casi todo el cálculo de un Transformer consiste en aplicar matrices aprendidas a vectores. En la atención (módulo 13), cada embedding $x \in \mathbb{R}^d$ se transforma en una *consulta* $q = W_Q x$, una *clave* $k = W_K x$ y un *valor* $v = W_V x$, con W_Q, W_K, W_V matrices $d_k \times d$. Estas matrices seleccionan qué rasgos del embedding intervienen en cada comparación.

Observación 3.11 (Matrices de transición). La matriz de transición P de un modelo de bigramas (módulo 1, tema 2) es estocástica por filas. Si $\pi_t \in \mathbb{R}^K$ es la distribución del token en la posición t, la de la posición siguiente es $\pi_{t+1} = P^\top \pi_t$, cuya componente j es $\sum_i P_{ij}(\pi_t)_i$. La matriz $P^\top$ tiene columnas que suman 1; es la convención que usa Strang para las *matrices de Markov* (ejercicio 3.5).

Lecturas recomendadas para este tema

- Strang [14], §2.1, imágenes por filas y por columnas de $Ax = b$.
- MIT 18.06SC [16], unidad I, sesión «The Geometry of Linear Equations».
- Deisenroth, Faisal y Ong [5], §2.2 «Matrices» y §2.7 «Linear Mappings».
- Boyd y Vandenberghe [3], §6.4 «Matrix-vector multiplication» y §8.1 «Linear and affine functions».

Ejercicios del tema 3

Ejercicio 3.1 ⋆ (a) Indique cuáles de las siguientes aplicaciones de $\mathbb{R}^2$ en $\mathbb{R}^2$ son lineales y, para las que lo sean, escriba su matriz: $f(x) = (x_1 + x_2,\, 3x_1)$, $g(x) = (x_1 + 1,\, x_2)$, $h(x) = (x_1 x_2,\, x_2)$. (b) Una matriz W es de tamaño 5×3. ¿De qué espacio a qué espacio transforma vectores?

Ejercicio 3.2 ⋆⋆ Sean $M = \begin{pmatrix} 1 & 0 & 2 \\ 2 & 1 & 0 \\ 0 & 3 & 1 \end{pmatrix}$ y $x = (2, -1, 3)$. Calcule Mx primero por filas y después como combinación lineal de las columnas. ¿Qué relación geométrica hay entre la tercera fila de M y x?

Fuente: adaptado de MIT 18.06SC [16], unidad I, sesión «The Geometry of Linear Equations», problema 1.2 (matriz y vector cambiados).

Ejercicio 3.3 ⋆⋆ Una aplicación lineal $T\colon \mathbb{R}^2 \to \mathbb{R}^2$ cumple $T(e_1) = (1, 2)$ y $T(e_2) = (-1, 1)$. Escriba su matriz y calcule $T(3, -2)$ de dos formas: con la matriz y con la linealidad.

Ejercicio 3.4 ⋆⋆ Escriba la matriz R_{60° y calcule $R_{60^\circ}(2, 0)$ y $R_{60^\circ}(1, 1)$. Compruebe que las normas se conservan.

Ejercicio 3.5 ⋆⋆ Sea $A = \begin{pmatrix} 0{,}8 & 0{,}3 \\ 0{,}2 & 0{,}7 \end{pmatrix}$, cuyas columnas suman 1, y sea $u_0 = (1, 0)$. (a) Calcule $u_1 = Au_0$, $u_2 = Au_1$ y $u_3 = Au_2$. ¿Qué propiedad comparten las componentes de todos ellos? (b) Compruebe que $s = (0{,}6;\, 0{,}4)$ cumple $As = s$. (c) Demuestre que, si las columnas de una matriz $A \in \mathbb{R}^{n \times n}$ suman 1, entonces $\mathbf{1}^\top (Au) = \mathbf{1}^\top u$ para todo $u \in \mathbb{R}^n$.

Fuente: adaptado de Strang [14], §2.1, problemas 29 y 30, propuestos en el curso 18.06 del MIT [15], primavera de 2010, hoja de problemas 1; se añade el apartado (c).

Ejercicio 3.6 ⋆⋆⋆ Sea $T\colon \mathbb{R}^n \to \mathbb{R}^m$ lineal. (a) Demuestre que T transforma la recta $\{p + td : t \in \mathbb{R}\}$ en una recta o en un punto, y caracterice cuándo ocurre lo segundo. (b) Demuestre que T conserva los puntos medios: $T\big(\tfrac{1}{2}(u + v)\big) = \tfrac{1}{2}\big(T(u) + T(v)\big)$. (c) Sea $b \neq 0$. Demuestre que la traslación $x \mapsto x + b$ cumple (a) y (b) pero no es lineal.

Tema 4

El producto de matrices

El producto de matrices se define de modo que represente la composición de aplicaciones lineales. De esa definición se siguen sus propiedades (asociativa, distributivas, comportamiento con la traspuesta) y su principal diferencia con el producto de números: no es conmutativo. El tema sigue la sección 2.4 de Strang [14] y la sesión «Multiplication and Inverse Matrices» de 18.06SC [16]; la composición y el coste computacional se tratan como en [3, §10.1 y §10.2].

4.1 Definición y composición

Definición 4.1 (Producto de matrices). Sean $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$. El producto $AB \in \mathbb{R}^{m\times p}$ es la matriz de entradas

$$(AB)_{ij} = \sum_{k=1}^{n} A_{ik}B_{kj}, \qquad 1 \le i \le m,\ 1 \le j \le p.$$

La entrada (i, j) es el producto escalar de la fila i de A por la columna j de B. El producto solo está definido si el número de columnas de A coincide con el número de filas de B: $(m \times n)(n \times p) = m \times p$.

Teorema 4.2 (El producto es la composición). *Sean $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$. Para todo $x \in \mathbb{R}^p$, $(AB)x = A(Bx)$. Es decir, la matriz de la aplicación «aplicar primero B y después A» es AB.*

Demostración. La componente i de $A(Bx)$ es

$$\sum_{k=1}^{n} A_{ik}(Bx)_k = \sum_{k=1}^{n} A_{ik}\sum_{j=1}^{p} B_{kj}x_j = \sum_{j=1}^{p}\Big(\sum_{k=1}^{n} A_{ik}B_{kj}\Big)x_j = \sum_{j=1}^{p}(AB)_{ij}x_j,$$

que es la componente i de $(AB)x$. Se ha usado solo que las sumas finitas pueden reordenarse. ∎

El orden de escritura es el de la composición de funciones, $(A \circ B)(x) = A(B(x))$: en AB actúa primero la matriz de la derecha.

Ejemplo 4.3. Sean $A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ y $B = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$. Entonces

$$AB = \begin{pmatrix} 2 & 1 \\ 4 & 3 \end{pmatrix}, \qquad BA = \begin{pmatrix} 3 & 4 \\ 1 & 2 \end{pmatrix}.$$

Multiplicar por B a la derecha intercambia las columnas de A; multiplicar por B a la izquierda intercambia sus filas.

4.2 Cuatro formas de calcular un producto

La definición 4.1 calcula el producto entrada a entrada. Strang subraya otras tres formas equivalentes [14, §2.4], cada una útil en contextos distintos.

Proposición 4.4. *Sean $A \in \mathbb{R}^{m\times n}$ con columnas $a_1,\dots,a_n$ y filas $r_1^\top,\dots,r_m^\top$, y $B \in \mathbb{R}^{n\times p}$ con columnas $b_1,\dots,b_p$ y filas $s_1^\top,\dots,s_n^\top$. Entonces:*

(i) (por columnas) la columna j de AB es Ab_j;

(ii) (por filas) la fila i de AB es $r_i^\top B$;

(iii) (columnas por filas) $AB = \sum_{k=1}^{n} a_k\, s_k^\top$, suma de n matrices $m\times p$.

Demostración. (i) La componente i de Ab_j es $\sum_k A_{ik}B_{kj} = (AB)_{ij}$. (ii) La componente j de $r_i^\top B$ es $\sum_k A_{ik}B_{kj}$. (iii) La entrada (i,j) de la matriz $a_k s_k^\top$ es $A_{ik}B_{kj}$; sumando en k se obtiene $(AB)_{ij}$. ∎

Una matriz de la forma $a\,s^\top$, con $a\in\mathbb{R}^m$ y $s\in\mathbb{R}^p$, se llama *producto exterior*; todas sus filas son múltiplos de $s^\top$. La forma (iii) descompone un producto de matrices en suma de productos exteriores y es la base de la descomposición en valores singulares y de las aproximaciones de bajo rango del módulo 3. En el ejemplo 4.3, $a_1 s_1^\top + a_2 s_2^\top = \begin{pmatrix}0&1\\0&3\end{pmatrix} + \begin{pmatrix}2&0\\4&0\end{pmatrix} = AB$.

4.3 Propiedades algebraicas

Proposición 4.5. *Siempre que los tamaños permitan formar los productos:*

(i) (asociativa) $(AB)C = A(BC)$;

(ii) (distributivas) $A(B+C) = AB + AC$ y $(B+C)A = BA + CA$;

(iii) (identidad) $I_m A = A = A I_n$ si $A\in\mathbb{R}^{m\times n}$;

(iv) (traspuesta) $(AB)^\top = B^\top A^\top$.

Demostración. (i) Por el teorema 4.2, para todo x, $((AB)C)x = (AB)(Cx) = A(B(Cx))$ y $(A(BC))x = A((BC)x) = A(B(Cx))$. Dos matrices que actúan igual sobre todo vector son iguales (basta tomar $x = e_j$ para ver que tienen las mismas columnas). (ii) $\sum_k A_{ik}(B_{kj}+C_{kj}) = \sum_k A_{ik}B_{kj} + \sum_k A_{ik}C_{kj}$, y análogamente por la derecha. (iii) Solo $k=i$ contribuye en $\sum_k (I_m)_{ik}A_{kj}$. (iv) $((AB)^\top)_{ij} = (AB)_{ji} = \sum_k A_{jk}B_{ki} = \sum_k (B^\top)_{ik}(A^\top)_{kj} = (B^\top A^\top)_{ij}$. ∎

La distributiva por la izquierda y la distributiva por la derecha son propiedades distintas: no puede pasarse de una a otra cambiando el lado (ejercicio 4.4), porque el producto no es conmutativo.

Observación 4.6 (No conmutatividad). En general $AB \neq BA$, incluso si ambos productos están definidos y son del mismo tamaño. Sean $R = \begin{pmatrix}0&-1\\1&0\end{pmatrix}$ (rotación de 90°), $S = \begin{pmatrix}2&0\\0&0{,}5\end{pmatrix}$ (escalado) y $x = (3,1)$. Escalar y después rotar da $R(Sx) = R(6;\,0{,}5) = (-0{,}5;\,6)$; rotar y después escalar da $S(Rx) = S(-1,3) = (-2;\,1{,}5)$. El orden de las transformaciones importa.

Definición 4.7 (Matriz ortogonal). Una matriz $Q\in\mathbb{R}^{n\times n}$ es *ortogonal* si $Q^\top Q = I_n$, es decir, si sus columnas son unitarias y ortogonales dos a dos.

Proposición 4.8. *Si Q es ortogonal, entonces $(Qu)\cdot(Qv) = u\cdot v$ para todos $u, v \in \mathbb{R}^n$. En consecuencia, Q conserva normas, distancias y ángulos.*

Demostración. Por la proposición 4.5(iv), $(Qu)^\top(Qv) = u^\top Q^\top Q v = u^\top I_n v = u^\top v$. Las normas, las distancias y los ángulos se expresan mediante productos escalares. ■

Las rotaciones R_θ son ortogonales (ejercicio 4.7), lo que generaliza la proposición 3.9. Las codificaciones posicionales rotatorias (RoPE) del módulo 14 aplican precisamente rotaciones de este tipo a las consultas y las claves.

4.4 Coste y matriz de Gram

Proposición 4.9 (Coste del producto). *Calcular AB con $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$ mediante la definición 4.1 requiere mnp multiplicaciones y $mp(n-1)$ sumas.*

Demostración. Cada una de las mp entradas es un producto escalar en $\mathbb{R}^n$, que requiere n multiplicaciones y $n-1$ sumas. ■

Aunque $(AB)C = A(BC)$, el coste de los dos órdenes puede ser muy distinto (ejercicio 4.5). Elegir bien el orden de los paréntesis es una optimización habitual en el cálculo con tensores.

Definición 4.10 (Matriz de Gram). Sea $X \in \mathbb{R}^{n\times d}$ la matriz cuyas filas son los vectores $x_1^\top, \dots, x_n^\top$. Su *matriz de Gram* es $G = XX^\top \in \mathbb{R}^{n\times n}$, con $G_{ij} = x_i \cdot x_j$.

La matriz de Gram es simétrica, porque $G^\top = (XX^\top)^\top = XX^\top$, y su diagonal contiene las normas al cuadrado, $G_{ii} = \|x_i\|^2$. Un único producto de matrices calcula los n^2 productos escalares entre n vectores.

Ejemplo 4.11. Con los embeddings del ejemplo 2.9, sea X la matriz 3×4 de filas «rey», «reina» y «manzana». Entonces

$$XX^\top = \begin{pmatrix} 9 & 7 & 0 \\ 7 & 9 & 0 \\ 0 & 0 & 4 \end{pmatrix}.$$

La entrada $(1,2)$ es rey $\cdot$ reina $= 7$, y dividiendo por $\sqrt{G_{11}G_{22}} = 9$ se recupera la similitud coseno $7/9$.

Observación 4.12. En la atención, las consultas y las claves de los n tokens de una secuencia se apilan como filas de matrices $Q, K \in \mathbb{R}^{n\times d_k}$, y todas las puntuaciones se calculan con un único producto $QK^\top \in \mathbb{R}^{n\times n}$, que generaliza la matriz de Gram. Las GPU están diseñadas para ejecutar este tipo de productos con gran rapidez (módulo 17).

Lecturas recomendadas para este tema

- Strang [14], §2.4, reglas de las operaciones con matrices, y §2.7, traspuestas.
- MIT 18.06SC [16], unidad I, sesión «Multiplication and Inverse Matrices».
- Deisenroth, Faisal y Ong [5], §2.2 «Matrices» y §3.9 «Rotations».
- Boyd y Vandenberghe [3], §10.1 «Matrix-matrix multiplication» y §10.2 «Composition of linear functions».

Ejercicios del tema 4

Ejercicio 4.1 ⋆ (a) ¿Qué tamaño tiene el producto de una matriz 3×4 por otra 4×2? ¿Puede multiplicarse una matriz 2×3 por otra 2×3? (b) Para $u, v \in \mathbb{R}^3$, ¿qué tamaños tienen $u^\top v$ y $uv^\top$? (c) Justifique si es verdadero o falso que $AB = BA$ para todo par de matrices cuadradas del mismo orden.

Ejercicio 4.2 ⋆⋆ Con R y S de la observación 4.6, calcule RS y SR, aplíquelas a $x = (3, 1)$ y compruebe que se obtiene $R(Sx)$ y $S(Rx)$, respectivamente.

Ejercicio 4.3 ⋆⋆ Sean $A = \begin{pmatrix} 1 & 0 & 2 \\ 0 & 1 & -1 \end{pmatrix}$ y $B = \begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 3 & 0 \end{pmatrix}$. Calcule AB y BA e indique sus tamaños. ¿Puede calcularse AA?

Ejercicio 4.4 ⋆⋆ Sean $A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$, $B = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ y $C = \begin{pmatrix} 0 & 0 \\ 2 & 1 \end{pmatrix}$. Calcule $AB + AC$ y $A(B + C)$ y compárelas. Calcule también $BA + CA$. ¿Coincide con $A(B + C)$?

Fuente: adaptado de MIT 18.06SC [16], unidad I, sesión «Multiplication and Inverse Matrices», problema 3.1 (matrices cambiadas).

Ejercicio 4.5 ⋆⋆ Sean $A \in \mathbb{R}^{3\times 5}$, $B \in \mathbb{R}^{5\times 2}$ y $C \in \mathbb{R}^{2\times 4}$. (a) Con la proposición 4.9, calcule el número de multiplicaciones de $(AB)C$ y de $A(BC)$. (b) Para $u, v, w \in \mathbb{R}^N$, compare el coste de $(u^\top v)\, w^\top$ y de $u^\top (vw^\top)$, y evalúelo para $N = 4096$.

Fuente: adaptado de Strang [14], §2.4, problema 36, propuesto en el curso 18.06 del MIT [15], primavera de 2010, hoja de problemas 1 (dimensiones cambiadas).

Ejercicio 4.6 ⋆⋆ Sea $A \in \mathbb{R}^{3\times 2}$ la matriz formada por las dos primeras columnas de I_3, y sea $b = (4, -1, 2)$. (a) Como las columnas de A son unitarias y ortogonales, la matriz de proyección sobre el plano que generan es $P = AA^\top$. Calcule P y Pb. (b) Compruebe que $P^2 = P$ y que $(I - P)^2 = I - P$. ¿Sobre qué proyecta $I - P$? (c) Escriba la proyección sobre la recta de $a = (1, 1, 1)$ de la proposición 2.5 como $P_a\, b$ con $P_a = aa^\top/(a^\top a)$ y compruebe el resultado del ejemplo 2.6.

Fuente: adaptado de MIT 18.06SC [16], unidad II, sesión «Projections onto Subspaces», problemas 15.1 y 15.2 (dimensión y vector cambiados).

Ejercicio 4.7 ⋆⋆⋆ (a) Demuestre que $R_\theta^\top R_\theta = I_2$ para todo θ. (b) Demuestre que $R_\theta R_\varphi = R_{\theta+\varphi}$ y deduzca que dos rotaciones del plano siempre conmutan. (c) Demuestre que el producto de dos matrices ortogonales del mismo orden es ortogonal. (d) Contraste (b) con la observación 4.6: ¿qué propiedad de S impide que conmute con R?

Tema 5

Embeddings, analogías y atención

Este tema aplica las herramientas anteriores a la entrada y la salida de un modelo de lenguaje. La capa de embeddings es una matriz; leer el vector de un token es multiplicar por un vector *one-hot*; las relaciones semánticas aparecen, de forma aproximada, como direcciones del espacio; y la atención compara tokens mediante productos escalares. La presentación sigue el capítulo 5 de Jurafsky y Martin [8] y la clase 2 de CS224N [18], junto con los artículos de Mikolov y coautores [9, 10] y de Vaswani y coautores [17].

5.1 La matriz de embeddings

En este tema se usa la notación del módulo 1: $\mathcal{V}$ es el vocabulario, $K = |\mathcal{V}|$ su tamaño y los tokens se identifican con sus índices $0, 1, \ldots, K-1$. Las filas de las matrices indexadas por tokens se numeran también desde 0.

Definición 5.1 (Matriz de embeddings). Sea $d \geq 1$. Una *matriz de embeddings* es una matriz $E \in \mathbb{R}^{K \times d}$. El *embedding* del token i es la fila i de E, que se denota $E_{i,:} \in \mathbb{R}^d$ (escrita como columna cuando se opera con ella).

Definición 5.2 (Vector one-hot). El vector *one-hot* del token i es el vector $e_i \in \mathbb{R}^K$ que tiene un 1 en la posición i y ceros en el resto.

Proposición 5.3. *Para todo token i, $e_i^\top E = E_{i,:}^\top$; es decir, multiplicar el vector one-hot de un token por la matriz de embeddings selecciona su fila. Si $x_{1:n}$ es una secuencia de tokens y $O \in \mathbb{R}^{n \times K}$ es la matriz cuyas filas son $e_{x_1}^\top, \ldots, e_{x_n}^\top$, entonces $X = OE \in \mathbb{R}^{n \times d}$ es la matriz cuya fila t es el embedding de x_t.*

Demostración. La componente j de $e_i^\top E$ es $\sum_k (e_i)_k E_{kj}$. Todos los sumandos con $k \neq i$ se anulan y queda E_{ij}. La segunda afirmación se sigue de la proposición 4.4(ii): la fila t de OE es $e_{x_t}^\top E$. ∎

Ejemplo 5.4. Sean $K = 4$, $d = 3$ y

$$E = \begin{pmatrix} 0{,}1 & 0{,}2 & 0 \\ 1 & 0 & -1 \\ 0{,}5 & 0{,}5 & 0{,}5 \\ -0{,}2 & 0{,}3 & 0{,}1 \end{pmatrix}.$$

El token 2 tiene vector one-hot $e_2 = (0, 0, 1, 0)$ y $e_2^\top E = (0{,}5;\ 0{,}5;\ 0{,}5)$. La secuencia $(2, 0, 2)$ produce una matriz $X \in \mathbb{R}^{3 \times 3}$ cuyas filas primera y tercera coinciden: sin información de posición, el modelo no distingue las dos apariciones del token 2 (módulo 14).

Observación 5.5 (Indexar en lugar de multiplicar). El producto $e_i^\top E$ requiere Kd multiplicaciones, casi todas por cero; leer directamente la fila i solo copia d números. Las bibliotecas

de redes neuronales implementan la capa de embeddings como una indexación, aunque matemáticamente sea el producto de la proposición 5.3. En GPT-2, con $K = 50\,257$ [13, §2.3] y $d = 768$, la matriz E tiene $50\,257 \cdot 768 = 38\,597\,376$ parámetros, unos 154 MB en precisión de 32 bits.

5.2 De dónde salen los embeddings

Los embeddings no se diseñan a mano como en el ejemplo 2.9: se inicializan al azar y se ajustan por descenso de gradiente (módulos 4 y 7) para que el modelo prediga bien el token siguiente. La justificación de que este procedimiento produzca vectores con significado es la *hipótesis distribucional*: las palabras que aparecen en contextos parecidos tienden a tener significados parecidos [7]. Firth la resumió en la frase «you shall know a word by the company it keeps» [6]. Dos tokens que aparecen en contextos similares reciben gradientes similares y acaban con embeddings próximos en el sentido del coseno [8, cap. 5].

Antes de los Transformers, los embeddings se entrenaban por separado con modelos como word2vec [9], que aprende un vector por palabra prediciendo las palabras vecinas en una ventana. En un LLM, en cambio, la matriz E se aprende junto con el resto de los parámetros.

5.3 La capa de salida y el atado de pesos

Al final del modelo, el vector $h \in \mathbb{R}^d$ de la última posición se compara con un vector por cada token del vocabulario. Si $U \in \mathbb{R}^{K \times d}$ es la matriz de salida, los logits son

$$z = Uh \in \mathbb{R}^K, \qquad z_i = U_{i,:} \cdot h,$$

y la softmax del módulo 1 (tema 4) los convierte en una distribución sobre el token siguiente. Cada logit es, por tanto, un producto escalar entre h y un vector asociado al token.

Definición 5.6 (Atado de pesos). Se dice que un modelo *ata* los pesos de entrada y salida (*weight tying*) si usa $U = E$: la misma matriz sirve para leer los embeddings de entrada y para calcular los logits.

Press y Wolf [12] mostraron que esta elección mejora los modelos de lenguaje recurrentes, y el Transformer original la adopta [17, §3.4]. Ahorra Kd parámetros, que en GPT-2 son 38 597 376, y da a ambos usos una interpretación común: el logit del token i es alto cuando h apunta en la dirección del embedding de i.

5.4 Analogías y aritmética de vectores

Sea v_w el embedding de la palabra w. Si un rasgo como el género corresponde aproximadamente a una dirección del espacio, la diferencia $v_{\text{mujer}} - v_{\text{hombre}}$ debería parecerse a $v_{\text{reina}} - v_{\text{rey}}$. Mikolov, Yih y Zweig [10] observaron este fenómeno en embeddings aprendidos y propusieron resolver analogías con el método siguiente.

Definición 5.7 (Analogía por desplazamiento de vectores). Dada la pregunta «a es a b como ? es a c», se calcula $q = v_a - v_b + v_c$ y se responde con

$$\hat{w} = \operatorname*{arg\,max}_{w \in \mathcal{V} \setminus \{a,b,c\}} \cos(v_w, q).$$

Proposición 5.8. *Si $v_a - v_b = v_{w^*} - v_c$, entonces $q = v_{w^*}$ y $\cos(v_{w^*}, q) = 1$, de modo que w^* es una respuesta de máxima similitud.*

Demostración. $q = v_a - v_b + v_c = (v_{w^*} - v_c) + v_c = v_{w^*}$, y $\cos(u, u) = 1$ para $u \neq 0$; por el teorema 1.14, ningún candidato supera este valor. ∎

Ejemplo 5.9. Con los vectores del ejemplo 2.9, $v_{\text{rey}} - v_{\text{hombre}} + v_{\text{mujer}} = (2, 1, 2, 0) - (0, 1, 2, 0) + (0, -1, 2, 0) = (2, -1, 2, 0) = v_{\text{reina}}$. La resta elimina «masculino» y «persona»; la suma añade «femenino» y «persona»; la realeza se conserva.

Observación 5.10 (Limitaciones). Con embeddings reales, la igualdad de la proposición 5.8 solo se cumple de forma aproximada, y q suele quedar más cerca de v_a que de la respuesta esperada; la exclusión de a, b y c en la definición 5.7 es esencial para que el método «funcione». Nissim, van Noord y van der Goot [11] analizan cómo esta exclusión distorsiona las conclusiones que se extraen de las analogías. En el cuaderno de prácticas del módulo, con 40 palabras en 16 dimensiones y ruido, la consulta rey − hombre + mujer da «reina» con coseno 0,924, pero sin la exclusión «rey» queda segunda con 0,835. Además, los embeddings heredan los sesgos de los textos de entrenamiento: Bolukbasi y coautores [2] encontraron analogías que reproducen estereotipos de género. La idea de que los conceptos son direcciones reaparece en la interpretabilidad de los LLM (módulo 23).

5.5 Adelanto: el producto escalar en la atención

La atención (módulo 13) es un mecanismo de búsqueda por similitud. Cada token emite una consulta $q \in \mathbb{R}^{d_k}$, la compara por producto escalar con las claves $k_1, \ldots, k_n$ de los tokens anteriores y reparte su atención con una softmax:

$$s_j = \frac{q \cdot k_j}{\sqrt{d_k}}, \qquad \alpha = \operatorname{softmax}(s_1, \ldots, s_n).$$

Para todos los tokens a la vez, las puntuaciones forman la matriz $QK^\top/\sqrt{d_k}$ (definición 4.10).

Ejemplo 5.11. Sean $d_k = 2$, $q = (1, 0)$ y las claves $k_1 = (1, 1)$, $k_2 = (0, 2)$, $k_3 = (-1, 0)$. Los productos escalares son 1, 0 y −1; divididos por $\sqrt{2}$ dan (0,7071; 0; −0,7071), y la softmax da $\alpha \approx$ (0,5760; 0,2840; 0,1400). El token cuya clave está más alineada con la consulta recibe más atención.

El factor $1/\sqrt{d_k}$ tiene una justificación estadística [17, §3.2.1]: si las componentes de q y k son variables independientes de media 0 y varianza 1, entonces $\operatorname{Var}(q \cdot k) = d_k$ (ejercicio 5.7). Sin el factor, para d_k grande las puntuaciones tendrían valores muy dispares, la softmax quedaría casi concentrada en un solo token y los gradientes serían casi nulos. Dividir por $\sqrt{d_k}$ devuelve la varianza a 1.

Lecturas recomendadas para este tema

- Jurafsky y Martin [8], cap. 5 «Embeddings».
- CS224N [18], clase 2 «Word Vectors» y tarea 1.
- Zhang *et al.* [19], §15.7 «Word Similarity and Analogy».
- Mikolov, Yih y Zweig [10]; Vaswani *et al.* [17], §3.2.1 y §3.4.

Ejercicios del tema 5

Ejercicio 5.1 ⋆ GPT-2 tiene $K = 50\,257$ y, en su versión más pequeña, $d = 768$. ¿Qué tamaño tiene E? ¿Cuántos parámetros tiene y cuánto ocupa con 4 bytes por número? Repita el cálculo con $d = 1600$, la dimensión de la versión más grande.

Ejercicio 5.2 ⋆ Explique, a partir de la definición de producto de matrices, por qué $e_i^\top E$ es la fila i de E, y estime cuántas veces más operaciones requiere el producto que la lectura directa de la fila en GPT-2.

Ejercicio 5.3 ⋆ Se desea encontrar las palabras más similares a una consulta q en un vocabulario muy grande. (a) Explique por qué, si se normalizan una vez todas las filas de E para formar $\hat{E}$, los K cosenos se obtienen con un único producto matriz-vector. (b) Cuente las multiplicaciones necesarias con $K = 50\,257$ y $d = 768$. (c) ¿Cómo se procesa a la vez un lote de B consultas?

Fuente: adaptado de Zhang *et al.* [19], §15.7, ejercicio 2.

Ejercicio 5.4 ⋆⋆ Con los vectores del ejemplo 2.9: (a) calcule $\cos(\text{hombre}, \text{mujer})$; (b) compruebe que $v_{\text{rey}} - v_{\text{hombre}} + v_{\text{mujer}} = v_{\text{reina}}$. (c) Con $v_{\text{España}} = (1, 0, 1, 0)$, $v_{\text{Madrid}} = (0, 1, 1, 0)$, $v_{\text{Francia}} = (1, 0, 0, 1)$, $v_{\text{París}} = (0, 1, 0, 1)$ y $v_{\text{Lyon}} = (0;\ 0{,}5;\ 0;\ 1)$, calcule $q = v_{\text{Madrid}} - v_{\text{España}} + v_{\text{Francia}}$ y su coseno con París y con Lyon.

Ejercicio 5.5 ⋆⋆ Con la matriz E del ejemplo 5.4: (a) calcule $e_2^\top E$ columna a columna; (b) escriba la matriz O de la proposición 5.3 para la secuencia $(2, 0, 2)$ y calcule $X = OE$ indicando su tamaño.

Ejercicio 5.6 ⋆⋆ Un modelo con pesos atados usa la matriz E del ejemplo 5.4 como matriz de salida. El vector final es $h = (1, 0, -1)$. Calcule los logits $z = Eh$ y la distribución $\text{softmax}(z)$. ¿Qué token es el más probable y por qué, en términos de ángulos?

Ejercicio 5.7 ⋆⋆⋆ (a) Reproduzca los cálculos del ejemplo 5.11. (b) Sean $q, k \in \mathbb{R}^d$ vectores aleatorios cuyas $2d$ componentes son independientes, de media 0 y varianza 1. Demuestre que $\mathbb{E}[q \cdot k] = 0$ y $\text{Var}(q \cdot k) = d$. (c) Con $d = 64$, compare la softmax de las puntuaciones típicas $(8, 0, -8)$, del orden de una desviación típica, con la de $(1, 0, -1)$, que se obtiene al dividir por $\sqrt{64}$.

Apéndice A

Soluciones de los ejercicios

Cada solución se presenta en cinco partes: datos, planteamiento, desarrollo, resultado y comprobación. En los pasos intermedios se redondea a cuatro cifras significativas salvo que se indique otra cosa; los resultados exactos se dan como fracción o radical cuando existe.

A.1 Tema 1

Solución del ejercicio 1.1

Datos. $u = (1, 2)$, $v = (3, -1)$, objetivo $(5, 3)$.

Planteamiento. igualar componente a componente $au + bv = (a + 3b,\ 2a - b)$ con $(5, 3)$ y resolver el sistema.

Desarrollo.

1. Sistema: $a + 3b = 5$ y $2a - b = 3$.
2. De la segunda ecuación, $b = 2a - 3$. Sustituyendo en la primera: $a + 3(2a - 3) = 5$, es decir, $7a - 9 = 5$, luego $a = 2$.
3. $b = 2 \cdot 2 - 3 = 1$.

Resultado. $a = 2$**,** $b = 1$**:** $(5, 3) = 2u + v$**.** Geométricamente, $(5, 3)$ es la diagonal del paralelogramo de lados $2u$ y v.

Comprobación. $2(1, 2) + (3, -1) = (2 + 3,\ 4 - 1) = (5, 3)$, que coincide con el ejemplo 1.5.

Solución del ejercicio 1.2

Datos. $w \in \mathbb{R}^n$ vector de recuentos; diccionario (el, gato, come, pez); documento «el gato come el pez».

Planteamiento. interpretar cada producto escalar y cada componente según la definición de w.

Desarrollo.

(a) $\mathbf{1} \cdot w = \sum_i w_i$ suma los recuentos de todas las palabras del diccionario: es el **número total de palabras** del documento.

(b) $w_{282} = 0$ significa que la palabra 282 del diccionario **no aparece** en el documento.

(c) $h_i = w_i / (\mathbf{1} \cdot w)$, es decir, $h = \dfrac{1}{\mathbf{1} \cdot w}\, w$, definido si el documento tiene al menos una palabra.

(d) «el» aparece dos veces y las demás una: $w = (2, 1, 1, 1)$; $\mathbf{1} \cdot w = 2 + 1 + 1 + 1 = 5$; $h = \frac{1}{5}(2, 1, 1, 1) = (0{,}4;\ 0{,}2;\ 0{,}2;\ 0{,}2)$.

Resultado. **(a) número total de palabras; (b) la palabra 282 no aparece; (c)** $h = w/(\mathbf{1}\cdot w)$**; (d)** $w = (2,1,1,1)$**,** $\mathbf{1}\cdot w = 5$**,** $h = (0{,}4;\ 0{,}2;\ 0{,}2;\ 0{,}2)$**.**

Comprobación. $\mathbf{1}\cdot h = 0{,}4+0{,}2+0{,}2+0{,}2 = 1$: el histograma es una distribución de probabilidad sobre el diccionario.

Solución del ejercicio 1.3

Datos. $x = (3, -4, 12)$.

Planteamiento. aplicar las definiciones de $\|\cdot\|_1$, $\|\cdot\|$ y $\|\cdot\|_\infty$; después dividir por la norma euclídea.

Desarrollo.

1. $\|x\|_1 = |3| + |-4| + |12| = 3 + 4 + 12 = 19$.
2. $\|x\| = \sqrt{9 + 16 + 144} = \sqrt{169} = 13$.
3. $\|x\|_\infty = \max\{3, 4, 12\} = 12$.
4. Orden: $12 \le 13 \le 19$.
5. $\hat{x} = x/13 = (3/13,\ -4/13,\ 12/13) \approx (0{,}2308;\ -0{,}3077;\ 0{,}9231)$.

Resultado. $\|x\|_1 = 19$**,** $\|x\| = 13$**,** $\|x\|_\infty = 12$**;** $\hat{x} = \frac{1}{13}(3, -4, 12)$**.**

Comprobación. $\|\hat{x}\|^2 = (9 + 16 + 144)/169 = 1$.

Solución del ejercicio 1.4

Datos. $u, v \in \mathbb{R}^d$ con $v \neq 0$ (si $v = 0$ ambos miembros valen 0).

Planteamiento. un polinomio de segundo grado con coeficiente principal positivo que no toma valores negativos tiene discriminante ≤ 0.

Desarrollo.

1. $f(t) = \|u - tv\|^2 \ge 0$ para todo $t \in \mathbb{R}$, por ser una norma al cuadrado.
2. Por la linealidad y la simetría del producto escalar, $f(t) = (u - tv)\cdot(u - tv) = \|v\|^2 t^2 - 2(u\cdot v)\,t + \|u\|^2$.
3. Es un polinomio $\alpha t^2 + \beta t + \gamma$ con $\alpha = \|v\|^2 > 0$, $\beta = -2(u\cdot v)$ y $\gamma = \|u\|^2$. Si su discriminante fuera positivo, tendría dos raíces reales distintas y sería negativo entre ellas; como $f \ge 0$, debe ser $\beta^2 - 4\alpha\gamma \le 0$.
4. Sustituyendo: $4(u\cdot v)^2 - 4\|u\|^2\|v\|^2 \le 0$, es decir, $(u\cdot v)^2 \le \|u\|^2\|v\|^2$.
5. Tomando raíces cuadradas (ambos miembros son ≥ 0): $|u\cdot v| \le \|u\|\|v\|$.
6. Si $u, v \neq 0$, dividiendo por $\|u\|\|v\| > 0$: $|u\cdot v|/(\|u\|\|v\|) \le 1$.

Resultado. $|u\cdot v| \le \|u\|\|v\|$ **y, por tanto,** $-1 \le u\cdot v/(\|u\|\|v\|) \le 1$**.**

Comprobación. con $u = (1,2)$ y $v = (3,4)$: $|u\cdot v| = 11$ y $\|u\|\|v\| = \sqrt{5}\cdot 5 \approx 11{,}18$. La desigualdad se cumple con poco margen porque los vectores son casi paralelos.

Solución del ejercicio 1.5

Datos. $u, v \in \mathbb{R}^d$; en (c), $u = (1,0)$ y $v = (0,1)$.

Planteamiento. desarrollar $\|u \pm v\|^2$ con la linealidad del producto escalar, y evaluar ambos miembros con la norma ℓ_1.

Desarrollo.

1. $\|u+v\|^2 = \|u\|^2 + 2\,u\cdot v + \|v\|^2$ y $\|u-v\|^2 = \|u\|^2 - 2\,u\cdot v + \|v\|^2$.
2. (a) Sumando: $\|u+v\|^2 + \|u-v\|^2 = 2\|u\|^2 + 2\|v\|^2$.
3. (b) Restando: $\|u+v\|^2 - \|u-v\|^2 = 4\,u\cdot v$, de donde se obtiene la identidad de polarización.
4. (c) $u+v = (1,1)$ y $u-v = (1,-1)$, luego $\|u+v\|_1 = \|u-v\|_1 = 2$ y el primer miembro vale $2^2 + 2^2 = 8$.
5. El segundo miembro vale $2\|u\|_1^2 + 2\|v\|_1^2 = 2 + 2 = 4 \neq 8$.
6. Los pasos 1 y 2 solo usan la simetría y la linealidad, válidas para todo producto interior. Si la norma ℓ_1 fuera $\sqrt{\langle u, u\rangle}$ para algún producto interior, cumpliría la ley del paralelogramo, lo que contradice el paso 5.

Resultado. **Se cumplen la ley del paralelogramo y la identidad de polarización; la norma ℓ_1 no cumple la primera ($8 \neq 4$) y, por tanto, no procede de ningún producto interior.**

Comprobación. con la norma euclídea y los mismos vectores: $\|u+v\|^2 + \|u-v\|^2 = 2 + 2 = 4 = 2\cdot 1 + 2\cdot 1$; y la polarización da $\frac{1}{4}(2-2) = 0 = u\cdot v$.

A.2 Tema 2

Solución del ejercicio 2.1

Datos. $a = (1,2)$, $b = (2,4)$, $c = (10,20)$.

Planteamiento. $u\cdot v = \sum_i u_i v_i$ y $\cos(u,v) = u\cdot v/(\|u\|\|v\|)$.

Desarrollo.

1. $a\cdot b = 1\cdot 2 + 2\cdot 4 = 10$ y $a\cdot c = 1\cdot 10 + 2\cdot 20 = 50$.
2. $\|a\| = \sqrt{5}$, $\|b\| = \sqrt{20}$, $\|c\| = \sqrt{500}$.
3. $\cos(a,b) = 10/\sqrt{5\cdot 20} = 10/10 = 1$ y $\cos(a,c) = 50/\sqrt{5\cdot 500} = 50/50 = 1$.

Resultado. $a\cdot b = 10$, $a\cdot c = 50$**; ambos cosenos valen 1.** El producto escalar crece con la longitud de los vectores; la similitud coseno solo mide la dirección, que es la misma en los tres.

Comprobación. $c = 10a$, luego $a\cdot c = 10\,(a\cdot a) = 10\cdot 5 = 50$; y, por la proposición 2.8(ii), vectores múltiplos positivos tienen coseno 1.

Solución del ejercicio 2.2

Planteamiento. buscar un contraejemplo o aplicar la definición.

Desarrollo.

(a) **Falsa.** $(1,0)\cdot(0,1) = 0$ y ninguno es nulo: $u\cdot v = 0$ significa que son ortogonales.

(b) **Verdadera.** $\cos(u,u) = u\cdot u/(\|u\|\|u\|) = \|u\|^2/\|u\|^2 = 1$ si $u \neq 0$.

(c) **Falsa.** $\cos((1,2),(2,4)) = 1$ y los vectores son distintos. Por la proposición 2.8(ii), $\cos(u,v) = 1$ solo implica $u = cv$ con $c > 0$.

Resultado. **(a) falsa; (b) verdadera; (c) falsa.**

Comprobación. en (b), con $u = (3,4)$: $25/(5 \cdot 5) = 1$.

Solución del ejercicio 2.3

Datos. $u = (2,-1,2)$, $v = (1,2,2)$.

Planteamiento. producto escalar, normas, coseno y $\theta = \arccos(\cos(u,v))$ (definición 2.1).

Desarrollo.

1. $u \cdot v = 2 \cdot 1 + (-1) \cdot 2 + 2 \cdot 2 = 2 - 2 + 4 = 4$.
2. $\|u\| = \sqrt{4+1+4} = 3$ y $\|v\| = \sqrt{1+4+4} = 3$.
3. $\cos(u,v) = 4/(3 \cdot 3) = 4/9 \approx 0{,}4444$.
4. $\theta = \arccos(0{,}4444) \approx 63{,}61°$.

Resultado. $u \cdot v = 4$**;** $\|u\| = \|v\| = 3$**;** $\cos(u,v) = 4/9 \approx 0{,}4444$**;** $\theta \approx 63{,}6°$**.**

Comprobación. $\cos 60° = 0{,}5$ y $\cos 90° = 0$; un coseno de 0,44 corresponde a un ángulo entre ambos, más próximo a 60°.

Solución del ejercicio 2.4

Datos. $a = (1,1)$, $b = (3,3)$, $c = (1,-1)$.

Planteamiento. comparar la distancia $\|a - x\|$ con la similitud $\cos(a,x)$ para $x = b, c$.

Desarrollo.

1. $a - b = (-2,-2)$ y $\|a - b\| = \sqrt{8} \approx 2{,}828$.
2. $a - c = (0,2)$ y $\|a - c\| = 2$.
3. $a \cdot b = 6$, $\|a\| = \sqrt{2}$, $\|b\| = \sqrt{18}$; $\cos(a,b) = 6/\sqrt{36} = 1$.
4. $a \cdot c = 1 - 1 = 0$, luego $\cos(a,c) = 0$.
5. Normalizando: $\hat{a} = \hat{b} = (1/\sqrt{2}, 1/\sqrt{2})$ y $\hat{c} = (1/\sqrt{2}, -1/\sqrt{2})$. Entonces $\|\hat{a} - \hat{b}\| = 0$ y $\|\hat{a} - \hat{c}\| = \|(0,\sqrt{2})\| = \sqrt{2}$.

Resultado. $\|a - b\| \approx 2{,}828$**,** $\|a - c\| = 2$**,** $\cos(a,b) = 1$**,** $\cos(a,c) = 0$**.** La distancia elige c y el coseno elige b: b tiene la dirección de a, pero es tres veces más largo. Tras normalizar, ambas medidas eligen b.

Comprobación. la proposición 2.10 da $\|\hat{a} - \hat{c}\|^2 = 2 - 2 \cdot 0 = 2$, que coincide con $(\sqrt{2})^2$.

Solución del ejercicio 2.5

Datos. $x = (3,4)$; $r = (1,0)$.

Planteamiento. $\hat{x} = x/\|x\|$; después evaluar ambos miembros de la identidad.

Desarrollo.

1. $\|x\| = \sqrt{9+16} = 5$ y $p = \hat{x} = (0{,}6;\ 0{,}8)$.
2. $p - r = (-0{,}4;\ 0{,}8)$ y $\|p - r\|^2 = 0{,}16 + 0{,}64 = 0{,}80$.

3. Como $\|p\| = \|r\| = 1$, $\cos(p, r) = p \cdot r = 0{,}6$.
4. $2 - 2\cos(p, r) = 2 - 1{,}2 = 0{,}80$.

Resultado. $\hat{x} = (0{,}6;\ 0{,}8)$**, y ambos miembros valen** $0{,}80$**.**

Comprobación. $\|p\|^2 = 0{,}36 + 0{,}64 = 1$: p es unitario y la identidad es aplicable.

Solución del ejercicio 2.6

Datos. vectores de $\mathbb{R}^2$ con todos los productos escalares por pares negativos.

Planteamiento. producto escalar negativo equivale a ángulo mayor que $90°$ (cuadro 2.1); tres ángulos de $120°$ completan la vuelta.

Desarrollo.

1. Se toman $u = (1, 0)$, $v = (-1/2, \sqrt{3}/2)$ y $w = (-1/2, -\sqrt{3}/2)$, que son unitarios: $\|v\|^2 = \frac{1}{4} + \frac{3}{4} = 1$, y lo mismo w.
2. $u \cdot v = -\frac{1}{2}$; $u \cdot w = -\frac{1}{2}$; $v \cdot w = \frac{1}{4} - \frac{3}{4} = -\frac{1}{2}$.
3. Como son unitarios, $\cos\theta = -\frac{1}{2}$ en los tres pares, luego $\theta = 120°$.
4. (b) Supóngase que cuatro vectores no nulos tienen los seis productos negativos. Se ordenan por su ángulo polar y se llaman $g_1, \ldots, g_4$ los ángulos que separan cada vector del siguiente en sentido antihorario, de modo que $g_1 + g_2 + g_3 + g_4 = 360°$.
5. El ángulo entre dos vectores consecutivos es $\min(g_i, 360° - g_i) \le g_i$, y debe ser mayor que $90°$; luego $g_i > 90°$ para todo i y la suma supera $360°$, lo cual es imposible.

Resultado. **(a) Sí: tres vectores unitarios a** $120°$**, con los tres productos iguales a** $-1/2$**. (b) No: cuatro vectores del plano no pueden tener los seis productos negativos.**

Comprobación. $u + v + w = (1 - \frac{1}{2} - \frac{1}{2},\ 0 + \frac{\sqrt{3}}{2} - \frac{\sqrt{3}}{2}) = (0, 0)$: las tres flechas se equilibran, como tres fuerzas iguales a $120°$. En $\mathbb{R}^3$, en cambio, los cuatro vértices de un tetraedro regular centrado en el origen sí tienen los seis productos negativos.

Solución del ejercicio 2.7

Datos. $\|u\| = \|v\| = 1$.

Planteamiento. desarrollar la norma al cuadrado mediante el producto escalar.

Desarrollo.

1. $\|u - v\|^2 = (u - v) \cdot (u - v) = \|u\|^2 - 2\,u \cdot v + \|v\|^2$, por la linealidad y la simetría.
2. Con normas unitarias: $\|u - v\|^2 = 2 - 2\,u \cdot v$.
3. También $\cos(u, v) = u \cdot v / (1 \cdot 1) = u \cdot v$, luego $\|u - v\|^2 = 2 - 2\cos(u, v)$.
4. La función $c \mapsto 2 - 2c$ es estrictamente decreciente. Si $\cos(q, a) > \cos(q, b)$, entonces $\|q - a\|^2 < \|q - b\|^2$ y, tomando raíces, $\|q - a\| < \|q - b\|$.
5. Si $\cos(u, v) = -1$: $\|u - v\|^2 = 4$ y $\|u - v\| = 2$.

Resultado. $\|u - v\|^2 = 2 - 2\cos(u, v)$**; entre vectores unitarios, el más cercano por distancia es el de mayor coseno. Con** $\cos = -1$**, la distancia es 2 (puntos antipodales de la esfera unidad).**

Comprobación. el ejercicio 2.5 da $0{,}80 = 2 - 2 \cdot 0{,}6$; con $\cos = 1$ la distancia es 0, como debe ser para $u = v$.

A.3 Tema 3

Solución del ejercicio 3.1

Datos. $f(x) = (x_1 + x_2, 3x_1)$, $g(x) = (x_1 + 1, x_2)$, $h(x) = (x_1 x_2, x_2)$; $W \in \mathbb{R}^{5\times 3}$.

Planteamiento. una aplicación lineal cumple $T(0) = 0$ y $T(cx) = cT(x)$; si es lineal, su matriz tiene por columnas $T(e_1)$ y $T(e_2)$ (teorema 3.8).

Desarrollo.

1. f es de la forma Ax con $A = \begin{pmatrix} 1 & 1 \\ 3 & 0 \end{pmatrix}$: $Ax = (x_1 + x_2,\ 3x_1)$. Por la proposición 3.7, es lineal. Columnas: $f(e_1) = (1, 3)$ y $f(e_2) = (1, 0)$.
2. $g(0) = (1, 0) \neq 0$, luego g no es lineal.
3. $h(2, 2) = (4, 2)$ y $2h(1, 1) = 2(1, 1) = (2, 2)$; como difieren, h no es lineal.
4. (b) W actúa sobre vectores de $\mathbb{R}^3$ (tres columnas) y produce vectores de $\mathbb{R}^5$ (cinco filas).

Resultado. **Solo f es lineal, con matriz $\begin{pmatrix} 1 & 1 \\ 3 & 0 \end{pmatrix}$. W transforma $\mathbb{R}^3$ en $\mathbb{R}^5$.**

Comprobación. $f(1, 1) = (2, 3)$ y $A(1, 1) = (1 + 1,\ 3 + 0) = (2, 3)$.

Solución del ejercicio 3.2

Datos. $M = \begin{pmatrix} 1 & 0 & 2 \\ 2 & 1 & 0 \\ 0 & 3 & 1 \end{pmatrix}$, $x = (2, -1, 3)$.

Planteamiento. las dos lecturas de la proposición 3.4.

Desarrollo.

1. Fila 1: $1 \cdot 2 + 0 \cdot (-1) + 2 \cdot 3 = 8$.
2. Fila 2: $2 \cdot 2 + 1 \cdot (-1) + 0 \cdot 3 = 3$.
3. Fila 3: $0 \cdot 2 + 3 \cdot (-1) + 1 \cdot 3 = 0$.
4. Columnas: $2(1, 2, 0) + (-1)(0, 1, 3) + 3(2, 0, 1) = (2, 4, 0) + (0, -1, -3) + (6, 0, 3) = (8, 3, 0)$.

Resultado. $Mx = (8, 3, 0)$**.** La tercera fila de M es ortogonal a x, porque su producto escalar es 0.

Comprobación. las dos lecturas dan el mismo vector, como garantiza la proposición 3.4.

Solución del ejercicio 3.3

Datos. $T(e_1) = (1, 2)$, $T(e_2) = (-1, 1)$; $x = (3, -2)$.

Planteamiento. por el teorema 3.8, las columnas de la matriz son $T(e_1)$ y $T(e_2)$.

Desarrollo.

1. $A = \begin{pmatrix} 1 & -1 \\ 2 & 1 \end{pmatrix}$.
2. Con la matriz: $Ax = (1 \cdot 3 + (-1)(-2),\ 2 \cdot 3 + 1 \cdot (-2)) = (5, 4)$.
3. Con la linealidad: $T(3e_1 - 2e_2) = 3T(e_1) - 2T(e_2) = (3, 6) + (2, -2) = (5, 4)$.

Resultado. $A = \begin{pmatrix} 1 & -1 \\ 2 & 1 \end{pmatrix}$ **y** $T(3,-2) = (5,4)$**.**

Comprobación. $Ae_1 = (1,2)$ y $Ae_2 = (-1,1)$, que son los datos.

Solución del ejercicio 3.4

Datos. $\theta = 60°$, $\cos 60° = \frac{1}{2}$, $\sin 60° = \frac{\sqrt{3}}{2}$.

Planteamiento. sustituir en la matriz R_θ del cuadro 3.1 y multiplicar.

Desarrollo.

1. $R_{60°} = \begin{pmatrix} 1/2 & -\sqrt{3}/2 \\ \sqrt{3}/2 & 1/2 \end{pmatrix}$.
2. $R_{60°}(2,0) = (1,\sqrt{3})$, cuya norma es $\sqrt{1+3} = 2 = \|(2,0)\|$.
3. $R_{60°}(1,1) = \left(\frac{1-\sqrt{3}}{2}, \frac{\sqrt{3}+1}{2}\right) \approx (-0{,}3660;\ 1{,}366)$.
4. Norma al cuadrado: $\frac{1}{4}\left[(1-\sqrt{3})^2 + (1+\sqrt{3})^2\right] = \frac{1}{4}\left[(4-2\sqrt{3}) + (4+2\sqrt{3})\right] = 2$, luego la norma es $\sqrt{2} = \|(1,1)\|$.

Resultado. $R_{60°}(2,0) = (1,\sqrt{3})$ **y** $R_{60°}(1,1) \approx (-0{,}3660;\ 1{,}366)$**; las normas (2 y** $\sqrt{2}$**) se conservan.**

Comprobación. el vector $(1,\sqrt{3})$ forma con el eje x un ángulo de $\arctan\sqrt{3} = 60°$, como se esperaba.

Solución del ejercicio 3.5

Datos. $A = \begin{pmatrix} 0{,}8 & 0{,}3 \\ 0{,}2 & 0{,}7 \end{pmatrix}$, $u_0 = (1,0)$, $s = (0{,}6;\ 0{,}4)$.

Planteamiento. aplicar A repetidamente; para (c), intercambiar el orden de las sumas.

Desarrollo.

1. $u_1 = Au_0 = (0{,}8;\ 0{,}2)$, la primera columna de A.
2. $u_2 = Au_1 = (0{,}8{\cdot}0{,}8{+}0{,}3{\cdot}0{,}2;\ 0{,}2{\cdot}0{,}8{+}0{,}7{\cdot}0{,}2) = (0{,}64{+}0{,}06;\ 0{,}16{+}0{,}14) = (0{,}70;\ 0{,}30)$.
3. $u_3 = Au_2 = (0{,}8{\cdot}0{,}7{+}0{,}3{\cdot}0{,}3;\ 0{,}2{\cdot}0{,}7{+}0{,}7{\cdot}0{,}3) = (0{,}56{+}0{,}09;\ 0{,}14{+}0{,}21) = (0{,}65;\ 0{,}35)$.
4. Las componentes de $u_0, \dots, u_3$ son no negativas y suman 1.
5. (b) $As = (0{,}48 + 0{,}12;\ 0{,}12 + 0{,}28) = (0{,}6;\ 0{,}4) = s$.
6. (c) $\mathbf{1}^\top(Au) = \sum_i \sum_j A_{ij}u_j = \sum_j u_j\left(\sum_i A_{ij}\right) = \sum_j u_j \cdot 1 = \mathbf{1}^\top u$.

Resultado. $u_1 = (0{,}8;\ 0{,}2)$**,** $u_2 = (0{,}7;\ 0{,}3)$**,** $u_3 = (0{,}65;\ 0{,}35)$**, todos con suma 1;** $As = s$**; una matriz con columnas de suma 1 conserva la suma de las componentes.**

Comprobación. los u_k se acercan a s: la primera componente pasa de 1 a 0,8, 0,7 y 0,65, y la distancia a 0,6 se reduce a la mitad en cada paso (0,4; 0,2; 0,1; 0,05).

Solución del ejercicio 3.6

Datos. $T\colon \mathbb{R}^n \to \mathbb{R}^m$ lineal; $p, d \in \mathbb{R}^n$; $b \neq 0$.

Planteamiento. aplicar la definición 3.6 a combinaciones concretas.

Desarrollo.

1. (a) Por linealidad, $T(p+td) = T(p) + t\,T(d)$ para todo t. Si $T(d) \neq 0$, la imagen es la recta que pasa por $T(p)$ con dirección $T(d)$; si $T(d) = 0$, la imagen es el punto $T(p)$.
2. (b) Con $a = b = \frac{1}{2}$ en la definición 3.6: $T\big(\frac{1}{2}u + \frac{1}{2}v\big) = \frac{1}{2}T(u) + \frac{1}{2}T(v)$.
3. (c) Sea $S(x) = x + b$. La imagen de la recta es $\{(p+b)+td\}$, otra recta, y $S\big(\frac{1}{2}(u+v)\big) = \frac{1}{2}(u+v) + b = \frac{1}{2}\big((u+b)+(v+b)\big)$.
4. Sin embargo, $S(0) = b \neq 0$, mientras que toda aplicación lineal fija el origen. Luego S no es lineal.

Resultado. **Una aplicación lineal transforma rectas en rectas (o en un punto, si $T(d) = 0$) y conserva puntos medios; las traslaciones tienen ambas propiedades sin ser lineales.** Las aplicaciones de la forma $x \mapsto Ax + b$ se llaman *afines* [3, §8.1]; una capa de red neuronal con sesgo es afín (módulo 9).

Comprobación. la proyección sobre el eje x del cuadro 3.1 envía la recta vertical $\{(1,0)+t(0,1)\}$ al punto $(1,0)$, porque $T(0,1) = (0,0)$.

A.4 Tema 4

Solución del ejercicio 4.1

Datos. tamaños de las matrices y $u, v \in \mathbb{R}^3$.

Planteamiento. $(m \times n)(n \times p) = m \times p$, solo si coinciden las dimensiones interiores.

Desarrollo.

(a) $(3 \times 4)(4 \times 2) = 3 \times 2$. El producto $(2 \times 3)(2 \times 3)$ no está definido, porque $3 \neq 2$.

(b) $u^\top v$ es $(1\times3)(3\times1) = 1\times1$, un número (el producto escalar); $uv^\top$ es $(3\times1)(1\times3) = 3\times3$, un producto exterior.

(c) **Falso.** En el ejemplo 4.3, $AB \neq BA$.

Resultado. **(a)** 3×2**; no. (b)** 1×1 **y** 3×3**. (c) Falso.**

Comprobación. con $u = v = (1,1,1)$: $u^\top v = 3$, y $uv^\top$ es la matriz 3×3 de unos, cuya traza es también 3.

Solución del ejercicio 4.2

Datos. $R = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$, $S = \begin{pmatrix} 2 & 0 \\ 0 & 0{,}5 \end{pmatrix}$, $x = (3,1)$.

Planteamiento. entrada (i,j) del producto = fila i del primer factor por columna j del segundo.

Desarrollo.

1. RS: fila 1, $(0\cdot2+(-1)\cdot0;\ 0\cdot0+(-1)\cdot0{,}5) = (0;\ -0{,}5)$; fila 2, $(1\cdot2+0;\ 0+0) = (2;\ 0)$.
2. SR: fila 1, $(2\cdot0+0\cdot1;\ 2\cdot(-1)+0\cdot0) = (0;\ -2)$; fila 2, $(0\cdot0+0{,}5\cdot1;\ 0+0) = (0{,}5;\ 0)$.

$$RS = \begin{pmatrix} 0 & -0{,}5 \\ 2 & 0 \end{pmatrix}, \qquad SR = \begin{pmatrix} 0 & -2 \\ 0{,}5 & 0 \end{pmatrix}.$$

3. $RSx = (0\cdot3 - 0{,}5\cdot1;\ 2\cdot3+0) = (-0{,}5;\ 6)$. Por pasos: $Sx = (6;\ 0{,}5)$ y $R(6;\ 0{,}5) = (-0{,}5;\ 6)$.

4. $SRx = (0{\cdot}3 - 2{\cdot}1;\ 0{,}5{\cdot}3 + 0) = (-2;\ 1{,}5)$. Por pasos: $Rx = (-1, 3)$ y $S(-1, 3) = (-2;\ 1{,}5)$.

Resultado. $RS = \begin{pmatrix} 0 & -0{,}5 \\ 2 & 0 \end{pmatrix}$, $SR = \begin{pmatrix} 0 & -2 \\ 0{,}5 & 0 \end{pmatrix}$; $RSx = (-0{,}5;\ 6)$ **y** $SRx = (-2;\ 1{,}5)$**.** Los resultados coinciden con la aplicación sucesiva, como afirma el teorema 4.2.

Comprobación. R conserva normas: $\|Sx\|^2 = 36 + 0{,}25 = 36{,}25$ y $\|R(Sx)\|^2 = 0{,}25 + 36 = 36{,}25$.

Solución del ejercicio 4.3

Datos. $A \in \mathbb{R}^{2\times 3}$ y $B \in \mathbb{R}^{3\times 2}$ del enunciado.

Planteamiento. $(2 \times 3)(3 \times 2) = 2 \times 2$ y $(3 \times 2)(2 \times 3) = 3 \times 3$.

Desarrollo.

1. $(AB)_{11} = 1 \cdot 1 + 0 \cdot 0 + 2 \cdot 3 = 7$; $(AB)_{12} = 1 \cdot 2 + 0 \cdot 1 + 2 \cdot 0 = 2$.
2. $(AB)_{21} = 0 \cdot 1 + 1 \cdot 0 + (-1) \cdot 3 = -3$; $(AB)_{22} = 0 \cdot 2 + 1 \cdot 1 + (-1) \cdot 0 = 1$.
3. Filas de BA (proposición 4.4(ii)): $(1, 2)A = (1, 2, 0)$; $(0, 1)A = (0, 1, -1)$; $(3, 0)A = (3, 0, 6)$.

$$AB = \begin{pmatrix} 7 & 2 \\ -3 & 1 \end{pmatrix}, \qquad BA = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & -1 \\ 3 & 0 & 6 \end{pmatrix}.$$

4. AA sería $(2 \times 3)(2 \times 3)$, que no está definido.

Resultado. AB **es** 2×2 **y** BA **es** 3×3**, con los valores indicados;** AA **no existe.**

Comprobación. las trazas de AB y de BA coinciden siempre: $7 + 1 = 8$ y $1 + 1 + 6 = 8$.

Solución del ejercicio 4.4

Datos. $A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$, $B = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$, $C = \begin{pmatrix} 0 & 0 \\ 2 & 1 \end{pmatrix}$.

Planteamiento. calcular cada producto entrada a entrada.

Desarrollo.

1. $AB = \begin{pmatrix} 2 & 0 \\ 1 & 0 \end{pmatrix}$ y $AC = \begin{pmatrix} 2\cdot 0 + 1 \cdot 2 & 2 \cdot 0 + 1 \cdot 1 \\ 1 \cdot 0 + 3 \cdot 2 & 1 \cdot 0 + 3 \cdot 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 6 & 3 \end{pmatrix}$.
2. $AB + AC = \begin{pmatrix} 4 & 1 \\ 7 & 3 \end{pmatrix}$.
3. $B + C = \begin{pmatrix} 1 & 0 \\ 2 & 1 \end{pmatrix}$ y $A(B + C) = \begin{pmatrix} 2 + 2 & 0 + 1 \\ 1 + 6 & 0 + 3 \end{pmatrix} = \begin{pmatrix} 4 & 1 \\ 7 & 3 \end{pmatrix}$.
4. $BA = \begin{pmatrix} 2 & 1 \\ 0 & 0 \end{pmatrix}$ y $CA = \begin{pmatrix} 0 & 0 \\ 2 \cdot 2 + 1 \cdot 1 & 2 \cdot 1 + 1 \cdot 3 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 5 & 5 \end{pmatrix}$.
5. $BA + CA = \begin{pmatrix} 2 & 1 \\ 5 & 5 \end{pmatrix}$.

Resultado. $AB + AC = A(B + C) = \begin{pmatrix} 4 & 1 \\ 7 & 3 \end{pmatrix}$**, mientras que** $BA + CA = (B + C)A = \begin{pmatrix} 2 & 1 \\ 5 & 5 \end{pmatrix}$ **es distinta.** Cada distributiva vale por su lado, pero no se puede cambiar el lado.

Comprobación. $(B+C)A = \begin{pmatrix}1 & 0\\ 2 & 1\end{pmatrix}\begin{pmatrix}2 & 1\\ 1 & 3\end{pmatrix} = \begin{pmatrix}2 & 1\\ 4+1 & 2+3\end{pmatrix} = \begin{pmatrix}2 & 1\\ 5 & 5\end{pmatrix}$, que coincide con el paso 5.

Solución del ejercicio 4.5

Datos. $A \in \mathbb{R}^{3\times 5}$, $B \in \mathbb{R}^{5\times 2}$, $C \in \mathbb{R}^{2\times 4}$; coste mnp (proposición 4.9).

Planteamiento. sumar el coste de los dos productos de cada orden.

Desarrollo.

1. $(AB)C$: AB cuesta $3\cdot 5\cdot 2 = 30$ y es 3×2; $(AB)C$ cuesta $3\cdot 2\cdot 4 = 24$. Total: 54.
2. $A(BC)$: BC cuesta $5\cdot 2\cdot 4 = 40$ y es 5×4; $A(BC)$ cuesta $3\cdot 5\cdot 4 = 60$. Total: 100.
3. (b) $(u^\top v)w^\top$: el escalar $u^\top v$ cuesta N y multiplicarlo por $w^\top$ cuesta N. Total: $2N$.
4. $u^\top(vw^\top)$: $vw^\top$ es $N\times N$ y cuesta N^2; $u^\top(vw^\top)$ cuesta otras N^2. Total: $2N^2$.
5. Con $N = 4096$: $2N = 8192$ y $2N^2 = 33\,554\,432$, un factor $N = 4096$ mayor.

Resultado. $(AB)C$ **cuesta 54 multiplicaciones y** $A(BC)$ **cuesta 100.** $(u^\top v)w^\top$ **cuesta** $2N$ **y** $u^\top(vw^\top)$ **cuesta** $2N^2$**.** El resultado es el mismo por la asociativa, pero el coste no.

Comprobación. ambos órdenes de (a) producen una matriz 3×4; en (b), ambos producen el vector fila $(u^\top v)\,w^\top$ de N componentes.

Solución del ejercicio 4.6

Datos. $A = \begin{pmatrix}1 & 0\\ 0 & 1\\ 0 & 0\end{pmatrix}$, $b = (4,-1,2)$, $a = (1,1,1)$.

Planteamiento. calcular $P = AA^\top$ (filas de A por filas de A) y aplicar $P^2 = P$; en (c), $P_a = aa^\top/(a^\top a)$.

Desarrollo.

1. (a) $(AA^\top)_{ij}$ es el producto escalar de las filas i y j de A, que son $(1,0)$, $(0,1)$ y $(0,0)$: $P = \mathrm{diag}(1,1,0)$.
2. $Pb = (4,-1,0)$: se conservan las dos primeras coordenadas y se anula la tercera.
3. (b) $P^2 = \mathrm{diag}(1^2,1^2,0^2) = P$.
4. $(I-P)^2 = I - 2P + P^2 = I - 2P + P = I - P$, usando $P^2 = P$.
5. $I-P = \mathrm{diag}(0,0,1)$ y $(I-P)b = (0,0,2)$: proyecta sobre el eje z, perpendicular al plano generado por las columnas de A.
6. (c) $a^\top a = 3$ y $aa^\top$ es la matriz 3×3 de unos; $P_a = \frac{1}{3}aa^\top$.
7. $P_a b = \frac{1}{3}(4-1+2)(1,1,1) = \frac{5}{3}(1,1,1) \approx (1{,}667;\ 1{,}667;\ 1{,}667)$.

Resultado. $P = \mathrm{diag}(1,1,0)$ **y** $Pb = (4,-1,0)$**;** $P^2 = P$ **y** $(I-P)^2 = I-P$**;** $I-P$ **proyecta sobre el eje** z**;** $P_a b = \frac{5}{3}(1,1,1)$**, como en el ejemplo 2.6.**

Comprobación. $Pb + (I-P)b = (4,-1,0) + (0,0,2) = b$ y $(4,-1,0)\cdot(0,0,2) = 0$: b se descompone en dos piezas ortogonales.

Solución del ejercicio 4.7

Datos. $R_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$; fórmulas del coseno y del seno de la suma.

Planteamiento. calcular los productos entrada a entrada; para (c), usar $(AB)^\top = B^\top A^\top$.

Desarrollo.

1. (a) Las columnas de R_θ son $c_1 = (\cos\theta, \sin\theta)$ y $c_2 = (-\sin\theta, \cos\theta)$. $(R_\theta^\top R_\theta)_{ij} = c_i \cdot c_j$: $c_1 \cdot c_1 = c_2 \cdot c_2 = \cos^2\theta + \sin^2\theta = 1$ y $c_1 \cdot c_2 = -\cos\theta\sin\theta + \sin\theta\cos\theta = 0$. Luego $R_\theta^\top R_\theta = I_2$.
2. (b) La primera columna de $R_\theta R_\varphi$ es
$$R_\theta \begin{pmatrix} \cos\varphi \\ \sin\varphi \end{pmatrix} = \begin{pmatrix} \cos\theta\cos\varphi - \sin\theta\sin\varphi \\ \sin\theta\cos\varphi + \cos\theta\sin\varphi \end{pmatrix} = \begin{pmatrix} \cos(\theta+\varphi) \\ \sin(\theta+\varphi) \end{pmatrix}.$$
3. La segunda columna es
$$R_\theta \begin{pmatrix} -\sin\varphi \\ \cos\varphi \end{pmatrix} = \begin{pmatrix} -\cos\theta\sin\varphi - \sin\theta\cos\varphi \\ -\sin\theta\sin\varphi + \cos\theta\cos\varphi \end{pmatrix} = \begin{pmatrix} -\sin(\theta+\varphi) \\ \cos(\theta+\varphi) \end{pmatrix}.$$
Por tanto, $R_\theta R_\varphi = R_{\theta+\varphi}$.
4. Como $\theta + \varphi = \varphi + \theta$, $R_\theta R_\varphi = R_{\theta+\varphi} = R_\varphi R_\theta$.
5. (c) Si $Q_1^\top Q_1 = Q_2^\top Q_2 = I$: $(Q_1Q_2)^\top(Q_1Q_2) = Q_2^\top Q_1^\top Q_1 Q_2 = Q_2^\top Q_2 = I$.
6. (d) Para $D = \operatorname{diag}(\lambda_1, \lambda_2)$ y $R = R_{90^\circ}$: $RD = \begin{pmatrix} 0 & -\lambda_2 \\ \lambda_1 & 0 \end{pmatrix}$ y $DR = \begin{pmatrix} 0 & -\lambda_1 \\ \lambda_2 & 0 \end{pmatrix}$, que coinciden si y solo si $\lambda_1 = \lambda_2$.

Resultado. **Las rotaciones son ortogonales, se componen sumando ángulos y conmutan entre sí; el producto de ortogonales es ortogonal.** S no conmuta con R porque escala los dos ejes por factores distintos ($2 \neq 0{,}5$) y no es ortogonal.

Comprobación. con $\theta = \varphi = 90^\circ$: $R_{90^\circ}^2 = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}^2 = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} = R_{180^\circ}$; con los datos del paso 6, $\lambda_1 = 2$ y $\lambda_2 = 0{,}5$ reproducen RS y SR del ejercicio 4.2.

A.5 Tema 5

Solución del ejercicio 5.1

Datos. $K = 50\,257$; $d = 768$ o $d = 1600$; 4 bytes por número.

Planteamiento. E tiene una fila por token y una columna por dimensión: Kd parámetros.

Desarrollo.

1. Tamaño: $E \in \mathbb{R}^{50\,257 \times 768}$.
2. Parámetros: $50\,257 \cdot 768 = 50\,257 \cdot 700 + 50\,257 \cdot 68 = 35\,179\,900 + 3\,417\,476 = 38\,597\,376$.
3. Memoria: $38\,597\,376 \cdot 4 = 154\,389\,504$ bytes ≈ 154 MB.
4. Con $d = 1600$: $50\,257 \cdot 1600 = 80\,411\,200$ parámetros y $80\,411\,200 \cdot 4 = 321\,644\,800$ bytes ≈ 322 MB.

Resultado. E **es** $50\,257 \times 768$**, con** $38\,597\,376$ **parámetros (**≈ 154 **MB); con** $d = 1600$**,** $80\,411\,200$ **parámetros (**≈ 322 **MB).**

Comprobación. orden de magnitud: $5 \cdot 10^4 \cdot 8 \cdot 10^2 = 4 \cdot 10^7 \approx 3{,}9 \cdot 10^7$.

Solución del ejercicio 5.2

Datos. $e_i \in \mathbb{R}^K$ one-hot; $E \in \mathbb{R}^{K \times d}$; en GPT-2, $K = 50\,257$ y $d = 768$.

Planteamiento. escribir la componente j del producto con la definición 4.1.

Desarrollo.

1. $(e_i^\top E)_j = \sum_k (e_i)_k E_{kj}$.
2. $(e_i)_k = 0$ si $k \neq i$ y $(e_i)_i = 1$, luego solo sobrevive el término $k = i$: $(e_i^\top E)_j = E_{ij}$.
3. Esto vale para $j = 1, \ldots, d$: $e_i^\top E = (E_{i1}, \ldots, E_{id})$, la fila i.
4. El producto requiere Kd multiplicaciones; la lectura copia d números. El cociente es $Kd/d = K = 50\,257$.

Resultado. $e_i^\top E$ **es la fila** i **de** E**; el producto requiere unas** $50\,000$ **veces más operaciones que la lectura directa.**

Comprobación. en el ejemplo 5.4, $(0, 0, 1, 0)\, E = (0{,}5;\ 0{,}5;\ 0{,}5)$, que es la fila 2.

Solución del ejercicio 5.3

Datos. $\hat{E}$ con filas unitarias; $K = 50\,257$, $d = 768$; lote de B consultas.

Planteamiento. $\cos(v_w, q) = \hat{v}_w \cdot \hat{q}$ y la lectura por filas del producto matriz-vector (proposición 3.4).

Desarrollo.

1. (a) La componente w de $\hat{E}\hat{q}$ es $\hat{E}_{w,:} \cdot \hat{q} = \cos(v_w, q)$. Un único producto matriz-vector da los K cosenos. Como dividir por $\|q\| > 0$ no altera el orden (proposición 2.8(i)), basta calcular $\hat{E}q$.
2. (b) $\hat{E}q$ requiere $Kd = 50\,257 \cdot 768 = 38\,597\,376$ multiplicaciones. La normalización de E se hace una sola vez y no se repite en cada consulta.
3. (c) Se apilan las consultas como columnas de $Q \in \mathbb{R}^{d \times B}$ y se calcula $\hat{E}Q \in \mathbb{R}^{K \times B}$, con KdB multiplicaciones en un solo producto de matrices, que la GPU ejecuta eficientemente.
4. Para vocabularios o colecciones mucho mayores se usan índices de búsqueda aproximada de vecinos, que evitan comparar con todos los candidatos (módulo 22).

Resultado. **Con filas normalizadas de antemano, los** K **cosenos son** $\hat{E}q$ **salvo un factor positivo común; cuesta unos** $3{,}86 \cdot 10^7$ **multiplicaciones por consulta, y un lote se procesa con el producto** $\hat{E}Q$**.**

Comprobación. el coste coincide con el del producto $e_i^\top E$ del ejercicio 5.2, porque ambos recorren una vez todas las entradas de una matriz $K \times d$.

Solución del ejercicio 5.4

Datos. vectores del ejemplo 2.9 y los cinco vectores geográficos del enunciado.

Planteamiento. aritmética componente a componente y similitud coseno.

Desarrollo.

1. (a) $v_{\text{hombre}} \cdot v_{\text{mujer}} = 0 + (-1) + 4 + 0 = 3$ y ambas normas valen $\sqrt{5}$: cos $= 3/5 = 0{,}6$.
2. (b) $v_{\text{rey}} - v_{\text{hombre}} = (2, 0, 0, 0)$; sumando v_{mujer}: $(2, -1, 2, 0) = v_{\text{reina}}$.
3. (c) $v_{\text{Madrid}} - v_{\text{España}} = (-1, 1, 0, 0)$; sumando v_{Francia}: $q = (0, 1, 0, 1) = v_{\text{París}}$, luego $\cos(q, v_{\text{París}}) = 1$.
4. $q \cdot v_{\text{Lyon}} = 0{,}5 + 1 = 1{,}5$; $\|q\| = \sqrt{2} \approx 1{,}414$; $\|v_{\text{Lyon}}\| = \sqrt{1{,}25} \approx 1{,}118$.
5. $\cos(q, v_{\text{Lyon}}) = 1{,}5/\sqrt{2{,}5} = 1{,}5/1{,}581 \approx 0{,}9487$.

Resultado. **(a)** $0{,}6$**; (b) se obtiene exactamente «reina»; (c)** $q = (0, 1, 0, 1)$**, con coseno 1 con París y** $\approx 0{,}9487$ **con Lyon.** París gana, pero Lyon queda cerca.

Comprobación. $0{,}9487 < 1$, como exige el teorema 1.14; y (b) es el caso exacto de la proposición 5.8.

Solución del ejercicio 5.5

Datos. $E \in \mathbb{R}^{4\times 3}$ del ejemplo 5.4; secuencia $(2, 0, 2)$.

Planteamiento. proposición 5.3: cada fila de O es el one-hot de un token y $X = OE$.

Desarrollo.

1. (a) Columna 1: $0 \cdot 0{,}1 + 0 \cdot 1 + 1 \cdot 0{,}5 + 0 \cdot (-0{,}2) = 0{,}5$. Las columnas 2 y 3 dan también 0,5.
2. (b) $O = \begin{pmatrix} 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix} \in \mathbb{R}^{3\times 4}$.
3. $X = OE$: sus filas son las filas 2, 0 y 2 de E:

$$X = \begin{pmatrix} 0{,}5 & 0{,}5 & 0{,}5 \\ 0{,}1 & 0{,}2 & 0 \\ 0{,}5 & 0{,}5 & 0{,}5 \end{pmatrix} \in \mathbb{R}^{3\times 3}.$$

Resultado. **(a)** $e_2^\top E = (0{,}5;\ 0{,}5;\ 0{,}5)$**. (b)** X **es** 3×3 $(n \times d)$**, con las filas primera y tercera iguales.**

Comprobación. tamaños: $(3 \times 4)(4 \times 3) = 3 \times 3$.

Solución del ejercicio 5.6

Datos. E del ejemplo 5.4; $h = (1, 0, -1)$.

Planteamiento. $z_i = E_{i,:} \cdot h$ y $\text{softmax}(z)_i = e^{z_i} / \sum_j e^{z_j}$.

Desarrollo.

1. $z_0 = 0{,}1 - 0 = 0{,}1$; $z_1 = 1 + 1 = 2$; $z_2 = 0{,}5 - 0{,}5 = 0$; $z_3 = -0{,}2 - 0{,}1 = -0{,}3$.
2. Exponenciales: $e^{0{,}1} = 1{,}105$; $e^2 = 7{,}389$; $e^0 = 1$; $e^{-0{,}3} = 0{,}7408$. Suma: 10,24.
3. Softmax: $1{,}105/10{,}24 = 0{,}1080$; $7{,}389/10{,}24 = 0{,}7219$; $1/10{,}24 = 0{,}0977$; $0{,}7408/10{,}24 = 0{,}0724$.

4. La fila 1, $(1, 0, -1)$, es igual a h: $\cos(E_{1,:}, h) = 1$ y $z_1 = \|E_{1,:}\|\|h\| \cos = \sqrt{2} \cdot \sqrt{2} \cdot 1 = 2$.

Resultado. $z = (0{,}1;\ 2;\ 0;\ -0{,}3)$ **y** $\text{softmax}(z) \approx (0{,}1080;\ 0{,}7219;\ 0{,}0977;\ 0{,}0724)$**. El token más probable es el 1, cuyo embedding apunta exactamente en la dirección de** h**.**

Comprobación. $0{,}1080 + 0{,}7219 + 0{,}0977 + 0{,}0724 = 1{,}0000$.

Solución del ejercicio 5.7

Datos. (a) $q = (1, 0)$, $k_1 = (1, 1)$, $k_2 = (0, 2)$, $k_3 = (-1, 0)$, $d_k = 2$. (b) Componentes independientes de media 0 y varianza 1. (c) $d = 64$.

Planteamiento. (a) puntuaciones y softmax; (b) linealidad de la esperanza y aditividad de la varianza para sumandos independientes.

Desarrollo.

1. (a) $q \cdot k_1 = 1$, $q \cdot k_2 = 0$, $q \cdot k_3 = -1$; divididos por $\sqrt{2} \approx 1{,}414$: $(0{,}7071;\ 0;\ -0{,}7071)$.
2. $e^{0{,}7071} = 2{,}028$, $e^0 = 1$, $e^{-0{,}7071} = 0{,}4931$; suma 3,521; softmax $(0{,}5760;\ 0{,}2840;\ 0{,}1400)$.
3. (b) $q \cdot k = \sum_{i=1}^{d} q_i k_i$. Por independencia, $\mathbb{E}[q_i k_i] = \mathbb{E}[q_i]\mathbb{E}[k_i] = 0$, luego $\mathbb{E}[q \cdot k] = 0$.
4. $\text{Var}(q_i k_i) = \mathbb{E}[q_i^2 k_i^2] - 0^2 = \mathbb{E}[q_i^2]\,\mathbb{E}[k_i^2] = 1 \cdot 1 = 1$, porque $\mathbb{E}[X^2] = \text{Var}(X) + \mathbb{E}[X]^2 = 1$.
5. Los d sumandos $q_i k_i$ dependen de pares disjuntos de variables independientes, luego son independientes y sus varianzas se suman: $\text{Var}(q \cdot k) = d$.
6. (c) Con $d = 64$, la desviación típica es $\sqrt{64} = 8$. La softmax de $(8, 0, -8)$ es $(2981;\ 1;\ 0{,}000335)/2982 \approx (0{,}99966;\ 0{,}00034;\ 1{,}1 \cdot 10^{-7})$: casi un vector one-hot.
7. La softmax de $(1, 0, -1)$ es $(2{,}718;\ 1;\ 0{,}3679)/4{,}086 \approx (0{,}6652;\ 0{,}2447;\ 0{,}0900)$: una distribución repartida.

Resultado. **(a) puntuaciones** $(0{,}7071;\ 0;\ -0{,}7071)$ **y pesos** $(0{,}576;\ 0{,}284;\ 0{,}140)$**. (b)** $\mathbb{E}[q \cdot k] = 0$ **y** $\text{Var}(q \cdot k) = d$**. (c) Sin dividir por** $\sqrt{d}$ **la softmax se satura; dividiendo, la distribución queda repartida y los gradientes no se anulan.**

Comprobación. (a) $0{,}576 + 0{,}284 + 0{,}140 = 1{,}000$. (b) Una simulación con 10^5 pares de vectores gaussianos de dimensión 64 da una varianza muestral de 63,8 antes de dividir por 8 y de 1,00 después.

Bibliografía

[1] A. Blum, J. Hopcroft y R. Kannan. *Foundations of Data Science*. Cambridge University Press, 2020. Cap. 2, «High-Dimensional Space». Texto del curso CS 4850 de Cornell. https://www.cs.cornell.edu/jeh/book.pdf

[2] T. Bolukbasi, K.-W. Chang, J. Zou, V. Saligrama y A. Kalai. Man is to computer programmer as woman is to homemaker? Debiasing word embeddings. En *Advances in Neural Information Processing Systems 29*, 2016. https://arxiv.org/abs/1607.06520

[3] S. Boyd y L. Vandenberghe. *Introduction to Applied Linear Algebra: Vectors, Matrices, and Least Squares*. Cambridge University Press, 2018. Texto del curso EE103 de Stanford. https://web.stanford.edu/~boyd/vmls/

[4] T. B. Brown *et al.* Language models are few-shot learners. En *Advances in Neural Information Processing Systems 33*, 2020. https://arxiv.org/abs/2005.14165

[5] M. P. Deisenroth, A. A. Faisal y C. S. Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020. Cap. 2, «Linear Algebra», y cap. 3, «Analytic Geometry». https://mml-book.github.io/

[6] J. R. Firth. A synopsis of linguistic theory, 1930–1955. En *Studies in Linguistic Analysis*, págs. 1–32. Blackwell, Oxford, 1957.

[7] Z. S. Harris. Distributional structure. *Word*, 10(2–3):146–162, 1954.

[8] D. Jurafsky y J. H. Martin. *Speech and Language Processing*, 3.ª ed., borrador del 19 de agosto de 2026. Cap. 5, «Embeddings». https://web.stanford.edu/~jurafsky/slp3/

[9] T. Mikolov, K. Chen, G. Corrado y J. Dean. Efficient estimation of word representations in vector space. arXiv:1301.3781, 2013. https://arxiv.org/abs/1301.3781

[10] T. Mikolov, W.-t. Yih y G. Zweig. Linguistic regularities in continuous space word representations. En *Proceedings of NAACL-HLT*, págs. 746–751, 2013. https://aclanthology.org/N13-1090/

[11] M. Nissim, R. van Noord y R. van der Goot. Fair is better than sensational: man is to doctor as woman is to doctor. *Computational Linguistics*, 46(2):487–497, 2020.

[12] O. Press y L. Wolf. Using the output embedding to improve language models. En *Proceedings of EACL*, vol. 2, págs. 157–163, 2017. https://aclanthology.org/E17-2025/

[13] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei e I. Sutskever. Language models are unsupervised multitask learners. Informe técnico, OpenAI, 2019.

[14] G. Strang. *Introduction to Linear Algebra*, 4.ª ed. Wellesley-Cambridge Press, 2009. Texto de los cursos 18.06 y 18.06SC del MIT. Hay 5.ª ed. (2016) y 6.ª ed. (2023); la numeración de secciones y problemas citada es la de la 4.ª ed.

[15] G. Strang. 18.06: Linear Algebra. Massachusetts Institute of Technology, primavera de 2010. Hoja de problemas 1. https://web.mit.edu/18.06/www/Spring10/

[16] G. Strang. 18.06SC: Linear Algebra. Massachusetts Institute of Technology, MIT OpenCourseWare, otoño de 2011. https://ocw.mit.edu/courses/18-06sc-linear-algebra-fall-2011/

[17] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser e I. Polosukhin. Attention is all you need. En *Advances in Neural Information Processing Systems 30*, 2017. https://arxiv.org/abs/1706.03762

[18] D. Yang y Y. Choi. CS224N: Natural Language Processing with Deep Learning. Stanford University, invierno de 2026. Clase 2, «Word Vectors». https://web.stanford.edu/class/cs224n/

[19] A. Zhang, Z. C. Lipton, M. Li y A. J. Smola. *Dive into Deep Learning*, versión 1.0.3. Cambridge University Press, 2023. https://d2l.ai/