Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase I · Fundamentos matemáticos

Módulo 2

Álgebra lineal I

Vectores, matrices y embeddings

Resumen del módulo

Edición de octubre de 2026

Sobre este resumen

Este documento reúne lo indispensable de los apuntes del Módulo 2: el texto expositivo, todas las definiciones y todos los resultados (teoremas, proposiciones, lemas y corolarios), las tablas y las observaciones de contenido. Se han suprimido las demostraciones, los ejemplos, las lecturas, las figuras, los ejercicios y sus soluciones. La numeración de temas, secciones, enunciados y ecuaciones es la misma que en los apuntes, de modo que cualquier referencia puede buscarse allí; las que remiten a elementos suprimidos (un ejemplo, una figura, una ecuación de una demostración) conservan su número en los apuntes.

Notación

Símbolo	Significado
$u = (u_1, \dots, u_d) \in \mathbb{R}^d$	vector columna de d componentes
$e_1, \dots, e_d$	vectores de la base canónica (o vectores *one-hot*)
$u \cdot v = u^\top v$	producto escalar
$\|u\|$, $\|u\|_1$, $\|u\|_\infty$	normas euclídea, ℓ_1 y del máximo
$\hat{u} = u/\|u\|$	vector normalizado ($u \neq 0$)
$\cos(u, v)$	similitud coseno
$A \in \mathbb{R}^{m \times n}$, A_{ij}	matriz de m filas y n columnas y su entrada (i, j)
$A^\top$, I_n	traspuesta e identidad de orden n
$\mathcal{V}$, $K = \|\mathcal{V}\|$, $E \in \mathbb{R}^{K \times d}$	vocabulario, su tamaño y matriz de embeddings
q, k, d_k	consulta, clave y su dimensión (atención)

Los vectores se escriben con letras minúsculas y se consideran columnas; cuando se escriben en línea, $(u_1, \dots, u_d)$ denota la columna correspondiente. Los índices de los tokens empiezan en 0, como en el módulo 1; los de las componentes de un vector, en 1.

Índice

Sobre este resumen **ii**

1 Vectores, producto escalar y norma **1**

1.1 El espacio $\mathbb{R}^d$ . . . 1

1.2 El producto escalar . . . 2

1.3 Normas . . . 2

2 Ángulos, ortogonalidad y similitud coseno **4**

2.1 El ángulo entre dos vectores . . . 4

2.2 Proyección sobre una recta . . . 5

2.3 Similitud coseno . . . 5

2.4 Geometría en alta dimensión . . . 5

3 Matrices y aplicaciones lineales **7**

3.1 Matrices . . . 7

3.2 El producto de una matriz por un vector . . . 7

3.3 Aplicaciones lineales . . . 8

4 El producto de matrices **10**

4.1 Definición y composición . . . 10

4.2 Cuatro formas de calcular un producto . . . 10

4.3 Propiedades algebraicas . . . 11

4.4 Coste y matriz de Gram . . . 11

5 Embeddings, analogías y atención **13**

5.1 La matriz de embeddings . . . 13

5.2 De dónde salen los embeddings . . . 13

5.3 La capa de salida y el atado de pesos . . . 14

5.4 Analogías y aritmética de vectores . . . 14

5.5 Adelanto: el producto escalar en la atención . . . 15

Bibliografía **16**

Tema 1

Vectores, producto escalar y norma

Este tema introduce el espacio $\mathbb{R}^d$, sus dos operaciones básicas y las dos herramientas métricas sobre las que descansa todo el módulo: el producto escalar y la norma. La presentación sigue las secciones 1.1 y 1.2 de Strang [14] y la clase 1 del curso 18.06SC [16]; las definiciones abstractas de espacio vectorial, norma y producto interior proceden de [5, §2.4, §3.1 y §3.2], y el punto de vista computacional, de [3, cap. 1 y §3.1].

1.1 El espacio $\mathbb{R}^d$

Definición 1.1 (Vector). Sea $d \geq 1$ un entero. Un *vector* de $\mathbb{R}^d$ es una lista ordenada $u = (u_1, \ldots, u_d)$ de d números reales, llamados *componentes* de u. Dos vectores son iguales si lo son todas sus componentes. El *vector nulo* es $0 = (0, \ldots, 0)$.

Un vector de $\mathbb{R}^2$ o de $\mathbb{R}^3$ admite dos lecturas geométricas equivalentes: un punto del plano o del espacio, o una flecha que parte del origen y termina en ese punto. Para $d > 3$ no hay dibujo posible, pero todas las definiciones de este módulo se formulan componente a componente y valen igual en cualquier dimensión.

Definición 1.2 (Suma y producto por un escalar). Para $u, v \in \mathbb{R}^d$ y $c \in \mathbb{R}$ se definen

$$u + v = (u_1 + v_1, \ldots, u_d + v_d), \qquad c\,u = (c\,u_1, \ldots, c\,u_d).$$

Geométricamente, $u+v$ se obtiene colocando la flecha v a continuación de la flecha u (regla del paralelogramo), y $c\,u$ estira la flecha si $c > 1$, la encoge si $0 < c < 1$ y la invierte si $c < 0$. La diferencia $u - v = u + (-1)v$ es la flecha que va del extremo de v al extremo de u.

Proposición 1.3. *Con la suma y el producto por un escalar, $\mathbb{R}^d$ satisface, para todos $u, v, w \in \mathbb{R}^d$ y $a, b \in \mathbb{R}$:*

(i) $u + v = v + u$ *y* $(u + v) + w = u + (v + w)$;

(ii) $u + 0 = u$ *y* $u + (-u) = 0$;

(iii) $a(u + v) = au + av$, $(a + b)u = au + bu$ *y* $(ab)u = a(bu)$;

(iv) $1\,u = u$.

Un conjunto dotado de una suma y de un producto por escalares reales que cumplen las propiedades de la proposición 1.3 se llama *espacio vectorial real* [5, §2.4]. Además de $\mathbb{R}^d$, son espacios vectoriales el conjunto $\mathbb{R}^{m\times n}$ de matrices (tema 3) y el de polinomios de grado a lo sumo n. Este módulo trabaja casi siempre en $\mathbb{R}^d$.

Definición 1.4 (Combinación lineal). Sean $v_1, \ldots, v_k \in \mathbb{R}^d$ y $c_1, \ldots, c_k \in \mathbb{R}$. El vector $c_1 v_1 + \cdots + c_k v_k$ es una *combinación lineal* de $v_1, \ldots, v_k$ con coeficientes $c_1, \ldots, c_k$.

Las combinaciones lineales son la operación central del álgebra lineal [14, §1.1]: el producto de una matriz por un vector (tema 3) es una combinación lineal de las columnas de la matriz, y la cuestión de qué vectores se obtienen como combinación de otros dados conduce a los conceptos de independencia, base y rango del módulo 3.

Observación 1.6 (Vectores en los modelos de lenguaje). Un modelo de lenguaje asigna a cada token un vector de $\mathbb{R}^d$, su *embedding* (tema 5). En el modelo más pequeño de GPT-2 es $d = 768$ [13], y en GPT-3, con 175 000 millones de parámetros, $d = 12\,288$ [4, tabla 2.1]. Anthropic, Google y xAI no publican este valor para los modelos actuales de Claude, Gemini y Grok. Otro ejemplo clásico es el *vector de recuentos* de un documento: fijado un diccionario de n palabras, la componente i es el número de veces que aparece la palabra i [3, §1.1].

1.2 El producto escalar

Definición 1.7 (Producto escalar). El *producto escalar* (o producto interior euclídeo) de $u, v \in \mathbb{R}^d$ es el número real

$$u \cdot v = \sum_{i=1}^{d} u_i v_i.$$

Con la notación matricial del tema 3, $u \cdot v = u^\top v$.

Proposición 1.9 (Propiedades del producto escalar). *Para todos $u, v, w \in \mathbb{R}^d$ y $a, b \in \mathbb{R}$:*

(i) (simetría) $u \cdot v = v \cdot u$;

(ii) (linealidad en cada argumento) $(au + bv) \cdot w = a\,(u \cdot w) + b\,(v \cdot w)$;

(iii) (positividad) $u \cdot u \geq 0$, *con igualdad si y solo si* $u = 0$.

Una aplicación $\langle \cdot, \cdot \rangle \colon V \times V \to \mathbb{R}$ sobre un espacio vectorial que cumple (i)–(iii) se llama *producto interior* [5, §3.2]. El producto escalar es el producto interior estándar de $\mathbb{R}^d$; todos los resultados de este tema, salvo los que usan componentes, valen para un producto interior cualquiera.

Observación 1.10 (Coste). Calcular $u \cdot v$ en $\mathbb{R}^d$ requiere d multiplicaciones y $d-1$ sumas, unas $2d$ operaciones en coma flotante [3, §1.5]. Un LLM calcula miles de millones de productos escalares por cada token generado, y su organización en productos de matrices (tema 4) es lo que permite ejecutarlos eficientemente en una GPU.

1.3 Normas

Definición 1.11 (Norma euclídea). La *norma* (o longitud) euclídea de $u \in \mathbb{R}^d$ es

$$\|u\| = \sqrt{u \cdot u} = \sqrt{u_1^2 + \cdots + u_d^2}.$$

Un vector u es *unitario* si $\|u\| = 1$. Si $u \neq 0$, el vector $\hat{u} = u/\|u\|$ es unitario y tiene la misma dirección y sentido que u; se dice que $\hat{u}$ es el *normalizado* de u. La *distancia* entre u y v es $\|u - v\|$.

En $\mathbb{R}^2$ y $\mathbb{R}^3$ la norma es la longitud de la flecha, por el teorema de Pitágoras. Por ejemplo, $\|(3,4)\| = 5$, $\|(1,2,2)\| = 3$ y el normalizado de $(3,4)$ es $(0{,}6;\ 0{,}8)$.

Definición 1.12 (Norma). Una *norma* sobre un espacio vectorial V es una aplicación $\|\cdot\| \colon V \to \mathbb{R}$ que cumple, para todos $u, v \in V$ y $c \in \mathbb{R}$ [5, §3.1]:

(i) (definida positiva) $\|u\| \geq 0$, con igualdad si y solo si $u = 0$;

(ii) (homogeneidad) $\|c\,u\| = |c|\,\|u\|$;

(iii) (desigualdad triangular) $\|u + v\| \leq \|u\| + \|v\|$.

Las propiedades (i) y (ii) de la definición 1.12 son inmediatas para la norma euclídea. La desigualdad triangular, en cambio, requiere un resultado previo que es probablemente la desigualdad más importante del álgebra lineal.

Teorema 1.14 (Desigualdad de Cauchy–Schwarz). *Para todos $u, v \in \mathbb{R}^d$,*

$$|u \cdot v| \leq \|u\|\,\|v\|,$$

y la igualdad se da si y solo si uno de los dos vectores es múltiplo del otro.

La elección de t^* no es arbitraria: $t^* v$ es la proyección de u sobre la recta de v (proposición 2.5), y la demostración dice que el cuadrado de la distancia de u a esa recta es no negativo. El ejercicio 1.4 propone una demostración alternativa.

Corolario 1.15 (Desigualdad triangular). *Para todos $u, v \in \mathbb{R}^d$, $\|u+v\| \leq \|u\| + \|v\|$. En consecuencia, la norma euclídea es una norma en el sentido de la definición 1.12.*

Observación 1.16. La desigualdad triangular expresa que el camino directo es el más corto: la longitud del lado $u + v$ de un triángulo no supera la suma de las de los otros dos. Aplicada a $u - w = (u - v) + (v - w)$, da $\|u - w\| \leq \|u - v\| + \|v - w\|$, que es la desigualdad triangular para distancias.

Tema 2

Ángulos, ortogonalidad y similitud coseno

La desigualdad de Cauchy–Schwarz permite definir el ángulo entre dos vectores en cualquier dimensión. Este tema desarrolla esa geometría: ortogonalidad, proyección sobre una recta y similitud coseno, que es la medida con la que se comparan los embeddings. Se sigue la sección 1.2 de Strang [14] y las secciones 3.3, 3.4 y 3.8 de [5]; el comportamiento en alta dimensión procede del capítulo 2 de Blum, Hopcroft y Kannan [1].

2.1 El ángulo entre dos vectores

Definición 2.1 (Ángulo). Sean $u, v \in \mathbb{R}^d$ no nulos. El *ángulo* entre u y v es el único $\theta \in [0, \pi]$ tal que

$$\cos\theta = \frac{u \cdot v}{\|u\|\,\|v\|}.$$

La definición es correcta porque, por el teorema 1.14, el cociente está en $[-1, 1]$, y la función coseno es una biyección de $[0, \pi]$ en $[-1, 1]$. La proposición siguiente muestra que, en el plano, coincide con el ángulo de la geometría elemental.

Proposición 2.2. *Sean $u, v \in \mathbb{R}^2$ no nulos y sea φ el ángulo geométrico que forman las flechas u y v. Entonces $u \cdot v = \|u\|\|v\| \cos\varphi$.*

El signo del producto escalar indica, por tanto, si dos vectores apuntan en direcciones parecidas u opuestas (cuadro 2.1). El ejercicio 2.6 explora hasta dónde pueden «llevarse mal» varios vectores del plano.

Cuadro 2.1: Signo del producto escalar y ángulo entre dos vectores no nulos.

Producto escalar	Ángulo	Interpretación
$u \cdot v > 0$	$0 \le \theta < \pi/2$	direcciones parecidas
$u \cdot v = 0$	$\theta = \pi/2$	direcciones perpendiculares
$u \cdot v < 0$	$\pi/2 < \theta \le \pi$	direcciones opuestas

Definición 2.3 (Ortogonalidad). Dos vectores $u, v \in \mathbb{R}^d$ son *ortogonales*, y se escribe $u \perp v$, si $u \cdot v = 0$.

El vector nulo es ortogonal a todos, y es el único vector ortogonal a sí mismo, por la positividad del producto escalar. Los vectores de la base canónica son ortogonales dos a dos: $e_i \cdot e_j = 0$ si $i \neq j$.

Teorema 2.4 (Pitágoras). *Si $u \perp v$, entonces $\|u + v\|^2 = \|u\|^2 + \|v\|^2$.*

2.2 Proyección sobre una recta

Proposición 2.5 (Proyección ortogonal sobre una recta). *Sean $u, a \in \mathbb{R}^d$ con $a \neq 0$. Entre todos los vectores de la recta $\{ta : t \in \mathbb{R}\}$, el más próximo a u es*

$$p = \frac{u \cdot a}{a \cdot a}\, a,$$

y es el único punto de la recta tal que $u - p \perp a$. El número $(u \cdot a)/\|a\|$ se llama proyección escalar *de u sobre a; si $\|a\| = 1$, coincide con $u \cdot a$.*

La proyección sobre una recta es el caso más sencillo de la proyección sobre un subespacio, que conduce a los mínimos cuadrados [14, §4.2]; en el tema 4 se escribe como producto de matrices (ejercicio 4.6).

2.3 Similitud coseno

Definición 2.7 (Similitud coseno). La *similitud coseno* de dos vectores no nulos $u, v \in \mathbb{R}^d$ es

$$\cos(u, v) = \frac{u \cdot v}{\|u\|\,\|v\|} = \hat{u} \cdot \hat{v} \in [-1, 1].$$

Proposición 2.8. *Sean $u, v \in \mathbb{R}^d$ no nulos.*

(i) $\cos(au, bv) = \cos(u, v)$ *para todos $a, b > 0$, y* $\cos(u, -v) = -\cos(u, v)$.

(ii) $\cos(u, v) = 1$ *si y solo si $u = cv$ con $c > 0$;* $\cos(u, v) = -1$ *si y solo si $u = cv$ con $c < 0$.*

La similitud coseno mide, por tanto, solo la dirección: $\cos((1, 2), (2, 4)) = 1$ aunque los vectores tengan longitudes distintas.

Proposición 2.10 (Coseno y distancia). *Si $\|u\| = \|v\| = 1$, entonces $\|u - v\|^2 = 2 - 2\cos(u, v)$. En consecuencia, entre vectores normalizados, ordenar los candidatos por distancia creciente a una consulta equivale a ordenarlos por similitud coseno decreciente.*

La demostración se propone en el ejercicio 2.7. Sin normalizar, ambas medidas pueden discrepar: un vector muy largo en la misma dirección que la consulta tiene coseno 1 pero puede estar lejos (ejercicio 2.4). Los buscadores vectoriales de los sistemas RAG (módulo 22) usan el coseno o el producto escalar sobre vectores normalizados.

2.4 Geometría en alta dimensión

En $\mathbb{R}^2$, dos direcciones elegidas al azar forman ángulos de cualquier tamaño. En dimensión alta el comportamiento es muy distinto: dos direcciones aleatorias son casi ortogonales [1, §2.4.2]. El resultado siguiente lo cuantifica.

Proposición 2.11. *Sea U un vector aleatorio de $\mathbb{R}^d$ con $\|U\| = 1$ cuya distribución no cambia al permutar sus componentes ni al cambiar el signo de cualquiera de ellas (por ejemplo, $U = G/\|G\|$ con $G_1, \ldots, G_d$ normales estándar independientes). Para todo vector unitario fijo v,*

$$\mathbb{E}[U \cdot v] = 0, \qquad \mathbb{E}\big[(U \cdot v)^2\big] = \frac{1}{d}.$$

En particular, la similitud coseno entre U y v tiene media 0 y desviación típica $1/\sqrt{d}$.

Si v también es aleatorio e independiente de U, el resultado se aplica condicionando al valor de v. Para $d = 768$, la desviación típica del coseno entre dos direcciones aleatorias es $1/\sqrt{768} \approx 0{,}0361$; para $d = 12\,288$, $\approx 0{,}0090$. Una simulación con 2000 pares de vectores gaussianos da 0,0363 y 0,0091, respectivamente. Por eso un coseno de 0,3 entre dos embeddings de dimensión 768, que equivale a más de ocho desviaciones típicas, es una señal fuerte de parecido.

Observación 2.12. Este fenómeno permite que un espacio de dimensión d contenga muchas más de d direcciones casi ortogonales entre sí. La hipótesis de *superposición* de la interpretabilidad (módulo 23) se apoya en esta propiedad: un modelo puede representar más conceptos que dimensiones tiene su espacio, asignando a cada uno una dirección casi ortogonal a las demás.

Tema 3

Matrices y aplicaciones lineales

Una matriz es una tabla de números, pero su papel en el álgebra lineal es el de una función: transforma vectores en vectores respetando las combinaciones lineales. Este tema establece esa correspondencia entre matrices y aplicaciones lineales. Se sigue la sección 2.1 de Strang [14] y la sesión «The Geometry of Linear Equations» de 18.06SC [16]; las definiciones proceden de [5, §2.2 y §2.7] y de [3, cap. 6 y §8.1].

3.1 Matrices

Definición 3.1 (Matriz). Sean $m, n \geq 1$. Una *matriz* real de tamaño $m \times n$ es una tabla $A = (A_{ij})$ de mn números reales dispuestos en m filas y n columnas; A_{ij} es la entrada de la fila i y la columna j. El conjunto de estas matrices se denota $\mathbb{R}^{m\times n}$. Se escribe $a_j \in \mathbb{R}^m$ para la columna j y $A = [\, a_1 \ \cdots \ a_n \,]$.

Un vector de $\mathbb{R}^d$ se identifica con una matriz $d\times 1$ (vector columna). Las matrices del mismo tamaño se suman y se multiplican por escalares entrada a entrada, y con esas operaciones $\mathbb{R}^{m\times n}$ es un espacio vectorial.

Definición 3.2 (Traspuesta e identidad). La *traspuesta* de $A \in \mathbb{R}^{m\times n}$ es la matriz $A^\top \in \mathbb{R}^{n\times m}$ con $(A^\top)_{ij} = A_{ji}$: las filas de A son las columnas de $A^\top$. Una matriz cuadrada es *simétrica* si $A^\top = A$. La *identidad* $I_n \in \mathbb{R}^{n\times n}$ tiene unos en la diagonal y ceros fuera de ella; sus columnas son los vectores $e_1, \ldots, e_n$ de la base canónica.

Si $u \in \mathbb{R}^d$ es una columna, $u^\top$ es una matriz $1 \times d$ (vector fila). Esta notación permite escribir el producto escalar como $u \cdot v = u^\top v$.

3.2 El producto de una matriz por un vector

Definición 3.3 (Producto matriz-vector). Sean $A \in \mathbb{R}^{m\times n}$ y $x \in \mathbb{R}^n$. El producto $Ax \in \mathbb{R}^m$ es el vector de componentes

$$(Ax)_i = \sum_{j=1}^{n} A_{ij} x_j, \qquad i = 1, \ldots, m.$$

El producto solo está definido si el número de columnas de A coincide con el número de componentes de x.

Proposición 3.4 (Dos lecturas del producto). *Sea $A \in \mathbb{R}^{m\times n}$ con filas $r_1^\top, \ldots, r_m^\top$ y columnas $a_1, \ldots, a_n$. Para todo $x \in \mathbb{R}^n$:*

(i) (por filas) la componente i de Ax es el producto escalar $r_i \cdot x$;

(ii) (por columnas) $Ax = x_1a_1 + x_2a_2 + \cdots + x_na_n$ *es una combinación lineal de las columnas de* A*.*

Las dos lecturas corresponden a las dos imágenes de un sistema de ecuaciones lineales $Ax = b$ que Strang llama imagen por filas e imagen por columnas [14, §2.1]: por filas, cada ecuación es un hiperplano y la solución es su intersección; por columnas, se buscan los coeficientes con los que las columnas de A se combinan para dar b.

3.3 Aplicaciones lineales

Definición 3.6 (Aplicación lineal). Una aplicación $T\colon \mathbb{R}^n \to \mathbb{R}^m$ es *lineal* si

$$T(au + bv) = a\,T(u) + b\,T(v) \qquad \text{para todos } u, v \in \mathbb{R}^n,\ a, b \in \mathbb{R}.$$

Tomando $a = b = 0$ se obtiene $T(0) = 0$: una aplicación lineal fija el origen. Por inducción, T transforma cualquier combinación lineal en la combinación lineal de las imágenes con los mismos coeficientes.

Proposición 3.7. *Para toda* $A \in \mathbb{R}^{m\times n}$*, la aplicación* $x \mapsto Ax$ *es lineal.*

El resultado recíproco es el que justifica la frase «una matriz es una aplicación lineal».

Teorema 3.8 (Matriz de una aplicación lineal). *Sea* $T\colon \mathbb{R}^n \to \mathbb{R}^m$ *lineal y sea* $A \in \mathbb{R}^{m\times n}$ *la matriz cuyas columnas son* $T(e_1), \ldots, T(e_n)$*. Entonces* $T(x) = Ax$ *para todo* $x \in \mathbb{R}^n$*, y* A *es la única matriz con esta propiedad.*

El teorema 3.8 da una receta práctica: para conocer una aplicación lineal basta saber adónde envía los vectores de la base canónica, y esas imágenes son las columnas de su matriz. El cuadro 3.1 recoge las transformaciones del plano más habituales, y la figura 3.1 muestra el efecto de una cizalla sobre el cuadrado unidad.

Cuadro 3.1: Transformaciones lineales del plano. Las columnas de cada matriz son las imágenes de e_1 y e_2.

Transformación	Matriz	$e_1 \mapsto$	$e_2 \mapsto$
Rotación de ángulo θ	$R_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$	$(\cos\theta, \sin\theta)$	$(-\sin\theta, \cos\theta)$
Rotación de 90°	$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$	$(0, 1)$	$(-1, 0)$
Escalado	$\begin{pmatrix} 2 & 0 \\ 0 & 0{,}5 \end{pmatrix}$	$(2, 0)$	$(0;\ 0{,}5)$
Cizalla	$\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$	$(1, 0)$	$(1, 1)$
Simetría respecto de $y = x$	$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$	$(0, 1)$	$(1, 0)$
Proyección sobre el eje x	$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$	$(1, 0)$	$(0, 0)$

Proposición 3.9 (Las rotaciones conservan la norma). *Para todo* $\theta \in \mathbb{R}$ *y todo* $x \in \mathbb{R}^2$*,* $\|R_\theta x\| = \|x\|$.

Las rotaciones conservan también los productos escalares y, por tanto, los ángulos (ejercicio 4.7). Los escalados no: con la matriz de escalado del cuadro 3.1, $e_1 + e_2$, de norma $\sqrt{2}$, pasa a $(2;\ 0{,}5)$, de norma $\sqrt{4{,}25}$.

Observación 3.10 (Matrices en los modelos de lenguaje). Casi todo el cálculo de un Transformer consiste en aplicar matrices aprendidas a vectores. En la atención (módulo 13), cada embedding $x \in \mathbb{R}^d$ se transforma en una *consulta* $q = W_Q x$, una *clave* $k = W_K x$ y un *valor* $v = W_V x$, con W_Q, W_K, W_V matrices $d_k \times d$. Estas matrices seleccionan qué rasgos del embedding intervienen en cada comparación.

Observación 3.11 (Matrices de transición). La matriz de transición P de un modelo de bigramas (módulo 1, tema 2) es estocástica por filas. Si $\pi_t \in \mathbb{R}^K$ es la distribución del token en la posición t, la de la posición siguiente es $\pi_{t+1} = P^\top \pi_t$, cuya componente j es $\sum_i P_{ij}(\pi_t)_i$. La matriz $P^\top$ tiene columnas que suman 1; es la convención que usa Strang para las *matrices de Markov* (ejercicio 3.5).

Tema 4

El producto de matrices

El producto de matrices se define de modo que represente la composición de aplicaciones lineales. De esa definición se siguen sus propiedades (asociativa, distributivas, comportamiento con la traspuesta) y su principal diferencia con el producto de números: no es conmutativo. El tema sigue la sección 2.4 de Strang [14] y la sesión «Multiplication and Inverse Matrices» de 18.06SC [16]; la composición y el coste computacional se tratan como en [3, §10.1 y §10.2].

4.1 Definición y composición

Definición 4.1 (Producto de matrices). Sean $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$. El producto $AB \in \mathbb{R}^{m\times p}$ es la matriz de entradas

$$(AB)_{ij} = \sum_{k=1}^{n} A_{ik}B_{kj}, \qquad 1 \le i \le m,\ 1 \le j \le p.$$

La entrada (i, j) es el producto escalar de la fila i de A por la columna j de B. El producto solo está definido si el número de columnas de A coincide con el número de filas de B: $(m \times n)(n \times p) = m \times p$.

Teorema 4.2 (El producto es la composición). *Sean $A \in \mathbb{R}^{m\times n}$ y $B \in \mathbb{R}^{n\times p}$. Para todo $x \in \mathbb{R}^p$, $(AB)x = A(Bx)$. Es decir, la matriz de la aplicación «aplicar primero B y después A» es AB.*

El orden de escritura es el de la composición de funciones, $(A \circ B)(x) = A(B(x))$: en AB actúa primero la matriz de la derecha.

4.2 Cuatro formas de calcular un producto

La definición 4.1 calcula el producto entrada a entrada. Strang subraya otras tres formas equivalentes [14, §2.4], cada una útil en contextos distintos.

Proposición 4.4. *Sean $A \in \mathbb{R}^{m\times n}$ con columnas $a_1, \dots, a_n$ y filas $r_1^\top, \dots, r_m^\top$, y $B \in \mathbb{R}^{n\times p}$ con columnas $b_1, \dots, b_p$ y filas $s_1^\top, \dots, s_n^\top$. Entonces:*

(i) (por columnas) la columna j de AB es Ab_j;

(ii) (por filas) la fila i de AB es $r_i^\top B$;

(iii) (columnas por filas) $AB = \sum_{k=1}^{n} a_k\, s_k^\top$, suma de n matrices $m \times p$.

Una matriz de la forma $a\, s^\top$, con $a \in \mathbb{R}^m$ y $s \in \mathbb{R}^p$, se llama *producto exterior*; todas sus filas son múltiplos de $s^\top$. La forma (iii) descompone un producto de matrices en suma de productos

exteriores y es la base de la descomposición en valores singulares y de las aproximaciones de bajo rango del módulo 3. En el ejemplo 4.3, $a_1 s_1^\top + a_2 s_2^\top = \begin{pmatrix} 0 & 1 \\ 0 & 3 \end{pmatrix} + \begin{pmatrix} 2 & 0 \\ 4 & 0 \end{pmatrix} = AB$.

4.3 Propiedades algebraicas

Proposición 4.5. *Siempre que los tamaños permitan formar los productos:*

(i) (asociativa) $(AB)C = A(BC)$;

(ii) (distributivas) $A(B+C) = AB + AC$ *y* $(B+C)A = BA + CA$;

(iii) (identidad) $I_m A = A = A I_n$ *si* $A \in \mathbb{R}^{m \times n}$;

(iv) (traspuesta) $(AB)^\top = B^\top A^\top$.

La distributiva por la izquierda y la distributiva por la derecha son propiedades distintas: no puede pasarse de una a otra cambiando el lado (ejercicio 4.4), porque el producto no es conmutativo.

Observación 4.6 (No conmutatividad). En general $AB \neq BA$, incluso si ambos productos están definidos y son del mismo tamaño. Sean $R = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ (rotación de 90°), $S = \begin{pmatrix} 2 & 0 \\ 0 & 0{,}5 \end{pmatrix}$ (escalado) y $x = (3, 1)$. Escalar y después rotar da $R(Sx) = R(6;\, 0{,}5) = (-0{,}5;\, 6)$; rotar y después escalar da $S(Rx) = S(-1, 3) = (-2;\, 1{,}5)$. El orden de las transformaciones importa.

Definición 4.7 (Matriz ortogonal). Una matriz $Q \in \mathbb{R}^{n \times n}$ es *ortogonal* si $Q^\top Q = I_n$, es decir, si sus columnas son unitarias y ortogonales dos a dos.

Proposición 4.8. *Si Q es ortogonal, entonces $(Qu) \cdot (Qv) = u \cdot v$ para todos $u, v \in \mathbb{R}^n$. En consecuencia, Q conserva normas, distancias y ángulos.*

Las rotaciones R_θ son ortogonales (ejercicio 4.7), lo que generaliza la proposición 3.9. Las codificaciones posicionales rotatorias (RoPE) del módulo 14 aplican precisamente rotaciones de este tipo a las consultas y las claves.

4.4 Coste y matriz de Gram

Proposición 4.9 (Coste del producto). *Calcular AB con $A \in \mathbb{R}^{m \times n}$ y $B \in \mathbb{R}^{n \times p}$ mediante la definición 4.1 requiere mnp multiplicaciones y $mp(n-1)$ sumas.*

Aunque $(AB)C = A(BC)$, el coste de los dos órdenes puede ser muy distinto (ejercicio 4.5). Elegir bien el orden de los paréntesis es una optimización habitual en el cálculo con tensores.

Definición 4.10 (Matriz de Gram). Sea $X \in \mathbb{R}^{n \times d}$ la matriz cuyas filas son los vectores $x_1^\top, \ldots, x_n^\top$. Su *matriz de Gram* es $G = XX^\top \in \mathbb{R}^{n \times n}$, con $G_{ij} = x_i \cdot x_j$.

La matriz de Gram es simétrica, porque $G^\top = (XX^\top)^\top = XX^\top$, y su diagonal contiene las normas al cuadrado, $G_{ii} = \|x_i\|^2$. Un único producto de matrices calcula los n^2 productos escalares entre n vectores.

Observación 4.12. En la atención, las consultas y las claves de los n tokens de una secuencia se apilan como filas de matrices $Q, K \in \mathbb{R}^{n \times d_k}$, y todas las puntuaciones se calculan con un

único producto $QK^\top \in \mathbb{R}^{n\times n}$, que generaliza la matriz de Gram. Las GPU están diseñadas para ejecutar este tipo de productos con gran rapidez (módulo 17).

Tema 5

Embeddings, analogías y atención

Este tema aplica las herramientas anteriores a la entrada y la salida de un modelo de lenguaje. La capa de embeddings es una matriz; leer el vector de un token es multiplicar por un vector *one-hot*; las relaciones semánticas aparecen, de forma aproximada, como direcciones del espacio; y la atención compara tokens mediante productos escalares. La presentación sigue el capítulo 5 de Jurafsky y Martin [8] y la clase 2 de CS224N [18], junto con los artículos de Mikolov y coautores [9, 10] y de Vaswani y coautores [17].

5.1 La matriz de embeddings

En este tema se usa la notación del módulo 1: $\mathcal{V}$ es el vocabulario, $K = |\mathcal{V}|$ su tamaño y los tokens se identifican con sus índices $0, 1, \ldots, K-1$. Las filas de las matrices indexadas por tokens se numeran también desde 0.

Definición 5.1 (Matriz de embeddings). Sea $d \geq 1$. Una *matriz de embeddings* es una matriz $E \in \mathbb{R}^{K \times d}$. El *embedding* del token i es la fila i de E, que se denota $E_{i,:} \in \mathbb{R}^d$ (escrita como columna cuando se opera con ella).

Definición 5.2 (Vector one-hot). El vector *one-hot* del token i es el vector $e_i \in \mathbb{R}^K$ que tiene un 1 en la posición i y ceros en el resto.

Proposición 5.3. *Para todo token i, $e_i^\top E = E_{i,:}^\top$; es decir, multiplicar el vector one-hot de un token por la matriz de embeddings selecciona su fila. Si $x_{1:n}$ es una secuencia de tokens y $O \in \mathbb{R}^{n \times K}$ es la matriz cuyas filas son $e_{x_1}^\top, \ldots, e_{x_n}^\top$, entonces $X = OE \in \mathbb{R}^{n \times d}$ es la matriz cuya fila t es el embedding de x_t.*

Observación 5.5 (Indexar en lugar de multiplicar). El producto $e_i^\top E$ requiere Kd multiplicaciones, casi todas por cero; leer directamente la fila i solo copia d números. Las bibliotecas de redes neuronales implementan la capa de embeddings como una indexación, aunque matemáticamente sea el producto de la proposición 5.3. En GPT-2, con $K = 50\,257$ [13, §2.3] y $d = 768$, la matriz E tiene $50\,257 \cdot 768 = 38\,597\,376$ parámetros, unos 154 MB en precisión de 32 bits.

5.2 De dónde salen los embeddings

Los embeddings no se diseñan a mano como en el ejemplo 2.9: se inicializan al azar y se ajustan por descenso de gradiente (módulos 4 y 7) para que el modelo prediga bien el token siguiente. La justificación de que este procedimiento produzca vectores con significado es la *hipótesis distribucional*: las palabras que aparecen en contextos parecidos tienden a tener significados parecidos [7]. Firth la resumió en la frase «you shall know a word by the company

it keeps» [6]. Dos tokens que aparecen en contextos similares reciben gradientes similares y acaban con embeddings próximos en el sentido del coseno [8, cap. 5].

Antes de los Transformers, los embeddings se entrenaban por separado con modelos como word2vec [9], que aprende un vector por palabra prediciendo las palabras vecinas en una ventana. En un LLM, en cambio, la matriz E se aprende junto con el resto de los parámetros.

5.3 La capa de salida y el atado de pesos

Al final del modelo, el vector $h \in \mathbb{R}^d$ de la última posición se compara con un vector por cada token del vocabulario. Si $U \in \mathbb{R}^{K \times d}$ es la matriz de salida, los logits son

$$z = Uh \in \mathbb{R}^K, \qquad z_i = U_{i,:} \cdot h,$$

y la softmax del módulo 1 (tema 4) los convierte en una distribución sobre el token siguiente. Cada logit es, por tanto, un producto escalar entre h y un vector asociado al token.

Definición 5.6 (Atado de pesos). Se dice que un modelo *ata* los pesos de entrada y salida (*weight tying*) si usa $U = E$: la misma matriz sirve para leer los embeddings de entrada y para calcular los logits.

Press y Wolf [12] mostraron que esta elección mejora los modelos de lenguaje recurrentes, y el Transformer original la adopta [17, §3.4]. Ahorra Kd parámetros, que en GPT-2 son 38 597 376, y da a ambos usos una interpretación común: el logit del token i es alto cuando h apunta en la dirección del embedding de i.

5.4 Analogías y aritmética de vectores

Sea v_w el embedding de la palabra w. Si un rasgo como el género corresponde aproximadamente a una dirección del espacio, la diferencia $v_{\text{mujer}} - v_{\text{hombre}}$ debería parecerse a $v_{\text{reina}} - v_{\text{rey}}$. Mikolov, Yih y Zweig [10] observaron este fenómeno en embeddings aprendidos y propusieron resolver analogías con el método siguiente.

Definición 5.7 (Analogía por desplazamiento de vectores). Dada la pregunta «a es a b como ? es a c», se calcula $q = v_a - v_b + v_c$ y se responde con

$$\hat{w} = \operatorname*{arg\,max}_{w \in \mathcal{V} \setminus \{a,b,c\}} \cos(v_w, q).$$

Proposición 5.8. *Si $v_a - v_b = v_{w^*} - v_c$, entonces $q = v_{w^*}$ y $\cos(v_{w^*}, q) = 1$, de modo que w^* es una respuesta de máxima similitud.*

Observación 5.10 (Limitaciones). Con embeddings reales, la igualdad de la proposición 5.8 solo se cumple de forma aproximada, y q suele quedar más cerca de v_a que de la respuesta esperada; la exclusión de a, b y c en la definición 5.7 es esencial para que el método «funcione». Nissim, van Noord y van der Goot [11] analizan cómo esta exclusión distorsiona las conclusiones que se extraen de las analogías. En el cuaderno de prácticas del módulo, con 40 palabras en 16 dimensiones y ruido, la consulta rey − hombre + mujer da «reina» con coseno 0,924, pero sin la exclusión «rey» queda segunda con 0,835. Además, los embeddings heredan los sesgos de los textos de entrenamiento: Bolukbasi y coautores [2] encontraron analogías que reproducen estereotipos de género. La idea de que los conceptos son direcciones reaparece en la interpretabilidad de los LLM (módulo 23).

5.5 Adelanto: el producto escalar en la atención

La atención (módulo 13) es un mecanismo de búsqueda por similitud. Cada token emite una consulta $q \in \mathbb{R}^{d_k}$, la compara por producto escalar con las claves $k_1, \ldots, k_n$ de los tokens anteriores y reparte su atención con una softmax:

$$s_j = \frac{q \cdot k_j}{\sqrt{d_k}}, \qquad \alpha = \mathrm{softmax}(s_1, \ldots, s_n).$$

Para todos los tokens a la vez, las puntuaciones forman la matriz $QK^\top/\sqrt{d_k}$ (definición 4.10).

El factor $1/\sqrt{d_k}$ tiene una justificación estadística [17, §3.2.1]: si las componentes de q y k son variables independientes de media 0 y varianza 1, entonces $\mathrm{Var}(q \cdot k) = d_k$ (ejercicio 5.7). Sin el factor, para d_k grande las puntuaciones tendrían valores muy dispares, la softmax quedaría casi concentrada en un solo token y los gradientes serían casi nulos. Dividir por $\sqrt{d_k}$ devuelve la varianza a 1.

Bibliografía

[1] A. Blum, J. Hopcroft y R. Kannan. *Foundations of Data Science*. Cambridge University Press, 2020. Cap. 2, «High-Dimensional Space». Texto del curso CS 4850 de Cornell. https://www.cs.cornell.edu/jeh/book.pdf

[2] T. Bolukbasi, K.-W. Chang, J. Zou, V. Saligrama y A. Kalai. Man is to computer programmer as woman is to homemaker? Debiasing word embeddings. En *Advances in Neural Information Processing Systems 29*, 2016. https://arxiv.org/abs/1607.06520

[3] S. Boyd y L. Vandenberghe. *Introduction to Applied Linear Algebra: Vectors, Matrices, and Least Squares*. Cambridge University Press, 2018. Texto del curso EE103 de Stanford. https://web.stanford.edu/~boyd/vmls/

[4] T. B. Brown *et al.* Language models are few-shot learners. En *Advances in Neural Information Processing Systems 33*, 2020. https://arxiv.org/abs/2005.14165

[5] M. P. Deisenroth, A. A. Faisal y C. S. Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020. Cap. 2, «Linear Algebra», y cap. 3, «Analytic Geometry». https://mml-book.github.io/

[6] J. R. Firth. A synopsis of linguistic theory, 1930–1955. En *Studies in Linguistic Analysis*, págs. 1–32. Blackwell, Oxford, 1957.

[7] Z. S. Harris. Distributional structure. *Word*, 10(2–3):146–162, 1954.

[8] D. Jurafsky y J. H. Martin. *Speech and Language Processing*, 3.ª ed., borrador del 19 de agosto de 2026. Cap. 5, «Embeddings». https://web.stanford.edu/~jurafsky/slp3/

[9] T. Mikolov, K. Chen, G. Corrado y J. Dean. Efficient estimation of word representations in vector space. arXiv:1301.3781, 2013. https://arxiv.org/abs/1301.3781

[10] T. Mikolov, W.-t. Yih y G. Zweig. Linguistic regularities in continuous space word representations. En *Proceedings of NAACL-HLT*, págs. 746–751, 2013. https://aclanthology.org/N13-1090/

[11] M. Nissim, R. van Noord y R. van der Goot. Fair is better than sensational: man is to doctor as woman is to doctor. *Computational Linguistics*, 46(2):487–497, 2020.

[12] O. Press y L. Wolf. Using the output embedding to improve language models. En *Proceedings of EACL*, vol. 2, págs. 157–163, 2017. https://aclanthology.org/E17-2025/

[13] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei e I. Sutskever. Language models are unsupervised multitask learners. Informe técnico, OpenAI, 2019.

[14] G. Strang. *Introduction to Linear Algebra*, 4.ª ed. Wellesley-Cambridge Press, 2009. Texto de los cursos 18.06 y 18.06SC del MIT. Hay 5.ª ed. (2016) y 6.ª ed. (2023); la numeración de secciones y problemas citada es la de la 4.ª ed.

[15] G. Strang. 18.06: Linear Algebra. Massachusetts Institute of Technology, primavera de 2010. Hoja de problemas 1. https://web.mit.edu/18.06/www/Spring10/

[16] G. Strang. 18.06SC: Linear Algebra. Massachusetts Institute of Technology, MIT OpenCourseWare, otoño de 2011. https://ocw.mit.edu/courses/18-06sc-linear-algebra-fall-2011/

[17] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser e I. Polosukhin. Attention is all you need. En *Advances in Neural Information Processing Systems 30*, 2017. https://arxiv.org/abs/1706.03762

[18] D. Yang y Y. Choi. CS224N: Natural Language Processing with Deep Learning. Stanford University, invierno de 2026. Clase 2, «Word Vectors». https://web.stanford.edu/class/cs224n/

[19] A. Zhang, Z. C. Lipton, M. Li y A. J. Smola. *Dive into Deep Learning*, versión 1.0.3. Cambridge University Press, 2023. https://d2l.ai/