Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase I · Fundamentos matemáticos

Módulo 3

Álgebra lineal II

Rango, autovalores, SVD y PCA

Apuntes del curso

Edición de octubre de 2026

Presentación del módulo

En el módulo 2 las matrices aparecieron como transformaciones lineales y los embeddings como vectores. Este módulo estudia la estructura interna de esas matrices: cuántas dimensiones usan realmente (rango), cuándo pueden invertirse, qué direcciones conservan (autovectores) y cómo se descomponen en una suma de piezas de rango 1 ordenadas por importancia (descomposición en valores singulares). Estas herramientas explican por qué el ajuste fino con LoRA entrena menos del 1 % de los parámetros de una capa, cómo se proyectan en el plano los embeddings de un modelo y qué limita la capacidad expresiva de la capa de salida de un modelo de lenguaje.

Objetivos

Al finalizar el módulo, el estudiante debe ser capaz de:

1. decidir si una familia de vectores es linealmente independiente, calcular coordenadas en una base y obtener el rango y el núcleo de una matriz;

2. enunciar las caracterizaciones de la invertibilidad, calcular inversas y determinantes pequeños y utilizar las propiedades de las matrices ortogonales;

3. calcular autovalores y autovectores, diagonalizar y demostrar que una matriz real simétrica tiene autovalores reales y autovectores ortogonales;

4. enunciar y demostrar la existencia de la descomposición en valores singulares y calcularla a mano en matrices pequeñas;

5. aplicar el teorema de Eckart–Young a la compresión y al ajuste fino de bajo rango, y realizar un análisis de componentes principales mediante la SVD;

6. operar con tensores y con las reglas de *broadcasting*, y razonar sobre las formas y los rangos de las matrices de un LLM.

Requisitos previos

Módulo 2: vectores, producto escalar, norma, producto matricial y matrices como transformaciones. Resolución de sistemas lineales pequeños y de ecuaciones de segundo grado. El tema 3 usa números complejos elementales (conjugado y módulo) en una sola demostración. El módulo 1 aporta la función softmax, que reaparece en el tema 6.

Organización

Tema	Contenido	Fuentes principales
1	Independencia lineal, bases y rango	[8], [10], [1]
2	Inversa, determinante y matrices ortogonales	[8], [10], [1]
3	Autovalores, autovectores y teorema espectral	[8], [10], [1]
4	La descomposición en valores singulares	[8], [12], [1]
5	Aproximación de bajo rango y PCA	[2], [12], [1], [4]
6	Tensores, *broadcasting* y formas de un LLM	[15], [5], [14]

Cada tema termina con una lista de lecturas y con ejercicios graduados en tres niveles: $\star$ comprensión, $\star\star$ cálculo y $\star\star\star$ demostración. Los ejercicios marcados con *Fuente* están adaptados de cursos y libros de texto universitarios; el enunciado se ha redactado de nuevo y, en algunos casos, se han cambiado los datos para que puedan resolverse a mano. Las soluciones completas, paso a paso, están en el apéndice A.

Sobre las fuentes

El texto es de redacción propia. La secuencia de los temas 1 a 4 sigue los capítulos 3 a 7 del libro de Strang [8] y las clases correspondientes del curso 18.06 del MIT [10]; los ejercicios de ese curso proceden de su versión de autoaprendizaje, 18.06SC [11]. La SVD, el teorema de Eckart–Young y el análisis de componentes principales siguen las clases 6 y 7 del curso 18.065 [12] y los capítulos 4 y 10 de Deisenroth, Faisal y Ong [1]. El tema 6 sigue los §2.1 y §2.3 de Zhang *et al.* [15] y la documentación de NumPy [5]. Las aplicaciones a modelos de lenguaje remiten a los artículos originales: LoRA [4], el cuello de botella de la softmax [14], GPT-2 [6] y Llama 2 [13].

Notación

Símbolo	Significado
$A \in \mathbb{R}^{m\times n}$, $A^\top$	matriz de m filas y n columnas y su traspuesta
$\operatorname{gen}\{v_1,\dots,v_k\}$	subespacio generado por $v_1,\dots,v_k$
$\mathcal{C}(A)$, $\mathcal{N}(A)$	espacio columna (imagen) y núcleo de A
$\operatorname{rango}(A)$, $\operatorname{tr}(A)$, $\det(A)$	rango, traza y determinante
I_n, e_i	matriz identidad y i-ésimo vector de la base canónica
λ_i, $\Lambda = \operatorname{diag}(\lambda_1,\dots,\lambda_n)$	autovalores y matriz diagonal de autovalores
Q	matriz ortogonal, $Q^\top Q = I$
$A = U\Sigma V^\top$, $\sigma_1 \ge \sigma_2 \ge \cdots \ge 0$	descomposición en valores singulares y valores singulares
$A_k = \sum_{i\le k} \sigma_i u_i v_i^\top$	truncamiento de rango k de la SVD
$\|A\|_F$, $\|A\|_2$	norma de Frobenius y norma espectral
$X \in \mathbb{R}^{n\times d}$, $C = X^\top X/n$	datos centrados (una fila por punto) y su covarianza
(B, T, d_{model})	forma de las activaciones: lote, longitud, dimensión del modelo

Los vectores son columnas: $v = (v_1,\dots,v_n)$ denota un vector de $\mathbb{R}^n$ escrito en horizontal por comodidad, y $u^\top v$ es su producto escalar.

Índice

Presentación del módulo **ii**

1 Independencia lineal, bases y rango **1**

1.1 Combinaciones lineales y subespacios 1

1.2 Bases, dimensión y coordenadas 1

1.3 Espacio columna, núcleo y rango 2

1.4 Matrices de rango 1 y rango de un producto 3

Ejercicios del tema 1 4

2 Inversa, determinante y matrices ortogonales **5**

2.1 La matriz inversa 5

2.2 El determinante 6

2.3 Bases ortonormales y matrices ortogonales 7

Ejercicios del tema 2 8

3 Autovalores, autovectores y teorema espectral **10**

3.1 Definición y polinomio característico 10

3.2 Diagonalización 11

3.3 Matrices simétricas y teorema espectral 12

3.4 El método de la potencia 13

Ejercicios del tema 3 14

4 La descomposición en valores singulares **15**

4.1 El teorema de la SVD 15

4.2 Cálculo a mano 16

4.3 Normas matriciales 17

Ejercicios del tema 4 17

5 Aproximación de bajo rango y análisis de componentes principales **19**

5.1 El teorema de Eckart–Young 19

5.2 Compresión de matrices 20

5.3 Ajuste fino de bajo rango 21

5.4 Análisis de componentes principales 21

Ejercicios del tema 5 23

6 Tensores, *broadcasting* y formas de un LLM **24**
6.1 Tensores como arrays . . . 24
6.2 Producto por lotes y notación de Einstein . . . 24
6.3 Broadcasting . . . 25
6.4 Formas de un LLM . . . 25
Ejercicios del tema 6 . . . 27

A Soluciones de los ejercicios **28**
A.1 Tema 1 . . . 28
A.2 Tema 2 . . . 31
A.3 Tema 3 . . . 33
A.4 Tema 4 . . . 36
A.5 Tema 5 . . . 39
A.6 Tema 6 . . . 42

Bibliografía **46**

Tema 1

Independencia lineal, bases y rango

Este tema introduce los conceptos que permiten medir cuántas dimensiones utiliza realmente una matriz: independencia lineal, base, dimensión, rango y núcleo. La presentación sigue los §3.1, §3.4 y §3.5 de Strang [8], las clases 9 a 11 del curso 18.06 [10] y los §2.5 a §2.7 de [1]. Se trabaja siempre en $\mathbb{R}^n$, aunque las definiciones valen en cualquier espacio vectorial real.

1.1 Combinaciones lineales y subespacios

Definición 1.1 (Subespacio). Un subconjunto $W \subseteq \mathbb{R}^n$ es un *subespacio vectorial* si contiene el vector nulo y es cerrado para la suma y el producto por escalares: si $u, v \in W$ y $c \in \mathbb{R}$, entonces $u + v \in W$ y $cu \in W$.

Definición 1.2 (Subespacio generado). Dados $v_1, \dots, v_k \in \mathbb{R}^n$, una *combinación lineal* de ellos es un vector $c_1 v_1 + \cdots + c_k v_k$ con $c_i \in \mathbb{R}$. El conjunto de todas las combinaciones lineales es un subespacio, que se denota $\operatorname{gen}\{v_1, \dots, v_k\}$ y se llama *subespacio generado* por los v_i.

Definición 1.3 (Independencia lineal). Los vectores $v_1, \dots, v_k$ son *linealmente independientes* si la única combinación lineal nula es la trivial:

$$c_1 v_1 + \cdots + c_k v_k = 0 \implies c_1 = \cdots = c_k = 0.$$

En caso contrario se dicen *linealmente dependientes*.

Si $V = [v_1 \mid \cdots \mid v_k] \in \mathbb{R}^{n \times k}$ es la matriz cuyas columnas son los vectores, la condición equivale a que el sistema homogéneo $Vc = 0$ tenga solo la solución $c = 0$.

Proposición 1.4. *Los vectores $v_1, \dots, v_k$ ($k \geq 2$) son linealmente dependientes si y solo si alguno de ellos es combinación lineal de los demás.*

Demostración. Si $\sum_i c_i v_i = 0$ con algún $c_j \neq 0$, despejando se obtiene $v_j = -\sum_{i \neq j} (c_i / c_j)\, v_i$. Recíprocamente, si $v_j = \sum_{i \neq j} a_i v_i$, la combinación $\sum_{i \neq j} a_i v_i - v_j = 0$ es nula y tiene el coeficiente $-1 \neq 0$ en v_j. ∎

1.2 Bases, dimensión y coordenadas

Definición 1.5 (Base). Una *base* de un subespacio W es una familia de vectores de W linealmente independiente que genera W.

Proposición 1.6 (Coordenadas). *Si $\{u_1, \dots, u_k\}$ es una base de W, todo $w \in W$ se escribe de forma única como $w = c_1 u_1 + \cdots + c_k u_k$. Los números $c_1, \dots, c_k$ son las* coordenadas *de w en esa base.*

Demostración. La existencia se debe a que la base genera W. Si $w = \sum_i c_i u_i = \sum_i c'_i u_i$, restando se obtiene $\sum_i (c_i - c'_i)u_i = 0$ y, por independencia, $c_i = c'_i$ para todo i. ∎

Lema 1.7. *Si $W = \operatorname{gen}\{v_1, \dots, v_m\}$ y $w_1, \dots, w_p \in W$ con $p > m$, entonces $w_1, \dots, w_p$ son linealmente dependientes.*

Demostración. Cada w_j es combinación de los v_i: $w_j = \sum_{i=1}^{m} a_{ij} v_i$. Sea $A = (a_{ij}) \in \mathbb{R}^{m \times p}$. El sistema homogéneo $Ax = 0$ tiene m ecuaciones y $p > m$ incógnitas; la eliminación gaussiana deja al menos $p - m$ variables libres, luego existe $x \neq 0$ con $Ax = 0$. Para ese x,

$$\sum_{j=1}^{p} x_j w_j = \sum_{j=1}^{p} x_j \sum_{i=1}^{m} a_{ij} v_i = \sum_{i=1}^{m} \Big(\sum_{j=1}^{p} a_{ij} x_j \Big) v_i = \sum_{i=1}^{m} (Ax)_i \, v_i = 0,$$

que es una combinación lineal nula no trivial de los w_j. ∎

Teorema 1.8 (Dimensión). *Todas las bases de un subespacio W tienen el mismo número de elementos. Ese número se llama* dimensión *de W y se denota* $\dim W$. *En particular,* $\dim \mathbb{R}^n = n$.

Demostración. Sean $\{v_1, \dots, v_m\}$ y $\{w_1, \dots, w_p\}$ dos bases de W. Si fuera $p > m$, el lema 1.7 aplicado a $W = \operatorname{gen}\{v_i\}$ haría dependientes a los w_j, lo que contradice que formen base; luego $p \leq m$. Intercambiando los papeles, $m \leq p$. La base canónica $e_1, \dots, e_n$ muestra que $\dim \mathbb{R}^n = n$. ∎

Ejemplo 1.9 (Cambio de coordenadas). Sean $u_1 = (1, 1)$ y $u_2 = (1, -1)$, que forman una base de $\mathbb{R}^2$. Para hallar las coordenadas de $b = (3, 1)$ se resuelve $c_1 u_1 + c_2 u_2 = b$:

$$\begin{cases} c_1 + c_2 = 3, \\ c_1 - c_2 = 1, \end{cases} \qquad \Longrightarrow \qquad c_1 = 2, \quad c_2 = 1.$$

El mismo vector tiene coordenadas $(3, 1)$ en la base canónica y $(2, 1)$ en la base $\{u_1, u_2\}$. En forma matricial, si $U = [u_1 \mid u_2]$, las coordenadas son $c = U^{-1} b$.

Observación 1.10. Las coordenadas de un embedding dependen de la base en la que se expresan. Un cambio de base invertible del espacio de activaciones de un modelo, compensado en las capas siguientes, no altera sus predicciones; por eso las coordenadas individuales de un embedding no tienen, en general, un significado propio. Esta observación es el punto de partida de los métodos de interpretabilidad del módulo 23, que buscan direcciones del espacio y no coordenadas.

1.3 Espacio columna, núcleo y rango

Definición 1.11 (Espacio columna y núcleo). Sea $A \in \mathbb{R}^{m \times n}$. El *espacio columna* (o imagen) de A es $\mathcal{C}(A) = \{Ax : x \in \mathbb{R}^n\} \subseteq \mathbb{R}^m$, el subespacio generado por sus columnas. El *núcleo* de A es $\mathcal{N}(A) = \{x \in \mathbb{R}^n : Ax = 0\} \subseteq \mathbb{R}^n$.

Definición 1.12 (Rango). El *rango* de A es $\operatorname{rango}(A) = \dim \mathcal{C}(A)$, el número máximo de columnas linealmente independientes de A.

Teorema 1.13 (Rango de filas igual a rango de columnas). *Para toda $A \in \mathbb{R}^{m \times n}$,* $\operatorname{rango}(A) = \operatorname{rango}(A^\top)$*: el número máximo de filas independientes coincide con el de columnas independientes.*

Demostración. Sea $r = \operatorname{rango}(A)$ y sea $C \in \mathbb{R}^{m\times r}$ la matriz formada por r columnas de A que constituyen una base de $\mathcal{C}(A)$. Cada columna a_j de A es combinación de las columnas de C, $a_j = Cr_j$ con $r_j \in \mathbb{R}^r$; agrupando, $A = CR$ con $R = [r_1 \mid \cdots \mid r_n] \in \mathbb{R}^{r\times n}$. Leída por filas, esta igualdad dice que cada fila de A es combinación lineal de las r filas de R. Por el lema 1.7, a lo sumo r filas de A son independientes: $\operatorname{rango}(A^\top) \le \operatorname{rango}(A)$. Aplicando el mismo argumento a $A^\top$ se obtiene la desigualdad contraria. ∎

La factorización $A = CR$ de la demostración es la que Strang usa como punto de partida en [8, §1.4].

Teorema 1.14 (Rango y nulidad). *Para toda $A \in \mathbb{R}^{m\times n}$,*

$$\operatorname{rango}(A) + \dim \mathcal{N}(A) = n.$$

Demostración. Sea $\{k_1, \dots, k_p\}$ una base de $\mathcal{N}(A)$ y complétese con $w_1, \dots, w_q$ hasta una base de $\mathbb{R}^n$, de modo que $p + q = n$. Se demuestra que $\{Aw_1, \dots, Aw_q\}$ es una base de $\mathcal{C}(A)$, lo que da $\operatorname{rango}(A) = q = n - p$.

Generan. Todo $x \in \mathbb{R}^n$ se escribe $x = \sum_i a_i k_i + \sum_j b_j w_j$, y como $Ak_i = 0$, $Ax = \sum_j b_j\, Aw_j$.

Son independientes. Si $\sum_j b_j Aw_j = 0$, entonces $A\big(\sum_j b_j w_j\big) = 0$, luego $\sum_j b_j w_j \in \mathcal{N}(A)$ y se escribe $\sum_j b_j w_j = \sum_i a_i k_i$. Como $\{k_i\} \cup \{w_j\}$ es una base de $\mathbb{R}^n$, todos los coeficientes son nulos; en particular, $b_j = 0$. ∎

Ejemplo 1.15. Sea

$$M = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 0 & 1 \end{pmatrix}.$$

La segunda fila es el doble de la primera, y las filas primera y tercera no son proporcionales; luego $\operatorname{rango}(M) = 2$. Por el teorema 1.14, $\dim \mathcal{N}(M) = 3 - 2 = 1$. El vector $(1, 1, -1)$ cumple $M(1, 1, -1) = (1 + 2 - 3,\ 2 + 4 - 6,\ 1 + 0 - 1) = 0$, luego $\mathcal{N}(M) = \operatorname{gen}\{(1, 1, -1)\}$. La matriz aplasta $\mathbb{R}^3$ sobre el plano $\mathcal{C}(M)$ y anula la dirección $(1, 1, -1)$.

1.4 Matrices de rango 1 y rango de un producto

Proposición 1.16. *Si $u \in \mathbb{R}^m$ y $v \in \mathbb{R}^n$ son no nulos, la matriz $uv^\top \in \mathbb{R}^{m\times n}$ tiene rango 1. Recíprocamente, toda matriz de rango 1 es de esta forma.*

Demostración. La columna j de $uv^\top$ es $v_j\, u$: todas las columnas son múltiplos de u, y alguna es no nula porque algún $v_j \neq 0$. Luego $\mathcal{C}(uv^\top) = \operatorname{gen}\{u\}$ y el rango es 1. Si $\operatorname{rango}(A) = 1$ y u genera $\mathcal{C}(A)$, cada columna es $a_j = v_j u$ para cierto $v_j \in \mathbb{R}$, y $A = uv^\top$ con $v = (v_1, \dots, v_n)$. ∎

Proposición 1.17 (Rango de un producto). *Si $B \in \mathbb{R}^{m\times r}$ y $A \in \mathbb{R}^{r\times n}$, entonces* $\operatorname{rango}(BA) \le \min\{\operatorname{rango}(A), \operatorname{rango}(B)\} \le r$.

La demostración se propone en el ejercicio 1.6. De la factorización $A = CR$ del teorema 1.13 se deduce además que toda matriz de rango r es suma de r matrices de rango 1, $A = \sum_{i=1}^{r} c_i\, \rho_i^\top$, donde c_i es la columna i de C y $\rho_i^\top$ la fila i de R. El tema 4 obtiene una descomposición de este tipo con piezas ortogonales y ordenadas por importancia.

Observación 1.18 (Matrices de bajo rango en un LLM). El ajuste fino LoRA [4], que se estudia en el módulo 20, mantiene congelada una matriz de pesos $W_0 \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ y aprende una corrección $\Delta W = BA$ con $B \in \mathbb{R}^{d_{\text{out}} \times r}$ y $A \in \mathbb{R}^{r \times d_{\text{in}}}$. Por la proposición 1.17, $\operatorname{rango}(\Delta W) \le r$, y el número de parámetros entrenables es $r(d_{\text{in}} + d_{\text{out}})$ en lugar de $d_{\text{in}} d_{\text{out}}$. Con $d_{\text{in}} = d_{\text{out}} = 4096$ y $r = 8$ se entrenan 65 536 parámetros, el 0,39 % de los 16 777 216 de la matriz completa.

Lecturas recomendadas para este tema

- Strang [8], §3.4 «Independence, Basis, and Dimension», §3.5 «Dimensions of the Four Subspaces» y apéndice 1 «The Ranks of AB and $A + B$».
- MIT 18.06 [10], clases 9 «Independence, basis, and dimension», 10 «The four fundamental subspaces» y 11 «Matrix spaces; rank 1; small world graphs».
- Deisenroth, Faisal y Ong [1], §2.5 «Linear Independence», §2.6 «Basis and Rank» y §2.7.3 «Image and Kernel» (teorema 2.24).

Ejercicios del tema 1

Ejercicio 1.1 ⋆ Justifique si son verdaderas o falsas: (a) tres vectores de $\mathbb{R}^2$ pueden ser linealmente independientes; (b) si las n columnas de $A \in \mathbb{R}^{m \times n}$ son independientes, entonces $n \le m$; (c) una matriz de 5×3 puede tener rango 4.

Ejercicio 1.2 ⋆⋆ Sean $u = (1, 2, 3)$ y $v = (1, -1)$. Escriba la matriz $uv^{\top}$, calcule su rango y dé una base de su espacio columna y de su núcleo.

Ejercicio 1.3 ⋆⋆ (a) Decida si $x_1 = (2, -1, 3)$, $x_2 = (1, 1, -2)$ y $x_3 = (3, -3, 8)$ son linealmente independientes; si no lo son, escriba una relación de dependencia. (b) Escriba $y = (1, -2, 5)$ como combinación lineal de $z_1 = (1, 1, 1)$, $z_2 = (1, 2, 3)$ y $z_3 = (2, -1, 1)$, y explique por qué los coeficientes son únicos.

Fuente: adaptado de Deisenroth, Faisal y Ong [1], cap. 2, ejercicios 2.10(a) y 2.11.

Ejercicio 1.4 ⋆⋆ Halle el mayor número de vectores linealmente independientes entre $v_1 = (1, -1, 0)$, $v_2 = (1, 0, -1)$, $v_3 = (0, 1, -1)$ y $v_4 = (1, 1, -2)$. Escriba las relaciones de dependencia, dé una base del subespacio que generan y obtenga una ecuación que cumplan todos sus vectores.

Fuente: adaptado de MIT 18.06SC [11], sesión «Independence, Basis and Dimension», problema 9.1 (vectores de $\mathbb{R}^3$ en lugar de $\mathbb{R}^4$).

Ejercicio 1.5 ⋆⋆ Sea

$$A = \begin{pmatrix} 1 & 2 & 0 & 1 \\ 2 & 4 & 1 & 3 \\ 3 & 6 & 1 & 4 \end{pmatrix}.$$

Calcule $\operatorname{rango}(A)$, una base de $\mathcal{C}(A)$ y una base de $\mathcal{N}(A)$, y compruebe el teorema 1.14.

Ejercicio 1.6 ⋆⋆⋆ Demuestre la proposición 1.17. Deduzca que una corrección LoRA $\Delta W = BA$ con $B \in \mathbb{R}^{d \times r}$ no puede igualar una matriz $\Delta W^{\star} \in \mathbb{R}^{d \times d}$ de rango mayor que r.

Tema 2

Inversa, determinante y matrices ortogonales

Este tema estudia cuándo una transformación lineal puede deshacerse, cómo lo detecta el determinante y por qué las matrices ortogonales, cuya inversa es su traspuesta, ocupan un lugar privilegiado. Se sigue a Strang [8, §2.2, cap. 5 y §4.4], las clases 3, 17, 18 y 20 de 18.06 [10] y el §4.1 de [1].

2.1 La matriz inversa

Definición 2.1 (Inversa). Una matriz cuadrada $A \in \mathbb{R}^{n\times n}$ es *invertible* si existe $A^{-1} \in \mathbb{R}^{n\times n}$ tal que $AA^{-1} = A^{-1}A = I_n$. Una matriz no invertible se llama *singular*.

Proposición 2.2. *Sean $A, B \in \mathbb{R}^{n\times n}$ invertibles.*

(i) *La inversa es única.*

(ii) *AB es invertible y $(AB)^{-1} = B^{-1}A^{-1}$.*

(iii) *$A^\top$ es invertible y $(A^\top)^{-1} = (A^{-1})^\top$.*

Demostración. (i) Si B_1 y B_2 son inversas de A, entonces $B_1 = B_1(AB_2) = (B_1A)B_2 = B_2$. (ii) $(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AA^{-1} = I$, y del mismo modo en el otro orden. (iii) Trasponiendo $AA^{-1} = I$ se obtiene $(A^{-1})^\top A^\top = I$, y análogamente $A^\top(A^{-1})^\top = I$. ∎

Teorema 2.3 (Caracterizaciones de la invertibilidad). *Para $A \in \mathbb{R}^{n\times n}$ son equivalentes:*

(i) *A es invertible;*

(ii) $\operatorname{rango}(A) = n$;

(iii) *$\mathcal{N}(A) = \{0\}$, es decir, $Ax = 0$ solo si $x = 0$;*

(iv) $\det(A) \neq 0$;

(v) *0 no es autovalor de A.*

Demostración. (i)⇒(iii): si $Ax = 0$, entonces $x = A^{-1}Ax = 0$. (iii)⇔(ii): por el teorema 1.14, $\operatorname{rango}(A) = n - \dim\mathcal{N}(A)$. (ii)⇒(i): si $\operatorname{rango}(A) = n$, las columnas de A son una base de $\mathbb{R}^n$, luego cada e_j se escribe $e_j = Ab_j$ de forma única; la matriz $B = [b_1 \mid \cdots \mid b_n]$ cumple $AB = I$. Para ver que también $BA = I$, obsérvese que $A(BA - I) = (AB)A - A = 0$, luego cada columna de $BA - I$ está en $\mathcal{N}(A) = \{0\}$. La equivalencia con (iv) se justifica en la apartado 2.2 y la equivalencia con (v) es inmediata a partir de la definición de autovalor del tema 3: 0 es autovalor si y solo si existe $x \neq 0$ con $Ax = 0$. ∎

Proposición 2.4 (Inversa de orden 2). *Sea* $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ *con* $ad - bc \neq 0$. *Entonces*

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

Demostración. Basta multiplicar: $\begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} = \begin{pmatrix} ad - bc & 0 \\ 0 & ad - bc \end{pmatrix} = (ad - bc)\, I$, y lo mismo en el orden inverso. ∎

Ejemplo 2.5. Para $A = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$, $ad - bc = 2 - 1 = 1$ y $A^{-1} = \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}$. La primera fila de AA^{-1} es $(2 - 1,\ -2 + 2) = (1, 0)$ y la segunda, $(1 - 1,\ -1 + 2) = (0, 1)$.

Observación 2.6 (Cálculo numérico). Para resolver $Ax = b$ no se calcula A^{-1}: se factoriza A (por ejemplo, $A = LU$) y se resuelven dos sistemas triangulares, lo que es más rápido y numéricamente más estable. En NumPy, `np.linalg.solve(A, b)` es preferible a `np.linalg.inv(A) @ b`. En los modelos de lenguaje las matrices de pesos no se invierten; lo que sí aparece constantemente es la ortogonalidad (apartado 2.3).

2.2 El determinante

Se adopta la presentación axiomática de [8, §5.1] y de la clase 18 de [10].

Definición 2.7 (Determinante). El *determinante* es la única función $\det\colon \mathbb{R}^{n\times n} \to \mathbb{R}$ que cumple:

(i) $\det(I_n) = 1$;

(ii) cambia de signo al intercambiar dos filas;

(iii) es lineal en cada fila cuando las demás se mantienen fijas.

De estas tres propiedades se deducen todas las demás [8, §5.1]: si dos filas son iguales, el determinante es nulo; restar a una fila un múltiplo de otra no lo cambia; el determinante de una matriz triangular es el producto de su diagonal; $\det(A^\top) = \det(A)$; y

$$\det(AB) = \det(A)\det(B).$$

La eliminación gaussiana lleva A a una matriz triangular U mediante operaciones que, a lo sumo, cambian el signo del determinante. Por tanto, $\det(A) \neq 0$ si y solo si todos los pivotes son no nulos, es decir, si y solo si $\operatorname{rango}(A) = n$. Esto completa la equivalencia (ii)⇔(iv) del teorema 2.3. Además, de $AA^{-1} = I$ se obtiene $\det(A^{-1}) = 1/\det(A)$.

Proposición 2.8 (Desarrollo por cofactores). *Para* $A \in \mathbb{R}^{n\times n}$ *y cualquier fila* i,

$$\det(A) = \sum_{j=1}^{n} (-1)^{i+j} a_{ij} \det(A_{ij}),$$

donde A_{ij} *es la submatriz de orden* $n - 1$ *obtenida al suprimir la fila* i *y la columna* j. *En particular,* $\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc$.

Esta fórmula es el desarrollo de Laplace [1, teorema 4.2]; su demostración, a partir de la linealidad en la fila i, está en [8, §5.2]. Para $n = 3$ equivale a la regla de Sarrus.

Observación 2.9 (Interpretación geométrica). $|\det(A)|$ es el factor por el que A multiplica volúmenes: el cubo unidad se transforma en un paralelepípedo de volumen $|\det(A)|$ [8, §5.3]. Un determinante nulo indica que el paralelepípedo es plano, es decir, que A aplasta alguna dimensión. Para la matriz M del ejemplo 1.15, $\det(M) = 0$.

2.3 Bases ortonormales y matrices ortogonales

Definición 2.10 (Familia ortonormal). Los vectores $q_1, \dots, q_k \in \mathbb{R}^n$ son *ortonormales* si $q_i^\top q_j = \delta_{ij}$, donde δ_{ij} vale 1 si $i = j$ y 0 en otro caso.

Una familia ortonormal es linealmente independiente: si $\sum_i c_i q_i = 0$, multiplicando por $q_j^\top$ se obtiene $c_j = 0$.

Proposición 2.11 (Coordenadas en una base ortonormal). *Si $\{q_1, \dots, q_n\}$ es una base ortonormal de $\mathbb{R}^n$, todo $x \in \mathbb{R}^n$ cumple*

$$x = \sum_{j=1}^{n} (q_j^\top x)\, q_j \qquad y \qquad \|x\|^2 = \sum_{j=1}^{n} (q_j^\top x)^2.$$

Si la base es solo ortogonal (con $q_j \neq 0$), la coordenada j es $c_j = q_j^\top x / q_j^\top q_j$.

Demostración. Escríbase $x = \sum_i c_i q_i$. Multiplicando por $q_j^\top$, $q_j^\top x = \sum_i c_i\, q_j^\top q_i = c_j$. Además, $\|x\|^2 = x^\top x = \sum_{i,j} c_i c_j\, q_i^\top q_j = \sum_j c_j^2$. En el caso ortogonal, $q_j^\top x = c_j\, q_j^\top q_j$. ∎

La segunda igualdad es el teorema de Pitágoras en $\mathbb{R}^n$. Calcular coordenadas en una base ortonormal no requiere resolver ningún sistema: basta un producto escalar por coordenada.

Definición 2.12 (Matriz ortogonal). Una matriz $Q \in \mathbb{R}^{n \times n}$ es *ortogonal* si sus columnas forman una base ortonormal de $\mathbb{R}^n$, es decir, si $Q^\top Q = I_n$. En ese caso, $Q^{-1} = Q^\top$.

Ejemplo 2.13 (Giros del plano). Para cada ángulo θ, la matriz

$$Q_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$$

es ortogonal: sus columnas tienen norma $\cos^2\theta + \sin^2\theta = 1$ y su producto escalar es $-\cos\theta\sin\theta + \sin\theta\cos\theta = 0$. Su inversa, $Q_\theta^\top = Q_{-\theta}$, es el giro en sentido contrario, y $\det(Q_\theta) = 1$. La reflexión $\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ también es ortogonal, con determinante -1.

Proposición 2.14. *Si Q es ortogonal, entonces $(Qx)^\top (Qy) = x^\top y$ y $\|Qx\| = \|x\|$ para todos x, y, y $\det(Q) = \pm 1$.*

La demostración se propone en el ejercicio 2.6. Las matrices ortogonales son, por tanto, las transformaciones lineales que conservan longitudes y ángulos: giros y reflexiones.

Observación 2.15 (Gram–Schmidt). A partir de cualquier base $a_1, \dots, a_n$ se obtiene una base ortonormal del mismo espacio restando a cada a_k su proyección sobre los vectores ya construidos y normalizando: $w_k = a_k - \sum_{i<k} (q_i^\top a_k)\, q_i$ y $q_k = w_k / \|w_k\|$ [8, §4.4]. En forma matricial, el proceso da la factorización $A = QR$ con R triangular superior.

Observación 2.16 (Ortogonalidad en un LLM). Las matrices ortogonales aparecen en varios puntos de un Transformer. La codificación posicional rotatoria (RoPE, módulo 14) aplica a cada par de coordenadas de las consultas y las claves un giro Q_θ cuyo ángulo depende de la posición; como los giros conservan la norma, solo cambian los ángulos entre vectores. Las matrices U y V de la SVD (tema 4) son ortogonales, y algunas inicializaciones de pesos usan matrices ortogonales aleatorias porque conservan la norma de las activaciones.

Lecturas recomendadas para este tema

- Strang [8], §2.2 «Elimination Matrices and Inverse Matrices», cap. 5 «Determinants» y §4.4 «Orthonormal Bases and Gram-Schmidt».
- MIT 18.06 [10], clases 3 «Multiplication and inverse matrices», 17 «Orthogonal matrices and Gram-Schmidt», 18 «Properties of determinants» y 20 «Cramer's rule, inverse matrix, and volume».
- Deisenroth, Faisal y Ong [1], §4.1 «Determinant and Trace».
- Goodfellow, Bengio y Courville [3], §2.3 «Identity and Inverse Matrices» y §2.11 «The Determinant».

Ejercicios del tema 2

Ejercicio 2.1 ⋆ Indique, sin calcular inversas, cuáles de las siguientes matrices son invertibles y qué condición del teorema 2.3 lo justifica: (a) la matriz M del ejemplo 1.15; (b) Q_θ del ejemplo 2.13; (c) $\begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$; (d) una matriz $A \in \mathbb{R}^{4\times 4}$ que cumple $A(1, 0, -1, 2) = 0$; (e) $\operatorname{diag}(3,\, 0{,}5,\, -1)$.

Ejercicio 2.2 ⋆⋆ Calcule la inversa de $A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$, compruebe que $AA^{-1} = I$ y verifique que $\det(A^{-1}) = 1/\det(A)$.

Ejercicio 2.3 ⋆⋆ (a) Calcule el determinante de

$$A = \begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \\ 0 & 2 & 4 \end{pmatrix}$$

mediante el desarrollo por la primera fila y mediante la regla de Sarrus. (b) Determine, si existe, la inversa de $B = \begin{pmatrix} 2 & 3 & 4 \\ 3 & 4 & 5 \\ 4 & 5 & 6 \end{pmatrix}$. En caso de que no exista, dé un vector no nulo de $\mathcal{N}(B)$.

Fuente: adaptado de Deisenroth, Faisal y Ong [1], ejercicios 4.1 y 2.8(a).

Ejercicio 2.4 ⋆⋆ (a) Compruebe que $Q_\alpha Q_\beta = Q_{\alpha+\beta}$. (b) Calcule $Q_{\pi/6}\,(2, 0)$ y compruebe que su norma es 2. (c) Explique por qué el producto escalar $(Q_\alpha x)^\top (Q_\beta y)$ depende de α y β solo a través de $\beta - \alpha$. Esta es la propiedad que aprovecha RoPE para que la atención dependa de la posición relativa.

Ejercicio 2.5 ⋆⋆⋆ En $\mathbb{R}^4$, la base de Haar está formada por $h_1 = (1,1,1,1)$, $h_2 = (1,1,-1,-1)$, $h_3 = (1,-1,0,0)$ y $h_4 = (0,0,1,-1)$. (a) Compruebe que es ortogonal y normalícela. (b) Escriba la señal $x = (4,2,5,5)$ en esa base. (c) Comprima x conservando solo los dos primeros coeficientes y calcule el error cuadrático. Justifique, mediante la proposición 2.11, que el error es la suma de los cuadrados de los coeficientes descartados multiplicados por $\|h_j\|^2$.

Fuente: adaptado de MIT 18.06SC [11], sesión «Change of Basis; Image Compression», problema 31.1 (base de 8 vectores reducida a 4; apartados (b) y (c) añadidos).

Ejercicio 2.6 ⋆⋆⋆ Demuestre la proposición 2.14. Demuestre además que el producto de dos matrices ortogonales es ortogonal.

Tema 3

Autovalores, autovectores y teorema espectral

Un autovector de una matriz cuadrada es una dirección que la matriz no gira, solo estira o encoge. Este tema define autovalores y autovectores, estudia la diagonalización y demuestra el resultado central para las aplicaciones: las matrices reales simétricas tienen autovalores reales y una base ortonormal de autovectores. Se sigue a Strang [8, §6.1–6.3], las clases 21, 22 y 25 de 18.06 [10], las clases 4 y 5 de 18.065 [12] y los §4.2 y §4.4 de [1].

3.1 Definición y polinomio característico

Definición 3.1 (Autovalor y autovector). Sea $A \in \mathbb{R}^{n\times n}$. Un número $\lambda \in \mathbb{C}$ es un *autovalor* de A si existe $v \neq 0$ tal que

$$Av = \lambda v.$$

Todo $v \neq 0$ que cumple la igualdad es un *autovector* asociado a λ. El conjunto $\mathcal{N}(A - \lambda I)$, formado por los autovectores y el vector nulo, es el *espacio propio* de λ.

Proposición 3.2 (Polinomio característico). *λ es autovalor de A si y solo si* $\det(A-\lambda I) = 0$. *La función $p_A(\lambda) = \det(A - \lambda I)$ es un polinomio de grado n en λ, llamado* polinomio característico.

Demostración. $Av = \lambda v$ con $v \neq 0$ equivale a $(A - \lambda I)v = 0$ con $v \neq 0$, es decir, a que $A - \lambda I$ tenga núcleo no trivial. Por el teorema 2.3, esto ocurre si y solo si $\det(A - \lambda I) = 0$. Que p_A es un polinomio de grado n se sigue del desarrollo por cofactores: el único término de grado n procede del producto de la diagonal, $\prod_i (a_{ii} - \lambda)$. ∎

Por el teorema fundamental del álgebra, p_A tiene n raíces complejas contadas con multiplicidad: $p_A(\lambda) = \prod_{i=1}^{n} (\lambda_i - \lambda)$.

Ejemplo 3.3. Sea $S = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$. Entonces $p_S(\lambda) = (2 - \lambda)^2 - 1 = 0$, luego $2 - \lambda = \pm 1$ y los autovalores son $\lambda_1 = 3$ y $\lambda_2 = 1$.

- $\lambda_1 = 3$: $(S - 3I)v = 0$ da $-v_1 + v_2 = 0$, y un autovector unitario es $q_1 = (1, 1)/\sqrt{2}$.
- $\lambda_2 = 1$: $(S - I)v = 0$ da $v_1 + v_2 = 0$, y un autovector unitario es $q_2 = (1, -1)/\sqrt{2}$.

Los dos autovectores son ortogonales, $q_1^\top q_2 = 0$. El teorema 3.7 muestra que no es casualidad.

Proposición 3.4 (Traza y determinante). *Si $\lambda_1, \dots, \lambda_n$ son los autovalores de A contados con multiplicidad, entonces*

$$\det(A) = \prod_{i=1}^{n} \lambda_i, \qquad \operatorname{tr}(A) = \sum_{i=1}^{n} a_{ii} = \sum_{i=1}^{n} \lambda_i.$$

Demostración. Evaluando $\det(A - \lambda I) = \prod_i (\lambda_i - \lambda)$ en $\lambda = 0$ se obtiene la primera igualdad. Para la segunda se compara el coeficiente de λ^{n-1} en ambos miembros. En el producto $\prod_i (\lambda_i - \lambda)$ vale $(-1)^{n-1} \sum_i \lambda_i$. En el desarrollo de $\det(A - \lambda I)$, todo término que no sea el producto de la diagonal omite al menos dos factores diagonales y tiene grado $\leq n - 2$; el producto $\prod_i (a_{ii} - \lambda)$ aporta $(-1)^{n-1} \sum_i a_{ii}$. ∎

En el ejemplo 3.3, $3 + 1 = 4 = \operatorname{tr}(S)$ y $3 \cdot 1 = 3 = \det(S)$. Estas dos comprobaciones detectan la mayoría de los errores de cálculo.

Cuadro 3.1: Autovalores de algunas matrices de orden 2.

Matriz	Autovalores	Interpretación
$\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$	3 y 1	estira por 3 la diagonal y conserva la antidiagonal
$\begin{pmatrix} 3 & 1 \\ 0 & 2 \end{pmatrix}$	3 y 2	triangular: los autovalores son la diagonal
$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$	1 y 0	proyección: conserva el eje x y anula el eje y
$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$	$\pm i$	giro de 90°: ninguna dirección real se conserva

3.2 Diagonalización

Proposición 3.5. *Autovectores asociados a autovalores distintos son linealmente independientes.*

Demostración. Supóngase lo contrario y sea k el menor número de autovectores $v_1, \dots, v_k$, con autovalores distintos $\lambda_1, \dots, \lambda_k$, que admiten una combinación nula $\sum_{i=1}^{k} c_i v_i = 0$ con todos los $c_i \neq 0$ (por minimalidad, ninguno puede ser nulo; además $k \geq 2$, porque $v_1 \neq 0$). Aplicando A se obtiene $\sum_i c_i \lambda_i v_i = 0$, y restando λ_k veces la combinación original, $\sum_{i=1}^{k-1} c_i (\lambda_i - \lambda_k) v_i = 0$. Los coeficientes $c_i(\lambda_i - \lambda_k)$ son no nulos, lo que da una combinación nula de $k-1$ autovectores y contradice la minimalidad de k. ∎

Teorema 3.6 (Diagonalización). *$A \in \mathbb{R}^{n \times n}$ admite una factorización $A = X \Lambda X^{-1}$, con Λ diagonal y X invertible, si y solo si A tiene n autovectores linealmente independientes. En ese caso, las columnas de X son autovectores, la diagonal de Λ contiene los autovalores correspondientes y $A^k = X \Lambda^k X^{-1}$ para todo $k \geq 1$.*

Demostración. La igualdad $AX = X\Lambda$ significa, columna a columna, $Ax_i = \lambda_i x_i$. Si los x_i son independientes, X es invertible (teorema 2.3) y $A = X \Lambda X^{-1}$. Recíprocamente, si $A = X \Lambda X^{-1}$, entonces $AX = X\Lambda$ y las columnas de X, independientes por ser X invertible, son autovectores. Finalmente, $A^k = X \Lambda X^{-1} X \Lambda X^{-1} \cdots X \Lambda X^{-1} = X \Lambda^k X^{-1}$. ∎

Por la proposición 3.5, una matriz con n autovalores distintos es diagonalizable. Con autovalores repetidos puede no serlo: $\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$ tiene el autovalor doble 1, pero su espacio propio es $\operatorname{gen}\{e_1\}$, de dimensión 1. La diagonalizabilidad no guarda relación con la invertibilidad (ejercicio 3.1).

3.3 Matrices simétricas y teorema espectral

Teorema 3.7. *Sea $S \in \mathbb{R}^{n\times n}$ simétrica, $S^\top = S$. Entonces:*

(i) todos los autovalores de S son reales;

(ii) autovectores asociados a autovalores distintos son ortogonales.

Demostración. La parte (i) se demuestra en el ejercicio 3.5. Para (ii), sean $Sv_1 = \lambda_1 v_1$ y $Sv_2 = \lambda_2 v_2$ con $\lambda_1 \neq \lambda_2$. Se calcula $v_1^\top S v_2$ de dos formas:

$$v_1^\top S v_2 = v_1^\top (\lambda_2 v_2) = \lambda_2\, v_1^\top v_2, \qquad v_1^\top S v_2 = (S^\top v_1)^\top v_2 = (S v_1)^\top v_2 = \lambda_1\, v_1^\top v_2.$$

Restando, $(\lambda_1 - \lambda_2)\, v_1^\top v_2 = 0$ y, como $\lambda_1 \neq \lambda_2$, $v_1^\top v_2 = 0$. ∎

Teorema 3.8 (Teorema espectral). *Toda matriz real simétrica $S \in \mathbb{R}^{n\times n}$ se factoriza como*

$$S = Q \Lambda Q^\top = \sum_{i=1}^{n} \lambda_i\, q_i q_i^\top,$$

donde $Q = [q_1 \mid \cdots \mid q_n]$ es ortogonal y $\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$ es real.

Demostración en el caso de autovalores distintos. Por el teorema 3.7, los autovalores son reales y los autovectores, que pueden tomarse reales y unitarios, son ortogonales dos a dos. Forman, pues, una base ortonormal, y el teorema 3.6 con $X = Q$ y $X^{-1} = Q^\top$ da $S = Q\Lambda Q^\top$. La forma de suma se obtiene multiplicando $Q\Lambda$ por $Q^\top$ como columnas por filas. El caso general, con autovalores repetidos, se demuestra mediante la factorización de Schur [8, §6.3]: en cada espacio propio se elige una base ortonormal por Gram–Schmidt. ∎

Leída de derecha a izquierda, $S = Q\Lambda Q^\top$ dice que S expresa el vector en la base de autovectores ($Q^\top$), estira cada eje por su autovalor (Λ) y vuelve a la base original (Q). Para el ejemplo 3.3,

$$S = 3\, q_1 q_1^\top + 1\, q_2 q_2^\top = \frac{3}{2}\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} + \frac{1}{2}\begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}.$$

Definición 3.9 (Matriz semidefinida positiva). Una matriz simétrica S es *semidefinida positiva* si $x^\top S x \geq 0$ para todo x, y *definida positiva* si $x^\top S x > 0$ para todo $x \neq 0$.

Proposición 3.10. *Para toda $A \in \mathbb{R}^{m\times n}$, la matriz $A^\top A$ es simétrica y semidefinida positiva, y sus autovalores son mayores o iguales que cero.*

Demostración. $(A^\top A)^\top = A^\top A$. Para todo x, $x^\top A^\top A x = (Ax)^\top (Ax) = \|Ax\|^2 \geq 0$. Si $A^\top A q = \lambda q$ con $\|q\| = 1$, entonces $\lambda = q^\top A^\top A q = \|Aq\|^2 \geq 0$. ∎

Proposición 3.11 (Cociente de Rayleigh). *Sea S simétrica con autovalores $\lambda_1 \geq \cdots \geq \lambda_n$ y autovectores ortonormales $q_1, \ldots, q_n$. Entonces*

$$\max_{\|x\|=1} x^\top S x = \lambda_1,$$

y el máximo se alcanza en $x = q_1$.

Demostración. Escríbase $x = \sum_i c_i q_i$ con $\sum_i c_i^2 = \|x\|^2 = 1$ (proposición 2.11). Por el teorema 3.8, $x^\top S x = \sum_i \lambda_i c_i^2 \leq \lambda_1 \sum_i c_i^2 = \lambda_1$. Con $x = q_1$ se obtiene $q_1^\top S q_1 = \lambda_1$. ∎

Este resultado es la base del análisis de componentes principales (tema 5): la dirección de máxima varianza de unos datos es el primer autovector de su matriz de covarianza.

3.4 El método de la potencia

Si S es simétrica con $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$, la iteración

$$x_{k+1} = \frac{S x_k}{\|S x_k\|}$$

converge, salvo signo, al autovector q_1 siempre que x_0 tenga componente no nula sobre q_1. El error decrece como $|\lambda_2/\lambda_1|^k$ (ejercicio 3.6).

Ejemplo 3.12. Con la matriz S del ejemplo 3.3 y $x_0 = (1, 0)$: $Sx_0 = (2, 1)$, $S^2 x_0 = (5, 4)$, $S^3 x_0 = (14, 13)$, $S^4 x_0 = (41, 40)$ y $S^5 x_0 = (122, 121)$. Normalizado, $S^5 x_0 / \|S^5 x_0\| \approx (0{,}7100;\ 0{,}7042)$, muy cerca de $q_1 \approx (0{,}7071;\ 0{,}7071)$. Como $|\lambda_2/\lambda_1| = 1/3$, cada iteración divide el error aproximadamente por 3.

Observación 3.13 (Conexión con los LLM). El método de la potencia, y sus variantes por bloques, es la forma habitual de calcular unos pocos autovalores o valores singulares dominantes de matrices grandes [12, clase 12]: se usa, por ejemplo, para estimar la norma espectral de una matriz de pesos sin calcular su SVD completa. Las matrices de covarianza de los embeddings son simétricas y semidefinidas positivas (proposición 3.10), de modo que el teorema 3.8 garantiza que tienen ejes principales ortogonales; esa es la idea del tema 5.

Lecturas recomendadas para este tema

- Strang [8], §6.1 «Introduction to Eigenvalues», §6.2 «Diagonalizing a Matrix» y §6.3 «Symmetric Positive Definite Matrices».
- MIT 18.06 [10], clases 21 «Eigenvalues and eigenvectors», 22 «Diagonalization and powers of A» y 25 «Symmetric matrices and positive definiteness».
- MIT 18.065 [12], clases 4 «Eigenvalues and Eigenvectors» y 5 «Positive Definite and Semidefinite Matrices».
- Deisenroth, Faisal y Ong [1], §4.2 «Eigenvalues and Eigenvectors» (teorema espectral 4.15) y §4.4 «Eigendecomposition and Diagonalization».

Ejercicios del tema 3

Ejercicio 3.1 ⋆ Determine, para cada una de las matrices

$$I_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad P = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad J = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}, \quad N = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix},$$

si es diagonalizable y si es invertible. Concluya que ninguna de las dos propiedades implica la otra.

Fuente: adaptado de Deisenroth, Faisal y Ong [1], ejercicio 4.5.

Ejercicio 3.2 ⋆⋆ Calcule los autovalores y autovectores de $B = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$. ¿Son ortogonales los autovectores? Relacione la respuesta con el teorema 3.7.

Ejercicio 3.3 ⋆⋆ Calcule los autovalores de

$$A = \begin{pmatrix} 2 & 1 & 4 \\ 0 & 3 & 5 \\ 0 & 0 & -1 \end{pmatrix}, \qquad B = \begin{pmatrix} 0 & 0 & 2 \\ 0 & 1 & 0 \\ 8 & 0 & 0 \end{pmatrix}, \qquad C = \begin{pmatrix} 3 & 3 & 3 \\ 3 & 3 & 3 \\ 3 & 3 & 3 \end{pmatrix},$$

y compruebe en cada caso la proposición 3.4.

Fuente: adaptado de MIT 18.06SC [11], sesión «Eigenvalues and Eigenvectors», problema 21.2 (matrices cambiadas).

Ejercicio 3.4 ⋆⋆ Una matriz $B \in \mathbb{R}^{3\times 3}$ tiene autovalores 0, 2 y 3. Calcule, si es posible: (a) $\operatorname{rango}(B)$; (b) $\det(B^\top B)$; (c) los autovalores de $(B^2 + I)^{-1}$. (d) ¿Pueden deducirse los autovalores de $B^\top B$?

Fuente: adaptado de MIT 18.06SC [11], sesión «Eigenvalues and Eigenvectors», problema 21.1 (autovalores cambiados).

Ejercicio 3.5 ⋆⋆⋆ Demuestre que todos los autovalores de una matriz real simétrica son reales. Indicación: si $Sv = \lambda v$ con $v \in \mathbb{C}^n$ no nulo, calcule $\bar{v}^\top S v$ de dos formas.

Ejercicio 3.6 ⋆⋆⋆ Sea S simétrica con autovectores ortonormales $q_1, \dots, q_n$ y autovalores $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$, y sea $x_0 = \sum_i c_i q_i$ con $c_1 \neq 0$. Demuestre que $S^k x_0 / \|S^k x_0\|$ tiende a $\pm q_1$ y que la distancia a la recta generada por q_1 es $O\big(|\lambda_2/\lambda_1|^k\big)$.

Tema 4

La descomposición en valores singulares

El teorema espectral solo se aplica a matrices cuadradas simétricas. La descomposición en valores singulares (SVD) extiende la misma idea a cualquier matriz rectangular: toda transformación lineal es un giro, seguido de un estiramiento a lo largo de ejes perpendiculares, seguido de otro giro. Este tema sigue a Strang [8, §7.1], la clase 29 de 18.06 [10], las clases 6 y 8 de 18.065 [12] y el §4.5 de [1].

4.1 El teorema de la SVD

Teorema 4.1 (Descomposición en valores singulares). *Sea $A \in \mathbb{R}^{m\times n}$ de rango r. Existen matrices ortogonales $U \in \mathbb{R}^{m\times m}$ y $V \in \mathbb{R}^{n\times n}$ y números $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ tales que*

$$A = U\Sigma V^\top = \sum_{i=1}^{r} \sigma_i\, u_i v_i^\top,$$

donde $\Sigma \in \mathbb{R}^{m\times n}$ tiene $\Sigma_{ii} = \sigma_i$ para $i \leq r$ y ceros en el resto, y u_i, v_i son las columnas de U y V. Los σ_i son los valores singulares *de A, y los u_i y v_i, sus* vectores singulares *izquierdos y derechos. Además, $Av_i = \sigma_i u_i$ y $A^\top u_i = \sigma_i v_i$ para $i \leq r$.*

Demostración. Por la proposición 3.10 y el teorema 3.8, $A^\top A \in \mathbb{R}^{n\times n}$ tiene una base ortonormal de autovectores $v_1, \ldots, v_n$ con autovalores $\lambda_1 \geq \cdots \geq \lambda_n \geq 0$. Como $\mathcal{N}(A^\top A) = \mathcal{N}(A)$ (si $A^\top Ax = 0$, entonces $\|Ax\|^2 = x^\top A^\top Ax = 0$), el teorema 1.14 da $\operatorname{rango}(A^\top A) = \operatorname{rango}(A) = r$, de modo que exactamente $\lambda_1, \ldots, \lambda_r$ son positivos. Se define $\sigma_i = \sqrt{\lambda_i}$ y, para $i \leq r$,

$$u_i = \frac{Av_i}{\sigma_i}.$$

Estos vectores son ortonormales:

$$u_i^\top u_j = \frac{v_i^\top A^\top A v_j}{\sigma_i \sigma_j} = \frac{\lambda_j\, v_i^\top v_j}{\sigma_i \sigma_j} = \delta_{ij}.$$

Se completan $u_1, \ldots, u_r$ con $u_{r+1}, \ldots, u_m$ hasta una base ortonormal de $\mathbb{R}^m$ (Gram–Schmidt). Para $i > r$, $\|Av_i\|^2 = \lambda_i = 0$, luego $Av_i = 0$. Por tanto, $Av_i = \sigma_i u_i$ para $i \leq r$ y $Av_i = 0$ para $i > r$, que en forma matricial es $AV = U\Sigma$. Multiplicando por $V^\top$ a la derecha, $A = U\Sigma V^\top$. Por último, $A^\top u_i = A^\top A v_i/\sigma_i = \lambda_i v_i/\sigma_i = \sigma_i v_i$. ∎

Observación 4.2 (SVD reducida). Como las columnas u_i y v_i con $i > r$ se multiplican por ceros, también se cumple $A = U_r \Sigma_r V_r^\top$, con $U_r \in \mathbb{R}^{m\times r}$, $\Sigma_r = \operatorname{diag}(\sigma_1, \ldots, \sigma_r)$ y $V_r \in \mathbb{R}^{n\times r}$. Es la versión que se almacena en la práctica (`np.linalg.svd` con `full_matrices=False`).

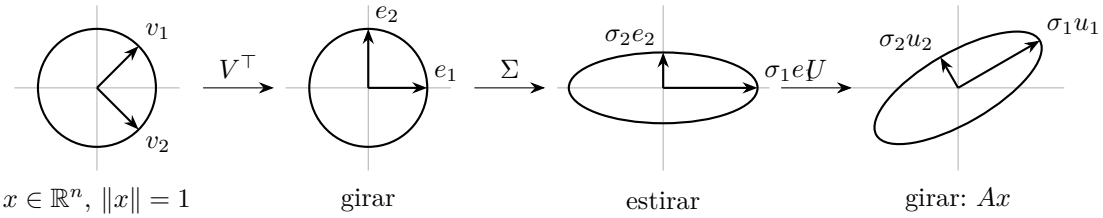


Figura 4.1: Interpretación geométrica de $A = U\Sigma V^\top$ para $m = n = 2$. La imagen de la circunferencia unidad es una elipse cuyos semiejes miden σ_1 y σ_2 y apuntan en las direcciones u_1 y u_2.

Corolario 4.3. *Sea $A = U\Sigma V^\top$ la SVD de $A \in \mathbb{R}^{m\times n}$.*

(i) $\operatorname{rango}(A)$ *es el número de valores singulares no nulos.*

(ii) $\sigma_i(A) = \sqrt{\lambda_i(A^\top A)}$*, y $AA^\top$ tiene los mismos autovalores no nulos que $A^\top A$, con autovectores u_i.*

(iii) $\{u_1, \dots, u_r\}$ *es una base ortonormal de $\mathcal{C}(A)$ y $\{v_{r+1}, \dots, v_n\}$, una base ortonormal de $\mathcal{N}(A)$.*

(iv) Si A es simétrica con autovalores λ_i, sus valores singulares son los $|\lambda_i|$. Si además es semidefinida positiva, la SVD coincide con la descomposición espectral.

Demostración. (i) y (iii) se leen en la demostración del teorema 4.1: $Av_i = \sigma_i u_i$ para $i \le r$ y $Av_i = 0$ para $i > r$, y $\dim \mathcal{N}(A) = n - r$. (ii) $AA^\top = U\Sigma\Sigma^\top U^\top$ es una descomposición espectral con autovalores σ_i^2; la primera igualdad es la definición de σ_i. (iv) Si $A = Q\Lambda Q^\top$, se toma $V = Q$ y $u_i = \operatorname{signo}(\lambda_i)\, q_i$ (con $u_i = q_i$ si $\lambda_i = 0$), de modo que $A = U|\Lambda|V^\top$. ■

4.2 Cálculo a mano

El procedimiento de la demostración sirve también para calcular la SVD de matrices pequeñas: (1) se forma $A^\top A$ o $AA^\top$, la que sea de menor orden; (2) se calculan sus autovalores σ_i^2 y autovectores ortonormales; (3) se obtienen los vectores singulares del otro lado con $u_i = Av_i/\sigma_i$ o $v_i = A^\top u_i/\sigma_i$.

Ejemplo 4.4. Sea $A = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$, la matriz del ejercicio 4.8 de [1].

1. Es más cómodo trabajar con $AA^\top = \begin{pmatrix} 17 & 8 \\ 8 & 17 \end{pmatrix}$, de orden 2. Sus autovalores cumplen $(17-\lambda)^2 = 64$, luego $\lambda = 25$ y $\lambda = 9$, y $\sigma_1 = 5$, $\sigma_2 = 3$.
2. Como en el ejemplo 3.3, los autovectores unitarios son $u_1 = (1,1)/\sqrt{2}$ y $u_2 = (1,-1)/\sqrt{2}$.
3. $v_1 = A^\top u_1/\sigma_1 = (5,5,0)/(5\sqrt{2}) = (1,1,0)/\sqrt{2}$ y $v_2 = A^\top u_2/\sigma_2 = (1,-1,4)/(3\sqrt{2})$.

Se comprueba que $\|v_2\|^2 = (1+1+16)/18 = 1$ y $v_1^\top v_2 = (1-1+0)/6 = 0$. El tercer vector singular derecho, v_3, genera $\mathcal{N}(A)$: resolviendo $Av_3 = 0$ se obtiene $v_3 = (2,-2,-1)/3$. La matriz tiene rango 2 y

$$A = 5\, u_1 v_1^\top + 3\, u_2 v_2^\top .$$

4.3 Normas matriciales

Definición 4.5 (Normas de Frobenius y espectral). Para $A \in \mathbb{R}^{m\times n}$ se definen la *norma de Frobenius* y la *norma espectral*

$$\|A\|_F = \Big(\sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}^2\Big)^{1/2}, \qquad \|A\|_2 = \max_{x\neq 0} \frac{\|Ax\|}{\|x\|}.$$

Proposición 4.6. *Para toda $A \in \mathbb{R}^{m\times n}$ con valores singulares $\sigma_1 \geq \cdots \geq \sigma_r > 0$,*

$$\|A\|_F^2 = \operatorname{tr}(A^\top A) = \sum_{i=1}^{r} \sigma_i^2, \qquad \|A\|_2 = \sigma_1.$$

En particular, $\|A\|_2 \leq \|A\|_F \leq \sqrt{r}\,\|A\|_2$.

Las dos igualdades se demuestran en los ejercicios 4.5 y 4.7; la segunda es el teorema 4.24 de [1]. Ambas normas son invariantes por transformaciones ortogonales: $\|Q_1 A Q_2\| = \|A\|$ para Q_1, Q_2 ortogonales, porque los valores singulares no cambian. Las desigualdades finales se siguen de $\sigma_1^2 \leq \sum_i \sigma_i^2 \leq r\sigma_1^2$.

Ejemplo 4.7. Para la matriz del ejemplo 4.4, $\|A\|_F^2 = 9+4+4+4+9+4 = 34 = 25+9$ y $\|A\|_2 = 5$: ningún vector unitario se alarga más de 5 veces, y v_1 alcanza ese máximo.

Observación 4.8 (Conexión con los LLM). Los valores singulares de una matriz de pesos describen cuánto puede amplificar una capa cada dirección de entrada. Una norma espectral grande indica que pequeñas perturbaciones de la entrada pueden producir grandes cambios en la salida, y el espectro de los pesos se usa para diagnosticar entrenamientos (módulo 11). El tema 5 usa la SVD para la propiedad más importante en la práctica: truncar la suma $\sum_i \sigma_i u_i v_i^\top$ da la mejor aproximación de rango bajo.

Lecturas recomendadas para este tema

- Strang [8], §7.1 «Singular Values and Singular Vectors».
- MIT 18.06 [10], clase 29 «Singular value decomposition».
- MIT 18.065 [12], clases 6 «Singular Value Decomposition (SVD)» y 8 «Norms of Vectors and Matrices»; lectura: Strang [9], §I.8.
- Deisenroth, Faisal y Ong [1], §4.5 «Singular Value Decomposition» (teorema 4.22) y §4.6 hasta el teorema 4.24.
- Goodfellow, Bengio y Courville [3], §2.8 «Singular Value Decomposition».

Ejercicios del tema 4

Ejercicio 4.1 ⋆ Justifique si son verdaderas o falsas: (a) la SVD solo existe para matrices cuadradas; (b) los valores singulares de una matriz pueden ser negativos; (c) si A es simétrica, sus valores singulares coinciden con sus autovalores; (d) A y $A^\top$ tienen los mismos valores singulares.

Ejercicio 4.2 ⋆⋆ Sea $A = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}$. (a) Calcule $A^\top A$ y $AA^\top$. (b) Calcule sus autovalores y deduzca los valores singulares de A. (c) Compruebe que $\sigma_1 = (1+\sqrt{5})/2$ y $\sigma_2 = (\sqrt{5}-1)/2$, y explique por qué coinciden con los valores absolutos de los autovalores de A.

Fuente: adaptado de MIT 18.06SC [11], sesión «Singular Value Decomposition», problema 29.1.

Ejercicio 4.3 ⋆⋆ Sea A una matriz cuyas columnas $w_1, \dots, w_n$ son ortogonales y no nulas, con $\|w_j\| = s_j$. Calcule $A^\top A$ y deduzca U, Σ y V. Aplíquelo a $A = \begin{pmatrix} 2 & 1 \\ 1 & 0 \\ 2 & -1 \end{pmatrix}$.

Fuente: adaptado de MIT 18.06SC [11], sesión «Singular Value Decomposition», problema 29.2 (caso numérico añadido).

Ejercicio 4.4 ⋆⋆ Calcule la descomposición en valores singulares de $A = \begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix}$ y compruebe que $U\Sigma V^\top = A$.

Fuente: adaptado de Deisenroth, Faisal y Ong [1], ejercicio 4.9.

Ejercicio 4.5 ⋆⋆⋆ Demuestre que $\|A\|_F^2 = \operatorname{tr}(A^\top A) = \sum_i \sigma_i^2$. Indicación: use que $\operatorname{tr}(XY) = \operatorname{tr}(YX)$.

Ejercicio 4.6 ⋆⋆⋆ Demuestre que, para toda $A \in \mathbb{R}^{m \times n}$, las matrices $A^\top A$ y $AA^\top$ tienen los mismos autovalores no nulos, con las mismas multiplicidades, sin usar la SVD.

Fuente: adaptado de Deisenroth, Faisal y Ong [1], ejercicio 4.11.

Ejercicio 4.7 ⋆⋆⋆ Demuestre que $\max_{x \neq 0} \|Ax\|/\|x\| = \sigma_1$ y que el máximo se alcanza en $x = v_1$.

Fuente: adaptado de Deisenroth, Faisal y Ong [1], ejercicio 4.12.

Tema 5

Aproximación de bajo rango y análisis de componentes principales

La SVD escribe una matriz como suma de piezas de rango 1 ordenadas por su valor singular. Este tema demuestra que quedarse con las k primeras piezas da la mejor aproximación posible de rango k (teorema de Eckart–Young [2]) y extrae tres consecuencias: la compresión de matrices, el ajuste fino de bajo rango LoRA [4] y el análisis de componentes principales (PCA). Se sigue la clase 7 de 18.065 [12], los §7.2 y §7.3 de [8], el §4.6 y el cap. 10 de [1] y el tutorial de Shlens [7].

5.1 El teorema de Eckart–Young

Sea $A = \sum_{i=1}^{r} \sigma_i u_i v_i^\top$ la SVD de $A \in \mathbb{R}^{m\times n}$ y, para $k < r$, sea

$$A_k = \sum_{i=1}^{k} \sigma_i \, u_i v_i^\top,$$

que tiene rango k y cuya SVD es la de A truncada. Como $A - A_k = \sum_{i>k} \sigma_i u_i v_i^\top$ es a su vez una SVD, la proposición 4.6 da

$$\|A - A_k\|_2 = \sigma_{k+1}, \qquad \|A - A_k\|_F = \Big(\sum_{i=k+1}^{r} \sigma_i^2 \Big)^{1/2}.$$

Lema 5.1. *Si W_1 y W_2 son subespacios de $\mathbb{R}^n$ con $\dim W_1 + \dim W_2 > n$, entonces $W_1 \cap W_2$ contiene un vector no nulo.*

Demostración. Sean $\{a_1, \dots, a_p\}$ y $\{b_1, \dots, b_q\}$ bases de W_1 y W_2, con $p + q > n$. Por el lema 1.7, los $p+q$ vectores son dependientes: $\sum_i \alpha_i a_i = \sum_j \beta_j b_j$ con algún coeficiente no nulo. Ese vector común es no nulo, porque si lo fuera, la independencia de cada base anularía todos los coeficientes. ∎

Teorema 5.2 (Eckart–Young). *Sea $A \in \mathbb{R}^{m\times n}$ con valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots$ y sea $k < \operatorname{rango}(A)$. Para toda $B \in \mathbb{R}^{m\times n}$ con $\operatorname{rango}(B) \leq k$,*

$$\|A - B\|_2 \geq \sigma_{k+1} = \|A - A_k\|_2 \qquad y \qquad \|A - B\|_F \geq \Big(\sum_{i>k} \sigma_i^2 \Big)^{1/2} = \|A - A_k\|_F.$$

Es decir, A_k es la mejor aproximación de rango a lo sumo k de A en ambas normas.

Demostración. Norma espectral. Por el teorema 1.14, $\dim \mathcal{N}(B) \geq n-k$. El subespacio $W = \operatorname{gen}\{v_1, \ldots, v_{k+1}\}$ tiene dimensión $k+1$, y $(n-k)+(k+1) > n$. Por el lema 5.1 existe un vector unitario $w \in \mathcal{N}(B) \cap W$. Escribiendo $w = \sum_{i \leq k+1} c_i v_i$ con $\sum_i c_i^2 = 1$,

$$\|(A-B)w\|^2 = \|Aw\|^2 = \Big\|\sum_{i=1}^{k+1} c_i \sigma_i u_i\Big\|^2 = \sum_{i=1}^{k+1} c_i^2 \sigma_i^2 \geq \sigma_{k+1}^2 \sum_{i=1}^{k+1} c_i^2 = \sigma_{k+1}^2.$$

Como $\|w\| = 1$, se concluye $\|A-B\|_2 \geq \sigma_{k+1}$.

Norma de Frobenius. Sea $E = A - B$ con valores singulares $\tau_1 \geq \tau_2 \geq \cdots$ y truncamientos E_j ($E_0 = 0$). Para cada $j \geq 1$, la matriz $B + E_{j-1}$ tiene rango a lo sumo $k+j-1$, y $A - (B + E_{j-1}) = E - E_{j-1}$. Por la parte ya demostrada aplicada a A con $k+j-1$ en lugar de k,

$$\sigma_{k+j} \leq \|E - E_{j-1}\|_2 = \tau_j$$

(si $k+j-1 \geq \operatorname{rango}(A)$, entonces $\sigma_{k+j} = 0$ y la desigualdad es trivial). Sumando los cuadrados, $\|A-B\|_F^2 = \sum_j \tau_j^2 \geq \sum_{j \geq 1} \sigma_{k+j}^2 = \sum_{i>k} \sigma_i^2$. ∎

La parte espectral es el teorema 4.25 de [1]; la de Frobenius es el enunciado original de Eckart y Young [2]. La desigualdad $\sigma_{k+j}(A) \leq \sigma_j(A-B)$ usada en la segunda parte es un caso de la desigualdad de Weyl para valores singulares.

Ejemplo 5.3. Con la matriz del ejemplo 4.4 y $k = 1$,

$$A_1 = 5 \cdot \frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\end{pmatrix}\frac{1}{\sqrt{2}}\begin{pmatrix}1 & 1 & 0\end{pmatrix} = \begin{pmatrix}2{,}5 & 2{,}5 & 0\\ 2{,}5 & 2{,}5 & 0\end{pmatrix},$$

y $\|A - A_1\|_F = \|A - A_1\|_2 = \sigma_2 = 3$. La fracción de la norma de Frobenius al cuadrado que conserva A_1, llamada *energía retenida*, es $\sigma_1^2/(\sigma_1^2+\sigma_2^2) = 25/34 \approx 0{,}7353$.

5.2 Compresión de matrices

Almacenar A_k requiere k columnas de U, k filas de $V^\top$ y k valores singulares: $k(m+n+1)$ números frente a los mn de A. La compresión compensa cuando $k(m+n+1) < mn$, y es eficaz cuando los valores singulares decrecen deprisa, pues entonces el error $(\sum_{i>k}\sigma_i^2)^{1/2}$ es pequeño con k pequeño.

Cuadro 5.1: Coste de almacenamiento de la aproximación de rango k.

Matriz	mn	k	$k(m+n+1)$	Fracción
Imagen de 512×512	262 144	20	20 500	7,8 %
Imagen de 1000×800	800 000	50	90 050	11,3 %
Pesos de 4096×4096	16 777 216	8	65 544	0,39 %

Una imagen en escala de grises es una matriz de intensidades. Las regiones uniformes, los bordes horizontales y verticales y los degradados suaves tienen rango bajo; los bordes diagonales y el ruido requieren muchos términos [8, §7.2]. La práctica del módulo aplica la SVD a una imagen sintética y muestra cómo decae el error con k.

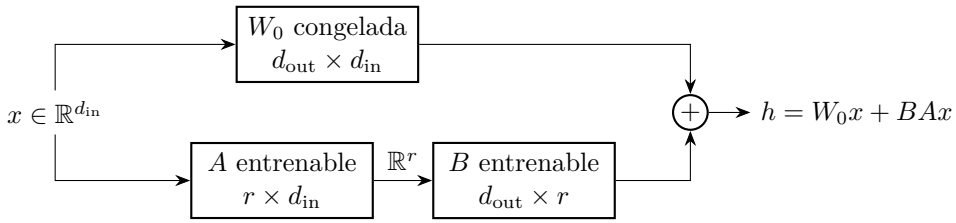


Figura 5.1: Capa lineal con LoRA. La entrada atraviesa la matriz congelada W_0 y, en paralelo, el cuello de dimensión r formado por A y B; la corrección $\Delta W = BA$ tiene rango a lo sumo r.

5.3 Ajuste fino de bajo rango

LoRA [4] parte de la hipótesis de que la modificación que el ajuste fino introduce en los pesos de un modelo preentrenado tiene un *rango intrínseco* bajo. En lugar de actualizar W_0, aprende $\Delta W = BA$ (figura 5.1), con $r(d_{\text{in}} + d_{\text{out}})$ parámetros (observación 1.18). Al terminar, BA puede sumarse a W_0, de modo que la inferencia no tiene coste adicional. El teorema 5.2 cuantifica lo que se pierde: si la actualización ideal es $\Delta W^\star$, ninguna corrección de rango r puede acercarse a ella más que $(\sum_{i>r} \sigma_i^2(\Delta W^\star))^{1/2}$ (ejercicio 5.7). La apuesta de LoRA, respaldada empíricamente en [4], es que el espectro de $\Delta W^\star$ decae deprisa.

5.4 Análisis de componentes principales

Definición 5.4 (Datos centrados y covarianza). Sean n puntos $x_1, \dots, x_n \in \mathbb{R}^d$ con media $\mu = \frac{1}{n}\sum_i x_i$. La matriz de datos centrados $X \in \mathbb{R}^{n\times d}$ tiene por filas $(x_i - \mu)^\top$. La *matriz de covarianza* es

$$C = \frac{1}{n} X^\top X \in \mathbb{R}^{d\times d}.$$

C es simétrica y semidefinida positiva (proposición 3.10). Algunos textos dividen por $n-1$ en lugar de n; el factor no cambia los autovectores. Para un vector unitario w, las proyecciones de los puntos sobre w son las componentes de Xw, que tienen media cero, y su varianza es

$$\frac{1}{n}\|Xw\|^2 = \frac{1}{n} w^\top X^\top X w = w^\top C w.$$

Teorema 5.5 (Dirección de máxima varianza). *Sean $\lambda_1 \geq \cdots \geq \lambda_d \geq 0$ los autovalores de C y $q_1, \dots, q_d$ autovectores ortonormales. La dirección unitaria w que maximiza la varianza de las proyecciones es $w = q_1$, y la varianza máxima es λ_1. Más en general, entre todos los subespacios de dimensión k, el que maximiza la varianza total de las proyecciones es $\operatorname{gen}\{q_1, \dots, q_k\}$, con varianza $\lambda_1 + \cdots + \lambda_k$.*

Demostración para $k = 1$. La varianza es $w^\top C w$ y la proposición 3.11 da su máximo, λ_1, en $w = q_1$. El caso general se demuestra por inducción, maximizando sobre los vectores ortogonales a $q_1, \dots, q_{k-1}$ [1, §10.2.2]. ∎

Los vectores q_i son las *componentes principales*, y la *varianza explicada* por la componente i es $\lambda_i / \sum_j \lambda_j$.

Teorema 5.6 (PCA mediante la SVD). *Sea $X = U\Sigma V^\top$ la SVD de la matriz de datos centrados. Entonces las componentes principales son las columnas de V, los autovalores de la*

covarianza son $\lambda_i = \sigma_i^2/n$ *y las coordenadas de los datos en las* k *primeras componentes son*

$$Z_k = XV_k = U_k\Sigma_k \in \mathbb{R}^{n\times k},$$

cuya columna i *tiene varianza* λ_i.

Demostración. $C = \frac{1}{n}X^\top X = \frac{1}{n}V\Sigma^\top U^\top U\Sigma V^\top = V\,\frac{\Sigma^\top\Sigma}{n}\,V^\top$, que es una descomposición espectral de C con autovectores v_i y autovalores σ_i^2/n. Además, $XV = U\Sigma V^\top V = U\Sigma$, y sus k primeras columnas son $\sigma_i u_i$. Su varianza es $\|\sigma_i u_i\|^2/n = \sigma_i^2/n$; la media es cero porque X está centrada. ■

La reconstrucción de los datos a partir de k componentes es $Z_kV_k^\top = U_k\Sigma_kV_k^\top = X_k$, el truncamiento de la SVD de X. Por el teorema 5.2, PCA es la mejor aproximación de rango k de los datos centrados, con error cuadrático total $\sum_{i>k}\sigma_i^2$: maximizar la varianza proyectada y minimizar el error de reconstrucción son el mismo problema [1, §10.3].

Ejemplo 5.7. Sean los puntos ya centrados $(2,2)$, $(-2,-2)$, $(1,-1)$ y $(-1,1)$. Entonces

$$X^\top X = \begin{pmatrix} 4+4+1+1 & 4+4-1-1 \\ 4+4-1-1 & 4+4+1+1 \end{pmatrix} = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix}, \qquad C = \frac{1}{4}X^\top X = \begin{pmatrix} 2{,}5 & 1{,}5 \\ 1{,}5 & 2{,}5 \end{pmatrix}.$$

Los autovalores de C son $\lambda_1 = 4$ y $\lambda_2 = 1$, y la primera componente principal es $q_1 = (1,1)/\sqrt{2}$, que explica $4/5 = 80\,\%$ de la varianza. Las proyecciones sobre q_1 son $2\sqrt{2}$, $-2\sqrt{2}$, 0 y 0, cuya varianza es $(8+8)/4 = 4 = \lambda_1$. Con la SVD, los valores singulares de X son $\sigma = (4,2)$ y $\sigma_i^2/4 = (4,1)$.

Observación 5.8 (Cálculo numérico). En la práctica se calcula la SVD de X y no la descomposición espectral de $X^\top X$: formar $X^\top X$ eleva al cuadrado el número de condición σ_1/σ_r y pierde precisión en las componentes de varianza pequeña [1, §10.4].

Observación 5.9 (Visualización de embeddings). Los embeddings de GPT-2 small tienen $d_{\text{model}} = 768$ componentes [6]. Proyectarlos sobre las dos primeras componentes principales da la imagen plana que conserva más varianza, y palabras de un mismo campo semántico suelen aparecer agrupadas. Conviene leer siempre la varianza explicada: una proyección ortogonal nunca alarga distancias, de modo que dos puntos alejados en el plano también lo están en $\mathbb{R}^{768}$, pero dos puntos cercanos en el plano pueden estar lejos en el espacio original (ejercicio 5.2). Los métodos de interpretabilidad del módulo 23 usan PCA para encontrar direcciones dominantes en las activaciones de un modelo.

Lecturas recomendadas para este tema

- MIT 18.065 [12], clase 7 «Eckart-Young: The Closest Rank k Matrix to A»; lectura: Strang [9], §I.9.
- Strang [8], §7.2 «Image Processing by Linear Algebra» y §7.3 «Principal Component Analysis (PCA by the SVD)».
- Deisenroth, Faisal y Ong [1], §4.6 «Matrix Approximation» (teorema 4.25) y cap. 10 «Dimensionality Reduction with Principal Component Analysis», §10.1–10.4.
- Shlens [7], tutorial completo.
- Hu *et al.* [4], §4 «Our Method» (formulación de LoRA).

Ejercicios del tema 5

Ejercicio 5.1 ⋆ Explique por qué PCA exige centrar los datos. ¿Qué dirección obtendría como primera componente si aplicara la receta a datos sin centrar y muy alejados del origen? Indicación: desarrolle $\frac{1}{n}\sum_i x_i x_i^\top$ en función de C y de la media μ.

Ejercicio 5.2 ⋆ El PCA de unos embeddings de dimensión 768 da varianzas explicadas 0,12 y 0,07 para las dos primeras componentes. ¿Qué fracción de la varianza muestra el gráfico bidimensional? Si dos puntos aparecen lejos en el gráfico, ¿lo están en $\mathbb{R}^{768}$? ¿Y si aparecen cerca?

Ejercicio 5.3 ⋆⋆ Sea $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$. Calcule (a) sus valores singulares; (b) el error $\|A - A_1\|_F$; (c) la energía retenida por A_1; (d) la matriz A_1.

Ejercicio 5.4 ⋆⋆ Con la SVD obtenida en el ejercicio 4.4, calcule la mejor aproximación de rango 1 de $A = \begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix}$, su error en norma de Frobenius y en norma espectral y la energía retenida.

Fuente: adaptado de Deisenroth, Faisal y Ong [1], ejercicio 4.10 (aplicado a la matriz del ejercicio 4.9).

Ejercicio 5.5 ⋆⋆ Realice el PCA de los puntos centrados $(4, 2)$, $(2, 4)$, $(-2, -4)$ y $(-4, -2)$: matriz de covarianza, autovalores, primera componente principal, varianza explicada y proyecciones sobre ella. Compruebe el resultado con el teorema 5.6.

Ejercicio 5.6 ⋆⋆ (a) Una imagen de 1000×800 se comprime con rango $k = 50$. ¿Cuántos números se almacenan y qué fracción del original suponen? ¿A partir de qué k deja de compensar? (b) Se aplica LoRA de rango $r = 16$ a una matriz de 4096×4096. ¿Cuántos parámetros se entrenan, qué porcentaje de la matriz suponen y cuál es el rango máximo de ΔW?

Ejercicio 5.7 ⋆⋆⋆ Sea $\Delta W^\star \in \mathbb{R}^{d\times n}$ con valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots$. Demuestre que

$$\min_{B\in\mathbb{R}^{d\times r},\, A\in\mathbb{R}^{r\times n}} \|\Delta W^\star - BA\|_F = \Big(\sum_{i>r} \sigma_i^2\Big)^{1/2},$$

dé matrices B y A que alcanzan el mínimo y calcule su valor para $\Delta W^\star = \operatorname{diag}(3, 2, 1)$ y $r = 1$.

Tema 6

Tensores, *broadcasting* y formas de un LLM

En el código de un modelo de lenguaje casi nunca aparecen vectores o matrices aislados, sino arrays de varios ejes que agrupan muchos vectores a la vez. Este tema formaliza esos arrays, el producto matricial por lotes y las reglas de *broadcasting*, y las aplica a las formas de las matrices de un Transformer y al rango de su capa de salida. Se sigue a Zhang *et al.* [15, §2.1 y §2.3], la documentación de NumPy [5] y el apéndice 6 de [8]; la última sección, a Yang *et al.* [14].

6.1 Tensores como arrays

Definición 6.1 (Tensor). Un *tensor* de orden k y forma $(n_1, \dots, n_k)$ es una familia de números reales $X[i_1, \dots, i_k]$ indexada por $0 \le i_j < n_j$; contiene $n_1 n_2 \cdots n_k$ elementos. Cada índice recorre un *eje*. Los escalares, vectores y matrices son tensores de orden 0, 1 y 2.

En física y en geometría diferencial, un tensor es una aplicación multilineal cuyas componentes cambian de una forma determinada al cambiar de base [8, apéndice 6]. En aprendizaje automático el término designa simplemente un array multidimensional [15, §2.3.4], y es el sentido que se usa en este curso.

Definición 6.2 (Reducción a lo largo de un eje). Sumar un tensor de forma $(n_1, \dots, n_k)$ a lo largo del eje j produce un tensor de forma $(n_1, \dots, n_{j-1}, n_{j+1}, \dots, n_k)$:

$$Y[i_1, \dots, \widehat{i_j}, \dots, i_k] = \sum_{i_j=0}^{n_j-1} X[i_1, \dots, i_k],$$

donde $\widehat{i_j}$ indica que el índice se suprime. Con la opción `keepdims=True`, el eje j se conserva con tamaño 1.

La media, el máximo y la función LSE del módulo 1 se reducen del mismo modo. En un LLM, la softmax se aplica a lo largo del último eje de los logits y la normalización por capas calcula media y varianza a lo largo del eje de d_{model}.

6.2 Producto por lotes y notación de Einstein

Definición 6.3 (Producto matricial por lotes). Sean X de forma $(\dots, m, p)$ e Y de forma $(\dots, p, q)$, con los mismos ejes iniciales (o ejes compatibles por *broadcasting*). El producto $X \mathbin{@} Y$ tiene forma $(\dots, m, q)$ y se obtiene multiplicando como matrices los dos últimos ejes para cada valor de los índices iniciales, que actúan como índices de lote.

Multiplicar una matriz de $m \times p$ por otra de $p \times q$ requiere mpq multiplicaciones. Por eso el orden en que se agrupa un producto de varias matrices afecta mucho al coste (ejercicio 6.5).

La notación de Einstein (`np.einsum`) describe estas operaciones nombrando los índices: los que aparecen en las entradas y no en la salida se suman. Por ejemplo, para Q y K de forma (B, T, d), la expresión `einsum('bid,bjd->bij', Q, K)` calcula

$$S[b, i, j] = \sum_{k} Q[b, i, k]\, K[b, j, k],$$

es decir, $S = QK^{\top}$ para cada elemento del lote, de forma (B, T, T). Es el núcleo de la atención del módulo 13. Con `@`, el mismo cálculo exige trasponer solo los dos últimos ejes: `Q @ K.transpose(0, 2, 1)`.

6.3 Broadcasting

Definición 6.4 (Reglas de *broadcasting*). Dos tensores de formas $(a_1, \ldots, a_p)$ y $(b_1, \ldots, b_q)$ se combinan elemento a elemento del siguiente modo [5]:

(i) se alinean las formas por la derecha y se completa la más corta con ejes de tamaño 1 por la izquierda;

(ii) en cada eje, los tamaños son *compatibles* si son iguales o si uno de ellos vale 1; en otro caso la operación produce un error;

(iii) el resultado tiene, en cada eje, el mayor de los dos tamaños, y el tensor con tamaño 1 en ese eje se repite a lo largo de él.

Cuadro 6.1: Ejemplos de *broadcasting* con activaciones de forma $(2, 3, 4)$.

Operación	Formas	Resultado
`x + b`	$(2,3,4) + (4,)$	$(2,3,4)$: sesgo sumado a cada token
`x - x.mean(-1, keepdims=True)`	$(2,3,4) - (2,3,1)$	$(2,3,4)$: centra cada token
`x @ W`	$(2,3,4) \,@\, (4,8)$	$(2,3,8)$: misma capa en cada token
`x + y`	$(2,3,4) + (3,)$	error: $4 \neq 3$

Observación 6.5. El *broadcasting* es la forma eficiente de escribir operaciones que en notación matemática llevan un vector de unos: si $X \in \mathbb{R}^{T \times d}$ y $b \in \mathbb{R}^{d}$, `X + b` calcula $X + \mathbf{1}b^{\top}$ sin construir la matriz $\mathbf{1}b^{\top}$. Su contrapartida es que algunas combinaciones de formas no producen error y dan un resultado no deseado; el ejercicio 6.1 muestra un caso típico. Comprobar las formas en cada paso es el hábito que más errores evita al programar un Transformer.

6.4 Formas de un LLM

El cuadro 6.2 recoge las formas de los tensores principales de un Transformer de tipo decodificador, con los valores de GPT-2 small [6]: vocabulario de $V = 50\,257$ tokens, $d_{\text{model}} = 768$, 12 cabezas de atención y contexto de 1024 tokens. Se escribe B para el tamaño del lote, T para la longitud de la secuencia y h para el número de cabezas. Las capas lineales se escriben aquí como en el código, $y = xW$ con W de forma $(d_{\text{in}}, d_{\text{out}})$.

Cuadro 6.2: Formas de los tensores de un Transformer decodificador.

Objeto	Forma	GPT-2 small, $B = 8$
Identificadores de tokens	(B, T)	$(8, 1024)$
Matriz de embeddings E	(V, d_{model})	$(50\,257, 768)$
Activaciones	(B, T, d_{model})	$(8, 1024, 768)$
Pesos de la primera capa del MLP	$(d_{\text{model}}, 4d_{\text{model}})$	$(768, 3072)$
Puntuaciones de atención	(B, h, T, T)	$(8, 12, 1024, 1024)$
Logits	(B, T, V)	$(8, 1024, 50\,257)$

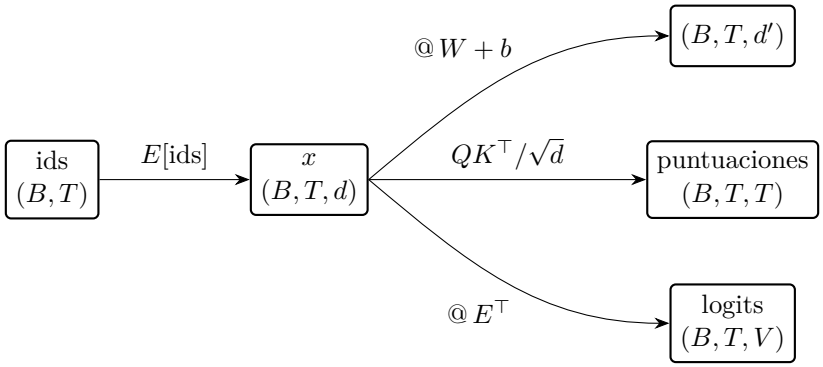


Figura 6.1: Transformaciones de forma en un LLM: búsqueda en la tabla de embeddings, capa lineal, puntuaciones de atención y logits con pesos atados.

La matriz de embeddings y el cuello de botella de la softmax

La matriz de embeddings $E \in \mathbb{R}^{V \times d_{\text{model}}}$ tiene muchas más filas que columnas. En GPT-2 small, $50\,257 \cdot 768 = 38\,597\,376$ parámetros, cerca del 31 % de los 124 millones del modelo; en Llama 2 7B [13], $32\,000 \cdot 4096 = 131\,072\,000$. GPT-2 *ata* los pesos de entrada y salida: los logits del token siguiente se calculan como $z = hE^\top$, donde $h \in \mathbb{R}^{d_{\text{model}}}$ es la última activación.

Proposición 6.6 (Cuello de botella de la softmax). *Sean N contextos con activaciones finales $h_1, \dots, h_N \in \mathbb{R}^d$, apiladas en $H \in \mathbb{R}^{N \times d}$, y sea $W \in \mathbb{R}^{V \times d}$ la matriz de salida. La matriz de logits $Z = HW^\top \in \mathbb{R}^{N \times V}$ tiene rango a lo sumo d, y la matriz de log-probabilidades L, con $L_{cj} = \ln \operatorname{softmax}(z_c)_j$, tiene rango a lo sumo $d + 1$.*

Demostración. Por la proposición 1.17, $\operatorname{rango}(Z) \le \operatorname{rango}(H) \le d$. Para cada contexto c, $\ln \operatorname{softmax}(z_c)_j = z_{cj} - \operatorname{LSE}(z_c)$, de modo que $L = Z - \ell \mathbf{1}^\top$, con $\ell_c = \operatorname{LSE}(z_c)$ y $\mathbf{1} \in \mathbb{R}^V$. La matriz $\ell \mathbf{1}^\top$ tiene rango a lo sumo 1 y, como $\mathcal{C}(L) \subseteq \mathcal{C}(Z) + \operatorname{gen}\{\ell\}$, $\operatorname{rango}(L) \le d + 1$. ∎

Yang *et al.* [14] plantean el modelado del lenguaje como una factorización de la matriz de log-probabilidades verdaderas. Si esa matriz, sobre todos los contextos posibles, tiene rango muy superior a $d + 1$, ningún modelo con salida softmax de dimensión d puede reproducirla exactamente. Con $V = 50\,257$ y $d = 768$, la restricción es severa en principio; los autores proponen una mezcla de varias softmax para superarla.

Lecturas recomendadas para este tema

– Zhang *et al.* [15], §2.1.4 «Broadcasting», §2.3.4 «Tensors», §2.3.6 «Reduction» y §2.3.10 «Matrix–Matrix Multiplication».

- Documentación de NumPy [5], «Broadcasting», reglas generales.
- Strang [8], apéndice 6 «Tensors».
- Yang *et al.* [14], §2 (formulación como factorización de matrices).

Ejercicios del tema 6

Ejercicio 6.1 ⋆ Indique la forma del resultado o si se produce un error: (a) $(16, 128, 512)$ `@` $(512, 2048)$; (b) $(16, 128, 512) + (128, 1)$; (c) $(16, 128, 512) + (16, 128)$. En el caso (b), ¿qué se ha sumado a cada rasgo? ¿Qué forma debería tener un sesgo por rasgo?

Ejercicio 6.2 ⋆ (a) Sea `X` un tensor de forma $(2, 3, 4)$. ¿Qué forma tiene la suma a lo largo de los ejes 0, 1 y 2? ¿Y con `keepdims=True`? (b) Sea `A` de forma $(3, 3)$. Explique qué calcula `A / A.sum(axis=1)` según la definición 6.4 y por qué no normaliza las filas. Corrija la expresión para que cada fila sume 1. ¿Qué ocurriría si `A` fuera de forma $(2, 3)$?

Fuente: adaptado de Zhang *et al.* [15], §2.3, ejercicios 6 y 8.

Ejercicio 6.3 ⋆⋆ (a) Calcule el número de parámetros de la matriz de embeddings de GPT-2 small y qué fracción representa de sus 124 439 808 parámetros. (b) Si GPT-2 no atara los pesos y tuviera una matriz de salida independiente de la misma forma, ¿cuántos parámetros tendría el modelo? (c) Llama 2 7B, con unos 6738 millones de parámetros, no ata los pesos. Calcule el tamaño conjunto de sus matrices de entrada y de salida y su porcentaje del total.

Ejercicio 6.4 ⋆⋆ Con $B = 8$, $h = 12$ y $T = 1024$, calcule el número de elementos del tensor de puntuaciones de atención de forma (B, h, T, T) y la memoria que ocupa con 2 bytes por elemento. ¿Por qué factor se multiplica esa memoria si se duplica la longitud del contexto?

Ejercicio 6.5 ⋆⋆ Sean $A \in \mathbb{R}^{2^{10} \times 2^{16}}$, $B \in \mathbb{R}^{2^{16} \times 2^{5}}$ y $C \in \mathbb{R}^{2^{5} \times 2^{14}}$. Calcule el número de multiplicaciones y el tamaño de la matriz intermedia al evaluar $(AB)C$ y $A(BC)$. ¿Qué orden conviene y por qué?

Fuente: adaptado de Zhang *et al.* [15], §2.3, ejercicio 10.

Ejercicio 6.6 ⋆⋆⋆ (a) Demuestre que, si la capa de salida incluye un vector de sesgo $b \in \mathbb{R}^V$, de modo que $z_c = W h_c + b$, la matriz de log-probabilidades de la proposición 6.6 tiene rango a lo sumo $d + 2$. (b) Sin sesgo, con $d = 1$, $V = 2$, $h_1 = 0$, $h_2 = 1$ y $W = (1, 0)^\top$, calcule la matriz de log-probabilidades y compruebe que tiene rango $2 = d + 1$, aunque los logits tengan rango 1. (c) Sean tres contextos cuyas distribuciones verdaderas sobre $V = 3$ tokens son $(\frac{1}{2}, \frac{1}{4}, \frac{1}{4})$, $(\frac{1}{4}, \frac{1}{2}, \frac{1}{4})$ y $(\frac{1}{4}, \frac{1}{4}, \frac{1}{2})$. Demuestre que ningún modelo sin sesgo con $d = 1$ puede representarlas exactamente.

Apéndice A

Soluciones de los ejercicios

Cada solución se presenta en cinco partes: datos, planteamiento, desarrollo, resultado y comprobación. En los pasos intermedios se redondea a cuatro cifras significativas salvo que se indique otra cosa; las raíces exactas ($\sqrt{2}$, $\sqrt{5}$) se conservan hasta el final cuando es posible. En las demostraciones, la comprobación consiste en un caso numérico o en un contraejemplo que muestra que las hipótesis son necesarias.

A.1 Tema 1

Solución del ejercicio 1.1

Planteamiento. aplicar el teorema 1.8, el lema 1.7 y el teorema 1.13.

Desarrollo.

(a) **Falsa.** $\mathbb{R}^2 = \operatorname{gen}\{e_1, e_2\}$ y, por el lema 1.7, tres vectores de $\mathbb{R}^2$ son dependientes. Por ejemplo, $(1,1) = (1,0) + (0,1)$.

(b) **Verdadera.** Las n columnas son vectores independientes de $\mathbb{R}^m$, generado por m vectores; si fuera $n > m$, el lema 1.7 las haría dependientes.

(c) **Falsa.** El rango es el número de columnas independientes, como mucho 3, y también el de filas independientes (teorema 1.13). Luego $\operatorname{rango}(A) \leq \min\{5,3\} = 3 < 4$.

Resultado. **(a) falsa; (b) verdadera; (c) falsa.**

Comprobación. en (c), una matriz de 5×3 con columnas $e_1, e_2, e_3 \in \mathbb{R}^5$ alcanza el rango máximo, que es 3.

Solución del ejercicio 1.2

Datos. $u = (1,2,3)$, $v = (1,-1)$.

Planteamiento. $(uv^\top)_{ij} = u_i v_j$; cada fila es $u_i\, v^\top$ y cada columna es $v_j\, u$.

Desarrollo.

1. Fila 1: $1 \cdot (1,-1) = (1,-1)$; fila 2: $2 \cdot (1,-1) = (2,-2)$; fila 3: $3 \cdot (1,-1) = (3,-3)$.

$$uv^\top = \begin{pmatrix} 1 & -1 \\ 2 & -2 \\ 3 & -3 \end{pmatrix}.$$

2. La columna 2 es -1 veces la columna 1, que es no nula: $\operatorname{rango}(uv^\top) = 1$ y $\mathcal{C}(uv^\top) = \operatorname{gen}\{(1,2,3)\}$.
3. Núcleo: $(uv^\top)x = u\,(v^\top x) = 0$ si y solo si $v^\top x = x_1 - x_2 = 0$. Luego $\mathcal{N}(uv^\top) = \operatorname{gen}\{(1,1)\}$.

Resultado. $uv^\top$ **es de** 3×2**, tiene rango 1; base de** $\mathcal{C}$**:** $\{(1,2,3)\}$**; base de** $\mathcal{N}$**:** $\{(1,1)\}$**.**

Comprobación. rango y nulidad: $1 + 1 = 2$, el número de columnas (teorema 1.14). Además, $uv^\top(1,1) = (1-1,\, 2-2,\, 3-3) = 0$.

Solución del ejercicio 1.3

Datos. $x_1 = (2,-1,3)$, $x_2 = (1,1,-2)$, $x_3 = (3,-3,8)$; $y = (1,-2,5)$, $z_1 = (1,1,1)$, $z_2 = (1,2,3)$, $z_3 = (2,-1,1)$.

Planteamiento. (a) buscar a, b con $x_3 = ax_1 + bx_2$, o probar que no existen; (b) resolver el sistema $c_1 z_1 + c_2 z_2 + c_3 z_3 = y$.

Desarrollo.

1. (a) Primeras dos componentes de $x_3 = ax_1 + bx_2$: $2a + b = 3$ y $-a + b = -3$. Restando, $3a = 6$, luego $a = 2$ y $b = 3 - 4 = -1$.
2. Tercera componente: $3a - 2b = 6 + 2 = 8$, que coincide con la de x_3. Por tanto, $x_3 = 2x_1 - x_2$: **son dependientes**, con relación $2x_1 - x_2 - x_3 = 0$.
3. (b) Sistema: $c_1 + c_2 + 2c_3 = 1$, $c_1 + 2c_2 - c_3 = -2$, $c_1 + 3c_2 + c_3 = 5$.
4. Restando la primera ecuación a la segunda y a la tercera: $c_2 - 3c_3 = -3$ y $2c_2 - c_3 = 4$.
5. De la primera de ellas, $c_2 = 3c_3 - 3$; sustituyendo, $6c_3 - 6 - c_3 = 4$, luego $c_3 = 2$ y $c_2 = 3$.
6. $c_1 = 1 - c_2 - 2c_3 = 1 - 3 - 4 = -6$.
7. Unicidad: la matriz cuyas columnas son z_1, z_2, z_3 es $Z = \begin{pmatrix} 1 & 1 & 2 \\ 1 & 2 & -1 \\ 1 & 3 & 1 \end{pmatrix}$. Desarrollando por la primera fila: $1\cdot(2\cdot 1 - (-1)\cdot 3) - 1\cdot(1\cdot 1 - (-1)\cdot 1) + 2\cdot(1\cdot 3 - 2\cdot 1) = 5 - 2 + 2 = 5 \neq 0$. Las z_i son una base de $\mathbb{R}^3$ y las coordenadas son únicas (proposición 1.6).

Resultado. **(a) dependientes:** $x_3 = 2x_1 - x_2$**. (b)** $y = -6z_1 + 3z_2 + 2z_3$**, de forma única porque** $\det Z = 5 \neq 0$**.**

Comprobación. $-6(1,1,1) + 3(1,2,3) + 2(2,-1,1) = (-6+3+4,\, -6+6-2,\, -6+9+2) = (1,-2,5)$.

Solución del ejercicio 1.4

Datos. $v_1 = (1,-1,0)$, $v_2 = (1,0,-1)$, $v_3 = (0,1,-1)$, $v_4 = (1,1,-2)$.

Planteamiento. buscar relaciones de dependencia; el número de independientes es el rango de la matriz de 3×4 con esas columnas.

Desarrollo.

1. $v_2 - v_1 = (1-1,\, 0+1,\, -1-0) = (0,1,-1) = v_3$. Relación: $v_1 - v_2 + v_3 = 0$.
2. $v_2 + v_3 = (1+0,\, 0+1,\, -1-1) = (1,1,-2) = v_4$. Relación: $v_2 + v_3 - v_4 = 0$.
3. v_1 y v_2 son independientes: $c_1(1,-1,0) + c_2(1,0,-1) = 0$ obliga a $c_1 = 0$ (segunda componente) y a $c_2 = 0$ (tercera componente).
4. Por los pasos 1 y 2, v_3 y v_4 son combinación de v_1 y v_2: el rango es 2 y $\{v_1, v_2\}$ es una base.

5. Las componentes de cada v_i suman cero: $1-1+0$, $1+0-1$, $0+1-1$ y $1+1-2$. El subespacio es el plano $x+y+z=0$.

Resultado. **como máximo 2 independientes; base $\{v_1, v_2\}$; el subespacio es el plano $x+y+z=0$.**

Comprobación. por el teorema 1.14, la matriz de 3×4 tiene núcleo de dimensión $4-2=2$, generado por los coeficientes de las relaciones $(1,-1,1,0)$ y $(0,1,1,-1)$. El plano tiene dimensión $3-1=2$.

Solución del ejercicio 1.5

Datos. $A=\begin{pmatrix}1&2&0&1\\2&4&1&3\\3&6&1&4\end{pmatrix}$.

Planteamiento. eliminación gaussiana para obtener los pivotes; las columnas pivote de A forman una base de $\mathcal{C}(A)$ y cada variable libre da un vector de la base de $\mathcal{N}(A)$.

Desarrollo.

1. $F_2 \leftarrow F_2-2F_1$: $(0,0,1,1)$. $F_3 \leftarrow F_3-3F_1$: $(0,0,1,1)$. $F_3 \leftarrow F_3-F_2$: $(0,0,0,0)$.
2. Forma escalonada: $\begin{pmatrix}1&2&0&1\\0&0&1&1\\0&0&0&0\end{pmatrix}$. Pivotes en las columnas 1 y 3: $\operatorname{rango}(A)=2$.
3. Base de $\mathcal{C}(A)$: columnas 1 y 3 de A, $\{(1,2,3),\,(0,1,1)\}$.
4. Núcleo: $x_3=-x_4$ y $x_1=-2x_2-x_4$, con x_2 y x_4 libres. Con $(x_2,x_4)=(1,0)$: $(-2,1,0,0)$. Con $(x_2,x_4)=(0,1)$: $(-1,0,-1,1)$.

Resultado. $\operatorname{rango}(A)=2$**.** Una base de $\mathcal{C}(A)$ la forman $(1,2,3)$ y $(0,1,1)$, y una base de $\mathcal{N}(A)$, los vectores $(-2,1,0,0)$ y $(-1,0,-1,1)$. Se cumple $2+2=4$, el número de columnas.

Comprobación. $A(-2,1,0,0)=(-2+2,\,-4+4,\,-6+6)=0$ y $A(-1,0,-1,1)=(-1+0+1,\,-2-1+3,\,-3-1+4)=0$. La fila 3 de A es la suma de las filas 1 y 2.

Solución del ejercicio 1.6

Datos. $B\in\mathbb{R}^{m\times r}$, $A\in\mathbb{R}^{r\times n}$; $\Delta W^\star\in\mathbb{R}^{d\times d}$ con $\operatorname{rango}(\Delta W^\star)>r$.

Planteamiento. comparar el espacio columna de BA con el de B, y el espacio de filas de BA con el de A.

Desarrollo.

1. Para todo x, $(BA)x=B(Ax)\in\mathcal{C}(B)$. Luego $\mathcal{C}(BA)\subseteq\mathcal{C}(B)$ y $\operatorname{rango}(BA)\le\operatorname{rango}(B)$.
2. Cada fila de BA es (fila de B)$\cdot A$, combinación lineal de las filas de A. Por tanto, $\mathcal{C}((BA)^\top)\subseteq\mathcal{C}(A^\top)$ y, por el teorema 1.13, $\operatorname{rango}(BA)=\operatorname{rango}((BA)^\top)\le\operatorname{rango}(A^\top)=\operatorname{rango}(A)$.
3. Juntando, $\operatorname{rango}(BA)\le\min\{\operatorname{rango}(A),\operatorname{rango}(B)\}$.
4. B tiene r columnas, luego $\operatorname{rango}(B)\le r$ y $\operatorname{rango}(BA)\le r$.
5. Si fuera $BA=\Delta W^\star$, ambas matrices tendrían el mismo rango; pero $\operatorname{rango}(BA)\le r<\operatorname{rango}(\Delta W^\star)$.

Resultado. $\operatorname{rango}(BA) \le \min\{\operatorname{rango} A, \operatorname{rango} B\} \le r$**, y ninguna corrección LoRA de rango r iguala una matriz de rango mayor que r.** El error mínimo que se comete se calcula en el ejercicio 5.7. ■

Comprobación. $B = (1,2)^\top$ y $A = (3,4)$ dan $BA = \begin{pmatrix} 3 & 4 \\ 6 & 8 \end{pmatrix}$, de rango $1 = r$.

A.2 Tema 2

Solución del ejercicio 2.1

Planteamiento. identificar en cada caso una condición del teorema 2.3 que se cumpla o falle.

Desarrollo.

(a) M no es invertible: $\operatorname{rango}(M) = 2 < 3$ y $M(1,1,-1) = 0$ (ejemplo 1.15).

(b) Q_θ es invertible: $\det(Q_\theta) = \cos^2\theta + \sin^2\theta = 1 \neq 0$; su inversa es $Q_\theta^\top$.

(c) No es invertible: la segunda fila es el doble de la primera, el rango es 1 y $\det = 1\cdot 4 - 2\cdot 2 = 0$.

(d) No es invertible: $(1,0,-1,2) \neq 0$ está en $\mathcal{N}(A)$, de modo que falla la condición (iii).

(e) Es invertible: es diagonal y $\det = 3\cdot 0{,}5\cdot(-1) = -1{,}5 \neq 0$; su inversa es $\operatorname{diag}(1/3,\ 2,\ -1)$.

Resultado. **invertibles: (b) y (e); singulares: (a), (c) y (d).**

Comprobación. $\operatorname{diag}(3,\ 0{,}5,\ -1)\cdot\operatorname{diag}(1/3,\ 2,\ -1) = \operatorname{diag}(1,1,1)$.

Solución del ejercicio 2.2

Datos. $A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$.

Planteamiento. proposición 2.4.

Desarrollo.

1. $\det A = 1\cdot 4 - 2\cdot 3 = -2 \neq 0$: A es invertible.
2. Matriz $\begin{pmatrix} d & -b \\ -c & a \end{pmatrix} = \begin{pmatrix} 4 & -2 \\ -3 & 1 \end{pmatrix}$.
3. Dividiendo por -2: $A^{-1} = \begin{pmatrix} -2 & 1 \\ 1{,}5 & -0{,}5 \end{pmatrix}$.
4. Fila 1 de AA^{-1}: $(1\cdot(-2) + 2\cdot 1{,}5;\ \ 1\cdot 1 + 2\cdot(-0{,}5)) = (1,0)$.
5. Fila 2 de AA^{-1}: $(3\cdot(-2) + 4\cdot 1{,}5;\ \ 3\cdot 1 + 4\cdot(-0{,}5)) = (0,1)$.
6. $\det(A^{-1}) = (-2)(-0{,}5) - 1\cdot 1{,}5 = 1 - 1{,}5 = -0{,}5$.

Resultado. $A^{-1} = \begin{pmatrix} -2 & 1 \\ 1{,}5 & -0{,}5 \end{pmatrix}$.

Comprobación. $AA^{-1} = I$ por los pasos 4 y 5, y $\det(A^{-1}) = -0{,}5 = 1/(-2) = 1/\det A$.

Solución del ejercicio 2.3

Datos. $A = \begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \\ 0 & 2 & 4 \end{pmatrix}$, $B = \begin{pmatrix} 2 & 3 & 4 \\ 3 & 4 & 5 \\ 4 & 5 & 6 \end{pmatrix}$.

Planteamiento. proposición 2.8 y regla de Sarrus para A; para B, calcular el determinante y, si es nulo, buscar un vector del núcleo.

Desarrollo.

1. Laplace por la primera fila de A: $1 \cdot (4 \cdot 4 - 6 \cdot 2) - 3 \cdot (2 \cdot 4 - 6 \cdot 0) + 5 \cdot (2 \cdot 2 - 4 \cdot 0) = 1 \cdot 4 - 3 \cdot 8 + 5 \cdot 4 = 4 - 24 + 20 = 0$.
2. Sarrus: diagonales descendentes $1 \cdot 4 \cdot 4 + 3 \cdot 6 \cdot 0 + 5 \cdot 2 \cdot 2 = 16 + 0 + 20 = 36$; ascendentes $5 \cdot 4 \cdot 0 + 1 \cdot 6 \cdot 2 + 3 \cdot 2 \cdot 4 = 0 + 12 + 24 = 36$. $\det A = 36 - 36 = 0$.
3. $\det B$ por la primera fila: $2 \cdot (4 \cdot 6 - 5 \cdot 5) - 3 \cdot (3 \cdot 6 - 5 \cdot 4) + 4 \cdot (3 \cdot 5 - 4 \cdot 4) = 2 \cdot (-1) - 3 \cdot (-2) + 4 \cdot (-1) = -2 + 6 - 4 = 0$.
4. B no es invertible. Las filas están en progresión aritmética: $F_1 - 2F_2 + F_3 = (2 - 6 + 4,\ 3 - 8 + 5,\ 4 - 10 + 6) = 0$. Lo mismo ocurre con las columnas, luego $B(1, -2, 1) = 0$.

Resultado. **(a)** $\det A = 0$ **por ambos métodos. (b)** B **no tiene inversa;** $(1, -2, 1) \in \mathcal{N}(B)$**.**

Comprobación. $B(1, -2, 1) = (2 - 6 + 4,\ 3 - 8 + 5,\ 4 - 10 + 6) = (0, 0, 0)$. En A, la segunda columna es la media de la primera y la tercera: $\frac{1}{2}\big((1, 2, 0) + (5, 6, 4)\big) = (3, 4, 2)$, lo que explica que $\det A = 0$.

Solución del ejercicio 2.4

Datos. $Q_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$.

Planteamiento. multiplicar y usar las fórmulas del coseno y del seno de una suma; para (c), $Q_\alpha^\top = Q_{-\alpha}$.

Desarrollo.

1. (a) Entrada $(1,1)$ de $Q_\alpha Q_\beta$: $\cos\alpha\cos\beta - \sin\alpha\sin\beta = \cos(\alpha + \beta)$. Entrada $(2,1)$: $\sin\alpha\cos\beta + \cos\alpha\sin\beta = \sin(\alpha + \beta)$.
2. Entrada $(1,2)$: $-\cos\alpha\sin\beta - \sin\alpha\cos\beta = -\sin(\alpha + \beta)$. Entrada $(2,2)$: $-\sin\alpha\sin\beta + \cos\alpha\cos\beta = \cos(\alpha + \beta)$. Luego $Q_\alpha Q_\beta = Q_{\alpha+\beta}$.
3. (b) $Q_{\pi/6}(2, 0) = (2\cos 30°,\ 2\sin 30°) = (\sqrt{3},\ 1) \approx (1{,}732;\ 1)$. Norma: $\sqrt{3 + 1} = 2$.
4. (c) $(Q_\alpha x)^\top (Q_\beta y) = x^\top Q_\alpha^\top Q_\beta y = x^\top Q_{-\alpha} Q_\beta y = x^\top Q_{\beta-\alpha} y$, por el apartado (a).

Resultado. $Q_\alpha Q_\beta = Q_{\alpha+\beta}$**;** $Q_{\pi/6}(2, 0) = (\sqrt{3}, 1)$**, de norma 2; el producto escalar depende solo de** $\beta - \alpha$**.** Si α y β son proporcionales a las posiciones de la consulta y de la clave, la puntuación depende solo de su diferencia.

Comprobación. con $\beta = -\alpha$, (a) da $Q_\alpha Q_{-\alpha} = Q_0 = I$, coherente con $Q_\alpha^{-1} = Q_{-\alpha}$.

Solución del ejercicio 2.5

Datos. $h_1 = (1, 1, 1, 1)$, $h_2 = (1, 1, -1, -1)$, $h_3 = (1, -1, 0, 0)$, $h_4 = (0, 0, 1, -1)$; $x = (4, 2, 5, 5)$.

Planteamiento. en una base ortogonal, $c_j = x^\top h_j / h_j^\top h_j$ (proposición 2.11); el error de suprimir términos se calcula por Pitágoras.

Desarrollo.

1. (a) $h_1^\top h_2 = 1+1-1-1 = 0$; $h_1^\top h_3 = 1-1 = 0$; $h_1^\top h_4 = 1-1 = 0$; $h_2^\top h_3 = 1-1 = 0$; $h_2^\top h_4 = -1+1 = 0$; $h_3^\top h_4 = 0$.
2. Normas: $\|h_1\| = \|h_2\| = 2$ y $\|h_3\| = \|h_4\| = \sqrt{2}$. Base ortonormal: $h_1/2$, $h_2/2$, $h_3/\sqrt{2}$, $h_4/\sqrt{2}$.
3. (b) $x^\top h_1 = 4+2+5+5 = 16$, $c_1 = 16/4 = 4$ (la media de la señal).
4. $x^\top h_2 = 4+2-5-5 = -4$, $c_2 = -4/4 = -1$.
5. $x^\top h_3 = 4-2 = 2$, $c_3 = 2/2 = 1$; $x^\top h_4 = 5-5 = 0$, $c_4 = 0$. Luego $x = 4h_1 - h_2 + h_3$.
6. (c) $\tilde{x} = 4h_1 - h_2 = (4-1,\, 4-1,\, 4+1,\, 4+1) = (3,3,5,5)$ y $x - \tilde{x} = (1,-1,0,0)$, con error cuadrático $1+1 = 2$.
7. Justificación: $x - \tilde{x} = c_3 h_3 + c_4 h_4$ y, por ortogonalidad, $\|x-\tilde{x}\|^2 = c_3^2\|h_3\|^2 + c_4^2\|h_4\|^2$.

Resultado. $x = 4h_1 - h_2 + h_3$**; la versión comprimida es** $(3,3,5,5)$**, con error cuadrático 2.**

Comprobación. $c_3^2\|h_3\|^2 + c_4^2\|h_4\|^2 = 1\cdot 2 + 0\cdot 2 = 2$. Es la misma lógica del teorema 5.2: descartar términos cuesta exactamente su energía.

Solución del ejercicio 2.6

Datos. $Q, Q_1, Q_2 \in \mathbb{R}^{n\times n}$ con $Q^\top Q = Q_1^\top Q_1 = Q_2^\top Q_2 = I$.

Planteamiento. usar $Q^\top Q = I$ y las propiedades del determinante.

Desarrollo.

1. $(Qx)^\top (Qy) = x^\top Q^\top Q y = x^\top I y = x^\top y$.
2. Tomando $y = x$: $\|Qx\|^2 = \|x\|^2$ y, como ambas normas son no negativas, $\|Qx\| = \|x\|$.
3. $1 = \det(I) = \det(Q^\top Q) = \det(Q^\top)\det(Q) = \det(Q)^2$, luego $\det Q = \pm 1$.
4. $(Q_1Q_2)^\top (Q_1Q_2) = Q_2^\top Q_1^\top Q_1 Q_2 = Q_2^\top Q_2 = I$: el producto es ortogonal.

Resultado. **las matrices ortogonales conservan productos escalares y normas, tienen determinante** ± 1 **y forman un conjunto cerrado para el producto.** ■

Comprobación. el recíproco de $\det Q = \pm 1$ es falso: diag(2, 0,5) tiene determinante 1 y no es ortogonal, porque $\|(2, 0{,}5)e_1\| = 2 \neq 1$.

A.3 Tema 3

Solución del ejercicio 3.1

Datos. I_2, $P = \operatorname{diag}(1,0)$, $J = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$, $N = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$.

Planteamiento. invertible si y solo si $\det \neq 0$; diagonalizable si y solo si hay dos autovectores independientes (teorema 3.6).

Desarrollo.

1. I_2: ya es diagonal; $\det = 1$. Diagonalizable e invertible.
2. P: ya es diagonal; $\det = 0$. Diagonalizable y no invertible.

3. J: triangular con autovalor doble 1. $J - I = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ da $v_2 = 0$, espacio propio $\text{gen}\{e_1\}$ de dimensión 1. No diagonalizable; $\det = 1$, invertible.
4. N: autovalor doble 0; $Nv = 0$ da $v_2 = 0$, espacio propio $\text{gen}\{e_1\}$. No diagonalizable; $\det = 0$, no invertible.

Resultado. **I_2: diagonalizable e invertible; P: diagonalizable, no invertible; J: invertible, no diagonalizable; N: ni lo uno ni lo otro.** Las cuatro combinaciones aparecen, luego ninguna propiedad implica la otra.

Comprobación. la invertibilidad depende de si 0 es autovalor; la diagonalizabilidad, de cuántos autovectores independientes hay. Son preguntas distintas.

Solución del ejercicio 3.2

Datos. $B = \begin{pmatrix} 4 & 1 \\ 2 & 3 \end{pmatrix}$.

Planteamiento. resolver $\det(B - \lambda I) = 0$ y, para cada raíz, $(B - \lambda I)v = 0$.

Desarrollo.

1. $\det(B - \lambda I) = (4 - \lambda)(3 - \lambda) - 2 = \lambda^2 - 7\lambda + 10$.
2. $\lambda = (7 \pm \sqrt{49 - 40})/2 = (7 \pm 3)/2$: $\lambda_1 = 5$, $\lambda_2 = 2$.
3. $\lambda = 5$: $B - 5I = \begin{pmatrix} -1 & 1 \\ 2 & -2 \end{pmatrix}$, ecuación $-v_1 + v_2 = 0$, autovector $(1, 1)$.
4. $\lambda = 2$: $B - 2I = \begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix}$, ecuación $2v_1 + v_2 = 0$, autovector $(1, -2)$.
5. $(1, 1)^\top (1, -2) = 1 - 2 = -1 \neq 0$: no son ortogonales.

Resultado. **$\lambda = 5$ con $v = (1, 1)$ y $\lambda = 2$ con $v = (1, -2)$; los autovectores no son ortogonales porque B no es simétrica ($b_{12} = 1 \neq b_{21} = 2$)** y el teorema 3.7 no se aplica.

Comprobación. $B(1, 1) = (5, 5)$ y $B(1, -2) = (2, -4)$. Traza: $4 + 3 = 7 = 5 + 2$; determinante: $12 - 2 = 10 = 5 \cdot 2$.

Solución del ejercicio 3.3

Datos. las matrices A, B y C del enunciado.

Planteamiento. A es triangular; para B se desarrolla por la fila central; C tiene rango 1.

Desarrollo.

1. A triangular superior: $\det(A - \lambda I) = (2 - \lambda)(3 - \lambda)(-1 - \lambda)$, autovalores 2, 3 y -1.
2. B: la fila 2 de $B - \lambda I$ es $(0,\, 1 - \lambda,\, 0)$; desarrollando por ella, $\det(B - \lambda I) = (1 - \lambda) \det \begin{pmatrix} -\lambda & 2 \\ 8 & -\lambda \end{pmatrix} = (1 - \lambda)(\lambda^2 - 16)$. Autovalores 1, 4 y -4.
3. $C = 3\,\mathbf{1}\mathbf{1}^\top$ con $\mathbf{1} = (1, 1, 1)$ tiene rango 1, luego $\dim \mathcal{N}(C) = 2$ y el autovalor 0 tiene dos autovectores independientes. El tercero es $C\mathbf{1} = (9, 9, 9) = 9 \cdot \mathbf{1}$. Autovalores 9, 0 y 0.
4. Trazas: A: $2 + 3 - 1 = 4$; B: $0 + 1 + 0 = 1 = 1 + 4 - 4$; C: $3 + 3 + 3 = 9 = 9 + 0 + 0$.

5. Determinantes: A: $2 \cdot 3 \cdot (-1) = -6$; B: desarrollando por la fila 2, $1 \cdot (0 \cdot 0 - 2 \cdot 8) = -16 = 1 \cdot 4 \cdot (-4)$; C: $0 = 9 \cdot 0 \cdot 0$.

Resultado. **A: 2, 3, -1. B: 1, 4, -4. C: 9, 0, 0.**

Comprobación. los pasos 4 y 5 verifican la proposición 3.4 en las tres matrices.

Solución del ejercicio 3.4

Datos. autovalores de B: 0, 2 y 3, distintos.

Planteamiento. autovalores distintos implican diagonalizable (proposición 3.5); si $Bv = \lambda v$, entonces $p(B)v = p(\lambda)v$ para todo polinomio p.

Desarrollo.

1. (a) $B = X\Lambda X^{-1}$ con $\Lambda = \operatorname{diag}(0, 2, 3)$. Multiplicar por matrices invertibles no cambia el rango, luego $\operatorname{rango}(B) = \operatorname{rango}(\Lambda) = 2$.
2. (b) $\det B = 0 \cdot 2 \cdot 3 = 0$ y $\det(B^\top B) = \det(B^\top)\det(B) = 0$.
3. (c) Si $Bv = \lambda v$: $(B^2 + I)v = (\lambda^2 + 1)v$, luego $(B^2 + I)^{-1}v = v/(\lambda^2 + 1)$.
4. Con $\lambda = 0, 2, 3$: $1/1 = 1$, $1/5 = 0{,}2$ y $1/10 = 0{,}1$.
5. (d) No. $B_1 = \operatorname{diag}(0, 2, 3)$ da $B_1^\top B_1 = \operatorname{diag}(0, 4, 9)$. La matriz triangular $B_2 = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix}$ tiene los mismos autovalores y $B_2^\top B_2 = \operatorname{diag}(0, 5, 9)$, con autovalores 0, 5 y 9.

Resultado. **(a) rango 2; (b) 0; (c) 1, 1/5 y 1/10; (d) no pueden deducirse.**

Comprobación. $B^2 + I$ es invertible porque $\lambda^2 + 1 \geq 1$. En (d), B_2 no es simétrica; solo para matrices simétricas se cumple $\sigma_i = |\lambda_i|$ (corolario 4.3).

Solución del ejercicio 3.5

Datos. $S \in \mathbb{R}^{n \times n}$ con $S^\top = S$; $Sv = \lambda v$ con $v \in \mathbb{C}^n$, $v \neq 0$.

Planteamiento. calcular el número $\bar{v}^\top S v$ de dos formas.

Desarrollo.

1. Conjugando $Sv = \lambda v$ y usando que S es real: $S\bar{v} = \bar{\lambda}\bar{v}$.
2. Primera forma: $\bar{v}^\top(Sv) = \lambda\, \bar{v}^\top v$.
3. Segunda forma: $\bar{v}^\top S v = (S^\top \bar{v})^\top v = (S\bar{v})^\top v = \bar{\lambda}\, \bar{v}^\top v$, por la simetría y el paso 1.
4. Restando: $(\lambda - \bar{\lambda})\, \bar{v}^\top v = 0$.
5. $\bar{v}^\top v = \sum_i |v_i|^2 > 0$ porque $v \neq 0$, luego $\lambda = \bar{\lambda}$ y $\lambda \in \mathbb{R}$.

Resultado. **todo autovalor de una matriz real simétrica es real.** Como $S - \lambda I$ es entonces una matriz real singular, también pueden tomarse autovectores reales. ■

Comprobación. sin simetría el resultado falla: el giro $\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ tiene autovalores $\pm i$ (cuadro 3.1).

Solución del ejercicio 3.6

Datos. $Sq_i = \lambda_i q_i$ con q_i ortonormales; $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$; $x_0 = \sum_i c_i q_i$ con $c_1 \neq 0$.

Planteamiento. en la base de autovectores, S^k multiplica cada coordenada por λ_i^k.

Desarrollo.

1. Por inducción, $S^k q_i = \lambda_i^k q_i$; por linealidad, $S^k x_0 = \sum_i c_i \lambda_i^k q_i$.
2. Sacando factor común $c_1\lambda_1^k \neq 0$: $S^k x_0 = c_1\lambda_1^k(q_1 + e_k)$, con $e_k = \sum_{i\geq 2}(c_i/c_1)(\lambda_i/\lambda_1)^k q_i$.
3. Por ortonormalidad, $\|e_k\|^2 = \sum_{i\geq 2}(c_i/c_1)^2(\lambda_i/\lambda_1)^{2k} \leq (\lambda_2/\lambda_1)^{2k}\sum_{i\geq 2}(c_i/c_1)^2$.
4. Luego $\|e_k\| \leq K|\lambda_2/\lambda_1|^k \to 0$, con $K = \left(\sum_{i\geq 2} c_i^2\right)^{1/2}/|c_1|$.
5. Normalizando: $S^k x_0/\|S^k x_0\| = s_k\,(q_1+e_k)/\|q_1+e_k\|$, con $s_k = \text{signo}(c_1\lambda_1^k) = \pm 1$. Como $e_k \perp q_1$, $\|q_1 + e_k\| = (1 + \|e_k\|^2)^{1/2} \to 1$.
6. La componente de x_k ortogonal a q_1 es $s_k\, e_k/\|q_1 + e_k\|$, de norma a lo sumo $\|e_k\| \leq K|\lambda_2/\lambda_1|^k$.

Resultado. $S^k x_0/\|S^k x_0\|$ **se aproxima a** $\pm q_1$ **(el signo alterna si** $\lambda_1 < 0$**), y su distancia a la recta** $\text{gen}\{q_1\}$ **es** $O(|\lambda_2/\lambda_1|^k)$**.** ■

Comprobación. en el ejemplo 3.12, $x_0 = (q_1 + q_2)/\sqrt{2}$, de modo que $c_1 = c_2$ y $K = 1$; tras 5 pasos, la cota es $3^{-5} \approx 0{,}004115$, y la componente de $S^5 x_0/\|S^5 x_0\|$ sobre q_2 vale $(0{,}7100 - 0{,}7042)/\sqrt{2} \approx 0{,}0041$.

A.4 Tema 4

Solución del ejercicio 4.1

Planteamiento. contrastar cada afirmación con el teorema 4.1 y el corolario 4.3.

Desarrollo.

(a) **Falsa.** El teorema 4.1 vale para cualquier $A \in \mathbb{R}^{m\times n}$; el ejemplo 4.4 trata una matriz de 2×3.

(b) **Falsa.** $\sigma_i = \sqrt{\lambda_i(A^\top A)} \geq 0$ por definición. Un signo negativo puede trasladarse siempre a u_i.

(c) **Falsa en general.** Son los valores absolutos de los autovalores: $\text{diag}(1, -2)$ tiene autovalores 1 y -2 y valores singulares 2 y 1. Es verdadera si además A es semidefinida positiva.

(d) **Verdadera.** Si $A = U\Sigma V^\top$, entonces $A^\top = V\Sigma^\top U^\top$ es una SVD de $A^\top$ con los mismos σ_i.

Resultado. **(a) falsa; (b) falsa; (c) falsa salvo que** A **sea semidefinida positiva; (d) verdadera.**

Solución del ejercicio 4.2

Datos. $A = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}$.

Planteamiento. $\sigma_i = \sqrt{\lambda_i(A^\top A)}$.

Desarrollo.

1. (a) A es simétrica, luego $A^\top A = AA^\top = A^2$. Fila 1: $(1+1,\, 1+0) = (2,1)$; fila 2: $(1+0,\, 1+0) = (1,1)$. $A^\top A = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$.
2. (b) $\det(A^\top A - \lambda I) = (2-\lambda)(1-\lambda) - 1 = \lambda^2 - 3\lambda + 1$, con raíces $\lambda = (3 \pm \sqrt{5})/2$, es decir, 2,618 y 0,3820.
3. $\sigma_1 = \sqrt{2{,}618} = 1{,}618$ y $\sigma_2 = \sqrt{0{,}3820} = 0{,}6180$.
4. (c) $\big((1+\sqrt{5})/2\big)^2 = (6+2\sqrt{5})/4 = (3+\sqrt{5})/2$ y $\big((\sqrt{5}-1)/2\big)^2 = (6-2\sqrt{5})/4 = (3-\sqrt{5})/2$.
5. Los autovalores de A son las raíces de $\lambda^2 - \lambda - 1 = 0$, $(1 \pm \sqrt{5})/2 \approx 1{,}618$ y $-0{,}6180$. Como A es simétrica, el corolario 4.3(iv) da $\sigma_i = |\lambda_i|$.

Resultado. $\sigma_1 = (1+\sqrt{5})/2 \approx 1{,}618$ **y** $\sigma_2 = (\sqrt{5}-1)/2 \approx 0{,}6180$, los valores absolutos de los autovalores de A, porque A es simétrica.

Comprobación. $\sigma_1\sigma_2 = (5-1)/4 = 1 = |\det A|$ y $\sigma_1^2 + \sigma_2^2 = 3 = \|A\|_F^2 = 1+1+1+0$.

Solución del ejercicio 4.3

Datos. columnas ortogonales w_j con $\|w_j\| = s_j > 0$; $A = \begin{pmatrix} 2 & 1 \\ 1 & 0 \\ 2 & -1 \end{pmatrix}$.

Planteamiento. $(A^\top A)_{ij} = w_i^\top w_j$; comparar con $A^\top A = V\Sigma^\top\Sigma V^\top$.

Desarrollo.

1. $(A^\top A)_{ij} = w_i^\top w_j$ vale 0 si $i \neq j$ y s_i^2 si $i = j$: $A^\top A = \operatorname{diag}(s_1^2, \ldots, s_n^2)$.
2. $A^\top A$ ya es diagonal: $V = I$ (con las columnas ordenadas de mayor a menor norma), $\Sigma = \operatorname{diag}(s_1, \ldots, s_n)$ y, de $AV = U\Sigma$, $u_j = w_j/s_j$.
3. Caso numérico: $w_1 = (2,1,2)$ y $w_2 = (1,0,-1)$, con $w_1^\top w_2 = 2+0-2 = 0$.
4. $s_1 = \sqrt{4+1+4} = 3$ y $s_2 = \sqrt{1+0+1} = \sqrt{2} \approx 1{,}414$; $A^\top A = \operatorname{diag}(9,2)$.
5. $u_1 = (2,1,2)/3$ y $u_2 = (1,0,-1)/\sqrt{2}$; para la SVD completa se añade u_3 unitario y ortogonal a ambos, $u_3 = (1,-4,1)/\sqrt{18}$.

Resultado. $A^\top A = \operatorname{diag}(s_j^2)$**,** $V = I$**,** $\Sigma = \operatorname{diag}(s_j)$ **y** U **tiene por columnas las** w_j **normalizadas. En el ejemplo,** $\sigma = (3, \sqrt{2})$**.**

Comprobación. $[\,3u_1 \mid \sqrt{2}\,u_2\,] = [(2,1,2) \mid (1,0,-1)] = A$ y $\|A\|_F^2 = 4+1+1+0+4+1 = 11 = 9+2$. Además, $u_3^\top u_1 = (2-4+2)/(3\sqrt{18}) = 0$ y $u_3^\top u_2 = (1-1)/6 = 0$.

Solución del ejercicio 4.4

Datos. $A = \begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix}$.

Planteamiento. autovectores de $A^\top A$ y $u_i = Av_i/\sigma_i$.

Desarrollo.

1. $A^\top A = \begin{pmatrix} 2 & -1 \\ 2 & 1 \end{pmatrix}\begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} 4+1 & 4-1 \\ 4-1 & 4+1 \end{pmatrix} = \begin{pmatrix} 5 & 3 \\ 3 & 5 \end{pmatrix}$.

2. $(5-\lambda)^2 = 9$, luego $\lambda = 8$ y $\lambda = 2$: $\sigma_1 = \sqrt{8} = 2\sqrt{2} \approx 2{,}828$ y $\sigma_2 = \sqrt{2} \approx 1{,}414$.
3. Autovectores: $v_1 = (1,1)/\sqrt{2}$ para $\lambda = 8$ y $v_2 = (-1,1)/\sqrt{2}$ para $\lambda = 2$.
4. $u_1 = Av_1/\sigma_1 = (4,0)/(\sqrt{2}\cdot 2\sqrt{2}) = (1,0)$.
5. $u_2 = Av_2/\sigma_2 = (-2+2,\ 1+1)/(\sqrt{2}\cdot\sqrt{2}) = (0,2)/2 = (0,1)$.

Resultado. $U = I_2$, $\Sigma = \operatorname{diag}(2\sqrt{2}, \sqrt{2})$, $V = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$.

Comprobación. $U\Sigma V^\top = \begin{pmatrix} 2\sqrt{2} & 0 \\ 0 & \sqrt{2} \end{pmatrix}\frac{1}{\sqrt{2}}\begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix} = A$. También $\sigma_1\sigma_2 = 4 = |\det A| = |2+2|$.

Solución del ejercicio 4.5

Datos. $A \in \mathbb{R}^{m\times n}$ con SVD $A = U\Sigma V^\top$.

Planteamiento. expresar $\|A\|_F^2$ como una traza y usar $\operatorname{tr}(XY) = \operatorname{tr}(YX)$.

Desarrollo.

1. $(A^\top A)_{jj} = \sum_i a_{ij}^2$; sumando en j, $\operatorname{tr}(A^\top A) = \sum_{i,j} a_{ij}^2 = \|A\|_F^2$.
2. $A^\top A = V\Sigma^\top U^\top U\Sigma V^\top = V(\Sigma^\top\Sigma)V^\top$, porque $U^\top U = I$.
3. $\operatorname{tr}(V(\Sigma^\top\Sigma)V^\top) = \operatorname{tr}((\Sigma^\top\Sigma)V^\top V) = \operatorname{tr}(\Sigma^\top\Sigma)$, porque $V^\top V = I$.
4. $\Sigma^\top\Sigma = \operatorname{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0)$, de traza $\sum_i \sigma_i^2$.

Resultado. $\|A\|_F^2 = \operatorname{tr}(A^\top A) = \sum_i \sigma_i^2$. ■

Comprobación. para el ejemplo 4.4: $9+4+4+4+9+4 = 34 = 25+9$.

Solución del ejercicio 4.6

Datos. $A \in \mathbb{R}^{m\times n}$.

Planteamiento. transportar autovectores de $A^\top A$ a $AA^\top$ mediante $v \mapsto Av$ y viceversa.

Desarrollo.

1. Sea $A^\top Av = \lambda v$ con $v \neq 0$ y $\lambda \neq 0$. Entonces $Av \neq 0$, pues en otro caso $\lambda v = A^\top(Av) = 0$.
2. $AA^\top(Av) = A(A^\top Av) = \lambda\, Av$: λ es autovalor de $AA^\top$ con autovector Av.
3. Multiplicidades: la aplicación $v \mapsto Av$ es inyectiva sobre el espacio propio E_λ de $A^\top A$, porque si $Av = 0$ con $v \in E_\lambda$, entonces $\lambda v = 0$ y $v = 0$. Lleva E_λ al espacio propio de λ en $AA^\top$, luego $\dim E_\lambda(A^\top A) \le \dim E_\lambda(AA^\top)$.
4. Intercambiando los papeles de A y $A^\top$ se obtiene la desigualdad contraria.
5. Ambas matrices son simétricas y, por tanto, diagonalizables (teorema 3.8): la multiplicidad de cada autovalor es la dimensión de su espacio propio.

Resultado. **$A^\top A$ y $AA^\top$ tienen los mismos autovalores no nulos con las mismas multiplicidades**; difieren solo en el número de ceros, $n-r$ frente a $m-r$. ■

Comprobación. en el ejemplo 4.4, $AA^\top$ tiene autovalores 25 y 9, y $A^\top A$, de orden 3, tiene 25, 9 y 0.

Solución del ejercicio 4.7

Datos. $A \in \mathbb{R}^{m\times n}$ con SVD $A = \sum_i \sigma_i u_i v_i^\top$.

Planteamiento. escribir x en la base ortonormal $\{v_i\}$ de $\mathbb{R}^n$.

Desarrollo.

1. $x = \sum_{i=1}^{n} c_i v_i$ con $\|x\|^2 = \sum_i c_i^2$ (proposición 2.11).
2. $Ax = \sum_{i\le r} c_i \sigma_i u_i$ y, por ortonormalidad de los u_i, $\|Ax\|^2 = \sum_{i\le r} c_i^2\sigma_i^2$.
3. $\sum_{i\le r} c_i^2\sigma_i^2 \le \sigma_1^2 \sum_i c_i^2 = \sigma_1^2\|x\|^2$, luego $\|Ax\|/\|x\| \le \sigma_1$.
4. Con $x = v_1$: $Av_1 = \sigma_1 u_1$ y $\|Av_1\|/\|v_1\| = \sigma_1$.

Resultado. $\|A\|_2 = \max_{x\neq 0}\|Ax\|/\|x\| = \sigma_1$**, alcanzado en** v_1**.** ■

Comprobación. en el ejercicio 4.4, $\|Av_1\| = \|(4,0)/\sqrt{2}\| = 2\sqrt{2} = \sigma_1$, y e_2 da $\|Ae_2\| = \|(2,1)\| = \sqrt{5} \approx 2{,}236 < 2{,}828$.

A.5 Tema 5

Solución del ejercicio 5.1

Datos. n puntos x_i con media μ y covarianza $C = \frac{1}{n}\sum_i (x_i-\mu)(x_i-\mu)^\top$.

Planteamiento. PCA busca la dirección de mayor dispersión alrededor de la media; se compara C con la matriz sin centrar $\frac{1}{n}\sum_i x_i x_i^\top$.

Desarrollo.

1. Escribiendo $x_i = (x_i-\mu)+\mu$: $\frac{1}{n}\sum_i x_i x_i^\top = C + \frac{1}{n}\sum_i\big[(x_i-\mu)\mu^\top + \mu(x_i-\mu)^\top\big] + \mu\mu^\top$.
2. Los términos cruzados se anulan porque $\sum_i (x_i-\mu) = 0$: $\frac{1}{n}\sum_i x_i x_i^\top = C + \mu\mu^\top$.
3. Si los datos están lejos del origen, $\|\mu\|^2$ domina sobre los autovalores de C, y $\mu\mu^\top$ es de rango 1 con autovector $\mu/\|\mu\|$.
4. La primera «componente» apunta entonces hacia la media, es decir, describe la posición de la nube y no la dirección en la que se estira.

Resultado. **hay que centrar porque PCA debe medir dispersión, no posición; sin centrar, la primera componente se aproxima a** $\mu/\|\mu\|$**.**

Comprobación. con los puntos $(101, 99)$ y $(99, 101)$, la nube se estira en la dirección $(1,-1)$: centrada, $C = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$, con autovector principal $(1,-1)/\sqrt{2}$. Sin centrar, $\frac{1}{2}\sum_i x_i x_i^\top = \begin{pmatrix} 10\,001 & 9999 \\ 9999 & 10\,001 \end{pmatrix}$, cuyo autovector principal es $(1,1)/\sqrt{2}$, con autovalor 20 000.

Solución del ejercicio 5.2

Datos. varianzas explicadas 0,12 y 0,07; dimensión 768.

Planteamiento. las varianzas explicadas se suman; una proyección ortogonal no alarga distancias.

Desarrollo.

1. Fracción mostrada: $0{,}12 + 0{,}07 = 0{,}19$, el 19 %. El 81 % restante queda oculto.
2. Sea P la proyección ortogonal sobre el plano de las dos componentes. Por Pitágoras, $\|x-y\|^2 = \|P(x-y)\|^2 + \|(I-P)(x-y)\|^2 \geq \|P(x-y)\|^2$.
3. Lejos en el gráfico implica lejos en $\mathbb{R}^{768}$: la distancia real es al menos la del gráfico.
4. Cerca en el gráfico no implica nada: los puntos pueden diferir mucho en las direcciones descartadas.

Resultado. **el gráfico muestra el 19 % de la varianza. Las separaciones son fiables; las cercanías, no.**

Comprobación. $(0,0,5)$ y $(0,0,-5)$ se proyectan sobre el mismo punto del plano xy y están a distancia 10.

Solución del ejercicio 5.3

Datos. $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$.

Planteamiento. $\sigma_i = \sqrt{\lambda_i(A^\top A)}$; por el teorema 5.2, $\|A - A_1\|_F = \sigma_2$; energía $\sigma_1^2/(\sigma_1^2+\sigma_2^2)$.

Desarrollo.

1. $A^\top A$: entrada $(1,1) = 9+16 = 25$, $(1,2) = 0+20 = 20$, $(2,2) = 0+25 = 25$. $A^\top A = \begin{pmatrix} 25 & 20 \\ 20 & 25 \end{pmatrix}$.
2. $(25-\lambda)^2 = 400$, luego $\lambda = 45$ y $\lambda = 5$.
3. (a) $\sigma_1 = \sqrt{45} = 3\sqrt{5} \approx 6{,}708$ y $\sigma_2 = \sqrt{5} \approx 2{,}236$.
4. (b) $\|A - A_1\|_F = \sigma_2 = \sqrt{5} \approx 2{,}236$.
5. (c) Energía: $45/(45+5) = 0{,}9$.
6. (d) $v_1 = (1,1)/\sqrt{2}$; $Av_1 = (3,9)/\sqrt{2}$; $u_1 = Av_1/\sigma_1 = (3,9)/(\sqrt{2}\cdot 3\sqrt{5}) = (1,3)/\sqrt{10}$.
7. $A_1 = \sigma_1 u_1 v_1^\top = 3\sqrt{5}\cdot \frac{1}{\sqrt{20}} \begin{pmatrix} 1 & 1 \\ 3 & 3 \end{pmatrix} = \frac{3}{2}\begin{pmatrix} 1 & 1 \\ 3 & 3 \end{pmatrix}$.

Resultado. **(a)** $\sigma_1 = 3\sqrt{5} \approx 6{,}708$, $\sigma_2 = \sqrt{5} \approx 2{,}236$; **(b)** $\approx 2{,}236$; **(c)** 90 %; **(d)** $A_1 = \begin{pmatrix} 1{,}5 & 1{,}5 \\ 4{,}5 & 4{,}5 \end{pmatrix}$.

Comprobación. $A - A_1 = \begin{pmatrix} 1{,}5 & -1{,}5 \\ -0{,}5 & 0{,}5 \end{pmatrix}$, con $\|A - A_1\|_F^2 = 2{,}25 + 2{,}25 + 0{,}25 + 0{,}25 = 5$. Además, $\|A\|_F^2 = 9+16+25 = 50 = 45+5$ y $\sigma_1\sigma_2 = 15 = |\det A|$.

Solución del ejercicio 5.4

Datos. SVD del ejercicio 4.4: $\sigma_1 = 2\sqrt{2}$, $\sigma_2 = \sqrt{2}$, $u_1 = (1,0)$, $v_1 = (1,1)/\sqrt{2}$.

Planteamiento. $A_1 = \sigma_1 u_1 v_1^\top$ y teorema 5.2.

Desarrollo.

1. $A_1 = 2\sqrt{2}\begin{pmatrix} 1 \\ 0 \end{pmatrix}\frac{1}{\sqrt{2}}\begin{pmatrix} 1 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 2 \\ 0 & 0 \end{pmatrix}$.

2. $A - A_1 = \begin{pmatrix} 0 & 0 \\ -1 & 1 \end{pmatrix}$, con $\|A - A_1\|_F = \sqrt{2}$.
3. $A - A_1 = \sigma_2 u_2 v_2^\top$ tiene un único valor singular, luego $\|A - A_1\|_2 = \sigma_2 = \sqrt{2}$.
4. Energía retenida: $\sigma_1^2/(\sigma_1^2 + \sigma_2^2) = 8/10 = 0{,}8$.

Resultado. $A_1 = \begin{pmatrix} 2 & 2 \\ 0 & 0 \end{pmatrix}$**; error** $\sqrt{2} \approx 1{,}414$ **en ambas normas; energía retenida** $80\,\%$**.**

Comprobación. $\|A\|_F^2 = 4 + 4 + 1 + 1 = 10 = 8 + 2$ y $\|A_1\|_F^2 = 8 = \sigma_1^2$.

Solución del ejercicio 5.5

Datos. puntos $(4, 2)$, $(2, 4)$, $(-2, -4)$, $(-4, -2)$; $n = 4$.

Planteamiento. $C = X^\top X/n$; autovalores y autovectores de C; proyecciones $z_i = x_i^\top q_1$.

Desarrollo.

1. Media: $\big((4 + 2 - 2 - 4)/4,\ (2 + 4 - 4 - 2)/4\big) = (0, 0)$; los datos ya están centrados.
2. $\sum x_i^2 = 16 + 4 + 4 + 16 = 40$, $\sum y_i^2 = 4 + 16 + 16 + 4 = 40$ y $\sum x_i y_i = 8 + 8 + 8 + 8 = 32$.
3. $C = \frac{1}{4}\begin{pmatrix} 40 & 32 \\ 32 & 40 \end{pmatrix} = \begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix}$.
4. $(10 - \lambda)^2 = 64$: $\lambda_1 = 18$ y $\lambda_2 = 2$.
5. $\lambda_1 = 18$: $C - 18I = \begin{pmatrix} -8 & 8 \\ 8 & -8 \end{pmatrix}$, luego $q_1 = (1, 1)/\sqrt{2}$. Varianza explicada: $18/20 = 0{,}9$.
6. Proyecciones $z = (x + y)/\sqrt{2}$: $6/\sqrt{2} = 3\sqrt{2} \approx 4{,}243$ para los dos primeros puntos y $-3\sqrt{2} \approx -4{,}243$ para los dos últimos.

Resultado. $C = \begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix}$**;** $\lambda = 18$ **y** 2**;** $q_1 = (1, 1)/\sqrt{2}$ **explica el** $90\,\%$**; proyecciones** $(4{,}243;\ 4{,}243;\ -4{,}243;\ -4{,}243)$**.**

Comprobación. varianza de las proyecciones: $4 \cdot 18/4 = 18 = \lambda_1$. Por el teorema 5.6, los valores singulares de X deben ser $\sqrt{4 \cdot 18} = \sqrt{72} \approx 8{,}485$ y $\sqrt{4 \cdot 2} = \sqrt{8} \approx 2{,}828$, como confirma el cálculo numérico.

Solución del ejercicio 5.6

Datos. (a) $m \times n = 1000 \times 800$, $k = 50$; (b) $d_{\text{in}} = d_{\text{out}} = 4096$, $r = 16$.

Planteamiento. A_k cuesta $k(m + n + 1)$ números; LoRA entrena $r(d_{\text{in}} + d_{\text{out}})$ parámetros.

Desarrollo.

1. (a) $50 \cdot (1000 + 800 + 1) = 50 \cdot 1801 = 90\,050$ números.
2. Original: $1000 \cdot 800 = 800\,000$. Fracción: $90\,050/800\,000 = 0{,}1126 \approx 11{,}3\,\%$.
3. Umbral: $1801\,k < 800\,000 \iff k < 444{,}2$. Con $k = 444$: $799\,644 < 800\,000$; con $k = 445$: $801\,445 > 800\,000$.
4. (b) $16 \cdot (4096 + 4096) = 16 \cdot 8192 = 131\,072$ parámetros.
5. $4096^2 = 16\,777\,216$; porcentaje: $131\,072/16\,777\,216 = 0{,}0078125 = 0{,}78\,\%$.
6. Por la proposición 1.17, $\text{rango}(\Delta W) = \text{rango}(BA) \leq 16$.

Resultado. **(a) 90 050 números (11,3 %); deja de compensar a partir de $k = 445$. (b) 131 072 parámetros (0,78 %);** rango$(\Delta W) \leq 16$**.**

Comprobación. (b) duplica los valores de la observación 1.18 (65 536 y 0,39 % con $r = 8$), como corresponde a duplicar r. En (a), el rango máximo de la imagen es $800 > 445$: la compresión deja de compensar antes de ser exacta.

Solución del ejercicio 5.7

Datos. $\Delta W^\star = \sum_i \sigma_i u_i v_i^\top$; matrices $B \in \mathbb{R}^{d\times r}$, $A \in \mathbb{R}^{r\times n}$.

Planteamiento. el conjunto de productos BA coincide con el de matrices de rango a lo sumo r; después se aplica el teorema 5.2.

Desarrollo.

1. Por la proposición 1.17, todo producto BA tiene rango $\leq r$.
2. Por el teorema 5.2, para toda matriz de rango $\leq r$, $\|\Delta W^\star - BA\|_F \geq (\sum_{i>r} \sigma_i^2)^{1/2}$.
3. La cota se alcanza: $B = U_r\Sigma_r = [\sigma_1 u_1 \mid \cdots \mid \sigma_r u_r]$ y $A = V_r^\top$ dan $BA = \sum_{i\leq r} \sigma_i u_i v_i^\top = \Delta W_r^\star$.
4. Caso numérico: diag$(3, 2, 1)$ tiene valores singulares 3, 2 y 1 con $u_i = v_i = e_i$. Con $r = 1$, $B = 3e_1$, $A = e_1^\top$, $BA = \text{diag}(3, 0, 0)$.
5. Error: $\|\text{diag}(0, 2, 1)\|_F = \sqrt{4+1} = \sqrt{5} \approx 2{,}236$.

Resultado. **el mínimo es $(\sum_{i>r} \sigma_i^2)^{1/2}$, alcanzado por $B = U_r\Sigma_r$, $A = V_r^\top$; es nulo solo si** rango$(\Delta W^\star) \leq r$**. En el ejemplo, $\sqrt{5} \approx 2{,}236$.** ■

Comprobación. la factorización no es única: $B = U_r$ y $A = \Sigma_r V_r^\top$, o BG y $G^{-1}A$ con cualquier $G \in \mathbb{R}^{r\times r}$ invertible, dan el mismo producto. En el ejemplo, $B = e_1$ y $A = 3e_1^\top$ también alcanzan el mínimo.

A.6 Tema 6

Solución del ejercicio 6.1

Planteamiento. `@` contrae el último eje del primer operando con el penúltimo del segundo; el *broadcasting* alinea por la derecha (definición 6.4).

Desarrollo.

1. (a) $512 = 512$: el resultado es $(16, 128, 2048)$.
2. (b) Se alinea $(16, 128, 512)$ con $(\cdot, 128, 1)$. Último eje: 512 frente a 1, se repite. Penúltimo: $128 = 128$. Primero: falta, se trata como 1 y se repite 16 veces. Resultado $(16, 128, 512)$.
3. (c) Se alinea $(16, 128, 512)$ con $(\cdot, 16, 128)$. Último eje: 512 frente a 128, ni iguales ni 1: error.
4. En (b), cada posición t recibe un único número, el mismo para sus 512 rasgos. Un sesgo por rasgo debe tener forma $(512,)$.

Resultado. **(a)** $(16, 128, 2048)$**; (b)** $(16, 128, 512)$**, pero suma un valor por posición, no por rasgo; (c) error.**

Comprobación. en NumPy, (a) y (b) dan esas formas y (c) produce el error «operands could not be broadcast together».

Solución del ejercicio 6.2

Datos. `X` de forma $(2, 3, 4)$; `A` de forma $(3, 3)$ o $(2, 3)$.

Planteamiento. una suma a lo largo de un eje lo elimina (o lo deja con tamaño 1 con `keepdims`); después se aplica la definición 6.4.

Desarrollo.

1. (a) Eje 0: $(3, 4)$; eje 1: $(2, 4)$; eje 2: $(2, 3)$. Con `keepdims=True`: $(1, 3, 4)$, $(2, 1, 4)$ y $(2, 3, 1)$.
2. (b) `A.sum(axis=1)` tiene forma $(3,)$ y contiene las sumas de las filas, $s_i = \sum_j a_{ij}$.
3. Al dividir, $(3, 3)/(3,)$ alinea el vector con el *último* eje: el elemento (i, j) se divide por s_j, la suma de la fila j, no por s_i.
4. Corrección: `A / A.sum(axis=1, keepdims=True)`, de forma $(3, 3)/(3, 1)$, divide el elemento (i, j) por s_i.
5. Si `A` es de $(2, 3)$, `A.sum(axis=1)` es de $(2,)$ y $(2, 3)/(2,)$ compara 3 con 2 en el último eje: error.

Resultado. **(a)** $(3, 4)$**,** $(2, 4)$**,** $(2, 3)$**. (b) divide cada columna** j **por la suma de la fila** j**; la versión correcta conserva el eje con tamaño 1; con forma** $(2, 3)$ **se produce un error.**

Comprobación. con $A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 2 & 2 \\ 1 & 1 & 1 \end{pmatrix}$, las sumas de filas son $(2, 4, 3)$; la versión correcta da la primera fila (0,5; 0,5; 0), que suma 1, y la incorrecta da (1/2, 1/4, 0), que suma 0,75.

Solución del ejercicio 6.3

Datos. GPT-2 small: $V = 50\,257$, $d_{\text{model}} = 768$, 124 439 808 parámetros. Llama 2 7B: $V = 32\,000$, $d_{\text{model}} = 4096$, unos 6738 millones de parámetros.

Planteamiento. la matriz de embeddings tiene $V \cdot d_{\text{model}}$ parámetros; sin pesos atados hay dos matrices de esa forma.

Desarrollo.

1. (a) $50\,257 \cdot 768 = 38\,597\,376$; fracción: $38\,597\,376/124\,439\,808 = 0{,}3102 \approx 31{,}0\,\%$.
2. (b) $124\,439\,808 + 38\,597\,376 = 163\,037\,184$ parámetros.
3. (c) Una matriz: $32\,000 \cdot 4096 = 131\,072\,000$; dos: 262 144 000.
4. Porcentaje: $262\,144\,000/(6738 \cdot 10^6) \approx 0{,}0389 = 3{,}89\,\%$.

Resultado. **(a)** 38 597 376 **(31 %); (b)** 163 037 184**; (c)** 262 144 000**, alrededor del** 3,9 % **de Llama 2 7B.**

Comprobación. en un modelo pequeño la tabla de embeddings es una fracción grande del total; al crecer d_{model} y el número de capas, el resto de parámetros crece más deprisa que Vd_{model}, y la fracción disminuye.

Solución del ejercicio 6.4

Datos. forma $(8, 12, 1024, 1024)$; 2 bytes por elemento.

Planteamiento. número de elementos = producto de los tamaños de los ejes.

Desarrollo.

1. $8 \cdot 12 = 96$; $1024 \cdot 1024 = 1\,048\,576$; $96 \cdot 1\,048\,576 = 100\,663\,296$ elementos.
2. Memoria: $100\,663\,296 \cdot 2 = 201\,326\,592$ bytes $\approx 201{,}3$ MB (192 MiB).
3. Con $T = 2048$, el factor T^2 pasa de 1024^2 a $2048^2 = 4 \cdot 1024^2$: la memoria se multiplica por 4.

Resultado. $100\,663\,296$ **elementos, unos** 201 **MB por capa; duplicar el contexto cuadruplica la memoria.**

Comprobación. $201\,326\,592/2^{20} = 192$ exactamente, porque $96 \cdot 2^{20} \cdot 2/2^{20} = 192$. El crecimiento cuadrático con T es la razón de ser de las implementaciones de atención que no almacenan la matriz completa (módulo 17).

Solución del ejercicio 6.5

Datos. $A \in \mathbb{R}^{2^{10} \times 2^{16}}$, $B \in \mathbb{R}^{2^{16} \times 2^{5}}$, $C \in \mathbb{R}^{2^{5} \times 2^{14}}$.

Planteamiento. un producto de $m \times p$ por $p \times q$ cuesta mpq multiplicaciones y produce mq elementos.

Desarrollo.

1. $(AB)C$: AB cuesta $2^{10} \cdot 2^{16} \cdot 2^{5} = 2^{31}$ y es de $2^{10} \times 2^{5}$ ($2^{15} = 32\,768$ elementos). Después, $(AB)C$ cuesta $2^{10} \cdot 2^{5} \cdot 2^{14} = 2^{29}$.
2. Total: $2^{31} + 2^{29} = 5 \cdot 2^{29} = 2\,684\,354\,560 \approx 2{,}68 \cdot 10^{9}$.
3. $A(BC)$: BC cuesta $2^{16} \cdot 2^{5} \cdot 2^{14} = 2^{35}$ y es de $2^{16} \times 2^{14}$ ($2^{30} \approx 1{,}07 \cdot 10^{9}$ elementos, 4 GiB en 32 bits). Después, $A(BC)$ cuesta $2^{10} \cdot 2^{16} \cdot 2^{14} = 2^{40}$.
4. Total: $2^{40} + 2^{35} = 33 \cdot 2^{35} \approx 1{,}134 \cdot 10^{12}$.
5. Cociente: $(33 \cdot 2^{35})/(5 \cdot 2^{29}) = 33 \cdot 64/5 = 422{,}4$.

Resultado. **conviene** $(AB)C$**: unas 422 veces menos operaciones y una matriz intermedia de** $32\,768$ **elementos frente a** 2^{30}**.** El motivo es que B estrecha la dimensión intermedia a 2^5: conviene aplicarla primero.

Comprobación. ambos órdenes dan el mismo resultado de $2^{10} \times 2^{14}$, por la asociatividad del producto. Es la misma razón por la que LoRA calcula $B(Ax)$ y no $(BA)x$: con $r \ll d$, el primero cuesta $r(d_{\text{in}} + d_{\text{out}})$ multiplicaciones por token.

Solución del ejercicio 6.6

Datos. $Z = HW^{\top}$ (con sesgo, $Z = HW^{\top} + \mathbf{1}_N b^{\top}$); $L = Z - \ell \mathbf{1}_V^{\top}$ con $\ell_c = \text{LSE}(z_c)$.

Planteamiento. cada término de rango 1 añadido aumenta el rango como mucho en 1, porque $\text{rango}(X + Y) \leq \text{rango}(X) + \text{rango}(Y)$ (el espacio columna de $X + Y$ está contenido en $\mathcal{C}(X) + \mathcal{C}(Y)$).

Desarrollo.

1. (a) $\operatorname{rango}(HW^\top) \le d$ (proposición 1.17); $\mathbf{1}_N b^\top$ y $\ell \mathbf{1}_V^\top$ tienen rango ≤ 1. Luego $\operatorname{rango}(L) \le d + 1 + 1 = d + 2$.
2. (b) $z_1 = Wh_1 = (0, 0)$ y $z_2 = Wh_2 = (1, 0)$. $\operatorname{LSE}(0, 0) = \ln 2$ y $\operatorname{LSE}(1, 0) = \ln(1 + e) \approx 1{,}313$.
3. $L = \begin{pmatrix} -\ln 2 & -\ln 2 \\ 1 - \ln(1+e) & -\ln(1+e) \end{pmatrix} \approx \begin{pmatrix} -0{,}6931 & -0{,}6931 \\ -0{,}3133 & -1{,}313 \end{pmatrix}$.
4. $\det L = (-\ln 2)(-\ln(1+e)) - (-\ln 2)(1 - \ln(1+e)) = \ln 2 \neq 0$: $\operatorname{rango}(L) = 2$, mientras que $\operatorname{rango}(Z) = 1$.
5. (c) La matriz verdadera es $L^\star = -2 \ln 2 \, J + \ln 2 \, I$, con J la matriz de unos: la diagonal vale $\ln \frac{1}{2} = -\ln 2$ y el resto $\ln \frac{1}{4} = -2 \ln 2$.
6. J tiene autovalores 3, 0, 0; luego $L^\star$ tiene autovalores $-6 \ln 2 + \ln 2 = -5 \ln 2$ y $\ln 2$ (doble), todos no nulos: $\operatorname{rango}(L^\star) = 3$.
7. Un modelo sin sesgo con $d = 1$ produce matrices de log-probabilidades de rango $\le d + 1 = 2$ (proposición 6.6), que no pueden ser iguales a $L^\star$.

Resultado. **(a)** $\operatorname{rango}(L) \le d + 2$ **con sesgo. (b)** $\det L = \ln 2$**, rango** $2 = d + 1$**. (c)** $\operatorname{rango}(L^\star) = 3 > 2$**: esas distribuciones no son representables con** $d = 1$**.** ■

Comprobación. $\det L^\star = (-5 \ln 2)(\ln 2)^2 = -5(\ln 2)^3 \approx -1{,}665$, que coincide con el valor numérico. Con sesgo, la cota del apartado (a) sería 3 y el argumento de (c) ya no se aplicaría: el sesgo añade un grado de libertad de rango 1.

Bibliografía

[1] M. P. Deisenroth, A. A. Faisal y C. S. Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020. Versión en línea del 15 de enero de 2024. Cap. 2 «Linear Algebra», cap. 4 «Matrix Decompositions» y cap. 10 «Dimensionality Reduction with Principal Component Analysis». https://mml-book.github.io/

[2] C. Eckart y G. Young. The approximation of one matrix by another of lower rank. *Psychometrika*, 1(3):211–218, 1936.

[3] I. Goodfellow, Y. Bengio y A. Courville. *Deep Learning*. MIT Press, 2016. Cap. 2 «Linear Algebra». https://www.deeplearningbook.org/

[4] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang y W. Chen. LoRA: Low-rank adaptation of large language models. En *International Conference on Learning Representations (ICLR)*, 2022. https://arxiv.org/abs/2106.09685

[5] NumPy Developers. Broadcasting. *NumPy User Guide*, versión 2.5. https://numpy.org/doc/stable/user/basics.broadcasting.html

[6] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei e I. Sutskever. Language models are unsupervised multitask learners. Informe técnico, OpenAI, 2019.

[7] J. Shlens. A tutorial on principal component analysis. arXiv:1404.1100, 2014. https://arxiv.org/abs/1404.1100

[8] G. Strang. *Introduction to Linear Algebra*, 6.ª ed. Wellesley-Cambridge Press, 2023. https://math.mit.edu/~gs/linearalgebra/ila6/

[9] G. Strang. *Linear Algebra and Learning from Data*. Wellesley-Cambridge Press, 2019. Texto del curso 18.065 del MIT.

[10] G. Strang. 18.06: Linear Algebra. Massachusetts Institute of Technology, MIT OpenCourseWare, primavera de 2010. https://ocw.mit.edu/courses/18-06-linear-algebra-spring-2010/

[11] G. Strang. 18.06SC: Linear Algebra. Massachusetts Institute of Technology, MIT OpenCourseWare, otoño de 2011. https://ocw.mit.edu/courses/18-06sc-linear-algebra-fall-2011/

[12] G. Strang. 18.065: Matrix Methods in Data Analysis, Signal Processing, and Machine Learning. Massachusetts Institute of Technology, MIT OpenCourseWare, primavera de 2018. https://ocw.mit.edu/courses/18-065-matrix-methods-in-data-analysis-signal-processing-and-machine-learning-spring-2018/

[13] H. Touvron *et al.* Llama 2: Open foundation and fine-tuned chat models. arXiv:2307.09288, 2023. https://arxiv.org/abs/2307.09288

[14] Z. Yang, Z. Dai, R. Salakhutdinov y W. W. Cohen. Breaking the softmax bottleneck: A high-rank RNN language model. En *International Conference on Learning Representations (ICLR)*, 2018. https://arxiv.org/abs/1711.03953

[15] A. Zhang, Z. C. Lipton, M. Li y A. J. Smola. *Dive into Deep Learning*, versión 1.0.3. Cambridge University Press, 2023. https://d2l.ai/