Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase I · Fundamentos matemáticos

Módulo 4

Cálculo para el aprendizaje automático

Apuntes del curso

Edición de octubre de 2026

Presentación del módulo

Entrenar un modelo de lenguaje consiste en minimizar una función de pérdida $L(\theta)$ que depende de un vector de parámetros $\theta \in \mathbb{R}^N$, con N del orden de 10^9 a 10^{12}. Todos los métodos de entrenamiento empleados en la práctica se basan en el gradiente $\nabla L(\theta)$: la información local de primer orden que indica cómo varía la pérdida al modificar cada parámetro. Este módulo desarrolla el cálculo diferencial de varias variables necesario para definir, calcular, interpretar y comprobar ese gradiente, y lo aplica a las dos piezas que aparecen en todo Transformer: la capa lineal y la combinación de softmax con entropía cruzada.

Objetivos

Al finalizar el módulo, el estudiante debe ser capaz de:

1. definir derivada parcial, diferenciabilidad, gradiente y derivada direccional, y demostrar que el gradiente indica la dirección de máximo ascenso;
2. enunciar y aplicar la regla de la cadena en forma matricial mediante jacobianos, y explicar por qué el modo inverso (retropropagación) es el adecuado para funciones escalares;
3. obtener a mano los gradientes de una capa lineal, $\partial L/\partial W = \delta x^\top$ y $\partial L/\partial x = W^\top \delta$, y el gradiente $p - y$ de la entropía cruzada respecto de los logits;
4. usar el desarrollo de Taylor de segundo orden y el hessiano para clasificar puntos críticos y analizar la estabilidad del descenso de gradiente;
5. reconocer funciones convexas mediante sus caracterizaciones de primer y segundo orden, demostrar que la entropía cruzada es convexa en los logits y explicar por qué las redes profundas no lo son;
6. comprobar numéricamente un gradiente con diferencias centradas, acotando los errores de truncamiento y de redondeo.

Requisitos previos

Cálculo diferencial de una variable, incluido el teorema de Taylor con resto de Lagrange. Del módulo 1, la función softmax, la función log-suma-exp y la entropía cruzada (tema 4 y tema 5). Del módulo 2, el producto escalar, la norma euclídea, la desigualdad de Cauchy–Schwarz y el producto matricial. Del módulo 3, los autovalores de una matriz simétrica y el teorema espectral, que se usan en los temas 4 y 5.

Organización

Tema	Contenido	Fuentes principales
1	Derivadas parciales y gradiente	[8], [6], [10]
2	Regla de la cadena y jacobiano	[6], [8], [7]
3	Derivadas matriciales: capa lineal y softmax	[6], [3], [9]
4	Taylor, hessiano y puntos críticos	[6], [7], [8]
5	Convexidad	[1], [2]
6	Diferenciación numérica y comprobación de gradientes	[7], [4]

Cada tema termina con una lista de lecturas y con ejercicios graduados en tres niveles: $\star$ comprensión, $\star\star$ cálculo y $\star\star\star$ demostración. Los ejercicios marcados con *Fuente* están adaptados de cursos y libros de texto universitarios; el enunciado se ha redactado de nuevo y, en algunos casos, se han cambiado los datos para que puedan resolverse a mano. Las soluciones completas, paso a paso, están en el apéndice A.

Sobre las fuentes

El texto es de redacción propia. El orden de los temas sigue el capítulo 5 de Deisenroth, Faisal y Ong [6], desde las derivadas parciales hasta la retropropagación y el desarrollo de Taylor multivariable; la intuición geométrica del gradiente y el criterio del hessiano siguen las clases 7 a 11 del curso 18.02 del MIT [8]. La convexidad se trata como en los capítulos 3 y 4 de Boyd y Vandenberghe [1], texto del curso EE364a de Stanford [2], y el análisis numérico del gradiente y del hessiano, como en el capítulo 4 de Goodfellow, Bengio y Courville [7]. Los gradientes de la capa de salida siguen la tarea 2 del curso CS224N de Stanford [3], y la comprobación de gradientes, las notas del curso CS231n [4].

Se adopta un convenio distinto del de [6]: allí el gradiente de una función escalar es un vector fila (un jacobiano $1 \times n$); aquí es un vector columna, $\nabla f = J_f^\top$, como en [1] y [7]. Con este convenio, el gradiente respecto de una matriz tiene la misma forma que la matriz.

Notación

Símbolo	Significado
$x = (x_1, \dots, x_n)^\top \in \mathbb{R}^n$	vector columna; e_i es el i-ésimo vector canónico
$\mathbf{1} = (1, \dots, 1)^\top$	vector de unos
$\mathbb{I}[\cdot]$	indicador: vale 1 si la condición se cumple y 0 en caso contrario
$\partial f/\partial x_i$, $\nabla f(x)$	derivada parcial y gradiente (vector columna)
$D_u f(x)$	derivada direccional en la dirección unitaria u
$J_g(x) \in \mathbb{R}^{m\times n}$	jacobiano de $g\colon \mathbb{R}^n \to \mathbb{R}^m$, $(J_g)_{ji} = \partial g_j/\partial x_i$
$H_f(x)$, $\nabla^2 f(x)$	hessiano, $(H_f)_{ij} = \partial^2 f/\partial x_i \partial x_j$
$A \succeq 0$, $A \succ 0$	A simétrica semidefinida o definida positiva
$\lambda_{\min}(A)$, $\lambda_{\max}(A)$	menor y mayor autovalor de una matriz simétrica
$\langle A, B\rangle = \operatorname{tr}(A^\top B)$	producto escalar de Frobenius de matrices
$z \in \mathbb{R}^K$, $p = \operatorname{softmax}(z)$, y	logits, probabilidades y vector *one-hot* del token correcto
$\delta = \partial L/\partial y$	señal de error que llega a la salida de una capa
$\eta > 0$	tasa de aprendizaje
$\varepsilon_{\text{máq}}$	épsilon de la máquina (unidad de redondeo)
$o(\cdot)$, $O(\cdot)$	símbolos de Landau

Índice

Presentación del módulo **ii**

1 Derivadas parciales y gradiente **1**

1.1 Derivadas parciales . . . 1
1.2 Diferenciabilidad y gradiente . . . 1
1.3 Derivada direccional . . . 2
1.4 La dirección de máximo ascenso . . . 3
1.5 Descenso de gradiente . . . 3
Ejercicios del tema 1 . . . 5

2 Regla de la cadena y jacobiano **6**

2.1 Funciones vectoriales y jacobiano . . . 6
2.2 La regla de la cadena . . . 6
2.3 Grafos computacionales . . . 7
2.4 Modo directo y modo inverso . . . 8
Ejercicios del tema 2 . . . 9

3 Derivadas matriciales: capa lineal y softmax **10**

3.1 Gradiente respecto de una matriz . . . 10
3.2 La capa lineal . . . 10
3.3 El jacobiano de la softmax . . . 11
3.4 Entropía cruzada y el gradiente $p - y$ . . . 12
Ejercicios del tema 3 . . . 13

4 Taylor, hessiano y puntos críticos **14**

4.1 El hessiano . . . 14
4.2 Desarrollo de Taylor de segundo orden . . . 14
4.3 Clasificación de puntos críticos . . . 15
4.4 Curvatura y descenso de gradiente . . . 16
Ejercicios del tema 4 . . . 17

5 Convexidad **19**
5.1 Conjuntos y funciones convexas . . . 19
5.2 Condiciones de primer y segundo orden . . . 20
5.3 Mínimos de funciones convexas . . . 21
5.4 Operaciones que conservan la convexidad . . . 21
5.5 Las redes profundas no son convexas . . . 22
Ejercicios del tema 5 . . . 23

6 Diferenciación numérica y comprobación de gradientes **25**
6.1 Diferencias finitas . . . 25
6.2 Error de redondeo y elección del paso . . . 26
6.3 Comprobación de gradientes . . . 26
Ejercicios del tema 6 . . . 28

A Soluciones de los ejercicios **29**
A.1 Tema 1 . . . 29
A.2 Tema 2 . . . 31
A.3 Tema 3 . . . 34
A.4 Tema 4 . . . 36
A.5 Tema 5 . . . 38
A.6 Tema 6 . . . 41

Bibliografía **44**

Tema 1

Derivadas parciales y gradiente

La pérdida de un modelo de lenguaje es una función escalar de muchas variables. Este tema define las derivadas parciales y la diferenciabilidad, introduce el gradiente y la derivada direccional, y demuestra que el gradiente señala la dirección de máximo ascenso, que es el fundamento del descenso de gradiente. Se siguen las clases 7, 10 y 11 del curso 18.02 del MIT [8], la §5.2 de [6] y la §2.4 de [10].

1.1 Derivadas parciales

Sea $U \subseteq \mathbb{R}^n$ un abierto y $f\colon U \to \mathbb{R}$. Para estudiar cómo varía f cerca de un punto, se empieza por moverse en una sola coordenada.

Definición 1.1 (Derivada parcial). La *derivada parcial* de f respecto de x_i en el punto $x \in U$ es

$$\frac{\partial f}{\partial x_i}(x) = \lim_{h \to 0} \frac{f(x + h\,e_i) - f(x)}{h},$$

si el límite existe. Equivale a derivar f como función de una sola variable x_i, tratando las demás como constantes.

Ejemplo 1.2. Sea $f(x, y) = x^2 y + 3y$. Con y fija, $\partial f/\partial x = 2xy$; con x fija, $\partial f/\partial y = x^2 + 3$. En el punto $(2, 1)$, donde $f(2, 1) = 7$, se obtiene $\partial f/\partial x = 4$ y $\partial f/\partial y = 7$: al aumentar ligeramente x, la función crece a razón de 4 unidades por unidad de x; al aumentar y, a razón de 7.

Observación 1.3 (Conexión con los LLM). Si $L(\theta)$ es la pérdida de entropía cruzada de un modelo con parámetros $\theta_1, \ldots, \theta_N$, la parcial $\partial L/\partial \theta_i$ mide cuánto aumenta la pérdida, a primer orden, al aumentar el parámetro θ_i con los demás fijos. Cada paso de entrenamiento calcula las N parciales a la vez.

1.2 Diferenciabilidad y gradiente

La existencia de las derivadas parciales no basta para que f se comporte bien cerca de x: las parciales solo exploran las direcciones de los ejes. La noción adecuada exige que f admita una buena aproximación lineal en todas las direcciones a la vez [6, §5.2].

Definición 1.4 (Diferenciabilidad y gradiente). La función f es *diferenciable* en $x \in U$ si existe un vector $g \in \mathbb{R}^n$ tal que

$$f(x + h) = f(x) + g^{\top} h + o(\|h\|) \qquad \text{cuando } h \to 0,$$

es decir, $\lim_{h \to 0} \big(f(x + h) - f(x) - g^{\top} h\big)/\|h\| = 0$. El vector g se llama *gradiente* de f en x y se escribe $\nabla f(x)$. La función afín $h \mapsto f(x) + \nabla f(x)^{\top} h$ es la *aproximación lineal* (o de primer orden) de f en x.

Proposición 1.5. *Si f es diferenciable en x, existen todas las parciales en x y*

$$\nabla f(x) = \Big(\frac{\partial f}{\partial x_1}(x), \dots, \frac{\partial f}{\partial x_n}(x)\Big)^{\top}.$$

En particular, el gradiente es único.

Demostración. Sea g un vector como en la definición 1.4. Tomando $h = t\,e_i$ con $t \to 0$, se tiene $\|h\| = |t|$ y $g^{\top}h = t\,g_i$, luego

$$\frac{f(x + t\,e_i) - f(x)}{t} - g_i = \frac{f(x + t\,e_i) - f(x) - g^{\top}h}{t} \longrightarrow 0,$$

porque el cociente por t difiere del cociente por $|t|$ solo en el signo. Así, $\partial f/\partial x_i(x)$ existe y vale g_i. Como las parciales están determinadas por f, también lo está g. ∎

El gradiente tiene la misma forma que la variable: si $x \in \mathbb{R}^n$, entonces $\nabla f(x) \in \mathbb{R}^n$. En el ejemplo 1.2, $\nabla f(2,1) = (4,7)^{\top}$. Para un LLM, el gradiente de la pérdida tiene tantas componentes como parámetros.

Teorema 1.6 (Condición suficiente de diferenciabilidad). *Si todas las derivadas parciales de f existen en un entorno de x y son continuas en x, entonces f es diferenciable en x. En particular, toda $f \in C^1(U)$ es diferenciable en todo punto de U.*

La demostración, estándar en los cursos de cálculo de varias variables, aplica el teorema del valor medio en cada coordenada por separado y se omite aquí. Las funciones que se usan para construir una red (polinomios, exponenciales, logaritmos, cocientes con denominador no nulo y sus composiciones) son de clase C^{∞} en su dominio. La excepción habitual es la función ReLU, $\max(0,t)$, que no es derivable en $t = 0$; el tema 6 vuelve sobre ella.

Observación 1.7 (Parciales sin diferenciabilidad). Sea $f(x,y) = xy/(x^2+y^2)$ si $(x,y) \neq (0,0)$ y $f(0,0) = 0$. Como f se anula sobre los dos ejes, $\partial f/\partial x(0,0) = \partial f/\partial y(0,0) = 0$. Sin embargo, $f(t,t) = 1/2$ para todo $t \neq 0$, de modo que f ni siquiera es continua en el origen y, por tanto, no es diferenciable allí. Las parciales existen, pero no son continuas en $(0,0)$.

1.3 Derivada direccional

Definición 1.8 (Derivada direccional). Sea $u \in \mathbb{R}^n$ con $\|u\| = 1$. La *derivada direccional* de f en x en la dirección u es

$$D_u f(x) = \lim_{t \to 0} \frac{f(x + t\,u) - f(x)}{t}.$$

Las derivadas parciales son las derivadas direccionales en las direcciones $e_1, \dots, e_n$.

Proposición 1.9. *Si f es diferenciable en x, entonces $D_u f(x) = \nabla f(x)^{\top} u$ para todo u unitario.*

Demostración. Con $h = t\,u$ se tiene $\|h\| = |t|$. Por la definición 1.4, $f(x + t\,u) - f(x) = t\,\nabla f(x)^{\top}u + o(|t|)$. Dividiendo por t y haciendo $t \to 0$ se obtiene el enunciado. ∎

Ejemplo 1.10. Con la función del ejemplo 1.2 y $u = (3/5,\ 4/5)^{\top}$, que es unitario, $D_u f(2,1) = 4 \cdot 0{,}6 + 7 \cdot 0{,}8 = 8$. Se verá a continuación que ninguna dirección supera $\|\nabla f(2,1)\| = \sqrt{65} \approx 8{,}062$.

1.4 La dirección de máximo ascenso

Teorema 1.11 (Máximo ascenso). *Sea f diferenciable en x con $\nabla f(x) \neq 0$. Para todo u unitario,*

$$-\|\nabla f(x)\| \leq D_u f(x) \leq \|\nabla f(x)\|.$$

La cota superior se alcanza únicamente en $u^* = \nabla f(x)/\|\nabla f(x)\|$ y la inferior únicamente en $-u^*$.

Demostración. Por la proposición 1.9 y la desigualdad de Cauchy–Schwarz (módulo 2),

$$|D_u f(x)| = |\nabla f(x)^\top u| \leq \|\nabla f(x)\|\,\|u\| = \|\nabla f(x)\|.$$

La igualdad en Cauchy–Schwarz se da si y solo si u es proporcional a $\nabla f(x)$; al ser u unitario, $u = \pm u^*$. Sustituyendo, $\nabla f(x)^\top u^* = \|\nabla f(x)\|^2/\|\nabla f(x)\| = \|\nabla f(x)\|$, y con $-u^*$ se obtiene el valor opuesto. ∎

Así, $\nabla f(x)$ apunta en la dirección en la que f crece más deprisa, su norma es esa tasa máxima de crecimiento y $-\nabla f(x)$ es la dirección de *máximo descenso*.

Lema 1.12 (Derivada a lo largo de una curva). *Sea $r\colon (a,b) \to U$ derivable en t_0 y f diferenciable en $r(t_0)$. Entonces $t \mapsto f(r(t))$ es derivable en t_0 y*

$$\frac{d}{dt} f(r(t))\Big|_{t=t_0} = \nabla f(r(t_0))^\top r'(t_0).$$

Demostración. Sea $x = r(t_0)$ y $h(s) = r(t_0 + s) - x$, de modo que $h(s) = s\,r'(t_0) + o(s)$ y $\|h(s)\| = O(|s|)$. Por la definición 1.4, $f(r(t_0 + s)) - f(x) = \nabla f(x)^\top h(s) + o(\|h(s)\|) = s\,\nabla f(x)^\top r'(t_0) + o(s)$. Dividiendo por s y haciendo $s \to 0$ se obtiene el enunciado. ∎

El lema 1.12 es un caso particular de la regla de la cadena, que se estudia en general en el tema 2.

Corolario 1.13 (Gradiente y conjuntos de nivel). *Sea r una curva derivable contenida en un conjunto de nivel de f, es decir, $f(r(t)) = c$ para todo t. Entonces $\nabla f(r(t))^\top r'(t) = 0$: el gradiente es ortogonal a la recta tangente a la curva de nivel.*

Demostración. La función $t \mapsto f(r(t))$ es constante; su derivada es nula y, por el lema 1.12, es igual a $\nabla f(r(t))^\top r'(t)$. ∎

1.5 Descenso de gradiente

El teorema 1.11 sugiere un método para minimizar f: desplazarse repetidamente en la dirección $-\nabla f$.

Definición 1.14 (Descenso de gradiente). Dado un punto inicial x_0 y una *tasa de aprendizaje* $\eta > 0$, el *descenso de gradiente* genera la sucesión

$$x_{k+1} = x_k - \eta\,\nabla f(x_k), \qquad k = 0, 1, 2, \ldots$$

Proposición 1.15 (Descenso a primer orden). *Si f es diferenciable en x y $g = \nabla f(x) \neq 0$, existe $\eta_0 > 0$ tal que $f(x - \eta g) < f(x)$ para todo $\eta \in (0, \eta_0)$.*

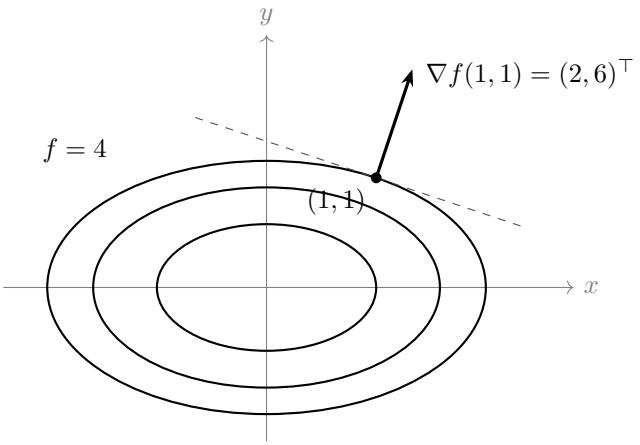


Figura 1.1: Curvas de nivel $x^2 + 3y^2 = c$ para $c = 1$; 2,5; 4. En $(1,1)$ el gradiente (flecha, a escala reducida) es perpendicular a la tangente a la curva $f = 4$ (trazo discontinuo), de dirección $(3,-1)^\top$.

Demostración. Por la definición 1.4 con $h = -\eta g$, $f(x - \eta g) = f(x) - \eta\|g\|^2 + o(\eta)$. Luego $\big(f(x-\eta g) - f(x)\big)/\eta \to -\|g\|^2 < 0$ cuando $\eta \to 0^+$, y el cociente es negativo para todo η suficientemente pequeño. ■

La proposición garantiza el descenso solo para pasos pequeños. El tamaño máximo admisible depende de la curvatura de f y se determina en el tema 4.

Ejemplo 1.16. Sea $f(x,y) = x^2 + 3y^2$, con $\nabla f = (2x, 6y)^\top$. Desde $(1,1)$, con $\nabla f(1,1) = (2,6)^\top$ y $\eta = 0{,}1$, el primer paso da $(1,1) - 0{,}1\,(2,6) = (0{,}8;\ 0{,}4)$, y la función baja de $f(1,1) = 4$ a $f(0{,}8;\ 0{,}4) = 0{,}64 + 0{,}48 = 1{,}12$.

Observación 1.17 (Conexión con los LLM). El entrenamiento de un modelo de lenguaje aplica la definición 1.14 a la pérdida $L(\theta)$, con el gradiente estimado sobre un lote de datos. Los métodos que se usan en la práctica (descenso estocástico, momento, Adam) modifican esta iteración y se estudian en el módulo 7.

Observación 1.18 (Relación con la física). Una partícula en un potencial $U(x)$ sometida a un rozamiento muy fuerte se mueve con velocidad proporcional a la fuerza $-\nabla U$: $\dot{x}(t) = -\nabla U(x(t))$. Esta ecuación se llama *flujo de gradiente*, y la definición 1.14 es su discretización por el método de Euler con paso η. Añadir un término de ruido da la dinámica de Langevin, que sirve de modelo para el descenso de gradiente estocástico.

Lecturas recomendadas para este tema

- MIT 18.02 [8], clase 7 «Level Curves, Partial Derivatives, Tangent Plane» y clase 11 «Gradient, Directional Derivative».
- Deisenroth, Faisal y Ong [6], §5.2 «Partial Differentiation and Gradients».
- Zhang *et al.* [10], §2.4.3 «Partial Derivatives and Gradients».
- Goodfellow, Bengio y Courville [7], §4.3 «Gradient-Based Optimization».

Ejercicios del tema 1

Ejercicio 1.1 ⋆ Justifique si son verdaderas o falsas: (a) el gradiente es perpendicular a las curvas de nivel; (b) $-\nabla f$ es la dirección de máximo descenso; (c) si existen todas las derivadas parciales de f en x, entonces f es diferenciable en x.

Ejercicio 1.2 ⋆⋆ Sea $f(x,y) = x^3 + 2xy^2$. Calcule $\nabla f(1,2)$, su norma y la derivada direccional en la dirección $(1,1)^\top/\sqrt{2}$. Compruebe que esta última no supera la norma del gradiente.

Ejercicio 1.3 ⋆⋆ Sea $f(x) = 3x_1^2 + 5e^{x_2}$. Calcule ∇f en un punto genérico y en $(1,0)$. Halle la derivada direccional en $(1,0)$ en la dirección del vector $(3,4)^\top$ y compárela con $\|\nabla f(1,0)\|$.

Fuente: adaptado de Zhang *et al.* [10], §2.4, ejercicio 7 (se añaden el punto y la dirección).

Ejercicio 1.4 ⋆⋆ Calcule el gradiente de $f(x) = \|x\|$ para $x \in \mathbb{R}^n \setminus \{0\}$ y evalúelo en $x = (3,4)^\top$. Estudie qué ocurre en $x = 0$. Relacione el resultado con el recorte de gradientes por norma, que divide un gradiente g por $\|g\|$ cuando esta supera un umbral.

Fuente: adaptado de Zhang *et al.* [10], §2.4, ejercicio 8.

Ejercicio 1.5 ⋆⋆ Sea $f(x,y) = x^3 - 3x^2 + xy - y^2 + x + y$. En el punto $(1, 1/2)$, determine la dirección unitaria en la que la derivada direccional es máxima y su valor, la dirección en la que es mínima y las direcciones en las que es nula.

Fuente: adaptado de MIT 18.02, primavera de 2006 [8], *Problem Set* 4, segunda parte, problema 5.

Ejercicio 1.6 ⋆⋆⋆ Sea f diferenciable en x con $\nabla f(x) \neq 0$. Demuestre, sin usar el teorema 1.11, que el mínimo de $D_u f(x)$ sobre los vectores unitarios vale $-\|\nabla f(x)\|$ y se alcanza solo en $u = -\nabla f(x)/\|\nabla f(x)\|$. Deduzca, para $f(x,y) = x^2 + y^2$, que el gradiente es perpendicular a las circunferencias $x^2 + y^2 = c$ parametrizándolas como $r(t) = \sqrt{c}\,(\cos t, \sin t)^\top$.

Tema 2

Regla de la cadena y jacobiano

Una red neuronal es una composición de muchas funciones sencillas, y su pérdida depende de cada parámetro a través de largas cadenas de cálculos intermedios. Este tema generaliza la derivada a funciones con valores vectoriales mediante el jacobiano, demuestra la regla de la cadena en forma matricial y muestra cómo se organiza el cálculo sobre un grafo computacional, en modo directo o en modo inverso. Se sigue [6, §5.2, §5.3 y §5.6], la clase 10 de [8] y [7, §6.5].

2.1 Funciones vectoriales y jacobiano

Definición 2.1 (Jacobiano). Sea $U \subseteq \mathbb{R}^n$ abierto y $g = (g_1, \dots, g_m)^\top : U \to \mathbb{R}^m$. La función g es *diferenciable* en x si existe una matriz $J \in \mathbb{R}^{m\times n}$ tal que

$$g(x+h) = g(x) + J\,h + o(\|h\|) \qquad \text{cuando } h \to 0.$$

La matriz J se llama *jacobiano* de g en x y se escribe $J_g(x)$. Aplicando la proposición 1.5 a cada componente, g es diferenciable si y solo si lo es cada g_j, y

$$\big(J_g(x)\big)_{ji} = \frac{\partial g_j}{\partial x_i}(x), \qquad j = 1, \dots, m, \quad i = 1, \dots, n.$$

La fila j de $J_g(x)$ es $\nabla g_j(x)^\top$; la columna i es la derivada de g respecto de x_i.

El jacobiano tiene una fila por cada salida y una columna por cada entrada. Para $m = 1$ es una matriz fila y $\nabla f(x) = J_f(x)^\top$.

Ejemplo 2.2. Si $g(x) = Ax + b$ con $A \in \mathbb{R}^{m\times n}$ y $b \in \mathbb{R}^m$, entonces $g(x+h) = g(x) + Ah$ exactamente, luego $J_g(x) = A$ en todo punto. El jacobiano de una aplicación afín es su matriz.

Ejemplo 2.3. Sea $g(x, y) = (xy,\ x^2 + y)^\top$. Entonces

$$J_g(x, y) = \begin{pmatrix} y & x \\ 2x & 1 \end{pmatrix}, \qquad J_g(2, 1) = \begin{pmatrix} 1 & 2 \\ 4 & 1 \end{pmatrix}.$$

2.2 La regla de la cadena

Teorema 2.4 (Regla de la cadena). *Sean $g\colon U \subseteq \mathbb{R}^n \to \mathbb{R}^m$ diferenciable en x y $f\colon V \subseteq \mathbb{R}^m \to \mathbb{R}^k$ diferenciable en $g(x)$, con $g(U) \subseteq V$. Entonces $f \circ g$ es diferenciable en x y*

$$J_{f\circ g}(x) = J_f\big(g(x)\big)\, J_g(x).$$

Demostración. Sean $A = J_g(x)$, $B = J_f(g(x))$ y $\Delta(h) = g(x+h) - g(x) = Ah + r_1(h)$, con $r_1(h) = o(\|h\|)$. Entonces $\|\Delta(h)\| \le \|A\|\,\|h\| + \|r_1(h)\| = O(\|h\|)$, donde $\|A\|$ es la norma de operador. Por la diferenciabilidad de f en $g(x)$,

$$f\big(g(x+h)\big) - f\big(g(x)\big) = B\,\Delta(h) + r_2\big(\Delta(h)\big) = BA\,h + B\,r_1(h) + r_2\big(\Delta(h)\big),$$

con $r_2(v) = o(\|v\|)$. El término $B\,r_1(h)$ es $o(\|h\|)$ porque $\|B\,r_1(h)\| \le \|B\|\,\|r_1(h)\|$. Para el último, si $\Delta(h) \neq 0$ se escribe $\|r_2(\Delta)\|/\|h\| = \big(\|r_2(\Delta)\|/\|\Delta\|\big)\big(\|\Delta\|/\|h\|\big)$: el primer factor tiende a 0 porque $\Delta(h) \to 0$, y el segundo está acotado; si $\Delta(h) = 0$, el término es nulo. Luego $f \circ g$ es diferenciable en x con jacobiano BA. ∎

Corolario 2.5 (Caso escalar). *Si $f\colon \mathbb{R}^m \to \mathbb{R}$ y $u = g(x)$, entonces*

$$\frac{\partial (f\circ g)}{\partial x_i}(x) = \sum_{j=1}^{m} \frac{\partial f}{\partial u_j}(u)\,\frac{\partial u_j}{\partial x_i}(x), \qquad \textit{es decir,} \qquad \nabla_x (f\circ g) = J_g(x)^{\top}\,\nabla_u f(u).$$

Demostración. Con $k = 1$, el teorema 2.4 da $J_{f\circ g} = \nabla f(u)^{\top} J_g(x)$, una matriz fila cuya entrada i es la suma del enunciado. Trasponiendo se obtiene la forma vectorial. ∎

La suma del corolario 2.5 tiene una lectura directa: si x_i influye en f a través de varias variables intermedias u_j, su efecto total es la suma de los efectos transmitidos por cada una de ellas.

Ejemplo 2.6. Sea $f(u,v) = u^2 v$ y g la del ejemplo 2.3, en el punto $(x,y) = (2,1)$.

1. Valores intermedios: $u = xy = 2$, $v = x^2 + y = 5$, $f = u^2 v = 20$.
2. Gradiente exterior: $\partial f/\partial u = 2uv = 20$ y $\partial f/\partial v = u^2 = 4$.
3. Por el corolario 2.5,

$$\nabla_{(x,y)} f = J_g(2,1)^{\top} \begin{pmatrix} 20 \\ 4 \end{pmatrix} = \begin{pmatrix} 1 & 4 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 20 \\ 4 \end{pmatrix} = \begin{pmatrix} 36 \\ 44 \end{pmatrix}.$$

Como comprobación, $f(g(x,y)) = x^2 y^2 (x^2 + y) = x^4 y^2 + x^2 y^3$, cuyas parciales en $(2,1)$ son $4x^3 y^2 + 2xy^3 = 32 + 4 = 36$ y $2x^4 y + 3x^2 y^2 = 32 + 12 = 44$.

2.3 Grafos computacionales

Definición 2.7 (Grafo computacional). Un *grafo computacional* es un grafo dirigido acíclico cuyos nodos son variables: los nodos sin predecesores son las entradas, y cada uno de los demás nodos v se calcula como una función diferenciable $v = \phi_v(\text{padres}(v))$ de sus predecesores. Si la salida es un escalar f, se llama *adjunto* de un nodo v a $\bar{v} = \partial f/\partial v$, la derivada de f respecto de v considerando todas las variables posteriores como funciones de v [7, §6.5.1].

Proposición 2.8 (Retropropagación). *En un grafo computacional con salida escalar f se cumple $\bar{f} = 1$ y, para todo nodo $v \neq f$,*

$$\bar{v} = \sum_{w\,:\,v \in \mathit{padres}(w)} \bar{w}\,\frac{\partial \phi_w}{\partial v}.$$

Por tanto, recorriendo los nodos en orden topológico inverso se obtienen los adjuntos de todas las entradas, es decir, el gradiente de f.

Demostración. La variable v influye en f solo a través de los nodos w de los que es padre. Considerando f como función de esos nodos y estos como funciones de v, el corolario 2.5 da la suma del enunciado. En orden topológico inverso, cuando se procesa v ya se conocen todos los $\bar{w}$ de sus hijos. ∎

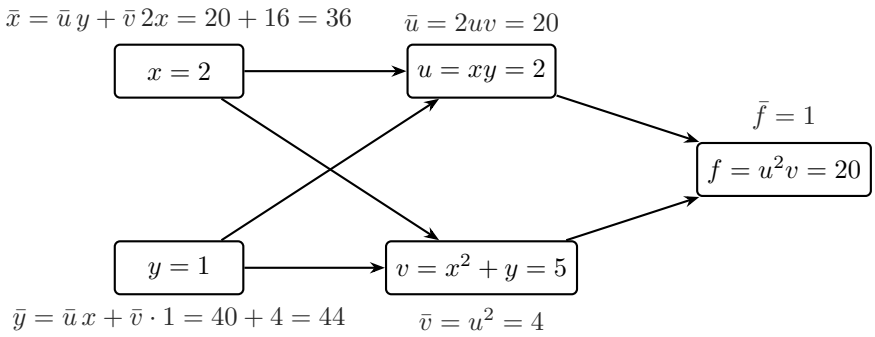


Figura 2.1: Grafo computacional del ejemplo 2.6. Dentro de cada nodo figura el valor calculado en el paso hacia delante; junto a él, en gris, el adjunto calculado en el paso hacia atrás con la proposición 2.8. La entrada x recibe contribuciones por dos caminos, que se suman.

2.4 Modo directo y modo inverso

Sea una composición $F = f_L \circ \cdots \circ f_1$, con $f_\ell \colon \mathbb{R}^{d_{\ell-1}} \to \mathbb{R}^{d_\ell}$. Por el teorema 2.4,

$$J_F = J_L\, J_{L-1} \cdots J_1, \qquad J_\ell \in \mathbb{R}^{d_\ell \times d_{\ell-1}},$$

con cada J_ℓ evaluado en el valor intermedio correspondiente. El producto de matrices es asociativo, pero el coste de calcularlo depende del orden en que se agrupen los factores [6, §5.6].

Proposición 2.9 (Coste de los dos modos). *Multiplicar una matriz $a \times b$ por otra $b \times c$ requiere abc productos escalares. En consecuencia:*

(i) en modo directo*, se calcula $J_F v = J_L(\cdots(J_2(J_1 v)))$ para un vector $v \in \mathbb{R}^{d_0}$ con $\sum_\ell d_\ell d_{\ell-1}$ productos; obtener el jacobiano completo exige repetirlo d_0 veces, una por columna;*

(ii) en modo inverso*, se calcula $w^\top J_F = ((w^\top J_L) J_{L-1}) \cdots J_1$ para un vector $w \in \mathbb{R}^{d_L}$ con el mismo número de productos; obtener el jacobiano completo exige repetirlo d_L veces, una por fila.*

Si la salida es escalar ($d_L = 1$), el gradiente se obtiene con una sola pasada en modo inverso.

Demostración. Cada factor J_ℓ aplicado a un vector (por la derecha o por la izquierda) cuesta $d_\ell d_{\ell-1}$ productos, y en cada modo se realizan L de estas operaciones. Con $v = e_i$ se obtiene la columna i de J_F, y con $w = e_j$, la fila j. Con $d_L = 1$, la única fila es $\nabla F^\top$. ∎

La retropropagación de la proposición 2.8 es el modo inverso aplicado a un grafo. Su coste es un múltiplo pequeño del coste de evaluar f, independiente del número de entradas; por ello la pérdida de un modelo con miles de millones de parámetros puede derivarse con una sola pasada hacia atrás. El precio es la memoria: el paso hacia atrás necesita los valores intermedios del paso hacia delante. La implementación de este mecanismo (diferenciación automática) es el objeto del módulo 10.

Observación 2.10 (Conexión con los LLM). Un Transformer es un grafo computacional con miles de millones de nodos. Su salida escalar es la pérdida media del lote, y las bibliotecas como PyTorch o JAX registran el grafo durante el paso hacia delante para recorrerlo después en orden inverso. Ninguna de ellas forma explícitamente un jacobiano: solo calculan productos de la forma $w^\top J_\ell$.

Lecturas recomendadas para este tema

- Deisenroth, Faisal y Ong [6], §5.2 (regla de la cadena), §5.3 «Gradients of Vector-Valued Functions» y §5.6 «Backpropagation and Automatic Differentiation».
- MIT 18.02 [8], clase 10 «Differentials; Chain Rule».
- Goodfellow, Bengio y Courville [7], §6.5.1 «Computational Graphs», §6.5.2 «Chain Rule of Calculus» y §6.5.3 «Recursively Applying the Chain Rule to Obtain Backprop».
- Zhang *et al.* [10], §2.4.4 «Chain Rule».

Ejercicios del tema 2

Ejercicio 2.1 ⋆ Sean $g\colon \mathbb{R}^5 \to \mathbb{R}^3$, $h\colon \mathbb{R}^3 \to \mathbb{R}^2$ y $f\colon \mathbb{R}^2 \to \mathbb{R}$ diferenciables. Indique la forma de J_g, J_h, J_f y $J_{f\circ h\circ g}$, y la del gradiente de $f \circ h \circ g$. Compruebe que las dimensiones del producto del teorema 2.4 encajan.

Ejercicio 2.2 ⋆⋆ Sea $F(x, y) = (x + y^2)(x^2 - y)$. Calcule $\partial F/\partial x$ y $\partial F/\partial y$ en $(1, 2)$ con la regla de la cadena, tomando $u = x + y^2$ y $v = x^2 - y$, y compruebe el resultado desarrollando F.

Ejercicio 2.3 ⋆⋆ Sea $g(x, y) = (x^2 y,\ 3x - y,\ xy)^\top$. Escriba $J_g(1, 2)$ e indique su forma. Use $J_g^\top$ para obtener el gradiente de $s = g_1 + g_2 + g_3$ en $(1, 2)$.

Ejercicio 2.4 ⋆⋆ Sea $w = f(x, y, z)$, donde x, y y z son funciones de dos variables a y b. (a) Escriba la regla de la cadena para $\partial w/\partial a$ y $\partial w/\partial b$. (b) Aplíquela con $f(x, y, z) = xyz$, $x = a + b$, $y = a - b$, $z = ab$, en $(a, b) = (2, 1)$, y compruebe el resultado expresando w directamente en función de a y b.

Fuente: adaptado de Zhang *et al.* [10], §2.4, ejercicio 9 (se añade el caso numérico).

Ejercicio 2.5 ⋆⋆ Sea $F = f_3 \circ f_2 \circ f_1$ con $f_1\colon \mathbb{R}^n \to \mathbb{R}^d$, $f_2\colon \mathbb{R}^d \to \mathbb{R}^d$ y $f_3\colon \mathbb{R}^d \to \mathbb{R}$. Cuente los productos escalares necesarios para obtener ∇F multiplicando los jacobianos (a) de derecha a izquierda, $J_3(J_2 J_1)$, y (b) de izquierda a derecha, $(J_3 J_2)J_1$. Evalúe ambos con $n = d = 1000$.

Ejercicio 2.6 ⋆⋆⋆ Sean $a, b\colon \mathbb{R}^n \to \mathbb{R}^m$ diferenciables y $s(x) = a(x)^\top b(x)$. Demuestre, con el teorema 2.4, que $\nabla s(x) = J_a(x)^\top b(x) + J_b(x)^\top a(x)$. Deduzca el gradiente de la forma cuadrática $q(x) = x^\top A x$ para $A \in \mathbb{R}^{n\times n}$ y particularícelo al caso simétrico.

Tema 3

Derivadas matriciales: capa lineal y softmax

Casi todo el cómputo del entrenamiento de un modelo de lenguaje consiste en derivar dos tipos de operación: capas lineales y la combinación de softmax con entropía cruzada en la salida. Este tema define el gradiente de una función escalar respecto de una matriz, obtiene los gradientes de la capa lineal, individualmente y por lotes, y deduce el resultado más usado del curso: el gradiente de la entropía cruzada respecto de los logits es $p - y$. Se sigue [6, §5.3–§5.5], la tarea 2 de [3] y, como tabla de consulta, [9].

3.1 Gradiente respecto de una matriz

Definición 3.1 (Gradiente respecto de una matriz). Sea $L\colon \mathbb{R}^{m\times n} \to \mathbb{R}$. Su *gradiente* en W es la matriz $\nabla_W L = \partial L/\partial W \in \mathbb{R}^{m\times n}$ de entradas

$$\Big(\frac{\partial L}{\partial W}\Big)_{ij} = \frac{\partial L}{\partial W_{ij}}.$$

Equivale a identificar $\mathbb{R}^{m\times n}$ con $\mathbb{R}^{mn}$ y reordenar el gradiente con la forma de W.

Proposición 3.2 (Aproximación lineal). *Si L es diferenciable en W, para toda perturbación $E \in \mathbb{R}^{m\times n}$,*

$$L(W+E) = L(W) + \Big\langle \frac{\partial L}{\partial W}, E \Big\rangle + o(\|E\|), \qquad \langle A, B\rangle = \sum_{i,j} A_{ij}B_{ij} = \operatorname{tr}(A^\top B).$$

Demostración. Es la definición 1.4 en $\mathbb{R}^{mn}$: el término lineal $\nabla L^\top h$ es $\sum_{i,j}(\partial L/\partial W_{ij})E_{ij}$. La igualdad $\sum_{i,j} A_{ij}B_{ij} = \operatorname{tr}(A^\top B)$ se obtiene desarrollando $(A^\top B)_{jj} = \sum_i A_{ij}B_{ij}$ y sumando en j. ∎

La regla práctica que se deriva es que *el gradiente de un escalar respecto de un parámetro tiene la misma forma que el parámetro*. Comprobar las formas es la primera verificación de cualquier fórmula de este tema.

3.2 La capa lineal

Proposición 3.3 (Gradientes de una capa lineal). *Sean $W \in \mathbb{R}^{m\times n}$, $x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, $y = Wx + b$ y $L = \ell(y)$ con $\ell\colon \mathbb{R}^m \to \mathbb{R}$ diferenciable. Sea $\delta = \nabla_y \ell \in \mathbb{R}^m$ la* señal de error *que llega a la salida. Entonces*

$$\frac{\partial L}{\partial W} = \delta\, x^\top, \qquad \frac{\partial L}{\partial b} = \delta, \qquad \frac{\partial L}{\partial x} = W^\top \delta.$$

Demostración. Como $y_k = \sum_j W_{kj}x_j + b_k$, se tiene $\partial y_k/\partial W_{ij} = \mathbb{I}[k=i]\,x_j$: la entrada W_{ij} solo afecta a la salida y_i. Por el corolario 2.5,

$$\frac{\partial L}{\partial W_{ij}} = \sum_k \delta_k \frac{\partial y_k}{\partial W_{ij}} = \delta_i\, x_j = (\delta x^\top)_{ij}.$$

Del mismo modo, $\partial y_k/\partial b_i = \mathbb{I}[k=i]$ da $\partial L/\partial b_i = \delta_i$. Por último, $J_y(x) = W$ (ejemplo 2.2) y el corolario 2.5 da $\partial L/\partial x = W^\top\delta$. ∎

Las formas encajan: $\delta x^\top$ es $(m\times 1)(1\times n) = m\times n$, como W, y $W^\top\delta$ es $(n\times m)(m\times 1) = n\times 1$, como x. El vector $W^\top\delta$ es la señal de error que la capa transmite a la capa anterior.

Ejemplo 3.4. Sean $W = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix}$, $x = (1,-1)^\top$, $b = 0$, un objetivo $t = (0,1)^\top$ y $L = \frac{1}{2}\|y-t\|^2$, de modo que $\delta = y - t$.

Paso	Cálculo	Resultado
Hacia delante	$y = Wx$	$(-1,-1)^\top$
Pérdida	$\frac{1}{2}\big((-1)^2 + (-2)^2\big)$	2,5
Señal de error	$\delta = y - t$	$(-1,-2)^\top$
Gradiente de W	$\delta x^\top$	$\begin{pmatrix} -1 & 1 \\ -2 & 2 \end{pmatrix}$
Gradiente de x	$W^\top\delta$	$(-1,-4)^\top$

Corolario 3.5 (Capa lineal por lotes). *Sean $X \in \mathbb{R}^{B\times n}$ una matriz cuyas filas son B ejemplos, $W \in \mathbb{R}^{n\times m}$, $Z = XW \in \mathbb{R}^{B\times m}$ y $L = \ell(Z)$ con $\Delta = \partial L/\partial Z \in \mathbb{R}^{B\times m}$. Entonces*

$$\frac{\partial L}{\partial W} = X^\top\Delta, \qquad \frac{\partial L}{\partial X} = \Delta\, W^\top.$$

Demostración. Como $Z_{bk} = \sum_j X_{bj}W_{jk}$, se tiene $\partial Z_{bk}/\partial W_{jl} = \mathbb{I}[k=l]\,X_{bj}$, y por la regla de la cadena $\partial L/\partial W_{jl} = \sum_b \Delta_{bl}X_{bj} = (X^\top\Delta)_{jl}$. Análogamente, $\partial Z_{bk}/\partial X_{cj} = \mathbb{I}[b=c]\,W_{jk}$ da $\partial L/\partial X_{cj} = \sum_k \Delta_{ck}W_{jk} = (\Delta W^\top)_{cj}$. ∎

El corolario 3.5 es la proposición 3.3 escrita con filas en lugar de columnas y sumada sobre los ejemplos del lote: $X^\top\Delta = \sum_b x_b\,\delta_b^\top$. Es la convención de las bibliotecas de aprendizaje profundo.

Observación 3.6 (Conexión con los LLM). Las proyecciones de consultas, claves y valores de la atención (módulo 13), las dos capas del bloque MLP y la capa final que produce los logits son capas lineales. El paso hacia atrás de un Transformer se compone, en su mayor parte, de los productos $X^\top\Delta$ y $\Delta W^\top$.

3.3 El jacobiano de la softmax

Se recuerda del módulo 1 que, para $z \in \mathbb{R}^K$, $p = \mathrm{softmax}(z)$ tiene componentes $p_i = e^{z_i}/S$ con $S = \sum_k e^{z_k}$.

Proposición 3.7 (Jacobiano de la softmax).

$$\frac{\partial p_i}{\partial z_j} = p_i\big(\mathbb{I}[i=j] - p_j\big), \qquad \textit{es decir,} \qquad J_{\mathrm{softmax}}(z) = \mathrm{diag}(p) - pp^\top.$$

Esta matriz es simétrica y cumple $J_{\mathrm{softmax}}(z)\,\mathbf{1} = 0$.

Demostración. Por la regla del cociente, con $\partial S/\partial z_j = e^{z_j}$: si $i = j$, $\partial p_i/\partial z_i = (e^{z_i}S - e^{z_i}e^{z_i})/S^2 = p_i - p_i^2$; si $i \neq j$, $\partial p_i/\partial z_j = (0 - e^{z_i}e^{z_j})/S^2 = -p_i p_j$. La simetría es evidente en $\operatorname{diag}(p) - pp^\top$. Por último, $\operatorname{diag}(p)\mathbf{1} = p$ y $pp^\top\mathbf{1} = p\,(p^\top\mathbf{1}) = p$, porque las componentes de p suman 1. ■

La igualdad $J_{\text{softmax}}\mathbf{1} = 0$ es la versión infinitesimal de la invariancia por traslación de la softmax (módulo 1, tema 4): sumar la misma constante a todos los logits no cambia las probabilidades.

3.4 Entropía cruzada y el gradiente $p - y$

Sea c el índice del token correcto e $y = e_c$ su vector *one-hot*. La pérdida de entropía cruzada es $L(z) = -\ln p_c$.

Teorema 3.8 (Gradiente de la entropía cruzada).

$$\nabla_z L = p - y.$$

Demostración. Primera demostración (regla de la cadena). L depende de z solo a través de p_c, con $\partial L/\partial p_c = -1/p_c$. Por la proposición 3.7,

$$\frac{\partial L}{\partial z_j} = -\frac{1}{p_c}\frac{\partial p_c}{\partial z_j} = -\frac{1}{p_c}\,p_c\big(\mathbb{I}[c = j] - p_j\big) = p_j - y_j.$$

Segunda demostración (log-suma-exp). $L = -\ln\big(e^{z_c}/S\big) = -z_c + \operatorname{LSE}(z)$. La derivada de $-z_c$ respecto de z_j es $-y_j$, y la de $\operatorname{LSE}(z) = \ln S$ es $e^{z_j}/S = p_j$ (módulo 1, tema 4). ■

Ejemplo 3.9. Sean $z = (2, 1, 0)^\top$ y $c = 1$.

	Token 1 (correcto)	Token 2	Token 3
$p = \operatorname{softmax}(z)$	0,665	0,245	0,090
y	1	0	0
$\nabla_z L = p - y$	−0,335	0,245	0,090

La pérdida es $L = -\ln 0{,}6652 \approx 0{,}408$ nats. Las componentes del gradiente suman 0.

Observación 3.10 (Interpretación). Un paso de descenso $z \leftarrow z - \eta(p - y)$ aumenta el logit correcto en $\eta(1 - p_c)$ y disminuye cada logit incorrecto en ηp_i: se penaliza más a los competidores más probables. El gradiente es pequeño cuando el modelo acierta con confianza ($p_c \approx 1$) y grande cuando se equivoca. Como la expresión $p - y$ no contiene cocientes por p_c, las bibliotecas implementan la softmax y la entropía cruzada como una sola operación, más estable que componer las dos (módulo 11).

Corolario 3.11 (Capa de salida de un LLM). *Sean $h \in \mathbb{R}^d$ el estado oculto de la última posición, $W \in \mathbb{R}^{K\times d}$ la matriz de salida, $z = Wh$ y $L = -\ln \operatorname{softmax}(z)_c$. Entonces*

$$\frac{\partial L}{\partial W} = (p - y)\,h^\top, \qquad \frac{\partial L}{\partial h} = W^\top(p - y).$$

Demostración. Basta aplicar la proposición 3.3 con $\delta = \nabla_z L = p - y$ (teorema 3.8). ■

Con un vocabulario de $K = 10^5$ tokens, W tiene 10^5 filas; la fila i recibe la corrección $(p_i - y_i)\,h$, de modo que todas las filas se actualizan en cada paso, no solo la del token correcto.

Lecturas recomendadas para este tema

- Deisenroth, Faisal y Ong [6], §5.3, §5.4 «Gradients of Matrices» y §5.5 «Useful Identities for Computing Gradients».
- Stanford CS224N [3], tarea 2 (word2vec), apartados escritos: gradientes de la softmax.
- Petersen y Pedersen [9], cap. 2 «Derivatives», como tabla de identidades.

Ejercicios del tema 3

Ejercicio 3.1 ⋆ Un modelo tiene una matriz de *embeddings* E de tamaño $50\,000 \times 4096$. ¿Qué forma tiene $\partial L/\partial E$ y cuántos números contiene? ¿Qué filas pueden ser no nulas en un lote concreto?

Ejercicio 3.2 ⋆ En el teorema 3.8, ¿qué signo tiene la componente del token correcto y qué signo tienen las demás? Describa el efecto de un paso de descenso de gradiente sobre cada logit.

Ejercicio 3.3 ⋆⋆ Sean $W = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 1 & 0 \end{pmatrix}$, $x = (1, 2, 1)^\top$, $t = (0, 3)^\top$ y $L = \tfrac{1}{2}\|Wx - t\|^2$. Calcule $y = Wx$, L, $\partial L/\partial W$ y $\partial L/\partial x$.

Ejercicio 3.4 ⋆⋆ Sean $z = (0, \ln 2, \ln 5)^\top$ y $c = 2$. Calcule p, la pérdida L y el gradiente $\nabla_z L$.

Ejercicio 3.5 ⋆⋆⋆ Demuestre que las componentes de $p - y$ suman cero y que $\mathbf{1}$ pertenece al núcleo de J_{softmax}. Demuestre además que $\nabla_z L$ es ortogonal a $\mathbf{1}$ y explique por qué es coherente con la invariancia de la softmax por traslación.

Ejercicio 3.6 ⋆⋆⋆ En el modelo *skip-gram* de word2vec, la palabra central tiene un vector $v_c \in \mathbb{R}^d$ y cada palabra w del vocabulario tiene un vector de contexto u_w, columna w de $U \in \mathbb{R}^{d \times |\mathcal{V}|}$. La pérdida para la palabra de contexto observada o es $J = -\ln \hat{y}_o$, con $\hat{y} = \text{softmax}(U^\top v_c)$. (a) Demuestre que $\partial J/\partial v_c = U(\hat{y} - y)$, con $y = e_o$. (b) Demuestre que $\partial J/\partial u_w = (\hat{y}_w - y_w)\, v_c$. (c) Calcule ambos con $d = 2$, $|\mathcal{V}| = 3$, $u_1 = (1, 0)^\top$, $u_2 = (0, 1)^\top$, $u_3 = (1, 1)^\top$, $v_c = (\ln 2, 0)^\top$ y $o = 2$.

Fuente: adaptado de Stanford CS224N, invierno de 2021 [3], tarea 2, apartados escritos (b) y (c); el caso numérico es propio.

Tema 4

Taylor, hessiano y puntos críticos

El gradiente describe la inclinación de una función; la curvatura la describe el hessiano. Este tema introduce las derivadas de segundo orden, demuestra el desarrollo de Taylor de segundo orden en varias variables, lo usa para clasificar puntos críticos y, como aplicación central, determina para qué tasas de aprendizaje converge el descenso de gradiente sobre una función cuadrática. Se sigue [6, §5.7 y §5.8], [7, §4.2 y §4.3.1] y la clase 9 de [8].

4.1 El hessiano

Definición 4.1 (Hessiano). Sea $f\colon U \subseteq \mathbb{R}^n \to \mathbb{R}$ con derivadas parciales segundas. El *hessiano* de f en x es la matriz $H_f(x) = \nabla^2 f(x) \in \mathbb{R}^{n\times n}$ de entradas

$$\big(H_f(x)\big)_{ij} = \frac{\partial^2 f}{\partial x_i\, \partial x_j}(x).$$

Equivalentemente, H_f es el jacobiano del gradiente: $H_f = J_{\nabla f}$.

Teorema 4.2 (Schwarz). *Si $f \in C^2(U)$, entonces $\partial^2 f/\partial x_i \partial x_j = \partial^2 f/\partial x_j \partial x_i$ en todo punto de U. En consecuencia, $H_f(x)$ es simétrica.*

La demostración se encuentra en los textos de análisis de varias variables y se omite. Al ser simétrico, el hessiano es diagonalizable en una base ortonormal con autovalores reales (teorema espectral, módulo 3), y esos autovalores son las curvaturas de f en las direcciones de los autovectores [7, §4.3.1].

Ejemplo 4.3. Para $f(x, y) = x^2y + 3y$ se tiene $\partial^2 f/\partial x^2 = 2y$, $\partial^2 f/\partial x\partial y = 2x$ y $\partial^2 f/\partial y^2 = 0$, luego

$$H_f(2, 1) = \begin{pmatrix} 2 & 4 \\ 4 & 0 \end{pmatrix},$$

con autovalores $1 \pm \sqrt{17}$, es decir, 5,123 y $-3{,}123$.

Observación 4.4 (Tamaño del hessiano). Para N parámetros el hessiano tiene N^2 entradas. Con $N = 7 \cdot 10^9$ serían $4{,}9 \cdot 10^{19}$ números, algo imposible de almacenar. En la práctica solo se calculan productos hessiano-vector Hv, que cuestan un múltiplo pequeño de un gradiente, o aproximaciones diagonales.

4.2 Desarrollo de Taylor de segundo orden

Teorema 4.5 (Taylor de segundo orden). *Sea $f \in C^2(U)$ y sean $x \in U$ y $h \in \mathbb{R}^n$ tales que el segmento $\{x + th : t \in [0, 1]\}$ está contenido en U. Entonces:*

(i) (forma de Lagrange) existe $\tau \in (0,1)$ *tal que*

$$f(x+h) = f(x) + \nabla f(x)^\top h + \tfrac{1}{2}\, h^\top H_f(x+\tau h)\, h;$$

(ii) (forma local) cuando $h \to 0$*,*

$$f(x+h) = f(x) + \nabla f(x)^\top h + \tfrac{1}{2}\, h^\top H_f(x)\, h + o(\|h\|^2).$$

Demostración. Sea $\varphi(t) = f(x+th)$ para $t \in [0,1]$. Por el lema 1.12, $\varphi'(t) = \nabla f(x+th)^\top h = \sum_i h_i\, \partial_i f(x+th)$. Aplicando de nuevo el lema a cada función $\partial_i f$, que es diferenciable por ser $f \in C^2$,

$$\varphi''(t) = \sum_i h_i \sum_j h_j\, \partial_j \partial_i f(x+th) = h^\top H_f(x+th)\, h.$$

El teorema de Taylor de una variable con resto de Lagrange da $\varphi(1) = \varphi(0) + \varphi'(0) + \tfrac{1}{2}\varphi''(\tau)$ para algún $\tau \in (0,1)$, que es (i). Para (ii), se resta el término $\tfrac{1}{2} h^\top H_f(x) h$:

$$\left| \tfrac{1}{2}\, h^\top \big(H_f(x+\tau h) - H_f(x)\big) h \right| \le \tfrac{1}{2}\, \|H_f(x+\tau h) - H_f(x)\|\, \|h\|^2,$$

y la norma de la diferencia tiende a 0 cuando $h \to 0$ por la continuidad de las segundas derivadas. ∎

Ejemplo 4.6. Con la función del ejemplo 4.3 en $x = (2,1)$ y $h = (0{,}1;\ -0{,}1)$, donde $f = 7$ y $\nabla f = (4,7)^\top$:

1. primer orden: $7 + (4 \cdot 0{,}1 - 7 \cdot 0{,}1) = 6{,}7$;
2. término cuadrático: $h^\top H h = 2 \cdot 0{,}01 + 2 \cdot 4 \cdot (0{,}1)(-0{,}1) + 0 = -0{,}06$, luego el segundo orden da $6{,}7 - 0{,}03 = 6{,}67$;
3. valor exacto: $f(2{,}1;\ 0{,}9) = 4{,}41 \cdot 0{,}9 + 2{,}7 = 6{,}669$.

El error baja de 0,031 a 0,001 al incluir la curvatura.

4.3 Clasificación de puntos críticos

Definición 4.7 (Punto crítico). Un punto $x^* \in U$ es *crítico* (o estacionario) si $\nabla f(x^*) = 0$. Es un *mínimo local* si existe $r > 0$ con $f(x) \ge f(x^*)$ para $\|x - x^*\| < r$, y un *mínimo local estricto* si la desigualdad es estricta para $x \neq x^*$. Un punto crítico que no es mínimo ni máximo local es un *punto de silla*.

Teorema 4.8 (Condición necesaria de primer orden). *Si* f *es diferenciable en* x^* *y* x^* *es un mínimo local, entonces* $\nabla f(x^*) = 0$*.*

Demostración. Si $g = \nabla f(x^*) \neq 0$, la proposición 1.15 da puntos $x^* - \eta g$, arbitrariamente próximos a x^*, con $f(x^* - \eta g) < f(x^*)$, lo que contradice que x^* sea un mínimo local. ∎

Teorema 4.9 (Criterio del hessiano). *Sea* $f \in C^2(U)$ *y* x^* *un punto crítico.*

(i) Si $H_f(x^*) \succ 0$ *(todos sus autovalores son positivos),* x^* *es un mínimo local estricto.*

(ii) Si $H_f(x^*) \prec 0$ *(todos negativos),* x^* *es un máximo local estricto.*

(iii) Si $H_f(x^*)$ *tiene autovalores de ambos signos,* x^* *es un punto de silla.*

Demostración. Sea $H = H_f(x^*)$. Por el teorema 4.5(ii) con $\nabla f(x^*) = 0$, $f(x^* + h) - f(x^*) = \frac{1}{2} h^\top H h + o(\|h\|^2)$.

(i) Por el teorema espectral, $h^\top H h \geq \lambda_{\min}(H)\|h\|^2$ con $\lambda_{\min}(H) > 0$. Existe $r > 0$ tal que el resto es menor que $\frac{1}{4}\lambda_{\min}\|h\|^2$ en valor absoluto si $0 < \|h\| < r$, y entonces $f(x^*+h) - f(x^*) \geq \frac{1}{4}\lambda_{\min}\|h\|^2 > 0$.

(ii) Basta aplicar (i) a $-f$.

(iii) Sean v_+ y v_- autovectores unitarios con autovalores $\lambda_+ > 0$ y $\lambda_- < 0$. Para $h = t\, v_\pm$ se tiene $f(x^* + t v_\pm) - f(x^*) = \frac{1}{2}\lambda_\pm t^2 + o(t^2)$, que para $t \neq 0$ pequeño tiene el signo de $\lambda_\pm$. Así, en todo entorno de x^* hay puntos con valores mayores y menores que $f(x^*)$. ∎

Cuadro 4.1: Clasificación de un punto crítico según los autovalores de $H_f(x^*)$.

Autovalores de $H_f(x^*)$	Tipo de punto	Ejemplo en $(0,0)$
todos > 0	mínimo local estricto	$x^2 + y^2$
todos < 0	máximo local estricto	$-x^2 - y^2$
de ambos signos	punto de silla	$x^2 - y^2$
alguno nulo, el resto del mismo signo	no concluyente	$x^4 + y^2$, $-x^4 + y^2$

Observación 4.10 (Criterio en dos variables). Para $n = 2$, el producto de los autovalores es $\det H$ y su suma es $\operatorname{tr} H$. Por ello, si $\det H < 0$ el punto es de silla, y si $\det H > 0$ es un mínimo cuando $f_{xx} > 0$ y un máximo cuando $f_{xx} < 0$. Es la forma en que se presenta el criterio en [8, clase 9].

Observación 4.11 (Conexión con los LLM). El hessiano del ejemplo 4.3 tiene autovalores de ambos signos: es una curvatura de silla. En espacios de dimensión muy alta, la mayoría de los puntos críticos de la pérdida de una red son puntos de silla, no mínimos locales malos, porque basta con que uno solo de los N autovalores sea negativo [5].

4.4 Curvatura y descenso de gradiente

El teorema 4.5 permite analizar el descenso de gradiente más allá de la proposición 1.15. El caso modelo es una función cuadrática, que coincide con su propio desarrollo de Taylor de segundo orden.

Proposición 4.12 (Descenso de gradiente sobre una cuadrática). *Sea $f(x) = \frac{1}{2} x^\top A x$ con A simétrica y autovalores $0 < \lambda_1 \leq \cdots \leq \lambda_n$. La iteración $x_{k+1} = x_k - \eta \nabla f(x_k)$ converge al mínimo $x^* = 0$ desde todo punto inicial si y solo si*

$$0 < \eta < \frac{2}{\lambda_n} = \frac{2}{\lambda_{\max}(A)}.$$

Demostración. Como $\nabla f(x) = Ax$, la iteración es $x_{k+1} = (I - \eta A)x_k$, luego $x_k = (I - \eta A)^k x_0$. Sea $A = Q \Lambda Q^\top$ la descomposición espectral y $c^{(k)} = Q^\top x_k$ las coordenadas en la base de autovectores. Entonces $c_i^{(k)} = (1 - \eta\lambda_i)^k c_i^{(0)}$ para cada i. Todas las coordenadas tienden a 0 para todo x_0 si y solo si $|1 - \eta\lambda_i| < 1$ para todo i, es decir, $0 < \eta\lambda_i < 2$. La condición más exigente es la del mayor autovalor. ∎

Ejemplo 4.13. La función $f(x,y) = x^2 + 3y^2$ del ejemplo 1.16 es $\frac{1}{2}x^\top Ax$ con $A = \operatorname{diag}(2,6)$. El descenso converge si y solo si $\eta < 2/6 = 1/3$. Con $\eta = 0{,}1$, los factores de contracción son $1 - 0{,}2 = 0{,}8$ en x y $1 - 0{,}6 = 0{,}4$ en y, lo que reproduce el paso $(1,1) \to (0{,}8;\ 0{,}4)$.

Observación 4.14 (Número de condición). El factor de contracción en la dirección i es $|1-\eta\lambda_i|$. Con la elección óptima $\eta = 2/(\lambda_1 + \lambda_n)$, el peor factor vale $(\kappa - 1)/(\kappa + 1)$, donde $\kappa = \lambda_n/\lambda_1$ es el *número de condición* de A. Cuando κ es grande, la tasa de aprendizaje está limitada por la dirección de mayor curvatura y el progreso en la de menor curvatura es muy lento. Es el fenómeno de mal condicionamiento descrito en [7, §4.2 y §4.3.1], y la motivación de métodos como Adam (módulo 7).

Proposición 4.15 (Paso óptimo a lo largo del gradiente). *Sea $g = \nabla f(x) \neq 0$ y $H = H_f(x)$ con $g^\top H g > 0$. La aproximación de segundo orden $q(\eta) = f(x) - \eta\, g^\top g + \frac{1}{2}\eta^2 g^\top H g$ de $f(x - \eta g)$ es mínima en*

$$\eta^* = \frac{g^\top g}{g^\top H g}.$$

Si f es cuadrática, η^* minimiza exactamente $f(x - \eta g)$.

Demostración. q es un polinomio de grado 2 en η con coeficiente director $\frac{1}{2}g^\top H g > 0$; su derivada $q'(\eta) = -g^\top g + \eta\, g^\top H g$ se anula en η^*. Si f es cuadrática, el resto del teorema 4.5 es nulo y $q(\eta) = f(x - \eta g)$. ∎

Ejemplo 4.16. En el ejemplo 1.16, $g = (2,6)^\top$, $g^\top g = 40$ y $g^\top H g = 2 \cdot 4 + 6 \cdot 36 = 224$, luego $\eta^* = 40/224 = 5/28 \approx 0{,}1786$. El paso lleva a $(9/14,\ -1/14) \approx (0{,}6429;\ -0{,}0714)$, con $f = 3/7 \approx 0{,}4286$, frente a 1,12 con $\eta = 0{,}1$.

Observación 4.17 (Relación con la física). Cerca de un mínimo, $f(x^* + h) \approx f(x^*) + \frac{1}{2}h^\top H h$ es la energía potencial de un sistema de muelles con matriz de rigidez H. Los autovalores grandes corresponden a muelles rígidos, que oscilan deprisa; un paso de descenso demasiado largo en esa dirección sobrepasa el equilibrio y el sistema discreto diverge, como establece la proposición 4.12.

Lecturas recomendadas para este tema

- Deisenroth, Faisal y Ong [6], §5.7 «Higher-Order Derivatives» y §5.8 «Linearization and Multivariate Taylor Series».
- Goodfellow, Bengio y Courville [7], §4.2 «Poor Conditioning» y §4.3.1 «Beyond the Gradient: Jacobian and Hessian Matrices».
- MIT 18.02 [8], clase 8 «Max-Min Problems» y clase 9 «2nd Derivative Test».
- Dauphin *et al.* [5], sobre la abundancia de puntos de silla en alta dimensión.

Ejercicios del tema 4

Ejercicio 4.1 ⋆ Justifique si son verdaderas o falsas: (a) si $\nabla f(x) = 0$, entonces x es un mínimo local; (b) si $f \in C^2$, su hessiano es simétrico; (c) si $\nabla f(x^*) = 0$ y $H_f(x^*)$ tiene un autovalor nulo y los demás positivos, x^* es un mínimo local.

Ejercicio 4.2 ⋆⋆ Sea $f(x, y) = x^3 + xy$. En $(1, 1)$ y con $h = (0{,}1; -0{,}2)$, calcule las aproximaciones de Taylor de primer y segundo orden de $f(x + h)$ y compárelas con el valor exacto. ¿Puede ser f convexa en un entorno de $(1, 1)$?

Ejercicio 4.3 ⋆⋆ Sea $f(x, y) = x^3 - 3x^2 + xy - y^2 + x + y$. Encuentre sus puntos críticos y clasifíquelos con el teorema 4.9.

Fuente: adaptado de MIT 18.02, primavera de 2006 [8], *Problem Set* 4, segunda parte, problema 1 (el original pide además los extremos en el cuadrado $[0, 2]^2$).

Ejercicio 4.4 ⋆⋆ Sea $f(x, y) = x^2 + 4y^2$. (a) Determine las tasas de aprendizaje η para las que el descenso de gradiente converge. (b) Desde $(1, 1)$, calcule dos iteraciones y el valor de f con $\eta = 0{,}2$ y con $\eta = 0{,}3$. (c) Calcule la tasa η que minimiza el peor factor de contracción y el valor de ese factor.

Ejercicio 4.5 ⋆⋆⋆ Sea $f \in C^2(U)$ y x^* un mínimo local. Demuestre que $H_f(x^*) \succeq 0$ (condición necesaria de segundo orden). Muestre con un ejemplo que el recíproco es falso: $\nabla f(x^*) = 0$ y $H_f(x^*) \succeq 0$ no implican que x^* sea un mínimo local.

Tema 5

Convexidad

En una función convexa, todo mínimo local es global, de modo que un método de descenso no puede quedar atrapado en un mínimo malo. Este tema define los conjuntos y las funciones convexas, demuestra las caracterizaciones de primer y segundo orden, establece las operaciones que conservan la convexidad y las aplica a la entropía cruzada. Termina explicando por qué la pérdida de una red profunda no es convexa. Se sigue [1, §3.1, §3.2 y §4.2] y las transparencias correspondientes de [2].

5.1 Conjuntos y funciones convexas

Definición 5.1 (Conjunto convexo). Un conjunto $C \subseteq \mathbb{R}^n$ es *convexo* si, para todo $a, b \in C$ y todo $\lambda \in [0,1]$, el punto $\lambda a + (1-\lambda)b$ pertenece a C: contiene el segmento que une dos cualesquiera de sus puntos.

Definición 5.2 (Función convexa). Sea $C \subseteq \mathbb{R}^n$ convexo. Una función $f\colon C \to \mathbb{R}$ es *convexa* si

$$f\big(\lambda a + (1-\lambda)b\big) \le \lambda f(a) + (1-\lambda) f(b) \qquad \text{para todo } a, b \in C,\ \lambda \in [0,1],$$

y *estrictamente convexa* si la desigualdad es estricta cuando $a \neq b$ y $\lambda \in (0,1)$. Se dice que f es *cóncava* si $-f$ es convexa.

Geométricamente, la cuerda que une $(a, f(a))$ con $(b, f(b))$ queda por encima de la gráfica (figura 5.1). Son convexas, por ejemplo, las funciones afines $a^\top x + b$ (con igualdad en la definición), toda norma (por la desigualdad triangular y la homogeneidad) y $x \mapsto e^x$ en $\mathbb{R}$.

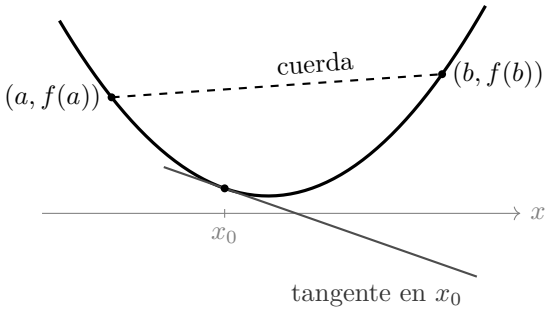


Figura 5.1: Una función convexa queda por debajo de sus cuerdas (definición 5.2) y por encima de sus tangentes (teorema 5.4).

Lema 5.3 (Restricción a rectas). *Sea C abierto y convexo. Una función $f\colon C \to \mathbb{R}$ es convexa si y solo si, para todo $x \in C$ y todo $v \in \mathbb{R}^n$, la función de una variable $\varphi(t) = f(x+tv)$ es convexa en el intervalo $\{t : x + tv \in C\}$.*

Demostración. Si f es convexa, para t_1, t_2 en el intervalo, $\varphi(\lambda t_1 + (1-\lambda)t_2) = f\big(\lambda(x+t_1 v) + (1-\lambda)(x+t_2 v)\big) \le \lambda\varphi(t_1) + (1-\lambda)\varphi(t_2)$. Recíprocamente, dados $a, b \in C$, se toma $x = b$, $v = a - b$: entonces $\varphi(\lambda) = f(\lambda a + (1-\lambda)b)$ y la convexidad de φ entre $t = 0$ y $t = 1$ es exactamente la desigualdad de la definición 5.2. ∎

5.2 Condiciones de primer y segundo orden

Teorema 5.4 (Condición de primer orden). *Sea C abierto y convexo y $f\colon C \to \mathbb{R}$ diferenciable. Entonces f es convexa si y solo si*

$$f(b) \ge f(a) + \nabla f(a)^\top (b - a) \qquad \text{para todo } a, b \in C.$$

Demostración. ($\Rightarrow$) Para $\lambda \in (0, 1]$, la convexidad da $f(a + \lambda(b-a)) \le f(a) + \lambda\big(f(b) - f(a)\big)$, es decir,

$$\frac{f(a + \lambda(b-a)) - f(a)}{\lambda} \le f(b) - f(a).$$

Cuando $\lambda \to 0^+$, el miembro izquierdo tiende a $\nabla f(a)^\top (b-a)$ (proposición 1.9, sin normalizar la dirección), y se obtiene la desigualdad.

($\Leftarrow$) Sean $a, b \in C$, $\lambda \in [0, 1]$ y $m = \lambda a + (1-\lambda)b$. Aplicando la hipótesis en el punto m hacia a y hacia b,

$$f(a) \ge f(m) + \nabla f(m)^\top (a - m), \qquad f(b) \ge f(m) + \nabla f(m)^\top (b - m).$$

Multiplicando por λ y $1-\lambda$ y sumando, el término del gradiente se anula, porque $\lambda(a-m) + (1-\lambda)(b-m) = 0$, y queda $\lambda f(a) + (1-\lambda) f(b) \ge f(m)$. ∎

La condición de primer orden dice que el plano tangente en cualquier punto es una cota inferior global de f: la información local del gradiente proporciona información global.

Teorema 5.5 (Condición de segundo orden). *Sea C abierto y convexo y $f \in C^2(C)$. Entonces f es convexa si y solo si $H_f(x) \succeq 0$ para todo $x \in C$. Si $H_f(x) \succ 0$ para todo $x \in C$, entonces f es estrictamente convexa.*

Demostración. ($\Leftarrow$) Sean $a, b \in C$. Por el teorema 4.5(i), $f(b) = f(a) + \nabla f(a)^\top (b-a) + \frac{1}{2}(b-a)^\top H_f(\xi)(b-a)$ para un punto ξ del segmento, que está en C. El último término es ≥ 0, luego se cumple la condición de primer orden y f es convexa por el teorema 5.4. Si $H_f \succ 0$ y $a \ne b$, el término es > 0; repitiendo la demostración del teorema 5.4 con desigualdades estrictas se obtiene la convexidad estricta.

($\Rightarrow$) Supóngase que existen $x \in C$ y v con $v^\top H_f(x) v < 0$, y sea $\varphi(t) = f(x + tv)$. Por la demostración del teorema 4.5, $\varphi''(0) = v^\top H_f(x) v < 0$ y, por continuidad, $\varphi'' < 0$ en un intervalo alrededor de 0. En ese intervalo φ es estrictamente cóncava, luego no es convexa, y por el lema 5.3 tampoco lo es f. ∎

Ejemplo 5.6. $f(x, y) = x^2 + xy + y^2$ tiene hessiano constante $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, con autovalores 1 y 3. Por el teorema 5.5, es estrictamente convexa en $\mathbb{R}^2$. En cambio, $x^2 - y^2$, con autovalores 2 y -2, no es convexa.

Observación 5.7. El recíproco de la segunda parte del teorema 5.5 es falso: $f(x) = x^4$ es estrictamente convexa en $\mathbb{R}$, pero $f''(0) = 0$.

5.3 Mínimos de funciones convexas

Teorema 5.8 (Mínimos locales y globales). *Sea $f\colon C \to \mathbb{R}$ convexa. Todo mínimo local de f es un mínimo global. Si además f es diferenciable y C es abierto, un punto x^* es mínimo global si y solo si $\nabla f(x^*) = 0$.*

Demostración. Sea x^* un mínimo local, con $f(x) \geq f(x^*)$ si $\|x - x^*\| < r$, y supóngase que existe $b \in C$ con $f(b) < f(x^*)$. Para $\lambda \in (0,1)$ suficientemente pequeño, el punto $m = (1-\lambda)x^* + \lambda b$ está a distancia $\lambda\|b - x^*\| < r$ de x^*, y por convexidad

$$f(m) \leq (1-\lambda)f(x^*) + \lambda f(b) < f(x^*),$$

lo que contradice que x^* sea mínimo local. Para la segunda afirmación: si x^* es mínimo, $\nabla f(x^*) = 0$ por el teorema 4.8; si $\nabla f(x^*) = 0$, el teorema 5.4 da $f(b) \geq f(x^*)$ para todo $b \in C$. ∎

Para funciones no convexas, $\nabla f = 0$ solo es una condición necesaria. Para funciones convexas es también suficiente, y además global. Por eso el descenso de gradiente con una tasa adecuada resuelve los problemas convexos, como la regresión lineal y la regresión logística o softmax del módulo 8.

5.4 Operaciones que conservan la convexidad

Proposición 5.9. *(i) Si $f_1, \ldots, f_k$ son convexas y $w_1, \ldots, w_k \geq 0$, entonces $\sum_i w_i f_i$ es convexa.*

(ii) Si $f\colon \mathbb{R}^m \to \mathbb{R}$ es convexa, $A \in \mathbb{R}^{m\times n}$ y $b \in \mathbb{R}^m$, entonces $g(x) = f(Ax + b)$ es convexa.

(iii) Si f_1 y f_2 son convexas, $\max(f_1, f_2)$ es convexa.

Demostración. (i) Se multiplica la desigualdad de la definición 5.2 de cada f_i por $w_i \geq 0$ y se suma. (ii) Para $u, u' \in \mathbb{R}^n$, $A(\lambda u + (1-\lambda)u') + b = \lambda(Au + b) + (1-\lambda)(Au' + b)$, luego $g(\lambda u + (1-\lambda)u') = f\big(\lambda(Au+b) + (1-\lambda)(Au'+b)\big) \leq \lambda g(u) + (1-\lambda)g(u')$. (iii) Para cada i, $f_i(\lambda a + (1-\lambda)b) \leq \lambda f_i(a) + (1-\lambda)f_i(b) \leq \lambda \max(f_1,f_2)(a) + (1-\lambda)\max(f_1,f_2)(b)$; basta tomar el máximo en i del miembro izquierdo. ∎

Proposición 5.10 (Convexidad de log-suma-exp). *La función $\mathrm{LSE}(z) = \ln \sum_{k=1}^{K} e^{z_k}$ es convexa en $\mathbb{R}^K$. Su hessiano es $H = \mathrm{diag}(p) - pp^\top$ con $p = \mathrm{softmax}(z)$, y para todo $v \in \mathbb{R}^K$*

$$v^\top H v = \sum_i p_i v_i^2 - \Big(\sum_i p_i v_i\Big)^2 = \mathrm{Var}_{i\sim p}[v_i] \geq 0,$$

con igualdad si y solo si v es proporcional a $\mathbf{1}$.

Demostración. El gradiente de LSE es $p = \mathrm{softmax}(z)$ (módulo 1, tema 4), y su jacobiano, por la proposición 3.7, es $\mathrm{diag}(p) - pp^\top$. Desarrollando la forma cuadrática se obtiene la varianza de la variable aleatoria que toma el valor v_i con probabilidad p_i, que es no negativa. Como todas las p_i son positivas, la varianza es nula si y solo si todos los v_i son iguales. Se concluye por el teorema 5.5. ∎

La demostración de [1, §3.1] obtiene la misma desigualdad mediante la de Cauchy–Schwarz.

Corolario 5.11 (Convexidad de la entropía cruzada). *La entropía cruzada* $L(z) = -z_c + \mathrm{LSE}(z)$ *es convexa en los logits* z*. Para un vector* x *fijo,* $W \mapsto -\ln \mathrm{softmax}(Wx)_c$ *es convexa en* W*, y la pérdida media de la regresión softmax sobre un conjunto de datos es convexa en sus parámetros.*

Demostración. L es la suma de una función afín y de LSE, ambas convexas (proposición 5.9(i) y proposición 5.10). La aplicación $W \mapsto Wx$ es lineal, y la (ii) da la convexidad en W. La pérdida media es una suma con pesos positivos de funciones convexas. ■

Para $z = (2, 1, 0)^\top$, el hessiano de la entropía cruzada tiene autovalores 0, 0,119 y 0,371. El autovalor nulo corresponde a la dirección $\mathbf{1}$, a lo largo de la cual la pérdida es constante.

5.5 Las redes profundas no son convexas

Proposición 5.12 (Simetría y convexidad). *Sea* $L\colon \mathbb{R}^N \to \mathbb{R}$ *convexa. El conjunto de sus mínimos globales es convexo. En consecuencia, si* θ_1 *y* θ_2 *son mínimos globales y* $\frac{1}{2}(\theta_1 + \theta_2)$ *no lo es,* L *no es convexa.*

Demostración. Sea $m = \min L$ y θ_1, θ_2 con $L(\theta_1) = L(\theta_2) = m$. Para $\lambda \in [0, 1]$, $L(\lambda\theta_1 + (1 - \lambda)\theta_2) \le \lambda m + (1 - \lambda)m = m$, y como m es el mínimo, se da la igualdad. ■

En una red con una capa oculta, intercambiar dos neuronas ocultas (junto con sus pesos de entrada y de salida) no cambia la función calculada. Si θ_1 es un mínimo, la permutación θ_2 también lo es, pero el punto medio promedia las dos neuronas y, en general, calcula otra función con pérdida mayor. Por la proposición 5.12, la pérdida no es convexa.

Ejemplo 5.13 (Una red lineal de dos capas). La red más sencilla con dos capas calcula $\hat{y} = w_2 w_1 x$. Con un único dato $(x, y) = (1, 1)$ y pérdida cuadrática, $L(w_1, w_2) = (1 - w_1 w_2)^2$. Los mínimos globales ($L = 0$) forman la hipérbola $w_1 w_2 = 1$, que no es un conjunto convexo: $(1, 1)$ y $(-1, -1)$ son mínimos, pero su punto medio $(0, 0)$ da $L = 1$. Además,

$$H_L(w_1, w_2) = \begin{pmatrix} 2w_2^2 & 4w_1 w_2 - 2 \\ 4w_1 w_2 - 2 & 2w_1^2 \end{pmatrix}, \qquad H_L(0, 0) = \begin{pmatrix} 0 & -2 \\ -2 & 0 \end{pmatrix},$$

con autovalores ± 2: el origen es un punto de silla. La función calculada, $w_1 w_2 x$, es lineal en x; la falta de convexidad procede solo de la composición de dos capas.

Observación 5.14 (Conexión con los LLM). La pérdida de un Transformer como función de sus pesos no es convexa, y no hay garantía teórica general de que el descenso de gradiente alcance un mínimo global. En la práctica, el entrenamiento funciona de manera muy robusta gracias a la sobreparametrización, la inicialización cuidadosa, la normalización y los métodos adaptativos (módulos 7 y 11). La explicación teórica completa de este hecho sigue siendo un problema abierto.

Lecturas recomendadas para este tema

– Boyd y Vandenberghe [1], §3.1 «Basic properties and examples» (definición, condiciones de primer y segundo orden, ejemplos, incluida log-suma-exp), §3.2 «Operations that preserve convexity» y §4.2 «Convex optimization» (óptimos locales y globales).

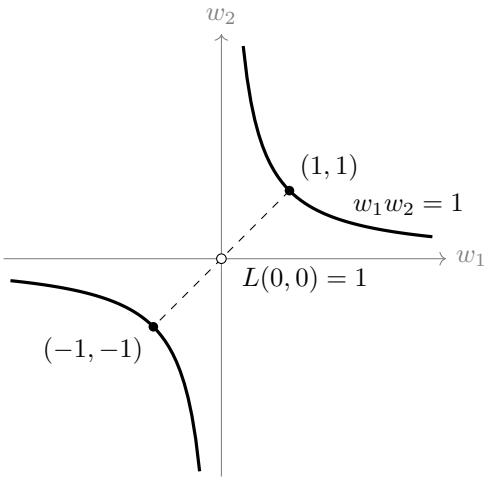


Figura 5.2: Mínimos globales de $L(w_1, w_2) = (1 - w_1 w_2)^2$ (ejemplo 5.13). El segmento que une dos mínimos sale del conjunto de mínimos: la pérdida no es convexa.

- Stanford EE364a [2], transparencias «Convex functions».
- Goodfellow, Bengio y Courville [7], §4.3 (optimización convexa frente a no convexa).

Ejercicios del tema 5

Ejercicio 5.1 ⋆ Justifique si son verdaderas o falsas: (a) toda función C^2 con hessiano semidefinido positivo en todo $\mathbb{R}^n$ es convexa; (b) el producto de dos funciones convexas es convexo; (c) el máximo de dos funciones convexas es convexo.

Ejercicio 5.2 ⋆⋆ Decida, con el teorema 5.5, cuáles de las siguientes funciones de $\mathbb{R}^2$ son convexas y cuáles estrictamente convexas: (a) $x^2 + xy + y^2$; (b) $x^2 - 4xy + y^2$; (c) e^{x+y}; (d) $x^4 + y^2$.

Ejercicio 5.3 ⋆⋆ En el dominio $\mathbb{R}^2_{++} = \{(x_1, x_2) : x_1 > 0,\ x_2 > 0\}$, determine si cada función es convexa, cóncava o ninguna de las dos: (a) $f(x) = x_1 x_2$; (b) $f(x) = 1/(x_1 x_2)$; (c) $f(x) = x_1^2 / x_2$.

Fuente: adaptado de Boyd y Vandenberghe [1], ejercicio 3.16 (selección de casos; se omite el estudio de la cuasiconvexidad).

Ejercicio 5.4 ⋆⋆ Sea $L(w_1, w_2) = (2 - w_1 w_2)^2$, la pérdida de una red lineal de dos capas con el dato $(x, y) = (1, 2)$. (a) Compruebe que $(1, 2)$ y $(2, 1)$ son mínimos globales y evalúe L en su punto medio. (b) Calcule $H_L(0, 0)$ y clasifique el origen. (c) Concluya sobre la convexidad de L.

Ejercicio 5.5 ⋆⋆⋆ Demuestre directamente, a partir de la definición 5.2 y de la convexidad de $\varphi(z) = -z_c + \mathrm{LSE}(z)$, que $L(W) = \varphi(Wx)$ es convexa en W para x fijo. Explique qué paso de la demostración falla para una red $\varphi(W_2\, \sigma(W_1 x))$ con una función de activación no lineal σ.

Ejercicio 5.6 ⋆⋆⋆ Sea $f\colon C \to \mathbb{R}$ estrictamente convexa. Demuestre que f tiene a lo sumo un mínimo global. Demuestre que la entropía cruzada $L(z)$ no es estrictamente convexa en $\mathbb{R}^K$. Demuestre que $L_\mu(z) = L(z) + \frac{\mu}{2}\|z\|^2$, con $\mu > 0$, es estrictamente convexa, que tiene a lo sumo un mínimo y que, si lo tiene, sus componentes suman cero.

Tema 6

Diferenciación numérica y comprobación de gradientes

Un error en la implementación de un gradiente no suele provocar un fallo visible: el entrenamiento avanza, pero peor de lo que debería. La herramienta estándar para detectarlo es comparar el gradiente analítico con una aproximación por diferencias finitas. Este tema analiza el error de truncamiento de las diferencias finitas con el teorema de Taylor, el error de redondeo de la aritmética de coma flotante y el compromiso entre ambos, y describe el procedimiento de comprobación de gradientes. Se sigue [7, §4.1] y las notas de [4].

6.1 Diferencias finitas

Definición 6.1 (Diferencias finitas). Sea $f\colon \mathbb{R}^n \to \mathbb{R}$ y $h > 0$. Las *diferencias hacia delante* y *centrada* en la coordenada i son

$$\Delta_i^{+} f(x) = \frac{f(x + h\,e_i) - f(x)}{h}, \qquad \Delta_i^{c} f(x) = \frac{f(x + h\,e_i) - f(x - h\,e_i)}{2h}.$$

Ambas aproximan $\partial f/\partial x_i(x)$ cuando $h \to 0$.

Proposición 6.2 (Error de truncamiento). *Sea $\phi\colon \mathbb{R} \to \mathbb{R}$ y $x \in \mathbb{R}$.*

(i) Si $\phi \in C^2$, existe $\xi \in (x, x+h)$ tal que $\dfrac{\phi(x+h) - \phi(x)}{h} = \phi'(x) + \dfrac{h}{2}\,\phi''(\xi)$.

(ii) Si $\phi \in C^3$, existe $\xi \in (x-h, x+h)$ tal que $\dfrac{\phi(x+h) - \phi(x-h)}{2h} = \phi'(x) + \dfrac{h^2}{6}\,\phi'''(\xi)$.

En consecuencia, el error de la diferencia hacia delante es $O(h)$ y el de la centrada es $O(h^2)$.

Demostración. (i) Es el teorema de Taylor con resto de Lagrange de orden 2: $\phi(x+h) = \phi(x) + h\phi'(x) + \frac{h^2}{2}\phi''(\xi)$; basta restar $\phi(x)$ y dividir por h.

(ii) Con resto de orden 3, $\phi(x \pm h) = \phi(x) \pm h\phi'(x) + \frac{h^2}{2}\phi''(x) \pm \frac{h^3}{6}\phi'''(\xi_{\pm})$, con $\xi_+ \in (x, x+h)$ y $\xi_- \in (x-h, x)$. Al restar, los términos de orden par se cancelan:

$$\frac{\phi(x+h) - \phi(x-h)}{2h} = \phi'(x) + \frac{h^2}{6} \cdot \frac{\phi'''(\xi_+) + \phi'''(\xi_-)}{2}.$$

La media de los dos valores de ϕ''' está entre ambos y, por el teorema de los valores intermedios aplicado a la función continua ϕ''', es igual a $\phi'''(\xi)$ para algún $\xi \in (x-h, x+h)$. ∎

Para una función de varias variables se aplica la proposición a $\phi(t) = f(x + t\,e_i)$.

Ejemplo 6.3. Para $f(x) = e^x$ en $x = 0$, con derivada exacta 1, la proposición 6.2 predice errores de $h/2$ y $h^2/6$ aproximadamente. El cuadro 6.1 lo confirma: al dividir h entre 10, el error hacia delante se divide entre 10 y el centrado entre 100.

Cuadro 6.1: Diferencias finitas para $f(x) = e^x$ en $x = 0$ (ejemplo 6.3).

h	Hacia delante	Error	Centrada	Error
0,1	1,051709	$5{,}17 \cdot 10^{-2}$	1,001668	$1{,}67 \cdot 10^{-3}$
0,01	1,005017	$5{,}02 \cdot 10^{-3}$	1,0000167	$1{,}67 \cdot 10^{-5}$
0,001	1,000500	$5{,}00 \cdot 10^{-4}$	1,00000017	$1{,}67 \cdot 10^{-7}$

6.2 Error de redondeo y elección del paso

En aritmética de coma flotante, cada evaluación de f tiene un error relativo de redondeo del orden del *épsilon de la máquina* $\varepsilon_{\text{máq}}$: unos $1{,}1 \cdot 10^{-16}$ en doble precisión (fp64), $6{,}0 \cdot 10^{-8}$ en simple precisión (fp32) y $3{,}9 \cdot 10^{-3}$ en el formato bf16 que se usa para entrenar modelos de lenguaje [7, §4.1]. Al restar dos valores casi iguales, $f(x+h)$ y $f(x-h)$, los errores absolutos, de tamaño $\varepsilon_{\text{máq}}|f(x)|$, no disminuyen, y al dividir por $2h$ se amplifican.

Proposición 6.4 (Paso óptimo de la diferencia centrada). *Supóngase que cada evaluación de f tiene un error absoluto a lo sumo $\varepsilon|f|$ y que $|\phi'''| \le M$ cerca de x. Entonces el error total de la diferencia centrada está acotado por*

$$E(h) = \frac{\varepsilon|f|}{h} + \frac{Mh^2}{6},$$

que alcanza su mínimo en

$$h^* = \left(\frac{3\varepsilon|f|}{M}\right)^{1/3}, \qquad E(h^*) = \frac{M}{2}\,(h^*)^2 = O\big(\varepsilon^{2/3}\big).$$

Demostración. El numerador calculado difiere del exacto en a lo sumo $2\varepsilon|f|$, y al dividir por $2h$ se obtiene el primer término; el segundo es la cota de truncamiento de la proposición 6.2(ii). En $(0,\infty)$, $E'(h) = -\varepsilon|f|/h^2 + Mh/3$ se anula solo en h^*, con $E' < 0$ antes y $E' > 0$ después, luego h^* es el mínimo. Sustituyendo $\varepsilon|f| = M(h^*)^3/3$ se obtiene $E(h^*) = M(h^*)^2/3 + M(h^*)^2/6 = M(h^*)^2/2$. ∎

Con $|f| \approx M \approx 1$ y doble precisión, $h^* \approx (3{,}3 \cdot 10^{-16})^{1/3} \approx 7 \cdot 10^{-6}$ y el error mínimo es del orden de 10^{-11}. Pasos más pequeños empeoran el resultado (figura 6.1). En simple precisión, $h^* \approx 6 \cdot 10^{-3}$ y el error mínimo es del orden de 10^{-5}; en bf16 la comprobación carece de sentido. Por ello, los gradientes se comprueban siempre en doble precisión.

6.3 Comprobación de gradientes

Definición 6.5 (Error relativo). Sean a una componente del gradiente analítico y n la correspondiente aproximación numérica, no ambas nulas. Su *error relativo* es

$$r(a,n) = \frac{|a-n|}{\max(|a|,|n|)}.$$

El error relativo, a diferencia del absoluto, no depende de la escala del gradiente. Las notas de [4] proponen como orientación, para comprobaciones en doble precisión: $r > 10^{-2}$ indica casi con seguridad un error; $10^{-4} < r < 10^{-2}$ es sospechoso, salvo en funciones con puntos no derivables; $r \le 10^{-7}$ indica un gradiente correcto. En redes profundas, el error relativo tiende a crecer con la profundidad.

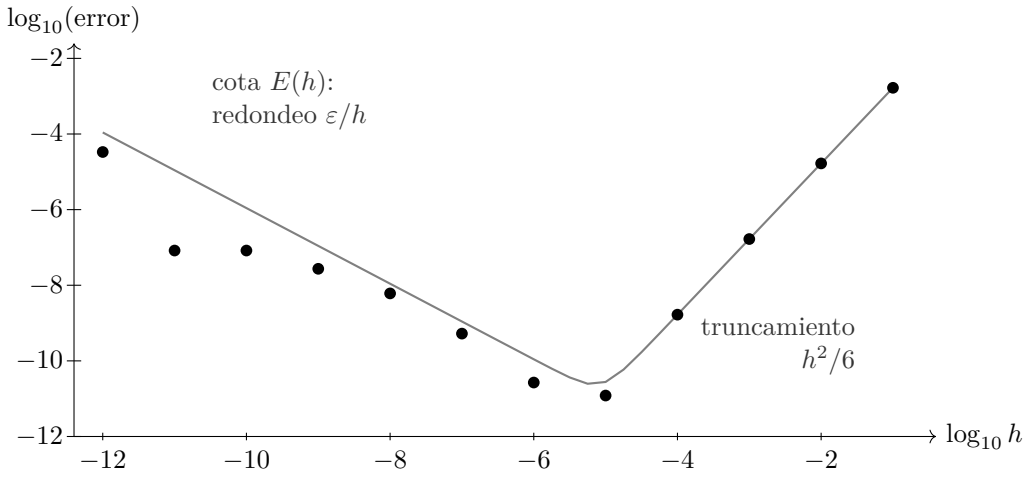


Figura 6.1: Error de la diferencia centrada para $f(x) = e^x$ en $x = 0$, calculada en doble precisión (puntos), y cota $E(h)$ de la proposición 6.4 con $\varepsilon = 1{,}1 \cdot 10^{-16}$ y $|f| = M = 1$ (línea). A la derecha domina el truncamiento (pendiente 2); a la izquierda, el redondeo (pendiente -1). El error medido mínimo, $1{,}2 \cdot 10^{-11}$, se obtiene con $h = 10^{-5}$.

Proposición 6.6 (Coste de la comprobación). *Calcular el gradiente completo de $f\colon \mathbb{R}^N \to \mathbb{R}$ por diferencias centradas requiere $2N$ evaluaciones de f. En cambio, para una dirección $v \in \mathbb{R}^N$, la derivada direccional $\nabla f(x)^\top v$ se aproxima con dos evaluaciones:*

$$\nabla f(x)^\top v = \frac{f(x + hv) - f(x - hv)}{2h} + O(h^2).$$

Demostración. La primera afirmación se sigue de la definición 6.1: dos evaluaciones por coordenada. Para la segunda, se aplica la proposición 6.2(ii) a $\phi(t) = f(x + tv)$, cuya derivada en 0 es $\nabla f(x)^\top v$ por el lema 1.12. ■

La retropropagación obtiene el gradiente completo con un coste equivalente a unas pocas evaluaciones de f (proposición 2.9). Las diferencias finitas, por tanto, no sirven para entrenar, sino para *verificar*. El procedimiento habitual es el siguiente [4]:

1. usar doble precisión y un modelo o un lote pequeños, con pocos datos;
2. comparar componentes elegidas al azar, o derivadas direccionales en direcciones aleatorias, mediante el error relativo;
3. tomar h del orden de 10^{-5} y repetir con 10^{-4} y 10^{-6} si el resultado es dudoso;
4. vigilar los puntos no derivables, como $t = 0$ en ReLU: si $x - h$ y $x + h$ quedan a distintos lados de uno de ellos, la aproximación numérica no es fiable.

Observación 6.7 (Conexión con los LLM). Las bibliotecas de diferenciación automática incluyen utilidades de comprobación de este tipo, como `torch.autograd.gradcheck` en PyTorch, que comparan los gradientes analítico y numérico en doble precisión. Se usan al implementar una operación nueva, por ejemplo una variante de la atención, antes de emplearla en un modelo grande.

Lecturas recomendadas para este tema

- Goodfellow, Bengio y Courville [7], §4.1 «Overflow and Underflow».
- Stanford CS231n [4], notas «Neural Networks Part 3», sección «Gradient checks».
- Deisenroth, Faisal y Ong [6], §5.1 (Taylor en una variable).

Ejercicios del tema 6

Ejercicio 6.1 ⋆ ¿Por qué no se entrena un LLM calculando el gradiente por diferencias finitas, si son tan sencillas de implementar? ¿Para qué se usan entonces?

Ejercicio 6.2 ⋆⋆ Para $f(x) = x^3$ en $x = 1$, calcule la diferencia hacia delante y la centrada con $h = 0{,}1$ y $h = 0{,}01$. ¿Cómo disminuye cada error al dividir h entre 10? Compare con la proposición 6.2.

Ejercicio 6.3 ⋆⋆ Sea $f(x, y) = x^2 y + 3y$. Compruebe el gradiente $\nabla f(2, 1) = (4, 7)^\top$ en la dirección $v = (1, 1)^\top$ mediante la proposición 6.6 con $h = 0{,}01$, y calcule el error relativo.

Ejercicio 6.4 ⋆⋆ Una comprobación de gradientes en doble precisión da los siguientes pares (analítico, numérico): (a) (1; 1,0000001); (b) (0,5; 0,52); (c) $(10^{-3}; 1{,}0005 \cdot 10^{-3})$. Calcule el error relativo de cada par y valore el resultado. (d) Para $f(x) = \max(0, x)$ en $x = 10^{-6}$ con $h = 10^{-5}$, calcule la diferencia centrada y su error relativo respecto de la derivada exacta, y explique el resultado.

Fuente: adaptado de Stanford CS231n [4], notas «Neural Networks Part 3», sección «Gradient checks» (criterios de error relativo y puntos no derivables).

Ejercicio 6.5 ⋆⋆ Se desea comprobar por diferencias centradas el gradiente completo de un modelo de $7 \cdot 10^9$ parámetros. ¿Cuántas evaluaciones de la pérdida se necesitan? Si cada una tarda 1 s, ¿cuántos años se tardaría? ¿Qué se haría en su lugar?

Ejercicio 6.6 ⋆⋆⋆ Demuestre la proposición 6.4 con todo detalle. Calcule h^* y $E(h^*)$ para $f(x) = e^x$ en $x = 0$ con $\varepsilon = 1{,}1 \cdot 10^{-16}$ y compárelos con la figura 6.1. Repita el razonamiento para la diferencia hacia delante y demuestre que, en ese caso, el paso óptimo es de orden $\varepsilon^{1/2}$ y el error mínimo también.

Apéndice A

Soluciones de los ejercicios

Cada solución se presenta en cinco partes: datos, planteamiento, desarrollo, resultado y comprobación. En los pasos intermedios se redondea a cuatro cifras significativas salvo que se indique otra cosa; los resultados exactos se dan como fracción o con radicales cuando existen.

A.1 Tema 1

Solución del ejercicio 1.1

Planteamiento. contrastar cada afirmación con los resultados del tema 1.

Desarrollo.

(a) **Verdadera** si f es diferenciable. Si $r(t)$ recorre una curva de nivel, $f(r(t)) = c$ y el corolario 1.13 da $\nabla f(r(t))^{\top} r'(t) = 0$: el gradiente es ortogonal a la tangente.

(b) **Verdadera.** Por el teorema 1.11, $D_u f \geq -\|\nabla f\|$, con igualdad solo en $u = -\nabla f/\|\nabla f\|$.

(c) **Falsa.** La función $f(x, y) = xy/(x^2 + y^2)$, con $f(0, 0) = 0$, tiene ambas parciales nulas en el origen, pero $f(t, t) = 1/2$ para $t \neq 0$; no es continua en $(0, 0)$ y, por tanto, no es diferenciable allí.

Resultado. **(a) verdadera; (b) verdadera; (c) falsa.**

Comprobación. en (c), si f fuera diferenciable en el origen, su gradiente sería $(0, 0)^{\top}$ (proposición 1.5) y se tendría $f(t, t) = o(|t|) \to 0$, en contradicción con $f(t, t) = 1/2$.

Solución del ejercicio 1.2

Datos. $f(x, y) = x^3 + 2xy^2$; punto $(1, 2)$; $u = (1, 1)^{\top}/\sqrt{2}$.

Planteamiento. derivar respecto de cada variable con la otra fija y aplicar la proposición 1.9.

Desarrollo.

1. $\partial f/\partial x = 3x^2 + 2y^2$; en $(1, 2)$: $3 + 8 = 11$.
2. $\partial f/\partial y = 4xy$; en $(1, 2)$: 8.
3. $\nabla f(1, 2) = (11, 8)^{\top}$ y $\|\nabla f(1, 2)\| = \sqrt{121 + 64} = \sqrt{185} \approx 13{,}60$.
4. $D_u f(1, 2) = (11 + 8)/\sqrt{2} = 19/\sqrt{2} \approx 13{,}44$.

Resultado. $\nabla f(1, 2) = (11, 8)^{\top}$**;** $\|\nabla f\| = \sqrt{185} \approx 13{,}60$**;** $D_u f = 19/\sqrt{2} \approx 13{,}44$**.**

Comprobación. $13{,}44 < 13{,}60$, como exige el teorema 1.11. Las dos cifras son próximas porque el ángulo entre u y ∇f es pequeño: su coseno es $13{,}44/13{,}60 \approx 0{,}988$.

Solución del ejercicio 1.3

Datos. $f(x) = 3x_1^2 + 5e^{x_2}$; punto $(1, 0)$; dirección $(3, 4)^\top$.

Planteamiento. calcular el gradiente, normalizar la dirección y usar $D_u f = \nabla f^\top u$.

Desarrollo.

1. $\nabla f(x) = (6x_1,\ 5e^{x_2})^\top$.
2. En $(1, 0)$: $\nabla f = (6,\ 5e^0)^\top = (6, 5)^\top$.
3. $\|(3, 4)\| = 5$, luego $u = (0{,}6;\ 0{,}8)^\top$.
4. $D_u f(1, 0) = 6 \cdot 0{,}6 + 5 \cdot 0{,}8 = 3{,}6 + 4 = 7{,}6$.
5. $\|\nabla f(1, 0)\| = \sqrt{36 + 25} = \sqrt{61} \approx 7{,}810$.

Resultado. $\nabla f(1, 0) = (6, 5)^\top$**;** $D_u f = 7{,}6 \le \sqrt{61} \approx 7{,}810$**.**

Comprobación. la diferencia centrada en x_2 con $h = 0{,}01$ da $5\,(e^{0{,}01} - e^{-0{,}01})/0{,}02 = 5 \cdot 1{,}0000167 \approx 5{,}0001$.

Solución del ejercicio 1.4

Datos. $f(x) = \|x\| = \left(\sum_i x_i^2\right)^{1/2}$; $x = (3, 4)^\top$.

Planteamiento. regla de la cadena en una variable con $s = \sum_i x_i^2$ y $f = s^{1/2}$.

Desarrollo.

1. $\partial s/\partial x_i = 2x_i$ y $d(s^{1/2})/ds = \frac{1}{2}s^{-1/2}$.
2. $\partial f/\partial x_i = \frac{1}{2}s^{-1/2} \cdot 2x_i = x_i/\|x\|$, luego $\nabla f(x) = x/\|x\|$, el vector unitario en la dirección de x. Las parciales son continuas fuera del origen, luego f es diferenciable allí (teorema 1.6).
3. En $(3, 4)$: $\|x\| = 5$ y $\nabla f = (0{,}6;\ 0{,}8)^\top$.
4. En $x = 0$: $f(t\,e_1) = |t|$, cuyo cociente $|t|/t$ vale -1 para $t < 0$ y $+1$ para $t > 0$. La parcial $\partial f/\partial x_1(0)$ no existe y f no es diferenciable en el origen.
5. El recorte por norma sustituye g por $c\,g/\|g\|$ cuando $\|g\| > c$: conserva la dirección $\nabla\|g\| = g/\|g\|$ y fija la longitud en c.

Resultado. $\nabla\|x\| = x/\|x\|$ **para** $x \neq 0$**; en** $(3, 4)$ **vale** $(0{,}6;\ 0{,}8)^\top$**; en** $x = 0$ **no existe.**

Comprobación. $\|\nabla f(x)\| = 1$ para todo $x \neq 0$: alejarse radialmente del origen aumenta la norma a razón de una unidad por unidad recorrida.

Solución del ejercicio 1.5

Datos. $f(x, y) = x^3 - 3x^2 + xy - y^2 + x + y$; punto $(1, 1/2)$.

Planteamiento. por el teorema 1.11, el máximo se alcanza en $\nabla f/\|\nabla f\|$, el mínimo en la dirección opuesta, y la derivada direccional es nula en las direcciones ortogonales al gradiente.

Desarrollo.

1. $f_x = 3x^2 - 6x + y + 1$; en $(1, 1/2)$: $3 - 6 + 0{,}5 + 1 = -1{,}5$.
2. $f_y = x - 2y + 1$; en $(1, 1/2)$: $1 - 1 + 1 = 1$.
3. $\nabla f = (-3/2,\ 1)^\top$ y $\|\nabla f\| = \sqrt{9/4 + 1} = \sqrt{13}/2 \approx 1{,}803$.

4. Máximo: $u = (-3, 2)^\top/\sqrt{13} \approx (-0{,}8321;\ 0{,}5547)$, con $D_u f = \sqrt{13}/2 \approx 1{,}803$.
5. Mínimo: $u = (3, -2)^\top/\sqrt{13}$, con $D_u f \approx -1{,}803$.
6. Nulas: los vectores unitarios ortogonales a $(-3, 2)$, es decir,

$$u = \pm(2, 3)^\top/\sqrt{13} \approx \pm(0{,}5547;\ 0{,}8321).$$

Resultado. **máximo $\sqrt{13}/2 \approx 1{,}803$ en $(-3, 2)^\top/\sqrt{13}$; mínimo $-1{,}803$ en $(3, -2)^\top/\sqrt{13}$; nula en $\pm(2, 3)^\top/\sqrt{13}$.**

Comprobación. $(-3, 2) \cdot (2, 3) = -6 + 6 = 0$, y $\nabla f^\top (-3, 2)^\top/\sqrt{13} = (4{,}5 + 2)/\sqrt{13} = 6{,}5/3{,}606 \approx 1{,}803$.

Solución del ejercicio 1.6

Datos. $g = \nabla f(x) \neq 0$; u unitario; $f(x, y) = x^2 + y^2$ y $r(t) = \sqrt{c}\,(\cos t, \sin t)^\top$.

Planteamiento. Cauchy–Schwarz para la cota y el lema 1.12 para la ortogonalidad.

Desarrollo.

1. Por la proposición 1.9, $D_u f(x) = g^\top u$.
2. Por Cauchy–Schwarz, $|g^\top u| \leq \|g\|\,\|u\| = \|g\|$; en particular, $g^\top u \geq -\|g\|$.
3. La cota se alcanza: para $u^- = -g/\|g\|$, que es unitario porque $g \neq 0$, se tiene $g^\top u^- = -\|g\|^2/\|g\| = -\|g\|$.
4. Unicidad: la igualdad en Cauchy–Schwarz exige $u = \alpha g$; con $\|u\| = 1$, $\alpha = \pm 1/\|g\|$, y solo el signo negativo da $-\|g\|$.
5. Circunferencias: $f(r(t)) = c(\cos^2 t + \sin^2 t) = c$ para todo t, y $r'(t) = \sqrt{c}\,(-\sin t, \cos t)^\top$.
6. $\nabla f(r(t)) = 2r(t) = 2\sqrt{c}\,(\cos t, \sin t)^\top$, luego $\nabla f(r(t))^\top r'(t) = 2c(-\cos t \sin t + \sin t \cos t) = 0$.

Resultado. $\min_{\|u\|=1} D_u f(x) = -\|\nabla f(x)\|$**, alcanzado solo en $u = -\nabla f/\|\nabla f\|$; en las circunferencias, el gradiente es radial y ortogonal a la tangente.** ■

Comprobación. la derivada de la constante $f(r(t)) = c$ es nula, como debe ser por el corolario 1.13.

A.2 Tema 2

Solución del ejercicio 2.1

Datos. $g\colon \mathbb{R}^5 \to \mathbb{R}^3$, $h\colon \mathbb{R}^3 \to \mathbb{R}^2$, $f\colon \mathbb{R}^2 \to \mathbb{R}$.

Planteamiento. el jacobiano de una función $\mathbb{R}^n \to \mathbb{R}^m$ es $m \times n$ (definición 2.1).

Desarrollo.

1. J_g es 3×5, J_h es 2×3 y J_f es 1×2.
2. Por el teorema 2.4, $J_{f \circ h \circ g} = J_f\, J_h\, J_g$: $(1 \times 2)(2 \times 3)(3 \times 5) = 1 \times 5$.
3. El gradiente es la traspuesta: un vector de $\mathbb{R}^5$, de forma 5×1.

Resultado. 3×5**,** 2×3**,** 1×2**; la composición tiene jacobiano** 1×5 **y gradiente en** $\mathbb{R}^5$**.**

Comprobación. en cada producto coinciden las dimensiones interiores (2 y 3), y el gradiente tiene la forma de la variable de entrada.

Solución del ejercicio 2.2

Datos. $F = uv$ con $u = x + y^2$, $v = x^2 - y$; punto $(1, 2)$.

Planteamiento. corolario 2.5: $\partial F/\partial x = F_u\, u_x + F_v\, v_x$ y análogamente para y.

Desarrollo.

1. Valores: $u = 1 + 4 = 5$ y $v = 1 - 2 = -1$.
2. Derivadas exteriores: $F_u = v = -1$ y $F_v = u = 5$.
3. Derivadas interiores: $u_x = 1$, $u_y = 2y = 4$, $v_x = 2x = 2$, $v_y = -1$.
4. $\partial F/\partial x = (-1) \cdot 1 + 5 \cdot 2 = 9$.
5. $\partial F/\partial y = (-1) \cdot 4 + 5 \cdot (-1) = -9$.

Resultado. $\partial F/\partial x = 9$ **y** $\partial F/\partial y = -9$ **en** $(1, 2)$**.**

Comprobación. $F = x^3 - xy + x^2y^2 - y^3$, luego $F_x = 3x^2 - y + 2xy^2 = 3 - 2 + 8 = 9$ y $F_y = -x + 2x^2y - 3y^2 = -1 + 4 - 12 = -9$.

Solución del ejercicio 2.3

Datos. $g(x, y) = (x^2y,\ 3x - y,\ xy)^\top$; punto $(1, 2)$; $s = g_1 + g_2 + g_3 = \mathbf{1}^\top g$.

Planteamiento. cada fila de J_g es el gradiente traspuesto de una componente; $\nabla s = J_g^\top \mathbf{1}$ (corolario 2.5).

Desarrollo.

1. Fila 1: $\nabla(x^2y) = (2xy,\ x^2) = (4, 1)$.
2. Fila 2: $\nabla(3x - y) = (3, -1)$.
3. Fila 3: $\nabla(xy) = (y,\ x) = (2, 1)$.
4. $J_g(1, 2) = \begin{pmatrix} 4 & 1 \\ 3 & -1 \\ 2 & 1 \end{pmatrix}$, de forma 3×2.
5. $\nabla s = J_g^\top \mathbf{1} = (4 + 3 + 2,\ 1 - 1 + 1)^\top = (9, 1)^\top$.

Resultado. $J_g(1, 2)$ **es la matriz** 3×2 **anterior y** $\nabla s(1, 2) = (9, 1)^\top$**.**

Comprobación. $s = x^2y + 3x - y + xy$: $s_x = 2xy + 3 + y = 4 + 3 + 2 = 9$ y $s_y = x^2 - 1 + x = 1$.

Solución del ejercicio 2.4

Datos. $w = f(x, y, z)$ con x, y, z funciones de (a, b); caso $f = xyz$, $x = a + b$, $y = a - b$, $z = ab$, en $(2, 1)$.

Planteamiento. corolario 2.5 con tres variables intermedias.

Desarrollo.

1. (a) $\dfrac{\partial w}{\partial a} = \dfrac{\partial f}{\partial x}\dfrac{\partial x}{\partial a} + \dfrac{\partial f}{\partial y}\dfrac{\partial y}{\partial a} + \dfrac{\partial f}{\partial z}\dfrac{\partial z}{\partial a}$, y lo mismo con b.

2. (b) Valores: $x = 3$, $y = 1$, $z = 2$.
3. Derivadas exteriores: $f_x = yz = 2$, $f_y = xz = 6$, $f_z = xy = 3$.
4. Respecto de a: $x_a = 1$, $y_a = 1$, $z_a = b = 1$; luego $\partial w/\partial a = 2 + 6 + 3 = 11$.
5. Respecto de b: $x_b = 1$, $y_b = -1$, $z_b = a = 2$; luego $\partial w/\partial b = 2 - 6 + 6 = 2$.

Resultado. $\partial w/\partial a = 11$ **y** $\partial w/\partial b = 2$ **en** $(a, b) = (2, 1)$**.**

Comprobación. $w = (a^2 - b^2)ab = a^3b - ab^3$, de modo que $w_a = 3a^2b - b^3 = 12 - 1 = 11$ y $w_b = a^3 - 3ab^2 = 8 - 6 = 2$.

Solución del ejercicio 2.5

Datos. $J_1 \in \mathbb{R}^{d\times n}$, $J_2 \in \mathbb{R}^{d\times d}$, $J_3 \in \mathbb{R}^{1\times d}$; $n = d = 1000$.

Planteamiento. un producto $(a \times b)(b \times c)$ cuesta abc productos escalares (proposición 2.9).

Desarrollo.

1. (a) J_2J_1: $d \cdot d \cdot n = d^2n$. Después $J_3(J_2J_1)$: $1 \cdot d \cdot n = dn$. Total: $d^2n + dn$.
2. (b) J_3J_2: $1 \cdot d \cdot d = d^2$. Después $(J_3J_2)J_1$: $1 \cdot d \cdot n = dn$. Total: $d^2 + dn$.
3. Con $n = d = 1000$: (a) $10^9 + 10^6 = 1{,}001 \cdot 10^9$; (b) $10^6 + 10^6 = 2 \cdot 10^6$.

Resultado. **(a)** $1{,}001 \cdot 10^9$ **productos (modo directo); (b)** $2 \cdot 10^6$ **(modo inverso), unas 500 veces menos.**

Comprobación. $1{,}001 \cdot 10^9/(2 \cdot 10^6) = 500{,}5$. El modo inverso nunca forma una matriz $d \times n$ intermedia: solo multiplica vectores fila por matrices.

Solución del ejercicio 2.6

Datos. a, b: $\mathbb{R}^n \to \mathbb{R}^m$ diferenciables; $s = a^\top b$; $q(x) = x^\top Ax$.

Planteamiento. escribir $s = \phi \circ G$ con $G(x) = (a(x), b(x)) \in \mathbb{R}^{2m}$ y $\phi(\alpha, \beta) = \alpha^\top\beta$, y aplicar el corolario 2.5.

Desarrollo.

1. $\phi(\alpha, \beta) = \sum_j \alpha_j\beta_j$, luego $\partial\phi/\partial\alpha_j = \beta_j$ y $\partial\phi/\partial\beta_j = \alpha_j$: $\nabla\phi = (\beta, \alpha)$.
2. $J_G = \begin{pmatrix} J_a \\ J_b \end{pmatrix} \in \mathbb{R}^{2m\times n}$, apilando los jacobianos por filas.
3. $\nabla s = J_G^\top \nabla\phi = \begin{pmatrix} J_a^\top & J_b^\top \end{pmatrix} \begin{pmatrix} b \\ a \end{pmatrix} = J_a^\top b + J_b^\top a$.
4. Forma cuadrática: $a(x) = x$ con $J_a = I$, y $b(x) = Ax$ con $J_b = A$ (ejemplo 2.2).
5. $\nabla q = I\,(Ax) + A^\top x = (A + A^\top)x$; si A es simétrica, $\nabla q = 2Ax$.

Resultado. $\nabla(a^\top b) = J_a^\top b + J_b^\top a$ **y** $\nabla(x^\top Ax) = (A + A^\top)x$**, que vale** $2Ax$ **si** $A = A^\top$**.** ■

Comprobación. con $A = \begin{pmatrix} 1 & 2 \\ 0 & 3 \end{pmatrix}$, $q = x_1^2 + 2x_1x_2 + 3x_2^2$ y $\nabla q = (2x_1 + 2x_2,\ 2x_1 + 6x_2)^\top$; en $(1, 1)$ vale $(4, 8)^\top$, y $(A + A^\top)(1, 1)^\top = \begin{pmatrix} 2 & 2 \\ 2 & 6 \end{pmatrix}(1, 1)^\top = (4, 8)^\top$.

A.3 Tema 3

Solución del ejercicio 3.1

Datos. $E \in \mathbb{R}^{50\,000\times 4096}$; L escalar.

Planteamiento. el gradiente respecto de una matriz tiene su misma forma (definición 3.1).

Desarrollo.

1. $\partial L/\partial E$ tiene forma $50\,000 \times 4096$.
2. Número de entradas: $50\,000 \cdot 4096 = 204\,800\,000$.
3. La fila i de E solo interviene en L si el token i aparece en el lote; en caso contrario, L no depende de ella y su gradiente es nulo.

Resultado. **forma $50\,000 \times 4096$, con $2{,}048 \cdot 10^8$ números; solo son no nulas las filas de los tokens presentes en el lote.**

Comprobación. orden de magnitud: $5 \cdot 10^4 \cdot 4 \cdot 10^3 = 2 \cdot 10^8$.

Solución del ejercicio 3.2

Datos. $\nabla_z L = p - y$ con $y = e_c$.

Planteamiento. estudiar el signo de cada componente y el efecto de restarla multiplicada por $\eta > 0$.

Desarrollo.

1. Componente correcta: $p_c - 1 < 0$, porque $0 < p_c < 1$ cuando $K \geq 2$.
2. Componentes incorrectas: $p_i - 0 = p_i > 0$.
3. Paso de descenso: $z_c \leftarrow z_c + \eta(1 - p_c)$ aumenta; $z_i \leftarrow z_i - \eta p_i$ disminuye para $i \neq c$, tanto más cuanto mayor es p_i.

Resultado. **la componente correcta es negativa y las demás positivas; el paso sube el logit correcto y baja los incorrectos en proporción a su probabilidad.**

Comprobación. en el ejemplo 3.9, $p - y = (-0{,}335;\ 0{,}245;\ 0{,}090)$: signos $(-, +, +)$ y suma nula.

Solución del ejercicio 3.3

Datos. $W = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 1 & 0 \end{pmatrix}$, $x = (1, 2, 1)^\top$, $t = (0, 3)^\top$, $L = \frac{1}{2}\|Wx - t\|^2$.

Planteamiento. $\delta = \nabla_y L = y - t$; después la proposición 3.3.

Desarrollo.

1. $y_1 = 1 - 1 = 0$ e $y_2 = 2 + 2 = 4$: $y = (0, 4)^\top$.
2. $\delta = y - t = (0, 1)^\top$ y $L = \frac{1}{2}(0 + 1) = 0{,}5$.
3. $\partial L/\partial W = \delta x^\top = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \begin{pmatrix} 1 & 2 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 1 & 2 & 1 \end{pmatrix}$.
4. $\partial L/\partial x = W^\top \delta = \begin{pmatrix} 1 & 2 \\ 0 & 1 \\ -1 & 0 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = (2, 1, 0)^\top$.

Resultado. $y = (0, 4)^\top$**;** $L = 0{,}5$**;** $\partial L/\partial W = \begin{pmatrix} 0 & 0 & 0 \\ 1 & 2 & 1 \end{pmatrix}$**;** $\partial L/\partial x = (2, 1, 0)^\top$**.**

Comprobación. las formas coinciden con las de W (2×3) y x (3 componentes). Como solo la segunda salida tiene error, $\partial L/\partial x$ es la segunda fila de W.

Solución del ejercicio 3.4

Datos. $z = (0, \ln 2, \ln 5)^\top$; $c = 2$, $y = (0, 1, 0)^\top$.

Planteamiento. $p_i = e^{z_i} / \sum_k e^{z_k}$, $L = -\ln p_c$ y teorema 3.8.

Desarrollo.

1. $e^z = (1, 2, 5)$, con suma 8.
2. $p = (1/8,\ 1/4,\ 5/8) = (0{,}125;\ 0{,}25;\ 0{,}625)$.
3. $L = -\ln(1/4) = \ln 4 = 2 \ln 2 \approx 1{,}386$ nats.
4. $\nabla_z L = p - y = (0{,}125;\ -0{,}75;\ 0{,}625)$.

Resultado. $p = (1/8, 1/4, 5/8)$**;** $L = \ln 4 \approx 1{,}386$ **nats;** $\nabla_z L = (0{,}125;\ -0{,}75;\ 0{,}625)$**.**

Comprobación. p suma 1 y $p - y$ suma $0{,}125 - 0{,}75 + 0{,}625 = 0$.

Solución del ejercicio 3.5

Datos. $p = \mathrm{softmax}(z)$, $y = e_c$, $J = \mathrm{diag}(p) - pp^\top$.

Planteamiento. usar $\mathbf{1}^\top p = 1$ y $\mathbf{1}^\top y = 1$.

Desarrollo.

1. $\sum_j (p_j - y_j) = \mathbf{1}^\top p - \mathbf{1}^\top y = 1 - 1 = 0$.
2. $\mathrm{diag}(p)\mathbf{1} = p$, porque la fila i de $\mathrm{diag}(p)$ solo tiene la entrada p_i.
3. $pp^\top \mathbf{1} = p\,(p^\top \mathbf{1}) = p$ por la asociatividad del producto.
4. $J\mathbf{1} = p - p = 0$: $\mathbf{1} \in \ker J$.
5. $\nabla_z L^\top \mathbf{1} = \sum_j (p_j - y_j) = 0$, luego el gradiente es ortogonal a $\mathbf{1}$.
6. Interpretación: $L(z + t\mathbf{1}) = L(z)$ para todo t (invariancia por traslación). Derivando en $t = 0$ con el lema 1.12, $\nabla_z L^\top \mathbf{1} = 0$, que es lo obtenido. Del mismo modo, $p(z + t\mathbf{1})$ es constante y su derivada, $J\mathbf{1}$, es nula.

Resultado. $\sum_j (p_j - y_j) = 0$**,** $J\mathbf{1} = 0$ **y** $\nabla_z L \perp \mathbf{1}$**: la dirección 1 no cambia ni las probabilidades ni la pérdida.** ■

Comprobación. para $z = (2, 1, 0)^\top$, J tiene autovalores 0; 0,119; 0,371, y el autovector del autovalor nulo es $\mathbf{1}/\sqrt{3}$.

Solución del ejercicio 3.6

Datos. $s = U^\top v_c$, con $s_w = u_w^\top v_c$; $\hat{y} = \mathrm{softmax}(s)$; $J = -\ln \hat{y}_o$; datos numéricos del apartado (c).

Planteamiento. por el teorema 3.8, $\partial J/\partial s = \hat{y} - y$; después, la regla de la cadena a través de $s = U^\top v_c$, que es una capa lineal.

Desarrollo.

1. (a) $\partial s_w/\partial v_c = u_w$, luego $\partial J/\partial v_c = \sum_w (\hat{y}_w - y_w)\, u_w$.
2. Una combinación lineal de las columnas de U con coeficientes $\hat{y} - y$ es $U(\hat{y} - y)$. Es la proposición 3.3 con matriz $U^\top$: $\partial J/\partial v_c = (U^\top)^\top \delta$.
3. (b) u_w solo aparece en s_w, con $\partial s_w/\partial u_w = v_c$; luego $\partial J/\partial u_w = (\hat{y}_w - y_w)\, v_c$.
4. (c) $s_1 = \ln 2$, $s_2 = 0$, $s_3 = \ln 2$; $e^s = (2, 1, 2)$, con suma 5; $\hat{y} = (0{,}4;\ 0{,}2;\ 0{,}4)$.
5. $J = -\ln 0{,}2 = \ln 5 \approx 1{,}609$ nats y $\hat{y} - y = (0{,}4;\ -0{,}8;\ 0{,}4)$.
6. $\partial J/\partial v_c = 0{,}4\,(1, 0) - 0{,}8\,(0, 1) + 0{,}4\,(1, 1) = (0{,}8;\ -0{,}4)$.
7. Con $\ln 2 \approx 0{,}6931$: $\partial J/\partial u_1 = \partial J/\partial u_3 = 0{,}4\,(\ln 2, 0) = (0{,}2773;\ 0)$ y $\partial J/\partial u_2 = -0{,}8\,(\ln 2, 0) = (-0{,}5545;\ 0)$.

Resultado. $\partial J/\partial v_c = U(\hat{y}-y) = (0{,}8;\ -0{,}4)^\top$**;** $\partial J/\partial u_w = (\hat{y}_w - y_w)v_c$**:** $(0{,}2773;\ 0)$**,** $(-0{,}5545;\ 0)$ **y** $(0{,}2773;\ 0)$**.** ■

Comprobación. la diferencia centrada con $h = 10^{-6}$ reproduce estos valores con nueve cifras. Como la segunda componente de v_c es nula, también lo es la de cada $\partial J/\partial u_w$.

A.4 Tema 4

Solución del ejercicio 4.1

Planteamiento. buscar contraejemplos para las falsas y aplicar el teorema 4.2 para la verdadera.

Desarrollo.

(a) **Falsa.** $f(x, y) = x^2 - y^2$ tiene $\nabla f(0, 0) = 0$, pero $f(t, 0) = t^2 > 0$ y $f(0, t) = -t^2 < 0$: el origen es un punto de silla.

(b) **Verdadera**, por el teorema 4.2.

(c) **Falsa.** $f(x, y) = -x^4 + y^2$ tiene $\nabla f(0, 0) = 0$ y $H_f(0, 0) = \operatorname{diag}(0, 2)$, pero $f(t, 0) = -t^4 < 0$ para $t \neq 0$.

Resultado. **(a) falsa; (b) verdadera; (c) falsa.**

Comprobación. en (c), con $x^4 + y^2$ se obtiene el mismo hessiano en el origen y sí hay mínimo: el hessiano no decide (cuadro 4.1).

Solución del ejercicio 4.2

Datos. $f(x, y) = x^3 + xy$; punto $(1, 1)$; $h = (0{,}1;\ -0{,}2)$.

Planteamiento. teorema 4.5(ii) truncado en el primer y en el segundo orden; convexidad local mediante los autovalores de H.

Desarrollo.

1. $f(1, 1) = 2$ y $\nabla f = (3x^2 + y,\ x)^\top = (4, 1)^\top$.
2. $\nabla f^\top h = 0{,}4 - 0{,}2 = 0{,}2$; primer orden: 2,2.
3. $H = \begin{pmatrix} 6x & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 6 & 1 \\ 1 & 0 \end{pmatrix}$.
4. $h^\top H h = 6 \cdot 0{,}01 + 2 \cdot (0{,}1)(-0{,}2) = 0{,}06 - 0{,}04 = 0{,}02$; segundo orden: $2{,}2 + 0{,}01 = 2{,}21$.

5. Exacto: $f(1{,}1;\,0{,}8) = 1{,}331 + 0{,}88 = 2{,}211$.
6. $\det(H - \lambda I) = \lambda^2 - 6\lambda - 1 = 0$ da $\lambda = 3 \pm \sqrt{10}$, es decir, 6,162 y $-0{,}1623$.

Resultado. **primer orden** 2,2**; segundo orden** 2,21**; exacto** 2,211**.** $H(1,1)$ **tiene un autovalor negativo, y por continuidad lo tiene en todo un entorno:** f **no es convexa en ningún entorno de** $(1,1)$**.**

Comprobación. el error de segundo orden, $0{,}001 = h_1^3$, es exactamente el término cúbico de x^3 que el desarrollo omite.

Solución del ejercicio 4.3

Datos. $f(x,y) = x^3 - 3x^2 + xy - y^2 + x + y$.

Planteamiento. resolver $\nabla f = 0$ y aplicar el teorema 4.9.

Desarrollo.

1. $f_x = 3x^2 - 6x + y + 1$ y $f_y = x - 2y + 1$.
2. De $f_y = 0$: $y = (x+1)/2$. Sustituyendo en $f_x = 0$ y multiplicando por 2: $6x^2 - 11x + 3 = 0$.
3. $x = (11 \pm \sqrt{121 - 72})/12 = (11 \pm 7)/12$, es decir, $x = 3/2$ o $x = 1/3$; los puntos son $(3/2,\ 5/4)$ y $(1/3,\ 2/3)$.
4. $H = \begin{pmatrix} 6x - 6 & 1 \\ 1 & -2 \end{pmatrix}$.
5. En $(3/2, 5/4)$: $H = \begin{pmatrix} 3 & 1 \\ 1 & -2 \end{pmatrix}$, $\det H = -7 < 0$; autovalores $(1 \pm \sqrt{29})/2 \approx 3{,}193$ y $-2{,}193$: punto de silla.
6. En $(1/3, 2/3)$: $H = \begin{pmatrix} -4 & 1 \\ 1 & -2 \end{pmatrix}$, $\det H = 7 > 0$ y $f_{xx} = -4 < 0$; autovalores $-3 \pm \sqrt{2} \approx -1{,}586$ y $-4{,}414$: máximo local.
7. Valores: $f(3/2, 5/4) = -5/16 = -0{,}3125$ y $f(1/3, 2/3) = 13/27 \approx 0{,}4815$.

Resultado. $(3/2, 5/4)$ **es un punto de silla y** $(1/3, 2/3)$ **un máximo local, con** $f = 13/27$**.**

Comprobación. en $(1/3, 2/3)$: $f_x = 1/3 - 2 + 2/3 + 1 = 0$ y $f_y = 1/3 - 4/3 + 1 = 0$.

Solución del ejercicio 4.4

Datos. $f(x,y) = x^2 + 4y^2 = \frac{1}{2} x^\top A x$ con $A = \operatorname{diag}(2, 8)$; punto inicial $(1,1)$, con $f = 5$.

Planteamiento. proposición 4.12: cada coordenada se multiplica por $1 - \eta\lambda_i$ en cada paso.

Desarrollo.

1. (a) $\lambda_{\max} = 8$: converge si y solo si $0 < \eta < 2/8 = 0{,}25$.
2. (b) $\eta = 0{,}2$: factores $1 - 0{,}4 = 0{,}6$ y $1 - 1{,}6 = -0{,}6$. Iteraciones: $(0{,}6;\ -0{,}6)$ con $f = 0{,}36 + 1{,}44 = 1{,}8$, y $(0{,}36;\ 0{,}36)$ con $f = 0{,}1296 + 0{,}5184 = 0{,}648$.
3. $\eta = 0{,}3$: factores $0{,}4$ y $1 - 2{,}4 = -1{,}4$. Iteraciones: $(0{,}4;\ -1{,}4)$ con $f = 0{,}16 + 7{,}84 = 8$, y $(0{,}16;\ 1{,}96)$ con $f = 0{,}0256 + 15{,}37 = 15{,}39$. La coordenada y oscila y crece: diverge.
4. (c) El peor factor $\max(|1 - 2\eta|, |1 - 8\eta|)$ es mínimo cuando $1 - 2\eta = -(1 - 8\eta)$, es decir, $\eta = 2/10 = 0{,}2$, y vale 0,6.

Resultado. **(a)** $0 < \eta < 0{,}25$**; (b) con** $\eta = 0{,}2$**,** f **pasa de** 5 **a** $1{,}8$ **y a** $0{,}648$**; con** $\eta = 0{,}3$**, a** 8 **y a** $15{,}39$**; (c)** $\eta = 0{,}2$**, con factor** $0{,}6$**.**

Comprobación. con $\kappa = 8/2 = 4$, la fórmula de la observación sobre el número de condición da $(\kappa - 1)/(\kappa + 1) = 3/5 = 0{,}6$; y en (b) cada paso multiplica f por $0{,}6^2 = 0{,}36$: $5 \cdot 0{,}36 = 1{,}8$.

Solución del ejercicio 4.5

Datos. $f \in C^2(U)$; x^* mínimo local.

Planteamiento. por reducción al absurdo con el teorema 4.5(ii) a lo largo de un autovector.

Desarrollo.

1. Por el teorema 4.8, $\nabla f(x^*) = 0$.
2. Supóngase que $H = H_f(x^*)$ no es semidefinida positiva: existe un autovector unitario v con autovalor $\lambda < 0$.
3. Por el teorema 4.5(ii), $f(x^* + tv) - f(x^*) = \frac{1}{2}\lambda t^2 + o(t^2)$.
4. Para $|t|$ pequeño y no nulo, el resto es menor que $\frac{1}{4}|\lambda| t^2$, luego $f(x^* + tv) - f(x^*) \leq \frac{1}{4}\lambda t^2 < 0$, en contradicción con que x^* es mínimo local.
5. Contraejemplo del recíproco: $f(x, y) = x^3 + y^2$ tiene $\nabla f(0,0) = 0$ y $H_f(0,0) = \operatorname{diag}(0, 2) \succeq 0$, pero $f(t, 0) = t^3 < 0$ para $t < 0$.

Resultado. **Si** x^* **es mínimo local,** $H_f(x^*) \succeq 0$**; el recíproco falla, por ejemplo, para** $x^3 + y^2$ **en el origen.** ■

Comprobación. el contraejemplo es coherente con el teorema 4.9: el autovalor nulo deja el caso sin decidir.

A.5 Tema 5

Solución del ejercicio 5.1

Planteamiento. aplicar los teoremas del tema 5 o buscar un contraejemplo.

Desarrollo.

(a) **Verdadera**: es el teorema 5.5 con $C = \mathbb{R}^n$, que es abierto y convexo.

(b) **Falsa.** $f(x) = x$ y $g(x) = x^2$ son convexas en $\mathbb{R}$, pero su producto x^3 tiene segunda derivada $6x < 0$ para $x < 0$.

(c) **Verdadera**, por la proposición 5.9(iii).

Resultado. **(a) verdadera; (b) falsa; (c) verdadera.**

Comprobación. en (b), la cuerda de x^3 entre -2 y 0 pasa por $(-1, -4)$, por debajo de la gráfica en $(-1, -1)$, lo que viola la definición 5.2.

Solución del ejercicio 5.2

Datos. cuatro funciones de $\mathbb{R}^2$.

Planteamiento. calcular el hessiano y sus autovalores (teorema 5.5).

Desarrollo.

(a) $H = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, autovalores 1 y 3: estrictamente convexa.

(b) $H = \begin{pmatrix} 2 & -4 \\ -4 & 2 \end{pmatrix}$, autovalores 2 ± 4, es decir, 6 y -2: no es convexa.

(c) $H = e^{x+y}\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$, autovalores 0 y $2e^{x+y}$: convexa. No es estrictamente convexa: es constante sobre cada recta $x + y = c$, donde la desigualdad de la definición 5.2 es una igualdad.

(d) $H = \operatorname{diag}(12x^2, 2) \succeq 0$: convexa. Es estrictamente convexa, aunque H sea singular en $x = 0$: si $a \neq b$, o bien $a_1 \neq b_1$ y la parte x^4 da desigualdad estricta, o bien $a_2 \neq b_2$ y la da la parte y^2.

Resultado. **(a) estrictamente convexa; (b) no convexa; (c) convexa, no estrictamente; (d) estrictamente convexa.**

Comprobación. en (b), $f(t,t) = -2t^2$ es cóncava a lo largo de la diagonal, dirección del autovector $(1,1)$ de autovalor -2.

Solución del ejercicio 5.3

Datos. dominio $\mathbb{R}^2_{++}$, abierto y convexo.

Planteamiento. teorema 5.5 aplicado a f y a $-f$.

Desarrollo.

(a) $f = x_1x_2$: $H = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$, autovalores ± 1. No es convexa ni cóncava.

(b) $f = x_1^{-1}x_2^{-1}$: $f_{11} = 2x_1^{-3}x_2^{-1}$, $f_{12} = x_1^{-2}x_2^{-2}$, $f_{22} = 2x_1^{-1}x_2^{-3}$. Entonces $f_{11} > 0$ y $\det H = 4x_1^{-4}x_2^{-4} - x_1^{-4}x_2^{-4} = 3(x_1x_2)^{-4} > 0$, luego $H \succ 0$: estrictamente convexa.

(c) $f = x_1^2/x_2$: $f_{11} = 2/x_2$, $f_{12} = -2x_1/x_2^2$ y $f_{22} = 2x_1^2/x_2^3$, es decir,

$$H = \frac{2}{x_2^3}\begin{pmatrix} x_2^2 & -x_1x_2 \\ -x_1x_2 & x_1^2 \end{pmatrix} = \frac{2}{x_2^3}\,ww^\top, \qquad w = (x_2, -x_1)^\top.$$

Como $v^\top ww^\top v = (w^\top v)^2 \geq 0$ y $x_2 > 0$, $H \succeq 0$: convexa.

Resultado. **(a) ni convexa ni cóncava; (b) convexa (estrictamente); (c) convexa.**

Comprobación. en $(1,1)$: en (b), $H = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, con autovalores 1 y 3; en (c), $H = \begin{pmatrix} 2 & -2 \\ -2 & 2 \end{pmatrix}$, con autovalores 0 y 4.

Solución del ejercicio 5.4

Datos. $L(w_1, w_2) = (2 - w_1w_2)^2$.

Planteamiento. proposición 5.12 y teorema 4.9.

Desarrollo.

1. (a) $L(1,2) = L(2,1) = (2-2)^2 = 0 = \min L$, porque $L \geq 0$.
2. Punto medio (1,5; 1,5): $L = (2 - 2{,}25)^2 = 0{,}0625 > 0$.

3. (b) $L_{w_1} = -2w_2(2 - w_1w_2)$, de donde $L_{w_1w_1} = 2w_2^2$ y $L_{w_1w_2} = -2(2 - w_1w_2) + 2w_1w_2 = 4w_1w_2 - 4$; por simetría, $L_{w_2w_2} = 2w_1^2$.
4. $H_L(0,0) = \begin{pmatrix} 0 & -4 \\ -4 & 0 \end{pmatrix}$, con autovalores ± 4; como $\nabla L(0,0) = 0$, el origen es un punto de silla.
5. (c) El conjunto de mínimos no es convexo, luego L no es convexa (proposición 5.12). Lo confirma también que $H_L(0,0)$ no es semidefinida positiva.

Resultado. **(a) $L(1,2) = L(2,1) = 0$ y $L(1{,}5;\ 1{,}5) = 0{,}0625$; (b) silla, con autovalores ± 4; (c) L no es convexa.**

Comprobación. la definición 5.2 exigiría $L(1{,}5;\ 1{,}5) \le \frac{1}{2} \cdot 0 + \frac{1}{2} \cdot 0 = 0$, que es falso.

Solución del ejercicio 5.5

Datos. $L(W) = \varphi(Wx)$ con $\varphi(z) = -z_c + \mathrm{LSE}(z)$ convexa (corolario 5.11) y x fijo.

Planteamiento. verificar la definición 5.2 usando la linealidad de $W \mapsto Wx$.

Desarrollo.

1. Sean W_1, W_2, $\lambda \in [0,1]$, $z_1 = W_1x$ y $z_2 = W_2x$.
2. Por la linealidad del producto, $\big(\lambda W_1 + (1-\lambda)W_2\big)x = \lambda z_1 + (1-\lambda)z_2$.
3. Luego $L\big(\lambda W_1 + (1-\lambda)W_2\big) = \varphi\big(\lambda z_1 + (1-\lambda)z_2\big) \le \lambda\varphi(z_1) + (1-\lambda)\varphi(z_2)$, por la convexidad de φ.
4. El último miembro es $\lambda L(W_1) + (1-\lambda)L(W_2)$, que es la desigualdad buscada.
5. En una red $\varphi(W_2\,\sigma(W_1x))$, la aplicación $(W_1, W_2) \mapsto W_2\,\sigma(W_1x)$ no es lineal: aparece el producto de dos parámetros y la no linealidad σ. El paso 2 deja de valer y la desigualdad no puede encadenarse.

Resultado. **$L(W)$ es convexa en W; en una red con capa oculta falla el paso 2, y la convexidad se pierde (ejemplo 5.13).** ■

Comprobación. con $K = 2$ y $m = z_c - z_{c'}$, $\varphi = \ln(1 + e^{-m})$, cuya segunda derivada respecto de m es $\sigma(m)(1 - \sigma(m)) \ge 0$, con σ la función logística.

Solución del ejercicio 5.6

Datos. f estrictamente convexa en C; $L(z) = -z_c + \mathrm{LSE}(z)$; $L_\mu = L + \frac{\mu}{2}\|z\|^2$.

Planteamiento. reducción al absurdo con el punto medio, y proposición 5.9.

Desarrollo.

1. Si $x_1 \neq x_2$ fueran mínimos globales con valor m, la convexidad estricta daría $f\big(\frac{1}{2}(x_1 + x_2)\big) < \frac{1}{2}m + \frac{1}{2}m = m$, imposible.
2. $L(z + t\mathbf{1}) = L(z)$ para todo t; con $a = z$ y $b = z + \mathbf{1}$, la desigualdad de la definición 5.2 es una igualdad, luego L no es estrictamente convexa.
3. $\frac{\mu}{2}\|z\|^2$ tiene hessiano $\mu I \succ 0$ y es estrictamente convexa; la suma de una función convexa y otra estrictamente convexa es estrictamente convexa, pues al sumar las dos desigualdades una de ellas es estricta.

4. Por el paso 1, L_μ tiene a lo sumo un mínimo z^*. Si existe, $\nabla L_\mu(z^*) = p - y + \mu z^* = 0$ (teorema 4.8).
5. Multiplicando por $\mathbf{1}^\top$: $\mathbf{1}^\top(p-y) + \mu\,\mathbf{1}^\top z^* = 0 + \mu \sum_i z_i^* = 0$, luego $\sum_i z_i^* = 0$.

Resultado. **Una función estrictamente convexa tiene a lo sumo un mínimo; L no es estrictamente convexa por su invariancia en la dirección 1, y L_μ sí lo es, con un mínimo (si existe) de componentes de suma nula.** ■

Comprobación. sin regularizar, L ni siquiera alcanza su ínfimo: $L(t\,e_c) = -t + \ln(e^t + K - 1) \to 0$ cuando $t \to \infty$, pero $L > 0$ siempre.

A.6 Tema 6

Solución del ejercicio 6.1

Datos. un modelo con $N \sim 10^{10}$ parámetros.

Planteamiento. comparar el coste de la proposición 6.6 con el de la retropropagación (proposición 2.9).

Desarrollo.

1. Las diferencias centradas requieren $2N$ evaluaciones de la pérdida por gradiente: unas $1{,}4 \cdot 10^{10}$ para $N = 7 \cdot 10^9$.
2. La retropropagación obtiene el gradiente exacto (salvo redondeo) con un coste de unas pocas evaluaciones, independiente de N.
3. Además, las diferencias finitas tienen errores de truncamiento y de redondeo (proposición 6.4), y en bf16 son inútiles.
4. Uso real: verificar la implementación de un gradiente en un modelo pequeño o en algunas componentes o direcciones aleatorias.

Resultado. **serían del orden de 10^9 a 10^{10} veces más caras por paso y menos precisas; se usan solo para comprobar gradientes.**

Comprobación. con un coste de retropropagación de unas 3 evaluaciones, la razón es $1{,}4 \cdot 10^{10}/3 \approx 5 \cdot 10^9$.

Solución del ejercicio 6.2

Datos. $f(x) = x^3$, $x = 1$, $f'(1) = 3$, $f''(1) = 6$, $f''' = 6$.

Planteamiento. definición 6.1; los errores previstos son $\frac{h}{2} f''(\xi)$ y $\frac{h^2}{6} f''' = h^2$.

Desarrollo.

1. $h = 0{,}1$: $f(1{,}1) = 1{,}331$ y $f(0{,}9) = 0{,}729$.
2. Hacia delante: $0{,}331/0{,}1 = 3{,}31$, error $0{,}31$. Centrada: $0{,}602/0{,}2 = 3{,}01$, error $0{,}01$.
3. $h = 0{,}01$: $f(1{,}01) = 1{,}030301$ y $f(0{,}99) = 0{,}970299$ (se conservan todas las cifras, porque la resta las necesita).
4. Hacia delante: $0{,}030301/0{,}01 = 3{,}0301$, error $0{,}0301$. Centrada: $0{,}060002/0{,}02 = 3{,}0001$, error $0{,}0001$.

Resultado. **al dividir h entre 10, el error hacia delante se divide aproximadamente entre 10 ($0{,}31 \to 0{,}0301$) y el centrado exactamente entre 100 ($0{,}01 \to 0{,}0001$).**

Comprobación. para un cúbico, f''' es constante y la proposición 6.2(ii) da el error exacto h^2: $0{,}1^2 = 0{,}01$ y $0{,}01^2 = 0{,}0001$. El error hacia delante es $3h + h^2$: 0,31 y 0,0301.

Solución del ejercicio 6.3

Datos. $f(x, y) = x^2 y + 3y$; $x = (2, 1)$; $v = (1, 1)^\top$; $h = 0{,}01$.

Planteamiento. proposición 6.6: comparar $\nabla f^\top v$ con $\big(f(x + hv) - f(x - hv)\big)/(2h)$.

Desarrollo.

1. Analítico: $\nabla f(2, 1)^\top v = 4 + 7 = 11$.
2. $f(2{,}01;\ 1{,}01) = 4{,}0401 \cdot 1{,}01 + 3{,}03 = 4{,}080501 + 3{,}03 = 7{,}110501$.
3. $f(1{,}99;\ 0{,}99) = 3{,}9601 \cdot 0{,}99 + 2{,}97 = 3{,}920499 + 2{,}97 = 6{,}890499$.
4. Numérico: $(7{,}110501 - 6{,}890499)/0{,}02 = 0{,}220002/0{,}02 = 11{,}0001$.
5. Error relativo: $0{,}0001/11{,}0001 \approx 9{,}1 \cdot 10^{-6}$.

Resultado. 11,0001 **frente a** 11**, con error relativo** $9{,}1 \cdot 10^{-6}$**: el gradiente es correcto; la discrepancia es de truncamiento.**

Comprobación. $\phi(t) = f(2 + t, 1 + t) = t^3 + 5t^2 + 8t + 4 + 3(1 + t)$ tiene $\phi''' = 6$, y el error previsto es $\frac{h^2}{6} \cdot 6 = h^2 = 10^{-4}$, exactamente el observado. Con $h = 10^{-5}$ el error relativo bajaría a unos 10^{-11}.

Solución del ejercicio 6.4

Datos. tres pares (analítico, numérico) y $f(x) = \max(0, x)$, $x = 10^{-6}$, $h = 10^{-5}$.

Planteamiento. definición 6.5 y criterios orientativos de [4].

Desarrollo.

(a) $r = 10^{-7}/1{,}0000001 \approx 1{,}0 \cdot 10^{-7}$: gradiente correcto.

(b) $r = 0{,}02/0{,}52 \approx 3{,}8 \cdot 10^{-2} > 10^{-2}$: casi con seguridad hay un error.

(c) $r = 5 \cdot 10^{-7}/1{,}0005 \cdot 10^{-3} \approx 5{,}0 \cdot 10^{-4}$: zona dudosa; en una función derivable debe revisarse. Obsérvese que el error absoluto, $5 \cdot 10^{-7}$, parecería pequeño: por eso se usa el relativo.

(d) $f(x + h) = 1{,}1 \cdot 10^{-5}$ y $f(x - h) = \max(0, -9 \cdot 10^{-6}) = 0$; la diferencia centrada es $1{,}1 \cdot 10^{-5}/(2 \cdot 10^{-5}) = 0{,}55$, frente a $f'(x) = 1$. Error relativo: $0{,}45/1 = 0{,}45$.

Resultado. **(a)** $1{,}0 \cdot 10^{-7}$**, correcto; (b)** $3{,}8 \cdot 10^{-2}$**, erróneo; (c)** $5{,}0 \cdot 10^{-4}$**, sospechoso; (d)** 0,55 **frente a 1, error relativo** 0,45**, porque** $x - h < 0 < x + h$**: el intervalo cruza el punto no derivable de ReLU.**

Comprobación. en (d), con $x = 10^{-3}$ el intervalo $[x - h, x + h]$ queda en la parte lineal y la diferencia centrada vale exactamente 1.

Solución del ejercicio 6.5

Datos. $N = 7 \cdot 10^9$; 1 s por evaluación.

Planteamiento. proposición 6.6: $2N$ evaluaciones.

Desarrollo.

1. Evaluaciones: $2 \cdot 7 \cdot 10^9 = 1{,}4 \cdot 10^{10}$.
2. Un año tiene $365{,}25 \cdot 24 \cdot 3600 = 3{,}156 \cdot 10^7$ s.
3. Tiempo: $1{,}4 \cdot 10^{10} / 3{,}156 \cdot 10^7 \approx 443{,}6$ años, para un solo gradiente.
4. Alternativa: retropropagación para el gradiente y comprobación numérica en un modelo diminuto o en unas pocas direcciones aleatorias, a dos evaluaciones por dirección.

Resultado. $1{,}4 \cdot 10^{10}$ **evaluaciones, unos 444 años por gradiente.**

Comprobación. 10^{10} s/$(3 \cdot 10^7$ s/año$) \approx 330$ años, que multiplicado por 1,4 da del orden de 450.

Solución del ejercicio 6.6

Datos. errores de evaluación $\leq \varepsilon|f|$; $|\phi'''| \leq M$, $|\phi''| \leq M_2$; $f = e^x$ en 0 con $|f| = M = 1$, $\varepsilon = 1{,}1 \cdot 10^{-16}$.

Planteamiento. acotar por separado redondeo y truncamiento, y minimizar la suma en $h > 0$.

Desarrollo.

1. Redondeo (centrada): el numerador calculado es $f(x+h) - f(x-h) + \epsilon_1 - \epsilon_2$ con $|\epsilon_i| \leq \varepsilon|f|$; dividido por $2h$, el error es $\leq 2\varepsilon|f|/(2h) = \varepsilon|f|/h$.
2. Truncamiento: $\leq Mh^2/6$ por la proposición 6.2(ii). Total: $E(h) = \varepsilon|f|/h + Mh^2/6$.
3. $E'(h) = -\varepsilon|f|/h^2 + Mh/3 = 0$ si y solo si $h^3 = 3\varepsilon|f|/M$; E' es negativa antes y positiva después, luego $h^* = (3\varepsilon|f|/M)^{1/3}$ es el mínimo global.
4. Con $\varepsilon|f| = M(h^*)^3/3$: $E(h^*) = M(h^*)^2/3 + M(h^*)^2/6 = M(h^*)^2/2$.
5. Caso numérico: $h^* = (3{,}3 \cdot 10^{-16})^{1/3} \approx 6{,}91 \cdot 10^{-6}$ y $E(h^*) = \frac{1}{2}(6{,}91 \cdot 10^{-6})^2 \approx 2{,}39 \cdot 10^{-11}$.
6. Hacia delante: $E_+(h) = 2\varepsilon|f|/h + M_2 h/2$; $E'_+(h) = 0$ da $h^*_+ = 2(\varepsilon|f|/M_2)^{1/2}$ y $E_+(h^*_+) = 2(\varepsilon|f|M_2)^{1/2}$, ambos de orden $\varepsilon^{1/2}$. Con los datos, $h^*_+ \approx 2{,}1 \cdot 10^{-8}$ y $E_+ \approx 2{,}1 \cdot 10^{-8}$.

Resultado. $h^* = (3\varepsilon|f|/M)^{1/3} \approx 6{,}9 \cdot 10^{-6}$ **y** $E(h^*) = \frac{M}{2}(h^*)^2 \approx 2{,}4 \cdot 10^{-11}$**; hacia delante, paso y error de orden** $\varepsilon^{1/2} \approx 10^{-8}$**.** ■

Comprobación. en la figura 6.1, el error medido mínimo es $1{,}2 \cdot 10^{-11}$ en $h = 10^{-5}$, por debajo de la cota $2{,}4 \cdot 10^{-11}$ y con un paso próximo a h^*. La diferencia centrada es unas mil veces más precisa que la diferencia hacia delante en su mejor caso.

Bibliografía

[1] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. Cap. 3, «Convex functions», y cap. 4, «Convex optimization problems». Texto del curso EE364a de Stanford. https://web.stanford.edu/~boyd/cvxbook/

[2] S. Boyd. EE364a: Convex Optimization I. Stanford University. Transparencias de la clase «Convex functions». https://web.stanford.edu/class/ee364a/lectures/functions.pdf

[3] C. Manning *et al.* CS224N: Natural Language Processing with Deep Learning. Stanford University, invierno de 2021. Tarea 2, «word2vec». https://web.stanford.edu/class/archive/cs/cs224n/cs224n.1214/assignments/a2.pdf

[4] A. Karpathy y equipo docente de CS231n. CS231n: Deep Learning for Computer Vision. Notas del curso, «Neural Networks Part 3: Learning and Evaluation», sección «Gradient checks». Stanford University. https://cs231n.github.io/neural-networks-3/

[5] Y. N. Dauphin, R. Pascanu, C. Gulcehre, K. Cho, S. Ganguli e Y. Bengio. Identifying and attacking the saddle point problem in high-dimensional non-convex optimization. En *Advances in Neural Information Processing Systems 27 (NeurIPS)*, 2014. https://arxiv.org/abs/1406.2572

[6] M. P. Deisenroth, A. A. Faisal y C. S. Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020. Cap. 5, «Vector Calculus». https://mml-book.github.io/

[7] I. Goodfellow, Y. Bengio y A. Courville. *Deep Learning*. MIT Press, 2016. Cap. 4, «Numerical Computation», y §6.5, «Back-Propagation and Other Differentiation Algorithms». https://www.deeplearningbook.org/

[8] D. Auroux. 18.02: Multivariable Calculus. Massachusetts Institute of Technology, MIT OpenCourseWare, primavera de 2006. https://ocw.mit.edu/courses/18-02-multivariable-calculus-spring-2006/

[9] K. B. Petersen y M. S. Pedersen. *The Matrix Cookbook*. Technical University of Denmark, versión del 15 de noviembre de 2012.

[10] A. Zhang, Z. C. Lipton, M. Li y A. J. Smola. *Dive into Deep Learning*, versión 1.0.3. Cambridge University Press, 2023. §2.4, «Calculus». https://d2l.ai/