Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase I · Hito 1 · Examen de hito

Hito 1

Fundamentos matemáticos

Módulos 1 a 6

Examen, proyecto de fase y soluciones

Edición de octubre de 2026

Instrucciones

Este examen cierra la Fase I del curso. Evalúa las herramientas matemáticas que se emplean en el resto del programa: la probabilidad del siguiente token, los vectores y las matrices, los gradientes, la estimación estadística y la medida de la información en bits.

Condiciones del examen

Duración	2 horas. Reparto orientativo: 30 minutos para la parte A y 90 minutos para la parte B.
Material permitido	Calculadora científica y una hoja A4 de fórmulas escrita a mano por el estudiante. No se permiten apuntes, libros ni dispositivos con conexión.
Puntuación total	100 puntos: parte A, 30 puntos; parte B, 70 puntos.
Aprobado	70 puntos o más (70 %).
Módulos evaluados	M01 a M06 (véase la tabla siguiente).

Normas

1. **Parte A. Cuestiones** (30 puntos): 20 preguntas de opción múltiple, de 1,5 puntos cada una. Cada pregunta tiene una sola respuesta correcta. Las respuestas en blanco y las erróneas valen 0 puntos; las erróneas no restan.
2. **Parte B. Problemas** (70 puntos): 6 problemas de desarrollo, uno por módulo. La puntuación de cada apartado figura entre corchetes.
3. En la parte B debe escribirse el razonamiento completo. Un resultado correcto sin justificación se puntúa con la mitad de los puntos del apartado.
4. Los resultados se dan con 3 cifras significativas salvo que se indique otra cosa; en los pasos intermedios conviene conservar 4 o más. Se escribe ln para el logaritmo natural (resultados en nats) y $\log_2$ para el logaritmo en base 2 (resultados en bits).
5. El *proyecto de fase* (capítulo final del enunciado) se entrega aparte, en el plazo de una semana, y cuenta en la nota de la fase, no en la de este examen.

Módulos evaluados

Módulo	Título	Cuestiones	Problema
M01	Modelos de lenguaje probabilísticos	1–4	B.1
M02	Álgebra lineal I	5–6	B.2
M03	Álgebra lineal II	7–11	B.3
M04	Cálculo para el aprendizaje automático	12–14	B.4
M05	Probabilidad y estadística	15–17	B.5
M06	Teoría de la información	18–20	B.6

Procedencia de los problemas

Los problemas B.3, B.4, B.5 y B.6 están adaptados, total o parcialmente, de exámenes y hojas de problemas de cursos universitarios (MIT 18.06, Stanford CS224N, MIT 18.05 y la asignatura *Information Theory* de la Universidad de Cambridge); la fuente se indica al pie de cada enunciado y en la bibliografía. Los enunciados son de redacción propia y los datos se han cambiado para que puedan resolverse a mano. Las soluciones completas están en el apéndice A, y la tabla de autoevaluación, en el apéndice B.

Índice

Instrucciones **ii**

Parte A. Cuestiones **1**

Parte B. Problemas **5**

Proyecto de fase **9**

A Soluciones **12**

A.1 Parte A: clave de respuestas 12

A.2 Parte B: soluciones de los problemas 13

B Autoevaluación **24**

B.1 Cálculo de la nota 24

B.2 Puntuación por módulo 24

B.3 Puerta de salida de la Fase I 24

B.4 Qué repasar según los fallos 25

B.5 Qué hacer si no se alcanza el umbral 25

Bibliografía **27**

Parte A. Cuestiones

Veinte preguntas de opción múltiple, de 1,5 puntos cada una (30 puntos en total). Cada pregunta tiene una sola respuesta correcta; las respuestas erróneas no restan. Tiempo orientativo: 30 minutos.

Módulo 1. Modelos de lenguaje probabilísticos

1. La regla de la cadena $P(x_1, \ldots, x_T) = \prod_{t=1}^{T} P(x_t \mid x_1, \ldots, x_{t-1})$: (1,5 puntos)

(a) es una aproximación que solo es válida para modelos de bigramas.

(b) es una identidad exacta para cualquier distribución sobre secuencias.

(c) exige que los tokens sean independientes entre sí.

(d) solo es válida si todas las probabilidades son estrictamente positivas.

2. Con un vocabulario de 28 tokens (27 letras y el símbolo $\langle . \rangle$), ¿cuántas casillas tiene la tabla de conteos de un modelo de trigramas? (1,5 puntos)

(a) 784

(b) 2187

(c) 21 952

(d) 614 656

3. Un modelo asigna probabilidad $1/4$ a cada token de un texto de validación. Su perplejidad sobre ese texto es: (1,5 puntos)

(a) 0,25

(b) 2

(c) 4

(d) $\ln 4 \approx 1{,}386$

4. Cuando la temperatura tiende a infinito, $T \to \infty$, la distribución $\mathrm{softmax}_T(z)$ de un vector de logits $z \in \mathbb{R}^K$ tiende a: (1,5 puntos)

(a) un vector one-hot en la posición del logit máximo.

(b) la distribución uniforme $(1/K, \ldots, 1/K)$.

(c) $\mathrm{softmax}(z)$, la distribución a temperatura $T = 1$.

(d) el vector nulo.

Módulo 2. Álgebra lineal I

5. La similitud coseno entre $u = (1, 1)$ y $v = (3, 0)$ vale: (1,5 puntos)

(a) 0

(b) 0,5

(c) 0,707

(d) 1

6. Sea $E \in \mathbb{R}^{K \times d}$ la matriz de embeddings, con una fila por token, y sea $e_i \in \mathbb{R}^K$ el vector one-hot del token i. El producto $e_i^\top E$ es: (1,5 puntos)

(a) la columna i de E.

(b) la fila i de E.

(c) la suma de todas las filas de E.

(d) un escalar.

Módulo 3. Álgebra lineal II

7. En NumPy, un tensor de forma $(8, 128, 512)$ multiplicado mediante el operador `@` por una matriz de forma (512, 50 000) produce un tensor de forma: (1,5 puntos)

(a) (8, 128, 50 000)

(b) (8, 512, 50 000)

(c) (128, 50 000)

(d) ninguna: se produce un error de dimensiones.

8. La matriz $\begin{pmatrix} 2 & 1 \\ 4 & 2 \end{pmatrix}$: (1,5 puntos)

(a) tiene rango 2 y es invertible.

(b) tiene rango 1 y uno de sus autovalores es 0.

(c) tiene rango 0.

(d) tiene determinante 8.

9. Una matriz tiene valores singulares 5, 3 y 1. El error, en norma de Frobenius, de su mejor aproximación de rango 1 es: (1,5 puntos)

(a) 1

(b) 3

(c) $\sqrt{10} \approx 3{,}16$

(d) 4

10. Antes de aplicar el análisis de componentes principales (PCA) se centran los datos porque: (1,5 puntos)

(a) sin centrar, la SVD de la matriz de datos no existe.

(b) sin centrar, la primera componente tiende a apuntar hacia la media de los datos en lugar de hacia la dirección de máxima varianza.

(c) al centrar, los autovalores de la covarianza son negativos.

(d) al centrar, la matriz de covarianza es diagonal.

11. Se suman dos arrays con las reglas de *broadcasting* de NumPy. ¿Cuál de estas combinaciones de formas produce un error? (1,5 puntos)

(a) $(16, 128, 512)$ y $(512,)$

(b) $(16, 128, 512)$ y $(128, 1)$

(c) $(16, 128, 512)$ y $(16, 128)$

(d) $(16, 128, 512)$ y $(1, 1, 512)$

Módulo 4. Cálculo para el aprendizaje automático

12. El gradiente de $f(x, y) = x^2 y$ en el punto $(1, 3)$ es: (1,5 puntos)

(a) $(2, 1)$

(b) $(6, 1)$

(c) $(6, 3)$

(d) $(3, 2)$

13. Sean $p = \text{softmax}(z)$ e y el vector one-hot de la clase correcta c. Para la pérdida $L = -\ln \text{softmax}(z)_c$, el gradiente $\nabla_z L$ es: (1,5 puntos)

(a) p

(b) $y - p$

(c) $p - y$

(d) $-\ln p$

14. Para una función f de clase C^3, el error de truncamiento de la diferencia centrada $[f(x + h) - f(x - h)]/(2h)$ como aproximación de $f'(x)$ es del orden de: (1,5 puntos)

(a) h

(b) h^2

(c) $1/h$

(d) no depende de h.

Módulo 5. Probabilidad y estadística

15. Una variable de Bernoulli de parámetro $p = 0{,}2$ tiene varianza: (1,5 puntos)

(a) 0,04

(b) 0,16

(c) 0,2

(d) 0,8

16. El estimador de máxima verosimilitud de los parámetros de una distribución categórica a partir de los conteos $N_1, \ldots, N_K$ es: (1,5 puntos)

(a) $\hat{p}_j = 1/K$

(b) $\hat{p}_j = (N_j + 1)/\big(\sum_k N_k + K\big)$

(c) $\hat{p}_j = N_j / \sum_k N_k$

(d) $\hat{p}_j = \sqrt{N_j} / \sum_k \sqrt{N_k}$

17. Si se multiplica por 4 el tamaño de un minilote de ejemplos *i.i.d.*, la desviación típica de la pérdida media del minilote: (1,5 puntos)

(a) se divide por 4.

(b) se divide por 2.

(c) no cambia.

(d) se multiplica por 2.

Módulo 6. Teoría de la información

18. La entropía de una distribución uniforme sobre 8 símbolos es: (1,5 puntos)

(a) 1 bit

(b) 2 bits

(c) 3 bits

(d) 8 bits

19. Sobre la divergencia de Kullback–Leibler $D(p \,\|\, q)$ entre distribuciones discretas es cierto que: (1,5 puntos)

(a) es simétrica: $D(p \,\|\, q) = D(q \,\|\, p)$.

(b) puede ser negativa si q se parece mucho a p.

(c) es mayor o igual que 0 y vale 0 si y solo si $p = q$.

(d) es igual a la entropía de q.

20. Un texto tiene entropía $H(p) = 2$ bits por carácter y un modelo q alcanza sobre él una entropía cruzada $H(p, q) = 2{,}5$ bits por carácter. La divergencia $D(p \,\|\, q)$ vale: (1,5 puntos)

(a) 0,5 bits

(b) 1,25 bits

(c) 4,5 bits

(d) no puede determinarse con estos datos.

Parte B. Problemas

Seis problemas de desarrollo, uno por módulo (70 puntos en total). La puntuación de cada apartado figura entre corchetes. Tiempo orientativo: 90 minutos.

Ejercicio B.1 ⋆⋆ Modelo de bigramas (M01). 12 puntos.

El corpus de entrenamiento está formado por las palabras «mar», «ama» y «rama». El vocabulario es $\mathcal{V} = \{\langle . \rangle, \mathtt{a}, \mathtt{m}, \mathtt{r}\}$, donde $\langle . \rangle$ marca el inicio y el fin de cada palabra.

(a) **[3]** Construya la matriz de conteos N y la matriz de probabilidades de máxima verosimilitud P. ¿Cuántos bigramas hay en total?

(b) **[3]** Calcule $P(\text{mar})$, $P(\text{rama})$ y $P(\text{mama})$. Explique por qué «mama», que no aparece en el corpus, recibe la misma probabilidad que «ama».

(c) **[3]** Calcule la pérdida media (entropía cruzada) del modelo sobre el corpus de entrenamiento, en nats y en bits, y su perplejidad. Compárela con la del modelo uniforme sobre $\mathcal{V}$ y valore la comparación.

(d) **[2]** Aplique suavizado de Laplace ($\alpha = 1$) y calcule $P(\mathtt{a} \mid \mathtt{m})$ y $P(\mathtt{r} \mid \mathtt{r})$.

(e) **[1]** Con el orden $(\langle . \rangle, \mathtt{a}, \mathtt{m}, \mathtt{r})$ y el método de la inversa de la función de distribución, determine el token que sigue a «a» para $u = 0{,}35$, $u = 0{,}55$ y $u = 0{,}9$.

Fuente: elaboración propia, con la notación de Jurafsky y Martin [5, cap. 3].

Ejercicio B.2 ⋆⋆ Embeddings y analogías (M02). 10 puntos.

Se consideran los siguientes embeddings de juguete en $\mathbb{R}^3$; e_w denota el embedding de la palabra w.

Palabra	Vector	Palabra	Vector	Palabra	Vector
rey	$(3, 2, 1)$	mujer	$(1, -2, 2)$	princesa	$(2, -1, 2)$
hombre	$(0, 2, 2)$	reina	$(3, -2, 1)$	niña	$(0, -1, 2)$

(a) **[2]** Calcule $e_{\text{rey}} \cdot e_{\text{reina}}$, $\|e_{\text{rey}}\|$ y $\cos(e_{\text{rey}}, e_{\text{reina}})$.

(b) **[4]** Calcule $q = e_{\text{rey}} - e_{\text{hombre}} + e_{\text{mujer}}$ y su coseno con e_{reina}, e_{princesa} y $e_{\text{niña}}$. ¿Qué palabra devuelve la analogía? ¿Qué coordenada parece codificar el género?

(c) **[2]** Aplique $W = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ a e_{rey} y a e_{reina}. ¿Qué coseno tienen las imágenes? Determine el núcleo de W y explique qué información destruye.

(d) **[2]** *Estimación.* La capa de salida de un LLM multiplica un vector de dimensión 1024 por una matriz de $50\,000 \times 1024$ para obtener los logits. ¿Cuántas operaciones de coma flotante (productos y sumas) cuesta por token? Con un procesador que ejecuta 10^{12} operaciones útiles por segundo, ¿cuánto tarda?

Fuente: elaboración propia, a partir del ejemplo de analogías de Mikolov *et al.* [6].

Ejercicio B.3 ⋆⋆ Autovalores, SVD y bajo rango (M03). 12 puntos.

Sean $A = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ y $B = \begin{pmatrix} 0 & -2 \\ 3 & 0 \end{pmatrix}$.

(a) **[3]** Calcule los autovalores de A y una base ortonormal de autovectores. ¿Son ortogonales los autovectores? Justifique por qué.

(b) **[2]** Calcule A^{-1}, compruebe que $AA^{-1} = I$ y relacione los autovalores de A^{-1} con los de A.

(c) **[3]** Calcule la SVD $B = U\Sigma V^\top$ en dos pasos: primero V y Σ a partir de $B^\top B$; después las columnas de U mediante $u_i = Bv_i/\sigma_i$. Obtenga la mejor aproximación de rango 1, B_1, el error $\|B - B_1\|_F$ y la fracción de energía $\sigma_1^2/(\sigma_1^2 + \sigma_2^2)$ que retiene. ¿Por qué la SVD de B no puede leerse de sus autovalores, como en el caso de A?

(d) **[4]** *Estimación.* Una matriz de pesos de 2048×1024 se almacena como aproximación de rango $k = 64$ (factores U_k, V_k y los k valores singulares). ¿Cuántos números se almacenan y qué fracción del original suponen? ¿A partir de qué k deja de compensar? Compárelo con LoRA de rango $r = 8$ sobre una matriz de 4096×4096: ¿cuántos parámetros se entrenan y qué porcentaje de la matriz representan?

Fuente: apartado (c) adaptado de MIT 18.06, primavera de 2010, examen 3, problema 3(c) [8] (SVD en dos pasos a partir de $A^\top A$, con otra matriz); apartado (d), del ejercicio de compresión y LoRA de los apuntes del M03 y de Hu *et al.* [4].

Ejercicio B.4 ⋆⋆⋆ Gradiente de la softmax con entropía cruzada (M04). 14 puntos.

Una capa lineal sin sesgo produce los logits $z = Wx$, con

$$W = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix}, \qquad x = \begin{pmatrix} 1 \\ 2 \end{pmatrix},$$

y el token correcto es el primero ($c = 1$). Sean $p = \mathrm{softmax}(z)$, y el vector one-hot de c y $L = -\ln p_c$.

(a) **[4]** *Derivación.* Demuestre que L coincide con la entropía cruzada $H(y, p) = -\sum_k y_k \ln p_k$ y que puede escribirse como $L = -z_c + \ln \sum_j e^{z_j}$. A partir de esta expresión, demuestre que $\partial L/\partial z_k = p_k - y_k$.

(b) **[3]** Calcule z, p y L.

(c) **[4]** Calcule $\nabla_z L$, $\partial L/\partial W$ y $\partial L/\partial x$ mediante la regla de la cadena, indicando la forma de cada resultado.

(d) **[2]** Dé un paso de descenso de gradiente sobre W con tasa de aprendizaje $\eta = 0{,}5$ y calcule la nueva pérdida.

(e) **[1]** Compruebe $\partial L/\partial W_{11}$ con una diferencia centrada de paso $h = 0{,}01$ y calcule el error relativo $r(a, n) = |a - n|/\max(|a|, |n|)$.

Fuente: apartados (a) y (c) adaptados de Stanford CS224N, tarea 2, preguntas 1(a), 1(b) y 1(d)–(e) [3] (equivalencia entre la pérdida *naive-softmax* y la entropía cruzada, y gradientes respecto de los vectores y de la matriz de salida); el resto, de elaboración propia.

Ejercicio B.5 ⋆⋆ Estimación y regla de Bayes (M05). 11 puntos.

(a) **[4]** *Derivación.* Un modelo muy simple supone que, tras cada letra, el nombre termina con probabilidad constante q, de modo que la longitud L (en letras) sigue la distribución geométrica $P(L = k) = (1 - q)^{k-1}q$, $k \geq 1$. Se observan las longitudes 3, 4, 5, 5, 6 y 7. Obtenga el estimador de máxima verosimilitud $\hat{q}$, compruebe que es un máximo y calcule su valor, $P(L = 3)$ y $\mathbb{E}[L] = 1/\hat{q}$.

(b) **[3]** Un cajón contiene tres dados de 4 caras, uno de 6 y uno de 12, todos equilibrados. Se extrae un dado al azar, se lanza una vez y sale un 5. Construya la tabla de Bayes (a priori, verosimilitud, producto y a posteriori) para el tipo de dado. Calcule la probabilidad predictiva a priori de obtener un 5 y la probabilidad de que un segundo lanzamiento del mismo dado dé un 6.

(c) **[4]** *Estimación numérica.* Un modelo acierta el 78 % de un banco de pruebas de 600 preguntas. Calcule el error típico de la exactitud y el intervalo de confianza aproximado del 95 %. ¿Cuántas preguntas harían falta para que la semianchura del intervalo fuera de 1 punto porcentual?

Fuente: apartado (b) adaptado de MIT 18.05, primavera de 2014, examen 2, problema 3 [7] (tabla de Bayes discreta para el tipo de dado, con otros dados y otra pregunta predictiva); apartados (a) y (c), de elaboración propia.

Ejercicio B.6 ⋆⋆ Entropía, compresión y bits por byte (M06). 11 puntos.

Una fuente emite los símbolos `a`, `b`, `c`, `d`, `e` con probabilidades $p = (1/4,\ 1/4,\ 1/4,\ 1/8,\ 1/8)$.

(a) **[3]** Calcule $H(p)$ en bits. Construya un código de Huffman, calcule su longitud media y compárela con $H(p)$. Compruebe la desigualdad de Kraft. Codifique el mensaje «`abed`» e indique cuántos bits ocupa.

(b) **[3]** Sean q la distribución uniforme sobre los cinco símbolos y q' la distribución $(1/8,\ 1/8,\ 1/4,\ 1/4,\ 1/4)$. Calcule $H(p, q)$, $D(p \,\|\, q)$, $H(p, q')$ y $D(p \,\|\, q')$. ¿Cuántos bits por símbolo de más paga cada modelo? ¿Cuál es mejor?

(c) **[5]** *Estimación.* Un LLM obtiene una pérdida de validación de 1,8 nats por token, con 4,2 bytes de texto por token en promedio. Calcule su perplejidad, los bits por token y los bits por byte. ¿Cuánto ocuparía 1 GB (10^9 bytes) de ese texto comprimido mediante codificación aritmética con este modelo? ¿Qué razón de compresión supone?

Fuente: apartado (a) adaptado de la hoja de ejemplos de *Information Theory*, Universidad de Cambridge, curso 2025–26, supervisión 1, ejercicio 12 [1] (códigos de Huffman y comparación de la longitud media con la entropía), según el planteamiento de Cover y Thomas [2, §5.6]; apartados (b) y (c), de elaboración propia.

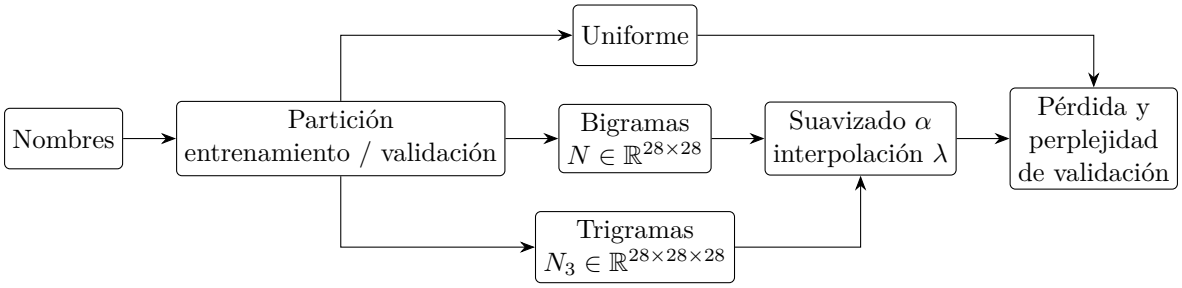
Proyecto de fase

Perplejidad: modelo uniforme, bigramas y trigramas

Objetivo. Medir, con la métrica con la que se comparan los modelos de lenguaje, cuánto mejora un modelo de caracteres al ampliar el contexto, y explicar por qué más contexto no siempre es mejor cuando hay pocos datos. El proyecto integra el modelo de n-gramas y el suavizado (M01, §2.3 y §3.3), la perplejidad (M01, §5.1), los tensores (M03, §6.1) y la conversión a bits (M06, §2.3).

Datos. La lista de 316 nombres del cuaderno de prácticas del M01, con el mismo vocabulario de 28 tokens ($\langle . \rangle$ y las 27 letras del alfabeto español) y la misma partición: generador `np.random.default_rng(7)`, un 15 % para validación (47 nombres, 321 tokens que predecir) y los 269 restantes para entrenamiento. No se descarga ningún dato.

Plazo. Una semana desde la realización del examen. El proyecto cuenta en la nota de la fase, no en la del examen.



Flujo de trabajo del proyecto de fase.

Entregables.

1. Un cuaderno `H1-proyecto.ipynb` que se ejecute de principio a fin en CPU en menos de un minuto y sin errores.
2. Una tabla con la pérdida de validación (en nats y en bits) y la perplejidad de cada modelo.
3. Una gráfica de la perplejidad de validación frente a α, con escala logarítmica en α, para bigramas y trigramas.
4. Un informe breve (a lo sumo una página, en celdas de texto del cuaderno) que responda a las preguntas del paso 6.

Pasos.

1. *Tokenización con relleno.* Para bigramas, cada nombre se rodea de un símbolo $\langle . \rangle$ a cada lado; para trigramas, se antepone $\langle . \rangle\langle . \rangle$ y se añade $\langle . \rangle$ al final. Así, ambos modelos predicen exactamente los mismos $\ell + 1$ tokens de un nombre de ℓ letras. Debe comprobarse con un `assert` que el número de predicciones coincide.

2. *Modelo uniforme.* $P(x_t) = 1/28$. Justifique, sin hacer ningún cálculo sobre los datos, que su perplejidad es 28.

3. *Bigramas.* Con la matriz N y el suavizado de Laplace generalizado del M01, $P_\alpha(j \mid i) = (N_{ij} + \alpha)/\big(\sum_k N_{ik} + 28\alpha\big)$.

4. *Trigramas.* Con el tensor N_3 de $28\times28\times28$ conteos, $P_\alpha(k \mid i, j) = (N_{3,ijk}+\alpha)/\big(\sum_l N_{3,ijl}+ 28\alpha\big)$. Cuente cuántas casillas son distintas de cero.

5. *Barrido de α.* Pruebe al menos $\alpha \in \{0{,}01;\ 0{,}05;\ 0{,}1;\ 0{,}2;\ 0{,}5;\ 1\}$ en ambos modelos y elija α en validación. Se recomienda separar una tercera partición de prueba para que la elección de α no contamine la medida final.

6. *Análisis.* (a) ¿Qué modelo obtiene la menor perplejidad y con qué margen? (b) ¿Por qué el trigrama con suavizado aditivo puede quedar por detrás del bigrama con estos datos? Relaciónelo con la proporción de casillas vacías y con el sobreajuste. (c) ¿Qué perplejidad tendría un modelo perfecto? (d) Convierta la mejor pérdida a bits por carácter y relaciónela con la entropía de la fuente (M06).

7. *Mejora* (necesaria para la calificación de excelente). Implemente la interpolación $P = \lambda P_3 + (1 - \lambda)P_2$, con P_3 el trigrama sin suavizar y P_2 el bigrama suavizado, y elija λ en validación (M01, §3.4). Opcionalmente, añada el modelo de unigramas como referencia intermedia.

Valores de referencia. Con la partición indicada, y solo para comprobar el código: uniforme, 28; unigramas, $\approx 15{,}7$; bigramas con $\alpha = 0{,}2$, $\approx 12{,}4$; trigramas con $\alpha = 0{,}2$, $\approx 13{,}2$; interpolación con bigrama de $\alpha = 0{,}2$ y $\lambda = 0{,}3$, $\approx 11{,}7$. El tensor de trigramas solo tiene 840 casillas no nulas de las 21 952.

Criterios de evaluación

Criterio	Peso	Excelente	Suficiente	Insuficiente
Corrección de los modelos	30 %	Los tres modelos reproducen los valores de referencia; hay `assert` de normalización y del número de predicciones.	Valores correctos, sin comprobaciones explícitas.	Algún modelo mal normalizado, pérdidas infinitas o relleno incoherente.
Metodología de evaluación	20 %	α elegido en validación y medida final en una partición de prueba independiente.	α elegido en validación.	Se evalúa en entrenamiento o se elige α a la vista de la medida final.
Resultados y visualización	15 %	Tabla completa en nats, bits y perplejidad; gráfica con ejes rotulados y escala logarítmica.	Tabla y gráfica legibles, con alguna carencia.	Falta la tabla o la gráfica.
Análisis	25 %	Responde a (a)–(d) con cifras, explica la dispersión del tensor de trigramas e implementa la interpolación.	Responde a (a)–(d) con cifras.	Respuestas vagas o sin números.
Código y reproducibilidad	10 %	Funciones reutilizables, semillas fijas, ejecución en menos de un minuto.	Se ejecuta de principio a fin.	Errores o dependencia del orden manual de ejecución.

Apéndice A

Soluciones

Las referencias a los apuntes siguen el formato «M05, §3.2»: módulo, y número de tema y sección tal como aparecen en el PDF de cada módulo. En los pasos intermedios se conservan al menos 4 cifras significativas y los resultados se dan con 3, como piden las instrucciones; cuando existe, se da también el valor exacto como fracción.

A.1 Parte A: clave de respuestas

Pregunta	Resp.	Justificación	Apuntes
1	(b)	Se obtiene aplicando repetidamente $P(A \cap B) = P(A)\,P(B \mid A)$, sin ninguna aproximación.	M01, §2.2
2	(c)	Dos tokens de contexto y uno predicho: $28^3 = 21\,952$ casillas.	M01, §2.3
3	(c)	PPL $= \exp(-\ln \frac{1}{4}) = 4$: el modelo duda por igual entre 4 opciones.	M01, §5.1
4	(b)	Cada $z_i/T \to 0$, luego cada $e^{z_i/T} \to 1$ y el cociente tiende a $1/K$.	M01, §4.1
5	(c)	$\cos = 3/(\sqrt{2}\cdot 3) = 1/\sqrt{2} \approx 0{,}707$.	M02, §2.3
6	(b)	El único 1 de e_i selecciona la fila i: es la capa de embeddings.	M02, §5.1
7	(a)	`@` actúa sobre las dos últimas dimensiones: $(128, 512)(512, 50\,000)$ para cada uno de los 8 elementos del lote.	M03, §6.2
8	(b)	La segunda fila es el doble de la primera: $\det = 0$, rango 1 y $\lambda = 0$ es autovalor (el otro es la traza, 4).	M03, §1.3 y §3.1
9	(c)	Eckart–Young: $\big(\sum_{i>1} \sigma_i^2\big)^{1/2} = \sqrt{9+1} = \sqrt{10}$.	M03, §5.1
10	(b)	Sin centrar, $X^\top X/n$ es la matriz de segundos momentos y su autovector dominante se orienta hacia la media.	M03, §5.4
11	(c)	Las formas se alinean por la derecha: 128 frente a 512 no coinciden y ninguna es 1.	M03, §6.3
12	(b)	$\partial_x f = 2xy = 6$ y $\partial_y f = x^2 = 1$ en $(1, 3)$.	M04, §1.2
13	(c)	Teorema del gradiente de la entropía cruzada; se deriva en el problema B.4(a).	M04, §3.4
14	(b)	En el desarrollo de Taylor se cancelan los términos pares y queda $\frac{h^2}{6} f'''(\xi)$.	M04, §6.1
15	(b)	$\mathrm{Var}(X) = p(1-p) = 0{,}2 \cdot 0{,}8 = 0{,}16$.	M05, §2.3
16	(c)	Maximizar $\sum_j N_j \ln p_j$ con $\sum_j p_j = 1$ da contar y normalizar; (b) es el suavizado de Laplace.	M05, §4.2; M01, §3.2
17	(b)	La desviación típica de la media de B ejemplos es $\sigma/\sqrt{B}$, y $\sqrt{4} = 2$.	M05, §5.6
18	(c)	$H = \log_2 8 = 3$ bits.	M06, §1.2
19	(c)	Desigualdad de Gibbs; la divergencia no es simétrica.	M06, §2.2
20	(a)	$H(p, q) = H(p) + D(p \,\|\, q)$, luego $D(p \,\|\, q) = 2{,}5 - 2 = 0{,}5$ bits.	M06, §2.3

A.2 Parte B: soluciones de los problemas

Solución del ejercicio B.1

Apartado (a)

Datos. corpus «mar», «ama», «rama»; $\mathcal{V} = \{\langle . \rangle, \mathtt{a}, \mathtt{m}, \mathtt{r}\}$.

Planteamiento. añadir $\langle . \rangle$ al principio y al final de cada palabra, contar cada par (anterior, siguiente) y dividir cada fila por su total (M01, §3.2).

Desarrollo.

1. Secuencias con marcadores: $\langle . \rangle \mathtt{mar} \langle . \rangle$, $\langle . \rangle \mathtt{ama} \langle . \rangle$, $\langle . \rangle \mathtt{rama} \langle . \rangle$.
2. Bigramas de $\langle . \rangle \mathtt{mar} \langle . \rangle$: $(\langle . \rangle, \mathtt{m})$, $(\mathtt{m}, \mathtt{a})$, $(\mathtt{a}, \mathtt{r})$, $(\mathtt{r}, \langle . \rangle)$; son 4.
3. Bigramas de $\langle . \rangle \mathtt{ama} \langle . \rangle$: $(\langle . \rangle, \mathtt{a})$, $(\mathtt{a}, \mathtt{m})$, $(\mathtt{m}, \mathtt{a})$, $(\mathtt{a}, \langle . \rangle)$; son 4.
4. Bigramas de $\langle . \rangle \mathtt{rama} \langle . \rangle$: $(\langle . \rangle, \mathtt{r})$, $(\mathtt{r}, \mathtt{a})$, $(\mathtt{a}, \mathtt{m})$, $(\mathtt{m}, \mathtt{a})$, $(\mathtt{a}, \langle . \rangle)$; son 5.
5. Total: $4+4+5 = 13$. Conteos y, entre paréntesis, probabilidades (fila: anterior; columna: siguiente):

	$\langle . \rangle$	a	m	r	Total
$\langle . \rangle$	0	1 (1/3)	1 (1/3)	1 (1/3)	3
a	2 (0,4)	0	2 (0,4)	1 (0,2)	5
m	0	3 (1)	0	0	3
r	1 (0,5)	1 (0,5)	0	0	2

Resultado. **13 bigramas; N y P como en la tabla.**

Comprobación. los totales de fila suman $3 + 5 + 3 + 2 = 13$ y cada fila de P suma 1.

Criterio de corrección. 2 puntos la matriz N; 1 punto la normalización por filas.

Apartado (b)

Datos. la matriz P del apartado (a).

Planteamiento. regla de la cadena con la hipótesis de Markov de orden 1: la probabilidad de una palabra es el producto de $P(\text{siguiente} \mid \text{anterior})$ a lo largo de $\langle . \rangle \text{palabra} \langle . \rangle$ (M01, §2.3).

Desarrollo.

1. $P(\text{mar}) = P(\mathtt{m} \mid \langle . \rangle) P(\mathtt{a} \mid \mathtt{m}) P(\mathtt{r} \mid \mathtt{a}) P(\langle . \rangle \mid \mathtt{r}) = \frac{1}{3} \cdot 1 \cdot \frac{1}{5} \cdot \frac{1}{2} = \frac{1}{30} \approx 0{,}03333$.
2. $P(\text{rama}) = \frac{1}{3} \cdot \frac{1}{2} \cdot \frac{2}{5} \cdot 1 \cdot \frac{2}{5} = \frac{2}{75} \approx 0{,}02667$.
3. $P(\text{mama}) = P(\mathtt{m} \mid \langle . \rangle) P(\mathtt{a} \mid \mathtt{m}) P(\mathtt{m} \mid \mathtt{a}) P(\mathtt{a} \mid \mathtt{m}) P(\langle . \rangle \mid \mathtt{a}) = \frac{1}{3} \cdot 1 \cdot \frac{2}{5} \cdot 1 \cdot \frac{2}{5} = \frac{4}{75} \approx 0{,}05333$.
4. $P(\text{ama}) = P(\mathtt{a} \mid \langle . \rangle) P(\mathtt{m} \mid \mathtt{a}) P(\mathtt{a} \mid \mathtt{m}) P(\langle . \rangle \mid \mathtt{a}) = \frac{1}{3} \cdot \frac{2}{5} \cdot 1 \cdot \frac{2}{5} = \frac{4}{75}$.
5. «mama» solo usa transiciones observadas. Como el modelo solo mira el token anterior y $P(\mathtt{a} \mid \mathtt{m}) = 1$, el prefijo «ma» cuesta $P(\mathtt{m} \mid \langle . \rangle) P(\mathtt{a} \mid \mathtt{m}) = \frac{1}{3}$, lo mismo que la «a» inicial de «ama», $P(\mathtt{a} \mid \langle . \rangle) = \frac{1}{3}$; el resto de ambas palabras es idéntico.

Resultado. $P(\textbf{mar}) = 1/30 \approx 0{,}0333$**;** $P(\textbf{rama}) = 2/75 \approx 0{,}0267$**;** $P(\textbf{mama}) = P(\textbf{ama}) = 4/75 \approx 0{,}0533$**.**

Comprobación. $P(\text{mama})/P(\text{ama}) = \left(\frac{1}{3} \cdot 1\right) / \frac{1}{3} = 1$.

Criterio de corrección. 1 punto por probabilidad; se resta 1 punto si no se explica la generalización.

Apartado (c)

Datos. $P(\text{mar}) = 1/30$, $P(\text{ama}) = 4/75$, $P(\text{rama}) = 2/75$; 13 predicciones; $|\mathcal{V}| = 4$.

Planteamiento. pérdida media $\mathcal{J} = -\frac{1}{13}\sum \ln P(\text{palabra})$; en bits, $\mathcal{J}/\ln 2$; PPL $= e^{\mathcal{J}}$ (M01, §5.1).

Desarrollo.

1. $\ln(1/30) = -3{,}4012$; $\ln(4/75) = -2{,}9312$; $\ln(2/75) = -3{,}6243$.
2. Suma: $-9{,}9567$.
3. $\mathcal{J} = 9{,}9567/13 = 0{,}7659$ nats.
4. En bits: $0{,}7659/0{,}6931 = 1{,}105$ bits.
5. PPL $= e^{0{,}7659} = 2{,}151$.
6. Modelo uniforme: $P = 1/4$ en cada paso, $\mathcal{J} = \ln 4 = 1{,}386$ nats $= 2$ bits y PPL $= 4$.

Resultado. $\mathcal{J} \approx 0{,}766$ **nats** $\approx 1{,}10$ **bits;** PPL $\approx 2{,}15$**, frente a** 4 **del modelo uniforme.** La comparación es optimista: se mide sobre el propio corpus de entrenamiento, no sobre datos de validación (M01, §5.3).

Comprobación. PPL $= P(\text{corpus})^{-1/13} = \left(\frac{1}{30}\cdot\frac{4}{75}\cdot\frac{2}{75}\right)^{-1/13} = (4{,}741\cdot 10^{-5})^{-1/13} = 2{,}151$.

Criterio de corrección. 1 punto la pérdida; 1 punto bits y perplejidad; 1 punto la comparación, con la advertencia sobre el conjunto de entrenamiento.

Apartado (d)

Datos. fila `m`: $(0, 3, 0, 0)$; fila `r`: $(1, 1, 0, 0)$; $|\mathcal{V}| = 4$; $\alpha = 1$.

Planteamiento. $P_\alpha(v \mid u) = (N(u,v) + \alpha)/\left(\sum_w N(u,w) + \alpha|\mathcal{V}|\right)$ (M01, §3.3).

Desarrollo.

1. Fila `m` suavizada: $(1, 4, 1, 1)$, total $3 + 4 = 7$; $P(\texttt{a} \mid \texttt{m}) = 4/7 \approx 0{,}5714$.
2. Fila `r` suavizada: $(2, 2, 1, 1)$, total $2 + 4 = 6$; $P(\texttt{r} \mid \texttt{r}) = 1/6 \approx 0{,}1667$.

Resultado. $P(\texttt{a} \mid \texttt{m}) = 4/7 \approx 0{,}571$**;** $P(\texttt{r} \mid \texttt{r}) = 1/6 \approx 0{,}167$**.**

Comprobación. la fila `m` suavizada suma $(1+4+1+1)/7 = 1$; el suavizado reduce la probabilidad máxima ($1 \to 0{,}571$) y da probabilidad positiva a los ceros.

Apartado (e)

Datos. fila `a`: $p = (0{,}4;\ 0;\ 0{,}4;\ 0{,}2)$ en el orden $(\langle . \rangle, \texttt{a}, \texttt{m}, \texttt{r})$.

Planteamiento. se calcula la acumulada F_k y se elige el menor k con $u < F_k$ (M01, §4.3).

Desarrollo.

1. $F = (0{,}4;\ 0{,}4;\ 0{,}8;\ 1)$.
2. $u = 0{,}35 < F_1 = 0{,}4$: sale $\langle . \rangle$.
3. $u = 0{,}55$: $F_1 = F_2 = 0{,}4 \le 0{,}55 < F_3 = 0{,}8$: sale `m`. El token `a`, de probabilidad 0, ocupa un intervalo vacío y nunca sale.
4. $u = 0{,}9$: $0{,}8 \le 0{,}9 < 1$: sale `r`.

Resultado. se obtienen, por este orden, los tokens ⟨`.`⟩, `m` y `r`.

Comprobación. los intervalos [0; 0,4), [0,4; 0,8) y [0,8; 1) tienen longitudes 0,4, 0,4 y 0,2, iguales a las probabilidades.

Repasar: M01, §2.3 y §3.2 (apartados a y b); M01, §5.1 y §5.3 (c); M01, §3.3 (d); M01, §4.3 (e).

Solución del ejercicio B.2

Apartado (a)

Datos. $e_{\text{rey}} = (3, 2, 1)$, $e_{\text{reina}} = (3, -2, 1)$.

Planteamiento. producto escalar componente a componente, $\|v\| = \sqrt{v \cdot v}$ y $\cos(u, v) = u \cdot v/(\|u\|\|v\|)$ (M02, §1.2, §1.3 y §2.3).

Desarrollo.

1. $e_{\text{rey}} \cdot e_{\text{reina}} = 9 - 4 + 1 = 6$.
2. $\|e_{\text{rey}}\| = \sqrt{9 + 4 + 1} = \sqrt{14} \approx 3{,}742$, e igualmente $\|e_{\text{reina}}\| = \sqrt{14}$.
3. $\cos = 6/14 = 3/7 \approx 0{,}4286$.

Resultado. **producto escalar** 6**;** $\|e_{\textbf{rey}}\| = \sqrt{14} \approx 3{,}74$**;** $\cos = 3/7 \approx 0{,}429$**.**

Comprobación. $0 < 3/7 < 1$: los vectores coinciden en las coordenadas primera y tercera y difieren en el signo de la segunda.

Apartado (b)

Datos. tabla de embeddings.

Planteamiento. aritmética de vectores y coseno con cada candidato (M02, §5.4).

Desarrollo.

1. $q = (3 - 0 + 1,\ 2 - 2 - 2,\ 1 - 2 + 2) = (4, -2, 1)$ y $\|q\| = \sqrt{21} \approx 4{,}583$.
2. Cosenos:

Palabra w	$q \cdot e_w$	$\|e_w\|$	$\cos(q, e_w)$
reina	$12 + 4 + 1 = 17$	$\sqrt{14}$	$17/\sqrt{294} \approx 0{,}991$
princesa	$8 + 2 + 2 = 12$	3	$12/(3\sqrt{21}) \approx 0{,}873$
niña	$0 + 2 + 2 = 4$	$\sqrt{5}$	$4/\sqrt{105} \approx 0{,}390$

3. Las palabras de la consulta tampoco ganan: rey, $9/\sqrt{294} \approx 0{,}525$; mujer, $10/(3\sqrt{21}) \approx 0{,}727$; hombre, $-2/(\sqrt{21}\sqrt{8}) \approx -0{,}154$.
4. La segunda coordenada vale $+2$ en rey y hombre y -2 en reina y mujer: codifica el género.

Resultado. $q = (4, -2, 1)$**; la analogía devuelve «reina»** ($\cos \approx 0{,}991$)**; el género está en la segunda coordenada.**

Comprobación. $q - e_{\text{reina}} = (1, 0, 0)$: q solo difiere de reina en una unidad de la primera coordenada.

Criterio de corrección. 1 punto q; 2 puntos los cosenos; 1 punto la interpretación.

Apartado (c)

Datos. $W = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$.

Planteamiento. $Wv = (v_1, v_3)$: W conserva la primera y la tercera coordenadas (M02, §3.3); el núcleo se define en M03, §1.3.

Desarrollo.

1. $We_{\text{rey}} = (3, 1)$ y $We_{\text{reina}} = (3, 1)$.
2. Coseno de las imágenes: $10/10 = 1$.
3. $Wv = 0 \iff v_1 = v_3 = 0$: el núcleo es la recta generada por $(0, 1, 0)$ y rango $W = 2$.

Resultado. **ambas imágenes son** $(3, 1)$**, con coseno 1. El núcleo de** W **es** $\text{gen}\{(0, 1, 0)\}$**:** W **destruye la coordenada del género.**

Comprobación. $e_{\text{rey}} - e_{\text{reina}} = (0, 4, 0)$ está en el núcleo, pues $W(0, 4, 0)^\top = (0, 0)^\top$.

Apartado (d)

Datos. vector de dimensión 1024; matriz de $50\,000 \times 1024$; 10^{12} operaciones por segundo.

Planteamiento. cada logit es un producto escalar de 1024 términos: 1024 productos y $1023 \approx 1024$ sumas (M02, §4.4).

Desarrollo.

1. Operaciones por logit: $2 \cdot 1024 = 2048$.
2. Por token: $50\,000 \cdot 2048 = 1{,}024 \cdot 10^8$.
3. Tiempo: $1{,}024 \cdot 10^8 / 10^{12} = 1{,}024 \cdot 10^{-4}$ s $\approx 0{,}1$ ms.

Resultado. $\approx 1{,}02 \cdot 10^8$ **operaciones por token, unos** $0{,}102$ **ms.**

Comprobación. regla de dos operaciones por peso: la matriz tiene $5{,}12 \cdot 10^7$ pesos y $2 \cdot 5{,}12 \cdot 10^7 = 1{,}024 \cdot 10^8$.

Criterio de corrección. se acepta cualquier valor entre $5 \cdot 10^7$ y $1{,}1 \cdot 10^8$ con razonamiento correcto (contar solo productos da la mitad).

Repasar: M02, §1.2, §1.3 y §2.3 (a); M02, §5.4 (b); M02, §3.3 y M03, §1.3 (c); M02, §4.4 (d).

Solución del ejercicio B.3

Apartado (a)

Datos. $A = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$.

Planteamiento. polinomio característico $\det(A - \lambda I) = 0$ y resolución de $(A - \lambda I)v = 0$ (M03, §3.1).

Desarrollo.

1. $\det(A - \lambda I) = (3 - \lambda)^2 - 1 = \lambda^2 - 6\lambda + 8 = (\lambda - 4)(\lambda - 2)$.
2. $\lambda_1 = 4$: $A - 4I = \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix}$ da $v_1 = v_2$; vector unitario $q_1 = (1, 1)/\sqrt{2}$.
3. $\lambda_2 = 2$: $A - 2I = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ da $v_1 = -v_2$; vector unitario $q_2 = (1, -1)/\sqrt{2}$.

4. $q_1 \cdot q_2 = (1-1)/2 = 0$.

Resultado. $\lambda = 4$ **con** $(1,1)/\sqrt{2}$ **y** $\lambda = 2$ **con** $(1,-1)/\sqrt{2}$**. Son ortogonales porque** A **es simétrica: por el teorema espectral (M03, §3.3), los autovectores de autovalores distintos de una matriz simétrica son ortogonales.**

Comprobación. $\operatorname{tr} A = 6 = 4 + 2$ y $\det A = 8 = 4 \cdot 2$.

Criterio de corrección. 1 punto el polinomio y los autovalores; 1 punto los autovectores unitarios; 1 punto la justificación.

Apartado (b)

Datos. $\det A = 8$.

Planteamiento. para una matriz 2×2, $A^{-1} = \frac{1}{\det A}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$ (M03, §2.1).

Desarrollo.

1. $A^{-1} = \frac{1}{8}\begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix} = \begin{pmatrix} 0{,}375 & -0{,}125 \\ -0{,}125 & 0{,}375 \end{pmatrix}$.
2. $AA^{-1} = \frac{1}{8}\begin{pmatrix} 9-1 & -3+3 \\ 3-3 & -1+9 \end{pmatrix} = I$.
3. Si $Av = \lambda v$ con $\lambda \neq 0$, entonces $A^{-1}v = \lambda^{-1}v$: A^{-1} tiene los mismos autovectores y autovalores $1/4$ y $1/2$.

Resultado. $A^{-1} = \frac{1}{8}\begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix}$**, con autovalores** $1/4$ **y** $1/2$**, inversos de los de** A**.**

Comprobación. $A^{-1}(1,1)^\top = \frac{1}{8}(2,2)^\top = \frac{1}{4}(1,1)^\top$ y $A^{-1}(1,-1)^\top = \frac{1}{8}(4,-4)^\top = \frac{1}{2}(1,-1)^\top$.

Apartado (c)

Datos. $B = \begin{pmatrix} 0 & -2 \\ 3 & 0 \end{pmatrix}$.

Planteamiento. los v_i y σ_i^2 son los autovectores y autovalores de $B^\top B$; las columnas de U se obtienen como $u_i = Bv_i/\sigma_i$ (M03, §4.2). Por Eckart–Young, $B_1 = \sigma_1 u_1 v_1^\top$ y $\|B - B_1\|_F = \sigma_2$ (M03, §5.1).

Desarrollo.

1. $B^\top B = \begin{pmatrix} 0 & 3 \\ -2 & 0 \end{pmatrix}\begin{pmatrix} 0 & -2 \\ 3 & 0 \end{pmatrix} = \begin{pmatrix} 9 & 0 \\ 0 & 4 \end{pmatrix}$.
2. Es diagonal: $\sigma_1 = \sqrt{9} = 3$ con $v_1 = (1,0)$, y $\sigma_2 = \sqrt{4} = 2$ con $v_2 = (0,1)$; $V = I$ y $\Sigma = \operatorname{diag}(3,2)$.
3. $u_1 = Bv_1/3 = (0,3)/3 = (0,1)$ y $u_2 = Bv_2/2 = (-2,0)/2 = (-1,0)$; $U = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$, que es ortogonal.
4. $B_1 = 3\,u_1 v_1^\top = 3\begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 3 & 0 \end{pmatrix}$.
5. $B - B_1 = \begin{pmatrix} 0 & -2 \\ 0 & 0 \end{pmatrix}$ y $\|B - B_1\|_F = 2 = \sigma_2$.
6. Energía retenida: $9/(9+4) = 9/13 \approx 0{,}6923$.

7. B no es simétrica: su polinomio característico es $\lambda^2 + 6$, con raíces complejas $\pm i\sqrt{6}$. Sus autovalores no son reales ni sus autovectores ortogonales, de modo que no pueden servir de valores y vectores singulares. Solo para matrices simétricas semidefinidas positivas, como A, coinciden la SVD y la descomposición espectral.

Resultado. $B = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$**;** $B_1 = \begin{pmatrix} 0 & 0 \\ 3 & 0 \end{pmatrix}$**; error** 2**; energía retenida** $9/13 \approx 69{,}2\,\%$**.**

Comprobación. $U\Sigma V^\top = \begin{pmatrix} 0 \cdot 3 & -1 \cdot 2 \\ 1 \cdot 3 & 0 \cdot 2 \end{pmatrix} = B$, y $\|B\|_F^2 = 4 + 9 = 13 = \sigma_1^2 + \sigma_2^2$.

Criterio de corrección. 1 punto V y Σ; 1 punto U y la reconstrucción; 1 punto B_1, el error, la energía y la explicación.

Apartado (d)

Datos. $m \times n = 2048 \times 1024$; $k = 64$; LoRA con $r = 8$ sobre $d \times d = 4096 \times 4096$.

Planteamiento. almacenar el truncamiento de rango k cuesta $k(m + n + 1)$ números (M03, §5.2); LoRA entrena $B \in \mathbb{R}^{d_{\text{out}} \times r}$ y $A \in \mathbb{R}^{r \times d_{\text{in}}}$, es decir, $r(d_{\text{in}} + d_{\text{out}})$ parámetros (M03, §5.3).

Desarrollo.

1. Original: $2048 \cdot 1024 = 2\,097\,152$ números.
2. Rango 64: $64 \cdot (2048 + 1024 + 1) = 64 \cdot 3073 = 196\,672$ números.
3. Fracción: $196\,672/2\,097\,152 = 0{,}09378$, un $9{,}38\,\%$.
4. Compensa mientras $3073\,k < 2\,097\,152$, es decir, $k < 682{,}4$: con $k = 682$ se almacenan $2\,095\,786$ números y aún se ahorra; con $k = 683$, $2\,098\,859$, que ya supera el original.
5. LoRA: $8 \cdot (4096 + 4096) = 65\,536$ parámetros, frente a $4096^2 = 16\,777\,216$.
6. Porcentaje: $65\,536/16\,777\,216 = 0{,}003906$, un $0{,}391\,\%$.

Resultado. $196\,672$ **números (**$9{,}38\,\%$**); compensa hasta** $k = 682$**; LoRA de rango 8 entrena** $65\,536$ **parámetros, el** $0{,}391\,\%$ **de la matriz.**

Comprobación. $65\,536/16\,777\,216 = 2^{16}/2^{24} = 2^{-8} = 1/256 \approx 0{,}39\,\%$.

Criterio de corrección. 1 punto por cada cifra: almacenamiento, umbral, parámetros de LoRA y porcentaje.

Repasar: M03, §3.1 y §3.3 (a); M03, §2.1 y §3.2 (b); M03, §4.1, §4.2 y §5.1 (c); M03, §5.2 y §5.3 (d).

Solución del ejercicio B.4

Apartado (a)

Datos. $L = -\ln p_c$, $p = \text{softmax}(z)$, $S = \sum_j e^{z_j}$, y one-hot de c.

Planteamiento. reescribir la pérdida con la definición de la softmax y derivar término a término (M04, §3.4).

Desarrollo.

1. $H(y, p) = -\sum_k y_k \ln p_k = -\ln p_c$, porque $y_k = 0$ para $k \neq c$ e $y_c = 1$. Luego $L = H(y, p)$.
2. $\ln p_c = \ln(e^{z_c}/S) = z_c - \ln S$, de donde $L = -z_c + \ln S$.

3. $\partial(-z_c)/\partial z_k = -\mathbb{I}[k=c] = -y_k$.
4. Regla de la cadena: $\partial(\ln S)/\partial z_k = \frac{1}{S}\,\partial S/\partial z_k = e^{z_k}/S = p_k$, pues solo el sumando $j=k$ de S depende de z_k.
5. Sumando: $\partial L/\partial z_k = p_k - y_k$. ■

Resultado. $L = H(y,p) = -z_c + \ln\sum_j e^{z_j}$ **y** $\nabla_z L = p - y$**.**

Comprobación. $\sum_k (p_k - y_k) = 1 - 1 = 0$, coherente con la invariancia de la softmax por traslación: sumar una constante a todos los logits no cambia L.

Criterio de corrección. 1 punto la equivalencia con la entropía cruzada; 1 punto la expresión con log-suma-exp; 2 puntos la derivación.

Apartado (b)

Datos. W, $x = (1,2)$, $c = 1$.

Planteamiento. $z = Wx$, $p = \mathrm{softmax}(z)$, $L = -\ln p_1$.

Desarrollo.

1. $z = (1\cdot 1 + 0\cdot 2,\ 0\cdot 1 + 1\cdot 2,\ 1\cdot 1 - 1\cdot 2) = (1, 2, -1)$.
2. $e^z = (2{,}7183;\ 7{,}3891;\ 0{,}36788)$ y $S = 10{,}475$.
3. $p = (0{,}25950;\ 0{,}70538;\ 0{,}035119)$.
4. $L = -\ln 0{,}25950 = 1{,}3490$ nats.

Resultado. $z = (1, 2, -1)$**;** $p \approx (0{,}260;\ 0{,}705;\ 0{,}0351)$**;** $L \approx 1{,}35$ **nats.**

Comprobación. p suma 1,0000, y $L = -z_1 + \ln S = -1 + 2{,}3490 = 1{,}3490$.

Apartado (c)

Datos. p del apartado (b), $y = (1,0,0)$, $x = (1,2)$.

Planteamiento. $\delta = \nabla_z L = p - y$; para la capa lineal $z = Wx$, $\partial L/\partial W = \delta x^\top$ y $\partial L/\partial x = W^\top \delta$ (M04, §3.2).

Desarrollo.

1. $\delta = (-0{,}74050;\ 0{,}70538;\ 0{,}035119)$, de forma 3×1.
2. $\partial L/\partial W = \delta x^\top$, de forma $(3\times 1)(1\times 2) = 3\times 2$, como W:

$$\frac{\partial L}{\partial W} = \begin{pmatrix} -0{,}7405 & -1{,}4810 \\ 0{,}7054 & 1{,}4108 \\ 0{,}0351 & 0{,}0702 \end{pmatrix}.$$

3. $\partial L/\partial x = W^\top \delta$, de forma $(2\times 3)(3\times 1) = 2\times 1$:

$$W^\top \delta = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} -0{,}7405 \\ 0{,}7054 \\ 0{,}0351 \end{pmatrix} = \begin{pmatrix} -0{,}7054 \\ 0{,}6703 \end{pmatrix}.$$

Resultado. $\nabla_z L \approx (-0{,}741;\ 0{,}705;\ 0{,}0351)$**;** $\partial L/\partial W$ **como arriba** (3×2)**;** $\partial L/\partial x \approx (-0{,}705;\ 0{,}670)$ (2×1)**.**

Comprobación. las componentes de δ suman 0, y también cada columna de $\partial L/\partial W$.

Criterio de corrección. 1 punto δ; 2 puntos $\partial L/\partial W$ con su forma; 1 punto $\partial L/\partial x$.

Apartado (d)

Datos. $\eta = 0{,}5$; W y $\partial L/\partial W$ del apartado (c).

Planteamiento. $W' = W - \eta\,\partial L/\partial W$ y nueva evaluación de $z' = W'x$, p' y L' (M04, §1.5).

Desarrollo.

1. $W' = \begin{pmatrix} 1+0{,}37025 & 0+0{,}74050 \\ 0-0{,}35269 & 1-0{,}70538 \\ 1-0{,}01756 & -1-0{,}03512 \end{pmatrix} = \begin{pmatrix} 1{,}3703 & 0{,}7405 \\ -0{,}3527 & 0{,}2946 \\ 0{,}9824 & -1{,}0351 \end{pmatrix}$.
2. $z'_1 = 1{,}3703 + 2\cdot 0{,}7405 = 2{,}8513$; $z'_2 = -0{,}3527 + 2\cdot 0{,}2946 = 0{,}2365$; $z'_3 = 0{,}9824 - 2\cdot 1{,}0351 = -1{,}0878$.
3. $e^{z'} = (17{,}310;\ 1{,}2669;\ 0{,}33696)$, con suma 18,913.
4. $p'_1 = 17{,}310/18{,}913 = 0{,}91520$ y $L' = -\ln 0{,}91520 = 0{,}08861$ nats.

Resultado. $W' \approx \begin{pmatrix} 1{,}37 & 0{,}741 \\ -0{,}353 & 0{,}295 \\ 0{,}982 & -1{,}04 \end{pmatrix}$**;** $p'_1 \approx 0{,}915$**; la pérdida baja de** 1,35 **a** 0,0886 **nats.**

Comprobación. la aproximación de primer orden predice un descenso $\eta\|\partial L/\partial W\|_F^2 = 0{,}5\cdot 5{,}236 = 2{,}62$, mayor que el real, 1,260: el paso es grande y la curvatura frena el descenso (M04, §4.4), pero la dirección es de descenso.

Apartado (e)

Datos. $h = 0{,}01$ sobre W_{11}; valor analítico $a = p_1 - 1 = -0{,}7405035$.

Planteamiento. $n = [L(W_{11}+h) - L(W_{11}-h)]/(2h)$ y error relativo $r(a,n)$ (M04, §6.1 y §6.3). Hacen falta 7 cifras porque se restan números muy próximos.

Desarrollo.

1. $W_{11} = 1{,}01$: $z = (1{,}01;\ 2;\ -1)$ y $L_+ = 1{,}3416168$.
2. $W_{11} = 0{,}99$: $z = (0{,}99;\ 2;\ -1)$ y $L_- = 1{,}3564268$.
3. $n = (1{,}3416168 - 1{,}3564268)/0{,}02 = -0{,}7405020$.
4. $r = |a-n|/\max(|a|,|n|) = 1{,}54\cdot 10^{-6}/0{,}7405 = 2{,}08\cdot 10^{-6}$.

Resultado. $n \approx -0{,}740502$ **frente a** $a \approx -0{,}740504$**;** $r \approx 2{,}1\cdot 10^{-6}$**: el gradiente analítico es correcto.**

Comprobación. la diferencia es el error de truncamiento previsto, $\frac{h^2}{6}L'''$, con $L''' = p_1(1-p_1)(1-2p_1) = 0{,}09243$ respecto de W_{11}: $10^{-4}\cdot 0{,}09243/6 = 1{,}54\cdot 10^{-6}$, que coincide con $n-a$. Con $h = 0{,}01$ el truncamiento domina sobre el redondeo, por lo que no cabe esperar $r \le 10^{-7}$.

Repasar: M04, §3.3 y §3.4 (a); M04, §3.2 (b y c); M04, §1.5 y §4.4 (d); M04, §6.1 y §6.3 (e).

Solución del ejercicio B.5

Apartado (a)

Datos. $P(L=k) = (1-q)^{k-1}q$; observaciones $3, 4, 5, 5, 6, 7$, con $n = 6$ y $\sum_i k_i = 30$.

Planteamiento. log-verosimilitud, condición de primer orden y comprobación del signo de la segunda derivada (M05, §4.2).

Desarrollo.

1. $\ell(q) = \sum_i \big[(k_i - 1)\ln(1-q) + \ln q\big] = \big(\sum_i k_i - n\big)\ln(1-q) + n\ln q$.
2. $\ell'(q) = \dfrac{n}{q} - \dfrac{\sum_i k_i - n}{1-q} = 0 \iff n(1-q) = q\big(\sum_i k_i - n\big) \iff \hat{q} = \dfrac{n}{\sum_i k_i}$.
3. $\ell''(q) = -\dfrac{n}{q^2} - \dfrac{\sum_i k_i - n}{(1-q)^2} < 0$ en $(0,1)$: ℓ es estrictamente cóncava y $\hat{q}$ es su máximo global.
4. $\hat{q} = 6/30 = 0{,}2$.
5. $P(L=3) = 0{,}8^2 \cdot 0{,}2 = 0{,}128$ y $\mathbb{E}[L] = 1/0{,}2 = 5$ letras.

Resultado. $\hat{q} = n/\sum_i k_i = 0{,}2$**;** $P(L=3) = 0{,}128$**;** $\mathbb{E}[L] = 5$ **letras.**

Comprobación. la media muestral es $30/6 = 5 = 1/\hat{q}$: el EMV iguala la media teórica a la muestral.

Criterio de corrección. 2 puntos la derivación (con la comprobación del máximo); 1 punto $\hat{q}$; 1 punto los dos valores.

Apartado (b)

Datos. tres dados de 4 caras, uno de 6 y uno de 12; resultado observado: 5.

Planteamiento. tabla de Bayes: a posteriori $\propto$ a priori $\times$ verosimilitud; la constante de normalización es la probabilidad predictiva a priori (M05, §1.3).

Desarrollo.

1. Tabla:

Dado	A priori	$P(5 \mid \text{dado})$	Producto	A posteriori
4 caras	3/5	0	0	0
6 caras	1/5	1/6	1/30	2/3
12 caras	1/5	1/12	1/60	1/3
Total	1		1/20	1

2. Probabilidad predictiva a priori: $P(5) = \frac{1}{30} + \frac{1}{60} = \frac{1}{20} = 0{,}05$.
3. Dado el tipo de dado, los dos lanzamientos son independientes; por probabilidad total con las probabilidades a posteriori, $P(6 \text{ en el segundo} \mid 5) = \frac{2}{3}\cdot\frac{1}{6} + \frac{1}{3}\cdot\frac{1}{12} = \frac{4}{36} + \frac{1}{36} = \frac{5}{36} \approx 0{,}139$.

Resultado. **a posteriori** $(0,\ 2/3,\ 1/3)$**;** $P(5) = 1/20$**;** $P(6$ **en el segundo lanzamiento** $\mid 5) = 5/36 \approx 0{,}139$**.**

Comprobación. las probabilidades a posteriori suman $2/3 + 1/3 = 1$. Antes de observar nada, $P(6) = \frac{3}{5}\cdot 0 + \frac{1}{5}\cdot\frac{1}{6} + \frac{1}{5}\cdot\frac{1}{12} = \frac{1}{20} = 0{,}05$; tras el 5 sube a $5/36 \approx 0{,}139$, porque la observación descarta los dados de 4 caras, que no pueden dar un 6.

Criterio de corrección. 1,5 puntos la tabla; 0,5 puntos la predictiva a priori; 1 punto la predictiva a posteriori.

Apartado (c)

Datos. $\hat{p} = 0{,}78$; $n = 600$; $z_{0{,}975} = 1{,}96$; semianchura objetivo 0,01.

Planteamiento. error típico $\sqrt{\hat{p}(1-\hat{p})/n}$; intervalo $\hat{p} \pm 1{,}96 \cdot \text{ET}$ por el teorema central del límite; para el tamaño, despejar n de $1{,}96\sqrt{\hat{p}(1-\hat{p})/n} = 0{,}01$ (M05, §5.5).

Desarrollo.

1. $\hat{p}(1-\hat{p}) = 0{,}78 \cdot 0{,}22 = 0{,}1716$.
2. ET $= \sqrt{0{,}1716/600} = \sqrt{2{,}86 \cdot 10^{-4}} = 0{,}01691$.
3. Semianchura: $1{,}96 \cdot 0{,}01691 = 0{,}03315$; intervalo $[0{,}7469;\ 0{,}8131]$.
4. $n = (1{,}96/0{,}01)^2 \cdot 0{,}1716 = 38\,416 \cdot 0{,}1716 = 6592{,}2$, que se redondea hacia arriba: 6593.

Resultado. ET $\approx 0{,}0169$**; intervalo del** $95\,\%$ $\approx [74{,}7\,\%;\ 81{,}3\,\%]$**; harían falta** 6593 **preguntas.**

Comprobación. reducir la semianchura de 3,315 a 1 punto exige multiplicar n por $3{,}315^2 \approx 10{,}99$, y $600 \cdot 10{,}99 \approx 6592$.

Criterio de corrección. 1 punto el error típico; 1 punto el intervalo; 2 puntos el tamaño (se aceptan 6592 y 6593).

Repasar: M05, §2.2 y §4.2 (a); M05, §1.3 (b); M05, §5.4 y §5.5 (c).

Solución del ejercicio B.6

Apartado (a)

Datos. $p = (1/4, 1/4, 1/4, 1/8, 1/8)$ para `a`, `b`, `c`, `d`, `e`; mensaje «`abed`».

Planteamiento. $H(p) = -\sum_i p_i \log_2 p_i$ (M06, §1.2); algoritmo de Huffman, que fusiona en cada paso los dos nodos de menor probabilidad (M06, §3.4); desigualdad de Kraft $\sum_i 2^{-\ell_i} \leq 1$ (M06, §3.2).

Desarrollo.

1. $H(p) = 3 \cdot \frac{1}{4} \cdot 2 + 2 \cdot \frac{1}{8} \cdot 3 = 1{,}5 + 0{,}75 = 2{,}25$ bits.
2. Huffman: se fusionan `d` y `e` (1/4); quedan cuatro nodos de 1/4, que se fusionan por pares, $\{$`a`, `b`$\}$ y $\{$`c`, `de`$\}$ (1/2 cada uno), y estos en la raíz.
3. Código: `a` = `00`, `b` = `01`, `c` = `10`, `d` = `110`, `e` = `111`. Cualquier otra elección en los empates da las mismas longitudes $(2, 2, 2, 3, 3)$.
4. Longitud media: $3 \cdot \frac{1}{4} \cdot 2 + 2 \cdot \frac{1}{8} \cdot 3 = 2{,}25$ bits $= H(p)$.
5. Kraft: $3 \cdot 2^{-2} + 2 \cdot 2^{-3} = 0{,}75 + 0{,}25 = 1$.
6. «`abed`» = `00` | `01` | `111` | `110` = `0001111110`: $2 + 2 + 3 + 3 = 10$ bits.

Resultado. $H(p) = 2{,}25$ **bits; código** $\{$`00`, `01`, `10`, `110`, `111`$\}$ **con longitud media** 2,25 **bits** $= H(p)$ **y suma de Kraft 1;** «`abed`» = `0001111110`**, 10 bits.**

Comprobación. la longitud media alcanza la entropía porque todas las probabilidades son potencias de 1/2 y $\ell_i = -\log_2 p_i$ (M06, §3.3); además, $-\log_2 P(\text{«abed»}) = 2+2+3+3 = 10$ bits.

Criterio de corrección. 1 punto $H(p)$; 1 punto el código y la comprobación de Kraft; 1 punto el mensaje.

Apartado (b)

Datos. p como en (a); $q = (1/5, \ldots, 1/5)$; $q' = (1/8, 1/8, 1/4, 1/4, 1/4)$.

Planteamiento. $H(p, q) = -\sum_i p_i \log_2 q_i$ y $D(p \,\|\, q) = H(p, q) - H(p)$ (M06, §2.2 y §2.3).

Desarrollo.

1. $H(p, q) = \log_2 5 = 2{,}3219$ bits y $D(p \,\|\, q) = 2{,}3219 - 2{,}25 = 0{,}0719$ bits.

2. $H(p, q') = \frac{1}{4} \cdot 3 + \frac{1}{4} \cdot 3 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 2 + \frac{1}{8} \cdot 2 = 2{,}5$ bits y $D(p \,\|\, q') = 2{,}5 - 2{,}25 = 0{,}25$ bits.

Resultado. $H(p, q) \approx 2{,}32$ **bits y** $D(p \,\|\, q) \approx 0{,}0719$ **bits;** $H(p, q') = 2{,}5$ **bits y** $D(p \,\|\, q') = 0{,}25$ **bits. Es mejor el modelo uniforme:** q' **concentra la probabilidad en símbolos equivocados, y un modelo seguro y equivocado puede ser peor que uno que no sabe nada.**

Comprobación. cálculo directo: $D(p \,\|\, q') = \frac{1}{4}\log_2 2 + \frac{1}{4}\log_2 2 + \frac{1}{4}\log_2 1 + \frac{1}{8}\log_2 \frac{1}{2} + \frac{1}{8}\log_2 \frac{1}{2} = 0{,}25 + 0{,}25 + 0 - 0{,}125 - 0{,}125 = 0{,}25$.

Criterio de corrección. 0,75 puntos por cada valor.

Apartado (c)

Datos. $\mathcal{J} = 1{,}8$ nats por token; $\bar{b} = 4{,}2$ bytes por token; 10^9 bytes.

Planteamiento. PPL $= e^{\mathcal{J}}$; bits por token $= \mathcal{J}/\ln 2$; bpb $= \mathcal{J}/(\bar{b} \ln 2)$; tamaño comprimido $= B \cdot \text{bpb}\,/8$ bytes (M06, §4.3 y §4.4).

Desarrollo.

1. PPL $= e^{1{,}8} = 6{,}050$.
2. Bits por token: $1{,}8/0{,}69315 = 2{,}5969$.
3. Bits por byte: $2{,}5969/4{,}2 = 0{,}61830$.
4. Tamaño comprimido: $10^9 \cdot 0{,}61830/8 = 7{,}729 \cdot 10^7$ bytes $\approx 77{,}3$ MB.
5. Razón de compresión: $8/0{,}61830 = 12{,}94$.
6. La codificación aritmética emplea menos de $-\log_2 q(x_{1:N}) + 2$ bits para todo el texto (M06, §4.2): el exceso es despreciable.

Resultado. PPL $\approx 6{,}05$**;** $2{,}60$ **bits por token;** $0{,}618$ **bits por byte; 1 GB se comprime a unos** $77{,}3$ **MB, con una razón de compresión** $\approx 12{,}9$**.**

Comprobación. $10^9/12{,}94 = 7{,}73 \cdot 10^7$ bytes, como en el paso 4.

Criterio de corrección. 1 punto por cada cifra; se aceptan redondeos razonables.

Repasar: M06, §1.2, §3.2, §3.3 y §3.4 (a); M06, §2.2 y §2.3 (b); M06, §4.2, §4.3 y §4.4, y M01, §5.1 (c).

Apéndice B

Autoevaluación

B.1 Cálculo de la nota

La nota del examen es la suma de los puntos de la parte A (máximo 30) y de la parte B (máximo 70). El examen se aprueba con **70 puntos o más**. Si se obtienen menos de 15 puntos en la parte A o menos de 40 en la parte B, conviene repasar esa parte aunque el examen esté aprobado: la Fase II (módulos 7 a 11) da por sabido todo este material.

Parte	Elemento	Puntos	Obtenidos
A	Cuestiones 1–20 (1,5 cada una)	30	
B	B.1 Modelo de bigramas	12	
B	B.2 Embeddings y analogías	10	
B	B.3 Autovalores, SVD y bajo rango	12	
B	B.4 Gradiente de la softmax con entropía cruzada	14	
B	B.5 Estimación y regla de Bayes	11	
B	B.6 Entropía, compresión y bits por byte	11	
	Total	**100**	

B.2 Puntuación por módulo

La tabla siguiente agrupa los puntos por módulo. Un módulo en el que se obtenga menos del 70 % de sus puntos debe repasarse aunque el examen esté aprobado.

Módulo	Cuestiones	Puntos A	Problema	Puntos B	Total
M01	1–4	6	B.1	12	18
M02	5–6	3	B.2	10	13
M03	7–11	7,5	B.3	12	19,5
M04	12–14	4,5	B.4	14	18,5
M05	15–17	4,5	B.5	11	15,5
M06	18–20	4,5	B.6	11	15,5
Total	20	**30**	6	**70**	**100**

B.3 Puerta de salida de la Fase I

Para pasar a la Fase II deben cumplirse las tres condiciones siguientes:

1. un resultado de al menos 9 sobre 12 en el test de cada módulo, M01 a M06;

2. una autoevaluación del laboratorio interactivo de la fase de al menos el 70 %;
3. una nota de este examen de hito de al menos el 70 % (70 puntos sobre 100).

El proyecto de fase se califica con la rúbrica del capítulo correspondiente y cuenta en la nota de la fase.

B.4 Qué repasar según los fallos

Fallo	Secciones de los apuntes
Cuestiones 1 y 2	M01, §2.2 (regla de la cadena) y §2.3 (n-gramas)
Cuestiones 3 y 4	M01, §5.1 (perplejidad) y §4.1 (softmax con temperatura)
B.1 (a), (b) y (e)	M01, §2.3, §3.2 y §4.3
B.1 (c) y (d)	M01, §5.1, §5.3 y §3.3 (suavizado aditivo)
Cuestión 5 y B.2 (a)	M02, §1.2, §1.3 y §2.3
Cuestión 6 y B.2 (b)	M02, §5.1 (matriz de embeddings) y §5.4 (analogías)
B.2 (c) y (d)	M02, §3.3 y §4.4; M03, §1.3 (núcleo)
Cuestiones 7 y 11	M03, §6.2 (producto por lotes) y §6.3 (*broadcasting*)
Cuestión 8 y B.3 (a) y (b)	M03, §1.3, §2.1, §3.1, §3.2 y §3.3
Cuestión 9 y B.3 (c) y (d)	M03, §4.1, §4.2, §5.1, §5.2 y §5.3
Cuestión 10	M03, §5.4 (PCA)
Cuestión 12	M04, §1.1 y §1.2
Cuestión 13 y B.4 (a)–(c)	M04, §3.2, §3.3 y §3.4
B.4 (d)	M04, §1.5 y §4.4
Cuestión 14 y B.4 (e)	M04, §6.1 y §6.3
Cuestión 15	M05, §2.3
Cuestión 16 y B.5 (a)	M05, §4.2; M01, §3.2
B.5 (b)	M05, §1.3
Cuestión 17 y B.5 (c)	M05, §5.4, §5.5 y §5.6
Cuestión 18 y B.6 (a)	M06, §1.2, §3.2, §3.3 y §3.4
Cuestiones 19 y 20 y B.6 (b)	M06, §2.2 y §2.3
B.6 (c)	M06, §4.2, §4.3 y §4.4; M01, §5.1

B.5 Qué hacer si no se alcanza el umbral

1. Anotar cada fallo en el registro de errores, clasificado como error de *concepto*, de *cálculo* o *despiste*.
2. Para cada módulo por debajo del 70 %, repetir el ciclo de estudio del método del curso con las secciones indicadas en la tabla anterior: teoría, laboratorio, práctica, ejercicios ⋆⋆⋆ del tema, test y tarjetas de repaso.
3. Rehacer los problemas fallados sin mirar la solución y, a continuación, los ejercicios del mismo tema en los apuntes del módulo.

4. Repetir el examen pasada al menos una semana, preferiblemente con datos cambiados, y no avanzar a la Fase II hasta superar las tres condiciones de la puerta de salida.

Bibliografía

[1] R. Harle. Information Theory. University of Cambridge, Department of Computer Science and Technology, Part II, curso 2025–26. *Examples Sheet*, supervisión 1, ejercicio 12 (códigos de Huffman): https://www.cl.cam.ac.uk/teaching/2526/InfoTheory/InfoTheoryExamplesSheet.pdf

[2] T. M. Cover y J. A. Thomas. *Elements of Information Theory*, 2.ª ed. Wiley, 2006. Cap. 5, «Data Compression».

[3] Stanford University. CS224N: Natural Language Processing with Deep Learning. Tarea 2, sección 1, «Understanding word2vec», preguntas 1(a), 1(b) y 1(d)–(e). Consultada en octubre de 2026. https://web.stanford.edu/class/cs224n/assignments/a2.pdf

[4] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang y W. Chen. LoRA: Low-rank adaptation of large language models. En *International Conference on Learning Representations (ICLR)*, 2022. https://arxiv.org/abs/2106.09685

[5] D. Jurafsky y J. H. Martin. *Speech and Language Processing*, 3.ª ed., borrador del 19 de agosto de 2026. Cap. 3, «N-gram Language Models». https://web.stanford.edu/~jurafsky/slp3/

[6] T. Mikolov, W.-t. Yih y G. Zweig. Linguistic regularities in continuous space word representations. En *Proceedings of NAACL-HLT*, págs. 746–751, 2013. https://aclanthology.org/N13-1090/

[7] J. Orloff y J. Bloom. 18.05: Introduction to Probability and Statistics. Massachusetts Institute of Technology, MIT OpenCourseWare, primavera de 2014. Examen 2, problema 3. https://ocw.mit.edu/courses/18-05-introduction-to-probability-and-statistics-spring-2014/pages/exams/

[8] G. Strang. 18.06: Linear Algebra. Massachusetts Institute of Technology, MIT OpenCourseWare, primavera de 2010. Examen 3, problema 3. https://ocw.mit.edu/courses/18-06-linear-algebra-spring-2010/pages/exams/