Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase II · Aprendizaje automático y redes neuronales

Módulo 7

Optimización

Apuntes del curso

Edición de octubre de 2026

Presentación del módulo

Entrenar un modelo de lenguaje es resolver un problema de optimización: hallar parámetros $\theta \in \mathbb{R}^n$, con n del orden de 10^9 a 10^{12}, que hagan pequeña la entropía cruzada media sobre un corpus de billones de tokens. El módulo 4 proporcionó el gradiente; este módulo estudia cómo usarlo para dar pasos. Se analiza primero el descenso de gradiente en el caso en que todo puede calcularse, las funciones cuadráticas y fuertemente convexas, y se identifica el número de condición como la magnitud que gobierna la velocidad de convergencia. Después se introducen las tres ideas que separan ese algoritmo de los que se usan en la práctica: el gradiente estocástico de minibatch, el momentum y la normalización adaptativa por coordenadas. El módulo termina con los ingredientes de la receta estándar de preentrenamiento: AdamW, el calendario de calentamiento lineal seguido de decaimiento coseno y el decaimiento de pesos.

Objetivos

Al finalizar el módulo, el estudiante debe ser capaz de:

1. definir convexidad, convexidad fuerte y suavidad de Lipschitz, y usar las condiciones de optimalidad de primer y segundo orden para clasificar puntos críticos;
2. demostrar la convergencia lineal del descenso de gradiente en funciones fuertemente convexas y suaves, y obtener el paso óptimo y el factor $(\kappa - 1)/(\kappa + 1)$ en cuadráticas;
3. demostrar que el gradiente de minibatch es un estimador insesgado, calcular su varianza con y sin reemplazamiento, y explicar por qué el ruido obliga a reducir la tasa de aprendizaje;
4. formular el método de momentum como discretización de un sistema mecánico con rozamiento y demostrar que acelera la convergencia en cuadráticas hasta el factor $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$;
5. escribir y aplicar a mano AdaGrad, RMSProp y Adam, y demostrar las propiedades de la corrección de sesgo de Adam;
6. distinguir la regularización L^2 del decaimiento de pesos desacoplado de AdamW y calcular calendarios de calentamiento y decaimiento coseno como los del preentrenamiento de modelos de lenguaje.

Requisitos previos

Del módulo 1, la entropía cruzada como pérdida de entrenamiento (tema 5). Del módulo 3, los autovalores de una matriz simétrica y el teorema espectral, que se usan en los temas 1, 2 y 4. Del módulo 4, el gradiente, el hessiano, el desarrollo de Taylor y la caracterización de la convexidad (temas 4 y 5). Del módulo 5, la esperanza, la varianza y la independencia de variables aleatorias, que se usan en los temas 3 y 5.

Organización

Tema	Contenido	Fuentes principales
1	Problemas de optimización y convexidad	[2], [9], [24]
2	Descenso de gradiente	[2], [24], [22]
3	Descenso de gradiente estocástico	[24], [9], [1]
4	Momentum	[18], [24], [8]
5	Métodos adaptativos: AdaGrad, RMSProp y Adam	[13], [24], [9]
6	Regularización y calendarios de la tasa de aprendizaje	[16], [15], [24]

Cada tema termina con una lista de lecturas y con ejercicios graduados en tres niveles: $\star$ comprensión, $\star\star$ cálculo y $\star\star\star$ demostración. Los ejercicios marcados con *Fuente* están adaptados de cursos y libros de texto universitarios; el enunciado se ha redactado de nuevo y, en algunos casos, se han cambiado los datos para que puedan resolverse a mano. Las soluciones completas, paso a paso, están en el apéndice A.

Sobre las fuentes

El texto es de redacción propia. La convexidad y el análisis del descenso de gradiente siguen los capítulos 3 y 9 de Boyd y Vandenberghe [2], texto del curso EE364a de Stanford [3], y las clases 22, 23 y 25 del curso 18.065 del MIT [22]. La parte de aprendizaje profundo sigue el capítulo 8 de Goodfellow, Bengio y Courville [9] y el capítulo 12 de Zhang *et al.* [24], que es también la fuente de la mayoría de los ejercicios adaptados; el análisis del gradiente estocástico se apoya en la revisión de Bottou, Curtis y Nocedal [1]. Cada método se presenta además según su artículo original: Polyak [18] para el momentum, Duchi, Hazan y Singer [7] para AdaGrad, Kingma y Ba [13] para Adam, y Loshchilov y Hutter [16, 15] para AdamW y el decaimiento coseno. Los hiperparámetros de modelos concretos se toman de sus artículos publicados; Anthropic, Google y xAI no han hecho públicos los optimizadores de Claude, Gemini y Grok.

Notación

Símbolo	Significado
$\theta \in \mathbb{R}^n$, θ_k	vector de parámetros e iterado k-ésimo
f, $f^* = \inf f$, θ^*	función objetivo, valor óptimo y minimizador
$J(\theta) = \frac{1}{N}\sum_{i=1}^{N} \ell_i(\theta)$	riesgo empírico: pérdida media sobre N ejemplos
∇f, $\nabla^2 f$	gradiente (vector columna) y hessiano
μ, L	constantes de convexidad fuerte y de suavidad
$\lambda_{\min}$, $\lambda_{\max}$, λ_i	autovalores de una matriz simétrica
$\kappa = L/\mu$	número de condición
η, η_k	tasa de aprendizaje (constante o en el paso k)
B, $\hat{g}$	tamaño del minibatch y gradiente estocástico
β; β_1, β_2	coeficiente de momentum; coeficientes de Adam
m_t, v_t; $\hat{m}_t$, $\hat{v}_t$	momentos de Adam y sus versiones corregidas
ε	constante de estabilidad numérica de los métodos adaptativos
λ	coeficiente de regularización o de decaimiento de pesos (tema 6)
$A \succeq 0$, $A \succ 0$	A simétrica semidefinida o definida positiva
$u \odot w$, u^2, $\sqrt{u}$	operaciones elemento a elemento sobre vectores

Índice

Presentación del módulo **ii**

1 Problemas de optimización y convexidad **1**
1.1 Minimización del riesgo empírico . . . 1
1.2 Convexidad, convexidad fuerte y suavidad . . . 1
1.3 Condiciones de optimalidad . . . 3
1.4 Paisajes de pérdida no convexos . . . 4
Ejercicios del tema 1 . . . 5

2 Descenso de gradiente **6**
2.1 El método y el lema de descenso . . . 6
2.2 Convergencia lineal en funciones fuertemente convexas . . . 7
2.3 Análisis exacto en cuadráticas . . . 7
2.4 La función de Rosenbrock y el borde de estabilidad . . . 9
Ejercicios del tema 2 . . . 10

3 Descenso de gradiente estocástico **11**
3.1 El gradiente de minibatch . . . 11
3.2 Convergencia en el caso convexo . . . 12
3.3 El ruido y la tasa de aprendizaje . . . 13
Ejercicios del tema 3 . . . 14

4 Momentum **16**
4.1 Medias móviles exponenciales . . . 16
4.2 El método de la bola pesada . . . 16
4.3 Interpretación física . . . 17
4.4 Convergencia en cuadráticas . . . 18
4.5 Momentum de Nesterov . . . 19
Ejercicios del tema 4 . . . 19

5 Métodos adaptativos: AdaGrad, RMSProp y Adam **21**
5.1 Preacondicionamiento diagonal . . . 21
5.2 AdaGrad y RMSProp . . . 21
5.3 Adam . . . 22
Ejercicios del tema 5 . . . 24

6 Regularización y calendarios de la tasa de aprendizaje **25**
6.1 Regularización L^2 . . . 25
6.2 Decaimiento de pesos desacoplado: AdamW . . . 26
6.3 Calendarios de la tasa de aprendizaje . . . 27
Ejercicios del tema 6 . . . 28

A Soluciones de los ejercicios **30**
A.1 Tema 1 . . . 30
A.2 Tema 2 . . . 32
A.3 Tema 3 . . . 36
A.4 Tema 4 . . . 38
A.5 Tema 5 . . . 41
A.6 Tema 6 . . . 44

Bibliografía **47**

Tema 1

Problemas de optimización y convexidad

Este tema plantea el entrenamiento de un modelo como un problema de minimización sin restricciones y reúne las herramientas de análisis que se usan en el resto del módulo: convexidad, convexidad fuerte, suavidad de Lipschitz y condiciones de optimalidad. Las definiciones y los resultados siguen los capítulos 2, 3 y 9 de [2]; la discusión sobre redes profundas sigue [9, §8.1 y §8.2] y [24, §12.1 y §12.2]. Parte de la materia de convexidad se introdujo en el módulo 4 (tema 5); aquí se completa con las constantes μ y L, que determinan la velocidad de los algoritmos.

1.1 Minimización del riesgo empírico

Definición 1.1 (Problema de optimización sin restricciones). Sea $f\colon \mathbb{R}^n \to \mathbb{R}$. El problema *minimizar* $f(\theta)$, $\theta \in \mathbb{R}^n$, consiste en hallar el *valor óptimo* $f^* = \inf_\theta f(\theta)$ y, si existe, un *minimizador global* θ^* con $f(\theta^*) = f^*$. Un punto $\bar\theta$ es un *minimizador local* si existe $r > 0$ tal que $f(\bar\theta) \le f(\theta)$ para todo θ con $\|\theta - \bar\theta\| < r$.

Definición 1.2 (Riesgo empírico). Sean N ejemplos de entrenamiento y $\ell_i(\theta)$ la pérdida del modelo de parámetros θ sobre el ejemplo i. El *riesgo empírico* es

$$J(\theta) = \frac{1}{N}\sum_{i=1}^{N} \ell_i(\theta).$$

En un modelo de lenguaje, cada ejemplo es una posición de un texto y $\ell_i(\theta) = -\ln p_\theta(x_t \mid x_{1:t-1})$ es la log-verosimilitud negativa del token observado; J es la pérdida $\mathcal{J}$ del módulo 1 (tema 5). El objetivo real no es minimizar J, sino el riesgo esperado sobre la distribución de los datos, al que J solo aproxima; por eso el aprendizaje se diferencia de la optimización pura [9, §8.1]. Este módulo trata, sin embargo, del problema de optimización.

1.2 Convexidad, convexidad fuerte y suavidad

Definición 1.3 (Conjunto y función convexos). Un conjunto $C \subseteq \mathbb{R}^n$ es *convexo* si $tx + (1-t)y \in C$ para todo $x, y \in C$ y $t \in [0,1]$. Una función $f\colon \mathbb{R}^n \to \mathbb{R}$ es *convexa* si

$$f\big(tx + (1-t)y\big) \le t f(x) + (1-t) f(y) \qquad \text{para todo } x, y \in \mathbb{R}^n,\ t \in [0,1],$$

y *estrictamente convexa* si la desigualdad es estricta cuando $x \neq y$ y $t \in (0,1)$ [2, cap. 2 y §3.1].

Teorema 1.4 (Caracterización de primer orden). *Sea f diferenciable. Entonces f es convexa si y solo si*

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) \qquad \text{para todo } x, y \in \mathbb{R}^n.$$

Demostración. ($\Rightarrow$) Sean x, y y $t \in (0, 1]$. Por convexidad, $f(x + t(y - x)) \leq f(x) + t\big(f(y) - f(x)\big)$, es decir,

$$\frac{f(x + t(y - x)) - f(x)}{t} \leq f(y) - f(x).$$

Cuando $t \to 0^+$, el primer miembro tiende a la derivada direccional $\nabla f(x)^\top (y - x)$, lo que da la desigualdad.

($\Leftarrow$) Sean x, y, $t \in [0, 1]$ y $z = tx + (1 - t)y$. Aplicando la hipótesis en el punto z a x y a y, $f(x) \geq f(z) + \nabla f(z)^\top (x - z)$ y $f(y) \geq f(z) + \nabla f(z)^\top (y - z)$. Multiplicando por t y por $1 - t$ y sumando, el término lineal es $\nabla f(z)^\top \big(tx + (1 - t)y - z\big) = 0$, y queda $tf(x) + (1 - t)f(y) \geq f(z)$. ∎

Geométricamente, una función convexa queda por encima de todas sus rectas (o hiperplanos) tangentes. Para funciones dos veces diferenciables, la convexidad equivale a $\nabla^2 f(x) \succeq 0$ para todo x (módulo 4, tema 5; [2, §3.1]). Las dos definiciones siguientes refuerzan esta condición por abajo y la limitan por arriba.

Definición 1.5 (Convexidad fuerte). Sea $\mu > 0$. Una función diferenciable f es *μ-fuertemente convexa* si

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|^2 \qquad \text{para todo } x, y.$$

Si f es dos veces diferenciable, esto equivale a $\nabla^2 f(x) \succeq \mu I$ para todo x [2, §9.1].

Definición 1.6 (Suavidad de Lipschitz). Sea $L > 0$. Una función diferenciable f es *L-suave* si su gradiente es lipschitziano de constante L:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\| \qquad \text{para todo } x, y.$$

Si f es dos veces diferenciable, esto equivale a que todos los autovalores de $\nabla^2 f(x)$ estén en $[-L, L]$ para todo x; para f convexa, a $\nabla^2 f(x) \preceq LI$.

Si f es μ-fuertemente convexa y L-suave, necesariamente $\mu \leq L$, y el cociente

$$\kappa = \frac{L}{\mu} \geq 1$$

se llama *número de condición* de f. En el tema 2 se demuestra que κ controla el número de iteraciones del descenso de gradiente.

Ejemplo 1.7 (Funciones cuadráticas). Sea $f(\theta) = \frac{1}{2}\theta^\top Q\theta + c^\top \theta + b$, con $Q \in \mathbb{R}^{n \times n}$ simétrica, $c \in \mathbb{R}^n$ y $b \in \mathbb{R}$. Entonces $\nabla f(\theta) = Q\theta + c$ y $\nabla^2 f = Q$ es constante. Si $Q \succ 0$, la función es μ-fuertemente convexa y L-suave con

$$\mu = \lambda_{\min}(Q), \qquad L = \lambda_{\max}(Q), \qquad \kappa = \frac{\lambda_{\max}(Q)}{\lambda_{\min}(Q)},$$

que es el número de condición espectral de Q del módulo 3. Para $f(x, y) = x^2 + 5y^2$ se tiene $Q = \operatorname{diag}(2, 10)$, $\mu = 2$, $L = 10$ y $\kappa = 5$: las curvas de nivel son elipses cuyos semiejes están en razón $\sqrt{\kappa} = \sqrt{5} \approx 2{,}236$.

1.3 Condiciones de optimalidad

Teorema 1.8 (Condición necesaria de primer orden). *Si f es diferenciable y $\bar\theta$ es un minimizador local, entonces $\nabla f(\bar\theta) = 0$.*

Demostración. Sea $d = -\nabla f(\bar\theta)$ y supóngase $d \neq 0$. La función $\varphi(t) = f(\bar\theta + td)$ cumple $\varphi'(0) = \nabla f(\bar\theta)^\top d = -\|\nabla f(\bar\theta)\|^2 < 0$, luego $\varphi(t) < \varphi(0)$ para todo $t > 0$ suficientemente pequeño. Esto contradice que $\bar\theta$ sea minimizador local. ∎

Un punto con $\nabla f(\bar\theta) = 0$ se llama *punto crítico* o *estacionario*. En general, la condición no es suficiente; para funciones convexas, sí lo es.

Teorema 1.9 (Optimalidad en el caso convexo). *Sea f convexa y diferenciable. Un punto θ^* es minimizador global si y solo si $\nabla f(\theta^*) = 0$. En particular, todo minimizador local de una función convexa es global.*

Demostración. Si θ^* es minimizador global, también es local y el teorema 1.8 da $\nabla f(\theta^*) = 0$. Recíprocamente, si $\nabla f(\theta^*) = 0$, el teorema 1.4 da $f(y) \geq f(\theta^*) + 0$ para todo y. La última afirmación se sigue de combinar ambas implicaciones con el teorema 1.8. ∎

Proposición 1.10 (Minimizador de una cuadrática). *Sea $f(\theta) = \tfrac{1}{2}\theta^\top Q\theta + c^\top\theta + b$ con $Q \succ 0$. Su único minimizador y su valor mínimo son*

$$\theta^* = -Q^{-1}c, \qquad f^* = b - \tfrac{1}{2}\, c^\top Q^{-1}c,$$

y para todo θ se cumple $f(\theta) - f^* = \tfrac{1}{2}(\theta - \theta^*)^\top Q(\theta - \theta^*)$.

Demostración. f es convexa porque $\nabla^2 f = Q \succ 0$. Por el teorema 1.9, los minimizadores son las soluciones de $Q\theta + c = 0$; como Q es invertible (sus autovalores son positivos), la única es $\theta^* = -Q^{-1}c$. Desarrollando $\tfrac{1}{2}(\theta - \theta^*)^\top Q(\theta - \theta^*)$ con $Q\theta^* = -c$ se obtiene $\tfrac{1}{2}\theta^\top Q\theta + c^\top\theta + \tfrac{1}{2}\theta^{*\top} Q\theta^*$, y $\tfrac{1}{2}\theta^{*\top} Q\theta^* = \tfrac{1}{2}c^\top Q^{-1}c$. Por tanto $f(\theta) = \tfrac{1}{2}(\theta - \theta^*)^\top Q(\theta - \theta^*) + b - \tfrac{1}{2}c^\top Q^{-1}c$, que es mínimo, con valor $b - \tfrac{1}{2}c^\top Q^{-1}c$, cuando $\theta = \theta^*$. ∎

La identidad de la proposición 1.10 permite trasladar el minimizador al origen: en lo que sigue, al estudiar cuadráticas se supondrá sin pérdida de generalidad $f(\theta) = \tfrac{1}{2}\theta^\top Q\theta$, con $\theta^* = 0$ y $f^* = 0$.

Proposición 1.11 (Desigualdad de Polyak–Łojasiewicz). *Si f es μ-fuertemente convexa y diferenciable, con valor óptimo f^*, entonces*

$$\|\nabla f(x)\|^2 \geq 2\mu\big(f(x) - f^*\big) \qquad \textit{para todo } x.$$

Demostración. Fijado x, el segundo miembro de la definición 1.5 es una cuadrática en y que se minimiza en $y = x - \nabla f(x)/\mu$, con valor $f(x) - \|\nabla f(x)\|^2/(2\mu)$. Por tanto, $f(y) \geq f(x) - \|\nabla f(x)\|^2/(2\mu)$ para todo y. Tomando el ínfimo en y, $f^* \geq f(x) - \|\nabla f(x)\|^2/(2\mu)$, que es la desigualdad buscada. ∎

La proposición 1.11 dice que, lejos del óptimo en valor, el gradiente no puede ser pequeño. Es la propiedad que hace converger linealmente al descenso de gradiente (teorema 2.5).

1.4 Paisajes de pérdida no convexos

La pérdida de una red neuronal profunda no es convexa en sus parámetros (módulo 4, tema 5). La información local en un punto crítico la proporciona el hessiano.

Proposición 1.12 (Clasificación de puntos críticos). *Sea f de clase C^2 y $\bar{\theta}$ un punto crítico.*

(i) Si $\nabla^2 f(\bar{\theta}) \succ 0$, $\bar{\theta}$ es un minimizador local estricto.

(ii) Si $\nabla^2 f(\bar{\theta})$ tiene un autovalor negativo, $\bar{\theta}$ no es minimizador local; si tiene autovalores de ambos signos, es un punto de silla.

(iii) Si $\nabla^2 f(\bar{\theta}) \succeq 0$ con algún autovalor nulo, el criterio no decide.

La demostración, basada en el desarrollo de Taylor de segundo orden, se dio en el módulo 4 (tema 4). El cuadro 1.1 recoge los casos con ejemplos en $\mathbb{R}^2$.

Cuadro 1.1: Puntos críticos en el origen y autovalores del hessiano.

Tipo	Autovalores de $\nabla^2 f$	Ejemplo	Comportamiento del descenso
Mínimo local	todos > 0	$x^2 + y^2$	converge si el paso es pequeño
Máximo local	todos < 0	$-x^2 - y^2$	se aleja
Punto de silla	de ambos signos	$x^2 - y^2$	se aleja salvo en un conjunto de medida nula
Valle plano	alguno nulo	x^2	no hay fuerza en la dirección plana

Ejemplo 1.13 (Silla). Para $f(x, y) = x^2 - y^2$, el descenso de gradiente con paso η actúa por coordenadas: $x \leftarrow (1 - 2\eta)x$ e $y \leftarrow (1 + 2\eta)y$. La coordenada x se contrae y la y se expande. Si el punto inicial tiene $y_0 = 0$, el método converge a la silla; cualquier perturbación $y_0 \neq 0$ crece geométricamente y escapa de ella (ejercicio 1.2).

Observación 1.14 (El paisaje de las redes profundas). Se conocen varios hechos empíricos sobre la pérdida de las redes profundas. (i) En alta dimensión, los puntos críticos de pérdida alta son mayoritariamente sillas, no mínimos locales: un mínimo exige que todas las curvaturas sean positivas a la vez [6], [9, §8.2.3]. (ii) El espectro del hessiano se concentra cerca de cero, con un grupo menor de autovalores alejados que dependen de los datos [20]; el problema está muy mal condicionado [9, §8.2.1]. (iii) Los lotes muy grandes tienden a llevar a mínimos más agudos, que se han asociado a una peor generalización [12]. (iv) Las conexiones residuales suavizan visiblemente el paisaje [14]; se estudian en el módulo 11. Los temas siguientes desarrollan algoritmos que funcionan razonablemente en este entorno aunque su análisis se haga en el caso convexo.

Lecturas recomendadas para este tema

- Boyd y Vandenberghe [2], cap. 2 «Convex sets», §3.1 «Basic properties and examples» y §9.1 «Unconstrained minimization problems».
- Stanford EE364a [3], transparencias del curso correspondientes a los capítulos 2, 3 y 9 de [2].
- Goodfellow, Bengio y Courville [9], §8.1 «How Learning Differs from Pure Optimization» y §8.2 «Challenges in Neural Network Optimization».
- Zhang *et al.* [24], §12.1 «Optimization and Deep Learning» y §12.2 «Convexity».

Ejercicios del tema 1

Ejercicio 1.1 ⋆ Sea $f(x) = x^4$ en $\mathbb{R}$. Justifique si es (a) convexa, (b) fuertemente convexa, (c) L-suave en todo $\mathbb{R}$ para algún L. ¿Contradice el apartado (b) que tenga un único minimizador?

Ejercicio 1.2 ⋆ Clasifique el punto $(0,0)$ de $f(x,y) = x^2 - y^2$ y explique por qué el descenso de gradiente, empezando exactamente en $(1,0)$, converge a él. ¿Qué ocurre si empieza en $(1,\delta)$ con $\delta \neq 0$? Tome $\eta = 0{,}1$ y $\delta = 10^{-6}$ y calcule y_{50}.

Ejercicio 1.3 ⋆⋆ Halle el minimizador y el valor mínimo de $h(x) = \tfrac{1}{2} x^\top Q x + x^\top c + b$ con $Q = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, $c = (-3, 0)^\top$ y $b = 1$.

Fuente: adaptado de Zhang *et al.* [24], §12.6, ejercicio 3.

Ejercicio 1.4 ⋆⋆ Sea $f(x,y) = x^2 + 2xy + 5y^2$. Calcule su hessiano, demuestre que f es fuertemente convexa y obtenga μ, L y κ.

Ejercicio 1.5 ⋆⋆⋆ Sean f y g funciones convexas en $\mathbb{R}^n$. (a) Demuestre que $h(x) = \max\{f(x), g(x)\}$ es convexa. (b) Muestre con un contraejemplo que $\min\{f(x), g(x)\}$ no es convexa en general.

Fuente: adaptado de Zhang *et al.* [24], §12.2, ejercicio 3.

Ejercicio 1.6 ⋆⋆⋆ Sea f diferenciable y μ-fuertemente convexa, con un minimizador θ^*. Demuestre que (a) $f(\theta) - f^* \geq \tfrac{\mu}{2}\|\theta - \theta^*\|^2$ para todo θ; (b) el minimizador es único; (c) $\|\nabla f(\theta)\| \geq \mu \|\theta - \theta^*\|$.

Tema 2

Descenso de gradiente

El descenso de gradiente es el algoritmo del que derivan todos los optimizadores del módulo. Este tema demuestra sus garantías de convergencia en tres situaciones de generalidad decreciente: funciones suaves arbitrarias, funciones fuertemente convexas y funciones cuadráticas, en las que el análisis es exacto. El resultado central es que el número de iteraciones crece proporcionalmente al número de condición κ. Se sigue [2, §9.2 y §9.3], [24, §12.3] y las clases 21 y 22 de [22].

2.1 El método y el lema de descenso

Definición 2.1 (Descenso de gradiente). Dados $\theta_0 \in \mathbb{R}^n$ y una *tasa de aprendizaje* (o *paso*) $\eta > 0$, el *descenso de gradiente* genera la sucesión

$$\theta_{k+1} = \theta_k - \eta\, \nabla f(\theta_k), \qquad k = 0, 1, 2, \dots$$

La dirección $-\nabla f(\theta_k)$ es la de máximo descenso local (módulo 4, tema 1). Por el desarrollo de Taylor de primer orden, $f(\theta_k - \eta \nabla f(\theta_k)) = f(\theta_k) - \eta \|\nabla f(\theta_k)\|^2 + o(\eta)$, de modo que un paso suficientemente pequeño reduce f siempre que el gradiente no sea nulo. El lema siguiente cuantifica «suficientemente pequeño».

Lema 2.2 (Lema de descenso). *Si f es L-suave, para todo $x, y \in \mathbb{R}^n$,*

$$f(y) \le f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2}\|y - x\|^2.$$

Demostración. Sea $d = y - x$ y $\varphi(t) = f(x + td)$, con $\varphi'(t) = \nabla f(x + td)^\top d$. Por el teorema fundamental del cálculo,

$$f(y) - f(x) - \nabla f(x)^\top d = \int_0^1 \big(\nabla f(x + td) - \nabla f(x)\big)^\top d \, dt.$$

Por la desigualdad de Cauchy–Schwarz y la definición 1.6, el integrando está acotado por $\|\nabla f(x + td) - \nabla f(x)\|\, \|d\| \le Lt\|d\|^2$. Integrando, $\int_0^1 Lt\|d\|^2\, dt = \frac{L}{2}\|d\|^2$. ∎

Corolario 2.3 (Descenso suficiente). *Si f es L-suave y $\theta^+ = \theta - \eta \nabla f(\theta)$ con $0 < \eta < 2/L$, entonces*

$$f(\theta^+) \le f(\theta) - \eta\Big(1 - \frac{L\eta}{2}\Big)\|\nabla f(\theta)\|^2.$$

Con $\eta = 1/L$ la cota es $f(\theta^+) \le f(\theta) - \frac{1}{2L}\|\nabla f(\theta)\|^2$, y es la mejor que da el lema.

Demostración. Basta tomar $x = \theta$ e $y = \theta^+$ en el lema 2.2, con $y - x = -\eta \nabla f(\theta)$: el término lineal es $-\eta\|\nabla f\|^2$ y el cuadrático, $\frac{L}{2}\eta^2\|\nabla f\|^2$. La función $\eta \mapsto \eta(1 - L\eta/2)$ es positiva en $(0, 2/L)$ y alcanza su máximo, $1/(2L)$, en $\eta = 1/L$. ∎

Teorema 2.4 (Caso no convexo). *Sea f L-suave y acotada inferiormente por f^*. El descenso de gradiente con $\eta = 1/L$ cumple, para todo $K \geq 1$,*

$$\min_{0 \leq k < K} \|\nabla f(\theta_k)\|^2 \leq \frac{2L\big(f(\theta_0) - f^*\big)}{K}.$$

Demostración. Por el corolario 2.3, $\frac{1}{2L}\|\nabla f(\theta_k)\|^2 \leq f(\theta_k) - f(\theta_{k+1})$. Sumando para $k = 0, \dots, K-1$, la suma de la derecha es telescópica y vale $f(\theta_0) - f(\theta_K) \leq f(\theta_0) - f^*$. El mínimo de K números no supera su media, luego $\min_k \|\nabla f(\theta_k)\|^2 \leq \frac{1}{K}\sum_k \|\nabla f(\theta_k)\|^2 \leq 2L(f(\theta_0) - f^*)/K$. ∎

El teorema 2.4 solo garantiza aproximarse a un punto crítico, que puede ser una silla; es la clase de garantía que cabe esperar para la pérdida de una red profunda.

2.2 Convergencia lineal en funciones fuertemente convexas

Teorema 2.5 (Convergencia lineal). *Sea f μ-fuertemente convexa y L-suave, con valor óptimo f^*. El descenso de gradiente con $\eta = 1/L$ cumple*

$$f(\theta_k) - f^* \leq \Big(1 - \frac{1}{\kappa}\Big)^k \big(f(\theta_0) - f^*\big), \qquad \kappa = \frac{L}{\mu}.$$

Demostración. Por el corolario 2.3 y la desigualdad de Polyak–Łojasiewicz (proposición 1.11),

$$f(\theta_{k+1}) - f^* \leq f(\theta_k) - f^* - \frac{1}{2L}\|\nabla f(\theta_k)\|^2 \leq f(\theta_k) - f^* - \frac{2\mu}{2L}\big(f(\theta_k) - f^*\big) = \Big(1 - \frac{\mu}{L}\Big)\big(f(\theta_k) - f^*\big).$$

Iterando k veces se obtiene el enunciado. ∎

Corolario 2.6 (Número de iteraciones). *En las condiciones del teorema 2.5, para alcanzar $f(\theta_k) - f^* \leq \epsilon\,(f(\theta_0) - f^*)$ basta con $k \geq \kappa \ln(1/\epsilon)$ iteraciones.*

Demostración. Como $\ln(1 - x) \leq -x$ para $x \in [0, 1)$, se tiene $(1 - 1/\kappa)^k \leq e^{-k/\kappa}$, que es $\leq \epsilon$ si $k \geq \kappa \ln(1/\epsilon)$. ∎

La convergencia se llama *lineal* porque el error se multiplica en cada paso por un factor constante menor que 1: el logaritmo del error decrece linealmente con k. El factor depende solo de κ. El análisis de [2, §9.3] obtiene el mismo factor $1 - \mu/L$, salvo constantes, para búsquedas lineales exacta y con retroceso.

2.3 Análisis exacto en cuadráticas

En una función cuadrática el método es lineal en θ y puede resolverse en forma cerrada. Toda función de clase C^2 es aproximadamente cuadrática cerca de un mínimo no degenerado, de modo que este caso describe el comportamiento asintótico general.

Ejemplo 2.7 (Una variable). Sea $f(x) = \frac{a}{2}x^2$ con $a > 0$. Entonces $x_{k+1} = x_k - \eta a x_k = (1 - \eta a)\,x_k$, de donde $x_k = (1 - \eta a)^k x_0$. El método converge si y solo si $|1 - \eta a| < 1$, es decir, $0 < \eta < 2/a$. Para $f(x) = 2x^2$ ($a = 4$), $x_0 = 1$ y $\eta = 0{,}1$, el factor es 0,6 y los iterados son 1; 0,6; 0,36; 0,216; 0,1296. Con $\eta = 0{,}6 > 2/a = 0{,}5$, el factor es $-1{,}4$: el iterado cambia de signo en cada paso y su módulo crece.

Teorema 2.8 (Descenso de gradiente en cuadráticas). *Sea $f(\theta) = \frac{1}{2}\theta^\top Q\theta$ con Q simétrica de autovalores $0 < \mu = \lambda_1 \le \cdots \le \lambda_n = L$. Sea $\rho(\eta) = \max_i |1 - \eta\lambda_i|$.*

(i) $\|\theta_k\| \le \rho(\eta)^k \|\theta_0\|$, con igualdad si θ_0 es autovector del autovalor que realiza el máximo.

(ii) El método converge a $\theta^* = 0$ para todo θ_0 si y solo si $0 < \eta < 2/L$.

(iii) El valor de η que minimiza $\rho(\eta)$ es $\eta^* = 2/(\mu + L)$, y

$$\rho(\eta^*) = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1}.$$

Demostración. Como $\nabla f(\theta) = Q\theta$, la iteración es $\theta_{k+1} = (I - \eta Q)\theta_k$, luego $\theta_k = (I - \eta Q)^k \theta_0$. Por el teorema espectral (módulo 3), $Q = U\Lambda U^\top$ con U ortogonal. En las coordenadas $z = U^\top\theta$, la iteración se desacopla: $z_k^{(i)} = (1 - \eta\lambda_i)^k z_0^{(i)}$.

(i) Como U conserva la norma, $\|\theta_k\|^2 = \sum_i (1 - \eta\lambda_i)^{2k} (z_0^{(i)})^2 \le \rho(\eta)^{2k} \|\theta_0\|^2$, con igualdad en el caso indicado.

(ii) Por (i), la condición $\rho(\eta) < 1$ es suficiente. Es necesaria: si $|1 - \eta\lambda_i| \ge 1$ para algún i, el autovector correspondiente no converge a 0. Y $|1 - \eta\lambda_i| < 1$ para todo i equivale a $0 < \eta\lambda_i < 2$ para todo i, es decir, a $0 < \eta < 2/L$.

(iii) Para η fijo, $\lambda \mapsto |1 - \eta\lambda|$ es convexa, así que su máximo en $[\mu, L]$ se alcanza en un extremo: $\rho(\eta) = \max\{|1 - \eta\mu|, |1 - \eta L|\}$. La primera función es decreciente en η mientras $\eta \le 1/\mu$, y la segunda es creciente para $\eta \ge 1/L$; el máximo de ambas es mínimo donde se cortan, $1 - \eta\mu = \eta L - 1$, es decir, $\eta^* = 2/(\mu + L)$. Sustituyendo, $\rho(\eta^*) = 1 - 2\mu/(\mu + L) = (L - \mu)/(L + \mu)$, y dividiendo por μ se obtiene $(\kappa - 1)/(\kappa + 1)$. ∎

Observación 2.9. El teorema 2.8 explica la conducta del método. La dirección de curvatura máxima, $\lambda_n = L$, limita el paso: $\eta < 2/L$. La dirección de curvatura mínima, $\lambda_1 = \mu$, se contrae entonces con un factor $1 - \eta\mu > 1 - 2/\kappa$, próximo a 1 si κ es grande. Con el paso óptimo, las dos direcciones extremas se contraen al mismo ritmo, pero con signos opuestos: la de curvatura alta oscila.

Ejemplo 2.10 (Dos variables). Sea $f(x, y) = x^2 + 5y^2$, con $Q = \mathrm{diag}(2, 10)$, $\mu = 2$, $L = 10$ y $\kappa = 5$. Con $\eta = 0{,}05$, los factores son $1 - 0{,}1 = 0{,}9$ en x y $1 - 0{,}5 = 0{,}5$ en y. Desde $(1, 1)$:

k	x_k	y_k	$f(x_k, y_k)$
0	1	1	6
1	0,9	0,5	2,06
2	0,81	0,25	0,9686
3	0,729	0,125	0,6096

La coordenada y, de curvatura alta, converge deprisa; la x se arrastra. El paso óptimo es $\eta^* = 2/12 = 1/6$, con $\rho = 4/6 = 2/3$; la figura 2.1 muestra la trayectoria resultante.

Corolario 2.11. *En las condiciones del teorema 2.8, con el paso óptimo, el menor k con $\rho^k \le \epsilon$ es $k = \lceil \ln\epsilon / \ln\rho \rceil$, que para κ grande es aproximadamente $\frac{\kappa}{2}\ln(1/\epsilon)$.*

Demostración. La primera afirmación se obtiene tomando logaritmos en $\rho^k \le \epsilon$, teniendo en cuenta que $\ln\rho < 0$. Para la segunda, $\ln\rho = \ln(1 - 1/\kappa) - \ln(1 + 1/\kappa) = -2/\kappa + O(\kappa^{-3})$. ∎

El cuadro 2.1 aplica el corolario con $\epsilon = 10^{-3}$. La última columna anticipa el resultado del tema 4: con momentum, el número de iteraciones crece como $\sqrt{\kappa}$ en lugar de como κ.

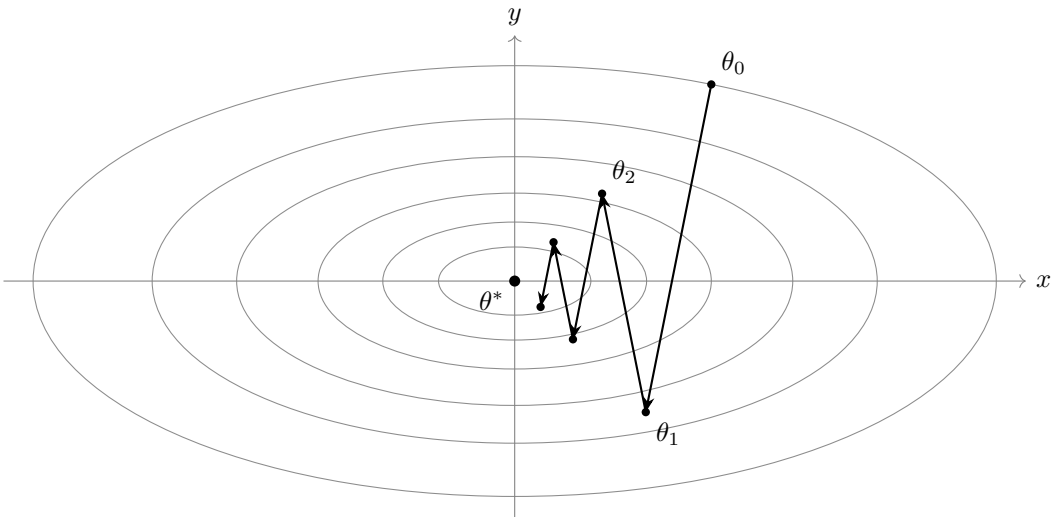


Figura 2.1: Descenso de gradiente sobre $f(x, y) = x^2 + 5y^2$ con el paso óptimo $\eta^* = 1/6$, desde $(1, 1)$. Cada coordenada se multiplica por $2/3$ (en x) o por $-2/3$ (en y): la trayectoria zigzaguea entre las paredes del valle. Las elipses son curvas de nivel.

Cuadro 2.1: Factor de contracción e iteraciones necesarias para reducir el error a 10^{-3} en una cuadrática, con parámetros óptimos.

κ	ρ del gradiente	Iteraciones	ρ con momentum (teorema 4.9)	Iteraciones
10	0,8182	35	0,5195	11
100	0,9802	346	0,8182	35
1000	0,9980	3454	0,9387	110

2.4 La función de Rosenbrock y el borde de estabilidad

Ejemplo 2.12 (Función de Rosenbrock). La función $f(x, y) = (1 - x)^2 + 100(y - x^2)^2$ es no convexa y tiene su único mínimo en $(1, 1)$, con $f = 0$. Su hessiano en el mínimo es

$$\nabla^2 f(1, 1) = \begin{pmatrix} 802 & -400 \\ -400 & 200 \end{pmatrix},$$

de autovalores $\lambda \approx 0{,}3994$ y $\lambda \approx 1001{,}6$ (ejercicio 2.6). Cerca del mínimo, $\kappa \approx 2508$ y el descenso de gradiente solo es estable con $\eta < 2/1001{,}6 \approx 0{,}002$. El mínimo está en el fondo de un valle curvo, estrecho y casi plano a lo largo de su eje. Con $\eta = 10^{-3}$ y desde $(-1{,}5;\ 2)$, el método no baja de $f \approx 6{,}5 \cdot 10^{-3}$ en 5000 iteraciones; es el banco de pruebas de la práctica del módulo.

Observación 2.13 (Borde de estabilidad). La condición $\eta < 2/\lambda_{\max}$ también se observa en redes profundas, pero en sentido inverso. Cohen *et al.* [5] observaron que, al entrenar con descenso de gradiente de paso fijo, la curvatura máxima $\lambda_{\max}$ del hessiano de la pérdida crece hasta situarse en torno a $2/\eta$ y permanece ahí; la pérdida deja de decrecer de forma monótona a corto plazo, pero sigue bajando a largo plazo. La red evoluciona hacia el límite de estabilidad del teorema 2.8.

Lecturas recomendadas para este tema

- Boyd y Vandenberghe [2], §9.2 «Descent methods» y §9.3 «Gradient descent method».
- MIT 18.065 [22], clases 21 «Minimizing a Function Step by Step» y 22 «Gradient Descent: Downhill to a Minimum»; Strang [21], cap. VI.
- Zhang *et al.* [24], §12.3 «Gradient Descent».
- Goodfellow, Bengio y Courville [9], §4.3 «Gradient-Based Optimization» y §8.2.1 «Ill-Conditioning».

Ejercicios del tema 2

Ejercicio 2.1 ⋆ Se multiplica la función objetivo por una constante $c > 0$, es decir, se minimiza cf en lugar de f. ¿Cómo cambian el minimizador, el paso máximo estable del descenso de gradiente y el número de condición? ¿Qué paso hay que usar con cf para reproducir exactamente los iterados obtenidos con f y paso η?

Ejercicio 2.2 ⋆⋆ Sea $f(x) = 3x^2$, $x_0 = 2$ y $\eta = 0{,}1$. Calcule x_1, x_2 y x_3. ¿Para qué valores de η converge el método?

Ejercicio 2.3 ⋆⋆ Sea $f(x, y) = x^2 + 5y^2$ con punto inicial $(1, 1)$ y $\eta = 1/6$. Calcule tres iteraciones y el factor por el que se multiplica la norma del iterado en cada paso. Compruebe que coincide con el del teorema 2.8.

Ejercicio 2.4 ⋆⋆ Sea $f(x, y) = \frac{1}{2}(x^2 + 25y^2)$. (a) Calcule κ, el paso óptimo η^* y el factor ρ del descenso de gradiente. (b) ¿Cuántas iteraciones hacen falta para reducir el error a 10^{-3}? (c) Repita (b) con el factor del momentum óptimo, $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$. (d) Calcule los dos primeros iterados desde $(1, 1)$ con η^*.

Fuente: adaptado de Zhang *et al.* [24], §12.3, ejercicio 3 (diseñar una función con coordenadas a escalas distintas en la que el descenso sea lento).

Ejercicio 2.5 ⋆⋆ Sea $F(x, y) = y^2 + (y - x)^2$, cuyo mínimo es $F = 0$ en $(0, 0)$. (a) Calcule $\nabla F(1, 1)$ y tres pasos de descenso de gradiente con paso $s = 1/2$ desde $(1, 1)$. ¿Qué ocurre con F? (b) Explique el resultado con los autovalores del hessiano. (c) Repita (a) con $s = 1/4$.

Fuente: adaptado de MIT 18.065 [22], problemas de la clase 25 (sección VI.5 de [21]), problema 2. Se usa la versión del enunciado cuyo mínimo es $(0, 0)$.

Ejercicio 2.6 ⋆⋆ Calcule los autovalores del hessiano de la función de Rosenbrock en $(1, 1)$ (ejemplo 2.12), su número de condición y el mayor paso estable del descenso de gradiente. Con $\eta = 10^{-3}$, estime cuántas iteraciones hacen falta para reducir a 10^{-3} el error en la dirección de curvatura mínima.

Ejercicio 2.7 ⋆⋆⋆ Demuestre con detalle el teorema 2.8, justificando en particular por qué el máximo de $|1 - \eta\lambda|$ sobre $[\mu, L]$ se alcanza en un extremo y por qué el valor óptimo de η iguala los dos extremos.

Tema 3

Descenso de gradiente estocástico

Un modelo de lenguaje se entrena con billones de tokens; calcular el gradiente exacto del riesgo empírico antes de cada paso es inviable. El descenso de gradiente estocástico sustituye ese gradiente por una estimación barata obtenida de un subconjunto aleatorio de ejemplos. Este tema estudia las propiedades estadísticas de esa estimación, demuestra una garantía de convergencia en el caso convexo y explica por qué el ruido obliga a reducir la tasa de aprendizaje al final del entrenamiento. Se sigue [24, §12.4 y §12.5], [9, §8.1.3 y §8.3.1], la revisión [1] y la clase 25 de [22].

3.1 El gradiente de minibatch

Sea $J(\theta) = \frac{1}{N}\sum_{i=1}^{N} \ell_i(\theta)$ el riesgo empírico (definición 1.2), con cada ℓ_i diferenciable.

Definición 3.1 (Descenso de gradiente estocástico). Sea $B \geq 1$. En cada paso k se eligen índices $I_1, \ldots, I_B$ en $\{1, \ldots, N\}$, independientes entre sí y de los pasos anteriores, y se calcula el *gradiente de minibatch*

$$\hat{g}_k = \frac{1}{B}\sum_{b=1}^{B} \nabla \ell_{I_b}(\theta_k).$$

El *descenso de gradiente estocástico* (SGD) es la iteración $\theta_{k+1} = \theta_k - \eta_k\, \hat{g}_k$. Con $B = 1$ se obtiene el SGD en sentido estricto; con $B = N$ y sin aleatoriedad, el descenso de gradiente del tema 2.

Para un vector aleatorio $X \in \mathbb{R}^n$ se usa la *varianza total* $\operatorname{Var}[X] = \mathbb{E}\|X - \mathbb{E}X\|^2$, suma de las varianzas de las componentes. Sea, para θ fijo,

$$\sigma^2(\theta) = \frac{1}{N}\sum_{i=1}^{N} \|\nabla \ell_i(\theta) - \nabla J(\theta)\|^2,$$

la varianza de los gradientes individuales.

Teorema 3.2 (Insesgadez y varianza del minibatch). *Si $I_1, \ldots, I_B$ son independientes y uniformes en $\{1, \ldots, N\}$ (muestreo con reemplazamiento), entonces, para θ fijo,*

$$\mathbb{E}[\hat{g}] = \nabla J(\theta), \qquad \operatorname{Var}[\hat{g}] = \frac{\sigma^2(\theta)}{B}.$$

Demostración. Sea $X_b = \nabla \ell_{I_b}(\theta)$. Como I_b es uniforme, $\mathbb{E}[X_b] = \sum_{i=1}^{N} \frac{1}{N} \nabla \ell_i(\theta) = \nabla J(\theta)$ y $\operatorname{Var}[X_b] = \sigma^2(\theta)$. Por linealidad de la esperanza, $\mathbb{E}[\hat{g}] = \frac{1}{B}\sum_b \mathbb{E}[X_b] = \nabla J(\theta)$. Las X_b son independientes, luego los términos cruzados $\mathbb{E}[(X_b - \nabla J)^\top (X_{b'} - \nabla J)]$ con $b \neq b'$ se anulan y

$$\operatorname{Var}[\hat{g}] = \frac{1}{B^2}\sum_{b=1}^{B} \operatorname{Var}[X_b] = \frac{B\sigma^2}{B^2} = \frac{\sigma^2}{B}. \qquad \blacksquare$$

En la práctica se recorre el conjunto de datos en orden aleatorio, lo que equivale a muestrear sin reemplazamiento dentro de cada época. La varianza es entonces algo menor.

Proposición 3.3 (Muestreo sin reemplazamiento). *Si $\{I_1, \dots, I_B\}$ es un subconjunto de B índices distintos elegido uniformemente entre los $\binom{N}{B}$ posibles, con $1 \le B \le N$, entonces $\mathbb{E}[\hat{g}] = \nabla J(\theta)$ y*

$$\operatorname{Var}[\hat{g}] = \frac{\sigma^2(\theta)}{B} \cdot \frac{N-B}{N-1}.$$

La demostración se propone en el ejercicio 3.5. El factor $(N-B)/(N-1)$ es la *corrección por población finita* de la estadística clásica: vale 1 si $B = 1$ y 0 si $B = N$, caso en que $\hat{g}$ es el gradiente exacto.

Ejemplo 3.4. Sean los datos $x = (1, 2, 3, 6)$, la pérdida $\ell_i(w) = \frac{1}{2}(w - x_i)^2$ y $w = 0$. Los gradientes individuales son $w - x_i = (-1, -2, -3, -6)$, de media $\nabla J = -3$ y varianza $\sigma^2 = (4 + 1 + 0 + 9)/4 = 3{,}5$. Los seis minibatches de tamaño $B = 2$ sin reemplazamiento dan

Minibatch	$\{1,2\}$	$\{1,3\}$	$\{1,6\}$	$\{2,3\}$	$\{2,6\}$	$\{3,6\}$
$\hat{g}$	$-1{,}5$	-2	$-3{,}5$	$-2{,}5$	-4	$-4{,}5$

Su media es $-18/6 = -3$, el gradiente exacto, y su varianza es $7/6 \approx 1{,}1667$, que coincide con $(3{,}5/2) \cdot (2/3)$ según la proposición 3.3.

Observación 3.5 (Coste y tamaño del lote). La desviación típica del gradiente decrece como $1/\sqrt{B}$, mientras que el coste de calcularlo crece como B: duplicar el lote solo divide el ruido por $\sqrt{2} \approx 1{,}414$. Por eso suele compensar dar muchos pasos ruidosos y baratos antes que pocos exactos [9, §8.1.3]. El tamaño del lote está limitado además por el paralelismo del hardware (módulo 17). Los modelos de lenguaje usan lotes del orden de millones de tokens: GPT-3, en su versión de $175 \cdot 10^9$ parámetros, se entrenó con lotes de 3,2 millones de tokens [4, tabla 2.1]. Al aumentar el lote, Goyal *et al.* [10] propusieron escalar la tasa de aprendizaje en la misma proporción (*regla de escalado lineal*), acompañada de un calentamiento inicial.

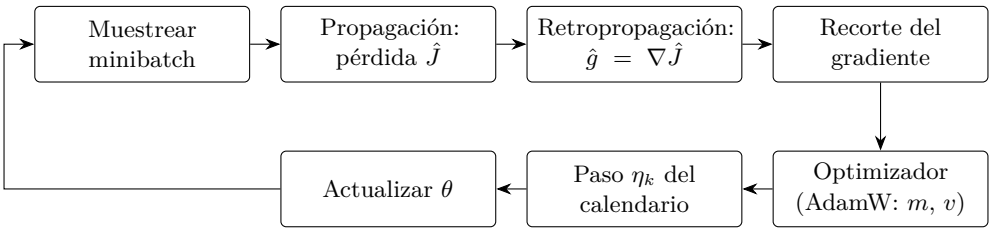


Figura 3.1: Un paso de entrenamiento de un modelo de lenguaje. La retropropagación se estudia en los módulos 9 y 10, el recorte del gradiente en el módulo 11, AdamW en los temas 5 y 6 y el calendario en el tema 6.

3.2 Convergencia en el caso convexo

Teorema 3.6 (SGD en funciones convexas). *Sea f convexa y diferenciable, con minimizador θ^*. Sea la iteración $\theta_{t+1} = \theta_t - \eta_t g_t$, $t = 1, \dots, T$, donde g_t es un gradiente estocástico que, condicionado a θ_t, cumple $\mathbb{E}[g_t \mid \theta_t] = \nabla f(\theta_t)$ y $\mathbb{E}[\|g_t\|^2 \mid \theta_t] \le G^2$. Sean $r = \|\theta_1 - \theta^*\|$ y*

$\bar\theta_T = \sum_t \eta_t\theta_t / \sum_t \eta_t$. *Entonces*

$$\mathbb{E}\big[f(\bar\theta_T)\big] - f(\theta^*) \le \frac{r^2 + G^2\sum_{t=1}^{T}\eta_t^2}{2\sum_{t=1}^{T}\eta_t}.$$

Demostración. Desarrollando el cuadrado,

$$\|\theta_{t+1}-\theta^*\|^2 = \|\theta_t-\theta^*\|^2 - 2\eta_t\, g_t^\top(\theta_t-\theta^*) + \eta_t^2\|g_t\|^2.$$

Se toma la esperanza condicionada a θ_t. Por la insesgadez, $\mathbb{E}[g_t^\top(\theta_t-\theta^*)\mid\theta_t] = \nabla f(\theta_t)^\top(\theta_t-\theta^*)$, y por el teorema 1.4 aplicado con $x=\theta_t$ e $y=\theta^*$, este producto es $\ge f(\theta_t)-f(\theta^*)$. Tomando después la esperanza total,

$$2\eta_t\,\mathbb{E}\big[f(\theta_t)-f(\theta^*)\big] \le \mathbb{E}\|\theta_t-\theta^*\|^2 - \mathbb{E}\|\theta_{t+1}-\theta^*\|^2 + \eta_t^2 G^2.$$

Sumando para $t=1,\dots,T$, la suma de las diferencias es telescópica y está acotada por $\|\theta_1-\theta^*\|^2 = r^2$:

$$2\sum_{t=1}^{T}\eta_t\,\mathbb{E}\big[f(\theta_t)-f(\theta^*)\big] \le r^2 + G^2\sum_{t=1}^{T}\eta_t^2.$$

Finalmente, $\bar\theta_T$ es una combinación convexa de los θ_t con pesos $\eta_t/\sum_s\eta_s$, y la desigualdad de Jensen para la función convexa f da $f(\bar\theta_T) \le \sum_t \eta_t f(\theta_t)/\sum_t\eta_t$. Dividiendo por $2\sum_t\eta_t$ se obtiene el enunciado. ∎

Corolario 3.7. *Con T fijado y paso constante $\eta_t = \eta = r/(G\sqrt{T})$, la cota del teorema 3.6 vale $rG/\sqrt{T}$.*

Demostración. Con η constante, la cota es $(r^2 + G^2T\eta^2)/(2T\eta)$. Sustituyendo $\eta = r/(G\sqrt{T})$, el numerador es $2r^2$ y el denominador $2\sqrt{T}\,r/G$; el cociente es $rG/\sqrt{T}$. ∎

Corolario 3.8 (Condiciones de Robbins–Monro). *Si $\sum_{t\ge1}\eta_t = \infty$ y $\sum_{t\ge1}\eta_t^2 < \infty$, la cota del teorema 3.6 tiende a 0 cuando $T\to\infty$.*

Demostración. El numerador permanece acotado por $r^2 + G^2\sum_{t\ge1}\eta_t^2 < \infty$ y el denominador tiende a infinito. ∎

Las dos condiciones del corolario 3.8 proceden del trabajo fundacional de Robbins y Monro sobre aproximación estocástica [19]: los pasos deben sumar lo suficiente para llegar a cualquier punto, pero sus cuadrados, que miden el ruido acumulado, deben ser sumables. La velocidad $O(1/\sqrt{T})$ es mucho más lenta que la convergencia lineal del teorema 2.5: es el precio del ruido.

3.3 El ruido y la tasa de aprendizaje

Con un paso constante, el SGD no converge al minimizador, sino que fluctúa a su alrededor. La proposición siguiente lo cuantifica en el caso más sencillo.

Proposición 3.9 (Suelo de ruido). *Sea $f(x) = \frac{a}{2}x^2$ con $a>0$ y la iteración $x_{k+1} = x_k - \eta(ax_k+\xi_k)$, donde las ξ_k son variables aleatorias de media 0 y varianza s^2, independientes entre sí y de x_0. Si $0<\eta a<2$, entonces $\mathbb{E}[x_k]\to0$ y*

$$\lim_{k\to\infty}\mathbb{E}[x_k^2] = \frac{\eta\, s^2}{a(2-\eta a)}, \qquad \lim_{k\to\infty}\mathbb{E}[f(x_k)] = \frac{\eta\, s^2}{2(2-\eta a)}.$$

Demostración. Sea $q = 1-\eta a$, con $|q| < 1$. La iteración es $x_{k+1} = qx_k - \eta\xi_k$, y x_k depende solo de $x_0, \xi_0, \ldots, \xi_{k-1}$, luego es independiente de ξ_k. Tomando esperanzas, $\mathbb{E}[x_{k+1}] = q\,\mathbb{E}[x_k]$, que tiende a 0. Elevando al cuadrado, $\mathbb{E}[x_{k+1}^2] = q^2\mathbb{E}[x_k^2] - 2q\eta\,\mathbb{E}[x_k]\mathbb{E}[\xi_k] + \eta^2 s^2 = q^2\mathbb{E}[x_k^2] + \eta^2 s^2$. Sea $e^* = \eta^2 s^2/(1-q^2)$, el punto fijo de esta recurrencia. Entonces $\mathbb{E}[x_{k+1}^2] - e^* = q^2(\mathbb{E}[x_k^2] - e^*)$, que tiende a 0. Como $1 - q^2 = \eta a(2 - \eta a)$, se tiene $e^* = \eta s^2/(a(2-\eta a))$, y $\mathbb{E}[f(x_k)] = \frac{a}{2}\mathbb{E}[x_k^2]$ tiende a $\frac{a}{2}e^*$. ■

El exceso de pérdida estacionario es aproximadamente $\eta s^2/4$ si $\eta a \ll 1$: proporcional a la tasa de aprendizaje y a la varianza del gradiente. Reducir η al final del entrenamiento rebaja ese suelo; es la justificación del decaimiento de la tasa de aprendizaje que se estudia en el tema 6.

Observación 3.10 (El ruido no es solo un inconveniente). En problemas no convexos, el ruido del minibatch tiene efectos favorables: una iteración exactamente sobre la variedad estable de una silla, como en el ejemplo 1.13, se desvía de ella con probabilidad 1, y los lotes pequeños tienden a encontrar mínimos más anchos [12]. Estos efectos se conocen sobre todo empíricamente; su análisis riguroso es materia de investigación.

Lecturas recomendadas para este tema

- Zhang *et al.* [24], §12.4 «Stochastic Gradient Descent» (en particular §12.4.3, análisis de convergencia en el caso convexo) y §12.5 «Minibatch Stochastic Gradient Descent».
- Goodfellow, Bengio y Courville [9], §8.1.3 «Batch and Minibatch Algorithms» y §8.3.1 «Stochastic Gradient Descent».
- Bottou, Curtis y Nocedal [1], revisión de los métodos de optimización para aprendizaje automático a gran escala.
- MIT 18.065 [22], clase 25 «Stochastic Gradient Descent».

Ejercicios del tema 3

Ejercicio 3.1 ⋆ Dé dos motivos por los que ningún modelo de lenguaje se entrena con descenso de gradiente sobre el corpus completo.

Ejercicio 3.2 ⋆⋆ Los gradientes individuales de un problema con $N = 4$ ejemplos valen $(-2, 0, 1, 5)$. Calcule el gradiente completo, la varianza σ^2, la media de los seis gradientes de minibatch con $B = 2$ sin reemplazamiento y su varianza. Compruebe el resultado con la proposición 3.3.

Ejercicio 3.3 ⋆⋆ Cuatro gradientes individuales valen $(2, 4, 6, 8)$. Con $B = 2$, calcule la media y la varianza del gradiente de minibatch si se muestrea (a) con reemplazamiento, enumerando los 16 pares ordenados, y (b) sin reemplazamiento, enumerando los 6 pares. Compare con σ^2/B.

Fuente: adaptado de Zhang *et al.* [24], §12.4, ejercicio 3.

Ejercicio 3.4 ⋆⋆ En la situación de la proposición 3.9, con $a = 1$ y $s^2 = 1$, calcule el valor límite de $\mathbb{E}[x_k^2]$ y del exceso de pérdida $\mathbb{E}[f(x_k)]$ para $\eta = 0{,}1$ y para $\eta = 0{,}01$. ¿En qué factor se reduce el exceso de pérdida al dividir el paso por 10? ¿Qué precio se paga en velocidad?

Ejercicio 3.5 ⋆⋆⋆ Demuestre la proposición 3.3. Indicación: sean $X_b = \nabla \ell_{I_b}(\theta) - \nabla J(\theta)$; calcule primero $\mathbb{E}[X_b^\top X_{b'}]$ para $b \neq b'$ usando que $\sum_{i=1}^{N} \big(\nabla \ell_i(\theta) - \nabla J(\theta)\big) = 0$.

Ejercicio 3.6 ⋆⋆⋆ Sea $f(x_1, x_2) = x_1^2 + 2x_2^2$ y $w = (w_1, w_2)$ un vector aleatorio con distribución $\mathcal{N}(0, s^2 I)$. Se define $F(x, w) = (x_1 - w_1)^2 + 2(x_2 - w_2)^2$. Demuestre que (a) $\nabla_x F(x, w)$ es igual a $\nabla f(x)$ más un ruido gaussiano de media 0, y calcule su matriz de covarianza; (b) $\mathbb{E}_w[F(x, w)] = f(x) + 3s^2$, de modo que minimizar $\mathbb{E}_w[F]$ y minimizar f tienen el mismo minimizador. Concluya que el SGD sobre F es un descenso de gradiente sobre f con gradiente ruidoso.

Fuente: adaptado de Zhang *et al.* [24], §12.4, ejercicio 2.

Tema 4

Momentum

El tema 2 mostró que el descenso de gradiente es lento en valles alargados: la dirección de curvatura alta obliga a usar pasos pequeños y la de curvatura baja avanza despacio. El método de momentum, propuesto por Polyak [18] con el nombre de método de la bola pesada, corrige este defecto acumulando los gradientes pasados. Este tema lo presenta como una media móvil exponencial, lo interpreta como la discretización de un sistema mecánico con rozamiento y demuestra que, en cuadráticas, reduce el número de iteraciones de un orden κ a un orden $\sqrt{\kappa}$. Se sigue [24, §12.6], [9, §8.3.2 y §8.3.3], la clase 23 de [22] y el artículo divulgativo de Goh [8].

4.1 Medias móviles exponenciales

Definición 4.1 (Media móvil exponencial). Sean $g_1, g_2, \dots$ vectores y $\beta \in [0,1)$. La *acumulación exponencial* con $v_0 = 0$ es $v_k = \beta v_{k-1} + g_k$, y la *media móvil exponencial* es $\bar{v}_k = \beta \bar{v}_{k-1} + (1-\beta) g_k$, con $\bar{v}_0 = 0$.

Proposición 4.2. *Con la notación de la definición 4.1,*

$$v_k = \sum_{j=1}^{k} \beta^{k-j} g_j, \qquad \bar{v}_k = (1-\beta)\, v_k.$$

En particular, si $g_j = g$ para todo j, entonces $v_k = \frac{1-\beta^k}{1-\beta}\, g \to \frac{g}{1-\beta}$ y $\bar{v}_k = (1-\beta^k)\, g \to g$.

Demostración. La fórmula de v_k se demuestra por inducción: es cierta para $k = 1$, y si lo es para $k-1$, entonces $v_k = \beta \sum_{j=1}^{k-1} \beta^{k-1-j} g_j + g_k = \sum_{j=1}^{k} \beta^{k-j} g_j$. Las dos recurrencias son lineales con la misma condición inicial y se diferencian en el factor $(1-\beta)$ del término nuevo, luego $\bar{v}_k = (1-\beta) v_k$. Con $g_j = g$, la suma es geométrica: $\sum_{j=1}^{k} \beta^{k-j} = \sum_{i=0}^{k-1} \beta^i = (1-\beta^k)/(1-\beta)$. ∎

El peso de un gradiente decae geométricamente con su antigüedad; la suma total de los pesos es $1/(1-\beta)$, que se interpreta como el número efectivo de gradientes promediados [24, §12.6.1]. Con $\beta = 0{,}9$ son unos 10; con $\beta = 0{,}99$, unos 100.

4.2 El método de la bola pesada

Definición 4.3 (Momentum). Dados θ_0, $v_0 = 0$, un paso $\eta > 0$ y un coeficiente $\beta \in [0,1)$, el método de *momentum* (o de la *bola pesada*) es

$$v_{k+1} = \beta v_k + \nabla f(\theta_k), \qquad \theta_{k+1} = \theta_k - \eta\, v_{k+1}.$$

Con $\beta = 0$ se recupera el descenso de gradiente.

Proposición 4.4 (Forma de dos pasos). *Los iterados del método de momentum cumplen, para $k \geq 1$,*

$$\theta_{k+1} = \theta_k - \eta \nabla f(\theta_k) + \beta\,(\theta_k - \theta_{k-1}).$$

Demostración. De la segunda ecuación, $\eta v_k = \theta_{k-1} - \theta_k$. Sustituyendo la primera en la segunda, $\theta_{k+1} = \theta_k - \eta\beta v_k - \eta\nabla f(\theta_k) = \theta_k - \eta\nabla f(\theta_k) + \beta(\theta_k - \theta_{k-1})$. ∎

El término $\beta(\theta_k - \theta_{k-1})$ es la inercia: el iterado conserva una fracción β de su desplazamiento anterior. Si el gradiente es constante, la proposición 4.2 da $\eta v_k \to \eta g/(1-\beta)$: con $\beta = 0{,}9$, el paso efectivo es diez veces el del descenso de gradiente. En un valle estrecho, las componentes del gradiente que cambian de signo de un paso al siguiente (las transversales al valle) se cancelan parcialmente en v_k, mientras que las que conservan el signo (a lo largo del valle) se acumulan.

Ejemplo 4.5. Sea $f(x) = x^2/2$, con $f'(x) = x$, $x_0 = 1$, $\eta = 0{,}1$ y $\beta = 0{,}9$:

k	v_k	x_k (momentum)	x_k (descenso de gradiente)
1	1	0,9	0,9
2	1,8	0,72	0,81
3	2,34	0,486	0,729
4	2,592	0,2268	0,6561
5	2,5596	−0,02916	0,59049

El momentum avanza más deprisa y en el paso 5 sobrepasa el mínimo: la bola tiene inercia.

4.3 Interpretación física

Considérese una partícula de masa $m > 0$ que se mueve en un potencial f con rozamiento viscoso de coeficiente $\gamma > 0$. Su posición $\theta(t)$ y su velocidad $u(t) = \dot\theta(t)$ cumplen

$$m\,\dot u = -\nabla f(\theta) - \gamma\, u, \qquad \dot\theta = u. \tag{4.1}$$

Proposición 4.6 (Disipación de energía). *Sea $E(t) = \frac{m}{2}\|u(t)\|^2 + f(\theta(t))$ la energía mecánica. A lo largo de las soluciones de (4.1), $\dot E = -\gamma\|u\|^2 \leq 0$.*

Demostración. Por la regla de la cadena, $\dot E = m\,u^\top \dot u + \nabla f(\theta)^\top \dot\theta = u^\top\big(-\nabla f(\theta) - \gamma u\big) + \nabla f(\theta)^\top u = -\gamma\|u\|^2$. ∎

La energía decrece mientras la partícula se mueve y solo se estabiliza cuando $u = 0$, es decir, en reposo en un punto crítico. Sin rozamiento, la energía se conserva y la partícula oscila indefinidamente.

Proposición 4.7 (Discretización). *Se discretiza (4.1) con paso temporal $\Delta t > 0$ mediante*

$$u_{k+1} = u_k + \frac{\Delta t}{m}\big(-\nabla f(\theta_k) - \gamma u_k\big), \qquad \theta_{k+1} = \theta_k + \Delta t\, u_{k+1}.$$

Con $v_k = -(m/\Delta t)\,u_k$, la iteración es exactamente el método de momentum de la definición 4.3 con

$$\beta = 1 - \frac{\gamma\,\Delta t}{m}, \qquad \eta = \frac{\Delta t^2}{m}.$$

Demostración. Multiplicando la primera ecuación por $-m/\Delta t$: $v_{k+1} = (1 - \gamma\Delta t/m)\, v_k + \nabla f(\theta_k) = \beta v_k + \nabla f(\theta_k)$. Y $\Delta t\, u_{k+1} = -(\Delta t^2/m)\, v_{k+1} = -\eta v_{k+1}$. ■

El coeficiente β mide la fracción de velocidad que sobrevive a un paso: $\beta \to 1$ corresponde a rozamiento nulo y $\beta = 0$ a un rozamiento tan grande que la partícula olvida su velocidad en cada paso, que es el descenso de gradiente.

4.4 Convergencia en cuadráticas

Lema 4.8 (Una dirección propia). *Sea $f(z) = \frac{\lambda}{2} z^2$ con $\lambda > 0$. Los iterados del método de momentum cumplen $z_{k+1} = (1 + \beta - \eta\lambda)\, z_k - \beta z_{k-1}$, cuyo polinomio característico es*

$$p(r) = r^2 - (1 + \beta - \eta\lambda)\, r + \beta.$$

Si $(1 - \sqrt{\beta})^2 \le \eta\lambda \le (1 + \sqrt{\beta})^2$, las dos raíces de p tienen módulo $\sqrt{\beta}$.

Demostración. La recurrencia es la proposición 4.4 con $\nabla f(z) = \lambda z$. Sea $b = 1 + \beta - \eta\lambda$. El discriminante de p es $b^2 - 4\beta$, que es ≤ 0 si y solo si $|b| \le 2\sqrt{\beta}$, es decir, $1 + \beta - 2\sqrt{\beta} \le \eta\lambda \le 1 + \beta + 2\sqrt{\beta}$, que es la condición del enunciado. En ese caso las raíces son complejas conjugadas (o una raíz doble real), y su producto, igual a $|r|^2$, es el término independiente β. ■

Teorema 4.9 (Momentum óptimo en cuadráticas). *Sea $f(\theta) = \frac{1}{2}\theta^\top Q\theta$ con Q simétrica de autovalores en $[\mu, L]$, $0 < \mu < L$, y $\kappa = L/\mu$. Con*

$$\eta = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \qquad \beta = \Big(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\Big)^2,$$

la iteración lineal del método de momentum sobre el par (θ_k, θ_{k-1}) tiene radio espectral

$$\rho = \sqrt{\beta} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

Demostración. En la base de autovectores de Q la iteración se desacopla, como en el teorema 2.8, en n recurrencias escalares como la del lema 4.8, una por autovalor λ_i. Cada una es una iteración lineal en $\mathbb{R}^2$ cuya matriz tiene por autovalores las raíces de p; el radio espectral global es el máximo de los módulos de esas raíces. Se comprueba que todos los $\lambda \in [\mu, L]$ cumplen la condición del lema. Como $\sqrt{\beta} = (\sqrt{L} - \sqrt{\mu})/(\sqrt{L} + \sqrt{\mu})$,

$$1 - \sqrt{\beta} = \frac{2\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}, \qquad 1 + \sqrt{\beta} = \frac{2\sqrt{L}}{\sqrt{L} + \sqrt{\mu}},$$

de donde $(1 - \sqrt{\beta})^2 = 4\mu/(\sqrt{L} + \sqrt{\mu})^2 = \eta\mu$ y $(1 + \sqrt{\beta})^2 = \eta L$. Para $\lambda \in [\mu, L]$, $\eta\lambda \in [\eta\mu, \eta L]$, que es justamente el intervalo del lema. Todas las raíces tienen módulo $\sqrt{\beta}$. ■

Observación 4.10. El radio espectral determina la tasa asintótica: para todo $\delta > 0$ existe C tal que $\|\theta_k\| \le C(\rho + \delta)^k$. A diferencia del teorema 2.8, la matriz de la iteración no es simétrica y la constante C puede ser mayor que 1; en los extremos $\lambda = \mu$ y $\lambda = L$ la raíz es doble y aparece un factor polinómico en k. Por eso las iteraciones reales pueden ser algo más que las que predice ρ (ejercicio 4.4).

Comparando con el teorema 2.8, para κ grande, $\ln \rho_{\text{mom}} \approx -2/\sqrt{\kappa}$ frente a $\ln \rho_{\text{gd}} \approx -2/\kappa$: el número de iteraciones pasa de ser proporcional a κ a serlo a $\sqrt{\kappa}$. Con $\kappa = 100$, el factor baja de 0,9802 a 0,8182 y las iteraciones para reducir el error a 10^{-3}, de 346 a 35 (cuadro 2.1). El artículo de Goh [8] permite explorar este resultado de forma interactiva.

Ejemplo 4.11 (Rosenbrock). En la función del ejemplo 2.12, desde $(-1{,}5;\, 2)$ y con $\eta = 10^{-3}$, el método de momentum con $\beta = 0{,}9$ alcanza $f < 10^{-4}$ en la iteración 934, mientras que el descenso de gradiente con el mismo paso no lo logra en 5000 iteraciones.

4.5 Momentum de Nesterov

Definición 4.12 (Momentum de Nesterov). El método de *momentum de Nesterov* evalúa el gradiente en el punto al que llevaría la inercia:

$$v_{k+1} = \beta v_k + \nabla f(\theta_k - \eta\beta v_k), \qquad \theta_{k+1} = \theta_k - \eta v_{k+1}.$$

Para funciones convexas y L-suaves, una versión de este método con β variable alcanza $f(\theta_k) - f^* = O(1/k^2)$, frente al $O(1/k)$ del descenso de gradiente, y ese orden es óptimo entre los métodos de primer orden [17]. En el caso estocástico, en cambio, el momentum de Nesterov no mejora el orden de convergencia [9, §8.3.3]. En el entrenamiento de redes profundas, el momentum se usa sobre todo a través de Adam (tema 5), cuyo primer momento es una media móvil exponencial del gradiente.

Lecturas recomendadas para este tema

- Zhang *et al.* [24], §12.6 «Momentum», en particular §12.6.3 «Theoretical Analysis».
- Goodfellow, Bengio y Courville [9], §8.3.2 «Momentum» y §8.3.3 «Nesterov Momentum».
- MIT 18.065 [22], clase 23 «Accelerating Gradient Descent (Use Momentum)».
- Goh [8], «Why Momentum Really Works», exposición interactiva del análisis de este tema.
- Polyak [18], artículo original del método de la bola pesada.

Ejercicios del tema 4

Ejercicio 4.1 ⋆ Con gradiente constante g, ¿por qué factor multiplica el momentum el paso del descenso de gradiente a largo plazo si $\beta = 0{,}9$? ¿Y si $\beta = 0{,}99$? ¿Cuántos pasos hacen falta, con $\beta = 0{,}9$, para alcanzar el 90 % de ese valor? Explique por qué un β grande favorece que el iterado sobrepase el mínimo.

Ejercicio 4.2 ⋆⋆ Aplique tres pasos del método de momentum a $f(x) = x^2/2$ con $x_0 = 1$, $v_0 = 0$, $\eta = 0{,}1$ y $\beta = 0{,}9$, y compárelos con tres pasos de descenso de gradiente con el mismo η. ¿Qué fracción de la distancia inicial al mínimo ha recorrido cada método?

Ejercicio 4.3 ⋆⋆ Una cuadrática tiene $\mu = 1$ y $L = 100$. Calcule los parámetros η y β del teorema 4.9, el factor ρ y el número de iteraciones estimado para reducir el error a 10^{-3}. Compárelo con el descenso de gradiente con paso óptimo.

Ejercicio 4.4 ⋆⋆ Sea $f(x) = \frac{1}{2}\sum_{i=1}^{3} \lambda_i x_i^2$ con $\lambda_i = 2^{-(i-1)}$, es decir, $\lambda = (1, \frac{1}{2}, \frac{1}{4})$, y $x_0 = (1, 1, 1)$. (a) Con descenso de gradiente y $\eta = 1$, ¿cuántos pasos hacen falta para que todas las coordenadas tengan módulo menor que 10^{-2}? (b) Repita con el paso óptimo del teorema 2.8. (c) Obtenga los parámetros óptimos del momentum, calcule a mano los dos primeros iterados y estime el número de pasos con el radio espectral.

Fuente: adaptado de Zhang *et al.* [24], §12.6, ejercicio 2 (autovalores $\lambda_i = 2^{-i}$; aquí se reduce a tres coordenadas para el cálculo a mano).

Ejercicio 4.5 ⋆⋆⋆ Demuestre la proposición 4.4. Demuestre después que, si $\nabla f(\theta_k) = g$ para todo k, el desplazamiento cumple $\theta_k - \theta_{k+1} = \eta\, \frac{1-\beta^{k+1}}{1-\beta}\, g$.

Ejercicio 4.6 ⋆⋆⋆ Sea $f(z) = \frac{\lambda}{2} z^2$ con $\lambda > 0$, $\eta > 0$ y $\beta \in [0, 1)$. Demuestre que las dos raíces del polinomio p del lema 4.8 tienen módulo menor que 1 si y solo si $0 < \eta\lambda < 2(1 + \beta)$. Compare con el límite $\eta\lambda < 2$ del descenso de gradiente.

Tema 5

Métodos adaptativos: AdaGrad, RMSProp y Adam

El momentum acelera el descenso en valles mal condicionados, pero usa la misma tasa de aprendizaje en todas las coordenadas. Los métodos adaptativos asignan a cada parámetro su propio paso, dividiendo su gradiente por una estimación de su escala típica. Este tema los presenta como preacondicionadores diagonales, estudia AdaGrad y RMSProp y analiza con detalle Adam, el optimizador sobre el que se construye la receta de preentrenamiento de los modelos de lenguaje. Se sigue [24, §12.7, §12.8 y §12.10], [9, §8.5] y los artículos originales [7, 11, 13].

En todo el tema, las operaciones entre vectores (g^2, $\sqrt{s}$, cocientes) se entienden elemento a elemento.

5.1 Preacondicionamiento diagonal

Definición 5.1 (Descenso preacondicionado). Sea $D \in \mathbb{R}^{n\times n}$ diagonal con entradas positivas. El *descenso de gradiente preacondicionado* por D es $\theta_{k+1} = \theta_k - \eta\, D^{-1}\nabla f(\theta_k)$.

Proposición 5.2. *El descenso preacondicionado por D sobre f es el descenso de gradiente ordinario sobre $\tilde{f}(\varphi) = f(D^{-1/2}\varphi)$ en las variables $\varphi = D^{1/2}\theta$. Si $f(\theta) = \frac{1}{2}\theta^\top Q\theta$, el hessiano de $\tilde{f}$ es $D^{-1/2}QD^{-1/2}$.*

Demostración. Por la regla de la cadena, $\nabla\tilde{f}(\varphi) = D^{-1/2}\nabla f(D^{-1/2}\varphi)$. Un paso de descenso sobre $\tilde{f}$ es $\varphi_{k+1} = \varphi_k - \eta D^{-1/2}\nabla f(\theta_k)$; multiplicando por $D^{-1/2}$, $\theta_{k+1} = \theta_k - \eta D^{-1}\nabla f(\theta_k)$. Para la cuadrática, $\tilde{f}(\varphi) = \frac{1}{2}\varphi^\top D^{-1/2}QD^{-1/2}\varphi$. ∎

Si $Q = \operatorname{diag}(a_1, \dots, a_n)$ y se toma $D = Q$, el hessiano transformado es la identidad y $\kappa = 1$: el método converge en un paso con $\eta = 1$. Un buen preacondicionador diagonal iguala las curvaturas de las coordenadas. Pero solo puede corregir el mal condicionamiento alineado con los ejes; si los autovectores de Q están girados respecto de ellos, una matriz diagonal no basta (ejercicio 5.4). Los métodos de este tema estiman D a partir de los propios gradientes, sin calcular el hessiano.

5.2 AdaGrad y RMSProp

Definición 5.3 (AdaGrad). Con $s_0 = 0$ y $\varepsilon > 0$ pequeño, *AdaGrad* [7] acumula los cuadrados de los gradientes:

$$s_t = s_{t-1} + g_t^2, \qquad \theta_t = \theta_{t-1} - \eta\,\frac{g_t}{\sqrt{s_t} + \varepsilon}.$$

Proposición 5.4. *Si $\varepsilon = 0$ y una coordenada recibe un gradiente constante $g \neq 0$, su paso en la iteración t mide $\eta/\sqrt{t}$.*

Demostración. $s_t = tg^2$, luego $\eta\, g/\sqrt{tg^2} = \eta\ \mathrm{signo}(g)/\sqrt{t}$. ∎

El paso de AdaGrad no depende de la escala del gradiente y decrece como $1/\sqrt{t}$, un calendario incorporado que es adecuado en problemas convexos pero demasiado agresivo en el entrenamiento de redes profundas, donde la acumulación sin olvido acaba paralizando el método [9, §8.5.1].

Definición 5.5 (RMSProp). *RMSProp* [11] sustituye la suma por una media móvil exponencial de coeficiente $\rho \in (0, 1)$:

$$s_t = \rho\, s_{t-1} + (1-\rho)\, g_t^2, \qquad \theta_t = \theta_{t-1} - \eta\, \frac{g_t}{\sqrt{s_t} + \varepsilon}.$$

$\sqrt{s_t}$ estima la raíz de la media cuadrática reciente del gradiente de cada coordenada. Una coordenada con gradientes grandes recibe pasos pequeños, y viceversa. Por la proposición 4.2, con gradiente constante $s_t = (1-\rho^t)g^2$, de modo que el primer paso mide $\eta/\sqrt{1-\rho}$: unas 3,16 veces η con $\rho = 0{,}9$. Este sesgo inicial, producido por el arranque en $s_0 = 0$, es lo que corrige Adam.

5.3 Adam

Definición 5.6 (Adam). Sean $\eta > 0$, $\beta_1, \beta_2 \in [0, 1)$, $\varepsilon > 0$ y $m_0 = v_0 = 0$. Para $t = 1, 2, \ldots$, con g_t el gradiente (estocástico) en θ_{t-1}, *Adam* [13, algoritmo 1] realiza

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)\, g_t, \qquad \hat{m}_t = \frac{m_t}{1-\beta_1^t},$$
$$v_t = \beta_2 v_{t-1} + (1-\beta_2)\, g_t^2, \qquad \hat{v}_t = \frac{v_t}{1-\beta_2^t},$$
$$\theta_t = \theta_{t-1} - \eta\, \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}.$$

Los valores recomendados en el artículo original son $\eta = 10^{-3}$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ y $\varepsilon = 10^{-8}$.

Adam combina el momentum (primer momento m_t, una media móvil del gradiente) con la normalización de RMSProp (segundo momento v_t, una media móvil de su cuadrado). Las divisiones por $1-\beta_1^t$ y $1-\beta_2^t$ son la *corrección de sesgo* [13, §3].

Proposición 5.7 (Corrección de sesgo). *Si $g_t = g$ para todo t, entonces $m_t = (1-\beta_1^t)\, g$ y $\hat{m}_t = g$. Más en general, si los g_t son aleatorios con $\mathbb{E}[g_t] = \bar{g}$ para todo t, entonces $\mathbb{E}[m_t] = (1-\beta_1^t)\, \bar{g}$ y $\mathbb{E}[\hat{m}_t] = \bar{g}$. Los mismos resultados valen para v_t y $\hat{v}_t$ con g_t^2 y β_2.*

Demostración. Por la proposición 4.2, $m_t = (1-\beta_1)\sum_{s=1}^{t} \beta_1^{t-s} g_s$. Por linealidad de la esperanza,

$$\mathbb{E}[m_t] = (1-\beta_1)\sum_{s=1}^{t} \beta_1^{t-s}\, \bar{g} = (1-\beta_1)\cdot \frac{1-\beta_1^t}{1-\beta_1}\, \bar{g} = (1-\beta_1^t)\, \bar{g},$$

y dividiendo por $1-\beta_1^t$ se obtiene $\mathbb{E}[\hat{m}_t] = \bar{g}$. El caso constante es el caso particular determinista. El argumento para v_t es idéntico. ∎

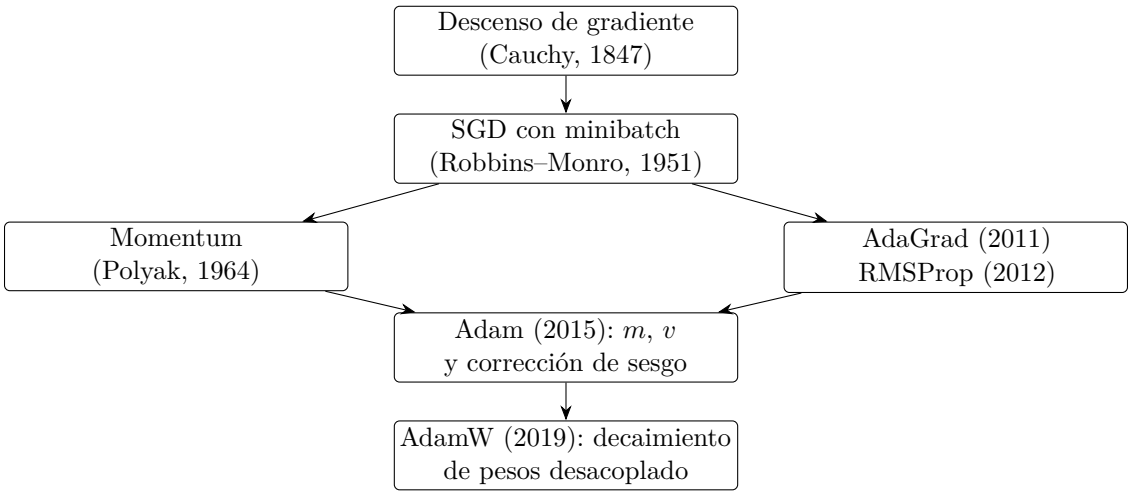


Figura 5.1: Genealogía de los optimizadores del módulo. AdamW, que se estudia en el tema 6, es el optimizador habitual en el preentrenamiento de los modelos de lenguaje abiertos documentados.

Sin corrección, m_t y v_t estarían sesgados hacia 0 al principio. Con $\beta_1 = 0{,}9$, $1-\beta_1^t$ vale 0,1 en $t=1$, 0,19 en $t=2$ y 0,6513 en $t=10$; con $\beta_2 = 0{,}999$, $1-\beta_2^t$ vale 0,001 en $t=1$ y solo 0,6323 en $t=1000$: el sesgo de v_t persiste durante unos miles de pasos.

Proposición 5.8 (Primer paso e invariancia de escala). *Sea $\varepsilon = 0$. (i) En $t=1$, cada coordenada con $g_1 \neq 0$ se desplaza exactamente $\eta\,\mathrm{signo}(g_1)$. (ii) Si todos los gradientes se multiplican por una constante $c>0$, los iterados de Adam no cambian.*

Demostración. (i) $\hat m_1 = g_1$ y $\hat v_1 = g_1^2$, luego $\hat m_1/\sqrt{\hat v_1} = g_1/|g_1|$. (ii) Se propone en el ejercicio 5.6. ∎

La invariancia de escala significa que η fija directamente el tamaño del paso en el espacio de parámetros: Kingma y Ba observan que el desplazamiento de cada coordenada queda aproximadamente acotado por η [13, §2.1]. Esto hace a Adam mucho menos sensible que el SGD a la escala de la pérdida y a las diferencias de escala entre capas. Con $\varepsilon > 0$ la invariancia es solo aproximada; ε evita divisiones por cero cuando $\hat v_t \approx 0$.

Ejemplo 5.9. Sea $\eta = 0{,}01$, $\theta_0 = 1$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, ε despreciable y gradientes $g_1 = 0{,}5$ y $g_2 = -0{,}1$:

t	m_t	v_t	$\hat m_t$	$\hat v_t$	$\eta\,\hat m_t/\sqrt{\hat v_t}$	θ_t
1	0,05	0,00025	0,5	0,25	0,01	0,99
2	0,035	0,00025975	0,1842	0,1299	0,005110	0,98489

El primer paso mide exactamente η. En el segundo, aunque el gradiente ha cambiado de signo, el primer momento conserva la inercia del primero y θ sigue disminuyendo, con un paso menor. Sin corrección de sesgo, el primer paso sería $\eta \cdot 0{,}05/\sqrt{0{,}00025} = \eta \cdot 0{,}1/\sqrt{0{,}001} \approx 3{,}162\,\eta$.

Observación 5.10 (Adam en los modelos de lenguaje). Los artículos de modelos de lenguaje abiertos documentan variantes de Adam con β_2 menor que el valor recomendado: LLaMA usa AdamW con $\beta_1 = 0{,}9$ y $\beta_2 = 0{,}95$ [23, §2.3]. Con $\beta_2 = 0{,}95$, el segundo momento promedia efectivamente unos $1/(1-\beta_2) = 20$ pasos en lugar de 1000, y se adapta antes a cambios

bruscos en la escala del gradiente. El precio de Adam es la memoria: guarda m y v, dos números adicionales por parámetro. En un modelo de $7 \cdot 10^9$ parámetros son $1{,}4 \cdot 10^{10}$ valores, 56 GB en precisión simple (módulo 17). Los optimizadores usados en Claude, Gemini y Grok no se han publicado.

Lecturas recomendadas para este tema

- Zhang *et al.* [24], §12.7 «Adagrad», §12.8 «RMSProp» y §12.10 «Adam».
- Goodfellow, Bengio y Courville [9], §8.5 «Algorithms with Adaptive Learning Rates» (§8.5.1–8.5.4).
- Kingma y Ba [13], §2 «Algorithm» y §3 «Initialization Bias Correction».
- Duchi, Hazan y Singer [7], artículo original de AdaGrad.

Ejercicios del tema 5

Ejercicio 5.1 ⋆ Justifique si es verdadera o falsa la afirmación: «si se multiplica la pérdida por 1000, el primer paso de Adam se multiplica por 1000». Compare con lo que ocurre en el SGD.

Ejercicio 5.2 ⋆ Calcule el primer paso de RMSProp, sin corrección de sesgo y con ε despreciable, para $\rho = 0{,}9$ y para $\rho = 0{,}999$, en función de η. Explique por qué este comportamiento motiva la corrección de sesgo de Adam.

Ejercicio 5.3 ⋆⋆ Aplique Adam con $\eta = 0{,}01$, $\theta_0 = 1$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ y ε despreciable a los gradientes $g_1 = 0{,}5$ y $g_2 = -0{,}1$. Calcule θ_1 y θ_2.

Ejercicio 5.4 ⋆⋆ Sea $f(x) = 0{,}1x_1^2 + 2x_2^2$. (a) Calcule el número de condición de su hessiano y el del hessiano preacondicionado por $D = \operatorname{diag}(\nabla^2 f)$. (b) Se gira el problema 45°: $g(y) = f(R^\top y)$ con R la rotación de ángulo $\pi/4$. Calcule el hessiano de g, su diagonal y el número de condición tras preacondicionar por esa diagonal. (c) ¿Qué concluye sobre los métodos adaptativos diagonales?

Fuente: adaptado de Zhang *et al.* [24], §12.7, ejercicios 2 y 4.

Ejercicio 5.5 ⋆⋆ Un modelo tiene $7 \cdot 10^9$ parámetros y se entrena con Adam guardando parámetros, gradientes y los dos momentos en precisión simple (4 bytes por número). Calcule la memoria total y la fracción que corresponde al estado del optimizador.

Ejercicio 5.6 ⋆⋆⋆ Demuestre la parte (ii) de la proposición 5.8: con $\varepsilon = 0$, si g_t se sustituye por cg_t con $c > 0$ para todo t, los iterados θ_t de Adam no cambian. ¿Es cierto también para $c < 0$? ¿Y para el SGD con momentum?

Ejercicio 5.7 ⋆⋆⋆ Demuestre que, con $\varepsilon \to 0$, Adam con corrección de sesgo equivale a usar m_t y v_t sin corregir con la tasa de aprendizaje $\eta_t = \eta\sqrt{1-\beta_2^t}/(1-\beta_1^t)$. Calcule η_t/η para $t = 1$, 2, 10 y 1000 con $\beta_1 = 0{,}9$ y $\beta_2 = 0{,}999$, y reproduzca el paso de $t = 2$ del ejercicio 5.3.

Fuente: adaptado de Zhang *et al.* [24], §12.10, ejercicio 2.

Tema 6

Regularización y calendarios de la tasa de aprendizaje

Este tema completa la receta de optimización de los modelos de lenguaje actuales con dos ingredientes que no cambian la dirección del paso, sino su forma y su tamaño: el decaimiento de pesos y el calendario de la tasa de aprendizaje. Se estudia primero la regularización L^2 y su relación con el decaimiento de pesos, que es una equivalencia para el SGD pero no para Adam; de ahí surge AdamW. Después se definen el calentamiento lineal y el decaimiento coseno y se justifican con los resultados de los temas 3 y 5. Se sigue [9, §7.1], [24, §12.11] y los artículos [16, 15, 10].

6.1 Regularización L^2

Definición 6.1 (Regularización L^2). Sea $\lambda > 0$. La pérdida *regularizada* con penalización L^2 es

$$J_\lambda(\theta) = J(\theta) + \frac{\lambda}{2}\|\theta\|^2.$$

Proposición 6.2 (Encogimiento). *Un paso de descenso de gradiente sobre J_λ es*

$$\theta_{k+1} = (1 - \eta\lambda)\,\theta_k - \eta\,\nabla J(\theta_k).$$

Demostración. $\nabla J_\lambda(\theta) = \nabla J(\theta) + \lambda\theta$, luego $\theta_k - \eta\nabla J_\lambda(\theta_k) = \theta_k - \eta\lambda\theta_k - \eta\nabla J(\theta_k)$. ■

Cada paso multiplica los pesos por $1-\eta\lambda < 1$ antes de aplicar el gradiente: de ahí el nombre de *decaimiento de pesos* (*weight decay*).

Proposición 6.3 (Efecto sobre el minimizador). *Sea $J(\theta) = \frac{1}{2}(\theta - c)^\top Q(\theta - c)$ con $Q = \operatorname{diag}(a_1, \dots, a_n)$, $a_i > 0$. El minimizador de J_λ es*

$$\theta_i^* = \frac{a_i}{a_i + \lambda}\, c_i, \qquad i = 1, \dots, n.$$

Demostración. J_λ es fuertemente convexa, y su gradiente se anula si y solo si $a_i(\theta_i - c_i) + \lambda\theta_i = 0$ para cada i, es decir, $\theta_i = a_i c_i/(a_i + \lambda)$. ■

La regularización encoge hacia 0 cada coordenada en el factor $a_i/(a_i + \lambda)$: apenas afecta a las direcciones de curvatura grande ($a_i \gg \lambda$), en las que la pérdida es sensible, y anula casi por completo las de curvatura pequeña ($a_i \ll \lambda$) [9, §7.1.1]. Por ejemplo, con $n = 1$, $a = 2$, $c = 3$ y $\lambda = 1$, el minimizador pasa de 3 a $6/3 = 2$.

Observación 6.4 (Interpretación bayesiana). Si J es la log-verosimilitud negativa total de los datos y se adopta sobre θ una distribución a priori gaussiana $\mathcal{N}(0, \lambda^{-1}I)$, entonces $-\ln p(\theta) = \frac{\lambda}{2}\|\theta\|^2 + \text{cte}$, y minimizar J_λ equivale a maximizar la distribución a posteriori (estimación MAP; módulo 5).

6.2 Decaimiento de pesos desacoplado: AdamW

Para el SGD, regularizar con L^2 y encoger los pesos en cada paso es lo mismo (proposición 6.2). Para un método preacondicionado no lo es [16, §2].

Observación 6.5 (Adam con L^2). Si se aplica Adam a J_λ, el término $\lambda\theta$ se suma al gradiente antes de calcular m_t y v_t, y queda dividido por $\sqrt{\hat{v}_t} + \varepsilon$. Cuando la normalización está dominada por ∇J, la contribución del término de regularización al paso de la coordenada i es aproximadamente

$$\frac{\eta\lambda\,\theta_i}{\sqrt{\hat{v}_{t,i}} + \varepsilon},$$

que depende de la escala del gradiente de esa coordenada, mientras que en el SGD es $\eta\lambda\theta_i$ para todas.

Las coordenadas con gradientes grandes ($\hat{v}_{t,i}$ grande) apenas se regularizan, y las de gradientes pequeños se regularizan en exceso. Loshchilov y Hutter [16] propusieron aplicar el decaimiento fuera de la normalización.

Definición 6.6 (AdamW). Con las cantidades $\hat{m}_t$ y $\hat{v}_t$ de la definición 5.6, calculadas con el gradiente de J sin regularizar, *AdamW* [16, algoritmo 2] realiza

$$\theta_t = \theta_{t-1} - \eta_t\Big(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} + \lambda\,\theta_{t-1}\Big),$$

donde η_t es la tasa de aprendizaje del calendario y λ el coeficiente de decaimiento de pesos.

En AdamW todos los pesos se encogen en el mismo factor $1 - \eta_t\lambda$, con independencia de sus gradientes. El cuadro 6.1 compara ambos métodos con $\eta = 10^{-3}$, $\lambda = 0{,}1$ y $\theta = 1$.

Cuadro 6.1: Encogimiento de un peso $\theta = 1$ en un paso, con $\eta = 10^{-3}$ y $\lambda = 0{,}1$.

$\hat{v}$ de la coordenada	Adam con L^2 ($\eta\lambda\theta/\sqrt{\hat{v}}$)	AdamW ($\eta\lambda\theta$)
10^{-4}	0,01	0,0001
1	0,0001	0,0001

Observación 6.7 (Convenios). En [16], el decaimiento de pesos del SGD se escribe $\theta_{t+1} = (1 - \lambda')\theta_t - \alpha\nabla J(\theta_t)$, sin multiplicar λ' por la tasa α; con ese convenio, la equivalencia con L^2 exige $\lambda = \lambda'/\alpha$ [16, proposición 1]. Aquí se sigue el convenio de la definición 6.6, en el que el decaimiento por paso es $\eta_t\lambda$ y sigue al calendario. La proposición 2 de [16] demuestra que, para un preacondicionador que no sea múltiplo de la identidad, no existe ningún coeficiente L^2 que reproduzca el decaimiento desacoplado.

Ejemplo 6.8 (Escala de un preentrenamiento). Con $\eta = 3 \cdot 10^{-4}$ y $\lambda = 0{,}1$, cada paso multiplica los pesos por $1 - 3 \cdot 10^{-5} = 0{,}99997$. En 10^5 pasos, si el gradiente no actuara, quedarían multiplicados por $(1 - 3 \cdot 10^{-5})^{10^5} \approx e^{-3} \approx 0{,}0498$. El gradiente compensa este

encogimiento en los pesos útiles; el resultado es un equilibrio entre ajuste y tamaño de los pesos.

6.3 Calendarios de la tasa de aprendizaje

La tasa de aprendizaje es el hiperparámetro más influyente: si es demasiado grande, el método diverge (teorema 2.8); si es demasiado pequeña, avanza despacio. Además, con gradientes estocásticos, un paso constante deja un suelo de ruido proporcional a η (proposición 3.9). Por eso no se usa un η fijo, sino un *calendario* η_t [24, §12.11].

Definición 6.9 (Calentamiento lineal y decaimiento coseno). Sean $0 \le \eta_{\min} < \eta_{\max}$, un número de pasos de calentamiento $W \ge 1$ y un número total de pasos $T > W$. El calendario de *calentamiento lineal y decaimiento coseno* es

$$\eta(t) = \begin{cases} \eta_{\max}\,\dfrac{t}{W}, & 0 \le t < W, \\[2ex] \eta_{\min} + \dfrac{\eta_{\max} - \eta_{\min}}{2}\left(1 + \cos\left(\pi\,\dfrac{t - W}{T - W}\right)\right), & W \le t \le T. \end{cases}$$

Proposición 6.10 (Propiedades). *El calendario de la definición 6.9 es continuo en $t = W$, vale $\eta_{\max}$ en $t = W$ y $\eta_{\min}$ en $t = T$, es estrictamente decreciente en $[W, T]$ y en el punto medio del tramo coseno vale $(\eta_{\max} + \eta_{\min})/2$.*

Demostración. Por la izquierda, $\eta_{\max} t/W \to \eta_{\max}$ cuando $t \to W$; por la derecha, en $t = W$ el coseno vale $\cos 0 = 1$ y $\eta(W) = \eta_{\min} + (\eta_{\max} - \eta_{\min}) = \eta_{\max}$. En $t = T$, $\cos \pi = -1$ y $\eta(T) = \eta_{\min}$. En $[W, T]$, el argumento $\pi(t - W)/(T - W)$ recorre $[0, \pi]$, donde el coseno es estrictamente decreciente. En el punto medio el argumento es $\pi/2$, $\cos(\pi/2) = 0$ y $\eta = \eta_{\min} + (\eta_{\max} - \eta_{\min})/2 = (\eta_{\max} + \eta_{\min})/2$. ∎

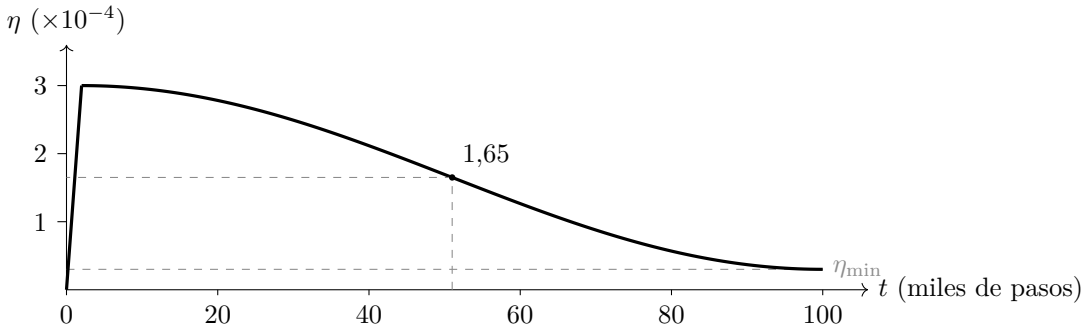


Figura 6.1: Calendario de la definición 6.9 con $\eta_{\max} = 3 \cdot 10^{-4}$, $\eta_{\min} = 3 \cdot 10^{-5}$, $W = 2000$ y $T = 10^5$. En el punto medio del tramo coseno, $t = 51\,000$, la tasa es $(\eta_{\max} + \eta_{\min})/2 = 1{,}65 \cdot 10^{-4}$.

Ejemplo 6.11. Con los parámetros de la figura 6.1:

t (miles de pasos)	0	1	2	26,5	51	75,5	100
η ($\times 10^{-4}$)	0	1,5	3	2,605	1,65	0,6954	0,3

Calentamiento. Al principio del entrenamiento, los gradientes son grandes e irregulares y los momentos de Adam se han estimado con muy pocos datos. Una tasa grande desde el primer paso puede hacer divergir la pérdida. Subir η gradualmente da tiempo a que $\hat{m}_t$ y $\hat{v}_t$ se estabilicen; el calentamiento se popularizó para entrenar con lotes grandes [10]. El ejercicio 5.7 muestra que la propia corrección de sesgo de Adam actúa como un calentamiento implícito.

Decaimiento. Por la proposición 3.9, el exceso de pérdida estacionario del SGD es proporcional a η; reducir η al final permite que los parámetros se asienten. El decaimiento coseno procede del método SGDR de Loshchilov y Hutter [15], que lo combinaba con reinicios periódicos; en el preentrenamiento se usa un único ciclo.

Observación 6.12 (La receta de los modelos de lenguaje abiertos). LLaMA documenta exactamente esta receta: AdamW con $\beta_1 = 0{,}9$, $\beta_2 = 0{,}95$, decaimiento de pesos $\lambda = 0{,}1$, recorte del gradiente a norma 1, 2000 pasos de calentamiento y decaimiento coseno hasta el 10 % de la tasa máxima [23, §2.3]. Es la misma estructura que la del ejemplo 6.11. Como se indicó en el tema 5, Anthropic, Google y xAI no han publicado los calendarios ni los optimizadores de Claude, Gemini y Grok.

Lecturas recomendadas para este tema

- Goodfellow, Bengio y Courville [9], §7.1 «Parameter Norm Penalties» y §7.1.1 «L^2 Parameter Regularization».
- Zhang *et al.* [24], §12.11 «Learning Rate Scheduling», en particular §12.11.3.3 «Cosine Scheduler» y §12.11.3.4 «Warmup».
- Loshchilov y Hutter [16], §2 «Decoupling the Weight Decay from the Gradient-based Update».
- Loshchilov y Hutter [15], calendario coseno con reinicios.
- Touvron *et al.* [23], §2.3 «Optimizer».

Ejercicios del tema 6

Ejercicio 6.1 ⋆ ¿Qué problema resuelve el calentamiento y cuál el decaimiento coseno? Relacione cada uno con un resultado de los temas 3 y 5.

Ejercicio 6.2 ⋆⋆ Con $\eta_{\max} = 6 \cdot 10^{-4}$, $\eta_{\min} = 6 \cdot 10^{-5}$, $W = 1000$ y $T = 11\,000$, calcule $\eta(t)$ para $t = 500$, 6000 y 8500.

Ejercicio 6.3 ⋆⋆ Con $\eta = 10^{-3}$, $\lambda = 0{,}1$ y $\theta = 1$, calcule cuánto encoge el peso en un paso con Adam y regularización L^2 si $\hat{v} = 10^{-4}$ (aproximación de la observación 6.5), y con AdamW. ¿Cuál es el cociente entre ambos?

Ejercicio 6.4 ⋆⋆ (a) Si el producto $\eta\lambda$ vale 10^{-4} en cada paso, ¿cuántos pasos tarda el decaimiento de pesos, actuando solo, en reducir un peso a la mitad? (b) Compruebe que con $\eta = 3 \cdot 10^{-4}$ y $\lambda = 0{,}1$ un peso queda multiplicado por aproximadamente 0,05 tras 10^5 pasos.

Ejercicio 6.5 ⋆⋆⋆ Sea $J_\lambda(w) = \frac{a}{2}(w - c)^2 + \frac{\lambda}{2}w^2$, con $a > 0$ y $\lambda \geq 0$. Halle su minimizador, demuestre que un paso de descenso de gradiente es $w \leftarrow (1 - \eta\lambda)w - \eta a(w - c)$ y evalúe el minimizador con $a = 2$, $c = 3$ y $\lambda = 2$. ¿Para qué η converge el método?

Ejercicio 6.6 ⋆⋆⋆ Se considera el calendario polinómico $\eta_t = \eta_0\, t^{-\alpha}$, $t \geq 1$, con $\eta_0 > 0$ y $\alpha > 0$. (a) Demuestre que cumple las condiciones de Robbins–Monro del corolario 3.8 si y solo si $\frac{1}{2} < \alpha \leq 1$. (b) Para $\alpha = \frac{1}{2}$, demuestre que $\sum_{t=1}^{T} \eta_t \geq 2\eta_0(\sqrt{T+1} - 1)$ y $\sum_{t=1}^{T} \eta_t^2 \leq \eta_0^2(1 + \ln T)$, y deduzca que la cota del teorema 3.6 es $O(\ln T / \sqrt{T})$.

Fuente: adaptado de Zhang *et al.* [24], §12.11, ejercicio 2 (efecto del exponente de decaimiento en la convergencia).

Apéndice A

Soluciones de los ejercicios

Cada solución se presenta en cinco partes: datos, planteamiento, desarrollo, resultado y comprobación. En los pasos intermedios se redondea a cuatro cifras significativas salvo que se indique otra cosa; los resultados exactos se dan como fracción cuando existe.

A.1 Tema 1

Solución del ejercicio 1.1

Datos. $f(x) = x^4$, $f'(x) = 4x^3$, $f''(x) = 12x^2$.

Planteamiento. usar las caracterizaciones de segundo orden de la convexidad y de la convexidad fuerte (definición 1.5) y la definición de L-suavidad (definición 1.6).

Desarrollo.

1. (a) $f''(x) = 12x^2 \geq 0$ para todo x: f es convexa.
2. (b) La convexidad fuerte exigiría $f''(x) \geq \mu > 0$ para todo x, pero $f''(0) = 0$. No es fuertemente convexa.
3. (c) $|f'(x) - f'(0)| = 4|x|^3$, y el cociente $4|x|^3/|x| = 4x^2$ no está acotado en $\mathbb{R}$. No existe L global.
4. Unicidad: $f(x) > 0 = f(0)$ si $x \neq 0$, luego 0 es el único minimizador. La convexidad fuerte es suficiente para la unicidad, no necesaria: basta la convexidad estricta, que f sí tiene.

Resultado. **convexa (incluso estrictamente), no fuertemente convexa y no L-suave en** $\mathbb{R}$; no hay contradicción.

Comprobación. cerca del mínimo la curvatura es nula, así que el descenso de gradiente con paso fijo converge solo sublinealmente: con η pequeño, $x_{k+1} = x_k(1-4\eta x_k^2)$, cuyo factor tiende a 1.

Solución del ejercicio 1.2

Datos. $f(x, y) = x^2 - y^2$; punto inicial $(1, 0)$ o $(1, \delta)$; $\eta = 0{,}1$; $\delta = 10^{-6}$.

Planteamiento. clasificar con el hessiano (proposición 1.12) y seguir la iteración por coordenadas (ejemplo 1.13).

Desarrollo.

1. $\nabla f = (2x, -2y)$ se anula en $(0, 0)$.
2. $\nabla^2 f = \operatorname{diag}(2, -2)$, con autovalores de signos opuestos: *punto de silla.*
3. Iteración: $x_{k+1} = (1 - 2\eta)x_k$, $y_{k+1} = (1 + 2\eta)y_k$.

4. Con $y_0 = 0$: $y_k = 0$ para todo k. Con $0 < \eta < 1$, $|1 - 2\eta| < 1$ y $x_k \to 0$: el método converge a la silla.
5. Con $y_0 = \delta$: $y_k = (1 + 2\eta)^k \delta = 1{,}2^k \cdot 10^{-6}$. Para $k = 50$, $1{,}2^{50} \approx 9100$ e $y_{50} \approx 9{,}1 \cdot 10^{-3}$.

Resultado. $(0, 0)$ **es un punto de silla**; desde $(1, 0)$ el método converge a él porque la coordenada inestable es exactamente nula; con $\delta = 10^{-6}$, $y_{50} \approx 9{,}1 \cdot 10^{-3}$ y sigue creciendo.

Comprobación. $\ln(1{,}2^{50}) = 50 \cdot 0{,}1823 = 9{,}116$ y $e^{9{,}116} \approx 9100$.

Solución del ejercicio 1.3

Datos. $Q = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, $c = (-3, 0)^\top$, $b = 1$.

Planteamiento. Q tiene autovalores 1 y 3, luego $Q \succ 0$ y se aplica la proposición 1.10.

Desarrollo.

1. $\det Q = 4 - 1 = 3$; $Q^{-1} = \frac{1}{3}\begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$.
2. $x^* = -Q^{-1}c = -\frac{1}{3}\big(2 \cdot (-3) + (-1) \cdot 0;\ (-1) \cdot (-3) + 2 \cdot 0\big) = -\frac{1}{3}(-6;\ 3) = (2;\ -1)$.
3. $c^\top Q^{-1} c = -c^\top x^* = -\big((-3) \cdot 2 + 0 \cdot (-1)\big) = 6$.
4. $h^* = b - \frac{1}{2} c^\top Q^{-1} c = 1 - 3 = -2$.

Resultado. $x^* = (2, -1)$ **y** $h(x^*) = -2$**.**

Comprobación. $\frac{1}{2} x^{*\top} Q x^* = \frac{1}{2}(2 \cdot 4 + 2 \cdot 2 \cdot (-1) + 2 \cdot 1) = \frac{1}{2} \cdot 6 = 3$; $x^{*\top} c = -6$; $h = 3 - 6 + 1 = -2$. Además $Qx^* + c = (4 - 1 - 3;\ 2 - 2 + 0) = (0;\ 0)$.

Solución del ejercicio 1.4

Datos. $f(x, y) = x^2 + 2xy + 5y^2$.

Planteamiento. $f = \frac{1}{2}\theta^\top Q \theta$ con Q el hessiano; $\mu = \lambda_{\min}(Q)$ y $L = \lambda_{\max}(Q)$ (ejemplo 1.7).

Desarrollo.

1. $\partial^2 f / \partial x^2 = 2$, $\partial^2 f / \partial x \partial y = 2$, $\partial^2 f / \partial y^2 = 10$: $Q = \begin{pmatrix} 2 & 2 \\ 2 & 10 \end{pmatrix}$.
2. Traza 12 y determinante $20 - 4 = 16$. Ecuación característica: $\lambda^2 - 12\lambda + 16 = 0$.
3. $\lambda = 6 \pm \sqrt{36 - 16} = 6 \pm 2\sqrt{5}$: $\lambda_{\min} = 6 - 2\sqrt{5} \approx 1{,}528$ y $\lambda_{\max} = 6 + 2\sqrt{5} \approx 10{,}47$.
4. Ambos son positivos, luego $Q \succ 0$ y f es μ-fuertemente convexa con $\mu \approx 1{,}528$, y L-suave con $L \approx 10{,}47$.
5. $\kappa = \dfrac{6 + 2\sqrt{5}}{6 - 2\sqrt{5}} = \dfrac{(3 + \sqrt{5})^2}{9 - 5} = \dfrac{14 + 6\sqrt{5}}{4} = 3{,}5 + 1{,}5\sqrt{5} \approx 6{,}854$.

Resultado. $\mu = 6 - 2\sqrt{5} \approx 1{,}528$**,** $L = 6 + 2\sqrt{5} \approx 10{,}47$ **y** $\kappa \approx 6{,}854$**.**

Comprobación. $\mu + L = 12$ (traza) y $\mu L = 36 - 20 = 16$ (determinante).

Solución del ejercicio 1.5

Datos. f, g convexas en $\mathbb{R}^n$; $h = \max\{f, g\}$.

Planteamiento. aplicar la definición de convexidad a h y acotar cada función por h.

Desarrollo.

1. Sean x, y y $t \in [0,1]$, y $z = tx+(1-t)y$. Por la convexidad de f, $f(z) \le tf(x)+(1-t)f(y)$.
2. Como $f \le h$ y $t, 1-t \ge 0$, $tf(x) + (1-t)f(y) \le th(x) + (1-t)h(y)$. Luego $f(z) \le th(x) + (1-t)h(y)$.
3. Del mismo modo, $g(z) \le th(x) + (1-t)h(y)$.
4. Por tanto, $h(z) = \max\{f(z), g(z)\} \le th(x) + (1-t)h(y)$: h es convexa.
5. (b) Contraejemplo en $\mathbb{R}$: $f(x) = (x-1)^2$ y $g(x) = (x+1)^2$. Sea $m = \min\{f, g\}$. Entonces $m(1) = m(-1) = 0$ y $m(0) = 1$.
6. Con $x = 1$, $y = -1$ y $t = \frac{1}{2}$: $m(0) = 1 > \frac{1}{2}m(1) + \frac{1}{2}m(-1) = 0$. La desigualdad de convexidad falla.

Resultado. **el máximo de funciones convexas es convexo; el mínimo, en general, no.**

Comprobación. la gráfica de m tiene forma de «W», con dos mínimos locales en ± 1; una función convexa no puede tener dos mínimos locales separados por un punto de valor mayor (teorema 1.9).

Solución del ejercicio 1.6

Datos. f diferenciable, μ-fuertemente convexa, con minimizador θ^*.

Planteamiento. aplicar la definición 1.5 en el punto θ^*, donde $\nabla f(\theta^*) = 0$ (teorema 1.8).

Desarrollo.

1. (a) Con $x = \theta^*$ e $y = \theta$: $f(\theta) \ge f(\theta^*) + 0 + \frac{\mu}{2}\|\theta - \theta^*\|^2$.
2. (b) Si θ' es otro minimizador, $f(\theta') = f^*$ y (a) da $0 \ge \frac{\mu}{2}\|\theta' - \theta^*\|^2$, luego $\theta' = \theta^*$.
3. (c) Se escribe la definición 1.5 con $x = \theta$, $y = \theta^*$: $f^* \ge f(\theta)+\nabla f(\theta)^\top(\theta^*-\theta)+\frac{\mu}{2}\|\theta-\theta^*\|^2$.
4. Se suma con la desigualdad de (a), $f(\theta) \ge f^* + \frac{\mu}{2}\|\theta - \theta^*\|^2$: queda $0 \ge \nabla f(\theta)^\top(\theta^* - \theta) + \mu\|\theta - \theta^*\|^2$, es decir, $\mu\|\theta - \theta^*\|^2 \le \nabla f(\theta)^\top(\theta - \theta^*)$.
5. Por Cauchy–Schwarz, $\nabla f(\theta)^\top(\theta - \theta^*) \le \|\nabla f(\theta)\|\,\|\theta - \theta^*\|$. Dividiendo por $\|\theta - \theta^*\|$ (si es no nulo; si es nulo, la desigualdad es trivial), $\mu\|\theta - \theta^*\| \le \|\nabla f(\theta)\|$.

Resultado. **se cumplen (a), (b) y (c)**: la función crece al menos cuadráticamente lejos del óptimo, y el gradiente, al menos linealmente.

Comprobación. para $f(\theta) = \frac{\mu}{2}\|\theta\|^2$, con $\theta^* = 0$, las tres desigualdades son igualdades: $f - f^* = \frac{\mu}{2}\|\theta\|^2$ y $\|\nabla f\| = \mu\|\theta\|$.

A.2 Tema 2

Solución del ejercicio 2.1

Datos. f con minimizador θ^*, constantes μ, L; se minimiza cf con $c > 0$.

Planteamiento. $\nabla(cf) = c\nabla f$ y $\nabla^2(cf) = c\nabla^2 f$.

Desarrollo.

1. Minimizador: $cf(\theta) \ge cf(\theta^*)$ para todo θ, luego el minimizador no cambia.

2. Las constantes pasan a ser $c\mu$ y cL: el paso máximo estable, $2/L$ en una cuadrática, pasa a ser $2/(cL)$.
3. $\kappa = cL/(c\mu) = L/\mu$: el número de condición no cambia.
4. Con paso η' sobre cf: $\theta_{k+1} = \theta_k - \eta' c\nabla f(\theta_k)$. Coincide con el descenso sobre f con paso η si y solo si $\eta' = \eta/c$.

Resultado. **el minimizador y κ no cambian; el paso máximo se divide por c; con η/c se reproducen los mismos iterados.**

Comprobación. contrasta con Adam, cuyos iterados no cambian aunque se mantenga el mismo η (proposición 5.8).

Solución del ejercicio 2.2

Datos. $f(x) = 3x^2$, $x_0 = 2$, $\eta = 0{,}1$.

Planteamiento. $f = \frac{a}{2}x^2$ con $a = 6$; cada paso multiplica x por $1 - \eta a$ (ejemplo 2.7).

Desarrollo.

1. $f'(x) = 6x$; factor $1 - 0{,}1 \cdot 6 = 0{,}4$.
2. $x_1 = 0{,}4 \cdot 2 = 0{,}8$; $x_2 = 0{,}4 \cdot 0{,}8 = 0{,}32$; $x_3 = 0{,}4 \cdot 0{,}32 = 0{,}128$.
3. Convergencia: $|1 - 6\eta| < 1 \iff 0 < \eta < 2/6 = 1/3$.

Resultado. $x_1 = 0{,}8$**,** $x_2 = 0{,}32$**,** $x_3 = 0{,}128$**; converge si y solo si** $0 < \eta < 1/3 \approx 0{,}3333$**.** Con $\eta = 1/3$ el factor es -1 y el iterado oscila entre ± 2.

Comprobación. $x_3 = 2 \cdot 0{,}4^3 = 2 \cdot 0{,}064 = 0{,}128$. Con $\eta = 0{,}4$ el factor sería $1 - 2{,}4 = -1{,}4$, de módulo mayor que 1.

Solución del ejercicio 2.3

Datos. $f(x, y) = x^2 + 5y^2$, $\theta_0 = (1, 1)$, $\eta = 1/6$.

Planteamiento. $Q = \mathrm{diag}(2, 10)$; cada coordenada se multiplica por $1 - \eta\lambda_i$ (teorema 2.8).

Desarrollo.

1. Factor en x: $1 - \frac{1}{6} \cdot 2 = \frac{2}{3}$. Factor en y: $1 - \frac{1}{6} \cdot 10 = -\frac{2}{3}$.
2. $\theta_1 = \left(\frac{2}{3}; -\frac{2}{3}\right)$, $\theta_2 = \left(\frac{4}{9}; \frac{4}{9}\right)$, $\theta_3 = \left(\frac{8}{27}; -\frac{8}{27}\right) \approx (0{,}2963; -0{,}2963)$.
3. Normas: $\|\theta_0\| = \sqrt{2} \approx 1{,}414$; $\|\theta_1\| = \frac{2}{3}\sqrt{2} \approx 0{,}9428$; $\|\theta_2\| = \frac{4}{9}\sqrt{2} \approx 0{,}6285$; $\|\theta_3\| = \frac{8}{27}\sqrt{2} \approx 0{,}4190$.
4. Cociente entre normas consecutivas: $\frac{2}{3}$.
5. Teorema: $\mu = 2$, $L = 10$, $\kappa = 5$; $\eta^* = 2/12 = 1/6$ y $\rho = (5 - 1)/(5 + 1) = \frac{2}{3}$.

Resultado. $\theta_3 = (8/27; -8/27)$ **y la norma se multiplica por** $2/3$ **en cada paso**, que es $(\kappa - 1)/(\kappa + 1)$ porque $\eta = 1/6$ es el paso óptimo.

Comprobación. $f(\theta_3) = 6 \cdot (8/27)^2 = 384/729 \approx 0{,}5267$ y $f(\theta_3)/f(\theta_0) = 0{,}5267/6 \approx 0{,}08779 = (2/3)^6$. La coordenada y cambia de signo en cada paso, como en la figura 2.1.

Solución del ejercicio 2.4

Datos. $f = \frac{1}{2}(x^2 + 25y^2)$, $Q = \mathrm{diag}(1, 25)$, $\theta_0 = (1, 1)$, $\epsilon = 10^{-3}$.

Planteamiento. teorema 2.8 y corolario 2.11: $\eta^* = 2/(\mu+L)$, $\rho = (\kappa-1)/(\kappa+1)$, $k = \lceil \ln\epsilon / \ln\rho \rceil$.

Desarrollo.

1. $\mu = 1$, $L = 25$, $\kappa = 25$.
2. $\eta^* = 2/26 = 1/13 \approx 0{,}07692$; $\rho = 24/26 = 12/13 \approx 0{,}9231$.
3. $\ln 10^{-3} = -6{,}908$; $\ln(12/13) = -0{,}08004$; $6{,}908/0{,}08004 \approx 86{,}3$, luego **87** iteraciones.
4. Momentum: $\sqrt{\kappa} = 5$, $\rho = 4/6 = 2/3$, $\ln(2/3) = -0{,}4055$; $6{,}908/0{,}4055 \approx 17{,}04$, luego **18** iteraciones.
5. Factores con η^*: $1 - \frac{1}{13} = \frac{12}{13}$ en x y $1 - \frac{25}{13} = -\frac{12}{13}$ en y.
6. $\theta_1 = \left(\frac{12}{13}; -\frac{12}{13}\right) \approx (0{,}9231; -0{,}9231)$ y $\theta_2 = \left(\frac{144}{169}; \frac{144}{169}\right) \approx (0{,}8521; 0{,}8521)$.

Resultado. $\kappa = 25$**,** $\eta^* = 1/13$**,** $\rho = 12/13$**; 87 iteraciones con descenso de gradiente frente a 18 con momentum.**

Comprobación. $\|\theta_1\|/\|\theta_0\| = 12/13 = \rho$. El cociente de iteraciones, $87/18 \approx 4{,}8$, es próximo a $\sqrt{\kappa} = 5$.

Solución del ejercicio 2.5

Datos. $F(x, y) = y^2 + (y - x)^2$, $(x_0, y_0) = (1, 1)$, pasos $s = 1/2$ y $s = 1/4$.

Planteamiento. calcular el gradiente, iterar y analizar la estabilidad con $s < 2/\lambda_{\max}$ (teorema 2.8).

Desarrollo.

1. $\partial F/\partial x = -2(y - x)$; $\partial F/\partial y = 2y + 2(y - x) = 4y - 2x$. En $(1, 1)$: $\nabla F = (0; 2)$.
2. $s = \frac{1}{2}$. Paso 1: $(1, 1) - \frac{1}{2}(0, 2) = (1, 0)$, $F = 0 + 1 = 1$.
3. Paso 2: $\nabla F(1, 0) = (2; -2)$; $(1, 0) - \frac{1}{2}(2, -2) = (0, 1)$, $F = 1 + 1 = 2$.
4. Paso 3: $\nabla F(0, 1) = (-2; 4)$; $(0, 1) - \frac{1}{2}(-2, 4) = (1, -1)$, $F = 1 + 4 = 5$. F crece: el método diverge.
5. (b) $\nabla^2 F = \begin{pmatrix} 2 & -2 \\ -2 & 4 \end{pmatrix}$, traza 6, determinante 4: $\lambda = 3 \pm \sqrt{5} \approx 0{,}7639$ y $5{,}236$. Límite: $2/5{,}236 \approx 0{,}3820 < 0{,}5$. El factor de la dirección rígida es $1 - 0{,}5 \cdot 5{,}236 = -1{,}618$, de módulo mayor que 1.
6. (c) $s = \frac{1}{4}$. Paso 1: $(1, 1) - \frac{1}{4}(0, 2) = (1; 0{,}5)$, $F = 0{,}25 + 0{,}25 = 0{,}5$.
7. Paso 2: $\nabla F(1; 0{,}5) = (1; 0)$; nuevo punto $(0{,}75; 0{,}5)$, $F = 0{,}25 + 0{,}0625 = 0{,}3125$.
8. Paso 3: $\nabla F(0{,}75; 0{,}5) = (0{,}5; 0{,}5)$; nuevo punto $(0{,}625; 0{,}375)$, $F = 0{,}1406 + 0{,}0625 = 0{,}2031$.

Resultado. **con** $s = 1/2$**,** $F = 1$**; 2; 5: diverge. Con** $s = 1/4$**,** $F = 0{,}5$**; 0,3125; 0,2031: converge.**

Comprobación. con $s = \frac{1}{4}$, los factores son $1 - 0{,}25 \cdot 0{,}7639 = 0{,}8090$ y $1 - 0{,}25 \cdot 5{,}236 = -0{,}3090$, ambos de módulo menor que 1.

Solución del ejercicio 2.6

Datos. $\nabla^2 f(1, 1) = \begin{pmatrix} 802 & -400 \\ -400 & 200 \end{pmatrix}$, $\eta = 10^{-3}$, $\epsilon = 10^{-3}$.

Planteamiento. autovalores de una matriz 2×2 con la traza y el determinante; $\kappa = \lambda_{\max}/\lambda_{\min}$, paso máximo $2/\lambda_{\max}$.

Desarrollo.

1. Traza: $802 + 200 = 1002$. Determinante: $802 \cdot 200 - 400^2 = 160\,400 - 160\,000 = 400$.
2. $\lambda^2 - 1002\lambda + 400 = 0$; discriminante $1002^2 - 1600 = 1\,002\,404$, de raíz $\approx 1001{,}2$.
3. $\lambda_{\max} = (1002 + 1001{,}2)/2 \approx 1001{,}6$. Para el menor se usa el producto, que evita restar números casi iguales: $\lambda_{\min} = 400/1001{,}6 \approx 0{,}3994$.
4. $\kappa \approx 1001{,}6/0{,}3994 \approx 2508$.
5. Paso máximo: $2/1001{,}6 \approx 1{,}997 \cdot 10^{-3}$.
6. Con $\eta = 10^{-3}$, el factor en la dirección plana es $1 - 10^{-3} \cdot 0{,}3994 = 0{,}9996$. Iteraciones: $\ln 10^{-3}/\ln 0{,}9996 \approx -6{,}908/(-3{,}995 \cdot 10^{-4}) \approx 1{,}73 \cdot 10^4$.

Resultado. $\lambda \approx 0{,}3994$ **y** $1001{,}6$**;** $\kappa \approx 2508$**; paso máximo** $\approx 0{,}002$**; unas** $17\,300$ **iteraciones** para reducir el error en 10^{-3} en la dirección plana.

Comprobación. $\lambda_{\min} + \lambda_{\max} \approx 1002$ (traza). Es coherente con que el descenso de gradiente no llegue a $f < 10^{-4}$ en 5000 iteraciones (ejemplo 2.12).

Solución del ejercicio 2.7

Datos. $f(\theta) = \frac{1}{2}\theta^\top Q\theta$, Q simétrica con autovalores $0 < \mu = \lambda_1 \le \cdots \le \lambda_n = L$.

Planteamiento. diagonalizar la iteración lineal $\theta_{k+1} = (I - \eta Q)\theta_k$ y estudiar $\rho(\eta) = \max_i |1 - \eta\lambda_i|$.

Desarrollo.

1. $\nabla f(\theta) = Q\theta$ por ser Q simétrica (módulo 4), luego $\theta_{k+1} = (I - \eta Q)\theta_k$.
2. Teorema espectral: $Q = U\Lambda U^\top$ con U ortogonal; $I - \eta Q = U(I - \eta\Lambda)U^\top$, de autovalores $1 - \eta\lambda_i$.
3. Con $z = U^\top\theta$, $z_k^{(i)} = (1 - \eta\lambda_i)^k z_0^{(i)}$ y $\|\theta_k\| = \|z_k\| \le \rho(\eta)^k\|\theta_0\|$.
4. Si $0 < \eta < 2/L$: para todo i, $0 < \eta\lambda_i \le \eta L < 2$, luego $-1 < 1 - \eta\lambda_i < 1$ y $\rho(\eta) < 1$: $\theta_k \to 0$.
5. Extremos: $\varphi(\lambda) = |1 - \eta\lambda|$ es el valor absoluto de una función afín, luego convexa. Todo $\lambda \in [\mu, L]$ es $\lambda = t\mu + (1-t)L$ y $\varphi(\lambda) \le t\varphi(\mu) + (1-t)\varphi(L) \le \max\{\varphi(\mu), \varphi(L)\}$. Así, $\rho(\eta) = \max\{|1 - \eta\mu|, |1 - \eta L|\}$.
6. Óptimo: para $\eta \le 2/(\mu + L)$ el máximo es $1 - \eta\mu$, decreciente en η; para $\eta \ge 2/(\mu + L)$ es $\eta L - 1$, creciente. En efecto, $1 - \eta\mu \ge \eta L - 1 \iff \eta \le 2/(\mu + L)$. El mínimo de ρ está, por tanto, en $\eta^* = 2/(\mu + L)$, donde ambos valores se igualan.
7. $\rho(\eta^*) = 1 - \frac{2\mu}{\mu+L} = \frac{L-\mu}{L+\mu} = \frac{\kappa-1}{\kappa+1}$.

Resultado. **el método converge para todo** $\eta \in (0, 2/L)$**, y el paso óptimo** $2/(\mu + L)$ **da el factor** $(\kappa - 1)/(\kappa + 1)$. Igualar los extremos es óptimo porque cualquier otro η empeora uno de los dos.

Comprobación. con $Q = \mathrm{diag}(2, 10)$: $\eta^* = 1/6$ y $\rho = 2/3$, el valor observado en el ejercicio 2.3.

A.3 Tema 3

Solución del ejercicio 3.1

Datos. un corpus de billones de tokens y la regla $\theta \leftarrow \theta - \eta \nabla J(\theta)$, con J la media sobre todo el corpus.

Planteamiento. comparar el coste de un paso exacto con el de uno de minibatch y considerar el efecto del ruido.

Desarrollo.

1. *Coste.* El gradiente exacto exige recorrer todo el corpus, con propagación y retropropagación, para dar un solo paso: un único paso costaría tanto como una época completa.
2. *Rendimiento por cálculo.* Por el teorema 3.2, un minibatch de B ejemplos da un estimador insesgado de varianza σ^2/B. Con el mismo cálculo que un paso exacto se dan N/B pasos aproximados, que avanzan mucho más.
3. *Ruido útil.* El ruido ayuda a abandonar puntos de silla y se asocia a mínimos más anchos (observación 1.14).

Resultado. **se usa SGD con minibatch porque el gradiente exacto es inasumible y porque los pasos ruidosos son más eficientes.**

Comprobación. GPT-3 usó lotes de $3{,}2 \cdot 10^6$ tokens [4, tabla 2.1], una fracción ínfima de los cientos de miles de millones de tokens con que se entrenó.

Solución del ejercicio 3.2

Datos. gradientes individuales $(-2, 0, 1, 5)$, $N = 4$, $B = 2$ sin reemplazamiento.

Planteamiento. media, varianza poblacional y enumeración de los $\binom{4}{2} = 6$ minibatches; comprobación con la proposición 3.3.

Desarrollo.

1. Gradiente completo: $(-2 + 0 + 1 + 5)/4 = 1$.
2. Desviaciones: $(-3, -1, 0, 4)$; cuadrados $(9, 1, 0, 16)$; $\sigma^2 = 26/4 = 6{,}5$.
3. Minibatches: $\{-2, 0\} \to -1$; $\{-2, 1\} \to -0{,}5$; $\{-2, 5\} \to 1{,}5$; $\{0, 1\} \to 0{,}5$; $\{0, 5\} \to 2{,}5$; $\{1, 5\} \to 3$.
4. Media: $(-1 - 0{,}5 + 1{,}5 + 0{,}5 + 2{,}5 + 3)/6 = 6/6 = 1$.
5. Desviaciones: $(-2; -1{,}5; 0{,}5; -0{,}5; 1{,}5; 2)$; cuadrados $(4; 2{,}25; 0{,}25; 0{,}25; 2{,}25; 4)$, que suman 13; varianza $13/6 \approx 2{,}167$.
6. Fórmula: $(6{,}5/2) \cdot (4 - 2)/(4 - 1) = 3{,}25 \cdot \frac{2}{3} = 13/6$.

Resultado. $\nabla J = 1$**;** $\sigma^2 = 6{,}5$**; media de los minibatches** 1 **(insesgado); varianza** $13/6 \approx 2{,}167$**.**

Comprobación. el cálculo directo y la fórmula coinciden, y $2{,}167 < \sigma^2/B = 3{,}25$.

Solución del ejercicio 3.3

Datos. $g = (2, 4, 6, 8)$, $N = 4$, $B = 2$.

Planteamiento. enumerar los pares y comparar con σ^2/B (teorema 3.2) y con $\frac{\sigma^2}{B}\cdot\frac{N-B}{N-1}$ (proposición 3.3).

Desarrollo.

1. Media $(2+4+6+8)/4 = 5$; $\sigma^2 = (9+1+1+9)/4 = 5$.
2. (a) Con reemplazamiento, las medias de los 16 pares ordenados toman los valores 2, 3, 4, 5, 6, 7, 8 con frecuencias 1, 2, 3, 4, 3, 2, 1.
3. Media: $(2+6+12+20+18+14+8)/16 = 80/16 = 5$.
4. Varianza: $(1\cdot 9 + 2\cdot 4 + 3\cdot 1 + 4\cdot 0 + 3\cdot 1 + 2\cdot 4 + 1\cdot 9)/16 = 40/16 = 2{,}5 = \sigma^2/B$.
5. (b) Sin reemplazamiento: $\{2,4\}\to 3$, $\{2,6\}\to 4$, $\{2,8\}\to 5$, $\{4,6\}\to 5$, $\{4,8\}\to 6$, $\{6,8\}\to 7$; media $30/6 = 5$.
6. Varianza: $(4+1+0+0+1+4)/6 = 10/6 \approx 1{,}667 = 2{,}5\cdot\frac{2}{3}$.

Resultado. **ambos estimadores son insesgados (media 5); varianza** $2{,}5$ **con reemplazamiento y** $5/3 \approx 1{,}667$ **sin él.**

Comprobación. las frecuencias del paso 2 suman 1+2+3+4+3+2+1 = 16. Sin reemplazamiento no se repite ningún ejemplo y la varianza es menor.

Solución del ejercicio 3.4

Datos. $a = 1$, $s^2 = 1$, $\eta \in \{0{,}1;\ 0{,}01\}$.

Planteamiento. proposición 3.9: $\mathbb{E}[x^2] \to \eta s^2/(a(2-\eta a))$ y $\mathbb{E}[f] \to \eta s^2/(2(2-\eta a))$.

Desarrollo.

1. $\eta = 0{,}1$: $\mathbb{E}[x^2] \to 0{,}1/1{,}9 \approx 0{,}05263$; $\mathbb{E}[f] \to 0{,}02632$.
2. $\eta = 0{,}01$: $\mathbb{E}[x^2] \to 0{,}01/1{,}99 \approx 0{,}005025$; $\mathbb{E}[f] \to 0{,}002513$.
3. Cociente: $0{,}02632/0{,}002513 \approx 10{,}47$.
4. Velocidad: la media se contrae con factor $1-\eta a$, que pasa de 0,9 a 0,99. Para reducir $\mathbb{E}[x_k]$ en e^{-1} hacen falta $-1/\ln(1-\eta a)$ pasos: unos 9,5 con $\eta = 0{,}1$ y unos 99,5 con $\eta = 0{,}01$.

Resultado. **el exceso de pérdida pasa de** $0{,}02632$ **a** $0{,}002513$**, unas** $10{,}5$ **veces menos; a cambio, la fase transitoria es unas 10 veces más lenta.** Es el compromiso que resuelve un calendario decreciente: pasos grandes al principio y pequeños al final.

Comprobación. para $\eta a \ll 1$, $\mathbb{E}[f] \approx \eta s^2/4$: 0,025 y 0,0025, próximos a los valores exactos.

Solución del ejercicio 3.5

Datos. $\{I_1,\dots,I_B\}$ uniforme entre los subconjuntos de B índices distintos; $X_b = \nabla\ell_{I_b}(\theta) - \nabla J(\theta)$; $d_i = \nabla\ell_i(\theta) - \nabla J(\theta)$, con $\sum_i d_i = 0$ y $\frac{1}{N}\sum_i \|d_i\|^2 = \sigma^2$.

Planteamiento. calcular $\mathbb{E}\|X_b\|^2$ y $\mathbb{E}[X_b^\top X_{b'}]$ para $b \neq b'$, y desarrollar $\mathrm{Var}[\hat{g}] = \mathbb{E}\|\frac{1}{B}\sum_b X_b\|^2$.

Desarrollo.

1. Por simetría, cada I_b es uniforme en $\{1,\dots,N\}$, luego $\mathbb{E}[X_b] = \frac{1}{N}\sum_i d_i = 0$ (insesgadez) y $\mathbb{E}\|X_b\|^2 = \sigma^2$.

2. Para $b \neq b'$, el par $(I_b, I_{b'})$ es uniforme entre los $N(N-1)$ pares ordenados de índices distintos: $\mathbb{E}[X_b^\top X_{b'}] = \frac{1}{N(N-1)} \sum_{i \neq j} d_i^\top d_j$.
3. Como $\sum_i d_i = 0$: $0 = \|\sum_i d_i\|^2 = \sum_i \|d_i\|^2 + \sum_{i \neq j} d_i^\top d_j$, luego $\sum_{i \neq j} d_i^\top d_j = -N\sigma^2$.
4. Por tanto $\mathbb{E}[X_b^\top X_{b'}] = -\sigma^2/(N-1)$.
5. $\mathrm{Var}[\hat{g}] = \frac{1}{B^2}\left(\sum_b \mathbb{E}\|X_b\|^2 + \sum_{b \neq b'} \mathbb{E}[X_b^\top X_{b'}]\right) = \frac{1}{B^2}\left(B\sigma^2 - \frac{B(B-1)\sigma^2}{N-1}\right)$.
6. Simplificando: $\frac{\sigma^2}{B}\left(1 - \frac{B-1}{N-1}\right) = \frac{\sigma^2}{B} \cdot \frac{N-B}{N-1}$.

Resultado. $\mathbb{E}[\hat{g}] = \nabla J(\theta)$ **y** $\mathrm{Var}[\hat{g}] = \frac{\sigma^2}{B} \cdot \frac{N-B}{N-1}$**.**
Comprobación. $B = 1$ da σ^2 y $B = N$ da 0. En el ejemplo 3.4, $(3{,}5/2) \cdot (2/3) = 7/6$, que es la varianza obtenida al enumerar.

Solución del ejercicio 3.6

Datos. $f(x) = x_1^2 + 2x_2^2$; $F(x, w) = (x_1 - w_1)^2 + 2(x_2 - w_2)^2$; $w \sim \mathcal{N}(0, s^2 I)$.
Planteamiento. derivar F respecto de x y separar la parte que no depende de w; después tomar la esperanza en w.
Desarrollo.

1. $\nabla_x F(x, w) = \big(2(x_1 - w_1);\, 4(x_2 - w_2)\big) = \nabla f(x) + \xi$, con $\nabla f(x) = (2x_1;\, 4x_2)$ y $\xi = (-2w_1;\, -4w_2)$.
2. ξ es una transformación lineal de un vector gaussiano, luego es gaussiano, de media $(0;\, 0)$ y covarianza $\mathrm{diag}(4s^2, 16s^2)$, porque w_1 y w_2 son independientes.
3. $\mathbb{E}_w[(x_1 - w_1)^2] = x_1^2 - 2x_1\mathbb{E}[w_1] + \mathbb{E}[w_1^2] = x_1^2 + s^2$; del mismo modo, $\mathbb{E}_w[(x_2 - w_2)^2] = x_2^2 + s^2$.
4. $\mathbb{E}_w[F(x, w)] = x_1^2 + s^2 + 2(x_2^2 + s^2) = f(x) + 3s^2$.
5. La constante $3s^2$ no depende de x: $\mathbb{E}_w[F]$ y f tienen el mismo minimizador, $x^* = 0$.

Resultado. $\nabla_x F = \nabla f + \xi$ **con** $\xi \sim \mathcal{N}(0, \mathrm{diag}(4s^2, 16s^2))$ **y** $\mathbb{E}_w[F] = f + 3s^2$**.** Cada paso de SGD sobre F con una muestra nueva de w es un paso de descenso sobre f con gradiente ruidoso insesgado.
Comprobación. con $s = 0$ el ruido desaparece y $F = f$.

A.4 Tema 4

Solución del ejercicio 4.1

Datos. gradiente constante g; $\beta \in \{0{,}9;\ 0{,}99\}$.
Planteamiento. por la proposición 4.2, $v_k = \frac{1-\beta^k}{1-\beta} g$.
Desarrollo.

1. Límite: $v_k \to g/(1-\beta)$. Con $\beta = 0{,}9$, factor 10; con $\beta = 0{,}99$, factor 100.
2. El 90 % del límite exige $1 - \beta^k \geq 0{,}9$, es decir, $\beta^k \leq 0{,}1$: $k \geq \ln 0{,}1 / \ln 0{,}9 = 21{,}85$, luego $k = 22$.

3. Sobrepaso: al acercarse al mínimo, el gradiente disminuye, pero v_k conserva una fracción β de la velocidad acumulada. Con β grande la memoria es larga y la velocidad tarda en frenarse, de modo que el iterado rebasa el mínimo.

Resultado. **factor 10 con $\beta = 0{,}9$ y 100 con $\beta = 0{,}99$; 22 pasos para llegar al 90 % con $\beta = 0{,}9$.**

Comprobación. $0{,}9^{22} = 0{,}0985 \leq 0{,}1$ y $0{,}9^{21} = 0{,}1094 > 0{,}1$.

Solución del ejercicio 4.2

Datos. $f(x) = x^2/2$, $f'(x) = x$, $x_0 = 1$, $v_0 = 0$, $\eta = 0{,}1$, $\beta = 0{,}9$.

Planteamiento. aplicar la definición 4.3; el descenso de gradiente es $x \leftarrow 0{,}9x$.

Desarrollo.

1. $k = 1$: $v_1 = 0 + 1 = 1$; $x_1 = 1 - 0{,}1 = 0{,}9$.
2. $k = 2$: $v_2 = 0{,}9 \cdot 1 + 0{,}9 = 1{,}8$; $x_2 = 0{,}9 - 0{,}18 = 0{,}72$.
3. $k = 3$: $v_3 = 0{,}9 \cdot 1{,}8 + 0{,}72 = 1{,}62 + 0{,}72 = 2{,}34$; $x_3 = 0{,}72 - 0{,}234 = 0{,}486$.
4. Descenso de gradiente: 0,9; 0,81; 0,729.
5. Fracción recorrida: momentum $1 - 0{,}486 = 0{,}514$; descenso de gradiente $1 - 0{,}729 = 0{,}271$.

Resultado. **momentum:** 0,9**;** 0,72**;** 0,486 **(51,4 % del camino). Descenso de gradiente:** 0,9**;** 0,81**;** 0,729 **(27,1 %).**

Comprobación. en el primer paso ambos coinciden porque $v_0 = 0$. Por la proposición 4.4, $x_3 = x_2 - 0{,}1x_2 + 0{,}9(x_2 - x_1) = 0{,}648 - 0{,}162 = 0{,}486$.

Solución del ejercicio 4.3

Datos. $\mu = 1$, $L = 100$, $\kappa = 100$, $\epsilon = 10^{-3}$.

Planteamiento. fórmulas del teorema 4.9 y $k = \lceil \ln \epsilon / \ln \rho \rceil$.

Desarrollo.

1. $\sqrt{L} = 10$, $\sqrt{\mu} = 1$: $\eta = 4/11^2 = 4/121 \approx 0{,}03306$.
2. $\beta = \left(\frac{10-1}{10+1}\right)^2 = \frac{81}{121} \approx 0{,}6694$; $\rho = \frac{9}{11} \approx 0{,}8182$.
3. Iteraciones: $\ln(9/11) = -0{,}2007$; $6{,}908/0{,}2007 \approx 34{,}4$, luego 35.
4. Descenso de gradiente: $\eta^* = 2/101 \approx 0{,}01980$, $\rho = 99/101 \approx 0{,}9802$; $\ln \rho = -0{,}02000$; $6{,}908/0{,}02000 \approx 345{,}4$, luego 346.

Resultado. $\eta = 4/121 \approx 0{,}03306$**,** $\beta = 81/121 \approx 0{,}6694$**,** $\rho = 9/11 \approx 0{,}8182$**: unas 35 iteraciones frente a 346**, una reducción en un factor próximo a $\sqrt{\kappa} = 10$.

Comprobación. coincide con la fila $\kappa = 100$ del cuadro 2.1. El paso del momentum es mayor que el límite $2/L = 0{,}02$ del descenso de gradiente, lo que es posible por el ejercicio 4.6.

Solución del ejercicio 4.4

Datos. $\lambda = (1, \frac{1}{2}, \frac{1}{4})$, $x_0 = (1, 1, 1)$, tolerancia 10^{-2}.

Planteamiento. las coordenadas evolucionan por separado; en el descenso de gradiente, $x_k^{(i)} = (1 - \eta\lambda_i)^k$.

Desarrollo.

1. (a) $\eta = 1$: factores $(0;\ \frac{1}{2};\ \frac{3}{4})$. La más lenta es la tercera: $0{,}75^k < 10^{-2}$ exige $k > \ln 0{,}01/\ln 0{,}75 = 16{,}01$, es decir, $k = 17$.
2. (b) $\mu = \frac{1}{4}$, $L = 1$: $\eta^* = 2/1{,}25 = 1{,}6$, factores $(-0{,}6;\ 0{,}2;\ 0{,}6)$ y $\rho = 0{,}6$. $0{,}6^k < 10^{-2}$ exige $k > 9{,}015$: $k = 10$.
3. (c) $\sqrt{L} = 1$, $\sqrt{\mu} = \frac{1}{2}$: $\eta = 4/(1{,}5)^2 = \frac{16}{9} \approx 1{,}778$, $\beta = \left(\frac{0{,}5}{1{,}5}\right)^2 = \frac{1}{9}$, $\rho = \frac{1}{3}$.
4. Primer paso: $v_1 = \lambda \odot x_0 = (1;\ \frac{1}{2};\ \frac{1}{4})$; $x_1 = x_0 - \frac{16}{9}v_1 = \left(-\frac{7}{9};\ \frac{1}{9};\ \frac{5}{9}\right)$.
5. Segundo paso: $v_2 = \frac{1}{9}v_1 + \lambda \odot x_1 = \left(\frac{1}{9} - \frac{7}{9};\ \frac{1}{18} + \frac{1}{18};\ \frac{1}{36} + \frac{5}{36}\right) = \left(-\frac{2}{3};\ \frac{1}{9};\ \frac{1}{6}\right)$.
6. $x_2 = x_1 - \frac{16}{9}v_2 = \left(-\frac{7}{9} + \frac{32}{27};\ \frac{1}{9} - \frac{16}{81};\ \frac{5}{9} - \frac{16}{54}\right) = \left(\frac{11}{27};\ -\frac{7}{81};\ \frac{7}{27}\right) \approx (0{,}4074;\ -0{,}08642;\ 0{,}2593)$.
7. Estimación: $(1/3)^k < 10^{-2}$ exige $k > \ln 0{,}01/\ln(1/3) = 4{,}19$, es decir, unos 5 pasos.

Resultado. **(a) 17 pasos; (b) 10 pasos; (c)** $\eta = 16/9$**,** $\beta = 1/9$**,** $x_2 = (11/27;\ -7/81;\ 7/27)$ **y una estimación de unos 5 pasos.** Una simulación numérica da 7 pasos: la estimación por el radio espectral es optimista porque en los autovalores extremos la raíz es doble (observación posterior al teorema 4.9).

Comprobación. la forma de dos pasos (proposición 4.4) en la primera coordenada da: $x_2^{(1)} = x_1^{(1)} - \eta x_1^{(1)} + \beta(x_1^{(1)} - x_0^{(1)}) = -\frac{7}{9} + \frac{112}{81} - \frac{16}{81} = \frac{-63+96}{81} = \frac{33}{81} = \frac{11}{27}$.

Solución del ejercicio 4.5

Datos. $v_0 = 0$, $v_{k+1} = \beta v_k + \nabla f(\theta_k)$, $\theta_{k+1} = \theta_k - \eta v_{k+1}$.

Planteamiento. eliminar v entre las dos ecuaciones; para el gradiente constante, usar la proposición 4.2.

Desarrollo.

1. De la segunda ecuación en el paso anterior, $\eta v_k = \theta_{k-1} - \theta_k$ para $k \geq 1$.
2. $\theta_{k+1} = \theta_k - \eta\beta v_k - \eta\nabla f(\theta_k) = \theta_k - \eta\nabla f(\theta_k) + \beta(\theta_k - \theta_{k-1})$.
3. Con $\nabla f(\theta_k) = g$: $v_{k+1} = \sum_{j=0}^{k} \beta^{k-j} g = \frac{1-\beta^{k+1}}{1-\beta} g$.
4. $\theta_k - \theta_{k+1} = \eta v_{k+1} = \eta\frac{1-\beta^{k+1}}{1-\beta} g$.

Resultado. $\theta_{k+1} = \theta_k - \eta\nabla f(\theta_k) + \beta(\theta_k - \theta_{k-1})$ **y, con gradiente constante,** $\theta_k - \theta_{k+1} = \eta\frac{1-\beta^{k+1}}{1-\beta} g$**.**

Comprobación. $k = 0$ da ηg, el paso del descenso de gradiente; $k \to \infty$ da $\eta g/(1-\beta)$. En el ejemplo 4.5, $v_2 = 1{,}8$ y $x_1 - x_2 = 0{,}18 = 0{,}1 \cdot 1{,}8$.

Solución del ejercicio 4.6

Datos. $p(r) = r^2 - br + \beta$ con $b = 1 + \beta - \eta\lambda$, $\beta \in [0, 1)$, $\eta\lambda > 0$.

Planteamiento. distinguir raíces complejas y reales; en el caso real, usar el signo de $p(\pm 1)$.

Desarrollo.

1. Se calcula $p(1) = 1 - b + \beta = \eta\lambda$ y $p(-1) = 1 + b + \beta = 2(1 + \beta) - \eta\lambda$.
2. *Raíces complejas o doble* ($b^2 \leq 4\beta$): su módulo es $\sqrt{\beta} < 1$. Además $|b| \leq 2\sqrt{\beta} < 1 + \beta$, luego $p(1) > 0$ y $p(-1) > 0$: la condición del enunciado se cumple.

3. *Raíces reales distintas* $r_1 < r_2$: $p(r) > 0$ fuera de $[r_1, r_2]$ y $p(r) < 0$ en su interior. Si ambas están en $(-1, 1)$, entonces ± 1 están fuera y $p(\pm 1) > 0$.

4. Recíprocamente, si $p(1) > 0$ y $p(-1) > 0$, ningún ± 1 está en $[r_1, r_2]$. Si $b \geq 2$, $p(1) = 1 + \beta - b \leq \beta - 1 < 0$, imposible; si $b \leq -2$, $p(-1) \leq \beta - 1 < 0$, imposible. Así $|b| < 2$ y el vértice $b/2$ está en $(-1, 1)$; como $[r_1, r_2]$ contiene el vértice y no contiene ± 1, está contenido en $(-1, 1)$.

5. En todos los casos: las raíces tienen módulo menor que 1 si y solo si $p(1) > 0$ y $p(-1) > 0$, es decir, $0 < \eta\lambda < 2(1 + \beta)$.

Resultado. **el método es estable si y solo si** $0 < \eta\lambda < 2(1 + \beta)$, frente a $0 < \eta\lambda < 2$ en el descenso de gradiente: con $\beta = 0{,}9$ el paso puede ser hasta 1,9 veces mayor.

Comprobación. con $\beta = 0$ se recupera $0 < \eta\lambda < 2$. En el ejercicio 4.3, $\eta L = 400/121 \approx 3{,}306 < 2(1 + 0{,}6694) = 3{,}339$.

A.5 Tema 5

Solución del ejercicio 5.1

Datos. Adam con $m_0 = v_0 = 0$; la pérdida se multiplica por $c = 1000$, de modo que g pasa a ser cg.

Planteamiento. calcular el primer paso de Adam en función de g (proposición 5.8).

Desarrollo.

1. $m_1 = (1 - \beta_1)g$ y $v_1 = (1 - \beta_2)g^2$.

2. $\hat{m}_1 = g$ y $\hat{v}_1 = g^2$, luego $\sqrt{\hat{v}_1} = |g|$.

3. Paso: $\eta g/(|g| + \varepsilon) \approx \eta$ signo(g).

4. Con cg: $\eta cg/(c|g| + \varepsilon) \approx \eta$ signo(g); el factor c se cancela.

5. En el SGD, el paso ηg pasa a ser ηcg: se multiplica por 1000.

Resultado. **falsa**: el primer paso de Adam mide η en ambos casos, salvo el efecto despreciable de ε; en el SGD, en cambio, sí se multiplicaría por 1000.

Comprobación. con $\eta = 0{,}01$, $\varepsilon = 10^{-8}$ y $g = 0{,}5$, el paso es $0{,}01 \cdot 0{,}5/(0{,}5 + 10^{-8}) \approx 0{,}0099999998$; con $g = 500$, $\approx 0{,}01$ con diez cifras.

Solución del ejercicio 5.2

Datos. RMSProp con $s_0 = 0$, $\varepsilon \approx 0$, gradiente inicial $g_1 \neq 0$; $\rho \in \{0{,}9;\ 0{,}999\}$.

Planteamiento. $s_1 = (1 - \rho)g_1^2$ y paso $\eta g_1/\sqrt{s_1}$.

Desarrollo.

1. Paso: $\eta g_1/(\sqrt{1 - \rho}\,|g_1|) = \eta$ signo$(g_1)/\sqrt{1 - \rho}$.

2. $\rho = 0{,}9$: $1/\sqrt{0{,}1} \approx 3{,}162$.

3. $\rho = 0{,}999$: $1/\sqrt{0{,}001} \approx 31{,}62$.

Resultado. **el primer paso mide unas** $3{,}16\,\eta$ **con** $\rho = 0{,}9$ **y** $31{,}6\,\eta$ **con** $\rho = 0{,}999$**.** El estimador s_t está sesgado hacia 0 por la inicialización, lo que agranda los primeros pasos justo cuando el gradiente es menos fiable; la corrección de sesgo de Adam divide v_t por $1 - \beta_2^t$ y elimina el efecto.

Comprobación. con corrección, $\hat{s}_1 = s_1/(1-\rho) = g_1^2$ y el paso vuelve a ser η.

Solución del ejercicio 5.3

Datos. $\eta = 0{,}01$, $\theta_0 = 1$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon \approx 0$, $g_1 = 0{,}5$, $g_2 = -0{,}1$.

Planteamiento. aplicar la definición 5.6 paso a paso.

Desarrollo.

1. $t = 1$: $m_1 = 0{,}1 \cdot 0{,}5 = 0{,}05$; $v_1 = 0{,}001 \cdot 0{,}25 = 0{,}00025$.
2. $\hat{m}_1 = 0{,}05/0{,}1 = 0{,}5$; $\hat{v}_1 = 0{,}00025/0{,}001 = 0{,}25$; $\sqrt{\hat{v}_1} = 0{,}5$.
3. Paso $0{,}01 \cdot 0{,}5/0{,}5 = 0{,}01$; $\theta_1 = 0{,}99$.
4. $t = 2$: $m_2 = 0{,}9 \cdot 0{,}05 + 0{,}1 \cdot (-0{,}1) = 0{,}045 - 0{,}01 = 0{,}035$.
5. $v_2 = 0{,}999 \cdot 0{,}00025 + 0{,}001 \cdot 0{,}01 = 0{,}00024975 + 0{,}00001 = 0{,}00025975$.
6. Correcciones: $1 - 0{,}9^2 = 0{,}19$ y $1 - 0{,}999^2 = 0{,}001999$.
7. $\hat{m}_2 = 0{,}035/0{,}19 = 0{,}1842$; $\hat{v}_2 = 0{,}00025975/0{,}001999 = 0{,}1299$; $\sqrt{\hat{v}_2} = 0{,}3605$.
8. Paso $0{,}01 \cdot 0{,}1842/0{,}3605 = 0{,}005110$; $\theta_2 = 0{,}99 - 0{,}005110 = 0{,}98489$.

Resultado. $\theta_1 = 0{,}99$ **y** $\theta_2 \approx 0{,}9849$**.**

Comprobación. aunque $g_2 < 0$, θ sigue bajando porque $m_2 = 0{,}035 > 0$ conserva la inercia del primer gradiente; el paso de $t = 2$ es menor que η, como corresponde a un cambio de signo del gradiente.

Solución del ejercicio 5.4

Datos. $f(x) = 0{,}1x_1^2 + 2x_2^2$; R rotación de ángulo $\pi/4$, $R = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$; $g(y) = f(R^\top y)$.

Planteamiento. proposición 5.2: el hessiano precondicionado es $D^{-1/2}QD^{-1/2}$, semejante a $D^{-1}Q$; para g, el hessiano es $RQR^\top$ por la regla de la cadena.

Desarrollo.

1. $Q = \nabla^2 f = \operatorname{diag}(0{,}2;\ 4)$, $\kappa = 4/0{,}2 = 20$.
2. $D = \operatorname{diag}(0{,}2;\ 4) = Q$: $D^{-1/2}QD^{-1/2} = I$, $\kappa = 1$.
3. $\nabla^2 g = RQR^\top$. Con $a = 0{,}2$ y $b = 4$: $RQR^\top = \frac{1}{2}\begin{pmatrix} a+b & a-b \\ a-b & a+b \end{pmatrix} = \begin{pmatrix} 2{,}1 & -1{,}9 \\ -1{,}9 & 2{,}1 \end{pmatrix}$.
4. Diagonal: $D' = \operatorname{diag}(2{,}1;\ 2{,}1) = 2{,}1\,I$. Precondicionar por D' divide el hessiano por 2,1: autovalores $0{,}2/2{,}1 \approx 0{,}09524$ y $4/2{,}1 \approx 1{,}905$, con $\kappa = 20$.
5. (c) El precondicionador diagonal elimina el mal condicionamiento cuando los ejes principales coinciden con los coordenados, pero no corrige nada si están girados.

Resultado. **(a) $\kappa = 20$, y $\kappa = 1$ tras preacondicionar; (b) $\nabla^2 g = \begin{pmatrix} 2{,}1 & -1{,}9 \\ -1{,}9 & 2{,}1 \end{pmatrix}$, diagonal $2{,}1\,I$ y $\kappa = 20$ tras preacondicionar.** Los métodos adaptativos diagonales dependen de la base: funcionan bien cuando las escalas distintas están alineadas con los parámetros.

Comprobación. la rotación conserva los autovalores: traza $4{,}2 = 0{,}2 + 4$ y determinante $2{,}1^2 - 1{,}9^2 = 0{,}8 = 0{,}2 \cdot 4$.

Solución del ejercicio 5.5

Datos. $N = 7 \cdot 10^9$ parámetros; 4 bytes por número; se guardan parámetros, gradientes, m y v.

Planteamiento. cada vector ocupa $4N$ bytes.

Desarrollo.

1. Un vector: $4 \cdot 7 \cdot 10^9 = 2{,}8 \cdot 10^{10}$ bytes $= 28$ GB.
2. Cuatro vectores: $4 \cdot 28 = 112$ GB.
3. Estado del optimizador (m y v): $2 \cdot 28 = 56$ GB.
4. Fracción: $56/112 = 0{,}5$.

Resultado. **112 GB en total, de los que 56 GB (el 50 %) son el estado de Adam**, sin contar las activaciones.

Comprobación. el SGD sin momentum no tiene estado y necesitaría 56 GB; con momentum, 84 GB. Las técnicas de reparto del estado entre dispositivos se estudian en el módulo 17.

Solución del ejercicio 5.6

Datos. Adam con $\varepsilon = 0$; gradientes g_t sustituidos por $g'_t = c g_t$.

Planteamiento. por inducción sobre t: si los iterados coinciden hasta $t-1$, los gradientes de ambas ejecuciones en θ_{t-1} están en razón c, y se comprueba cómo escalan m_t, v_t y el cociente.

Desarrollo.

1. Hipótesis: $\theta'_s = \theta_s$, $m'_s = c m_s$ y $v'_s = c^2 v_s$ para $s \le t-1$ (cierto para $s = 0$, con $m_0 = v_0 = 0$).
2. Entonces $g'_t = c g_t$, $m'_t = \beta_1 c m_{t-1} + (1-\beta_1) c g_t = c m_t$ y $v'_t = \beta_2 c^2 v_{t-1} + (1-\beta_2) c^2 g_t^2 = c^2 v_t$.
3. $\hat{m}'_t / \sqrt{\hat{v}'_t} = c\hat{m}_t / (|c|\sqrt{\hat{v}_t}) = \hat{m}_t / \sqrt{\hat{v}_t}$ si $c > 0$. Luego $\theta'_t = \theta_t$.
4. Si $c < 0$, el cociente cambia de signo: los iterados se mueven en sentido contrario (se asciende por f). No hay invariancia.
5. SGD con momentum: $v'_k = c v_k$ y el paso es $\eta c v_k$: se multiplica por c. No hay invariancia.

Resultado. **los iterados de Adam son invariantes frente a $g \mapsto cg$ con $c > 0$**, pero no con $c < 0$, y el SGD con momentum no tiene esta propiedad.

Comprobación. con $c > 0$ y $\varepsilon > 0$, el cociente es $c\hat{m}_t / (c\sqrt{\hat{v}_t} + \varepsilon)$, que solo coincide si $\varepsilon \ll c\sqrt{\hat{v}_t}$; de ahí que ε se elija muy pequeño.

Solución del ejercicio 5.7

Datos. $\hat{m}_t = m_t/(1-\beta_1^t)$, $\hat{v}_t = v_t/(1-\beta_2^t)$, $\varepsilon \to 0$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$.

Planteamiento. sacar los factores de corrección fuera del cociente.

Desarrollo.

1. $\eta\dfrac{\hat{m}_t}{\sqrt{\hat{v}_t}} = \eta\,\dfrac{m_t/(1-\beta_1^t)}{\sqrt{v_t}/\sqrt{1-\beta_2^t}} = \eta\,\dfrac{\sqrt{1-\beta_2^t}}{1-\beta_1^t}\cdot\dfrac{m_t}{\sqrt{v_t}} = \eta_t\,\dfrac{m_t}{\sqrt{v_t}}$.
2. $t=1$: $\sqrt{0{,}001}/0{,}1 = 0{,}03162/0{,}1 = 0{,}3162$.
3. $t=2$: $\sqrt{0{,}001999}/0{,}19 = 0{,}04471/0{,}19 = 0{,}2353$.
4. $t=10$: $1-0{,}999^{10} = 0{,}009955$, de raíz 0,09978; $1-0{,}9^{10} = 0{,}6513$; cociente 0,1532.
5. $t=1000$: $1-0{,}999^{1000} = 0{,}6323$, de raíz 0,7952; $1-0{,}9^{1000} \approx 1$; cociente 0,7952.
6. Paso de $t=2$: $m_2 = 0{,}035$ y $\sqrt{v_2} = \sqrt{0{,}00025975} = 0{,}01612$; $0{,}01 \cdot 0{,}2353 \cdot 0{,}035/0{,}01612 = 0{,}005109$.

Resultado. $\eta_t/\eta = 0{,}3162$**;** $0{,}2353$**;** $0{,}1532$**;** $0{,}7952$ **para** $t=1$**, 2, 10 y 1000.** La corrección equivale a una tasa que crece hacia η durante los primeros miles de pasos: un calentamiento implícito.

Comprobación. el paso de $t=2$ coincide con el del ejercicio 5.3 (0,00511) salvo redondeo. Cuando $t\to\infty$, ambos factores tienden a 1 y $\eta_t \to \eta$.

A.6 Tema 6

Solución del ejercicio 6.1

Datos. calendario de calentamiento lineal y decaimiento coseno (definición 6.9).

Planteamiento. identificar qué falla al principio y al final del entrenamiento con η constante.

Desarrollo.

1. *Al principio.* Los gradientes son grandes e irregulares y los momentos de Adam se estiman con muy pocos gradientes. Una tasa grande desde el primer paso puede hacer divergir la pérdida (teorema 2.8: el paso debe ser menor que $2/\lambda_{\max}$). El calentamiento sube η gradualmente; el ejercicio 5.7 muestra que la corrección de sesgo de Adam ya produce un efecto parecido.
2. *Al final.* Con gradientes estocásticos, el exceso de pérdida estacionario es proporcional a η (proposición 3.9). El decaimiento coseno reduce η suavemente y rebaja ese suelo de ruido.

Resultado. **el calentamiento aporta estabilidad inicial y el decaimiento, precisión final.**

Comprobación. en el ejercicio 3.4, dividir η por 10 divide el exceso de pérdida por 10,5.

Solución del ejercicio 6.2

Datos. $\eta_{\max} = 6\cdot10^{-4}$, $\eta_{\min} = 6\cdot10^{-5}$, $W = 1000$, $T = 11\,000$.

Planteamiento. definición 6.9; progreso del tramo coseno $(t-1000)/10\,000$; amplitud $\frac{1}{2}(\eta_{\max}-\eta_{\min}) = 2{,}7\cdot10^{-4}$.

Desarrollo.

1. $t = 500 < W$: $\eta = 6 \cdot 10^{-4} \cdot 500/1000 = 3 \cdot 10^{-4}$.
2. $t = 6000$: progreso 0,5; $\cos(\pi/2) = 0$; $\eta = 6 \cdot 10^{-5} + 2{,}7 \cdot 10^{-4} = 3{,}3 \cdot 10^{-4}$.
3. $t = 8500$: progreso 0,75; $\cos(0{,}75\pi) = -0{,}7071$; $1 - 0{,}7071 = 0{,}2929$.
4. $\eta = 6 \cdot 10^{-5} + 2{,}7 \cdot 10^{-4} \cdot 0{,}2929 = 6 \cdot 10^{-5} + 7{,}908 \cdot 10^{-5} = 1{,}391 \cdot 10^{-4}$.

Resultado. $\eta(500) = 3 \cdot 10^{-4}$**;** $\eta(6000) = 3{,}3 \cdot 10^{-4}$**;** $\eta(8500) \approx 1{,}391 \cdot 10^{-4}$**.**

Comprobación. en el punto medio, $(\eta_{\max} + \eta_{\min})/2 = (6 + 0{,}6) \cdot 10^{-4}/2 = 3{,}3 \cdot 10^{-4}$ (proposición 6.10).

Solución del ejercicio 6.3

Datos. $\eta = 10^{-3}$, $\lambda = 0{,}1$, $\theta = 1$, $\hat{v} = 10^{-4}$, $\varepsilon \approx 0$.

Planteamiento. con L^2, el término $\lambda\theta$ queda dividido por $\sqrt{\hat{v}}$ (observación 6.5); en AdamW se resta $\eta\lambda\theta$ (definición 6.6).

Desarrollo.

1. $\sqrt{\hat{v}} = 10^{-2}$.
2. Adam con L^2: $\eta\lambda\theta/\sqrt{\hat{v}} = 10^{-3} \cdot 0{,}1/10^{-2} = 10^{-2}$.
3. AdamW: $\eta\lambda\theta = 10^{-3} \cdot 0{,}1 = 10^{-4}$.
4. Cociente: $10^{-2}/10^{-4} = 100$.

Resultado. **Adam con L^2 encoge** 0,01 **($\theta \to 0{,}99$) y AdamW** 0,0001 **($\theta \to 0{,}9999$); el cociente es 100.** El parámetro de gradientes pequeños se regulariza 100 veces más con L^2.

Comprobación. con $\hat{v} = 1$ ambos métodos coinciden en 10^{-4}, como en el cuadro 6.1.

Solución del ejercicio 6.4

Datos. (a) factor por paso $1 - 10^{-4}$; (b) $\eta = 3 \cdot 10^{-4}$, $\lambda = 0{,}1$, 10^5 pasos.

Planteamiento. tras k pasos de decaimiento puro, el peso queda multiplicado por $(1 - \eta\lambda)^k$.

Desarrollo.

1. (a) $(1 - 10^{-4})^k = \frac{1}{2}$, luego $k = \ln 0{,}5 / \ln(1 - 10^{-4}) = -0{,}6931/(-1{,}0001 \cdot 10^{-4}) \approx 6931$.
2. (b) $\eta\lambda = 3 \cdot 10^{-5}$; $\ln\big((1 - 3 \cdot 10^{-5})^{10^5}\big) = 10^5 \ln(1 - 3 \cdot 10^{-5}) \approx -3{,}0000$.
3. $e^{-3} \approx 0{,}04979$.

Resultado. **(a) unos 6931 pasos; (b) el peso queda multiplicado por** $\approx 0{,}0498$**.**

Comprobación. para x pequeño, $(1 - x)^k \approx e^{-kx}$: en (a), $e^{-6931 \cdot 10^{-4}} = e^{-0{,}6931} = 0{,}5$.

Solución del ejercicio 6.5

Datos. $J_\lambda(w) = \frac{a}{2}(w - c)^2 + \frac{\lambda}{2}w^2$, $a > 0$, $\lambda \geq 0$; caso numérico $a = 2$, $c = 3$, $\lambda = 2$.

Planteamiento. anular la derivada; $J''_\lambda = a + \lambda > 0$ garantiza que es el mínimo (teorema 1.9).

Desarrollo.

1. $J'_\lambda(w) = a(w - c) + \lambda w$.
2. $J'_\lambda(w^*) = 0 \Rightarrow (a + \lambda)w^* = ac \Rightarrow w^* = ac/(a + \lambda)$.

3. Paso de descenso: $w - \eta J'_\lambda(w) = w - \eta\lambda w - \eta a(w-c) = (1-\eta\lambda)w - \eta a(w-c)$.
4. Números: $w^* = 2\cdot 3/(2+2) = 1{,}5$.
5. Convergencia: J_λ es una cuadrática de curvatura $a+\lambda$; por el ejemplo 2.7, converge si y solo si $0 < \eta < 2/(a+\lambda)$, que con los datos es $0 < \eta < 0{,}5$.

Resultado. $w^* = ac/(a+\lambda) = 1{,}5$**; el paso de descenso es** $(1-\eta\lambda)w - \eta a(w-c)$ **y converge para** $0 < \eta < 2/(a+\lambda)$**.**

Comprobación. $J'_\lambda(1{,}5) = 2\cdot(1{,}5-3) + 2\cdot 1{,}5 = -3+3 = 0$. Con $\lambda = 0$ se recupera $w^* = c = 3$, y el factor $a/(a+\lambda) = 1/2$ es el de la proposición 6.3.

Solución del ejercicio 6.6

Datos. $\eta_t = \eta_0 t^{-\alpha}$, $t \geq 1$, $\eta_0 > 0$, $\alpha > 0$.

Planteamiento. criterio de las series $\sum t^{-p}$ (convergen si y solo si $p > 1$) y comparación con integrales para acotar sumas de funciones decrecientes.

Desarrollo.

1. (a) $\sum_t \eta_t = \eta_0 \sum_t t^{-\alpha}$ diverge si y solo si $\alpha \leq 1$.
2. $\sum_t \eta_t^2 = \eta_0^2 \sum_t t^{-2\alpha}$ converge si y solo si $2\alpha > 1$, es decir, $\alpha > \frac{1}{2}$.
3. Ambas condiciones a la vez: $\frac{1}{2} < \alpha \leq 1$.
4. (b) $\alpha = \frac{1}{2}$. Como $x \mapsto x^{-1/2}$ es decreciente, $t^{-1/2} \geq \int_t^{t+1} x^{-1/2}\,dx$; sumando, $\sum_{t=1}^{T} t^{-1/2} \geq \int_1^{T+1} x^{-1/2}\,dx = 2(\sqrt{T+1} - 1)$.
5. $\eta_t^2 = \eta_0^2/t$ y, para $t \geq 2$, $1/t \leq \int_{t-1}^{t} dx/x$; así $\sum_{t=1}^{T} 1/t \leq 1 + \int_1^T dx/x = 1 + \ln T$.
6. Cota del teorema 3.6: $\dfrac{r^2 + G^2\eta_0^2(1+\ln T)}{4\eta_0(\sqrt{T+1}-1)}$. El numerador crece como $\ln T$ y el denominador como $\sqrt{T}$.

Resultado. **(a) las condiciones de Robbins–Monro se cumplen si y solo si** $\frac{1}{2} < \alpha \leq 1$**; (b) con** $\alpha = \frac{1}{2}$ **la cota es** $O(\ln T/\sqrt{T})$, casi la velocidad $O(1/\sqrt{T})$ del paso constante óptimo (corolario 3.7), sin necesidad de conocer T de antemano.

Comprobación. con $T = 100$: $\sum_{t=1}^{100} t^{-1/2} \approx 18{,}59 \geq 2(\sqrt{101} - 1) \approx 18{,}10$, y $\sum_{t=1}^{100} 1/t \approx 5{,}187 \leq 1 + \ln 100 \approx 5{,}605$.

Bibliografía

[1] L. Bottou, F. E. Curtis y J. Nocedal. Optimization methods for large-scale machine learning. *SIAM Review*, 60(2):223–311, 2018. https://arxiv.org/abs/1606.04838

[2] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. Cap. 2, «Convex sets»; cap. 3, «Convex functions»; cap. 9, «Unconstrained minimization». Texto del curso EE364a de Stanford. https://web.stanford.edu/~boyd/cvxbook/

[3] S. Boyd. EE364a: Convex Optimization I. Stanford University. Transparencias del curso. https://web.stanford.edu/class/ee364a/lectures.html

[4] T. B. Brown *et al.* Language models are few-shot learners. En *Advances in Neural Information Processing Systems 33 (NeurIPS)*, 2020. https://arxiv.org/abs/2005.14165

[5] J. M. Cohen, S. Kaur, Y. Li, J. Z. Kolter y A. Talwalkar. Gradient descent on neural networks typically occurs at the edge of stability. En *International Conference on Learning Representations (ICLR)*, 2021. https://arxiv.org/abs/2103.00065

[6] Y. N. Dauphin, R. Pascanu, C. Gulcehre, K. Cho, S. Ganguli e Y. Bengio. Identifying and attacking the saddle point problem in high-dimensional non-convex optimization. En *Advances in Neural Information Processing Systems 27 (NeurIPS)*, 2014. https://arxiv.org/abs/1406.2572

[7] J. Duchi, E. Hazan e Y. Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12:2121–2159, 2011.

[8] G. Goh. Why momentum really works. *Distill*, 2017. https://distill.pub/2017/momentum/

[9] I. Goodfellow, Y. Bengio y A. Courville. *Deep Learning*. MIT Press, 2016. Cap. 4, «Numerical Computation»; cap. 7, «Regularization for Deep Learning»; cap. 8, «Optimization for Training Deep Models». https://www.deeplearningbook.org/

[10] P. Goyal, P. Dollár, R. Girshick *et al.* Accurate, large minibatch SGD: Training ImageNet in 1 hour. Prepublicación, 2017. https://arxiv.org/abs/1706.02677

[11] G. Hinton, N. Srivastava y K. Swersky. Neural Networks for Machine Learning, clase 6e: «rmsprop: Divide the gradient by a running average of its recent magnitude». Curso en línea, Coursera, 2012.

[12] N. S. Keskar, D. Mudigere, J. Nocedal, M. Smelyanskiy y P. T. P. Tang. On large-batch training for deep learning: Generalization gap and sharp minima. En *International Conference on Learning Representations (ICLR)*, 2017. https://arxiv.org/abs/1609.04836

[13] D. P. Kingma y J. Ba. Adam: A method for stochastic optimization. En *International Conference on Learning Representations (ICLR)*, 2015. https://arxiv.org/abs/1412.6980

[14] H. Li, Z. Xu, G. Taylor, C. Studer y T. Goldstein. Visualizing the loss landscape of neural nets. En *Advances in Neural Information Processing Systems 31 (NeurIPS)*, 2018. https://arxiv.org/abs/1712.09913

[15] I. Loshchilov y F. Hutter. SGDR: Stochastic gradient descent with warm restarts. En *International Conference on Learning Representations (ICLR)*, 2017. https://arxiv.org/abs/1608.03983

[16] I. Loshchilov y F. Hutter. Decoupled weight decay regularization. En *International Conference on Learning Representations (ICLR)*, 2019. https://arxiv.org/abs/1711.05101

[17] Y. Nesterov. A method for solving the convex programming problem with convergence rate $O(1/k^2)$. *Soviet Mathematics Doklady*, 27:372–376, 1983.

[18] B. T. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 4(5):1–17, 1964.

[19] H. Robbins y S. Monro. A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407, 1951.

[20] L. Sagun, L. Bottou e Y. LeCun. Eigenvalues of the Hessian in deep learning: Singularity and beyond. Prepublicación, 2016. https://arxiv.org/abs/1611.07476

[21] G. Strang. *Linear Algebra and Learning from Data*. Wellesley-Cambridge Press, 2019. Texto del curso 18.065 del MIT.

[22] G. Strang. 18.065: Matrix Methods in Data Analysis, Signal Processing, and Machine Learning. Massachusetts Institute of Technology, MIT OpenCourseWare, primavera de 2018. https://ocw.mit.edu/courses/18-065-matrix-methods-in-data-analysis-signal-processing-and-machine-learning-spring-2018/

[23] H. Touvron *et al.* LLaMA: Open and efficient foundation language models. Prepublicación, 2023. https://arxiv.org/abs/2302.13971

[24] A. Zhang, Z. C. Lipton, M. Li y A. J. Smola. *Dive into Deep Learning*, versión 1.0.3. Cambridge University Press, 2023. Cap. 12, «Optimization Algorithms». https://d2l.ai/