Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase II · Aprendizaje automático y redes neuronales

Módulo 7

Optimización

Resumen del módulo

Edición de octubre de 2026

Sobre este resumen

Este documento reúne lo indispensable de los apuntes del Módulo 7: el texto expositivo, todas las definiciones y todos los resultados (teoremas, proposiciones, lemas y corolarios), las tablas y las observaciones de contenido. Se han suprimido las demostraciones, los ejemplos, las lecturas, las figuras, los ejercicios y sus soluciones. La numeración de temas, secciones, enunciados y ecuaciones es la misma que en los apuntes, de modo que cualquier referencia puede buscarse allí; las que remiten a elementos suprimidos (un ejemplo, una figura, una ecuación de una demostración) conservan su número en los apuntes.

Notación

Símbolo	Significado
$\theta \in \mathbb{R}^n$, θ_k	vector de parámetros e iterado k-ésimo
f, $f^* = \inf f$, θ^*	función objetivo, valor óptimo y minimizador
$J(\theta) = \frac{1}{N}\sum_{i=1}^{N} \ell_i(\theta)$	riesgo empírico: pérdida media sobre N ejemplos
∇f, $\nabla^2 f$	gradiente (vector columna) y hessiano
μ, L	constantes de convexidad fuerte y de suavidad
$\lambda_{\min}$, $\lambda_{\max}$, λ_i	autovalores de una matriz simétrica
$\kappa = L/\mu$	número de condición
η, η_k	tasa de aprendizaje (constante o en el paso k)
B, $\hat{g}$	tamaño del minibatch y gradiente estocástico
β; β_1, β_2	coeficiente de momentum; coeficientes de Adam
m_t, v_t; $\hat{m}_t$, $\hat{v}_t$	momentos de Adam y sus versiones corregidas
ε	constante de estabilidad numérica de los métodos adaptativos
λ	coeficiente de regularización o de decaimiento de pesos (tema 6)
$A \succeq 0$, $A \succ 0$	A simétrica semidefinida o definida positiva
$u \odot w$, u^2, $\sqrt{u}$	operaciones elemento a elemento sobre vectores

Índice

Sobre este resumen **ii**

1 Problemas de optimización y convexidad **1**
1.1 Minimización del riesgo empírico . . . 1
1.2 Convexidad, convexidad fuerte y suavidad . . . 1
1.3 Condiciones de optimalidad . . . 2
1.4 Paisajes de pérdida no convexos . . . 3

2 Descenso de gradiente **4**
2.1 El método y el lema de descenso . . . 4
2.2 Convergencia lineal en funciones fuertemente convexas . . . 5
2.3 Análisis exacto en cuadráticas . . . 5
2.4 La función de Rosenbrock y el borde de estabilidad . . . 5

3 Descenso de gradiente estocástico **7**
3.1 El gradiente de minibatch . . . 7
3.2 Convergencia en el caso convexo . . . 8
3.3 El ruido y la tasa de aprendizaje . . . 8

4 Momentum **10**
4.1 Medias móviles exponenciales . . . 10
4.2 El método de la bola pesada . . . 10
4.3 Interpretación física . . . 11
4.4 Convergencia en cuadráticas . . . 11
4.5 Momentum de Nesterov . . . 12

5 Métodos adaptativos: AdaGrad, RMSProp y Adam **13**
5.1 Preacondicionamiento diagonal . . . 13
5.2 AdaGrad y RMSProp . . . 13
5.3 Adam . . . 14

6 Regularización y calendarios de la tasa de aprendizaje **16**
6.1 Regularización L^2 . . . 16
6.2 Decaimiento de pesos desacoplado: AdamW . . . 17
6.3 Calendarios de la tasa de aprendizaje . . . 17

Bibliografía **19**

Tema 1

Problemas de optimización y convexidad

Este tema plantea el entrenamiento de un modelo como un problema de minimización sin restricciones y reúne las herramientas de análisis que se usan en el resto del módulo: convexidad, convexidad fuerte, suavidad de Lipschitz y condiciones de optimalidad. Las definiciones y los resultados siguen los capítulos 2, 3 y 9 de [2]; la discusión sobre redes profundas sigue [9, §8.1 y §8.2] y [24, §12.1 y §12.2]. Parte de la materia de convexidad se introdujo en el módulo 4 (tema 5); aquí se completa con las constantes μ y L, que determinan la velocidad de los algoritmos.

1.1 Minimización del riesgo empírico

Definición 1.1 (Problema de optimización sin restricciones). Sea $f\colon \mathbb{R}^n \to \mathbb{R}$. El problema *minimizar* $f(\theta)$, $\theta \in \mathbb{R}^n$, consiste en hallar el *valor óptimo* $f^* = \inf_\theta f(\theta)$ y, si existe, un *minimizador global* θ^* con $f(\theta^*) = f^*$. Un punto $\bar\theta$ es un *minimizador local* si existe $r > 0$ tal que $f(\bar\theta) \le f(\theta)$ para todo θ con $\|\theta - \bar\theta\| < r$.

Definición 1.2 (Riesgo empírico). Sean N ejemplos de entrenamiento y $\ell_i(\theta)$ la pérdida del modelo de parámetros θ sobre el ejemplo i. El *riesgo empírico* es

$$J(\theta) = \frac{1}{N}\sum_{i=1}^{N} \ell_i(\theta).$$

En un modelo de lenguaje, cada ejemplo es una posición de un texto y $\ell_i(\theta) = -\ln p_\theta(x_t \mid x_{1:t-1})$ es la log-verosimilitud negativa del token observado; J es la pérdida $\mathcal{J}$ del módulo 1 (tema 5). El objetivo real no es minimizar J, sino el riesgo esperado sobre la distribución de los datos, al que J solo aproxima; por eso el aprendizaje se diferencia de la optimización pura [9, §8.1]. Este módulo trata, sin embargo, del problema de optimización.

1.2 Convexidad, convexidad fuerte y suavidad

Definición 1.3 (Conjunto y función convexos). Un conjunto $C \subseteq \mathbb{R}^n$ es *convexo* si $tx + (1-t)y \in C$ para todo $x, y \in C$ y $t \in [0,1]$. Una función $f\colon \mathbb{R}^n \to \mathbb{R}$ es *convexa* si

$$f\big(tx + (1-t)y\big) \le t f(x) + (1-t) f(y) \qquad \text{para todo } x, y \in \mathbb{R}^n,\ t \in [0,1],$$

y *estrictamente convexa* si la desigualdad es estricta cuando $x \neq y$ y $t \in (0,1)$ [2, cap. 2 y §3.1].

Teorema 1.4 (Caracterización de primer orden). *Sea f diferenciable. Entonces f es convexa si y solo si*

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) \qquad \text{para todo } x, y \in \mathbb{R}^n.$$

Geométricamente, una función convexa queda por encima de todas sus rectas (o hiperplanos) tangentes. Para funciones dos veces diferenciables, la convexidad equivale a $\nabla^2 f(x) \succeq 0$ para todo x (módulo 4, tema 5; [2, §3.1]). Las dos definiciones siguientes refuerzan esta condición por abajo y la limitan por arriba.

Definición 1.5 (Convexidad fuerte). Sea $\mu > 0$. Una función diferenciable f es *μ-fuertemente convexa* si

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|^2 \qquad \text{para todo } x, y.$$

Si f es dos veces diferenciable, esto equivale a $\nabla^2 f(x) \succeq \mu I$ para todo x [2, §9.1].

Definición 1.6 (Suavidad de Lipschitz). Sea $L > 0$. Una función diferenciable f es *L-suave* si su gradiente es lipschitziano de constante L:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\| \qquad \text{para todo } x, y.$$

Si f es dos veces diferenciable, esto equivale a que todos los autovalores de $\nabla^2 f(x)$ estén en $[-L, L]$ para todo x; para f convexa, a $\nabla^2 f(x) \preceq LI$.

Si f es μ-fuertemente convexa y L-suave, necesariamente $\mu \leq L$, y el cociente

$$\kappa = \frac{L}{\mu} \geq 1$$

se llama *número de condición* de f. En el tema 2 se demuestra que κ controla el número de iteraciones del descenso de gradiente.

1.3 Condiciones de optimalidad

Teorema 1.8 (Condición necesaria de primer orden). *Si f es diferenciable y $\bar{\theta}$ es un minimizador local, entonces $\nabla f(\bar{\theta}) = 0$.*

Un punto con $\nabla f(\bar{\theta}) = 0$ se llama *punto crítico* o *estacionario*. En general, la condición no es suficiente; para funciones convexas, sí lo es.

Teorema 1.9 (Optimalidad en el caso convexo). *Sea f convexa y diferenciable. Un punto θ^* es minimizador global si y solo si $\nabla f(\theta^*) = 0$. En particular, todo minimizador local de una función convexa es global.*

Proposición 1.10 (Minimizador de una cuadrática). *Sea $f(\theta) = \frac{1}{2}\theta^\top Q\theta + c^\top\theta + b$ con $Q \succ 0$. Su único minimizador y su valor mínimo son*

$$\theta^* = -Q^{-1}c, \qquad f^* = b - \tfrac{1}{2}\, c^\top Q^{-1} c,$$

y para todo θ se cumple $f(\theta) - f^* = \frac{1}{2}(\theta - \theta^*)^\top Q(\theta - \theta^*)$.

La identidad de la proposición 1.10 permite trasladar el minimizador al origen: en lo que sigue, al estudiar cuadráticas se supondrá sin pérdida de generalidad $f(\theta) = \frac{1}{2}\theta^\top Q\theta$, con $\theta^* = 0$ y $f^* = 0$.

Proposición 1.11 (Desigualdad de Polyak–Łojasiewicz). *Si f es μ-fuertemente convexa y diferenciable, con valor óptimo f^*, entonces*

$$\|\nabla f(x)\|^2 \geq 2\mu\big(f(x) - f^*\big) \qquad \text{para todo } x.$$

La proposición 1.11 dice que, lejos del óptimo en valor, el gradiente no puede ser pequeño. Es la propiedad que hace converger linealmente al descenso de gradiente (teorema 2.5).

1.4 Paisajes de pérdida no convexos

La pérdida de una red neuronal profunda no es convexa en sus parámetros (módulo 4, tema 5). La información local en un punto crítico la proporciona el hessiano.

Proposición 1.12 (Clasificación de puntos críticos). *Sea f de clase C^2 y $\bar\theta$ un punto crítico.*

(i) Si $\nabla^2 f(\bar\theta) \succ 0$, $\bar\theta$ es un minimizador local estricto.

(ii) Si $\nabla^2 f(\bar\theta)$ tiene un autovalor negativo, $\bar\theta$ no es minimizador local; si tiene autovalores de ambos signos, es un punto de silla.

(iii) Si $\nabla^2 f(\bar\theta) \succeq 0$ con algún autovalor nulo, el criterio no decide.

La demostración, basada en el desarrollo de Taylor de segundo orden, se dio en el módulo 4 (tema 4). El cuadro 1.1 recoge los casos con ejemplos en $\mathbb{R}^2$.

Cuadro 1.1: Puntos críticos en el origen y autovalores del hessiano.

Tipo	Autovalores de $\nabla^2 f$	Ejemplo	Comportamiento del descenso
Mínimo local	todos > 0	$x^2 + y^2$	converge si el paso es pequeño
Máximo local	todos < 0	$-x^2 - y^2$	se aleja
Punto de silla	de ambos signos	$x^2 - y^2$	se aleja salvo en un conjunto de medida nula
Valle plano	alguno nulo	x^2	no hay fuerza en la dirección plana

Observación 1.14 (El paisaje de las redes profundas). Se conocen varios hechos empíricos sobre la pérdida de las redes profundas. (i) En alta dimensión, los puntos críticos de pérdida alta son mayoritariamente sillas, no mínimos locales: un mínimo exige que todas las curvaturas sean positivas a la vez [6], [9, §8.2.3]. (ii) El espectro del hessiano se concentra cerca de cero, con un grupo menor de autovalores alejados que dependen de los datos [20]; el problema está muy mal condicionado [9, §8.2.1]. (iii) Los lotes muy grandes tienden a llevar a mínimos más agudos, que se han asociado a una peor generalización [12]. (iv) Las conexiones residuales suavizan visiblemente el paisaje [14]; se estudian en el módulo 11. Los temas siguientes desarrollan algoritmos que funcionan razonablemente en este entorno aunque su análisis se haga en el caso convexo.

Tema 2

Descenso de gradiente

El descenso de gradiente es el algoritmo del que derivan todos los optimizadores del módulo. Este tema demuestra sus garantías de convergencia en tres situaciones de generalidad decreciente: funciones suaves arbitrarias, funciones fuertemente convexas y funciones cuadráticas, en las que el análisis es exacto. El resultado central es que el número de iteraciones crece proporcionalmente al número de condición κ. Se sigue [2, §9.2 y §9.3], [24, §12.3] y las clases 21 y 22 de [22].

2.1 El método y el lema de descenso

Definición 2.1 (Descenso de gradiente). Dados $\theta_0 \in \mathbb{R}^n$ y una *tasa de aprendizaje* (o *paso*) $\eta > 0$, el *descenso de gradiente* genera la sucesión

$$\theta_{k+1} = \theta_k - \eta\, \nabla f(\theta_k), \qquad k = 0, 1, 2, \dots$$

La dirección $-\nabla f(\theta_k)$ es la de máximo descenso local (módulo 4, tema 1). Por el desarrollo de Taylor de primer orden, $f(\theta_k - \eta \nabla f(\theta_k)) = f(\theta_k) - \eta \|\nabla f(\theta_k)\|^2 + o(\eta)$, de modo que un paso suficientemente pequeño reduce f siempre que el gradiente no sea nulo. El lema siguiente cuantifica «suficientemente pequeño».

Lema 2.2 (Lema de descenso). *Si f es L-suave, para todo $x, y \in \mathbb{R}^n$,*

$$f(y) \le f(x) + \nabla f(x)^{\top}(y - x) + \frac{L}{2}\|y - x\|^2.$$

Corolario 2.3 (Descenso suficiente). *Si f es L-suave y $\theta^{+} = \theta - \eta \nabla f(\theta)$ con $0 < \eta < 2/L$, entonces*

$$f(\theta^{+}) \le f(\theta) - \eta\Big(1 - \frac{L\eta}{2}\Big)\|\nabla f(\theta)\|^2.$$

Con $\eta = 1/L$ la cota es $f(\theta^{+}) \le f(\theta) - \frac{1}{2L}\|\nabla f(\theta)\|^2$, y es la mejor que da el lema.

Teorema 2.4 (Caso no convexo). *Sea f L-suave y acotada inferiormente por f^{*}. El descenso de gradiente con $\eta = 1/L$ cumple, para todo $K \ge 1$,*

$$\min_{0 \le k < K} \|\nabla f(\theta_k)\|^2 \le \frac{2L\big(f(\theta_0) - f^{*}\big)}{K}.$$

El teorema 2.4 solo garantiza aproximarse a un punto crítico, que puede ser una silla; es la clase de garantía que cabe esperar para la pérdida de una red profunda.

2.2 Convergencia lineal en funciones fuertemente convexas

Teorema 2.5 (Convergencia lineal). *Sea f μ-fuertemente convexa y L-suave, con valor óptimo f^*. El descenso de gradiente con $\eta = 1/L$ cumple*

$$f(\theta_k) - f^* \leq \Big(1 - \frac{1}{\kappa}\Big)^k \big(f(\theta_0) - f^*\big), \qquad \kappa = \frac{L}{\mu}.$$

Corolario 2.6 (Número de iteraciones). *En las condiciones del teorema 2.5, para alcanzar $f(\theta_k) - f^* \leq \epsilon\,(f(\theta_0) - f^*)$ basta con $k \geq \kappa \ln(1/\epsilon)$ iteraciones.*

La convergencia se llama *lineal* porque el error se multiplica en cada paso por un factor constante menor que 1: el logaritmo del error decrece linealmente con k. El factor depende solo de κ. El análisis de [2, §9.3] obtiene el mismo factor $1 - \mu/L$, salvo constantes, para búsquedas lineales exacta y con retroceso.

2.3 Análisis exacto en cuadráticas

En una función cuadrática el método es lineal en θ y puede resolverse en forma cerrada. Toda función de clase C^2 es aproximadamente cuadrática cerca de un mínimo no degenerado, de modo que este caso describe el comportamiento asintótico general.

Teorema 2.8 (Descenso de gradiente en cuadráticas). *Sea $f(\theta) = \frac{1}{2}\theta^\top Q\theta$ con Q simétrica de autovalores $0 < \mu = \lambda_1 \leq \cdots \leq \lambda_n = L$. Sea $\rho(\eta) = \max_i |1 - \eta\lambda_i|$.*

(i) $\|\theta_k\| \leq \rho(\eta)^k \|\theta_0\|$, *con igualdad si θ_0 es autovector del autovalor que realiza el máximo.*

(ii) El método converge a $\theta^* = 0$ para todo θ_0 si y solo si $0 < \eta < 2/L$.

(iii) El valor de η que minimiza $\rho(\eta)$ es $\eta^* = 2/(\mu + L)$, y

$$\rho(\eta^*) = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1}.$$

Observación 2.9. El teorema 2.8 explica la conducta del método. La dirección de curvatura máxima, $\lambda_n = L$, limita el paso: $\eta < 2/L$. La dirección de curvatura mínima, $\lambda_1 = \mu$, se contrae entonces con un factor $1 - \eta\mu > 1 - 2/\kappa$, próximo a 1 si κ es grande. Con el paso óptimo, las dos direcciones extremas se contraen al mismo ritmo, pero con signos opuestos: la de curvatura alta oscila.

Corolario 2.11. *En las condiciones del teorema 2.8, con el paso óptimo, el menor k con $\rho^k \leq \epsilon$ es $k = \lceil \ln \epsilon / \ln \rho \rceil$, que para κ grande es aproximadamente $\frac{\kappa}{2}\ln(1/\epsilon)$.*

El cuadro 2.1 aplica el corolario con $\epsilon = 10^{-3}$. La última columna anticipa el resultado del tema 4: con momentum, el número de iteraciones crece como $\sqrt{\kappa}$ en lugar de como κ.

2.4 La función de Rosenbrock y el borde de estabilidad

Observación 2.13 (Borde de estabilidad). La condición $\eta < 2/\lambda_{\max}$ también se observa en redes profundas, pero en sentido inverso. Cohen *et al.* [5] observaron que, al entrenar con descenso de gradiente de paso fijo, la curvatura máxima $\lambda_{\max}$ del hessiano de la pérdida crece hasta situarse en torno a $2/\eta$ y permanece ahí; la pérdida deja de decrecer de forma monótona

Cuadro 2.1: Factor de contracción e iteraciones necesarias para reducir el error a 10^{-3} en una cuadrática, con parámetros óptimos.

κ	ρ del gradiente	Iteraciones	ρ con momentum (teorema 4.9)	Iteraciones
10	0,8182	35	0,5195	11
100	0,9802	346	0,8182	35
1000	0,9980	3454	0,9387	110

a corto plazo, pero sigue bajando a largo plazo. La red evoluciona hacia el límite de estabilidad del teorema 2.8.

Tema 3

Descenso de gradiente estocástico

Un modelo de lenguaje se entrena con billones de tokens; calcular el gradiente exacto del riesgo empírico antes de cada paso es inviable. El descenso de gradiente estocástico sustituye ese gradiente por una estimación barata obtenida de un subconjunto aleatorio de ejemplos. Este tema estudia las propiedades estadísticas de esa estimación, demuestra una garantía de convergencia en el caso convexo y explica por qué el ruido obliga a reducir la tasa de aprendizaje al final del entrenamiento. Se sigue [24, §12.4 y §12.5], [9, §8.1.3 y §8.3.1], la revisión [1] y la clase 25 de [22].

3.1 El gradiente de minibatch

Sea $J(\theta) = \frac{1}{N}\sum_{i=1}^{N} \ell_i(\theta)$ el riesgo empírico (definición 1.2), con cada ℓ_i diferenciable.

Definición 3.1 (Descenso de gradiente estocástico). Sea $B \geq 1$. En cada paso k se eligen índices $I_1, \ldots, I_B$ en $\{1, \ldots, N\}$, independientes entre sí y de los pasos anteriores, y se calcula el *gradiente de minibatch*

$$\hat{g}_k = \frac{1}{B}\sum_{b=1}^{B} \nabla \ell_{I_b}(\theta_k).$$

El *descenso de gradiente estocástico* (SGD) es la iteración $\theta_{k+1} = \theta_k - \eta_k\, \hat{g}_k$. Con $B = 1$ se obtiene el SGD en sentido estricto; con $B = N$ y sin aleatoriedad, el descenso de gradiente del tema 2.

Para un vector aleatorio $X \in \mathbb{R}^n$ se usa la *varianza total* $\operatorname{Var}[X] = \mathbb{E}\|X - \mathbb{E}X\|^2$, suma de las varianzas de las componentes. Sea, para θ fijo,

$$\sigma^2(\theta) = \frac{1}{N}\sum_{i=1}^{N} \|\nabla \ell_i(\theta) - \nabla J(\theta)\|^2,$$

la varianza de los gradientes individuales.

Teorema 3.2 (Insesgadez y varianza del minibatch). *Si $I_1, \ldots, I_B$ son independientes y uniformes en $\{1, \ldots, N\}$ (muestreo con reemplazamiento), entonces, para θ fijo,*

$$\mathbb{E}[\hat{g}] = \nabla J(\theta), \qquad \operatorname{Var}[\hat{g}] = \frac{\sigma^2(\theta)}{B}.$$

En la práctica se recorre el conjunto de datos en orden aleatorio, lo que equivale a muestrear sin reemplazamiento dentro de cada época. La varianza es entonces algo menor.

Proposición 3.3 (Muestreo sin reemplazamiento). *Si $\{I_1, \dots, I_B\}$ es un subconjunto de B índices distintos elegido uniformemente entre los $\binom{N}{B}$ posibles, con $1 \le B \le N$, entonces $\mathbb{E}[\hat{g}] = \nabla J(\theta)$ y*

$$\operatorname{Var}[\hat{g}] = \frac{\sigma^2(\theta)}{B} \cdot \frac{N - B}{N - 1}.$$

La demostración se propone en el ejercicio 3.5. El factor $(N-B)/(N-1)$ es la *corrección por población finita* de la estadística clásica: vale 1 si $B = 1$ y 0 si $B = N$, caso en que $\hat{g}$ es el gradiente exacto.

Observación 3.5 (Coste y tamaño del lote). La desviación típica del gradiente decrece como $1/\sqrt{B}$, mientras que el coste de calcularlo crece como B: duplicar el lote solo divide el ruido por $\sqrt{2} \approx 1{,}414$. Por eso suele compensar dar muchos pasos ruidosos y baratos antes que pocos exactos [9, §8.1.3]. El tamaño del lote está limitado además por el paralelismo del hardware (módulo 17). Los modelos de lenguaje usan lotes del orden de millones de tokens: GPT-3, en su versión de $175 \cdot 10^9$ parámetros, se entrenó con lotes de 3,2 millones de tokens [4, tabla 2.1]. Al aumentar el lote, Goyal *et al.* [10] propusieron escalar la tasa de aprendizaje en la misma proporción (*regla de escalado lineal*), acompañada de un calentamiento inicial.

3.2 Convergencia en el caso convexo

Teorema 3.6 (SGD en funciones convexas). *Sea f convexa y diferenciable, con minimizador θ^*. Sea la iteración $\theta_{t+1} = \theta_t - \eta_t g_t$, $t = 1, \dots, T$, donde g_t es un gradiente estocástico que, condicionado a θ_t, cumple $\mathbb{E}[g_t \mid \theta_t] = \nabla f(\theta_t)$ y $\mathbb{E}[\|g_t\|^2 \mid \theta_t] \le G^2$. Sean $r = \|\theta_1 - \theta^*\|$ y $\bar{\theta}_T = \sum_t \eta_t \theta_t / \sum_t \eta_t$. Entonces*

$$\mathbb{E}\big[f(\bar{\theta}_T)\big] - f(\theta^*) \le \frac{r^2 + G^2 \sum_{t=1}^{T} \eta_t^2}{2 \sum_{t=1}^{T} \eta_t}.$$

Corolario 3.7. *Con T fijado y paso constante $\eta_t = \eta = r/(G\sqrt{T})$, la cota del teorema 3.6 vale $rG/\sqrt{T}$.*

Corolario 3.8 (Condiciones de Robbins–Monro). *Si $\sum_{t \ge 1} \eta_t = \infty$ y $\sum_{t \ge 1} \eta_t^2 < \infty$, la cota del teorema 3.6 tiende a 0 cuando $T \to \infty$.*

Las dos condiciones del corolario 3.8 proceden del trabajo fundacional de Robbins y Monro sobre aproximación estocástica [19]: los pasos deben sumar lo suficiente para llegar a cualquier punto, pero sus cuadrados, que miden el ruido acumulado, deben ser sumables. La velocidad $O(1/\sqrt{T})$ es mucho más lenta que la convergencia lineal del teorema 2.5: es el precio del ruido.

3.3 El ruido y la tasa de aprendizaje

Con un paso constante, el SGD no converge al minimizador, sino que fluctúa a su alrededor. La proposición siguiente lo cuantifica en el caso más sencillo.

Proposición 3.9 (Suelo de ruido). *Sea $f(x) = \frac{a}{2}x^2$ con $a > 0$ y la iteración $x_{k+1} = x_k - \eta(a x_k + \xi_k)$, donde las ξ_k son variables aleatorias de media 0 y varianza s^2, independientes entre sí y de x_0. Si $0 < \eta a < 2$, entonces $\mathbb{E}[x_k] \to 0$ y*

$$\lim_{k \to \infty} \mathbb{E}[x_k^2] = \frac{\eta\, s^2}{a(2 - \eta a)}, \qquad \lim_{k \to \infty} \mathbb{E}[f(x_k)] = \frac{\eta\, s^2}{2(2 - \eta a)}.$$

El exceso de pérdida estacionario es aproximadamente $\eta s^2/4$ si $\eta a \ll 1$: proporcional a la tasa de aprendizaje y a la varianza del gradiente. Reducir η al final del entrenamiento rebaja ese suelo; es la justificación del decaimiento de la tasa de aprendizaje que se estudia en el tema 6.

Observación 3.10 (El ruido no es solo un inconveniente). En problemas no convexos, el ruido del minibatch tiene efectos favorables: una iteración exactamente sobre la variedad estable de una silla, como en el ejemplo 1.13, se desvía de ella con probabilidad 1, y los lotes pequeños tienden a encontrar mínimos más anchos [12]. Estos efectos se conocen sobre todo empíricamente; su análisis riguroso es materia de investigación.

Tema 4

Momentum

El tema 2 mostró que el descenso de gradiente es lento en valles alargados: la dirección de curvatura alta obliga a usar pasos pequeños y la de curvatura baja avanza despacio. El método de momentum, propuesto por Polyak [18] con el nombre de método de la bola pesada, corrige este defecto acumulando los gradientes pasados. Este tema lo presenta como una media móvil exponencial, lo interpreta como la discretización de un sistema mecánico con rozamiento y demuestra que, en cuadráticas, reduce el número de iteraciones de un orden κ a un orden $\sqrt{\kappa}$. Se sigue [24, §12.6], [9, §8.3.2 y §8.3.3], la clase 23 de [22] y el artículo divulgativo de Goh [8].

4.1 Medias móviles exponenciales

Definición 4.1 (Media móvil exponencial). Sean $g_1, g_2, \dots$ vectores y $\beta \in [0,1)$. La *acumulación exponencial* con $v_0 = 0$ es $v_k = \beta v_{k-1} + g_k$, y la *media móvil exponencial* es $\bar{v}_k = \beta \bar{v}_{k-1} + (1-\beta) g_k$, con $\bar{v}_0 = 0$.

Proposición 4.2. *Con la notación de la definición 4.1,*

$$v_k = \sum_{j=1}^{k} \beta^{k-j} g_j, \qquad \bar{v}_k = (1-\beta)\, v_k.$$

En particular, si $g_j = g$ para todo j, entonces $v_k = \frac{1-\beta^k}{1-\beta}\, g \to \frac{g}{1-\beta}$ y $\bar{v}_k = (1-\beta^k)\, g \to g$.

El peso de un gradiente decae geométricamente con su antigüedad; la suma total de los pesos es $1/(1-\beta)$, que se interpreta como el número efectivo de gradientes promediados [24, §12.6.1]. Con $\beta = 0{,}9$ son unos 10; con $\beta = 0{,}99$, unos 100.

4.2 El método de la bola pesada

Definición 4.3 (Momentum). Dados θ_0, $v_0 = 0$, un paso $\eta > 0$ y un coeficiente $\beta \in [0,1)$, el método de *momentum* (o de la *bola pesada*) es

$$v_{k+1} = \beta v_k + \nabla f(\theta_k), \qquad \theta_{k+1} = \theta_k - \eta\, v_{k+1}.$$

Con $\beta = 0$ se recupera el descenso de gradiente.

Proposición 4.4 (Forma de dos pasos). *Los iterados del método de momentum cumplen, para $k \geq 1$,*

$$\theta_{k+1} = \theta_k - \eta \nabla f(\theta_k) + \beta\, (\theta_k - \theta_{k-1}).$$

El término $\beta(\theta_k - \theta_{k-1})$ es la inercia: el iterado conserva una fracción β de su desplazamiento anterior. Si el gradiente es constante, la proposición 4.2 da $\eta v_k \to \eta g/(1-\beta)$: con $\beta = 0{,}9$, el

paso efectivo es diez veces el del descenso de gradiente. En un valle estrecho, las componentes del gradiente que cambian de signo de un paso al siguiente (las transversales al valle) se cancelan parcialmente en v_k, mientras que las que conservan el signo (a lo largo del valle) se acumulan.

4.3 Interpretación física

Considérese una partícula de masa $m > 0$ que se mueve en un potencial f con rozamiento viscoso de coeficiente $\gamma > 0$. Su posición $\theta(t)$ y su velocidad $u(t) = \dot{\theta}(t)$ cumplen

$$m\,\dot{u} = -\nabla f(\theta) - \gamma\, u, \qquad \dot{\theta} = u. \tag{4.1}$$

Proposición 4.6 (Disipación de energía). *Sea $E(t) = \frac{m}{2}\|u(t)\|^2 + f(\theta(t))$ la energía mecánica. A lo largo de las soluciones de (4.1), $\dot{E} = -\gamma\|u\|^2 \le 0$.*

La energía decrece mientras la partícula se mueve y solo se estabiliza cuando $u = 0$, es decir, en reposo en un punto crítico. Sin rozamiento, la energía se conserva y la partícula oscila indefinidamente.

Proposición 4.7 (Discretización). *Se discretiza (4.1) con paso temporal $\Delta t > 0$ mediante*

$$u_{k+1} = u_k + \frac{\Delta t}{m}\big(-\nabla f(\theta_k) - \gamma u_k\big), \qquad \theta_{k+1} = \theta_k + \Delta t\, u_{k+1}.$$

Con $v_k = -(m/\Delta t)\, u_k$, la iteración es exactamente el método de momentum de la definición 4.3 con

$$\beta = 1 - \frac{\gamma\,\Delta t}{m}, \qquad \eta = \frac{\Delta t^2}{m}.$$

El coeficiente β mide la fracción de velocidad que sobrevive a un paso: $\beta \to 1$ corresponde a rozamiento nulo y $\beta = 0$ a un rozamiento tan grande que la partícula olvida su velocidad en cada paso, que es el descenso de gradiente.

4.4 Convergencia en cuadráticas

Lema 4.8 (Una dirección propia). *Sea $f(z) = \frac{\lambda}{2}z^2$ con $\lambda > 0$. Los iterados del método de momentum cumplen $z_{k+1} = (1 + \beta - \eta\lambda)\, z_k - \beta z_{k-1}$, cuyo polinomio característico es*

$$p(r) = r^2 - (1 + \beta - \eta\lambda)\, r + \beta.$$

Si $(1 - \sqrt{\beta})^2 \le \eta\lambda \le (1 + \sqrt{\beta})^2$, las dos raíces de p tienen módulo $\sqrt{\beta}$.

Teorema 4.9 (Momentum óptimo en cuadráticas). *Sea $f(\theta) = \frac{1}{2}\theta^\top Q\theta$ con Q simétrica de autovalores en $[\mu, L]$, $0 < \mu < L$, y $\kappa = L/\mu$. Con*

$$\eta = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \qquad \beta = \Big(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\Big)^2,$$

la iteración lineal del método de momentum sobre el par (θ_k, θ_{k-1}) tiene radio espectral

$$\rho = \sqrt{\beta} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

Observación 4.10. El radio espectral determina la tasa asintótica: para todo $\delta > 0$ existe C tal que $\|\theta_k\| \le C(\rho + \delta)^k$. A diferencia del teorema 2.8, la matriz de la iteración no es simétrica y la constante C puede ser mayor que 1; en los extremos $\lambda = \mu$ y $\lambda = L$ la raíz es doble y aparece un factor polinómico en k. Por eso las iteraciones reales pueden ser algo más que las que predice ρ (ejercicio 4.4).

Comparando con el teorema 2.8, para κ grande, $\ln \rho_{\text{mom}} \approx -2/\sqrt{\kappa}$ frente a $\ln \rho_{\text{gd}} \approx -2/\kappa$: el número de iteraciones pasa de ser proporcional a κ a serlo a $\sqrt{\kappa}$. Con $\kappa = 100$, el factor baja de 0,9802 a 0,8182 y las iteraciones para reducir el error a 10^{-3}, de 346 a 35 (cuadro 2.1). El artículo de Goh [8] permite explorar este resultado de forma interactiva.

4.5 Momentum de Nesterov

Definición 4.12 (Momentum de Nesterov). El método de *momentum de Nesterov* evalúa el gradiente en el punto al que llevaría la inercia:

$$v_{k+1} = \beta v_k + \nabla f(\theta_k - \eta \beta v_k), \qquad \theta_{k+1} = \theta_k - \eta v_{k+1}.$$

Para funciones convexas y L-suaves, una versión de este método con β variable alcanza $f(\theta_k) - f^* = O(1/k^2)$, frente al $O(1/k)$ del descenso de gradiente, y ese orden es óptimo entre los métodos de primer orden [17]. En el caso estocástico, en cambio, el momentum de Nesterov no mejora el orden de convergencia [9, §8.3.3]. En el entrenamiento de redes profundas, el momentum se usa sobre todo a través de Adam (tema 5), cuyo primer momento es una media móvil exponencial del gradiente.

Tema 5

Métodos adaptativos: AdaGrad, RMSProp y Adam

El momentum acelera el descenso en valles mal condicionados, pero usa la misma tasa de aprendizaje en todas las coordenadas. Los métodos adaptativos asignan a cada parámetro su propio paso, dividiendo su gradiente por una estimación de su escala típica. Este tema los presenta como preacondicionadores diagonales, estudia AdaGrad y RMSProp y analiza con detalle Adam, el optimizador sobre el que se construye la receta de preentrenamiento de los modelos de lenguaje. Se sigue [24, §12.7, §12.8 y §12.10], [9, §8.5] y los artículos originales [7, 11, 13].

En todo el tema, las operaciones entre vectores (g^2, $\sqrt{s}$, cocientes) se entienden elemento a elemento.

5.1 Preacondicionamiento diagonal

Definición 5.1 (Descenso preacondicionado). Sea $D \in \mathbb{R}^{n\times n}$ diagonal con entradas positivas. El *descenso de gradiente preacondicionado* por D es $\theta_{k+1} = \theta_k - \eta\, D^{-1}\nabla f(\theta_k)$.

Proposición 5.2. *El descenso preacondicionado por D sobre f es el descenso de gradiente ordinario sobre $\tilde{f}(\varphi) = f(D^{-1/2}\varphi)$ en las variables $\varphi = D^{1/2}\theta$. Si $f(\theta) = \frac{1}{2}\theta^\top Q\theta$, el hessiano de $\tilde{f}$ es $D^{-1/2}QD^{-1/2}$.*

Si $Q = \operatorname{diag}(a_1, \dots, a_n)$ y se toma $D = Q$, el hessiano transformado es la identidad y $\kappa = 1$: el método converge en un paso con $\eta = 1$. Un buen preacondicionador diagonal iguala las curvaturas de las coordenadas. Pero solo puede corregir el mal condicionamiento alineado con los ejes; si los autovectores de Q están girados respecto de ellos, una matriz diagonal no basta (ejercicio 5.4). Los métodos de este tema estiman D a partir de los propios gradientes, sin calcular el hessiano.

5.2 AdaGrad y RMSProp

Definición 5.3 (AdaGrad). Con $s_0 = 0$ y $\varepsilon > 0$ pequeño, *AdaGrad* [7] acumula los cuadrados de los gradientes:

$$s_t = s_{t-1} + g_t^2, \qquad \theta_t = \theta_{t-1} - \eta\, \frac{g_t}{\sqrt{s_t} + \varepsilon}.$$

Proposición 5.4. *Si $\varepsilon = 0$ y una coordenada recibe un gradiente constante $g \neq 0$, su paso en la iteración t mide $\eta/\sqrt{t}$.*

El paso de AdaGrad no depende de la escala del gradiente y decrece como $1/\sqrt{t}$, un calendario incorporado que es adecuado en problemas convexos pero demasiado agresivo en el entrenamiento de redes profundas, donde la acumulación sin olvido acaba paralizando el método [9, §8.5.1].

Definición 5.5 (RMSProp). *RMSProp* [11] sustituye la suma por una media móvil exponencial de coeficiente $\rho \in (0, 1)$:

$$s_t = \rho\, s_{t-1} + (1-\rho)\, g_t^2, \qquad \theta_t = \theta_{t-1} - \eta\, \frac{g_t}{\sqrt{s_t} + \varepsilon}.$$

$\sqrt{s_t}$ estima la raíz de la media cuadrática reciente del gradiente de cada coordenada. Una coordenada con gradientes grandes recibe pasos pequeños, y viceversa. Por la proposición 4.2, con gradiente constante $s_t = (1-\rho^t)g^2$, de modo que el primer paso mide $\eta/\sqrt{1-\rho}$: unas 3,16 veces η con $\rho = 0{,}9$. Este sesgo inicial, producido por el arranque en $s_0 = 0$, es lo que corrige Adam.

5.3 Adam

Definición 5.6 (Adam). Sean $\eta > 0$, $\beta_1, \beta_2 \in [0, 1)$, $\varepsilon > 0$ y $m_0 = v_0 = 0$. Para $t = 1, 2, \ldots$, con g_t el gradiente (estocástico) en θ_{t-1}, *Adam* [13, algoritmo 1] realiza

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)\, g_t, \qquad \hat{m}_t = \frac{m_t}{1-\beta_1^t},$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2)\, g_t^2, \qquad \hat{v}_t = \frac{v_t}{1-\beta_2^t},$$

$$\theta_t = \theta_{t-1} - \eta\, \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}.$$

Los valores recomendados en el artículo original son $\eta = 10^{-3}$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ y $\varepsilon = 10^{-8}$.

Adam combina el momentum (primer momento m_t, una media móvil del gradiente) con la normalización de RMSProp (segundo momento v_t, una media móvil de su cuadrado). Las divisiones por $1-\beta_1^t$ y $1-\beta_2^t$ son la *corrección de sesgo* [13, §3].

Proposición 5.7 (Corrección de sesgo). *Si $g_t = g$ para todo t, entonces $m_t = (1-\beta_1^t)\, g$ y $\hat{m}_t = g$. Más en general, si los g_t son aleatorios con $\mathbb{E}[g_t] = \bar{g}$ para todo t, entonces $\mathbb{E}[m_t] = (1-\beta_1^t)\, \bar{g}$ y $\mathbb{E}[\hat{m}_t] = \bar{g}$. Los mismos resultados valen para v_t y $\hat{v}_t$ con g_t^2 y β_2.*

Sin corrección, m_t y v_t estarían sesgados hacia 0 al principio. Con $\beta_1 = 0{,}9$, $1-\beta_1^t$ vale 0,1 en $t = 1$, 0,19 en $t = 2$ y 0,6513 en $t = 10$; con $\beta_2 = 0{,}999$, $1-\beta_2^t$ vale 0,001 en $t = 1$ y solo 0,6323 en $t = 1000$: el sesgo de v_t persiste durante unos miles de pasos.

Proposición 5.8 (Primer paso e invariancia de escala). *Sea $\varepsilon = 0$. (i) En $t = 1$, cada coordenada con $g_1 \neq 0$ se desplaza exactamente η $\operatorname{signo}(g_1)$. (ii) Si todos los gradientes se multiplican por una constante $c > 0$, los iterados de Adam no cambian.*

La invariancia de escala significa que η fija directamente el tamaño del paso en el espacio de parámetros: Kingma y Ba observan que el desplazamiento de cada coordenada queda aproximadamente acotado por η [13, §2.1]. Esto hace a Adam mucho menos sensible que el SGD a la escala de la pérdida y a las diferencias de escala entre capas. Con $\varepsilon > 0$ la invariancia es solo aproximada; ε evita divisiones por cero cuando $\hat{v}_t \approx 0$.

Observación 5.10 (Adam en los modelos de lenguaje). Los artículos de modelos de lenguaje abiertos documentan variantes de Adam con β_2 menor que el valor recomendado: LLaMA usa AdamW con $\beta_1 = 0{,}9$ y $\beta_2 = 0{,}95$ [23, §2.3]. Con $\beta_2 = 0{,}95$, el segundo momento promedia efectivamente unos $1/(1-\beta_2) = 20$ pasos en lugar de 1000, y se adapta antes a cambios bruscos en la escala del gradiente. El precio de Adam es la memoria: guarda m y v, dos números adicionales por parámetro. En un modelo de $7 \cdot 10^9$ parámetros son $1{,}4 \cdot 10^{10}$ valores, 56 GB en precisión simple (módulo 17). Los optimizadores usados en Claude, Gemini y Grok no se han publicado.

Tema 6

Regularización y calendarios de la tasa de aprendizaje

Este tema completa la receta de optimización de los modelos de lenguaje actuales con dos ingredientes que no cambian la dirección del paso, sino su forma y su tamaño: el decaimiento de pesos y el calendario de la tasa de aprendizaje. Se estudia primero la regularización L^2 y su relación con el decaimiento de pesos, que es una equivalencia para el SGD pero no para Adam; de ahí surge AdamW. Después se definen el calentamiento lineal y el decaimiento coseno y se justifican con los resultados de los temas 3 y 5. Se sigue [9, §7.1], [24, §12.11] y los artículos [16, 15, 10].

6.1 Regularización L^2

Definición 6.1 (Regularización L^2). Sea $\lambda > 0$. La pérdida *regularizada* con penalización L^2 es

$$J_\lambda(\theta) = J(\theta) + \frac{\lambda}{2}\|\theta\|^2.$$

Proposición 6.2 (Encogimiento). *Un paso de descenso de gradiente sobre J_λ es*

$$\theta_{k+1} = (1 - \eta\lambda)\,\theta_k - \eta\,\nabla J(\theta_k).$$

Cada paso multiplica los pesos por $1-\eta\lambda < 1$ antes de aplicar el gradiente: de ahí el nombre de *decaimiento de pesos* (*weight decay*).

Proposición 6.3 (Efecto sobre el minimizador). *Sea $J(\theta) = \frac{1}{2}(\theta - c)^\top Q(\theta - c)$ con $Q = \operatorname{diag}(a_1, \dots, a_n)$, $a_i > 0$. El minimizador de J_λ es*

$$\theta_i^* = \frac{a_i}{a_i + \lambda}\, c_i, \qquad i = 1, \dots, n.$$

La regularización encoge hacia 0 cada coordenada en el factor $a_i/(a_i + \lambda)$: apenas afecta a las direcciones de curvatura grande ($a_i \gg \lambda$), en las que la pérdida es sensible, y anula casi por completo las de curvatura pequeña ($a_i \ll \lambda$) [9, §7.1.1]. Por ejemplo, con $n = 1$, $a = 2$, $c = 3$ y $\lambda = 1$, el minimizador pasa de 3 a $6/3 = 2$.

Observación 6.4 (Interpretación bayesiana). Si J es la log-verosimilitud negativa total de los datos y se adopta sobre θ una distribución a priori gaussiana $\mathcal{N}(0, \lambda^{-1} I)$, entonces $-\ln p(\theta) = \frac{\lambda}{2}\|\theta\|^2 + \text{cte}$, y minimizar J_λ equivale a maximizar la distribución a posteriori (estimación MAP; módulo 5).

6.2 Decaimiento de pesos desacoplado: AdamW

Para el SGD, regularizar con L^2 y encoger los pesos en cada paso es lo mismo (proposición 6.2). Para un método preacondicionado no lo es [16, §2].

Observación 6.5 (Adam con L^2). Si se aplica Adam a J_λ, el término $\lambda\theta$ se suma al gradiente antes de calcular m_t y v_t, y queda dividido por $\sqrt{\hat{v}_t}+\varepsilon$. Cuando la normalización está dominada por ∇J, la contribución del término de regularización al paso de la coordenada i es aproximadamente

$$\frac{\eta\lambda\,\theta_i}{\sqrt{\hat{v}_{t,i}}+\varepsilon},$$

que depende de la escala del gradiente de esa coordenada, mientras que en el SGD es $\eta\lambda\theta_i$ para todas.

Las coordenadas con gradientes grandes ($\hat{v}_{t,i}$ grande) apenas se regularizan, y las de gradientes pequeños se regularizan en exceso. Loshchilov y Hutter [16] propusieron aplicar el decaimiento fuera de la normalización.

Definición 6.6 (AdamW). Con las cantidades $\hat{m}_t$ y $\hat{v}_t$ de la definición 5.6, calculadas con el gradiente de J sin regularizar, *AdamW* [16, algoritmo 2] realiza

$$\theta_t = \theta_{t-1} - \eta_t\Big(\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\varepsilon} + \lambda\,\theta_{t-1}\Big),$$

donde η_t es la tasa de aprendizaje del calendario y λ el coeficiente de decaimiento de pesos.

En AdamW todos los pesos se encogen en el mismo factor $1-\eta_t\lambda$, con independencia de sus gradientes. El cuadro 6.1 compara ambos métodos con $\eta = 10^{-3}$, $\lambda = 0{,}1$ y $\theta = 1$.

Cuadro 6.1: Encogimiento de un peso $\theta = 1$ en un paso, con $\eta = 10^{-3}$ y $\lambda = 0{,}1$.

$\hat{v}$ de la coordenada	Adam con L^2 ($\eta\lambda\theta/\sqrt{\hat{v}}$)	AdamW ($\eta\lambda\theta$)
10^{-4}	0,01	0,0001
1	0,0001	0,0001

Observación 6.7 (Convenios). En [16], el decaimiento de pesos del SGD se escribe $\theta_{t+1} = (1-\lambda')\theta_t - \alpha\nabla J(\theta_t)$, sin multiplicar λ' por la tasa α; con ese convenio, la equivalencia con L^2 exige $\lambda = \lambda'/\alpha$ [16, proposición 1]. Aquí se sigue el convenio de la definición 6.6, en el que el decaimiento por paso es $\eta_t\lambda$ y sigue al calendario. La proposición 2 de [16] demuestra que, para un preacondicionador que no sea múltiplo de la identidad, no existe ningún coeficiente L^2 que reproduzca el decaimiento desacoplado.

6.3 Calendarios de la tasa de aprendizaje

La tasa de aprendizaje es el hiperparámetro más influyente: si es demasiado grande, el método diverge (teorema 2.8); si es demasiado pequeña, avanza despacio. Además, con gradientes estocásticos, un paso constante deja un suelo de ruido proporcional a η (proposición 3.9). Por eso no se usa un η fijo, sino un *calendario* η_t [24, §12.11].

Definición 6.9 (Calentamiento lineal y decaimiento coseno). Sean $0 \le \eta_{\min} < \eta_{\max}$, un número de pasos de calentamiento $W \ge 1$ y un número total de pasos $T > W$. El calendario

de *calentamiento lineal y decaimiento coseno* es

$$\eta(t) = \begin{cases} \eta_{\max}\,\dfrac{t}{W}, & 0 \le t < W, \\[2ex] \eta_{\min} + \dfrac{\eta_{\max} - \eta_{\min}}{2}\Big(1 + \cos\Big(\pi\,\dfrac{t - W}{T - W}\Big)\Big), & W \le t \le T. \end{cases}$$

Proposición 6.10 (Propiedades). *El calendario de la definición 6.9 es continuo en $t = W$, vale $\eta_{\max}$ en $t = W$ y $\eta_{\min}$ en $t = T$, es estrictamente decreciente en $[W, T]$ y en el punto medio del tramo coseno vale $(\eta_{\max} + \eta_{\min})/2$.*

Calentamiento. Al principio del entrenamiento, los gradientes son grandes e irregulares y los momentos de Adam se han estimado con muy pocos datos. Una tasa grande desde el primer paso puede hacer divergir la pérdida. Subir η gradualmente da tiempo a que $\hat{m}_t$ y $\hat{v}_t$ se estabilicen; el calentamiento se popularizó para entrenar con lotes grandes [10]. El ejercicio 5.7 muestra que la propia corrección de sesgo de Adam actúa como un calentamiento implícito.

Decaimiento. Por la proposición 3.9, el exceso de pérdida estacionario del SGD es proporcional a η; reducir η al final permite que los parámetros se asienten. El decaimiento coseno procede del método SGDR de Loshchilov y Hutter [15], que lo combinaba con reinicios periódicos; en el preentrenamiento se usa un único ciclo.

Observación 6.12 (La receta de los modelos de lenguaje abiertos). LLaMA documenta exactamente esta receta: AdamW con $\beta_1 = 0{,}9$, $\beta_2 = 0{,}95$, decaimiento de pesos $\lambda = 0{,}1$, recorte del gradiente a norma 1, 2000 pasos de calentamiento y decaimiento coseno hasta el 10 % de la tasa máxima [23, §2.3]. Es la misma estructura que la del ejemplo 6.11. Como se indicó en el tema 5, Anthropic, Google y xAI no han publicado los calendarios ni los optimizadores de Claude, Gemini y Grok.

Bibliografía

[1] L. Bottou, F. E. Curtis y J. Nocedal. Optimization methods for large-scale machine learning. *SIAM Review*, 60(2):223–311, 2018. https://arxiv.org/abs/1606.04838

[2] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. Cap. 2, «Convex sets»; cap. 3, «Convex functions»; cap. 9, «Unconstrained minimization». Texto del curso EE364a de Stanford. https://web.stanford.edu/~boyd/cvxbook/

[3] S. Boyd. EE364a: Convex Optimization I. Stanford University. Transparencias del curso. https://web.stanford.edu/class/ee364a/lectures.html

[4] T. B. Brown *et al.* Language models are few-shot learners. En *Advances in Neural Information Processing Systems 33 (NeurIPS)*, 2020. https://arxiv.org/abs/2005.14165

[5] J. M. Cohen, S. Kaur, Y. Li, J. Z. Kolter y A. Talwalkar. Gradient descent on neural networks typically occurs at the edge of stability. En *International Conference on Learning Representations (ICLR)*, 2021. https://arxiv.org/abs/2103.00065

[6] Y. N. Dauphin, R. Pascanu, C. Gulcehre, K. Cho, S. Ganguli e Y. Bengio. Identifying and attacking the saddle point problem in high-dimensional non-convex optimization. En *Advances in Neural Information Processing Systems 27 (NeurIPS)*, 2014. https://arxiv.org/abs/1406.2572

[7] J. Duchi, E. Hazan e Y. Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12:2121–2159, 2011.

[8] G. Goh. Why momentum really works. *Distill*, 2017. https://distill.pub/2017/momentum/

[9] I. Goodfellow, Y. Bengio y A. Courville. *Deep Learning*. MIT Press, 2016. Cap. 4, «Numerical Computation»; cap. 7, «Regularization for Deep Learning»; cap. 8, «Optimization for Training Deep Models». https://www.deeplearningbook.org/

[10] P. Goyal, P. Dollár, R. Girshick *et al.* Accurate, large minibatch SGD: Training ImageNet in 1 hour. Prepublicación, 2017. https://arxiv.org/abs/1706.02677

[11] G. Hinton, N. Srivastava y K. Swersky. Neural Networks for Machine Learning, clase 6e: «rmsprop: Divide the gradient by a running average of its recent magnitude». Curso en línea, Coursera, 2012.

[12] N. S. Keskar, D. Mudigere, J. Nocedal, M. Smelyanskiy y P. T. P. Tang. On large-batch training for deep learning: Generalization gap and sharp minima. En *International Conference on Learning Representations (ICLR)*, 2017. https://arxiv.org/abs/1609.04836

[13] D. P. Kingma y J. Ba. Adam: A method for stochastic optimization. En *International Conference on Learning Representations (ICLR)*, 2015. https://arxiv.org/abs/1412.6980

[14] H. Li, Z. Xu, G. Taylor, C. Studer y T. Goldstein. Visualizing the loss landscape of neural nets. En *Advances in Neural Information Processing Systems 31 (NeurIPS)*, 2018. https://arxiv.org/abs/1712.09913

[15] I. Loshchilov y F. Hutter. SGDR: Stochastic gradient descent with warm restarts. En *International Conference on Learning Representations (ICLR)*, 2017. https://arxiv.org/abs/1608.03983

[16] I. Loshchilov y F. Hutter. Decoupled weight decay regularization. En *International Conference on Learning Representations (ICLR)*, 2019. https://arxiv.org/abs/1711.05101

[17] Y. Nesterov. A method for solving the convex programming problem with convergence rate $O(1/k^2)$. *Soviet Mathematics Doklady*, 27:372–376, 1983.

[18] B. T. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 4(5):1–17, 1964.

[19] H. Robbins y S. Monro. A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407, 1951.

[20] L. Sagun, L. Bottou e Y. LeCun. Eigenvalues of the Hessian in deep learning: Singularity and beyond. Prepublicación, 2016. https://arxiv.org/abs/1611.07476

[21] G. Strang. *Linear Algebra and Learning from Data*. Wellesley-Cambridge Press, 2019. Texto del curso 18.065 del MIT.

[22] G. Strang. 18.065: Matrix Methods in Data Analysis, Signal Processing, and Machine Learning. Massachusetts Institute of Technology, MIT OpenCourseWare, primavera de 2018. https://ocw.mit.edu/courses/18-065-matrix-methods-in-data-analysis-signal-processing-and-machine-learning-spring-2018/

[23] H. Touvron *et al.* LLaMA: Open and efficient foundation language models. Prepublicación, 2023. https://arxiv.org/abs/2302.13971

[24] A. Zhang, Z. C. Lipton, M. Li y A. J. Smola. *Dive into Deep Learning*, versión 1.0.3. Cambridge University Press, 2023. Cap. 12, «Optimization Algorithms». https://d2l.ai/