Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

---

Fase II · Hito 2 · Examen de hito

# Hito 2

## Aprendizaje

Optimización, aprendizaje supervisado, redes neuronales,
diferenciación automática y redes profundas

---

Examen, proyecto de fase y soluciones

Edición de octubre de 2026

# Instrucciones

Este examen cierra la Fase II del curso, *Aprendizaje*, y evalúa los módulos 7 a 11. Comprueba que el estudiante sabe entrenar una red neuronal: plantear la pérdida, optimizarla, derivar sus gradientes a mano y con diferenciación automática, y mantener estable el entrenamiento.

## Condiciones

| | |
|---|---|
| Duración | 2 h 30 min |
| Material permitido | calculadora científica y una hoja A4 de fórmulas escrita a mano |
| Puntuación total | 100 puntos |
| Aprobado | 70 puntos (70 %) |
| Módulos evaluados | M07 Optimización, M08 Aprendizaje supervisado, M09 Redes neuronales, M10 Diferenciación automática, M11 Entrenamiento de redes profundas |

## Estructura y puntuación

- **Parte A. Cuestiones** (30 puntos): 20 preguntas de opción múltiple, de 1,5 puntos cada una. Cada pregunta tiene una única respuesta correcta. Las respuestas erróneas no restan.
- **Parte B. Problemas** (70 puntos): 6 problemas de desarrollo, con la puntuación indicada en cada apartado. Deben escribirse todos los pasos: el planteamiento correcto puntúa aunque el resultado numérico sea erróneo, y un error aritmético arrastrado de forma coherente solo se penaliza en el apartado en que se comete.
- El **proyecto de fase** se entrega aparte, en un plazo de dos semanas. En la nota de la fase, el examen pesa un 40 % y el proyecto un 30 %.

## Convenios

- Salvo indicación en contrario, se redondea a cuatro cifras decimales y se usan logaritmos naturales (las pérdidas se expresan en nats).
- **Vectores fila**, como en NumPy y PyTorch: $z^{(1)} = xW_1 + b_1$, $h = \varphi(z^{(1)})$, $z^{(2)} = hW_2 + b_2$, $p = \mathrm{softmax}(z^{(2)})$ y $L = -\ln p_y$. Con un lote, $x$ pasa a ser la matriz $X$ de tamaño $B \times n$ y la softmax se aplica por filas.
- Los *deltas* son $\delta^{(l)} = \partial L / \partial z^{(l)}$; con un lote, $\Delta^{(l)}$ apila los deltas de los ejemplos por filas.
- En un grafo computacional, $\bar{v} = \partial L / \partial v$ es el *adjunto* del nodo $v$ (M10, §3.1).
- Las clases se numeran $0, 1, 2, \ldots$ y $e_k$ es el vector canónico con un 1 en la posición $k$.
- $\sigma(t) = 1/(1 + e^{-t})$ es la sigmoide y $\sigma'(t) = \sigma(t)\big(1 - \sigma(t)\big)$.

## Procedencia de los problemas

Cuatro de los seis problemas de la parte B (los problemas 1 a 4) están adaptados de exámenes y hojas de problemas de cursos universitarios: dos exámenes parciales y un examen final de CS189 de Berkeley y la primera tarea de CS224N de Stanford; un apartado del problema 5 procede también de esta última. Cada problema indica su *Fuente*. Los enunciados son de redacción propia y los datos se han elegido para que puedan resolverse a mano. Las soluciones completas están en el apéndice A y la tabla de autoevaluación en el apéndice B.

# Índice

**Instrucciones** **ii**

**Parte A. Cuestiones** **1**

**Parte B. Problemas** **4**

Problema 1. Retropropagación en un perceptrón de dos capas . . . . . 4
Problema 2. Optimización . . . . . 5
Problema 3. Aprendizaje supervisado . . . . . 5
Problema 4. Diferenciación automática . . . . . 6
Problema 5. Entrenamiento de redes profundas . . . . . 6
Problema 6. Estimación de parámetros, cómputo y memoria . . . . . 7

**Proyecto de fase** **8**

**A Soluciones** **11**

A.1 Clave de la parte A . . . . . 11
A.2 Soluciones de la parte B . . . . . 12

**B Autoevaluación** **24**

B.1 Puntuación por parte . . . . . 24
B.2 Puntuación por módulo . . . . . 24
B.3 Umbral de aprobado y puerta de salida de la fase . . . . . 24
B.4 Qué hacer si no se alcanza el umbral . . . . . 25

**Bibliografía** **26**

# Parte A. Cuestiones

Veinte preguntas de opción múltiple, de 1,5 puntos cada una (30 puntos en total). Cada pregunta tiene una única respuesta correcta; las respuestas erróneas no restan. La clave y su justificación están en el apéndice A.1.

**1.** (1,5 p) Para $f(\theta) = 2\theta^2$, el descenso de gradiente con tasa constante $\eta > 0$ converge al mínimo desde cualquier $\theta_0$ si y solo si $\eta$ pertenece a

(a) $(0;\ 0{,}25)$ (b) $(0;\ 0{,}5)$ (c) $(0;\ 1)$ (d) $(0;\ 2)$

**2.** (1,5 p) En el método de la bola pesada, $v_{k+1} = \beta v_k + \nabla f(\theta_k)$ y $\theta_{k+1} = \theta_k - \eta v_{k+1}$, con $v_0 = 0$. Si $\beta = 0{,}95$ y el gradiente es constante e igual a $g$, la velocidad $v_k$ tiende a

(a) $0{,}95\,g$ (b) $1{,}95\,g$ (c) $20\,g$ (d) $95\,g$

**3.** (1,5 p) Los ejemplos de un minibatch se muestrean de forma independiente y uniforme (con reemplazamiento). Si el tamaño del minibatch se multiplica por 4, la desviación típica de cada componente del gradiente estimado

(a) se divide por 4.
(b) se divide por 2.
(c) no cambia.
(d) se multiplica por 2.

**4.** (1,5 p) En AdamW con $\eta = 10^{-3}$ y $\lambda = 0{,}01$, ¿cuánto disminuye en un paso un peso $\theta = 4$ por efecto del término de decaimiento de pesos?

(a) $4 \cdot 10^{-5}$ (b) $4 \cdot 10^{-3}$ (c) $10^{-5}$ (d) Depende de $\hat{v}_t$.

**5.** (1,5 p) El calentamiento lineal de la tasa de aprendizaje se usa sobre todo porque, al principio del entrenamiento,

(a) los pesos son demasiado pequeños para que el gradiente sea informativo.
(b) los gradientes son grandes e irregulares y los momentos de Adam ($\hat{m}_t$, $\hat{v}_t$) se han estimado con muy pocos gradientes.
(c) la pérdida es convexa y admite una tasa mayor que al final.
(d) el dropout todavía no está activado.

**6.** (1,5 p) Si $X^\top X$ es invertible, la solución de mínimos cuadrados de $\min_\theta \|X\theta - y\|^2$ es

(a) $\theta = X^\top y$
(b) $\theta = (XX^\top)^{-1} y$
(c) $\theta = (X^\top X)^{-1} X^\top y$
(d) $\theta = X^{-1} y$

**7.** (1,5 p) En regresión logística, con $p = \sigma(w^\top x + b)$ y pérdida $\ell = -\big[y \ln p + (1-y)\ln(1-p)\big]$, el gradiente $\nabla_w \ell$ es

(a) $(p - y)\, x$
(b) $p(1-p)\, x$
(c) $(y - p)\, \sigma'(w^\top x + b)$
(d) $x/p$

**8.** (1,5 p) Un modelo de caracteres con $|\mathcal{V}| = 28$ que al inicio predice la distribución uniforme tiene una entropía cruzada inicial, en nats, de

(a) 1 (b) 2,8 (c) 3,3322 (d) 28

**9.** (1,5 p) Un clasificador obtiene una exactitud de 0,99 en entrenamiento y de 0,62 en validación. Lo más probable es que sufra

(a) sesgo alto (infraajuste).
(b) varianza alta (sobreajuste).
(c) una tasa de aprendizaje demasiado baja.
(d) etiquetas erróneas en validación.

**10.** (1,5 p) La capa `nn.Linear(30, 64)` de PyTorch implementa $z = xW + b$ con $x$ de tamaño $1 \times 30$. ¿Qué forma tiene su atributo `weight`?

(a) $(30, 64)$ (b) $(64, 30)$ (c) $(1, 64)$ (d) $(30, 30)$

**11.** (1,5 p) La inicialización de Xavier con distribución normal para una capa $100 \to 200$ usa una desviación típica de

(a) 0,0577 (b) 0,0816 (c) 0,1 (d) 0,1414

**12.** (1,5 p) ¿Cuál de estas activaciones toma un valor negativo en $t = -1$?

(a) ReLU (b) GELU (c) Ambas. (d) Ninguna.

**13.** (1,5 p) La capa prealimentada SwiGLU de LLaMA 7B [10] tiene $d = 4096$, anchura oculta 11 008 y no tiene sesgos. ¿Cuántos parámetros tiene en cada bloque?

(a) 90 177 536 (b) 135 266 304 (c) 67 108 864 (d) 180 355 072

**14.** (1,5 p) Se quiere el jacobiano completo de $f\colon \mathbb{R}^{10} \to \mathbb{R}^3$ en modo inverso. ¿Cuántas pasadas hacia atrás hacen falta?

(a) 1 (b) 3 (c) 10 (d) 30

**15.** (1,5 p) Con números duales ($\varepsilon^2 = 0$), la parte en $\varepsilon$ de $(2 + \varepsilon)^3$ vale

(a) 8 (b) 6 (c) 12 (d) 3

**16.** (1,5 p) Con $\epsilon = 0$ y ganancia $g = \mathbf{1}$, para todo $x \neq 0$ el vector $\mathrm{RMSNorm}(10x)$, comparado con $\mathrm{RMSNorm}(x)$, es

(a) 10 veces mayor. (b) igual. (c) 10 veces menor. (d) Depende de $x$.

**17.** (1,5 p) Con dropout invertido de probabilidad $p = 0{,}25$, una activación $h = 4$ vale durante el entrenamiento

(a) 0 o 4 (b) 0 o 5,3333 (c) siempre 3 (d) 0 o 3

**18.** (1,5 p) El producto $260 \cdot 260$, calculado en fp16 con redondeo al más próximo, da

(a) 67 600 (b) 67 584 (c) `inf` (d) 65 504

**19.** (1,5 p) En fp16, $\exp(z)$ se desborda a infinito a partir de $z \approx$

(a) 11,09 (b) 88,72 (c) 15 (d) 65 504

**20.** (1,5 p) Entrenando en fp32, la pérdida pasa de 2,1 a `NaN` de un paso al siguiente sin haber crecido antes. Según el árbol de diagnóstico de M11, §6.4, lo primero que debe buscarse es

(a) una tasa de aprendizaje demasiado alta.
(b) un logaritmo, una división o una exponencial sin proteger.
(c) un desbordamiento de fp16.
(d) dropout activo durante la evaluación.

# Parte B. Problemas

Seis problemas de desarrollo (70 puntos en total). La puntuación de cada apartado figura entre paréntesis. Las soluciones están en el apéndice A.2; el título de cada problema enlaza con la suya.

## Problema 1. Retropropagación en un perceptrón de dos capas (18 puntos)

**Problema 1** ⋆⋆⋆ **Módulos M08 y M09.** Una red $2 \to 2 \to 3$ con activación ReLU procesa un lote de dos ejemplos. La pérdida es la entropía cruzada media del lote:

$$Z^{(1)} = XW_1 + b_1, \qquad H = \mathrm{ReLU}\big(Z^{(1)}\big), \qquad Z^{(2)} = HW_2 + b_2,$$

$$P = \mathrm{softmax}\big(Z^{(2)}\big) \text{ por filas}, \qquad L = \frac{1}{2}\sum_{i=1}^{2}\big(-\ln P_{i,y_i}\big),$$

con

$$X = \begin{pmatrix} 2 & 1 \\ 1 & -1 \end{pmatrix}, \qquad y = (0,\, 2), \qquad W_1 = \begin{pmatrix} 1 & 0{,}5 \\ -1 & 1 \end{pmatrix}, \qquad b_1 = (0;\ -0{,}5),$$

$$W_2 = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 1 \end{pmatrix}, \qquad b_2 = (0;\ 0;\ 0).$$

El primer ejemplo es de la clase 0 y el segundo, de la clase 2. Sea $Y$ la matriz de etiquetas en codificación *one-hot*.

(a) (3 p) Realice la pasada hacia delante: calcule $Z^{(1)}$, $H$, $Z^{(2)}$, $P$, la pérdida $\ell_i$ de cada ejemplo y $L$.

(b) (3 p) Para el primer ejemplo, calcule el jacobiano de la softmax, $J = \mathrm{diag}(p) - p^\top p$, y el vector fila $\partial \ell_1 / \partial p$. Compruebe que su producto es $p - e_{y_1}$ y demuestre en general que, si $\hat{y} = \mathrm{softmax}(\theta)$ y $\mathrm{CE}(y, \hat{y}) = -\sum_k y_k \ln \hat{y}_k$ con $y$ *one-hot*, entonces $\partial \mathrm{CE}/\partial \theta = \hat{y} - y$. Explique de dónde procede el factor $1/2$ de $\Delta^{(2)} = (P - Y)/2$.

(c) (3 p) Calcule $\Delta^{(2)}$, $\nabla W_2 = H^\top \Delta^{(2)}$ y $\nabla b_2$ (suma de las filas de $\Delta^{(2)}$). Compruebe las formas.

(d) (3 p) Retropropague: $\nabla H = \Delta^{(2)} W_2^\top$, $\Delta^{(1)} = \nabla H \odot \mathbf{1}\big[Z^{(1)} > 0\big]$, $\nabla W_1 = X^\top \Delta^{(1)}$ y $\nabla b_1$. Identifique la única de las cuatro unidades ocultas (dos neuronas por dos ejemplos) que está apagada y demuestre que la segunda columna de $\nabla W_1$ solo recibe la contribución del primer ejemplo.

(e) (2 p) Obtenga la expresión de $\nabla_X L$ en función de $\Delta^{(1)}$ y $W_1$, y calcúlela. ¿Qué componente de la entrada tiene más influencia sobre la pérdida?

(f) (2 p) Dé un paso de descenso de gradiente con $\eta = 0{,}5$ sobre los cuatro tensores de parámetros y recalcule la pérdida de cada ejemplo y la media. ¿Mejoran los dos ejemplos?

(g) (2 p) Para una red con una capa oculta de este tipo, con entrada de dimensión $D_x$, $H_o$ unidades ocultas y salida de dimensión $D_y$, cuente los parámetros y aplique la fórmula a esta red. Explique qué cambia en las fórmulas anteriores si la pérdida es la *suma* del lote en lugar de la media, y por qué se prefiere la media cuando se cambia el tamaño del lote.

*Fuente:* adaptado de Stanford CS224N, invierno de 2018, tarea 1, problema 2 «Neural Network Basics», apartados (b), (c) y (d) [8]. Se sustituye la sigmoide por ReLU, se añade un lote de dos ejemplos y los datos numéricos son propios.

## Problema 2. Optimización (10 puntos)

**Problema 2** ⋆⋆ **Módulo M07.** En este problema los vectores son columnas.

(a) (5 p) Sea $J(w) = w^\top A w + b^\top w$ con

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix}, \qquad b = \begin{pmatrix} -4 \\ -1 \end{pmatrix},$$

y sea el descenso de gradiente $w^{(k+1)} = w^{(k)} - \eta \nabla J\big(w^{(k)}\big)$. (i) Calcule $\nabla J$ y el minimizador $w^*$. (ii) Demuestre que el error $e^{(k)} = w^{(k)} - w^*$ cumple $e^{(k+1)} = (I - 2\eta A)\, e^{(k)}$. (iii) Deduzca la condición sobre $\eta$ para que el método converja desde cualquier punto de partida y calcule el número de condición $\kappa$ de la hessiana. (iv) Calcule la tasa $\eta^* = 2/(\mu + L)$ y el factor de contracción que produce. (v) Con $\eta^*$, dé dos pasos desde $w^{(0)} = (0, 0)^\top$.

(b) (3 p) AdamW con un único parámetro: $\theta_0 = 2$, $\eta = 0{,}1$, $\lambda = 0{,}1$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ y $\varepsilon = 0$. Los gradientes son $g_1 = 4$ y $g_2 = 1$. Calcule $m_t$, $v_t$, $\hat{m}_t$, $\hat{v}_t$ y $\theta_t$ para $t = 1$ y $t = 2$.

(c) (2 p) Un calendario combina calentamiento lineal durante $W = 500$ pasos y decaimiento coseno hasta $T = 5500$, con $\eta_{\max} = 10^{-3}$ y $\eta_{\min} = 10^{-4}$. Calcule $\eta_t$ en $t = 250$, 3000, 4250 y 5500.

*Fuente:* el apartado (a) está adaptado de Berkeley CS189, primavera de 2023, examen parcial, pregunta 2 «Convergence of Gradient Descent» [5]; se particulariza a una matriz diagonal y se añaden las preguntas (iii)–(v). Los apartados (b) y (c) son de elaboración propia.

## Problema 3. Aprendizaje supervisado (12 puntos)

**Problema 3** ⋆⋆ **Módulo M08.**

(a) (4 p) Ajuste por mínimos cuadrados la recta $y = \theta_0 + \theta_1 x$ a los datos $x = (1, 2, 3)$, $y = (1, 2, 6)$. Calcule $X^\top X$, $X^\top y$, $\hat{\theta}$, los residuos, la suma de cuadrados residual SSE y la varianza de máxima verosimilitud $\hat{\sigma}^2$ del ruido gaussiano.

(b) (4 p) *Regresión logística con un único parámetro.* Cada ejemplo tiene una característica $x \in \mathbb{R}$ y una etiqueta $y \in \{0, 1\}$. El modelo es $P(y = 1 \mid x) = \sigma(x - \alpha)$, de modo que la frontera de decisión es $x = \alpha$. Para un ejemplo, la pérdida es

$$J(\alpha) = -y \ln \sigma(x - \alpha) - (1 - y) \ln\big(1 - \sigma(x - \alpha)\big).$$

(i) Demuestre que $J'(\alpha) = y - \sigma(x - \alpha)$ y escriba la regla del SGD con paso $\epsilon > 0$. Aplíquela una vez con $\epsilon = 0{,}5$, desde $\alpha = 1$, al ejemplo $(x, y) = (3, 1)$. (ii) Calcule $J''(\alpha)$ y decida si $J$ es convexa en $\mathbb{R}$. (iii) Para los dos ejemplos $(0, 0)$ y $(2, 1)$, demuestre que la suma de las pérdidas se minimiza en $\alpha^* = 1$. (iv) Dé un conjunto de datos para el que la suma de las pérdidas no tenga mínimo en $\mathbb{R}$ y justifíquelo.

(c) (2 p) Una regresión softmax devuelve los logits $z = (1, 0, -1, 2)$ y la clase correcta es la 3. Calcule $p$, la pérdida y el gradiente respecto a $z$.

(d) (2 p) Con 1200 ejemplos se comparan 5 valores de $\lambda$ mediante validación cruzada con $k = 4$ particiones. ¿Cuántos ejemplos tiene cada partición? ¿Con cuántos se entrena en cada ronda? ¿Cuántos entrenamientos se hacen en total, contando el reentrenamiento final? ¿Por qué no se elige $\lambda$ con el conjunto de prueba?

*Fuente:* el apartado (b) está adaptado de Berkeley CS189, primavera de 2019, examen parcial, pregunta 5 «Logistic Regression with One Feature» [4]; los datos numéricos de (i) y (iii) son propios. Los apartados (a), (c) y (d) son de elaboración propia.

## Problema 4. Diferenciación automática (10 puntos)

**Problema 4** ⋆⋆ **Módulo M10.** Con entradas $a$, $b$ y $c$, se evalúa la expresión

$$d = ab, \quad e = \sigma(d), \quad f = \mathrm{ReLU}(a), \quad g = 3a, \quad h = 2e + f + g, \quad i = ch, \quad j = f + i^2,$$

en el punto $a = 1$, $b = 0$, $c = 0{,}5$. Se usa $\mathrm{ReLU}'(t) = \mathbf{1}[t \geq 0]$.

(a) (2 p) Dibuje el grafo computacional, indique qué nodos tienen más de una salida y realice la pasada hacia delante.

(b) (3 p) Aplique el modo inverso con adjuntos, empezando por $\bar{j} = 1$, hasta obtener $\partial j/\partial a$, $\partial j/\partial b$ y $\partial j/\partial c$. Escriba también $\partial j/\partial a$ como expresión simbólica en las variables $a, \ldots, i$, sin símbolos de derivada.

(c) (2 p) Repita el cálculo de $\partial j/\partial a$ en modo directo con el número dual $a = 1 + \varepsilon$, usando $\sigma(u + v\varepsilon) = \sigma(u) + \sigma'(u)\, v\varepsilon$ y $\mathrm{ReLU}(u + v\varepsilon) = \mathrm{ReLU}(u) + \mathbf{1}[u \geq 0]\, v\varepsilon$. ¿Cuántas pasadas necesitaría cada modo para obtener el gradiente completo respecto a $(a, b, c)$?

(d) (3 p) El modelo `MLPCaracteres` de M10, §6.2, tiene contexto $B = 3$, embeddings de dimensión $d = 10$, $H = 64$ unidades ocultas y $|\mathcal{V}| = 28$, con $N = 4084$ parámetros. Con un lote de 128 ejemplos, el modo inverso guarda la matriz de embeddings concatenados $E$ ($128 \times 30$), $z^{(1)}$, $h$, $z^{(2)}$ y $p$. Cuente cuántos números ocupan y compárelo con $N$. Para la capa oculta, calcule los FLOP de la pasada hacia delante y de la pasada hacia atrás (2 FLOP por multiplicación-suma) y relaciónelos con la regla $C \approx 6ND$.

*Fuente:* los apartados (a) y (b) están adaptados de Berkeley CS189, primavera de 2023, examen final, pregunta 4 «Backpropagation on an Arithmetic Expression» [6], que pide las mismas derivadas en forma simbólica; aquí se añaden valores numéricos y el modo directo. El apartado (d) es de elaboración propia.

## Problema 5. Entrenamiento de redes profundas (10 puntos)

**Problema 5** ⋆⋆ **Módulo M11.**

(a) (3 p) Demuestre que $\mathrm{softmax}(z + c\mathbf{1}) = \mathrm{softmax}(z)$ para todo $c \in \mathbb{R}$. Para los logits $z = (90, 88, 80)$, explique qué ocurre si la softmax se calcula de forma ingenua en fp32. Calcule $\mathrm{LSE}(z)$ de forma estable, $p$ y la pérdida si la clase correcta es la 1 (logit 88).

(b) (3 p) Normalice $x = (-1, 0, 2, 3)$ con LayerNorm y con RMSNorm ($\gamma = g = \mathbf{1}$, $\beta = 0$, $\epsilon = 0$). Compruebe que $\mathrm{RMSNorm}(10x) = \mathrm{RMSNorm}(x)$. ¿Ocurre lo mismo con LayerNorm? ¿Y al sumar una constante a todas las componentes?

(c) (2 p) Recorte el gradiente $g = (2, -1, 2)$ a norma global máxima $c = 1{,}5$. Una pila de 8 capas tanh escalares tiene todas sus preactivaciones en $z = 2$. Calcule el factor del gradiente sin conexiones residuales, $\prod_{\ell=1}^{8} \tanh'(2)$, y con ellas, $\big(1 \pm \tanh'(2)\big)^8$, para los dos signos.

(d) (2 p) En bf16, entre 0,5 y 1 los números representables están separados por $2^{-8}$. Se aplica a un peso $w = 1$, por separado, cada una de las actualizaciones $-0{,}001$, $-0{,}003$ y $-0{,}005$ (tres casos independientes). ¿Qué valor se obtiene en bf16 en cada caso? ¿Qué remedio usa la precisión mixta? Por otra parte, 16 bloques residuales suman a un flujo de varianza inicial 1 contribuciones incorreladas de varianza 1 cada una. ¿Qué desviación típica tiene el flujo final?

*Fuente:* la demostración del apartado (a) está adaptada de Stanford CS224N, invierno de 2018, tarea 1, problema 1(a) [8]. El resto del problema es de elaboración propia.

## Problema 6. Estimación de parámetros, cómputo y memoria (10 puntos)

**Problema 6** ⋆ **Módulos M07, M09, M10 y M11.**

(a) (3 p) Se amplía el modelo de lenguaje de caracteres: contexto $B = 5$, $|\mathcal{V}| = 28$, $d = 16$, $H = 128$, con sesgos. Cuente sus parámetros por capa. Estime los FLOP de 800 pasos con minibatches de 128 ejemplos mediante $C \approx 6ND$.

(b) (4 p) Se pasa a nivel de palabra: $|\mathcal{V}| = 50\,000$, $d = 64$, contexto de 8 palabras y $H = 512$. Cuente los parámetros por capa y el total. ¿Qué fracción está en la capa de salida? Estime la memoria de entrenamiento con AdamW en fp32 (pesos, gradientes, $m$ y $v$), sin contar las activaciones.

(c) (3 p) Se entrena el modelo de (b) con $D = 10^8$ tokens en un equipo que alcanza $10^{12}$ FLOP/s efectivos. Estime el tiempo. ¿Cabe un modelo de 7000 millones de parámetros, con la misma receta de 16 bytes por parámetro, en una GPU de 80 GB?

# Proyecto de fase

## Generador de nombres españoles con un perceptrón multicapa en PyTorch

**Objetivo.** Construir un modelo de lenguaje de caracteres basado en un perceptrón multicapa, según el modelo de Bengio *et al.* [1] estudiado en M09, §6.3, que supere en *perplejidad de validación* al modelo de bigramas del módulo 1 con los mismos datos. El punto de partida es la clase `MLPCaracteres` de M10, §6.2. El proyecto consiste en mejorarla con las técnicas de los módulos 7 y 11 y en documentar los experimentos.

**Datos y protocolo.** Son fijos, para que todos los resultados sean comparables.

- La lista de 316 nombres del cuaderno `M1_bigramas.ipynb`, con el vocabulario de $|\mathcal{V}| = 28$ símbolos

  `.abcdefghijklmnñopqrstuvwxyz`

  en el que «`.`» marca el inicio y el fin de cada nombre.
- Partición: `rng = np.random.default_rng(7)` e `idx = rng.permutation(316)`. Los 47 primeros índices (15 %) forman el conjunto de validación y los 269 restantes, el de entrenamiento.
- Perplejidad: PPL = exp(entropía cruzada media por carácter predicho), incluido el «`.`» final de cada nombre (M01, §5.1).
- Línea base: modelo de bigramas con suavizado aditivo de parámetro $\alpha$ (M01, §3.3). Con esta partición, $\alpha = 0{,}2$ da una perplejidad de validación de 12,42, y $\alpha = 1$, de 12,96. Esta cifra debe reproducirse antes de cualquier otro experimento.

**Entregables.**

1. Un cuaderno `H2-proyecto.ipynb` que se ejecute en CPU de principio a fin en menos de 3 minutos, con semilla fija.
2. Un informe de dos páginas como máximo con la arquitectura y el número de parámetros, las curvas de pérdida de entrenamiento y validación, una tabla de experimentos, la perplejidad final frente a la línea base y 20 nombres generados.
3. Una celda que compruebe con `assert` que la perplejidad de validación del perceptrón es menor que la del modelo de bigramas.

**Pasos sugeridos.**

1. Reproducir la línea base de bigramas y elegir $\alpha$ por validación (M08, §6.5).
2. Construir el conjunto de datos con un contexto de $B$ caracteres, rellenado con «`.`» al inicio. Con $B = 3$ resultan 1885 ejemplos de entrenamiento y 321 de validación.

3. Partir de `MLPCaracteres` (`nn.Embedding`, `view`, `nn.Linear`, ReLU, `nn.Linear`) y usar `F.cross_entropy` sobre los logits, que aplica la evaluación estable de log-sum-exp (M11, §6.3). Reproducir su perplejidad de validación de 10,31 (descenso de gradiente con el lote completo, $\eta = 0{,}5$, $\lambda = 0{,}005$, 1000 pasos).
4. Vigilar la validación cada pocos pasos. Sin decaimiento de pesos, el modelo memoriza los 269 nombres: perplejidad de entrenamiento 3,76 y de validación 30,73 (M09, §6.4).
5. Regularizar y optimizar: dropout (M11, §4.1), decaimiento de pesos o AdamW (M07, §6.1 y §6.2), calendario coseno (M07, §6.3) y recorte del gradiente (M11, §4.2).
6. Barrer al menos $B \in \{2, 3, 4, 5\}$ y dos valores de $H$. Repetir la mejor configuración con 3 semillas e informar de la media y la dispersión.
7. Generar nombres por muestreo con temperatura (M01, §4.3) y comentar cuáles son nuevos y cuáles están copiados del conjunto de entrenamiento.

**Referencia orientativa.** Con la receta de M10, §6.2, tres semillas dan perplejidades de 10,31, 10,36 y 10,37. Basta añadir dropout de 0,3 y alargar el contexto a $B = 4$ (4724 parámetros) para bajar a valores entre 9,92 y 10,07, con media 9,99; con $B = 5$ se obtiene 9,89 en una semilla. No es la única ruta: AdamW con minibatches de 128 ejemplos y decaimiento coseno también supera al modelo de bigramas. Con poca regularización, el sobreajuste aparece en unos cientos de pasos.

**Criterios de evaluación.** El proyecto se califica sobre 100 según la cuadro 1.

Cuadro 1: Criterios de evaluación del proyecto de fase.

| Criterio | Peso | Excelente | Suficiente | Insuficiente |
|---|---|---|---|---|
| Línea base y protocolo | 15 % | Reproduce 12,42, justifica $\alpha$ por validación y respeta la partición | Bigrama correcto con otro $\alpha$ razonable | Partición distinta o perplejidad mal calculada |
| Modelo y código PyTorch | 25 % | `nn.Module` limpio, semilla fija, menos de 3 min, `model.eval()` y `torch.no_grad()` al validar, sin fugas de validación | Funciona, pero con código repetido o lento | No se ejecuta o mezcla entrenamiento y validación |
| Resultado frente al bigrama | 25 % | Perplejidad media $\leq 10{,}1$ en 3 semillas (mejora la receta de M10, §6.2) | Supera al bigrama ($< 12{,}42$) en la semilla entregada | No lo supera |
| Experimentos y diagnóstico | 20 % | Barrido de $B$ y $H$, curvas, sobreajuste identificado y corregido, efecto de cada regularizador medido por separado | Una o dos variantes con curvas | Un único entrenamiento sin curvas |
| Informe y muestras | 15 % | Claro, dos páginas como máximo, muestras comentadas (nuevas frente a copiadas) | Completo, pero sin análisis de las muestras | Faltan el informe o las muestras |

Apéndice A

# Soluciones

Las soluciones de la parte B se presentan con el esquema de los apuntes: datos, planteamiento, desarrollo, resultado y comprobación. Los valores intermedios se redondean a cuatro decimales; cuando el redondeo altera la cuarta cifra del resultado se indica el valor obtenido con todas las cifras. Todos los resultados numéricos se han comprobado con Python (NumPy y PyTorch). Cada solución termina con las secciones de los apuntes que conviene repasar si se ha fallado.

## A.1 Clave de la parte A

| Nº | Resp. | Justificación | Apuntes |
|---|---|---|---|
| 1 | (b) | $f'' = 4 = L$; el método converge si y solo si $\lvert 1 - 4\eta\rvert < 1$, es decir, $0 < \eta < 2/L = 0{,}5$. | M07, §2.3 |
| 2 | (c) | La acumulación exponencial de un valor constante tiende a $g/(1-\beta) = g/0{,}05 = 20\,g$. | M07, §4.1 |
| 3 | (b) | $\mathrm{Var}[\hat{g}] = \sigma^2/B$; la desviación típica escala como $1/\sqrt{B}$ y $\sqrt{4} = 2$. | M07, §3.1 |
| 4 | (a) | El decaimiento desacoplado resta $\eta\lambda\theta = 10^{-3} \cdot 0{,}01 \cdot 4 = 4 \cdot 10^{-5}$, sin dividir por $\sqrt{\hat{v}_t}$. | M07, §6.2 |
| 5 | (b) | Al principio los momentos de Adam se basan en muy pocos gradientes, que además son grandes e irregulares. | M07, §6.3 |
| 6 | (c) | Anular el gradiente da las ecuaciones normales $X^\top X\theta = X^\top y$. | M08, §2.2 |
| 7 | (a) | $\sigma'$ se cancela con la derivada del logaritmo y queda $(p - y)\,x$. | M08, §3.4 |
| 8 | (c) | Con logits iguales la pérdida es $\ln K = \ln 28 = 3{,}3322$ nats. | M08, §4.5 |
| 9 | (b) | Error bajo en entrenamiento y alto en validación: el modelo memoriza y no generaliza. | M08, §5.3 |
| 10 | (b) | `nn.Linear(n, m)` guarda `weight` con forma $(m, n)$, traspuesta de $W$. | M10, §6.2 |
| 11 | (b) | $s = \sqrt{2/(100 + 200)} = \sqrt{1/150} = 0{,}0816$. | M09, §4.3 |
| 12 | (b) | $\mathrm{GELU}(-1) = -0{,}1587 < 0$, mientras que $\mathrm{ReLU}(-1) = 0$. | M09, §2.3 |
| 13 | (b) | Tres matrices de $4096 \times 11\,008$: $3 \cdot 45\,088\,768 = 135\,266\,304$. | M09, §2.4 |
| 14 | (b) | Cada pasada inversa da una fila del jacobiano; hay $m = 3$ salidas. | M10, §3.1 |
| 15 | (c) | $(2 + \varepsilon)^3 = 8 + 3 \cdot 2^2\varepsilon = 8 + 12\varepsilon$. | M10, §2.2 |
| 16 | (b) | $\mathrm{RMS}(10x) = 10\,\mathrm{RMS}(x)$ y el cociente no cambia (invariancia de escala). | M11, §3.2 |
| 17 | (b) | Se anula con probabilidad 0,25 o se divide por 0,75: $4/0{,}75 = 5{,}3333$. | M11, §4.1 |
| 18 | (c) | 67 600 supera el máximo de fp16, 65 504, y se redondea a `inf`. (En bf16 daría 67 584.) | M11, §5.1 |
| 19 | (a) | $\ln 65\,504 = 11{,}09$. (El valor 88,72 es el umbral de fp32.) | M11, §6.1 |
| 20 | (b) | Salto brusco, sin crecimiento previo y sin fp16: operación sin proteger. | M11, §6.4 |

## A.2 Soluciones de la parte B

### Solución del problema 1

**Apartado (a).** *Datos.* $X$, $y = (0, 2)$, $W_1$, $b_1 = (0;\ -0{,}5)$, $W_2$, $b_2 = 0$.

*Planteamiento.* pasada hacia delante fila a fila (M09, §5.5). La pérdida de cada ejemplo se calcula como $\ell_i = \mathrm{LSE}\big(z_i^{(2)}\big) - z_{i,y_i}^{(2)}$, que es más precisa que $-\ln P_{i,y_i}$ con $P$ redondeada (M11, §6.3).

*Desarrollo.*

1. Fila 1 de $XW_1$: $(2 \cdot 1 + 1 \cdot (-1);\ 2 \cdot 0{,}5 + 1 \cdot 1) = (1;\ 2)$; con $b_1$, $(1;\ 1{,}5)$.
2. Fila 2 de $XW_1$: $(1 + 1;\ 0{,}5 - 1) = (2;\ -0{,}5)$; con $b_1$, $(2;\ -1)$.
3. La ReLU anula el $-1$. $HW_2$: fila 1, $(1;\ 1{,}5;\ -1 + 1{,}5) = (1;\ 1{,}5;\ 0{,}5)$; fila 2, $(2;\ 0;\ -2)$.

$$Z^{(1)} = \begin{pmatrix} 1 & 1{,}5 \\ 2 & -1 \end{pmatrix}, \qquad H = \begin{pmatrix} 1 & 1{,}5 \\ 2 & 0 \end{pmatrix}, \qquad Z^{(2)} = \begin{pmatrix} 1 & 1{,}5 & 0{,}5 \\ 2 & 0 & -2 \end{pmatrix}.$$

4. Fila 1: $e^z = (2{,}7183;\ 4{,}4817;\ 1{,}6487)$, suma $8{,}8487$; $P_1 = (0{,}3072;\ 0{,}5065;\ 0{,}1863)$.
5. Fila 2: $e^z = (7{,}3891;\ 1;\ 0{,}1353)$, suma $8{,}5244$; $P_2 = (0{,}8668;\ 0{,}1173;\ 0{,}0159)$.
6. $\ell_1 = \ln 8{,}8487 - 1 = 2{,}1803 - 1 = 1{,}1803$; $\ell_2 = \ln 8{,}5244 - (-2) = 2{,}1429 + 2 = 4{,}1429$.
7. $L = (1{,}1803 + 4{,}1429)/2 = 2{,}6616$.

*Resultado.* $P = \begin{pmatrix} 0{,}3072 & 0{,}5065 & 0{,}1863 \\ 0{,}8668 & 0{,}1173 & 0{,}0159 \end{pmatrix}$, $\ell_1 = 1{,}1803$, $\ell_2 = 4{,}1429$, $L = 2{,}6616$.

*Comprobación.* cada fila de $P$ suma 1. Con $P$ redondeada, $-\ln 0{,}0159 = 4{,}1414$: por eso se usa $\mathrm{LSE}\,{-z}$. El segundo ejemplo, de la clase 2, recibe solo un 1,6 % de probabilidad.

**Apartado (b).** *Datos.* $p = (0{,}3072;\ 0{,}5065;\ 0{,}1863)$, $y_1 = 0$, $\ell_1 = -\ln p_0$.

*Planteamiento.* $J_{ij} = \partial p_i / \partial z_j = p_i(\mathbf{1}[i = j] - p_j)$ y, por la regla de la cadena con vectores fila, $\partial \ell_1 / \partial z = (\partial \ell_1 / \partial p)\, J$ (M09, §5.2).

*Desarrollo.*

1. Diagonal: $p_0(1 - p_0) = 0{,}2128$, $p_1(1 - p_1) = 0{,}2500$, $p_2(1 - p_2) = 0{,}1516$. Fuera de la diagonal: $-p_0 p_1 = -0{,}1556$, $-p_0 p_2 = -0{,}0572$, $-p_1 p_2 = -0{,}0944$.

$$J = \begin{pmatrix} 0{,}2128 & -0{,}1556 & -0{,}0572 \\ -0{,}1556 & 0{,}2500 & -0{,}0944 \\ -0{,}0572 & -0{,}0944 & 0{,}1516 \end{pmatrix}, \qquad \frac{\partial \ell_1}{\partial p} = \Big(-\frac{1}{p_0};\ 0;\ 0\Big) = (-3{,}2553;\ 0;\ 0).$$

2. Solo cuenta la primera fila de $J$:

$$-3{,}2553 \cdot (0{,}2128;\ -0{,}1556;\ -0{,}0572) = (-0{,}6927;\ 0{,}5065;\ 0{,}1862),$$

que coincide con $p - e_0 = (-0{,}6928;\ 0{,}5065;\ 0{,}1863)$ salvo redondeo en la cuarta cifra.

3. Caso general: si $y = e_k$, $\mathrm{CE} = -\ln \hat{y}_k = -\theta_k + \mathrm{LSE}(\theta)$. Como $\partial\,\mathrm{LSE}\,/\partial\theta_j = e^{\theta_j} / \sum_m e^{\theta_m} = \hat{y}_j$, se obtiene $\partial \mathrm{CE}/\partial\theta_j = \hat{y}_j - \mathbf{1}[j = k]$, es decir, $\partial \mathrm{CE}/\partial\theta = \hat{y} - y$.

4. Factor 1/2: $L = (\ell_1 + \ell_2)/2$ y $\ell_i$ solo depende de la fila $i$ de $Z^{(2)}$, luego $\partial L/\partial Z_i^{(2)} = \frac{1}{2}(P_i - e_{y_i})$. Apilando las filas, $\Delta^{(2)} = (P - Y)/2$.

*Resultado.* $(\partial \ell_1/\partial p)\, J = p - e_0 \approx (-0{,}6928;\ 0{,}5065;\ 0{,}1863)$; el factor $1/2$ procede de promediar dos ejemplos.

*Comprobación.* las filas de $J$ suman 0 $(0{,}2128 - 0{,}1556 - 0{,}0572 = 0)$, por lo que el gradiente también suma 0.

**Apartado (c).** *Datos.* $P$ y $H$ de (a); $Y = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$.

*Planteamiento.* $\Delta^{(2)} = (P - Y)/2$; $\nabla W_2 = H^\top \Delta^{(2)}$; $\nabla b_2 = \mathbf{1}^\top \Delta^{(2)}$ (M09, §5.3).

*Desarrollo.*

1. $P - Y = \begin{pmatrix} -0{,}6928 & 0{,}5065 & 0{,}1863 \\ 0{,}8668 & 0{,}1173 & -0{,}9841 \end{pmatrix}$, luego $\Delta^{(2)} = \begin{pmatrix} -0{,}3464 & 0{,}2532 & 0{,}0932 \\ 0{,}4334 & 0{,}0587 & -0{,}4921 \end{pmatrix}$.
2. Fila 1 de $\nabla W_2$: $1 \cdot \Delta_1^{(2)} + 2 \cdot \Delta_2^{(2)} = (0{,}5204;\ 0{,}3706;\ -0{,}8910)$.
3. Fila 2 de $\nabla W_2$: $1{,}5 \cdot \Delta_1^{(2)} + 0 \cdot \Delta_2^{(2)} = (-0{,}5196;\ 0{,}3799;\ 0{,}1397)$.
4. $\nabla b_2 = (-0{,}3464 + 0{,}4334;\ 0{,}2532 + 0{,}0587;\ 0{,}0932 - 0{,}4921) = (0{,}0870;\ 0{,}3119;\ -0{,}3989)$.

*Resultado.* $\nabla W_2 = \begin{pmatrix} 0{,}5204 & 0{,}3706 & -0{,}8910 \\ -0{,}5196 & 0{,}3799 & 0{,}1397 \end{pmatrix}$, $\nabla b_2 = (0{,}0870;\ 0{,}3119;\ -0{,}3989)$.

*Comprobación.* $H^\top$ $(2 \times 2)$ por $\Delta^{(2)}$ $(2 \times 3)$ da $2 \times 3$, como $W_2$. Las filas de $\nabla W_2$ y $\nabla b_2$ suman 0 porque las de $\Delta^{(2)}$ también.

**Apartado (d).** *Datos.* $\Delta^{(2)}$, $W_2$, $Z^{(1)}$ y $X$.

*Planteamiento.* la ReLU deja pasar el gradiente solo donde $Z^{(1)} > 0$ (M09, §5.4); $\nabla W_1 = X^\top \Delta^{(1)} = \sum_i x_i^\top \Delta_i^{(1)}$.

*Desarrollo.*

1. $\nabla H = \Delta^{(2)} W_2^\top$: fila 1, $(-0{,}3464 - 0{,}0932;\ 0{,}2532 + 0{,}0932) = (-0{,}4396;\ 0{,}3464)$; fila 2, $(0{,}4334 + 0{,}4921;\ 0{,}0587 - 0{,}4921) = (0{,}9255;\ -0{,}4334)$.
2. Máscara $\mathbf{1}[Z^{(1)} > 0] = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}$: está apagada la neurona 2 en el ejemplo 2 $(Z_{22}^{(1)} = -1)$. Luego $\Delta^{(1)} = \begin{pmatrix} -0{,}4396 & 0{,}3464 \\ 0{,}9255 & 0 \end{pmatrix}$.
3. Fila 1 de $\nabla W_1$: $2 \cdot (-0{,}4396;\ 0{,}3464) + 1 \cdot (0{,}9255;\ 0) = (0{,}0463;\ 0{,}6928)$. Fila 2: $1 \cdot (-0{,}4396;\ 0{,}3464) - 1 \cdot (0{,}9255;\ 0) = (-1{,}3650;\ 0{,}3464)$.
4. $\nabla b_1 = (-0{,}4396 + 0{,}9255;\ 0{,}3464 + 0) = (0{,}4859;\ 0{,}3464)$.
5. Columna 2 de $\nabla W_1$: $x_1^\top \Delta_{12}^{(1)} + x_2^\top \Delta_{22}^{(1)} = (2;\ 1)^\top \cdot 0{,}3464 + (1;\ -1)^\top \cdot 0 = (0{,}6928;\ 0{,}3464)^\top$: solo contribuye el primer ejemplo.

*Resultado.* $\nabla W_1 = \begin{pmatrix} 0{,}0463 & 0{,}6928 \\ -1{,}3650 & 0{,}3464 \end{pmatrix}$, $\nabla b_1 = (0{,}4859;\ 0{,}3464)$; la unidad apagada es la neurona 2 en el ejemplo 2.

*Comprobación.* las diferencias centradas con paso $10^{-6}$ (M09, §5.6) reproducen $\nabla W_1$ con cuatro decimales. La neurona 2 no está *muerta*: lo estaría si se apagara con todos los ejemplos (M09, §2.2).

**Apartado (e).** *Datos.* $\Delta^{(1)}$ de (d) y $W_1$.

*Planteamiento.* $Z^{(1)} = XW_1 + b_1$ es afín en $X$; por la regla de una capa afín (M09, §5.3), $\nabla_X L = \Delta^{(1)} W_1^\top$.

*Desarrollo.*

1. $W_1^\top = \begin{pmatrix} 1 & -1 \\ 0{,}5 & 1 \end{pmatrix}$.
2. Fila 1: $(-0{,}4396 + 0{,}5 \cdot 0{,}3464;\ 0{,}4396 + 0{,}3464) = (-0{,}2664;\ 0{,}7860)$.
3. Fila 2: $(0{,}9255 + 0;\ -0{,}9255 + 0) = (0{,}9255;\ -0{,}9255)$.

*Resultado.* $\nabla_X L = \Delta^{(1)} W_1^\top = \begin{pmatrix} -0{,}2664 & 0{,}7860 \\ 0{,}9255 & -0{,}9255 \end{pmatrix}$. Las mayores sensibilidades, en valor absoluto 0,9255, corresponden a las dos componentes del segundo ejemplo, el peor clasificado; en el primero domina la segunda componente.

*Comprobación.* las diferencias centradas dan el mismo resultado. Es la expresión $\partial J/\partial x = \delta^{(1)} W_1^\top$ de la fuente, con $\delta^{(1)} = \delta^{(2)} W_2^\top \odot \sigma'(z^{(1)})$ y la sigmoide sustituida por la ReLU.

**Apartado (f).** *Datos.* gradientes de (c) y (d); $\eta = 0{,}5$.

*Planteamiento.* $\theta \leftarrow \theta - \eta \nabla_\theta L$ en los cuatro tensores y nueva pasada hacia delante.

*Desarrollo.*

1. $W_1 = \begin{pmatrix} 0{,}9768 & 0{,}1536 \\ -0{,}3175 & 0{,}8268 \end{pmatrix}$, $b_1 = (-0{,}2430;\ -0{,}6732)$.
2. $W_2 = \begin{pmatrix} 0{,}7398 & -0{,}1853 & -0{,}5545 \\ 0{,}2598 & 0{,}8101 & 0{,}9301 \end{pmatrix}$, $b_2 = (-0{,}0435;\ -0{,}1559;\ 0{,}1995)$.
3. $Z^{(1)} = \begin{pmatrix} 1{,}3932 & 0{,}4608 \\ 1{,}0514 & -1{,}3464 \end{pmatrix}$ y $Z^{(2)} = \begin{pmatrix} 1{,}1069 & -0{,}0408 & -0{,}1445 \\ 0{,}7343 & -0{,}3507 & -0{,}3835 \end{pmatrix}$.
4. Fila 1: $e^z = (3{,}0250;\ 0{,}9600;\ 0{,}8654)$, suma 4,8505; $P_1 = (0{,}6237;\ 0{,}1979;\ 0{,}1784)$; $\ell_1 = -\ln 0{,}6237 = 0{,}4722$.
5. Fila 2: $e^z = (2{,}0840;\ 0{,}7042;\ 0{,}6814)$, suma 3,4696; $P_2 = (0{,}6006;\ 0{,}2030;\ 0{,}1964)$; $\ell_2 = \ln 3{,}4696 + 0{,}3835 = 1{,}6276$.
6. $L = (0{,}4722 + 1{,}6276)/2 = 1{,}0499$.

*Resultado.* $\ell_1 = 0{,}4722$ (antes 1,1803), $\ell_2 = 1{,}6276$ (antes 4,1429), $L = 1{,}0499$ (antes 2,6616). Mejoran los dos ejemplos.

*Comprobación.* con los parámetros sin redondear, PyTorch da $L = 1{,}0499$. La bajada es grande porque $\eta = 0{,}5$ es un paso generoso para una red tan pequeña.

**Apartado (g).** *Datos.* red $D_x \to H_o \to D_y$ con sesgos; aquí $D_x = 2$, $H_o = 2$, $D_y = 3$.

*Planteamiento.* cada capa afín $n \to m$ tiene $nm$ pesos y $m$ sesgos; si la pérdida es la suma, $L_{\text{suma}} = B\, L_{\text{media}}$.

*Desarrollo.*

1. Total: $D_x H_o + H_o + H_o D_y + D_y = (D_x + 1)H_o + (H_o + 1)D_y$.
2. Aquí: $(2 + 1) \cdot 2 + (2 + 1) \cdot 3 = 6 + 9 = 15$.
3. Con la suma, $\Delta^{(2)} = P - Y$ sin el factor $1/2$ y, por linealidad de la retropropagación, todos los gradientes se multiplican por $B = 2$.
4. Con la suma, la escala del gradiente crece con $B$ y habría que reajustar $\eta$ al cambiar el tamaño del lote; con la media, el gradiente de minibatch es un estimador insesgado de $\nabla J$ cuya escala no depende de $B$ (M07, §3.1).

*Resultado.* $(D_x + 1)H_o + (H_o + 1)D_y$ **parámetros, 15 en esta red; con la suma, todos los gradientes se multiplican por $B$; la media hace que $\eta$ no dependa de $B$.**

*Comprobación.* con la suma, $\nabla b_2 = 2 \cdot (0{,}0870;\ 0{,}3119;\ -0{,}3989) = (0{,}1740;\ 0{,}6238;\ -0{,}7978)$.

**Criterios de corrección.** (a) 1 p $Z^{(1)}$ y $H$, 1 p $Z^{(2)}$, 1 p $P$ y pérdidas. (b) 1 p jacobiano y producto, 1 p demostración general, 1 p factor 1/2. (c) 1 p por cada resultado. (d) 1 p $\Delta^{(1)}$ y unidad apagada, 1 p $\nabla W_1$ y $\nabla b_1$, 1 p columna 2. (e) 1 p fórmula, 1 p valores. (f) 1 p parámetros, 1 p pérdidas. (g) 1 p conteo, 1 p suma frente a media.

*Repasar:* M09, §5.2–5.5; M08, §4.3; M09, §5.6; M07, §3.1.

## Solución del problema 2

**Apartado (a).** *Datos.* $J(w) = w^\top A w + b^\top w$, $A = \operatorname{diag}(2,\ 1/2)$, $b = (-4,\ -1)^\top$, $w^{(0)} = 0$.

*Planteamiento.* $A$ es simétrica, luego $\nabla J = 2Aw + b$ y la hessiana es $2A$. En una cuadrática el descenso de gradiente es lineal en el error y se analiza por valores propios (M07, §2.3; [2, §9.3], texto del curso EE364a [3]).

*Desarrollo.*

1. $\nabla J(w) = 2Aw + b = (4w_1 - 4;\ w_2 - 1)^\top$. Se anula en $w^* = -\frac{1}{2}A^{-1}b = (1,\ 1)^\top$.
2. Restando $w^*$ a la iteración y usando $2Aw^* + b = 0$: $e^{(k+1)} = e^{(k)} - \eta(2Aw^{(k)} + b) = e^{(k)} - \eta\, 2A\big(w^{(k)} - w^*\big) = (I - 2\eta A)\, e^{(k)}$.
3. $I - 2\eta A = \operatorname{diag}(1 - 4\eta,\ 1 - \eta)$. El error tiende a 0 desde todo $e^{(0)}$ si y solo si $|1 - 4\eta| < 1$ y $|1 - \eta| < 1$, es decir, $0 < \eta < 0{,}5$. Equivale a la condición de la fuente, $0 < \lambda_i(A) < 1/\eta$.
4. Hessiana $2A = \operatorname{diag}(4, 1)$: $L = 4$, $\mu = 1$, $\kappa = L/\mu = 4$.
5. $\eta^* = 2/(\mu + L) = 2/5 = 0{,}4$; factor $(\kappa - 1)/(\kappa + 1) = 3/5 = 0{,}6$. Los factores por coordenada son $1 - 0{,}4 \cdot 4 = -0{,}6$ y $1 - 0{,}4 = 0{,}6$.
6. $e^{(0)} = (-1,\ -1)^\top$; $e^{(1)} = (0{,}6;\ -0{,}6)^\top$, luego $w^{(1)} = (1{,}6;\ 0{,}4)^\top$; $e^{(2)} = (-0{,}36;\ -0{,}36)^\top$, luego $w^{(2)} = (0{,}64;\ 0{,}64)^\top$.

*Resultado.* $w^* = (1,1)^\top$; **convergencia si y solo si** $0 < \eta < 0{,}5$; $\kappa = 4$; $\eta^* = 0{,}4$ **con factor** $0{,}6$; $w^{(1)} = (1{,}6;\ 0{,}4)^\top$, $w^{(2)} = (0{,}64;\ 0{,}64)^\top$.

*Comprobación.* directamente, $\nabla J(w^{(1)}) = (2{,}4;\ -0{,}6)^\top$ y $w^{(1)} - 0{,}4 \cdot (2{,}4;\ -0{,}6)^\top = (0{,}64;\ 0{,}64)^\top$. La primera coordenada del error cambia de signo en cada paso y la segunda no; ambas se reducen en un factor 0,6.

**Apartado (b).** *Datos.* $\theta_0 = 2$, $\eta = 0{,}1$, $\lambda = 0{,}1$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 0$, $g_1 = 4$, $g_2 = 1$.

*Planteamiento.* Adam (M07, §5.3) con el decaimiento desacoplado de AdamW (M07, §6.2): $\theta_t = \theta_{t-1} - \eta\big(\hat{m}_t/\sqrt{\hat{v}_t} + \lambda\theta_{t-1}\big)$.

*Desarrollo.*

1. $t = 1$: $m_1 = 0{,}1 \cdot 4 = 0{,}4$; $v_1 = 0{,}001 \cdot 16 = 0{,}016$; $\hat{m}_1 = 0{,}4/0{,}1 = 4$; $\hat{v}_1 = 0{,}016/0{,}001 = 16$.
2. $\hat{m}_1/\sqrt{\hat{v}_1} = 4/4 = 1$; $\lambda\theta_0 = 0{,}2$; paso $0{,}1 \cdot 1{,}2 = 0{,}12$; $\theta_1 = 1{,}88$.
3. $t = 2$: $m_2 = 0{,}36 + 0{,}1 = 0{,}46$; $v_2 = 0{,}015984 + 0{,}001 = 0{,}016984$; $\hat{m}_2 = 0{,}46/0{,}19 = 2{,}4211$; $\hat{v}_2 = 0{,}016984/0{,}001999 = 8{,}4962$.
4. $\sqrt{8{,}4962} = 2{,}9148$; $\hat{m}_2/\sqrt{\hat{v}_2} = 0{,}8306$; $\lambda\theta_1 = 0{,}188$; paso $0{,}1 \cdot 1{,}0186 = 0{,}1019$; $\theta_2 = 1{,}7781$.

| $t$ | $g_t$ | $m_t$ | $v_t$ | $\hat{m}_t$ | $\hat{v}_t$ | $\hat{m}_t/\sqrt{\hat{v}_t}$ | $\theta_t$ |
|---|---|---|---|---|---|---|---|
| 1 | 4 | 0,4 | 0,016 | 4 | 16 | 1 | 1,88 |
| 2 | 1 | 0,46 | 0,016984 | 2,4211 | 8,4962 | 0,8306 | 1,7781 |

*Resultado.* $\theta_1 = 1{,}88$, $\theta_2 = 1{,}7781$.

*Comprobación.* en $t = 1$, $\hat{m}_1/\sqrt{\hat{v}_1} = g_1/|g_1| = 1$ (M07, §5.3). `torch.optim.AdamW` con estos datos da 1,8800 y 1,7781.

**Apartado (c).** *Datos.* $\eta_{\max} = 10^{-3}$, $\eta_{\min} = 10^{-4}$, $W = 500$, $T = 5500$.

*Planteamiento.* $\eta_t = \eta_{\max} t/W$ si $t < W$, y $\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})\big(1 + \cos(\pi(t-W)/(T-W))\big)$ si $W \le t \le T$ (M07, §6.3).

*Desarrollo.*

1. $t = 250$: $10^{-3} \cdot 250/500 = 5 \cdot 10^{-4}$.
2. $\frac{1}{2}(\eta_{\max} - \eta_{\min}) = 4{,}5 \cdot 10^{-4}$ y $T - W = 5000$.
3. $t = 3000$: cociente 0,5, $\cos(\pi/2) = 0$: $10^{-4} + 4{,}5 \cdot 10^{-4} = 5{,}5 \cdot 10^{-4}$.
4. $t = 4250$: cociente 0,75, $\cos(3\pi/4) = -0{,}7071$: $10^{-4} + 4{,}5 \cdot 10^{-4} \cdot 0{,}2929 = 2{,}318 \cdot 10^{-4}$.
5. $t = 5500$: $\cos\pi = -1$: $10^{-4}$.

*Resultado.* $5 \cdot 10^{-4}$, $5{,}5 \cdot 10^{-4}$, $2{,}318 \cdot 10^{-4}$ **y** $10^{-4}$.

*Comprobación.* en el punto medio del tramo coseno, $\eta = (\eta_{\max} + \eta_{\min})/2 = 5{,}5 \cdot 10^{-4}$, como establece la proposición de M07, §6.3.

**Criterios de corrección.** (a) 1 p gradiente y $w^*$, 1 p recurrencia, 1 p condición y $\kappa$, 1 p $\eta^*$ y factor, 1 p iterados. (b) 1,5 p por fila. (c) 0,5 p por valor.

*Repasar:* M07, §2.2–2.3; M07, §5.3; M07, §6.2–6.3.

### Solución del problema 3

**Apartado (a).** *Datos.* $x = (1, 2, 3)$, $y = (1, 2, 6)$; $X$ tiene filas $(1,\, x_i)$.

*Planteamiento.* ecuaciones normales $X^\top X\theta = X^\top y$ (M08, §2.2) y $\hat\sigma^2 = \mathrm{SSE}\,/n$ (M08, §2.5; [9, §1.3]).

*Desarrollo.*

1. $X^\top X = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}$ y $X^\top y = (9;\ 23)^\top$.
2. $\det = 42 - 36 = 6$; $\hat\theta = \frac{1}{6}\begin{pmatrix} 14 & -6 \\ -6 & 3 \end{pmatrix}\begin{pmatrix} 9 \\ 23 \end{pmatrix} = \frac{1}{6}\begin{pmatrix} -12 \\ 15 \end{pmatrix} = \begin{pmatrix} -2 \\ 2{,}5 \end{pmatrix}$.
3. Predicciones $(0{,}5;\ 3;\ 5{,}5)$; residuos $y - \hat y = (0{,}5;\ -1;\ 0{,}5)$.
4. $\mathrm{SSE} = 0{,}25 + 1 + 0{,}25 = 1{,}5$; $\hat\sigma^2 = 1{,}5/3 = 0{,}5$.

*Resultado.* $\hat\theta = (-2;\ 2{,}5)$, **residuos** $(0{,}5;\ -1;\ 0{,}5)$, $\mathrm{SSE} = 1{,}5$, $\hat\sigma^2 = 0{,}5$.

*Comprobación.* el vector de residuos es ortogonal a las columnas de $X$ (M08, §2.3): suma 0 y $1 \cdot 0{,}5 + 2 \cdot (-1) + 3 \cdot 0{,}5 = 0$.

**Apartado (b).** *Datos.* $P(y = 1 \mid x) = \sigma(x - \alpha)$; $J(\alpha) = -y \ln s - (1 - y)\ln(1 - s)$ con $s = \sigma(x - \alpha)$.

*Planteamiento.* regla de la cadena con $\mathrm{d}s/\mathrm{d}\alpha = -s(1 - s)$ (M08, §3.1) y convexidad por el signo de $J''$ (M08, §3.4).

*Desarrollo.*

1. $J'(\alpha) = -y\,\dfrac{-s(1-s)}{s} - (1-y)\,\dfrac{s(1-s)}{1-s} = y(1-s) - (1-y)s = y - s$.
2. SGD: $\alpha \leftarrow \alpha - \epsilon J'(\alpha) = \alpha + \epsilon\big(\sigma(x-\alpha) - y\big)$. Con $(x, y) = (3, 1)$ y $\alpha = 1$: $s = \sigma(2) = 0{,}8808$ y $\alpha \leftarrow 1 + 0{,}5\,(0{,}8808 - 1) = 0{,}9404$.
3. $J''(\alpha) = -\mathrm{d}s/\mathrm{d}\alpha = s(1 - s) > 0$ porque $s \in (0, 1)$: $J$ es estrictamente convexa en $\mathbb{R}$.
4. Con $(0, 0)$ y $(2, 1)$: la derivada de la suma es $\big(0 - \sigma(-\alpha)\big) + \big(1 - \sigma(2 - \alpha)\big)$. En $\alpha = 1$ vale $1 - \sigma(-1) - \sigma(1) = 1 - 0{,}2689 - 0{,}7311 = 0$, porque $\sigma(-t) = 1 - \sigma(t)$. Como la suma es estrictamente convexa, $\alpha^* = 1$ es su único mínimo.
5. Si todos los ejemplos son de la clase 1, por ejemplo $\{(0, 1), (1, 1)\}$, la derivada de la suma es $\sum_i \big(1 - \sigma(x_i - \alpha)\big) > 0$: la pérdida es estrictamente creciente en $\alpha$, tiende a 0 cuando $\alpha \to -\infty$ y ese ínfimo no se alcanza. Lo mismo ocurre, con la desigualdad contraria, si todos son de la clase 0.

*Resultado.* $J'(\alpha) = y - \sigma(x - \alpha)$; **tras un paso,** $\alpha = 0{,}9404$; $J'' = s(1 - s) > 0$ **(convexa)**; $\alpha^* = 1$; **sin mínimo si todos los ejemplos son de la misma clase.**

*Comprobación.* el paso desplaza la frontera hacia la izquierda, de modo que $x = 3$ queda más claramente en la clase 1. El mínimo $\alpha^* = 1$ es el punto medio entre 0 y 2, como exige la

simetría del problema. La situación del paso 5 es la versión unidimensional del caso de datos separables de M08, §3.4: la pérdida tiene ínfimo pero no mínimo, y el SGD desplaza $\alpha$ sin límite.

**Apartado (c).** *Datos.* $z = (1,\ 0,\ -1,\ 2)$, clase correcta 3.

*Planteamiento.* $p = \mathrm{softmax}(z)$, $\ell = \mathrm{LSE}(z) - z_3$ y $\nabla_z \ell = p - e_3$ (M08, §4.3).

*Desarrollo.*

1. $e^z = (2{,}7183;\ 1;\ 0{,}3679;\ 7{,}3891)$, suma 11,4752; $p = (0{,}2369;\ 0{,}0871;\ 0{,}0321;\ 0{,}6439)$.
2. $\ell = -\ln 0{,}6439 = 0{,}4402$.
3. $\nabla_z \ell = (0{,}2369;\ 0{,}0871;\ 0{,}0321;\ -0{,}3561)$.

*Resultado.* $p \approx (0{,}2369;\ 0{,}0871;\ 0{,}0321;\ 0{,}6439)$, $\ell \approx 0{,}4402$, $\nabla_z \ell \approx (0{,}2369;\ 0{,}0871;\ 0{,}0321;\ -0{,}3561)$.

*Comprobación.* el gradiente suma 0 y $\ln 11{,}4752 - 2 = 2{,}4402 - 2 = 0{,}4402$.

**Apartado (d).** *Datos.* $n = 1200$, $k = 4$, 5 valores de $\lambda$.

*Planteamiento.* en cada ronda una partición valida y las $k - 1$ restantes entrenan; tras elegir $\lambda$ se reentrena con todos los datos (M08, §6.5).

*Desarrollo.*

1. Cada partición: $1200/4 = 300$ ejemplos; se entrena con $3 \cdot 300 = 900$.
2. Entrenamientos: $5 \cdot 4 = 20$, más el final con los 1200: 21.
3. El conjunto de prueba debe quedar intacto: si se usa para elegir $\lambda$, su error deja de ser una estimación insesgada del error de generalización (M08, §1.4).

*Resultado.* **300 por partición, 900 para entrenar en cada ronda, 21 entrenamientos.**

*Comprobación.* para cada $\lambda$, cada ejemplo valida exactamente una vez: $4 \cdot 300 = 1200$.

**Criterios de corrección.** (a) 1 p $X^\top X$ y $X^\top y$, 2 p $\hat{\theta}$, 1 p residuos, SSE y $\hat{\sigma}^2$. (b) 1 p derivada y paso, 1 p convexidad, 1 p $\alpha^*$, 1 p contraejemplo. (c) 1 p $p$, 1 p pérdida y gradiente. (d) 1 p cuentas, 1 p justificación.

*Repasar:* M08, §2.2–2.5; M08, §3.4; M08, §4.3; M08, §6.5.

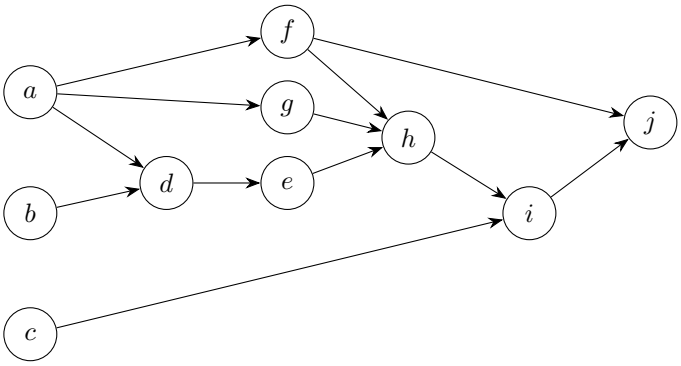
### Solución del problema 4

**Apartado (a).** *Datos.* $a = 1$, $b = 0$, $c = 0{,}5$.

*Planteamiento.* traza de evaluación en orden topológico (M10, §1.1).

*Desarrollo.*

1. Grafo: $a \to d$, $b \to d$, $d \to e$, $a \to f$, $a \to g$, $(e, f, g) \to h$, $(c, h) \to i$, $(f, i) \to j$. Tienen más de una salida $a$ (hacia $d$, $f$ y $g$) y $f$ (hacia $h$ y $j$); sus adjuntos acumulan varias contribuciones.




2. $d = 1 \cdot 0 = 0$; $e = \sigma(0) = 0{,}5$; $f = \mathrm{ReLU}(1) = 1$; $g = 3$.
3. $h = 2 \cdot 0{,}5 + 1 + 3 = 5$; $i = 0{,}5 \cdot 5 = 2{,}5$; $j = 1 + 2{,}5^2 = 7{,}25$.

*Resultado.* $d = 0,\ e = 0{,}5,\ f = 1,\ g = 3,\ h = 5,\ i = 2{,}5,\ j = 7{,}25$.

*Comprobación.* $j = f + (c(2\sigma(ab) + \mathrm{ReLU}(a) + 3a))^2 = 1 + (0{,}5 \cdot 5)^2 = 7{,}25$.

**Apartado (b).** *Datos.* valores de (a); $\sigma'(0) = 0{,}25$; $\mathrm{ReLU}'(1) = 1$.

*Planteamiento.* recorrido inverso con $\bar{j} = 1$; cada nodo suma (`+=`) las contribuciones de todos sus sucesores (M10, §3.1–3.2): los gradientes se suman en las bifurcaciones [7].

*Desarrollo.*

1. $\bar{\imath} = \bar{\jmath} \cdot 2i = 5$.
2. $\bar{h} = \bar{\imath} \cdot c = 2{,}5$ y $\bar{c} = \bar{\imath} \cdot h = 25$.
3. $\bar{e} = 2\bar{h} = 5$; $\bar{g} = \bar{h} = 2{,}5$; $\bar{f} = \bar{\jmath} \cdot 1 + \bar{h} \cdot 1 = 1 + 2{,}5 = 3{,}5$ (dos contribuciones).
4. $\bar{d} = \bar{e}\,\sigma'(d) = 5 \cdot 0{,}25 = 1{,}25$; $\bar{b} = \bar{d} \cdot a = 1{,}25$.
5. $\bar{a} = \bar{d} \cdot b + \bar{f} \cdot \mathbf{1}[a \geq 0] + \bar{g} \cdot 3 = 0 + 3{,}5 + 7{,}5 = 11$ (tres contribuciones).
6. Simbólicamente, como en la fuente: $\dfrac{\partial j}{\partial a} = 4icb\,\sigma(d)\big(1 - \sigma(d)\big) + (2ic + 1)\,\mathbf{1}[a \geq 0] + 6ic$.

*Resultado.* $\partial j/\partial a = 11$, $\partial j/\partial b = 1{,}25$, $\partial j/\partial c = 25$.

*Comprobación.* la expresión simbólica da $0 + (2 \cdot 2{,}5 \cdot 0{,}5 + 1) + 6 \cdot 2{,}5 \cdot 0{,}5 = 3{,}5 + 7{,}5 = 11$. Las diferencias centradas con paso $10^{-6}$ dan 11,0000, 1,2500 y 25,0000.

**Apartado (c).** *Datos.* $a = 1 + \varepsilon$, $b = 0$, $c = 0{,}5$.

*Planteamiento.* se propaga el par (valor, tangente); la parte en $\varepsilon$ de $j$ es $\partial j/\partial a$ (M10, §2.2).

*Desarrollo.*

1. $d = (1 + \varepsilon) \cdot 0 = 0$; $e = \sigma(0) = 0{,}5$; $f = 1 + \varepsilon$; $g = 3 + 3\varepsilon$.
2. $h = 1 + (1 + \varepsilon) + (3 + 3\varepsilon) = 5 + 4\varepsilon$; $i = 2{,}5 + 2\varepsilon$.
3. $i^2 = 6{,}25 + 2 \cdot 2{,}5 \cdot 2\varepsilon = 6{,}25 + 10\varepsilon$ (pues $\varepsilon^2 = 0$); $j = 7{,}25 + 11\varepsilon$.
4. El modo directo da una columna del jacobiano por pasada: el gradiente respecto a $(a, b, c)$ exige 3 pasadas, frente a 1 del modo inverso (M10, §2.3 y §4.2).

*Resultado.* $j = 7{,}25 + 11\varepsilon$**: coincide con el modo inverso. Directo: 3 pasadas; inverso: 1.**

*Comprobación.* la parte real, 7,25, es el valor de (a).

**Apartado (d).** *Datos.* lote de 128; $E$ ($128 \times 30$), $z^{(1)}$ y $h$ ($128 \times 64$), $z^{(2)}$ y $p$ ($128 \times 28$); $N = 4084$; capa oculta $30 \to 64$.

*Planteamiento.* contar elementos de los tensores guardados (M10, §5.1); un producto $(B \times n)(n \times k)$ cuesta $2Bnk$ FLOP y la pasada hacia atrás hace dos productos del mismo tamaño (M10, §4.4).

*Desarrollo.*

1. $E$: $128 \cdot 30 = 3840$; $z^{(1)}$ y $h$: $2 \cdot 128 \cdot 64 = 16\,384$; $z^{(2)}$ y $p$: $2 \cdot 128 \cdot 28 = 7168$.
2. Total: $3840 + 16\,384 + 7168 = 27\,392$ números, $27\,392/4084 = 6{,}71$ veces los parámetros.
3. Pesos de la capa oculta: $30 \cdot 64 = 1920$. Hacia delante: $2 \cdot 128 \cdot 1920 = 491\,520$ FLOP.
4. Hacia atrás ($\bar{E}W^\top$ y $E^\top \bar{Z}$): $2 \cdot 491\,520 = 983\,040$ FLOP.
5. Total: $1\,474\,560 = 6 \cdot 1920 \cdot 128$.

*Resultado.* 27 392 **activaciones guardadas (**$\approx 6{,}7$ **veces** $N$**);** 491 520 **FLOP hacia delante y** 983 040 **hacia atrás, en total** $6ND$ **con** $N = 1920$ **y** $D = 128$**.**

*Comprobación.* la proporción 1 : 2 entre las dos pasadas es la que da la regla $C \approx 6ND$ (M10, §4.4). Las activaciones crecen con el tamaño del lote y los parámetros no; por eso dominan la memoria del entrenamiento (M10, §5.1).

**Criterios de corrección.** (a) 1 p grafo, 1 p valores. (b) 1 p adjuntos hasta $\bar{d}$, 1 p acumulación en $\bar{f}$ y $\bar{a}$, 1 p expresión simbólica. (c) 1 p dual, 1 p número de pasadas. (d) 1,5 p memoria, 1,5 p FLOP.

*Repasar:* M10, §1.1; M10, §2.2–2.3; M10, §3.1–3.2; M10, §4.4; M10, §5.1.

### Solución del problema 5

**Apartado (a).** *Datos.* $z = (90, 88, 80)$; máximo de fp32 $3{,}40 \cdot 10^{38} = e^{88{,}72}$; clase correcta 1.

*Planteamiento.* $\mathrm{LSE}(z) = c + \ln \sum_i e^{z_i - c}$ con $c = \max_i z_i$ (M11, §6.2) y pérdida $\mathrm{LSE}(z) - z_1$ (M11, §6.3).

*Desarrollo.*

1. Invariancia: $e^{z_i + c} = e^c e^{z_i}$ y el factor $e^c > 0$ es común al numerador y al denominador, luego se cancela.
2. Ingenuo: $e^{90} = 1{,}22 \cdot 10^{39} > 3{,}40 \cdot 10^{38}$ da `inf`; el denominador también es `inf` y `inf/inf` = `NaN`.
3. $z - 90 = (0, -2, -10)$; $e^{z-90} = (1;\ 0{,}1353;\ 4{,}540 \cdot 10^{-5})$; suma 1,1354; $\ln 1{,}1354 = 0{,}1270$.
4. $\mathrm{LSE}(z) = 90{,}1270$; $p = (0{,}8808;\ 0{,}1192;\ 4{,}00 \cdot 10^{-5})$.
5. Pérdida: $90{,}1270 - 88 = 2{,}1270$.

*Resultado.* **ingenuo:** `inf` **y** `NaN`; $\mathrm{LSE}(z) = 90{,}1270$; $p \approx (0{,}8808;\ 0{,}1192;\ 4{,}0 \cdot 10^{-5})$; **pérdida** 2,1270.

*Comprobación.* $-\ln 0{,}1192 = 2{,}127$. Cotas: $\max z \le \mathrm{LSE}(z) \le \max z + \ln 3$, es decir, $90 \le 90{,}127 \le 91{,}099$.

**Apartado (b).** *Datos.* $x = (-1, 0, 2, 3)$, $d = 4$, $\epsilon = 0$.

*Planteamiento.* $\mathrm{LN}(x) = (x - \mu)/\sigma$ y $\mathrm{RMSNorm}(x) = x/\,\mathrm{RMS}(x)$ (M11, §3.1); invariancias de M11, §3.2.

*Desarrollo.*

1. $\mu = 1$; $x - \mu = (-2, -1, 1, 2)$; $\sigma^2 = 10/4 = 2{,}5$; $\sigma = 1{,}5811$; $\mathrm{LN}(x) = (-1{,}2649;\ -0{,}6325;\ 0{,}6325;\ 1{,}2649)$.
2. $\mathrm{RMS}(x) = \sqrt{14/4} = \sqrt{3{,}5} = 1{,}8708$; $\mathrm{RMSNorm}(x) = (-0{,}5345;\ 0;\ 1{,}0690;\ 1{,}6036)$.
3. $\mathrm{RMS}(10x) = \sqrt{350} = 18{,}708 = 10\,\mathrm{RMS}(x)$, luego $\mathrm{RMSNorm}(10x) = \mathrm{RMSNorm}(x)$.
4. LayerNorm también es invariante a la escala: $\mu$ y $\sigma$ se multiplican por 10 y el cociente no cambia.
5. Traslación: $\mathrm{LN}(x + c\mathbf{1}) = \mathrm{LN}(x)$, porque la media absorbe $c$; RMSNorm no lo es: $\mathrm{RMSNorm}(x + \mathbf{1}) = (0;\ 1;\ 3;\ 4)/\sqrt{6{,}5} = (0;\ 0{,}3922;\ 1{,}1767;\ 1{,}5689)$.

*Resultado.* $\mathrm{LN}(x) \approx (-1{,}2649;\ -0{,}6325;\ 0{,}6325;\ 1{,}2649)$, $\mathrm{RMSNorm}(x) \approx (-0{,}5345;\ 0;\ 1{,}0690;\ 1{,}6036)$; **ambas son invariantes a la escala y solo LN lo es a la traslación.**

*Comprobación.* la media de los cuadrados de ambas salidas vale 1: $(1{,}6 + 0{,}4 + 0{,}4 + 1{,}6)/4 = 1$ y $(0{,}2857 + 0 + 1{,}1429 + 2{,}5714)/4 = 1$.

**Apartado (c).** *Datos.* $g = (2, -1, 2)$, $c = 1{,}5$; 8 capas con $z = 2$.

*Planteamiento.* recorte $g \cdot \min(1, c/\|g\|)$ (M11, §4.2); factor plano $\prod \tanh'(z)$ (M11, §1.3) y residual $(1 \pm \tanh'(z))^8$ (M11, §2.2).

*Desarrollo.*

1. $\|g\| = 3 > 1{,}5$; factor $0{,}5$; $g = (1;\ -0{,}5;\ 1)$.
2. $\tanh 2 = 0{,}9640$; $\tanh'(2) = 1 - 0{,}9640^2 = 0{,}07065$.
3. Sin residuos: $0{,}07065^8 = 6{,}21 \cdot 10^{-10}$.
4. Con residuos: $1{,}07065^8 = 1{,}7266$ y $0{,}92935^8 = 0{,}5565$.

*Resultado.* $g = (1;\ -0{,}5;\ 1)$; **factor plano** $6{,}21 \cdot 10^{-10}$; **residual** 1,7266 **(+) o** 0,5565 **(−).**

*Comprobación.* $\|(1; -0{,}5; 1)\| = \sqrt{2{,}25} = 1{,}5 = c$. La identidad mantiene el gradiente en orden 1, frente a $10^{-10}$ sin ella.

**Apartado (d).** *Datos.* separación $2^{-8} = 0{,}00390625$ en $[0{,}5;\ 1)$; $w = 1$; tres actualizaciones independientes; 16 contribuciones de varianza 1.

*Planteamiento.* redondeo al representable más próximo (M11, §5.2); las varianzas de sumandos incorrelados se suman (M11, §2.3).

*Desarrollo.*

1. Vecinos por debajo de 1: 0,99609 y 0,99219; medio hueco, $2^{-9} = 0{,}00195$.
2. 0,999 dista 0,001 $<$ 0,00195 de 1: se redondea a 1 y la actualización se pierde.
3. 0,997 dista 0,00091 de 0,99609: se redondea a 0,99609.
4. 0,995 dista 0,00109 de 0,99609 y 0,0028 de 0,99219: se redondea a 0,99609.
5. Remedio: copia maestra de los pesos en fp32 y acumulación de las actualizaciones en fp32 (M11, §5.3).
6. Flujo: Var $= 1 + 16 \cdot 1 = 17$; desviación típica $\sqrt{17} = 4{,}1231$.

*Resultado.* 1**;** 0,9961**;** 0,9961 **(la primera actualización se pierde y las otras dos dan el mismo peso); desviación típica del flujo** $\sqrt{17} \approx 4{,}1231$**.**

*Comprobación.* PyTorch con `dtype=torch.bfloat16` da 1,0, 0,99609375 y 0,99609375. El crecimiento como $\sqrt{L}$ motiva la normalización previa y el escalado de las proyecciones residuales (M11, §2.3).

**Criterios de corrección.** (a) 1 p invariancia y diagnóstico, 1 p LSE, 1 p $p$ y pérdida. (b) 1 p LN, 1 p RMSNorm, 1 p invariancias. (c) 1 p recorte, 1 p factores. (d) 1 p redondeos y remedio, 1 p desviación típica.

*Repasar:* M11, §6.2–6.3; M11, §3.1–3.2; M11, §4.2; M11, §1.3; M11, §2.2–2.3; M11, §5.2–5.3.

### Solución del problema 6

**Apartado (a).** *Datos.* $B = 5$, $|\mathcal{V}| = 28$, $d = 16$, $H = 128$, con sesgos; 800 pasos de 128 ejemplos.

*Planteamiento.* parámetros por capa como en M09, §6.3; $C \approx 6ND$ con $D$ el número de ejemplos procesados (M10, §4.4).

*Desarrollo.*

1. Embeddings: $28 \cdot 16 = 448$.
2. Oculta: entrada $5 \cdot 16 = 80$; $80 \cdot 128 + 128 = 10\,368$.
3. Salida: $128 \cdot 28 + 28 = 3612$.
4. $N = 448 + 10\,368 + 3612 = 14\,428$; $D = 800 \cdot 128 = 102\,400$; $C = 6 \cdot 14\,428 \cdot 102\,400 = 8{,}86 \cdot 10^9$ FLOP.

*Resultado.* $N = 14\,428$; $C \approx 8{,}86 \cdot 10^9$ **FLOP**, unos segundos en un portátil.

*Comprobación.* la consulta de embeddings no es un producto de matrices; sin ella, $6 \cdot 13\,980 \cdot 102\,400 = 8{,}59 \cdot 10^9$. La regla es una cota por exceso.

**Apartado (b).** *Datos.* $|\mathcal{V}| = 50\,000$, $d = 64$, contexto 8, $H = 512$.

*Planteamiento.* mismo conteo; AdamW en fp32 guarda pesos, gradientes, $m$ y $v$: $4 \cdot 4 = 16$ bytes por parámetro (M07, §5.3).

*Desarrollo.*

1. Embeddings: $50\,000 \cdot 64 = 3\,200\,000$.

2. Oculta: $(8 \cdot 64) \cdot 512 + 512 = 262\,656$.
3. Salida: $512 \cdot 50\,000 + 50\,000 = 25\,650\,000$.
4. $N = 29\,112\,656$; fracción de la salida: $25\,650\,000/29\,112\,656 = 0{,}8811$.
5. Memoria: $16 \cdot 29\,112\,656 = 465\,802\,496$ bytes $\approx 466$ MB (444 MiB).

*Resultado.* $N = 29\,112\,656$; **la salida es el** 88,1 %; $\approx 466$ **MB**.

*Comprobación.* embeddings y salida suman el 99,1 %: en los modelos pequeños, el vocabulario domina el recuento (M08, §4.5).

**Apartado (c).** *Datos.* $N = 2{,}911 \cdot 10^7$, $D = 10^8$, $10^{12}$ FLOP/s; $7 \cdot 10^9$ parámetros a 16 bytes; 80 GB.

*Planteamiento.* tiempo $= 6ND/(\text{FLOP/s})$; memoria $= 16N$ bytes.

*Desarrollo.*

1. $C = 6 \cdot 2{,}911 \cdot 10^7 \cdot 10^8 = 1{,}747 \cdot 10^{16}$ FLOP.
2. Tiempo: $1{,}747 \cdot 10^{16}/10^{12} = 17\,468$ s $= 4{,}85$ h.
3. $16 \cdot 7 \cdot 10^9 = 1{,}12 \cdot 10^{11}$ bytes $= 112$ GB $> 80$ GB: no cabe.

*Resultado.* $\approx 1{,}75 \cdot 10^{16}$ **FLOP, unas 4,9 h; el modelo de 7000 millones necesita 112 GB y no cabe en 80 GB**. Habría que repartir el estado del optimizador entre varias GPU o reducir la precisión (anticipo del módulo 17).

*Comprobación.* orden de magnitud: $6 \cdot 3 \cdot 10^7 \cdot 10^8 = 1{,}8 \cdot 10^{16}$ y $1{,}8 \cdot 10^4$ s $\approx 5$ h.

**Criterios de corrección.** (a) 2 p conteo, 1 p FLOP. (b) 2 p conteo, 1 p fracción, 1 p memoria. (c) 2 p tiempo, 1 p conclusión. Se aceptan resultados dentro de un factor 2 si el razonamiento es correcto.

*Repasar:* M09, §6.3; M10, §4.4; M07, §5.3; M08, §4.5.

Apéndice B

# Autoevaluación

## B.1 Puntuación por parte

| Parte | Contenido | Puntos | Nota obtenida |
|---|---|---|---|
| A | Cuestiones ($20 \times 1{,}5$) | 30 | |
| B1 | Retropropagación en un perceptrón de dos capas | 18 | |
| B2 | Optimización | 10 | |
| B3 | Aprendizaje supervisado | 12 | |
| B4 | Diferenciación automática | 10 | |
| B5 | Entrenamiento de redes profundas | 10 | |
| B6 | Estimación de parámetros, cómputo y memoria | 10 | |
| | **Total** | **100** | |

La nota sobre 10 es la puntuación total dividida por 10. La nota de la fase es

$$0{,}4 \cdot \text{examen} + 0{,}3 \cdot \text{proyecto} + 0{,}2 \cdot \text{ejercicios} + 0{,}1 \cdot \text{tests},$$

y exige, además, al menos un 70 % en este examen.

## B.2 Puntuación por módulo

La tabla reparte los 100 puntos entre los módulos. El problema 6 combina varios módulos y se contabiliza aparte.

| Módulo | Cuestiones | Puntos A | Problemas | Puntos B | Total |
|---|---|---|---|---|---|
| M07 Optimización | 1–5 | 7,5 | 2; 1(g) | 10 + 1 | 18,5 |
| M08 Aprendizaje supervisado | 6–9 | 6 | 3; 1(b) | 12 + 3 | 21 |
| M09 Redes neuronales | 11–13 | 4,5 | 1(a), (c)–(g) | 14 | 18,5 |
| M10 Diferenciación automática | 10, 14, 15 | 4,5 | 4 | 10 | 14,5 |
| M11 Redes profundas | 16–20 | 7,5 | 5 | 10 | 17,5 |
| Varios (M07, M09–M11) | — | — | 6 | 10 | 10 |
| **Total** | | **30** | | **70** | **100** |

En el problema 1 se asignan a M08 los 3 puntos del apartado (b) (gradiente de la entropía cruzada), a M07 un punto del apartado (g) (suma frente a media) y a M09 los 14 restantes.

## B.3 Umbral de aprobado y puerta de salida de la fase

- **Examen de hito:** al menos 70 de 100 puntos.

- **Puerta de salida de la Fase II:** además del examen, se requiere una puntuación mínima de 9/12 en el test de cada módulo (M07 a M11) y al menos un 70 % en la autoevaluación del laboratorio interactivo de la fase.
- **Proyecto de fase:** debe superar al modelo de bigramas ($\mathrm{PPL}_{\mathrm{val}} < 12{,}42$) para obtener al menos la calificación de suficiente en el criterio de resultado.

## B.4 Qué hacer si no se alcanza el umbral

Si un módulo obtiene menos del 70 % de sus puntos en la tabla anterior, conviene repasar las secciones indicadas, rehacer los ejercicios $\star\star\star$ de esos temas en los apuntes del módulo y repetir el examen al cabo de una semana sin consultar las soluciones.

| Si se falla… | Repasar |
|---|---|
| Cuestiones 1–5, problema 2 | M07, §2.2–2.3 (convergencia y $\kappa$), §3.1 (minibatch), §4.1–4.2 (momentum), §5.3 (Adam), §6.2–6.3 (AdamW, calentamiento y coseno) |
| Cuestiones 6–9, problema 3 | M08, §2.2 y §2.5 (ecuaciones normales y máxima verosimilitud), §3.4 (logística), §4.3 y §4.5 (softmax y capa de salida), §5.3 (diagnóstico), §6.5 (validación cruzada) |
| Cuestiones 11–13 | M09, §2.2–2.4 (ReLU, GELU y SwiGLU), §4.3 (Xavier) |
| Problema 1 | M09, §5.2–5.5 (retropropagación y ejemplo completo), §5.6 (comprobación numérica); M08, §4.3 |
| Cuestiones 10, 14, 15; problema 4 | M10, §1.1 (trazas), §2.2–2.3 (números duales y coste), §3.1–3.2 (adjuntos), §4.4 (regla $6ND$), §5.1 (memoria), §6.2 (PyTorch) |
| Cuestión 16, problema 5(b) | M11, §3.1–3.2 (LayerNorm, RMSNorm e invariancias) |
| Cuestión 17, problema 5(c) | M11, §1.3 (saturación), §2.2 (residuales), §4.1–4.2 (dropout y recorte) |
| Cuestiones 18–19, problema 5(d) | M11, §5.1–5.3 (formatos, redondeo y precisión mixta) |
| Cuestión 20, problema 5(a) | M11, §6.1–6.4 (log-sum-exp y diagnóstico de `NaN`) |
| Problema 6 | M09, §6.3 (modelo de Bengio); M10, §4.4; M07, §5.3; M08, §4.5 |
| Proyecto por debajo del bigrama | M09, §6.3–6.4; M10, §6.2; M07, §6.2–6.3; M11, §4.1 |

**Siguiente.** Fase III, módulo 12: tokenización.

# Bibliografía


[1] Y. Bengio, R. Ducharme, P. Vincent y C. Jauvin. A neural probabilistic language model. *Journal of Machine Learning Research*, 3:1137–1155, 2003. https://www.jmlr.org/papers/v3/bengio03a.html

[2] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. Cap. 9, «Unconstrained minimization». Texto del curso EE364a de Stanford.

[3] S. Boyd. EE364a: Convex Optimization I. Stanford University. Transparencias del curso. https://web.stanford.edu/class/ee364a/lectures.html

[4] J. R. Shewchuk. CS 189/289A: Introduction to Machine Learning. Examen parcial (*Midterm*), primavera de 2019. University of California, Berkeley. Pregunta 5, «Logistic Regression with One Feature». https://people.eecs.berkeley.edu/~jrs/189s24/exam/mids19.pdf

[5] J. R. Shewchuk. CS 189/289A: Introduction to Machine Learning. Examen parcial (*Midterm*), primavera de 2023. University of California, Berkeley. Pregunta 2, «Convergence of Gradient Descent». https://people.eecs.berkeley.edu/~jrs/189s24/exam/mids23.pdf

[6] J. R. Shewchuk. CS 189/289A: Introduction to Machine Learning. Examen final, primavera de 2023. University of California, Berkeley. Pregunta 4, «Backpropagation on an Arithmetic Expression». https://people.eecs.berkeley.edu/~jrs/189s24/exam/finals23.pdf

[7] A. Karpathy y equipo docente de CS231n. CS231n: Deep Learning for Computer Vision. Notas del curso, «Backpropagation, Intuitions». Stanford University. https://cs231n.github.io/optimization-2/

[8] C. Manning y R. Socher. CS224N: Natural Language Processing with Deep Learning. Tarea 1. Stanford University, invierno de 2018. Problema 1, «Softmax», y problema 2, «Neural Network Basics». https://web.stanford.edu/class/archive/cs/cs224n/cs224n.1184/assignment1/assignment1.pdf

[9] A. Ng y T. Ma. CS229 Lecture Notes. Stanford University. Parte I, «Supervised learning». https://cs229.stanford.edu/main_notes.pdf

[10] H. Touvron, T. Lavril, G. Izacard, X. Martinet *et al.* LLaMA: Open and efficient foundation language models. Prepublicación arXiv:2302.13971, 2023. https://arxiv.org/abs/2302.13971