Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase III · Secuencias y Transformer

Módulo 13

Atención

Apuntes del curso

Edición de octubre de 2026

Presentación del módulo

Una red recurrente resume todo el pasado de una secuencia en un vector de dimensión fija y lo actualiza token a token. El mecanismo de atención sustituye ese resumen por una consulta directa: cada posición calcula su parecido con todas las demás, lo convierte en una distribución de probabilidad mediante una softmax y devuelve la media de unos vectores de valor ponderada por esa distribución. La operación es diferenciable, se expresa con dos productos de matrices y se evalúa en paralelo sobre toda la secuencia. Introducida en traducción automática por Bahdanau, Cho y Bengio y convertida en la pieza central del Transformer por Vaswani *et al.*, es el componente que distingue a los grandes modelos de lenguaje actuales (Claude, Gemini, Grok y los modelos abiertos) de sus predecesores. Este módulo la estudia con detalle: su definición como agrupación ponderada, la forma matricial con producto escalar escalado y la justificación probabilística del factor $1/\sqrt{d_k}$, la máscara causal que permite entrenar un modelo autorregresivo en paralelo, la atención multi-cabeza con su recuento de parámetros y de operaciones, y dos lecturas estructurales de la operación: los circuitos de cabezas de inducción y las memorias asociativas de Hopfield.

Objetivos

Al finalizar el módulo, el estudiante debe ser capaz de:

1. definir la agrupación por atención con consultas, claves y valores, relacionarla con la regresión por núcleos de Nadaraya y Watson y con la atención aditiva de Bahdanau, y demostrar que su salida pertenece a la envolvente convexa de los valores;
2. calcular a mano $\mathrm{softmax}(QK^\top/\sqrt{d_k})V$, demostrar que la varianza del producto escalar de vectores aleatorios independientes es d_k y explicar, mediante la jacobiana de la softmax, por qué la saturación anula el gradiente;
3. demostrar que la autoatención es equivariante por permutaciones y que la máscara causal con $-\infty$ antes de la softmax garantiza la causalidad y permite obtener n predicciones en una sola pasada;
4. construir la atención multi-cabeza, contar sus parámetros y sus operaciones de coma flotante y determinar a partir de qué longitud domina el coste cuadrático;
5. describir los circuitos QK y OV de una cabeza, construir a mano una cabeza de inducción de dos capas y deducir la equivalencia entre la regla de actualización de una red de Hopfield moderna y la atención.

Requisitos previos

Del módulo 1, la softmax con temperatura (tema 4). Del módulo 2, el producto escalar, el producto de matrices y su recuento de operaciones; del módulo 3, el rango de una matriz. Del módulo 4, la matriz jacobiana y la regla de la cadena. Del módulo 5, la esperanza, la varianza,

la independencia y el teorema central del límite, que se usan en el tema 2. Del módulo 11, la aritmética de 16 bits y la evaluación estable de la softmax. Del módulo 12, los embeddings de tokens y las redes recurrentes, cuyo cuello de botella motiva el tema 1.

Organización

Tema	Contenido	Fuentes principales
1	Atención como agrupación ponderada	[12], [1], [8], [3]
2	Atención por producto escalar escalado	[11], [8], [12], [2]
3	La máscara causal	[11], [8], [4]
4	Atención multi-cabeza y coste computacional	[11], [4], [12], [8]
5	Circuitos de atención y memorias asociativas	[6], [9], [10], [12]

Cada tema termina con una lista de lecturas y con ejercicios graduados en tres niveles: $\star$ comprensión, $\star\star$ cálculo y $\star\star\star$ demostración. Los ejercicios marcados con *Fuente* están adaptados de cursos y libros de texto universitarios; el enunciado se ha redactado de nuevo y, en algunos casos, se han cambiado los datos para que puedan resolverse a mano. Las soluciones completas, paso a paso, están en el apéndice A.

Sobre las fuentes

El texto es de redacción propia. La presentación de la atención como agrupación ponderada sigue las secciones 11.1 a 11.4 de Zhang *et al.* [12] y el artículo de Bahdanau, Cho y Bengio [1]. La forma matricial, el escalado, la máscara y la atención multi-cabeza siguen las secciones 3.2.1 a 3.2.3 y 4 del artículo de Vaswani *et al.* [11], el capítulo 7 de Jurafsky y Martin [8] (§7.1 y §7.3), la sección 12.1 de Bishop y Bishop [2], las secciones 11.3, 11.5 y 11.6 de [12] y la clase 5 y la tarea 3 del curso CS224N de Stanford [3]. El recuento de operaciones sigue la tarea 1 del curso CS336 de Stanford [4] (§3.4.4, §3.4.5 y §3.5). El tema 5 sigue los artículos de Elhage *et al.* [6] y Olsson *et al.* [9], de Anthropic, la §10.6 de [8] y el artículo de Ramsauer *et al.* [10]. Sobre Claude, Gemini y Grok solo se usa información pública: los informes técnicos documentan longitudes de contexto, pero no la variante de atención ni la forma en que se reduce su coste.

Notación

Símbolo	Significado
n, d	longitud de la secuencia y dimensión del modelo
$x_i \in \mathbb{R}^{1\times d}$, $X \in \mathbb{R}^{n\times d}$	vector (fila) del token i y matriz que los apila
$q_i, k_j \in \mathbb{R}^{1\times d_k}$, $v_j \in \mathbb{R}^{1\times d_v}$	consulta (*query*), clave (*key*) y valor (*value*)
Q, K, V	matrices que apilan consultas, claves y valores
$W_Q, W_K \in \mathbb{R}^{d\times d_k}$, $W_V \in \mathbb{R}^{d\times d_v}$	matrices de proyección aprendidas
$S = QK^\top$, $s_{ij} = q_i \cdot k_j$	matriz de puntuaciones (parecidos)
A, α_{ij}	matriz de atención y peso que la posición i asigna a la j
$O = AV$, o_i	salida de la atención
M	máscara aditiva, con entradas 0 o $-\infty$
h, W_O	número de cabezas y proyección de salida
β, $\tau = 1/\beta$	inverso de la temperatura y temperatura
P	matriz de permutación
$\mathrm{conv}\{v_1, \ldots, v_n\}$	envolvente convexa de los valores
e_t, p_i	vectores *one-hot* de token y de posición (tema 5)

Los vectores de token, consulta, clave y valor son vectores fila, como en [11] y [8]; así, $Q = XW_Q$. La softmax de una matriz se aplica por filas.

Índice

Presentación del módulo **ii**

1 Atención como agrupación ponderada **1**

1.1 Del diccionario a la búsqueda suave . . . 1

1.2 Propiedades de la agrupación . . . 2

1.3 Regresión por núcleos de Nadaraya y Watson . . . 3

1.4 La atención aditiva de Bahdanau . . . 3

Ejercicios del tema 1 . . . 4

2 Atención por producto escalar escalado **5**

2.1 Forma matricial . . . 5

2.2 Equivariancia por permutaciones . . . 6

2.3 Por qué se divide por $\sqrt{d_k}$ . . . 7

Ejercicios del tema 2 . . . 8

3 La máscara causal **9**

3.1 Máscaras aditivas . . . 9

3.2 Causalidad . . . 10

Ejercicios del tema 3 . . . 11

4 Atención multi-cabeza y coste computacional **13**

4.1 Definición . . . 13

4.2 Parámetros y estructura . . . 14

4.3 Coste en operaciones . . . 15

4.4 Memoria y contexto largo . . . 15

Ejercicios del tema 4 . . . 16

5 Circuitos de atención y memorias asociativas **18**

5.1 El flujo residual y los circuitos QK y OV . . . 18

5.2 Cabezas de inducción . . . 18

5.3 Atención y redes de Hopfield modernas . . . 20

Ejercicios del tema 5 . . . 21

A Soluciones de los ejercicios **22**

A.1 Tema 1 22

A.2 Tema 2 24

A.3 Tema 3 27

A.4 Tema 4 29

A.5 Tema 5 32

Bibliografía **35**

Tema 1

Atención como agrupación ponderada

Este tema define la atención en su forma más general: una consulta se compara con un conjunto de claves, los parecidos se convierten en pesos mediante una softmax y la salida es la media de los valores asociados ponderada por esos pesos. Se demuestran las dos propiedades estructurales básicas de la operación, la pertenencia de la salida a la envolvente convexa de los valores y su comportamiento en los límites de temperatura, y se presentan sus dos antecedentes: la regresión por núcleos de Nadaraya y Watson y la atención aditiva de Bahdanau, Cho y Bengio. Se siguen las §11.1, §11.2 y §11.4 de [12], la §3.1 de [1], la §7.1 de [8] y la clase 5 de [3].

1.1 Del diccionario a la búsqueda suave

Un diccionario almacena pares (k_j, v_j) y, ante una consulta q, devuelve el valor v_j cuya clave coincide con q, o un error si ninguna coincide. La búsqueda es *dura*: el resultado depende de q de forma discontinua y no admite gradientes. La atención sustituye la coincidencia exacta por un grado de parecido y la elección de un valor por una media ponderada [12, §11.1].

Definición 1.1 (Agrupación por atención). Sean $q \in \mathbb{R}^{1\times d_k}$ una *consulta*, $k_1, \dots, k_n \in \mathbb{R}^{1\times d_k}$ unas *claves* y $v_1, \dots, v_n \in \mathbb{R}^{1\times d_v}$ los *valores* asociados. Sea $a\colon \mathbb{R}^{1\times d_k} \times \mathbb{R}^{1\times d_k} \to \mathbb{R}$ una *función de puntuación*. La *agrupación por atención* de los valores respecto de q es

$$\operatorname{Attn}\big(q; (k_j, v_j)_{j=1}^n\big) = \sum_{j=1}^{n} \alpha_j\, v_j, \qquad \alpha_j = \frac{\exp a(q, k_j)}{\sum_{l=1}^{n} \exp a(q, k_l)},$$

es decir, $(\alpha_1, \dots, \alpha_n) = \operatorname{softmax}\big(a(q, k_1), \dots, a(q, k_n)\big)$. Los números α_j se llaman *pesos de atención*.

La función de puntuación más usada es el producto escalar, $a(q, k) = q \cdot k = qk^\top$, que es grande cuando los dos vectores apuntan en direcciones parecidas y tienen norma grande (módulo 2). Las claves deciden *cuánto* contribuye cada par; los valores, *qué* se contribuye. Separar ambos papeles permite que el criterio por el que un elemento es encontrado no coincida con la información que entrega.

Definición 1.2 (Autoatención). Sean $x_1, \dots, x_n \in \mathbb{R}^{1\times d}$ los vectores de los tokens de una secuencia y $W_Q, W_K \in \mathbb{R}^{d\times d_k}$, $W_V \in \mathbb{R}^{d\times d_v}$ matrices de parámetros. La *autoatención* asigna a cada posición i la salida $o_i = \operatorname{Attn}\big(q_i; (k_j, v_j)_{j=1}^n\big)$, con

$$q_i = x_i W_Q, \qquad k_j = x_j W_K, \qquad v_j = x_j W_V.$$

Si las consultas proceden de una secuencia y las claves y valores de otra, se habla de *atención cruzada*.

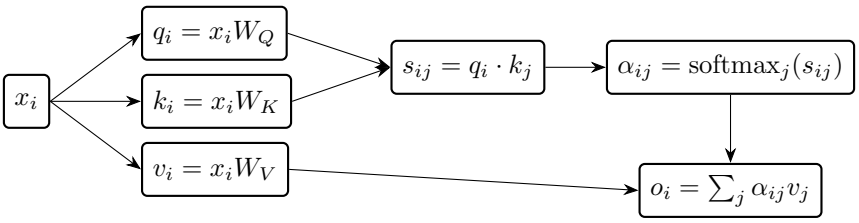


Figura 1.1: Autoatención para la posición i. Tres proyecciones aprendidas asignan a cada token los papeles de consulta, clave y valor; los parecidos de q_i con todas las claves se normalizan con una softmax y ponderan los valores.

Observación 1.3. La figura 1.1 resume la definición. En un modelo de lenguaje del tipo *decoder-only*, como los que se estudian en este curso, toda la atención es autoatención; la atención cruzada aparece en los modelos codificador-decodificador de traducción (apartado 1.4).

1.2 Propiedades de la agrupación

Proposición 1.4 (Envolvente convexa). *Para cualesquiera q, claves, valores y función de puntuación, la salida de la definición 1.1 pertenece a la envolvente convexa* $\mathrm{conv}\{v_1, \dots, v_n\}$. *En particular, para cada coordenada c,*

$$\min_j v_j[c] \;\le\; \mathrm{Attn}(q)[c] \;\le\; \max_j v_j[c].$$

Demostración. Los pesos son exponenciales divididas por su suma, luego $\alpha_j > 0$ y $\sum_j \alpha_j = 1$. Una combinación lineal de $v_1, \dots, v_n$ con coeficientes no negativos que suman 1 es, por definición, una combinación convexa. Para la cota por coordenadas, sean $m = \min_j v_j[c]$ y $m' = \max_j v_j[c]$; multiplicando $m \le v_j[c] \le m'$ por $\alpha_j > 0$ y sumando en j se obtiene $m \sum_j \alpha_j \le \sum_j \alpha_j v_j[c] \le m' \sum_j \alpha_j$, y se usa $\sum_j \alpha_j = 1$. ∎

La atención, por tanto, solo *mezcla* información existente: no puede producir una coordenada mayor que la mayor de los valores. Por esa razón un bloque Transformer combina la atención con una red de alimentación hacia delante y con conexiones residuales (módulo 14).

Para estudiar la dependencia respecto de la escala de las puntuaciones se introduce un factor $\beta > 0$, el *inverso de la temperatura* del módulo 1: $\alpha_j(\beta) = \exp(\beta s_j) / \sum_l \exp(\beta s_l)$, con $s_j = a(q, k_j)$.

Teorema 1.5 (Límites de temperatura). *Sean $s_1, \dots, s_n$ las puntuaciones y supóngase que el máximo $s^* = \max_j s_j$ se alcanza en un único índice j^*. Entonces*

$$\lim_{\beta \to +\infty} \mathrm{Attn}_\beta(q) = v_{j^*}, \qquad \lim_{\beta \to 0^+} \mathrm{Attn}_\beta(q) = \frac{1}{n} \sum_{j=1}^{n} v_j.$$

Demostración. Dividiendo numerador y denominador por $\exp(\beta s^*)$,

$$\alpha_j(\beta) = \frac{\exp\big(\beta(s_j - s^*)\big)}{\sum_l \exp\big(\beta(s_l - s^*)\big)}.$$

Si $j \neq j^*$, entonces $s_j - s^* < 0$ y $\exp(\beta(s_j - s^*)) \to 0$ cuando $\beta \to +\infty$; el término j^* vale $e^0 = 1$. El denominador tiende a 1, luego $\alpha_{j^*} \to 1$ y $\alpha_j \to 0$ para $j \neq j^*$. Cuando $\beta \to 0^+$,

cada $\exp(\beta s_j) \to 1$ por continuidad, el denominador tiende a n y $\alpha_j \to 1/n$. En ambos casos el límite de la salida se obtiene sumando, porque la suma es finita. ■

La atención interpola, pues, entre el diccionario exacto (límite $\beta \to \infty$, que devuelve el valor de la clave más parecida) y la media simple de los valores ($\beta \to 0$). El caso con empates se trata en el ejercicio 1.5.

1.3 Regresión por núcleos de Nadaraya y Watson

La idea de promediar respuestas con pesos que dependen del parecido entre la consulta y unos puntos de referencia es anterior al aprendizaje profundo. Zhang *et al.* [12, §11.2] la presentan a partir de la regresión no paramétrica.

Definición 1.6 (Estimador de Nadaraya–Watson). Sean $(k_j, v_j)_{j=1}^{n}$ observaciones de entrada y salida y $\kappa(q,k) \geq 0$ un *núcleo*. El estimador de Nadaraya–Watson en el punto q es

$$\hat{f}(q) = \sum_{j=1}^{n} \frac{\kappa(q,k_j)}{\sum_{l} \kappa(q,k_l)}\, v_j.$$

Con el núcleo gaussiano, $\kappa(q,k) = \exp\!\big(-\tfrac{1}{2}\|q-k\|^2\big)$.

Proposición 1.7. *Con el núcleo gaussiano, el estimador de Nadaraya–Watson es la agrupación por atención con puntuación $a(q,k) = -\tfrac{1}{2}\|q-k\|^2$. Si además todas las claves tienen la misma norma, coincide con la agrupación con puntuación $a(q,k) = q \cdot k$.*

Demostración. La primera afirmación es la definición 1.1 con $\exp a(q,k) = \kappa(q,k)$. Para la segunda, se desarrolla $-\tfrac{1}{2}\|q-k_j\|^2 = q\cdot k_j - \tfrac{1}{2}\|q\|^2 - \tfrac{1}{2}\|k_j\|^2$. Si $\|k_j\| = r$ para todo j, los dos últimos términos no dependen de j. La softmax es invariante al sumar una misma constante a todas sus entradas (módulo 1), luego los pesos coinciden con los de $\mathrm{softmax}(q\cdot k_1, \dots, q\cdot k_n)$. ■

1.4 La atención aditiva de Bahdanau

En un traductor codificador-decodificador con redes recurrentes, el codificador produce un vector h_j por cada palabra de la frase de origen. En el modelo clásico, el decodificador solo recibía el último de ellos, un resumen de tamaño fijo de toda la frase; Bahdanau, Cho y Bengio propusieron que en cada paso el decodificador construyese su propio resumen como media ponderada de todos los h_j [1, §3.1].

Definición 1.8 (Atención aditiva). Sean $h_1, \dots, h_T$ los vectores del codificador y s_{i-1} el estado del decodificador antes de emitir la palabra i. El *vector de contexto* es

$$c_i = \sum_{j=1}^{T} \alpha_{ij} h_j, \qquad \alpha_{ij} = \frac{\exp e_{ij}}{\sum_{l} \exp e_{il}}, \qquad e_{ij} = v_a^{\top} \tanh\!\big(W_a s_{i-1} + U_a h_j\big),$$

donde W_a, U_a y v_a son parámetros aprendidos (los vectores de esta definición son columnas, como en el artículo original).

Es una agrupación por atención en la que la consulta es s_{i-1}, claves y valores son los h_j y la puntuación es una red de una capa oculta [1, apéndice A.1.2]. Vaswani *et al.* señalan que

la puntuación por producto escalar tiene una complejidad teórica similar, pero es mucho más rápida en la práctica porque se reduce a productos de matrices optimizados [11, §3.2.1]; es la que se estudia en el resto del módulo.

Lecturas recomendadas para este tema

- Zhang *et al.* [12], §11.1 «Queries, Keys, and Values», §11.2 «Attention Pooling by Similarity» y §11.4 «The Bahdanau Attention Mechanism».
- Bahdanau, Cho y Bengio [1], §3.1 «Decoder: General Description» y apéndice A.1.2 «Alignment Model».
- Jurafsky y Martin [8], §7.1 «Attention».
- CS224N [3], clase 5, «Transformers».

Ejercicios del tema 1

Ejercicio 1.1 ⋆ Explique la diferencia entre el papel de la clave k_j y el del valor v_j en la definición 1.1. ¿Qué capacidad perdería el modelo si se impusiera $W_K = W_V$ (con $d_k = d_v$)?

Ejercicio 1.2 ⋆⋆ Una consulta $q = (1, 1)$ se compara, con puntuación $a(q, k) = q \cdot k/\sqrt{2}$, con las claves $k_1 = (1, 0)$, $k_2 = (0, 1)$ y $k_3 = (1, 1)$, cuyos valores escalares son 10, 20 y 30. Calcule los pesos de atención y la salida.

Ejercicio 1.3 ⋆⋆ En la definición 1.8, tómense $W_a = U_a = I_2$, $v_a = (1, 1)^\top$, el estado $s_{i-1} = (1, -1)^\top$ y los vectores del codificador $h_1 = (1, 0)^\top$, $h_2 = (0, 1)^\top$, $h_3 = (1, 1)^\top$. Calcule las puntuaciones e_{ij}, los pesos α_{ij} y el vector de contexto c_i.

Ejercicio 1.4 ⋆⋆ Se usa la puntuación sin escalar $a(q, k) = q \cdot k$ con las claves ortonormales $k_1 = (1, 0, 0)$, $k_2 = (0, 1, 0)$, $k_3 = (0, 0, 1)$ y los valores $v_1 = (2, 0)$, $v_2 = (0, 4)$, $v_3 = (6, 6)$. (a) ¿Qué condición deben cumplir la consulta y las claves para que casi todo el peso recaiga en un único índice? Compruébelo con $q = 10\, k_3$. (b) Encuentre una consulta cuya salida sea aproximadamente $\frac{1}{2}(v_1 + v_2)$ y calcule la salida. (c) Repita el cálculo con $q = k_1 + k_2$ y comente la diferencia.

Fuente: adaptado de CS224N [3], tarea 3, pregunta 1, apartados (a) y (b) (datos numéricos añadidos).

Ejercicio 1.5 ⋆⋆⋆ Generalice el teorema 1.5 al caso con empates: si el máximo s^* se alcanza en un conjunto J^* de r índices, demuestre que $\lim_{\beta \to \infty} \mathrm{Attn}_\beta(q) = \frac{1}{r} \sum_{j \in J^*} v_j$. Deduzca de la proposición 1.4 que, si todos los valores son iguales, la salida no depende de la consulta.

Tema 2

Atención por producto escalar escalado

Este tema escribe la autoatención de todas las posiciones a la vez como dos productos de matrices y una softmax por filas, resuelve a mano un ejemplo completo, demuestra que la operación es equivariante por permutaciones y justifica el factor $1/\sqrt{d_k}$ con un argumento de varianza y con la jacobiana de la softmax. Se siguen la §3.2.1 de [11], las §7.1.1 y §7.3 de [8], la §11.3 de [12] y la §12.1 de [2].

2.1 Forma matricial

Se apilan las consultas, claves y valores de las n posiciones como filas de $Q = XW_Q \in \mathbb{R}^{n\times d_k}$, $K = XW_K \in \mathbb{R}^{n\times d_k}$ y $V = XW_V \in \mathbb{R}^{n\times d_v}$.

Definición 2.1 (Atención por producto escalar escalado). Para $Q \in \mathbb{R}^{n\times d_k}$, $K \in \mathbb{R}^{m\times d_k}$ y $V \in \mathbb{R}^{m\times d_v}$,

$$\operatorname{Attn}(Q,K,V) = \operatorname{softmax}\!\Big(\frac{QK^\top}{\sqrt{d_k}}\Big)V,$$

donde la softmax se aplica a cada fila. La matriz $A = \operatorname{softmax}(QK^\top/\sqrt{d_k}) \in \mathbb{R}^{n\times m}$ se llama *matriz* (o *mapa*) *de atención*.

La entrada (i,j) de $S = QK^\top$ es $q_i \cdot k_j$, de modo que la fila i de A contiene los pesos de la definición 1.1 para la consulta q_i con puntuación $q\cdot k/\sqrt{d_k}$, y la fila i de AV es la salida o_i. La cuadro 2.1 resume las formas. Vaswani *et al.* introdujeron el nombre y la fórmula [11, §3.2.1, ec. (1)]; la tarea 1 de CS336 la adopta con $m \neq n$ para cubrir la atención cruzada [4, §3.4.4].

Paso	Operación	Forma	Significado
1	$S = QK^\top$	$n \times m$	$s_{ij} = q_i \cdot k_j$
2	$S/\sqrt{d_k}$	$n \times m$	escalado (apartado 2.3)
3	$A = \operatorname{softmax}(S/\sqrt{d_k})$	$n \times m$	cada fila es una distribución
4	$O = AV$	$n \times d_v$	fila i: media ponderada de valores

Cuadro 2.1: Formas de las matrices intermedias de la atención.

Ejemplo 2.2 (Tres tokens). Sean $d_k = 4$, $d_v = 2$ y

$$Q = \begin{pmatrix} 2 & 0 & 2 & 0 \\ 0 & 2 & 0 & 2 \\ 2 & 2 & 0 & 0 \end{pmatrix}, \quad K = \begin{pmatrix} 2 & 0 & 0 & 0 \\ 0 & 2 & 0 & 2 \\ 1 & 1 & 1 & 1 \end{pmatrix}, \quad V = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}.$$

Los parecidos son, por ejemplo, $s_{11} = 2 \cdot 2 = 4$ y $s_{22} = 2 \cdot 2 + 2 \cdot 2 = 8$; en total, y tras dividir por $\sqrt{4} = 2$,

$$S = \begin{pmatrix} 4 & 0 & 4 \\ 0 & 8 & 4 \\ 4 & 4 & 4 \end{pmatrix}, \qquad \frac{S}{2} = \begin{pmatrix} 2 & 0 & 2 \\ 0 & 4 & 2 \\ 2 & 2 & 2 \end{pmatrix}.$$

Fila 1: $e^2 = 7{,}389$, $e^0 = 1$, $e^2 = 7{,}389$, de suma 15,78, y pesos 0,468, 0,063, 0,468. Fila 2: 1, $e^4 = 54{,}60$, 7,389, de suma 62,99, y pesos 0,016, 0,867, 0,117. Fila 3: tres puntuaciones iguales, pesos 1/3. Por tanto

$$A = \begin{pmatrix} 0{,}468 & 0{,}063 & 0{,}468 \\ 0{,}016 & 0{,}867 & 0{,}117 \\ 0{,}333 & 0{,}333 & 0{,}333 \end{pmatrix}, \qquad O = AV = \begin{pmatrix} 0{,}937 & 0{,}532 \\ 0{,}133 & 0{,}984 \\ 0{,}667 & 0{,}667 \end{pmatrix}.$$

La consulta 2 busca las coordenadas segunda y cuarta, que ofrece sobre todo la clave 2: la posición 2 se atiende casi solo a sí misma. La consulta 3 es igual de parecida a todas las claves y promedia. Cada fila de O está en la envolvente convexa de las filas de V (proposición 1.4).

	$j=1$	$j=2$	$j=3$
$i=1$	0,468	0,063	0,468
$i=2$	0,016	0,867	0,117
$i=3$	0,333	0,333	0,333

Figura 2.1: Mapa de atención del ejemplo 2.2; la intensidad del gris es proporcional a α_{ij}. La fila i indica a qué posiciones atiende la posición i.

2.2 Equivariancia por permutaciones

Proposición 2.3 (Equivariancia). *Sea* $f(X) = \mathrm{softmax}\big(XW_Q(XW_K)^\top/\sqrt{d_k}\big)XW_V$ *la autoatención sin máscara y sea* $P \in \mathbb{R}^{n\times n}$ *una matriz de permutación. Entonces* $f(PX) = P\,f(X)$.

Demostración. Sustituyendo X por PX: $Q' = PXW_Q = PQ$, $K' = PK$, $V' = PV$. Luego $S' = PQ(PK)^\top = PQK^\top P^\top = PSP^\top$, que reordena filas y columnas de S con la misma permutación. La softmax por filas actúa sobre cada fila por separado y permutar las entradas de un vector permuta del mismo modo las de su softmax; por tanto $A' = PAP^\top$. Finalmente $O' = A'V' = PAP^\top PV = PAV = PO$, porque $P^\top P = I$: las columnas de P son vectores distintos de la base canónica y, por tanto, ortonormales. ∎

La autoatención no distingue, por sí sola, el orden de los tokens: «el perro muerde al hombre» y «el hombre muerde al perro» producen las mismas salidas, solo que en otras filas. Por eso los modelos de lenguaje añaden información de posición a los vectores de entrada (módulo 14), y por eso la máscara causal del tema 3, que sí depende del orden, rompe esta simetría.

2.3 Por qué se divide por $\sqrt{d_k}$

Vaswani *et al.* justifican el factor con un argumento de varianza que enuncian en una nota al pie [11, §3.2.1, nota 4]; Zhang *et al.* [12, §11.3.3] y Jurafsky y Martin [8, §7.1.1] lo reproducen. Se da aquí con demostración.

Teorema 2.4 (Varianza del producto escalar). *Sean $q = (q_1, \dots, q_{d_k})$ y $k = (k_1, \dots, k_{d_k})$ vectores aleatorios cuyas $2d_k$ componentes son independientes, de media 0 y varianza 1. Entonces*

$$\mathbb{E}[q \cdot k] = 0, \qquad \operatorname{Var}(q \cdot k) = d_k, \qquad \operatorname{Var}\Big(\frac{q \cdot k}{\sqrt{d_k}}\Big) = 1.$$

Demostración. Sea $X_i = q_i k_i$. Por la independencia de q_i y k_i, $\mathbb{E}[X_i] = \mathbb{E}[q_i]\,\mathbb{E}[k_i] = 0$. Además $\mathbb{E}[q_i^2] = \operatorname{Var}(q_i) + \mathbb{E}[q_i]^2 = 1$, e igual para k_i; como q_i^2 y k_i^2 también son independientes, $\operatorname{Var}(X_i) = \mathbb{E}[q_i^2 k_i^2] - \mathbb{E}[X_i]^2 = \mathbb{E}[q_i^2]\,\mathbb{E}[k_i^2] = 1$. Las variables $X_1, \dots, X_{d_k}$ son independientes entre sí, porque cada una es función de un par de componentes distinto, de modo que la varianza de su suma es la suma de las varianzas (módulo 5): $\operatorname{Var}(q \cdot k) = \sum_i \operatorname{Var}(X_i) = d_k$. Por linealidad, $\mathbb{E}[q \cdot k] = 0$, y $\operatorname{Var}(cY) = c^2 \operatorname{Var}(Y)$ con $c = 1/\sqrt{d_k}$ da la última igualdad. ∎

Por el teorema central del límite, $q \cdot k / \sqrt{d_k}$ es aproximadamente $\mathcal{N}(0, 1)$ para d_k grande. Sin el factor, con $d_k = 64$ los parecidos tendrían desviación típica 8 en la inicialización y diferencias de 16 entre dos claves serían frecuentes. Una simulación con $2 \cdot 10^5$ pares de vectores gaussianos da varianzas empíricas 4,00 para $d_k = 4$ y 63,8 para $d_k = 64$.

Para ver por qué importa la escala se necesita la jacobiana de la softmax, calculada en el módulo 4 con la regla del cociente.

Proposición 2.5 (Saturación de la softmax). *Sea $p = \operatorname{softmax}(z) \in \mathbb{R}^n$ y $J = \partial p / \partial z$, de entradas $J_{ij} = p_i(\delta_{ij} - p_j)$. Entonces*

$$\max_{i,j} |J_{ij}| \;\le\; 1 - \max_{l} p_l.$$

En consecuencia, si una probabilidad tiende a 1, todas las derivadas parciales de la softmax tienden a 0.

Demostración. Sea $p_k = \max_l p_l$, de modo que $p_i \le 1 - p_k$ para todo $i \neq k$ (las probabilidades suman 1). Si $i = j$, $|J_{ii}| = p_i(1 - p_i)$: para $i = k$ vale $p_k(1 - p_k) \le 1 - p_k$, y para $i \neq k$, $p_i(1 - p_i) \le p_i \le 1 - p_k$. Si $i \neq j$, $|J_{ij}| = p_i p_j$ y al menos uno de los dos índices es distinto de k; si lo es i, $p_i p_j \le p_i \le 1 - p_k$, y análogamente si lo es j. ∎

Logits z	$\operatorname{softmax}(z)$	$\max\lvert J_{ij}\rvert$
$(1, 0, 0)$	(0,576; 0,212; 0,212)	0,244
$(8, 0, 0)$	(0,9993; 0,0003; 0,0003)	0,00067

Cuadro 2.2: Con logits ocho veces mayores, las derivadas de la softmax se reducen en un factor de unos 360.

Observación 2.6 (El factor como temperatura). Dividir por $\sqrt{d_k}$ equivale a aplicar la softmax con temperatura $\tau = \sqrt{d_k}$ (módulo 1, tema 4). Sin ella, el modelo empezaría en la región saturada: en el ejemplo 2.2, sin dividir por 2, el peso de la fila 2 sobre la posición 2 pasa de 0,867 a 0,982. Vaswani *et al.* observan, en la misma línea, que sin escalado la atención aditiva

supera a la de producto escalar cuando d_k es grande [11, §3.2.1]. Durante el entrenamiento, la red puede modificar la escala efectiva agrandando o encogiendo W_Q y W_K.

Observación 2.7 (Evaluación estable). Como la softmax es invariante al restar una constante a todas las entradas, se evalúa restando el máximo de cada fila antes de exponenciar, lo que evita desbordamientos en fp16 (módulo 11). La tarea 1 de CS336 exige implementarla así [4, §3.4.4].

Lecturas recomendadas para este tema

- Vaswani *et al.* [11], §3.2.1 «Scaled Dot-Product Attention» y su nota 4.
- Jurafsky y Martin [8], §7.1.1 «Attention more formally» y §7.3 «Parallelizing computation using a single matrix X».
- Zhang *et al.* [12], §11.3 «Attention Scoring Functions», en particular §11.3.3.
- Bishop y Bishop [2], cap. 12, §12.1 «Attention».

Ejercicios del tema 2

Ejercicio 2.1 ⋆ ¿Qué formas tienen $S = QK^\top$, A y O en la autoatención si $n = 10$, $d_k = 16$ y $d_v = 32$? ¿Por qué d_k no aparece en la forma de O?

Ejercicio 2.2 ⋆⋆ En las hipótesis del teorema 2.4, calcule $\mathrm{Var}(q \cdot k)$ y la desviación típica de $q \cdot k$ y de $q \cdot k/\sqrt{d_k}$ para $d_k = 64$ y $d_k = 128$.

Ejercicio 2.3 ⋆⋆ Los logits de cuatro palabras candidatas son $z = (1{,}2;\ 0{,}9;\ 0{,}1;\ -0{,}5)$. Calcule $\mathrm{softmax}(z/\tau)$ para $\tau = 0{,}2$ y $\tau = 2$, compruebe que cada distribución suma 1 y describa los límites $\tau \to 0^+$ y $\tau \to \infty$. Relacione el resultado con el factor $1/\sqrt{d_k}$.

Fuente: adaptado de Jurafsky y Martin [8], cap. 7, ejercicio 7.5 (logits propios).

Ejercicio 2.4 ⋆⋆ Para $z = (1, 0, 0)$, calcule la matriz jacobiana completa de la softmax y compruebe la cota de la proposición 2.5. Verifique que la suma de cada columna de J es 0 y explique por qué debe serlo.

Ejercicio 2.5 ⋆⋆⋆ Generalice el teorema 2.4 al caso en que las componentes tienen media 0 y varianza σ^2. ¿Qué factor c hace que $\mathrm{Var}(c\,q \cdot k) = 1$?

Ejercicio 2.6 ⋆⋆⋆ En la atención cruzada, las consultas $Q = YW_Q$ proceden de una secuencia $Y \in \mathbb{R}^{m \times d}$ y las claves y valores, $K = XW_K$ y $V = XW_V$, de otra $X \in \mathbb{R}^{n \times d}$. Demuestre que la salida es *invariante* (no solo equivariante) si se permutan las filas de X: para toda permutación P, $\mathrm{Attn}(Q, PK, PV) = \mathrm{Attn}(Q, K, V)$.

Tema 3

La máscara causal

Un modelo de lenguaje autorregresivo factoriza la probabilidad de una secuencia con la regla de la cadena (módulo 1, tema 2): la distribución del token $t+1$ solo puede depender de los tokens $1, \dots, t$. Este tema define las máscaras aditivas, demuestra que sumar $-\infty$ antes de la softmax equivale a restringir la softmax al conjunto de posiciones permitidas, prueba que la máscara causal hace que cada salida dependa solo de su pasado y deduce de ello que una única pasada produce las n predicciones de una secuencia. Se siguen la §3.2.3 de [11], la §7.3 de [8], las §3.4.4 y §3.4.5 de la tarea 1 de CS336 [4] y la §11.3.2.1 de [12].

3.1 Máscaras aditivas

Definición 3.1 (Máscara aditiva). Sea $\mathcal{P} \subseteq \{1, \dots, n\} \times \{1, \dots, m\}$ el conjunto de pares (i, j) *permitidos*, con la condición de que cada fila i contenga al menos un par permitido. La *máscara aditiva* asociada es la matriz $M \in \{0, -\infty\}^{n \times m}$ con $M_{ij} = 0$ si $(i, j) \in \mathcal{P}$ y $M_{ij} = -\infty$ en otro caso. La *atención enmascarada* es

$$\operatorname{Attn}_M(Q, K, V) = \operatorname{softmax}\Big(\frac{QK^\top}{\sqrt{d_k}} + M\Big)V,$$

con el convenio $e^{-\infty} = 0$.

Definición 3.2 (Máscara causal). En la autoatención ($m = n$), la *máscara causal* es la asociada a $\mathcal{P} = \{(i, j) : j \le i\}$:

$$M_{ij} = \begin{cases} 0, & j \le i, \\ -\infty, & j > i. \end{cases}$$

Es triangular estrictamente superior en sus entradas $-\infty$; la diagonal siempre está permitida.

Vaswani *et al.* la describen como el bloqueo de las conexiones «ilegales» de la autoatención del decodificador, fijando a $-\infty$ las entradas correspondientes de la softmax [11, §3.2.3]; Jurafsky y Martin la presentan en la §7.3 de [8], y la tarea 1 de CS336 la implementa con una máscara booleana en la que `True` indica «puede atender» [4, §3.4.4]. La figura 3.1 muestra su estructura.

Proposición 3.3 (Softmax restringida). *Sea $z \in \mathbb{R}^m$ y sea $\mathcal{P}_i \subseteq \{1, \dots, m\}$ no vacío. Si $\mu_j = 0$ para $j \in \mathcal{P}_i$ y $\mu_j = -\infty$ en otro caso, entonces*

$$\operatorname{softmax}(z + \mu)_j = \begin{cases} \dfrac{e^{z_j}}{\sum_{l \in \mathcal{P}_i} e^{z_l}}, & j \in \mathcal{P}_i, \\ 0, & j \notin \mathcal{P}_i. \end{cases}$$

En particular, los pesos permitidos suman 1 y no dependen de las puntuaciones z_j con $j \notin \mathcal{P}_i$.

	posición atendida j				
	1	2	3	4	5
$i=1$	0	$-\infty$	$-\infty$	$-\infty$	$-\infty$
$i=2$	0	0	$-\infty$	$-\infty$	$-\infty$
$i=3$	0	0	0	$-\infty$	$-\infty$
$i=4$	0	0	0	0	$-\infty$
$i=5$	0	0	0	0	0

Figura 3.1: Máscara causal para $n = 5$. La fila i solo permite las posiciones $j \le i$; las celdas sombreadas reciben peso exactamente nulo.

Demostración. Por el convenio $e^{-\infty} = 0$, el numerador $e^{z_j+\mu_j}$ vale e^{z_j} si $j \in \mathcal{P}_i$ y 0 en otro caso, y el denominador $\sum_l e^{z_l+\mu_l}$ se reduce a $\sum_{l\in\mathcal{P}_i} e^{z_l}$, que es positivo porque $\mathcal{P}_i \neq \varnothing$. Ninguna de las dos expresiones contiene z_j con $j \notin \mathcal{P}_i$. ∎

La condición $\mathcal{P}_i \neq \varnothing$ es necesaria: una fila enteramente enmascarada daría $0/0$, que en coma flotante produce `NaN` (módulo 11). En la máscara causal no puede ocurrir, porque (i, i) siempre está permitido.

Observación 3.4 (Por qué $-\infty$ antes de la softmax). Sumar 0 antes de la softmax no anula nada, porque $e^0 = 1$. Poner a 0 los pesos *después* de la softmax deja filas que suman menos de 1 y pesos del pasado más pequeños de lo debido; hay que renormalizar, y el resultado coincide entonces con el de la proposición 3.3 (ejercicio 3.5). En la práctica se usa `-inf` o un número negativo grande; el ejercicio 3.4 cuantifica cuánto debe valer.

Ejemplo 3.5. Con el ejemplo 2.2 y la máscara causal,

$$\frac{S}{\sqrt{d_k}} + M = \begin{pmatrix} 2 & -\infty & -\infty \\ 0 & 4 & -\infty \\ 2 & 2 & 2 \end{pmatrix} \quad\Longrightarrow\quad A = \begin{pmatrix} 1 & 0 & 0 \\ 0{,}018 & 0{,}982 & 0 \\ 0{,}333 & 0{,}333 & 0{,}333 \end{pmatrix}.$$

En la fila 2, $e^0 = 1$ y $e^4 = 54{,}60$, de modo que los pesos son $1/55{,}60 = 0{,}018$ y $0{,}982$. La primera posición solo puede atenderse a sí misma. La salida es $O = AV$, con filas $(1, 0)$, $(0{,}018;\ 0{,}982)$ y $(0{,}667;\ 0{,}667)$.

3.2 Causalidad

Teorema 3.6 (Causalidad de la atención enmascarada). *Sean $q_i = x_i W_Q$, $k_j = x_j W_K$, $v_j = x_j W_V$ y sea o_i la fila i de la autoatención con máscara causal. Entonces, para cada i, o_i es función únicamente de $x_1, \dots, x_i$.*

Demostración. Por la proposición 3.3 con $\mathcal{P}_i = \{1, \dots, i\}$,

$$o_i = \sum_{j=1}^{i} \alpha_{ij} v_j, \qquad \alpha_{ij} = \frac{\exp\!\big(q_i \cdot k_j/\sqrt{d_k}\big)}{\sum_{l=1}^{i} \exp\!\big(q_i \cdot k_l/\sqrt{d_k}\big)}.$$

En esta expresión solo intervienen q_i, que depende únicamente de x_i, y k_l y v_l con $l \le i$, que dependen únicamente de x_l. Luego o_i no depende de x_j para $j > i$. ∎

Corolario 3.7 (Entrenamiento en paralelo). *Sea f la autoatención con máscara causal y, para cada $t \leq n$, sea f_t la misma operación aplicada solo al prefijo $x_{1:t}$. Entonces la fila t de $f(x_{1:n})$ coincide con la última fila de $f_t(x_{1:t})$. En consecuencia, una sola evaluación sobre la secuencia completa proporciona las n representaciones que una red usa para predecir $x_2, \ldots, x_{n+1}$, cada una calculada solo con su prefijo.*

Demostración. Por el teorema 3.6, la fila t de $f(x_{1:n})$ es la expresión de su demostración con $i = t$, que solo usa $x_1, \ldots, x_t$. La última fila de $f_t(x_{1:t})$ se obtiene con la misma fórmula, pues en el prefijo también están permitidas las posiciones $1, \ldots, t$. Ambas coinciden. ■

La tarea 1 de CS336 describe la alternativa ingenua, ejecutar la atención n veces, una por prefijo, y la descarta en favor de la máscara [4, §3.4.5]. Una red recurrente necesita, en cambio, n pasos secuenciales, porque el estado en t depende del estado en $t-1$ (módulo 12). Esta diferencia, que Vaswani *et al.* cuantifican como $O(1)$ operaciones secuenciales frente a $O(n)$ [11, §4, tabla 1], es la razón práctica principal por la que los Transformer desplazaron a las redes recurrentes en el preentrenamiento de modelos de lenguaje.

Observación 3.8 (Otras máscaras). La definición 3.1 admite otros conjuntos $\mathcal{P}$. La máscara de relleno (*padding*) prohíbe las posiciones añadidas para igualar la longitud de las secuencias de un lote [12, §11.3.2.1]; la de ventana deslizante permite solo $i - w < j \leq i$, lo que reduce el coste a $O(nw)$ (tema 4). La combinación de varias máscaras es la intersección de sus conjuntos permitidos, es decir, la suma de sus matrices.

Lecturas recomendadas para este tema

- Vaswani *et al.* [11], §3.2.3 «Applications of Attention in our Model» y §4 «Why Self-Attention».
- Jurafsky y Martin [8], §7.3, apartado «Masking out the future».
- CS336 [4], tarea 1, §3.4.4 «Scaled Dot-Product Attention» y §3.4.5 «Causal Multi-Head Self-Attention».
- Zhang *et al.* [12], §11.3.2.1 «Masked Softmax Operation».

Ejercicios del tema 3

Ejercicio 3.1 ⋆ Un estudiante implementa la máscara causal de dos formas erróneas: (a) pone a 0 los pesos futuros *después* de la softmax; (b) pone a 0 las puntuaciones futuras *antes* de la softmax. Con la fila 2 del ejemplo 2.2, de puntuaciones escaladas $(0, 4, 2)$, calcule el resultado de cada versión y explique qué falla.

Ejercicio 3.2 ⋆ ¿Por qué la máscara causal usa $-\infty$ y no 0 en las posiciones prohibidas? Calcule la fila de pesos correspondiente a las puntuaciones $(0, 4, 2)$, con el tercer token prohibido, en ambos casos.

Fuente: adaptado de Jurafsky y Martin [8], cap. 7, ejercicio 7.2 (datos numéricos añadidos).

Ejercicio 3.3 ⋆⋆ Una matriz de puntuaciones ya escaladas es

$$S = \begin{pmatrix} 1 & 5 & 5 \\ 0 & \ln 3 & 5 \\ 0 & 0 & \ln 2 \end{pmatrix}.$$

Aplique la máscara causal, calcule A y las salidas si los valores son los escalares 4, 8 y 12. ¿Cambia algo si los cincos se sustituyen por cienes?

Ejercicio 3.4 ⋆⋆ En lugar de $-\infty$, una implementación suma $-c$, con $c > 0$ finito, a las puntuaciones prohibidas. Para la fila $(0, 4, 2)$ con el tercer token prohibido, halle el menor entero c para el que el peso que se filtra al futuro es menor que 10^{-6}.

Ejercicio 3.5 ⋆⋆⋆ Sea $p = \mathrm{softmax}(z)$ y $\mathcal{P}_i$ un conjunto no vacío de índices. Se define $\tilde{p}_j = p_j \mathbb{1}[j \in \mathcal{P}_i] / \sum_{l \in \mathcal{P}_i} p_l$, es decir, se anulan los pesos prohibidos después de la softmax y se renormaliza. Demuestre que $\tilde{p} = \mathrm{softmax}(z + \mu)$, con μ como en la proposición 3.3. ¿Por qué se prefiere, aun así, sumar la máscara antes?

Tema 4

Atención multi-cabeza y coste computacional

Una sola cabeza de atención define una única noción de parecido entre posiciones. La atención multi-cabeza ejecuta varias en paralelo, cada una en un subespacio de dimensión d/h, y combina sus resultados con una proyección lineal. Este tema la define, demuestra que su número de parámetros no depende del número de cabezas, muestra que cada cabeza tiene una forma bilineal de rango acotado, cuenta las operaciones de coma flotante de la capa y estudia la memoria de la matriz de atención, que es el obstáculo principal para los contextos largos. Se siguen la §3.2.2 y la §4 de [11], las §3.4.5 y §3.5 de la tarea 1 de CS336 [4], las §11.5 y §11.6.2 de [12] y las §7.1.1 y §7.3 de [8].

4.1 Definición

Definición 4.1 (Atención multi-cabeza). Sean d la dimensión del modelo, h un divisor de d y $d_k = d_v = d/h$. Para cada cabeza $r = 1, \dots, h$ se toman matrices $W_Q^{(r)}, W_K^{(r)}, W_V^{(r)} \in \mathbb{R}^{d \times d/h}$, y además $W_O \in \mathbb{R}^{d \times d}$. La *atención multi-cabeza* de $X \in \mathbb{R}^{n \times d}$ es

$$\mathrm{MHA}(X) = \mathrm{Concat}\big(H_1, \dots, H_h\big)\, W_O, \qquad H_r = \mathrm{Attn}\big(XW_Q^{(r)}, XW_K^{(r)}, XW_V^{(r)}\big) \in \mathbb{R}^{n \times d/h},$$

donde Concat yuxtapone las h matrices por columnas y la atención de cada cabeza puede llevar máscara causal.

Vaswani *et al.* usan $d = 512$ y $h = 8$, de modo que $d_k = d_v = 64$, y observan que el coste total es similar al de una sola cabeza de dimensión completa [11, §3.2.2]. Zhang *et al.* dan la definición con dimensiones generales y la misma elección [12, §11.5.1].

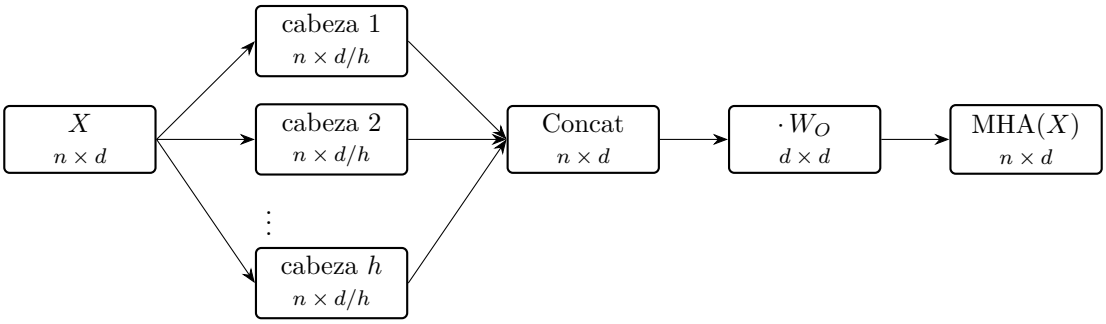


Figura 4.1: Atención multi-cabeza: h atenciones independientes en subespacios de dimensión d/h, concatenadas y mezcladas por W_O.

Observación 4.2 (Implementación). No se calculan h productos pequeños. Se apilan las matrices de las cabezas en $W_Q = \big(W_Q^{(1)} \ \cdots \ W_Q^{(h)}\big) \in \mathbb{R}^{d \times d}$, se calcula $Q = XW_Q$ con un único

producto y se reordena el resultado de forma (n, d) a $(h, n, d/h)$; la fórmula de la atención se aplica entonces con un eje adicional de cabezas, que se trata como un eje de lote (módulo 3). La tarea 1 de CS336 pide calcular así las tres proyecciones con tres productos de matrices, o con uno solo concatenando las tres matrices [4, §3.4.5].

4.2 Parámetros y estructura

Proposición 4.3 (Parámetros). *Sin sesgos, la atención multi-cabeza tiene $4d^2$ parámetros, cualquiera que sea h.*

Demostración. Cada una de las $3h$ matrices $W_Q^{(r)}, W_K^{(r)}, W_V^{(r)}$ tiene $d \cdot d/h$ entradas; en total, $3h \cdot d^2/h = 3d^2$. La matriz W_O aporta d^2 más. ∎

Con $d = 768$, la capa tiene $4 \cdot 768^2 = 2\,359\,296$ parámetros; con $d = 512$, $1\,048\,576$. En el módulo 14 se suman los $8d^2$ de la red de alimentación hacia delante con $d_{ff} = 4d$ y se obtiene que la atención es un tercio de los parámetros de cada bloque.

Proposición 4.4 (Descomposición por cabezas). *Sea $W_O^{(r)} \in \mathbb{R}^{d/h \times d}$ el bloque de filas $(r-1)d/h + 1, \dots, rd/h$ de W_O. Entonces*

$$\mathrm{MHA}(X) = \sum_{r=1}^{h} H_r \, W_O^{(r)} = \sum_{r=1}^{h} A_r \, X \, W_V^{(r)} W_O^{(r)},$$

donde A_r es la matriz de atención de la cabeza r. Además, las puntuaciones de la cabeza r son $s_{ij}^{(r)} = x_i \, W_Q^{(r)} W_K^{(r)\top} x_j^\top$, una forma bilineal cuya matriz $W_{QK}^{(r)} = W_Q^{(r)} W_K^{(r)\top} \in \mathbb{R}^{d \times d}$ tiene rango a lo sumo d/h.

Demostración. El producto de una matriz particionada por columnas en bloques $H_1, \dots, H_h$ por otra particionada por filas en los bloques correspondientes es la suma de los productos de los bloques: $\big(H_1 \cdots H_h\big) W_O = \sum_r H_r W_O^{(r)}$. Sustituyendo $H_r = A_r (X W_V^{(r)})$ se obtiene la segunda igualdad. Para las puntuaciones, $s_{ij}^{(r)} = q_i^{(r)} \cdot k_j^{(r)} = x_i W_Q^{(r)} \big(x_j W_K^{(r)}\big)^\top$. Por último, el rango de un producto no supera el de ninguno de sus factores (módulo 3), y $W_Q^{(r)}$ tiene d/h columnas, luego $\operatorname{rg} W_{QK}^{(r)} \le d/h$. ∎

La proposición muestra que la multi-cabeza no es una sola atención grande cortada en trozos: es una *suma* de h atenciones, cada una con su propia matriz de pesos A_r, una forma bilineal de rango $\le d/h$ que decide a dónde mirar y una aplicación $W_V^{(r)} W_O^{(r)}$ que decide qué escribir. Esta lectura es la base del análisis de circuitos del tema 5. La tarea 3 de CS224N ilustra con un ejemplo de claves ruidosas por qué promediar dos cabezas puede ser más robusto que una sola [3, tarea 3, pregunta 1].

Observación 4.5 (Variantes). Muchos modelos abiertos comparten las claves y los valores entre grupos de cabezas (atención *multi-query* y *grouped-query*) para reducir la memoria de inferencia; se estudian en el módulo 18. Qué variante usan Claude, Gemini o Grok en sus versiones actuales no se ha publicado en detalle.

4.3 Coste en operaciones

Se cuenta en operaciones de coma flotante (FLOP), con el convenio de CS336 de que una multiplicación seguida de una suma cuenta como dos [4, §3.5].

Lema 4.6. *El producto de una matriz $a \times b$ por una $b \times c$ requiere $2abc$ FLOP.*

Demostración. Cada una de las ac entradas del resultado es un producto escalar de longitud b: b multiplicaciones y $b-1$ sumas, unas $2b$ operaciones (exactamente $2b$ si se acumula sobre un cero inicial). ■

Proposición 4.7 (Coste de la capa). *Con h cabezas de dimensión d/h, una pasada de la atención multi-cabeza sobre n posiciones requiere*

$$\begin{aligned} \mathrm{FLOP}_{proy} &= 8nd^2 && \textit{(proyecciones } Q, K, V \textit{ y } W_O\textit{)}, \\ \mathrm{FLOP}_{at} &= 4n^2 d && \textit{(productos } QK^\top \textit{ y } AV\textit{)}, \end{aligned}$$

sin contar la softmax, que es de orden hn^2. La parte cuadrática domina si y solo si $n > 2d$.

Demostración. Por el lema 4.6, cada una de las cuatro proyecciones $(n \times d)(d \times d)$ cuesta $2nd^2$, en total $8nd^2$. En cada cabeza, $QK^\top$ es $(n \times d/h)(d/h \times n)$ y cuesta $2n^2 d/h$; AV es $(n \times n)(n \times d/h)$ y cuesta lo mismo. Sumando las h cabezas: $h \cdot 4n^2 d/h = 4n^2 d$. Finalmente, $4n^2 d > 8nd^2$ equivale, dividiendo por $4nd > 0$, a $n > 2d$. ■

Con $d = 512$, la atención propiamente dicha domina a partir de 1024 tokens. Vaswani *et al.* resumen esta comparación en su tabla 1: complejidad por capa $O(n^2 d)$ para la autoatención frente a $O(nd^2)$ para una red recurrente, a cambio de $O(1)$ operaciones secuenciales y longitud máxima de camino $O(1)$ entre dos posiciones [11, §4]. Zhang *et al.* hacen el mismo análisis en [12, §11.6.2].

4.4 Memoria y contexto largo

La matriz de atención tiene n^2 entradas por cabeza y por capa. En fp16, con dos bytes por número (módulo 11), ocupa $2n^2$ bytes.

n (tokens)	Memoria de A (una cabeza, una capa, fp16)
4096	0,034 GB
10^5	20 GB
10^6	2000 GB

Cuadro 4.1: Memoria de una matriz de atención completa (1 GB = 10^9 bytes).

Multiplicar el contexto por k multiplica esta memoria y los $4n^2 d$ FLOP por k^2. Las técnicas que lo mitigan se estudian en módulos posteriores: FlashAttention [5] calcula la softmax por bloques sin almacenar A completa, de modo que la memoria adicional pasa a ser lineal en n mientras el número de FLOP sigue siendo $O(n^2 d)$ (módulo 17); las ventanas deslizantes y la atención dispersa reducen el conjunto permitido $\mathcal{P}$; y en inferencia la caché de claves y valores evita recalcular las del pasado (módulo 19).

Observación 4.8 (Contexto largo en modelos comerciales). El informe técnico de Gemini 1.5 [7] documenta recuperación casi perfecta en experimentos con contextos de hasta diez millones de tokens, y Anthropic ofrece para Claude ventanas de cientos de miles de tokens. Ninguna de las dos empresas ha publicado cómo resuelven internamente el coste cuadrático.

Lecturas recomendadas para este tema

- Vaswani *et al.* [11], §3.2.2 «Multi-Head Attention» y §4 «Why Self-Attention», tabla 1.
- CS336 [4], tarea 1, §3.4.5 y §3.5 «The Full Transformer LM», problema *transformer_accounting*.
- Zhang *et al.* [12], §11.5 «Multi-Head Attention» y §11.6.2 «Comparing CNNs, RNNs, and Self-Attention».
- Jurafsky y Martin [8], §7.1.1 y §7.3.
- Dao *et al.* [5], para una primera lectura de FlashAttention.

Ejercicios del tema 4

Ejercicio 4.1 ⋆ Justifique si son verdaderas o falsas: (a) duplicar el número de cabezas con d fijo duplica los parámetros de la atención; (b) la autoatención sin máscara ni información de posición da el mismo resultado, salvo el orden de las filas, si se barajan los tokens; (c) la máscara causal impide entrenar en paralelo.

Ejercicio 4.2 ⋆⋆ Cuente los parámetros sin sesgos de una atención multi-cabeza con $d = 512$ y $h = 8$. ¿Cuántos tiene cada $W_Q^{(r)}$? Compruebe que las ocho juntas forman una matriz $d \times d$.

Ejercicio 4.3 ⋆⋆ (a) Calcule los FLOP de $QK^\top$ para una cabeza con $n = 2048$ y $d_k = 128$, y los de $QK^\top$ y AV juntos. (b) Con $d = 512$ y $n = 2048$, compare $8nd^2$ con $4n^2d$ y compruebe el criterio $n > 2d$ de la proposición 4.7.

Ejercicio 4.4 ⋆⋆ ¿Cuánta memoria ocupa la matriz de atención de una cabeza y una capa en fp16 con $n = 10^5$? ¿Y con $n = 10^6$? ¿Por qué factor se multiplica el coste de la atención al pasar de 1024 a 8192 tokens?

Ejercicio 4.5 ⋆⋆ Un Transformer tiene $L = 6$ capas, $d = 512$, $A = 8$ cabezas con $d_k = d_v = d/A$ y una red de alimentación hacia delante con $d_{ff} = 4d$ (dos matrices). Sin sesgos ni normalizaciones: (a) cuente los parámetros de W_Q, W_K, W_V y W_O de una capa y diga si dependen de A; (b) cuente los de la red de alimentación; (c) demuestre que la pila tiene unos $12Ld^2$ parámetros y calcúlelos.

Fuente: adaptado de Jurafsky y Martin [8], cap. 7, ejercicio 7.1 (con valores numéricos).

Ejercicio 4.6 ⋆⋆⋆ Considérese un modelo del tamaño de GPT-2 pequeño: $L = 12$, $d = 768$, vocabulario $|\mathcal{V}| = 50\,257$, red de alimentación con $d_{ff} = 4d$ y contexto $n = 1024$. Por capa, las proyecciones Q, K, V cuestan $6nd^2$ FLOP, la salida W_O $2nd^2$, la atención $4n^2d$ y la red de alimentación $16nd^2$; la capa de salida, una sola vez, $2nd|\mathcal{V}|$. (a) Calcule los FLOP de cada componente y su porcentaje del total. (b) Repita el cálculo con $n = 16\,384$: ¿por qué factor crece el total y qué componente pasa a dominar? (c) Deduzca de la proposición 4.7 a partir de qué n la atención supera a la red de alimentación.

Fuente: adaptado de CS336 [4], tarea 1, §3.5, problema *transformer_accounting*, apartados (b) a (e) (con GPT-2 pequeño en lugar de GPT-2 XL).

Ejercicio 4.7 ⋆⋆⋆ (a) Demuestre que una cabeza con $d_k < d$ no puede representar una forma bilineal $x_i B x_j^\top$ arbitraria: existe $B \in \mathbb{R}^{d\times d}$ que no se escribe como $W_Q W_K^\top$ con $W_Q, W_K \in \mathbb{R}^{d\times d_k}$. (b) Demuestre, en cambio, que toda B de rango $\leq d_k$ sí se escribe así. (c) Con $d = 512$ y $h = 8$, ¿cuál es el rango máximo de la matriz $\sum_r W_{QK}^{(r)}$ que se obtendría sumando las ocho formas bilineales, y por qué esa suma no describe la atención multi-cabeza?

Tema 5

Circuitos de atención y memorias asociativas

Los temas anteriores tratan la atención como una operación aislada. Este tema estudia dos lecturas estructurales de ella. La primera, debida a Elhage *et al.* [6], descompone cada cabeza en un circuito que decide a dónde mirar y otro que decide qué copiar, y muestra que dos cabezas en capas sucesivas pueden componerse para implementar una *cabeza de inducción*, el mecanismo que Olsson *et al.* [9] relacionaron con el aprendizaje en contexto. La segunda, debida a Ramsauer *et al.* [10], identifica la atención con la regla de actualización de una red de Hopfield moderna, una memoria asociativa direccionable por contenido. Se siguen esos tres artículos y la §10.6 de [8].

5.1 El flujo residual y los circuitos QK y OV

En un Transformer, cada capa *suma* su salida a la representación de cada posición, que recorre así la red como un *flujo residual* (módulos 11 y 14). Elhage *et al.* estudian modelos formados solo por capas de atención, en los que el vector final de la posición i es su embedding más las contribuciones de todas las cabezas de todas las capas [6]. Por la proposición 4.4, la contribución de una cabeza a la posición i es

$$\sum_{j \le i} \alpha_{ij}\, x_j\, W_{OV}, \qquad \alpha_{ij} = \operatorname{softmax}_j\!\Big(\frac{x_i\, W_{QK}\, x_j^{\top}}{\sqrt{d_k}}\Big),$$

con $W_{QK} = W_Q W_K^{\top}$ y $W_{OV} = W_V W_O^{(r)}$, ambas de tamaño $d \times d$ (en esta sección se omite el índice de la cabeza).

Definición 5.1 (Circuitos QK y OV). En una cabeza de atención, el *circuito QK* es la forma bilineal $W_{QK} = W_Q W_K^{\top}$, que determina los pesos de atención, y el *circuito OV* es la aplicación lineal $W_{OV} = W_V W_O$, que determina qué se escribe en el flujo residual de la posición que atiende a partir de la posición atendida.

Los dos circuitos son independientes: el primero decide *a dónde* se mira; el segundo, *qué* se copia. Si los vectores de entrada son *one-hot*, $x_i W_{QK} x_j^{\top}$ es una entrada de la matriz W_{QK} y la tabla completa de preferencias de la cabeza puede leerse directamente.

5.2 Cabezas de inducción

Una *cabeza de inducción* implementa la regla «si antes apareció a seguido de b y ahora vuelve a aparecer a, predecir b», es decir, completa patrones del tipo $[a][b]\ldots[a] \to [b]$ [9]. Permite

copiar del propio contexto secuencias que nunca se vieron en el entrenamiento, como un nombre propio inventado que se repite en un texto.

Proposición 5.2. *En un modelo de una sola capa de atención cuyas entradas en cada posición son el embedding de su token más el de su posición, la puntuación s_{ij} es función de (x_i, x_j). En consecuencia, para dos posiciones permitidas $j, l \le i$, el cociente α_{ij}/α_{il} solo depende de x_i, x_j y x_l; en particular, ninguna cabeza de esa capa puede preferir la posición j a la l en función del token* anterior *x_{j-1}.*

Demostración. La puntuación es $s_{ij} = x_i W_{QK} x_j^\top / \sqrt{d_k}$, que solo contiene x_i y x_j. Por la proposición 3.3, los pesos permitidos comparten el mismo denominador, de modo que $\alpha_{ij}/\alpha_{il} = \exp(s_{ij} - s_{il})$, función de x_i, x_j y x_l. Si $j - 1 \notin \{i, j, l\}$, cambiar el token x_{j-1} no altera ese cociente. ■

Hace falta, por tanto, que una capa anterior haya escrito en la posición j información sobre x_{j-1}. La construcción de Elhage *et al.* usa dos cabezas [6]:

1. una *cabeza de token anterior* en la capa 1, cuyo mapa de atención es la subdiagonal: la posición j atiende a $j - 1$ y su circuito OV copia la identidad del token, de modo que escribe en j «mi token anterior era x_{j-1}»;
2. una *cabeza de inducción* en la capa 2, cuyas claves se construyen a partir de lo escrito por la capa 1 y cuya consulta es el token actual: la posición i atiende a las j con $x_{j-1} = x_i$, y su circuito OV copia el token x_j.

Que las claves de la capa 2 lean la salida de una cabeza de la capa 1 se llama *composición K*; análogamente se definen las composiciones Q y V. La figura 5.1 ilustra el mecanismo.

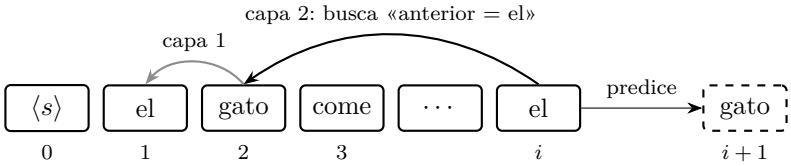


Figura 5.1: Cabeza de inducción. La capa 1 escribe en la posición 2 que su token anterior es «el»; en una posición posterior i con el token «el», la consulta de la capa 2 encaja con esa clave y el circuito OV copia «gato», que se convierte en la predicción para la posición $i + 1$.

Teorema 5.3 (Cabeza de token anterior). *Sean $p_0, \dots, p_{n-1}$ vectores* one-hot *de posición y $\beta > 0$. Con máscara causal, consultas $q_i = \beta p_i$ y claves $k_j = \beta p_{j+1}$ (con $p_n = 0$), y sin escalado adicional, el peso que la posición $i \ge 1$ asigna a $i - 1$ es*

$$\alpha_{i,i-1} = \frac{e^{\beta^2}}{e^{\beta^2} + i} \xrightarrow[\beta \to \infty]{} 1.$$

Demostración. Para $j \le i$, $q_i \cdot k_j = \beta^2\, p_i \cdot p_{j+1}$, que vale β^2 si $j + 1 = i$ y 0 en otro caso, porque los vectores de posición son ortonormales. La fila i tiene $i + 1$ posiciones permitidas, $j = 0, \dots, i$: una con puntuación β^2 y las i restantes con puntuación 0. Por la proposición 3.3, $\alpha_{i,i-1} = e^{\beta^2}/(e^{\beta^2} + i \cdot e^0)$, que tiende a 1 porque $i/e^{\beta^2} \to 0$. ■

Con valores $v_j = e_{x_j}$ (el *one-hot* del token), la salida de esta cabeza en la posición j es, para β grande, aproximadamente $e_{x_{j-1}}$. El ejercicio 5.4 completa la construcción con la segunda capa.

Observación 5.4 (Evidencia empírica). Olsson *et al.* presentan seis líneas de evidencia complementarias de que las cabezas de inducción explican una parte importante del aprendizaje en contexto: entre otras, que se forman durante el entrenamiento en el mismo intervalo en el que la capacidad de aprendizaje en contexto mejora bruscamente, visible como un escalón en la curva de pérdida. La evidencia es causal en modelos pequeños formados solo por atención y correlacional en modelos mayores con redes de alimentación hacia delante [9]. Jurafsky y Martin resumen estos resultados en la §10.6 de [8]; el módulo 23 retoma los circuitos.

5.3 Atención y redes de Hopfield modernas

Una memoria asociativa almacena patrones y, ante un estímulo parecido a uno de ellos, devuelve el patrón completo. Ramsauer *et al.* definen una red de Hopfield con estados continuos cuya regla de actualización es la atención [10, §2]. En esta sección se usa su convención: $X = (x_1, \dots, x_N) \in \mathbb{R}^{d\times N}$ tiene los patrones almacenados como *columnas* y el estado $\xi \in \mathbb{R}^d$ es un vector columna.

Definición 5.5 (Energía de Hopfield moderna). Sean $\beta > 0$ y $\operatorname{lse}(\beta, z) = \beta^{-1} \ln \sum_{l=1}^{N} e^{\beta z_l}$. La energía del estado ξ es

$$E(\xi) = -\operatorname{lse}\big(\beta, X^\top \xi\big) + \tfrac{1}{2}\,\xi^\top \xi + \beta^{-1} \ln N + \tfrac{1}{2} M^2, \qquad M = \max_l \|x_l\|,$$

y la *regla de actualización* es $\xi^{\text{nuevo}} = X \operatorname{softmax}\big(\beta X^\top \xi\big)$.

Proposición 5.6 (Puntos estacionarios). *El gradiente de la energía es* $\nabla E(\xi) = \xi - X \operatorname{softmax}(\beta X^\top \xi)$. *Por tanto,* ξ *es un punto estacionario de* E *si y solo si es un punto fijo de la regla de actualización, y la actualización consiste en saltar al punto que anula el gradiente de la parte cuadrática con la parte* lse *congelada.*

Demostración. Sea $z = X^\top \xi$. Para la función $g(z) = \beta^{-1} \ln \sum_l e^{\beta z_l}$, $\partial g / \partial z_l = \beta^{-1} \cdot \beta e^{\beta z_l} / \sum_m e^{\beta z_m} = \operatorname{softmax}(\beta z)_l$. Por la regla de la cadena (módulo 4), con $\partial z / \partial \xi = X^\top$, se tiene $\nabla_\xi \operatorname{lse}(\beta, X^\top \xi) = X \operatorname{softmax}(\beta X^\top \xi)$. El gradiente de $\frac{1}{2}\xi^\top \xi$ es ξ y los dos últimos términos son constantes. Por tanto $\nabla E(\xi) = 0$ si y solo si $\xi = X \operatorname{softmax}(\beta X^\top \xi)$. La última afirmación se sigue de que ξ^{nuevo} es la solución de $\xi - c = 0$ con $c = X \operatorname{softmax}(\beta X^\top \xi)$ fijo. ∎

Ramsauer *et al.* demuestran además que la actualización hace decrecer la energía y converge, que la red puede almacenar un número de patrones exponencial en la dimensión y que, si los patrones están bien separados, un solo paso basta para recuperar uno de ellos con error exponencialmente pequeño [10, §2, teoremas 1 a 5].

Observación 5.7 (Hopfield como atención). Si los patrones almacenados y los estados se proyectan linealmente para formar claves, valores y consultas y se toma $\beta = 1/\sqrt{d_k}$, la regla de actualización, escrita con vectores fila, adopta la forma $\operatorname{softmax}(QK^\top/\sqrt{d_k})V$ de la definición 2.1 [10, §2]. La atención es, pues, un paso de recuperación en una memoria asociativa, y β desempeña el papel de inverso de una temperatura: el teorema 1.5 describe sus dos regímenes extremos, recuperación de un patrón y media de todos ellos.

Lecturas recomendadas para este tema

- Elhage *et al.* [6], «A Mathematical Framework for Transformer Circuits»: modelos de solo atención, circuitos QK y OV y composición de cabezas.
- Olsson *et al.* [9], «In-context Learning and Induction Heads».
- Jurafsky y Martin [8], §10.6 «In-Context Learning and Induction Heads».
- Ramsauer *et al.* [10], §2 «Modern Hopfield Nets with Continuous States».

Ejercicios del tema 5

Ejercicio 5.1 ⋆ Explique con un ejemplo concreto por qué una cabeza de una sola capa no puede completar «el señor Dursley …el señor» con «Dursley» si solo dispone de los embeddings de token y de posición. ¿Qué información debe haberse escrito antes en la posición de «Dursley»?

Ejercicio 5.2 ⋆⋆ En la cabeza del teorema 5.3: (a) calcule $\alpha_{5,4}$ con $\beta = 2$; (b) halle el menor β que garantiza $\alpha_{i,i-1} \geq 0{,}99$ para todas las posiciones de una secuencia de diez tokens ($i \leq 9$).

Ejercicio 5.3 ⋆⋆ Sean $\beta = 1$, los patrones $x_1 = (2, 0)^\top$ y $x_2 = (0, 2)^\top$ y el estado inicial $\xi = (1;\ 0{,}5)^\top$. Aplique dos veces la regla de actualización de la definición 5.5 y diga a qué patrón se acerca el estado.

Ejercicio 5.4 ⋆⋆⋆ Diseñe una cabeza de inducción de dos capas para tokens con embeddings *one-hot* y posiciones *one-hot*, indicando consultas, claves y valores de cada capa (con $\beta = 10$). Aplíquela a la secuencia «$\langle s\rangle$ el gato come pescado y luego el gato duerme» (posiciones 0 a 9) y determine qué predice en las posiciones 7, 8 y 9.

Ejercicio 5.5 ⋆⋆⋆ Sea $o(\xi) = X\,\mathrm{softmax}(\beta X^\top \xi)$ la regla de actualización, con patrones $x_1, \ldots, x_N$ y pesos $p = \mathrm{softmax}(\beta X^\top \xi)$. (a) Demuestre que su jacobiana es $\partial o/\partial \xi = \beta\big(\sum_l p_l x_l x_l^\top - o\,o^\top\big)$, es decir, β veces la covarianza de los patrones bajo la distribución p. (b) Compruébelo en dimensión uno con $\beta = 1$, patrones 0 y 2 y $\xi = \frac{1}{2}\ln 3$. (c) ¿Qué ocurre con la jacobiana cuando p se concentra en un solo patrón?

Fuente: adaptado de Zhang *et al.* [12], §11.1, ejercicio 2 (con el factor β y un caso numérico).

Ejercicio 5.6 ⋆⋆⋆ Sean $x_1, \ldots, x_N \in \mathbb{R}^d$ patrones ortonormales y $\xi = x_k$. Demuestre que tras una actualización

$$\|\xi^{\text{nuevo}} - x_k\| = \frac{\sqrt{N(N-1)}}{e^\beta + N - 1},$$

y calcule el error con $N = 4$ y $\beta = 5$.

Apéndice A

Soluciones de los ejercicios

Cada solución se presenta en cinco partes: datos, planteamiento, desarrollo, resultado y comprobación. En los pasos intermedios se redondea a cuatro cifras significativas salvo que se indique otra cosa; los resultados exactos se dan como fracción o como expresión cerrada cuando existe. Todos los valores numéricos se han comprobado con un programa en Python.

A.1 Tema 1

Solución del ejercicio 1.1

Datos. $o = \sum_j \alpha_j v_j$ con $\alpha_j = \mathrm{softmax}_j\big(a(q, k_j)\big)$; $k_j = x_j W_K$, $v_j = x_j W_V$.

Planteamiento. localizar en qué parte de la definición 1.1 interviene cada vector.

Desarrollo.

1. La clave k_j solo aparece en la puntuación $a(q, k_j)$: determina *si* la posición j recibe peso y cuánto.
2. El valor v_j solo aparece en la suma ponderada: determina *qué* información aporta la posición j cuando recibe peso.
3. Con $W_K = W_V$, ambos vectores coinciden: las características por las que un token es encontrado serían las mismas que transmite. Un token no podría, por ejemplo, anunciarse por su categoría gramatical y transmitir su significado.

Resultado. **la clave fija el peso y el valor fija el contenido**; imponer $W_K = W_V$ obliga a que el criterio de búsqueda y la información transmitida vivan en el mismo subespacio, lo que reduce la capacidad del modelo.

Comprobación. en el ejemplo 2.2, la tercera clave $(1, 1, 1, 1)$ hace que la posición 3 sea «medio parecida» a todas las consultas, mientras que su valor $(1, 1)$ aporta las dos coordenadas: los papeles son distintos.

Solución del ejercicio 1.2

Datos. $q = (1, 1)$; $k_1 = (1, 0)$, $k_2 = (0, 1)$, $k_3 = (1, 1)$; valores 10, 20, 30; $a(q, k) = q \cdot k/\sqrt{2}$.

Planteamiento. puntuaciones, softmax y media ponderada (definición 1.1).

Desarrollo.

1. Productos escalares: $q \cdot k_1 = 1$, $q \cdot k_2 = 1$, $q \cdot k_3 = 2$.
2. Escalado: $1/\sqrt{2} = 0{,}7071$ (dos veces) y $2/\sqrt{2} = 1{,}414$.
3. Exponenciales: $e^{0{,}7071} = 2{,}028$ (dos veces) y $e^{1{,}414} = 4{,}113$; suma $2{,}028 + 2{,}028 + 4{,}113 = 8{,}169$.

4. Pesos: $2{,}028/8{,}169 = 0{,}2483$ (dos veces) y $4{,}113/8{,}169 = 0{,}5035$.
5. Salida: $0{,}2483 \cdot 10 + 0{,}2483 \cdot 20 + 0{,}5035 \cdot 30 = 2{,}483 + 4{,}966 + 15{,}10 = 22{,}55$.

Resultado. pesos $(0{,}2483;\ 0{,}2483;\ 0{,}5035)$; salida 22,55.

Comprobación. los pesos suman 1,000 y la salida está entre 10 y 30 (proposición 1.4); supera la media simple, 20, porque k_3 es la clave más parecida a q.

Solución del ejercicio 1.3

Datos. $W_a = U_a = I_2$, $v_a = (1,1)^\top$, $s_{i-1} = (1,-1)^\top$; $h_1 = (1,0)^\top$, $h_2 = (0,1)^\top$, $h_3 = (1,1)^\top$.

Planteamiento. $e_{ij} = v_a^\top \tanh(s_{i-1} + h_j)$ es la suma de las dos componentes de $\tanh(s_{i-1} + h_j)$; después, softmax y media ponderada (definición 1.8).

Desarrollo.

1. $s_{i-1} + h_1 = (2,-1)$, tanh $= (0{,}9640;\ -0{,}7616)$, $e_{i1} = 0{,}2024$.
2. $s_{i-1} + h_2 = (1,0)$, tanh $= (0{,}7616;\ 0)$, $e_{i2} = 0{,}7616$.
3. $s_{i-1} + h_3 = (2,0)$, tanh $= (0{,}9640;\ 0)$, $e_{i3} = 0{,}9640$.
4. Exponenciales: $e^{0{,}2024} = 1{,}224$, $e^{0{,}7616} = 2{,}142$, $e^{0{,}9640} = 2{,}622$; suma 5,988.
5. Pesos: $1{,}224/5{,}988 = 0{,}2045$, $2{,}142/5{,}988 = 0{,}3577$, $2{,}622/5{,}988 = 0{,}4379$.
6. Contexto: $c_i = 0{,}2045\,(1,0) + 0{,}3577\,(0,1) + 0{,}4379\,(1,1) = (0{,}2045 + 0{,}4379;\ 0{,}3577 + 0{,}4379) = (0{,}6424;\ 0{,}7955)$.

Resultado. $e_{i\cdot} = (0{,}2024;\ 0{,}7616;\ 0{,}9640)$, $\alpha_{i\cdot} = (0{,}2045;\ 0{,}3577;\ 0{,}4379)$ y $c_i = (0{,}6424;\ 0{,}7955)$.

Comprobación. los pesos suman 1,000, y cada coordenada de c_i está en $[0,1]$, el rango de las coordenadas de los h_j (proposición 1.4).

Solución del ejercicio 1.4

Datos. k_1, k_2, k_3 base canónica de $\mathbb{R}^3$; $v_1 = (2,0)$, $v_2 = (0,4)$, $v_3 = (6,6)$; $\alpha = \text{softmax}(q \cdot k_1, q \cdot k_2, q \cdot k_3)$.

Planteamiento. con claves ortonormales, $q \cdot k_j$ es la coordenada j de q; la concentración del peso depende de las diferencias entre puntuaciones (teorema 1.5).

Desarrollo.

1. (a) Condición: $q \cdot k_j \gg q \cdot k_l$ para todo $l \neq j$; es decir, q alineada con k_j, de norma grande y casi ortogonal a las demás claves.
2. Con $q = 10k_3 = (0,0,10)$: puntuaciones $0, 0, 10$; exponenciales $1, 1, e^{10} = 22\,026$; suma $22\,028$. Pesos $4{,}540 \cdot 10^{-5}$ (dos veces) y 0,99991.
3. Salida: $4{,}540 \cdot 10^{-5}(2,0) + 4{,}540 \cdot 10^{-5}(0,4) + 0{,}99991\,(6,6) = (5{,}9995;\ 5{,}9996) \approx v_3$.
4. (b) Con $q = 10(k_1 + k_2) = (10,10,0)$: exponenciales $e^{10}, e^{10}, 1$, suma $44\,053$; pesos 0,49999 (dos veces) y $2{,}270 \cdot 10^{-5}$.
5. Salida: $0{,}49999(2,0) + 0{,}49999(0,4) + 2{,}270 \cdot 10^{-5}(6,6) = (1{,}0001;\ 2{,}0001) \approx \frac{1}{2}(v_1 + v_2) = (1,2)$.

6. (c) Con $q = k_1 + k_2 = (1, 1, 0)$: exponenciales $e = 2{,}718$ (dos veces) y 1, suma 6,437; pesos 0,4223, 0,4223, 0,1554.
7. Salida: $0{,}4223(2, 0) + 0{,}4223(0, 4) + 0{,}1554(6, 6) = (0{,}8446 + 0{,}9322;\ 1{,}689 + 0{,}9322) = (1{,}777;\ 2{,}621)$.

Resultado. (a) q alineada con una clave y de norma grande; con $10k_3$, $c \approx (6, 6) = v_3$. (b) $q = 10(k_1 + k_2)$ da $c \approx (1, 2)$. (c) Sin el factor 10, $c = (1{,}777;\ 2{,}621)$: el valor v_3 se filtra con un peso del 15,5 %.

Comprobación. en los tres casos los pesos suman 1. La norma de q actúa como el factor β del teorema 1.5; en un modelo entrenado, la red la ajusta agrandando W_Q.

Solución del ejercicio 1.5

Datos. $\alpha_j(\beta) = e^{\beta s_j} / \sum_l e^{\beta s_l}$; $s^* = \max_j s_j$, alcanzado en J^* con $|J^*| = r$.

Planteamiento. repetir la demostración del teorema 1.5 sin suponer unicidad.

Desarrollo.

1. Dividiendo por $e^{\beta s^*}$: $\alpha_j(\beta) = e^{\beta(s_j - s^*)} / \sum_l e^{\beta(s_l - s^*)}$.
2. Si $j \in J^*$, el numerador vale $e^0 = 1$ para todo β; si $j \notin J^*$, $s_j - s^* < 0$ y el numerador tiende a 0 cuando $\beta \to \infty$.
3. El denominador es la suma de r unos y de términos que tienden a 0: tiende a r.
4. Luego $\alpha_j \to 1/r$ si $j \in J^*$ y $\alpha_j \to 0$ en otro caso, y la salida tiende a $\sum_{j \in J^*} \frac{1}{r} v_j$.
5. Si $v_1 = \cdots = v_n = v$, la envolvente convexa de la proposición 1.4 es el punto $\{v\}$, luego la salida vale v para toda consulta.

Resultado. $\lim_{\beta \to \infty} \mathrm{Attn}_\beta(q) = \dfrac{1}{r} \displaystyle\sum_{j \in J^*} v_j$; con valores iguales, la salida es constante.

Comprobación. con $r = 1$ se recupera el teorema 1.5. En la fila 3 del ejemplo 2.2, las tres puntuaciones empatan y la salida es la media (0,667; 0,667) para cualquier β, de acuerdo con el resultado con $r = 3$.

A.2 Tema 2

Solución del ejercicio 2.1

Datos. $n = 10$, $d_k = 16$, $d_v = 32$; $Q, K \in \mathbb{R}^{10 \times 16}$, $V \in \mathbb{R}^{10 \times 32}$.

Planteamiento. regla de formas $(a \times b)(b \times c) = a \times c$; la softmax por filas conserva la forma.

Desarrollo.

1. $S = QK^\top$: $(10 \times 16)(16 \times 10) = 10 \times 10$.
2. $A = \mathrm{softmax}(S/4)$: 10×10.
3. $O = AV$: $(10 \times 10)(10 \times 32) = 10 \times 32$.

Resultado. S **y** A **son** 10×10**;** O **es** 10×32**.** La dimensión d_k se contrae en el producto escalar $q_i \cdot k_j$ y no sobrevive en la salida.

Comprobación. O tiene una fila por posición, y cada fila es una combinación de valores, de dimensión $d_v = 32$ (cuadro 2.1).

Solución del ejercicio 2.2

Datos. componentes independientes de media 0 y varianza 1; $d_k \in \{64, 128\}$.

Planteamiento. por el teorema 2.4, $\mathrm{Var}(q \cdot k) = d_k$ y $\mathrm{Var}(q \cdot k/\sqrt{d_k}) = 1$.

Desarrollo.

1. $d_k = 64$: varianza 64, desviación típica $\sqrt{64} = 8$.
2. $d_k = 128$: varianza 128, desviación típica $\sqrt{128} = 8\sqrt{2} = 11{,}31$.
3. Tras escalar: varianza $d_k/d_k = 1$ y desviación típica 1 en ambos casos.

Resultado. **varianzas** 64 **y** 128 **(desviaciones** 8 **y** 11,31**); tras escalar,** 1 **y** 1**.**

Comprobación. la simulación citada tras el teorema 2.4 da 63,8 para $d_k = 64$, a menos de un 0,5 % del valor teórico.

Solución del ejercicio 2.3

Datos. $z = (1{,}2;\ 0{,}9;\ 0{,}1;\ -0{,}5)$; $\tau \in \{0{,}2;\ 2\}$.

Planteamiento. $\mathrm{softmax}(z/\tau)_i = e^{z_i/\tau} / \sum_j e^{z_j/\tau}$; dividir por τ es multiplicar por $\beta = 1/\tau$.

Desarrollo.

1. $\tau = 0{,}2$: $z/\tau = (6;\ 4{,}5;\ 0{,}5;\ -2{,}5)$. Exponenciales 403,4; 90,02; 1,649; 0,08208; suma 495,2.
2. Probabilidades: 0,8147; 0,1818; 0,003330; 0,0001657.
3. $\tau = 2$: $z/\tau = (0{,}6;\ 0{,}45;\ 0{,}05;\ -0{,}25)$. Exponenciales 1,822; 1,568; 1,051; 0,7788; suma 5,221.
4. Probabilidades: 0,3490; 0,3004; 0,2014; 0,1492.
5. $\tau \to 0^+$ equivale a $\beta \to \infty$: por el teorema 1.5, la distribución tiende a $(1, 0, 0, 0)$, el *argmax*. $\tau \to \infty$ equivale a $\beta \to 0$: tiende a la uniforme $(0{,}25;\ 0{,}25;\ 0{,}25;\ 0{,}25)$.

Resultado. $\tau = 0{,}2$**:** $(0{,}8147;\ 0{,}1818;\ 0{,}0033;\ 0{,}0002)$**;** $\tau = 2$**:** $(0{,}3490;\ 0{,}3004;\ 0{,}2014;\ 0{,}1492)$; los límites son el *argmax* y la uniforme. En la atención, $\sqrt{d_k}$ desempeña el papel de τ: sin él, las puntuaciones crecen con d_k y es como trabajar con una temperatura demasiado baja.

Comprobación. las dos distribuciones suman 1,000; con $\tau = 1$ se obtiene $(0{,}4432;\ 0{,}3283;\ 0{,}1475;\ 0{,}0810)$, intermedia entre ambas.

Solución del ejercicio 2.4

Datos. $z = (1, 0, 0)$; $J_{ij} = p_i(\delta_{ij} - p_j)$, es decir, $J = \mathrm{diag}(p) - p\,p^\top$.

Planteamiento. calcular p y sustituir.

Desarrollo.

1. $p = \big(e, 1, 1\big)/(e + 2)$: $e + 2 = 4{,}718$, luego $p = (0{,}5761;\ 0{,}2119;\ 0{,}2119)$.
2. Diagonal: $p_1(1 - p_1) = 0{,}5761 \cdot 0{,}4239 = 0{,}2442$; $p_2(1 - p_2) = 0{,}2119 \cdot 0{,}7881 = 0{,}1670$, igual para p_3.

3. Fuera de la diagonal: $-p_1p_2 = -0{,}1221$, $-p_1p_3 = -0{,}1221$, $-p_2p_3 = -0{,}04492$.
4. Cota: $1 - \max_l p_l = 1 - 0{,}5761 = 0{,}4239 \geq 0{,}2442 = \max|J_{ij}|$.
5. Suma de la columna 1: $0{,}2442 - 0{,}1221 - 0{,}1221 = 0$; de la columna 2: $-0{,}1221 + 0{,}1670 - 0{,}04492 = 0$ (con el redondeo).
6. Motivo: $\sum_i p_i = 1$ para todo z, luego $\sum_i \partial p_i/\partial z_j = \partial(1)/\partial z_j = 0$.

Resultado.

$$J = \begin{pmatrix} 0{,}2442 & -0{,}1221 & -0{,}1221 \\ -0{,}1221 & 0{,}1670 & -0{,}04492 \\ -0{,}1221 & -0{,}04492 & 0{,}1670 \end{pmatrix}, \qquad \max|J_{ij}| = 0{,}2442 \leq 0{,}4239.$$

Comprobación. el máximo coincide con el de la cuadro 2.2. La matriz es simétrica, como corresponde a la hessiana de LSE (módulo 4).

Solución del ejercicio 2.5

Datos. q_i, k_i independientes, de media 0 y varianza σ^2, $i = 1, \ldots, d_k$.

Planteamiento. repetir la demostración del teorema 2.4 con σ^2.

Desarrollo.

1. $\mathbb{E}[q_ik_i] = \mathbb{E}[q_i]\,\mathbb{E}[k_i] = 0$.
2. $\mathbb{E}[q_i^2] = \mathrm{Var}(q_i) + \mathbb{E}[q_i]^2 = \sigma^2$, igual para k_i.
3. $\mathrm{Var}(q_ik_i) = \mathbb{E}[q_i^2]\,\mathbb{E}[k_i^2] - 0 = \sigma^4$.
4. Los d_k sumandos son independientes: $\mathrm{Var}(q \cdot k) = d_k\sigma^4$.
5. $\mathrm{Var}(c\,q \cdot k) = c^2 d_k\sigma^4 = 1$ si y solo si $c = 1/(\sigma^2\sqrt{d_k})$ (tomando $c > 0$).

Resultado. $\mathrm{Var}(q \cdot k) = d_k\sigma^4$ **y** $c = 1/(\sigma^2\sqrt{d_k})$**.**

Comprobación. con $\sigma = 1$ se recupera $1/\sqrt{d_k}$. Con $\sigma = 2$ y $d_k = 16$, la fórmula da $16 \cdot 16 = 256$; una simulación con $2 \cdot 10^5$ pares da 256,6. En la práctica se usa $1/\sqrt{d_k}$ y las capas de normalización (módulo 11) mantienen $\sigma \approx 1$.

Solución del ejercicio 2.6

Datos. $Q \in \mathbb{R}^{m\times d_k}$; $K = XW_K$, $V = XW_V$ con $X \in \mathbb{R}^{n\times d}$; $P \in \mathbb{R}^{n\times n}$ de permutación.

Planteamiento. sustituir X por PX, de modo que $K' = PK$ y $V' = PV$, y seguir cada operación como en la proposición 2.3.

Desarrollo.

1. Puntuaciones: $S' = Q(PK)^\top = QK^\top P^\top = SP^\top$. Multiplicar por $P^\top$ a la derecha permuta las *columnas* de S.
2. La softmax de cada fila es equivariante respecto de permutaciones de sus entradas: $A' = \mathrm{softmax}(S'/\sqrt{d_k}) = AP^\top$.
3. Salida: $O' = A'V' = AP^\top PV = AV = O$, porque $P^\top P = I$.

Resultado. $\mathrm{Attn}(Q, PK, PV) = \mathrm{Attn}(Q, K, V)$: la atención cruzada trata la memoria (K, V) como un conjunto no ordenado.

Comprobación. en la autoatención la permutación afecta también a las consultas y aparece un factor P a la izquierda: se recupera $O' = PO$, la equivariancia de la proposición 2.3.

A.3 Tema 3

Solución del ejercicio 3.1

Datos. puntuaciones escaladas $(0, 4, 2)$; el tercer token es futuro.

Planteamiento. comparar cada versión con la correcta, $\mathrm{softmax}(0, 4, -\infty) = (0{,}018;\ 0{,}982;\ 0)$ (ejemplo 3.5).

Desarrollo.

1. (a) $\mathrm{softmax}(0, 4, 2) = (0{,}01588;\ 0{,}8668;\ 0{,}1173)$. Anulando el tercero queda $(0{,}01588;\ 0{,}8668;\ 0)$, que suma 0,8827.
2. Renormalizando: $0{,}01588/0{,}8827 = 0{,}01799$ y $0{,}8668/0{,}8827 = 0{,}9820$, que es el resultado correcto; sin renormalizar, la fila no es una distribución.
3. (b) Puntuaciones $(0, 4, 0)$: softmax $= (0{,}01767;\ 0{,}9647;\ 0{,}01767)$. Como $e^0 = 1$, el futuro conserva peso.

Resultado. **(a) la fila suma** 0,883 **y los pesos del pasado son menores de lo debido** (habría que renormalizar); **(b) el token futuro recibe un** 1,8 % **del peso**: el modelo «ve» el futuro.

Comprobación. la versión (a) renormalizada coincide con la correcta, como predice el ejercicio 3.5.

Solución del ejercicio 3.2

Datos. fila $(0, 4, 2)$, tercer token prohibido.

Planteamiento. calcular $\mathrm{softmax}(0, 4, -\infty)$ y $\mathrm{softmax}(0, 4, 0)$.

Desarrollo.

1. Con $-\infty$: exponenciales 1; 54,60; 0. Suma 55,60. Pesos 0,01799; 0,9820; 0.
2. Con 0: exponenciales 1; 54,60; 1. Suma 56,60. Pesos 0,01767; 0,9647; 0,01767.
3. Con 0, la posición prohibida recibe peso, y además el resultado depende del valor que tuviera la puntuación original sustituida, lo que es arbitrario.

Resultado. **con** $-\infty$**:** $(0{,}018;\ 0{,}982;\ 0)$**; con 0:** $(0{,}0177;\ 0{,}9647;\ 0{,}0177)$**.** Solo $-\infty$ anula exactamente el peso, porque $e^{-\infty} = 0$ mientras que $e^0 = 1$.

Comprobación. la fila con $-\infty$ coincide con la del ejemplo 3.5; ambas filas suman 1.

Solución del ejercicio 3.3

Datos. S escalada como en el enunciado; valores 4, 8, 12.

Planteamiento. sumar la máscara causal y aplicar la proposición 3.3 fila a fila.

Desarrollo.

1. Con máscara, las entradas por encima de la diagonal pasan a $-\infty$.
2. Fila 1: solo queda e^1; pesos $(1, 0, 0)$.
3. Fila 2: $e^0 = 1$, $e^{\ln 3} = 3$; suma 4; pesos $(1/4, 3/4, 0)$.
4. Fila 3: $e^0 = 1$, $e^0 = 1$, $e^{\ln 2} = 2$; suma 4; pesos $(1/4, 1/4, 1/2)$.
5. Salidas: $o_1 = 4$; $o_2 = \frac{1}{4} \cdot 4 + \frac{3}{4} \cdot 8 = 1 + 6 = 7$; $o_3 = \frac{1}{4} \cdot 4 + \frac{1}{4} \cdot 8 + \frac{1}{2} \cdot 12 = 1 + 2 + 6 = 9$.

Resultado.

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 1/4 & 3/4 & 0 \\ 1/4 & 1/4 & 1/2 \end{pmatrix}, \qquad (o_1, o_2, o_3) = (4, 7, 9).$$

Sustituir los cincos por cienes **no cambia nada**: son puntuaciones prohibidas y, por la proposición 3.3, los pesos no dependen de ellas.

Comprobación. cada fila suma 1 y cada salida está entre el mínimo y el máximo de los valores permitidos: $o_2 \in [4, 8]$, $o_3 \in [4, 12]$.

Solución del ejercicio 3.4

Datos. fila $(0, 4, 2)$; se suma $-c$ al tercer elemento; umbral 10^{-6}.

Planteamiento. el peso filtrado es $w(c) = e^{2-c}/(1 + e^4 + e^{2-c})$, decreciente en c; se despeja c de $w(c) < 10^{-6}$.

Desarrollo.

1. $1 + e^4 = 55{,}60$. La condición $w < 10^{-6}$ equivale a $e^{2-c}(1 - 10^{-6}) < 10^{-6} \cdot 55{,}60$, es decir, $e^{2-c} < 5{,}560 \cdot 10^{-5}$ (el factor $1 - 10^{-6}$ es despreciable).
2. Tomando logaritmos: $2 - c < \ln(5{,}560 \cdot 10^{-5}) = -9{,}797$, luego $c > 11{,}80$.
3. El menor entero es $c = 12$. Verificación: $w(12) = e^{-10}/(55{,}60 + e^{-10}) = 4{,}540 \cdot 10^{-5}/55{,}60 = 8{,}17 \cdot 10^{-7}$; $w(11) = e^{-9}/55{,}60 = 2{,}22 \cdot 10^{-6}$.

Resultado. $c = 12$, con un peso filtrado de $8{,}17 \cdot 10^{-7}$.

Comprobación. el umbral depende de la diferencia entre la puntuación prohibida y las permitidas, que no está acotada a priori; por eso se usa $-\infty$ o el menor número representable, y no un valor fijo pequeño.

Solución del ejercicio 3.5

Datos. $p_j = e^{z_j}/Z$ con $Z = \sum_l e^{z_l}$; $\tilde{p}_j = p_j \mathbb{1}[j \in \mathcal{P}_i] / \sum_{l \in \mathcal{P}_i} p_l$.

Planteamiento. sustituir p_j y simplificar Z; comparar con la proposición 3.3.

Desarrollo.

1. Para $j \in \mathcal{P}_i$: $\tilde{p}_j = \dfrac{e^{z_j}/Z}{\sum_{l \in \mathcal{P}_i} e^{z_l}/Z} = \dfrac{e^{z_j}}{\sum_{l \in \mathcal{P}_i} e^{z_l}}$.
2. Para $j \notin \mathcal{P}_i$: $\tilde{p}_j = 0$.
3. Ambas expresiones coinciden con las de la proposición 3.3; luego $\tilde{p} = \mathrm{softmax}(z + \mu)$.
4. Preferencia por la máscara previa: evita una segunda pasada de normalización y, sobre todo, es numéricamente robusta. Si una puntuación prohibida es mucho mayor que las

permitidas, los p_j permitidos pueden redondearse a 0 en coma flotante y la renormalización produce 0/0; restando el máximo *de las permitidas*, la máscara previa nunca lo hace.

Resultado. $\tilde{p} = \mathrm{softmax}(z + \mu)$: anular y renormalizar es matemáticamente equivalente, pero más caro y menos estable.

Comprobación. con $z = (0, 4, 2)$ y $\mathcal{P}_i = \{1, 2\}$ se obtiene (0,01799; 0,9820; 0) por ambos caminos (ejercicio 3.1).

A.4 Tema 4

Solución del ejercicio 4.1

Planteamiento. contrastar cada afirmación con la proposición 4.3, la proposición 2.3 y el corolario 3.7.

Desarrollo.

(a) **Falsa.** Los parámetros son $4d^2$ para todo h: cambiar h solo cambia cómo se cortan W_Q, W_K y W_V en bloques de $d \times d/h$.

(b) **Verdadera.** Por la proposición 2.3, $f(PX) = Pf(X)$: cada token recibe la misma salida, en otra fila. Por eso se añade información de posición (módulo 14).

(c) **Falsa.** Por el corolario 3.7, una sola pasada con máscara produce las n predicciones; la máscara es precisamente lo que permite entrenar en paralelo.

Resultado. **(a) falsa; (b) verdadera; (c) falsa.**

Comprobación. para (a), con $d = 512$: $4 \cdot 512^2 = 1\,048\,576$ tanto con $h = 8$ (bloques de 64 columnas) como con $h = 16$ (bloques de 32).

Solución del ejercicio 4.2

Datos. $d = 512$, $h = 8$, sin sesgos.

Planteamiento. proposición 4.3; cada $W_Q^{(r)}$ es $d \times d/h$.

Desarrollo.

1. $d^2 = 262\,144$; $4d^2 = 1\,048\,576$.
2. $d/h = 64$; $W_Q^{(r)} \in \mathbb{R}^{512\times 64}$ tiene 32 768 parámetros.
3. $8 \cdot 32\,768 = 262\,144 = 512^2$: las ocho juntas, yuxtapuestas por columnas, forman $W_Q \in \mathbb{R}^{512\times 512}$.

Resultado. $1\,048\,576$ **parámetros;** $32\,768$ **por cada** $W_Q^{(r)}$**.**

Comprobación. coincide con la cifra dada tras la proposición 4.3 para $d = 512$.

Solución del ejercicio 4.3

Datos. (a) $n = 2048$, $d_k = 128$; (b) $d = 512$, $n = 2048$.

Planteamiento. lema 4.6 y proposición 4.7.

Desarrollo.

1. (a) $QK^\top$ es $(2048 \times 128)(128 \times 2048)$: $2 \cdot 2048 \cdot 128 \cdot 2048 = 2 \cdot 4\,194\,304 \cdot 128 = 1\,073\,741\,824 \approx 1{,}074 \cdot 10^9$ FLOP, exactamente 2^{30}.
2. AV es $(2048 \times 2048)(2048 \times 128)$ y cuesta lo mismo; en total, $2\,147\,483\,648 \approx 2{,}147 \cdot 10^9$ FLOP.
3. (b) Proyecciones: $8nd^2 = 8 \cdot 2048 \cdot 262\,144 = 4\,294\,967\,296 \approx 4{,}295 \cdot 10^9$.
4. Atención: $4n^2d = 4 \cdot 4\,194\,304 \cdot 512 = 8\,589\,934\,592 \approx 8{,}590 \cdot 10^9$.
5. Cociente: $4n^2d/(8nd^2) = n/(2d) = 2048/1024 = 2$; como $n = 2048 > 2d = 1024$, domina la parte cuadrática.

Resultado. **(a)** $1{,}074 \cdot 10^9$ **FLOP para** $QK^\top$ **y** $2{,}147 \cdot 10^9$ **con** AV**; (b)** $4{,}295 \cdot 10^9$ **frente a** $8{,}590 \cdot 10^9$**: la atención cuesta el doble**, de acuerdo con el criterio $n > 2d$.

Comprobación. con potencias de 2: $2 \cdot 2^{11} \cdot 2^7 \cdot 2^{11} = 2^{30}$ y $8 \cdot 2^{11} \cdot 2^{18} = 2^{32} = 4\,294\,967\,296$.

Solución del ejercicio 4.4

Datos. fp16, 2 bytes por número; n^2 números por cabeza y capa; 1 GB $= 10^9$ bytes.

Planteamiento. memoria $= 2n^2$ bytes; el coste de la atención es proporcional a n^2.

Desarrollo.

1. $n = 10^5$: $2 \cdot 10^{10}$ bytes $= 20$ GB.
2. $n = 10^6$: $2 \cdot 10^{12}$ bytes $= 2000$ GB.
3. $8192/1024 = 8$; el coste se multiplica por $8^2 = 64$.

Resultado. 20 **GB;** 2000 **GB; factor** 64**.**

Comprobación. de 10^5 a 10^6, n se multiplica por 10 y la memoria por 100: $20 \cdot 100 = 2000$, como en la cuadro 4.1.

Solución del ejercicio 4.5

Datos. $L = 6$, $d = 512$, $A = 8$, $d_k = d_v = 64$, $d_{ff} = 2048$.

Planteamiento. contar las entradas de cada matriz y sumar.

Desarrollo.

1. (a) W_Q, W_K, W_V: A cabezas de $d \times d/A$, es decir, d^2 cada una; con W_O, $4d^2 = 4 \cdot 262\,144 = 1\,048\,576$. No depende de A, porque $A \cdot d/A = d$.
2. (b) Red de alimentación: $d \cdot d_{ff} + d_{ff} \cdot d = 2 \cdot 4d^2 = 8d^2 = 2\,097\,152$.
3. (c) Por capa, $4d^2 + 8d^2 = 12d^2 = 3\,145\,728$; la pila, $12Ld^2 = 6 \cdot 3\,145\,728 = 18\,874\,368$.

Resultado. **(a)** $1\,048\,576$**, independiente de** A**; (b)** $2\,097\,152$**; (c)** $12Ld^2 = 18\,874\,368 \approx 1{,}89 \cdot 10^7$**.**

Comprobación. la atención es $4/12 = 1/3$ de cada bloque. Los embeddings y la capa de salida, de $|\mathcal{V}|\,d$ parámetros, no están incluidos en $12Ld^2$.

Solución del ejercicio 4.6

Datos. $L = 12$, $d = 768$, $|\mathcal{V}| = 50\,257$; $n = 1024$ y $n = 16\,384$.

Planteamiento. sustituir en cada fórmula, multiplicar por L las que son por capa y sumar. Se trabaja en unidades de 10^9 FLOP.

Desarrollo.

1. Auxiliares con $n = 1024$: $d^2 = 589\,824$; $n^2 = 1\,048\,576$; $nd^2 = 603\,979\,776$.
2. Proyecciones ($8nd^2$ por capa): $12 \cdot 8 \cdot 603\,979\,776 = 57{,}98 \cdot 10^9$.
3. Atención ($4n^2d$ por capa): $12 \cdot 4 \cdot 1\,048\,576 \cdot 768 = 38{,}65 \cdot 10^9$.
4. Red de alimentación ($16nd^2$ por capa): $12 \cdot 16 \cdot 603\,979\,776 = 116{,}0 \cdot 10^9$.
5. Capa de salida: $2 \cdot 1024 \cdot 768 \cdot 50\,257 = 79{,}05 \cdot 10^9$.
6. Total: $291{,}6 \cdot 10^9$ (exactamente 291 648 307 200). Porcentajes: proyecciones 19,9 %, atención 13,3 %, red de alimentación 39,8 %, salida 27,1 %.
7. (b) Con $n = 16\,384 = 16 \cdot 1024$, los términos lineales en n se multiplican por 16 y la atención por $16^2 = 256$: proyecciones 927,7, atención 9896, red de alimentación 1855, salida 1265 (en 10^9 FLOP).
8. Total: $13\,944 \cdot 10^9 \approx 1{,}394 \cdot 10^{13}$; cociente $13\,944/291{,}6 = 47{,}8$. Porcentajes: atención 71,0 %, red de alimentación 13,3 %, salida 9,1 %, proyecciones 6,7 %.
9. (c) La atención supera a la red de alimentación cuando $4n^2d > 16nd^2$, es decir, $n > 4d = 3072$.

Resultado. **con $n = 1024$, $2{,}916 \cdot 10^{11}$ FLOP y domina la red de alimentación (39,8 %); con $n = 16\,384$, $1{,}394 \cdot 10^{13}$ FLOP ($\times 47{,}8$) y domina la atención (71,0 %).** La atención supera a la red de alimentación a partir de $n = 3072$ y a las proyecciones a partir de $n = 2d = 1536$.

Comprobación. los porcentajes suman 100,1 % por redondeo en ambos casos. El total crece menos que 256 veces porque solo una parte del coste es cuadrática.

Solución del ejercicio 4.7

Datos. $W_Q, W_K \in \mathbb{R}^{d \times d_k}$ con $d_k < d$; en (c), $d = 512$, $h = 8$, $d_k = 64$.

Planteamiento. usar que el rango de un producto no supera el de sus factores y la factorización de rango (módulo 3).

Desarrollo.

1. (a) Para cualesquiera W_Q, W_K, $\operatorname{rg}(W_Q W_K^\top) \le \operatorname{rg} W_Q \le d_k < d$. La matriz $B = I_d$ tiene rango d, luego no se escribe como $W_Q W_K^\top$.
2. (b) Si $\operatorname{rg} B = r \le d_k$, sean $c_1, \ldots, c_r$ una base de su espacio de columnas y $C \in \mathbb{R}^{d \times r}$ la matriz que las tiene por columnas. Cada columna de B es combinación de ellas: $B = CR$ con $R \in \mathbb{R}^{r \times d}$. Basta tomar $W_Q = (C \;\; 0)$ y $W_K = (R^\top \;\; 0)$, completadas con $d_k - r$ columnas nulas, para que $W_Q W_K^\top = CR = B$.
3. (c) La suma de ocho matrices de rango ≤ 64 tiene rango $\le 8 \cdot 64 = 512 = d$, que puede ser completo.
4. Pero la atención multi-cabeza no aplica una softmax a la suma de las puntuaciones: aplica una softmax distinta a cada cabeza y suma después las salidas (proposición 4.4). Por la no linealidad de la softmax, $\sum_r \operatorname{softmax}(S_r) \neq \operatorname{softmax}(\sum_r S_r)$ en general.

Resultado. **(a) I_d no es representable; (b) toda forma de rango $\leq d_k$ sí; (c) rango ≤ 512, pero la suma no describe la multi-cabeza, que combina h distribuciones de atención distintas.**

Comprobación. ejemplo de la no linealidad con dos cabezas de una sola fila y puntuaciones $S_1 = (2, 0)$, $S_2 = (0, 0)$: $\mathrm{softmax}(S_1) + \mathrm{softmax}(S_2) = (0{,}8808 + 0{,}5;\ 0{,}1192 + 0{,}5) = (1{,}381;\ 0{,}6192)$, mientras que $2\,\mathrm{softmax}(S_1 + S_2) = 2\,\mathrm{softmax}(2, 0) = (1{,}762;\ 0{,}2384)$.

A.5 Tema 5

Solución del ejercicio 5.1

Datos. secuencia «el señor Dursley …el señor»; la posición final contiene «señor».

Planteamiento. aplicar la proposición 5.2: los pesos de la posición final solo comparan x_i con cada x_j.

Desarrollo.

1. Para predecir «Dursley», la posición final debería atender a la posición de «Dursley», cuyo rasgo distintivo es que *su token anterior* es «señor».
2. En una capa, la puntuación de esa posición depende de los embeddings de «señor» (consulta) y de «Dursley» y su posición (clave). Una cabeza podría aprender a preferir «Dursley», pero solo como token concreto, no como «el token que siguió a señor».
3. Si «Dursley» nunca se vio en el entrenamiento, ninguna preferencia aprendida lo favorece; y si el nombre fuera otro, haría falta otra preferencia distinta.
4. Lo necesario es que una capa anterior haya escrito en la posición de «Dursley» la información «mi token anterior es señor» (cabeza de token anterior).

Resultado. **con una sola capa no puede seleccionarse la posición por su token anterior; hace falta que antes se haya escrito en la posición de «Dursley» la identidad de su predecesor.**

Comprobación. es exactamente la composición K de dos capas descrita tras la proposición 5.2.

Solución del ejercicio 5.2

Datos. $\alpha_{i,i-1} = e^{\beta^2}/(e^{\beta^2} + i)$ (teorema 5.3).

Planteamiento. sustituir; para (b), la condición es más exigente cuanto mayor es i, luego basta imponerla en $i = 9$.

Desarrollo.

1. (a) $\beta = 2$: $e^4 = 54{,}60$; $\alpha_{5,4} = 54{,}60/(54{,}60 + 5) = 54{,}60/59{,}60 = 0{,}9161$.
2. (b) $\alpha \geq 0{,}99$ equivale a $e^{\beta^2} \geq 0{,}99\,(e^{\beta^2} + i)$, es decir, $0{,}01\,e^{\beta^2} \geq 0{,}99\,i$, o $e^{\beta^2} \geq 99\,i$.
3. Con $i = 9$: $e^{\beta^2} \geq 891$, $\beta^2 \geq \ln 891 = 6{,}792$, $\beta \geq 2{,}606$.

Resultado. **(a)** $\alpha_{5,4} = 0{,}9161$**; (b)** $\beta \geq 2{,}606$**.**

Comprobación. con $\beta^2 = \ln 891$, $\alpha_{9,8} = 891/(891 + 9) = 891/900 = 0{,}99$ exactamente.

Solución del ejercicio 5.3

Datos. $\beta = 1$; $X = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$ (columnas x_1, x_2); $\xi^{(0)} = (1;\ 0{,}5)^\top$.

Planteamiento. $\xi^{(t+1)} = X\,\mathrm{softmax}(X^\top \xi^{(t)})$.

Desarrollo.

1. $X^\top \xi^{(0)} = (2, 1)$. Softmax: $e^2/(e^2 + e) = 1/(1 + e^{-1}) = 0{,}7311$ y $0{,}2689$.
2. $\xi^{(1)} = 0{,}7311\,(2, 0) + 0{,}2689\,(0, 2) = (1{,}462;\ 0{,}5379)$.
3. $X^\top \xi^{(1)} = (2{,}924;\ 1{,}076)$; diferencia $1{,}848$; pesos $1/(1 + e^{-1{,}848}) = 0{,}8640$ y $0{,}1360$.
4. $\xi^{(2)} = 0{,}8640\,(2, 0) + 0{,}1360\,(0, 2) = (1{,}728;\ 0{,}2721)$.

Resultado. $\xi^{(1)} = (1{,}462;\ 0{,}5379)$, $\xi^{(2)} = (1{,}728;\ 0{,}2721)$: el estado se acerca al patrón $x_1 = (2, 0)$, el más parecido al estímulo inicial.

Comprobación. una tercera actualización da pesos $(0{,}9484;\ 0{,}0516)$ y $\xi^{(3)} = (1{,}897;\ 0{,}1032)$, aún más cerca de x_1; cada estado está en el segmento que une x_1 y x_2 (proposición 1.4).

Solución del ejercicio 5.4

Datos. secuencia «$\langle s\rangle$ el gato come pescado y luego el gato duerme», posiciones 0 a 9; e_t *one-hot* de token, p_i *one-hot* de posición; $\beta = 10$; máscara causal; sin escalado adicional.

Planteamiento. capa 1: cabeza de token anterior (teorema 5.3); capa 2: consulta con el token actual y claves con la salida de la capa 1 (composición K).

Desarrollo.

1. Capa 1: $q_i = \beta p_i$, $k_j = \beta p_{j+1}$, $v_j = e_{x_j}$. Por el teorema 5.3, $\alpha_{i,i-1} = e^{100}/(e^{100} + i) \approx 1$, y la salida es $h_i \approx e_{x_{i-1}}$ para $i \geq 1$ (en $i = 0$, $h_0 = e_{\langle s\rangle}$).
2. Capa 2: $q_i = \beta e_{x_i}$, $k_j = \beta h_j$, $v_j = e_{x_j}$. La puntuación $q_i \cdot k_j \approx \beta^2 = 100$ si $x_{j-1} = x_i$ y ≈ 0 en otro caso.
3. Posición 7 («el»): entre $j \leq 7$, solo $j = 2$ cumple $x_{j-1} = x_1 =$ «el» (la propia $j = 8$ está prohibida por la máscara). Peso ≈ 1 en $j = 2$; valor e_{gato}: predice **«gato»**.
4. Posición 8 («gato»): solo $j = 3$ cumple $x_2 =$ «gato». Valor e_{come}: predice **«come»**.
5. Posición 9 («duerme»): ninguna $j \leq 9$ tiene «duerme» como token anterior; todas las puntuaciones valen 0 y la atención es uniforme, $1/10$ por posición: no se copia nada útil.

Resultado. **capa 1:** $Q = \beta\cdot$**posición,** $K = \beta\cdot$**posición desplazada,** $V =$ **token; capa 2:** $Q = \beta\cdot$**token actual,** $K = \beta\cdot$**salida de la capa 1,** $V =$ **token.** Predice «gato» tras el segundo «el» y «come» tras el segundo «gato»; en la posición 9 no hay patrón previo.

Comprobación. una simulación en NumPy da pesos 1,0000 en la posición 2 (para $i = 7$) y en la 3 (para $i = 8$), y peso máximo $0{,}1 = 1/10$ en $i = 9$.

Solución del ejercicio 5.5

Datos. $o(\xi) = \sum_l p_l x_l$, $p_l = e^{\beta x_l^\top \xi}/Z$, $Z = \sum_m e^{\beta x_m^\top \xi}$.

Planteamiento. derivar p_l respecto de ξ con la regla del cociente (módulo 4) y sustituir.

Desarrollo.

1. $\nabla_\xi e^{\beta x_l^\top \xi} = \beta e^{\beta x_l^\top \xi} x_l$ y $\nabla_\xi Z = \beta \sum_m e^{\beta x_m^\top \xi} x_m = \beta Z\, o$.
2. Regla del cociente: $\nabla_\xi p_l = \big(\beta e^{\beta x_l^\top \xi} x_l Z - e^{\beta x_l^\top \xi} \beta Z o\big)/Z^2 = \beta p_l (x_l - o)$.
3. $\dfrac{\partial o}{\partial \xi} = \sum_l x_l (\nabla_\xi p_l)^\top = \beta \sum_l p_l x_l (x_l - o)^\top = \beta\Big(\sum_l p_l x_l x_l^\top - o\, o^\top\Big)$, usando $\sum_l p_l x_l = o$.
4. La matriz entre paréntesis es $\mathbb{E}_p[x x^\top] - \mathbb{E}_p[x]\mathbb{E}_p[x]^\top = \mathrm{Cov}_p(x)$.
5. (b) Patrones 0 y 2, $\xi = \frac{1}{2}\ln 3$: puntuaciones 0 y $\ln 3$; pesos 1/4 y 3/4; $o = \frac{3}{4}\cdot 2 = 1{,}5$; $\mathbb{E}_p[x^2] = \frac{3}{4}\cdot 4 = 3$; varianza $3 - 1{,}5^2 = 0{,}75$.
6. (c) Si p se concentra en un patrón, $\mathrm{Cov}_p(x) \to 0$ y la jacobiana se anula.

Resultado. $\partial o/\partial \xi = \beta\, \mathrm{Cov}_p(x)$**; en el ejemplo,** $do/d\xi = 0{,}75$**; con** p **concentrada, la jacobiana tiende a 0.**

Comprobación. la diferencia finita $[o(\xi + 10^{-6}) - o(\xi - 10^{-6})]/(2\cdot 10^{-6})$ da 0,7500. El apartado (c) es la saturación de la proposición 2.5 vista desde la salida: un punto fijo bien separado es estable porque pequeñas perturbaciones del estado apenas cambian la salida.

Solución del ejercicio 5.6

Datos. $x_1, \ldots, x_N$ ortonormales; $\xi = x_k$; $\xi^{\text{nuevo}} = X\,\mathrm{softmax}(\beta X^\top \xi)$.

Planteamiento. calcular los pesos y la norma del error con el teorema de Pitágoras.

Desarrollo.

1. Por ortonormalidad, $X^\top x_k = e_k$: puntuación 1 en k y 0 en el resto.
2. Pesos: $p_k = e^\beta/(e^\beta + N - 1)$ y $p_l = w := 1/(e^\beta + N - 1)$ para $l \neq k$. Además $1 - p_k = (N-1)w$.
3. $\xi^{\text{nuevo}} - x_k = -(1 - p_k)x_k + \sum_{l\neq k} w\, x_l$.
4. Como los x_l son ortonormales: $\|\xi^{\text{nuevo}} - x_k\|^2 = (1-p_k)^2 + (N-1)w^2 = (N-1)^2 w^2 + (N-1)w^2 = N(N-1)w^2$.
5. Raíz: $\|\xi^{\text{nuevo}} - x_k\| = \sqrt{N(N-1)}\, w$.
6. Con $N = 4$, $\beta = 5$: $e^5 = 148{,}4$; $w = 1/151{,}4 = 0{,}006605$; $\sqrt{12} = 3{,}464$; error $3{,}464 \cdot 0{,}006605 = 0{,}02288$.

Resultado. $\|\xi^{\text{nuevo}} - x_k\| = \sqrt{N(N-1)}/(e^\beta + N - 1)$**; con** $N = 4$ **y** $\beta = 5$**,** 0,02288**.**

Comprobación. el error decrece como $e^{-\beta}$: es el error de recuperación exponencialmente pequeño de [10, §2] en su caso más sencillo. El cálculo directo con la matriz identidad de 4×4 da el mismo valor.

Bibliografía

[1] D. Bahdanau, K. Cho e Y. Bengio. Neural machine translation by jointly learning to align and translate. En *International Conference on Learning Representations (ICLR)*, 2015. https://arxiv.org/abs/1409.0473

[2] C. M. Bishop y H. Bishop. *Deep Learning: Foundations and Concepts*. Springer, 2024. Cap. 12, «Transformers» (§12.1 «Attention»). https://www.bishopbook.com/

[3] D. Yang y Y. Choi. CS224N: Natural Language Processing with Deep Learning. Stanford University, invierno de 2026. Clase 5, «Transformers»; tarea 3, «Self-Attention and Transformers». https://web.stanford.edu/class/cs224n/

[4] Equipo docente de CS336. CS336: Language Modeling from Scratch. Tarea 1, «Basics», versión 26.0.3. Stanford University, primavera de 2026. https://github.com/stanford-cs336/assignment1-basics

[5] T. Dao, D. Y. Fu, S. Ermon, A. Rudra y C. Ré. FlashAttention: Fast and memory-efficient exact attention with IO-awareness. En *Advances in Neural Information Processing Systems 35*, 2022. https://arxiv.org/abs/2205.14135

[6] N. Elhage, N. Nanda, C. Olsson *et al.* A mathematical framework for Transformer circuits. *Transformer Circuits Thread*, Anthropic, 2021. https://transformer-circuits.pub/2021/framework/index.html

[7] Gemini Team, Google. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. Informe técnico, 2024. https://arxiv.org/abs/2403.05530

[8] D. Jurafsky y J. H. Martin. *Speech and Language Processing*, 3.ª ed., borrador del 19 de agosto de 2026. Cap. 7, «Transformers and Pretraining»; cap. 10, «Interpretability». https://web.stanford.edu/~jurafsky/slp3/

[9] C. Olsson, N. Elhage, N. Nanda *et al.* In-context learning and induction heads. *Transformer Circuits Thread*, Anthropic, 2022. https://arxiv.org/abs/2209.11895

[10] H. Ramsauer, B. Schäfl, J. Lehner, P. Seidl, M. Widrich, T. Adler, L. Gruber, M. Holzleitner, M. Pavlović, G. K. Sandve, V. Greiff, D. Kreil, M. Kopp, G. Klambauer, J. Brandstetter y S. Hochreiter. Hopfield networks is all you need. En *International Conference on Learning Representations (ICLR)*, 2021. https://arxiv.org/abs/2008.02217

[11] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser e I. Polosukhin. Attention is all you need. En *Advances in Neural Information Processing Systems 30*, 2017. https://arxiv.org/abs/1706.03762

[12] A. Zhang, Z. C. Lipton, M. Li y A. J. Smola. *Dive into Deep Learning*, versión 1.0.3. Cambridge University Press, 2023. Cap. 11, «Attention Mechanisms and Transformers». https://d2l.ai/