Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase IV · Escala, sistemas y arquitecturas modernas

Módulo 16

Preentrenamiento a escala

Apuntes del curso

Edición de octubre de 2026

Presentación del módulo

Los módulos 14 y 15 construyeron un Transformer, contaron su coste y lo entrenaron a pequeña escala. Este módulo estudia qué ocurre cuando el mismo procedimiento se lleva a billones de tokens y a decenas de miles de millones de parámetros. La pregunta central es económica: con un presupuesto de cómputo C fijo, ¿qué tamaño de modelo N y qué número de tokens D conviene elegir, y de dónde salen esos tokens? La respuesta tiene dos partes. La primera es la ingeniería de los datos: filtrar la web, eliminar duplicados con MinHash y LSH y mezclar fuentes. La segunda son las *leyes de escalado*, relaciones empíricas en forma de ley de potencia entre la pérdida y los recursos, que permiten plantear el reparto como un problema de optimización con restricciones y resolverlo con multiplicadores de Lagrange. El módulo termina con dos cuestiones abiertas: si las capacidades «emergentes» son reales y qué cuesta ampliar la ventana de contexto.

Objetivos

Al finalizar el módulo, el estudiante debe ser capaz de:

1. describir las etapas de preparación de un corpus de preentrenamiento, aplicar reglas heurísticas de calidad, relacionar el filtro por perplejidad con la entropía cruzada y calcular las épocas de cada fuente de una mezcla;
2. definir la similitud de Jaccard, demostrar la propiedad fundamental de MinHash, obtener la varianza de su estimador y analizar la curva en S del LSH por bandas;
3. caracterizar las leyes de potencia, ajustarlas por mínimos cuadrados en escala log-log y enunciar las leyes de escalado de Kaplan *et al.*;
4. derivar con multiplicadores de Lagrange el reparto óptimo de Chinchilla entre N y D, demostrar sus consecuencias y justificar la regla de unos 20 tokens por parámetro;
5. explicar los tres métodos empíricos de Hoffmann *et al.*, incorporar el coste de inferencia y la repetición de datos al reparto y calcular cuándo se amortiza sobreentrenar un modelo pequeño;
6. analizar el argumento de la métrica sobre las capacidades emergentes y cuantificar el coste en cómputo, memoria y codificación posicional del contexto largo.

Requisitos previos

Del módulo 1, la entropía cruzada, la perplejidad y la desigualdad de Gibbs (tema 5). Del módulo 4, los multiplicadores de Lagrange y la convexidad. Del módulo 5, la independencia, la distribución binomial y la varianza de una media. Del módulo 6, la divergencia de Kullback–Leibler. Del módulo 7, los calendarios de tasa de aprendizaje con decaimiento coseno. Del módulo 8, la regresión lineal por mínimos cuadrados. Del módulo 12, la tokenización. Del módulo 13, el coste cuadrático de la atención. Del módulo 14, la regla $C \approx 6ND$, el coste $2N$

por token de la inferencia y RoPE (temas 4 y 6). Del módulo 15, el bucle de entrenamiento y las curvas de pérdida.

Organización

Tema	Contenido	Fuentes principales
1	Datos de preentrenamiento	[22], [28], [20], [25], [10]
2	Deduplicación: MinHash y LSH	[15], [14], [4], [13], [10]
3	Leyes de potencia y leyes de Kaplan	[12], [16], [9]
4	El reparto óptimo del cómputo: Chinchilla	[11], [3], [9]
5	Estimación empírica, inferencia y datos limitados	[11], [18], [23], [9]
6	Capacidades emergentes y contexto largo	[27], [24], [6], [7]

Cada tema termina con una lista de lecturas y con ejercicios graduados en tres niveles: $\star$ comprensión, $\star\star$ cálculo y $\star\star\star$ demostración. Los ejercicios marcados con *Fuente* están adaptados de cursos y libros de texto universitarios; el enunciado se ha redactado de nuevo y, en algunos casos, se han cambiado los datos para que puedan resolverse a mano. Las soluciones completas, paso a paso, están en el apéndice A.

Sobre las fuentes

El texto es de redacción propia. La deduplicación sigue el capítulo 3, «Finding Similar Items», de Leskovec, Rajaraman y Ullman [15], libro de texto del curso CS246 de Stanford [14], y la sección 3 de la práctica de datos del curso CS336 de Stanford [10]. Las leyes de escalado siguen los artículos originales de Kaplan *et al.* [12] y de Hoffmann *et al.* [11], la clase sobre leyes de escalado del curso CS324 de Stanford [16] y la práctica de leyes de escalado de CS336 [9]; la forma convexa del problema de reparto procede de la programación geométrica de Boyd y Vandenberghe [3, §4.5]. Los datos sobre corpus reales proceden de los informes de Gopher [22], LLaMA [25, 26, 7], RefinedWeb [19] y FineWeb [20]; la repetición de datos, de Muennighoff *et al.* [18]; las capacidades emergentes, de Wei *et al.* [27] y Schaeffer, Miranda y Koyejo [24]. Anthropic, Google y xAI no publican el tamaño ni la composición de los corpus de Claude, Gemini y Grok; sobre ellos solo se usa información pública [8].

Notación

Símbolo	Significado
N, D, C	parámetros, tokens de entrenamiento y FLOPs de entrenamiento
L, $L(N, D)$	pérdida de validación (nats por token) y su ley de escalado
E, A, B, α, β	constantes de la ley de Chinchilla
$N_{\text{opt}}(C)$, $D_{\text{opt}}(C)$	reparto óptimo para el presupuesto C
w_i, U_i, e_i	peso, tokens únicos y épocas de la fuente i de una mezcla
$J(A, B)$	similitud de Jaccard de dos conjuntos
h, $\text{sig}(S)$	función hash y firma MinHash del conjunto S
b, r	bandas y filas por banda del LSH ($n = br$ funciones hash)
k	longitud de una respuesta en tokens o de un *shingle*
n, n_{ctx}	longitud de la secuencia y ventana de contexto
ln, $\log_{10}$	logaritmo natural y decimal

Las pérdidas se miden en nats por token. Se usa la escala numérica larga del español: un *billón* es 10^{12} y mil millones, 10^9.

Índice

Presentación del módulo **ii**

1 Datos de preentrenamiento **1**

1.1 Del rastreo web al corpus . . . 1
1.2 Filtros heurísticos de calidad . . . 1
1.3 Filtro por perplejidad . . . 2
1.4 Clasificadores de calidad . . . 3
1.5 Mezcla de fuentes y épocas . . . 3
1.6 La escala de los datos . . . 4
Ejercicios del tema 1 . . . 5

2 Deduplicación: MinHash y LSH **6**

2.1 Por qué deduplicar . . . 6
2.2 Duplicados exactos . . . 6
2.3 Shingles y similitud de Jaccard . . . 7
2.4 Firmas MinHash . . . 7
2.5 LSH por bandas . . . 8
Ejercicios del tema 2 . . . 9

3 Leyes de potencia y leyes de escalado de Kaplan **11**

3.1 Leyes de potencia . . . 11
3.2 Ajuste en escala log-log . . . 11
3.3 Las leyes de Kaplan . . . 12
3.4 Ley conjunta y sobreajuste . . . 13
3.5 El reparto de Kaplan . . . 13
Ejercicios del tema 3 . . . 14

4 El reparto óptimo del cómputo: Chinchilla **15**

4.1 El problema del reparto . . . 15
4.2 La ley paramétrica de Chinchilla . . . 15
4.3 La solución en forma cerrada . . . 16
4.4 Gopher frente a Chinchilla . . . 17
4.5 La regla de los 20 tokens . . . 17
4.6 El mínimo es plano . . . 17

4.7 Forma convexa del problema . . . 18
Ejercicios del tema 4 . . . 18

5 Estimación empírica, inferencia y datos limitados 20
5.1 Tres métodos de estimación . . . 20
5.2 Por qué difieren Kaplan y Chinchilla . . . 21
5.3 El coste de la inferencia . . . 22
5.4 Datos limitados: el valor de repetir . . . 23
Ejercicios del tema 5 . . . 24

6 Capacidades emergentes y contexto largo 25
6.1 Capacidades emergentes . . . 25
6.2 El argumento de la métrica . . . 25
6.3 El coste del contexto largo . . . 27
6.4 Posiciones no vistas: interpolación de RoPE . . . 27
6.5 La receta habitual y sus límites . . . 28
Ejercicios del tema 6 . . . 28

A Soluciones de los ejercicios 30
A.1 Tema 1 . . . 30
A.2 Tema 2 . . . 33
A.3 Tema 3 . . . 36
A.4 Tema 4 . . . 38
A.5 Tema 5 . . . 41
A.6 Tema 6 . . . 44

Bibliografía 47

Tema 1

Datos de preentrenamiento

El preentrenamiento minimiza la entropía cruzada media sobre un corpus (módulo 1, tema 5), de modo que el modelo aprende la distribución del texto que se le muestra. La composición de ese corpus es, por tanto, una decisión de diseño tan importante como la arquitectura. Este tema describe cómo se obtiene un corpus a partir de la web y formaliza tres de sus etapas: los filtros de calidad, el filtro por perplejidad y la mezcla de fuentes. Se siguen las secciones 2 y 4 de la práctica de datos de CS336 [10], la clase sobre datos de CS324 [16] y los informes de CCNet [28], Gopher [22, §3.4 y apéndice A], RefinedWeb [19, §3], FineWeb [20] y LLaMA [25, §2.1]. La deduplicación, que también forma parte del proceso, se estudia por separado en el tema 2.

1.1 Del rastreo web al corpus

Definición 1.1 (Corpus de preentrenamiento). Un *corpus de preentrenamiento* es una colección finita de documentos $\mathcal{C} = \{x^{(1)}, \ldots, x^{(M)}\}$, cada uno una secuencia de tokens. Su *tamaño* es el número total de tokens, $\sum_m |x^{(m)}|$. Un *filtro* es un predicado f sobre documentos; aplicarlo a $\mathcal{C}$ produce $\{x \in \mathcal{C} : f(x) = 1\}$. Un proceso de preparación es una composición de transformaciones (extracción, normalización) y filtros.

La fuente principal es la web. Common Crawl publica volcados periódicos de miles de millones de páginas; FineWeb, por ejemplo, se construyó a partir de 96 volcados y contiene unos 15 billones de tokens [20]. La figura 1.1 resume las etapas habituales. Casi todo el material en bruto se descarta: en RefinedWeb, la identificación del idioma elimina cerca de la mitad de los documentos, y el conjunto del proceso, casi el 90 % [19, §3 y figura 2].

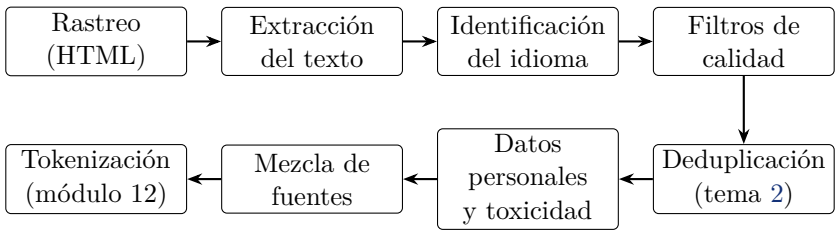


Figura 1.1: Etapas habituales de la preparación de un corpus a partir de la web, según [10, 19, 20]. El orden concreto varía de un informe a otro.

1.2 Filtros heurísticos de calidad

Los filtros más sencillos son reglas sobre estadísticas superficiales del documento. Son baratos, deterministas y fáciles de auditar. El informe de Gopher [22, apéndice A] define un conjunto

de ellas; la práctica de CS336 [10, §2.6] usa el siguiente subconjunto.

Definición 1.2 (Filtros de Gopher, subconjunto de CS336). Un documento con W palabras, longitud media de palabra $\bar{\ell}$ (en caracteres) y Λ líneas *pasa* el filtro si se cumplen las cuatro condiciones siguientes:

(i) $50 \le W \le 100\,000$;

(ii) $3 \le \bar{\ell} \le 10$;

(iii) como mucho el 30 % de las Λ líneas termina en puntos suspensivos;

(iv) al menos el 80 % de las palabras contiene un carácter alfabético.

Ejemplo 1.3. Un documento de 120 palabras y 480 caracteres en palabras, con 10 líneas, 4 de las cuales terminan en «...», tiene $\bar{\ell} = 480/120 = 4$, pero una fracción de líneas truncadas de $4/10 = 0{,}40 > 0{,}30$. No pasa el filtro: es típico de las páginas de listados con fragmentos de artículos.

1.3 Filtro por perplejidad

CCNet [28] puntúa cada página con un modelo de n-gramas entrenado sobre Wikipedia y conserva las de perplejidad baja; LLaMA usó este proceso para su parte de Common Crawl [25, §2.1]. La idea es que el texto parecido al de referencia recibe probabilidad alta. El caso de un modelo de unigramas permite analizar exactamente qué mide el filtro.

Definición 1.4 (Perplejidad de un documento). Sea q una distribución sobre $\mathcal{V}$ con $q(v) > 0$ para todo v (un modelo de unigramas de referencia) y sea $x = (x_1, \dots, x_T)$ un documento. La perplejidad de x según q es

$$\mathrm{PPL}_q(x) = \exp\Big(-\frac{1}{T}\sum_{t=1}^{T} \ln q(x_t)\Big).$$

La *distribución empírica* de x es $\hat{p}_x(v) = |\{t : x_t = v\}|/T$.

Proposición 1.5. *Para todo documento x,*

$$\ln \mathrm{PPL}_q(x) = H(\hat{p}_x, q) = H(\hat{p}_x) + D(\hat{p}_x \,\|\, q).$$

Demostración. Agrupando las posiciones por token, $\sum_t \ln q(x_t) = \sum_v T\hat{p}_x(v) \ln q(v)$. Dividiendo por $-T$ se obtiene $-\sum_v \hat{p}_x(v) \ln q(v) = H(\hat{p}_x, q)$, la entropía cruzada (módulo 1, tema 5). La segunda igualdad es la descomposición $H(p, q) = H(p) + D(p \,\|\, q)$ del módulo 6, que se comprueba sumando y restando $\sum_v \hat{p}_x(v) \ln \hat{p}_x(v)$. ∎

La proposición 1.5 muestra que el filtro premia dos cosas distintas: que el documento se parezca a la referencia (divergencia pequeña) y que el documento sea poco variado (entropía empírica pequeña). La segunda es indeseable.

Corolario 1.6 (El filtro premia la repetición). *Sea $q_{\max} = \max_v q(v)$. Para todo documento x, $\mathrm{PPL}_q(x) \ge 1/q_{\max}$, con igualdad si y solo si todos los tokens de x maximizan q.*

Demostración. Cada factor cumple $-\ln q(x_t) \geq -\ln q_{\max}$, luego la media también, y $\mathrm{PPL}_q(x) \geq e^{-\ln q_{\max}} = 1/q_{\max}$. La igualdad en la media exige la igualdad en cada término, es decir, $q(x_t) = q_{\max}$ para todo t. ■

Ejemplo 1.7. Sea $q(\texttt{a}) = 0{,}5$, $q(\texttt{b}) = 0{,}3$, $q(\texttt{c}) = 0{,}2$. El documento «a b a c» tiene $\mathrm{PPL}_q = (0{,}5 \cdot 0{,}3 \cdot 0{,}5 \cdot 0{,}2)^{-1/4} = 0{,}015^{-1/4} = 2{,}857$. Su distribución empírica es $(1/2, 1/4, 1/4)$, con $H(\hat{p}) = 1{,}0397$ nats y $D(\hat{p} \,\|\, q) = 0{,}0102$ nats; la suma, 1,0499, es $\ln 2{,}857$, como predice la proposición 1.5. El documento degenerado «a a a a» obtiene la perplejidad mínima, $1/0{,}5 = 2$. Por eso los procesos reales combinan el filtro por perplejidad con reglas contra la repetición [22, apéndice A].

1.4 Clasificadores de calidad

Una alternativa es aprender qué es «calidad» a partir de ejemplos. Se toman como positivos documentos de una fuente de referencia (por ejemplo, páginas citadas desde Wikipedia) y como negativos páginas aleatorias de Common Crawl, y se entrena un clasificador lineal [10, §2.7].

Definición 1.8 (Filtro por clasificador). Sea $g\colon \mathcal{X} \to [0, 1]$ un clasificador que estima la probabilidad de que un documento proceda de la fuente de referencia. El filtro con umbral τ conserva los documentos con $g(x) \geq \tau$. Subir τ aumenta la precisión y reduce la cobertura.

LLaMA entrenó un clasificador lineal que distingue las páginas usadas como referencia en Wikipedia de páginas aleatorias, y descartó las no clasificadas como referencia [25, §2.1]. FineWeb-Edu sustituye la fuente de referencia por anotaciones de un modelo grande: Llama-3-70B-Instruct puntuó el «valor educativo» de una muestra de páginas de 0 a 5, se ajustó una regresión sobre embeddings y se conservaron las páginas con puntuación al menos 3, unos 1,3 billones de tokens [20, §4].

Observación 1.9. «Calidad» es una elección, no una propiedad objetiva del texto. Un clasificador entrenado con Wikipedia como modelo de lo deseable tiende a descartar registros informales, variedades dialectales e idiomas con pocos recursos, y el modelo resultante hereda ese sesgo. Las reglas heurísticas tienen el mismo problema en menor grado: un umbral de longitud media de palabra pensado para el inglés no es neutral para otros idiomas.

1.5 Mezcla de fuentes y épocas

El corpus final combina varias fuentes (web, código, libros, artículos científicos, Wikipedia) con pesos fijados por experimentos.

Definición 1.10 (Mezcla y épocas). Sean m fuentes con U_i tokens únicos cada una y sean $w_i \geq 0$, $\sum_i w_i = 1$, los *pesos de muestreo*. Un entrenamiento de D tokens extrae $w_i D$ tokens de la fuente i; su número de *épocas* es

$$e_i = \frac{w_i D}{U_i}.$$

Si $e_i > 1$, la fuente se *sobremuestrea*: parte de su texto se ve varias veces.

Proposición 1.11. *Sea $E_{\max} > 0$. Existe una mezcla con $e_i \leq E_{\max}$ para todo i si y solo si $D \leq E_{\max} \sum_i U_i$.*

Demostración. Si $e_i \le E_{\max}$ para todo i, entonces $w_i D \le E_{\max} U_i$; sumando sobre i y usando $\sum_i w_i = 1$, $D \le E_{\max} \sum_i U_i$. Recíprocamente, si se cumple la desigualdad, los pesos proporcionales $w_i = U_i / \sum_j U_j$ dan $e_i = D / \sum_j U_j \le E_{\max}$ para todo i. ■

Ejemplo 1.12 (La mezcla de LLaMA). La tabla 1 de [25] da, para el entrenamiento de 1,4 billones de tokens, el peso y las épocas de cada fuente. Despejando $U_i = w_i D / e_i$ se obtienen los tokens únicos implícitos:

Fuente	w_i	e_i	$w_i D$ (10^9)	$U_i = w_i D / e_i$ (10^9)
CommonCrawl	0,670	1,10	938	853
C4	0,150	1,06	210	198
GitHub	0,045	0,64	63	98
Wikipedia	0,045	2,45	63	26
Libros	0,045	2,23	63	28
ArXiv	0,025	1,06	35	33
StackExchange	0,020	1,03	28	27

Wikipedia y los libros, fuentes pequeñas y valiosas, se recorren más de dos veces; parte de GitHub no llega a verse. El tema 5 cuantifica cuánto vale un token repetido: hasta unas cuatro épocas, casi lo mismo que uno nuevo [18].

1.6 La escala de los datos

La cuadro 1.1 recoge la relación entre tokens de entrenamiento y parámetros de varios modelos con informe público. El cambio entre 2020 y 2023 se explica en los temas 4 y 5.

Cuadro 1.1: Parámetros, tokens de entrenamiento y tokens por parámetro.

Modelo (referencia)	N	D	D/N
GPT-3 [5]	$1{,}75 \cdot 10^{11}$	$3 \cdot 10^{11}$	1,7
Gopher [22]	$2{,}8 \cdot 10^{11}$	$3 \cdot 10^{11}$	1,1
Chinchilla [11]	$7 \cdot 10^{10}$	$1{,}4 \cdot 10^{12}$	20
LLaMA 7B [25]	$6{,}7 \cdot 10^{9}$	10^{12}	149
Llama 2 7B [26]	$6{,}74 \cdot 10^{9}$	$2 \cdot 10^{12}$	297
Llama 3 405B [7]	$4{,}05 \cdot 10^{11}$	$1{,}56 \cdot 10^{13}$	38,5

Lecturas recomendadas para este tema

- Stanford CS336 [10], práctica 4 «Data», §2.6 «Quality Rules», §2.7 «Quality Classifier» y §4 «Filter data for language modeling».
- Stanford CS324 [16], clase «Data».
- Wenzek *et al.* [28], CCNet: filtro por perplejidad con modelos de n-gramas.
- Penedo *et al.* [19], §3, y [20], §3 y §4: procesos completos sobre Common Crawl.
- Touvron *et al.* [25], §2.1 «Pre-training Data», tabla 1.

Ejercicios del tema 1

Ejercicio 1.1 ⋆ Un equipo entrena un clasificador de calidad con páginas citadas desde la Wikipedia en inglés como ejemplos positivos y lo aplica a un rastreo multilingüe. Indique dos tipos de texto que el filtro tenderá a descartar injustificadamente y una consecuencia para el modelo resultante. ¿Qué medida reduciría el problema?

Ejercicio 1.2 ⋆ Aplique los filtros de la definición 1.2 a los cuatro documentos siguientes y decida cuáles pasan.

Doc.	Palabras	Caracteres en palabras	Líneas	Líneas con «...»	Palabras con letra
A	40	200	4	0	38
B	1200	5640	60	24	1170
C	800	4160	50	6	720
D	3000	13 500	100	5	2250

Fuente: adaptado de Stanford CS336 [10], práctica 4, §2.6, problema `gopher_quality_filters` (se sustituye la implementación por el cálculo).

Ejercicio 1.3 ⋆⋆ Se entrena con $D = 10^{12}$ tokens una mezcla de cuatro fuentes: web ($8 \cdot 10^{11}$ tokens únicos, peso 0,60), código ($2 \cdot 10^{11}$, 0,25), libros ($5 \cdot 10^{10}$, 0,10) y ciencia (10^{10}, 0,05). Calcule las épocas de cada fuente. ¿Cuál preocupa, si se acepta un máximo de unas 4 épocas? Proponga un ajuste de pesos.

Ejercicio 1.4 ⋆⋆ Un modelo de unigramas de referencia asigna $q(\text{de}) = 0{,}4$, $q(\text{la}) = 0{,}3$, $q(\text{casa}) = 0{,}2$ y $q(\text{oferta}) = 0{,}1$. Calcule la perplejidad de los documentos A = «la casa de la», B = «oferta oferta oferta casa» y C = «de de de de». ¿Cuáles conserva un filtro con umbral $\text{PPL} \le 4$? Compruebe la proposición 1.5 para el documento A.

Ejercicio 1.5 ⋆⋆ Un proceso de filtrado procesa 2500 archivos WET de Common Crawl en 1,5 horas en una máquina. Supóngase que un volcado completo tiene 100 000 archivos WET. (a) ¿Cuánto tarda en filtrarse un volcado en esa máquina? (b) ¿Cuántas máquinas hacen falta para filtrarlo en 2 horas? (c) ¿Cuántas horas-máquina requieren los 96 volcados de FineWeb?

Fuente: adaptado de Stanford CS336 [10], práctica 4, §4, problema `filter_data`, apartado (b) (con tiempos supuestos).

Ejercicio 1.6 ⋆⋆⋆ Con la notación de la definición 1.10, demuestre que, para D fijo, la mezcla que minimiza el máximo de las épocas, $\max_i e_i$, es la proporcional, $w_i = U_i / \sum_j U_j$, y que es la única. Calcule ese mínimo para la mezcla de LLaMA del ejemplo 1.12 y compárelo con las épocas de Wikipedia elegidas por sus autores.

Tema 2

Deduplicación: MinHash y LSH

La web contiene muchas copias del mismo texto: páginas idénticas, plantillas, licencias que solo cambian en el año y el autor, artículos reproducidos con otro pie de página. Este tema estudia cómo detectarlas a escala de miles de millones de documentos. Los duplicados exactos se resuelven con funciones hash; los casi duplicados, con la similitud de Jaccard, las firmas MinHash y el *hashing* sensible a la localidad (LSH). Se sigue el capítulo 3 de Leskovec, Rajaraman y Ullman [15] (§3.1, §3.3 y §3.4), las clases «Locality-Sensitive Hashing I y II» del curso CS246 [14] y la sección 3 de la práctica de datos de CS336 [10]. MinHash procede de Broder [4].

2.1 Por qué deduplicar

Lee *et al.* [13] mostraron que eliminar duplicados de corpus estándar reduce la frecuencia con que el modelo reproduce texto literal del entrenamiento y permite alcanzar la misma calidad con menos pasos. Hay tres razones complementarias.

(i) *Cómputo.* Con un presupuesto $C \approx 6ND$ fijo (módulo 14), cada token repetido ocupa el lugar de uno nuevo.

(ii) *Memorización.* Lo que aparece cientos de veces se aprende literalmente y puede regurgitarse, incluidos datos personales o protegidos.

(iii) *Contaminación.* Si un documento de evaluación tiene copias en el corpus de entrenamiento, las métricas se inflan.

2.2 Duplicados exactos

Definición 2.1 (Huella). Sea $H\colon \Sigma^* \to \{0,1\}^\ell$ una función hash de ℓ bits (por ejemplo, SHA-1 o MD5). La *huella* de un documento normalizado x es $H(x)$. La deduplicación exacta conserva un documento por huella, con un recorrido y un diccionario de huellas: coste lineal en el tamaño del corpus.

Proposición 2.2 (Colisiones). *Supóngase que H asigna a cada uno de M documentos distintos un valor uniforme e independiente en $\{0,1\}^\ell$. El número esperado de pares de documentos distintos con la misma huella es $\binom{M}{2}2^{-\ell}$.*

Demostración. Para cada par $\{i,j\}$ sea I_{ij} la indicatriz de $H(x^{(i)}) = H(x^{(j)})$. Fijado el valor de $H(x^{(i)})$, la probabilidad de que $H(x^{(j)})$ coincida es $2^{-\ell}$, luego $\mathbb{E}[I_{ij}] = 2^{-\ell}$. Por la linealidad de la esperanza, el número esperado de colisiones es $\sum_{i<j} \mathbb{E}[I_{ij}] = \binom{M}{2}2^{-\ell}$. ∎

Con $M = 10^9$ documentos hay $\binom{M}{2} \approx 5 \cdot 10^{17}$ pares: una huella de 64 bits produce en promedio 0,027 colisiones, y una de 128 bits, $1{,}5 \cdot 10^{-21}$. La deduplicación exacta también puede hacerse por líneas: se cuentan las apariciones de cada línea en el corpus y se eliminan las repetidas, lo que borra cabeceras, menús y pies de página [10, §3.1]. Llama 3 elimina las líneas que aparecen más de seis veces en cada grupo de 30 millones de documentos [7, §3.1.1].

2.3 Shingles y similitud de Jaccard

Dos páginas que solo difieren en la fecha tienen huellas distintas. Para detectar casi duplicados se representa cada documento por un conjunto y se mide el solapamiento [15, §3.1].

Definición 2.3 (Shingles). Sea $k \geq 1$. El conjunto de *k-shingles* de un documento de palabras $(u_1, \ldots, u_T)$ es $S_k = \{(u_t, \ldots, u_{t+k-1}) : 1 \leq t \leq T - k + 1\}$, el conjunto de grupos de k palabras consecutivas.

Definición 2.4 (Similitud de Jaccard). Sean A y B conjuntos finitos, no ambos vacíos. Su *similitud de Jaccard* es

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \in [0, 1].$$

Vale 1 si y solo si $A = B$ y vale 0 si y solo si son disjuntos. La *distancia de Jaccard* $1 - J(A, B)$ es una distancia en el sentido métrico [15, cap. 3].

Ejemplo 2.5. Con 2-shingles, «el gato duerme en el sofá» da {el gato, gato duerme, duerme en, en el, el sofá} y «el gato duerme en la cama» da {el gato, gato duerme, duerme en, en la, la cama}. Comparten 3 shingles y la unión tiene $5 + 5 - 3 = 7$, de modo que $J = 3/7 \approx 0{,}429$.

Comparar todos los pares de $M = 10^9$ documentos exige unos $5 \cdot 10^{17}$ cálculos de J, inabordable. Las dos secciones siguientes resuelven, respectivamente, el coste de almacenar los conjuntos y el de compararlos todos.

2.4 Firmas MinHash

Definición 2.6 (MinHash). Sea Ω un universo finito que contiene todos los shingles y sea π una permutación de Ω, identificada con una biyección $\pi \colon \Omega \to \{1, \ldots, |\Omega|\}$. El *minhash* de un conjunto no vacío $S \subseteq \Omega$ es $h_\pi(S) = \min_{x \in S} \pi(x)$. Con n permutaciones $\pi_1, \ldots, \pi_n$, la *firma* de S es el vector $\operatorname{sig}(S) = \big(h_{\pi_1}(S), \ldots, h_{\pi_n}(S)\big)$.

Teorema 2.7 (Propiedad fundamental de MinHash). *Si π es una permutación uniforme de Ω y $A, B \subseteq \Omega$ son no vacíos,*

$$\mathbb{P}\big(h_\pi(A) = h_\pi(B)\big) = J(A, B).$$

Demostración. Sea x^* el elemento de $A \cup B$ con menor valor de π. Como π es uniforme, cada elemento de $A \cup B$ tiene la misma probabilidad, $1/|A \cup B|$, de ser el primero de $A \cup B$ en el orden de π, luego x^* es uniforme en $A \cup B$. Si $x^* \in A \cap B$, es el mínimo tanto de A como de B y los minhash coinciden. Si $x^* \in A \setminus B$, entonces $h_\pi(A) = \pi(x^*)$, mientras que $h_\pi(B) = \pi(y)$ para algún $y \in B$ distinto de x^*, y $\pi(y) \neq \pi(x^*)$ porque π es inyectiva; los minhash difieren. El caso $x^* \in B \setminus A$ es simétrico. Por tanto, los minhash coinciden si y solo si $x^* \in A \cap B$, suceso de probabilidad $|A \cap B|/|A \cup B|$. ∎

Corolario 2.8 (Estimador de Jaccard). *Sean $\pi_1, \dots, \pi_n$ permutaciones uniformes e independientes y sea $\hat{J}$ la fracción de coordenadas en que coinciden* $\operatorname{sig}(A)$ *y* $\operatorname{sig}(B)$*. Entonces $n\hat{J} \sim \operatorname{Bin}(n, J)$, con $J = J(A, B)$; en particular,*

$$\mathbb{E}[\hat{J}] = J \qquad y \qquad \operatorname{Var}(\hat{J}) = \frac{J(1-J)}{n}.$$

Demostración. Cada coordenada coincide con probabilidad J por el teorema 2.7, de forma independiente porque las permutaciones lo son. El número de coincidencias es una suma de n variables de Bernoulli independientes de parámetro J, es decir, una binomial (módulo 5). Dividiendo por n, $\mathbb{E}[\hat{J}] = nJ/n = J$ y $\operatorname{Var}(\hat{J}) = nJ(1-J)/n^2 = J(1-J)/n$. ∎

Con $n = 100$ funciones, la desviación típica es como mucho $\sqrt{0{,}25/100} = 0{,}05$. La firma sustituye un conjunto de miles de shingles por n enteros. En la práctica, las permutaciones se aproximan con funciones hash de una misma familia con semillas distintas [10, §3.2]: calcular $\min_{x \in S} h(x)$ requiere un único recorrido de S.

2.5 LSH por bandas

Definición 2.9 (LSH por bandas). Sea $n = br$. Se divide la firma en b bandas de r coordenadas consecutivas. Dos documentos son *candidatos* si sus firmas coinciden en todas las coordenadas de al menos una banda. En la práctica se asigna cada banda de cada documento a un cubo mediante una función hash, y solo se comparan los documentos que comparten algún cubo.

Proposición 2.10 (Curva en S). *Sean dos documentos con similitud de Jaccard s y firmas construidas con permutaciones independientes. La probabilidad de que sean candidatos es*

$$P(s) = 1 - \left(1 - s^r\right)^b.$$

La función P es creciente en $[0, 1]$, con $P(0) = 0$ y $P(1) = 1$; vale $1/2$ en $s_{1/2} = (1 - 2^{-1/b})^{1/r}$ y, si $r \geq 2$ y $b \geq 2$, tiene un único punto de inflexión en $(0, 1)$,

$$s^* = \left(\frac{r-1}{rb-1}\right)^{1/r}.$$

Demostración. Por el teorema 2.7 y la independencia, las r coordenadas de una banda coinciden con probabilidad s^r, y la banda falla con probabilidad $1 - s^r$. Las b bandas usan permutaciones distintas, luego fallan todas con probabilidad $(1 - s^r)^b$, y $P(s)$ es el complementario. La derivada $P'(s) = br\, s^{r-1}(1 - s^r)^{b-1}$ es positiva en $(0, 1)$. Despejando $P(s) = 1/2$ se obtiene $(1 - s^r)^b = 1/2$, es decir, $s^r = 1 - 2^{-1/b}$. Para la inflexión, se anula la derivada de $\ln P'(s) = \ln(br) + (r-1)\ln s + (b-1)\ln(1 - s^r)$:

$$\frac{r-1}{s} - \frac{(b-1)rs^{r-1}}{1-s^r} = 0 \iff (r-1)(1-s^r) = (b-1)rs^r \iff s^r = \frac{r-1}{rb-1}.$$

La función $(r-1)/s - (b-1)rs^{r-1}/(1-s^r)$ es estrictamente decreciente en $(0, 1)$, pasa de $+\infty$ a $-\infty$ y cambia de signo una sola vez, de modo que P' crece hasta s^* y decrece después. ∎

Cuando r es grande, $(r-1)/(rb-1) \to 1/b$, y se recupera la aproximación habitual del umbral, $s^* \approx (1/b)^{1/r}$ [15, §3.4]. Los pares con s muy por debajo del umbral casi nunca se comparan y los pares con s muy por encima casi siempre (figura 2.1).

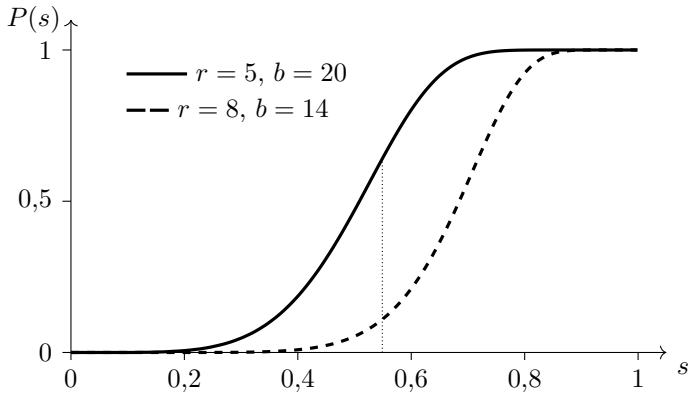


Figura 2.1: Curva en S de la proposición 2.10 para $(r, b) = (5, 20)$ (continua; la línea punteada marca $(1/b)^{1/r} \approx 0{,}549$) y para la configuración de FineWeb, $(r, b) = (8, 14)$ (discontinua).

Ejemplo 2.11 (FineWeb). FineWeb calcula 112 minhash sobre los 5-gramas de palabras de cada documento y los agrupa en $b = 14$ bandas de $r = 8$ [20, §3.4]. Para un par con $s = 0{,}75$, $s^8 = 0{,}1001$ y $P = 1 - 0{,}8999^{14} = 0{,}772$, el valor del orden del 77 % que declara el artículo. La inflexión está en $s^* = (7/111)^{1/8} = 0{,}708$. Los autores observaron además que deduplicar cada volcado por separado funcionaba mejor que deduplicar los 96 volcados conjuntamente, que eliminaba hasta el 90 % de los datos antiguos.

Lecturas recomendadas para este tema

- Leskovec, Rajaraman y Ullman [15], cap. 3 «Finding Similar Items», §3.1 a §3.4.
- Stanford CS246 [14], clases «Locality-Sensitive Hashing I» y «Locality-Sensitive Hashing II».
- Stanford CS336 [10], práctica 4, §3 «Deduplication» (problemas `exact_deduplication` y `minhash_deduplication`).
- Broder [4], artículo original de MinHash.
- Lee *et al.* [13], efecto de la deduplicación sobre la memorización.

Ejercicios del tema 2

Ejercicio 2.1 ⋆ ¿Por qué un corpus con muchos duplicados es peor que uno deduplicado del mismo tamaño en tokens? Dé dos razones y un caso límite que las ilustre.

Ejercicio 2.2 ⋆ Calcule la similitud de Jaccard de cada par de conjuntos entre $S_1 = \{a, b, c, d\}$, $S_2 = \{b, c, e\}$ y $S_3 = \{a, c, e, f\}$. ¿Qué par es el más parecido?

Fuente: adaptado de Leskovec, Rajaraman y Ullman [15], cap. 3, ejercicio 3.1.1 (conjuntos modificados).

Ejercicio 2.3 ⋆⋆ Calcule la similitud de Jaccard con 2-shingles entre «la luna brilla sobre el mar» y «la luna brilla sobre el río». Explique por qué el resultado debe ser menor que 4/5.

Ejercicio 2.4 ⋆⋆ El universo es $\{0, 1, 2, 3, 4, 5\}$, con $S_1 = \{0, 2, 5\}$, $S_2 = \{1, 2, 3\}$ y $S_3 = \{0, 3, 5\}$. Se usan $h_1(x) = (x + 1) \bmod 6$, $h_2(x) = (5x + 1) \bmod 6$ y $h_3(x) = (2x + 3) \bmod 6$.

(a) ¿Cuáles de ellas son permutaciones del universo? (b) Calcule la firma MinHash de cada conjunto. (c) Compare la similitud estimada con la real para cada par.

Fuente: adaptado de Leskovec, Rajaraman y Ullman [15], cap. 3, ejercicio 3.3.3 (conjuntos y funciones modificados).

Ejercicio 2.5 ⋆⋆ En un LSH con $r = 4$ filas y $b = 25$ bandas, calcule la probabilidad de que dos documentos sean candidatos si $s = 0{,}3$ y si $s = 0{,}85$. Calcule el umbral aproximado $(1/b)^{1/r}$ y el punto de inflexión exacto de la proposición 2.10.

Ejercicio 2.6 ⋆⋆ Para $(r, b) = (3, 10)$, $(6, 20)$ y $(5, 50)$: (a) calcule $P(s)$ en $s = 0{,}2$, $0{,}5$ y $0{,}8$; (b) calcule el valor exacto $s_{1/2}$ en que $P = 1/2$ y compárelo con la aproximación $(1/b)^{1/r}$.

Fuente: adaptado de Leskovec, Rajaraman y Ullman [15], cap. 3, ejercicios 3.4.1 y 3.4.2.

Ejercicio 2.7 ⋆⋆⋆ (a) Demuestre que, para todo $J \in [0, 1]$, la desviación típica del estimador del corolario 2.8 es a lo sumo $1/(2\sqrt{n})$. (b) Halle el menor n que garantiza una desviación típica no mayor que $0{,}05$ para cualquier par de documentos, y el menor que la garantiza para pares con $J = 0{,}8$. (c) Use la desigualdad de Chebyshev para acotar $\mathbb{P}(|\hat{J} - J| \geq 0{,}1)$ con $n = 100$.

Tema 3

Leyes de potencia y leyes de escalado de Kaplan

Kaplan *et al.* [12] observaron en 2020 que la pérdida de validación de un Transformer disminuye como una ley de potencia en cada uno de tres recursos, el número de parámetros N, el número de tokens D y el cómputo C, a lo largo de varios órdenes de magnitud. Este tema estudia primero las leyes de potencia como objeto matemático (por qué son las funciones invariantes por cambio de escala y cómo se ajustan) y después enuncia las leyes de Kaplan y su recomendación de reparto. Se sigue [12, §1.2, §4 y §6], la clase «Scaling laws» del curso CS324 [16] y la revisión de leyes de escalado de la práctica 3 de CS336 [9, §2].

3.1 Leyes de potencia

Definición 3.1 (Ley de potencia). Una función $f\colon (0,\infty)\to(0,\infty)$ es una *ley de potencia* si existen $c>0$ y $\alpha\in\mathbb{R}$ tales que $f(x)=c\,x^{-\alpha}$ para todo $x>0$. El número α es el *exponente*; si $\alpha>0$, f es decreciente.

La propiedad que distingue a las leyes de potencia es que no tienen escala característica: multiplicar x por un factor λ multiplica f por un factor que no depende del punto de partida.

Proposición 3.2 (Invariancia de escala). *Sea $f\colon(0,\infty)\to(0,\infty)$ continua. Existe una función g con $f(\lambda x)=g(\lambda)f(x)$ para todos $\lambda,x>0$ si y solo si f es una ley de potencia. En ese caso, $g(\lambda)=\lambda^{-\alpha}$.*

Demostración. Si $f(x)=cx^{-\alpha}$, entonces $f(\lambda x)=c\lambda^{-\alpha}x^{-\alpha}=\lambda^{-\alpha}f(x)$. Recíprocamente, con $x=1$ se obtiene $g(\lambda)=f(\lambda)/f(1)$, de modo que $F=f/f(1)$ cumple $F(\lambda x)=F(\lambda)F(x)$. Sea $\varphi(t)=\ln F(e^t)$, continua en $\mathbb{R}$. Entonces $\varphi(s+t)=\ln F(e^s e^t)=\varphi(s)+\varphi(t)$: es la ecuación funcional de Cauchy. Por inducción, $\varphi(mt)=m\varphi(t)$ para $m\in\mathbb{N}$; de ahí $\varphi(p/q)=(p/q)\varphi(1)$ para todo racional positivo, y $\varphi(0)=0$, $\varphi(-t)=-\varphi(t)$ extienden la igualdad a todos los racionales. Por continuidad y densidad de $\mathbb{Q}$, $\varphi(t)=-\alpha t$ con $\alpha=-\varphi(1)$. Deshaciendo el cambio, $F(x)=x^{-\alpha}$ y $f(x)=f(1)\,x^{-\alpha}$. ∎

Corolario 3.3. *Si $L=cN^{-\alpha}$, cada vez que N se multiplica por λ la pérdida se multiplica por $\lambda^{-\alpha}$, sea cual sea N. En particular, la mejora relativa por cada duplicación de N es constante, $1-2^{-\alpha}$.*

3.2 Ajuste en escala log-log

Proposición 3.4. *$L=cN^{-\alpha}$ si y solo si $\log L=\log c-\alpha\log N$. En el plano $(u,v)=(\log N,\log L)$, una ley de potencia es una recta de pendiente $-\alpha$, en cualquier base del loga-*

ritmo.

Demostración. Se aplica el logaritmo, que es inyectivo, y se usan $\log(xy) = \log x + \log y$ y $\log x^a = a \log x$. El cambio de base multiplica u y v por la misma constante, que no altera la pendiente. ■

En consecuencia, el exponente se estima por regresión lineal de v sobre u (módulo 8).

Definición 3.5 (Ajuste de una ley de potencia). Dados entrenamientos (N_j, L_j), $j = 1, \ldots, m$, con $u_j = \log N_j$ y $v_j = \log L_j$, el ajuste por mínimos cuadrados en escala log-log es la recta $v = b_0 + b_1 u$ con

$$b_1 = \frac{\sum_j (u_j - \bar{u})(v_j - \bar{v})}{\sum_j (u_j - \bar{u})^2}, \qquad b_0 = \bar{v} - b_1 \bar{u},$$

y la ley ajustada es $\hat{L}(N) = 10^{b_0} N^{b_1}$ (con $\log = \log_{10}$), de exponente $\hat{\alpha} = -b_1$.

Observación 3.6. El ajuste en escala logarítmica minimiza errores *relativos*, no absolutos, y da el mismo peso a cada orden de magnitud. Es lo adecuado cuando los entrenamientos están espaciados geométricamente, como es habitual. Extrapolar es otra cuestión: una recta ajustada en 10^7–10^9 parámetros y usada en 10^{11} supone que nada cambia en dos órdenes de magnitud sin observar.

3.3 Las leyes de Kaplan

Kaplan *et al.* entrenaron Transformers decoder-only sobre WebText2 y midieron la entropía cruzada de validación en nats por token sobre contextos de 1024 tokens [12, §2]. El número de parámetros N excluye los embeddings de vocabulario y de posición [12, §1.3].

Definición 3.7 (Leyes de Kaplan). Cuando el crecimiento de la pérdida está limitado por un único recurso, la pérdida sigue [12, ecuaciones (1.1)–(1.3)]

$$L(N) = \left(\frac{N_c}{N}\right)^{\alpha_N}, \qquad L(D) = \left(\frac{D_c}{D}\right)^{\alpha_D}, \qquad L(C_{\min}) = \left(\frac{C_c}{C_{\min}}\right)^{\alpha_C},$$

con los valores ajustados de la cuadro 3.1. La ley en N supone datos suficientes y entrenamiento hasta la convergencia; la ley en D, un modelo grande con parada temprana; la ley en $C_{\min}$, el mejor reparto posible del cómputo.

Cuadro 3.1: Constantes de las leyes de Kaplan *et al.* [12, §1.2]. Un PF-día son $10^{15} \cdot 86\,400 = 8{,}64 \cdot 10^{19}$ FLOP.

Ley	Exponente	Constante
$L(N)$	$\alpha_N \approx 0{,}076$	$N_c \approx 8{,}8 \cdot 10^{13}$ parámetros
$L(D)$	$\alpha_D \approx 0{,}095$	$D_c \approx 5{,}4 \cdot 10^{13}$ tokens
$L(C_{\min})$	$\alpha_C \approx 0{,}050$	$C_c \approx 3{,}1 \cdot 10^{8}$ PF-días

Ejemplo 3.8. Con $N = 10^9$, $L = (8{,}8 \cdot 10^4)^{0{,}076} = 2{,}376$ nats. Por el corolario 3.3, duplicar N multiplica la pérdida por $2^{-0{,}076} = 0{,}9487$ (un 5 % menos) y multiplicarlo por diez, por $10^{-0{,}076} = 0{,}8395$: con $N = 10^{10}$, $L = 1{,}994$ nats.

Las constantes dependen del tokenizador y de la distribución de los datos: no se trasladan a otro corpus. Los exponentes son más estables, y son lo que interesa para decidir cómo crecer.

3.4 Ley conjunta y sobreajuste

Cuando ambos recursos son finitos, Kaplan *et al.* proponen [12, ecuación (1.5) y §4]

$$L(N, D) = \left[\left(\frac{N_c}{N}\right)^{\alpha_N/\alpha_D} + \frac{D_c}{D}\right]^{\alpha_D}. \tag{3.1}$$

Proposición 3.9. *La función* (3.1) *es decreciente en N y en D, y sus límites son las leyes de un solo recurso:*

$$\lim_{D\to\infty} L(N, D) = L(N), \qquad \lim_{N\to\infty} L(N, D) = L(D).$$

Demostración. Ambos sumandos del corchete son decrecientes en su variable y el exponente α_D es positivo. Cuando $D \to \infty$, $D_c/D \to 0$ y, por continuidad de $y \mapsto y^{\alpha_D}$, $L \to \left[(N_c/N)^{\alpha_N/\alpha_D}\right]^{\alpha_D} = (N_c/N)^{\alpha_N}$. Cuando $N \to \infty$, el primer sumando tiende a 0 y $L \to (D_c/D)^{\alpha_D}$. ∎

La forma (3.1) permite cuantificar el sobreajuste: la penalización relativa por datos finitos depende de N y D solo a través de $N^{\alpha_N/\alpha_D}/D$ (ejercicio 3.5). De ahí la regla empírica de Kaplan *et al.* para que el sobreajuste quede dentro de la variación entre semillas, $D \gtrsim 5 \cdot 10^3\, N^{0{,}74}$ [12, ecuación (4.4)]. Con $N = 10^9$, la regla pide $D \gtrsim 2{,}3 \cdot 10^{10}$ tokens.

3.5 El reparto de Kaplan

El cómputo de entrenamiento es $C \approx 6ND$ FLOP (módulo 14, tema 6; [12, §2.1]). Kaplan *et al.* estudian cómo repartir un presupuesto creciente y concluyen que el tamaño óptimo crece como [12, ecuación (6.1)]

$$N_{\text{opt}} \propto C^{0{,}73},$$

y los datos, como $D \propto C^{0{,}27}$ [12, §1.1]. Con diez veces más cómputo, el modelo debería crecer $10^{0{,}73} = 5{,}4$ veces y los datos solo $10^{0{,}27} = 1{,}9$ veces. GPT-3 siguió esa pauta: $N = 1{,}75 \cdot 10^{11}$ parámetros y $D = 3 \cdot 10^{11}$ tokens [5], es decir, $C \approx 6 \cdot 1{,}75 \cdot 10^{11} \cdot 3 \cdot 10^{11} = 3{,}15 \cdot 10^{23}$ FLOP, unos 3650 PF-días, con menos de dos tokens por parámetro. El tema 4 muestra que esta recomendación no se sostiene.

Observación 3.10 (Hace falta un suelo). Una ley de potencia pura tiende a 0 cuando el recurso crece. Pero la pérdida de un modelo es una entropía cruzada $H(p, q)$, y por la desigualdad de Gibbs (módulo 1, tema 5) nunca baja de la entropía $H(p)$ del propio texto. Toda ley realista debe incluir, por tanto, un término constante irreducible; es lo que hace la ley de Chinchilla del tema 4.

Lecturas recomendadas para este tema

- Kaplan *et al.* [12], §1.2 «Summary of Scaling Laws», §4 «Charting the Infinite Data Limit and Overfitting» y §6 «Optimal Allocation of the Compute Budget».
- Stanford CS324 [16], clase «Scaling laws».

– Stanford CS336 [9], práctica 3 «Scaling», §2 «Scaling Laws Review».

– Para el ajuste por mínimos cuadrados, el tema correspondiente del módulo 8.

Ejercicios del tema 3

Ejercicio 3.1 ⋆ Explique por qué una ley de potencia $L = kN^{-\alpha}$ es una recta en escala log-log y qué representa su pendiente. Con $\alpha = 0{,}076$ y logaritmos decimales, ¿cuánto baja $\log_{10} L$ al multiplicar N por 10?

Ejercicio 3.2 ⋆⋆ Calcule el cómputo de entrenamiento de un modelo de $1{,}3 \cdot 10^9$ parámetros con $2{,}6 \cdot 10^{10}$ tokens, en FLOP y en PF-días. ¿Cuántos tokens por parámetro son?

Ejercicio 3.3 ⋆⋆ Con la ley $L(D) = (5{,}4 \cdot 10^{13}/D)^{0{,}095}$, calcule L para $D = 10^9$ y $D = 10^{11}$. ¿Por qué factor se multiplica L cada vez que D se multiplica por 10?

Ejercicio 3.4 ⋆⋆ Se entrenan tres modelos con la forma de la práctica de CS336, cuyo número de parámetros sin embeddings se estima como $N = 12\, n_{\text{layer}} d_{\text{model}}^2$, y se obtienen las pérdidas finales siguientes:

n_{layer}	d_{model}	L (nats)
4	256	4,20
8	512	3,62
16	1024	3,12

(a) Calcule N para cada modelo. (b) Ajuste $\log_{10} L = b_0 + b_1 \log_{10} N$ por mínimos cuadrados (definición 3.5). (c) Prediga la pérdida de un modelo con $n_{\text{layer}} = 32$ y $d_{\text{model}} = 2048$ y comente la fiabilidad de la predicción.

Fuente: adaptado de Stanford CS336 [9], práctica 3, §3.3, problema `scaling_laws` (datos sintéticos en lugar de la API de entrenamiento).

Ejercicio 3.5 ⋆⋆⋆ Sea $L(N, D)$ la ley (3.1). (a) Demuestre que

$$\frac{L(N, D)}{L(N)} = \Big(1 + \frac{N^{\alpha_N/\alpha_D}}{N_c^{\alpha_N/\alpha_D}} \cdot \frac{D_c}{D}\Big)^{\alpha_D}.$$

(b) Deduzca que, para mantener constante la penalización relativa por datos finitos al crecer el modelo, D debe crecer como N^{α_N/α_D}. (c) Calcule el exponente con $\alpha_D = 0{,}095$ y con el ajuste conjunto de Kaplan *et al.*, que usa $\alpha_D \approx 0{,}103$, y compárelo con el de la ecuación (4.4).

Ejercicio 3.6 ⋆⋆⋆ Demuestre que el exponente estimado $\hat{\alpha}$ de la definición 3.5 no cambia si (a) se usan logaritmos en otra base, (b) se mide N en otras unidades, $N' = \kappa N$ con $\kappa > 0$, o (c) se multiplican todas las pérdidas por una constante, por ejemplo al pasar de nats a bits. ¿Qué parámetro del ajuste sí cambia en cada caso?

Tema 4

El reparto óptimo del cómputo: Chinchilla

Hoffmann *et al.* [11] entrenaron más de 400 modelos, de menos de 70 millones a más de 16 000 millones de parámetros, con entre unos 5 000 millones y más de 400 000 millones de tokens, y concluyeron que, a cómputo fijo, el número de parámetros y el de tokens deben crecer aproximadamente al mismo ritmo. Este tema plantea el reparto como un problema de optimización con restricciones, lo resuelve en forma cerrada con multiplicadores de Lagrange para la ley paramétrica de Hoffmann *et al.* y extrae sus consecuencias. Se sigue [11, §3.3, ecuaciones (2) y (4), y apéndice D.2], la revisión de la práctica 3 de CS336 [9, §2] y, para la forma convexa del problema, la programación geométrica de Boyd y Vandenberghe [3, §4.5]. Los métodos empíricos con que se estiman las constantes se estudian en el tema 5.

4.1 El problema del reparto

Definición 4.1 (Reparto óptimo del cómputo). Sea $L(N, D)$ la pérdida esperada de un modelo de N parámetros entrenado con D tokens y sea $C > 0$ un presupuesto de FLOP. El *reparto óptimo* es la solución de

$$\min_{N,D>0} \; L(N, D) \qquad \text{sujeto a} \qquad 6ND = C.$$

Sus componentes se denotan $N_{\text{opt}}(C)$ y $D_{\text{opt}}(C)$. La *frontera eficiente* es la curva $C \mapsto (N_{\text{opt}}(C), D_{\text{opt}}(C))$.

4.2 La ley paramétrica de Chinchilla

Definición 4.2 (Ley de Chinchilla). La ley paramétrica de Hoffmann *et al.* [11, ecuación (2)] es

$$L(N, D) = E + \frac{A}{N^{\alpha}} + \frac{B}{D^{\beta}}, \qquad A, B, \alpha, \beta, E > 0.$$

El ajuste del enfoque 3 da [11, apéndice D.2]

$$E = 1{,}69, \qquad A = 406{,}4, \qquad B = 410{,}7, \qquad \alpha = 0{,}34, \qquad \beta = 0{,}28.$$

Los tres términos tienen una interpretación directa [11, §3.3]. E es la pérdida de un predictor ideal: la entropía del texto, que ningún modelo puede rebajar (desigualdad de Gibbs). A/N^{α} es el exceso de un modelo de tamaño finito entrenado con datos ilimitados. B/D^{β} es el exceso por entrenar con un número finito de tokens, es decir, de pasos de optimización. A diferencia de las leyes de Kaplan, la ley tiene un suelo: con $N = D = 10^{30}$, los dos términos de error valen $2{,}6 \cdot 10^{-8}$ y $1{,}6 \cdot 10^{-6}$, y $L \approx E$.

4.3 La solución en forma cerrada

Teorema 4.3 (Frontera eficiente de Chinchilla). *Sea L como en la definición 4.2. Para cada $C > 0$, el problema de la definición 4.1 tiene una única solución,*

$$N_{\text{opt}}(C) = G\Big(\frac{C}{6}\Big)^{a}, \qquad D_{\text{opt}}(C) = G^{-1}\Big(\frac{C}{6}\Big)^{b},$$

con

$$G = \Big(\frac{\alpha A}{\beta B}\Big)^{\frac{1}{\alpha+\beta}}, \qquad a = \frac{\beta}{\alpha+\beta}, \qquad b = \frac{\alpha}{\alpha+\beta}.$$

Demostración. Condiciones necesarias. El término E no influye en el óptimo. La lagrangiana es $\Lambda(N, D, \lambda) = AN^{-\alpha} + BD^{-\beta} + \lambda(6ND - C)$, y en un óptimo interior se anulan sus derivadas (módulo 4):

$$\frac{\partial \Lambda}{\partial N} = -\alpha A N^{-\alpha-1} + 6\lambda D = 0, \qquad \frac{\partial \Lambda}{\partial D} = -\beta B D^{-\beta-1} + 6\lambda N = 0.$$

Multiplicando la primera por N y la segunda por D,

$$\alpha A N^{-\alpha} = 6\lambda N D = \beta B D^{-\beta}. \tag{4.1}$$

Sustituyendo $D = c/N$, con $c = C/6$, en la igualdad de los extremos: $\alpha A N^{-\alpha} = \beta B c^{-\beta} N^{\beta}$, luego $N^{\alpha+\beta} = \frac{\alpha A}{\beta B} c^{\beta}$ y $N = G c^{a}$. Entonces $D = c/N = G^{-1} c^{1-a} = G^{-1} c^{b}$, porque $1 - a = \alpha/(\alpha+\beta) = b$.

Unicidad y carácter de mínimo. Sobre la restricción, con $u = \ln N$, la función objetivo es

$$\phi(u) = A e^{-\alpha u} + B c^{-\beta} e^{\beta u},$$

suma de dos exponenciales estrictamente convexas; ϕ es estrictamente convexa en $\mathbb{R}$ y tiende a $+\infty$ cuando $u \to \pm\infty$. Tiene, por tanto, un único mínimo global, que es el único punto crítico, y coincide con el hallado. ∎

Corolario 4.4 (Equilibrio de los términos de error). *En el óptimo, $\dfrac{A/N_{\text{opt}}^{\alpha}}{B/D_{\text{opt}}^{\beta}} = \dfrac{\beta}{\alpha}$. Con los valores de Chinchilla, el término de datos es $\alpha/\beta = 1{,}214$ veces el de parámetros.*

Demostración. Es la igualdad de los extremos de (4.1), dividida por $\alpha B D_{\text{opt}}^{-\beta}$. ∎

Corolario 4.5 (Exponentes del reparto). *$N_{\text{opt}} \propto C^{a}$ y $D_{\text{opt}} \propto C^{b}$, con $a + b = 1$. Con los valores de Chinchilla, $a = 0{,}28/0{,}62 = 0{,}452$, $b = 0{,}548$ y $G = 1{,}345$.*

Demostración. Se lee en el teorema 4.3; $a+b = (\beta+\alpha)/(\alpha+\beta) = 1$ refleja que $N_{\text{opt}} D_{\text{opt}} = C/6$. Los valores numéricos: $\alpha A = 138{,}2$, $\beta B = 115{,}0$, $G = (1{,}202)^{1/0{,}62} = 1{,}345$. ∎

El artículo da $a \approx 0{,}46$ para este enfoque y $a \approx 0{,}50$ y $0{,}49$ para los otros dos [11, tabla 2], frente al $0{,}73$ de Kaplan *et al.*: el modelo y los datos crecen, aproximadamente, como $\sqrt{C}$.

Corolario 4.6 (Pérdida en la frontera). *Sea $\gamma = \alpha\beta/(\alpha+\beta)$. Existe $K > 0$ tal que $L(N_{\text{opt}}(C), D_{\text{opt}}(C)) - E = K\, C^{-\gamma}$. Con los valores de Chinchilla, $\gamma = 0{,}1535$.*

Demostración. Con $c = C/6$, $A N_{\text{opt}}^{-\alpha} = A G^{-\alpha} c^{-\alpha a}$ y $B D_{\text{opt}}^{-\beta} = B G^{\beta} c^{-\beta b}$. Los dos exponentes son iguales: $\alpha a = \alpha\beta/(\alpha+\beta) = \beta b = \gamma$. La suma es $(A G^{-\alpha} + B G^{\beta})\, 6^{\gamma} C^{-\gamma}$. ∎

El corolario 4.6 reconcilia las dos líneas de trabajo: el exceso sobre la entropía irreducible decae como una ley de potencia en el cómputo, como observaron Kaplan *et al.*, aunque el reparto que la produce es otro.

4.4 Gopher frente a Chinchilla

Ejemplo 4.7 (El presupuesto de Gopher). Hoffmann *et al.* toman como referencia el presupuesto de Gopher, $C = 5{,}76 \cdot 10^{23}$ FLOP [11, tabla 3]. Con la aproximación $6ND$, Gopher gasta $5{,}04 \cdot 10^{23}$ y Chinchilla $5{,}88 \cdot 10^{23}$: ambos están cerca del mismo presupuesto. La ley de la definición 4.2 da:

Configuración	N	D	$L(N, D)$
Gopher	$2{,}8 \cdot 10^{11}$	$3 \cdot 10^{11}$	1,993
Chinchilla	$7 \cdot 10^{10}$	$1{,}4 \cdot 10^{12}$	1,937
Óptimo del teorema 4.3	$3{,}22 \cdot 10^{10}$	$2{,}98 \cdot 10^{12}$	1,931

Un modelo cuatro veces menor, con casi cinco veces más datos, mejora a Gopher en 0,056 nats con el mismo cómputo. El óptimo del ajuste es aún menor, pero solo gana 0,006 nats más: el mínimo es plano.

4.5 La regla de los 20 tokens

Los enfoques 1 y 2 de Hoffmann *et al.* conducen en la práctica a unos 20 tokens por parámetro: la tabla 3 de [11] asigna $20{,}2 \cdot 10^9$ tokens a un modelo de 10^9 parámetros y $205{,}1 \cdot 10^9$ a uno de 10^{10}.

Proposición 4.8 (Regla de proporción fija). *Si se impone $D = \rho N$ con $\rho > 0$ fijo, la restricción $6ND = C$ da $N = \sqrt{C/(6\rho)}$ y $D = \rho N$. Con $\rho = 20$, $N = \sqrt{C/120}$.*

Demostración. $C = 6N \cdot \rho N = 6\rho N^2$; se despeja $N > 0$. ∎

Por ejemplo, $C = 1{,}2 \cdot 10^{20}$ da $N = 10^9$ y $D = 2 \cdot 10^{10}$, de acuerdo con la tabla 3 de [11]. El ajuste del enfoque 3 da, en cambio, unos 63 tokens por parámetro a 10^{22} FLOP (ejercicio 4.3); la discrepancia entre los enfoques se discute en el tema 5.

4.6 El mínimo es plano

Proposición 4.9 (Coste de desviarse del óptimo). *Sobre la restricción $6ND = C$, sea $\delta = \ln(N/N_{\text{opt}})$ la desviación logarítmica del tamaño, y sean $T_N = AN_{\text{opt}}^{-\alpha}$ y $T_D = BD_{\text{opt}}^{-\beta}$ los términos de error en el óptimo. El exceso de pérdida es*

$$\Delta(\delta) = T_N\big(e^{-\alpha\delta} - 1\big) + T_D\big(e^{\beta\delta} - 1\big) = \tfrac{1}{2}\big(\alpha^2 T_N + \beta^2 T_D\big)\delta^2 + O(\delta^3).$$

Demostración. Si $N = N_{\text{opt}}e^{\delta}$, la restricción obliga a $D = D_{\text{opt}}e^{-\delta}$, y los términos de error pasan a $T_N e^{-\alpha\delta}$ y $T_D e^{\beta\delta}$; restando los valores en el óptimo se obtiene la expresión exacta. Desarrollando $e^x = 1 + x + x^2/2 + O(x^3)$, el término lineal es $(-\alpha T_N + \beta T_D)\delta$, que se anula por el corolario 4.4 ($\alpha T_N = \beta T_D$), y queda el cuadrático. ∎

Ejemplo 4.10. Con $C = 10^{22}$, $T_N = 0{,}2026$ y $T_D = 0{,}2460$ (ejercicio 4.3), luego $\frac{1}{2}(\alpha^2 T_N + \beta^2 T_D) = \frac{1}{2}(0{,}02342 + 0{,}01929) = 0{,}02135$. Un modelo el doble de grande que el óptimo ($\delta = \ln 2$) pierde, según la aproximación, $0{,}02135 \cdot 0{,}4805 = 0{,}0103$ nats; el valor exacto es 0,0102. Equivocarse en un factor 2 en el tamaño cuesta un 0,5 % de la pérdida.

4.7 Forma convexa del problema

El problema de la definición 4.1 con la ley de Chinchilla es un *programa geométrico* [3, §4.5]: el objetivo $AN^{-\alpha} + BD^{-\beta}$ es un posinomio (suma de monomios con coeficientes positivos y exponentes reales) y la restricción $6ND \le C$ es una cota sobre un monomio. Con el cambio de variables $u = \ln N$, $v = \ln D$, el objetivo pasa a ser $Ae^{-\alpha u} + Be^{-\beta v}$, convexo, y la restricción, $u + v \le \ln(C/6)$, afín. El problema transformado es convexo, y sus condiciones de Karush–Kuhn–Tucker son suficientes para el óptimo global (ejercicio 4.7).

Lecturas recomendadas para este tema

- Hoffmann *et al.* [11], §3 «Estimating the optimal parameter/training tokens allocation», en particular §3.3 «Fitting a parametric loss function», tablas 2 y 3, y apéndice D.
- Stanford CS336 [9], práctica 3, §2 «Scaling Laws Review».
- Stanford CS324 [16], clase «Scaling laws».
- Boyd y Vandenberghe [3], §4.5 «Geometric programming».

Ejercicios del tema 4

Ejercicio 4.1 ⋆ Justifique si son verdaderas o falsas: (a) Kaplan *et al.* recomendaban hacer crecer N más deprisa que D; (b) Chinchilla demostró que más parámetros siempre es mejor; (c) el término E de la ley de Chinchilla puede reducirse con más datos.

Ejercicio 4.2 ⋆⋆ Con la regla $D = 20N$, ¿qué N y qué D corresponden a $C = 10^{23}$ FLOP? Compruebe el resultado.

Ejercicio 4.3 ⋆⋆ Con la ley de Chinchilla y $C = 10^{22}$ FLOP, calcule N_{opt}, D_{opt}, $D_{\text{opt}}/N_{\text{opt}}$ y la pérdida. Compare con la regla de los 20 tokens.

Ejercicio 4.4 ⋆⋆ Con los datos del ejemplo 4.10, calcule el exceso de pérdida exacto y el aproximado de la proposición 4.9 para un modelo cuatro veces mayor y para uno cuatro veces menor que el óptimo. ¿Por qué no son iguales los dos excesos exactos?

Ejercicio 4.5 ⋆⋆⋆ Demuestre que, si el cómputo se multiplica por 4, N_{opt} se multiplica por $4^{\beta/(\alpha+\beta)}$ y D_{opt} por $4^{\alpha/(\alpha+\beta)}$. Calcule ambos factores con los valores de Chinchilla y compruebe su producto.

Ejercicio 4.6 ⋆⋆⋆ Obtenga explícitamente la constante K del corolario 4.6 en función de A, B, α, β y G, y calcúlela con los valores de Chinchilla. Calcule la reducción del exceso de pérdida al pasar de 10^{22} a 10^{24} FLOP y compruébela calculando directamente el óptimo en 10^{24}.

Ejercicio 4.7 ⋆⋆⋆ Considere el problema $\min AN^{-\alpha}+BD^{-\beta}$ sujeto a $6ND \le C$, con $N, D > 0$. (a) Con $u = \ln N$ y $v = \ln D$, escriba el problema transformado y demuestre que es convexo. (b) Demuestre que en el óptimo la restricción es activa. (c) Escriba las condiciones de Karush–Kuhn–Tucker, compruebe que el punto del teorema 4.3 las satisface con un multiplicador $\mu > 0$ y demuestre que $\mu C = \alpha T_N$, con T_N como en la proposición 4.9. (d) Interprete μ como la derivada de la pérdida óptima respecto de $\ln C$ y compruébelo con el corolario 4.6 y los datos del ejercicio 4.3.

Fuente: adaptado de Boyd y Vandenberghe [3], §4.5 (forma convexa de un programa geométrico) y §5.5 (condiciones de optimalidad).

Tema 5

Estimación empírica, inferencia y datos limitados

El tema 4 supuso conocida la ley $L(N, D)$. Este tema estudia cómo se estima a partir de entrenamientos pequeños, por qué Kaplan *et al.* y Hoffmann *et al.* llegaron a conclusiones distintas y cómo cambia el reparto cuando el objetivo no es solo el cómputo de entrenamiento: cuando el modelo va a servirse durante mucho tiempo y cuando los datos únicos escasean. Se sigue [11, §3.1–3.3 y tabla 2], la práctica 3 de CS336 [9, §2.1], Muennighoff *et al.* [18, §3.1 y apéndice A], Sardana *et al.* [23] y la réplica de Besiroglu *et al.* [2].

5.1 Tres métodos de estimación

Hoffmann *et al.* estimaron la frontera eficiente por tres caminos independientes.

Definición 5.1 (Enfoque 1: envolvente de las curvas de entrenamiento). Se fijan varios tamaños de modelo y, para cada uno, se entrenan varias longitudes de entrenamiento con un calendario de tasa de aprendizaje ajustado a cada longitud [11, §3.1]. Cada curva de pérdida, reexpresada en función de los FLOP consumidos, $6N \cdot$ (tokens vistos), aporta puntos (C, L). Para cada C se toma el entrenamiento de menor pérdida, y los pares $(C, N_{\text{opt}}(C))$ resultantes se ajustan con una ley de potencia.

Definición 5.2 (Enfoque 2: perfiles IsoFLOP). Se fijan varios presupuestos C_i y, para cada uno, se entrenan modelos de distintos tamaños N_{ij} con $D_{ij} = C_i/(6N_{ij})$ tokens. La curva $N \mapsto L$ a C_i fijo es el *perfil IsoFLOP* de C_i. Hoffmann *et al.* ajustan una parábola en $\log N$ a cada perfil y toman su vértice como $N_{\text{opt}}(C_i)$ [11, §3.2]; la práctica de CS336 recomienda tomar sin más el entrenamiento de menor pérdida [9, §2.1]. Después se ajustan $N_{\text{opt}} \propto C^a$ y $D_{\text{opt}} \propto C^b$ por mínimos cuadrados en escala log-log.

La forma en U de cada perfil tiene una explicación sencilla [9, §2.1]: un modelo muy pequeño no puede ajustar los datos por mucho que se entrene, y uno muy grande agota el presupuesto en pocos pasos de optimización. La figura 5.1 muestra el esquema.

Proposición 5.3 (Vértice de un perfil). *Sean tres entrenamientos de un perfil IsoFLOP con $x_j = \log_{10} N_j$ equiespaciados, $x_1 = x_2 - h$, $x_3 = x_2 + h$, y pérdidas L_1, L_2, L_3 con $\Delta_2 = L_1 - 2L_2 + L_3 > 0$. La parábola que pasa por los tres puntos tiene su vértice en*

$$x^* = x_2 - \frac{h\,(L_3 - L_1)}{2\Delta_2}, \qquad L^* = L_2 - \frac{(L_3 - L_1)^2}{8\Delta_2}.$$

Demostración. Con $t = (x - x_2)/h$, se busca $p(t) = L_2 + \beta_1 t + \beta_2 t^2$ con $p(-1) = L_1$ y $p(1) = L_3$. Sumando y restando ambas condiciones, $\beta_2 = \Delta_2/2$ y $\beta_1 = (L_3 - L_1)/2$. Como

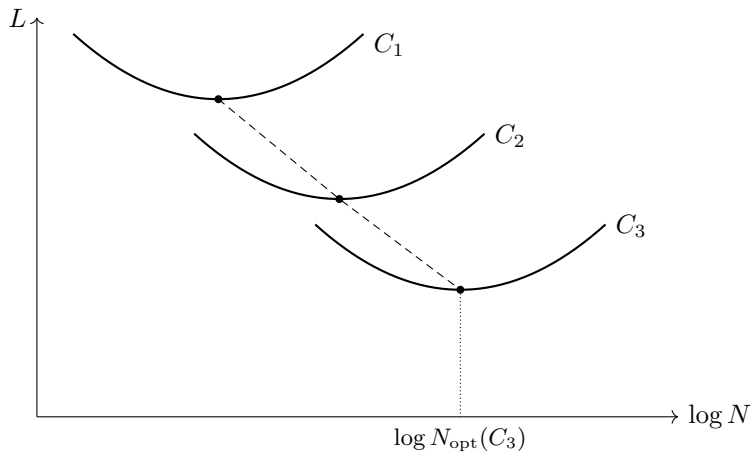


Figura 5.1: Perfiles IsoFLOP esquemáticos para tres presupuestos $C_1 < C_2 < C_3$. Los vértices (puntos) dan $N_{\text{opt}}(C_i)$; su ajuste en escala log-log da el exponente a.

$\beta_2 > 0$, el mínimo está en $t^* = -\beta_1/(2\beta_2) = -(L_3 - L_1)/(2\Delta_2)$, y $p(t^*) = L_2 - \beta_1^2/(4\beta_2) = L_2 - (L_3 - L_1)^2/(8\Delta_2)$. Se deshace el cambio, $x^* = x_2 + ht^*$. ■

Definición 5.4 (Enfoque 3: ajuste paramétrico). Se ajustan directamente las cinco constantes de la definición 4.2 a todos los entrenamientos (N_j, D_j, L_j) minimizando

$$\sum_j \text{Huber}_\delta\Big(\ln \hat{L}(N_j, D_j) - \ln L_j\Big), \qquad \text{Huber}_\delta(z) = \begin{cases} z^2/2, & |z| \le \delta, \\ \delta(|z| - \delta/2), & |z| > \delta, \end{cases}$$

con $\delta = 10^{-3}$, mediante L-BFGS desde una rejilla de puntos iniciales [11, §3.3]. La pérdida de Huber crece linealmente para residuos grandes, lo que reduce el peso de los entrenamientos anómalos.

Cuadro 5.1: Exponentes de la frontera eficiente, $N_{\text{opt}} \propto C^a$ y $D_{\text{opt}} \propto C^b$, según [11, tabla 2].

Método	a	b
Enfoque 1: envolvente de las curvas	0,50	0,50
Enfoque 2: perfiles IsoFLOP	0,49	0,51
Enfoque 3: ajuste paramétrico	0,46	0,54
Kaplan *et al.* [12]	0,73	0,27

5.2 Por qué difieren Kaplan y Chinchilla

Hoffmann *et al.* atribuyen la mayor parte de la discrepancia a un detalle experimental: Kaplan *et al.* usaron el mismo número de tokens y el mismo calendario de tasa de aprendizaje para todos los modelos [11, §2 y apéndice B]. Con un decaimiento coseno (módulo 7) pensado para un entrenamiento largo, las pérdidas intermedias de un entrenamiento corto se miden con la tasa de aprendizaje todavía alta, y son peores de lo que serían con un calendario ajustado a esa longitud. Eso penaliza a los entrenamientos con pocos tokens de forma desigual y sesga la conclusión hacia modelos grandes con pocos datos.

Observación 5.5 (Las constantes son frágiles). Besiroglu *et al.* [2] reconstruyeron los datos del enfoque 3 a partir de las figuras del artículo y concluyeron que las constantes publicadas no ajustan bien esos datos, que los intervalos de confianza declarados son demasiado estrechos y que un nuevo ajuste da resultados compatibles con los enfoques 1 y 2. La conclusión cualitativa, $a \approx b \approx 1/2$, es robusta; las constantes exactas, no. Por eso los ejemplos numéricos de estos apuntes deben leerse como ilustración del método.

5.3 El coste de la inferencia

El reparto de Chinchilla minimiza el cómputo de *entrenamiento*. Pero un modelo se entrena una vez y se usa muchas veces, y cada token generado cuesta unos $2N$ FLOP (módulo 14, tema 6).

Definición 5.6 (Coste total). Si un modelo de N parámetros se entrena con D tokens y se usa para procesar T_{inf} tokens de inferencia, su coste total es

$$C_{\text{tot}} = 6ND + 2NT_{\text{inf}}.$$

Proposición 5.7 (Amortización del sobreentrenamiento). *Sean dos configuraciones con la misma pérdida, (N_1, D_1) y (N_2, D_2), con $N_2 < N_1$ y $6N_2D_2 > 6N_1D_1$. La configuración pequeña tiene menor coste total si y solo si*

$$T_{\text{inf}} > T^* = \frac{6(N_2D_2 - N_1D_1)}{2(N_1 - N_2)}.$$

Demostración. $6N_2D_2 + 2N_2T_{\text{inf}} < 6N_1D_1 + 2N_1T_{\text{inf}}$ equivale a $2(N_1 - N_2)T_{\text{inf}} > 6(N_2D_2 - N_1D_1)$, y se divide por $2(N_1 - N_2) > 0$. ∎

Con la ley de Chinchilla, el sobrecoste relativo de entrenamiento de reducir el modelo en un factor fijo no depende del presupuesto.

Proposición 5.8 (Sobrecoste de reducir el modelo). *Sea $(N_{\text{opt}}, D_{\text{opt}})$ el óptimo del teorema 4.3 para el presupuesto C y sea $0 < \kappa < 1$ con $(\kappa^{-\alpha} - 1)\beta/\alpha < 1$. El modelo de κN_{opt} parámetros alcanza la pérdida óptima con $D_2 = D_{\text{opt}}\big(1 - (\kappa^{-\alpha} - 1)\beta/\alpha\big)^{-1/\beta}$ tokens, y su cómputo de entrenamiento es*

$$\frac{C_2}{C} = \kappa\Big(1 - \frac{\beta}{\alpha}\big(\kappa^{-\alpha} - 1\big)\Big)^{-1/\beta},$$

independiente de C. Si $\kappa \le (1 + \alpha/\beta)^{-1/\alpha}$, ningún número de tokens iguala la pérdida óptima.

Demostración. Sean T_N y T_D los términos de error en el óptimo; por el corolario 4.4, $T_N = (\beta/\alpha)T_D$. Con κN_{opt} parámetros, el término de parámetros pasa a $\kappa^{-\alpha}T_N$, y para conservar la pérdida el de datos debe valer $T_D' = T_D - (\kappa^{-\alpha} - 1)T_N = T_D\big(1 - (\kappa^{-\alpha} - 1)\beta/\alpha\big)$, positivo por hipótesis. Como $BD^{-\beta}$ es decreciente, $D_2 = D_{\text{opt}}(T_D/T_D')^{1/\beta}$, que es la expresión del enunciado, y $C_2/C = \kappa N_{\text{opt}}D_2/(N_{\text{opt}}D_{\text{opt}})$. Ningún término depende de C. Si $\kappa^{-\alpha} - 1 \ge \alpha/\beta$, haría falta $T_D' \le 0$, imposible con D finito. ∎

Ejemplo 5.9. Con los valores de Chinchilla y $\kappa = 1/2$: $2^{0{,}34} = 1{,}2658$, $(1{,}2658-1)\cdot 0{,}28/0{,}34 = 0{,}2189$ y $C_2/C = 0{,}5\cdot 0{,}7811^{-1/0{,}28} = 1{,}208$. A $C = 10^{21}$ FLOP, el óptimo es $N_{\text{opt}} = 1{,}82\cdot 10^9$; el modelo de $9{,}12\cdot 10^8$ parámetros necesita $2{,}21\cdot 10^{11}$ tokens (242 por parámetro), y el sobrecoste

de $2{,}08 \cdot 10^{20}$ FLOP se amortiza, por la proposición 5.7, tras $T^* = 2{,}08 \cdot 10^{20}/(2 \cdot 9{,}12 \cdot 10^{8}) = 1{,}14 \cdot 10^{11}$ tokens de inferencia. El límite de la proposición 5.8 es $\kappa = (1 + 0{,}34/0{,}28)^{-1/0{,}34} = 0{,}097$: por debajo de una décima parte del tamaño óptimo, la pérdida óptima es inalcanzable.

Esta es la lógica de los modelos abiertos recientes. LLaMA entrenó un modelo de $7 \cdot 10^9$ parámetros con 10^{12} tokens, más de siete veces lo que daría la regla de los 20 tokens, y observó que su rendimiento seguía mejorando; sus autores señalan que la regla de Hoffmann *et al.* ignora el presupuesto de inferencia [25, §1]. Llama 2 7B duplicó esa cifra (cuadro 1.1). Sardana *et al.* [23] incorporan la demanda de inferencia a la ley de escalado y concluyen que, con una demanda del orden de mil millones de peticiones, conviene entrenar modelos más pequeños y durante más tiempo que el óptimo de Chinchilla.

5.4 Datos limitados: el valor de repetir

Si cada modelo pide billones de tokens, el texto único de calidad se agota. Muennighoff *et al.* [18] estudiaron qué vale un token visto por segunda, tercera o k-ésima vez.

Definición 5.10 (Datos efectivos). Sea un entrenamiento que recorre U tokens únicos durante $1 + R$ épocas, es decir, con $R \geq 0$ repeticiones. Los *datos efectivos* son [18, §3.1, ecuación (5)]

$$D' = U + U\,R^*\big(1 - e^{-R/R^*}\big),$$

donde $R^* > 0$ es una constante ajustada; Muennighoff *et al.* obtienen $R^* \approx 15{,}4$ [18, apéndice A]. Se usa D' en lugar de D en la ley de Chinchilla.

Proposición 5.11. *Como función de $R \geq 0$, D' es creciente y cóncava, $D'(0) = U$, $D' < U(1 + R)$ para todo $R > 0$ y $D' \to U(1 + R^*)$ cuando $R \to \infty$.*

Demostración. $dD'/dR = Ue^{-R/R^*} > 0$ y $d^2D'/dR^2 = -(U/R^*)e^{-R/R^*} < 0$. En $R = 0$, $1 - e^0 = 0$. Por la desigualdad $1 - e^{-x} < x$ para $x > 0$, con $x = R/R^*$, $R^*(1 - e^{-R/R^*}) < R$. El límite se sigue de $e^{-R/R^*} \to 0$. ∎

El primer token repetido vale casi lo mismo que uno nuevo, pero el valor marginal decae exponencialmente con escala R^*: por muchas épocas que se hagan, un corpus de U tokens nunca equivale a más de unos $16{,}4\,U$ tokens nuevos. Con cuatro épocas ($R = 3$), $D' = U(1 + 15{,}39 \cdot 0{,}1772) = 3{,}73\,U$, el 93 % de los $4U$ tokens procesados. Los experimentos del artículo muestran que repetir hasta unas cuatro épocas apenas cambia la pérdida respecto de usar datos nuevos [18].

Lecturas recomendadas para este tema

- Hoffmann *et al.* [11], §3.1 a §3.3, tabla 2 y apéndice B.
- Stanford CS336 [9], práctica 3, §2.1 «Scaling Laws from IsoFLOPs profiles» y §3 «Constructing Scaling Laws».
- Muennighoff *et al.* [18], §3 «Method: Data-Constrained Scaling Laws» y §6.
- Sardana *et al.* [23] y Besiroglu *et al.* [2].

Ejercicios del tema 5

Ejercicio 5.1 ⋆ Explique por qué un laboratorio que va a servir un modelo a millones de usuarios elige un modelo más pequeño que el óptimo de Chinchilla y lo entrena con más tokens. ¿En qué caso sería preferible el óptimo de Chinchilla?

Ejercicio 5.2 ⋆⋆ Para tres presupuestos se entrenan modelos con $D = C/(6N)$ y se anota la pérdida final:

C (FLOP)	N y pérdida final		
10^{18}	$2{,}5 \cdot 10^7$: 3,92	$5 \cdot 10^7$: 3,85	10^8: 3,89
10^{19}	$8 \cdot 10^7$: 3,45	$1{,}6 \cdot 10^8$: 3,40	$3{,}2 \cdot 10^8$: 3,43
10^{20}	$2{,}5 \cdot 10^8$: 3,05	$5 \cdot 10^8$: 3,01	10^9: 3,04

(a) Tome en cada presupuesto el entrenamiento de menor pérdida como $N_{\text{opt}}(C)$. (b) Ajuste $\log_{10} N_{\text{opt}} = b_0 + a \log_{10} C$ por mínimos cuadrados. (c) Prediga N_{opt} y D_{opt} para 10^{23} y 10^{24} FLOP y compare $D_{\text{opt}}/N_{\text{opt}}$ con la regla de los 20 tokens.

Fuente: adaptado de Stanford CS336 [9], práctica 3, §2.1, problema `chinchilla_isoflops`, apartados (a) y (b) (datos sintéticos propios).

Ejercicio 5.3 ⋆⋆ En el perfil IsoFLOP de $C = 10^{19}$ FLOP se han medido tres entrenamientos con $\log_{10} N = 8{,}0$, 8,3 y 8,6 y pérdidas 3,47, 3,40 y 3,43. (a) Calcule con la proposición 5.3 el vértice de la parábola y el N_{opt} estimado. (b) Calcule D_{opt} y los tokens por parámetro. (c) Compare con el criterio de tomar el entrenamiento de menor pérdida.

Fuente: adaptado de Stanford CS336 [9], práctica 3, §2.1 (ajuste cuadrático de los perfiles de Hoffmann *et al.* [11, §3.2]).

Ejercicio 5.4 ⋆⋆ Se dispone de $U = 10^{11}$ tokens únicos. Con la definición 5.10 y $R^* = 15{,}39$, calcule los datos efectivos de un entrenamiento de $4 \cdot 10^{11}$ tokens y de otro de $1{,}6 \cdot 10^{12}$ tokens, y la fracción que representan de los tokens procesados. ¿Cuál es el máximo de datos efectivos que puede obtenerse de este corpus?

Ejercicio 5.5 ⋆⋆⋆ Con la ley de Chinchilla y $C = 10^{22}$ FLOP, se entrena un modelo con la mitad de parámetros que N_{opt}. Calcule los tokens necesarios para igualar la pérdida óptima, el sobrecoste de entrenamiento y cuántos tokens de inferencia hacen falta para amortizarlo. Compruebe que el sobrecoste relativo coincide con el de la proposición 5.8.

Ejercicio 5.6 ⋆⋆⋆ Con la notación de la definición 5.10, demuestre que

$$U(1+R) - \frac{UR^2}{2R^*} \le D' \le U(1+R) \qquad \text{para todo } R \ge 0,$$

y deduzca que la fracción de valor perdida por repetir, $1 - D'/\big(U(1+R)\big)$, es a lo sumo $R/(2R^*)$. Evalúe la cota para cuatro épocas y compárela con el valor exacto.

Tema 6

Capacidades emergentes y contexto largo

Las leyes de escalado predicen bien la pérdida de preentrenamiento. Este tema trata dos cuestiones en las que la escala produce efectos menos regulares. La primera es la aparición aparentemente brusca de capacidades al crecer el modelo, y si esa brusquedad es una propiedad del modelo o de la forma de medir. La segunda es la ampliación de la ventana de contexto, que tropieza con el coste cuadrático de la atención, con la memoria de la caché de claves y valores y con la codificación de posiciones no vistas en el entrenamiento. Se sigue a Wei *et al.* [27], Schaeffer, Miranda y Koyejo [24] y la clase «Capabilities» de CS324 [16] para la primera parte, y a Chen *et al.* [6], el informe de Llama 3 [7, §3.4.2] y Liu *et al.* [17] para la segunda; el modelo probabilístico de las respuestas usa la independencia de Bertsekas y Tsitsiklis [1, §1.5].

6.1 Capacidades emergentes

Definición 6.1 (Capacidad emergente; Wei *et al.* [27]). Una capacidad es *emergente* si no está presente en los modelos pequeños de una familia y sí en los grandes, de modo que no puede predecirse extrapolando el rendimiento de los primeros.

Los ejemplos habituales son tareas de aritmética de varias cifras y algunas tareas del conjunto BIG-Bench, en las que la exactitud permanece cerca del azar en varios órdenes de magnitud de cómputo y después sube con rapidez [27]. Si fueran saltos genuinos, la planificación de un modelo grande no podría apoyarse en experimentos pequeños, que es justo lo que hacen los temas 3 a 5.

6.2 El argumento de la métrica

Schaeffer, Miranda y Koyejo [24] proponen que muchas de esas discontinuidades las crea la métrica. Supóngase que una respuesta tiene k tokens y que el modelo acierta cada uno con probabilidad p, de forma independiente [1, §1.5]. La *exactitud exacta* (todo o nada) es la probabilidad de acertar los k:

$$\mathbb{P}(\text{respuesta correcta}) = p^k.$$

Una mejora gradual de p se convierte en un cambio brusco de p^k cuando k es grande:

p	0,5	0,8	0,9	0,95	0,99
p^5	0,031	0,328	0,590	0,774	0,951
p^{10}	0,001	0,107	0,349	0,599	0,904

Pasar de $p = 0{,}8$ a $p = 0{,}95$ lleva la exactitud de 0,107 a 0,599 con $k = 10$. En cambio, el número esperado de tokens correctos, kp, crece linealmente con p.

La pérdida por token sí sigue una ley de potencia suave en N. La proposición siguiente muestra qué forma adopta entonces la exactitud exacta.

Proposición 6.2 (Exactitud exacta bajo una ley de potencia). *Supóngase que la pérdida por token de la respuesta es $\ell(N) = (N_1/N)^\theta$, con $N_1, \theta > 0$, que $p(N) = e^{-\ell(N)}$ y que la respuesta tiene k tokens. Sea $x = \ln N$. Entonces:*

(i) $A(N) = p(N)^k = \exp\bigl(-e^{-\theta(x-x_0)}\bigr)$, *con* $x_0 = \ln N_1 + (\ln k)/\theta$*: una curva de Gompertz en* $\ln N$*, creciente de* 0 *a* 1*;*

(ii) su único punto de inflexión está en $N_0 = N_1 k^{1/\theta}$*, donde* $A = 1/e$*;*

(iii) en cambio, $-\ln A(N) = k\,\ell(N)$ *es una ley de potencia en* N*, una recta en escala log-log.*

Demostración. (i) $A = e^{-k\ell}$ y $k\ell = k\,N_1^\theta e^{-\theta x} = e^{\ln k + \theta \ln N_1 - \theta x} = e^{-\theta(x-x_0)}$. Como $e^{-\theta(x-x_0)}$ decrece de $+\infty$ a 0, A crece de 0 a 1. (ii) Sea $y = e^{-\theta(x-x_0)}$, de modo que $dy/dx = -\theta y$ y $A = e^{-y}$. Entonces $dA/dx = \theta y e^{-y}$ y $d^2A/dx^2 = \theta(dy/dx)(1-y)e^{-y} = -\theta^2 y(1-y)e^{-y}$, que solo se anula en $y = 1$, es decir, en $x = x_0$, y cambia allí de signo. En ese punto $A = e^{-1}$ y $N = e^{x_0} = N_1 k^{1/\theta}$. (iii) $-\ln A = k\ell(N) = kN_1^\theta N^{-\theta}$. ∎

La proposición 6.2 contiene el argumento completo. La capacidad «aparece» en torno a $N_0 = N_1 k^{1/\theta}$, y el umbral se desplaza hacia modelos mayores cuanto más larga es la respuesta exigida, aunque la mejora por token sea la misma. Con pocos tamaños de modelo y escala lineal en el eje vertical, la curva parece un escalón (figura 6.1); con la métrica continua $-\ln A$, es una recta en escala log-log.

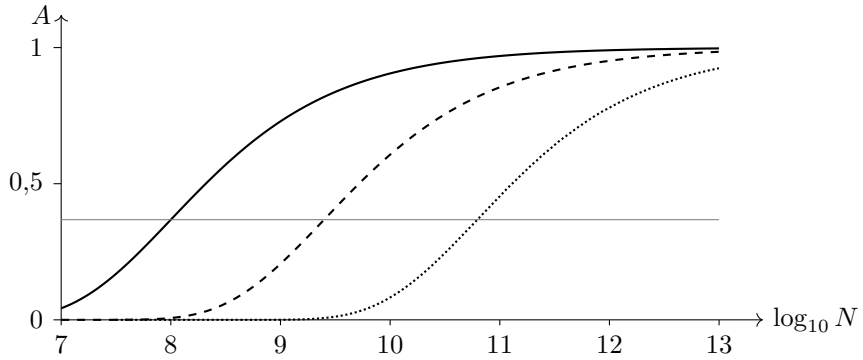


Figura 6.1: Exactitud exacta $A(N) = \exp\bigl(-k(10^8/N)^{1/2}\bigr)$ de la proposición 6.2 para respuestas de $k = 1$ (continua), $k = 5$ (discontinua) y $k = 25$ (punteada) tokens. La línea gris marca $A = 1/e$; los puntos de inflexión están en $\log_{10} N_0 = 8$, 9,40 y 10,80.

Observación 6.3 (El debate sigue abierto). El argumento explica muchas discontinuidades observadas, y Schaeffer *et al.* las hacen desaparecer cambiando la métrica o aumentando la resolución estadística [24]. No demuestra que no existan cambios cualitativos con la escala: muestra que una curva brusca en una métrica de todo o nada no es, por sí sola, prueba de ellos. Lo que sí está claro es que la pérdida de preentrenamiento es predecible y el rendimiento en una tarea concreta lo es mucho menos.

6.3 El coste del contexto largo

La ventana de contexto ha crecido de 2048 tokens en GPT-3 [5] a 128K (131 072) en Llama 3 [7]; el informe de Gemini 1.5 describe ventanas de millones de tokens, con recuperación casi perfecta hasta al menos 10 millones, y cita 200 000 tokens para Claude 3.0 [8]. Hay tres obstáculos.

Cómputo de la atención

Por el módulo 14 (tema 6), una pasada hacia delante cuesta por token unos $2N + 4Ln_{\text{ctx}}d$ FLOP, donde L es el número de bloques y d la dimensión del modelo. El segundo término procede de los productos $QK^\top$ y AV y crece linealmente con el contexto; sobre una secuencia completa, el coste de la atención crece como n_{ctx}^2. Pasar de 4096 a 10^6 tokens multiplica ese término total por $(10^6/4096)^2 \approx 59\,600$.

Ejemplo 6.4. Para LLaMA-2 7B ($N = 6{,}738 \cdot 10^9$, $L = 32$, $d = 4096$), el término de atención por token vale $4 \cdot 32 \cdot 4096 \cdot n_{\text{ctx}}$. Con $n_{\text{ctx}} = 4096$ es $2{,}15 \cdot 10^9$, el 13,7 % del total; con 32 768, $1{,}72 \cdot 10^{10}$, el 56,0 %; con 131 072, $6{,}87 \cdot 10^{10}$, el 83,6 %. A partir de unos 25 700 tokens, la atención cuesta más que todas las matrices de pesos juntas. FlashAttention (módulo 17) reduce el tráfico de memoria, pero no el número de operaciones.

Memoria de la caché KV

Proposición 6.5 (Tamaño de la caché KV). *Un Transformer de L bloques con h_{kv} cabezas de claves y valores de dimensión d_k, que almacena cada número con β_b bytes, necesita para una secuencia de n tokens una caché de*

$$M_{KV} = 2\,L\,n\,h_{kv}\,d_k\,\beta_b \text{ bytes.}$$

Demostración. En cada bloque y para cada token previo se guardan un vector de claves y uno de valores por cabeza, cada uno de d_k números: $2h_{kv}d_k$ números por token y bloque. Se multiplica por L bloques, n tokens y β_b bytes por número. ■

Para LLaMA-2 7B, con atención multicabeza estándar ($h_{kv} = 32$, $d_k = 128$) en bf16 ($\beta_b = 2$), son $2 \cdot 32 \cdot 4096 \cdot 2 = 524\,288$ bytes, 0,5 MiB por token: 2 GiB con 4096 tokens y 64 GiB con 131 072, más que la memoria de una GPU de 40 GiB para una sola secuencia. La atención con consultas agrupadas (GQA, módulo 18) reduce h_{kv}: con 8 cabezas de claves y valores, la caché se divide por 4. La caché domina el coste de la inferencia con contexto largo (módulo 19).

6.4 Posiciones no vistas: interpolación de RoPE

En RoPE (módulo 14, tema 4), el par de coordenadas i de la consulta y la clave en la posición m se rota un ángulo $m\theta_i$, con $\theta_i = \text{base}^{-2i/d_k}$ para $i = 0, \ldots, d_k/2 - 1$, y el producto escalar resultante depende solo de la diferencia de posiciones. Un modelo entrenado con contexto L_{tr} solo ha visto ángulos en $[0, L_{\text{tr}}\theta_i)$. Para las frecuencias bajas, ese intervalo es una fracción pequeña de una vuelta, y las posiciones $m \geq L_{\text{tr}}$ producen ángulos que el modelo nunca ha visto.

Definición 6.6 (Interpolación de posiciones; Chen *et al.* [6]). Sea $L' > L_{\text{tr}}$ el nuevo contexto. La *interpolación de posiciones* sustituye la posición m por $m\,L_{\text{tr}}/L'$ en todas las rotaciones de RoPE, y se ajusta brevemente el modelo con secuencias de longitud L'.

Proposición 6.7. *Con interpolación de posiciones, para toda posición $0 \le m < L'$ y toda frecuencia i, el ángulo de rotación está en $[0, L_{\text{tr}}\theta_i)$, el rango visto en el entrenamiento. El producto escalar rotado entre las posiciones m y n sigue dependiendo solo de $m-n$, ahora a través de $(m-n)L_{\text{tr}}/L'$.*

Demostración. El ángulo es $\theta_i\, mL_{\text{tr}}/L'$, y $0 \le mL_{\text{tr}}/L' < L'L_{\text{tr}}/L' = L_{\text{tr}}$. Para la segunda afirmación, RoPE aplicado a posiciones reales μ y ν da un producto escalar que depende solo de $\mu-\nu$ (módulo 14, tema 4); con $\mu = mL_{\text{tr}}/L'$ y $\nu = nL_{\text{tr}}/L'$, $\mu-\nu = (m-n)L_{\text{tr}}/L'$. ■

Ejemplo 6.8. Con base 10^4 y $d_k = 128$, la frecuencia más baja es $\theta_{63} = 10^{-4\cdot 126/128} = 1{,}155\cdot 10^{-4}$ rad por posición, con una longitud de onda de $2\pi/\theta_{63} \approx 54\,400$ posiciones. Con $L_{\text{tr}} = 2048$, el modelo solo ha visto ángulos hasta 0,237 rad en esa frecuencia; en la posición 32 768 el ángulo sería 3,78 rad, nunca visto. Con interpolación, el máximo sigue siendo 0,237. Chen *et al.* ampliaron así modelos LLaMA de $7\cdot 10^9$ a $65\cdot 10^9$ parámetros hasta 32 768 tokens con unos 1000 pasos de ajuste, y obtuvieron una cota del error de la interpolación unas 600 veces menor que la de la extrapolación [6].

El precio es la resolución: dos posiciones contiguas quedan a L_{tr}/L' de distancia en lugar de 1. Las variantes posteriores reparten el reescalado entre frecuencias (YaRN [21]) o aumentan la base de RoPE; Llama 3 usa base 500 000 [7, §3.2].

6.5 La receta habitual y sus límites

Como el coste de la atención crece con el contexto, casi todo el preentrenamiento se hace con secuencias cortas y se añade una fase final con documentos largos. Llama 3 amplió su ventana de 8K a 128K tokens en seis etapas, con unos 800 000 millones de tokens en total [7, §3.4.2]. Aceptar un contexto largo no equivale a usarlo bien: Liu *et al.* [17] observaron que los modelos aprovechan peor la información situada en el centro de un contexto largo que la situada al principio o al final.

Lecturas recomendadas para este tema

- Wei *et al.* [27] y Schaeffer, Miranda y Koyejo [24].
- Stanford CS324 [16], clase «Capabilities».
- Bertsekas y Tsitsiklis [1], §1.5 «Independence» (ensayos independientes).
- Chen *et al.* [6], interpolación de posiciones; Peng *et al.* [21], YaRN.
- Dubey *et al.* [7], §3.4.2 (preentrenamiento con contexto largo); Liu *et al.* [17].

Ejercicios del tema 6

Ejercicio 6.1 ⋆ Un equipo afirma: «la capacidad X aparece de golpe a partir de 10^{10} parámetros». Enumere tres comprobaciones que haría antes de aceptarlo y justifique cada una.

Ejercicio 6.2 ⋆⋆ Una tarea exige generar exactamente una respuesta de k tokens, y el modelo acierta cada token con probabilidad p, de forma independiente. (a) ¿Qué p hace falta para una exactitud del 50 % con $k = 10$? ¿Y con $k = 20$? (b) Con $k = 10$, ¿por qué factor se multiplica la exactitud al pasar de $p = 0{,}8$ a $p = 0{,}9$? (c) ¿Cuánto cambia, en el mismo paso, el número esperado de tokens correctos?

Fuente: adaptado de Bertsekas y Tsitsiklis [1], §1.5 (probabilidad de que tengan éxito todos los ensayos independientes de una serie).

Ejercicio 6.3 ⋆⋆ LLaMA 13B tiene $N \approx 1{,}3 \cdot 10^{10}$ parámetros, $L = 40$ bloques y $d = 5120$. (a) ¿A partir de qué contexto el término de atención por token, $4Ln_{\text{ctx}}d$, supera a $2N$? (b) ¿Qué fracción del coste por token de la pasada hacia delante corresponde a la atención con $n_{\text{ctx}} = 8192$ y con $n_{\text{ctx}} = 131\,072$?

Ejercicio 6.4 ⋆⋆ Para el modelo del ejercicio 6.3, con 40 cabezas de dimensión $d_k = 128$ y caché en bf16: (a) calcule la caché KV por token; (b) calcule la caché de una secuencia de 32 768 tokens y la de un lote de 8 secuencias; (c) ¿cuánto ocuparía la de una secuencia si el modelo usara GQA con 8 cabezas de claves y valores?

Ejercicio 6.5 ⋆⋆⋆ Con las hipótesis de la proposición 6.2, $N_1 = 10^8$ y $\theta = 1/2$: (a) calcule $A(N)$ para $k = 5$ y $N = 10^8$, 10^9, 10^{10} y 10^{11}; (b) halle el punto de inflexión para $k = 1$, 5 y 25 y demuestre que multiplicar k por λ desplaza el umbral en $(\log_{10}\lambda)/\theta$ órdenes de magnitud; (c) demuestre que la pendiente máxima de A respecto de $\ln N$ vale θ/e, independiente de k, e interprete el resultado.

Ejercicio 6.6 ⋆⋆⋆ Un modelo con RoPE (base 10^4, $d_k = 128$) se entrenó con $L_{\text{tr}} = 4096$ y se quiere ampliar a $L' = 32\,768$. (a) Calcule el ángulo máximo visto en el entrenamiento para la frecuencia más baja y el que se alcanzaría sin interpolar. (b) Demuestre que con interpolación de posiciones todos los ángulos quedan en el rango visto. (c) Como alternativa, se aumenta la base: halle la base b' con la que el ángulo máximo de la frecuencia más baja en L' coincide con el del entrenamiento, y demuestre que con esa base las demás frecuencias $i \geq 1$ también giran menos que con la base original.

Apéndice A

Soluciones de los ejercicios

Cada solución se presenta en cinco partes: datos, planteamiento, desarrollo, resultado y comprobación. En los pasos intermedios se redondea a cuatro cifras significativas salvo que se indique otra cosa. Cuando un logaritmo se multiplica después por un exponente grande o se eleva a una potencia, se conservan cinco decimales, porque un error en la cuarta cifra de $\log_{10} N$ se nota en la tercera cifra de N. Todas las cifras se han comprobado con un programa en Python.

A.1 Tema 1

Solución del ejercicio 1.1

Datos. clasificador entrenado con páginas citadas desde la Wikipedia en inglés como positivos; rastreo multilingüe.

Planteamiento. el clasificador aprende a reconocer lo que se parece a sus positivos; todo lo que difiere de ellos por razones ajenas a la calidad recibe puntuación baja.

Desarrollo.

1. Texto en otros idiomas, sobre todo los que tienen pocas páginas citadas en la Wikipedia inglesa: el clasificador confunde «distinto del inglés enciclopédico» con «de baja calidad».
2. Registros informales y variedades dialectales (foros, conversación, literatura popular), útiles para un modelo de lenguaje general y ausentes del estilo enciclopédico.
3. Consecuencia: el modelo resultante ve menos de esas variedades y las modeliza peor; su perplejidad sobre ellas es mayor y sus respuestas se sesgan hacia un registro y una cultura concretos.
4. Medidas: aplicar el clasificador por idioma, con positivos de referencia de cada idioma; fijar el umbral por idioma o por dominio; y auditar muestras de lo descartado.

Resultado. **se descartan injustificadamente el texto en idiomas con pocos recursos y los registros informales o dialectales; el modelo hereda ese sesgo. Se mitiga con clasificadores y umbrales por idioma y con auditoría de lo descartado.**

Comprobación. la observación del tema 1 sobre la calidad como elección describe exactamente este mecanismo.

Solución del ejercicio 1.2

Datos. la tabla de cuatro documentos y las cuatro reglas de la definición 1.2.

Planteamiento. calcular por documento la longitud media de palabra, la fracción de líneas con «...» y la fracción de palabras con letra; basta que falle una regla para descartarlo.

Desarrollo.

1. A: $40 < 50$ palabras, **falla** la regla (i). El resto pasaría: $200/40 = 5{,}0$; $0/4 = 0$; $38/40 = 0{,}95$.
2. B: 1200 palabras, bien. Media $5640/1200 = 4{,}7$, bien. Líneas con «...»: $24/60 = 0{,}40 > 0{,}30$, **falla**. Letras: $1170/1200 = 0{,}975$.
3. C: 800 palabras; media $4160/800 = 5{,}2$; «...» $6/50 = 0{,}12 \leq 0{,}30$; letras $720/800 = 0{,}90 \geq 0{,}80$. **Pasa**.
4. D: 3000 palabras; media $13\,500/3000 = 4{,}5$; «...» $5/100 = 0{,}05$; letras $2250/3000 = 0{,}75 < 0{,}80$, **falla**.

Resultado. **solo pasa C.** A es demasiado corto, B parece un listado de fragmentos truncados y D tiene demasiadas «palabras» sin letras (tablas, precios, códigos).

Comprobación. cada documento descartado falla exactamente una regla y con margen claro (40 frente a 50; 0,40 frente a 0,30; 0,75 frente a 0,80): ningún resultado depende del redondeo.

Solución del ejercicio 1.3

Datos. $D = 10^{12}$. Web: $U = 8 \cdot 10^{11}$, $w = 0{,}60$. Código: $2 \cdot 10^{11}$, 0,25. Libros: $5 \cdot 10^{10}$, 0,10. Ciencia: 10^{10}, 0,05.

Planteamiento. $e_i = w_i D/U_i$ (definición 1.10); más de unas 4 épocas rinde poco (tema 5).

Desarrollo.

1. Web: $0{,}60 \cdot 10^{12} = 6 \cdot 10^{11}$ tokens vistos; $6 \cdot 10^{11}/8 \cdot 10^{11} = 0{,}75$ épocas.
2. Código: $2{,}5 \cdot 10^{11}/2 \cdot 10^{11} = 1{,}25$ épocas.
3. Libros: $10^{11}/5 \cdot 10^{10} = 2$ épocas.
4. Ciencia: $5 \cdot 10^{10}/10^{10} = 5$ épocas.
5. Ajuste: con $w = 0{,}04$, la ciencia queda en $4 \cdot 10^{10}/10^{10} = 4$ épocas; el 0,01 sobrante pasa a la web, que sube a $0{,}61 \cdot 10^{12}/8 \cdot 10^{11} = 0{,}7625$ épocas.

Resultado. **web** 0,75**; código** 1,25**; libros** 2**; ciencia** 5 **épocas. Preocupa la ciencia** $(5 > 4)$**; bajar su peso a** 0,04 **y pasar** 0,01 **a la web la deja en** 4**.**

Comprobación. los pesos suman $0{,}60+0{,}25+0{,}10+0{,}05 = 1$ y los tokens vistos, $6+2{,}5+1+0{,}5 = 10$ (en 10^{11}), es decir, $10^{12} = D$.

Solución del ejercicio 1.4

Datos. $q(\text{de}) = 0{,}4$, $q(\text{la}) = 0{,}3$, $q(\text{casa}) = 0{,}2$, $q(\text{oferta}) = 0{,}1$; documentos A, B y C de cuatro palabras; umbral $\text{PPL} \leq 4$.

Planteamiento. $\text{PPL}_q(x) = \left(\prod_t q(x_t)\right)^{-1/T}$ con $T = 4$; para A, comparar $\ln \text{PPL}$ con $H(\hat{p}) + D(\hat{p} \,\|\, q)$.

Desarrollo.

1. A: $\prod q = 0{,}3 \cdot 0{,}2 \cdot 0{,}4 \cdot 0{,}3 = 0{,}0072$; $\ln 0{,}0072 = -4{,}9337$; $\ln \text{PPL} = 4{,}9337/4 = 1{,}2334$; $\text{PPL} = e^{1{,}2334} = 3{,}433$.
2. B: $\prod q = 0{,}1^3 \cdot 0{,}2 = 0{,}0002$; $\ln \text{PPL} = 8{,}5172/4 = 2{,}1293$; $\text{PPL} = 8{,}409$.
3. C: $\prod q = 0{,}4^4$; $\text{PPL} = 1/0{,}4 = 2{,}5$.

4. Con umbral 4 se conservan A y C, y se descarta B.
5. Comprobación de la proposición 1.5 para A: $\hat{p} = (\text{de} : 1/4,\ \text{la} : 1/2,\ \text{casa} : 1/4)$. $H(\hat{p}) = -\left(\frac{1}{4}\ln\frac{1}{4} + \frac{1}{2}\ln\frac{1}{2} + \frac{1}{4}\ln\frac{1}{4}\right) = 1{,}0397$. $D(\hat{p}\,\|\,q) = \frac{1}{4}\ln\frac{0{,}25}{0{,}4} + \frac{1}{2}\ln\frac{0{,}5}{0{,}3} + \frac{1}{4}\ln\frac{0{,}25}{0{,}2} = -0{,}1175 + 0{,}2554 + 0{,}0558 = 0{,}1937$. Suma: 1,2334.

Resultado. PPL(**A**) = 3,433**,** PPL(**B**) = 8,409**,** PPL(**C**) = 2,5**; pasan A y C.** El documento degenerado C obtiene la mejor puntuación, como predice el corolario 1.6.

Comprobación. $1/q_{\max} = 1/0{,}4 = 2{,}5$ es la cota inferior del corolario 1.6, y la alcanza exactamente C; $H(\hat{p}) + D(\hat{p}\,\|\,q) = 1{,}2334 = \ln 3{,}433$.

Solución del ejercicio 1.5

Datos. 2500 archivos en 1,5 h por máquina; 100 000 archivos por volcado; 96 volcados.

Planteamiento. el filtrado es paralelo por archivos: el tiempo es proporcional al número de archivos e inversamente proporcional al número de máquinas.

Desarrollo.

1. (a) $100\,000/2500 = 40$ lotes; $40 \cdot 1{,}5 = 60$ horas en una máquina.
2. (b) $60/2 = 30$ máquinas.
3. (c) $96 \cdot 60 = 5760$ horas-máquina.

Resultado. **(a)** 60 **h; (b)** 30 **máquinas; (c)** 5760 **horas-máquina.**

Comprobación. 30 máquinas $\times$ 2 h = 60 horas-máquina, el coste de un volcado; el orden de magnitud explica por qué la práctica de CS336 insiste en paralelizar [10, §4].

Solución del ejercicio 1.6

Datos. D fijo; fuentes con U_i tokens únicos; $e_i = w_i D/U_i$; tabla del ejemplo 1.12.

Planteamiento. acotar inferiormente $\max_i e_i$ sumando las desigualdades $e_i \le \max_j e_j$, y estudiar cuándo se alcanza la cota.

Desarrollo.

1. Sea $e = \max_i e_i$. Para todo i, $w_i D/U_i \le e$, es decir, $w_i \le eU_i/D$.
2. Sumando y usando $\sum_i w_i = 1$: $1 \le e\sum_i U_i/D$, luego $e \ge D/\sum_i U_i$ para toda mezcla.
3. La mezcla proporcional $w_i = U_i/\sum_j U_j$ da $e_i = D/\sum_j U_j$ para todo i: alcanza la cota y es óptima.
4. Unicidad: si una mezcla alcanza $e = D/\sum_j U_j$, la suma del paso 2 es una igualdad, $\sum_i w_i = \sum_i eU_i/D$, y como cada sumando cumple $w_i \le eU_i/D$, todas las desigualdades son igualdades: $w_i = U_i/\sum_j U_j$.
5. LLaMA: $\sum_i U_i = 852{,}7 + 198{,}1 + 98{,}4 + 25{,}7 + 28{,}3 + 33{,}0 + 27{,}2 = 1263{,}4$ (en 10^9). El mínimo es $1400/1263{,}4 = 1{,}108$ épocas.

Resultado. **la mezcla proporcional es la única que minimiza** $\max_i e_i$**, con valor** $D/\sum_i U_i$**; para LLaMA,** 1,108 **épocas, frente a las** 2,45 **que sus autores eligieron para Wikipedia.**

Comprobación. la elección de LLaMA no minimiza la repetición: sobremuestrea a propósito las fuentes pequeñas y valiosas, aceptando hasta 2,45 épocas, por debajo del límite de unas 4 del tema 5.

A.2 Tema 2

Solución del ejercicio 2.1

Datos. dos corpus del mismo tamaño en tokens, uno con muchos duplicados y otro deduplicado.

Planteamiento. comparar cuánta información nueva aporta cada token y qué hace el modelo con el texto que ve muchas veces.

Desarrollo.

1. *Cómputo malgastado.* Un token duplicado no aporta información nueva: la entropía cruzada sobre él ya se redujo la primera vez. Con $C \approx 6ND$ fijo, el corpus efectivo es menor que su tamaño nominal.
2. *Memorización.* Lo repetido cientos de veces se aprende literalmente y puede regurgitarse, incluidos datos personales o protegidos [13].
3. Además, *contaminación*: si los duplicados cruzan la frontera entre entrenamiento y evaluación, las métricas se inflan.

Resultado. **(i) desperdicio de cómputo en información repetida; (ii) memorización literal (y, además, contaminación de la evaluación).**

Comprobación. caso límite: un corpus formado por un único documento repetido un millón de veces tiene el mismo tamaño en tokens, pero solo permite aprender ese documento.

Solución del ejercicio 2.2

Datos. $S_1 = \{a, b, c, d\}$, $S_2 = \{b, c, e\}$, $S_3 = \{a, c, e, f\}$.

Planteamiento. $J = |X \cap Y|/|X \cup Y|$ con $|X \cup Y| = |X| + |Y| - |X \cap Y|$.

Desarrollo.

1. S_1, S_2: intersección $\{b, c\}$; unión $4 + 3 - 2 = 5$; $J = 2/5 = 0{,}4$.
2. S_1, S_3: intersección $\{a, c\}$; unión $4 + 4 - 2 = 6$; $J = 2/6 = 1/3$.
3. S_2, S_3: intersección $\{c, e\}$; unión $3 + 4 - 2 = 5$; $J = 2/5 = 0{,}4$.

Resultado. $J(S_1, S_2) = 0{,}4$**;** $J(S_1, S_3) = 1/3 \approx 0{,}333$**;** $J(S_2, S_3) = 0{,}4$**. Empatan** S_1–S_2 **y** S_2–S_3**.**

Comprobación. las tres intersecciones tienen 2 elementos; el par con mayor unión, S_1–S_3, debe tener la menor similitud, y así es.

Solución del ejercicio 2.3

Datos. A = «la luna brilla sobre el mar», B = «la luna brilla sobre el río»; $k = 2$.

Planteamiento. un texto de T palabras tiene $T - 1$ shingles de 2 palabras; $J = |A \cap B|/|A \cup B|$.

Desarrollo.

1. A: {la luna, luna brilla, brilla sobre, sobre el, el mar}, 5 shingles.
2. B: {la luna, luna brilla, brilla sobre, sobre el, el río}, 5 shingles.
3. Intersección: los cuatro primeros, $|A \cap B| = 4$. Unión: $5 + 5 - 4 = 6$.
4. $J = 4/6 = 2/3$.

Resultado. $J = 2/3 \approx 0{,}667$**.**

Comprobación. solo cambia la última palabra, que aparece en un único shingle de cada frase: cada conjunto pierde 1 de sus 5 elementos y gana otro distinto. La fracción compartida de cada conjunto es $4/5$, pero la unión tiene $6 > 5$ elementos, de modo que $J < 4/5$.

Solución del ejercicio 2.4

Datos. $S_1 = \{0, 2, 5\}$, $S_2 = \{1, 2, 3\}$, $S_3 = \{0, 3, 5\}$; h_1, h_2, h_3 del enunciado.

Planteamiento. una función es permutación del universo si toma los 6 valores distintos; la firma es $(\min h_1, \min h_2, \min h_3)$ sobre cada conjunto; la similitud estimada es la fracción de coordenadas iguales.

Desarrollo.

1. Valores en $x = 0, \ldots, 5$: $h_1 = (1, 2, 3, 4, 5, 0)$, permutación; $h_2 = (1, 0, 5, 4, 3, 2)$, permutación (5 y 6 son primos entre sí); $h_3 = (3, 5, 1, 3, 5, 1)$, no lo es (2 y 6 comparten el factor 2).
2. $S_1 = \{0, 2, 5\}$: $\min(1, 3, 0) = 0$; $\min(1, 5, 2) = 1$; $\min(3, 1, 1) = 1$. Firma $(0, 1, 1)$.
3. $S_2 = \{1, 2, 3\}$: $\min(2, 3, 4) = 2$; $\min(0, 5, 4) = 0$; $\min(5, 1, 3) = 1$. Firma $(2, 0, 1)$.
4. $S_3 = \{0, 3, 5\}$: $\min(1, 4, 0) = 0$; $\min(1, 4, 2) = 1$; $\min(3, 3, 1) = 1$. Firma $(0, 1, 1)$.
5. Similitudes reales: $J(S_1, S_2) = 1/5 = 0{,}2$; $J(S_1, S_3) = 2/4 = 0{,}5$; $J(S_2, S_3) = 1/5 = 0{,}2$.
6. Estimadas con las tres funciones: S_1–S_2 coinciden solo en h_3, $1/3$; S_1–S_3 en las tres, 1; S_2–S_3 solo en h_3, $1/3$. Solo con h_1 y h_2: 0, 1 y 0.

Resultado. **(a)** h_1 **y** h_2 **son permutaciones;** h_3 **no. (b)** $\mathrm{sig}(S_1) = (0, 1, 1)$**,** $\mathrm{sig}(S_2) = (2, 0, 1)$**,** $\mathrm{sig}(S_3) = (0, 1, 1)$**. (c) Reales:** 0,2**;** 0,5**;** 0,2**. Estimadas:** $1/3$**;** 1**;** $1/3$**.** Con tan pocas funciones el error es grande, y h_3, que no es permutación, coincide más de la cuenta.

Comprobación. por el corolario 2.8, con $J = 0{,}5$ y $n = 3$ la desviación típica es $\sqrt{0{,}25/3} = 0{,}29$: estimar 1 está a menos de dos desviaciones típicas y es compatible con el azar.

Solución del ejercicio 2.5

Datos. $r = 4$, $b = 25$; $s = 0{,}3$ y $s = 0{,}85$.

Planteamiento. $P(s) = 1 - (1 - s^r)^b$ (proposición 2.10); para elevar a 25, $x^{25} = e^{25 \ln x}$.

Desarrollo.

1. $s = 0{,}3$: $s^4 = 0{,}0081$; $\ln(0{,}9919) = -0{,}008133$; $25 \cdot (-0{,}008133) = -0{,}2033$; $e^{-0{,}2033} = 0{,}8160$; $P = 0{,}1840$.
2. $s = 0{,}85$: $0{,}85^4 = 0{,}5220$; $\ln 0{,}4780 = -0{,}7382$; $25 \cdot (-0{,}7382) = -18{,}45$; $e^{-18{,}45} = 9{,}7 \cdot 10^{-9}$; $P = 1 - 9{,}7 \cdot 10^{-9}$.
3. Umbral aproximado: $(1/25)^{1/4} = \sqrt{\sqrt{0{,}04}} = \sqrt{0{,}2} = 0{,}4472$.
4. Inflexión exacta: $\big((r-1)/(rb-1)\big)^{1/r} = (3/99)^{1/4} = 0{,}4172$.

Resultado. $P(0{,}3) \approx 0{,}184$**;** $P(0{,}85) \approx 1 - 10^{-8}$**; umbral aproximado** 0,447**; inflexión** 0,417**.**

Comprobación. $0{,}3 < 0{,}417 < 0{,}85$, así que la curva debe dar una probabilidad baja en el primer caso y casi 1 en el segundo. Con $r = 4$, pequeño, la aproximación $(1/b)^{1/r}$ se separa algo de la inflexión exacta, como prevé la proposición 2.10.

Solución del ejercicio 2.6

Datos. $(r, b) = (3, 10)$, $(6, 20)$, $(5, 50)$; $s = 0{,}2$, $0{,}5$, $0{,}8$.

Planteamiento. $P(s) = 1 - (1 - s^r)^b$; de $P = 1/2$ se despeja $s_{1/2} = (1 - 2^{-1/b})^{1/r}$.

Desarrollo.

1. $(3, 10)$. $s = 0{,}2$: $s^3 = 0{,}008$; $0{,}992^{10} = 0{,}9228$; $P = 0{,}0772$. $s = 0{,}5$: $0{,}875^{10} = 0{,}2631$; $P = 0{,}7369$. $s = 0{,}8$: $0{,}488^{10} = 7{,}66 \cdot 10^{-4}$; $P = 0{,}9992$.
2. $(6, 20)$. $s = 0{,}2$: $s^6 = 6{,}4 \cdot 10^{-5}$; $P = 0{,}0013$. $s = 0{,}5$: $s^6 = 0{,}015625$; $0{,}984375^{20} = 0{,}7298$; $P = 0{,}2702$. $s = 0{,}8$: $s^6 = 0{,}2621$; $0{,}7379^{20} = 0{,}00229$; $P = 0{,}9977$.
3. $(5, 50)$. $s = 0{,}2$: $s^5 = 3{,}2 \cdot 10^{-4}$; $0{,}99968^{50} = 0{,}9841$; $P = 0{,}0159$. $s = 0{,}5$: $0{,}96875^{50} = 0{,}2044$; $P = 0{,}7956$. $s = 0{,}8$: $0{,}6723^{50} = 2{,}4 \cdot 10^{-9}$; $P \approx 1$.
4. $s_{1/2}$ para $(3, 10)$: $2^{-1/10} = 0{,}9330$; $0{,}0670^{1/3} = 0{,}4061$, frente a $(1/10)^{1/3} = 0{,}4642$.
5. Para $(6, 20)$: $2^{-1/20} = 0{,}9659$; $0{,}0341^{1/6} = 0{,}5694$, frente a $(1/20)^{1/6} = 0{,}6070$.
6. Para $(5, 50)$: $2^{-1/50} = 0{,}9862$; $0{,}0138^{1/5} = 0{,}4244$, frente a $(1/50)^{1/5} = 0{,}4573$.

Resultado. **(a)** $(0{,}077;\ 0{,}737;\ 0{,}999)$ **para** $(3, 10)$**;** $(0{,}001;\ 0{,}270;\ 0{,}998)$ **para** $(6, 20)$**;** $(0{,}016;\ 0{,}796;\ 1{,}000)$ **para** $(5, 50)$**. (b)** $s_{1/2} = 0{,}406$**;** $0{,}569$**;** $0{,}424$**, frente a** $0{,}464$**;** $0{,}607$**;** $0{,}457$**: la aproximación sobrestima el punto del** $50\,\%$ **entre** $0{,}03$ **y** $0{,}06$**.**

Comprobación. $0{,}4061^3 = 0{,}0670$ y $0{,}9330^{10} = 0{,}500$. Además, $(6, 20)$, con más filas por banda, es la curva más exigente: da la menor P en $s = 0{,}5$.

Solución del ejercicio 2.7

Datos. $\mathrm{Var}(\hat{J}) = J(1 - J)/n$ (corolario 2.8).

Planteamiento. acotar $J(1 - J)$ en $[0, 1]$; despejar n; aplicar Chebyshev, $\mathbb{P}(|X - \mathbb{E}X| \geq \varepsilon) \leq \mathrm{Var}(X)/\varepsilon^2$ (módulo 5).

Desarrollo.

1. (a) $J(1-J) = \frac{1}{4} - (J - \frac{1}{2})^2 \leq \frac{1}{4}$, con igualdad en $J = 1/2$. Luego $\sqrt{\mathrm{Var}(\hat{J})} \leq \sqrt{1/(4n)} = 1/(2\sqrt{n})$.
2. (b) Para todo par: $1/(2\sqrt{n}) \leq 0{,}05 \iff \sqrt{n} \geq 10 \iff n \geq 100$.
3. Con $J = 0{,}8$: $J(1 - J) = 0{,}16$; $0{,}16/n \leq 0{,}0025 \iff n \geq 64$.
4. (c) $\mathbb{P}(|\hat{J} - J| \geq 0{,}1) \leq \dfrac{J(1 - J)}{100 \cdot 0{,}01} \leq \dfrac{0{,}25}{1} = 0{,}25$.

Resultado. **(a)** $\sigma \leq 1/(2\sqrt{n})$**; (b)** $n = 100$ **en general y** $n = 64$ **si** $J = 0{,}8$**; (c) probabilidad a lo sumo** $0{,}25$**.**

Comprobación. con $n = 100$ y $J = 1/2$, el error de $0{,}1$ son dos desviaciones típicas; la aproximación normal daría una probabilidad de unos $0{,}05$, compatible con la cota de Chebyshev, que es más conservadora.

A.3 Tema 3

Solución del ejercicio 3.1

Datos. $L = kN^{-\alpha}$; $\alpha = 0{,}076$.

Planteamiento. tomar logaritmos con $\log(xy) = \log x + \log y$ y $\log x^a = a \log x$ (proposición 3.4).

Desarrollo.

1. $\log L = \log k + \log N^{-\alpha} = \log k - \alpha \log N$.
2. Con $u = \log N$ y $v = \log L$: $v = \log k - \alpha u$, una recta de pendiente $-\alpha$ y ordenada $\log k$.
3. Multiplicar N por 10 aumenta $u = \log_{10} N$ en 1, luego v baja $\alpha = 0{,}076$.

Resultado. **la ley es una recta de pendiente $-\alpha$; la pendiente es el cambio de $\log L$ por cada unidad de $\log N$. Con $\alpha = 0{,}076$, $\log_{10} L$ baja 0,076 por cada factor 10 en N.**

Comprobación. $10^{-0{,}076} = 0{,}8395$: L se multiplica por 0,84, como en el ejemplo 3.8.

Solución del ejercicio 3.2

Datos. $N = 1{,}3 \cdot 10^9$; $D = 2{,}6 \cdot 10^{10}$; 1 PF-día $= 8{,}64 \cdot 10^{19}$ FLOP.

Planteamiento. $C \approx 6ND$; tokens por parámetro $= D/N$.

Desarrollo.

1. $6N = 7{,}8 \cdot 10^9$.
2. $C = 7{,}8 \cdot 10^9 \cdot 2{,}6 \cdot 10^{10} = 20{,}28 \cdot 10^{19} = 2{,}028 \cdot 10^{20}$ FLOP.
3. En PF-días: $2{,}028 \cdot 10^{20} / 8{,}64 \cdot 10^{19} = 2{,}347$.
4. $D/N = 2{,}6 \cdot 10^{10} / 1{,}3 \cdot 10^9 = 20$.

Resultado. $C = 2{,}028 \cdot 10^{20}$ **FLOP** $\approx 2{,}35$ **PF-días; 20 tokens por parámetro.**

Comprobación. con la proposición 4.8, $\sqrt{C/120} = \sqrt{1{,}69 \cdot 10^{18}} = 1{,}3 \cdot 10^9$: se recupera el N de partida.

Solución del ejercicio 3.3

Datos. $L(D) = (5{,}4 \cdot 10^{13}/D)^{0{,}095}$; $D = 10^9$ y 10^{11}.

Planteamiento. $x^{0{,}095} = 10^{0{,}095 \log_{10} x}$.

Desarrollo.

1. $D = 10^9$: $x = 5{,}4 \cdot 10^4$; $\log_{10} x = 4{,}73239$; $0{,}095 \cdot 4{,}73239 = 0{,}44958$; $L = 10^{0{,}44958} = 2{,}816$.
2. $D = 10^{11}$: $x = 540$; $\log_{10} x = 2{,}73239$; $0{,}095 \cdot 2{,}73239 = 0{,}25958$; $L = 10^{0{,}25958} = 1{,}818$.
3. Factor por cada factor 10: $10^{-0{,}095} = 0{,}8035$.

Resultado. $L(10^9) \approx 2{,}816$ **nats;** $L(10^{11}) \approx 1{,}818$ **nats; cada factor 10 en D multiplica L por 0,804.**

Comprobación. de 10^9 a 10^{11} hay dos factores 10: $2{,}816 \cdot 0{,}8035^2 = 2{,}816 \cdot 0{,}6456 = 1{,}818$.

Solución del ejercicio 3.4

Datos. configuraciones $(4, 256)$, $(8, 512)$, $(16, 1024)$ con $L = 4{,}20,\ 3{,}62,\ 3{,}12$; $N = 12 n_{\text{layer}} d_{\text{model}}^2$.

Planteamiento. calcular $u_j = \log_{10} N_j$ y $v_j = \log_{10} L_j$ y aplicar la definición 3.5.

Desarrollo.

1. (a) $N_1 = 12 \cdot 4 \cdot 65\,536 = 3\,145\,728$; $N_2 = 12 \cdot 8 \cdot 262\,144 = 25\,165\,824$; $N_3 = 12 \cdot 16 \cdot 1\,048\,576 = 201\,326\,592$. Cada uno es 8 veces el anterior.
2. $u = (6{,}49772;\ 7{,}40081;\ 8{,}30390)$, equiespaciados con paso $\log_{10} 8 = 0{,}90309$; $\bar{u} = 7{,}40081$.
3. $v = (0{,}62325;\ 0{,}55871;\ 0{,}49415)$; $\bar{v} = 0{,}55870$.
4. Numerador: $(-0{,}90309)(0{,}06455) + 0 + (0{,}90309)(-0{,}06455) = -0{,}11658$. Denominador: $2 \cdot 0{,}90309^2 = 1{,}63114$.
5. $b_1 = -0{,}11658/1{,}63114 = -0{,}07147$; $b_0 = 0{,}55870 + 0{,}07147 \cdot 7{,}40081 = 1{,}08767$.
6. (c) $N = 12 \cdot 32 \cdot 2048^2 = 1\,610\,612\,736$; $\log_{10} N = 9{,}20700$; $\log_{10} \hat{L} = 1{,}08767 - 0{,}07147 \cdot 9{,}20700 = 0{,}42963$; $\hat{L} = 2{,}689$.

Resultado. **(a)** $N = 3{,}15 \cdot 10^6$**,** $2{,}52 \cdot 10^7$**,** $2{,}01 \cdot 10^8$**; (b)** $\hat{L} = 10^{1{,}0877} N^{-0{,}0715}$**, exponente** $\hat{\alpha} = 0{,}0715$**; (c)** $\hat{L} \approx 2{,}69$ **nats para** $N = 1{,}61 \cdot 10^9$**.** La predicción extrapola un orden de magnitud con solo tres puntos y supone que los hiperparámetros (tasa de aprendizaje, lote, tokens) se ajustan bien en todos los tamaños; sin varias semillas no hay barras de error.

Comprobación. la recta ajustada reproduce los datos: $10^{1{,}08767 - 0{,}07147 \cdot 6{,}49772} = 4{,}200$, $3{,}620$ y $3{,}120$. El exponente es del orden del $\alpha_N = 0{,}076$ de Kaplan *et al.*

Solución del ejercicio 3.5

Datos. $L(N, D)$ de (3.1); $L(N) = (N_c/N)^{\alpha_N}$; $\alpha_N = 0{,}076$; $\alpha_D = 0{,}095$ o $0{,}103$.

Planteamiento. sacar factor común $(N_c/N)^{\alpha_N/\alpha_D}$ dentro del corchete.

Desarrollo.

1. Sea $\rho = \alpha_N/\alpha_D$. El corchete es $(N_c/N)^{\rho}\big(1 + (N/N_c)^{\rho} D_c/D\big)$.
2. Elevando a α_D y usando $\rho\alpha_D = \alpha_N$:

$$L(N, D) = \Big(\frac{N_c}{N}\Big)^{\rho\alpha_D} \Big(1 + \Big(\frac{N}{N_c}\Big)^{\rho} \frac{D_c}{D}\Big)^{\alpha_D} = L(N)\Big(1 + \frac{N^{\rho} D_c}{N_c^{\rho} D}\Big)^{\alpha_D},$$

   que es la igualdad (a).
3. (b) El cociente depende de N y D solo a través de $z = N^{\rho}/D$, y es creciente en z. Para mantenerlo constante al crecer N, z debe mantenerse constante: $D \propto N^{\rho} = N^{\alpha_N/\alpha_D}$.
4. (c) Con $\alpha_D = 0{,}095$: $\rho = 0{,}076/0{,}095 = 0{,}80$. Con $\alpha_D = 0{,}103$: $\rho = 0{,}076/0{,}103 = 0{,}738$.

Resultado. $L(N, D)/L(N) = \big(1 + (N/N_c)^{\alpha_N/\alpha_D} D_c/D\big)^{\alpha_D}$**;** D **debe crecer como** N^{α_N/α_D}**, con exponente** $0{,}80$ **o** $0{,}74$ **según el ajuste.** El segundo valor es el de la regla $D \gtrsim 5 \cdot 10^3 N^{0{,}74}$.

Comprobación. cuando $D \to \infty$, el cociente tiende a 1, de acuerdo con la proposición 3.9; el crecimiento sublineal ($\rho < 1$) significa que los modelos grandes necesitan menos datos por parámetro para no sobreajustar.

Solución del ejercicio 3.6

Datos. $b_1 = \sum(u_j - \bar{u})(v_j - \bar{v}) / \sum(u_j - \bar{u})^2$, $b_0 = \bar{v} - b_1\bar{u}$, $\hat{\alpha} = -b_1$.

Planteamiento. cada transformación cambia u o v de forma afín; ver cómo cambian las desviaciones respecto de la media.

Desarrollo.

1. (a) Cambiar de base multiplica todos los logaritmos por la misma constante $\kappa_0 > 0$: $u'_j = \kappa_0 u_j$, $v'_j = \kappa_0 v_j$. Las desviaciones se multiplican por κ_0; numerador y denominador de b_1 por κ_0^2, y $b'_1 = b_1$. La ordenada pasa a $b'_0 = \kappa_0 b_0$.
2. (b) $N' = \kappa N$ da $u'_j = u_j + \log\kappa$: $\bar{u}' = \bar{u} + \log\kappa$ y $u'_j - \bar{u}' = u_j - \bar{u}$. Luego $b'_1 = b_1$ y $b'_0 = \bar{v} - b_1(\bar{u} + \log\kappa) = b_0 - b_1\log\kappa$.
3. (c) $L' = cL$ da $v'_j = v_j + \log c$, con $v'_j - \bar{v}' = v_j - \bar{v}$: $b'_1 = b_1$ y $b'_0 = b_0 + \log c$. De nats a bits, $c = 1/\ln 2$.

Resultado. $\hat{\alpha}$ **es invariante en los tres casos; cambia la ordenada:** $b'_0 = \kappa_0 b_0$**,** $b'_0 = b_0 - b_1\log\kappa$ **y** $b'_0 = b_0 + \log c$**, respectivamente.**

Comprobación. es coherente con la proposición 3.2: el exponente es la única característica de una ley de potencia que no depende de las unidades, y la constante absorbe todos los cambios de escala.

A.4 Tema 4

Solución del ejercicio 4.1

Planteamiento. recordar los exponentes de N_{opt} en cada trabajo y el papel de E.

Desarrollo.

(a) **Verdadera.** Kaplan *et al.* obtienen $N_{\text{opt}} \propto C^{0{,}73}$ y $D \propto C^{0{,}27}$: el exponente del modelo es casi el triple que el de los datos.

(b) **Falsa.** A cómputo fijo hay un tamaño óptimo (teorema 4.3); Gopher era demasiado grande para su presupuesto y Chinchilla, cuatro veces menor, obtiene menos pérdida: 1,937 frente a 1,993 (ejemplo 4.7).

(c) **Falsa.** $E = 1{,}69$ no depende de N ni de D: es la entropía del texto, y $L \to E$ cuando $N, D \to \infty$.

Resultado. **(a) V; (b) F; (c) F.**

Comprobación. en (c), con $N = D = 10^{30}$ los términos de error valen $2{,}6 \cdot 10^{-8}$ y $1{,}6 \cdot 10^{-6}$, y $L \approx 1{,}69$.

Solución del ejercicio 4.2

Datos. $C = 10^{23}$; $D = 20N$.

Planteamiento. por la proposición 4.8, $N = \sqrt{C/120}$.

Desarrollo.

1. $N^2 = 10^{23}/120 = 8{,}333 \cdot 10^{20}$.

2. $N = \sqrt{8{,}333} \cdot 10^{10} = 2{,}887 \cdot 10^{10}$.
3. $D = 20 \cdot 2{,}887 \cdot 10^{10} = 5{,}774 \cdot 10^{11}$.

Resultado. $N \approx 2{,}89 \cdot 10^{10}$ **parámetros y** $D \approx 5{,}77 \cdot 10^{11}$ **tokens.**

Comprobación. $6 \cdot 2{,}887 \cdot 10^{10} \cdot 5{,}774 \cdot 10^{11} = 1{,}000 \cdot 10^{23}$.

Solución del ejercicio 4.3

Datos. $E = 1{,}69$, $A = 406{,}4$, $\alpha = 0{,}34$, $B = 410{,}7$, $\beta = 0{,}28$; $C = 10^{22}$.

Planteamiento. teorema 4.3: $N_{\text{opt}} = G(C/6)^a$, $D_{\text{opt}} = (C/6)/N_{\text{opt}}$; después $L = E + AN_{\text{opt}}^{-\alpha} + BD_{\text{opt}}^{-\beta}$.

Desarrollo.

1. $a = 0{,}28/0{,}62 = 0{,}45161$; $1/(\alpha+\beta) = 1{,}6129$.
2. $\alpha A = 138{,}18$; $\beta B = 115{,}00$; cociente $1{,}20157$; $\ln 1{,}20157 = 0{,}18363$; $G = e^{1{,}6129 \cdot 0{,}18363} = e^{0{,}29618} = 1{,}3447$.
3. $C/6 = 1{,}6667 \cdot 10^{21}$; $\log_{10}(C/6) = 21{,}22185$; $(C/6)^a = 10^{0{,}45161 \cdot 21{,}22185} = 10^{9{,}58406} = 3{,}8376 \cdot 10^9$.
4. $N_{\text{opt}} = 1{,}3447 \cdot 3{,}8376 \cdot 10^9 = 5{,}160 \cdot 10^9$.
5. $D_{\text{opt}} = 1{,}6667 \cdot 10^{21}/5{,}160 \cdot 10^9 = 3{,}230 \cdot 10^{11}$; $D_{\text{opt}}/N_{\text{opt}} = 62{,}6$.
6. $\log_{10} N_{\text{opt}} = 9{,}71265$; $N_{\text{opt}}^{0{,}34} = 10^{3{,}30230} = 2006$; $T_N = 406{,}4/2006 = 0{,}2026$.
7. $\log_{10} D_{\text{opt}} = 11{,}50920$; $D_{\text{opt}}^{0{,}28} = 10^{3{,}22258} = 1669{,}5$; $T_D = 410{,}7/1669{,}5 = 0{,}2460$.
8. $L = 1{,}69 + 0{,}2026 + 0{,}2460 = 2{,}1386$.
9. Regla de 20: $N = \sqrt{10^{22}/120} = 9{,}129 \cdot 10^9$ y $D = 1{,}826 \cdot 10^{11}$. Términos de error: $406{,}4/10^{0{,}34 \cdot 9{,}96042} = 406{,}4/2435 = 0{,}1669$ y $410{,}7/10^{0{,}28 \cdot 11{,}26150} = 410{,}7/1423 = 0{,}2886$. Pérdida: $L = 2{,}1455$.

Resultado. $N_{\text{opt}} \approx 5{,}16 \cdot 10^9$**;** $D_{\text{opt}} \approx 3{,}23 \cdot 10^{11}$**;** $D_{\text{opt}}/N_{\text{opt}} \approx 63$**;** $L \approx 2{,}1386$ **nats. La regla de 20 da** $N \approx 9{,}13 \cdot 10^9$**,** $D \approx 1{,}83 \cdot 10^{11}$ **y** $L \approx 2{,}1455$**: solo** $0{,}007$ **nats peor.**

Comprobación. (i) $6 \cdot 5{,}160 \cdot 10^9 \cdot 3{,}230 \cdot 10^{11} = 1{,}000 \cdot 10^{22}$. (ii) Por el corolario 4.4, T_D/T_N debe valer $\alpha/\beta = 1{,}214$: $0{,}2460/0{,}2026 = 1{,}214$.

Solución del ejercicio 4.4

Datos. $T_N = 0{,}2026$, $T_D = 0{,}2460$, $\alpha = 0{,}34$, $\beta = 0{,}28$; factores $\lambda = 4$ y $\lambda = 1/4$.

Planteamiento. proposición 4.9 con $\delta = \ln\lambda = \pm 1{,}3863$.

Desarrollo.

1. Coeficiente cuadrático: $\frac{1}{2}(\alpha^2 T_N + \beta^2 T_D) = \frac{1}{2}(0{,}1156 \cdot 0{,}2026 + 0{,}0784 \cdot 0{,}2460) = 0{,}02135$; con $\delta^2 = 1{,}9218$, aproximación $0{,}0410$ en ambos casos.
2. $\lambda = 4$: $e^{-0{,}34 \cdot 1{,}3863} = e^{-0{,}4713} = 0{,}6242$ y $e^{0{,}28 \cdot 1{,}3863} = e^{0{,}3882} = 1{,}4743$. $\Delta = 0{,}2026 \cdot (-0{,}3758) + 0{,}2460 \cdot 0{,}4743 = -0{,}07614 + 0{,}11668 = 0{,}0405$.
3. $\lambda = 1/4$: $e^{0{,}4713} = 1{,}6021$ y $e^{-0{,}3882} = 0{,}6783$. $\Delta = 0{,}2026 \cdot 0{,}6021 + 0{,}2460 \cdot (-0{,}3217) = 0{,}12198 - 0{,}07914 = 0{,}0429$.

4. Asimetría: el término cúbico del desarrollo es $\frac{1}{6}(-\alpha^3 T_N + \beta^3 T_D)\delta^3$, con $-\alpha^3 T_N + \beta^3 T_D = -0{,}00796 + 0{,}00540 = -0{,}00256 < 0$; resta en $\delta > 0$ y suma en $\delta < 0$.

Resultado. **exceso exacto** 0,0405 **nats con** $4N_{\text{opt}}$ **y** 0,0429 **con** $N_{\text{opt}}/4$**; la aproximación cuadrática da** 0,0410 **en ambos.** Equivocarse por exceso en el tamaño cuesta algo menos que por defecto, porque $\alpha > \beta$.

Comprobación. $\delta^3/6 \cdot (-0{,}00256) = \mp 0{,}00114$, y $0{,}0410 - 0{,}0011 = 0{,}0399$ y $0{,}0410 + 0{,}0011 = 0{,}0421$ se acercan a los valores exactos; el resto lo aportan los términos de orden 4.

Solución del ejercicio 4.5

Datos. $N_{\text{opt}} = G(C/6)^a$, $a = \beta/(\alpha+\beta)$; $D_{\text{opt}} = (C/6)/N_{\text{opt}}$; $\alpha = 0{,}34$, $\beta = 0{,}28$.

Planteamiento. dividir la fórmula en $4C$ entre la fórmula en C; G y el factor $1/6$ se cancelan.

Desarrollo.

1. $N_{\text{opt}}(4C)/N_{\text{opt}}(C) = G(4C/6)^a / \big(G(C/6)^a\big) = 4^a$.
2. $D_{\text{opt}} = G^{-1}(C/6)^{1-a}$, porque $x/x^a = x^{1-a}$; del mismo modo, $D_{\text{opt}}(4C)/D_{\text{opt}}(C) = 4^{1-a}$.
3. $1 - a = (\alpha + \beta - \beta)/(\alpha+\beta) = \alpha/(\alpha+\beta)$.
4. $a = 0{,}45161$ y $1 - a = 0{,}54839$; $\log_{10} 4 = 0{,}60206$.
5. $4^{0{,}45161} = 10^{0{,}27190} = 1{,}870$; $4^{0{,}54839} = 10^{0{,}33017} = 2{,}139$.

Resultado. N_{opt} **se multiplica por** $4^{\beta/(\alpha+\beta)} \approx 1{,}870$ **y** D_{opt} **por** $4^{\alpha/(\alpha+\beta)} \approx 2{,}139$**.**

Comprobación. $1{,}870 \cdot 2{,}139 = 4{,}000$, como exige $6N_{\text{opt}}D_{\text{opt}} = C$.

Solución del ejercicio 4.6

Datos. $N_{\text{opt}} = Gc^a$, $D_{\text{opt}} = G^{-1}c^b$, $c = C/6$; valores de Chinchilla; del ejercicio 4.3, $T_N + T_D = 0{,}4486$ en 10^{22}.

Planteamiento. seguir la demostración del corolario 4.6 conservando las constantes.

Desarrollo.

1. $AN_{\text{opt}}^{-\alpha} = AG^{-\alpha}c^{-\gamma}$ y $BD_{\text{opt}}^{-\beta} = BG^{\beta}c^{-\gamma}$, con $\gamma = \alpha a = \beta b = \alpha\beta/(\alpha+\beta)$.
2. $L^* - E = (AG^{-\alpha} + BG^{\beta})c^{-\gamma} = (AG^{-\alpha} + BG^{\beta})\,6^{\gamma}\,C^{-\gamma}$, luego $K = (AG^{-\alpha} + BG^{\beta})\,6^{\gamma}$.
3. $\gamma = 0{,}0952/0{,}62 = 0{,}15355$. $G^{-\alpha} = 1{,}3447^{-0{,}34} = 0{,}9042$ y $G^{\beta} = 1{,}3447^{0{,}28} = 1{,}0865$; $AG^{-\alpha} = 367{,}47$ y $BG^{\beta} = 446{,}21$; suma 813,68; $6^{\gamma} = 1{,}3167$; $K = 1071{,}4$.
4. En 10^{22}: $C^{-\gamma} = 10^{-22 \cdot 0{,}15355} = 4{,}187 \cdot 10^{-4}$, y $KC^{-\gamma} = 0{,}4486$.
5. De 10^{22} a 10^{24}: factor $100^{-\gamma} = 10^{-0{,}30710} = 0{,}4931$; exceso $0{,}4486 \cdot 0{,}4931 = 0{,}2212$.
6. Directamente en 10^{24}: $N_{\text{opt}} = 4{,}130 \cdot 10^{10}$, $D_{\text{opt}} = 4{,}036 \cdot 10^{12}$, $T_N = 0{,}0999$, $T_D = 0{,}1213$; suma 0,2212.

Resultado. $K = (AG^{-\alpha} + BG^{\beta})6^{\gamma} \approx 1071$**,** $\gamma \approx 0{,}154$**. Con** 100 **veces más cómputo, el exceso pasa de** 0,449 **a** 0,221 **nats (factor** 0,493**).**

Comprobación. el cálculo directo del paso 6 coincide con la ley del paso 5, y el valor de $KC^{-\gamma}$ en 10^{22} reproduce la suma $T_N + T_D$ del ejercicio 4.3.

Solución del ejercicio 4.7

Datos. $f(N, D) = AN^{-\alpha} + BD^{-\beta}$; restricción $6ND \leq C$; $T_N = 0{,}2026$, $T_D = 0{,}2460$, $\gamma = 0{,}15355$ en $C = 10^{22}$.

Planteamiento. cambio de variables logarítmico [3, §4.5]; condiciones KKT [3, §5.5]; comparación con el corolario 4.6.

Desarrollo.

1. (a) Con $N = e^u$, $D = e^v$: minimizar $\tilde{f}(u, v) = Ae^{-\alpha u} + Be^{-\beta v}$ sujeto a $u + v - \ln(C/6) \leq 0$. Cada sumando es la exponencial, convexa y creciente, de una función afín, luego convexo; la suma es convexa. La restricción es afín. El problema es convexo.
2. (b) Si en un punto factible la restricción no fuera activa, $u + v < \ln(C/6)$, aumentar u ligeramente seguiría siendo factible y reduciría estrictamente $Ae^{-\alpha u}$. Luego en el óptimo $u + v = \ln(C/6)$, es decir, $6ND = C$.
3. (c) En las variables originales, KKT: $\nabla f + \mu \nabla(6ND - C) = 0$, $\mu \geq 0$, $\mu(6ND - C) = 0$. Las componentes dan $-\alpha AN^{-\alpha-1} + 6\mu D = 0$ y $-\beta BD^{-\beta-1} + 6\mu N = 0$, que son las del teorema 4.3 con $\lambda = \mu$. De la primera, $\mu = \alpha AN^{-\alpha}/(6ND) = \alpha T_N/C > 0$, compatible con la restricción activa. Como el problema transformado es convexo, estas condiciones son suficientes.
4. Numéricamente, $\mu C = \alpha T_N = 0{,}34 \cdot 0{,}2026 = 0{,}0689$.
5. (d) Por el corolario 4.6, $dL^*/d\ln C = -\gamma K C^{-\gamma} = -\gamma(T_N + T_D)$. Como $T_D = (\alpha/\beta)T_N$, $\gamma(T_N + T_D) = \gamma T_N(\alpha + \beta)/\beta = \alpha T_N = \mu C$. Luego $dL^*/d\ln C = -\mu C$, es decir, $dL^*/dC = -\mu$.
6. Con los datos: $\gamma(T_N + T_D) = 0{,}15355 \cdot 0{,}4486 = 0{,}0689$.

Resultado. **el problema es convexo en $(\ln N, \ln D)$; la restricción es activa; el punto del teorema 4.3 satisface KKT con $\mu = \alpha T_N/C > 0$, y μ es el ritmo al que baja la pérdida óptima por unidad de cómputo: $dL^*/d\ln C = -0{,}0689$ nats en 10^{22} FLOP.**

Comprobación. duplicar el cómputo ($\Delta \ln C = 0{,}693$) debería reducir la pérdida en unos $0{,}0689 \cdot 0{,}693 = 0{,}048$ nats; el corolario 4.6 da $0{,}4486 \cdot (1 - 2^{-0{,}15355}) = 0{,}4486 \cdot 0{,}1009 = 0{,}0453$, del mismo orden (la diferencia procede de la curvatura).

A.5 Tema 5

Solución del ejercicio 5.1

Datos. coste de entrenamiento $6ND$; coste de inferencia $2N$ por token servido.

Planteamiento. comparar costes totales (proposición 5.7).

Desarrollo.

1. El óptimo de Chinchilla minimiza solo $6ND$ para una pérdida dada. Un modelo menor necesita más tokens para igualar la pérdida, y su entrenamiento cuesta más (proposición 5.8).
2. Pero cada token servido cuesta $2N$: un modelo la mitad de grande ahorra la mitad del cómputo de inferencia, para siempre. Con millones de usuarios, T_{inf} supera enseguida el umbral T^* de la proposición 5.7.

3. Además, un modelo menor requiere menos memoria y responde con menos latencia.
4. El óptimo de Chinchilla es preferible cuando el modelo se usará poco (un experimento, un prototipo, un modelo de investigación) o cuando el cuello de botella es el cómputo de entrenamiento disponible.

Resultado. **porque el coste total incluye $2NT_{\text{inf}}$, que domina con mucha demanda; el óptimo de Chinchilla conviene cuando se servirán pocos tokens.**

Comprobación. en el ejemplo 5.9, el sobrecoste se amortiza tras $1{,}1 \cdot 10^{11}$ tokens: 10^6 usuarios que generan 10^5 tokens cada uno ya lo superan.

Solución del ejercicio 5.2

Datos. la tabla de nueve entrenamientos en tres presupuestos.

Planteamiento. mínimo de cada perfil; recta en $(\log_{10} C, \log_{10} N_{\text{opt}})$; $D = C/(6N)$.

Desarrollo.

1. Mínimos: $10^{18} \to 5 \cdot 10^7$ (3,85); $10^{19} \to 1{,}6 \cdot 10^8$ (3,40); $10^{20} \to 5 \cdot 10^8$ (3,01).
2. $x = 18, 19, 20$; $y = 7{,}69897;\ 8{,}20412;\ 8{,}69897$; $\bar{x} = 19$; $\bar{y} = 24{,}60206/3 = 8{,}20069$.
3. Pendiente: numerador $(-1)(-0{,}50172) + 0 + (1)(0{,}49828) = 1{,}00000$; denominador 2; $a = 0{,}5$.
4. Ordenada: $b_0 = 8{,}20069 - 0{,}5 \cdot 19 = -1{,}29931$.
5. $C = 10^{23}$: $\log_{10} N = 10{,}20069$; $N = 1{,}587 \cdot 10^{10}$; $D = 10^{23}/(9{,}522 \cdot 10^{10}) = 1{,}050 \cdot 10^{12}$; $D/N = 66{,}1$.
6. $C = 10^{24}$: $\log_{10} N = 10{,}70069$; $N = 5{,}020 \cdot 10^{10}$; $D = 3{,}320 \cdot 10^{12}$; $D/N = 66{,}1$.

Resultado. $N_{\text{opt}} \propto C^{0{,}5}$**. En** 10^{23}**:** $N \approx 1{,}59 \cdot 10^{10}$**,** $D \approx 1{,}05 \cdot 10^{12}$**; en** 10^{24}**:** $N \approx 5{,}02 \cdot 10^{10}$**,** $D \approx 3{,}32 \cdot 10^{12}$**; unos** 66 **tokens por parámetro, más que la regla de 20 en estos datos sintéticos.**

Comprobación. con $a = 0{,}5$, N y D crecen como $\sqrt{C}$ y D/N es constante: sale 66 en ambos presupuestos; además, $6 \cdot 1{,}587 \cdot 10^{10} \cdot 1{,}050 \cdot 10^{12} = 1{,}000 \cdot 10^{23}$.

Solución del ejercicio 5.3

Datos. $C = 10^{19}$; $x = (8{,}0;\ 8{,}3;\ 8{,}6)$, $h = 0{,}3$; $L = (3{,}47;\ 3{,}40;\ 3{,}43)$.

Planteamiento. proposición 5.3; $D = C/(6N)$.

Desarrollo.

1. $\Delta_2 = 3{,}47 - 6{,}80 + 3{,}43 = 0{,}10 > 0$; $L_3 - L_1 = -0{,}04$.
2. $x^* = 8{,}3 - 0{,}3 \cdot (-0{,}04)/(2 \cdot 0{,}10) = 8{,}3 + 0{,}06 = 8{,}36$; $N_{\text{opt}} = 10^{8{,}36} = 2{,}291 \cdot 10^8$.
3. $L^* = 3{,}40 - 0{,}0016/0{,}8 = 3{,}398$.
4. $D_{\text{opt}} = 10^{19}/(6 \cdot 2{,}291 \cdot 10^8) = 7{,}275 \cdot 10^9$; $D_{\text{opt}}/N_{\text{opt}} = 31{,}8$.
5. El criterio del mínimo observado daría $10^{8{,}3} = 1{,}995 \cdot 10^8$, un 13 % menos.

Resultado. **vértice en** $\log_{10} N = 8{,}36$**:** $N_{\text{opt}} \approx 2{,}29 \cdot 10^8$**,** $L^* \approx 3{,}398$**,** $D_{\text{opt}} \approx 7{,}3 \cdot 10^9$ **(32 tokens por parámetro). El mínimo observado da** $2{,}0 \cdot 10^8$**.**

Comprobación. la parábola $p(t) = 3{,}40 - 0{,}02t + 0{,}05t^2$ pasa por los tres puntos ($p(-1) = 3{,}47$, $p(1) = 3{,}43$) y su mínimo, en $t^* = 0{,}2$, vale $3{,}40 - 0{,}004 + 0{,}002 = 3{,}398$. El vértice se desplaza hacia el lado de la pérdida menor ($L_3 < L_1$).

Solución del ejercicio 5.4

Datos. $U = 10^{11}$; $R^* = 15{,}39$; entrenamientos de $4 \cdot 10^{11}$ y $1{,}6 \cdot 10^{12}$ tokens.

Planteamiento. épocas $= D/U$; $R =$ épocas -1; $D' = U\big(1 + R^*(1 - e^{-R/R^*})\big)$.

Desarrollo.

1. Primer entrenamiento: 4 épocas, $R = 3$; $R/R^* = 0{,}1949$; $1 - e^{-0{,}1949} = 0{,}1771$; $D' = 10^{11}(1 + 15{,}39 \cdot 0{,}1771) = 3{,}726 \cdot 10^{11}$; fracción $3{,}726/4 = 0{,}931$.
2. Segundo: 16 épocas, $R = 15$; $R/R^* = 0{,}9748$; $1 - e^{-0{,}9748} = 0{,}6227$; $D' = 10^{11}(1 + 15{,}39 \cdot 0{,}6227) = 1{,}058 \cdot 10^{12}$; fracción $1{,}058/1{,}6 = 0{,}661$.
3. Máximo: $U(1 + R^*) = 1{,}639 \cdot 10^{12}$ (proposición 5.11).

Resultado. $D' = 3{,}73 \cdot 10^{11}$ **(93 % de lo procesado) con** 4 **épocas y** $D' = 1{,}06 \cdot 10^{12}$ **(66 %) con** 16**; el máximo alcanzable es** $1{,}64 \cdot 10^{12}$ **tokens efectivos.**

Comprobación. cuadruplicar el entrenamiento de 4 a 16 épocas solo multiplica los datos efectivos por $1{,}058/0{,}3726 = 2{,}84$: el rendimiento marginal decrece, como exige la concavidad de la proposición 5.11.

Solución del ejercicio 5.5

Datos. $C = 10^{22}$; del ejercicio 4.3, $N_1 = 5{,}1605 \cdot 10^9$, $L_1 = 2{,}13861$; $N_2 = N_1/2$; inferencia $2N$ por token.

Planteamiento. despejar D_2 de $L(N_2, D_2) = L_1$; $C_2 = 6N_2D_2$; T^* de la proposición 5.7 con $6N_1D_1 = C$. Se usan cinco cifras porque el exponente $1/0{,}28 = 3{,}571$ amplifica los errores.

Desarrollo.

1. $N_2 = 2{,}5802 \cdot 10^9$; $\log_{10} N_2 = 9{,}41165$; $N_2^{0{,}34} = 10^{3{,}19996} = 1584{,}7$; $A/N_2^{\alpha} = 0{,}25645$.
2. $B/D_2^{\beta} = 2{,}13861 - 1{,}69 - 0{,}25645 = 0{,}19216$.
3. $D_2^{0{,}28} = 410{,}7/0{,}19216 = 2137{,}3$; $\log_{10} D_2 = 3{,}32986/0{,}28 = 11{,}89236$; $D_2 = 7{,}803 \cdot 10^{11}$.
4. Tokens por parámetro: $7{,}803 \cdot 10^{11}/2{,}5802 \cdot 10^9 = 302$.
5. $C_2 = 6 \cdot 2{,}5802 \cdot 10^9 \cdot 7{,}803 \cdot 10^{11} = 1{,}208 \cdot 10^{22}$; sobrecoste $2{,}08 \cdot 10^{21}$ FLOP.
6. Ahorro por token servido: $2(N_1 - N_2) = 5{,}160 \cdot 10^9$ FLOP; $T^* = 2{,}08 \cdot 10^{21}/5{,}160 \cdot 10^9 = 4{,}03 \cdot 10^{11}$ tokens.
7. proposición 5.8 con $\kappa = 1/2$: $C_2/C = 1{,}208$, igual que en el paso 5.

Resultado. $D_2 \approx 7{,}80 \cdot 10^{11}$ **tokens (302 por parámetro); el entrenamiento cuesta** 1,208 **veces más (**$+2{,}08 \cdot 10^{21}$ **FLOP) y se amortiza tras unos** $4{,}0 \cdot 10^{11}$ **tokens de inferencia.**

Comprobación. sustituyendo, $1{,}69 + 0{,}25645 + 410{,}7/2137{,}3 = 1{,}69 + 0{,}25645 + 0{,}19216 = 2{,}13861 = L_1$. El sobrecoste relativo es el mismo que a 10^{21} FLOP (ejemplo 5.9), como predice la proposición 5.8; el umbral de amortización, en cambio, escala con el presupuesto.

Solución del ejercicio 5.6

Datos. $D' = U + UR^*(1 - e^{-R/R^*})$, $R \geq 0$.

Planteamiento. acotar $1 - e^{-x}$ entre $x - x^2/2$ y x para $x \geq 0$.

Desarrollo.

1. Sea $\psi(x) = x - (1 - e^{-x})$. $\psi(0) = 0$ y $\psi'(x) = 1 - e^{-x} \geq 0$: $1 - e^{-x} \leq x$.
2. Sea $\chi(x) = (1 - e^{-x}) - x + x^2/2$. $\chi(0) = 0$ y $\chi'(x) = e^{-x} - 1 + x \geq 0$ por el paso 1 aplicado a $e^{-x} \geq 1 - x$: $1 - e^{-x} \geq x - x^2/2$.
3. Con $x = R/R^*$ y multiplicando por $UR^* > 0$: $UR - UR^2/(2R^*) \leq UR^*(1 - e^{-R/R^*}) \leq UR$. Sumando U se obtiene la doble desigualdad.
4. Dividiendo por $U(1 + R)$: $1 - D'/(U(1 + R)) \leq R^2/\big(2R^*(1 + R)\big) \leq R/(2R^*)$, porque $R/(1 + R) \leq 1$.
5. Cuatro épocas ($R = 3$): cota $3/(2 \cdot 15{,}39) = 0{,}0975$ (la intermedia, $9/(2 \cdot 15{,}39 \cdot 4) = 0{,}0731$); valor exacto $1 - 0{,}9314 = 0{,}0686$.

Resultado. $U(1 + R) - UR^2/(2R^*) \leq D' \leq U(1 + R)$**; la pérdida de valor es a lo sumo** $R/(2R^*)$**: un** $9{,}8\,\%$ **con cuatro épocas, frente al** $6{,}9\,\%$ **exacto.**

Comprobación. con $R = 3$, la cota inferior da $4 - 0{,}2924 = 3{,}708$ (en unidades de U), y el valor exacto, 3,726, está entre ella y 4.

A.6 Tema 6

Solución del ejercicio 6.1

Datos. una afirmación de emergencia a partir de 10^{10} parámetros.

Planteamiento. aplicar el argumento de la métrica (proposición 6.2) y las precauciones experimentales habituales.

Desarrollo.

1. *La métrica.* Si es exactitud exacta sobre respuestas de k tokens, vale p^k: con $k = 10$, pasar de $p = 0{,}8$ a 0,95 lleva la exactitud de 0,107 a 0,599. Hay que repetir la medida con una métrica continua (log-probabilidad de la respuesta correcta, distancia de edición). Si la curva es suave, el salto lo crea la métrica.
2. *La resolución.* Con tres o cuatro tamaños de modelo, cualquier curva en S parece un escalón. Hacen falta tamaños intermedios y varias semillas para estimar barras de error.
3. *La contaminación.* Un modelo mayor memoriza más; si la tarea aparece en el corpus, puede «aprobar» por haber visto las respuestas.

Resultado. **comprobaría la métrica (todo o nada frente a continua), la densidad de tamaños con su incertidumbre y la contaminación del corpus.**

Comprobación. con la tabla del tema 6, pasar de $p = 0{,}8$ a 0,9 con $k = 10$ multiplica la exactitud por $0{,}349/0{,}107 \approx 3{,}3$, mientras que p solo crece un $12{,}5\,\%$.

Solución del ejercicio 6.2

Datos. k tokens independientes con probabilidad de acierto p.

Planteamiento. exactitud p^k (independencia); número esperado de aciertos kp (esperanza de una binomial).

Desarrollo.

1. (a) $p^{10} = 0{,}5 \iff p = 0{,}5^{1/10} = 0{,}9330$. Con $k = 20$: $p = 0{,}5^{1/20} = 0{,}9659$.
2. (b) $0{,}9^{10} = 0{,}3487$ y $0{,}8^{10} = 0{,}1074$; cociente $(0{,}9/0{,}8)^{10} = 1{,}125^{10} = 3{,}247$.
3. (c) kp pasa de 8 a 9: un 12,5 % más, el mismo aumento relativo que p.

Resultado. **(a)** $p \approx 0{,}933$ **con** $k = 10$ **y** $p \approx 0{,}966$ **con** $k = 20$**; (b) la exactitud se multiplica por** 3,25**; (c) los aciertos esperados crecen un** 12,5 % **(de** 8 **a** 9**).**

Comprobación. $0{,}9330^{10} = 0{,}500$; la respuesta más larga exige una p mayor para la misma exactitud, coherente con el desplazamiento del umbral de la proposición 6.2.

Solución del ejercicio 6.3

Datos. $N = 1{,}3 \cdot 10^{10}$; $L = 40$; $d = 5120$.

Planteamiento. coste por token $2N + 4Ln_{\text{ctx}}d$ (módulo 14); umbral $n^* = N/(2Ld)$.

Desarrollo.

1. (a) $n^* = 1{,}3 \cdot 10^{10}/(2 \cdot 40 \cdot 5120) = 1{,}3 \cdot 10^{10}/409\,600 = 31\,738$ tokens.
2. (b) $n_{\text{ctx}} = 8192$: $4 \cdot 40 \cdot 8192 \cdot 5120 = 6{,}711 \cdot 10^9$; $2N = 2{,}6 \cdot 10^{10}$; fracción $6{,}711/(26 + 6{,}711) = 0{,}205$.
3. $n_{\text{ctx}} = 131\,072$: $1{,}074 \cdot 10^{11}$; fracción $1{,}074/(0{,}26 + 1{,}074) = 0{,}805$.

Resultado. **(a) a partir de unos** 31 700 **tokens; (b) la atención es el** 20,5 % **del coste por token con** 8192 **tokens y el** 80,5 % **con** 131 072**.**

Comprobación. el término de atención es lineal en n_{ctx}: $131\,072/8192 = 16$ y $16 \cdot 6{,}711 \cdot 10^9 = 1{,}074 \cdot 10^{11}$.

Solución del ejercicio 6.4

Datos. $L = 40$; $h_{kv} = 40$, $d_k = 128$ ($h_{kv}d_k = 5120$); bf16, $\beta_b = 2$.

Planteamiento. proposición 6.5; 1 MiB $= 2^{20}$ bytes y 1 GiB $= 2^{30}$ bytes.

Desarrollo.

1. (a) Por token: $2 \cdot 40 \cdot 5120 \cdot 2 = 819\,200$ bytes $= 0{,}78125$ MiB.
2. (b) 32 768 tokens: $819\,200 \cdot 32\,768 = 26\,843\,545\,600$ bytes $= 25$ GiB. Lote de 8: 200 GiB.
3. (c) Con $h_{kv} = 8$, la caché se multiplica por $8/40 = 1/5$: 5 GiB por secuencia.

Resultado. **(a)** 0,78 **MiB por token; (b)** 25 **GiB por secuencia y** 200 **GiB por lote; (c)** 5 **GiB con GQA de** 8 **cabezas.**

Comprobación. $819\,200 = 0{,}78125 \cdot 2^{20}$ y $0{,}78125 \cdot 32\,768 = 25\,600$ MiB $= 25$ GiB: la caché de una sola secuencia larga supera ya la mitad de una GPU de 40 GiB.

Solución del ejercicio 6.5

Datos. $\ell(N) = (10^8/N)^{1/2}$; $A(N) = e^{-k\ell(N)}$.

Planteamiento. evaluar A; usar la proposición 6.2 (ii) para la inflexión; derivar A respecto de $x = \ln N$.

Desarrollo.

1. (a) $k = 5$: $N = 10^8$: $\ell = 1$, $A = e^{-5} = 0{,}0067$. $N = 10^9$: $\ell = 0{,}3162$, $A = e^{-1{,}581} = 0{,}2057$. $N = 10^{10}$: $\ell = 0{,}1$, $A = e^{-0{,}5} = 0{,}6065$. $N = 10^{11}$: $\ell = 0{,}0316$, $A = e^{-0{,}1581} = 0{,}8538$.
2. (b) $N_0 = N_1 k^{1/\theta} = 10^8 k^2$: 10^8, $2{,}5 \cdot 10^9$ y $6{,}25 \cdot 10^{10}$ para $k = 1$, 5 y 25 ($\log_{10} N_0 = 8$; 9,40; 10,80).
3. Con $k \to \lambda k$: $\log_{10} N_0$ pasa de $\log_{10} N_1 + (\log_{10} k)/\theta$ a $\log_{10} N_1 + (\log_{10} k + \log_{10} \lambda)/\theta$: se desplaza $(\log_{10} \lambda)/\theta$ órdenes de magnitud. Con $\lambda = 5$ y $\theta = 1/2$, $2 \log_{10} 5 = 1{,}40$.
4. (c) Por la demostración de la proposición 6.2, $dA/dx = \theta y e^{-y}$ con $y = e^{-\theta(x - x_0)} > 0$. La función ye^{-y} alcanza su máximo, e^{-1}, en $y = 1$; luego $\max dA/dx = \theta/e$, que no depende de k.

Resultado. **(a)** $A = 0{,}007$**;** $0{,}206$**;** $0{,}607$**;** $0{,}854$**; (b) inflexiones en** 10^8**,** $2{,}5 \cdot 10^9$ **y** $6{,}25 \cdot 10^{10}$**; el umbral se desplaza** $(\log_{10} \lambda)/\theta$ **órdenes de magnitud; (c) pendiente máxima** θ/e**.** La «brusquedad» de la transición en escala logarítmica es la misma para cualquier longitud de respuesta: alargar la respuesta solo traslada la curva hacia modelos mayores.

Comprobación. en $N_0 = 2{,}5 \cdot 10^9$ con $k = 5$: $\ell = (1/25)^{1/2} = 0{,}2$ y $A = e^{-1} = 0{,}368$, como exige la proposición 6.2; el valor cae entre los de 10^9 y 10^{10} del apartado (a).

Solución del ejercicio 6.6

Datos. base 10^4; $d_k = 128$; $L_{\text{tr}} = 4096$; $L' = 32\,768$.

Planteamiento. frecuencia más baja $\theta_{63} = \text{base}^{-126/128}$; proposición 6.7; para la base nueva, igualar $L'\theta'_{63} = L_{\text{tr}}\theta_{63}$.

Desarrollo.

1. (a) $\theta_{63} = 10^{-4 \cdot 0{,}984375} = 10^{-3{,}9375} = 1{,}1548 \cdot 10^{-4}$. Ángulo máximo en el entrenamiento: $4096 \cdot 1{,}1548 \cdot 10^{-4} = 0{,}4730$ rad. Sin interpolar, en L': $32\,768 \cdot 1{,}1548 \cdot 10^{-4} = 3{,}784$ rad.
2. (b) Con interpolación, la posición $m < L'$ se sustituye por $m/8$, y el ángulo es $\theta_i m/8 < \theta_i L'/8 = \theta_i L_{\text{tr}}$, dentro del rango visto (proposición 6.7).
3. (c) Se busca b' con $L'(b')^{-126/128} = L_{\text{tr}}\, 10^{-4 \cdot 126/128}$, es decir, $(b'/10^4)^{126/128} = L'/L_{\text{tr}} = 8$, de donde $b' = 10^4 \cdot 8^{128/126} = 10^4 \cdot 8{,}2685 = 82\,685$.
4. Para $i \geq 1$, $\theta'_i = (b')^{-2i/d_k} < 10^{-4 \cdot 2i/d_k} = \theta_i$ porque $b' > 10^4$ y el exponente $-2i/d_k$ es negativo: todas las frecuencias giran más despacio.

Resultado. **(a)** $0{,}473$ **rad en el entrenamiento frente a** $3{,}78$ **rad sin interpolar; (b) con interpolación ningún ángulo supera el rango visto; (c)** $b' \approx 82\,700$**, y con ella todas las frecuencias giran más despacio que con la base original.**

Comprobación. $32\,768 \cdot 82\,685^{-126/128} = 32\,768 \cdot 1{,}4436 \cdot 10^{-5} = 0{,}4730$ rad, el máximo del entrenamiento. A diferencia de la interpolación, aumentar la base no comprime por igual todas las frecuencias: las altas, que ya daban muchas vueltas en el entrenamiento, cambian poco.

Bibliografía

[1] D. P. Bertsekas y J. N. Tsitsiklis. *Introduction to Probability*, 2.ª ed. Athena Scientific, 2008. Texto del curso 6.041 del MIT. §1.5, «Independence».

[2] T. Besiroglu, E. Erdil, M. Barnett y J. You. Chinchilla scaling: A replication attempt. Prepublicación, 2024. https://arxiv.org/abs/2404.10102

[3] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. §4.5 «Geometric programming» y §5.5 «Optimality conditions». https://web.stanford.edu/~boyd/cvxbook/

[4] A. Z. Broder. On the resemblance and containment of documents. En *Proceedings of Compression and Complexity of Sequences*, IEEE, 1997.

[5] T. B. Brown *et al.* Language models are few-shot learners. En *Advances in Neural Information Processing Systems 33 (NeurIPS)*, 2020. https://arxiv.org/abs/2005.14165

[6] S. Chen, S. Wong, L. Chen e Y. Tian. Extending context window of large language models via positional interpolation. Prepublicación, 2023. https://arxiv.org/abs/2306.15595

[7] A. Dubey *et al.* (Llama Team, Meta). The Llama 3 herd of models. Prepublicación, 2024. https://arxiv.org/abs/2407.21783

[8] Gemini Team, Google. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. Informe técnico, 2024. https://arxiv.org/abs/2403.05530

[9] T. Hashimoto y P. Liang. CS336: Language Modeling from Scratch. Stanford University, primavera de 2026. Práctica 3, «Scaling Laws», versión 26.0.5. https://github.com/stanford-cs336/assignment3-scaling

[10] T. Hashimoto y P. Liang. CS336: Language Modeling from Scratch. Stanford University, primavera de 2026. Práctica 4, «Data: Filtering Language Modeling Data», versión 26.0.1. https://github.com/stanford-cs336/assignment4-data

[11] J. Hoffmann, S. Borgeaud, A. Mensch *et al.* Training compute-optimal large language models. En *Advances in Neural Information Processing Systems 35 (NeurIPS)*, 2022. https://arxiv.org/abs/2203.15556

[12] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu y D. Amodei. Scaling laws for neural language models. Prepublicación, 2020. https://arxiv.org/abs/2001.08361

[13] K. Lee, D. Ippolito, A. Nystrom, C. Zhang, D. Eck, C. Callison-Burch y N. Carlini. Deduplicating training data makes language models better. En *Proceedings of ACL*, 2022. https://arxiv.org/abs/2107.06499

[14] J. Leskovec. CS246: Mining Massive Data Sets. Stanford University, invierno de 2026. Clases «Locality-Sensitive Hashing I» y «Locality-Sensitive Hashing II». https://web.stanford.edu/class/cs246/

[15] J. Leskovec, A. Rajaraman y J. D. Ullman. *Mining of Massive Datasets*, 3.ª ed. Cambridge University Press, 2020. Cap. 3, «Finding Similar Items». http://infolab.stanford.edu/~ullman/mmds/ch3n.pdf

[16] P. Liang, T. Hashimoto y C. Ré. CS324: Large Language Models. Stanford University, invierno de 2022. Notas de las clases «Capabilities», «Data» y «Scaling laws». https://stanford-cs324.github.io/winter2022/lectures/

[17] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni y P. Liang. Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12, 2024. https://arxiv.org/abs/2307.03172

[18] N. Muennighoff, A. M. Rush, B. Barak, T. Le Scao, A. Piktus, N. Tazi, S. Pyysalo, T. Wolf y C. Raffel. Scaling data-constrained language models. En *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. https://arxiv.org/abs/2305.16264

[19] G. Penedo *et al.* The RefinedWeb dataset for Falcon LLM: Outperforming curated corpora with web data, and web data only. Prepublicación, 2023. https://arxiv.org/abs/2306.01116

[20] G. Penedo, H. Kydlíček, L. Ben Allal, A. Lozhkov, M. Mitchell, C. Raffel, L. Von Werra y T. Wolf. The FineWeb datasets: Decanting the web for the finest text data at scale. Prepublicación, 2024. https://arxiv.org/abs/2406.17557

[21] B. Peng, J. Quesnelle, H. Fan y E. Shippole. YaRN: Efficient context window extension of large language models. Prepublicación, 2023. https://arxiv.org/abs/2309.00071

[22] J. W. Rae *et al.* Scaling language models: Methods, analysis & insights from training Gopher. Prepublicación, 2021. https://arxiv.org/abs/2112.11446

[23] N. Sardana, J. Portes, S. Doubov y J. Frankle. Beyond Chinchilla-optimal: Accounting for inference in language model scaling laws. Prepublicación, 2023. https://arxiv.org/abs/2401.00448

[24] R. Schaeffer, B. Miranda y S. Koyejo. Are emergent abilities of large language models a mirage? En *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. https://arxiv.org/abs/2304.15004

[25] H. Touvron *et al.* LLaMA: Open and efficient foundation language models. Prepublicación, 2023. https://arxiv.org/abs/2302.13971

[26] H. Touvron *et al.* Llama 2: Open foundation and fine-tuned chat models. Prepublicación, 2023. https://arxiv.org/abs/2307.09288

[27] J. Wei, Y. Tay, R. Bommasani, C. Raffel, B. Zoph, S. Borgeaud, D. Yogatama, M. Bosma, D. Zhou, D. Metzler, E. H. Chi, T. Hashimoto, O. Vinyals, P. Liang, J. Dean y W. Fedus. Emergent abilities of large language models. *Transactions on Machine Learning Research*, 2022. https://arxiv.org/abs/2206.07682

[28] G. Wenzek, M.-A. Lachaux, A. Conneau, V. Chaudhary, F. Guzmán, A. Joulin y E. Grave. CCNet: Extracting high quality monolingual datasets from web crawl data. En *Proceedings of LREC*, 2020. https://arxiv.org/abs/1911.00359