Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase IV · Hito 4 · Examen de hito

Hito 4

Escala, sistemas y arquitecturas modernas

Módulos 16 (preentrenamiento a escala), 17 (hardware y sistemas),
18 (arquitecturas modernas) y 19 (inferencia)

Examen y proyecto de fase

Edición de octubre de 2026

Instrucciones

Este examen evalúa la fase IV del curso: preentrenamiento a escala (módulo 16), hardware y sistemas (módulo 17), arquitecturas modernas (módulo 18) e inferencia (módulo 19). Casi todas las preguntas son estimaciones de orden de magnitud; se valora más el razonamiento, con unidades en cada paso, que el último decimal.

Condiciones

Duración	3 horas.
Material permitido	Calculadora científica no programable y una hoja A4 de fórmulas escrita a mano por ambas caras. No se permiten apuntes, libros ni dispositivos conectados.
Puntuación	100 puntos: Parte A, 40 puntos (20 cuestiones de 2 puntos); Parte B, 60 puntos (6 problemas de 10 puntos).
Aprobado	70 puntos (70 %) o más.
Módulos	M16, M17, M18 y M19 (véase el reparto por módulo en el apéndice II).
Proyecto de fase	Se evalúa aparte sobre 100 puntos (parte C) y se entrega en el plazo que fije el profesor.

Normas

1. En la Parte A hay una sola opción correcta por cuestión. Las respuestas erróneas no restan.
2. En la Parte B deben escribirse las unidades en cada paso. Los resultados finales se dan con tres cifras significativas; los intermedios, con cuatro.
3. Salvo que el enunciado diga otra cosa, se usan los datos de referencia del cuadro 1 y las fórmulas que siguen. Las cifras de hardware son aproximadas y proceden de hojas de especificaciones públicas; las de modelos reales, de sus artículos o fichas técnicas públicas. Los modelos «Cernícalo-MoE», «Halcón-35» y «Alcotán» son inventados.
4. Se toma 1 GB $= 10^9$ bytes y 1 KiB $= 1024$ bytes, 1 GiB $= 2^{30}$ bytes.

Datos de referencia

Fórmulas

$$C \approx 6ND, \qquad t = \frac{C}{n_{\mathrm{d}}\, P_{\mathrm{pico}}\, \mathrm{MFU}}, \qquad c_{\mathrm{kv}} = 2\, L\, n_{\mathrm{kv}}\, d_{\mathrm{h}}\, s \ \text{ bytes por token}, \qquad I^{*} = \frac{P_{\mathrm{pico}}}{B_{\mathrm{mem}}},$$

donde n_{d} es el número de dispositivos, L el número de capas, n_{kv} el de cabezas de clave y valor, d_{h} la dimensión de cada cabeza y s los bytes por número (2 en bf16).

Cuadro 1: Datos de referencia del examen (valores aproximados).

Dato	Valor
NVIDIA H100 SXM	989 TFLOP/s en bf16 densos; 80 GB de HBM3; 3,35 TB/s; hasta 700 W
NVIDIA A100 SXM 80 GB	312 TFLOP/s en bf16 densos; 80 GB; 2 TB/s; 400 W
NVLink (H100, dentro de un nodo de 8 GPU)	$\approx$ 900 GB/s por GPU
InfiniBand entre nodos	$\approx$ 50 GB/s por GPU (400 Gb/s)
Bytes por parámetro con Adam y precisión mixta	16 (2 de pesos, 2 de gradientes y 12 del optimizador)
Ley de Chinchilla (enfoque 3)	$L(N, D) = E + A/N^{\alpha} + B/D^{\beta}$, con $E = 1{,}69$, $A = 406{,}4$, $B = 410{,}7$, $\alpha = 0{,}34$, $\beta = 0{,}28$

Índice

Instrucciones **ii**

A Cuestiones **1**

B Problemas **5**

Problema B.1. El óptimo de Chinchilla a mano 5

Problema B.2. Estimación de Fermi de un entrenamiento 5

Problema B.3. Plan de paralelismo 3D 6

Problema B.4. Mezcla de expertos 7

Problema B.5. Servir un modelo denso 7

Problema B.6. Extrapolar, deduplicar y desconfiar 8

C Proyecto de fase **9**

Informe técnico del modelo «Alcotán» 9

I Soluciones **11**

I.1 Parte A: clave de respuestas 11

I.2 Parte B: soluciones de los problemas 11

I.3 Proyecto: valores de referencia para la corrección 19

II Autoevaluación **20**

II.1 Puntuación por parte y por módulo 20

II.2 Umbral de aprobado 20

II.3 Qué hacer si no se alcanza el umbral 21

Bibliografía **22**

Parte A

Cuestiones

Veinte cuestiones de opción múltiple, de 2 puntos cada una (40 puntos en total). Hay una sola respuesta correcta en cada cuestión y las respuestas erróneas no restan. La clave y su justificación están en el apéndice I.

1. *(2 p)* Número de FLOP necesarios para entrenar un modelo de $3 \cdot 10^9$ parámetros con $6 \cdot 10^{10}$ tokens:

(a) $1{,}8 \cdot 10^{20}$
(b) $3{,}6 \cdot 10^{20}$
(c) $1{,}08 \cdot 10^{21}$
(d) $1{,}08 \cdot 10^{22}$

2. *(2 p)* Según la regla aproximada de Chinchilla de unos 20 tokens por parámetro, ¿cuántos tokens corresponden a un modelo de $8 \cdot 10^9$ parámetros?

(a) $1{,}6 \cdot 10^{11}$
(b) $8 \cdot 10^9$
(c) $4 \cdot 10^{10}$
(d) $1{,}5 \cdot 10^{13}$

3. *(2 p)* Frente a Kaplan *et al.* (2020), Hoffmann *et al.* (Chinchilla, 2022) concluyeron que, para un cómputo fijo, conviene entrenar:

(a) modelos más grandes con menos datos;
(b) con el mismo reparto entre parámetros y datos;
(c) más épocas sobre los mismos datos;
(d) modelos más pequeños con más datos.

4. *(2 p)* Un modelo de $1{,}3 \cdot 10^{10}$ parámetros se entrena con Adam, precisión mixta y ZeRO-3 en 16 GPU. Memoria de estado por GPU, sin contar las activaciones:

(a) 1,6 GB
(b) 13 GB
(c) 26 GB
(d) 208 GB

5. *(2 p)* Intensidad aritmética crítica de la H100 (989 TFLOP/s; 3,35 TB/s), en FLOP/byte:

(a) ≈ 30
(b) ≈ 156
(c) ≈ 295

(d) ≈ 3300

6. *(2 p)* Cota superior de la velocidad de decodificación, con lote 1, de un modelo de $3 \cdot 10^{10}$ parámetros en bf16 en una H100, ignorando la caché KV:

(a) ≈ 56 tokens/s
(b) ≈ 28 tokens/s
(c) ≈ 112 tokens/s
(d) $\approx 16\,500$ tokens/s

7. *(2 p)* Caché KV por token de un modelo con $L = 40$, $n_{\text{kv}} = 8$ y $d_{\text{h}} = 128$, en bf16:

(a) 40 KiB
(b) 80 KiB
(c) 1,25 MiB
(d) 160 KiB

8. *(2 p)* Fracción del tiempo ociosa (burbuja) de un pipeline de GPipe con $p_{\text{e}} = 8$ etapas y $m = 24$ microlotes:

(a) 7,0 %
(b) 22,6 %
(c) 25,0 %
(d) 33,3 %

9. *(2 p)* Grok-1, cuyos pesos se publicaron en 2024, tiene unos $3{,}14 \cdot 10^{11}$ parámetros, y xAI indicó que en cada token se activa alrededor del 25 % de los pesos. Parámetros activos por token, aproximadamente:

(a) $7{,}85 \cdot 10^{10}$
(b) $3{,}9 \cdot 10^{10}$
(c) $1{,}57 \cdot 10^{11}$
(d) $3{,}14 \cdot 10^{11}$

10. *(2 p)* En una capa de mezcla de expertos con enrutado top-2, al pasar de 8 a 64 expertos del mismo tamaño crece:

(a) el número de FLOP por token;
(b) la caché KV;
(c) la memoria de pesos;
(d) la longitud de contexto.

11. *(2 p)* La principal ventaja de la atención de consultas agrupadas (GQA) frente a la atención multicabeza clásica es:

(a) menos FLOP en el MLP;
(b) un contexto ilimitado;
(c) entrenar sin máscara causal;
(d) una caché KV más pequeña.

12. *(2 p)* Atención con ventana deslizante $W = 2048$ en 24 capas apiladas. Campo receptivo teórico aproximado, $L \cdot W$:

(a) 2048 tokens
(b) 49 152 tokens
(c) 24 576 tokens
(d) ilimitado

13. *(2 p)* Cuatro expertos con fracciones de tráfico $f = (0{,}4;\ 0{,}3;\ 0{,}2;\ 0{,}1)$ y probabilidades medias del enrutador $P = (0{,}25;\ 0{,}25;\ 0{,}25;\ 0{,}25)$. Valor de $\mathcal{L}_{\text{bal}} = N \sum_i f_i P_i$:

(a) 1
(b) 0,25
(c) 1,2
(d) 4

14. *(2 p)* ¿Qué afirmación sobre FlashAttention es correcta? (n es la longitud de la secuencia.)

(a) Aproxima la softmax para ir más rápido.
(b) Reduce los FLOP de la atención a $O(n)$.
(c) Es exacta y su memoria adicional en HBM es $O(n)$.
(d) Solo puede usarse en inferencia.

15. *(2 p)* El *prefill* de un prompt largo está limitado sobre todo por:

(a) el ancho de banda de memoria;
(b) la red entre nodos;
(c) el tokenizador;
(d) la capacidad de cómputo.

16. *(2 p)* La decodificación especulativa con la regla de aceptación $\min(1, p/q)$ y remuestreo del residuo:

(a) aproxima la distribución p del modelo objetivo con un error pequeño;
(b) reproduce exactamente la distribución p del modelo objetivo;
(c) solo funciona con decodificación voraz;
(d) reduce la memoria de pesos del modelo objetivo.

17. *(2 p)* Bits por peso en int4 con una escala fp16 por cada grupo de 64 pesos:

(a) 4,25
(b) 4
(c) 4,125
(d) 4,5

18. *(2 p)* Una respuesta de 20 tokens solo cuenta como correcta si acierta todos, y cada token se acierta, de forma independiente, con probabilidad 0,95. La exactitud exacta vale, aproximadamente:

(a) 0,95

(b) 0,60
(c) 0,36
(d) 0,05

19. *(2 p)* PagedAttention (vLLM) aumenta el rendimiento del servicio porque:

(a) reduce los FLOP de la atención;
(b) cuantiza la caché KV;
(c) elimina la fase de *prefill*;
(d) evita reservar para cada petición una caché KV contigua del tamaño máximo.

20. *(2 p)* La utilización de FLOP del modelo (MFU) de un entrenamiento es:

(a) la memoria usada dividida por la memoria total;
(b) los FLOP útiles del modelo por segundo divididos por el rendimiento máximo teórico;
(c) los tokens por segundo y por GPU;
(d) los vatios consumidos por FLOP.

Parte B

Problemas

Seis problemas de 10 puntos cada uno (60 puntos en total). La puntuación de cada apartado figura entre paréntesis. Los problemas marcados con *Fuente* están adaptados de tareas, hojas de problemas o libros de texto de cursos universitarios; el enunciado es de redacción propia y los datos se han cambiado para que puedan resolverse con calculadora. Las soluciones completas están en el apéndice I.

Problema B.1. El óptimo de Chinchilla a mano (M16)

Ejercicio B.1 ⋆⋆⋆ Se usa la ley $L(N, D) = E + A/N^{\alpha} + B/D^{\beta}$ con los valores del cuadro 1 y la restricción $C = 6ND$, con C fijo.

(a) *(3 p)* Demuestre que en el óptimo se cumple $\alpha A/N^{\alpha} = \beta B/D^{\beta}$ e interprete la igualdad en una frase.

(b) *(2 p)* Deduzca que $N_{\text{opt}} = G\,(C/6)^{a}$ con $a = \beta/(\alpha+\beta)$ y $G = \big(\alpha A/(\beta B)\big)^{1/(\alpha+\beta)}$. Calcule a y G.

(c) *(2 p)* Prediga N_{opt} y D_{opt} para $C = 10^{23}$ y para $C = 10^{24}$ FLOP. Para $C = 10^{24}$, calcule además $D_{\text{opt}}/N_{\text{opt}}$ y la pérdida prevista.

(d) *(2 p)* Con $C = 10^{24}$, compare con el reparto de la regla de 20 tokens por parámetro (N, D y pérdida). ¿Cuál de los dos repartos da menor pérdida según la ley? ¿Por cuánto?

(e) *(1 p)* Solo se dispone de $2 \cdot 10^{12}$ tokens únicos y no se quiere repetir épocas. Con $C = 10^{24}$, ¿qué N se usa y cuánta pérdida se pierde frente al óptimo de (c)?

Fuente: apartado (c) adaptado de Stanford CS336, primavera de 2026, tarea 3 («Scaling Laws»), problema `chinchilla_isoflops`, apartados (a) y (b): predicción de N_{opt} y D_{opt} a 10^{23} y 10^{24} FLOP [3]. Aquí se parte de la ley paramétrica en lugar de los perfiles IsoFLOP.

Problema B.2. Estimación de Fermi de un entrenamiento (M16–M17)

Ejercicio B.2 ⋆⋆ Según su ficha técnica pública, Llama 3 70B se entrenó con unos $1{,}5 \cdot 10^{13}$ tokens en GPU H100 [10]. Supóngase $N = 7 \cdot 10^{10}$, 8192 H100, MFU = 40 %, 700 W por GPU, PUE = 1,2 y 2,5 $ por GPU-hora (cifras aproximadas e hipotéticas).

(a) *(1 p)* Calcule el cómputo de entrenamiento C en FLOP.

(b) *(3 p)* Calcule las GPU-horas, los días de reloj, la energía en MWh y el coste en dólares.

(c) *(2 p)* Un modelo con la forma de GPT-2 XL y la arquitectura de los apuntes (RMSNorm, MLP SwiGLU, RoPE, *embeddings* de entrada y salida no compartidos, sin sesgos) tiene vocabulario $V = 50\,257$, contexto de 1024 tokens, $L = 48$ capas, $d = 1600$, 25 cabezas y $d_{\text{ff}} = 4288$. Calcule su número de parámetros entrenables y la memoria para cargarlo en fp32. ¿Cuánto tardaría entrenarlo $4 \cdot 10^5$ pasos con lotes de 1024 secuencias de 1024 tokens en una sola H100 a 495 TFLOP/s (TF32) con MFU = 50 %? Use $C \approx 6ND$, que ignora la atención.

(d) *(2 p)* La ficha pública de Llama 3 70B declara unos $6{,}4 \cdot 10^6$ GPU-horas. ¿Qué MFU efectiva implica? Dé dos razones por las que es menor que el 40 %.

(e) *(2 p)* ¿Cuántos tokens por parámetro usa Llama 3 70B? ¿Qué N y D daría la regla de 20 tokens con el mismo C? Comparando el coste de servir 10^{13} tokens con cada modelo (unos $2N$ FLOP por token), explique por qué tiene sentido «sobreentrenar».

Fuente: apartado (c) adaptado de Stanford CS336, primavera de 2026, tarea 1 («Basics»), problemas `transformer_accounting` (a) y `adamw_accounting` (d) [1].

Problema B.3. Plan de paralelismo 3D (M17)

Ejercicio B.3 ⋆⋆⋆ Se entrena un modelo denso de $\Psi = 7 \cdot 10^{10}$ parámetros y 80 capas en 2048 H100 (256 nodos de 8 GPU) con paralelismo de tensores TP = 8, de etapas PP = 4 y de datos DP = 64, como en la figura B.1. El lote global es de 1024 secuencias de 4096 tokens y el microlote, de una secuencia.

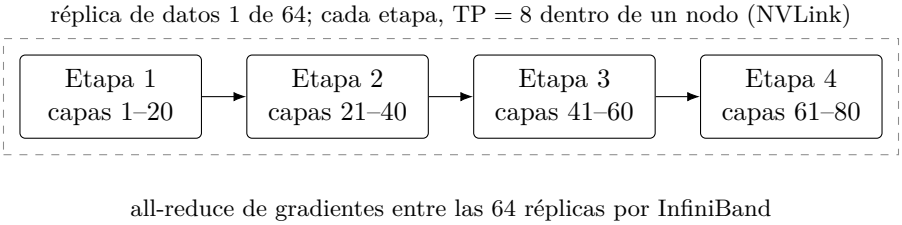


Figura B.1: Plan de paralelismo del ejercicio B.3.

(a) *(1 p)* Compruebe el número de GPU. ¿Por qué TP = 8 y no TP = 16?

(b) *(2 p)* Calcule la memoria de estado por GPU sin ZeRO (16 bytes por parámetro, repartidos solo entre las TP · PP GPU de una réplica). ¿Cabe en 80 GB? ¿Sería viable el paralelismo de datos puro, sin TP ni PP?

(c) *(2 p)* Con ZeRO-1 sobre la dimensión de datos (pesos y gradientes repartidos entre TP · PP; el estado del optimizador, además, entre las DP réplicas), ¿cuánta memoria de estado queda por GPU?

(d) *(2 p)* Calcule los tokens por paso, el número m de microlotes por réplica y la burbuja del pipeline.

(e) *(2 p)* Calcule el tiempo de cómputo de un paso (MFU = 40 %) y el del all-reduce en anillo de los gradientes bf16 de cada GPU entre las 64 réplicas a 50 GB/s. ¿Es la comunicación un cuello de botella? Si se redujera el lote global manteniendo DP = 64,

¿con cuántas secuencias por réplica, como mínimo, quedaría la comunicación por debajo del cómputo?

(f) *(1 p)* ¿Cuántos pasos y cuántos días hacen falta para $1{,}5 \cdot 10^{13}$ tokens?

Fuente: apartado (b) adaptado de Austin *et al.*, *How to Scale Your Model*, parte 5 («Training»), problemas 2 y 3(a) [5]; apartado (e) adaptado de Stanford CS336, primavera de 2026, tarea 2 («Systems»), problema `data_parallel_calcs` (c) [2].

Problema B.4. Mezcla de expertos (M18)

Ejercicio B.4 ⋆⋆ «Cernícalo-MoE» es un modelo inventado con $d = 5120$ y $L = 40$ capas. Cada capa tiene 16 expertos con enrutado top-2; cada experto es un MLP SwiGLU de tres matrices sin sesgos con $d_{\text{ff}} = 8192$. La atención es GQA con 40 cabezas de consulta, $n_{\text{kv}} = 8$ y $d_{\text{h}} = 128$. El vocabulario tiene $V = 64\,000$ tokens, con *embeddings* de entrada y salida no compartidos. En (a) y (b) se ignoran las normalizaciones y el enrutador.

(a) *(2 p)* Calcule los parámetros de un experto, de la atención de una capa y de los *embeddings*. Dé el total, los activos por token y la fracción activa.

(b) *(2 p)* Calcule los FLOP por token en la pasada hacia delante y la memoria de pesos en bf16. ¿Cuántas H100 de 80 GB hacen falta, como mínimo, solo para los pesos? ¿Qué ahorra una MoE respecto a un modelo denso con los mismos parámetros totales y qué no ahorra?

(c) *(2 p)* Para un token, los logits del enrutador son

$$z = (0{,}4;\ 1{,}9;\ -0{,}3;\ 1{,}2;\ 0{,}0;\ 2{,}6;\ 0{,}8;\ -1{,}1;\ 0{,}5;\ 1{,}0;\ -0{,}6;\ 0{,}3;\ 1{,}7;\ -0{,}2;\ 0{,}1;\ 0{,}9).$$

Elija los expertos top-2 y calcule sus pesos g_i, con la softmax restringida a los elegidos (M18, §4.1).

(d) *(2 p)* En un lote, 4 expertos reciben cada uno una fracción $f_i = 0{,}16$ del tráfico con $P_i = 0{,}12$, y los otros 12 reciben $f_i = 0{,}03$ con $P_i = 13/300$. Compruebe que f y P suman 1 y calcule $\mathcal{L}_{\text{bal}} = N \sum_i f_i P_i$. Compárelo con el valor del reparto perfecto.

(e) *(2 p)* Con un lote de 8192 tokens, $k = 2$ y factor de capacidad 1,25, ¿cuántas plazas tiene cada experto? ¿Cuántas asignaciones descarta cada experto saturado del apartado (d)?

Fuente: apartados (a) y (b) adaptados de Austin *et al.*, *How to Scale Your Model*, parte 7 («Inference»), problema 5 (variante MoE de un modelo denso: parámetros totales y activos, caché KV y FLOP) [5].

Problema B.5. Servir un modelo denso (M19)

Ejercicio B.5 ⋆⋆⋆ «Halcón-35» es un modelo denso inventado con $L = 56$, $d = 7168$, 56 cabezas de consulta y GQA con $n_{\text{kv}} = 8$ y $d_{\text{h}} = 128$. Se toma $N = 3{,}5 \cdot 10^{10}$ parámetros. Se sirve en bf16 en 2 H100 con paralelismo de tensores, reservando 10 GB para activaciones y sistema; el ancho de banda agregado es la suma del de las dos GPU, y el rendimiento de cómputo, también.

(a) *(2 p)* Compruebe que $12Ld^2$ se acerca a N. Calcule la memoria de pesos, la memoria libre para la caché KV, la caché por token y la caché de una secuencia de 8192 tokens.

(b) *(2 p)* ¿Cuántas secuencias de 8192 tokens caben? ¿Y si el modelo usara atención multicabeza clásica, con 56 cabezas de clave y valor?

(c) *(3 p)* Calcule el tiempo por paso de decodificación y los tokens/s (totales y por usuario) en dos casos: (i) lote 1 con 8192 tokens de contexto; (ii) lote 32 con 4096 tokens de contexto cada uno. Compruebe que en (ii) el cómputo no limita. Ignorando la caché KV, ¿a partir de qué lote pasaría la decodificación a estar limitada por el cómputo? ¿Cabría ese lote, con 4096 tokens por secuencia?

(d) *(1 p)* Calcule el tiempo hasta el primer token de un prompt de 4000 tokens con MFU = 50 % en el *prefill*.

(e) *(2 p)* Con pesos int4 en grupos de 64 con escala fp16, ¿cuál es la cota de tokens/s del caso (i)? Si además se usa decodificación especulativa con tasa de aceptación $\alpha = 0{,}75$, $\gamma = 5$ propuestas por ronda y un borrador que cuesta el 4 % de una pasada del modelo, ¿qué aceleración adicional cabe esperar?

Fuente: apartados (a)–(c) adaptados de Austin *et al.*, *How to Scale Your Model*, parte 7 («Inference»), problemas 1 a 3 (caché KV por token, lote máximo y tiempo de lectura de los pesos), y parte 1 («Rooflines»), problema 5 (lote crítico de la H100) [5].

Problema B.6. Extrapolar, deduplicar y desconfiar (M16)

Ejercicio B.6 ⋆⋆

(a) *(4 p)* Dos entrenamientos pequeños dan pérdida 3,2 con $C = 10^{20}$ FLOP y 2,6 con $C = 10^{22}$. Supóngase $L(C) = 1{,}7 + k\,C^{-b}$. Calcule b, prediga $L(10^{24})$ y calcule el cómputo necesario para reducir a la mitad el exceso sobre 1,7 respecto al de 10^{22}.

(b) *(3 p)* Se deduplica con MinHash y LSH por bandas con una firma de 128 valores: $b = 16$ bandas de $r = 8$ filas. Calcule $P(\text{candidato}) = 1 - (1 - s^r)^b$ para $s = 0{,}5$, 0,7 y 0,9; el umbral aproximado $(1/b)^{1/r}$, y el umbral exacto $s_{1/2}$, en el que $P = 1/2$. ¿Es más o menos estricto que la configuración $r = 5$, $b = 20$ de los apuntes? ¿Qué tipo de error aumenta?

(c) *(3 p)* Una respuesta de $k = 20$ tokens solo puntúa si acierta todos. Para $p = 0{,}9$, 0,95, 0,98 y 0,995 por token, calcule la exactitud exacta p^{20} y la log-probabilidad de la respuesta correcta, $20 \ln p$. Compare la forma de las dos curvas y explique la tesis de Schaeffer, Miranda y Koyejo (2023).

Fuente: apartado (b) adaptado de Leskovec, Rajaraman y Ullman, *Mining of Massive Datasets*, 3.ª ed., ejercicios 3.4.1 y 3.4.2, libro de texto de Stanford CS246 [6, 7]; el procedimiento (firmas MinHash, bandas LSH y verificación de la similitud de Jaccard de los candidatos) es el del problema `minhash_deduplication` de la tarea 4 de Stanford CS336, primavera de 2026 [4].

Parte C

Proyecto de fase

Informe técnico del modelo «Alcotán»

Objetivo. El estudiante actúa como equipo de sistemas de un laboratorio ficticio y debe proponer y justificar el modelo Alcotán: cuánto cómputo hay disponible, qué tamaño y cuántos datos usar, cómo repartir el entrenamiento en el clúster y cómo servir el modelo. Alcotán es un modelo inventado; ninguna de sus cifras debe atribuirse a un modelo real. El proyecto integra los cuatro módulos de la fase: leyes de escalado (M16), sistemas (M17), arquitectura (M18) e inferencia (M19).

Restricciones.

- Clúster: 2048 H100 (256 nodos de 8 GPU, NVLink dentro del nodo e InfiniBand entre nodos) durante 60 días, con una MFU objetivo del 40 % (cifras aproximadas).
- Electricidad: 700 W por GPU y PUE = 1,2. Precio de alquiler: 2,5 $ por GPU-hora.
- Servicio: al menos 30 tokens/s por usuario con 64 usuarios simultáneos y 4096 tokens de contexto, en un nodo de 8 H100.
- Datos: $1{,}2 \cdot 10^{13}$ tokens únicos tras filtrar y deduplicar.

Entregables.

1. Informe de 6 a 10 páginas (PDF o Markdown) con las secciones: resumen, presupuesto de cómputo, tamaño óptimo, arquitectura, plan de paralelismo, plan de servicio y riesgos.
2. Cuaderno o *script* de Python que reproduzca todas las cifras del informe.
3. Al menos dos diagramas: el plan de paralelismo y la arquitectura del bloque.
4. Una tabla resumen final con N, D, C, GPU-horas, días, MWh, coste y tokens/s servidos.

Pasos sugeridos.

1. Calcular C a partir del clúster. Hallar el óptimo con la ley de Chinchilla (M16, §4.3) y con la regla de 20 tokens (M16, §4.5), y discutir la diferencia.
2. Decidir N y D finales teniendo en cuenta el coste de inferencia (M16, §5.3), el límite de tokens únicos y el número de épocas aceptable (M16, §5.4) y la restricción de servicio.
3. Elegir la arquitectura: d, L, cabezas, n_{kv}, d_{ff}; modelo denso o MoE (M18, §1.3, §2.3 y §4.2). Comprobar que $N \approx 12Ld^2$ cuadra con la elección, o su equivalente MoE.
4. Diseñar el paralelismo: TP, PP, DP, etapa de ZeRO y microlotes (M17, §5.3–§5.6). Calcular memoria por GPU, burbuja y tiempo de comunicación por paso.

5. Diseñar el servicio: precisión de los pesos, caché KV, lote máximo y tokens/s (M19, §2.2–§2.4); decidir si se usa cuantización (M19, §4.3) o decodificación especulativa (M19, §3.4).
6. Enumerar los riesgos (fallos de hardware, MFU inferior a la prevista, datos insuficientes, picos de pérdida) y proponer una mitigación para cada uno.

Criterios de evaluación. El proyecto se puntúa sobre 100 puntos con la rúbrica del cuadro C.1. Se aprueba con 70 puntos o más.

Cuadro C.1: Rúbrica del proyecto de fase.

Criterio	Peso	Excelente	Suficiente	Insuficiente
Presupuesto de cómputo, tiempo, energía y coste	20	C, GPU-horas, MWh y coste correctos y reproducibles; análisis de sensibilidad a la MFU	Cifras correctas sin análisis de sensibilidad	Errores de orden de magnitud o de unidades
Tamaño óptimo y datos	20	Compara Chinchilla y la regla de 20; justifica la desviación por inferencia y por datos únicos	Aplica un criterio correctamente	Elige N sin justificar o ignora el límite de tokens únicos
Arquitectura	15	Dimensiones coherentes con N; justifica GQA y la elección entre denso y MoE	Dimensiones coherentes sin discusión	Dimensiones que no cuadran con N
Plan de paralelismo	20	TP, PP, DP y ZeRO justificados por la topología; memoria, burbuja y comunicación calculadas	Plan viable con algún cálculo ausente	Plan que no cabe en memoria o que ignora la red
Plan de servicio	15	Cumple la restricción con cálculo de caché KV y ancho de banda; valora la cuantización	Calcula los tokens/s con alguna simplificación	No comprueba la restricción
Claridad, diagramas y reproducibilidad	10	Informe claro, diagramas útiles y código que reproduce todo	Informe legible y código parcial	Sin código o con cifras sin origen

Calificación del hito. Nota del examen = puntos/10; nota del proyecto = puntos/10. Nota del hito = $0{,}6 \cdot \text{examen} + 0{,}4 \cdot \text{proyecto}$. Para superar el hito hay que obtener al menos un 7 en cada una de las dos partes.

Apéndice I

Soluciones

Los resultados finales se dan con tres cifras significativas y los intermedios con cuatro, para que el redondeo no se acumule. Las remisiones «M16, §4.3» indican el módulo y la sección de sus apuntes. Al final de cada solución figuran, entre corchetes, los criterios de corrección.

I.1 Parte A: clave de respuestas

Cuadro I.1: Clave de la Parte A.

N.º	Resp.	Justificación	Repasar
1	(c)	$6 \cdot 3 \cdot 10^9 \cdot 6 \cdot 10^{10} = 1{,}08 \cdot 10^{21}$ FLOP.	M17, §1.2
2	(a)	$20 \cdot 8 \cdot 10^9 = 1{,}6 \cdot 10^{11}$ tokens.	M16, §4.5
3	(d)	Chinchilla escala N y D casi por igual ($a \approx 0{,}5$); Kaplan daba $a = 0{,}73$.	M16, §5.2
4	(b)	ZeRO-3: $16\Psi/n_{\mathrm{d}} = 16 \cdot 1{,}3 \cdot 10^{10}/16 = 1{,}3 \cdot 10^{10}$ bytes.	M17, §5.6
5	(c)	$I^* = 989 \cdot 10^{12}/(3{,}35 \cdot 10^{12}) = 295{,}2$; 156 es la A100.	M17, §2.2
6	(a)	$B_{\mathrm{mem}}/(sN) = 3{,}35 \cdot 10^{12}/(6 \cdot 10^{10}) = 55{,}8$ tokens/s; los FLOP no intervienen.	M19, §2.3
7	(d)	$2 \cdot 40 \cdot 8 \cdot 128 \cdot 2 = 163\,840$ bytes = 160 KiB.	M19, §2.2
8	(b)	$(p_{\mathrm{e}} - 1)/(m + p_{\mathrm{e}} - 1) = 7/31 = 0{,}2258$.	M17, §5.5
9	(a)	$0{,}25 \cdot 3{,}14 \cdot 10^{11} = 7{,}85 \cdot 10^{10}$.	M18, §4.6
10	(c)	Cada token sigue usando 2 expertos (mismos FLOP), pero hay que guardar los 64.	M18, §4.2
11	(d)	Las cabezas de consulta comparten K y V: la caché se divide por h/n_{kv}.	M18, §2.3
12	(b)	$24 \cdot 2048 = 49\,152$ (el valor exacto es $24 \cdot 2047 + 1 = 49\,129$).	M18, §3.2
13	(a)	Con $P_i = 1/4$: $4 \cdot \frac{1}{4}\sum_i f_i = 1$, aunque f esté desequilibrado.	M18, §4.3
14	(c)	Resultado exacto con $O(n^2 d)$ FLOP y $O(n)$ memoria adicional: no escribe S en HBM.	M17, §3.4
15	(d)	Procesa todas las posiciones a la vez: productos matriz por matriz, de intensidad alta.	M19, §2.1
16	(b)	$\min(p, q) + \max(0, p - q) = p$: el muestreo por rechazo modificado es exacto.	M19, §3.2
17	(a)	$b + b_\Delta/g = 4 + 16/64 = 4{,}25$; 4,125 corresponde a $g = 128$.	M19, §4.3
18	(c)	$0{,}95^{20} = 0{,}3585$.	M16, §6.2
19	(d)	Asigna bloques bajo demanda y elimina la fragmentación; caben lotes mayores.	M19, §6.3
20	(b)	MFU $= 6N\tau/(n_{\mathrm{d}} P_{\mathrm{pico}})$, con τ los tokens/s (definición de PaLM).	M17, §2.5

Las cifras y afirmaciones sobre trabajos concretos proceden de sus fuentes públicas: Kaplan *et al.* [9] y Hoffmann *et al.* [8] (cuestiones 2 y 3), ZeRO [13] (4), FlashAttention [14] (14), el anuncio de Grok-1 [15] (9), Leviathan *et al.* [16] (16), vLLM [17] (19), PaLM [12] (20) y Schaeffer *et al.* [11] (18). Los apuntes de los módulos [18] desarrollan cada resultado.

I.2 Parte B: soluciones de los problemas

Solución del ejercicio B.1

Datos. $L(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ con $E = 1{,}69$, $A = 406{,}4$, $B = 410{,}7$, $\alpha = 0{,}34$, $\beta = 0{,}28$; restricción $C = 6ND$ con C fijo.

Planteamiento. se despeja $D = C/(6N)$, se sustituye en L y se anula la derivada respecto a N (es el teorema de la frontera eficiente, M16, §4.3). Después se evalúa la ley en los repartos pedidos.

Desarrollo.

(a)

1. Con $c = C/6$, $D = c/N$ y $B/D^{\beta} = Bc^{-\beta}N^{\beta}$, luego $L(N) = E + AN^{-\alpha} + Bc^{-\beta}N^{\beta}$.
2. $\dfrac{dL}{dN} = -\alpha AN^{-\alpha-1} + \beta Bc^{-\beta}N^{\beta-1}$. Se iguala a 0 y se multiplica por $N > 0$: $\alpha AN^{-\alpha} = \beta Bc^{-\beta}N^{\beta}$.
3. Como $c^{-\beta}N^{\beta} = (c/N)^{-\beta} = D^{-\beta}$, queda $\alpha A/N^{\alpha} = \beta B/D^{\beta}$.
4. Interpretación: $-N\,\partial L/\partial N = \alpha A/N^{\alpha}$ y $-D\,\partial L/\partial D = \beta B/D^{\beta}$; en el óptimo, aumentar un 1 % los parámetros reduce la pérdida lo mismo que aumentar un 1 % los datos.

(b)

1. De la igualdad del paso 2: $N^{\alpha+\beta} = \dfrac{\alpha A}{\beta B}\,c^{\beta}$, luego $N = \left(\dfrac{\alpha A}{\beta B}\right)^{1/(\alpha+\beta)} c^{\beta/(\alpha+\beta)} = G\,c^{a}$.
2. $\alpha A = 0{,}34 \cdot 406{,}4 = 138{,}2$; $\beta B = 0{,}28 \cdot 410{,}7 = 115{,}0$; cociente 1,2016.
3. $a = 0{,}28/0{,}62 = 0{,}4516$. $\ln 1{,}2016 = 0{,}1836$; $0{,}1836/0{,}62 = 0{,}2962$; $G = e^{0{,}2962} = 1{,}345$.

(c)

1. $C = 10^{24}$: $c = 1{,}667 \cdot 10^{23}$, $\log_{10} c = 23{,}22$; $a \log_{10} c = 10{,}49$; $c^{a} = 3{,}071 \cdot 10^{10}$.
2. $N_{\text{opt}} = 1{,}345 \cdot 3{,}071 \cdot 10^{10} = 4{,}130 \cdot 10^{10}$; $D_{\text{opt}} = c/N_{\text{opt}} = 4{,}036 \cdot 10^{12}$; $D_{\text{opt}}/N_{\text{opt}} = 97{,}7$.
3. $C = 10^{23}$: N_{opt} se divide por $10^{a} = 2{,}829$: $N_{\text{opt}} = 1{,}460 \cdot 10^{10}$ y $D_{\text{opt}} = 1{,}667 \cdot 10^{22}/1{,}460 \cdot 10^{10} = 1{,}142 \cdot 10^{12}$.
4. Pérdida a 10^{24}: $N^{0{,}34} = e^{0{,}34 \cdot 24{,}44} = 4068$, $A/N^{\alpha} = 0{,}09990$; $D^{0{,}28} = e^{0{,}28 \cdot 29{,}03} = 3386$, $B/D^{\beta} = 0{,}1213$; $L = 1{,}69 + 0{,}09990 + 0{,}1213 = 1{,}911$.

(d)

1. $C = 6N \cdot 20N = 120N^{2}$: $N = \sqrt{10^{24}/120} = 9{,}129 \cdot 10^{10}$; $D = 20N = 1{,}826 \cdot 10^{12}$.
2. $A/N^{\alpha} = 406{,}4/5328 = 0{,}07628$; $B/D^{\beta} = 410{,}7/2712 = 0{,}1515$; $L = 1{,}918$.
3. Diferencia: $1{,}9177 - 1{,}9112 = 0{,}0066$.

(e)

1. Con $D = 2 \cdot 10^{12}$: $N = 10^{24}/(6 \cdot 2 \cdot 10^{12}) = 8{,}333 \cdot 10^{10}$.
2. $A/N^{\alpha} = 406{,}4/5165 = 0{,}07868$; $B/D^{\beta} = 410{,}7/2782 = 0{,}1477$; $L = 1{,}916$, es decir, 0,0051 más que el óptimo.

Resultado. (a) $\alpha A/N^{\alpha} = \beta B/D^{\beta}$. (b) $a = 0{,}452$, $G = 1{,}34$. (c) A 10^{23} FLOP, $N_{\text{opt}} \approx 1{,}46 \cdot 10^{10}$ y $D_{\text{opt}} \approx 1{,}14 \cdot 10^{12}$; a 10^{24} FLOP, $N_{\text{opt}} \approx 4{,}13 \cdot 10^{10}$, $D_{\text{opt}} \approx 4{,}04 \cdot 10^{12}$, $D_{\text{opt}}/N_{\text{opt}} \approx 97{,}7$ y $L \approx 1{,}91$. (d) Regla de 20: $N \approx 9{,}13 \cdot 10^{10}$, $D \approx 1{,}83 \cdot 10^{12}$ y $L \approx 1{,}92$; el óptimo gana por solo 0,0066: el mínimo es muy plano (M16, §4.6). (e) $N \approx 8{,}33 \cdot 10^{10}$ y $L \approx 1{,}92$, 0,0051 peor que el óptimo.

Comprobación. en (c), $0{,}34 \cdot 0{,}09990 = 0{,}03397$ y $0{,}28 \cdot 0{,}1213 = 0{,}03396$: se cumple la igualdad de (a); además, $6 \cdot 4{,}130 \cdot 10^{10} \cdot 4{,}036 \cdot 10^{12} = 1{,}000 \cdot 10^{24}$. El término de datos es $0{,}1213/0{,}09990 = 1{,}214 = \alpha/\beta$ veces el de parámetros, como dice el corolario de equilibrio (M16, §4.3). En (e), el punto queda entre el óptimo y la regla de 20, y su pérdida también: $1{,}911 < 1{,}916 < 1{,}918$. La función $\phi(u) = Ae^{-\alpha u} + Bc^{-\beta}e^{\beta u}$, con $u = \ln N$, es estrictamente convexa, así que el punto crítico es el mínimo.

[Criterios: (a) 1 p por sustituir la restricción, 1 p por la derivada y 1 p por la interpretación; se admite la resolución con multiplicadores de Lagrange. (b) 2 p. (c) 1 p por cada presupuesto. (d) 2 p, o 1 p si solo se calculan las cifras. (e) 1 p.]

Repasar: M16, §4.2, §4.3, §4.5 y §4.6.

Solución del ejercicio B.2

Datos. $N = 7 \cdot 10^{10}$; $D = 1{,}5 \cdot 10^{13}$ tokens; 8192 H100 a 989 TFLOP/s; MFU = 0,4; 700 W; PUE = 1,2; 2,5 \$/GPU-hora. GPT-2 XL: $V = 50\,257$, $L = 48$, $d = 1600$, $d_{\text{ff}} = 4288$; 495 TFLOP/s en TF32 con MFU = 0,5.

Planteamiento. $C \approx 6ND$ (M17, §1.2); duración $t = C/(n_{\text{d}} P_{\text{pico}} \text{MFU})$ (M17, §6.1); energía ≈ GPU-horas $\cdot P_{\text{GPU}} \cdot$ PUE (M17, §6.2); coste de inferencia $\approx 2N$ FLOP por token (M16, §5.3).

Desarrollo.

(a)

1. $C = 6 \cdot 7 \cdot 10^{10} \cdot 1{,}5 \cdot 10^{13} = 6{,}3 \cdot 10^{24}$ FLOP.

(b)

1. Rendimiento útil por GPU: $0{,}4 \cdot 989 \cdot 10^{12} = 3{,}956 \cdot 10^{14}$ FLOP/s.
2. GPU-segundos: $6{,}3 \cdot 10^{24}/3{,}956 \cdot 10^{14} = 1{,}593 \cdot 10^{10}$ s; GPU-horas: $1{,}593 \cdot 10^{10}/3600 = 4{,}424 \cdot 10^{6}$.
3. Horas de reloj: $4{,}424 \cdot 10^{6}/8192 = 540{,}0$ h, es decir, 22,50 días.
4. Energía: $4{,}424 \cdot 10^{6}$ h $\cdot\, 0{,}7$ kW $\cdot\, 1{,}2 = 3{,}716 \cdot 10^{6}$ kWh = 3716 MWh.
5. Coste: $4{,}424 \cdot 10^{6} \cdot 2{,}5 = 1{,}106 \cdot 10^{7}$ \$.

(c)

1. *Embeddings* no compartidos: $2Vd = 2 \cdot 50\,257 \cdot 1600 = 160\,822\,400$.
2. Por capa: atención $4d^2 = 10\,240\,000$; MLP SwiGLU $3dd_{\text{ff}} = 3 \cdot 1600 \cdot 4288 = 20\,582\,400$; dos RMSNorm, $2d = 3200$. Suma: 30 825 600.
3. Total: $48 \cdot 30\,825\,600 + 160\,822\,400 + 1600 = 1\,640\,452\,800 \approx 1{,}640 \cdot 10^{9}$ (el último sumando es la RMSNorm final). En fp32: $4 \cdot 1{,}640 \cdot 10^{9} = 6{,}562 \cdot 10^{9}$ bytes.
4. Tokens: $4 \cdot 10^{5} \cdot 1024 \cdot 1024 = 4{,}194 \cdot 10^{11}$. Cómputo: $6 \cdot 1{,}640 \cdot 10^{9} \cdot 4{,}194 \cdot 10^{11} = 4{,}128 \cdot 10^{21}$ FLOP.
5. $t = 4{,}128 \cdot 10^{21}/(0{,}5 \cdot 495 \cdot 10^{12}) = 1{,}668 \cdot 10^{7}$ s = 4633 h = 193,1 días.

(d)

1. GPU-segundos declarados: $6{,}4 \cdot 10^{6} \cdot 3600 = 2{,}304 \cdot 10^{10}$ s; FLOP de pico disponibles: $2{,}304 \cdot 10^{10} \cdot 989 \cdot 10^{12} = 2{,}279 \cdot 10^{25}$.

2. $\mathrm{MFU_{ef}} = 6{,}3 \cdot 10^{24} / 2{,}279 \cdot 10^{25} = 0{,}2765$.

(e)

1. $D/N = 1{,}5 \cdot 10^{13} / 7 \cdot 10^{10} = 214{,}3$ tokens por parámetro, 10,71 veces la regla.
2. Regla de 20 con el mismo C: $N = \sqrt{6{,}3 \cdot 10^{24}/120} = 2{,}291 \cdot 10^{11}$ y $D = 20N = 4{,}583 \cdot 10^{12}$.
3. Servir 10^{13} tokens: $2 \cdot 7 \cdot 10^{10} \cdot 10^{13} = 1{,}4 \cdot 10^{24}$ FLOP con el modelo de 70 000 millones, frente a $2 \cdot 2{,}291 \cdot 10^{11} \cdot 10^{13} = 4{,}583 \cdot 10^{24}$ con el de la regla.

Resultado. (a) $C \approx 6{,}30 \cdot 10^{24}$ FLOP. (b) $4{,}42 \cdot 10^{6}$ GPU-horas, 22,5 días, $\approx$ 3720 MWh y $\approx 1{,}11 \cdot 10^{7}$ \$. (c) $N \approx 1{,}64 \cdot 10^{9}$ parámetros, 6,56 GB en fp32 y $\approx$ 4630 h, unos 193 días en una sola GPU. (d) $\mathrm{MFU_{ef}} \approx 27{,}6\,\%$; razones: la ficha cuenta todo el tiempo de GPU (reinicios tras fallos, puntos de control, evaluaciones y experimentos), la comunicación no solapada, la burbuja del pipeline y los FLOP de la atención y de la fase de contexto largo, que $6ND$ no cuenta. (e) ≈ 214 tokens por parámetro, unas 11 veces la regla; la regla daría $N \approx 2{,}29 \cdot 10^{11}$ y $D \approx 4{,}58 \cdot 10^{12}$. Servir 10^{13} tokens cuesta $1{,}40 \cdot 10^{24}$ FLOP con el modelo pequeño y $4{,}58 \cdot 10^{24}$ con el grande: con un uso intenso, el coste de inferencia es del orden del de entrenamiento, y un modelo más pequeño y más entrenado resulta más barato en su ciclo de vida.

Comprobación. (b) $8192 \cdot 22{,}5 \cdot 24 = 4{,}424 \cdot 10^{6}$ GPU-horas. (c) Con la atención, cada token añade unos $4LdT$ FLOP hacia delante con $T = 1024$; frente a $2N$, son $4 \cdot 48 \cdot 1600 \cdot 1024/(2 \cdot 1{,}640 \cdot 10^{9}) = 9{,}6\,\%$ más, de modo que la cifra de 193 días es una cota inferior (ampliación: la tarea de CS336 pide contar también esos productos). (d) $4{,}424 \cdot 10^{6} / 6{,}4 \cdot 10^{6} = 0{,}6913$ y $0{,}6913 \cdot 40\,\% = 27{,}65\,\%$. (e) $4{,}583/1{,}4 = 3{,}27 = 2{,}291 \cdot 10^{11}/7 \cdot 10^{10}$: la inferencia escala con N.

[Criterios: (a) 1 p. (b) 0,75 p por cada cifra. (c) 1 p por N y la memoria, 1 p por el tiempo. (d) 1 p por la MFU y 1 p por las razones. (e) 1 p por las cifras y 1 p por el argumento.]

Repasar: M17, §1.2, §2.5, §6.1 y §6.2; M16, §5.3.

Solución del ejercicio B.3

Datos. $\Psi = 7 \cdot 10^{10}$; TP = 8, PP = $p_{\mathrm{e}} = 4$, DP = 64; 2048 H100; lote de 1024 secuencias de 4096 tokens; microlote de una secuencia; NVLink $\approx$ 900 GB/s e InfiniBand $\approx$ 50 GB/s por GPU.

Planteamiento. $n_{\mathrm{d}} = \mathrm{TP} \cdot \mathrm{PP} \cdot \mathrm{DP}$. Memoria de estado con la tabla de ZeRO (M17, §5.6). Burbuja $(p_{\mathrm{e}} - 1)/(m + p_{\mathrm{e}} - 1)$ (M17, §5.5). All-reduce en anillo: $t_{\mathrm{AR}} = 2(n-1)S/(nW)$ (M17, §5.1).

Desarrollo.

(a)

1. $8 \cdot 4 \cdot 64 = 2048 = 256 \cdot 8$: cuadra.
2. TP comunica activaciones varias veces por capa y necesita el enlace más rápido. Con TP = 16, cada grupo ocuparía dos nodos y sus all-reduce cruzarían InfiniBand, $900/50 = 18$ veces más lento que NVLink.

(b)

1. $16\Psi = 1{,}12 \cdot 10^{12}$ bytes; entre $\mathrm{TP} \cdot \mathrm{PP} = 32$ GPU: $3{,}5 \cdot 10^{10}$ bytes = 35 GB por GPU. Quedan $80 - 35 = 45$ GB para activaciones.

2. Paralelismo de datos puro: cada GPU guardaría los $1{,}12 \cdot 10^{12}$ bytes = 1120 GB, 14 veces su memoria. Ni siquiera los pesos en bf16 (140 GB) caben. No es viable.

(c)

1. Pesos y gradientes: $4\Psi/32 = 2{,}8 \cdot 10^{11}/32 = 8{,}75 \cdot 10^{9}$ bytes.
2. Optimizador: $12\Psi/(32 \cdot 64) = 8{,}4 \cdot 10^{11}/2048 = 4{,}102 \cdot 10^{8}$ bytes.
3. Total: $8{,}75 + 0{,}4102 = 9{,}160$ GB por GPU; se recuperan $35 - 9{,}160 = 25{,}84$ GB.

(d)

1. Tokens por paso: $1024 \cdot 4096 = 4\,194\,304$.
2. Secuencias por réplica: $1024/64 = 16$; con microlotes de una secuencia, $m = 16$.
3. Burbuja: $(4-1)/(16+4-1) = 3/19 = 0{,}1579$.

(e)

1. FLOP por paso: $6 \cdot 7 \cdot 10^{10} \cdot 4{,}194 \cdot 10^{6} = 1{,}762 \cdot 10^{18}$. Rendimiento útil del clúster: $2048 \cdot 989 \cdot 10^{12} \cdot 0{,}4 = 8{,}102 \cdot 10^{17}$ FLOP/s. $t_{\mathrm{c}} = 2{,}174$ s.
2. Gradientes bf16 por GPU: $S = 2\Psi/32 = 4{,}375 \cdot 10^{9}$ bytes. Volumen enviado: $2 \cdot (63/64) \cdot 4{,}375 \cdot 10^{9} = 8{,}613 \cdot 10^{9}$ bytes. $t_{\mathrm{AR}} = 8{,}613 \cdot 10^{9}/(50 \cdot 10^{9}) = 0{,}1723$ s, el 7,9 % de t_{c}.
3. El cómputo por secuencia y réplica es $t_{\mathrm{c}}/16 = 0{,}1359$ s, mientras que t_{AR} no depende del lote. Con s secuencias por réplica, la comunicación queda por debajo del cómputo si $0{,}1359\, s \geq 0{,}1723$, es decir, $s \geq 1{,}268$: hacen falta al menos 2 secuencias por réplica.

(f)

1. Pasos: $1{,}5 \cdot 10^{13}/4{,}194 \cdot 10^{6} = 3{,}577 \cdot 10^{6}$; tiempo: $3{,}577 \cdot 10^{6} \cdot 2{,}174 = 7{,}776 \cdot 10^{6}$ s = 90,00 días.

Resultado. (a) 2048 GPU; TP = 8 cabe en un nodo y usa NVLink. (b) 35,0 GB por GPU: cabe; el paralelismo de datos puro exigiría 1120 GB por GPU y no es viable. (c) ≈ 9,16 GB por GPU. (d) 4 194 304 tokens por paso, $m = 16$ y burbuja ≈ 15,8 %. (e) $t_{\mathrm{c}} \approx 2{,}17$ s y $t_{\mathrm{AR}} \approx 0{,}172$ s (7,9 %); como además se solapa con la pasada hacia atrás, no es el cuello de botella: pesa más la burbuja. Con una sola secuencia por réplica sí lo sería; bastan 2. (f) $\approx 3{,}58 \cdot 10^{6}$ pasos y ≈ 90,0 días.

Comprobación. (c) El optimizador era el $12/16 = 75\,\%$ de los 35 GB, 26,25 GB; ahora ocupa 0,41 GB, y $26{,}25 - 0{,}41 = 25{,}84$ GB. (d) Con $m \to \infty$ la burbuja tiende a 0 y con $m = 1$ vale 3/4. (e) Para que la comunicación igualase al cómputo con el lote completo, el enlace debería bajar a $8{,}613/2{,}174 = 3{,}96$ GB/s. (f) Son 4 veces los 22,5 días del ejercicio B.2, porque hay $8192/2048 = 4$ veces menos GPU con la misma MFU.

[Criterios: (a) 1 p. (b) 1 p por la memoria y 1 p por el paralelismo de datos puro. (c) 2 p. (d) 2 p. (e) 1 p por los dos tiempos y 1 p por el lote mínimo. (f) 1 p.]

Repasar: M17, §5.1, §5.3, §5.4, §5.5 y §5.6.

Solución del ejercicio B.4

Datos. $d = 5120$; $L = 40$; 16 expertos top-2; $d_{\mathrm{ff}} = 8192$, SwiGLU con 3 matrices; 40 cabezas de consulta, $n_{\mathrm{kv}} = 8$, $d_{\mathrm{h}} = 128$; $V = 64\,000$ sin compartir.

Planteamiento. se suman expertos, atención y *embeddings*; los activos cuentan 2 expertos por capa (M18, §4.2). FLOP hacia delante $\approx 2N_{\text{act}}$ por token; memoria $= 2N_{\text{tot}}$ bytes en bf16. Pesos del enrutador como softmax entre los elegidos (M18, §4.1); $\mathcal{L}_{\text{bal}}$ (M18, §4.3); capacidad $C_{\text{exp}} = c\,kB_{\text{t}}/N$ (M18, §4.4).

Desarrollo.

(a)

1. Experto: $3 \cdot 5120 \cdot 8192 = 125\,829\,120$.
2. Atención: K y V tienen dimensión $8 \cdot 128 = 1024$. W_Q y W_O: $2 \cdot 5120^2 = 52\,428\,800$; W_K y W_V: $2 \cdot 5120 \cdot 1024 = 10\,485\,760$. Suma: $62\,914\,560$.
3. *Embeddings*: $2 \cdot 64\,000 \cdot 5120 = 655\,360\,000$.
4. Total: $40 \cdot (16 \cdot 125\,829\,120 + 62\,914\,560) + 655\,360\,000 = 40 \cdot 2\,076\,180\,480 + 655\,360\,000 = 83\,702\,579\,200$.
5. Activos: $40 \cdot (2 \cdot 125\,829\,120 + 62\,914\,560) + 655\,360\,000 = 40 \cdot 314\,572\,800 + 655\,360\,000 = 13\,238\,272\,000$.
6. Fracción activa: $13\,238\,272\,000/83\,702\,579\,200 = 0{,}1582$.

(b)

1. FLOP por token: $2 \cdot 1{,}324 \cdot 10^{10} = 2{,}648 \cdot 10^{10}$.
2. Memoria: $2 \cdot 8{,}370 \cdot 10^{10} = 1{,}674 \cdot 10^{11}$ bytes $= 167{,}4$ GB; $167{,}4/80 = 2{,}093$, luego hacen falta al menos 3 H100.

(c)

1. Los dos logits mayores son 2,6 (experto 6) y 1,9 (experto 2); el siguiente, 1,7 (experto 13), queda fuera.
2. Con dos elegidos, $g_6 = 1/(1 + e^{-\Delta})$ con $\Delta = 2{,}6 - 1{,}9 = 0{,}7$: $e^{-0{,}7} = 0{,}4966$ y $g_6 = 1/1{,}4966 = 0{,}6682$; $g_2 = 1 - 0{,}6682 = 0{,}3318$.

(d)

1. $\sum f_i = 4 \cdot 0{,}16 + 12 \cdot 0{,}03 = 0{,}64 + 0{,}36 = 1$; $\sum P_i = 4 \cdot 0{,}12 + 12 \cdot 13/300 = 0{,}48 + 0{,}52 = 1$.
2. $\sum f_i P_i = 4 \cdot 0{,}16 \cdot 0{,}12 + 12 \cdot 0{,}03 \cdot 13/300 = 0{,}0768 + 0{,}0156 = 0{,}0924$.
3. $\mathcal{L}_{\text{bal}} = 16 \cdot 0{,}0924 = 1{,}478$.

(e)

1. Asignaciones: $2 \cdot 8192 = 16\,384$. Capacidad: $1{,}25 \cdot 16\,384/16 = 1280$ plazas.
2. Asignaciones a un experto saturado: $0{,}16 \cdot 16\,384 = 2621$; descartes: $2621 - 1280 = 1341$.

Resultado. (a) Experto, $1{,}26 \cdot 10^8$; atención por capa, $6{,}29 \cdot 10^7$; *embeddings*, $6{,}55 \cdot 10^8$; total $\approx 8{,}37 \cdot 10^{10}$; activos $\approx 1{,}32 \cdot 10^{10}$; fracción activa $\approx 15{,}8\,\%$. El enrutador añade solo $5120 \cdot 16 \cdot 40 = 3\,276\,800$ parámetros. (b) $\approx 2{,}65 \cdot 10^{10}$ FLOP por token, como un denso de $1{,}3 \cdot 10^{10}$; 167 GB de pesos y al menos 3 H100. Una MoE ahorra cómputo por token, pero no memoria de pesos ni caché KV. (c) Expertos 6 y 2, con $g_6 \approx 0{,}668$ y $g_2 \approx 0{,}332$. (d) $\mathcal{L}_{\text{bal}} \approx 1{,}48$, frente a 1 con reparto perfecto; el gradiente $\partial\mathcal{L}_{\text{bal}}/\partial P_i = N f_i$ es mayor en los expertos saturados y reduce su probabilidad. (e) 1280 plazas por experto; cada experto saturado descarta ≈ 1341

asignaciones, que en esa capa solo pasan por la conexión residual (o por el otro experto elegido).

Comprobación. (a) $N_{\text{tot}} - N_{\text{act}} = 70\,464\,307\,200 = 40 \cdot 14 \cdot 125\,829\,120$: los 14 expertos no usados de cada capa. (b) La caché KV solo depende de L, n_{kv} y d_{h}, iguales que en un denso con la misma atención. (c) $e^{2,6} = 13{,}46$ y $e^{1,9} = 6{,}686$; $13{,}46/(13{,}46 + 6{,}686) = 0{,}6682$. (d) Reparto perfecto: $16 \cdot 16 \cdot \frac{1}{16} \cdot \frac{1}{16} = 1$; el valor 1,478 está en $[1, 16]$. (e) Se pierde $1341/2621 = 51\,\%$ del tráfico de esos expertos: un desequilibrio de 0,16 frente al ideal $1/16 = 0{,}0625$ (2,56 veces) no cabe con un factor 1,25.

[Criterios: 2 p por apartado. En (c), 1 p si se aplica la softmax a los 16 logits sin renormalizar.]

Repasar: M18, §4.1, §4.2, §4.3 y §4.4.

Solución del ejercicio B.5

Datos. $L = 56$; $d = 7168$; $n_{\text{kv}} = 8$; $d_{\text{h}} = 128$; $N = 3{,}5 \cdot 10^{10}$; bf16 ($s = 2$); 2 H100: 160 GB, $B_{\text{mem}} = 6{,}7$ TB/s y $1{,}978 \cdot 10^{15}$ FLOP/s; 10 GB reservados.

Planteamiento. caché por token $c_{\text{kv}} = 2Ln_{\text{kv}}d_{\text{h}}s$ (M19, §2.2). En la decodificación, $t_{\text{paso}} \approx$ (bytes de pesos+bytes de caché)$/B_{\text{mem}}$ (M19, §2.3–§2.4). El *prefill* está limitado por el cómputo (M19, §2.1). Coste de las escalas: $b + b_\Delta/g$ bits por peso (M19, §4.3). Decodificación especulativa: $\mathbb{E}[N_{\text{r}}] = (1 - \alpha^{\gamma+1})/(1 - \alpha)$ tokens por ronda con un coste de $\gamma c + 1$ pasadas (M19, §3.4).

Desarrollo.

(a)

1. $12 \cdot 56 \cdot 7168^2 = 672 \cdot 51\,380\,224 = 3{,}453 \cdot 10^{10} \approx 3{,}5 \cdot 10^{10}$.
2. Pesos: $2 \cdot 3{,}5 \cdot 10^{10} = 7 \cdot 10^{10}$ bytes = 70 GB. Libre: $160 - 70 - 10 = 80$ GB.
3. $c_{\text{kv}} = 2 \cdot 56 \cdot 8 \cdot 128 \cdot 2 = 229\,376$ bytes = 224 KiB. Por secuencia: $229\,376 \cdot 8192 = 1{,}879 \cdot 10^9$ bytes = 1,75 GiB.

(b)

1. GQA: $80/1{,}879 = 42{,}58$, luego caben 42 secuencias.
2. MHA: $2 \cdot 56 \cdot 56 \cdot 128 \cdot 2 = 1\,605\,632$ bytes por token (7 veces más); por secuencia, $1{,}315 \cdot 10^{10}$ bytes; $80/13{,}15 = 6{,}08$, luego caben 6.

(c)

1. (i) Bytes por paso: 70+1,879 = 71,88 GB; $t = 71{,}88 \cdot 10^9/6{,}7 \cdot 10^{12} = 10{,}73$ ms; $1/t = 93{,}21$ tokens/s.
2. (ii) Caché: $32 \cdot 4096 \cdot 229\,376 = 3{,}006 \cdot 10^{10}$ bytes; $t = (70 + 30{,}06) \cdot 10^9/6{,}7 \cdot 10^{12} = 14{,}94$ ms; totales $32/0{,}01494 = 2142$ tokens/s; por usuario, 66,96 tokens/s.
3. Cómputo en (ii): $2 \cdot 3{,}5 \cdot 10^{10} \cdot 32 = 2{,}24 \cdot 10^{12}$ FLOP; $2{,}24 \cdot 10^{12}/1{,}978 \cdot 10^{15} = 1{,}132$ ms $< 14{,}94$ ms.
4. Lote crítico: un paso con lote B hace $2NB$ FLOP y lee $2N$ bytes de pesos, con intensidad $I = B$ FLOP/byte; pasa a estar limitado por el cómputo cuando $B \geq I^* = 989/3{,}35 = 295{,}2$ (el cociente es el mismo con una o con dos GPU).

5. Memoria de ese lote: $295 \cdot 4096 \cdot 229\,376 = 2{,}772 \cdot 10^{11}$ bytes = 277,2 GB > 80 GB; con 4096 tokens solo caben $80/0{,}9395 = 85$ secuencias.

(d)

1. FLOP: $2 \cdot 3{,}5 \cdot 10^{10} \cdot 4000 = 2{,}8 \cdot 10^{14}$; rendimiento útil: $0{,}5 \cdot 1{,}978 \cdot 10^{15} = 9{,}89 \cdot 10^{14}$ FLOP/s; TTFT = 0,2831 s.

(e)

1. Bits por peso: $4 + 16/64 = 4{,}25$; pesos: $3{,}5 \cdot 10^{10} \cdot 4{,}25/8 = 1{,}859 \cdot 10^{10}$ bytes.
2. Bytes por paso en (i): 18,59 + 1,879 = 20,47 GB; cota: $6{,}7 \cdot 10^{12}/20{,}47 \cdot 10^{9} = 327{,}3$ tokens/s, 3,511 veces más que en (i).
3. Especulativa: $0{,}75^{6} = 0{,}1780$; $\mathbb{E}[N_{\mathrm{r}}] = (1 - 0{,}1780)/0{,}25 = 3{,}288$ tokens por ronda; coste $5 \cdot 0{,}04 + 1 = 1{,}2$ pasadas; aceleración $3{,}288/1{,}2 = 2{,}740$.

Resultado. (a) 70 GB de pesos y 80 GB libres; 224 KiB por token y ≈ 1,88 GB (1,75 GiB) por secuencia. (b) 42 secuencias con GQA y solo 6 con MHA. (c) (i) 10,7 ms por paso y 93,2 tokens/s; (ii) 14,9 ms por paso, ≈ 2140 tokens/s totales y ≈ 67,0 por usuario; el cómputo (1,13 ms) no limita. El lote crítico es $B \approx 295$, que no cabe: su caché ocuparía unos 277 GB y solo caben 85 secuencias. La decodificación de este servidor estará siempre limitada por la memoria. (d) TTFT ≈ 0,283 s. (e) ≈ 327 tokens/s con int4 (3,51 veces más); la decodificación especulativa añade un factor ≈ 2,74.

Comprobación. (a) $229\,376 \cdot 8192 = 1{,}75 \cdot 2^{30}$ exactamente. (b) $42/6 = 7 = 56/8$. (c) El lote se multiplica por 32 y el tiempo por paso solo por $14{,}94/10{,}73 = 1{,}39$: los pesos se leen una vez para todo el lote. (d) La intensidad del *prefill* es $2N \cdot 4000/(2N) = 4000$ FLOP/byte, muy por encima de $I^{*} \approx 295$: limitado por el cómputo, como se supuso. (e) Sin caché, int4 daría $70/18{,}59 = 3{,}77$ veces; la caché, que sigue en bf16 y pesa el $1{,}879/20{,}47 = 9{,}2\,\%$ de los bytes, rebaja la mejora a 3,51.

[Criterios: (a) 2 p. (b) 2 p. (c) 1 p por cada caso y 1 p por las comprobaciones de cómputo y del lote crítico. (d) 1 p. (e) 1 p por int4 y 1 p por la decodificación especulativa.]

Repasar: M19, §2.1, §2.2, §2.3, §2.4, §3.4 y §4.3; M17, §2.2; M18, §2.3.

Solución del ejercicio B.6

Datos. $L(10^{20}) = 3{,}2$; $L(10^{22}) = 2{,}6$; $L(C) = 1{,}7 + kC^{-b}$. LSH con $(r, b) = (8, 16)$ y $(5, 20)$. Respuestas de $k = 20$ tokens con $p \in \{0{,}9;\ 0{,}95;\ 0{,}98;\ 0{,}995\}$.

Planteamiento. (a) El cociente de los excesos sobre 1,7 elimina k (M16, §3.2). (b) Curva en S $P(s) = 1 - (1 - s^{r})^{b}$ (M16, §2.5); el umbral exacto resuelve $1 - (1 - s^{r})^{b} = 1/2$, es decir, $s_{1/2} = (1 - 2^{-1/b})^{1/r}$. (c) $\mathbb{P}(\text{respuesta correcta}) = p^{k} = e^{k \ln p}$ (M16, §6.2).

Desarrollo.

(a)

1. Excesos: $3{,}2 - 1{,}7 = 1{,}5$ y $2{,}6 - 1{,}7 = 0{,}9$; $0{,}9/1{,}5 = 100^{-b} = 0{,}6$.
2. $b = \ln(1{,}5/0{,}9)/\ln 100 = 0{,}5108/4{,}605 = 0{,}1109$.
3. $L(10^{24}) = 1{,}7 + 0{,}9 \cdot 100^{-b} = 1{,}7 + 0{,}9 \cdot 0{,}6 = 2{,}24$.
4. Para pasar de un exceso de 0,9 a 0,45 hace falta un factor F con $F^{-b} = 0{,}5$: $F = 2^{1/b} = 2^{9{,}015} = 517{,}4$, luego $C = 517{,}4 \cdot 10^{22} = 5{,}174 \cdot 10^{24}$.

(b)

1. $s = 0{,}5$: $s^8 = 0{,}003906$; $(1 - 0{,}003906)^{16} = 0{,}9393$; $P = 0{,}0607$.
2. $s = 0{,}7$: $s^8 = 0{,}05765$; $0{,}94235^{16} = 0{,}3867$; $P = 0{,}6133$. (Con bases tan próximas a 1 conviene no redondear la base.)
3. $s = 0{,}9$: $s^8 = 0{,}4305$; $0{,}5695^{16} = 1{,}225 \cdot 10^{-4}$; $P = 0{,}9999$.
4. Umbral aproximado: $(1/16)^{1/8} = e^{-2{,}773/8} = 0{,}7071$. Umbral exacto: $2^{-1/16} = 0{,}9576$, $1 - 0{,}9576 = 0{,}04240$, $s_{1/2} = 0{,}04240^{1/8} = 0{,}6736$.
5. Configuración $(5, 20)$: aproximado $(1/20)^{1/5} = 0{,}5493$; exacto $(1 - 2^{-1/20})^{1/5} = 0{,}5087$.

(c)

1. $p = 0{,}9$: $20 \ln p = -2{,}107$; $p^{20} = 0{,}1216$.
2. $p = 0{,}95$: $20 \ln p = -1{,}026$; $p^{20} = 0{,}3585$.
3. $p = 0{,}98$: $20 \ln p = -0{,}4041$; $p^{20} = 0{,}6676$.
4. $p = 0{,}995$: $20 \ln p = -0{,}1003$; $p^{20} = 0{,}9046$.

Resultado. (a) $b \approx 0{,}111$; $L(10^{24}) \approx 2{,}24$; hace falta $C \approx 5{,}17 \cdot 10^{24}$ FLOP, unas 517 veces el cómputo de 10^{22}. Extrapolar cuatro órdenes de magnitud con dos puntos es arriesgado: el término irreducible 1,7 se ha supuesto, no ajustado. (b) $P = 0{,}0607$; 0,613 y 0,9999; umbral aproximado 0,707 y exacto 0,674, frente a 0,549 y 0,509 con $(5, 20)$: la configuración $(8, 16)$ es más estricta. Aumentan los falsos negativos (casi duplicados con $s \approx 0{,}6$ escapan más a menudo) y disminuyen los falsos positivos que hay que verificar. (c) $p^{20} = 0{,}122$; 0,358; 0,668; 0,905, y $20 \ln p = -2{,}11$; $-1{,}03$; $-0{,}404$; $-0{,}100$. La log-probabilidad mejora de forma suave (es lineal en $\ln p$), mientras que la exactitud exacta permanece baja y después se dispara. Schaeffer, Miranda y Koyejo sostienen que muchas capacidades «emergentes» son un efecto de métricas discontinuas o no lineales como esta: con métricas continuas, la curva vuelve a ser suave.

Comprobación. (a) $L(5{,}174 \cdot 10^{24}) = 1{,}7 + 0{,}9 \cdot 517{,}4^{-0{,}1109} = 1{,}7 + 0{,}9 \cdot 0{,}5 = 2{,}15$. (b) En $s = (1/b)^{1/r}$, $s^r = 1/16$ y $P = 1 - (15/16)^{16} = 0{,}6439$, cerca del punto de máxima pendiente; el umbral exacto queda por debajo del aproximado, como en el ejercicio 3.4.2 de [6]. (c) $p^{20} = e^{20 \ln p}$: las dos columnas contienen la misma información en escalas distintas; el valor para $p = 0{,}95$ coincide con la cuestión 18.

[Criterios: (a) 2 p por b, 1 p por la predicción y 1 p por el cómputo; mencionar el riesgo de extrapolar suma, no resta. (b) 2 p por los cálculos y 1 p por la discusión. (c) 2 p por las tablas y 1 p por la interpretación.]

Repasar: M16, §2.5, §3.1, §3.2, §6.1 y §6.2.

I.3 Proyecto: valores de referencia para la corrección

$C = 2048 \cdot 60 \cdot 86\,400 \cdot 989 \cdot 10^{12} \cdot 0{,}4 \approx 4{,}20 \cdot 10^{24}$ FLOP; $2{,}95 \cdot 10^6$ GPU-horas; 2477 MWh; $7{,}37 \cdot 10^6$ \$. Óptimo de la ley de Chinchilla: $N \approx 7{,}90 \cdot 10^{10}$ y $D \approx 8{,}87 \cdot 10^{12}$. Regla de 20: $N \approx 1{,}87 \cdot 10^{11}$ y $D \approx 3{,}74 \cdot 10^{12}$. Ambos repartos caben en los $1{,}2 \cdot 10^{13}$ tokens únicos. La pérdida prevista apenas cambia entre $N = 5 \cdot 10^{10}$ (1,869) y $N = 10^{11}$ (1,868), de modo que un N menor que el óptimo es defendible por el coste de inferencia. Cualquier elección bien argumentada es válida.

Apéndice II

Autoevaluación

II.1 Puntuación por parte y por módulo

El examen se corrige con la clave del cuadro I.1 y con los criterios entre corchetes de cada solución. El cuadro II.1 recoge la puntuación por parte y el cuadro II.2, la puntuación por módulo, que sirve para localizar las debilidades.

Cuadro II.1: Puntuación por parte.

Parte	Puntos	Nota obtenida
A. Cuestiones (20 de 2 puntos)	40	
B. Problemas (6 de 10 puntos)	60	
Examen	**100**	
C. Proyecto de fase (se califica aparte)	100	

Cuadro II.2: Puntuación por módulo.

Módulo	Cuestiones	Problemas	Puntos	Obtenidos
M16. Preentrenamiento a escala	2, 3, 18 (6 p)	B.1 y B.6 (20 p)	26	
M17. Hardware y sistemas	1, 4, 5, 8, 14, 20 (12 p)	B.2 y B.3 (20 p)	32	
M18. Arquitecturas modernas	9, 10, 11, 12, 13 (10 p)	B.4 (10 p)	20	
M19. Inferencia	6, 7, 15, 16, 17, 19 (12 p)	B.5 (10 p)	22	
Total	20 cuestiones (40 p)	6 problemas (60 p)	**100**	

El ejercicio B.2 combina los módulos 16 y 17; se asigna al 17 porque la mayor parte de su puntuación (apartados b, c y d) corresponde a la duración, la energía y la MFU.

II.2 Umbral de aprobado

- **Examen de hito**: 70 puntos de 100 (70 %) o más.
- **Proyecto de fase**: 70 puntos de 100 o más en la rúbrica del cuadro C.1.
- **Puerta de salida de la fase IV**: además del examen, cada uno de los módulos M16 a M19 exige un test de módulo con al menos 9 respuestas correctas de 12 y una autoevaluación del laboratorio interactivo de la fase de al menos el 70 %.

Como orientación por módulo, una puntuación inferior al 70 % de los puntos de un módulo en el cuadro II.2 (por ejemplo, menos de 18 de 26 en M16) indica que conviene repasarlo aunque el examen esté aprobado.

II.3 Qué hacer si no se alcanza el umbral

1. Anotar cada fallo en el registro de errores clasificándolo como error de concepto, de cálculo o despiste.
2. Repasar las secciones del cuadro II.3 correspondientes a los fallos, empezando por los errores de concepto.
3. Rehacer sin mirar la solución los ejercicios de nivel ⋆⋆ y ⋆⋆⋆ de esos temas en los apuntes del módulo.
4. Repetir el test del módulo afectado hasta alcanzar 9 de 12 y volver a presentarse al examen de hito con una versión nueva, no antes de una semana.

Cuadro II.3: Secciones de repaso según el fallo.

Fallo	Repasar
Cuestiones 1, 2, 3	M17, §1.2 (regla $6ND$); M16, §4.5 (regla de 20 tokens) y §5.2 (Kaplan frente a Chinchilla)
Problema B.1	M16, §4.2, §4.3 (forma cerrada), §4.5 y §4.6 (el mínimo es plano)
Problema B.2	M17, §1.2, §2.5 (MFU), §6.1 y §6.2; M16, §5.3 (coste de la inferencia)
Cuestiones 4, 8; problema B.3	M17, §5.1 (all-reduce en anillo), §5.3–§5.5 (paralelismo de datos, tensores y etapas; burbuja) y §5.6 (ZeRO)
Cuestiones 5, 20	M17, §2.2 (intensidad crítica y roofline) y §2.5 (MFU)
Cuestión 14	M17, §3.3 (softmax en línea) y §3.4 (FlashAttention)
Cuestiones 9, 10, 13; problema B.4	M18, §4.1 (enrutado top-k), §4.2 (parámetros totales y activos), §4.3 (balanceo), §4.4 (capacidad) y §4.6 (casos públicos)
Cuestiones 7, 11	M18, §2.1 y §2.3 (caché KV, MQA y GQA); M19, §2.2
Cuestión 12	M18, §3.1 y §3.2 (ventana deslizante y campo receptivo)
Cuestiones 6, 15; problema B.5 (a)–(d)	M19, §2.1 a §2.4 (*prefill*, caché KV, intensidad y lote)
Cuestión 16; problema B.5 (e)	M19, §3.2 a §3.4 (decodificación especulativa)
Cuestión 17; problema B.5 (e)	M19, §4.3 (granularidad y coste de las escalas)
Cuestión 19	M19, §6.2 y §6.3 (*batching* continuo y PagedAttention)
Cuestión 18; problema B.6	M16, §2.5 (LSH por bandas), §3.1–§3.2 (leyes de potencia) y §6.1–§6.2 (emergencia y métricas)

Siguiente paso. Superado el hito, se continúa con la fase V, módulo 20: ajuste fino.

Bibliografía

Cursos y problemas universitarios citados

[1] Equipo docente de CS336 (T. Hashimoto y P. Liang). CS336: Language Modeling from Scratch. Tarea 1, «Basics», versión 26.0.3. Stanford University, primavera de 2026. Problemas `transformer_accounting` y `adamw_accounting`. https://github.com/stanford-cs336/assignment1-basics

[2] Equipo docente de CS336 (T. Hashimoto y P. Liang). CS336: Language Modeling from Scratch. Tarea 2, «Systems and Parallelism», versión 26.1.3. Stanford University, primavera de 2026. §8, problema `data_parallel_calcs`. https://github.com/stanford-cs336/assignment2-systems

[3] Equipo docente de CS336 (T. Hashimoto y P. Liang). CS336: Language Modeling from Scratch. Tarea 3, «Scaling Laws», versión 26.0.5. Stanford University, primavera de 2026. §2.1, problema `chinchilla_isoflops`. https://github.com/stanford-cs336/assignment3-scaling

[4] Equipo docente de CS336 (T. Hashimoto y P. Liang). CS336: Language Modeling from Scratch. Tarea 4, «Data: Filtering Language Modeling Data», versión 26.0.1. Stanford University, primavera de 2026. Problema `minhash_deduplication`. https://github.com/stanford-cs336/assignment4-data

[5] J. Austin, S. Douglas, R. Frostig, A. Levskaya *et al.* *How to Scale Your Model: A Systems View of LLMs on TPUs*. Google DeepMind, 2025. Parte 1 («All About Rooflines»), problema 5; parte 5 («How to Parallelize a Transformer for Training»), problemas 2 y 3; parte 7 («All About Transformer Inference»), problemas 1, 2, 3 y 5. https://jax-ml.github.io/scaling-book/

[6] J. Leskovec, A. Rajaraman y J. D. Ullman. *Mining of Massive Datasets*, 3.ª ed. Cambridge University Press, 2020. Cap. 3, «Finding Similar Items», ejercicios 3.4.1 y 3.4.2. http://infolab.stanford.edu/~ullman/mmds/ch3.pdf

[7] J. Leskovec. CS246: Mining Massive Data Sets. Stanford University. Curso cuyo libro de texto es [6]. https://web.stanford.edu/class/cs246/

Artículos y fichas técnicas

[8] J. Hoffmann, S. Borgeaud, A. Mensch *et al.* Training compute-optimal large language models. En *Advances in Neural Information Processing Systems 35 (NeurIPS)*, 2022. https://arxiv.org/abs/2203.15556

[9] J. Kaplan, S. McCandlish, T. Henighan *et al.* Scaling laws for neural language models. Prepublicación, 2020. https://arxiv.org/abs/2001.08361

[10] A. Grattafiori *et al.* (Llama Team, AI @ Meta). The Llama 3 herd of models. Informe técnico, 2024. https://arxiv.org/abs/2407.21783

[11] R. Schaeffer, B. Miranda y S. Koyejo. Are emergent abilities of large language models a mirage? En *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. https://arxiv.org/abs/2304.15004

[12] A. Chowdhery, S. Narang, J. Devlin *et al.* PaLM: Scaling language modeling with Pathways. *Journal of Machine Learning Research*, 24, 2023. https://arxiv.org/abs/2204.02311

[13] S. Rajbhandari, J. Rasley, O. Ruwase e Y. He. ZeRO: Memory optimizations toward training trillion parameter models. En *Proceedings of SC20*, 2020. https://arxiv.org/abs/1910.02054

[14] T. Dao, D. Y. Fu, S. Ermon, A. Rudra y C. Ré. FlashAttention: Fast and memory-efficient exact attention with IO-awareness. En *Advances in Neural Information Processing Systems 35 (NeurIPS)*, 2022. https://arxiv.org/abs/2205.14135

[15] xAI. Open release of Grok-1, 17 de marzo de 2024. https://x.ai/news/grok-os

[16] Y. Leviathan, M. Kalman e Y. Matias. Fast inference from transformers via speculative decoding. En *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023. https://arxiv.org/abs/2211.17192

[17] W. Kwon, Z. Li, S. Zhuang *et al.* Efficient memory management for large language model serving with PagedAttention. En *Proceedings of the 29th Symposium on Operating Systems Principles (SOSP)*, 2023. https://arxiv.org/abs/2309.06180

Apuntes del curso

[18] Anatomía de un LLM. Apuntes de los módulos 16 («Preentrenamiento a escala»), 17 («Hardware y sistemas»), 18 («Arquitecturas modernas») y 19 («Inferencia»), edición de octubre de 2026.