Anatomía de un LLM

Fundamentos matemáticos de los modelos de lenguaje

Fase VI · Diseño y construcción de optimizadores con IA

Módulo 24

Formular y resolver problemas de optimización

Programación lineal y entera, restricciones, convexidad, metaheurísticas y decisiones con predicciones

---

Apuntes del curso

Edición de octubre de 2026

Presentación del módulo

Un optimizador basado en IA no empieza con una red neuronal, sino con una pregunta bien planteada: qué se decide, con qué datos, qué se quiere mejorar y qué no se puede violar. Este módulo abre la fase VI enseñando ese oficio. Primero se estudia cómo pasar de un problema real a un modelo matemático y cómo encaja ese modelo en la arquitectura completa de un sistema que predice, decide y se vigila a sí mismo; con ello se traza el mapa de métodos que recorre la fase. Después se estudian las familias de problemas que la industria resuelve a diario con resolvedores maduros: programación lineal y entera mixta, con la dualidad y los precios sombra; problemas combinatorios y programación por restricciones, con rutas de reparto y programación de talleres; optimización convexa y condiciones de Karush–Kuhn–Tucker, con el despacho económico de energía; metaheurísticas y optimización multiobjetivo, con la distribución en planta. El último tema trata el momento en que el aprendizaje automático entra en la formulación: los parámetros del modelo se predicen y la decisión debe tener en cuenta el error de esa predicción. Cada tema se apoya en un caso de estudio con datos numéricos que el cuaderno de prácticas implementa y comprueba.

Objetivos

Al finalizar el módulo, el estudiante debe ser capaz de:

1. traducir un problema de decisión a un modelo con variables, parámetros, objetivo y restricciones; distinguir el objetivo de los indicadores de seguimiento, y reformular valores absolutos y criterios minimax como problemas lineales;
2. describir la arquitectura de un optimizador con IA (datos, modelo predictivo, modelo de optimización, resolvedor, decisión y monitorización) y elegir la familia de métodos adecuada para un problema dado;
3. plantear y resolver programas lineales y enteros mixtos, escribir el dual, demostrar la dualidad débil y la holgura complementaria, interpretar los precios sombra y modelizar decisiones lógicas con variables binarias y cotas big-M válidas;
4. explicar la ramificación y acotación, formular problemas de rutas con ventanas horarias y de programación de talleres, y obtener cotas inferiores que midan la calidad de una solución;
5. reconocer problemas convexos, aplicar las condiciones KKT, interpretar los multiplicadores como sensibilidades y resolver modelos con CVXPY;
6. aplicar recocido simulado, algoritmos genéticos y CMA-ES a problemas de caja negra, y calcular frentes de Pareto con NSGA-II conociendo las limitaciones de la suma ponderada;
7. combinar predicción y optimización (predecir y después optimizar, vendedor de periódicos, programación estocástica en dos etapas, decisión robusta) y evaluar las decisiones fuera de muestra sin fugas de datos.

Requisitos previos

Del módulo 0.7 (tema 5, §5.4) se usan los multiplicadores de Lagrange, y del módulo 0.9, los cuantiles (tema 1), los intervalos de confianza (tema 4) y la regresión lineal (tema 6). Del módulo 4 se usan el gradiente (tema 1), el hessiano (tema 4) y la convexidad de conjuntos y funciones (tema 5); del módulo 5, la esperanza, la distribución normal (tema 3) y el método de Monte Carlo (tema 5, §5.3); del módulo 7, el planteamiento de problemas de optimización, la convexidad y las condiciones de optimalidad (tema 1, §§1.2–1.3) y el descenso de gradiente (tema 2); del módulo 8, la separación en entrenamiento, validación y prueba (tema 1, §1.4), la regresión lineal (tema 2) y la generalización (tema 5). Las referencias al aprendizaje por refuerzo remiten al módulo 21 (tema 1: procesos de decisión de Markov) y las referencias a los modelos de lenguaje como agentes, al módulo 22 (tema 6). La distribución de Boltzmann que aparece en el recocido simulado se estudió en el módulo 6 (tema 5, §5.2).

Organización

Tema	Contenido y caso de estudio	Fuentes principales
1	Del problema real al modelo; anatomía de un optimizador con IA; mapa de métodos. Caso: fábrica de piensos	[5], [30], [27], [15], [23]
2	Programación lineal y entera mixta: dualidad, precios sombra, big-M, ramificación y acotación. Caso: plan de producción de una cervecera	[5], [10], [30], [28], [22]
3	Problemas combinatorios y programación por restricciones. Casos: reparto con ventanas horarias y taller *job-shop*	[30], [37], [20], [19], [25]
4	Optimización continua y convexa: KKT y CVXPY. Caso: despacho económico de energía	[8], [32], [39], [12]
5	Metaheurísticas, optimización sin derivadas y multiobjetivo. Caso: distribución en planta	[27], [26], [21], [11]
6	Predecir y después optimizar; programación estocástica y robusta. Caso: plan de cerveza fresca con demanda predicha	[6], [9], [14], [3], [4]

Cada tema contiene teoría formal, un caso de estudio con datos numéricos, una tabla de tecnologías, una observación sobre errores frecuentes en la práctica, una lista de lecturas y ejercicios graduados en tres niveles: ⋆ comprensión, ⋆⋆ formulación y cálculo a mano, y ⋆⋆⋆ demostración o diseño razonado. Los ejercicios marcados con *Fuente* están adaptados de cursos y libros universitarios; el enunciado se ha redactado de nuevo y, en algunos casos, se han cambiado los datos. Las soluciones completas están en el apéndice A. El cuaderno `M24-practica.ipynb` implementa los seis casos de estudio paso a paso y comprueba con un segundo método (enumeración, condiciones de optimalidad o simulación) todos los resultados numéricos que aparecen en estos apuntes.

Sobre las fuentes

El texto es de redacción propia. La formulación y la programación lineal siguen el libro de Bertsimas y Tsitsiklis [5], texto del curso 6.251J del MIT [29], y el curso 15.053 del MIT (Orlin y Nasrabadi, 2013) [30], cuyas clases sobre formulaciones, análisis de sensibilidad y precios sombra, programación entera y ramificación y acotación, y viajante de comercio se citan por su número, igual que sus hojas de problemas [31]; varios ejercicios proceden del libro de Bradley,

Hax y Magnanti [10], que es el texto de ese curso. La optimización convexa sigue a Boyd y Vandenberghe [8] (curso EE364a de Stanford) y, para las condiciones de optimalidad con restricciones, el capítulo 12 de Nocedal y Wright [32]. Las metaheurísticas, la optimización multiobjetivo y la optimización con incertidumbre siguen a Kochenderfer y Wheeler [27] y los artículos originales: Kirkpatrick, Gelatt y Vecchi [26] para el recocido, Hansen [21] para CMA-ES y Deb *et al.* [11] para NSGA-II. La programación estocástica sigue a Birge y Louveaux [6] y a las transparencias de EE364a [9]; la optimización robusta, a Bertsimas y Sim [4] y a Ben-Tal, El Ghaoui y Nemirovski [2]; la integración de predicción y decisión, a Elmachtoub y Grigas [14] y a Bertsimas y Kallus [3]. Las aplicaciones industriales citadas (la refrigeración de los centros de datos de Google [15] y el sistema de rutas ORION de UPS [23]) se describen solo con la información que sus autores han publicado. Las herramientas se describen según su documentación oficial [22, 20, 19, 18, 12, 13, 34].

Notación

Símbolo	Significado
$x \in \mathbb{R}^n$, $\mathcal{X}$	vector de decisión y conjunto factible
f, g_i, h_j	función objetivo, restricciones de desigualdad ($g_i \le 0$) y de igualdad ($h_j = 0$)
θ, $\hat{\theta}$	parámetros (datos) del problema y su estimación o predicción
c, A, b	datos de un programa lineal $\max\{c^{\mathsf{T}}x : Ax \le b,\ x \ge 0\}$
y, y^*	variables duales; precios sombra en el óptimo
z^*, z_{LP}	valor óptimo de un problema y de su relajación lineal
M	constante de las restricciones big-M
$\mathcal{L}(x, \lambda, \nu)$	lagrangiana con multiplicadores $\lambda \ge 0$ (desigualdades) y ν (igualdades)
T	temperatura del recocido simulado
$\succ$	dominancia de Pareto ($u \succ v$: u domina a v)
ξ, Ξ	parámetro incierto y conjunto de incertidumbre
c_u, c_o	coste unitario por defecto y por exceso (vendedor de periódicos)
F, F^{-1}	función de distribución y función cuantil
hL, MW, MWh, h	hectolitros, megavatios, megavatios hora, horas

Índice

Presentación del módulo **ii**

1 Del problema real al modelo matemático **1**

1.1 Elementos de un modelo de optimización 1

1.2 Anatomía de un optimizador con IA 3

1.3 Mapa de métodos de la fase 5

Ejercicios del tema 1 6

2 Programación lineal y entera mixta **9**

2.1 Programas lineales y vértices 9

2.2 Dualidad y precios sombra 9

2.3 Programación entera mixta 11

2.4 Ramificación y acotación 12

Ejercicios del tema 2 14

3 Problemas combinatorios y programación por restricciones **16**

3.1 Explosión combinatoria 16

3.2 Rutas de vehículos con ventanas horarias 17

3.3 Programación por restricciones y taller 18

Ejercicios del tema 3 20

4 Optimización continua y convexa **22**

4.1 Problemas convexos 22

4.2 Lagrangiana, dualidad y condiciones KKT 22

4.3 Caso de estudio: despacho económico 24

Ejercicios del tema 4 25

5 Metaheurísticas, optimización sin derivadas y multiobjetivo **27**

5.1 Optimización de caja negra 27

5.2 Recocido simulado 27

5.3 Algoritmos genéticos y estrategias evolutivas 28

5.4 Optimización multiobjetivo 29

Ejercicios del tema 5 31

6 Cuando la IA entra en la formulación: predecir y optimizar **33**
6.1 Predecir y después optimizar . . . 33
6.2 El vendedor de periódicos . . . 34
6.3 Programación estocástica y robusta . . . 34
6.4 Caso de estudio: plan de cerveza fresca con demanda predicha . . . 35
Ejercicios del tema 6 . . . 37

A Soluciones de los ejercicios **39**
A.1 Tema 1 . . . 39
A.2 Tema 2 . . . 43
A.3 Tema 3 . . . 46
A.4 Tema 4 . . . 49
A.5 Tema 5 . . . 52
A.6 Tema 6 . . . 54

Bibliografía **58**

Tema 1

Del problema real al modelo matemático

Antes de elegir un algoritmo hay que saber qué se decide, qué se quiere mejorar y qué no se puede violar. Este tema fija el vocabulario de la modelización siguiendo el capítulo 1 de Bertsimas y Tsitsiklis [5], la clase 1 («Formulations») del curso 6.251J del MIT [29] y la clase 2 («Formulations of linear and non-linear programs») del curso 15.053 [30]; describe la arquitectura de un sistema que predice y decide, con dos aplicaciones industriales publicadas [15, 23], y traza el mapa de métodos que recorre la fase, con el capítulo 1 de Kochenderfer y Wheeler [27] como guía.

1.1 Elementos de un modelo de optimización

Un problema real llega como una descripción verbal: «queremos producir lo más rentable posible sin parar la línea y sin dejar a ningún cliente sin pedido». Modelizar consiste en separar lo que se elige de lo que se sabe y en escribir con precisión lo que se quiere y lo que se exige.

Definición 1.1 (Problema de optimización). Un *problema de optimización* es

$$\min_{x \in X} \; f(x) \qquad \text{s.a. } g_i(x) \le 0 \;\; (i = 1, \dots, m), \qquad h_j(x) = 0 \;\; (j = 1, \dots, p),$$

donde x es el vector de *variables de decisión*, X un conjunto básico (por ejemplo $\mathbb{R}^n$, $\mathbb{R}^n_{\ge 0}$ o $\mathbb{Z}^{n_1} \times \mathbb{R}^{n_2}$), f la *función objetivo* y g_i, h_j las *restricciones*. El *conjunto factible* es $\mathcal{X} = \{x \in X : g_i(x) \le 0,\ h_j(x) = 0\}$. Un punto $x^* \in \mathcal{X}$ es *óptimo (global)* si $f(x^*) \le f(x)$ para todo $x \in \mathcal{X}$, y *óptimo local* si la desigualdad se cumple en $\mathcal{X} \cap B(x^*, r)$ para algún $r > 0$. El problema es *infactible* si $\mathcal{X} = \varnothing$ y *no acotado* si $\inf_{\mathcal{X}} f = -\infty$.

Definición 1.2 (Datos, decisiones e indicadores). En un modelo se distinguen:

(a) los *parámetros* o datos θ (precios, capacidades, demandas, tiempos), que el decisor no controla y que pueden ser inciertos o predichos;

(b) las *variables de decisión* x, que el decisor fija;

(c) las *restricciones duras*, que ninguna decisión puede violar (seguridad, física, contratos), y las *restricciones blandas*, que pueden violarse con una penalización en el objetivo;

(d) el *objetivo* $f(x; \theta)$, un único escalar que se optimiza;

(e) los *indicadores clave* (KPIs, *key performance indicators*): magnitudes que se miden para vigilar el sistema (utilización, nivel de servicio, emisiones, tiempo de cálculo) y que no tienen por qué coincidir con el objetivo.

Observación 1.3. El objetivo es una decisión de diseño: si se optimiza el coste y se vigila el nivel de servicio, conviene comprobar que el óptimo del coste no hunde el servicio. Cuando varios KPIs son igualmente importantes, el problema es multiobjetivo (tema 5). Optimizar un indicador que solo aproxima lo que se quiere conduce a la ley de Goodhart que el módulo 21 estudió como sobreoptimización de la recompensa.

Muchos modelos que no parecen lineales lo son tras una reformulación. Las tres siguientes son las más útiles.

Proposición 1.4 (Reformulaciones elementales). *(i) Maximizar f equivale a minimizar $-f$:* $\max_{\mathcal{X}} f = -\min_{\mathcal{X}}(-f)$*, con los mismos puntos óptimos.*

(ii) Una igualdad $h(x) = 0$ equivale a las dos desigualdades $h(x) \le 0$ y $-h(x) \le 0$; una desigualdad $a^{\mathsf{T}}x \le b$ equivale a $a^{\mathsf{T}}x + s = b$ con una holgura *$s \ge 0$.*

(iii) Una variable libre $x_j \in \mathbb{R}$ puede sustituirse por $x_j = x_j^{+} - x_j^{-}$ con $x_j^{\pm} \ge 0$.

Demostración. (i) $f(x^*) \ge f(x)$ para todo x si y solo si $-f(x^*) \le -f(x)$ para todo x. (ii) Un número es nulo si y solo si es a la vez ≤ 0 y ≥ 0; y $a^{\mathsf{T}}x \le b$ si y solo si $s = b - a^{\mathsf{T}}x \ge 0$. (iii) Todo real es diferencia de dos no negativos (por ejemplo, $x^{+} = \max(x, 0)$ y $x^{-} = \max(-x, 0)$), y toda diferencia de no negativos es un real; la correspondencia conserva los valores de f y de las restricciones. ∎

Proposición 1.5 (Epígrafe de un máximo). *Sean $f_1, \dots, f_k$ funciones sobre $\mathcal{X}$. Los problemas*

$$(P)\quad \min_{x \in \mathcal{X}} \max_{i} f_i(x) \qquad y \qquad (Q)\quad \min_{x \in \mathcal{X},\, t \in \mathbb{R}} t \quad \text{s.a. } f_i(x) \le t \quad (i = 1, \dots, k)$$

tienen el mismo valor óptimo, y x^* es óptimo de (P) si y solo si $(x^*, \max_i f_i(x^*))$ es óptimo de (Q). Si las f_i son afines y $\mathcal{X}$ es un poliedro, (Q) es un programa lineal.

Demostración. Para cada x fijo, el menor t factible en (Q) es $t = \max_i f_i(x)$. Minimizar (Q) en t primero y en x después da exactamente (P). Si (x, t) es óptimo de (Q), necesariamente $t = \max_i f_i(x)$, porque en otro caso podría reducirse t. ∎

Proposición 1.6 (Suma de valores absolutos). *El problema* $\min_{x \in \mathcal{X}} \sum_{i=1}^{k} |a_i^{\mathsf{T}}x - b_i|$ *equivale a*

$$\min_{x \in \mathcal{X},\, e \in \mathbb{R}^k} \sum_{i=1}^{k} e_i \qquad \text{s.a. } -e_i \le a_i^{\mathsf{T}}x - b_i \le e_i \quad (i = 1, \dots, k).$$

Demostración. Es la proposición 1.5 aplicada término a término, porque $|r| = \max(r, -r)$: para x fijo, el menor e_i factible es $|a_i^{\mathsf{T}}x - b_i|$, y la suma se minimiza por separado en cada e_i. ∎

Ejemplo 1.7 (Caso de estudio: la fábrica de piensos). Una fábrica de piensos compuestos elabora pienso de engorde y pienso de puesta. Cada tonelada pasa por el molino y por la granuladora, con los tiempos del cuadro 1.1. La dirección quiere el plan semanal de máximo margen; el departamento comercial informa de que no se pueden colocar más de 160 t semanales de pienso de puesta.

Variables: $E, P \ge 0$, toneladas por semana. *Parámetros:* los de la tabla. *Objetivo y restricciones:*

$$\max\ 40E + 30P \quad \text{s.a. } 0{,}5E + 0{,}5P \le 100, \quad 0{,}6E + 0{,}3P \le 90, \quad P \le 160, \quad E, P \ge 0.$$

Cuadro 1.1: Datos del caso de la fábrica de piensos.

	Engorde (E)	Puesta (P)	Disponible
Molino (h/t)	0,5	0,5	100 h/semana
Granuladora (h/t)	0,6	0,3	90 h/semana
Margen (€/t)	40	30	
Demanda máxima (t/semana)	—	160	

Dividiendo, las dos primeras restricciones son $E+P \le 200$ y $2E+P \le 300$. La región factible es el pentágono de la figura 1.1, de vértices $(0,0)$, $(150,0)$, $(100,100)$, $(40,160)$ y $(0,160)$. Evaluando el margen en ellos: 0, 6000, 7000, 6400 y 4800 €. El óptimo es $\boldsymbol{E^* = P^* = 100}$ t con un margen de **7000 €/semana**. La elección del método es inmediata: dos variables continuas y todo lineal, luego programación lineal; con dos variables basta el método gráfico, y con miles, un resolvedor como HiGHS (tema 2).

KPIs del plan: utilización del molino $100/100 = 100\,\%$, utilización de la granuladora $(60+30)/90 = 100\,\%$ y demanda de puesta cubierta $100/160 = 62{,}5\,\%$ del potencial. Los dos recursos están saturados; el tema 2 calculará cuánto vale una hora más de cada uno.

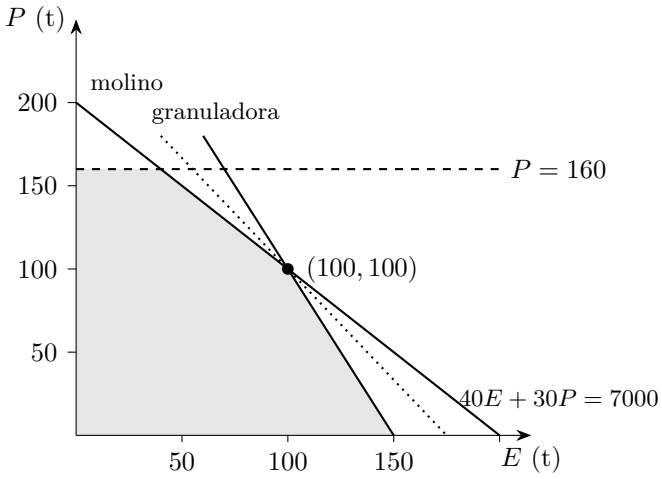


Figura 1.1: Región factible del caso de los piensos (sombreada) y recta de nivel óptima.

1.2 Anatomía de un optimizador con IA

En la industria el modelo matemático es una pieza de un sistema mayor que se ejecuta de forma periódica (cada semana, cada hora, cada cinco minutos). La figura 1.2 muestra sus componentes.

Definición 1.8 (Optimizador con IA). Un *optimizador con IA* es un procedimiento que, a partir de observaciones w (contexto: fecha, temperatura, estado de la planta), produce una decisión

$$\hat{x}(w) \in \arg\min_{x \in \mathcal{X}(\hat{\theta})} f\big(x;\hat{\theta}\big), \qquad \hat{\theta} = m_\phi(w),$$

donde m_ϕ es un modelo aprendido de datos con parámetros ϕ que predice los parámetros inciertos del problema (o el propio valor de una decisión), y el conjunto factible incluye las

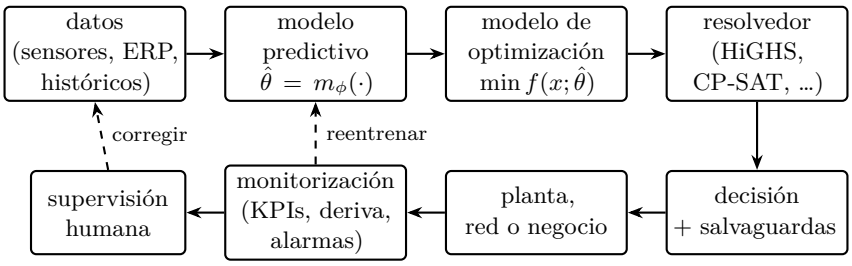


Figura 1.2: Arquitectura de un optimizador con IA. Las flechas continuas forman el ciclo de decisión; las discontinuas, el de aprendizaje y supervisión.

restricciones de seguridad. La calidad del sistema se mide por el coste real $f(\hat{x}(w);\theta)$ con el θ verdadero, no por el error de predicción.

Los componentes de la figura 1.2 son:

1. *Datos*: históricos, tiempo real y datos maestros (capacidades, recetas, tarifas). Su calidad limita todo lo demás.
2. *Modelo predictivo*: estima demandas, tiempos, rendimientos o el estado futuro del sistema (regresión, árboles, redes; módulos 8–11).
3. *Modelo de optimización*: la formulación de la definición 1.1, con los parámetros predichos y las restricciones duras.
4. *Resolvedor*: el algoritmo elegido según la estructura (apartado 1.3).
5. *Decisión con salvaguardas*: comprobaciones independientes del modelo (límites físicos, cambios máximos entre periodos, plan de respaldo) antes de ejecutar.
6. *Monitorización*: KPIs, error de predicción, deriva de los datos, tiempo de cálculo y tasa de intervenciones humanas; disparan el reentrenamiento o la revisión del modelo.

Ejemplo 1.9 (Dos sistemas publicados). *Refrigeración de centros de datos de Google (DeepMind, 2016).* Según la descripción publicada por sus autores [15], se entrenó un conjunto de redes neuronales profundas con datos históricos de miles de sensores (temperaturas, potencias, velocidades de bombas, consignas) para predecir la eficiencia energética media futura (PUE, cociente entre la energía total del edificio y la consumida por los equipos informáticos); otros dos conjuntos de redes predecían la temperatura y la presión de la hora siguiente para comprobar que las acciones recomendadas respetaban los límites de operación. El sistema redujo de forma consistente un 40 % la energía usada en refrigeración, lo que equivalía a una reducción del 15 % de la sobrecarga de PUE. Es exactamente la arquitectura de la figura 1.2: modelos predictivos, un optimizador de las consignas y restricciones de seguridad predichas.

Rutas de UPS (ORION). Holland *et al.* [23] describen el sistema que planifica a diario las rutas de unos 55 000 conductores en Estados Unidos. Los autores estiman, con el despliegue completo, una reducción de unos 100 millones de millas recorridas al año, de 10 millones de galones de combustible y un ahorro anual de 300 a 400 millones de dólares. El núcleo es un problema de rutas con ventanas horarias (tema 3), con reglas operativas que los conductores deben poder aceptar.

1.3 Mapa de métodos de la fase

La estructura matemática del problema, no la moda, decide el método. El cuadro 1.2 resume la elección; la figura 1.3 la presenta como árbol de decisión.

Cuadro 1.2: Mapa de métodos: estructura del problema, familia y herramienta típica.

Estructura	Familia	Métodos y herramientas
objetivo y restricciones lineales, variables continuas	PL (LP)	símplex, punto interior; HiGHS (tema 2)
lineal con decisiones discretas (sí/no, lotes, turnos)	PLEM (MILP)	ramificación y acotación con cortes; HiGHS, SCIP, Gurobi (tema 2)
secuenciación, rutas, asignación con lógica compleja	combinatoria, programación por restricciones	CP-SAT, OR-Tools Routing, búsqueda local (tema 3)
convexo y diferenciable (cuadrático, cónico)	optimización convexa	punto interior; CVXPY con Clarabel u OSQP (tema 4)
no convexo y diferenciable	programación no lineal	SQP, punto interior, multiarranque; SciPy (tema 4)
caja negra barata, sin derivadas	metaheurísticas	recocido, genéticos, CMA-ES, NSGA-II (tema 5)
caja negra cara (simulación, experimento)	optimización bayesiana	modelo sustituto gaussiano y función de adquisición [17, 16]
decisiones secuenciales con incertidumbre	control y RL	control predictivo, aprendizaje por refuerzo (módulo 21) [38]
parámetros inciertos que se predicen	predecir y optimizar, estocástica, robusta	SAA, recurso, conjuntos de incertidumbre (tema 6)
espacio de programas o heurísticas	búsqueda con LLM y evaluador	FunSearch [35], AlphaEvolve [33], OPRO [40]

Observación 1.10 (Modelos de lenguaje en la optimización). Los LLM intervienen en la optimización de dos formas distintas. Como *asistentes de formulación*, traducen un enunciado en lenguaje natural a un modelo para un resolvedor clásico; OptiMUS [1] es un ejemplo publicado para PL y PLEM, y su salida debe verificarse como cualquier código. Como *generadores de candidatos* dentro de un bucle evolutivo con un evaluador automático, proponen programas o soluciones que el evaluador puntúa: FunSearch [35] encontró así construcciones matemáticas y heurísticas de empaquetado, AlphaEvolve [33] extendió la idea a algoritmos completos y OPRO [40] usa el propio LLM como optimizador de instrucciones. En ambos casos la garantía procede del evaluador o del resolvedor, no del modelo de lenguaje; los módulos posteriores de la fase desarrollan este enfoque.

Observación 1.11 (Errores frecuentes al modelizar). (a) *Unidades inconsistentes*: mezclar horas y minutos o toneladas y kilogramos produce soluciones absurdas que el resolvedor da por buenas. Conviene anotar la unidad de cada parámetro y escalar los coeficientes a magnitudes parecidas, lo que además mejora la estabilidad numérica.

(b) *Optimizar el KPI equivocado*: minimizar el coste sin restricción de servicio puede ser

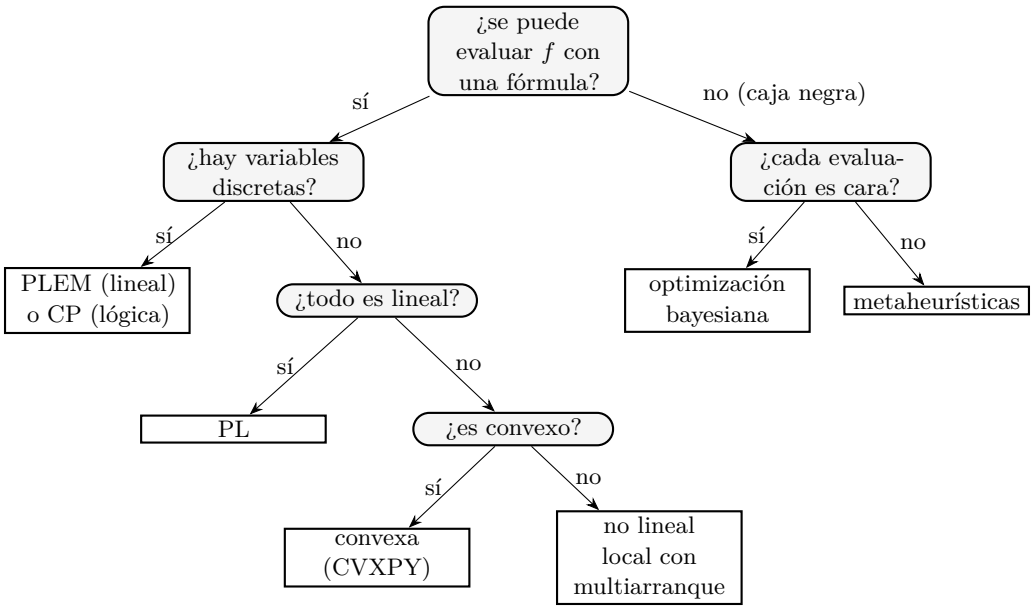


Figura 1.3: Árbol de decisión simplificado para elegir la familia de métodos. Los problemas con parámetros inciertos o decisiones secuenciales se tratan en el tema 6 y en los módulos posteriores.

óptimo y desastroso; hay que revisar los KPIs de la solución, no solo el valor del objetivo.

(c) *Restricciones de seguridad blandas*: una penalización finita siempre puede compensarse con suficiente ahorro; lo que no se puede violar debe ser una restricción dura.

(d) *Infactibilidad sin diagnóstico*: cuando el modelo es infactible conviene añadir variables de holgura penalizadas para saber qué restricción falla.

(e) *Datos maestros desactualizados*: capacidades o tiempos que ya no son los reales invalidan la decisión aunque el algoritmo sea perfecto.

Lecturas recomendadas para este tema

- Bertsimas y Tsitsiklis [5], cap. 1 (formulaciones; lectura de la clase 1 de MIT 6.251J [29]).
- MIT 15.053 [30], clases 1 «Introduction» y 2 «Formulations of linear and non-linear programs».
- Kochenderfer y Wheeler [27], cap. 1 «Introduction».
- R. Evans y J. Gao [15] y C. Holland *et al.* [23], para los dos sistemas industriales.

Ejercicios del tema 1

Ejercicio 1.1 ⋆ Un invernadero de 1 ha controla cada hora la apertura de ventanas, la calefacción y la inyección de CO_2. Se dispone de una predicción de radiación y temperatura exterior. La temperatura interior debe estar entre 16 y 28 ºC; la concentración de CO_2 no debe superar 1000 ppm por seguridad de los trabajadores; se quiere maximizar el crecimiento estimado menos el coste energético. Identifique variables de decisión, parámetros (indicando cuáles se predicen), objetivo, restricciones duras y blandas, y proponga tres KPIs que no coincidan con el objetivo.

Cuadro 1.3: Tecnologías del tema 1: lenguajes de modelización y resolvedores generales.

Herramienta	Para qué sirve	Licencia o tipo	Cuándo elegirla
SciPy (`optimize`)	PL y PLEM con HiGHS, mínimos cuadrados, no lineal local	abierta (BSD-3)	prototipos y modelos pequeños sin dependencias extra
PuLP [34]	modelizar PL/PLEM y enviarlos a CBC, HiGHS, SCIP, Gurobi…	abierta (MIT)	modelos lineales legibles en Python
Pyomo	modelización algebraica general (lineal y no lineal)	abierta (BSD-3)	modelos grandes, con estructura por índices y varios resolvedores
OR-Tools [18]	CP-SAT, rutas, flujos, PL (GLOP)	abierta (Apache 2.0)	combinatoria, programación y rutas
CVXPY [12]	optimización convexa disciplinada	abierta (Apache 2.0)	problemas convexos con verificación automática
Gurobi, CPLEX	resolvedores comerciales de PL/PLEM/cuadráticos	comercial (licencia académica gratuita)	PLEM grandes en producción con exigencia de tiempo

Ejercicio 1.2 ⋆ Asigne a cada problema la familia del cuadro 1.2 y justifique la elección en una línea: (a) mezcla de materias primas de mínimo coste con requisitos nutricionales lineales; (b) decidir qué 5 de 20 almacenes abrir, con costes fijos y de transporte lineales; (c) ajustar 8 parámetros de un simulador de horno que tarda 2 h por ejecución; (d) asignar 300 tareas con precedencias a 12 máquinas; (e) despachar generadores con costes cuadráticos convexos; (f) regular cada minuto la temperatura de un reactor ante perturbaciones.

Ejercicio 1.3 ⋆⋆ Convierta en un programa lineal el problema $\min |x_1| + 2|x_2|$ s.a. $x_1 + x_2 \geq 4$, $x_1 - x_2 \leq 2$, y resuélvalo.

Fuente: adaptado de Bertsimas y Tsitsiklis [5], cap. 1, reformulación de objetivos lineales a trozos (lectura de la clase 1 de MIT 6.251J [29]).

Ejercicio 1.4 ⋆⋆ Una oficina de correos necesita, de lunes a domingo, al menos 17, 13, 15, 19, 14, 16 y 11 empleados. Cada empleado trabaja cinco días consecutivos y descansa dos. (a) Formule el problema de contratar el mínimo número de empleados; explique por qué conviene tomar como variable el número de empleados que *empiezan* cada día. (b) Sumando las siete restricciones, obtenga una cota inferior del óptimo. (c) La relajación lineal vale 22,33 y el óptimo entero, 23; interprete los tres números.

Fuente: adaptado de MIT 15.053, primavera de 2013, clase 2 «Formulations of linear and non-linear programs», ejemplo de los turnos de correos [30].

Ejercicio 1.5 ⋆⋆ En el caso de los piensos (ejemplo 1.7), el margen del pienso de puesta sube a 45 €/t. Encuentre el nuevo plan óptimo con el método de los vértices y calcule sus KPIs. ¿Para qué intervalo de márgenes m_P del pienso de puesta sigue siendo óptimo $(100, 100)$?

Ejercicio 1.6 ⋆⋆ Tres turbinas tienen pérdidas (en kW) que dependen de un reparto $x \in [0, 10]$: $x - 1$, $-2x + 8$ y $0{,}5x + 1$. Formule como programa lineal el problema de minimizar la mayor de las tres pérdidas y resuélvalo gráficamente.

Ejercicio 1.7 ⋆⋆⋆ Para penalizar la falta y el exceso de personal se escribe $\sum_j a_{ij}x_j + d_i - e_i = r_i$ con $d_i, e_i \geq 0$ y se minimiza $\sum_i (\alpha d_i + \beta e_i)$ con $\alpha, \beta > 0$. Demuestre que en toda solución óptima se cumple $d_i e_i = 0$ para todo i, de modo que d_i y e_i son exactamente la falta y el exceso. ¿Sigue siendo cierto si el objetivo es $\sum_i (5d_i^2 + e_i^2)$?

Fuente: adaptado de MIT 15.053, primavera de 2013, clase 2, modificación con penalizaciones por falta y exceso de personal [30].

Ejercicio 1.8 ⋆⋆⋆ Diseñe, siguiendo la figura 1.2, el optimizador del invernadero del ejercicio 1.1: qué datos recoger, qué predecir y con qué modelo, qué familia de optimización usar si el modelo térmico es lineal en los controles, qué salvaguardas independientes añadir y qué cinco magnitudes monitorizar para decidir cuándo reentrenar. Justifique cada elección.

Tema 2

Programación lineal y entera mixta

La programación lineal y la entera mixta resuelven la mayor parte de los problemas de planificación de la industria: producción, mezclas, transporte, turnos, inversiones. Este tema sigue los capítulos 2 a 5, 10 y 11 de Bertsimas y Tsitsiklis [5], que son las lecturas del curso 6.251J del MIT [29], y las clases 6 («Sensitivity analysis and shadow prices»), 10–12 (programación entera y ramificación y acotación) del curso 15.053 [30], con los capítulos 3 («Sensitivity Analysis») y 9 («Integer Programming») de Bradley, Hax y Magnanti [10]. La ramificación y acotación procede de Land y Doig [28]; el resolvedor de referencia es HiGHS [22, 24].

2.1 Programas lineales y vértices

Definición 2.1 (Programa lineal). Un *programa lineal* (PL) en forma canónica es

$$z^{*} = \max\ c^{\mathsf{T}} x \qquad \text{s.a. } Ax \le b, \quad x \ge 0,$$

con $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^{m}$ y $c \in \mathbb{R}^{n}$. Su conjunto factible $\mathcal{P} = \{x : Ax \le b,\ x \ge 0\}$ es un *poliedro*. Un punto $v \in \mathcal{P}$ es un *vértice* si no es combinación convexa $\lambda u + (1-\lambda) w$ de dos puntos distintos $u, w \in \mathcal{P}$ con $\lambda \in (0,1)$; equivalentemente, si en v hay n restricciones activas linealmente independientes [5].

Teorema 2.2 (Teorema fundamental de la programación lineal). *Si $\mathcal{P}$ es no vacío y acotado, el PL tiene un óptimo que es un vértice de $\mathcal{P}$.*

Demostración. Un poliedro acotado y no vacío tiene un número finito de vértices $v_1, \dots, v_K$ y todo punto suyo es combinación convexa de ellos (teorema de representación; Bertsimas y Tsitsiklis [5], cap. 2). Sea $x \in \mathcal{P}$ con $x = \sum_{k} \lambda_k v_k$, $\lambda_k \ge 0$, $\sum_k \lambda_k = 1$. Entonces

$$c^{\mathsf{T}} x = \sum_{k} \lambda_k\, c^{\mathsf{T}} v_k \le \Big(\sum_{k} \lambda_k\Big) \max_{k} c^{\mathsf{T}} v_k = \max_{k} c^{\mathsf{T}} v_k .$$

Luego el vértice con mayor $c^{\mathsf{T}} v_k$ es óptimo. ∎

El *método símplex* (Dantzig) explota el teorema: recorre vértices adyacentes mejorando el objetivo hasta que ninguna arista mejora. Los *métodos de punto interior* avanzan por el interior del poliedro y tienen complejidad polinómica. HiGHS implementa ambos (su símplex dual revisado paralelo se describe en [24]) y un resolvedor de PLEM; SciPy lo usa en `linprog` y `milp` [22].

2.2 Dualidad y precios sombra

Definición 2.3 (Problema dual). El *dual* del PL de la definición 2.1 es

$$w^{*} = \min\ b^{\mathsf{T}} y \qquad \text{s.a. } A^{\mathsf{T}} y \ge c, \quad y \ge 0.$$

Cada variable dual y_i corresponde a la restricción i del primal.

Teorema 2.4 (Dualidad débil). *Si x es factible para el primal e y para el dual, entonces $c^{\mathsf{T}}x \le b^{\mathsf{T}}y$. En consecuencia $z^* \le w^*$, y si $c^{\mathsf{T}}x = b^{\mathsf{T}}y$ ambos son óptimos.*

Demostración. Como $x \ge 0$ y $A^{\mathsf{T}}y \ge c$, se tiene $c^{\mathsf{T}}x \le (A^{\mathsf{T}}y)^{\mathsf{T}}x = y^{\mathsf{T}}(Ax)$. Como $y \ge 0$ y $Ax \le b$, $y^{\mathsf{T}}(Ax) \le y^{\mathsf{T}}b$. Encadenando, $c^{\mathsf{T}}x \le b^{\mathsf{T}}y$. Si hay igualdad, ningún primal factible puede superar $c^{\mathsf{T}}x$ (estaría por encima de $b^{\mathsf{T}}y$) y ningún dual puede bajar de $b^{\mathsf{T}}y$. ∎

Teorema 2.5 (Dualidad fuerte). *Si el primal tiene óptimo, también lo tiene el dual y $z^* = w^*$ (Bertsimas y Tsitsiklis [5], cap. 4).*

Corolario 2.6 (Holgura complementaria). *Sean x e y factibles. Ambos son óptimos si y solo si*

$$y_i\,\big(b_i - (Ax)_i\big) = 0 \quad \text{para todo } i \qquad y \qquad x_j\,\big((A^{\mathsf{T}}y)_j - c_j\big) = 0 \quad \text{para todo } j.$$

Demostración. En la demostración de la dualidad débil, $b^{\mathsf{T}}y - c^{\mathsf{T}}x = \sum_i y_i(b_i - (Ax)_i) + \sum_j x_j((A^{\mathsf{T}}y)_j - c_j)$, suma de términos no negativos. Por la dualidad fuerte, ambos son óptimos si y solo si la diferencia es cero, es decir, si y solo si todos los términos se anulan. ∎

La holgura complementaria tiene una lectura económica directa: un recurso que sobra (restricción no activa) tiene precio cero, y un producto que no se fabrica no cubre con su margen el valor de los recursos que consumiría.

Proposición 2.7 (Precios sombra). *Sea $z^*(b)$ el valor óptimo en función del término independiente. La función z^* es cóncava en el conjunto de b con primal factible y acotado, y si y^* es una solución dual óptima para b, para todo b' de ese conjunto*

$$z^*(b') \le z^*(b) + (y^*)^{\mathsf{T}}(b' - b).$$

Si el dual óptimo es único, z^* es diferenciable en b con $\partial z^*/\partial b_i = y_i^*$: el precio sombra *$y_i^*$ es lo que aumenta el valor óptimo por unidad adicional del recurso i, mientras la base óptima no cambia.*

Demostración. La factibilidad dual ($A^{\mathsf{T}}y \ge c$, $y \ge 0$) no depende de b, así que y^* es factible para el dual del problema con b'. Por la dualidad débil y la fuerte,

$$z^*(b') \le (b')^{\mathsf{T}}y^* = b^{\mathsf{T}}y^* + (b' - b)^{\mathsf{T}}y^* = z^*(b) + (y^*)^{\mathsf{T}}(b' - b).$$

Además $z^*(b') = \min_{y \in D}(b')^{\mathsf{T}}y$, con D el poliedro dual, es un mínimo de funciones lineales de b' y por tanto cóncava. Una función cóncava con un único supergradiente en un punto es diferenciable en él. ∎

Ejemplo 2.8 (Precios sombra en la fábrica de piensos). En el ejemplo 1.7, las restricciones activas en $(100, 100)$ son el molino y la granuladora; la demanda de puesta no lo es ($100 < 160$), luego $y_3^* = 0$. Por la holgura complementaria, como $E, P > 0$, las dos restricciones duales son igualdades:

$$0{,}5y_1 + 0{,}6y_2 = 40, \qquad 0{,}5y_1 + 0{,}3y_2 = 30.$$

Restando, $0{,}3y_2 = 10$, de donde $y_2^* = 33{,}33$ €/h y $y_1^* = (30 - 10)/0{,}5 = 40$ €/h. Comprobación: $b^{\mathsf{T}}y^* = 100 \cdot 40 + 90 \cdot 33{,}33 = 7000$ €, el valor primal. Una hora más de granuladora vale 33,33 € (el cuaderno lo confirma resolviendo con 91 h: 7033,33 €), y no merece la pena pagar más de 40 € por una hora extra de molino.

2.3 Programación entera mixta

Definición 2.9 (PLEM y relajación lineal). Un *programa lineal entero mixto* (PLEM, en inglés MILP) es un PL en el que un subconjunto J de variables debe ser entero: $\max\{c^{\mathsf{T}}x : Ax \le b,\ x \ge 0,\ x_j \in \mathbb{Z}\ (j \in J)\}$. Su *relajación lineal* es el mismo problema sin la condición de integralidad; su valor se denota z_{LP}.

Proposición 2.10 (La relajación acota). *En un problema de maximización, $z^* \le z_{\mathrm{LP}}$; en uno de minimización, $z^* \ge z_{\mathrm{LP}}$. Si la solución de la relajación cumple la integralidad, es óptima para el PLEM.*

Demostración. El conjunto factible del PLEM está contenido en el de la relajación, y el máximo sobre un conjunto mayor no es menor. Si el óptimo de la relajación es entero, es factible para el PLEM y alcanza una cota de su valor, luego es óptimo. ■

La diferencia relativa entre el mejor valor entero conocido (el *incumbente*) y la mejor cota se llama *gap*; los resolvedores se detienen cuando es menor que una tolerancia (por defecto, del orden de 10^{-4}).

Las variables binarias $y \in \{0,1\}$ permiten modelizar decisiones lógicas con restricciones lineales:

(a) *coste fijo o de preparación*: $x \le My$ con coste fy en el objetivo; si se produce ($x > 0$), se paga f;

(b) *lote mínimo*: $Ly \le x \le My$; o no se produce, o se producen al menos L unidades;

(c) *implicación* «si se elige A, se elige B»: $y_A \le y_B$; *exclusión*: $y_A + y_B \le 1$; *al menos k de n*: $\sum_i y_i \ge k$;

(d) *disyunción* «se cumple $a^{\mathsf{T}}x \le b$ o $d^{\mathsf{T}}x \le e$»: $a^{\mathsf{T}}x \le b + M\delta$, $d^{\mathsf{T}}x \le e + M(1-\delta)$, $\delta \in \{0,1\}$.

Proposición 2.11 (Validez y fuerza de una cota big-M). *Sea $\mathcal{X}$ el conjunto factible sin la restricción $x \le My$ y sea $U = \sup\{x : x \in \mathcal{X}\}$.*

(i) La restricción $x \le My$, con $y \in \{0,1\}$, no elimina ninguna solución con $y = 1$ si y solo si $M \ge U$.

(ii) Si $U \le M \le M'$, la relajación lineal con M está contenida en la relajación con M'; la menor cota válida, $M = U$, da la relajación más ajustada.

Demostración. (i) Con $y = 1$ la restricción es $x \le M$, que no corta nada si y solo si $M \ge x$ para todo x factible, es decir, $M \ge U$. (ii) En la relajación, $y \in [0,1]$; si (x,y) cumple $x \le My$ con $y \ge 0$, entonces $x \le My \le M'y$. Por tanto cualquier punto de la relajación con M pertenece a la relajación con M'. ■

Con una M grande la relajación permite valores de y diminutos, por ejemplo $y = x/M$, y paga solo una fracción del coste fijo: la cota es mala y el árbol de búsqueda crece. Una M desmesurada causa además errores numéricos, porque los resolvedores trabajan con tolerancias del orden de 10^{-6} a 10^{-9}.

2.4 Ramificación y acotación

La *ramificación y acotación* (*branch and bound*) [28] explora un árbol de subproblemas. En cada nodo se resuelve la relajación lineal con las cotas acumuladas. Para un problema de maximización:

1. si la relajación es infactible, el nodo se *poda*;
2. si su valor no supera el del incumbente, se poda *por cota*: ningún descendiente puede mejorar (proposición 2.10);
3. si la solución es entera, se actualiza el incumbente y se poda;
4. si no, se elige una variable x_j con valor fraccionario x_j^* y se crean dos hijos con $x_j \le \lfloor x_j^* \rfloor$ y $x_j \ge \lceil x_j^* \rceil$.

Si todas las variables enteras están acotadas, el árbol es finito y el incumbente final es óptimo: cada nodo podado lo es con una justificación válida y las ramas cubren todos los enteros factibles. Si los coeficientes del objetivo son enteros, el valor de cualquier solución entera también lo es, y un nodo puede podarse cuando $\lfloor z_{\mathrm{LP}} \rfloor$ no supera al incumbente. Los resolvedores modernos añaden preproceso, planos de corte (desigualdades válidas que eliminan soluciones fraccionarias; clase 13 de [30]), heurísticas primales y reglas de ramificación elaboradas.

Ejemplo 2.12 (Caso de estudio: plan semanal de una cervecera). Una cervecera planifica cuatro semanas de tres cervezas. La demanda prevista (hL) es

	sem. 1	sem. 2	sem. 3	sem. 4	total
Lager	120	140	160	190	610
IPA	60	50	80	100	290
Tostada	40	50	30	60	180
total	220	240	270	350	1080

La capacidad de fermentación es $C = 280$ hL/semana. Los costes variables son $c = (60, 85, 70)$ €/hL; el almacenamiento en frío cuesta $h = (4, 8, 4)$ €/hL y semana (la IPA pierde aroma y se penaliza más); cada semana en que se elabora una cerveza se paga una preparación y limpieza de $f = 500$ €, y si se elabora, el lote mínimo es de $L = 20$ hL (un fermentador). El inventario inicial y el final son nulos.

Variables: $x_{pt} \ge 0$ (hL elaborados), $I_{pt} \ge 0$ (hL en inventario al final de la semana) e $y_{pt} \in \{0, 1\}$ (se elabora p en la semana t). *Modelo:*

$$\begin{aligned} \min\ & \sum_{p,t} \big(c_p x_{pt} + h_p I_{pt} + f\, y_{pt} \big) \\ \text{s.a.}\ & I_{p,t-1} + x_{pt} - I_{pt} = d_{pt} \quad (I_{p,0} = 0), \qquad \sum_{p} x_{pt} \le C, \\ & L\, y_{pt} \le x_{pt} \le M_{pt}\, y_{pt}, \qquad M_{pt} = \min\Big(C,\ \sum_{s \ge t} d_{ps} \Big). \end{aligned}$$

Por la proposición 2.11, M_{pt} es la menor cota válida: no se puede elaborar más que la capacidad ni, con inventario final nulo, más que la demanda pendiente. *Elección del método:* 12 binarias y 24 continuas con estructura lineal; PLEM con HiGHS. *Por qué no basta un PL:* sin binarias el coste de preparación desaparece y el plan sería producir cada semana su demanda, con nueve preparaciones adicionales que nadie ha pagado.

Resultado (cuaderno, parte 2). Coste mínimo **79 390 €**: coste variable 73 850 € (fijo, porque se produce toda la demanda), almacenamiento 1040 € y nueve preparaciones, 4500 €. Un plan óptimo es

	elaboración x_{pt} (hL)				inventario I_{pt} (hL)			
	1	2	3	4	1	2	3	4
Lager	120	140	170	180	0	0	10	0
IPA	110	0	80	100	50	0	0	0
Tostada	40	140	0	0	0	90	60	0
total	270	280	250	280				

La IPA de la semana 2 y la Tostada de las semanas 3 y 4 se adelantan para ahorrar preparaciones (guardar 50 hL de IPA una semana cuesta 400 €, menos que una preparación), y 10 hL de Lager se adelantan a la semana 3 porque la semana 4 está saturada. La relajación lineal vale 77 284,36 €, de modo que el *gap* de integralidad es $(79\,390 - 77\,284{,}36)/79\,390 = 2{,}65\,\%$; HiGHS cierra ese gap en el nodo raíz, gracias a su preproceso y a sus planos de corte. La enumeración de los $2^{12} = 4096$ patrones de preparación, resolviendo un PL para cada uno, confirma el óptimo.

Precios sombra. Fijando las binarias en su valor óptimo y resolviendo el PL resultante, la capacidad solo tiene precio en la semana 4: 4 €/hL. Un hectolitro más de fermentación esa semana evitaría adelantar un hectolitro de Lager a la semana 3 y ahorraría su almacenamiento. El precio sombra es local: solo se adelantan 10 hL, así que la capacidad adicional vale 4 €/hL para los primeros 10 hL y nada a partir de ahí. Resolviendo de nuevo con 290 y 300 hL en la semana 4 se obtiene 79 350 € en ambos casos: un fermentador extra de 20 hL vale como mucho $10 \cdot 4 = 40$ €, no $20 \cdot 4 = 80$ €.

Cuadro 2.1: Tecnologías del tema 2: programación lineal y entera mixta.

Herramienta	Para qué sirve	Licencia o tipo	Cuándo elegirla
HiGHS [22]	PL (símplex dual, punto interior), PLEM, cuadrático	abierta (MIT)	resolvedor abierto de referencia; incluido en SciPy
SciPy `linprog`/`milp`	interfaz matricial a HiGHS, con duales	abierta (BSD-3)	modelos pequeños y docencia
PuLP [34]	modelización por nombres; CBC, HiGHS, SCIP…	abierta (MIT)	modelos de planificación legibles
SCIP	PLEM y no lineal entero, con cortes y ramificación configurables	abierta (Apache 2.0 desde la 8.0.3)	investigación y PLEM difíciles sin licencia comercial
Gurobi, CPLEX	PL/PLEM a gran escala	comercial	producción con exigencias de tiempo y soporte
OR-Tools (GLOP, MathOpt)	PL y envoltorio de resolvedores	abierta (Apache 2.0)	si ya se usa OR-Tools para rutas o CP

Observación 2.13 (Errores frecuentes en PL y PLEM). (a) *Big-M desmesuradas*: relajaciones flojas, árboles enormes y soluciones con $y = 10^{-7}$ que el resolvedor acepta por tolerancia. Hay que derivar la menor M válida de los datos.

(b) *Leer duales de un PLEM como si fuera un PL*: solo tienen sentido con las enteras fijas y valen mientras no cambie la parte discreta.

(c) *Degeneración*: si hay más restricciones activas que variables, el dual puede no ser único y el precio sombra depende del sentido del cambio (derivadas laterales distintas).

(d) *Óptimos alternativos*: otro plan con el mismo coste puede ser operativamente preferible; conviene un segundo objetivo de desempate.

(e) *Simetría*: fermentadores o camiones idénticos generan soluciones equivalentes que multiplican el árbol; se rompe con restricciones de orden.

(f) *Confiar en el gap por defecto*: un gap del 1 % sobre millones de euros puede ser mucho dinero; se fija según el problema y se informa junto con la solución.

Lecturas recomendadas para este tema

- Bertsimas y Tsitsiklis [5], caps. 2–5 (geometría, símplex, dualidad, sensibilidad) y 10–11 (programación entera), según el calendario de MIT 6.251J [29].
- MIT 15.053 [30], clases 6 «Sensitivity analysis and shadow prices», 10–11 (formulaciones enteras) y 12 «Branch and bound».
- Bradley, Hax y Magnanti [10], cap. 3 «Sensitivity Analysis» y cap. 9 «Integer Programming», §§9.1–9.6.
- A. H. Land y A. G. Doig [28], artículo original de la ramificación y acotación.

Ejercicios del tema 2

Ejercicio 2.1 ⋆ En el ejemplo 2.8, explique con la holgura complementaria por qué el precio sombra de la demanda de pienso de puesta es cero y por qué las dos restricciones duales se cumplen con igualdad. ¿Qué precio máximo pagaría la fábrica por una hora extra de granuladora?

Ejercicio 2.2 ⋆⋆ Escriba el dual del PL de los piensos, compruebe que $y^* = (40;\ 33{,}33;\ 0)$ es factible y verifique la dualidad fuerte.

Ejercicio 2.3 ⋆⋆ Una empresa fabrica sillas, bancos y mesas de jardín. Por unidad consumen 1,2, 1,7 y 1,2 h de curvado (1000 h disponibles), 0,8, 0 y 2,3 h de soldadura (1200 h) y 2, 3 y 4,5 kg de tubo (2000 kg), con márgenes de 3, 3 y 5 \$. El plan óptimo es 700 sillas y 133,33 mesas, con margen 2766,67 \$; los precios sombra son 1,1667 \$/h (curvado), 0 (soldadura) y 0,80 \$/kg (tubo), y el lado derecho del tubo puede aumentar hasta 555,56 kg sin cambiar de base. (a) Un proveedor ofrece tubo a 0,70 \$/kg: ¿conviene comprar 550 kg y cuánto aumenta el margen neto? (b) ¿Qué margen mínimo debe tener un toldo que consuma 1,8 h de curvado, 0,5 h de soldadura y 1,3 kg de tubo para que merezca fabricarse?

Fuente: adaptado de MIT 15.053, primavera de 2013, hoja de problemas 4, problema 1 [31], basado en Bradley, Hax y Magnanti, cap. 3, ejercicio 1 [10].

Ejercicio 2.4 ⋆⋆ Resuelva $\max\ x_1 + 5x_2$ s.a. $-4x_1 + 3x_2 \le 6$, $3x_1 + 2x_2 \le 18$, $x_1, x_2 \ge 0$ enteros por ramificación y acotación, resolviendo cada relajación gráficamente. Dibuje el árbol.

Fuente: adaptado de Bradley, Hax y Magnanti, cap. 9, ejercicio 10 [10].

Ejercicio 2.5 ⋆⋆ Seis inversiones tienen valor actual neto $(33, 45, 25, 17, 39, 23)$ y requieren $(10, 14, 8, 6, 12, 8)$ unidades de capital; el presupuesto es 28. (a) Formule el problema. (b) Resuelva la relajación lineal ordenando por rentabilidad (valor por unidad de capital). (c) La cartera $\{1, 4, 5\}$ vale 89: calcule el gap. (d) Ramifique sobre la variable fraccionaria y calcule las cotas de los dos hijos. ¿Puede podarse alguno?

Fuente: adaptado de MIT 15.053, primavera de 2013, hoja de problemas 6, problema 2 [31].

Ejercicio 2.6 ⋆⋆ Sean $x_1, x_2 \in \{0, 1\}$. Escriba restricciones lineales que definan $w = x_1 \wedge x_2$ e $y = x_1 \vee x_2$ sin variables auxiliares, y $z = x_1 \oplus x_2$ (o exclusivo) con una variable auxiliar. Compruebe las cuatro combinaciones.

Fuente: adaptado de MIT 15.053, primavera de 2013, hoja de problemas 5, problema 3 [31].

Ejercicio 2.7 ⋆⋆ En el caso de la cervecera (ejemplo 2.12): (a) calcule M_{pt} para la Lager en la semana 3 y para la IPA en la semana 4; (b) si la Lager de la semana 3 se elabora en una cantidad de 170 hL, ¿qué valor mínimo puede tomar y en la relajación con $M = 280$ y con $M = 10^4$? ¿Qué parte del coste de preparación se «paga» en cada caso? (c) Exprese con binarias la regla «si se elabora IPA en una semana, no se elabora Tostada esa misma semana».

Fuente: adaptado de MIT 15.053, primavera de 2013, hoja de problemas 5, problema 4 (elegir la menor M válida) [31].

Ejercicio 2.8 ⋆⋆⋆ Demuestre que, para un PL de maximización con dual factible, la función $z^*(b)$ es cóncava y lineal a trozos en el conjunto de b donde el primal es factible. Deduzca que el valor de una hora adicional de un recurso no puede aumentar al disponer de más horas (rendimientos decrecientes).

Tema 3

Problemas combinatorios y programación por restricciones

Rutas, secuencias y calendarios tienen un número de soluciones que crece de forma factorial con el tamaño. Este tema estudia cómo formularlos y qué herramientas los resuelven en la práctica. Sigue la clase 17 («Traveling salesman problem») del curso 15.053 del MIT [30] para la complejidad y las heurísticas, el capítulo 10 de Bertsimas y Tsitsiklis [5] para las formulaciones enteras, el artículo de Solomon [37] para las rutas con ventanas horarias, el de Johnson [25] para el taller con dos máquinas y la documentación de OR-Tools [20, 19, 18] para la programación por restricciones.

3.1 Explosión combinatoria

Proposición 3.1 (Número de circuitos). *Con $n \geq 3$ ciudades y distancias simétricas hay $(n-1)!/2$ circuitos hamiltonianos distintos.*

Demostración. Fijando la ciudad de salida (un circuito no depende de dónde empiece), las $n-1$ restantes pueden ordenarse de $(n-1)!$ maneras. Cada circuito y su recorrido en sentido contrario tienen la misma longitud y se cuentan dos veces; como $n \geq 3$, son ordenaciones distintas. ∎

Con $n = 20$ hay $19!/2 \approx 6{,}1 \cdot 10^{16}$ circuitos. El problema del viajante (TSP) es NP-difícil: no se conoce un algoritmo polinómico, y encontrarlo daría uno para todos los problemas NP-completos [30]. En la práctica se combinan tres enfoques:

(a) *métodos exactos*: PLEM con ramificación, cortes y generación de columnas, o programación dinámica para instancias pequeñas; dan el óptimo y una cota;

(b) *heurísticas constructivas*: vecino más próximo, inserción, ahorros; dan una solución rápida;

(c) *búsqueda local y metaheurísticas*: intercambios 2-opt y 3-opt, recolocación de clientes, búsqueda local guiada, recocido (tema 5).

Definición 3.2 (Movimiento 2-opt). Dado un circuito $(\dots, a, b, \dots, c, d, \dots)$, el movimiento 2-opt elimina las aristas (a, b) y (c, d) y añade (a, c) y (b, d), invirtiendo el tramo de b a c. La longitud cambia en $\Delta = d(a,c) + d(b,d) - d(a,b) - d(c,d)$; el movimiento se aplica si $\Delta < 0$. Un circuito es *2-óptimo* si ningún movimiento 2-opt lo mejora.

En el plano euclídeo, un circuito con dos aristas que se cruzan nunca es 2-óptimo: deshacer el cruce lo acorta, por la desigualdad triangular aplicada a los dos triángulos que forman las diagonales (ejercicio 3.3).

3.2 Rutas de vehículos con ventanas horarias

Definición 3.3 (VRPTW). En el *problema de rutas de vehículos con ventanas horarias* (VRPTW) se tiene un depósito 0, clientes $1,\dots,n$ con demanda q_i, tiempo de servicio s_i y ventana $[a_i, b_i]$, una flota de K vehículos de capacidad Q y tiempos de viaje t_{ij}. Se buscan rutas que empiecen y acaben en el depósito, visiten cada cliente exactamente una vez, no superen la capacidad y empiecen cada servicio dentro de su ventana (se puede esperar si se llega antes de a_i), minimizando el tiempo total de viaje.

Una formulación PLEM usa $x_{ij} \in \{0,1\}$ (un vehículo va de i a j), el instante de inicio de servicio T_i y la carga acumulada u_i:

$$
\begin{aligned}
\min\ & \sum_{i \neq j} t_{ij} x_{ij} \\
\text{s.a.}\ & \sum_{j} x_{ij} = 1, \quad \sum_{j} x_{ji} = 1 \quad (i = 1,\dots,n), \qquad \sum_{j} x_{0j} \le K, \\
& T_j \ge T_i + s_i + t_{ij} - M_{ij}(1 - x_{ij}) \quad (i \neq j,\ j \ge 1), \qquad a_i \le T_i \le b_i, \\
& u_j \ge u_i + q_j - Q(1 - x_{ij}) \quad (i \neq j,\ j \ge 1), \qquad q_i \le u_i \le Q.
\end{aligned}
$$

Las restricciones de tiempo y de carga eliminan además los subcircuitos, porque a lo largo de un ciclo sin depósito T debería crecer indefinidamente.

Proposición 3.4 (Cota big-M de las ventanas). *La restricción temporal con* $M_{ij} = \max(0,\ b_i + s_i + t_{ij} - a_j)$ *es válida: si* $x_{ij} = 1$ *impone la llegada correcta y si* $x_{ij} = 0$ *no elimina ninguna combinación de instantes que respete las ventanas.*

Demostración. Si $x_{ij} = 1$ la restricción es $T_j \ge T_i + s_i + t_{ij}$, la propagación del tiempo. Si $x_{ij} = 0$ queda $T_j \ge T_i + s_i + t_{ij} - M_{ij}$. Como $T_i \le b_i$ y $T_j \ge a_j$, el lado derecho es a lo sumo $b_i + s_i + t_{ij} - M_{ij} \le a_j \le T_j$ cuando $M_{ij} \ge b_i + s_i + t_{ij} - a_j$; la restricción se cumple sola. ■

Con más de unas decenas de clientes, la formulación anterior es lenta, y los resolvedores de rutas usan búsqueda local sobre las propias rutas. OR-Tools modela el tiempo como una *dimensión*: una variable acumulada por nodo, con una holgura que representa la espera y un rango que impone la ventana [20].

Ejemplo 3.5 (Caso de estudio: reparto de barriles con ventanas horarias). El almacén de la cervecera del ejemplo 2.12 abastece a ocho bares con dos furgonetas de 22 barriles. Las coordenadas (km) y los datos de cada bar son:

Nodo	0	1	2	3	4	5	6	7	8
x (km)	0	2	5	6	3	−2	−5	−6	−3
y (km)	0	6	4	−1	−5	−6	−2	3	5
barriles	—	4	6	5	3	7	4	5	6
apertura (min)	0	60	0	120	30	150	0	60	150
cierre (min)	300	120	90	180	120	240	90	150	210

Los tiempos se miden en minutos desde las 8:00; el almacén cierra a los 300 min. En ciudad se usa la distancia de Manhattan y una velocidad media de 30 km/h, es decir, $t_{ij} = 2(|x_i - x_j| + |y_i - y_j|)$ min; cada descarga dura $s = 10$ min. La demanda total es de 40 barriles para una capacidad de 44.

Elección del método. Con ocho clientes el problema puede resolverse de forma exacta por programación dinámica sobre subconjuntos (etiquetas no dominadas de hora de llegada y tiempo de viaje para cada subconjunto y último cliente), lo que sirve para certificar la solución de OR-Tools; con cientos de clientes solo quedaría la búsqueda local.

Resultado (cuaderno, parte 3a). OR-Tools, con construcción por el arco más barato y búsqueda local guiada durante 2 s, encuentra un tiempo total de viaje de **152 min**, y la programación dinámica certifica que es óptimo:

Furgoneta	Ruta y llegadas (min)	Carga y viaje
1	$0 \to 1\,(60) \to 2\,(80) \to 4\,(112) \to 3\,(136) \to 0\,(160)$	18 barriles, 76 min
2	$0 \to 6\,(14) \to 7\,(60) \to 8\,(150) \to 5\,(184) \to 0\,(210)$	22 barriles, 76 min

La primera furgoneta espera 44 min ante el bar 1 (llega a los 16, abre a los 60); la segunda espera 24 min en el bar 7 (llega a los 36, abre a los 60) y 70 min en el bar 8 (llega a los 80, abre a los 150): las ventanas, no la distancia, dominan la solución. Un KPI útil aquí es el tiempo de espera, que el objetivo no penaliza; si se quisiera reducir habría que añadirlo al objetivo o negociar las ventanas.

3.3 Programación por restricciones y taller

Definición 3.6 (Problema de satisfacción de restricciones). Un *problema de satisfacción de restricciones* consta de variables $v_1, \dots, v_k$ con dominios finitos $D_1, \dots, D_k$ y un conjunto de restricciones, cada una una relación sobre algunas variables. La *programación por restricciones* (CP) lo resuelve alternando *propagación* (eliminar de los dominios valores que no pueden formar parte de ninguna solución) y *búsqueda* (fijar una variable y retroceder si se llega a un dominio vacío). Con un objetivo, se añade la restricción «objetivo mejor que el incumbente» cada vez que se encuentra una solución.

La CP brilla cuando las restricciones son lógicas o de secuenciación, difíciles de expresar linealmente. Sus restricciones globales encapsulan estructuras frecuentes con propagadores eficientes: `AllDifferent`, `NoOverlap` (intervalos que no se solapan en un recurso), `Cumulative` (recurso con capacidad). CP-SAT, de OR-Tools, combina propagación de restricciones con técnicas de resolvedores SAT y de programación entera, y exige coeficientes enteros [18].

Definición 3.7 (Job-shop). En el problema de *taller* (*job-shop*) hay J trabajos; el trabajo j es una secuencia de operaciones $(m_{j1}, p_{j1}), \dots, (m_{jk_j}, p_{jk_j})$ que deben ejecutarse en ese orden, cada una en una máquina m y con duración p. Cada máquina procesa una operación a la vez y sin interrupción. Se minimiza el *makespan* $C_{\max}$, el instante en que termina el último trabajo.

En CP-SAT cada operación es un intervalo $[S_{jk}, S_{jk} + p_{jk})$; se impone $S_{j,k+1} \geq S_{jk} + p_{jk}$, una restricción `NoOverlap` por máquina y $C_{\max} \geq S_{jk_j} + p_{jk_j}$ [19]. En PLEM, cada par de operaciones en la misma máquina necesita una binaria de orden y dos restricciones big-M, y la relajación lineal resultante es muy débil.

Proposición 3.8 (Cotas inferiores del makespan). *Para todo programa factible,*

$$C_{\max} \;\geq\; \max\Big(\max_{m} \sum_{(j,k)\colon m_{jk}=m} p_{jk},\quad \max_{j} \sum_{k} p_{jk}\Big).$$

Demostración. Las operaciones de la máquina m no se solapan y empiezan en instantes ≥ 0, así que la última termina como pronto en la suma de sus duraciones. Las operaciones de un trabajo se ejecutan en serie, así que el trabajo termina como pronto en la suma de las suyas. $C_{\max}$ es mayor o igual que cualquier instante de fin. ■

Ejemplo 3.9 (Caso de estudio: taller mecánico). Un taller recibe cuatro pedidos que pasan por torno (T), fresadora (F) y taladro (D) en el orden indicado, con duraciones en horas:

Pedido	Operaciones (máquina, h)
P1	(T, 3), (F, 2), (D, 2)
P2	(F, 4), (T, 2), (D, 1)
P3	(D, 3), (T, 3), (F, 2)
P4	(T, 2), (D, 3), (F, 3)

Las cargas son 10 h (torno), 11 h (fresadora) y 9 h (taladro), y los pedidos duran 7, 7, 8 y 8 h; por la proposición 3.8, $C_{\max} \geq 11$ h. *Elección del método:* secuenciación con recursos disyuntivos, CP-SAT. Con cuatro pedidos se puede además enumerar el orden de los pedidos en cada máquina, $(4!)^3 = 13\,824$ combinaciones, y construir para cada una el programa que adelanta cada operación al máximo.

Resultado (cuaderno, parte 3b). CP-SAT demuestra que el óptimo es $\boldsymbol{C_{\max} = 12}$ h, y la enumeración lo confirma. Un programa óptimo es: torno P4 [0,2], P1 [2,5], P2 [5,7], P3 [7,10]; fresadora P2 [0,4], P1 [5,7], P4 [7,10], P3 [10,12]; taladro P3 [0,3], P4 [3,6], P1 [7,9], P2 [9,10]. La cota de 11 h no se alcanza: la fresadora, que es el cuello de botella, no puede empezar el trabajo de P1 hasta que este sale del torno. La diferencia entre la cota y el óptimo es la información que un jefe de taller necesita para negociar plazos.

Cuadro 3.1: Tecnologías del tema 3: combinatoria, rutas y programación por restricciones.

Herramienta	Para qué sirve	Licencia o tipo	Cuándo elegirla
OR-Tools CP-SAT [18]	CP con intervalos, `NoOverlap`, `Cumulative`; también PLEM con coeficientes enteros	abierta (Apache 2.0)	programación de talleres, turnos y calendarios
OR-Tools Routing [20]	VRP con capacidades, ventanas, recogidas y entregas	abierta (Apache 2.0)	rutas reales de decenas a miles de paradas
PLEM (HiGHS, SCIP, Gurobi)	formulaciones con binarias de orden o de arco	abierta o comercial	instancias pequeñas, o con fuerte estructura lineal
Programación dinámica propia	exacto sobre subconjuntos	código propio	certificar instancias pequeñas
Heurísticas propias (2-opt, inserción)	solución rápida y controlable	código propio	tiempo real o reglas de negocio muy específicas

Observación 3.10 (Errores frecuentes en problemas combinatorios). (a) *Tiempos de viaje irreales*: distancias en línea recta o velocidades medias sin franja horaria producen rutas

que no se pueden cumplir; los tiempos deben proceder de la red viaria y, a ser posible, del histórico.

(b) *Reglas tácitas no modelizadas*: conductores que no aceptan rutas que cruzan la ciudad, máquinas que requieren un operario concreto. Las soluciones que ignoran esas reglas no se ejecutan; en ORION, que las rutas fueran aceptables para los conductores fue parte del diseño [23].

(c) *Comparar heurísticas sin cota*: sin una cota inferior no se sabe si una solución está a un 1 % o a un 30 % del óptimo.

(d) *Límites de tiempo sin semilla ni registro*: con búsqueda local y paralelismo, dos ejecuciones pueden dar soluciones distintas; para auditar hay que fijar semilla, número de hilos y límite.

(e) *Escalar CP-SAT con reales*: CP-SAT exige enteros; redondear tiempos de forma descuidada introduce infactibilidades o pérdida de precisión.

Lecturas recomendadas para este tema

- MIT 15.053 [30], clase 17 «Networks 3: Traveling salesman problem» (complejidad, vecino más próximo, 2-opt y 3-opt, recocido).
- Bertsimas y Tsitsiklis [5], cap. 10 (formulaciones de programación entera).
- M. M. Solomon [37], heurísticas e instancias de referencia para el VRPTW.
- Documentación de OR-Tools: «Vehicle Routing Problem with Time Windows» [20] y «The Job Shop Problem» [19].

Ejercicios del tema 3

Ejercicio 3.1 ⋆ Calcule el número de circuitos distintos de un TSP simétrico con 10 y con 20 ciudades. ¿Cuánto tardaría en evaluarlos todos un ordenador que evalúa 10^9 circuitos por segundo? Compare con la tabla de la clase 17 de 15.053.

Fuente: adaptado de MIT 15.053, primavera de 2013, clase 17, tabla de fuerza bruta frente a una cota polinómica [30].

Ejercicio 3.2 ⋆⋆ Con los datos del ejemplo 3.5, compruebe que la ruta $0 \to 1 \to 2 \to 4 \to 3 \to 0$ es factible calculando la hora de llegada y la espera en cada bar, y su tiempo de viaje. Después compruebe que la ruta $0 \to 3 \to 1 \to 0$ es infactible.

Ejercicio 3.3 ⋆⋆ Cuatro puntos tienen coordenadas $A = (0, 0)$, $B = (4, 0)$, $C = (4, 3)$ y $D = (0, 3)$. (a) Calcule la longitud euclídea del circuito $A \to C \to B \to D \to A$ y la del que resulta de aplicar el movimiento 2-opt que elimina las aristas cruzadas. (b) Demuestre que en el plano, si dos aristas (a, b) y (c, d) de un circuito se cruzan, el movimiento 2-opt correspondiente reduce la longitud.

Fuente: adaptado de MIT 15.053, primavera de 2013, clase 17, heurística 2-opt [30].

Ejercicio 3.4 ⋆⋆ Una emisora de radio programa anuncios de 12, 18, 22, 35, 40 y 59 s en bloques de 60 s. (a) Formule como PLEM el problema de usar el mínimo número de bloques.

(b) Obtenga una cota inferior con la suma de duraciones y encuentre una solución que la alcance.

Fuente: adaptado de MIT 15.053, primavera de 2013, hoja de problemas 5, problema 1 [31].

Ejercicio 3.5 ⋆⋆ Cinco piezas pasan por una sierra y después por una pulidora, con tiempos (h) $J1 = (3, 6)$, $J2 = (5, 2)$, $J3 = (1, 2)$, $J4 = (6, 6)$, $J5 = (7, 5)$. La regla de Johnson coloca primero, en orden creciente del tiempo en la primera máquina, las piezas con $p_1 \leq p_2$, y después, en orden decreciente del tiempo en la segunda, las piezas con $p_1 > p_2$. Aplíquela y calcule el makespan. ¿Qué cota inferior da la proposición 3.8?

Fuente: adaptado de S. M. Johnson [25], regla para dos máquinas en serie.

Ejercicio 3.6 ⋆⋆ Para el ejemplo 3.5, calcule la cota M_{ij} de la proposición 3.4 para los arcos $1 \to 2$, $8 \to 5$ y $3 \to 1$. Demuestre que el arco $3 \to 1$ no puede formar parte de ninguna ruta factible y describa un preproceso que elimine de antemano todos los arcos de ese tipo.

Ejercicio 3.7 ⋆⋆⋆ (a) Demuestre la proposición 3.8. (b) Construya una instancia de dos trabajos y dos máquinas en la que la cota se alcance y otra en la que no. (c) Razone por qué, en el ejemplo 3.9, la fresadora no puede terminar antes de las 12 h: estudie qué operaciones deben preceder a la primera tarea de la fresadora que no sea la de P2.

Tema 4

Optimización continua y convexa

Cuando las variables son continuas y el problema es convexo, todo mínimo local es global, existen certificados de optimalidad y los multiplicadores tienen interpretación económica. Este tema sigue los capítulos 4 («Convex optimization problems») y 5 («Duality»), en especial las secciones 5.5 («Optimality conditions») y 5.6 («Perturbation and sensitivity analysis»), de Boyd y Vandenberghe [8], texto del curso EE364a de Stanford; el capítulo 12 de Nocedal y Wright [32] para las condiciones de Karush–Kuhn–Tucker en problemas no convexos; y el capítulo 3 («Economic Dispatch of Thermal Units and Methods of Solution») de Wood, Wollenberg y Sheblé [39] para el caso de estudio. Las herramientas son CVXPY [12, 13] y SciPy. El módulo 7 (tema 1) introdujo la convexidad en el contexto del entrenamiento; aquí se añaden las restricciones.

4.1 Problemas convexos

Definición 4.1 (Problema convexo). El problema de la definición 1.1 es *convexo* si $X = \mathbb{R}^n$, f y las g_i son funciones convexas y las h_j son afines, $h_j(x) = a_j^{\mathsf{T}} x - b_j$. Su conjunto factible es entonces convexo, como intersección de subniveles de funciones convexas e hiperplanos.

Teorema 4.2 (Local implica global). *En un problema convexo, todo óptimo local es óptimo global.*

Demostración. Sea $x^\ast$ óptimo local en $\mathcal{X} \cap B(x^\ast, r)$ y supóngase que existe $\tilde{x} \in \mathcal{X}$ con $f(\tilde{x}) < f(x^\ast)$. Para $\theta \in (0,1]$ el punto $x_\theta = (1-\theta)x^\ast + \theta\tilde{x}$ es factible, por la convexidad de $\mathcal{X}$, y $f(x_\theta) \le (1-\theta)f(x^\ast) + \theta f(\tilde{x}) < f(x^\ast)$, por la de f. Tomando θ pequeño, $x_\theta \in B(x^\ast, r)$, lo que contradice la optimalidad local. ∎

Las clases convexas más usadas, de menor a mayor generalidad, son la programación lineal, la cuadrática (objetivo $\tfrac{1}{2}x^{\mathsf{T}}Px + q^{\mathsf{T}}x$ con $P \succeq 0$ y restricciones lineales), la cónica de segundo orden y la semidefinida. CVXPY sigue las reglas de la *programación convexa disciplinada* (DCP): construye las expresiones con funciones atómicas de curvatura conocida y reglas de composición que garantizan la convexidad, de modo que rechaza un modelo cuya convexidad no puede certificar, y lo traduce a la forma cónica que aceptan resolvedores como Clarabel, SCS u OSQP [12, 13].

4.2 Lagrangiana, dualidad y condiciones KKT

Definición 4.3 (Lagrangiana y función dual). Para el problema de la definición 1.1 con $X = \mathbb{R}^n$, la *lagrangiana* es

$$\mathcal{L}(x, \lambda, \nu) = f(x) + \sum_{i=1}^{m} \lambda_i g_i(x) + \sum_{j=1}^{p} \nu_j h_j(x), \qquad \lambda \ge 0,$$

y la *función dual* es $q(\lambda,\nu)=\inf_x \mathcal{L}(x,\lambda,\nu)$.

Proposición 4.4 (Dualidad débil). *Si $\lambda\geq 0$, entonces $q(\lambda,\nu)\leq f(x)$ para todo x factible; por tanto $q(\lambda,\nu)\leq p^*$, el valor óptimo.*

Demostración. Si x es factible, $g_i(x)\leq 0$ y $h_j(x)=0$, luego $\sum_i \lambda_i g_i(x)+\sum_j \nu_j h_j(x)\leq 0$ y $\mathcal{L}(x,\lambda,\nu)\leq f(x)$. El ínfimo sobre todos los x es menor o igual que el valor en ese x. ∎

En un problema convexo que cumple la *condición de Slater* (existe un punto estrictamente factible, $g_i(x)<0$ para las restricciones no afines), la dualidad es fuerte: $\max q = p^*$ (Boyd y Vandenberghe [8], cap. 5).

Teorema 4.5 (Condiciones de Karush–Kuhn–Tucker). *Sean f, g_i y h_j diferenciables. Se dice que (x^*,λ^*,ν^*) cumple las condiciones KKT si*

(i) factibilidad primal*: $g_i(x^*)\leq 0$, $h_j(x^*)=0$;*

(ii) factibilidad dual*: $\lambda^*\geq 0$;*

(iii) holgura complementaria*: $\lambda_i^* g_i(x^*)=0$ para todo i;*

(iv) estacionariedad*: $\nabla f(x^*)+\sum_i \lambda_i^*\nabla g_i(x^*)+\sum_j \nu_j^*\nabla h_j(x^*)=0$.*

Si el problema es convexo y se cumplen las condiciones KKT, x^* es óptimo global. Si el problema es convexo y cumple la condición de Slater, todo óptimo satisface las KKT para algún (λ^*,ν^*) [8]. En problemas no convexos, las KKT son necesarias en un mínimo local bajo una cualificación de restricciones, pero no suficientes [32].

Demostración de la suficiencia. Con $\lambda^*\geq 0$ y h_j afines, $x\mapsto \mathcal{L}(x,\lambda^*,\nu^*)$ es convexa y diferenciable, y por (iv) su gradiente se anula en x^*; una función convexa alcanza su mínimo donde se anula el gradiente, así que $q(\lambda^*,\nu^*)=\mathcal{L}(x^*,\lambda^*,\nu^*)$. Por (i) y (iii), $\mathcal{L}(x^*,\lambda^*,\nu^*)=f(x^*)$. Para cualquier x factible, por la proposición 4.4, $f(x)\geq q(\lambda^*,\nu^*)=f(x^*)$. ∎

Proposición 4.6 (Multiplicadores como sensibilidades). *Sea el problema convexo perturbado $\min f(x)$ s.a. $g_i(x)\leq u_i$, $h_j(x)=w_j$, con valor óptimo $p^*(u,w)$, y sea (λ^*,ν^*) dual óptimo del problema sin perturbar con dualidad fuerte. Entonces*

$$p^*(u,w)\ \geq\ p^*(0,0)-\lambda^{*\mathsf{T}}u-\nu^{*\mathsf{T}}w,$$

y si p^* es diferenciable en $(0,0)$, $\partial p^*/\partial u_i=-\lambda_i^*$ y $\partial p^*/\partial w_j=-\nu_j^*$.

Demostración. Para x factible en el problema perturbado, $f(x)\geq f(x)+\sum_i \lambda_i^*(g_i(x)-u_i)+\sum_j \nu_j^*(h_j(x)-w_j)\geq q(\lambda^*,\nu^*)-\lambda^{*\mathsf{T}}u-\nu^{*\mathsf{T}}w$, y $q(\lambda^*,\nu^*)=p^*(0,0)$. Tomando el ínfimo en x se obtiene la desigualdad. Si p^* es diferenciable, la desigualdad dice que el plano $p^*(0,0)-\lambda^{*\mathsf{T}}u-\nu^{*\mathsf{T}}w$ queda por debajo de la función y la toca en el origen, de modo que coincide con su plano tangente (Boyd y Vandenberghe [8], §5.6). ∎

Es la generalización de los precios sombra de la proposición 2.7: relajar una restricción activa abarata el óptimo, en primera aproximación, en su multiplicador por unidad.

4.3 Caso de estudio: despacho económico

Ejemplo 4.7 (Despacho económico de tres grupos térmicos). Un operador debe cubrir una demanda de $D = 850$ MW durante una hora con tres grupos térmicos. El coste horario de cada grupo, ajustado a sus curvas de consumo, es cuadrático, $C_i(P_i) = a_i + b_i P_i + c_i P_i^2$ (€/h):

Grupo	a_i (€/h)	b_i (€/MWh)	c_i (€/MW^{2}h)	$P_i^{\min}$ (MW)	$P_i^{\max}$ (MW)
1	500	18	0,020	100	400
2	400	20	0,010	50	350
3	300	26	0,005	50	300

Modelo. $\min \sum_i C_i(P_i)$ s.a. $\sum_i P_i = D$ y $P_i^{\min} \le P_i \le P_i^{\max}$. Como $c_i > 0$, el objetivo es convexo y las restricciones son lineales: es un programa cuadrático convexo y se cumple la condición de Slater (por ejemplo, $P = (300, 300, 250)$ es estrictamente factible en los límites). *Elección del método:* KKT a mano para entender la solución, CVXPY para resolverla y verificarla.

Condiciones KKT. Con multiplicador λ para el balance y $\mu_i^{\pm} \ge 0$ para los límites, la estacionariedad es $b_i + 2c_iP_i - \lambda - \mu_i^- + \mu_i^+ = 0$. Si ningún grupo está en un límite, todos operan al mismo *coste incremental*:

$$b_i + 2c_iP_i = \lambda \quad \Longrightarrow \quad P_i = \frac{\lambda - b_i}{2c_i} = 25(\lambda - 18),\ 50(\lambda - 20),\ 100(\lambda - 26).$$

Paso 1. Sumando e igualando a D: $175\lambda - 4050 = 850$, de donde $\lambda = 28$ y $P = (250, 400, 200)$; pero $P_2 = 400 > 350$ viola el límite. *Paso 2.* Se fija $P_2 = 350$ (límite activo) y se reparte el resto, 500 MW, entre los grupos 1 y 3: $25(\lambda - 18) + 100(\lambda - 26) = 500$, es decir, $125\lambda = 3550$ y $\lambda = 28{,}4$ €/MWh. Entonces $P_1 = 25 \cdot 10{,}4 = 260$ y $P_3 = 100 \cdot 2{,}4 = 240$ MW, ambos dentro de sus límites. *Paso 3.* El multiplicador del límite del grupo 2 es $\mu_2^+ = \lambda - (b_2 + 2c_2P_2) = 28{,}4 - 27 = 1{,}4 \ge 0$: las KKT se cumplen y, por el teorema 4.5, la solución es óptima.

Resultado. $\boldsymbol{P^* = (260,\ 350,\ 240)}$ MW, con coste **21 985 €/h** $(6532 + 8625 + 6828)$. El multiplicador $\lambda = 28{,}4$ €/MWh es el precio marginal del sistema: por la proposición 4.6, 10 MW más de demanda costarían unos 284 €/h; el valor exacto, resolviendo de nuevo, es 284,4 €/h, porque el coste es cuadrático. El multiplicador $\mu_2^+ = 1{,}4$ €/MWh indica cuánto se ahorraría por MW si el grupo 2 pudiera producir más. CVXPY reproduce la solución y devuelve los mismos multiplicadores (cuaderno, parte 4):

```
P = cp.Variable(3); bal = cp.sum(P) == D
coste = cp.sum(a + cp.multiply(b, P) + cp.multiply(c, cp.square(P)))
cp.Problem(cp.Minimize(coste), [bal, P >= Pmin, P <= Pmax]).solve()
bal.dual_value   # 28,4 en valor absoluto (signo según convenio)
```

Observación 4.8 (Cuando se pierde la convexidad). El caso anterior deja de ser convexo con detalles realistas: costes con efecto de apertura de válvulas (términos sinusoidales), mínimos técnicos con arranque y parada (variables binarias, el problema de asignación de unidades del cap. 4 de [39]) o mezclas con calidades que se multiplican por caudales (términos bilineales). Entonces las KKT son solo necesarias, los métodos locales (SQP, punto interior) pueden quedarse en óptimos locales y conviene arrancar desde varios puntos, usar un resolvedor global o reformular. En el ajuste de redes neuronales del módulo 7 el problema tampoco es convexo, pero allí basta con un buen mínimo local.

Cuadro 4.1: Tecnologías del tema 4: optimización continua.

Herramienta	Para qué sirve	Licencia o tipo	Cuándo elegirla
CVXPY [12]	modelización convexa con verificación DCP y duales	abierta (Apache 2.0)	cualquier problema convexo de tamaño medio
Clarabel, SCS, OSQP	resolvedores cónicos (Clarabel, SCS) y cuadráticos (OSQP)	abiertos (Apache 2.0; SCS, MIT)	los usa CVXPY; OSQP, para control predictivo rápido
SciPy `minimize`	SLSQP, `trust-constr`, L-BFGS-B	abierta (BSD-3)	no lineal local con pocas variables
Ipopt	punto interior no lineal a gran escala	abierta (EPL-2.0)	no lineal grande con derivadas (vía Pyomo o CasADi)
Gurobi	cuadrático y no convexo bilineal global	comercial	mezclas y redes con términos bilineales

Observación 4.9 (Errores frecuentes en optimización continua). (a) *Creer que el problema es convexo sin comprobarlo*: un coste cóncavo a trozos (descuentos por volumen) o una restricción $x_1 x_2 \geq k$ rompen la convexidad; DCP lo detecta, un resolvedor local no.

(b) *Signos de los duales*: cada herramienta tiene su convenio (`dual_value` en CVXPY, `marginals` en SciPy); hay que comprobar el signo con una perturbación pequeña antes de usarlo como precio.

(c) *Escalado*: mezclar MW con €/MWh^2 produce coeficientes de órdenes muy distintos y tolerancias que no significan lo mismo en todas las restricciones.

(d) *Diferencias finitas en simuladores con ruido*: el gradiente numérico de una función ruidosa es basura; en ese caso conviene un método sin derivadas (tema 5).

(e) *Ignorar los límites de validez del modelo*: una curva de coste ajustada entre 100 y 400 MW no dice nada a 450 MW; los límites técnicos deben ser restricciones duras.

Lecturas recomendadas para este tema

- Boyd y Vandenberghe [8], cap. 4 (§4.3 «Linear optimization problems», §4.4 «Quadratic optimization problems») y cap. 5 (§5.5 «Optimality conditions», §5.6 «Perturbation and sensitivity analysis»).
- Nocedal y Wright [32], cap. 12 (teoría de la optimización con restricciones).
- Wood, Wollenberg y Sheblé [39], cap. 3, despacho económico de grupos térmicos.
- Documentación de CVXPY [13]: «Disciplined Convex Programming» y variables duales.

Ejercicios del tema 4

Ejercicio 4.1 ⋆ Indique si cada problema es convexo y por qué: (a) $\min x_1^2 + x_2^2$ s.a. $x_1 + x_2 \geq 1$; (b) $\min -\log x_1 - \log x_2$ s.a. $x_1 + x_2 = 1$; (c) $\min x_1^2$ s.a. $x_1^2 + x_2^2 = 1$; (d) $\min \max(x_1, x_2)$ s.a. $x \geq 0$, $x_1 x_2 \geq 1$; (e) $\min \|Ax - b\|_2$ s.a. $\|x\|_\infty \leq 1$.

Ejercicio 4.2 ⋆⋆ Resuelva con las condiciones KKT el problema $\min x_1^2+x_2^2$ s.a. $x_1+2x_2 \geq 5$. Calcule el multiplicador e interprételo: ¿cuánto cambia aproximadamente el valor óptimo si el lado derecho pasa de 5 a 5,1? Compruebe con el valor exacto.

Fuente: adaptado de Boyd y Vandenberghe [8], cap. 5, §5.5 (condiciones KKT) y §5.6 (sensibilidad).

Ejercicio 4.3 ⋆⋆ Dos grupos tienen costes $C_1 = 20P_1 + 0{,}01P_1^2$ y $C_2 = 18P_2 + 0{,}02P_2^2$ (€/h) y deben cubrir 500 MW, sin límites activos. Obtenga el despacho por la regla del coste incremental igual y el precio marginal. Compruebe el resultado con el coste total.

Fuente: adaptado de Wood, Wollenberg y Sheblé [39], cap. 3, despacho económico por igualdad de costes incrementales.

Ejercicio 4.4 ⋆⋆ Se reparte una potencia total de 1 W entre tres canales con niveles de ruido $\alpha = (0{,}5;\ 1;\ 1{,}5)$ para maximizar $\sum_i \log(\alpha_i + x_i)$ con $x \geq 0$ y $\sum_i x_i = 1$. Escriba las KKT, deduzca que $x_i = \max(0,\ 1/\nu - \alpha_i)$ y calcule ν y la asignación.

Fuente: adaptado de Boyd y Vandenberghe [8], cap. 5, §5.5, ejemplo del llenado de agua (*water-filling*).

Ejercicio 4.5 ⋆⋆ En el ejemplo 4.7: (a) estime con λ el ahorro de reducir la demanda en 20 MW y compárelo con el valor exacto; (b) ¿hasta qué demanda sigue activo solo el límite superior del grupo 2, si los demás límites no cambian?

Ejercicio 4.6 ⋆⋆ Para el despacho sin límites técnicos del ejemplo 4.7 (paso 1), calcule la función dual $q(\lambda) = \min_P \left[\sum_i C_i(P_i) - \lambda(\sum_i P_i - D)\right]$ de forma explícita y compruebe que su máximo se alcanza en $\lambda = 28$ y vale lo mismo que el coste primal.

Ejercicio 4.7 ⋆⋆⋆ Sea f convexa y diferenciable y $\mathcal{X}$ convexo. Demuestre que $x^* \in \mathcal{X}$ minimiza f en $\mathcal{X}$ si y solo si $\nabla f(x^*)^{\mathsf{T}}(x - x^*) \geq 0$ para todo $x \in \mathcal{X}$. Interprete la condición geométricamente y deduzca la condición $\nabla f(x^*) = 0$ cuando x^* es interior.

Fuente: adaptado de Boyd y Vandenberghe [8], cap. 4, criterio de optimalidad para funciones diferenciables.

Tema 5

Metaheurísticas, optimización sin derivadas y multiobjetivo

Cuando el objetivo solo puede evaluarse (un simulador, un código heredado, un ensayo) o cuando la estructura del problema es tan irregular que ningún resolvedor exacto escala, se recurre a métodos que solo usan evaluaciones de f. Este tema sigue los capítulos 7 («Direct Methods»), 8 («Stochastic Methods»), 9 («Population Methods») y 12 («Multiobjective Optimization») de Kochenderfer y Wheeler [27], la clase 17 del curso 15.053 [30] para el recocido, y los artículos originales de Kirkpatrick, Gelatt y Vecchi [26] (recocido simulado), Hansen [21] (CMA-ES) y Deb *et al.* [11] (NSGA-II).

5.1 Optimización de caja negra

Definición 5.1 (Problema de caja negra). Un problema $\min_{x\in\mathcal{X}} f(x)$ es de *caja negra* si solo se dispone de un oráculo que devuelve $f(x)$ (quizá con ruido) para cada x consultado, sin gradientes ni estructura explícita. Su coste se mide por el *número de evaluaciones*.

Hay dos regímenes. Si cada evaluación es barata (milisegundos), se pueden permitir miles o millones de evaluaciones y se usan metaheurísticas. Si es cara (horas de simulación o un experimento de planta), cada evaluación debe elegirse con cuidado con un modelo sustituto, como en la optimización bayesiana [17, 16], que la fase desarrolla más adelante. Los métodos directos locales, como Nelder–Mead o Powell (cap. 7 de [27]), son adecuados cuando el problema es continuo, de pocas variables y con un único valle.

5.2 Recocido simulado

El recocido simulado [26] imita el enfriamiento lento de un metal. Desde una solución x se propone un vecino x' (por ejemplo, intercambiar dos departamentos) con un mecanismo simétrico, $\mathbb{P}(x \to x') = \mathbb{P}(x' \to x)$, y se acepta con la probabilidad de Metropolis

$$\alpha(x, x') = \min\Big(1,\ e^{-(f(x')-f(x))/T}\Big),$$

donde la temperatura $T > 0$ disminuye según un calendario, típicamente $T_{k+1} = \rho T_k$ con $\rho \in (0{,}9;\ 0{,}999)$. Con T alta se aceptan muchos empeoramientos y se explora; con T baja solo se aceptan mejoras y se explota.

Proposición 5.2 (Distribución estacionaria de Boltzmann). *Sea $\mathcal{X}$ finito, la propuesta simétrica e irreducible y T fija. La cadena de Markov del recocido satisface el equilibrio detallado con*

$$\pi_T(x) = \frac{e^{-f(x)/T}}{\sum_{z\in\mathcal{X}} e^{-f(z)/T}},$$

que es por tanto una distribución estacionaria. Cuando $T \to 0$, π_T se concentra uniformemente en el conjunto de mínimos globales.

Demostración. Para $x \neq x'$, la probabilidad de transición es $P(x, x') = \mathbb{P}(x \to x')\,\alpha(x, x')$. Supóngase $f(x') \geq f(x)$. Entonces $\alpha(x, x') = e^{-(f(x')-f(x))/T}$ y $\alpha(x', x) = 1$, y

$$\pi_T(x)P(x, x') \propto e^{-f(x)/T}\,\mathbb{P}(x \to x')\,e^{-(f(x')-f(x))/T} = e^{-f(x')/T}\,\mathbb{P}(x' \to x) \propto \pi_T(x')P(x', x).$$

El caso $f(x') < f(x)$ es simétrico. Sumando el equilibrio detallado sobre x se obtiene $\sum_x \pi_T(x)P(x, x') = \pi_T(x')$. Para el límite, sea $f^* = \min f$ y $\mathcal{X}^*$ el conjunto de minimizadores: $\pi_T(x) = e^{-(f(x)-f^*)/T} / \sum_z e^{-(f(z)-f^*)/T}$; el numerador tiende a 1 si $x \in \mathcal{X}^*$ y a 0 en otro caso, y el denominador tiende a $|\mathcal{X}^*|$. ∎

La distribución de Boltzmann es la del módulo 6 (tema 5). La garantía de convergencia al óptimo exige calendarios logarítmicos, demasiado lentos; en la práctica se usa el geométrico y varias ejecuciones independientes.

5.3 Algoritmos genéticos y estrategias evolutivas

Un *algoritmo genético* mantiene una población de soluciones y la renueva con tres operadores (cap. 9 de [27]): *selección* de padres favoreciendo a los mejores (por ejemplo, por torneo entre dos individuos al azar), *cruce* que combina dos padres y *mutación* que perturba un hijo. Con *elitismo* los mejores pasan intactos a la generación siguiente. La representación debe respetar las restricciones: para permutaciones, el *cruce por orden* (OX) copia un tramo del primer padre y completa los huecos con los genes que faltan en el orden en que aparecen en el segundo, de modo que el hijo sigue siendo una permutación.

Definición 5.3 (CMA-ES). La *estrategia evolutiva con adaptación de la matriz de covarianza* (CMA-ES) [21] optimiza en $\mathbb{R}^n$ manteniendo una distribución $\mathcal{N}(m, \sigma^2 C)$. En cada generación:

1. muestrea λ candidatos $x_k = m + \sigma y_k$, con $y_k \sim \mathcal{N}(0, C)$, y los ordena por f;
2. actualiza la media con los μ mejores: $m \leftarrow \sum_{i=1}^{\mu} w_i x_{i:\lambda}$, con pesos positivos decrecientes que suman 1; la referencia propone $w_i \propto \ln \frac{\lambda+1}{2} - \ln i$;
3. actualiza C con los pasos que tuvieron éxito (actualizaciones de rango uno y de rango μ) y ajusta σ comparando la longitud del camino evolutivo con la esperada bajo selección aleatoria.

El *tamaño efectivo de selección* es $\mu_{\text{eff}} = 1/\sum_i w_i^2$.

CMA-ES aprende la forma del valle: en un problema mal condicionado, C tiende a una matriz proporcional a la inversa del hessiano, de modo que se comporta como un método de segundo orden sin derivadas. Es invariante a transformaciones monótonas de f (solo usa el orden) y a rotaciones del espacio. Es una elección sólida para calibrar simuladores de caja negra con decenas de parámetros continuos y miles de evaluaciones posibles.

5.4 Optimización multiobjetivo

Definición 5.4 (Dominancia y frente de Pareto). Sea $F = (f_1, \dots, f_k)$ un vector de objetivos que se minimizan. Se dice que x *domina* a x', $x \succ x'$, si $f_i(x) \le f_i(x')$ para todo i y $f_j(x) < f_j(x')$ para algún j. Un punto factible es *Pareto-óptimo* si ningún otro punto factible lo domina. La imagen $F(\mathcal{X}^{\mathrm{P}})$ del conjunto de Pareto-óptimos es el *frente de Pareto*.

Proposición 5.5 (Suma ponderada). *Si $w_i > 0$ para todo i y x^* minimiza $\sum_i w_i f_i(x)$ en $\mathcal{X}$, entonces x^* es Pareto-óptimo. El recíproco es falso: los puntos del frente que no están en la frontera de su envolvente convexa no minimizan ninguna suma ponderada.*

Demostración. Si algún x dominase a x^*, sería $f_i(x) \le f_i(x^*)$ para todo i, con desigualdad estricta en algún j; como todos los pesos son positivos, $\sum_i w_i f_i(x) < \sum_i w_i f_i(x^*)$, en contra de la minimalidad. Para el recíproco, el ejemplo 5.6 da un contraejemplo. ∎

El método de la ε-restricción, $\min f_1$ s.a. $f_2 \le \varepsilon$, sí alcanza los puntos no apoyados variando ε (ejercicio 5.7). Para problemas de caja negra, el *NSGA-II* [11] combina un algoritmo genético con dos ideas:

(a) *ordenación no dominada*: la población se divide en frentes $\mathcal{F}_1$ (no dominados), $\mathcal{F}_2$ (no dominados al quitar $\mathcal{F}_1$), etc., y el rango de un individuo es el índice de su frente;

(b) *distancia de aglomeración* (*crowding distance*): dentro de un frente, para cada objetivo se ordenan los puntos, los extremos reciben distancia infinita y cada punto interior suma $(f_k^{\mathrm{sig}} - f_k^{\mathrm{ant}})/(f_k^{\max} - f_k^{\min})$; se prefieren los puntos aislados para mantener la diversidad.

La selección por torneo compara primero el rango y después la distancia, y la nueva generación se forma con los mejores frentes de la unión de padres e hijos (elitismo).

Ejemplo 5.6 (Caso de estudio: distribución en planta). Una nave industrial tiene seis módulos en una cuadrícula de 2×3 con centros separados 20 m; las carretillas circulan por pasillos ortogonales, de modo que la distancia entre módulos es la de Manhattan. Hay que asignar seis departamentos: Recepción (R), Almacén (A), Mecanizado (M), Soldadura (S), Pintura (P) y Expedición (E). Los viajes diarios de carretilla entre departamentos son R–A: 30, A–M: 25, A–S: 10, A–E: 5, M–S: 20, M–P: 5, S–P: 25 y P–E: 30.

Objetivos. (1) Recorrido de carretillas $f_1(\pi) = \sum_{i<j} F_{ij}\, d_{\pi(i)\pi(j)}$ (m/día), con $\pi(i)$ el módulo del departamento i. (2) Riesgo por proximidad de departamentos incompatibles, $f_2(\pi) = \sum w_{ij} \cdot 20/d_{\pi(i)\pi(j)}$, con pesos 10 para soldadura–pintura (chispas y disolventes), 4 para mecanizado–pintura (polvo) y 3 para soldadura–almacén; vale w_{ij} si los dos departamentos son contiguos y disminuye con la distancia.

Elección del método. Es un problema cuadrático de asignación, NP-difícil en general. Con seis departamentos hay $6! = 720$ distribuciones, lo que permite certificar por enumeración lo que hacen las metaheurísticas; con 30 departamentos ($\approx 2{,}7 \cdot 10^{32}$) solo quedarían estas.

Resultados (cuaderno, parte 5).

(a) El recorrido mínimo es **3400 m/día**, alcanzado por 16 distribuciones (simetrías de la cuadrícula). El recocido con intercambios, $T_0 = 500$, $\rho = 0{,}995$ y 3000 iteraciones lo encuentra en las cinco semillas probadas.

(b) El frente de Pareto tiene cuatro puntos: (3400; 13,5), (3700; 10,5), (3900; 7,83) y (4400; 6,83). El punto (3700; 10,5) no lo alcanza ninguna suma ponderada: el segmento

que une (3400; 13,5) y (3900; 7,83) pasa en $f_1 = 3700$ por $f_2 = 13{,}5 - 0{,}6 \cdot 5{,}67 = 10{,}1 < 10{,}5$, de modo que el punto queda por encima de la envolvente convexa.

(c) Un NSGA-II mínimo (población 40, 40 generaciones, cruce OX y mutación por intercambio) recupera los cuatro puntos del frente en 0,3 s.

La figura 5.1 muestra dos distribuciones del frente. Con f_1 mínimo, el flujo sigue una U (R–A–M abajo, S–P–E arriba), pero soldadura y pintura quedan contiguas. Separándolas cuesta 500 m/día más de carretilla y el riesgo baja de 13,5 a 7,83. Elegir entre ellas no es tarea del algoritmo, sino de quien conoce el valor relativo del riesgo y del tiempo de transporte.

E	P	S
R	A	M

$f_1 = 3400,\ f_2 = 13{,}5$

P	E	S
R	A	M

$f_1 = 3900,\ f_2 = 7{,}83$

Figura 5.1: Dos distribuciones Pareto-óptimas del caso de la planta. A la izquierda, mínimo recorrido; a la derecha, soldadura y pintura separadas por expedición.

Cuadro 5.1: Tecnologías del tema 5: metaheurísticas y multiobjetivo.

Herramienta	Para qué sirve	Licencia o tipo	Cuándo elegirla
`cma` (Hansen *et al.*)	CMA-ES de referencia, con restricciones de caja y ruido	abierta (BSD-3)	calibrar simuladores continuos de caja negra
pymoo [7]	NSGA-II, NSGA-III, indicadores de calidad de frentes	abierta (Apache 2.0)	problemas multiobjetivo con operadores estándar
SciPy `optimize`	recocido dual, evolución diferencial, Nelder–Mead, Powell	abierta (BSD-3)	continuo, pocas variables, sin dependencias extra
Optuna	búsqueda de hiperparámetros (muestreadores TPE y CMA-ES, multiobjetivo)	abierta (MIT)	ajustar modelos o configuraciones con evaluaciones caras
Código propio	recocido, búsqueda tabú, genéticos sobre una representación específica	propio	combinatoria con vecindarios propios del dominio

Observación 5.7 (Errores frecuentes con metaheurísticas). (a) *Conclusiones con una sola semilla*: un resultado estocástico se informa con varias ejecuciones (media, peor caso, dispersión) y con el mismo número de evaluaciones para todos los métodos comparados.

(b) *Ajustar hiperparámetros sobre la instancia de evaluación*: igual que en aprendizaje automático, es sobreajuste; se ajustan en instancias de entrenamiento y se evalúan en otras.

(c) *Restricciones como penalizaciones mal escaladas*: con penalización pequeña la solución final es infactible; con una enorme el paisaje se vuelve plano. Mejor representaciones que garanticen la factibilidad o una reparación explícita.

(d) *Ruido en la evaluación*: con un simulador estocástico, el mejor valor observado está

sesgado a la baja (maldición del optimizador, tema 6); hay que reevaluar el candidato final con nuevas réplicas.

(e) *Presentar el frente sin decidir*: un frente con cien puntos no es una decisión; hay que acordar con el usuario las preferencias o el punto de compromiso.

Lecturas recomendadas para este tema

- Kochenderfer y Wheeler [27], caps. 7 «Direct Methods», 8 «Stochastic Methods», 9 «Population Methods» y 12 «Multiobjective Optimization».
- S. Kirkpatrick, C. D. Gelatt y M. P. Vecchi [26], artículo original del recocido simulado.
- N. Hansen [21], tutorial de CMA-ES.
- K. Deb *et al.* [11], artículo original de NSGA-II.

Ejercicios del tema 5

Ejercicio 5.1 ⋆ Un movimiento empeora el objetivo en $\Delta = 50$. Calcule su probabilidad de aceptación con $T = 100$ y con $T = 25$. Con el calendario $T_{k+1} = 0{,}99\,T_k$ y $T_0 = 500$, ¿cuántas iteraciones hacen falta para que $T < 1$?

Fuente: adaptado de MIT 15.053, primavera de 2013, clase 17, recocido simulado con enfriamiento $T := 0{,}99\,T$ [30].

Ejercicio 5.2 ⋆⋆ Seis soluciones de un problema con dos objetivos que se minimizan tienen imágenes $a = (1, 9)$, $b = (2, 7)$, $c = (3, 8)$, $d = (4, 4)$, $e = (5, 5)$ y $f = (7, 2)$. Calcule los frentes de la ordenación no dominada y el rango de cada solución.

Fuente: adaptado de K. Deb *et al.* [11], ordenación rápida no dominada.

Ejercicio 5.3 ⋆⋆ Calcule la distancia de aglomeración de los puntos del primer frente del ejercicio 5.2. ¿Cuál se descartaría primero si hubiera que eliminar uno que no sea extremo?

Fuente: adaptado de K. Deb *et al.* [11], distancia de aglomeración.

Ejercicio 5.4 ⋆⋆ Con los cuatro puntos del frente del ejemplo 5.6, demuestre que no existe ningún peso $w \in [0, 1]$ tal que (3700; 10,5) minimice $w f_1 + (1 - w) f_2$ entre ellos.

Ejercicio 5.5 ⋆⋆ Aplique el cruce por orden (OX) a los padres $p_1 = (1, 2, 3, 4, 5, 6)$ y $p_2 = (4, 6, 2, 1, 5, 3)$ copiando de p_1 las posiciones 3 a 5 y rellenando el resto de izquierda a derecha con los genes que faltan en el orden en que aparecen en p_2. Compruebe que el hijo es una permutación.

Ejercicio 5.6 ⋆⋆ Para CMA-ES con $\lambda = 6$ candidatos y $\mu = 3$ padres, calcule los pesos $w_i \propto \ln \frac{\lambda+1}{2} - \ln i$, normalizados para sumar 1, y el tamaño efectivo μ_{eff}.

Fuente: adaptado de N. Hansen [21], elección por defecto de los pesos de recombinación.

Ejercicio 5.7 ⋆⋆⋆ (a) Demuestre que toda solución óptima única de $\min f_1(x)$ s.a. $f_2(x) \le \varepsilon$ es Pareto-óptima. (b) Muestre con el ejemplo 5.6 que eligiendo ε adecuadamente se obtiene el punto (3700; 10,5), que la suma ponderada no alcanza.

Fuente: adaptado de Kochenderfer y Wheeler [27], cap. 12, métodos de restricción para el frente de Pareto.

Ejercicio 5.8 ⋆⋆⋆ Demuestre que si la propuesta del recocido no es simétrica, la aceptación de Metropolis–Hastings $\alpha(x, x') = \min\!\big(1,\ e^{-(f(x')-f(x))/T}\,\mathbb{P}(x' \to x)/\mathbb{P}(x \to x')\big)$ restaura el equilibrio detallado con π_T. Explique por qué un error en esa corrección sesga la búsqueda hacia las regiones donde la propuesta concentra su masa.

Fuente: adaptado de Kochenderfer y Wheeler [27], cap. 8, y de S. Kirkpatrick *et al.* [26].

Tema 6

Cuando la IA entra en la formulación: predecir y optimizar

En los temas anteriores los datos eran conocidos. En la práctica la demanda, los tiempos de viaje o los rendimientos se *predicen*, y la decisión hereda el error de la predicción. Este tema estudia cómo combinar ambos pasos. Sigue el capítulo 1 («Introduction and Examples») de Birge y Louveaux [6] y las transparencias de programación estocástica del curso EE364a de Stanford [9]; el capítulo 17 («Optimization under Uncertainty») de Kochenderfer y Wheeler [27]; los artículos de Elmachtoub y Grigas [14] y de Bertsimas y Kallus [3] sobre la integración de predicción y decisión; el de Bertsimas y Sim [4] y el libro de Ben-Tal, El Ghaoui y Nemirovski [2] para la optimización robusta, y el de Smith y Winkler [36] para la maldición del optimizador.

6.1 Predecir y después optimizar

Definición 6.1 (Predecir y después optimizar). Sea un problema $\min_{x\in\mathcal{X}} \mathbb{E}[c(x,\xi) \mid w]$, donde ξ es un parámetro incierto (la demanda) y w el contexto observado (temperatura, festivos). El enfoque *predecir y después optimizar* entrena un modelo $\hat{\xi} = m_\phi(w)$ y resuelve $\hat{x}(w) \in \arg\min_{x\in\mathcal{X}} c(x,\hat{\xi})$, sustituyendo el parámetro por su predicción puntual.

Proposición 6.2 (Cuándo basta la media). *Si el coste es lineal en el parámetro, $c(x,\xi) = \xi^{\mathsf{T}}x$, y $\mathcal{X}$ no depende de ξ, la decisión que minimiza el coste esperado condicionado es la que resulta de sustituir ξ por su media condicionada $\mathbb{E}[\xi \mid w]$.*

Demostración. Por la linealidad de la esperanza, $\mathbb{E}[\xi^{\mathsf{T}}x \mid w] = \mathbb{E}[\xi \mid w]^{\mathsf{T}}x$ para todo $x \in \mathcal{X}$. Los dos problemas tienen el mismo objetivo y, por tanto, los mismos minimizadores. ■

La proposición explica el éxito del enfoque cuando la incertidumbre está en los costes de un PL (rutas con tiempos inciertos y objetivo lineal) y su fracaso cuando el coste es no lineal en ξ: con inventario, el coste de quedarse corto y el de sobrar son distintos, y la media deja de ser suficiente. Incluso en el caso lineal, dos modelos con el mismo error cuadrático pueden inducir decisiones de calidad muy distinta: lo que importa no es el error en la predicción, sino el error en la decisión, que es lo que mide la pérdida SPO (*smart predict-then-optimize*) de Elmachtoub y Grigas [14] (ejercicio 6.3). Bertsimas y Kallus [3] proponen, en lugar de predecir un valor, aprender pesos sobre escenarios históricos parecidos al contexto y optimizar contra esa distribución empírica.

6.2 El vendedor de periódicos

Definición 6.3 (Problema del vendedor de periódicos). Se decide una cantidad $q \geq 0$ antes de conocer la demanda D, con función de distribución F. Cada unidad que falta cuesta $c_u > 0$ (margen perdido) y cada unidad que sobra, $c_o > 0$ (coste menos valor de saldo). El coste esperado es

$$G(q) = \mathbb{E}\big[c_u (D - q)^+ + c_o (q - D)^+\big].$$

Teorema 6.4 (Fractil crítico). *Si F es continua, $q^* = F^{-1}\big(c_u/(c_u + c_o)\big)$ minimiza G. Si D es discreta, es óptimo el menor q con $F(q) \geq c_u/(c_u + c_o)$.*

Demostración. G es convexa, porque $(D-q)^+$ y $(q-D)^+$ lo son en q y la esperanza conserva la convexidad. Su derivada (lateral, en el caso discreto) es

$$G'(q) = -c_u\,\mathbb{P}(D > q) + c_o\,\mathbb{P}(D \leq q) = -c_u + (c_u + c_o) F(q),$$

porque aumentar q en $\mathrm{d}q$ ahorra $c_u\,\mathrm{d}q$ cuando falta producto y cuesta $c_o\,\mathrm{d}q$ cuando sobra. $G'(q)$ es no decreciente y cambia de signo donde $F(q) = c_u/(c_u + c_o)$. En el caso continuo, $G'(q^*) = 0$ y por convexidad q^* es mínimo global. En el discreto, G es lineal a trozos y su pendiente pasa a ser no negativa en el menor q con $F(q) \geq c_u/(c_u + c_o)$. ∎

Si la demanda es normal, $q^* = \mu + \sigma\,\Phi^{-1}(c_u/(c_u + c_o))$: se produce por encima de la media cuando el margen perdido supera al coste del sobrante. Predecir la media, por precisa que sea, no basta; hace falta un *cuantil*, y por tanto una estimación de la incertidumbre calibrada fuera de muestra.

6.3 Programación estocástica y robusta

Definición 6.5 (Programa estocástico en dos etapas). En un *programa en dos etapas* se fija una decisión x antes de observar ξ y, una vez observado, una decisión de recurso y:

$$\mathrm{RP} = \min_{x \in \mathcal{X}} \; c^{\mathsf{T}} x + \mathbb{E}_{\xi}\big[Q(x, \xi)\big], \qquad Q(x, \xi) = \min_{y \in \mathcal{Y}(x, \xi)} q(\xi)^{\mathsf{T}} y.$$

La *aproximación por media muestral* (SAA) sustituye la esperanza por la media sobre S escenarios $\xi^1, \ldots, \xi^S$ y, si todo es lineal, da un único PL con una copia de y por escenario [9].

Definición 6.6 (Valor de la solución estocástica y de la información perfecta). Para un problema de minimización, sea $\bar{x}$ la solución del *problema del valor esperado* (sustituir ξ por $\mathbb{E}\xi$), $\mathrm{EEV} = c^{\mathsf{T}}\bar{x} + \mathbb{E}[Q(\bar{x}, \xi)]$ su coste esperado real, y $\mathrm{WS} = \mathbb{E}_{\xi}[\min_x (c^{\mathsf{T}} x + Q(x, \xi))]$ el coste esperado si se conociera ξ antes de decidir (*wait-and-see*). Se definen el *valor de la solución estocástica* $\mathrm{VSS} = \mathrm{EEV} - \mathrm{RP}$ y el *valor esperado de la información perfecta* $\mathrm{EVPI} = \mathrm{RP} - \mathrm{WS}$ [6].

Proposición 6.7. $\mathrm{WS} \leq \mathrm{RP} \leq \mathrm{EEV}$*; en consecuencia,* $\mathrm{VSS} \geq 0$ *y* $\mathrm{EVPI} \geq 0$.

Demostración. $\mathrm{RP} \leq \mathrm{EEV}$ porque $\bar{x}$ es factible y RP es el mínimo del coste esperado. Para la otra desigualdad, sea x^* óptima de RP; para cada ξ, $\min_x (c^{\mathsf{T}} x + Q(x, \xi)) \leq c^{\mathsf{T}} x^* + Q(x^*, \xi)$, y tomando esperanzas, $\mathrm{WS} \leq \mathrm{RP}$. ∎

La *optimización robusta* renuncia a la distribución y exige factibilidad o buen coste para todo ξ de un *conjunto de incertidumbre* Ξ: $\min_x \max_{\xi\in\Xi} c(x,\xi)$. Para restricciones lineales con coeficientes en una caja, el problema robusto sigue siendo lineal.

Proposición 6.8 (Contrapartida robusta de una caja). *Sea $x \geq 0$ y $a_j \in [\bar{a}_j - \delta_j,\ \bar{a}_j + \delta_j]$ con $\delta_j \geq 0$. La restricción $a^\mathsf{T} x \leq b$ se cumple para todos los a de la caja si y solo si $(\bar{a}+\delta)^\mathsf{T} x \leq b$. Para x de signo libre, la condición es $\bar{a}^\mathsf{T} x + \delta^\mathsf{T}|x| \leq b$, que se linealiza con la proposición 1.6.*

Demostración. El máximo de $a^\mathsf{T} x = \sum_j a_j x_j$ sobre la caja se alcanza eligiendo cada a_j por separado: $\bar{a}_j + \delta_j$ si $x_j \geq 0$ y $\bar{a}_j - \delta_j$ si $x_j < 0$, lo que da $\bar{a}^\mathsf{T} x + \sum_j \delta_j |x_j|$. La restricción se cumple para toda la caja si y solo si se cumple en ese máximo. ■

La caja completa es muy conservadora: supone que todos los coeficientes toman su peor valor a la vez. Bertsimas y Sim [4] limitan a Γ el número de coeficientes que se desvían y controlan así el *precio de la robustez*: el coste que se paga por protegerse.

Observación 6.9 (La maldición del optimizador). Si se eligen la mejor de varias alternativas por su valor estimado, el valor estimado de la elegida sobrestima su valor real, aunque cada estimación sea insesgada: $\mathbb{E}[\max_i \hat{J}_i] \geq \max_i \mathbb{E}[\hat{J}_i]$ [36] (ejercicio 6.8). Por eso el beneficio que promete un optimizador sobre datos predichos debe validarse con datos nuevos, nunca con los usados para elegir.

6.4 Caso de estudio: plan de cerveza fresca con demanda predicha

Ejemplo 6.10 (Cerveza sin pasteurizar con demanda predicha). La cervecera de los temas anteriores vende dos cervezas sin pasteurizar, IPA y Lager, que caducan en una semana. Cada lunes decide cuántos hectolitros envasar, $q = (q_1, q_2)$, con una capacidad conjunta de $K = 260$ hL. Lo que no se vende se liquida a precio de saldo. Por hectolitro: precio $p = (300, 220)$ €, coste $c = (70, 60)$ € y saldo $s = (20, 10)$ €; por tanto $c_u = p - c = (230, 160)$ y $c_o = c - s = (50, 50)$, con fractiles críticos 0,821 y 0,762.

Datos (sintéticos, 208 semanas; cuaderno, parte 6). La demanda semanal depende de la temperatura media, de si hay festivo y de una tendencia de crecimiento, con ruido multiplicativo log-normal de desviación 0,22 en escala logarítmica y correlación 0,5 entre las dos cervezas. Su media pasa de (72,5; 100,1) hL en los dos primeros años a (91,1; 115,0) hL en el último.

Protocolo sin fugas. Las semanas 0–103 se usan para entrenar una regresión lineal del logaritmo de la demanda sobre temperatura, festivo y semana (módulo 8); las semanas 104–155, para medir los residuos fuera de muestra (desviación 0,21 en ambas cervezas), y las 156–207, como periodo de prueba en el que se simula la operación. El error porcentual absoluto medio de la predicción de la media en prueba es del 18 y el 21 %.

Decisiones comparadas. (A) Envasar la media predicha. (B) Envasar el cuantil del fractil crítico, predicción por el cuantil empírico de los residuos (teorema 6.4). (C) SAA: un PL por semana con los 52 vectores de residuos de calibración como escenarios conjuntos, que respeta la capacidad y la correlación. (D) Robusto: envasar el peor caso de una caja del 90 % (cuantil del 5 % de los residuos). En las cuatro, si se supera la capacidad se reduce en proporción, salvo en C, que la incluye en el modelo.

Resultados en las 52 semanas de prueba:

Decisión	Beneficio medio (€/semana)	Peor semana (€)	Semanas sin rotura (IPA, Lager)
A: media predicha	34 145	16 390	56 %, 50 %
B: cuantil del fractil	34 595	15 482	75 %, 62 %
C: SAA con capacidad	34 615	15 465	77 %, 60 %
D: robusto (caja del 90 %)	26 562	16 440	6 %, 8 %
información perfecta	36 502	19 105	81 %, 81 %

Usar la media en lugar del cuantil cuesta 450 €/semana, unos 23 400 €/año: con márgenes altos, quedarse corto sale caro. SAA añade una mejora pequeña porque la capacidad solo limita en las semanas de más calor. La decisión robusta tiene la mejor peor semana, pero su beneficio medio es 8053 €/semana menor que el de SAA: ese es su precio de la robustez, que solo se justifica si una mala semana tuviera consecuencias graves (por ejemplo, de tesorería). La información perfecta acota lo que puede ganar cualquier mejora del modelo de predicción: 1887 €/semana sobre SAA. Incluso con ella hay semanas con rotura, porque la capacidad no alcanza en los picos de demanda.

Cuadro 6.1: Tecnologías del tema 6: predecir y optimizar bajo incertidumbre.

Herramienta	Para qué sirve	Licencia o tipo	Cuándo elegirla
scikit-learn	regresión, cuantiles (`GradientBoostingRegressor` con pérdida cuantílica), validación temporal	abierta (BSD-3)	modelos de predicción tabulares
SciPy / HiGHS	PL de SAA con escenarios	abierta (BSD-3; MIT)	programas estocásticos lineales de tamaño medio
CVXPY [12]	modelos robustos y con restricciones probabilísticas convexas	abierta (Apache 2.0)	contrapartidas robustas cónicas, CVaR
Pyomo	modelos estocásticos por escenarios y descomposición	abierta (BSD-3)	problemas grandes en dos o más etapas
PyTorch	capas de optimización diferenciables para aprender con la pérdida de decisión	abierta (BSD)	enfoques SPO o de aprendizaje orientado a la decisión

Observación 6.11 (Errores frecuentes al combinar predicción y decisión). (a) *Fugas de datos*: calibrar los cuantiles con residuos de entrenamiento (demasiado optimistas en modelos flexibles), usar variables que no se conocen al decidir (la temperatura real de la semana en vez de la previsión) o validar con particiones aleatorias en series temporales.

(b) *Optimizar contra la media*: correcto solo si el coste es lineal en el parámetro (proposición 6.2).

(c) *Evaluar la predicción y no la decisión*: un modelo con menos error cuadrático puede dar peores decisiones; se compara el beneficio simulado fuera de muestra.

(d) *Maldición del optimizador*: el beneficio previsto por el modelo para la decisión elegida está sesgado al alza (observación 6.9).

(e) *Deriva*: la tendencia del caso hace que un modelo entrenado sin la variable de semana quede desfasado; hay que monitorizar el error y reentrenar (figura 1.2).

(f) *Robustez sin calibrar*: una caja demasiado grande regala beneficio; su tamaño debe justificarse con el riesgo que se quiere cubrir.

Lecturas recomendadas para este tema

- Birge y Louveaux [6], cap. 1 «Introduction and Examples» (vendedor de periódicos y ejemplos en dos etapas).
- Transparencias de EE364a «Stochastic programming» [9]: SAA, validación fuera de muestra y planificación de la producción con demanda incierta.
- Kochenderfer y Wheeler [27], cap. 17 «Optimization under Uncertainty».
- A. N. Elmachtoub y P. Grigas [14]; D. Bertsimas y N. Kallus [3]; D. Bertsimas y M. Sim [4].

Ejercicios del tema 6

Ejercicio 6.1 ⋆ Señale la fuga de datos o el error de evaluación en cada caso: (a) los cuantiles de la demanda se estiman con los residuos del mismo conjunto con el que se entrenó un bosque aleatorio; (b) el modelo usa la temperatura media observada de la semana que se planifica; (c) se elige entre cinco planes el de mayor beneficio simulado y se informa de ese beneficio a la dirección; (d) la validación cruzada mezcla al azar semanas de 2023 y 2025.

Ejercicio 6.2 ⋆⋆ La demanda semanal de IPA fresca es normal con media 80 hL y desviación 16 hL; $c_u = 230$ y $c_o = 50$ €/hL. Calcule la cantidad óptima y compárela con la media. ¿Qué cantidad sería óptima si el saldo bajase a 0 €/hL?

Fuente: adaptado de Birge y Louveaux [6], cap. 1, problema del vendedor de periódicos.

Ejercicio 6.3 ⋆⋆ Hay que elegir una de dos rutas con costes reales $c = (1{,}0;\ 1{,}2)$ h. El modelo A predice $(1{,}25;\ 1{,}2)$ y el modelo B, $(0{,}75;\ 1{,}2)$. Calcule el error cuadrático de cada predicción, la ruta que elige cada modelo y su pérdida de decisión (coste real de la ruta elegida menos el óptimo). ¿Qué enseña el resultado?

Fuente: adaptado de A. N. Elmachtoub y P. Grigas [14], motivación de la pérdida SPO.

Ejercicio 6.4 ⋆⋆ Se envasa q antes de conocer la demanda, que vale 60, 100 o 140 hL con probabilidades 0,3, 0,4 y 0,3; precio 300, coste 70 y saldo 20 €/hL. Se maximiza el beneficio esperado. Calcule (a) la solución del valor esperado y su beneficio esperado real (EEV); (b) la solución estocástica (RP) con el teorema 6.4; (c) WS, VSS y EVPI, adaptando los signos a la maximización.

Fuente: adaptado de Birge y Louveaux [6], cap. 1, valor de la solución estocástica y de la información perfecta.

Ejercicio 6.5 ⋆⋆ Un lote de 100 kg de pienso se mezcla con x_1 kg de maíz y x_2 kg de soja ($x_1 + x_2 = 100$, $x \geq 0$) y debe contener al menos 18 kg de proteína: $a_1 x_1 + a_2 x_2 \geq 1800$, con a_j el contenido de proteína en porcentaje. El contenido de proteína del maíz es $a_1 \in [7;\ 9]$ y el de la soja, $a_2 \in [42;\ 46]$ (%). (a) Escriba la contrapartida robusta. (b) Calcule la mínima cantidad de soja con la caja completa y con los valores nominales. (c) ¿Cuál es el precio de la robustez si la soja cuesta 0,40 €/kg y el maíz 0,22 €/kg?

Fuente: adaptado de D. Bertsimas y M. Sim [4], contrapartida robusta de restricciones lineales.

Ejercicio 6.6 ⋆⋆ Se dispone de cinco escenarios equiprobables de demanda: 72, 95, 88, 110 y 64 hL, con $c_u = 230$ y $c_o = 50$. Resuelva el problema SAA del vendedor de periódicos y compare la decisión con la que daría una normal ajustada a esos cinco valores. ¿Qué riesgo tiene usar tan pocos escenarios?

Fuente: adaptado de las transparencias «Stochastic programming» de EE364a [9], método de Monte Carlo y validación fuera de muestra.

Ejercicio 6.7 ⋆⋆⋆ Demuestre el teorema 6.4 para una demanda discreta con valores $d_1 < \cdots < d_K$, comprobando que G es lineal a trozos con vértices en los d_k y calculando las pendientes laterales.

Ejercicio 6.8 ⋆⋆⋆ Sean $\hat{J}_1, \dots, \hat{J}_k$ estimaciones insesgadas de los valores $J_1, \dots, J_k$ de k alternativas. (a) Demuestre que $\mathbb{E}[\max_i \hat{J}_i] \geq \max_i J_i$. (b) Si $J_1 = \cdots = J_k = J$ y los errores son independientes $\mathcal{N}(0, \sigma^2)$, calcule el sesgo de la alternativa elegida para $k = 2$. (c) Proponga un procedimiento de validación que elimine el sesgo.

Fuente: adaptado de J. E. Smith y R. L. Winkler [36].

Apéndice A

Soluciones de los ejercicios

Cada solución se presenta en cinco partes: datos, planteamiento, desarrollo, resultado y comprobación. En los pasos intermedios se redondea a cuatro cifras significativas salvo que se indique otra cosa. Los resultados numéricos de los casos de estudio se han comprobado con el cuaderno `M24-practica.ipynb`.

A.1 Tema 1

Solución del ejercicio 1.1

Datos. invernadero de 1 ha con control horario de ventanas, calefacción y CO_2; predicción de radiación y temperatura exterior.

Planteamiento. clasificar cada elemento según la definición 1.2.

Desarrollo.

1. Variables de decisión, por hora t: apertura de ventanas $v_t \in [0, 1]$, potencia de calefacción $u_t \geq 0$ (kW) y caudal de CO_2 $g_t \geq 0$ (kg/h).
2. Parámetros: radiación R_t y temperatura exterior T_t^{ext} (predichos); precio de la energía y del CO_2 (conocidos o predichos); coeficientes del modelo térmico y del modelo de crecimiento (estimados con datos).
3. Objetivo: $\max \sum_t \big[\text{crecimiento estimado}(T_t, \text{CO}_{2,t}, R_t) - p_t^{\text{e}} u_t - p^{\text{c}} g_t\big]$.
4. Restricciones duras: $\text{CO}_{2,t} \leq 1000$ ppm (seguridad de las personas), límites físicos de los actuadores y la dinámica térmica y de CO_2 del invernadero.
5. Restricción que conviene tratar como blanda: $16 \leq T_t \leq 28$ ºC, con penalización por grado fuera de rango, porque una helada imprevista podría hacerla infactible; si el cultivo sufre daños irreversibles fuera del rango, debe ser dura.
6. KPIs distintos del objetivo: horas fuera del rango de temperatura, kWh por kilogramo producido, error de la predicción de temperatura interior, número de intervenciones manuales.

Resultado. **decisiones v_t, u_t, g_t; parámetros predichos R_t, T_t^{ext}; objetivo crecimiento menos coste; CO_2 como restricción dura y temperatura como blanda; KPIs de confort, eficiencia, predicción y supervisión.**

Comprobación. cada elemento es o bien elegible por el sistema (decisión) o bien externo (parámetro); ningún KPI coincide con el objetivo.

Solución del ejercicio 1.2

Datos. seis problemas.

Planteamiento. identificar en cada uno el tipo de variables, la linealidad y el coste de evaluación (cuadro 1.2 y figura 1.3).

Desarrollo.

1. (a) Variables continuas, todo lineal: *PL*.
2. (b) Decisión binaria de apertura con costes lineales: *PLEM* (localización con costes fijos).
3. (c) Caja negra de 2 h por evaluación y 8 variables continuas: *optimización bayesiana*.
4. (d) Secuenciación con precedencias y recursos disyuntivos: *programación por restricciones* (CP-SAT).
5. (e) Objetivo cuadrático convexo y restricciones lineales: *optimización convexa* (programa cuadrático).
6. (f) Decisiones secuenciales con realimentación cada minuto: *control predictivo o aprendizaje por refuerzo*.

Resultado. **(a) PL; (b) PLEM; (c) optimización bayesiana; (d) CP; (e) convexa; (f) control o RL.**

Comprobación. en ningún caso se usa una metaheurística genérica donde existe un método que explota la estructura.

Solución del ejercicio 1.3

Datos. $\min |x_1| + 2|x_2|$ s.a. $x_1 + x_2 \geq 4$, $x_1 - x_2 \leq 2$.

Planteamiento. proposición 1.4 (iii): $x_j = x_j^+ - x_j^-$; en el óptimo $|x_j| = x_j^+ + x_j^-$.

Desarrollo.

1. PL: $\min x_1^+ + x_1^- + 2x_2^+ + 2x_2^-$ s.a. $x_1^+ - x_1^- + x_2^+ - x_2^- \geq 4$, $x_1^+ - x_1^- - x_2^+ + x_2^- \leq 2$, todas ≥ 0.
2. Es mejor hacer grande x_1 (coste 1) que x_2 (coste 2), pero $x_1 \leq 2 + x_2$.
3. Con $x_1, x_2 \geq 0$, el objetivo es $x_1 + 2x_2$; sobre la recta $x_1 = 2 + x_2$, la restricción $x_1 + x_2 \geq 4$ da $x_2 \geq 1$; el mínimo es $x_2 = 1$, $x_1 = 3$, con valor $3 + 2 = 5$.
4. Con $x_2 < 0$ haría falta $x_1 \geq 4 - x_2 > 4$ y $x_1 \leq 2 + x_2 < 2$: imposible. Con $x_1 < 0$ haría falta $x_2 > 4$ y coste > 8.

Resultado. $\boldsymbol{x^* = (3, 1)}$, valor óptimo **5**.

Comprobación. $3 + 1 = 4 \geq 4$ y $3 - 1 = 2 \leq 2$ (ambas activas); HiGHS da el mismo resultado sobre el PL del paso 1.

Solución del ejercicio 1.4

Datos. demandas $r = (17, 13, 15, 19, 14, 16, 11)$ de lunes a domingo; cinco días seguidos de trabajo.

Planteamiento. variables x_j, empleados que empiezan el día j; cada día lo cubren los que empezaron ese día o en los cuatro anteriores.

Desarrollo.

1. (a) $\min \sum_{j=1}^{7} x_j$ s.a. $x_1 + x_4 + x_5 + x_6 + x_7 \geq 17$ (lunes), $x_1 + x_2 + x_5 + x_6 + x_7 \geq 13$, …, $x_3 + x_4 + x_5 + x_6 + x_7 \geq 11$ (domingo), $x_j \geq 0$ enteros. Con la variable «empleados presentes el día j» no se puede expresar la regla de cinco días seguidos; con la variable de inicio la regla queda incorporada en los coeficientes.
2. (b) Cada x_j aparece en exactamente cinco restricciones. Sumándolas: $5 \sum_j x_j \geq \sum_j r_j = 105$, luego $\sum_j x_j \geq 21$.
3. (c) La relajación (22,33) es una cota mejor que 21 porque usa las restricciones por separado; como el número de empleados es entero, el óptimo no puede bajar de $\lceil 22{,}33 \rceil = 23$; al encontrar una solución entera con 23, la cota redondeada demuestra que es óptima.

Resultado. **cota por suma: 21; relajación:** 22,33**; óptimo entero: 23**, certificado por $\lceil 22{,}33 \rceil = 23$.

Comprobación. la solución entera $x = (7, 5, 1, 8, 0, 2, 0)$ suma 23 y cubre el lunes con $7 + 8 + 0 + 2 + 0 = 17$ y el jueves con $7 + 5 + 1 + 8 + 0 = 21 \geq 19$.

Solución del ejercicio 1.5

Datos. vértices $(0, 0)$, $(150, 0)$, $(100, 100)$, $(40, 160)$, $(0, 160)$; nuevo margen $40E + 45P$.

Planteamiento. evaluar el objetivo en los vértices (teorema 2.2) y estudiar el cono de las restricciones activas.

Desarrollo.

1. Valores: 0; 6000; $4000 + 4500 = 8500$; $1600 + 7200 = 8800$; 7200.
2. El óptimo es $(40, 160)$ con 8800 €. KPIs: molino $0{,}5 \cdot 200 = 100$ h (100 %); granuladora $24 + 48 = 72$ h (80 %); demanda de puesta cubierta al 100 %.
3. $(100, 100)$ es óptimo si el gradiente $(40, m_P)$ es combinación no negativa de las normales activas $(1, 1)$ y $(2, 1)$: $(40, m_P) = \alpha(1, 1) + \beta(2, 1)$, es decir, $\beta = 40 - m_P \geq 0$ y $\alpha = 2m_P - 40 \geq 0$.

Resultado. **con $m_P = 45$:** $(E, P) = (40, 160)$ **y 8800 €/semana;** $(100, 100)$ **es óptimo para** $20 \leq m_P \leq 40$ **€/t.**

Comprobación. con $m_P = 40$ empatan $(100, 100)$ y $(40, 160)$: $4000 + 4000 = 8000 = 1600 + 6400$; con $m_P = 20$ empatan $(100, 100)$ y $(150, 0)$: 6000 en ambos.

Solución del ejercicio 1.6

Datos. $f_1 = x - 1$, $f_2 = -2x + 8$, $f_3 = 0{,}5x + 1$, $x \in [0, 10]$.

Planteamiento. proposición 1.5: $\min t$ s.a. $f_i(x) \leq t$, $0 \leq x \leq 10$.

Desarrollo.

1. PL: $\min t$ s.a. $x - 1 \leq t$, $-2x + 8 \leq t$, $0{,}5x + 1 \leq t$, $0 \leq x \leq 10$.
2. La envolvente superior decrece mientras domina f_2 y crece después. $f_2 = f_3$ en $-2x + 8 = 0{,}5x + 1$, es decir, $x = 2{,}8$, con valor 2,4.
3. En $x = 2{,}8$, $f_1 = 1{,}8 < 2{,}4$: la envolvente es $\max(f_2, f_3)$ en ese punto.

Resultado. $\boldsymbol{x^* = 2{,}8}$, pérdida máxima **2,4 kW**.

Comprobación. en $x = 2{,}7$, $\max = f_2 = 2{,}6$; en $x = 2{,}9$, $\max = f_3 = 2{,}45$; ambos mayores que 2,4.

Solución del ejercicio 1.7

Datos. $\sum_j a_{ij}x_j + d_i - e_i = r_i$, $d_i, e_i \geq 0$; objetivo $\sum_i(\alpha d_i + \beta e_i)$ con $\alpha, \beta > 0$.

Planteamiento. por reducción al absurdo: si $d_i, e_i > 0$, se construye una solución mejor.

Desarrollo.

1. Sea una solución óptima con $d_i > 0$ y $e_i > 0$. Sea $\delta = \min(d_i, e_i) > 0$.
2. Se define $d'_i = d_i - \delta \geq 0$, $e'_i = e_i - \delta \geq 0$; la restricción se mantiene porque $d'_i - e'_i = d_i - e_i$.
3. El objetivo baja en $(\alpha + \beta)\delta > 0$, en contra de la optimalidad. Luego $d_i e_i = 0$.
4. Con $5d_i^2 + e_i^2$ el argumento es el mismo: $5(d_i - \delta)^2 + (e_i - \delta)^2 < 5d_i^2 + e_i^2$ porque ambos términos decrecen al reducir sus bases positivas.

Resultado. **en el óptimo $d_i e_i = 0$ para todo i, con costes lineales positivos y también con el coste cuadrático.**

Comprobación. es el argumento de la clase 2 de 15.053: con $d_1 = 1$ y $e_1 = 4$, restar 1 a ambos da $d_1 = 0$, $e_1 = 3$, mejor.

Solución del ejercicio 1.8

Datos. invernadero del ejercicio 1.1; modelo térmico lineal en los controles.

Planteamiento. recorrer los bloques de la figura 1.2.

Desarrollo.

1. *Datos*: sensores interiores (temperatura, humedad, CO_2, radiación), estación exterior, consumo de energía, estado de actuadores y previsión meteorológica, con marca de tiempo y control de calidad.
2. *Predicción*: modelo de regresión o red pequeña para radiación y temperatura exterior de las próximas 24 h a partir de la previsión oficial (corrige su sesgo local); modelo identificado del invernadero (lineal en los controles) validado en semanas no usadas para ajustarlo.
3. *Optimización*: control predictivo con horizonte de 24 h repetido cada hora; con modelo lineal y coste lineal o cuadrático convexo es un PL o un problema cuadrático, resoluble en milisegundos con HiGHS u OSQP.
4. *Salvaguardas*: un controlador de respaldo por reglas que abre ventanas si el CO_2 supera 1000 ppm o la temperatura 30 ºC, independiente del optimizador; límites de variación de los actuadores.
5. *Monitorización*: error de la predicción de temperatura interior, horas fuera de rango, energía por kilogramo, frecuencia de actuación de las salvaguardas y tiempo de cálculo; si el error crece de forma sostenida, se reidentifica el modelo.

Resultado. **control predictivo lineal o cuadrático alimentado por predicciones corregidas, con salvaguardas por reglas independientes y monitorización del error de predicción y de los KPIs.**

Comprobación. el diseño respeta la separación entre restricciones duras (salvaguardas) y objetivo, y cada bloque tiene un indicador que permite detectar su fallo.

A.2 Tema 2

Solución del ejercicio 2.1

Datos. óptimo $(100, 100)$; holguras: molino 0, granuladora 0, demanda $160 - 100 = 60$.

Planteamiento. corolario 2.6.

Desarrollo.

1. $y_3(160 - 100) = 0$ con holgura $60 > 0$ obliga a $y_3^* = 0$: un recurso que sobra no tiene valor marginal.
2. $E = 100 > 0$ obliga a que la restricción dual de E sea activa: $0{,}5y_1 + 0{,}6y_2 + 0 \cdot y_3 = 40$; igual con $P = 100 > 0$: $0{,}5y_1 + 0{,}3y_2 + y_3 = 30$.
3. Precio máximo por una hora de granuladora: su precio sombra, 33,33 €, válido mientras la base no cambie.

Resultado. $y_3^* = 0$ **porque la demanda no está saturada; las duales son igualdades porque se fabrican ambos productos; se pagarían como mucho 33,33 €/h.**

Comprobación. el cuaderno resuelve con 91 h de granuladora y obtiene 7033,33 €, exactamente 33,33 € más.

Solución del ejercicio 2.2

Datos. primal $\max 40E + 30P$ s.a. $0{,}5E + 0{,}5P \leq 100$, $0{,}6E + 0{,}3P \leq 90$, $P \leq 160$, $E, P \geq 0$.

Planteamiento. definición 2.3: una variable por restricción, una restricción por variable.

Desarrollo.

1. Dual: $\min 100y_1 + 90y_2 + 160y_3$ s.a. $0{,}5y_1 + 0{,}6y_2 \geq 40$, $0{,}5y_1 + 0{,}3y_2 + y_3 \geq 30$, $y \geq 0$.
2. Con $y^* = (40;\ 100/3;\ 0)$: $20 + 20 = 40 \geq 40$ y $20 + 10 + 0 = 30 \geq 30$. Factible.
3. $b^\mathsf{T} y^* = 4000 + 3000 + 0 = 7000$.

Resultado. y^* **es dual factible y** $b^\mathsf{T} y^* = c^\mathsf{T} x^* = 7000$: ambos son óptimos (teorema 2.4).

Comprobación. la holgura complementaria se cumple: las dos restricciones duales son activas y $E, P > 0$; $y_3 = 0$ y la demanda tiene holgura.

Solución del ejercicio 2.3

Datos. precios sombra 1,1667 (curvado), 0 (soldadura), 0,80 (tubo); aumento permitido del tubo: 555,56 kg; margen óptimo 2766,67 \$.

Planteamiento. proposición 2.7: dentro del rango, el valor óptimo cambia en precio sombra por unidad; un producto nuevo compensa si su margen supera el valor de los recursos que consume.

Desarrollo.

1. (a) 550 kg está dentro del rango ($550 < 555{,}56$). Aumento del margen bruto: $550 \cdot 0{,}80 = 440$ \$. Coste: $550 \cdot 0{,}70 = 385$ \$. Ganancia neta: 55 \$. Conviene.
2. (b) Valor de los recursos del toldo: $1{,}8 \cdot 1{,}1667 + 0{,}5 \cdot 0 + 1{,}3 \cdot 0{,}80 = 2{,}10 + 1{,}04 = 3{,}14$ \$.

Resultado. **(a) sí: el margen sube 440 $ y la ganancia neta es de 55 $; (b) el toldo debe aportar más de 3,14 $ por unidad.**

Comprobación. resolviendo con 2550 kg de tubo se obtiene $3206{,}67 = 2766{,}67 + 440$ $ (480 sillas y 353,33 mesas).

Solución del ejercicio 2.4

Datos. $\max x_1 + 5x_2$ s.a. $-4x_1 + 3x_2 \le 6$, $3x_1 + 2x_2 \le 18$, $x \in \mathbb{Z}^2_{\ge 0}$.

Planteamiento. ramificación y acotación en profundidad, ramificando en una variable fraccionaria.

Desarrollo.

1. Raíz: el óptimo de la relajación está en la intersección de las dos rectas: de $-4x_1+3x_2 = 6$ y $3x_1 + 2x_2 = 18$ sale $x = (42/17,\ 90/17) = (2{,}47;\ 5{,}29)$, $z = 28{,}94$. Se ramifica en x_2.
2. $x_2 \ge 6$: $-4x_1 + 18 \le 6$ exige $x_1 \ge 3$ y $3x_1 + 12 \le 18$ exige $x_1 \le 2$: infactible.
3. $x_2 \le 5$: óptimo en $x_2 = 5$, $x_1 = 8/3$ (sobre $3x_1 + 2x_2 = 18$), $z = 27{,}67$. Se ramifica en x_1.
4. $x_2 \le 5$, $x_1 \ge 3$: $x = (3;\ 4{,}5)$, $z = 25{,}5$. Se ramifica en x_2: con $x_2 \ge 5$ es infactible; con $x_2 \le 4$, $x = (10/3;\ 4)$, $z = 23{,}33$; se ramifica en x_1: $x_1 \ge 4$ da $(4, 3)$, $z = 19$, primer incumbente; $x_1 \le 3$ da $(3, 4)$, $z = 23$, nuevo incumbente.
5. $x_2 \le 5$, $x_1 \le 2$: $x = (2;\ 4{,}67)$, $z = 25{,}33$. Con $x_2 \ge 5$ es infactible; con $x_2 \le 4$, $(2, 4)$, $z = 22 < 23$: podado por cota.

Resultado. **óptimo** $x^* = (3, 4)$**,** $z^* = 23$, frente a 28,94 de la relajación (11 nodos en profundidad).

Comprobación. $(3, 4)$ cumple $-12 + 12 = 0 \le 6$ y $9 + 8 = 17 \le 18$; la enumeración de los enteros factibles confirma que ninguno supera 23.

Solución del ejercicio 2.5

Datos. valores $v = (33, 45, 25, 17, 39, 23)$, pesos $w = (10, 14, 8, 6, 12, 8)$, presupuesto 28.

Planteamiento. la relajación de una mochila se resuelve llenando por orden de v_j/w_j (Dantzig).

Desarrollo.

1. (a) $\max v^{\mathsf{T}} x$ s.a. $w^{\mathsf{T}} x \le 28$, $x \in \{0, 1\}^6$.
2. (b) Ratios: 3,30; 3,21; 3,13; 2,83; 3,25; 2,88. Orden: 1, 5, 2, 3, 6, 4. Se toman $x_1 = 1$ (capital 10) y $x_5 = 1$ (22); quedan 6 para la 2, que pide 14: $x_2 = 6/14 = 0{,}4286$. Valor: $33 + 39 + 45 \cdot 0{,}4286 = 91{,}29$.
3. (c) Como los valores son enteros, la cota útil es $\lfloor 91{,}29 \rfloor = 91$; gap $= (91{,}29 - 89)/89 = 2{,}6\,\%$, o $(91 - 89)/89 = 2{,}2\,\%$ con la cota entera.
4. (d) Rama $x_2 = 1$: quedan 14 de capital; 1 entra entero (4 de capital restante), 5 entra en 4/12: $45 + 33 + 13 = 91$. Rama $x_2 = 0$: 1 y 5 (22), quedan 6 para la 3: $x_3 = 0{,}75$, $33 + 39 + 18{,}75 = 90{,}75$.
5. Ninguna rama puede podarse: $\lfloor 91 \rfloor = 91 > 89$ y $\lfloor 90{,}75 \rfloor = 90 > 89$.

Resultado. **relajación** 91,29 **(cota 91); hijos** 91 **y** 90,75**; ninguno se poda.** El óptimo, 89, requiere 17 nodos en profundidad.

Comprobación. $\{1, 4, 5\}$ usa $10 + 6 + 12 = 28$ y vale $33 + 17 + 39 = 89$; la enumeración de las 64 carteras no encuentra ninguna mejor.

Solución del ejercicio 2.6

Datos. $x_1, x_2 \in \{0, 1\}$.

Planteamiento. cotas superiores e inferiores que fuercen el valor lógico.

Desarrollo.

1. Conjunción: $w \le x_1$, $w \le x_2$, $w \ge x_1 + x_2 - 1$, $w \ge 0$.
2. Disyunción: $y \ge x_1$, $y \ge x_2$, $y \le x_1 + x_2$, $y \le 1$.
3. O exclusivo con $a = x_1 \wedge x_2$ (restricciones del paso 1): $z = x_1 + x_2 - 2a$.
4. Comprobación de (x_1, x_2): $(0, 0)$: $w = 0$, $y = 0$, $z = 0$; $(1, 0)$ y $(0, 1)$: $w = 0$, $y = 1$, $z = 1$; $(1, 1)$: $w \ge 1$ luego $w = 1$, $y = 1$, $a = 1$, $z = 0$.

Resultado. w**:** $w \le x_1$**,** $w \le x_2$**,** $w \ge x_1 + x_2 - 1$**;** y**:** $y \ge x_1$**,** $y \ge x_2$**,** $y \le x_1 + x_2$**;** $z = x_1 + x_2 - 2a$ **con** $a = x_1 \wedge x_2$**.**

Comprobación. las cuatro combinaciones reproducen las tablas de verdad, y en cada caso las restricciones fijan un único valor entero.

Solución del ejercicio 2.7

Datos. $C = 280$; demanda pendiente de Lager desde la semana 3: $160 + 190 = 350$; de IPA en la semana 4: 100.

Planteamiento. $M_{pt} = \min(C, \sum_{s \ge t} d_{ps})$ (proposición 2.11); en la relajación, el menor y compatible con $x \le My$ es x/M.

Desarrollo.

1. (a) Lager, semana 3: $\min(280, 350) = 280$. IPA, semana 4: $\min(280, 100) = 100$.
2. (b) Con $x = 170$ y $M = 280$: $y \ge 0{,}607$, y se «paga» $0{,}607 \cdot 500 = 303{,}6$ € de preparación. Con $M = 10^4$: $y \ge 0{,}017$ y se pagan 8,50 €.
3. (c) $y_{\text{IPA},t} + y_{\text{Tost},t} \le 1$ para cada t.

Resultado. **(a) 280 y 100 hL; (b)** $y \ge 0{,}607$ **(303,6 €) frente a** $y \ge 0{,}017$ **(8,5 €); (c)** $y_{\text{IPA},t} + y_{\text{Tost},t} \le 1$**.**

Comprobación. con la M grande la relajación casi ignora las preparaciones y su cota empeora, como predice la proposición 2.11 (ii).

Solución del ejercicio 2.8

Datos. PL $\max\{c^{\mathsf{T}}x : Ax \le b,\ x \ge 0\}$ con poliedro dual $D = \{y \ge 0 : A^{\mathsf{T}}y \ge c\}$ no vacío.

Planteamiento. por dualidad fuerte, $z^*(b) = \min_{y \in D} b^{\mathsf{T}}y$.

Desarrollo.

1. Si el primal es factible para b y el dual es factible, el primal está acotado (teorema 2.4) y tiene óptimo; por la teorema 2.5, $z^*(b) = \min_{y \in D} b^{\mathsf{T}}y$.

2. Si D tiene vértices $y^1, \dots, y^K$ y el mínimo se alcanza en un vértice (teorema 2.2 aplicado al dual), $z^*(b) = \min_k b^\mathsf{T} y^k$.
3. Un mínimo de funciones lineales de b es cóncavo y lineal a trozos.
4. Para un recurso i, la función $\beta \mapsto z^*(b + \beta e_i)$ es cóncava en β, así que su pendiente (el precio sombra y_i^*) es no creciente en β.

Resultado. $z^*(b) = \min_k y^{k\mathsf{T}} b$ **es cóncava y lineal a trozos; el valor marginal de cada recurso no crece al aumentar su disponibilidad.**

Comprobación. en la cervecera, la capacidad de la semana 4 vale 4 €/hL hasta 290 hL y 0 después: pendiente no creciente.

A.3 Tema 3

Solución del ejercicio 3.1

Datos. $n = 10$ y $n = 20$; 10^9 circuitos por segundo.

Planteamiento. proposición 3.1: $(n-1)!/2$.

Desarrollo.

1. $n = 10$: $9!/2 = 362\,880/2 = 181\,440$ circuitos; tiempo $1{,}8 \cdot 10^{-4}$ s.
2. $n = 20$: $19!/2 = 1{,}216 \cdot 10^{17}/2 = 6{,}08 \cdot 10^{16}$; tiempo $6{,}08 \cdot 10^7$ s, unos 1,9 años.

Resultado. **181 440 circuitos (0,18 ms) y** $6{,}08 \cdot 10^{16}$ **circuitos (casi 2 años).**

Comprobación. la tabla de 15.053, con 10^{21} pasos por segundo, muestra el mismo crecimiento: $n!$ pasa de milisegundos con 20 ciudades a miles de años con 30.

Solución del ejercicio 3.2

Datos. $t_{01} = 16$, $t_{12} = 10$, $t_{24} = 22$, $t_{43} = 14$, $t_{30} = 14$; $s = 10$; ventanas del ejemplo 3.5.

Planteamiento. llegada $= \max(a_j,\ \text{salida} + t_{ij})$, con salida $=$ llegada $+ s$.

Desarrollo.

1. Bar 1: llega a los 16, espera hasta 60 (44 min), sale a los 70.
2. Bar 2: $70 + 10 = 80 \le 90$; sale a los 90.
3. Bar 4: $90 + 22 = 112 \in [30, 120]$; sale a los 122.
4. Bar 3: $122 + 14 = 136 \in [120, 180]$; sale a los 146.
5. Almacén: $146 + 14 = 160 \le 300$. Carga: $4 + 6 + 3 + 5 = 18 \le 22$. Viaje: $16 + 10 + 22 + 14 + 14 = 76$ min.
6. Ruta $0 \to 3 \to 1$: llega al bar 3 a los 14, espera hasta 120, sale a los 130 y llega al bar 1 a los $130 + 22 = 152 > 120$: infactible.

Resultado. **la primera ruta es factible (llegadas 60, 80, 112, 136 y regreso a los 160; 76 min de viaje); la segunda no.**

Comprobación. coincide con `evalua_ruta` del cuaderno.

Solución del ejercicio 3.3

Datos. $A = (0, 0)$, $B = (4, 0)$, $C = (4, 3)$, $D = (0, 3)$.

Planteamiento. definición 3.2; las aristas (A, C) y (B, D) son las diagonales y se cruzan.

Desarrollo.

1. $A \to C \to B \to D \to A$: $5 + 3 + 5 + 3 = 16$.
2. El 2-opt elimina (A, C) y (B, D), añade (A, B) y (C, D) e invierte el tramo: $A \to B \to C \to D \to A$, longitud $4 + 3 + 4 + 3 = 14$.
3. (b) Si (a, b) y (c, d) se cortan en P, por la desigualdad triangular $d(a, c) \le d(a, P)+d(P, c)$ y $d(b, d) \le d(b, P)+d(P, d)$. Sumando, $d(a, c)+d(b, d) \le d(a, b)+d(c, d)$, con desigualdad estricta salvo si los puntos están alineados.

Resultado. **de 16 a 14 (ahorro de 2); deshacer un cruce nunca alarga el circuito.**

Comprobación. $\Delta = d(A, B) + d(C, D) - d(A, C) - d(B, D) = 4 + 4 - 5 - 5 = -2 < 0$.

Solución del ejercicio 3.4

Datos. duraciones 12, 18, 22, 35, 40, 59 s; bloques de 60 s.

Planteamiento. empaquetado en contenedores: $y_k = 1$ si se usa el bloque k; $x_{ik} = 1$ si el anuncio i va en el bloque k.

Desarrollo.

1. PLEM: $\min \sum_k y_k$ s.a. $\sum_k x_{ik} = 1$ para cada anuncio; $\sum_i \ell_i x_{ik} \le 60 y_k$ para cada bloque; binarias, con $k = 1, \ldots, 6$.
2. Cota: $\sum \ell_i = 186$; $\lceil 186/60 \rceil = 4$.
3. Solución con 4 bloques: $\{59\}$, $\{40, 18\}$, $\{35, 22\}$, $\{12\}$ (o $\{40, 12\}$, $\{35, 22\}$, $\{59\}$, $\{18\}$).

Resultado. **4 bloques, óptimo por coincidir con la cota.**

Comprobación. $40 + 18 = 58$, $35 + 22 = 57$; ningún par cabe con el anuncio de 59 s.

Solución del ejercicio 3.5

Datos. $J1 = (3, 6)$, $J2 = (5, 2)$, $J3 = (1, 2)$, $J4 = (6, 6)$, $J5 = (7, 5)$.

Planteamiento. regla de Johnson y recurrencia $C_1 \leftarrow C_1 + p_1$, $C_2 \leftarrow \max(C_2, C_1) + p_2$.

Desarrollo.

1. $p_1 \le p_2$: J1, J3, J4; por p_1 creciente: J3, J1, J4. $p_1 > p_2$: J2, J5; por p_2 decreciente: J5, J2. Secuencia: J3, J1, J4, J5, J2.
2. J3: $C_1 = 1$, $C_2 = 3$. J1: $C_1 = 4$, $C_2 = \max(3, 4) + 6 = 10$. J4: $C_1 = 10$, $C_2 = 16$. J5: $C_1 = 17$, $C_2 = \max(16, 17) + 5 = 22$. J2: $C_1 = 22$, $C_2 = \max(22, 22) + 2 = 24$.
3. Cota de la proposición 3.8: cargas 22 y 21, piezas de a lo sumo 13 h: $C_{\max} \ge 22$.

Resultado. **secuencia J3, J1, J4, J5, J2 con makespan 24 h**; cota 22 h.

Comprobación. una cota más fina es la carga de la sierra más el menor p_2 de la última pieza, $22 + 2 = 24$, de modo que 24 es óptimo; la enumeración de las 120 secuencias lo confirma.

Solución del ejercicio 3.6

Datos. $b_1 = 120$, $b_8 = 210$, $b_3 = 180$; $a_2 = 0$, $a_5 = 150$, $a_1 = 60$; $t_{12} = 10$, $t_{85} = 24$, $t_{31} = 22$; $s = 10$.

Planteamiento. $M_{ij} = \max(0,\ b_i + s + t_{ij} - a_j)$ (proposición 3.4); un arco es imposible si $a_i + s + t_{ij} > b_j$.

Desarrollo.

1. $M_{12} = 120 + 10 + 10 - 0 = 140$.
2. $M_{85} = 210 + 10 + 24 - 150 = 94$.
3. $M_{31} = 180 + 10 + 22 - 60 = 152$.
4. El bar 3 no puede servirse antes de los 120 min; la llegada más temprana al bar 1 por ese arco es $120 + 10 + 22 = 152 > 120 = b_1$. Ninguna ruta puede usar $3 \to 1$.
5. Preproceso: eliminar todo arco con $a_i + s + t_{ij} > b_j$; en este caso hay 19 de los 56 arcos entre clientes.

Resultado. $M_{12} = 140$**,** $M_{85} = 94$**,** $M_{31} = 152$**; el arco** $3 \to 1$ **es infactible y se elimina, como otros 18.**

Comprobación. la ruta óptima no usa ningún arco eliminado: sus arcos entre clientes son $1 \to 2$, $2 \to 4$, $4 \to 3$, $6 \to 7$, $7 \to 8$ y $8 \to 5$.

Solución del ejercicio 3.7

Datos. caso del ejemplo 3.9; cota 11 h.

Planteamiento. (a) como en la proposición 3.8; (b) construcción; (c) análisis de casos suponiendo $C_{\max} = 11$.

Desarrollo.

1. (a) Véase la demostración de la proposición 3.8.
2. (b) Se alcanza: J1 $= (M_1, 2), (M_2, 1)$, J2 $= (M_2, 2), (M_1, 1)$: se programa J1 en M_1 [0,2] y J2 en M_2 [0,2], después J1 en M_2 [2,3] y J2 en M_1 [2,3]; $C_{\max} = 3 =$ cota. No se alcanza: J1 $= (M_1, 2), (M_2, 2)$ y J2 $= (M_1, 2), (M_2, 2)$: la cota es 4, pero M_2 no puede empezar antes de las 2 y debe trabajar 4 h, así que $C_{\max} = 6$.
3. (c) Con $C_{\max} = 11$ la fresadora (11 h de carga) trabaja sin pausa de 0 a 11. En $t = 0$ solo puede empezar P2 (las demás operaciones de fresadora van precedidas de otras): P2 ocupa [0,4].
4. En $t = 4$ debe empezar otra: P3 y P4 necesitan antes $3 + 3 = 6$ y $2 + 3 = 5$ h, luego solo P1, que exige su torno (3 h) terminado: torno con P1 en [0,3] o [1,4]; fresadora con P1 en [4,6].
5. En $t = 6$: P4 necesitaría torno y taladro terminados, pero el torno está ocupado por P1 hasta las 3 como pronto, y $3 + 2 + 3 = 8 > 6$. Luego P3, que necesita su taladro [0,3] y su torno de 3 h terminado a las 6: torno con P3 en [3,6], lo que obliga a P1 en [0,3]. Fresadora con P3 en [6,8].
6. En $t = 8$, P4: su torno solo puede ir en [6,8] (el torno está ocupado hasta las 6) y su taladro en [8,11], de modo que su fresado empezaría a las 11. Contradicción.

Resultado. **la cota de 11 h es inalcanzable y** $C^*_{\max} \geq 12$; el programa del ejemplo 3.9 alcanza 12, luego es óptimo.

Comprobación. CP-SAT y la enumeración de los 13 824 órdenes del cuaderno dan 12 h.

A.4 Tema 4

Solución del ejercicio 4.1

Datos. cinco problemas.

Planteamiento. definición 4.1: objetivo convexo, desigualdades $g \leq 0$ con g convexa, igualdades afines.

Desarrollo.

1. (a) Convexo: cuadrática definida positiva y restricción lineal.
2. (b) Convexo: $-\log$ es convexa y la igualdad es afín.
3. (c) No convexo: la igualdad $x_1^2 + x_2^2 = 1$ no es afín (el conjunto es una circunferencia).
4. (d) Convexo aunque no lo parezca: max es convexa, y $\{x \geq 0 : x_1 x_2 \geq 1\}$ es convexo (es $\{x > 0 : \log x_1 + \log x_2 \geq 0\}$, superconjunto de nivel de una función cóncava). Para DCP hay que escribirla como `geo_mean(x) >= 1`.
5. (e) Convexo: norma de una función afín y restricción de norma.

Resultado. **convexos (a), (b), (d) y (e); no convexo (c).**

Comprobación. (c) tiene dos mínimos en $(0, \pm 1)$, ambos globales, pero el conjunto no es convexo: el punto medio $(0, 0)$ no es factible.

Solución del ejercicio 4.2

Datos. $\min x_1^2 + x_2^2$ s.a. $5 - x_1 - 2x_2 \leq 0$.

Planteamiento. teorema 4.5 con $g(x) = 5 - x_1 - 2x_2$.

Desarrollo.

1. Estacionariedad: $(2x_1, 2x_2) + \lambda(-1, -2) = 0$, de donde $x = \frac{\lambda}{2}(1, 2)$.
2. Si $\lambda = 0$, $x = 0$, infactible. Luego la restricción es activa: $\frac{\lambda}{2}(1+4) = 5$, $\lambda = 2$, $x = (1, 2)$, $p^* = 5$.
3. Sensibilidad: con lado derecho u, $x = \frac{u}{5}(1, 2)$ y $p^*(u) = u^2/5$; $\mathrm{d}p^*/\mathrm{d}u = 2u/5 = 2 = \lambda$ en $u = 5$.
4. Estimación: $\Delta p^* \approx 2 \cdot 0{,}1 = 0{,}2$. Exacto: $5{,}1^2/5 - 5 = 5{,}202 - 5 = 0{,}202$.

Resultado. $x^* = (1, 2)$, $\lambda^* = 2$**; el valor óptimo sube unas 0,2 unidades (exactamente 0,202).**

Comprobación. x^* es la proyección del origen sobre la recta $x_1 + 2x_2 = 5$: distancia al cuadrado $25/5 = 5$.

Solución del ejercicio 4.3

Datos. $C_1 = 20P_1 + 0{,}01P_1^2$, $C_2 = 18P_2 + 0{,}02P_2^2$, $D = 500$ MW.

Planteamiento. igual coste incremental: $20 + 0{,}02P_1 = 18 + 0{,}04P_2 = \lambda$ y $P_1 + P_2 = 500$.

Desarrollo.

1. $P_1 = 50(\lambda - 20)$, $P_2 = 25(\lambda - 18)$.
2. $50\lambda - 1000 + 25\lambda - 450 = 500$, luego $75\lambda = 1950$ y $\lambda = 26$ €/MWh.
3. $P_1 = 300$ MW, $P_2 = 200$ MW.
4. Coste: $C_1 = 6000 + 900 = 6900$; $C_2 = 3600 + 800 = 4400$; total 11 300 €/h.

Resultado. $\boldsymbol{P = (300, 200)}$ MW, $\boldsymbol{\lambda = 26}$ €/MWh, coste **11 300 €/h**.

Comprobación. repartos vecinos son más caros: con $(301, 199)$, $C_1 = 6926{,}01$ y $C_2 = 4374{,}02$, total 11 300,03.

Solución del ejercicio 4.4

Datos. $\max \sum_i \log(\alpha_i + x_i)$, $\alpha = (0{,}5;\ 1;\ 1{,}5)$, $\sum x_i = 1$, $x \geq 0$.

Planteamiento. KKT del problema equivalente $\min -\sum \log(\alpha_i + x_i)$ con multiplicadores ν (igualdad) y $\lambda_i \geq 0$ $(-x_i \leq 0)$.

Desarrollo.

1. Estacionariedad: $-1/(\alpha_i + x_i) - \lambda_i + \nu = 0$; holgura: $\lambda_i x_i = 0$.
2. Si $x_i > 0$: $\lambda_i = 0$ y $x_i = 1/\nu - \alpha_i$. Si $x_i = 0$: $\lambda_i = \nu - 1/\alpha_i \geq 0$, es decir, $1/\nu \leq \alpha_i$. En ambos casos $x_i = \max(0,\ 1/\nu - \alpha_i)$.
3. Probando los tres canales activos: $3/\nu - 3 = 1$, $1/\nu = 4/3$, $x_3 = 4/3 - 1{,}5 < 0$: no vale.
4. Con los canales 1 y 2: $2/\nu - 1{,}5 = 1$, $1/\nu = 1{,}25$; $x = (0{,}75;\ 0{,}25;\ 0)$, y $1{,}25 \leq 1{,}5$ confirma $x_3 = 0$.

Resultado. $\boldsymbol{\nu = 0{,}8}$, $\boldsymbol{x^* = (0{,}75;\ 0{,}25;\ 0)}$.

Comprobación. $0{,}75 + 0{,}25 = 1$; el «nivel del agua» $\alpha_i + x_i$ es 1,25 en los canales activos y el canal 3 ($\alpha_3 = 1{,}5$) queda por encima.

Solución del ejercicio 4.5

Datos. $\lambda = 28{,}4$; $P_2 = 350$ en su máximo; incrementales $18 + 0{,}04P_1$, $20 + 0{,}02P_2$, $26 + 0{,}01P_3$.

Planteamiento. (a) proposición 4.6 y nuevo cálculo; (b) mientras se mantenga la estructura de límites activos.

Desarrollo.

1. (a) Estimación: $20 \cdot 28{,}4 = 568$ €/h.
2. Exacto con $D = 830$: $25(\lambda - 18) + 100(\lambda - 26) = 480$, $\lambda = 28{,}24$, $P = (256, 350, 224)$, coste 21 418,6 €/h; ahorro $21\,985 - 21\,418{,}6 = 566{,}4$ €/h.
3. (b) Al subir D, el primero en tocar un límite es el grupo 3 con $26 + 0{,}01P_3 = \lambda$ y $P_3 = 300$, es decir, $\lambda = 29$, $P_1 = 275$: $D = 275 + 350 + 300 = 925$.
4. Al bajar D, el grupo 2 deja su máximo cuando $\lambda = 20 + 0{,}02 \cdot 350 = 27$: $P_1 = 225$, $P_3 = 100$, $D = 675$.

Resultado. **(a) ahorro estimado 568 €/h, exacto 566,4 €/h; (b) para** $675 \le D \le 925$ **MW solo está activo el máximo del grupo 2.**

Comprobación. en ambos extremos los mínimos técnicos no se tocan ($P_1 \ge 225 > 100$, $P_3 \ge 100 > 50$).

Solución del ejercicio 4.6

Datos. $C_i = a_i + b_i P_i + c_i P_i^2$ con los datos del ejemplo 4.7, sin límites; $D = 850$.

Planteamiento. minimizar la lagrangiana en cada P_i por separado.

Desarrollo.

1. $\min_{P_i}\left[a_i + (b_i - \lambda)P_i + c_i P_i^2\right]$ se alcanza en $P_i = (\lambda - b_i)/(2c_i)$ y vale $a_i - (\lambda - b_i)^2/(4c_i)$.
2. $q(\lambda) = \sum_i a_i - \sum_i (\lambda - b_i)^2/(4c_i) + \lambda D$.
3. $q'(\lambda) = -\sum_i (\lambda - b_i)/(2c_i) + D = 0$ es la ecuación de balance: $\lambda = 28$.
4. $q(28) = 1200 - \left(10^2/0{,}08 + 8^2/0{,}04 + 2^2/0{,}02\right) + 28 \cdot 850 = 1200 - (1250 + 1600 + 200) + 23\,800 = 21\,950$.
5. Primal en $P = (250, 400, 200)$: $6250 + 10\,000 + 5700 = 21\,950$.

Resultado. $q(\lambda) = 1200 - \sum_i (\lambda - b_i)^2/(4c_i) + 850\lambda$**, máximo en** $\lambda = 28$ **con valor 21 950 €/h, igual al coste primal**: dualidad fuerte.

Comprobación. $q''(\lambda) = -\sum_i 1/(2c_i) = -175 < 0$: el punto crítico es un máximo.

Solución del ejercicio 4.7

Datos. f convexa y diferenciable, $\mathcal{X}$ convexo.

Planteamiento. desigualdad de primer orden de la convexidad, $f(x) \ge f(x^*) + \nabla f(x^*)^\mathsf{T}(x - x^*)$ (módulo 4, tema 5).

Desarrollo.

1. Suficiencia: si $\nabla f(x^*)^\mathsf{T}(x - x^*) \ge 0$ para todo $x \in \mathcal{X}$, la desigualdad de primer orden da $f(x) \ge f(x^*)$.
2. Necesidad: si existiera $x \in \mathcal{X}$ con $\nabla f(x^*)^\mathsf{T}(x - x^*) < 0$, la derivada direccional de f en x^* hacia x sería negativa y, para $t > 0$ pequeño, $x^* + t(x - x^*) \in \mathcal{X}$ (convexidad) tendría f menor que $f(x^*)$.
3. Geometría: $-\nabla f(x^*)$ forma un ángulo de al menos 90° con toda dirección factible; el gradiente negativo «apunta hacia fuera» de $\mathcal{X}$.
4. Si x^* es interior, las direcciones $\pm e_k$ son factibles: $\pm\partial_k f(x^*) \ge 0$ implica $\nabla f(x^*) = 0$.

Resultado. x^* **es óptimo si y solo si** $\nabla f(x^*)^\mathsf{T}(x - x^*) \ge 0$ **para todo** $x \in \mathcal{X}$**; en el interior,** $\nabla f(x^*) = 0$**.**

Comprobación. en el ejercicio 4.2, $\nabla f(1, 2) = (2, 4)$ y para x factible $(2, 4)^\mathsf{T}(x - (1, 2)) = 2(x_1 + 2x_2 - 5) \ge 0$.

A.5 Tema 5

Solución del ejercicio 5.1

Datos. $\Delta = 50$; $T = 100$ y $T = 25$; $T_{k+1} = 0{,}99T_k$, $T_0 = 500$.

Planteamiento. probabilidad $e^{-\Delta/T}$; $500 \cdot 0{,}99^k < 1$.

Desarrollo.

1. $T = 100$: $e^{-0{,}5} = 0{,}6065$.
2. $T = 25$: $e^{-2} = 0{,}1353$.
3. $k > \ln 500/(-\ln 0{,}99) = 6{,}2146/0{,}010050 = 618{,}3$, luego $k = 619$.

Resultado. **60,65 % y 13,53 %; hacen falta 619 iteraciones.**

Comprobación. $500 \cdot 0{,}99^{619} = 0{,}993 < 1$ y $500 \cdot 0{,}99^{618} = 1{,}004 > 1$.

Solución del ejercicio 5.2

Datos. $a = (1, 9)$, $b = (2, 7)$, $c = (3, 8)$, $d = (4, 4)$, $e = (5, 5)$, $f = (7, 2)$.

Planteamiento. definición 5.4: se buscan los no dominados, se retiran y se repite.

Desarrollo.

1. c está dominado por b ($2 \le 3$, $7 \le 8$); e por d ($4 \le 5$, $4 \le 5$).
2. a, b, d y f no están dominados: cada uno es el mejor en f_1 entre los que tienen su f_2 o menos.
3. Sin el primer frente, c y e no se dominan entre sí ($3 < 5$ pero $8 > 5$).

Resultado. $\mathcal{F}_1 = \{a, b, d, f\}$ **(rango 1) y** $\mathcal{F}_2 = \{c, e\}$ **(rango 2).**

Comprobación. la función `ordenacion_no_dominada` del cuaderno devuelve los mismos rangos.

Solución del ejercicio 5.3

Datos. $\mathcal{F}_1$: $a = (1, 9)$, $b = (2, 7)$, $d = (4, 4)$, $f = (7, 2)$; rangos $f_1^{\max} - f_1^{\min} = 6$, $f_2^{\max} - f_2^{\min} = 7$.

Planteamiento. distancia de aglomeración de NSGA-II.

Desarrollo.

1. Orden por f_1: a, b, d, f; extremos a y f: distancia infinita.
2. b: $(4 - 1)/6 + (9 - 4)/7 = 0{,}5 + 0{,}7143 = 1{,}214$ (en f_2 sus vecinos son d y a).
3. d: $(7 - 2)/6 + (7 - 2)/7 = 0{,}8333 + 0{,}7143 = 1{,}548$.

Resultado. a, f**:** ∞**;** b**: 1,214;** d**: 1,548. Se descartaría primero** b, el más rodeado.

Comprobación. la función `crowding` del cuaderno da los mismos valores con estos cuatro puntos.

Solución del ejercicio 5.4

Datos. $A = (3400;\ 13{,}5)$, $B = (3700;\ 10{,}5)$, $C = (3900;\ 7{,}833)$, $D = (4400;\ 6{,}833)$.

Planteamiento. para cada w, comparar B con A y con C.

Desarrollo.

1. A es mejor que B si $w{\cdot}3400+(1-w)\,13{,}5 < w{\cdot}3700+(1-w)\,10{,}5$, es decir, $3(1-w) < 300w$: $w > 3/303 = 0{,}00990$.
2. C es mejor que B si $200w < 2{,}667(1-w)$: $w < 2{,}667/202{,}67 = 0{,}01316$.
3. Como $0{,}00990 < 0{,}01316$, todo $w \in [0,1]$ cumple alguna de las dos condiciones.

Resultado. **para todo w, A o C tiene menor suma ponderada que B**: B no está apoyado.
Comprobación. geométricamente, B queda 0,4 por encima del segmento AC en $f_1 = 3700$.

Solución del ejercicio 5.5

Datos. $p_1 = (1,2,3,4,5,6)$, $p_2 = (4,6,2,1,5,3)$, tramo de las posiciones 3 a 5.
Planteamiento. copiar el tramo y rellenar con el orden de p_2.
Desarrollo.

1. Tramo copiado: $(_,_,3,4,5,_)$.
2. Genes de p_2 que faltan, en su orden: $6,2,1$ (se saltan 4, 5 y 3).
3. Relleno de izquierda a derecha: posiciones 1, 2 y 6 reciben 6, 2 y 1.

Resultado. **hijo** $(6,2,3,4,5,1)$**.**
Comprobación. contiene cada número del 1 al 6 exactamente una vez.

Solución del ejercicio 5.6

Datos. $\lambda = 6$, $\mu = 3$.
Planteamiento. $w'_i = \ln 3{,}5 - \ln i$, normalizados.
Desarrollo.

1. $w' = (1{,}2528;\ 0{,}5596;\ 0{,}1542)$, suma 1,9665.
2. $w = (0{,}6370;\ 0{,}2846;\ 0{,}0784)$.
3. $\sum w_i^2 = 0{,}4058 + 0{,}0810 + 0{,}0061 = 0{,}4929$; $\mu_{\text{eff}} = 2{,}029$.

Resultado. $\boldsymbol{w = (0{,}637;\ 0{,}285;\ 0{,}078)}$, $\boldsymbol{\mu_{\text{eff}} \approx 2{,}03}$.
Comprobación. $1 \le \mu_{\text{eff}} \le \mu = 3$, con igualdad superior solo para pesos iguales.

Solución del ejercicio 5.7

Datos. problema $\min f_1$ s.a. $f_2 \le \varepsilon$ con solución única x^*; frente del ejemplo 5.6.
Planteamiento. reducción al absurdo; elegir $\varepsilon = 10{,}5$.
Desarrollo.

1. (a) Si x dominara a x^*: $f_2(x) \le f_2(x^*) \le \varepsilon$, así que x es factible, y $f_1(x) \le f_1(x^*)$. Por la unicidad, $x = x^*$, que no puede dominarse a sí mismo.
2. (b) Con $\varepsilon = 10{,}5$, las distribuciones con $f_2 \le 10{,}5$ tienen $f_1 \ge 3700$ (si alguna tuviera menos, dominaría a $(3700;\ 10{,}5)$ o tendría $f_2 > 10{,}5$), y el mínimo es 3700.

Resultado. **(a) la solución única es Pareto-óptima; (b)** $\varepsilon = 10{,}5$ **devuelve** $(3700;\ 10{,}5)$**.**

Comprobación. en el cuaderno, filtrando las 720 distribuciones con $f_2 \leq 10{,}5$, el menor f_1 es 3700.

Solución del ejercicio 5.8

Datos. propuesta $\mathbb{P}(x \to x')$ no simétrica; aceptación de Metropolis–Hastings.

Planteamiento. comprobar $\pi_T(x)P(x, x') = \pi_T(x')P(x', x)$.

Desarrollo.

1. Sea $r = \dfrac{\pi_T(x')\mathbb{P}(x' \to x)}{\pi_T(x)\mathbb{P}(x \to x')}$; la aceptación es $\alpha(x, x') = \min(1, r)$ y $\alpha(x', x) = \min(1, 1/r)$.
2. Si $r \leq 1$: $\pi_T(x)\mathbb{P}(x \to x')\, r = \pi_T(x')\mathbb{P}(x' \to x) = \pi_T(x')\mathbb{P}(x' \to x) \cdot 1$.
3. Si $r > 1$: simétrico intercambiando papeles.
4. Sin la corrección, el flujo de x a x' es proporcional a $\mathbb{P}(x \to x')$, y la cadena pasa más tiempo donde la propuesta lleva más masa, aunque f no sea mejor allí.

Resultado. **con la corrección se cumple el equilibrio detallado con** π_T**; sin ella, la distribución estacionaria se sesga hacia las regiones favorecidas por la propuesta.**

Comprobación. con propuesta simétrica el cociente de propuestas vale 1 y se recupera la regla de la proposición 5.2.

A.6 Tema 6

Solución del ejercicio 6.1

Datos. cuatro prácticas.

Planteamiento. preguntar en cada caso qué información no estaría disponible al decidir o qué se usa dos veces.

Desarrollo.

1. (a) Residuos dentro de muestra de un modelo flexible: casi nulos, cuantiles demasiado estrechos y producción insuficiente. Hay que usar residuos de un periodo de calibración.
2. (b) La temperatura real de la semana no se conoce el lunes: se debe usar la previsión disponible en ese momento.
3. (c) Maldición del optimizador: el beneficio del plan elegido está sesgado al alza; hay que reevaluarlo con datos nuevos.
4. (d) En series temporales, mezclar el futuro con el pasado en la validación permite que el modelo aprenda la tendencia futura; la validación debe respetar el orden temporal.

Resultado. **(a) calibración dentro de muestra; (b) variable no disponible al decidir; (c) sesgo de selección; (d) validación no temporal.**

Comprobación. el protocolo del ejemplo 6.10 (entrenamiento, calibración y prueba consecutivos) evita las cuatro.

Solución del ejercicio 6.2

Datos. $D \sim \mathcal{N}(80, 16^2)$; $c_u = 230$, $c_o = 50$; después $c_o = 70$.

Planteamiento. teorema 6.4: $q^* = \mu + \sigma\Phi^{-1}(c_u/(c_u + c_o))$.

Desarrollo.

1. Fractil: $230/280 = 0{,}8214$; $\Phi^{-1}(0{,}8214) = 0{,}9208$.
2. $q^* = 80 + 16 \cdot 0{,}9208 = 94{,}73$ hL, 14,7 hL por encima de la media.
3. Con saldo nulo, $c_o = 70$: fractil $230/300 = 0{,}7667$, $\Phi^{-1} = 0{,}7279$, $q^* = 80 + 11{,}65 = 91{,}65$ hL.

Resultado. $\boldsymbol{q^* = 94{,}7}$ **hL**; sin saldo, **91,6 hL**.

Comprobación. al encarecerse el sobrante, q^* baja, como debe; ambos superan la media porque el fractil es mayor que 0,5.

Solución del ejercicio 6.3

Datos. $c = (1{,}0;\ 1{,}2)$; $\hat{c}_A = (1{,}25;\ 1{,}2)$; $\hat{c}_B = (0{,}75;\ 1{,}2)$.

Planteamiento. error cuadrático $\|\hat{c} - c\|^2$; decisión $\arg\min_k \hat{c}_k$; pérdida $c_{\text{elegida}} - \min_k c_k$.

Desarrollo.

1. Errores: A, $0{,}25^2 = 0{,}0625$; B, $(-0{,}25)^2 = 0{,}0625$.
2. A elige la ruta 2 ($1{,}2 < 1{,}25$): pérdida $1{,}2 - 1{,}0 = 0{,}2$ h.
3. B elige la ruta 1 ($0{,}75 < 1{,}2$): pérdida 0.

Resultado. **mismo error cuadrático (0,0625), pérdidas de decisión 0,2 h y 0 h.** Lo que importa es el orden que induce la predicción, no su exactitud media.

Comprobación. en el caso lineal, la decisión solo depende de la predicción a través del arg min (proposición 6.2); SPO mide precisamente esa pérdida.

Solución del ejercicio 6.4

Datos. $D \in \{60, 100, 140\}$ con probabilidades $(0{,}3;\ 0{,}4;\ 0{,}3)$; $p = 300$, $c = 70$, $s = 20$; $c_u = 230$, $c_o = 50$.

Planteamiento. beneficio $\pi(q, D) = 300\min(q, D) - 70q + 20(q - D)^+$; en maximización, VSS = RP − EEV y EVPI = WS − RP.

Desarrollo.

1. (a) $\mathbb{E}D = 100$, luego $\bar{q} = 100$. Beneficios: $D = 60$: $18\,000 - 7000 + 800 = 11\,800$; $D \geq 100$: $30\,000 - 7000 = 23\,000$. EEV $= 0{,}3 \cdot 11\,800 + 0{,}7 \cdot 23\,000 = 19\,640$ €.
2. (b) Fractil 0,8214; $F(100) = 0{,}7 < 0{,}8214 \leq F(140) = 1$: $q^* = 140$. Beneficios: $D = 60$: $18\,000 - 9800 + 1600 = 9800$; $D = 100$: $30\,000 - 9800 + 800 = 21\,000$; $D = 140$: $42\,000 - 9800 = 32\,200$. RP $= 2940 + 8400 + 9660 = 21\,000$ €.
3. (c) WS $= 230 \cdot \mathbb{E}D = 230 \cdot 100 = 23\,000$ € (se produce exactamente D).
4. VSS $= 21\,000 - 19\,640 = 1360$ €; EVPI $= 23\,000 - 21\,000 = 2000$ €.

Resultado. **EEV** $= 19\,640$**, RP** $= 21\,000$ **(**$q = 140$**), WS** $= 23\,000$**; VSS** $= 1360$ **€ y EVPI** $= 2000$ **€.**

Comprobación. se cumple EEV $\leq$ RP $\leq$ WS (proposición 6.7 en versión de maximización).

Solución del ejercicio 6.5

Datos. $a_1 \in [7, 9]$, $a_2 \in [42, 46]$; $x_1 + x_2 = 100$; precios 0,22 y 0,40 €/kg.

Planteamiento. para una restricción $\geq$ con $x \geq 0$, el peor caso usa las cotas inferiores (proposición 6.8 con el signo cambiado).

Desarrollo.

1. (a) Contrapartida robusta: $7x_1 + 42x_2 \geq 1800$.
2. (b) Robusta: $7(100 - x_2) + 42x_2 \geq 1800$, $35x_2 \geq 1100$, $x_2 \geq 31{,}43$ kg. Nominal ($a = (8, 44)$): $800 + 36x_2 \geq 1800$, $x_2 \geq 27{,}78$ kg.
3. (c) Coste nominal: $0{,}22 \cdot 72{,}22 + 0{,}40 \cdot 27{,}78 = 27{,}00$ €. Robusto: $0{,}22 \cdot 68{,}57 + 0{,}40 \cdot 31{,}43 = 27{,}66$ €.

Resultado. **soja mínima 31,43 kg (robusta) frente a 27,78 kg (nominal); precio de la robustez 0,66 € por cada 100 kg (2,4 %).**

Comprobación. con la mezcla robusta y los contenidos mínimos: $7 \cdot 68{,}57 + 42 \cdot 31{,}43 = 480 + 1320 = 1800$.

Solución del ejercicio 6.6

Datos. escenarios $64, 72, 88, 95, 110$ (ordenados), fractil 0,8214.

Planteamiento. con la distribución empírica, el teorema 6.4 discreto da el menor escenario con $\hat{F} \geq 0{,}8214$.

Desarrollo.

1. $\hat{F}(95) = 4/5 = 0{,}8 < 0{,}8214$; $\hat{F}(110) = 1$: $q_{\text{SAA}} = 110$ hL.
2. Normal ajustada: media 85,8, desviación muestral 18,31; $q = 85{,}8 + 0{,}9208 \cdot 18{,}31 = 102{,}7$ hL.
3. Con cinco escenarios, el cuantil empírico salta de 95 a 110 y depende de un único valor extremo; la decisión tiene mucha varianza y su beneficio dentro de muestra está sesgado al alza.

Resultado. **SAA: 110 hL; normal ajustada: 102,7 hL**; con tan pocos escenarios, la decisión es inestable y hay que validarla fuera de muestra.

Comprobación. las transparencias de EE364a recomiendan aumentar el número de muestras hasta que el valor fuera de muestra se estabilice.

Solución del ejercicio 6.7

Datos. D discreta con valores $d_1 < \cdots < d_K$ y probabilidades p_k.

Planteamiento. estudiar $G(q) = \sum_k p_k[c_u(d_k - q)^+ + c_o(q - d_k)^+]$ entre dos valores consecutivos.

Desarrollo.

1. Cada término es lineal en q salvo en d_k, así que G es lineal a trozos con vértices en los d_k.

2. En (d_k, d_{k+1}), las demandas $\leq d_k$ son de sobrante y las demás de falta: pendiente $c_o F(d_k) - c_u(1 - F(d_k)) = (c_u + c_o)F(d_k) - c_u$.
3. La pendiente es no decreciente en k (convexidad) y pasa de negativa a no negativa en el primer k con $F(d_k) \geq c_u/(c_u + c_o)$.
4. El mínimo de una función convexa lineal a trozos está en el vértice donde cambia el signo de la pendiente: $q^* = d_k$ para ese k.

Resultado. $q^* = \min\{d_k : F(d_k) \geq c_u/(c_u + c_o)\}$**.**

Comprobación. en el ejercicio 6.4, $F(100) = 0{,}7 < 0{,}8214 \leq F(140)$ da $q^* = 140$, el valor obtenido allí.

Solución del ejercicio 6.8

Datos. $\mathbb{E}\hat{J}_i = J_i$; en (b), $\hat{J}_i = J + \varepsilon_i$ con $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ independientes.

Planteamiento. (a) desigualdad entre el máximo de esperanzas y la esperanza del máximo; (b) esperanza del máximo de dos normales.

Desarrollo.

1. (a) Para cada j, $\max_i \hat{J}_i \geq \hat{J}_j$; tomando esperanzas, $\mathbb{E}[\max_i \hat{J}_i] \geq J_j$ para todo j, luego $\mathbb{E}[\max_i \hat{J}_i] \geq \max_j J_j$.
2. (b) $\max(\varepsilon_1, \varepsilon_2) = \frac{1}{2}(\varepsilon_1 + \varepsilon_2) + \frac{1}{2}|\varepsilon_1 - \varepsilon_2|$. Como $\varepsilon_1 - \varepsilon_2 \sim \mathcal{N}(0, 2\sigma^2)$ y $\mathbb{E}|Z| = s\sqrt{2/\pi}$ para $Z \sim \mathcal{N}(0, s^2)$: $\mathbb{E}\max = \frac{1}{2}\sqrt{2}\sigma\sqrt{2/\pi} = \sigma/\sqrt{\pi} \approx 0{,}564\,\sigma$.
3. (c) Separar los datos: elegir la alternativa con un conjunto de escenarios o semanas y estimar su valor con otro independiente; o usar estimadores con contracción hacia la media.

Resultado. **(a)** $\mathbb{E}[\max \hat{J}] \geq \max J$**; (b) sesgo** $\sigma/\sqrt{\pi} \approx 0{,}564\,\sigma$ **con dos alternativas iguales; (c) validar con datos no usados para elegir.**

Comprobación. una simulación con 10^6 pares de normales estándar da una media del máximo de 0,565, frente al valor teórico $1/\sqrt{\pi} = 0{,}564$.

Bibliografía

[1] A. AhmadiTeshnizi, W. Gao y M. Udell. OptiMUS: Scalable optimization modeling with (MI)LP solvers and large language models. En *Proceedings of the 41st International Conference on Machine Learning*, PMLR 235:577–596, 2024. https://proceedings.mlr.press/v235/ahmaditeshnizi24a.html

[2] A. Ben-Tal, L. El Ghaoui y A. Nemirovski. *Robust Optimization*. Princeton University Press, 2009.

[3] D. Bertsimas y N. Kallus. From predictive to prescriptive analytics. *Management Science*, 66(3), 2020. Prepublicación de 2014. https://arxiv.org/abs/1402.5481

[4] D. Bertsimas y M. Sim. The price of robustness. *Operations Research*, 52(1):35–53, 2004.

[5] D. Bertsimas y J. N. Tsitsiklis. *Introduction to Linear Optimization*. Athena Scientific, 1997. Texto del curso 6.251J del MIT.

[6] J. R. Birge y F. Louveaux. *Introduction to Stochastic Programming*, 2.ª ed. Springer, 2011. Cap. 1, «Introduction and Examples».

[7] J. Blank y K. Deb. pymoo: Multi-objective optimization in Python. *IEEE Access*, 8, 2020. https://arxiv.org/abs/2002.04504

[8] S. Boyd y L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004. Cap. 4, «Convex optimization problems», y cap. 5, «Duality». Texto del curso EE364a de Stanford. https://web.stanford.edu/~boyd/cvxbook/

[9] S. Boyd y equipo docente de EE364a. Stochastic programming. Transparencias complementarias del curso EE364a: Convex Optimization I. Stanford University. https://web.stanford.edu/class/ee364a/lectures/stoch_prog.pdf

[10] S. P. Bradley, A. C. Hax y T. L. Magnanti. *Applied Mathematical Programming*. Addison-Wesley, 1977. Cap. 3, «Sensitivity Analysis», y cap. 9, «Integer Programming». Texto del curso 15.053 del MIT. https://web.mit.edu/15.053/www/

[11] K. Deb, A. Pratap, S. Agarwal y T. Meyarivan. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6(2):182–197, 2002.

[12] S. Diamond y S. Boyd. CVXPY: A Python-embedded modeling language for convex optimization. *Journal of Machine Learning Research*, 17(83):1–5, 2016. https://www.jmlr.org/papers/v17/15-408.html

[13] Desarrolladores de CVXPY. CVXPY User Guide: «Disciplined Convex Programming» y «Advanced Features» (variables duales). https://www.cvxpy.org/tutorial/index.html

[14] A. N. Elmachtoub y P. Grigas. Smart «predict, then optimize». *Management Science*, 68(1):9–26, 2022. https://arxiv.org/abs/1710.08005

[15] R. Evans y J. Gao. DeepMind AI reduces Google data centre cooling bill by 40 %. Blog de Google DeepMind, 20 de julio de 2016. https://deepmind.google/discover/blog/deepmind-ai-reduces-google-data-centre-cooling-bill-by-40/

[16] P. I. Frazier. A tutorial on Bayesian optimization. Prepublicación, 2018. https://arxiv.org/abs/1807.02811

[17] R. Garnett. *Bayesian Optimization*. Cambridge University Press, 2023. Edición libre en línea. https://bayesoptbook.com/

[18] Google OR-Tools. CP-SAT Solver. Documentación oficial. https://developers.google.com/optimization/cp/cp_solver

[19] Google OR-Tools. The Job Shop Problem. Documentación oficial. https://developers.google.com/optimization/scheduling/job_shop

[20] Google OR-Tools. Vehicle Routing Problem with Time Windows. Documentación oficial. https://developers.google.com/optimization/routing/vrptw

[21] N. Hansen. The CMA evolution strategy: A tutorial. Prepublicación, 2016 (revisada en 2023). https://arxiv.org/abs/1604.00772

[22] HiGHS. High performance software for linear optimization. Documentación oficial; licencia MIT. https://highs.dev/

[23] C. Holland, J. Levis, R. Nuggehalli, B. Santilli y J. Winters. UPS optimizes delivery routes. *Interfaces*, 47(1):8–23, 2017.

[24] Q. Huangfu y J. A. J. Hall. Parallelizing the dual revised simplex method. *Mathematical Programming Computation*, 10(1):119–142, 2018.

[25] S. M. Johnson. Optimal two- and three-stage production schedules with setup times included. *Naval Research Logistics Quarterly*, 1(1):61–68, 1954.

[26] S. Kirkpatrick, C. D. Gelatt y M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983.

[27] M. J. Kochenderfer y T. A. Wheeler. *Algorithms for Optimization*. MIT Press, 2019. Caps. 1 «Introduction», 7 «Direct Methods», 8 «Stochastic Methods», 9 «Population Methods», 12 «Multiobjective Optimization» y 17 «Optimization under Uncertainty».

[28] A. H. Land y A. G. Doig. An automatic method of solving discrete programming problems. *Econometrica*, 28(3):497–520, 1960.

[29] MIT OpenCourseWare. 6.251J / 15.081J: Introduction to Mathematical Programming. Massachusetts Institute of Technology, otoño de 2009. Clase 1 «Formulations», clases 9–12 (dualidad y sensibilidad) y 24–25 (optimización discreta), con lecturas de [5]. https://ocw.mit.edu/courses/6-251j-introduction-to-mathematical-programming-fall-2009/

[30] J. Orlin y E. Nasrabadi. 15.053: Optimization Methods in Management Science. Massachusetts Institute of Technology, primavera de 2013. Clases 2 «Formulations of linear and non-linear programs», 6 «Sensitivity analysis and shadow prices», 10–11 (programación entera), 12 «Branch and bound», 13 «Cutting planes» y 17 «Traveling salesman problem». https://ocw.mit.edu/courses/15-053-optimization-methods-in-management-science-spring-2013/

[31] J. Orlin y E. Nasrabadi. 15.053: Optimization Methods in Management Science. Hojas de problemas 4, 5 y 6. Massachusetts Institute of Technology, primavera de 2013. https://ocw.mit.edu/courses/15-053-optimization-methods-in-management-science-spring-2013/pages/assignments/

[32] J. Nocedal y S. J. Wright. *Numerical Optimization*, 2.ª ed. Springer, 2006. Cap. 12, teoría de la optimización con restricciones.

[33] A. Novikov, N. Vũ, M. Eisenberger, E. Dupont *et al.* AlphaEvolve: A coding agent for scientific and algorithmic discovery. Prepublicación, Google DeepMind, 2025. https://arxiv.org/abs/2506.13131

[34] S. Mitchell, A. Kean, A. Mason, M. O'Sullivan, A. Phillips y F. Peschiera. PuLP: documentación oficial (licencia MIT). https://coin-or.github.io/pulp/

[35] B. Romera-Paredes, M. Barekatain, A. Novikov *et al.* Mathematical discoveries from program search with large language models. *Nature*, 625:468–475, 2024.

[36] J. E. Smith y R. L. Winkler. The optimizer's curse: Skepticism and postdecision surprise in decision analysis. *Management Science*, 52(3):311–322, 2006.

[37] M. M. Solomon. Algorithms for the vehicle routing and scheduling problems with time window constraints. *Operations Research*, 35(2):254–265, 1987.

[38] R. S. Sutton y A. G. Barto. *Reinforcement Learning: An Introduction*, 2.ª ed. MIT Press, 2018. http://incompleteideas.net/book/the-book-2nd.html

[39] A. J. Wood, B. F. Wollenberg y G. B. Sheblé. *Power Generation, Operation, and Control*, 3.ª ed. Wiley, 2014. Cap. 3, «Economic Dispatch of Thermal Units and Methods of Solution».

[40] C. Yang, X. Wang, Y. Lu, H. Liu, Q. V. Le, D. Zhou y X. Chen. Large language models as optimizers. Prepublicación, 2023. https://arxiv.org/abs/2309.03409